

Métodos Inferenciais

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa Modelos de Sobrevida e Aplicações.

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	13
Direitos Autorais e Uso da Obra	13
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	13
Prefácio	14
Identificação da(s) Disciplina(s)	15
EMENTA	15
OBJETIVO GERAL	16
OBJETIVOS ESPECÍFICOS	16
CONTEÚDO PROGRAMÁTICO	17
Unidade I – Fundamentos da Inferência Estatística	17
Unidade II – Distribuições Amostrais	17
Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados . . .	17
Unidade IV – Métodos de Estimação Pontual	18
Unidade V – Estimação Intervalar	18
Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos	18
METODOLOGIA	18
AVALIAÇÃO	19
CRITÉRIOS DE AVALIAÇÃO	19
BIBLIOGRAFIA BÁSICA	20
BIBLIOGRAFIA COMPLEMENTAR	20
1 Revisão de Probabilidade e Modelos Probabilísticos	22
1.1 Probabilidade e condicionamento	22
1.1.1 Experimentos aleatórios, espaço amostral e eventos	22
1.1.2 Probabilidade	23
1.1.3 Revisão de combinatória	24
1.1.4 Probabilidade condicional	25
1.1.5 Lei da probabilidade total	26
1.1.6 Teorema de Bayes	27
1.1.7 Independência de eventos	28
1.2 Variáveis aleatórias e distribuições	29
1.2.1 Função de distribuição	29
1.2.2 Quantis	30

1.2.3	Variáveis aleatórias discretas	30
1.2.4	Variáveis aleatórias absolutamente contínuas	31
1.2.5	Função indicadora	32
1.2.6	Funções de variáveis aleatórias	34
1.3	Esperança, variância e momentos	35
1.3.1	Esperança	35
1.3.2	Momentos	36
1.3.3	Variância	36
1.4	Distribuições conjuntas e dependência	37
1.4.1	Distribuição conjunta	37
1.4.2	Distribuições marginais	39
1.4.3	Distribuições condicionais	39
1.4.4	Independência de variáveis aleatórias	42
1.4.5	Independência de várias variáveis	43
1.4.6	Variáveis independentes e identicamente distribuídas	43
1.4.7	Covariância e correlação	44
1.4.8	Variância de combinações lineares	46
1.4.9	Esperança condicional	46
1.4.10	Variância condicional	48
1.4.11	Vetores de médias e matrizes de covariâncias	50
1.5	Função geradora de momentos	51
1.5.1	Obtenção de momentos	52
1.5.2	Transformações lineares	52
1.5.3	Soma de variáveis independentes	53
1.5.4	Identificação de distribuições	54
1.6	Modelos probabilísticos discretos	54
1.6.1	Distribuição uniforme discreta	54
1.6.2	Distribuição de Bernoulli	56
1.6.3	Distribuição binomial	59
1.6.4	Distribuição hipergeométrica	64
1.6.5	Binomial e hipergeométrica	67
1.6.6	Distribuição geométrica	68
1.6.7	Distribuição binomial negativa	71
1.6.8	Distribuição de Poisson	73
1.6.9	Relação entre binomial e Poisson	78
1.6.10	Soma de variáveis Poisson independentes	79
1.6.11	Relações entre os modelos discretos	80
1.7	Modelo multinomial	81
1.7.1	Distribuição multinomial	81
1.7.2	Suporte e função de massa conjunta	82
1.7.3	Esperanças, variâncias e covariâncias	83
1.7.4	Distribuições marginais	84
1.7.5	Função geradora de momentos conjunta	84

1.8	Modelos probabilísticos contínuos	88
1.8.1	Distribuição uniforme contínua	88
1.8.2	Distribuição exponencial	92
1.8.3	Distribuição gama	96
1.8.4	Distribuição normal	101
1.8.5	Distribuição beta	106
1.8.6	Relações entre gama e beta	110
1.8.7	Escolha entre alguns modelos contínuos	110
1.9	Transformações de variáveis aleatórias	111
1.9.1	Método da função de distribuição	112
1.9.2	Transformação monótona	113
1.9.3	Exemplo de transformação entre modelos	114
1.9.4	Transformações não monótonas	116
1.9.5	Transformações em problemas inferenciais	117
1.10	Quadro-síntese dos modelos probabilísticos	118
1.10.1	Modelos discretos univariados	118
1.10.2	Modelos contínuos univariados	118
1.10.3	Funções geradoras de momentos	119
1.11	Relações entre os principais modelos	119
1.11.1	Modelos discretos	119
1.11.2	Modelos contínuos	121
1.11.3	Leitura do mapa	122
1.12	Síntese	122
1.13	Exercícios de consolidação	124
2	Resultados Matemáticos e Assintóticos para Inferência	131
2.1	Mapa de dependências	131
2.2	Ferramentas matemáticas	132
2.2.1	Somatórios, produtos e logaritmos	132
2.2.2	Vetores e matrizes	134
2.2.3	Diferenciação	136
2.2.4	Fórmula de Taylor	138
2.2.5	Formas quadráticas	140
2.2.6	Projeções	141
2.2.7	Transformações multivariadas e jacobiano	144
2.3	Ferramentas assintóticas	147
2.3.1	Modos de convergência	147
2.3.2	Relações entre os modos de convergência	148
2.3.3	Lei Fraca dos Grandes Números	149
2.3.4	Teorema Central do Limite	152
2.3.5	Lei dos Grandes Números e Teorema Central do Limite	154
2.3.6	Teorema do mapeamento contínuo	156
2.3.7	Lema de Slutsky	157

2.3.8	Aprofundamento	158
2.3.9	Ordens estocásticas	162
2.4	Síntese	164
2.5	Exercícios de consolidação	165
2.5.1	Ferramentas matemáticas	165
2.5.2	Ferramentas assintóticas	168
3	Fundamentos da Inferência Estatística	172
3.1	O problema da inferência estatística	172
3.2	Processo Gerador de Dados (PGD)	173
3.3	Conceitos fundamentais	174
	Mecanismo de seleção da amostra	175
3.4	Experimento em sala de aula	176
	Verificação de aprendizagem	177
3.5	Estatísticas, estimadores e estimativas	177
3.6	Exemplo-guia: modelo Bernoulli para a urna	180
3.7	Modelo estatístico e função de verossimilhança	183
	Modelo estatístico	183
	Função de verossimilhança	187
	Verossimilhança no modelo Bernoulli	188
	Verossimilhança e estimação	196
	Verificação de aprendizagem	200
3.8	Variabilidade dos estimadores	201
3.9	Exploração computacional do experimento da urna	201
	Preparação do ambiente computacional	202
	População virtual e uma amostra	202
	Repetição da amostragem e variabilidade	205
	Verificação de aprendizagem	208
	Atividade computacional de consolidação	209
	Questões de revisão	209
	Referências	212
4	Distribuições Amostrais	213
4.1	Introdução	213
	Objetivos do capítulo	214
4.2	Amostra e estatística: recordação	214
4.3	Dois referenciais para a geração da amostra	215
4.3.1	Amostragem no modelo i.i.d.	215
4.3.2	Amostragem aleatória simples sem reposição	217
4.4	Construção de uma distribuição amostral por enumeração	226
4.5	Somas, transformações e funções geradoras de momentos	231
4.6	Distribuição amostral da média	239
4.6.1	Diferença de médias de duas amostras independentes	247

4.7	Lei dos Grandes Números	249
4.8	Teorema Central do Limite	250
	Diferença de médias em grandes amostras	251
4.8.1	Padronização com variância estimada	253
4.9	Distribuição amostral da proporção	255
	Proporção em uma população finita	257
4.9.1	Aproximação normal da binomial	261
4.9.2	Aproximação de Poisson para a binomial	266
4.10	Distribuição amostral da variância	272
4.10.1	Variância de S^2 sem hipótese de normalidade	273
4.11	Distribuições derivadas do modelo normal	281
4.11.1	Distribuição qui-quadrado	281
4.11.2	Independência entre média e variância	284
4.11.3	Distribuição da variância amostral no modelo normal	288
4.11.4	Distribuição t de Student	296
4.11.5	Distribuição F	308
4.12	Estatísticas de ordem	320
4.12.1	Mínimo e máximo	321
4.12.2	k -ésima estatística de ordem	325
4.12.3	Transformação pela função de distribuição	330
4.13	Distribuições amostrais por simulação	339
	Exemplo computacional: aproximação normal da média exponencial	340
	Exemplo computacional: enumeração com e sem reposição	342
4.14	Quadro-síntese	344
4.15	Exercícios	346
	Exercícios conceituais	346
	Exercícios de cálculo	346
	Exercícios teóricos e computacionais	350
	Referências	351
5	Avaliação de Estimadores e Princípios de Redução de Dados	352
	Objetivos do capítulo	352
5.1	Avaliação de estimadores	353
	Função de perda, risco e erro quadrático médio	353
	Viés, variância e erro-padrão	354
	Exemplo-guia — Estimação do limite de uma distribuição uniforme	357
	Consistência	362
	Comparação por variância entre estimadores não viesados	371
	Informação de Fisher	372
	Desigualdade de Cramér–Rao	377
	Exemplo — Média de uma distribuição normal com variância conhecida	382
	Exemplo — Parâmetro de uma distribuição de Poisson	384
	Eficiência assintótica	386

5.2	Aprofundamento: Princípios de redução de dados	389
	Estatística suficiente	390
	Teorema da fatoração de Neyman–Fisher	391
	Exemplo — Suficiência no modelo Bernoulli	394
	Suficiência minimal	397
	Famílias exponenciais	404
	Completeness	417
	Estimadores não viesados de variância uniformemente mínima	422
	Teorema de Rao–Blackwell	423
	Exemplo adaptado — Estimação no modelo de Poisson	426
	Teorema de Lehmann–Scheffé	430
	Exemplo — ENVVUM da taxa exponencial	433
	Estatísticas ancilares e teorema de Basu	438
	Exemplo integrado — Avaliação e redução no modelo gama	443
5.3	Síntese conceitual	449
5.4	Exercícios	450
	Exercícios — Aprofundamento	452
	Exercícios extras	457
	Referências	462
6	Métodos de Estimação Pontual	463
6.1	Método dos Momentos	463
	Momentos populacionais e amostrais	464
	Fundamentação probabilística	465
	Procedimento geral	466
	Exemplo — distribuição de Pareto	467
	Exemplo — distribuição uniforme contínua	468
	Exemplo — distribuição uniforme discreta	469
	Exemplo — distribuição exponencial	470
	Exemplo — distribuição gama	471
	Exercícios	472
6.2	Máxima Verossimilhança	472
	Exemplo motivacional — moeda com probabilidade desconhecida	473
	6.2.1 Definição formal	475
	6.2.2 Existência e unicidade	475
	6.2.3 Log-verossimilhança	476
	6.2.4 Invariância	477
	6.2.5 Função escore e informação	477
	Exemplos	479
	6.2.6 Procedimento geral de obtenção do estimador	488
	6.2.7 Exercícios	489
	6.2.8 Síntese	494

6.3	Mínimos Quadrados	495
6.3.1	Exemplo motivacional — renda familiar e auxílio financeiro	495
6.3.2	Definição formal	497
6.3.3	Relação com o método de máxima verossimilhança	503
6.3.4	Exemplos	509
6.3.5	Exercícios	514
6.3.6	Síntese	519
6.4	Aprofundamento	520
6.4.1	Minimax e equivariância	520
6.4.2	Distribuição assintótica de estimadores e método delta	531
6.4.3	Algoritmo Expectation-Maximization (EM)	543
	Exercícios Complementares	569
	Referências	571
7	Estimação intervalar	572
	Objetivos do capítulo	572
7.1	Definição formal	573
7.2	Interpretação frequentista	574
7.3	Quantis e valores críticos	575
7.4	Construção por quantidade pivotal	575
7.4.1	Procedimento geral	577
7.5	Intervalos para parâmetros da distribuição normal	578
7.5.1	Média com variância conhecida	578
7.5.2	Média com variância desconhecida	579
7.5.3	Variância de uma população normal	581
7.6	Exemplo de intervalo exato por pivô — distribuição exponencial	582
7.7	Intervalos assintóticos e método de Wald	584
7.7.1	Exemplo — média de uma distribuição de Poisson	585
7.8	Intervalos para uma proporção binomial	586
7.8.1	Intervalo de Wald	586
7.8.2	Intervalo de Wilson ou de score	586
7.8.3	Intervalo exato de Clopper–Pearson	587
7.9	Intervalos unilaterais	588
7.10	Dualidade entre intervalos de confiança e testes de hipóteses	589
7.11	Amplitude, precisão e tamanho amostral	590
7.12	Cobertura por simulação	592
7.13	Métodos bootstrap	594
7.14	Intervalo de confiança não é intervalo de predição	596
7.15	Roteiro para construção e apresentação	596
7.16	Síntese dos principais procedimentos	597
7.17	Exercícios	597
7.18	Gabarito sucinto	600
	Referências	601

8	Testes de Hipóteses e Análise de Dados Categóricos	602
8.1	Objetivos de aprendizagem	602
8.2	Motivação: uma moeda aparentemente honesta	602
8.3	Formulação estatística do problema	603
8.3.1	Função de teste e região crítica	604
8.3.2	Função poder, tamanho e nível	605
8.3.3	Erros dos tipos I e II	606
8.4	Valor- p	606
8.4.1	Regra de decisão	608
8.5	Procedimento recomendado	608
8.6	Exemplo motivacional	608
8.7	Aprofundamento	610
8.7.1	Lema de Neyman–Pearson	610
8.7.2	Testes uniformemente mais poderosos	612
8.7.3	Teste da razão de verossimilhanças	615
8.8	Testes usuais para parâmetros populacionais	619
8.8.1	Uma média com variância conhecida	619
8.8.2	Uma média com variância desconhecida	620
8.8.3	Uma proporção	620
8.8.4	Duas médias independentes: teste de Welch	622
8.8.5	Duas médias independentes com variância comum	623
8.8.6	Amostras pareadas	623
8.8.7	Duas proporções independentes	624
8.9	Testes exatos, de permutação e robustez	625
8.9.1	Testes de permutação	626
8.9.2	Robustez	626
8.10	Planejamento amostral e poder	627
8.10.1	Uma média com variância conhecida	627
8.10.2	Uma proporção	628
8.11	Análise de dados categóricos	630
8.11.1	Estatística qui-quadrado de Pearson	630
8.11.2	Estatística da razão de verossimilhanças	631
8.12	Teste qui-quadrado de aderência	631
8.12.1	Exemplo — dado de seis faces	632
8.13	Tabelas de contingência	633
8.13.1	Homogeneidade e independência	634
8.13.2	Exemplo — renda e hipertensão	635
8.14	Diagnóstico por resíduos	636
8.15	Condições e tabelas esparsas	637
8.16	Teste exato de Fisher	638
8.17	Medidas de tamanho do efeito em tabelas	639
8.18	Poder e tamanho amostral em testes qui-quadrado	640
8.19	Relação entre testes e intervalos de confiança	642

8.20	Boas práticas de apresentação	643
8.20.1	Modelo de redação	643
8.21	Erros frequentes de interpretação	643
8.22	Quadro-síntese	644
8.23	Exercícios	645
8.23.1	Exercícios conceituais	645
8.23.2	Neyman–Pearson e testes UMP	646
8.23.3	Razão de verossimilhanças	647
8.23.4	Testes para médias e proporções	647
8.23.5	Dados categóricos	648
8.23.6	Reamostragem e robustez	649
	Referências	649
9	Projetos Aplicados	650
9.1	Objetivo	650
9.2	Descrição Geral	650
9.2.1	Exemplos de Temas e Variáveis de Interesse	650
9.2.2	Etapas do Trabalho	653
9.2.3	Critérios de Avaliação	655
9.2.4	Observações	656
10	Exemplos Aplicados	657
10.0.1	Exemplo Aplicado	657
10.0.2	Variância e desvio-padrão populacionais	657
10.0.3	Objetivo	658
10.0.4	Cálculo do tamanho mínimo de amostra	658
10.0.5	Seleção da amostra aleatória	659
10.0.6	Teste Z para uma média com variância conhecida	660
10.0.7	Cálculo do p-valor	660
10.0.8	Regra de Decisão	660
10.0.9	Intervalo de confiança de 95%	661
10.0.10	Conclusão	661
10.1	Exemplo Aplicado	661
10.1.1	Amostra piloto	661
10.1.2	Cálculo do tamanho mínimo de amostra	662
10.1.3	Seleção da amostra aleatória	663
10.1.4	Verificando normalidade dos dados	664
10.1.5	Teste t para uma média com variância desconhecida	666
10.1.6	Cálculo do p-valor	667
10.1.7	Regra de Decisão	667
10.1.8	Intervalo de confiança de 95%	668
10.1.9	Exemplo Aplicado	668
10.1.10	Exemplo Prático	673

10.1.11 Seleção da amostra	675
10.2 Inferências para duas médias populacionais com amostras independentes e variâncias desiguais	679
10.2.1 Exemplo Prático	679
10.2.2 Hipóteses	680
10.2.3 Preparação dos Dados e Amostra Piloto	680
10.3 Cálculo do tamanho amostral	680
10.3.1 Seleção da Amostra	681
10.3.2 Estatística de Teste	681
10.4 Referências	683
11 Demonstrações	684
Mapa das demonstrações e fontes	684
Resultados fundamentais de probabilidade	687
Demonstração 1 — Lei fraca dos grandes números para a média amostral	687
Enunciado	687
Demonstração	687
Demonstração 2 — Teorema Central do Limite por funções geradoras de momentos .	688
Enunciado	688
Demonstração	688
Distribuições amostrais	690
Demonstração 3 — Distribuições de $\bar{X}$ e S^2 no modelo normal	690
Enunciado	690
Demonstração	690
Demonstração 4 — Independência entre $\bar{X}$ e S^2	692
Enunciado	692
Demonstração	692
Demonstração 5 — Derivação da distribuição t de Student	693
Enunciado	693
Demonstração	693
Redução de dados e estimação	695
Demonstração 6 — Teorema da fatoração de Fisher–Neyman: versão discreta	695
Enunciado	695
Demonstração	695
Demonstração 7 — Teorema de Rao–Blackwell	696
Enunciado	696
Demonstração	697
Demonstração 8 — Teorema de Lehmann–Scheffé	698
Enunciado	698
Demonstração	698

Demonstração 9 — Desigualdade de Cramér–Rao	699
Enunciado	699
Demonstração	700
Demonstração 10 — Invariância do estimador de máxima verossimilhança	701
Enunciado	701
Demonstração	701
Demonstração 11 — Teorema de Gauss–Markov	702
Enunciado	702
Demonstração	702
Demonstração 12 — Estimadores de Bayes sob perdas quadrática, absoluta e 0–1 . .	704
Perda quadrática	704
Perda absoluta	704
Perda 0–1 no caso discreto	705
Verossimilhança e teoria assintótica	706
Demonstração 13 — Consistência do EMV em famílias exponenciais regulares	706
Enunciado	706
Demonstração	706
Demonstração 14 — Normalidade assintótica do EMV	708
Enunciado	708
Demonstração	708
Demonstração 15 — Método delta univariado e multivariado	709
Enunciado	709
Demonstração	709
Demonstração 16 — Equivalência assintótica entre Wald, escore e razão de verossi-	
milhanças	711
Enunciado	711
Demonstração	711
Demonstração 17 — Teorema de Wilks para uma subfamília exponencial curva . . .	713
Enunciado	713
Demonstração	713
Testes de hipóteses e intervalos de confiança	715
Demonstração 18 — Lema de Neyman–Pearson	715
Enunciado	715
Demonstração	715
Demonstração 19 — Teorema de Karlin–Rubin	716
Enunciado	716
Demonstração	716
Demonstração 20 — Dualidade entre testes e regiões de confiança	718
Enunciado	718
Demonstração	718

Demonstração 21 — Teste t de uma amostra como teste da razão de verossimilhanças	
generalizada	719
Enunciado	719
Demonstração	719
Inferência computacional, reamostragem e métodos modernos	722
Demonstração 22 — Monotonicidade do algoritmo EM	722
Definição	722
Demonstração	722
Demonstração 23 — Consistência de minimizadores convexos	724
Enunciado	724
Demonstração	724
Demonstração 24 — Função de influência e eficiência semiparamétrica	725
Função de influência de um funcional	725
Resultado de eficiência semiparamétrica	725
Demonstração	726
Demonstração 25 — Validade exata de um teste de permutação	727
Enunciado	727
Demonstração	727
Demonstração 26 — Princípio <i>plug-in</i> e bootstrap da média	728
Definição	728
Demonstração para a média	729
Síntese conceitual	731
Referências	732

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e das decisões dos autores ao longo da elaboração da obra.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro resulta da experiência acumulada no ensino, na orientação de estudantes e no desenvolvimento de pesquisas em Estatística. Somos docentes pesquisadores do Departamento de Estatística e Matemática Aplicada da Universidade Federal do Ceará (DEMA/UFC), com atuação em modelagem estatística, inferência e aplicações. Integramos o Laboratório de Inovação em Estatística — StatLab/UFC (<https://statlab.quarto.pub/>) e o Grupo de Pesquisa *Modelos de Sobrevivência e Aplicações* do CNPq (<http://dgp.cnpq.br/dgp/espelhogrupo/9639095385610769>), espaços nos quais articulamos ensino, pesquisa e aplicação a problemas reais.

O material tem como base disciplinas de Inferência Estatística oferecidas em cursos de graduação e pós-graduação. Ao longo dos anos, consolidamos a convicção de que o ensino de Inferência Estatística exige equilíbrio entre fundamentação teórica, clareza interpretativa e compreensão das condições que sustentam cada procedimento.

O livro desenvolve os conceitos de Inferência Estatística de forma progressiva, articulando propriedades, interpretação e aplicação. R e Python são utilizados ao longo do material como ambientes de experimentação conceitual, simulação e análise, de acordo com as necessidades de cada capítulo.

As ferramentas matemáticas necessárias são apresentadas de forma articulada ao desenvolvimento inferencial. Conteúdos que ampliam a fundamentação conceitual, matemática ou metodológica são identificados como **Aprofundamento** e podem ser consultados sem interromper o percurso principal do livro.

Acreditamos que a Inferência Estatística deve ser ensinada como fundamento para a análise e a tomada de decisões sob incerteza, com atenção às suposições dos modelos, às limitações dos procedimentos e às implicações das conclusões obtidas.

Esperamos que este livro contribua para a formação de profissionais capazes de tomar decisões com rigor técnico, pensamento estatístico crítico e responsabilidade analítica.

Identificação da(s) Disciplina(s)

- Curso: Bacharelado em Ciência de Dados e Pós-graduação em Modelagem e Métodos Quantitativos (PPGMMQ)
- Disciplina: Análise Inferencial (Graduação) e Inferência Estatística (Pós-graduação)
- Carga Horária: 96 horas (Graduação) e 64 horas (Pós-graduação)
- Créditos: 6 (Graduação) e 4 (Pós-graduação)
- Regime: Semestral
- Pré-requisitos: Modelos Probabilísticos (CC0446) (Graduação)
- Período Letivo: 2026.2
- Professor(a): Dr. Manoel Santos-Neto (Graduação) e Dr. Rafael Bráz (Pós-graduação)

EMENTA

Nível	Ementa
Graduação	Conceitos de população e amostra; parâmetros, estatísticas, estimadores e suas propriedades; distribuições amostrais; métodos de estimação pontual: método dos momentos, máxima verossimilhança e mínimos quadrados; estimação intervalar; testes de hipóteses; testes de homogeneidade e independência.

Nível	Ementa
Pós-graduação	Conceitos de inferência. Avaliação de estimadores. Princípios da suficiência e completude. Função de verossimilhança. Estimação pontual: método dos momentos, máxima verossimilhança, mínimos quadrados, minimax e equivariância. Distribuição assintótica dos estimadores. Método delta. Algoritmo EM. Estimação intervalar. Testes de hipóteses. Testes mais poderosos. Teste da razão de verossimilhanças. Testes assintóticos. Testes de aderência. Testes de independência.

OBJETIVO GERAL

Apresentar os fundamentos da inferência estatística, capacitando o discente a formular, analisar e interpretar problemas inferenciais em contextos de análise de dados, com ênfase na quantificação da incerteza, validação de modelos e capacidade de generalização.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- compreender a diferença entre população, amostra, parâmetro e estatística;
- interpretar estatísticas como variáveis aleatórias;
- compreender e utilizar distribuições amostrais;
- aplicar métodos de estimação pontual e intervalar;
- formular e testar hipóteses estatísticas de forma adequada;
- interpretar corretamente valores-p, intervalos de confiança e decisões inferenciais;
- analisar criticamente resultados estatísticos obtidos a partir de dados reais.

CONTEÚDO PROGRAMÁTICO

Unidade I – Fundamentos da Inferência Estatística

- Motivação para a inferência: conceitos de população, amostra e parâmetros
- Estatísticas e estimadores como funções da amostra
- Função de verossimilhança: definição e papel central na inferência clássica

Unidade II – Distribuições Amostrais

- Estatísticas como variáveis aleatórias e suas distribuições amostrais
- Distribuição amostral da média e da proporção
- Lei dos Grandes Números
- Teorema Central do Limite

Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados

- Propriedades de pequenas amostras: viés, variância e erro quadrático médio
- Propriedades assintóticas: consistência e eficiência assintótica
- Princípio da Suficiência: definições formais, Critério de Fatoração de Neyman-Fisher e suficiência minimal
- Princípio da Completude e Unicidade
- Família Exponencial: formas canônicas, posto completo e estatísticas completas e suficientes
- Teorema de Rao-Blackwell e Teorema de Lehmann-Scheffé: construção do Estimador Não-Viesado de Variância Uniformemente Mínima (ENVVUM)

Unidade IV – Métodos de Estimação Pontual

- Método dos momentos e suas aplicações
- Máxima verossimilhança: procedimentos, propriedades de invariância e otimalidade
- Mínimos quadrados: derivação, propriedades e relação com máxima verossimilhança
- Estimadores Minimax e Equivariância: critérios de risco e simetrias (locação e escala)
- Método Delta e Distribuição assintótica dos estimadores
- Algoritmo EM: estimação com dados ausentes ou não observáveis

Unidade V – Estimação Intervalar

- Conceitos e interpretação correta dos intervalos de confiança
- Métodos de construção: Método da Quantidade Pivotal e Inversão de Testes
- Intervalos baseados em aproximações assintóticas (Grandes amostras)

Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos

- Fundamentos: hipóteses nula/alternativa, estatísticas de teste, valor-p e decisões
- Teoria de erros (Tipo I e II) e Poder do teste
- Testes mais poderosos: Lema de Neyman-Pearson e Testes Uniformemente Mais Poderosos
- Teste da razão de verossimilhanças e sua versão generalizada
- Análise de Variáveis Categóricas: Testes qui-quadrado, testes de aderência, independência e homogeneidade em tabelas de contingência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, articuladas com atividades práticas computacionais. O conteúdo teórico será constantemente ilustrado por simulações e análises de dados reais, utilizando ferramentas computacionais (R ou Python).

AVALIAÇÃO

A avaliação será contínua e composta por:

Nível	Atividades
Graduação	• Listas obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.
Pós-graduação	• Listas semanais obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.

A aprovação na disciplina seguirá os critérios estabelecidos pelas normas vigentes da UFC.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados nos trabalhos e atividades:

Nível	CrITÉrios
Graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.
Pós-graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.

BIBLIOGRAFIA BÁSICA

Nível	Bibliografias
Graduação	1. Bussab, W. O.; Morettin, P. A. <i>Estatística Básica</i> . 6ª ed. São Paulo: Saraiva, 2010.2. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. Duxbury Press, 2002.3. Casella, G.; Berger, R. L. <i>Inferência Estatística</i> . Tradução da 2ª edição norte-americana. São Paulo: Cengage Learning, 2011.
Pós-graduação	1. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.2. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Coleção Matemática Aplicada. Rio de Janeiro: SBM, 2001.3. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. Duxbury Press, 2002.

BIBLIOGRAFIA COMPLEMENTAR

Nível	Bibliografias
Graduação	1. Devore, J. L. <i>Probabilidade e Estatística para Engenharia e Ciências</i> . São Paulo: Thomson, 2006.2. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i> . 3rd ed. New York: McGraw-Hill, 1974.3. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Rio de Janeiro: SBM, 2001.4. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.5. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i> . New York: John Wiley, 1988.

Nível	Bibliografias
Pós-graduação	1. Casella, G.; Berger, R. L. <i>Inferência Estatística</i>. Tradução da 2^a edição norte-americana. São Paulo: Cengage Learning, 2011.2. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i>. New York: John Wiley, 1988.3. Lehmann, E. L.; Casella, G. <i>Theory of Point Estimation</i>. 2nd ed. New York: Springer, 2003.4. Lehmann, E. L.; Romano, J. P. <i>Testing Statistical Hypotheses</i>. 3rd ed. New York: Springer, 2010.5. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i>. 3rd ed. New York: McGraw-Hill, 1974.6. Rohatgi, V. K. <i>Statistical Inference</i>. New York: Dover, 2003.7. Shao, J. <i>Mathematical Statistics</i>. 2nd ed. New York: Springer, 2003.

1 Revisão de Probabilidade e Modelos Probabilísticos

Este capítulo revisa conceitos de Probabilidade e modelos probabilísticos que serão utilizados ao longo do estudo de Inferência Estatística. O conteúdo pressupõe uma formação anterior em Probabilidade e concentra-se nas definições, propriedades e relações necessárias aos capítulos seguintes.

A revisão abrange probabilidade condicional, independência, variáveis aleatórias, distribuições, esperança, variância, distribuições conjuntas, função geradora de momentos e modelos probabilísticos discretos e contínuos. O objetivo é recuperar uma linguagem probabilística comum para o desenvolvimento da inferência, sem reproduzir integralmente os conteúdos de uma disciplina de Probabilidade (Dantas, 1997; Magalhães, 2006; Meyer, 1983).

Delimitação do capítulo

Neste capítulo, as distribuições e os modelos probabilísticos são tratados como objetos conhecidos da teoria da Probabilidade. Conceitos propriamente inferenciais, como parâmetro desconhecido, modelo estatístico, verossimilhança, estimação, intervalos de confiança e testes de hipóteses, serão introduzidos posteriormente.

Resultados sobre convergência, Lei dos Grandes Números, Teorema Central do Limite, lema de Slutsky, método delta e ordens estocásticas serão reunidos no capítulo **Resultados Matemáticos e Assintóticos para Inferência**.

1.1 Probabilidade e condicionamento

1.1.1 Experimentos aleatórios, espaço amostral e eventos

Um **experimento aleatório** é um procedimento cujo resultado não pode ser determinado antecipadamente, embora seja possível especificar o conjunto de resultados que podem ocorrer.

O **espaço amostral**, denotado por Ω , é o conjunto dos resultados possíveis do experimento. Um **evento** é um subconjunto de Ω .

Por exemplo, no lançamento de um dado de seis faces,

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

O evento

$$A = \{2, 4, 6\}$$

representa a ocorrência de um resultado par.

As operações entre eventos seguem as operações usuais entre conjuntos. Para eventos A e B :

- $A \cup B$ representa a ocorrência de pelo menos um dos eventos;
- $A \cap B$ representa a ocorrência simultânea de A e B ;
- A^c representa a não ocorrência de A ;
- $A \setminus B$ representa a ocorrência de A sem a ocorrência de B .

Dois eventos são **mutuamente exclusivos** quando

$$A \cap B = \emptyset.$$

1.1.2 Probabilidade

Uma medida de probabilidade P associa a cada evento A um número $P(A)$ que representa sua probabilidade de ocorrência. Suas propriedades básicas são

$$P(A) \geq 0,$$

$$P(\Omega) = 1$$

e, para uma sequência de eventos mutuamente exclusivos $A_1, A_2, \dots$,

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Dessas propriedades decorrem relações utilizadas com frequência, como

$$P(A^c) = 1 - P(A)$$

e

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Se

$$A \subseteq B,$$

então

$$P(A) \leq P(B).$$

Em espaços amostrais finitos com resultados equiprováveis,

$$P(A) = \frac{|A|}{|\Omega|},$$

em que $|A|$ e $|\Omega|$ representam, respectivamente, o número de elementos de A e de Ω (Dantas, 1997; Meyer, 1983).

1.1.3 Revisão de combinatória

Em problemas com resultados equiprováveis, o cálculo de probabilidades pode depender da contagem dos resultados possíveis. Nesta revisão, serão utilizados principalmente o princípio multiplicativo, o fatorial e os coeficientes binomial e multinomial.

Se um procedimento pode ser realizado de n_1 formas em uma primeira etapa e, para cada uma delas, de n_2 formas em uma segunda etapa, então o número de resultados possíveis é

$$n_1 n_2.$$

Para n objetos distintos, o número de ordenações possíveis é

$$n!.$$

O número de maneiras de selecionar k elementos dentre n , sem considerar a ordem, é

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad k = 0, 1, \dots, n.$$

Se n elementos são distribuídos em m categorias de tamanhos

$$n_1, \dots, n_m,$$

com

$$n_1 + \dots + n_m = n,$$

o número de configurações é dado pelo coeficiente multinomial

$$\binom{n}{n_1, \dots, n_m} = \frac{n!}{n_1! \dots n_m!}.$$

Uso posterior

Os coeficientes binomial e multinomial aparecem diretamente nas funções de probabilidade das distribuições binomial, hipergeométrica e multinomial. Nesta revisão, a combinatória será utilizada como ferramenta para descrever esses modelos, sem desenvolver novamente técnicas mais específicas de contagem.

1.1.4 Probabilidade condicional

A informação de que um evento ocorreu pode alterar a probabilidade atribuída a outro evento. Se $P(B) > 0$, a **probabilidade condicional** de A dado B é

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

A expressão representa a probabilidade de A quando o espaço de possibilidades é restringido pela ocorrência de B .

Da definição decorre a regra do produto:

$$P(A \cap B) = P(A | B)P(B).$$

Quando $P(A) > 0$, também podemos escrever

$$P(A \cap B) = P(B | A)P(A).$$

Para eventos $A_1, \dots, A_n$,

$$P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2 \mid A_1) \dots P(A_n \mid A_1 \cap \dots \cap A_{n-1}),$$

desde que as probabilidades condicionais envolvidas estejam definidas (Magalhães, 2006; Ross, 2006).

1.1.5 Lei da probabilidade total

Considere uma partição do espaço amostral formada pelos eventos

$$B_1, \dots, B_k,$$

tais que

$$B_i \cap B_j = \emptyset, \quad i \neq j,$$

e

$$\bigcup_{j=1}^k B_j = \Omega.$$

Se

$$P(B_j) > 0, \quad j = 1, \dots, k,$$

então, para qualquer evento A ,

$$P(A) = \sum_{j=1}^k P(A \mid B_j)P(B_j).$$

A probabilidade de A é decomposta segundo as diferentes partes do espaço amostral.

1.1.6 Teorema de Bayes

Considerando a mesma partição $B_1, \dots, B_k$, se $P(A) > 0$, então

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{\ell=1}^k P(A | B_\ell)P(B_\ell)}.$$

O teorema de Bayes permite inverter o condicionamento quando são conhecidas as probabilidades $P(B_j)$ e $P(A | B_j)$.

Considere uma condição genética presente em 2% de uma população. Um teste apresenta sensibilidade de 95% e produz resultado positivo em 5% das pessoas que não apresentam a condição.

Se G representa a presença da condição e T representa um resultado positivo no teste, então

$$P(G) = 0,02,$$

$$P(T | G) = 0,95$$

e

$$P(T | G^c) = 0,05.$$

Pela lei da probabilidade total,

$$P(T) = P(T | G)P(G) + P(T | G^c)P(G^c).$$

Logo,

$$P(T) = 0,95(0,02) + 0,05(0,98) = 0,068.$$

Aplicando o teorema de Bayes,

$$P(G | T) = \frac{P(T | G)P(G)}{P(T)}$$

e, portanto,

$$P(G | T) = \frac{0,95(0,02)}{0,068} \approx 0,279.$$

A probabilidade de uma pessoa apresentar a condição genética (G) dado que recebeu um resultado positivo no teste (T) não coincide com a sensibilidade do teste. O cálculo também depende da frequência da condição na população e da probabilidade de resultado positivo entre as pessoas que não apresentam a condição.

1.1.7 Independência de eventos

Dois eventos A e B são **independentes** quando

$$P(A \cap B) = P(A)P(B).$$

Se $P(B) > 0$, essa condição equivale a

$$P(A | B) = P(A).$$

Nesse caso, a informação de que B ocorreu não altera a probabilidade atribuída a A .

Independência não deve ser confundida com exclusão mútua. Se A e B são mutuamente exclusivos e ambos possuem probabilidade positiva,

$$P(A \cap B) = 0,$$

enquanto

$$P(A)P(B) > 0.$$

Portanto, eventos mutuamente exclusivos com probabilidades positivas não são independentes.

Para eventos

$$A_1, \dots, A_n,$$

a independência conjunta exige que, para todo subconjunto de índices

$$\{i_1, \dots, i_r\},$$

tenhamos

$$P(A_{i_1} \cap \cdots \cap A_{i_r}) = \prod_{j=1}^r P(A_{i_j}).$$

A independência aos pares, isoladamente, não garante independência conjunta (Dantas, 1997; Magalhães, 2006).

1.2 Variáveis aleatórias e distribuições

Uma variável aleatória associa valores numéricos aos resultados de um experimento aleatório. Sua distribuição descreve quais valores podem ocorrer e como a probabilidade é distribuída entre esses valores ou conjuntos de valores.

Ao longo do livro, letras maiúsculas, como X , Y e Z , representarão variáveis aleatórias. Letras minúsculas, como x , y e z , representarão valores possíveis ou observados dessas variáveis.

1.2.1 Função de distribuição

A **função de distribuição acumulada** de uma variável aleatória X é definida por

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Toda função de distribuição satisfaz:

1. F_X é não decrescente;
2. F_X é contínua à direita;
3. $F_X(x) \rightarrow 0$ quando $x \rightarrow -\infty$;
4. $F_X(x) \rightarrow 1$ quando $x \rightarrow +\infty$.

A função F_X caracteriza completamente a distribuição de X (Rice, 2007, caps. 1–2; Ramachandran; Tsokos, 2021, sec. 3.1).

1.2.2 Quantis

Para

$$u \in (0, 1),$$

o quantil de ordem u pode ser definido por

$$F_X^{-1}(u) = \inf\{x : F_X(x) \geq u\}.$$

Essa definição é válida tanto para distribuições contínuas quanto para distribuições discretas.

A mediana, por exemplo, está associada ao quantil de ordem

$$u = 0,5.$$

Quantis serão utilizados posteriormente na construção de intervalos e regiões associados a distribuições amostrais.

1.2.3 Variáveis aleatórias discretas

Uma variável aleatória X é **discreta** quando assume valores em um conjunto finito ou enumerável.

Sua distribuição pode ser descrita por uma **função de massa de probabilidade**,

$$p_X(x) = P(X = x),$$

que satisfaz

$$p_X(x) \geq 0$$

e

$$\sum_x p_X(x) = 1.$$

O **suporte** de X é o conjunto dos valores aos quais a função de massa de probabilidade atribui probabilidade positiva. Neste livro, o suporte de X será representado pela letra maiúscula caligráfica

$\mathcal{X}$.

Assim,

$$\mathcal{X} = \{x : p_X(x) > 0\}.$$

Por exemplo, se X é uma variável de contagem que pode assumir qualquer valor inteiro não negativo, então

$$\mathcal{X} = \{0, 1, 2, \dots\}.$$

A função de distribuição é obtida acumulando as probabilidades:

$$F_X(x) = \sum_{t \leq x} p_X(t).$$

Como consequência, a função de distribuição de uma variável discreta apresenta saltos nos valores que recebem probabilidade positiva.

1.2.4 Variáveis aleatórias absolutamente contínuas

Uma variável aleatória X é **absolutamente contínua** quando existe uma função de densidade f_X tal que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt,$$

com

$$f_X(x) \geq 0$$

e

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Também utilizaremos

$\mathcal{X}$

para representar o suporte de uma variável aleatória absolutamente contínua X . Neste caso, o suporte será entendido como o conjunto de valores admissíveis para X em que a densidade é positiva, desconsiderando diferenças em conjuntos de probabilidade nula.

Por exemplo, se X representa um tempo de espera estritamente positivo, então

$$\mathcal{X} = (0, \infty).$$

Nesse caso,

$$P(a < X \leq b) = \int_a^b f_X(x) dx.$$

Para qualquer valor isolado x ,

$$P(X = x) = 0.$$

A probabilidade pontual é nula porque conjuntos unitários possuem comprimento nulo, e não simplesmente porque uma variável contínua pode assumir infinitos valores (Ramachandran; Tsokos, 2021, secs. 3.1–3.2; Rice, 2007, cap. 2).

Em modelos paramétricos, o suporte pode depender do parâmetro. Quando for necessário explicitar essa dependência, utilizaremos uma notação como

$$\mathcal{X}_\theta.$$

Essa característica será retomada posteriormente, pois algumas condições de regularidade utilizadas em Inferência Estatística pressupõem que o suporte seja comum aos diferentes valores possíveis do parâmetro.

1.2.5 Função indicadora

Para um conjunto A , a **função indicadora** de A é definida por

$$\mathbf{1}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

Quando o conjunto considerado é o suporte $\mathcal{X}$ de uma variável aleatória X , escreveremos

$$\mathbf{1}_{\mathcal{X}}(x) = \begin{cases} 1, & x \in \mathcal{X}, \\ 0, & x \notin \mathcal{X}. \end{cases}$$

Essa notação permite incorporar diretamente o suporte à expressão de uma função de massa de probabilidade ou de uma densidade.

No caso discreto, uma função de massa de probabilidade poderá ser escrita na forma

$$p_X(x) = h(x)\mathbf{1}_{\mathcal{X}}(x),$$

indicando que

$$p_X(x) = \begin{cases} h(x), & x \in \mathcal{X}, \\ 0, & x \notin \mathcal{X}. \end{cases}$$

De forma análoga, para uma variável aleatória absolutamente contínua, uma densidade poderá ser escrita como

$$f_X(x) = h(x)\mathbf{1}_{\mathcal{X}}(x),$$

isto é,

$$f_X(x) = \begin{cases} h(x), & x \in \mathcal{X}, \\ 0, & x \notin \mathcal{X}. \end{cases}$$

A função indicadora permite, portanto, apresentar em uma única expressão a forma da função de massa ou da densidade e o suporte ao qual ela está associada. Essa notação será utilizada sistematicamente na apresentação dos modelos probabilísticos deste capítulo.

A função indicadora também permite representar contagens de ocorrências. Considere os eventos

$$A_1, \dots, A_n,$$

e defina

$$I_i = \mathbf{1}_{A_i}.$$

Então,

$$I_i = \begin{cases} 1, & \text{se } A_i \text{ ocorre,} \\ 0, & \text{caso contrário.} \end{cases}$$

A soma

$$R = \sum_{i=1}^n I_i = \sum_{i=1}^n \mathbf{1}_{A_i}$$

representa o número de ocorrências dos eventos considerados.

Consequentemente,

$$\frac{R}{n} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{A_i}$$

representa a proporção de ocorrências.

Essa representação será utilizada na distribuição binomial e, posteriormente, permitirá relacionar contagens, proporções e médias de variáveis Bernoulli.

1.2.6 Funções de variáveis aleatórias

Se X é uma variável aleatória e

$$Y = g(X),$$

então Y também é uma variável aleatória.

Sua distribuição depende da distribuição de X e da transformação g . Uma forma geral de obtê-la consiste em utilizar sua função de distribuição:

$$F_Y(y) = P(Y \leq y) = P\{g(X) \leq y\}.$$

Métodos específicos para transformações de variáveis aleatórias serão retomados posteriormente neste capítulo.

1.3 Esperança, variância e momentos

1.3.1 Esperança

A **esperança matemática** de uma variável aleatória representa uma média ponderada de seus possíveis valores segundo a distribuição de probabilidade.

No caso discreto,

$$E(X) = \sum_x x p_X(x),$$

desde que a soma esteja bem definida.

No caso absolutamente contínuo,

$$E(X) = \int_{-\infty}^{\infty} x f_X(x) dx,$$

desde que a integral esteja bem definida.

Mais geralmente, para uma função g ,

$$E\{g(X)\} = \sum_x g(x) p_X(x)$$

no caso discreto e

$$E\{g(X)\} = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

no caso absolutamente contínuo.

A esperança é linear. Para constantes $a_1, \dots, a_n$ e b ,

$$E\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i E(X_i) + b.$$

Essa propriedade não exige independência entre as variáveis.

1.3.2 Momentos

Para $r = 1, 2, \dots$, o **momento de ordem r em torno da origem** é

$$E(X^r),$$

quando existe.

O **momento centrado (na média) de ordem r** é

$$E[\{X - E(X)\}^r],$$

quando existe.

A média corresponde ao primeiro momento em torno da origem. A variância corresponde ao segundo momento centrado.

Medidas como assimetria e curtose são construídas a partir de momentos centrais padronizados (Casella; Berger, 2011, ex. 2.28; Ramachandran; Tsokos, 2021, secs. 3.1 e 3.3).

1.3.3 Variância

A **variância** de X é

$$\text{Var}(X) = E[\{X - E(X)\}^2].$$

Uma forma equivalente é

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

Para constantes a e b ,

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

A raiz quadrada da variância,

$$\text{DP}(X) = \sqrt{\text{Var}(X)},$$

é o desvio-padrão da distribuição.

1.4 Distribuições conjuntas e dependência

Muitos problemas probabilísticos envolvem mais de uma variável aleatória considerada simultaneamente. Nesses casos, além de descrever o comportamento individual de cada variável, é necessário estudar como elas se comportam conjuntamente e como se relacionam.

Variáveis aleatórias

$$X_1, \dots, X_k$$

consideradas conjuntamente podem ser reunidas no vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top.$$

A distribuição conjunta descreve o comportamento probabilístico de suas componentes consideradas simultaneamente. A partir dela, podem ser obtidas distribuições marginais e condicionais e estudadas relações de dependência entre as variáveis.

Quando forem consideradas apenas duas variáveis aleatórias, utilizaremos a notação X e Y .

1.4.1 Distribuição conjunta

Considere duas variáveis aleatórias X e Y , com suportes $\mathcal{X}$ e $\mathcal{Y}$, respectivamente. Os pares formados por seus valores pertencem ao produto cartesiano

$$\mathcal{X} \times \mathcal{Y}.$$

A distribuição conjunta descreve o comportamento probabilístico de X e Y consideradas simultaneamente. Sua função de distribuição conjunta é definida por

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y).$$

O **suporte conjunto** de (X, Y) é formado pelos pares

$$(x, y) \in \mathcal{X} \times \mathcal{Y}$$

admissíveis sob a distribuição conjunta considerada.

O suporte conjunto não precisa coincidir com todo o produto cartesiano

$$\mathcal{X} \times \mathcal{Y}.$$

Dependendo da relação entre X e Y , apenas parte das combinações entre seus valores individuais pode pertencer ao suporte conjunto.

No caso discreto, a distribuição conjunta pode ser descrita pela função de massa de probabilidade

$$p_{X,Y}(x, y) = P(X = x, Y = y),$$

que satisfaz

$$p_{X,Y}(x, y) \geq 0$$

e

$$\sum_x \sum_y p_{X,Y}(x, y) = 1.$$

No caso absolutamente contínuo, a distribuição conjunta é descrita por uma densidade

$$f_{X,Y}(x, y) \geq 0,$$

com

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx \, dy = 1.$$

Para uma região

$$A \subseteq \mathbb{R}^2,$$

temos

$$P\{(X, Y) \in A\} = \iint_A f_{X,Y}(x, y) \, dx \, dy.$$

A mesma ideia se estende a vetores aleatórios com mais de duas componentes.

1.4.2 Distribuições marginais

A distribuição marginal descreve o comportamento de uma componente do vetor sem condicionar aos valores das demais.

No caso discreto,

$$p_X(x) = \sum_y p_{X,Y}(x, y)$$

e

$$p_Y(y) = \sum_x p_{X,Y}(x, y).$$

No caso absolutamente contínuo,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$$

e

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

A soma ou integração elimina da distribuição conjunta a variável que não aparece na distribuição marginal desejada.

1.4.3 Distribuições condicionais

A distribuição condicional descreve o comportamento de uma variável quando o valor de outra é conhecido.

No caso discreto, se

$$p_Y(y) > 0,$$

então

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Para cada y fixado,

$$\sum_x p_{X|Y}(x | y) = 1.$$

No caso absolutamente contínuo, se

$$f_Y(y) > 0,$$

então

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

com

$$\int_{-\infty}^{\infty} f_{X|Y}(x | y) dx = 1.$$

A distribuição conjunta pode ser recuperada a partir de uma marginal e de uma condicional. No caso discreto,

$$p_{X,Y}(x, y) = p_{X|Y}(x | y)p_Y(y),$$

e, no caso absolutamente contínuo,

$$f_{X,Y}(x, y) = f_{X|Y}(x | y)f_Y(y).$$

A construção de distribuições marginais e condicionais a partir da distribuição conjunta é tratada, por exemplo, em (Rice, 2007, secs. 3.2–3.5; Ramachandran; Tsokos, 2021, sec. 3.3).

Distribuições condicionais serão utilizadas posteriormente em resultados como o teorema de Rao–Blackwell (Rice, 2007, sec. 8.8.2) e no algoritmo EM (Gupta; Chen, 2011).

Considere duas variáveis aleatórias X e Y com função de probabilidade conjunta dada por

X	$Y = 0$	$Y = 1$
0	0,20	0,10
1	0,30	0,40

A distribuição marginal de X é

$$P(X = 0) = 0,20 + 0,10 = 0,30$$

e

$$P(X = 1) = 0,30 + 0,40 = 0,70.$$

Para Y ,

$$P(Y = 0) = 0,20 + 0,30 = 0,50$$

e

$$P(Y = 1) = 0,10 + 0,40 = 0,50.$$

Condiccionando em $Y = 1$,

$$P(X = 1 \mid Y = 1) = \frac{P(X = 1, Y = 1)}{P(Y = 1)} = \frac{0,40}{0,50} = 0,80.$$

Portanto,

$$P(X = 1) = 0,70$$

e

$$P(X = 1 \mid Y = 1) = 0,80.$$

A informação de que $Y = 1$ altera a distribuição atribuída a X .

1.4.4 Independência de variáveis aleatórias

As variáveis aleatórias X e Y são **independentes** quando

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

para todos os conjuntos admissíveis A e B .

No caso discreto, essa condição equivale a

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

para todos os valores possíveis de x e y .

No caso absolutamente contínuo,

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

quase sempre.

Se X e Y são independentes e as esperanças envolvidas existem,

$$E\{g(X)h(Y)\} = E\{g(X)\}E\{h(Y)\}.$$

Em particular,

$$E(XY) = E(X)E(Y).$$

A recíproca não é válida em geral. A igualdade de determinados momentos não é suficiente para estabelecer independência (Rice, 2007, sec. 3.4; Ramachandran; Tsokos, 2021, secs. 2.4 e 3.3).

1.4.5 Independência de várias variáveis

As variáveis

$$X_1, \dots, X_n$$

são mutuamente independentes quando, para quaisquer conjuntos

$$A_1, \dots, A_n,$$

temos

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n P(X_i \in A_i).$$

No caso discreto,

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i).$$

No caso absolutamente contínuo,

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$$

quase sempre.

1.4.6 Variáveis independentes e identicamente distribuídas

Se, além de mutuamente independentes, as variáveis

$$X_1, \dots, X_n$$

possuem a mesma distribuição, dizemos que são **independentes e identicamente distribuídas**.

Formalmente, existe uma função de distribuição comum F tal que

$$F_{X_i}(x) = F(x), \quad i = 1, \dots, n.$$

Nesse caso, escrevemos

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

A sigla **i.i.d.** corresponde à expressão *independentes e identicamente distribuídas*.

i Estrutura i.i.d.

A notação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F$$

reúne duas condições distintas:

1. $X_1, \dots, X_n$ são mutuamente independentes;
2. todas possuem a mesma distribuição F .

Serem identicamente distribuídas não significa que as variáveis assumam os mesmos valores. Significa que todas são regidas pela mesma distribuição probabilística.

A estrutura i.i.d. será utilizada repetidamente ao longo do livro e, posteriormente, aparecerá na definição usual de uma amostra aleatória. Ela representa uma hipótese específica sobre o mecanismo probabilístico de geração das observações e não se aplica a todos os processos de obtenção de dados.

1.4.7 Covariância e correlação

Se X e Y possuem segundos momentos finitos, a **covariância** entre X e Y é

$$\text{Cov}(X, Y) = E[\{X - E(X)\}\{Y - E(Y)\}].$$

Equivalentemente,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

A covariância descreve a direção da associação linear entre as duas variáveis.

Se X e Y são independentes e possuem segundos momentos finitos,

$$E(XY) = E(X)E(Y)$$

e, portanto,

$$\text{Cov}(X, Y) = 0.$$

Assim,

$$X \perp Y \implies \text{Cov}(X, Y) = 0.$$

A implicação inversa não é válida em geral.

A covariância depende das unidades de medida. Uma medida adimensional da associação linear é o **coeficiente de correlação**,

$$\rho_{X,Y} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}},$$

desde que

$$\text{Var}(X) > 0$$

e

$$\text{Var}(Y) > 0.$$

O coeficiente satisfaz

$$-1 \leq \rho_{X,Y} \leq 1.$$

Valores positivos correspondem a associação linear positiva, valores negativos a associação linear negativa e

$$\rho_{X,Y} = 0$$

indica ausência de associação linear. Correlação nula, entretanto, não implica ausência de dependência.

i Independência e correlação

Independência implica covariância nula quando os segundos momentos são finitos. Se, além disso, ambas as variâncias são positivas, a correlação está definida e é igual a zero. A implicação inversa não vale para distribuições arbitrárias.

Para variáveis conjuntamente normais com variâncias positivas, correlação nula implica

independência.

1.4.8 Variância de combinações lineares

Para variáveis com segundos momentos finitos,

$$\text{Var} \left(\sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j).$$

Se as variáveis são independentes, as covariâncias cruzadas são nulas e

$$\text{Var} \left(\sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i).$$

Esse resultado será utilizado repetidamente na obtenção das variâncias de somas, médias e outras estatísticas construídas a partir de observações independentes (Rice, 2007, secs. 4.2–4.3; Ramachandran; Tsokos, 2021, sec. 3.3.1).

1.4.9 Esperança condicional

A distribuição condicional permite definir momentos condicionais.

No caso discreto,

$$E(X | Y = y) = \sum_x x p_{X|Y}(x | y),$$

desde que a soma esteja bem definida.

No caso absolutamente contínuo,

$$E(X | Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x | y) dx.$$

Ao permitir que Y varie, obtemos a variável aleatória

$$E(X | Y).$$

Mais geralmente,

$$E\{g(X) \mid Y = y\}$$

é calculada utilizando a distribuição condicional de X dado $Y = y$.

Se X e Y são independentes e

$$E|X| < \infty,$$

então

$$E(X \mid Y) = E(X).$$

! Lei da esperança total

Se $E|X| < \infty$, então

$$E(X) = E\{E(X \mid Y)\}.$$

A lei da esperança total permite obter a média não condicional a partir das médias condicionais.

Considere uma variável Y que identifica dois grupos,

$$Y \in \{0, 1\},$$

com

$$P(Y = 0) = 0,6$$

e

$$P(Y = 1) = 0,4.$$

Suponha que

$$E(X \mid Y = 0) = 10$$

e

$$E(X \mid Y = 1) = 20.$$

Então,

$$E(X) = E\{E(X \mid Y)\}$$

e

$$E(X) = 10(0,6) + 20(0,4) = 14.$$

1.4.10 Variância condicional

A variância condicional de X dado $Y = y$ é

$$\text{Var}(X \mid Y = y) = E[\{X - E(X \mid Y = y)\}^2 \mid Y = y].$$

Equivalentemente,

$$\text{Var}(X \mid Y = y) = E(X^2 \mid Y = y) - [E(X \mid Y = y)]^2.$$

Ao permitir que Y varie, obtém-se a variável aleatória

$$\text{Var}(X \mid Y).$$

! Lei da variância total

Se $E(X^2) < \infty$, então

$$\text{Var}(X) = E\{\text{Var}(X \mid Y)\} + \text{Var}\{E(X \mid Y)\}.$$

A primeira parcela,

$$E\{\text{Var}(X \mid Y)\},$$

representa a média das variâncias condicionais. A segunda,

$$\text{Var}\{E(X \mid Y)\},$$

representa a variabilidade entre as médias condicionais.

A decomposição separa, portanto, a variabilidade total de X em uma componente associada à variação dentro das distribuições condicionais e outra associada à variação entre suas médias (Rice, 2007, sec. 4.4; Ramachandran; Tsokos, 2021, sec. 3.3).

Considere novamente

$$P(Y = 0) = 0,6, \quad P(Y = 1) = 0,4,$$

com

$$E(X \mid Y = 0) = 10$$

e

$$E(X \mid Y = 1) = 20.$$

Suponha ainda que

$$\text{Var}(X \mid Y = 0) = 9$$

e

$$\text{Var}(X \mid Y = 1) = 16.$$

A primeira parcela da lei da variância total é

$$E\{\text{Var}(X \mid Y)\} = 9(0,6) + 16(0,4) = 11,8.$$

Como

$$E(X) = 14,$$

a variância das médias condicionais é

$$\text{Var}\{E(X \mid Y)\} = 0,6(10 - 14)^2 + 0,4(20 - 14)^2 = 24.$$

Portanto,

$$\text{Var}(X) = 11,8 + 24 = 35,8.$$

1.4.11 Vetores de médias e matrizes de covariâncias

Para um vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top,$$

o vetor de médias é

$$E(\mathbf{X}) = \begin{pmatrix} E(X_1) \\ \vdots \\ E(X_k) \end{pmatrix}.$$

A matriz de covariâncias é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[\{\mathbf{X} - E(\mathbf{X})\}\{\mathbf{X} - E(\mathbf{X})\}^\top].$$

Sua forma é

$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_k) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_k, X_1) & \text{Cov}(X_k, X_2) & \cdots & \text{Var}(X_k) \end{pmatrix}.$$

A diagonal contém as variâncias das componentes e os elementos fora da diagonal contêm as covariâncias entre pares de variáveis.

A matriz de covariâncias é simétrica e positiva semidefinida. Essa representação será retomada no estudo de parâmetros vetoriais, distribuições assintóticas multivariadas e modelos lineares (Rice, 2007, secs. 4.2–4.3; Ramachandran; Tsokos, 2021, sec. 3.3.1).

i Em síntese: distribuições conjuntas e dependência

Os principais resultados desta seção podem ser organizados a partir da distribuição conjunta.

A partir de uma distribuição conjunta, podem ser obtidas as **distribuições marginais** de cada componente e, quando as condições necessárias são satisfeitas, suas **distribuições condicionais**.

A independência corresponde à fatoração da distribuição conjunta. No caso discreto,

$$p_{X,Y}(x, y) = p_X(x)p_Y(y),$$

e, no caso absolutamente contínuo,

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

O condicionamento também permite decompor momentos. A lei da esperança total estabelece que

$$E(X) = E\{E(X | Y)\},$$

enquanto a lei da variância total fornece

$$\text{Var}(X) = E\{\text{Var}(X | Y)\} + \text{Var}\{E(X | Y)\}.$$

Quando várias variáveis são independentes e possuem a mesma distribuição, utilizamos a notação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

1.5 Função geradora de momentos

A **função geradora de momentos (fgm)** de uma variável aleatória X é definida por

$$M_X(t) = E(e^{tX}),$$

desde que essa esperança exista em uma vizinhança de $t = 0$.

No caso discreto,

$$M_X(t) = \sum_x e^{tx} p_X(x),$$

enquanto, no caso absolutamente contínuo,

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx.$$

A fgm será utilizada neste capítulo para três finalidades: obter momentos, estudar distribuições de somas de variáveis independentes e reconhecer distribuições a partir de sua forma funcional (Rice, 2007, sec. 4.5; Chihara; Hesterberg, 2022, ap. A.8).

1.5.1 Obtenção de momentos

Para $r = 1, 2, \dots$, quando a fgm é finita em uma vizinhança de zero, sua derivada de ordem r é

$$M_X^{(r)}(t) = \frac{d^r}{dt^r} M_X(t).$$

Avaliando em $t = 0$,

$$M_X^{(r)}(0) = E(X^r).$$

Em particular,

$$M_X'(0) = E(X)$$

e

$$M_X''(0) = E(X^2).$$

Consequentemente,

$$\text{Var}(X) = M_X''(0) - [M_X'(0)]^2.$$

Assim, quando a fgm possui uma expressão simples, ela fornece uma forma alternativa de obter os momentos da distribuição.

1.5.2 Transformações lineares

Se

$$Y = aX + b,$$

então

$$M_Y(t) = E(e^{t(aX+b)}).$$

Como

$$e^{t(aX+b)} = e^{bt}e^{atX},$$

segue que

$$M_Y(t) = e^{bt}M_X(at).$$

Essa relação permite obter a fgm de uma transformação linear a partir da FGM da variável original.

1.5.3 Soma de variáveis independentes

Se

$$X_1, \dots, X_n$$

são independentes e suas funções geradoras de momentos existem em uma vizinhança de zero, então

$$M_{X_1+\dots+X_n}(t) = \prod_{i=1}^n M_{X_i}(t).$$

Se, além disso, $X_1, \dots, X_n$ são i.i.d. e possuem a mesma distribuição de uma variável aleatória X , e

$$S_n = X_1 + \dots + X_n,$$

então

$$M_{S_n}(t) = M_{X_1+\dots+X_n}(t) = [M_X(t)]^n.$$

Essa propriedade será utilizada nas seções seguintes para estabelecer relações entre alguns modelos probabilísticos.

1.5.4 Identificação de distribuições

Se duas variáveis aleatórias possuem funções geradoras de momentos que existem e coincidem em uma vizinhança de $t = 0$, então elas possuem a mesma distribuição.

Assim, quando a fgm de uma variável ou de uma soma de variáveis coincide com a fgm de uma distribuição conhecida, essa igualdade pode ser utilizada para identificar sua distribuição.

i Existência da fgm

Nem toda distribuição possui função geradora de momentos. Neste capítulo, a FGM será apresentada junto aos modelos em que sua expressão é útil para os desenvolvimentos posteriores.

Não será introduzida uma expressão complicada apenas para completar uma tabela. Quando a FGM de determinado modelo envolver funções especiais que não serão utilizadas no livro, essa forma será omitida.

1.6 Modelos probabilísticos discretos

Modelos probabilísticos discretos descrevem variáveis aleatórias que assumem valores em conjuntos finitos ou enumeráveis. A escolha de uma distribuição depende do mecanismo que produz a variável observada. Um único resultado binário, uma contagem de sucessos, uma amostragem sem reposição, o número de tentativas até determinado evento e o número de ocorrências em um intervalo correspondem a estruturas probabilísticas distintas.

Nesta seção, serão revisadas as distribuições uniforme discreta, Bernoulli, binomial, hipergeométrica, geométrica, binomial negativa e Poisson. Para cada modelo serão apresentados seu mecanismo probabilístico, suporte, função de massa de probabilidade, esperança, variância, função geradora de momentos, situações que podem originar problemas inferenciais e o comportamento gráfico da função de massa e da função de distribuição acumulada (Dantas, 1997; Magalhães, 2006; Ross, 2006).

1.6.1 Distribuição uniforme discreta

A distribuição uniforme discreta descreve situações em que um número finito de resultados possui a mesma probabilidade de ocorrência.

Considere uma variável aleatória X que pode assumir os valores

$$x_1, \dots, x_m,$$

todos com a mesma probabilidade. Sua função de massa de probabilidade é

$$p_X(x) = \frac{1}{m} \mathbf{1}_{\{x_1, \dots, x_m\}}(x).$$

Um caso particular ocorre quando

$$X \in \{1, \dots, m\}.$$

Nesse caso, escrevemos

$$X \sim U\{1, \dots, m\}$$

e

$$p_X(x) = \frac{1}{m} \mathbf{1}_{\{1, \dots, m\}}(x).$$

A esperança é

$$E(X) = \frac{m+1}{2},$$

e a variância é

$$\text{Var}(X) = \frac{m^2 - 1}{12}.$$

A função geradora de momentos é

$$M_X(t) = \frac{1}{m} \sum_{x=1}^m e^{tx}.$$

Para $t \neq 0$, a soma geométrica fornece

$$M_X(t) = \frac{e^t(e^{mt} - 1)}{m(e^t - 1)},$$

enquanto

$$M_X(0) = 1.$$

Considere uma população cujos elementos são numerados consecutivamente de 1 até um valor máximo desconhecido m . Se um elemento é selecionado aleatoriamente e todos os números possuem a mesma probabilidade de seleção, então

$$X \sim U\{1, \dots, m\}.$$

Um exemplo ocorre quando números de série são atribuídos sequencialmente aos itens produzidos por uma empresa. Se apenas alguns números de série são observados, pode haver interesse em obter informação sobre o número total m de itens produzidos.

Nesse problema, o mecanismo probabilístico é uniforme discreto e a quantidade que assumirá posteriormente o papel de parâmetro desconhecido é m .

A Figura 1.1 mostra que todos os valores do suporte possuem a mesma massa de probabilidade. À medida que m aumenta, essa massa individual diminui, pois a probabilidade total igual a 1 é distribuída entre um número maior de valores. A função de distribuição apresenta saltos de mesma magnitude, iguais a $1/m$. Assim, quanto maior o número de valores possíveis, menores são os saltos da função de distribuição.

1.6.2 Distribuição de Bernoulli

Um **ensaio de Bernoulli** é um experimento com dois resultados possíveis, representados por 1 e 0. Convencionalmente, esses resultados são denominados sucesso e fracasso.

Uma variável aleatória X possui distribuição de Bernoulli com parâmetro

$$0 < p < 1$$

quando sua função de massa de probabilidade é

$$p_X(x) = p^x(1-p)^{1-x}\mathbf{1}_{\{0,1\}}(x).$$

Escrevemos

$$X \sim \text{Ber}(p).$$

O parâmetro p representa a probabilidade de sucesso:

$$P(X = 1) = p,$$

enquanto




Figura 1.1: Função de massa de probabilidade e função de distribuição acumulada da distribuição uniforme discreta para diferentes parâmetros.

$$P(X = 0) = 1 - p.$$

A esperança é

$$E(X) = p,$$

e a variância é

$$\text{Var}(X) = p(1 - p).$$

A função geradora de momentos é

$$M_X(t) = E(e^{tX}).$$

Como X assume apenas os valores 0 e 1,

$$M_X(t) = (1 - p)e^0 + pe^t,$$

de modo que

$$M_X(t) = 1 - p + pe^t.$$

A função indicadora fornece uma representação direta de uma variável Bernoulli. Para um evento A ,

$$X = \mathbf{1}_A$$

possui distribuição de Bernoulli com

$$p = P(A).$$

Considere uma pesquisa em que cada pessoa entrevistada responde se utiliza ou não determinado serviço público. Defina

$$X = \begin{cases} 1, & \text{se a pessoa utiliza o serviço,} \\ 0, & \text{caso contrário.} \end{cases}$$

Se p representa a probabilidade de uma pessoa da população utilizar o serviço, então

$$X \sim \text{Ber}(p).$$

Em uma situação inferencial, podem ser observadas respostas de várias pessoas com o objetivo de obter informação sobre a proporção populacional p de usuários do serviço.

A Figura 1.2 mostra que o parâmetro p redistribui a massa entre os dois valores possíveis. Quando p é pequeno, a maior massa está em $X = 0$; quando p é grande, concentra-se em $X = 1$. Para $p = 0,5$, os dois resultados possuem a mesma probabilidade. Na função de distribuição, o primeiro salto possui magnitude $1 - p$ e ocorre em $x = 0$; o segundo completa a probabilidade acumulada em $x = 1$.

1.6.3 Distribuição binomial

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

A variável

$$X = \sum_{i=1}^n X_i$$

representa o número de sucessos nos n ensaios.

Nesse caso,

$$X \sim \text{Binom}(n, p),$$

com

$$n \in \mathbb{N} \quad \text{e} \quad 0 < p < 1.$$

O suporte é

$$\mathcal{X} = \{0, 1, \dots, n\}.$$

Sua função de massa de probabilidade é

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x} \mathbf{1}_{\{0,1,\dots,n\}}(x).$$




Figura 1.2: Função de massa de probabilidade e função de distribuição acumulada da distribuição de Bernoulli para diferentes parâmetros.

Como X é uma soma de variáveis Bernoulli independentes,

$$E(X) = \sum_{i=1}^n E(X_i) = np$$

e

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(X_i) = np(1-p).$$

Além da contagem total de sucessos, a mesma representação permite considerar a **proporção de sucessos** nos n ensaios. Como

$$X = \sum_{i=1}^n X_i,$$

temos

$$\frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Assim, quando X_i indica a ocorrência de sucesso no i -ésimo ensaio, X/n representa a proporção de sucessos observada nos n ensaios.

Utilizando a linearidade da esperança,

$$E\left(\frac{X}{n}\right) = \frac{1}{n}E(X) = p.$$

Da mesma forma,

$$\text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) = \frac{p(1-p)}{n}.$$

Essa relação será retomada posteriormente no estudo da proporção amostral. Ela mostra que a proporção de sucessos pode ser escrita como a média de variáveis Bernoulli independentes.

A função geradora de momentos também decorre da representação como soma. Como

$$M_{X_i}(t) = 1 - p + pe^t,$$

temos

$$M_X(t) = \prod_{i=1}^n M_{X_i}(t),$$

e, portanto,

$$M_X(t) = (1 - p + pe^t)^n.$$

i Estrutura do modelo binomial

A distribuição binomial resulta das seguintes condições:

1. o número de ensaios n é fixado;
2. cada ensaio possui dois resultados possíveis;
3. os ensaios são independentes;
4. a probabilidade de sucesso p é a mesma em todos os ensaios.

A alteração dessas condições pode exigir outro modelo probabilístico.

Considere uma pesquisa de satisfação realizada com $n = 100$ usuários de determinado serviço. Cada pessoa é classificada como satisfeita ou não satisfeita.

Se as respostas puderem ser representadas por ensaios de Bernoulli independentes com probabilidade de satisfação p , o número total X de pessoas satisfeitas pode ser modelado por

$$X \sim \text{Binom}(100, p).$$

O interesse inferencial pode estar na proporção p de usuários satisfeitos na população. O valor de p é desconhecido, enquanto X é observado a partir da amostra.

A Figura 1.3 mostra como p modifica a localização e a forma da distribuição para um mesmo número de ensaios. Como

$$E(X) = np,$$

o aumento de p desloca a massa de probabilidade para valores maiores de x . Para $p = 0,5$, a distribuição é simétrica em torno de $x = 5$. Os casos $p = 0,2$ e $p = 0,8$ apresentam formas espelhadas, consequência da troca entre as probabilidades de sucesso e fracasso. Na função de distribuição, esse deslocamento aparece na posição em que a probabilidade acumulada cresce.




Figura 1.3: Função de massa de probabilidade e função de distribuição acumulada da distribuição binomial para diferentes parâmetros.

1.6.4 Distribuição hipergeométrica

A distribuição hipergeométrica descreve o número de sucessos em uma amostra retirada **sem reposição** de uma população finita.

Considere uma população formada por:

- N unidades;
- M unidades classificadas como sucesso;
- $N - M$ unidades classificadas como fracasso.

Seleciona-se uma amostra de tamanho n sem reposição e define-se X como o número de sucessos observados.

Então,

$$X \sim \text{Hiper}(N, M, n),$$

com

$$N \in \mathbb{N}, \quad 0 \leq M \leq N$$

e

$$0 \leq n \leq N.$$

Defina

$$\mathcal{X} = \{\max\{0, n - N + M\}, \dots, \min\{n, M\}\}.$$

A função de massa de probabilidade é

$$p_X(x) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}} \mathbf{1}_{\mathcal{X}}(x).$$

Definindo

$$p = \frac{M}{N},$$

a esperança é

$$E(X) = np.$$

Para $N > 1$, a variância é

$$\text{Var}(X) = np(1-p) \frac{N-n}{N-1}.$$

O fator

$$\frac{N-n}{N-1}$$

é denominado **correção para população finita**. Ele surge porque as retiradas sem reposição não são independentes.

No caso degenerado $N = 1$, a variável X é constante e, portanto,

$$\text{Var}(X) = 0.$$

A função geradora de momentos pode ser escrita como a soma finita

$$M_X(t) = \sum_{x \in \mathcal{X}} e^{tx} \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}.$$

Sua forma será suficiente para esta revisão; não será necessária uma representação adicional por funções especiais.

Considere um lote com $N = 500$ componentes eletrônicos. Uma quantidade desconhecida M desses componentes apresenta determinado defeito. Uma amostra de $n = 30$ componentes é selecionada sem reposição e X representa o número de itens defeituosos encontrados.

Condicionalmente ao número M de componentes defeituosos existentes no lote,

$$X \sim \text{Hiper}(500, M, 30).$$

Em um problema inferencial, a contagem observada X pode fornecer informação sobre M ou sobre a proporção

$$p = \frac{M}{500}$$

de componentes defeituosos no lote.

Função de massa de probabilidade

$N = 50, n = 10, M = 10$ $N = 50, n = 10, M = 25$ $N = 50, n = 10, M = 40$





Figura 1.4: Função de massa de probabilidade e função de distribuição acumulada da distribuição hipergeométrica para diferentes parâmetros.

A Figura 1.4 mantém fixados o tamanho da população e o tamanho da amostra e altera o número M de sucessos existentes na população. Como

$$E(X) = n \frac{M}{N},$$

o aumento de M desloca a distribuição para contagens maiores. Os casos $M = 10$ e $M = 40$ apresentam comportamento aproximadamente espelhado, enquanto $M = 25$ corresponde a uma população com metade das unidades em cada categoria.

1.6.5 Binomial e hipergeométrica

As distribuições binomial e hipergeométrica podem descrever o número de sucessos em n observações, mas correspondem a mecanismos de obtenção dos dados diferentes.

Característica	Binomial	Hipergeométrica
Número de observações	n	n
Número de sucessos	X	X
Probabilidade inicial de sucesso	p	$p = M/N$
Estrutura	ensaios independentes	amostragem sem reposição
População	conceitualmente ilimitada ou reposição	finita
Esperança	np	np
Variância	$np(1 - p)$	$np(1 - p) \frac{N - n}{N - 1}$

A diferença entre as variâncias decorre da dependência introduzida pela amostragem sem reposição.

Quando N é grande em relação a n ,

$$\frac{N - n}{N - 1}$$

fica próximo de 1. Nessa situação, a distribuição binomial pode fornecer uma aproximação para a distribuição hipergeométrica.

A distribuição hipergeométrica, e não a binomial, é o modelo exato para amostragem sem reposição em população finita (Ramachandran; Tsokos, 2021, secs. 3.2.1–3.2.4; Chihara; Hesterberg, 2022, aps. B.1–B.6).

💡 Relação com o experimento da urna

Essa distinção será utilizada posteriormente no estudo da amostragem.

Considere uma urna com N bolas, das quais M apresentam determinada característica, por exemplo, a cor vermelha. Se são realizadas n retiradas **sem reposição** e X representa o número de bolas vermelhas observadas, então

$$X \sim \text{Hiper}(N, M, n).$$

Nesse mecanismo, as retiradas não são independentes, pois a composição da urna é modificada após cada seleção.

Se, em vez disso, cada retirada for realizada **com reposição**, a probabilidade de observar uma bola vermelha permanece constante,

$$p = \frac{M}{N},$$

e as retiradas podem ser representadas por variáveis Bernoulli independentes:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Nesse caso,

$$X = \sum_{i=1}^n X_i \sim \text{Binom}(n, p).$$

Assim, mecanismos de amostragem diferentes podem produzir variáveis com interpretações semelhantes, mas distribuições probabilísticas distintas.

1.6.6 Distribuição geométrica

Considere uma sequência de ensaios de Bernoulli independentes, todos com probabilidade de sucesso

$$0 < p < 1.$$

Se X representa o **número de ensaios necessários até a ocorrência do primeiro sucesso**, então

$$X \sim \text{Geo}(p).$$

O suporte é

$$\mathcal{X} = \{1, 2, 3, \dots\},$$

e a função de massa de probabilidade é

$$p_X(x) = p(1-p)^{x-1} \mathbf{1}_{\{1,2,\dots\}}(x).$$

A esperança é

$$E(X) = \frac{1}{p},$$

e a variância é

$$\text{Var}(X) = \frac{1-p}{p^2}.$$

A função geradora de momentos é

$$M_X(t) = \sum_{x=1}^{\infty} e^{tx} p(1-p)^{x-1}.$$

Utilizando a soma de uma série geométrica,

$$M_X(t) = \frac{pe^t}{1 - (1-p)e^t},$$

para

$$t < -\log(1-p).$$

Considere ligações realizadas por uma central até que um cliente aceite participar de uma pesquisa. Suponha que cada ligação resulte em aceitação com probabilidade p e que os resultados possam ser tratados como independentes.

Se X representa o número de ligações necessárias até a primeira aceitação,

$$X \sim \text{Geo}(p).$$

Em um problema inferencial, os números de ligações necessários em diferentes sequências de contatos podem fornecer informação sobre a probabilidade p de aceitação de um convite.




Figura 1.5: Função de massa de probabilidade e função de distribuição acumulada da distribuição geométrica para diferentes parâmetros.

A Figura 1.5 mostra que a distribuição concentra sua maior massa em $x = 1$ e decresce à medida que o número de tentativas aumenta. Para valores maiores de p , o primeiro sucesso tende a ocorrer mais cedo. Essa relação também aparece em

$$E(X) = \frac{1}{p}.$$

Assim, para $p = 0,8$, a probabilidade acumulada aproxima-se rapidamente de 1, enquanto para $p = 0,2$ a distribuição apresenta uma cauda mais longa.

1.6.6.1 Falta de memória

A distribuição geométrica possui a propriedade de falta de memória. Para inteiros não negativos m e n ,

$$P(X > m + n \mid X > m) = P(X > n).$$

A expressão indica que, após m tentativas sem sucesso, o número adicional de tentativas necessário para observar o primeiro sucesso segue o mesmo mecanismo probabilístico do início da sequência.

i Parametrização

Outra convenção define a distribuição geométrica pelo número de fracassos observados antes do primeiro sucesso, resultando no suporte

$$\{0, 1, 2, \dots\}.$$

Neste livro, X representa o número total de ensaios até o primeiro sucesso e, portanto, seu suporte começa em 1.

1.6.7 Distribuição binomial negativa

A distribuição binomial negativa generaliza a distribuição geométrica.

Considere ensaios de Bernoulli independentes com probabilidade de sucesso

$$0 < p < 1.$$

Se X representa o número total de ensaios necessários para observar o r -ésimo sucesso, com

$$r \in \mathbb{N},$$

então

$$X \sim \text{BN}(r, p).$$

Seu suporte é

$$\mathcal{X} = \{r, r+1, r+2, \dots\}.$$

A função de massa de probabilidade é

$$p_X(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r} \mathbf{1}_{\{r, r+1, \dots\}}(x).$$

Para que o r -ésimo sucesso ocorra exatamente no ensaio x , entre os primeiros $x-1$ ensaios devem ocorrer $r-1$ sucessos, e o último ensaio deve ser um sucesso.

A esperança é

$$E(X) = \frac{r}{p},$$

e a variância é

$$\text{Var}(X) = \frac{r(1-p)}{p^2}.$$

Como uma variável binomial negativa pode ser representada como a soma de r variáveis geométricas independentes com parâmetro p , sua função geradora de momentos é

$$M_X(t) = \left[\frac{pe^t}{1 - (1-p)e^t} \right]^r,$$

para

$$t < -\log(1-p).$$

Quando

$$r = 1,$$

a distribuição binomial negativa reduz-se à distribuição geométrica.

Considere uma equipe de recrutamento que entra em contato com candidatos até obter $r = 5$ aceitações para determinada etapa de uma seleção.

Se cada contato resulta em aceitação com probabilidade p , sob condições que permitam tratar os resultados como independentes, o número total X de contatos necessários até a quinta aceitação pode ser modelado por

$$X \sim \text{BN}(5, p).$$

Os números de contatos necessários em diferentes processos podem ser utilizados para obter informação sobre a probabilidade p de aceitação.

A Figura 1.6 permite observar separadamente os efeitos de r e p . Mantendo $p = 0,4$, a passagem de $r = 2$ para $r = 5$ desloca a distribuição para valores maiores, pois mais sucessos precisam ser acumulados. Mantendo $r = 5$, o aumento de p de 0,4 para 0,7 desloca a distribuição para valores menores, pois os sucessos passam a ocorrer com maior frequência. Essas relações são compatíveis com

$$E(X) = \frac{r}{p}.$$

1.6.8 Distribuição de Poisson

A distribuição de Poisson é utilizada para modelar o número de ocorrências de determinado evento em uma região de observação, como um intervalo de tempo, uma área, um comprimento ou um volume.

Se

$$X \sim \text{Poisson}(\lambda), \quad \lambda > 0,$$

o suporte é

$$\mathcal{X} = \{0, 1, 2, \dots\},$$

e a função de massa de probabilidade é




Figura 1.6: Função de massa de probabilidade e função de distribuição acumulada da distribuição binomial negativa para diferentes parâmetros.

$$p_X(x) = e^{-\lambda} \frac{\lambda^x}{x!} \mathbf{1}_{\{0,1,2,\dots\}}(x).$$

O parâmetro λ representa o número esperado de ocorrências na região de observação considerada.

Quando o número esperado de ocorrências é determinado por uma taxa média por unidade de exposição, é útil distinguir a taxa da quantidade esperada no intervalo observado.

Se ρ representa a taxa média de ocorrências por unidade de exposição e t representa a exposição considerada, então

$$\lambda = \rho t.$$

Assim, ρ representa uma taxa por unidade de tempo, área, comprimento, volume ou outra medida de exposição, enquanto λ representa o número esperado de ocorrências na exposição específica t .

Por exemplo, se uma taxa média é de $\rho = 3$ ocorrências por hora e o período observado possui $t = 4$ horas, então

$$\lambda = 3(4) = 12.$$

Nesse período,

$$X \sim \text{Poisson}(12).$$

A esperança e a variância coincidem:

$$E(X) = \lambda$$

e

$$\text{Var}(X) = \lambda.$$

A função geradora de momentos é

$$M_X(t) = \sum_{x=0}^{\infty} e^{tx} e^{-\lambda} \frac{\lambda^x}{x!}.$$

Reorganizando os termos,

$$M_X(t) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!}.$$

Como

$$\sum_{x=0}^{\infty} \frac{a^x}{x!} = e^a,$$

segue que

$$M_X(t) = \exp \{ \lambda(e^t - 1) \}.$$

Considere uma agência bancária e seja X o número de clientes atendidos durante o turno da manhã, cuja duração é de t horas.

Suponha que ρ represente a taxa média de atendimentos por hora. Se a distribuição de Poisson fornecer uma representação adequada para essa contagem, então

$$X \sim \text{Poisson}(\lambda),$$

com

$$\lambda = \rho t.$$

Nesse caso, ρ representa o número médio de atendimentos por hora, enquanto λ representa o número médio de atendimentos durante todo o turno.

Ao observar as quantidades de clientes atendidos em vários turnos da manhã, pode haver interesse inferencial em obter informação sobre ρ ou, de forma equivalente quando t é conhecido, sobre λ . Também pode haver interesse em comparar as taxas médias de atendimento entre períodos ou avaliar se uma mudança no processo de trabalho modificou essa taxa.

Os procedimentos utilizados para realizar essas inferências serão desenvolvidos posteriormente.

Considere X como o número de defeitos encontrados em uma determinada área de uma chapa metálica. Se a distribuição de Poisson fornecer uma representação adequada para essas contagens, λ corresponde ao número esperado de defeitos na área considerada.

Observações realizadas em várias chapas podem ser utilizadas para obter informação sobre essa intensidade média de defeitos.




Figura 1.7: Função de massa de probabilidade e função de distribuição acumulada da distribuição de Poisson para diferentes parâmetros.

A Figura 1.7 mostra que o aumento de λ desloca a distribuição para contagens maiores e também aumenta sua dispersão. Isso decorre das relações

$$E(X) = \lambda$$

e

$$\text{Var}(X) = \lambda.$$

Para $\lambda = 1$, a distribuição apresenta maior concentração nos primeiros valores e assimetria à direita. À medida que λ aumenta, a massa se desloca para valores maiores e a forma da distribuição torna-se visualmente menos assimétrica.

1.6.9 Relação entre binomial e Poisson

A distribuição de Poisson pode surgir como limite da distribuição binomial em situações com grande número de ensaios e pequena probabilidade individual de sucesso.

Considere

$$X_n \sim \text{Binom}(n, p_n).$$

Se

$$n \rightarrow \infty,$$

$$p_n \rightarrow 0$$

e

$$np_n \rightarrow \lambda,$$

então, para cada

$$x = 0, 1, 2, \dots,$$

temos

$$P(X_n = x) \longrightarrow e^{-\lambda} \frac{\lambda^x}{x!}.$$

Assim, em determinadas situações, uma contagem resultante de muitos ensaios com baixa probabilidade individual de sucesso pode ser aproximada por uma distribuição de Poisson.

1.6.10 Soma de variáveis Poisson independentes

Considere variáveis independentes

$$X_1, \dots, X_k,$$

com

$$X_j \sim \text{Poisson}(\lambda_j).$$

A FGM de cada variável é

$$M_{X_j}(t) = \exp\{\lambda_j(e^t - 1)\}.$$

Pela independência,

$$M_{\sum_{j=1}^k X_j}(t) = \prod_{j=1}^k M_{X_j}(t).$$

Logo,

$$M_{\sum_{j=1}^k X_j}(t) = \exp\left\{\left(\sum_{j=1}^k \lambda_j\right)(e^t - 1)\right\}.$$

Essa é a função geradora de momentos de uma distribuição de Poisson com parâmetro

$$\sum_{j=1}^k \lambda_j.$$

Portanto,

$$\sum_{j=1}^k X_j \sim \text{Poisson} \left(\sum_{j=1}^k \lambda_j \right).$$

Esse resultado mostra uma das utilidades da função geradora de momentos: propriedades de fechamento de famílias probabilísticas podem ser obtidas pela identificação da FGM resultante.

1.6.11 Relações entre os modelos discretos

Os modelos discretos apresentados nesta seção correspondem a diferentes mecanismos de geração das observações.

Modelo	Variável modelada	Estrutura probabilística
Uniforme discreta	resultado entre valores equiprováveis	probabilidades iguais
Bernoulli(p)	resultado de um único ensaio	sucesso ou fracasso
Binomial(n, p)	número de sucessos em n ensaios	soma de Bernoulli independentes
Hipergeométrica(N, M, n)	número de sucessos em uma amostra	população finita, sem reposição
Geométrica(p)	número de ensaios até o primeiro sucesso	sequência de Bernoulli
Binomial negativa(r, p)	número de ensaios até o r -ésimo sucesso	soma de variáveis geométricas
Poisson(λ)	número de ocorrências em uma região	modelo de contagens

Algumas relações podem ser representadas por

$$\text{Ber} \longrightarrow \text{Binom},$$

pois a distribuição binomial resulta da soma de variáveis Bernoulli independentes, e por

$$\text{Geo} \longrightarrow \text{BN},$$

pois a binomial negativa pode ser representada pela soma dos tempos de espera entre sucessivos sucessos.

A distribuição hipergeométrica descreve uma estrutura semelhante à binomial quando a seleção ocorre sem reposição em uma população finita. A distribuição de Poisson, por sua vez, descreve outra classe de problemas de contagem e pode surgir como limite da distribuição binomial.

1.7 Modelo multinomial

1.7.1 Distribuição multinomial

A distribuição multinomial generaliza a distribuição binomial para situações em que cada ensaio pode resultar em uma entre m categorias mutuamente exclusivas.

Considere $n \in \mathbb{N}$ ensaios independentes. Em cada ensaio, o resultado pertence a exatamente uma entre $m \geq 2$ categorias,

$$1, \dots, m,$$

com probabilidades

$$p_1, \dots, p_m,$$

tais que

$$0 < p_j < 1, \quad j = 1, \dots, m,$$

e

$$\sum_{j=1}^m p_j = 1.$$

Com essa convenção, todas as categorias possuem probabilidade positiva de ocorrência.

Se X_j representa o número de observações classificadas na categoria j , então o vetor

$$\mathbf{X} = (X_1, \dots, X_m)^\top$$

satisfaz

$$\sum_{j=1}^m X_j = n.$$

Escrevemos

$$\mathbf{X} \sim \text{Multinomial}(n; p_1, \dots, p_m).$$

1.7.2 Suporte e função de massa conjunta

O suporte da distribuição multinomial é

$$\mathcal{X}_n = \left\{ (x_1, \dots, x_m) \in \mathbb{N}_0^m : \sum_{j=1}^m x_j = n \right\}.$$

A função de massa de probabilidade conjunta é

$$p_{\mathbf{X}}(\mathbf{x}) = \frac{n!}{x_1! \cdots x_m!} \prod_{j=1}^m p_j^{x_j} \mathbf{1}_{\mathcal{X}_n}(\mathbf{x}).$$

O coeficiente multinomial

$$\frac{n!}{x_1! \cdots x_m!}$$

representa o número de sequências de n ensaios que produzem as contagens

$$x_1, \dots, x_m.$$

Quando

$$m = 2,$$

temos

$$X_2 = n - X_1,$$

e o modelo multinomial reduz-se à distribuição binomial.

1.7.3 Esperanças, variâncias e covariâncias

Para cada categoria,

$$E(X_j) = np_j$$

e

$$\text{Var}(X_j) = np_j(1 - p_j).$$

Para categorias distintas,

$$\text{Cov}(X_j, X_k) = -np_j p_k, \quad j \neq k.$$

A covariância negativa decorre da restrição

$$X_1 + \cdots + X_m = n.$$

Como o total n é fixado, uma observação classificada em determinada categoria deixa de estar disponível para as demais.

O vetor de médias é

$$E(\mathbf{X}) = n \begin{pmatrix} p_1 \\ \vdots \\ p_m \end{pmatrix}.$$

A matriz de covariâncias possui elementos

$$\Sigma_{jj} = np_j(1 - p_j)$$

na diagonal e

$$\Sigma_{jk} = -np_j p_k, \quad j \neq k,$$

fora da diagonal.

1.7.4 Distribuições marginais

Embora as componentes de $\mathbf{X}$ não sejam independentes, cada contagem individual possui distribuição binomial.

Para

$$j = 1, \dots, m,$$

temos

$$X_j \sim \text{Binom}(n, p_j).$$

Portanto,

$$P(X_j = x) = \binom{n}{x} p_j^x (1 - p_j)^{n-x}, \quad x = 0, \dots, n.$$

Essa propriedade permite interpretar cada componente separadamente, embora a distribuição conjunta contenha informação adicional sobre a dependência entre as contagens.

1.7.5 Função geradora de momentos conjunta

Para um vetor

$$\mathbf{t} = (t_1, \dots, t_m)^\top,$$

a função geradora de momentos conjunta é

$$M_{\mathbf{X}}(\mathbf{t}) = E \left[\exp \left(\sum_{j=1}^m t_j X_j \right) \right].$$

Para uma distribuição multinomial,

$$M_{\mathbf{X}}(t_1, \dots, t_m) = \left(\sum_{j=1}^m p_j e^{t_j} \right)^n.$$

A partir dessa expressão podem ser obtidos os momentos individuais e cruzados por diferenciação em relação às componentes de $\mathbf{t}$.

Considere uma pesquisa sobre o principal meio de transporte utilizado para deslocamentos diários. Cada participante é classificado em uma entre três categorias:

1. transporte coletivo;
2. transporte individual;
3. deslocamento a pé ou por bicicleta.

Defina

$$\mathbf{X} = (X_1, X_2, X_3)^\top,$$

em que X_j representa o número de pessoas classificadas na categoria j em uma amostra de tamanho n .

Se as respostas forem representadas por ensaios independentes com probabilidades populacionais

$$p_1, p_2, p_3,$$

então

$$(X_1, X_2, X_3) \sim \text{Multinomial}(n; p_1, p_2, p_3).$$

Em um problema inferencial, as contagens observadas podem ser utilizadas para obter informação sobre o vetor de proporções populacionais

$$\mathbf{p} = (p_1, p_2, p_3)^\top.$$

O interesse pode estar em uma proporção específica, na comparação entre categorias ou no conjunto completo de proporções.

Considere um processo de controle de qualidade no qual cada produto inspecionado é classificado como

1. sem defeito;
2. defeito leve;
3. defeito grave.





Figura 1.8: Função de massa de probabilidade conjunta de uma distribuição multinomial com três categorias e funções de massa das respectivas distribuições marginais.

As contagens observadas em uma amostra podem ser representadas por uma distribuição multinomial quando as condições do modelo forem adequadas.

Nesse contexto, pode haver interesse em obter informação sobre as proporções populacionais de produtos pertencentes a cada categoria.

Na parte superior da Figura 1.8, cada posição representa uma combinação possível de contagens

$$(x_1, x_2, x_3)$$

satisfazendo

$$x_1 + x_2 + x_3 = 10.$$

Como apenas duas contagens podem variar livremente, o valor de x_3 é determinado por

$$x_3 = 10 - x_1 - x_2.$$

A intensidade do preenchimento representa a massa de probabilidade atribuída a cada combinação.

No painel inferior aparecem as três distribuições marginais. Como

$$X_j \sim \text{Binom}(n, p_j),$$

a categoria com maior probabilidade, $p_3 = 0,5$, apresenta sua massa concentrada em valores maiores do que as categorias com $p_1 = 0,2$ e $p_2 = 0,3$.

A representação também evidencia uma diferença em relação aos modelos discretos univariados: a distribuição multinomial descreve simultaneamente várias contagens relacionadas pela restrição de soma.

1.8 Modelos probabilísticos contínuos

Modelos probabilísticos contínuos descrevem variáveis aleatórias cujos valores pertencem a intervalos ou outros subconjuntos contínuos da reta real. Nesse caso, as probabilidades são determinadas por áreas sob uma função de densidade, enquanto a probabilidade atribuída a qualquer valor isolado é nula.

Nesta seção, serão revisadas as distribuições uniforme, exponencial, gama, normal e beta. Para cada modelo serão apresentados o mecanismo probabilístico, o suporte, a função densidade de probabilidade, a esperança, a variância, a função geradora de momentos quando sua expressão for útil, situações que podem originar problemas inferenciais e o comportamento gráfico da densidade e da função de distribuição acumulada (Dantas, 1997; Magalhães, 2006; Meyer, 1983).

1.8.1 Distribuição uniforme contínua

A distribuição uniforme contínua descreve uma variável cujos intervalos de mesmo comprimento, contidos em determinado intervalo (a, b) , possuem a mesma probabilidade.

Uma variável aleatória X possui distribuição uniforme no intervalo (a, b) , com

$$a < b,$$

quando

$$X \sim U(a, b)$$

e sua densidade é

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{(a,b)}(x).$$

O suporte é

$$\mathcal{X} = (a, b).$$

A função de distribuição é

$$F_X(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b. \end{cases}$$

A esperança é

$$E(X) = \frac{a+b}{2},$$

e a variância é

$$\text{Var}(X) = \frac{(b-a)^2}{12}.$$

A função geradora de momentos é

$$M_X(t) = E(e^{tX}) = \frac{1}{b-a} \int_a^b e^{tx} dx.$$

Para $t \neq 0$,

$$M_X(t) = \frac{e^{bt} - e^{at}}{t(b-a)},$$

enquanto

$$M_X(0) = 1.$$

A esperança depende da posição do intervalo, enquanto a variância depende apenas de seu comprimento

$$b-a.$$

Considere um instrumento de medição cujo erro X seja representado, de forma idealizada, por uma distribuição uniforme no intervalo

$$(-\theta, \theta),$$

com $\theta > 0$.

Nesse caso,

$$X \sim U(-\theta, \theta),$$

e θ determina o limite máximo da magnitude do erro.

Ao observar erros de medição obtidos em diferentes calibrações, pode haver interesse inferencial em obter informação sobre θ e, conseqüentemente, sobre a amplitude da variação produzida pelo instrumento.

Esse exemplo também ilustra uma característica que será retomada posteriormente: o suporte da distribuição depende do parâmetro desconhecido.

i Caso de referência: uniforme com extremo desconhecido

Um caso particular que será utilizado novamente nos capítulos posteriores é

$$X \sim U(0, \theta), \quad \theta > 0.$$

Sua densidade é

$$f_X(x | \theta) = \frac{1}{\theta} \mathbf{1}_{(0, \theta)}(x),$$

e seu suporte é

$$\mathcal{X}_\theta = (0, \theta).$$

Nesse modelo,

$$E(X) = \frac{\theta}{2}$$

e

$$\text{Var}(X) = \frac{\theta^2}{12}.$$

A característica que merece atenção é que o próprio conjunto de valores admissíveis para X depende de θ . Por exemplo, se $\theta = 2$, os valores possíveis pertencem a $(0, 2)$; se $\theta = 5$, pertencem a $(0, 5)$.

Essa dependência entre suporte e parâmetro fará com que o modelo $U(0, \theta)$ tenha comportamento diferente de modelos como normal, Poisson e exponencial em alguns resultados inferenciais. Por esse motivo, ele será retomado como caso de referência ao discutir máxima verossimilhança e condições de regularidade.

A Figura 1.9 mostra separadamente os efeitos da posição e do comprimento do intervalo. As distribuições $U(-2, 2)$ e $U(0, 4)$ possuem a mesma amplitude, igual a 4, e conseqüentemente a




Figura 1.9: Função densidade de probabilidade e função de distribuição acumulada da distribuição uniforme para diferentes intervalos.

mesma altura da densidade e a mesma variância. A segunda distribuição está apenas deslocada para a direita.

Para $U(-1, 1)$, a amplitude é menor. Como a área total sob a densidade deve permanecer igual a 1, a redução do comprimento do intervalo aumenta a altura da densidade. Na função de distribuição, intervalos menores produzem um crescimento mais rápido de 0 até 1.

1.8.2 Distribuição exponencial

A distribuição exponencial é utilizada para representar tempos até a ocorrência de determinado evento em situações nas quais uma taxa de ocorrência constante constitui uma descrição adequada do mecanismo considerado.

Uma variável aleatória X possui distribuição exponencial com taxa

$$\lambda > 0$$

quando

$$X \sim \text{Exp}(\lambda)$$

e sua densidade é

$$f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x).$$

O suporte é

$$\mathcal{X} = (0, \infty).$$

A função de distribuição é

$$F_X(x) = \begin{cases} 0, & x \leq 0, \\ 1 - e^{-\lambda x}, & x > 0. \end{cases}$$

Consequentemente, para $x \geq 0$,

$$P(X > x) = e^{-\lambda x}.$$

A esperança é

$$E(X) = \frac{1}{\lambda},$$

e a variância é

$$\text{Var}(X) = \frac{1}{\lambda^2}.$$

A função geradora de momentos é

$$M_X(t) = \int_0^\infty e^{tx} \lambda e^{-\lambda x} dx.$$

Para

$$t < \lambda,$$

temos

$$M_X(t) = \frac{\lambda}{\lambda - t}.$$

O parâmetro λ é uma taxa. Seu inverso,

$$\frac{1}{\lambda},$$

corresponde ao tempo médio representado pelo modelo.

Considere uma agência bancária e seja X o tempo transcorrido entre a chegada de um cliente e o início de seu atendimento.

Se uma distribuição exponencial fornecer uma representação adequada para esses tempos,

$$X \sim \text{Exp}(\lambda),$$

em que $\lambda > 0$ é o parâmetro de taxa da distribuição.

Sob esse modelo, o tempo médio de espera é

$$E(X) = \frac{1}{\lambda}.$$

Assim, valores maiores de λ correspondem a tempos médios de espera menores, enquanto valores menores de λ correspondem a tempos médios maiores.

Ao observar os tempos de espera de vários clientes, pode haver interesse inferencial em obter informação sobre λ ou, de forma equivalente, sobre o tempo médio $1/\lambda$. Também poderia haver interesse em comparar esses tempos entre diferentes turnos, dias ou formas de organização do atendimento.

A Figura 1.10 mostra que o aumento de λ concentra a distribuição em tempos menores. Essa relação decorre de

$$E(X) = \frac{1}{\lambda}.$$

Para $\lambda = 2$, a densidade decresce rapidamente e a função de distribuição aproxima-se de 1 em valores relativamente pequenos de x . Para $\lambda = 0,5$, tempos maiores recebem probabilidade mais elevada e a função de distribuição cresce mais lentamente.

1.8.2.1 Falta de memória

A distribuição exponencial possui a propriedade de falta de memória. Para

$$s, t > 0,$$

temos

$$P(X > s + t \mid X > s) = P(X > t).$$

Assim, condicionado ao fato de que o evento ainda não ocorreu até o instante s , o tempo adicional de espera possui a mesma distribuição do tempo de espera inicialmente considerado.

Essa propriedade é a versão contínua da falta de memória apresentada para a distribuição geométrica.

i Parametrização

Nesta seção, a distribuição exponencial está parametrizada pela **taxa** λ , de modo que

$$E(X) = \frac{1}{\lambda}.$$

Quando a distribuição exponencial for parametrizada diretamente pela média, utilizaremos o símbolo




Figura 1.10: Função densidade de probabilidade e função de distribuição acumulada da distribuição exponencial para diferentes parâmetros.

$$\mu > 0,$$

escrevendo

$$X \sim \text{Exp}(\mu),$$

com

$$E(X) = \mu$$

e densidade

$$f_X(x) = \frac{1}{\mu} e^{-x/\mu} \mathbf{1}_{(0,\infty)}(x).$$

As duas parametrizações descrevem a mesma família e estão relacionadas por

$$\lambda = \frac{1}{\mu}.$$

O uso de símbolos distintos permite identificar explicitamente qual parametrização está sendo adotada em cada contexto.

1.8.3 Distribuição gama

A distribuição gama generaliza a distribuição exponencial e permite representar diferentes formas para variáveis aleatórias positivas.

Como parametrização geral, utilizaremos a **forma**

$$\alpha > 0$$

e a **escala**

$$\beta > 0.$$

Escrevemos

$$X \sim \text{Gama}(\alpha, \beta)$$

quando sua densidade é

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \mathbf{1}_{(0,\infty)}(x),$$

em que

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt$$

é a função gama.

O suporte é

$$\mathcal{X} = (0, \infty).$$

A esperança é

$$E(X) = \alpha\beta,$$

e a variância é

$$\text{Var}(X) = \alpha\beta^2.$$

A função geradora de momentos é

$$M_X(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

Quando

$$\alpha = 1,$$

a distribuição gama coincide com uma distribuição exponencial cuja média satisfaz

$$\mu = \beta.$$

Assim,

$$X \sim \text{Gama}(1, \beta)$$

é equivalente a uma variável exponencial com média $\mu = \beta$.

Considere um procedimento bancário composto por três etapas sucessivas de atendimento. Suponha que os tempos necessários para completar cada etapa possam ser representados por variáveis exponenciais independentes com a mesma taxa λ .

Se

$$X_1, X_2, X_3 \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

o tempo total

$$T = X_1 + X_2 + X_3$$

possui distribuição gama. Como nesta seção a notação $\text{Gama}(\alpha, \beta)$ foi definida na parametrização forma-escala, a taxa λ corresponde à escala

$$\beta = \frac{1}{\lambda}.$$

Portanto,

$$T \sim \text{Gama}\left(3, \frac{1}{\lambda}\right).$$

Ao observar tempos totais de atendimento de vários clientes, pode haver interesse inferencial em obter informação sobre λ e, conseqüentemente, sobre

$$E(T) = \frac{3}{\lambda}.$$

A distribuição gama permite, portanto, modelar um tempo positivo resultante da soma de vários tempos de espera.

A distribuição gama também pode ser considerada para variáveis positivas que apresentam assimetria à direita. Considere, por exemplo, o custo associado à execução de determinado procedimento, desde que as características empíricas e o mecanismo considerado sejam compatíveis com esse modelo.

Nesse caso, observações de diferentes unidades podem ser utilizadas para obter informação sobre os parâmetros que determinam a média e a dispersão da distribuição.

A Figura 1.11 permite observar separadamente os efeitos dos parâmetros de forma e escala. Para

$$\alpha = 1 \quad \text{e} \quad \beta = 1,$$

a distribuição gama coincide com uma distribuição exponencial de média 1, e sua densidade é decrescente.




Figura 1.11: Função densidade de probabilidade e função de distribuição acumulada da distribuição gama para diferentes parâmetros.

Mantendo $\beta = 1$ e aumentando α de 1 para 3, a massa da distribuição desloca-se para valores maiores e a forma da densidade deixa de ser monotonicamente decrescente. Mantendo $\alpha = 3$ e reduzindo β de 1 para 0,5, a distribuição se concentra em valores menores, resultado compatível com

$$E(X) = \alpha\beta.$$

1.8.3.1 Relação entre exponencial e gama

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

então

$$S_n = \sum_{i=1}^n X_i$$

possui distribuição gama. Como a taxa exponencial λ corresponde à escala $1/\lambda$,

$$S_n \sim \text{Gama}\left(n, \frac{1}{\lambda}\right).$$

Esse resultado pode ser obtido diretamente pelas funções geradoras de momentos. Como

$$M_{X_i}(t) = \frac{\lambda}{\lambda - t},$$

pela independência,

$$M_{S_n}(t) = \left(\frac{\lambda}{\lambda - t}\right)^n.$$

Essa é a FGM de uma distribuição gama com forma n e escala $1/\lambda$.

Consequentemente,

$$E(S_n) = \frac{n}{\lambda}$$

e

$$\text{Var}(S_n) = \frac{n}{\lambda^2}.$$

i Forma, escala e taxa

Na parametrização adotada neste livro,

$$X \sim \text{Gama}(\alpha, \beta),$$

o primeiro parâmetro α representa a **forma** e o segundo parâmetro β representa a **escala**, em concordância com a parametrização utilizada por Casella e Berger.

Quando a distribuição gama surge a partir de variáveis exponenciais parametrizadas pela taxa λ , utilizamos a relação

$$\beta = \frac{1}{\lambda}.$$

Assim,

$$X \sim \text{Gama}\left(\alpha, \frac{1}{\lambda}\right)$$

possui

$$E(X) = \frac{\alpha}{\lambda}$$

e

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

Dessa forma, a notação $\text{Gama}(\alpha, \beta)$ mantém sempre o segundo parâmetro como escala, enquanto a taxa λ pode ser utilizada nos modelos exponenciais sem ambiguidade.

1.8.4 Distribuição normal

A distribuição normal é uma família de distribuições contínuas simétricas determinada por um parâmetro de localização e outro de dispersão.

Uma variável aleatória X possui distribuição normal com média

$$\mu \in \mathbb{R}$$

e variância

$$\sigma^2 > 0$$

quando

$$X \sim N(\mu, \sigma^2)$$

e sua densidade é

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} \mathbf{1}_{\mathbb{R}}(x).$$

O suporte é

$$\mathcal{X} = \mathbb{R}.$$

A esperança é

$$E(X) = \mu,$$

e a variância é

$$\text{Var}(X) = \sigma^2.$$

O parâmetro μ determina a localização da distribuição, enquanto σ determina sua dispersão.

A densidade é simétrica em torno de μ . Consequentemente,

$$P(X \leq \mu) = \frac{1}{2}.$$

A função geradora de momentos é

$$M_X(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right), \quad t \in \mathbb{R}.$$

Considere uma máquina utilizada para envasar determinado produto. Seja X o peso de uma unidade produzida.

Se uma distribuição normal fornecer uma representação adequada para os pesos,

$$X \sim N(\mu, \sigma^2),$$

então μ representa o peso médio do processo e σ representa sua dispersão.

Uma amostra de produtos pode ser utilizada para obter informação sobre μ , sobre σ^2 ou sobre ambos. Por exemplo, pode haver interesse em avaliar se o peso médio está próximo do valor nominal especificado para o produto ou em quantificar a variabilidade do processo produtivo.

Considere X como determinada medida morfológica em indivíduos de uma população, como comprimento ou peso, em uma situação na qual a distribuição normal seja adequada.

As observações obtidas em uma amostra podem ser utilizadas para estudar a média populacional μ e a variância σ^2 dessa característica.

A Figura 1.12 mostra separadamente os efeitos dos parâmetros μ e σ . Mantendo $\sigma = 1$, a alteração de μ desloca a distribuição ao longo do eixo horizontal sem modificar sua forma. Mantendo $\mu = 0$, o aumento de σ produz maior dispersão e reduz a altura máxima da densidade.

Na função de distribuição, mudanças em μ deslocam a curva horizontalmente, enquanto valores maiores de σ tornam a transição entre probabilidades próximas de 0 e de 1 mais gradual.

1.8.4.1 Padronização

Se

$$X \sim N(\mu, \sigma^2),$$

então

$$Z = \frac{X - \mu}{\sigma}$$

possui distribuição normal padrão,

$$Z \sim N(0, 1).$$

Consequentemente,

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right),$$

em que Φ representa a função de distribuição da normal padrão.




Figura 1.12: Função densidade de probabilidade e função de distribuição acumulada da distribuição normal para diferentes parâmetros.

A transformação separa a posição e a escala da variável original e permite expressar probabilidades de qualquer distribuição normal em termos de uma única distribuição de referência.

1.8.4.2 Transformações lineares da distribuição normal

Se

$$X \sim N(\mu, \sigma^2)$$

e

$$Y = aX + b,$$

com $a \neq 0$, então

$$Y \sim N(a\mu + b, a^2\sigma^2).$$

Além disso, se

$$X_1, \dots, X_n$$

são independentes e

$$X_i \sim N(\mu_i, \sigma_i^2),$$

então, para constantes $a_1, \dots, a_n$,

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right).$$

Em particular, se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

então

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

possui distribuição

$$\overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Esse resultado será retomado no estudo das distribuições amostrais.

1.8.5 Distribuição beta

A distribuição beta forma uma família de distribuições contínuas definidas no intervalo $(0, 1)$. Seus dois parâmetros permitem representar diferentes padrões de simetria, assimetria e concentração.

Uma variável aleatória X possui distribuição beta com parâmetros

$$\alpha > 0 \quad \text{e} \quad \beta > 0$$

quando

$$X \sim \text{Beta}(\alpha, \beta)$$

e sua densidade é

$$f_X(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} \mathbf{1}_{(0,1)}(x),$$

em que

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx.$$

A função beta relaciona-se à função gama por

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

O suporte é

$$\mathcal{X} = (0, 1).$$

A esperança é

$$E(X) = \frac{\alpha}{\alpha + \beta},$$

e a variância é

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

A função geradora de momentos existe para todo

$$t \in \mathbb{R},$$

mas sua expressão geral envolve funções especiais. Como essa forma não será utilizada nos desenvolvimentos posteriores, ela não será apresentada nesta revisão.

i Valores nos extremos do intervalo

A distribuição beta apresentada nesta seção possui suporte

$$(0, 1).$$

Portanto, ela é adequada para variáveis contínuas que assumem valores estritamente entre 0 e 1.

Quando valores exatamente iguais a 0 ou 1 podem ocorrer com probabilidade positiva, a distribuição beta padrão não representa diretamente essa massa de probabilidade nos extremos. Nesses casos, pode ser necessário considerar outra especificação probabilística. Essa distinção deve ser considerada, por exemplo, ao modelar proporções que possam assumir exatamente 0% ou 100%.

Considere X como a proporção da área de uma parcela coberta por vegetação, expressa em escala de 0 a 1.

Se a distribuição beta fornecer uma representação adequada para a variação dessas proporções entre parcelas,

$$X \sim \text{Beta}(\alpha, \beta).$$

Observações realizadas em várias parcelas podem ser utilizadas para obter informação sobre α e β ou sobre quantidades derivadas desses parâmetros, como a média

$$E(X) = \frac{\alpha}{\alpha + \beta}.$$

Assim, o interesse pode estar na cobertura média da população de parcelas e na variabilidade existente entre elas.

A distribuição beta também pode ser considerada para índices contínuos naturalmente limitados ao intervalo $(0, 1)$, desde que sua forma seja compatível com os dados e com o mecanismo considerado.

Nesse contexto, diferentes combinações de α e β permitem representar distribuições simétricas ou assimétricas e diferentes níveis de concentração em determinadas regiões do intervalo.

A Figura 1.13 mostra a flexibilidade da distribuição beta. Para

$$\alpha = \beta = 2,$$

a distribuição é simétrica em torno de 0,5.

Quando

$$\alpha = 2 \quad \text{e} \quad \beta = 5,$$

a massa está concentrada em valores menores. Quando os parâmetros são invertidos,

$$\alpha = 5 \quad \text{e} \quad \beta = 2,$$

obtém-se uma distribuição espelhada, concentrada em valores maiores. Esse comportamento também aparece nas médias:

$$E(X) = \frac{2}{7}, \quad \frac{1}{2} \quad \text{e} \quad \frac{5}{7},$$

respectivamente.

1.8.5.1 Casos particulares e simetria

Quando

$$\alpha = \beta,$$

a distribuição beta é simétrica em torno de

$$\frac{1}{2}.$$




Figura 1.13: Função densidade de probabilidade e função de distribuição acumulada da distribuição beta para diferentes parâmetros.

Em particular,

$$\text{Beta}(1, 1) = \text{U}(0, 1).$$

Assim, a distribuição uniforme padrão aparece como um caso particular da família beta.

1.8.6 Relações entre gama e beta

As distribuições gama e beta estão relacionadas por transformações de variáveis aleatórias independentes.

Se

$$X \sim \text{Gama}(\alpha, \theta)$$

e

$$Y \sim \text{Gama}(\beta, \theta),$$

independentes, com o mesmo parâmetro de escala $\theta > 0$, então

$$X + Y \sim \text{Gama}(\alpha + \beta, \theta),$$

enquanto

$$\frac{X}{X + Y} \sim \text{Beta}(\alpha, \beta).$$

A primeira relação decorre diretamente da função geradora de momentos. A segunda mostra como uma variável limitada ao intervalo $(0, 1)$ pode ser construída a partir da razão entre duas variáveis gama positivas.

Essas relações serão úteis posteriormente para compreender algumas distribuições derivadas de funções de variáveis aleatórias.

1.8.7 Escolha entre alguns modelos contínuos

Os modelos contínuos apresentados correspondem a estruturas probabilísticas diferentes. A tabela resume alguns contextos que podem orientar sua interpretação.

Situação representada	Modelo possível	Característica
valores equiprováveis em um intervalo	Uniforme	densidade constante
tempo até um evento sob taxa constante	Exponencial	suporte positivo e falta de memória
soma de tempos exponenciais ou variável positiva assimétrica	Gama	suporte positivo e diferentes formas
variável aproximadamente simétrica em torno de uma média	Normal	localização e dispersão em $\mathbb{R}$
proporção ou índice contínuo em $(0, 1)$	Beta	formas flexíveis em intervalo limitado

A escolha de uma distribuição não depende apenas do suporte da variável. O mecanismo probabilístico, a forma da distribuição e as hipóteses utilizadas também precisam ser compatíveis com o fenômeno considerado.

i Distribuições derivadas do modelo normal

As distribuições qui-quadrado, t de Student e F estão relacionadas a funções de variáveis normais e gama. Elas não serão desenvolvidas nesta revisão. Sua apresentação será feita no capítulo **Distribuições Amostrais**, quando surgirem associadas a estatísticas construídas a partir de amostras normais.

1.9 Transformações de variáveis aleatórias

Transformações de variáveis aleatórias permitem construir novas variáveis a partir de variáveis cuja distribuição é conhecida.

Se

$$Y = g(X),$$

a distribuição de Y é determinada pela distribuição de X e pela transformação g .

Esse problema aparece em diferentes contextos. Uma estatística calculada a partir de observações é uma função de variáveis aleatórias, assim como muitas transformações utilizadas para alterar escala, estabilizar variância ou expressar uma quantidade de interesse de forma diferente.

Nesta revisão serão considerados o método da função de distribuição e a transformação de densidades no caso univariado. Transformações multivariadas e o determinante jacobiano serão retomados no capítulo **Resultados Matemáticos e Assintóticos para Inferência**.

1.9.1 Método da função de distribuição

Uma forma geral de determinar a distribuição de

$$Y = g(X)$$

consiste em obter sua função de distribuição:

$$F_Y(y) = P(Y \leq y).$$

Como

$$Y = g(X),$$

temos

$$F_Y(y) = P\{g(X) \leq y\}.$$

O problema é então reescrever o evento

$$\{g(X) \leq y\}$$

em termos dos valores assumidos por X .

Depois de obtida F_Y , a função de massa ou a densidade de Y pode ser determinada quando necessário.

1.9.2 Transformação monótona

Suponha que X seja absolutamente contínua e que

$$Y = g(X),$$

em que g é estritamente monótona no suporte de X . Suponha ainda que a função inversa

$$x = g^{-1}(y)$$

seja continuamente diferenciável no suporte da variável transformada.

Então, a densidade de Y é

$$f_Y(y) = f_X\{g^{-1}(y)\} \left| \frac{d}{dy} g^{-1}(y) \right|,$$

para y pertencente ao suporte da variável transformada (Casella; Berger, 2011, sec. 2.1; Rice, 2007, secs. 2.3 e 3.6; Ramachandran; Tsokos, 2021, sec. 3.4).

O termo

$$\left| \frac{d}{dy} g^{-1}(y) \right|$$

corrige a alteração de escala produzida pela transformação.

Considere

$$Y = aX + b, \quad a \neq 0.$$

A transformação inversa é

$$x = \frac{y - b}{a}.$$

Logo,

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y-b}{a}\right) \frac{1}{|a|}.$$

Se

$$X \sim N(\mu, \sigma^2),$$

essa transformação conduz a

$$Y \sim N(a\mu + b, a^2\sigma^2),$$

resultado já apresentado para a distribuição normal.

1.9.3 Exemplo de transformação entre modelos

Considere

$$X \sim U(0, 1)$$

e defina

$$Y = -\log X.$$

Como

$$0 < X < 1,$$

temos

$$Y > 0.$$

Para $y > 0$,

$$F_Y(y) = P(Y \leq y).$$

Substituindo a definição de Y ,

$$F_Y(y) = P(-\log X \leq y).$$

Como a função exponencial é crescente,

$$-\log X \leq y$$

equivale a

$$X \geq e^{-y}.$$

Portanto,

$$F_Y(y) = P(X \geq e^{-y}).$$

Como X possui distribuição uniforme em $(0, 1)$,

$$F_Y(y) = 1 - e^{-y}.$$

Para $y \leq 0$,

$$F_Y(y) = 0.$$

Assim,

$$F_Y(y) = \begin{cases} 0, & y \leq 0, \\ 1 - e^{-y}, & y > 0. \end{cases}$$

Essa é a função de distribuição de uma variável exponencial com taxa 1. Portanto,

$$-\log X \sim \text{Exp}(1).$$

O exemplo mostra que diferentes famílias probabilísticas podem estar relacionadas por transformações de variáveis aleatórias.

1.9.4 Transformações não monótonas

Quando g não é monotônica em todo o suporte de X , um mesmo valor de Y pode corresponder a mais de um valor de X .

Considere, por exemplo,

$$Y = X^2.$$

Para

$$y \geq 0,$$

temos

$$F_Y(y) = P(X^2 \leq y).$$

O evento

$$X^2 \leq y$$

equivale a

$$-\sqrt{y} \leq X \leq \sqrt{y}.$$

Logo,

$$F_Y(y) = P(-\sqrt{y} \leq X \leq \sqrt{y}).$$

Se X é contínua,

$$F_Y(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y}),$$

para

$$y \geq 0.$$

Para

$$y < 0,$$

temos

$$F_Y(y) = 0,$$

pois X^2 não pode assumir valores negativos.

A densidade de Y , quando necessária, pode ser obtida diferenciando $F_Y(y)$ em relação a y .

i Transformações multivariadas

Para transformações de vetores aleatórios, a mudança de variáveis envolve o determinante da matriz jacobiana da transformação inversa.

Esse resultado exige ferramentas de cálculo multivariado e será retomado no capítulo **Resultados Matemáticos e Assintóticos para Inferência**, quando for necessário obter distribuições de funções de vetores aleatórios.

1.9.5 Transformações em problemas inferenciais

Transformações também aparecem quando a quantidade de interesse é uma função de um parâmetro.

Por exemplo, em uma distribuição exponencial parametrizada pela taxa λ ,

$$E(X) = \frac{1}{\lambda}.$$

Um problema pode ser formulado em termos da taxa λ , enquanto outro pode ter como quantidade de interesse o tempo médio

$$\mu = \frac{1}{\lambda}.$$

Embora ambos descrevam o mesmo modelo probabilístico, a interpretação da quantidade desconhecida é diferente.

Posteriormente, métodos como a propriedade de invariância dos estimadores de máxima verossimilhança e o método delta permitirão estudar sistematicamente funções de parâmetros e de estimadores.

1.10 Quadro-síntese dos modelos probabilísticos

Os modelos apresentados ao longo deste capítulo diferem quanto ao suporte, aos parâmetros e ao mecanismo probabilístico utilizado para representar a variável observada. As tabelas seguintes reúnem suas principais características para consulta.

A escolha de uma distribuição não deve ser determinada apenas pela semelhança entre o formato de um gráfico e a forma de uma densidade ou função de massa conhecida. O suporte da variável, o mecanismo que produz os dados, as relações de dependência e o significado dos parâmetros também precisam ser considerados.

1.10.1 Modelos discretos univariados

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$
Uniforme discreta	$\{1, \dots, m\}$	m	$\frac{m+1}{2}$	$\frac{m^2-1}{12}$
Bernoulli	$\{0, 1\}$	p	p	$p(1-p)$
Binomial	$\{0, \dots, n\}$	n, p	np	$np(1-p)$
Hipergeométrica	$\{\max(0, n - N + M), \dots, \min(n, M)\}$	N, M, n	$np, p = M/N$	$np(1-p)\frac{N-n}{N-1},$ para $N > 1$; 0, para $N = 1$
Geométrica	$\{1, 2, \dots\}$	p	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Binomial negativa	$\{r, r+1, \dots\}$	r, p	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
Poisson	$\{0, 1, 2, \dots\}$	λ	λ	λ

1.10.2 Modelos contínuos univariados

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$
Uniforme	(a, b)	a, b	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponencial	$(0, \infty)$	λ	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Gama	$(0, \infty)$	α, β	$\alpha\beta$	$\alpha\beta^2$
Normal	$\mathbb{R}$	μ, σ^2	μ	σ^2
Beta	$(0, 1)$	α, β	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

1.10.3 Funções geradoras de momentos

As funções geradoras de momentos apresentadas no capítulo podem ser reunidas em uma tabela de referência.

Distribuição	$M_X(t)$	Condição
Uniforme discreta em $\{1, \dots, m\}$	$\frac{1}{m} \sum_{x=1}^m e^{tx}$	$t \in \mathbb{R}$
Bernoulli(p)	$1 - p + pe^t$	$t \in \mathbb{R}$
Binomial(n, p)	$(1 - p + pe^t)^n$	$t \in \mathbb{R}$
Hipergeométrica(N, M, n)	$\sum_{x \in \mathcal{X}} e^{tx} p_X(x)$	$t \in \mathbb{R}$
Geométrica(p)	$\frac{pe^t}{1 - (1-p)e^t}$	$t < -\log(1-p)$
Binomial negativa(r, p)	$\left[\frac{pe^t}{1 - (1-p)e^t} \right]^r$	$t < -\log(1-p)$
Poisson(λ)	$\exp\{\lambda(e^t - 1)\}$	$t \in \mathbb{R}$
Uniforme(a, b)	$\frac{e^{bt} - e^{at}}{t(b-a)}$	$t \neq 0; M_X(0) = 1$
Exponencial(λ)	$\frac{\lambda}{\lambda - t}$	$t < \lambda$
Gama(α, β)	$(1 - \beta t)^{-\alpha}$	$t < 1/\beta$
Normal(μ, σ^2)	$\exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$	$t \in \mathbb{R}$

A distribuição beta não aparece nessa tabela porque sua função geradora de momentos, embora exista para todo $t \in \mathbb{R}$, envolve uma função especial que não será utilizada nos capítulos seguintes.

1.11 Relações entre os principais modelos

As relações desenvolvidas ao longo do capítulo podem ser reunidas em um mapa de referência. Elas decorrem de diferentes mecanismos: soma de variáveis independentes, mudança no esquema de amostragem, generalização de um modelo, transformação ou passagem ao limite.

1.11.1 Modelos discretos

Um ensaio Bernoulli representa um único resultado binário,

$$X_i \sim \text{Ber}(p).$$

A soma de ensaios Bernoulli independentes com a mesma probabilidade de sucesso produz a distribuição binomial:

$$\boxed{\text{Ber}(p) \xrightarrow{\text{soma de } n \text{ ensaios}} \text{Binom}(n, p)}$$

Quando a contagem de sucessos é realizada em uma amostra retirada sem reposição de uma população finita, o mecanismo muda:

$$\boxed{\text{contagem de sucessos sem reposição} \longrightarrow \text{Hiper}(N, M, n)}$$

A distribuição geométrica representa o número de ensaios até o primeiro sucesso, enquanto a binomial negativa estende esse mecanismo até o r -ésimo sucesso:

$$\boxed{\text{Geo}(p) = \text{BN}(1, p)}$$

e, de forma mais geral,

$$\boxed{\text{Geo}(p) \xrightarrow{r \text{ sucessos}} \text{BN}(r, p)}.$$

A distribuição de Poisson pode surgir como limite de distribuições binomiais quando o número de ensaios cresce, a probabilidade individual de sucesso diminui e o número esperado de sucessos converge para λ :

$$\boxed{\text{Binom}(n, p_n) \xrightarrow{n \rightarrow \infty, p_n \rightarrow 0, np_n \rightarrow \lambda} \text{Poisson}(\lambda)}.$$

A distribuição multinomial estende a estrutura binomial de duas categorias para m categorias:

$$\boxed{\text{Binom} \xrightarrow{\text{mais de duas categorias}} \text{Multinomial} .}$$

1.11.2 Modelos contínuos

Na relação entre a distribuição exponencial e a distribuição gama, lembramos que uma exponencial com taxa λ corresponde a uma gama com forma 1 e escala $1/\lambda$:

$$\text{Exp}(\lambda) = \text{Gama}\left(1, \frac{1}{\lambda}\right).$$

Além disso, a soma de variáveis exponenciais independentes com a mesma taxa produz uma variável gama:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda) \implies \sum_{i=1}^n X_i \sim \text{Gama}\left(n, \frac{1}{\lambda}\right).$$

A distribuição uniforme padrão é um caso particular da família beta:

$$\text{U}(0, 1) = \text{Beta}(1, 1).$$

Se

$$X \sim \text{Gama}(\alpha, \theta)$$

e

$$Y \sim \text{Gama}(\beta, \theta)$$

são independentes e possuem o mesmo parâmetro de escala $\theta > 0$, então

$$X + Y \sim \text{Gama}(\alpha + \beta, \theta)$$

e

$$\frac{X}{X + Y} \sim \text{Beta}(\alpha, \beta).$$

1.11.3 Leitura do mapa

As relações anteriores possuem naturezas diferentes:

Relação	Mecanismo
Bernoulli $\rightarrow$ Binomial	soma de ensaios independentes
Binomial $\leftrightarrow$ Hipergeométrica	alteração do mecanismo de amostragem
Geométrica $\rightarrow$ Binomial negativa	extensão do número de sucessos
Binomial $\rightarrow$ Poisson	resultado limite
Binomial $\rightarrow$ Multinomial	generalização do número de categorias
Exponencial $\rightarrow$ Gama	caso particular e soma de variáveis independentes
Uniforme $\rightarrow$ Beta	caso particular
Gama $\rightarrow$ Beta	transformação de variáveis independentes

O mapa mostra que os modelos probabilísticos não constituem uma coleção isolada de fórmulas. Suas relações decorrem dos mecanismos utilizados para produzir, combinar ou transformar variáveis aleatórias.

1.12 Síntese

O conteúdo deste capítulo pode ser organizado em seis componentes.

O primeiro corresponde à **estrutura básica da Probabilidade**. Eventos, probabilidade condicional, lei da probabilidade total, teorema de Bayes e independência permitem descrever relações entre acontecimentos aleatórios e incorporar informações condicionais.

O segundo reúne **variáveis aleatórias e suas distribuições**. A função de distribuição caracteriza a distribuição de uma variável aleatória, enquanto a função de massa de probabilidade e a densidade descrevem, respectivamente, variáveis discretas e absolutamente contínuas. O suporte, representado por $\mathcal{X}$ para uma variável X , identifica os valores admissíveis sob a distribuição considerada. A função indicadora permite incorporar esse suporte diretamente às expressões probabilísticas e também representar contagens e proporções.

O terceiro corresponde a **esperança, variância e momentos**. Essas quantidades descrevem características da distribuição de uma variável aleatória e permitem estudar transformações lineares, somas e combinações de variáveis.

O quarto reúne **distribuições conjuntas e dependência**. Distribuições marginais e condicionais descrevem diferentes aspectos de uma distribuição conjunta, enquanto covariância e correlação quantificam formas de associação. A independência estabelece uma condição probabilística mais forte e, quando várias variáveis são simultaneamente independentes e possuem a

mesma distribuição, obtém-se a estrutura i.i.d., que será utilizada posteriormente na definição usual de amostras aleatórias. Esperança e variância condicionais também permitem decompor momentos por meio das leis da esperança total e da variância total.

O quinto componente corresponde à **função geradora de momentos e às transformações de variáveis aleatórias**. Quando existe em uma vizinhança de zero, a função geradora de momentos permite obter momentos, identificar distribuições e estudar somas de variáveis independentes. As transformações permitem determinar a distribuição de novas variáveis construídas a partir de variáveis com distribuição conhecida.

O sexto reúne os **modelos probabilísticos** apresentados no capítulo. As distribuições uniforme discreta, Bernoulli, binomial, hipergeométrica, geométrica, binomial negativa, Poisson, uniforme contínua, exponencial, gama, normal, beta e multinomial representam diferentes mecanismos probabilísticos. Sua utilização depende do tipo de variável, de seu suporte, do mecanismo que produz os dados e da interpretação de seus parâmetros.

As situações inferenciais apresentadas ao longo do capítulo mostram como parâmetros desses modelos podem representar quantidades de interesse em problemas posteriores. Por exemplo:

- em um modelo Bernoulli ou binomial, p pode representar uma proporção populacional;
- em um modelo hipergeométrico, M pode representar uma quantidade desconhecida de unidades com determinada característica em uma população finita;
- em um modelo Poisson, λ representa o número esperado de ocorrências na exposição considerada e, quando $\lambda = \rho t$, ρ representa a taxa média por unidade de exposição;
- em um modelo exponencial parametrizado pela taxa λ , $1/\lambda$ representa o valor esperado da variável, podendo corresponder, por exemplo, a um tempo médio; quando a parametrização utiliza diretamente a média, essa quantidade é representada por μ ;
- em um modelo normal, μ e σ^2 descrevem localização e variabilidade;
- em um modelo multinomial, $p_1, \dots, p_m$ descrevem as probabilidades associadas às diferentes categorias.

Até este ponto, a direção predominante foi partir de um modelo probabilístico e estudar suas consequências:

modelo probabilístico $\longrightarrow$ comportamento das variáveis aleatórias.

Na Inferência Estatística, a questão será diferente. Os dados serão observados, enquanto uma ou mais características do modelo que os produziu serão desconhecidas. A direção do problema passa, então, a ser

dados observados $\longrightarrow$ informação sobre quantidades desconhecidas do modelo.

Essa passagem exigirá conceitos como população, parâmetro, amostra, estatística, estimador, modelo estatístico e verossimilhança. Antes de introduzi-los formalmente, o próximo capítulo reúne as ferramentas matemáticas e assintóticas utilizadas nos desenvolvimentos posteriores. Em seguida, o capítulo **Fundamentos da Inferência Estatística** formulará propriamente o problema inferencial.

1.13 Exercícios de consolidação

Exercício 1

Considere eventos A e B tais que $P(A) = 0,4$, $P(B) = 0,5$ e $P(A \cap B) = 0,2$.

- Calcule $P(A | B)$ e $P(B | A)$.
- Verifique se A e B são independentes.
- Explique a diferença entre **eventos independentes** e **eventos mutuamente exclusivos**.
- Mostre que dois eventos mutuamente exclusivos com probabilidades positivas não podem ser independentes.

Exercício 2

Uma condição ocorre em 1% de determinada população. Um teste apresenta sensibilidade de 90% e especificidade de 95%.

Calcule a probabilidade de uma pessoa apresentar a condição dado que recebeu resultado positivo no teste.

Identifique, no cálculo, o papel da prevalência da condição, da sensibilidade e da especificidade.

Exercício 3

Para cada situação abaixo:

- defina a variável aleatória;
- indique seu suporte $\mathcal{X}$;
- proponha uma distribuição probabilística plausível entre as estudadas neste capítulo;
- identifique o significado dos parâmetros;
- indique a característica do mecanismo que sustenta a escolha do modelo.

Considere:

- a. presença ou ausência de determinada característica em uma unidade selecionada;
- b. número de unidades com essa característica entre 50 observações independentes;
- c. número de unidades com a característica em uma amostra retirada sem reposição de uma população finita;
- d. número de chamadas recebidas por uma central durante uma hora;
- e. número de tentativas necessárias até o primeiro sucesso;
- f. número de tentativas necessárias até o quinto sucesso;
- g. tempo de espera até a ocorrência de determinado evento, admitindo uma taxa constante;
- h. duração total de várias etapas positivas e independentes com a mesma taxa;
- i. medida contínua aproximadamente simétrica em torno de um valor de localização;
- j. proporção contínua que assume valores estritamente entre 0 e 1.

Em cada caso, a distribuição proposta deve ser entendida como um modelo plausível, cuja adequação dependeria do fenômeno observado.

Exercício 4

Considere $X \sim \text{Uniforme}(0, \theta)$, com $\theta > 0$.

- a. Escreva o suporte de X utilizando a notação $\mathcal{X}_\theta$.
- b. Determine $E(X)$ e $\text{Var}(X)$.
- c. Explique como o suporte se modifica quando θ varia.
- d. Suponha que tenha sido observado um valor $x_0 > 0$. Quais valores de θ são incompatíveis com essa observação? Justifique.

O objetivo é reconhecer uma característica particular desse modelo: o suporte depende do parâmetro.

i Exercício 5

Considere duas formas de retirar 20 bolas de uma urna contendo 100 bolas, das quais 30 são vermelhas:

1. cada bola retirada é devolvida à urna antes da retirada seguinte;
2. as bolas são retiradas sem reposição.

Defina X como o número de bolas vermelhas observadas.

- a. Especifique a distribuição de X em cada mecanismo.
- b. Compare $E(X)$ nos dois casos.
- c. Compare $\text{Var}(X)$ nos dois casos.
- d. Explique a origem da diferença entre as variâncias.
- e. Relacione essa diferença à independência, ou não, das retiradas.

i Exercício 6

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

- a. Explique separadamente o significado de **independentes** e **identicamente distribuídas**.
- b. Explique por que a condição i.i.d. não significa que $X_1 = \dots = X_n$.
- c. Suponha que a distribuição comum seja absolutamente contínua, com densidade f_X . Escreva a densidade conjunta de $(X_1, \dots, X_n)$.
- d. Suponha ainda que $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$, para todo i , e defina

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Obtenha $E(\bar{X}_n)$ e $\text{Var}(\bar{X}_n)$.

- e. Explique por que a estrutura i.i.d. será particularmente útil quando forem estudadas amostras aleatórias.

i Exercício 7

Considere a função de massa de probabilidade conjunta:

X	$Y = 0$	$Y = 1$
0	0,10	0,20
1	0,30	0,40

- Identifique o suporte conjunto de (X, Y) e os suportes marginais de X e Y .
- Obtenha as funções de massa marginais de X e Y .
- Calcule $P(X = 1 \mid Y = 1)$.
- Verifique se X e Y são independentes.
- Calcule $E(X)$, $E(Y)$ e $E(XY)$.
- Determine $\text{Cov}(X, Y)$.

i Exercício 8

Considere uma variável Y que assume os valores 0 e 1, com $P(Y = 1) = p$. Suponha que

$$E(X \mid Y = 0) = \mu_0, \quad E(X \mid Y = 1) = \mu_1$$

e

$$\text{Var}(X \mid Y = 0) = \sigma_0^2, \quad \text{Var}(X \mid Y = 1) = \sigma_1^2.$$

- Utilize a lei da esperança total para obter $E(X)$.
- Utilize a lei da variância total para obter $\text{Var}(X)$.
- Mostre que

$$\text{Var}(X) = (1 - p)\sigma_0^2 + p\sigma_1^2 + p(1 - p)(\mu_1 - \mu_0)^2.$$

- Interprete as duas fontes de variabilidade presentes nessa decomposição.

i Exercício 9

Mostre que, se X e Y são independentes e possuem segundos momentos finitos, então $\text{Cov}(X, Y) = 0$.

A recíproca é verdadeira? Apresente um exemplo de duas variáveis aleatórias com covariância zero que não sejam independentes.

i Exercício 10

Considere

$$(X_1, X_2, X_3) \sim \text{Multinomial}(20; 0,2, 0,3, 0,5).$$

- Obtenha $E(X_1)$, $E(X_2)$ e $E(X_3)$.
- Determine $\text{Var}(X_1)$, $\text{Var}(X_2)$ e $\text{Var}(X_3)$.
- Calcule $\text{Cov}(X_1, X_2)$.
- Determine a distribuição marginal de X_3 .
- Explique por que X_1 , X_2 e X_3 não são independentes.
- Relacione essa dependência à restrição $X_1 + X_2 + X_3 = 20$.

i Exercício 11

Efetue os seguintes cálculos utilizando as propriedades das distribuições estudadas no capítulo.

- Se $X \sim \text{Binom}(20, 0,3)$, obtenha $E(X)$, $\text{Var}(X)$ e $P(X \leq 4)$.
- Se $Y \sim \text{Poisson}(4)$, obtenha $P(Y = 0)$ e $P(Y > 5)$.
- Se $Z \sim N(100, 15^2)$, obtenha $P(85 < Z < 115)$ e o valor c tal que $P(Z \leq c) = 0,975$.

i Exercício 12

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

- Obtenha a função geradora de momentos de X_i .
- Utilize a função geradora de momentos para recuperar $E(X_i)$ e $\text{Var}(X_i)$.

- c. Defina $S_n = \sum_{i=1}^n X_i$. Utilize funções geradoras de momentos para identificar a distribuição de S_n .
- d. Mostre que $S_n/n = \bar{X}_n$ representa a proporção de sucessos.
- e. Obtenha $E(S_n/n)$ e $\text{Var}(S_n/n)$.

Esse resultado será retomado posteriormente no estudo da proporção amostral.

i Exercício 13

Utilize funções geradoras de momentos para estabelecer as seguintes relações.

- a. Se $X_1, \dots, X_k$ são independentes e $X_i \sim \text{Poisson}(\lambda_i)$, identifique a distribuição de

$$S = \sum_{i=1}^k X_i.$$

- b. Se

$$Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

identifique a distribuição de $T_n = \sum_{i=1}^n Y_i$.

- c. No item anterior, obtenha $E(T_n)$ e $\text{Var}(T_n)$.
- d. Compare os resultados dos itens (a) e (b): em ambos os casos estamos somando variáveis independentes, mas a família da distribuição resultante se comporta da mesma forma? Explique.
- e. Indique o papel da independência na propriedade multiplicativa das funções geradoras de momentos.

i Exercício 14

Considere $X \sim \text{Exp}(\lambda)$ e $Y = cX$, com $c > 0$.

- a. Determine o suporte $\mathcal{Y}$ de Y .
- b. Obtenha a função de distribuição de Y .
- c. Obtenha a densidade de Y pelo método da transformação.

d. Identifique a distribuição resultante e seu parâmetro.

i Exercício 15

Considere $X \sim N(0, 1)$ e defina $Y = X^2$.

- Determine o suporte $\mathcal{Y}$ de Y .
- Para $y > 0$, escreva o evento $\{Y \leq y\}$ em termos de X .
- Obtenha a função de distribuição de Y .
- Diferencie a expressão obtida para encontrar sua densidade.

A distribuição resultante será identificada posteriormente no estudo das distribuições amostrais associadas ao modelo normal.

i Exercício 16

Escolha uma situação aplicada de uma área de interesse e formule um modelo probabilístico para uma variável observável.

Em sua resposta:

- defina claramente a variável aleatória X ;
- indique seu suporte $\mathcal{X}$;
- proponha uma distribuição probabilística;
- descreva o mecanismo que justifica a escolha dessa distribuição;
- interprete os parâmetros do modelo no contexto do problema;
- indique qual parâmetro ou função dos parâmetros poderia constituir uma quantidade desconhecida de interesse;
- se várias observações da variável fossem obtidas, discuta se a hipótese de que sejam independentes e identicamente distribuídas seria plausível e justifique.

O objetivo é formular e interpretar a estrutura probabilística do problema. Os procedimentos utilizados para obter informação sobre as quantidades desconhecidas a partir dos dados serão desenvolvidos nos capítulos de Inferência Estatística.

2 Resultados Matemáticos e Assintóticos para Inferência

Este capítulo reúne ferramentas matemáticas e assintóticas que podem ser utilizadas nos desenvolvimentos posteriores de Inferência Estatística. O objetivo é estabelecer uma notação comum e registrar resultados de cálculo, álgebra linear e teoria assintótica importantes no estudo de distribuições amostrais, propriedades de estimadores, métodos de estimação, intervalos de confiança e testes de hipóteses (Rice, 2007, caps. 1–6; Ramachandran; Tsokos, 2021, caps. 2–4; Lauritzen, 2023, ap. A).

Os conceitos e modelos probabilísticos foram apresentados no capítulo anterior. Aqui, a atenção se concentra em duas classes de ferramentas. A primeira permite manipular funções, vetores, matrizes e transformações. A segunda permite estudar o comportamento de sequências de variáveis aleatórias quando o tamanho da amostra aumenta.

Delimitação do capítulo

Os resultados apresentados neste capítulo podem ser utilizados como ferramentas. O objetivo não é desenvolver novamente conteúdos de Cálculo ou Álgebra Linear nem apresentar demonstrações dos resultados assintóticos.

A Lei dos Grandes Números e o Teorema Central do Limite serão enunciados e interpretados aqui. Suas consequências para distribuições de estatísticas serão desenvolvidas no capítulo **Distribuições Amostrais**.

O método delta e sua versão multivariada também são estabelecidos neste capítulo como **Aprofundamento**. Esses resultados serão aplicados posteriormente nos desenvolvimentos inferenciais correspondentes.

2.1 Mapa de dependências

Ferramenta	Utilização posterior
Somatórios, produtos e logaritmos	verossimilhança, função escore e métodos de estimação

Ferramenta	Utilização posterior
Vetores e matrizes	parâmetros vetoriais, matrizes de covariâncias, informação de Fisher e modelos lineares
Diferenciação	otimização, função escore e informação observada
Expansões de Taylor	aproximações, método delta e resultados assintóticos
Formas quadráticas	distribuições associadas ao modelo normal, mínimos quadrados e estatísticas inferenciais
Projeções	mínimos quadrados e decomposição da variabilidade
Transformações multivariadas e jacobiano	obtenção de distribuições e reparametrizações
Modos de convergência	consistência e aproximações assintóticas
Lei dos Grandes Números	médias e momentos amostrais, consistência
Teorema Central do Limite	aproximações normais e normalidade assintótica
Mapeamento contínuo e Slutsky	transformação e combinação de sequências convergentes
Método delta	distribuições assintóticas de funções — Aprofundamento
Ordens estocásticas	representação da magnitude de erros e termos de aproximação

2.2 Ferramentas matemáticas

2.2.1 Somatórios, produtos e logaritmos

Para uma sequência $a_1, \dots, a_n$, utilizaremos

$$\sum_{i=1}^n a_i = a_1 + \dots + a_n$$

e

$$\prod_{i=1}^n a_i = a_1 \cdots a_n.$$

A linearidade dos somatórios permite escrever

$$\sum_{i=1}^n (ax_i + by_i) = a \sum_{i=1}^n x_i + b \sum_{i=1}^n y_i,$$

para constantes a e b .

A média aritmética de $x_1, \dots, x_n$ será representada por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Duas identidades serão utilizadas repetidamente:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

e

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - a)^2.$$

A transformação logarítmica converte produtos em somas:

$$\log \left(\prod_{i=1}^n a_i \right) = \sum_{i=1}^n \log a_i, \quad a_i > 0.$$

Também utilizaremos $\log(a^b) = b \log a$.

Essas identidades serão particularmente úteis quando uma função construída como produto puder ser estudada por meio de sua transformação logarítmica.

Considere

$$L(\theta) = \prod_{i=1}^n \theta e^{-\theta x_i}, \quad \theta > 0.$$

O produto pode ser escrito como

$$L(\theta) = \theta^n \exp \left(-\theta \sum_{i=1}^n x_i \right).$$

Aplicando o logaritmo,

$$\log L(\theta) = n \log \theta - \theta \sum_{i=1}^n x_i.$$

A transformação preserva a informação contida em $L(\theta)$ e produz uma expressão mais simples para diferenciação.

2.2.2 Vetores e matrizes

Um vetor coluna em $\mathbb{R}^k$ será representado por

$$\mathbf{x} = (x_1, \dots, x_k)^\top.$$

Seu transposto é $\mathbf{x}^\top = (x_1, \dots, x_k)$.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^k$, o produto interno é

$$\mathbf{x}^\top \mathbf{y} = \sum_{j=1}^k x_j y_j,$$

e a norma euclidiana é

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}}.$$

2.2.2.1 Matrizes

Uma matriz com m linhas e k colunas será representada por $\mathbf{A} = [a_{ij}] \in \mathbb{R}^{m \times k}$.

Sua transposta $\mathbf{A}^\top$ possui dimensão $k \times m$ e satisfaz

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

A matriz identidade de ordem k será representada por $\mathbf{I}_k$, ou simplesmente $\mathbf{I}$ quando sua dimensão estiver clara.

Uma matriz quadrada $\mathbf{A}$ é **simétrica** quando $\mathbf{A}^\top = \mathbf{A}$.

O **determinante**, representado por $\det(\mathbf{A})$, é um escalar associado a uma matriz quadrada. Uma matriz é invertível se, e somente se,

$$\det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível, existe $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}.$$

Além disso,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

O **posto** de uma matriz corresponde ao número máximo de colunas, ou equivalentemente de linhas, linearmente independentes.

Se $\mathbf{X} \in \mathbb{R}^{n \times p}$ possui posto p , suas colunas são linearmente independentes. Quando $n \geq p$, a matriz $\mathbf{X}^T \mathbf{X}$ é então invertível.

Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}.$$

A matriz é simétrica e

$$\det(\mathbf{A}) = 2(3) - 1(1) = 5.$$

Como o determinante é diferente de zero, $\mathbf{A}$ é invertível. Sua inversa é

$$\mathbf{A}^{-1} = \frac{1}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix}.$$

2.2.3 Diferenciação

Diversos procedimentos posteriores envolverão a maximização ou minimização de funções.

Para uma função real diferenciável g , todo ponto interior x_0 em que g apresente um extremo local satisfaz

$$g'(x_0) = 0.$$

Se, além disso, a segunda derivada existe em x_0 , então:

- se $g''(x_0) < 0$, o ponto corresponde a um máximo local;
- se $g''(x_0) > 0$, o ponto corresponde a um mínimo local;
- se $g''(x_0) = 0$, o teste da segunda derivada é inconclusivo.

2.2.3.1 Gradiente e hessiana

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

as derivadas de primeira ordem são reunidas no **gradiente**,

$$\nabla g(\theta) = \begin{pmatrix} \frac{\partial g}{\partial \theta_1} \\ \vdots \\ \frac{\partial g}{\partial \theta_k} \end{pmatrix}.$$

As derivadas de segunda ordem formam a **matriz hessiana**,

$$\nabla^2 g(\theta) = \left[\frac{\partial^2 g}{\partial \theta_i \partial \theta_j} \right]_{i,j=1}^k.$$

2.2.3.2 Matriz jacobiana

Para uma função vetorial

$$g : \mathbb{R}^k \longrightarrow \mathbb{R}^m,$$

com componentes $g_1, \dots, g_m$, a **matriz jacobiana** é

$$Dg(\mathbf{x}) = \left[\frac{\partial g_i(\mathbf{x})}{\partial x_j} \right]_{\substack{i=1,\dots,m \\ j=1,\dots,k}}.$$

Quando $m = 1$, a matriz jacobiana corresponde ao transposto do gradiente, de acordo com a convenção adotada.

O gradiente, a hessiana e a jacobiana aparecerão em contextos diferentes ao longo do livro:

- o gradiente será utilizado na diferenciação de funções escalares;
- a hessiana será utilizada em aproximações de segunda ordem;
- a jacobiana será utilizada em transformações vetoriais e no método delta multivariado.

Considere

$$g(\theta_1, \theta_2) = \theta_1^2 + \theta_1\theta_2 + 2\theta_2^2.$$

O gradiente é

$$\nabla g(\theta_1, \theta_2) = \begin{pmatrix} 2\theta_1 + \theta_2 \\ \theta_1 + 4\theta_2 \end{pmatrix},$$

e a hessiana é

$$\nabla^2 g(\theta_1, \theta_2) = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}.$$

2.2.4 Fórmula de Taylor

A fórmula de Taylor permite aproximar uma função em torno de um ponto conhecido. Essa ferramenta será utilizada posteriormente para estudar funções de estatísticas e para construir aproximações locais.

Se g é diferenciável em uma vizinhança de a , a aproximação de primeira ordem é

$$g(x) = g(a) + g'(a)(x - a) + o(|x - a|), \quad x \rightarrow a.$$

A notação $r(x) = o(|x - a|)$ significa que

$$\frac{r(x)}{|x - a|} \rightarrow 0$$

quando $x \rightarrow a$.

Quando g possui duas derivadas contínuas, a aproximação de segunda ordem pode ser escrita como

$$g(x) = g(a) + g'(a)(x - a) + \frac{1}{2}g''(a)(x - a)^2 + o\{(x - a)^2\}.$$

Considere $g(x) = \log x$. Em torno de $a = 1$, temos $g(1) = 0$ e $g'(1) = 1$.

Assim,

$$\log x = (x - 1) + o(|x - 1|), \quad x \rightarrow 1.$$

Para valores próximos de 1, podemos utilizar

$$\log x \approx x - 1.$$

Por exemplo, para $x = 1,05$, a aproximação fornece 0,05, enquanto $\log(1,05) \approx 0,0488$.

A aproximação linear pode ser comparada graficamente com a função original.

A Figura 2.1 mostra que a aproximação linear coincide com a função no ponto $x = 1$ e acompanha seu comportamento em uma vizinhança desse ponto. À medida que x se afasta de 1, a diferença entre a função e sua aproximação aumenta.

Esse caráter **local** da aproximação será utilizado nos resultados assintóticos: quando uma sequência de quantidades aleatórias se aproxima de determinado valor, uma função dessas quantidades pode ser aproximada por sua expansão de Taylor em torno do valor limite.

Aproximação de Taylor de primeira ordem




Figura 2.1: Função logarítmica e sua aproximação de Taylor de primeira ordem em torno de $a = 1$.

2.2.4.1 Taylor em várias dimensões

Se $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ é diferenciável em ξ , então

$$g(\mathbf{x}) = g(\xi) + Dg(\xi)(\mathbf{x} - \xi) + o(\|\mathbf{x} - \xi\|), \quad \mathbf{x} \rightarrow \xi.$$

Quando $g : \mathbb{R}^k \rightarrow \mathbb{R}$, a aproximação de primeira ordem pode ser escrita como

$$g(\mathbf{x}) = g(\xi) + \nabla g(\xi)^\top (\mathbf{x} - \xi) + o(\|\mathbf{x} - \xi\|), \quad \mathbf{x} \rightarrow \xi.$$

Se g possui derivadas de segunda ordem contínuas em uma vizinhança de ξ , a aproximação de segunda ordem utiliza a hessiana:

$$g(\mathbf{x}) \approx g(\xi) + \nabla g(\xi)^\top (\mathbf{x} - \xi) + \frac{1}{2}(\mathbf{x} - \xi)^\top \nabla^2 g(\xi)(\mathbf{x} - \xi).$$

2.2.5 Formas quadráticas

Para uma matriz simétrica $\mathbf{A} \in \mathbb{R}^{k \times k}$ e um vetor $\mathbf{x} \in \mathbb{R}^k$, a expressão

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

é denominada **forma quadrática**.

A matriz $\mathbf{A}$ é **positiva semidefinida** quando $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$ para todo $\mathbf{x}$.

Ela é **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Analogamente, $\mathbf{A}$ é **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Uma matriz simétrica é **indefinida** quando sua forma quadrática assume valores positivos para alguns vetores não nulos e valores negativos para outros.

Matrizes de covariâncias são positivas semidefinidas. Formas quadráticas também serão utilizadas na representação de somas de quadrados e em resultados associados ao modelo normal.

Quando $\mathbf{A} = \mathbf{I}$,

$$\mathbf{x}^T \mathbf{x} = \sum_{j=1}^k x_j^2.$$

Assim, para $\mathbf{x} = (2, -1, 3)^T$,

$$\mathbf{x}^T \mathbf{x} = 2^2 + (-1)^2 + 3^2 = 14.$$

2.2.5.1 Critério de segunda ordem

Considere uma função $g : \mathbb{R}^k \rightarrow \mathbb{R}$ com derivadas de segunda ordem contínuas em uma vizinhança de θ_0 e suponha que

$$\nabla g(\theta_0) = \mathbf{0}.$$

A matriz hessiana permite classificar o comportamento local da função:

- se $\nabla^2 g(\theta_0)$ é positiva definida, θ_0 é um mínimo local;
- se $\nabla^2 g(\theta_0)$ é negativa definida, θ_0 é um máximo local;
- se $\nabla^2 g(\theta_0)$ é indefinida, θ_0 é um ponto de sela;
- se $\nabla^2 g(\theta_0)$ é apenas positiva ou negativa semidefinida, sem ser definida, o critério de segunda ordem pode ser inconclusivo.

Esse critério será utilizado posteriormente na análise de funções que precisam ser maximizadas ou minimizadas.

2.2.6 Projeções

Uma matriz $\mathbf{P}$ é uma matriz de **projeção ortogonal** quando

$$\mathbf{P}^T = \mathbf{P} \quad \text{e} \quad \mathbf{P}^2 = \mathbf{P}.$$

Considere $\mathbf{X} \in \mathbb{R}^{n \times p}$ com posto completo nas colunas. A matriz

$$\mathbf{P}_{\mathbf{X}} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

projeta vetores de $\mathbb{R}^n$ sobre o espaço coluna de $\mathbf{X}$.

Para $\mathbf{y} \in \mathbb{R}^n$, definimos

$$\hat{\mathbf{y}} = \mathbf{P}_{\mathbf{X}}\mathbf{y}$$

e

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

O vetor $\hat{\mathbf{y}}$ pertence ao espaço coluna de $\mathbf{X}$, enquanto $\mathbf{e}$ é ortogonal a esse espaço. Em particular,

$$\mathbf{X}^T \mathbf{e} = \mathbf{0}.$$

Essa decomposição será utilizada posteriormente no método de mínimos quadrados (Lauritzen, 2023, ap. A.1; Rice, 2007, secs. 14.3–14.4).

Considere

$$\mathbf{y} = \begin{pmatrix} 1 \\ 2 \\ 6 \end{pmatrix}$$

e

$$\mathbf{X} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Nesse caso,

$$\mathbf{P}_{\mathbf{X}} = \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}.$$

A projeção é

$$\hat{\mathbf{y}} = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix},$$

pois 3 é a média dos elementos de $\mathbf{y}$.

O vetor residual é

$$\mathbf{e} = \begin{pmatrix} -2 \\ -1 \\ 3 \end{pmatrix},$$

e seus elementos somam zero. Essa é a forma mais simples da decomposição que aparecerá posteriormente em mínimos quadrados.

A interpretação geométrica da projeção pode ser visualizada na Figura 2.2.




Figura 2.2: Representação geométrica de uma projeção ortogonal: o vetor $\mathbf{y}$ é decomposto em sua projeção sobre um subespaço e em um resíduo ortogonal.

A Figura 2.2 representa geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

O vetor $\hat{\mathbf{y}}$ pertence ao espaço sobre o qual $\mathbf{y}$ é projetado, enquanto o resíduo $\mathbf{e}$ é ortogonal a esse espaço.

2.2.7 Transformações multivariadas e jacobiano

O capítulo anterior apresentou transformações de uma variável aleatória. Para vetores aleatórios, a mudança de variáveis requer considerar simultaneamente a transformação e a alteração de volume que ela produz.

Considere um vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top$$

com suporte $\mathcal{X} \subseteq \mathbb{R}^k$ e densidade conjunta $f_{\mathbf{X}}$.

Seja

$$\mathbf{Y} = g(\mathbf{X}),$$

em que $g : \mathcal{X} \rightarrow \mathcal{Y}$ é uma transformação bijetiva e diferenciável no domínio considerado, com inversa diferenciável

$$\mathbf{X} = h(\mathbf{Y}).$$

Admitiremos que o determinante jacobiano da transformação inversa seja diferente de zero nos pontos considerados.

O suporte transformado é

$$\mathcal{Y} = g(\mathcal{X}).$$

A densidade conjunta de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\{h(\mathbf{y})\} |\det Dh(\mathbf{y})|, \quad \mathbf{y} \in \mathcal{Y}.$$

O fator

$$|\det Dh(\mathbf{y})|$$

é o valor absoluto do **determinante jacobiano da transformação inversa**. Ele ajusta a densidade à alteração de escala ou volume produzida pela transformação.

2.2.7.1 Transformação linear

Considere a transformação

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que $\mathbf{A} \in \mathbb{R}^{k \times k}$ é invertível e $\mathbf{b} \in \mathbb{R}^k$.

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

Nesse caso,

$$Dh(\mathbf{y}) = \mathbf{A}^{-1},$$

e, portanto,

$$|\det Dh(\mathbf{y})| = \frac{1}{|\det(\mathbf{A})|}.$$

Consequentemente,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\{\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})\} \frac{1}{|\det(\mathbf{A})|}, \quad \mathbf{y} \in \mathcal{Y}.$$

A transformação linear é um caso particularmente simples de mudança multivariada, pois sua matriz jacobiana não depende de $\mathbf{y}$.

i Duas utilizações da matriz jacobiana

A matriz jacobiana aparecerá novamente no método delta multivariado.

Na mudança de variáveis, utiliza-se o **determinante da jacobiana da transformação inversa** para ajustar uma densidade.

No método delta, utiliza-se a **própria matriz jacobiana da transformação** para aproximar localmente uma função vetorial.

Considere X_1 e X_2 independentes, ambas com distribuição exponencial de taxa λ . Defina

$$Y_1 = X_1 + X_2, \quad Y_2 = X_2.$$

A transformação inversa é

$$X_1 = Y_1 - Y_2, \quad X_2 = Y_2.$$

Sua matriz jacobiana é

$$Dh(\mathbf{y}) = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix},$$

de modo que $|\det Dh(\mathbf{y})| = 1$.

Como $X_1 > 0$ e $X_2 > 0$, o suporte transformado é

$$\mathcal{Y} = \{(y_1, y_2) : 0 < y_2 < y_1\}.$$

A densidade conjunta transformada é

$$f_{Y_1, Y_2}(y_1, y_2) = \lambda^2 e^{-\lambda y_1}, \quad 0 < y_2 < y_1.$$

Integrando em relação a y_2 ,

$$f_{Y_1}(y_1) = \lambda^2 y_1 e^{-\lambda y_1}, \quad y_1 > 0.$$

Portanto, a soma de duas variáveis exponenciais independentes com a mesma taxa possui distribuição gama com forma 2 e escala $1/\lambda$,

$$Y_1 \sim \text{Gama}\left(2, \frac{1}{\lambda}\right),$$

em concordância com a parametrização forma-escala adotada no capítulo anterior.

2.3 Ferramentas assintóticas

Resultados exatos descrevem uma variável ou estatística para um tamanho amostral específico. Resultados assintóticos descrevem seu comportamento quando o tamanho da amostra cresce.

A teoria assintótica será utilizada quando uma distribuição exata for difícil de obter ou quando for necessário estudar propriedades que emergem à medida que n aumenta.

O ponto de partida é definir diferentes formas de convergência de sequências de variáveis aleatórias.

2.3.1 Modos de convergência

Considere uma sequência $X_1, X_2, \dots$ de variáveis aleatórias e uma variável aleatória X .

2.3.1.1 Convergência quase certa

Dizemos que X_n **converge quase certamente** para X , e escrevemos

$$X_n \xrightarrow{\text{q.c.}} X,$$

quando

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

2.3.1.2 Convergência em média quadrática

Dizemos que X_n **converge em média quadrática** para X , e escrevemos

$$X_n \xrightarrow{L^2} X,$$

quando

$$E[(X_n - X)^2] \rightarrow 0.$$

2.3.1.3 Convergência em probabilidade

Dizemos que X_n **converge em probabilidade** para X , e escrevemos

$$X_n \xrightarrow{P} X,$$

quando, para todo $\varepsilon > 0$,

$$P(|X_n - X| > \varepsilon) \rightarrow 0.$$

2.3.1.4 Convergência em distribuição

Dizemos que X_n **converge em distribuição** para X , e escrevemos

$$X_n \xrightarrow{d} X,$$

quando

$$F_{X_n}(x) \rightarrow F_X(x)$$

em todo ponto de continuidade de F_X .

A notação de convergência em distribuição também será utilizada para vetores aleatórios, especialmente no método delta multivariado.

2.3.2 Relações entre os modos de convergência

As principais implicações utilizadas neste livro são

$$X_n \xrightarrow{\text{q.c.}} X \implies X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X$$

e

$$X_n \xrightarrow{L^2} X \implies X_n \xrightarrow{P} X.$$

Em geral, não existe implicação entre convergência quase certa e convergência em média quadrática.

As implicações anteriores também não podem, em geral, ser invertidas. Uma exceção particularmente útil ocorre quando o limite é uma constante c :

$$X_n \xrightarrow{d} c \implies X_n \xrightarrow{P} c.$$

(Lauritzen, 2023, ap. A.2; Rice, 2007, cap. 5)

Se Z possui segundo momento finito e definimos $X_n = Z/n$, então

$$E(X_n^2) = \frac{E(Z^2)}{n^2} \rightarrow 0.$$

Logo,

$$X_n \xrightarrow{L^2} 0.$$

Consequentemente, também temos $X_n \xrightarrow{P} 0$ e $X_n \xrightarrow{d} 0$.

Considere

$$X_n \sim N\left(0, 1 + \frac{1}{n}\right).$$

À medida que n aumenta, sua distribuição se aproxima de $N(0, 1)$. Assim,

$$X_n \xrightarrow{d} N(0, 1).$$

Como o limite não é uma constante, a convergência em distribuição, isoladamente, não permite concluir convergência em probabilidade.

2.3.3 Lei Fraca dos Grandes Números

Considere uma sequência $X_1, X_2, \dots$ de variáveis aleatórias independentes e identicamente distribuídas, com $E|X_1| < \infty$.

Defina

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

A Lei Fraca dos Grandes Números estabelece

$$\overline{X}_n \xrightarrow{P} E(X_1).$$

Se $E(X_1) = \mu$, escrevemos

$$\overline{X}_n \xrightarrow{P} \mu.$$

O resultado descreve a estabilização da média amostral em torno da média da distribuição quando o tamanho da amostra aumenta (Rice, 2007, sec. 5.2; Ramachandran; Tsokos, 2021, sec. 3.5).

! Interpretação

A Lei dos Grandes Números responde a uma questão de **convergência**:

a média calculada a partir de muitas observações tende a se aproximar da média da distribuição?

O resultado não fornece, por si só, a forma da distribuição de $\overline{X}_n$ para um valor específico de n .

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Como $E(X_i) = p$,

$$\overline{X}_n \xrightarrow{P} p.$$

Como

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

é a proporção de sucessos observada, a Lei dos Grandes Números estabelece que essa proporção tende a se aproximar de p quando n aumenta.

Estabilização da média amostral

Trajectoria — 1 - - 2 ··· 3 · - 4 — 5




Figura 2.3: Trajetórias de médias acumuladas de amostras exponenciais com média 1.

2.3.3.1 Visualização da estabilização

A estabilização da média pode ser observada por meio de diferentes sequências de observações provenientes da mesma distribuição.

A Figura 2.3 apresenta diferentes trajetórias de médias acumuladas de observações exponenciais com $E(X) = 1$. Para valores pequenos de n , as médias apresentam maior variabilidade entre as trajetórias. À medida que n aumenta, tendem a permanecer mais próximas de $\mu = 1$.

A figura ilustra a **estabilização** descrita pela Lei Fraca dos Grandes Números. Ela não informa, porém, a forma da distribuição das flutuações em torno de μ .

2.3.4 Teorema Central do Limite

Considere $X_1, X_2, \dots$ independentes e identicamente distribuídas, com $E(X_1) = \mu$ e

$$0 < \text{Var}(X_1) = \sigma^2 < \infty.$$

O Teorema Central do Limite estabelece

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Equivalentemente,

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

O resultado descreve a distribuição limite das flutuações padronizadas da média ou da soma em torno de seus respectivos valores esperados (Rice, 2007, sec. 5.3; Ramachandran; Tsokos, 2021, sec. 3.5; Chihara; Hesterberg, 2022, sec. 4.3).

2.3.4.1 Centralização e mudança de escala

A quantidade $\bar{X}_n - \mu$ representa o desvio da média amostral em relação à média da distribuição.

Como

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n},$$

o desvio-padrão de $\bar{X}_n$ é $\sigma/\sqrt{n}$. Portanto,

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}.$$

A padronização utilizada no Teorema Central do Limite envolve, assim, duas operações: a **centralização**, obtida subtraindo μ , e a **mudança de escala**, obtida dividindo pelo desvio-padrão da média amostral.

O fator $\sqrt{n}$ surge porque a variância de $\bar{X}_n$ diminui à taxa $1/n$, enquanto seu desvio-padrão diminui à taxa $1/\sqrt{n}$.

Para valores suficientemente grandes de n , o resultado sugere a aproximação

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

A qualidade dessa aproximação depende da distribuição das observações e do tamanho da amostra.

! O que o Teorema Central do Limite estabelece

O Teorema Central do Limite não afirma que as observações individuais se tornam normais à medida que n aumenta.

A convergência refere-se à distribuição da **média ou soma padronizada**. Distribuições muito assimétricas ou com caudas pesadas podem exigir amostras maiores para que a aproximação normal seja satisfatória.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda).$$

Como

$$E(X_i) = \frac{1}{\lambda} \quad \text{e} \quad \text{Var}(X_i) = \frac{1}{\lambda^2},$$

o Teorema Central do Limite fornece

$$\lambda\sqrt{n}\left(\bar{X}_n - \frac{1}{\lambda}\right) \xrightarrow{d} N(0, 1).$$

Consequentemente, para amostras suficientemente grandes,

$$\bar{X}_n \approx N\left(\frac{1}{\lambda}, \frac{1}{n\lambda^2}\right).$$

2.3.4.2 Visualização da convergência

A aproximação produzida pelo Teorema Central do Limite pode ser visualizada partindo de uma distribuição que não é normal.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(1).$$

Nesse caso, $E(X_i) = 1$ e $\text{Var}(X_i) = 1$. Além disso,

$$S_n = \sum_{i=1}^n X_i \sim \text{Gama}(n, 1).$$

A média padronizada pode ser escrita como

$$Z_n = \sqrt{n}(\bar{X}_n - 1) = \frac{S_n - n}{\sqrt{n}}.$$

O Teorema Central do Limite estabelece $Z_n \xrightarrow{d} N(0, 1)$.

A Figura 2.4 parte de observações exponenciais, cuja distribuição é assimétrica. À medida que n aumenta, a densidade da média padronizada Z_n se aproxima da densidade da distribuição $N(0, 1)$.

A figura destaca que o objeto que se aproxima da distribuição normal é a **média padronizada**, e não a distribuição das observações individuais.

2.3.5 Lei dos Grandes Números e Teorema Central do Limite

Os dois resultados descrevem aspectos diferentes do comportamento da média amostral.

Resultado	Questão
Lei dos Grandes Números	$\bar{X}_n$ se aproxima de μ ?
Teorema Central do Limite	como as flutuações de $\bar{X}_n$ em torno de μ se distribuem após padronização?




Figura 2.4: Densidade da média exponencial padronizada para diferentes tamanhos de amostra e densidade da distribuição normal padrão.

A Lei dos Grandes Números estabelece

$$\overline{X}_n \xrightarrow{P} \mu,$$

enquanto o Teorema Central do Limite estabelece

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Assim, a Lei dos Grandes Números descreve **estabilização**, enquanto o Teorema Central do Limite descreve **flutuação em torno do limite**.

2.3.6 Teorema do mapeamento contínuo

O teorema do mapeamento contínuo permite transportar um resultado de convergência através de uma função contínua.

Se

$$X_n \xrightarrow{P} X$$

e g é contínua em todos os pontos de um conjunto C tal que

$$P(X \in C) = 1,$$

então

$$g(X_n) \xrightarrow{P} g(X).$$

De forma análoga, se

$$X_n \xrightarrow{d} X$$

e g é contínua em todos os pontos de um conjunto C tal que

$$P(X \in C) = 1,$$

então

$$g(X_n) \xrightarrow{d} g(X).$$

(Lauritzen, 2023, teorema A.11)

Suponha que $T_n \xrightarrow{P} \theta$, com $\theta > 0$.

Como as funções $g_1(x) = \sqrt{x}$, $g_2(x) = \log x$ e $g_3(x) = 1/x$ são contínuas em θ , temos

$$\sqrt{T_n} \xrightarrow{P} \sqrt{\theta},$$

$$\log T_n \xrightarrow{P} \log \theta$$

e

$$\frac{1}{T_n} \xrightarrow{P} \frac{1}{\theta}.$$

Como $\theta > 0$, a convergência implica também $P(T_n > 0) \rightarrow 1$, de modo que as transformações ficam bem definidas com probabilidade tendendo a um.

2.3.7 Lema de Slutsky

Se

$$X_n \xrightarrow{d} X \quad \text{e} \quad Y_n \xrightarrow{P} c,$$

em que c é uma constante, então

$$X_n + Y_n \xrightarrow{d} X + c,$$

$$X_n Y_n \xrightarrow{d} cX$$

e, se $c \neq 0$,

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}.$$

O lema permite combinar uma sequência com distribuição limite não degenerada com outra que converge em probabilidade para uma constante (Lauritzen, 2023, corolário A.12).

Suponha que

$$\frac{\sqrt{n}(T_n - \theta)}{\sigma} \xrightarrow{d} N(0, 1)$$

e que $S_n \xrightarrow{P} \sigma$, com $\sigma > 0$.

Então

$$\frac{\sqrt{n}(T_n - \theta)}{S_n} = \frac{\sqrt{n}(T_n - \theta)}{\sigma} \frac{\sigma}{S_n}.$$

Como $\sigma/S_n \xrightarrow{P} 1$, o lema de Slutsky fornece

$$\frac{\sqrt{n}(T_n - \theta)}{S_n} \xrightarrow{d} N(0, 1).$$

Esse mecanismo será utilizado posteriormente quando uma quantidade desconhecida presente em uma padronização for substituída por uma aproximação consistente.

2.3.8 Aprofundamento

As subseções seguintes apresentam o método delta em suas versões univariada e multivariada. Esse bloco utiliza conjuntamente expansão de Taylor, convergência em distribuição e o lema de Slutsky.

2.3.8.1 Método delta

O método delta permite obter a distribuição assintótica de uma transformação a partir da distribuição assintótica da quantidade original (Casella; Berger, 2011, sec. 5.5.4).

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \tau^2)$$

e que g seja diferenciável em θ , com

$$g'(\theta) \neq 0.$$

Então,

$$\sqrt{n}\{g(T_n) - g(\theta)\} \xrightarrow{d} N(0, [g'(\theta)]^2 \tau^2).$$

Essa é a forma usual do método delta de primeira ordem (Casella; Berger, 2011, sec. 5.5.4).

Quando $g'(\theta) = 0$, essa forma não fornece uma distribuição limite não degenerada. Nesse caso, uma expansão de Taylor de ordem superior e uma escala diferente podem ser necessárias (Chihara; Hesterberg, 2022, sec. 7.7).

i Relação com Taylor

O método delta utiliza localmente a aproximação

$$g(T_n) \approx g(\theta) + g'(\theta)(T_n - \theta).$$

Assim, uma transformação suave herda, em primeira ordem, a distribuição assintótica de T_n , ajustada pela derivada $g'(\theta)$.

Suponha que

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2), \quad \mu > 0.$$

Considere $g(x) = \log x$. Como $g'(\mu) = 1/\mu$, o método delta fornece

$$\sqrt{n}\{\log(\bar{X}_n) - \log(\mu)\} \xrightarrow{d} N\left(0, \frac{\sigma^2}{\mu^2}\right).$$

Esse resultado mostra como uma distribuição assintótica conhecida pode ser transportada para uma escala transformada.

Visualização do método delta

A aproximação fornecida pelo método delta pode ser observada no mesmo modelo exponencial utilizado para ilustrar o Teorema Central do Limite.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(1).$$

Como $E(X_i) = 1$ e $\text{Var}(X_i) = 1$, o Teorema Central do Limite fornece

$$\sqrt{n}(\bar{X}_n - 1) \xrightarrow{d} N(0, 1).$$

Para $g(x) = \log x$, temos $g(1) = 0$ e $g'(1) = 1$. Portanto, pelo método delta,

$$\sqrt{n} \log \bar{X}_n \xrightarrow{d} N(0, 1).$$

A Figura 2.5 mostra que, para amostras pequenas, a distribuição de $\sqrt{n} \log \bar{X}_n$ ainda apresenta diferenças em relação à normal padrão. À medida que n aumenta, a distribuição simulada se aproxima de $N(0, 1)$, como previsto pelo método delta.

O resultado é assintótico. A qualidade da aproximação para um tamanho de amostra específico depende do modelo, da transformação e do valor de n .

2.3.8.2 Método delta multivariado

Considere um vetor $\mathbf{T}_n \in \mathbb{R}^k$ tal que

$$\sqrt{n}(\mathbf{T}_n - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Sigma).$$

Se $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ é diferenciável em θ , então

$$\sqrt{n}\{g(\mathbf{T}_n) - g(\theta)\} \xrightarrow{d} N_m[\mathbf{0}, Dg(\theta)\Sigma Dg(\theta)^\top].$$

A matriz jacobiana transforma a matriz de covariâncias assintótica da mesma forma que uma transformação linear atua sobre uma matriz de covariâncias.

Considere

$$g(\theta_1, \theta_2) = \frac{\theta_1}{\theta_2}, \quad \theta_2 \neq 0.$$

O gradiente é

$$\nabla g(\theta) = \begin{pmatrix} \frac{1}{\theta_2} \\ \frac{\theta_1}{\theta_2^2} \end{pmatrix}.$$

Se




Figura 2.5: Distribuição simulada da transformação da média amostral e densidade normal padrão prevista pelo método delta.

$$\sqrt{n}(\mathbf{T}_n - \theta) \xrightarrow{d} N_2(\mathbf{0}, \Sigma),$$

então

$$\sqrt{n} \left\{ \frac{T_{1n}}{T_{2n}} - \frac{\theta_1}{\theta_2} \right\} \xrightarrow{d} N(0, V),$$

em que

$$V = \nabla g(\theta)^\top \Sigma \nabla g(\theta).$$

2.3.9 Ordens estocásticas

As ordens estocásticas fornecem uma notação compacta para descrever a magnitude de sequências aleatórias.

Seja $a_n > 0$ uma sequência determinística.

Escrevemos

$$X_n = o_P(a_n)$$

quando

$$\frac{X_n}{a_n} \xrightarrow{P} 0.$$

Nesse caso, X_n é assintoticamente desprezível em relação a a_n .

Escrevemos

$$X_n = O_P(a_n)$$

quando X_n/a_n é **limitado em probabilidade**. Isso significa que, para todo $\varepsilon > 0$, existe $M > 0$ tal que, para valores suficientemente grandes de n ,

$$P \left(\left| \frac{X_n}{a_n} \right| > M \right) < \varepsilon.$$

As duas notações não possuem o mesmo significado. A relação

$$X_n = o_P(a_n)$$

é mais forte que

$$X_n = O_P(a_n).$$

Algumas consequências e regras que serão utilizadas posteriormente são:

- se $X_n \xrightarrow{P} 0$, então $X_n = o_P(1)$;
- se $X_n \xrightarrow{d} X$, então $X_n = O_P(1)$;
- se $X_n = O_P(a_n)$ e $Y_n = O_P(b_n)$, então $X_n Y_n = O_P(a_n b_n)$;
- se $X_n = o_P(a_n)$ e $Y_n = O_P(b_n)$, então $X_n Y_n = o_P(a_n b_n)$;
- se $X_n = O_P(a_n)$ e $Y_n = O_P(a_n)$, então $X_n + Y_n = O_P(a_n)$;
- se $X_n = o_P(a_n)$ e $Y_n = o_P(a_n)$, então $X_n + Y_n = o_P(a_n)$.

Essas regras permitem identificar quais parcelas possuem a mesma ordem e quais se tornam desprezíveis em expansões assintóticas.

Se

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2),$$

então

$$\sqrt{n}(\bar{X}_n - \mu) = O_P(1).$$

Consequentemente,

$$\bar{X}_n - \mu = O_P(n^{-1/2}).$$

A expressão indica que as flutuações da média em torno de μ possuem, sob as condições do Teorema Central do Limite, ordem $n^{-1/2}$.

2.4 Síntese

Os resultados deste capítulo podem ser organizados em dois componentes.

O primeiro reúne **ferramentas matemáticas**. Somatórios, produtos e logaritmos permitem reorganizar expressões; vetores e matrizes fornecem a linguagem necessária para parâmetros e estatísticas multidimensionais; diferenciação, gradientes, hessianas e expansões de Taylor permitem estudar localmente funções; formas quadráticas e projeções serão utilizadas principalmente em distribuições associadas ao modelo normal e em mínimos quadrados; e o jacobiano permite trabalhar com transformações multivariadas.

O segundo reúne **ferramentas assintóticas**. Os modos de convergência formalizam diferentes sentidos em que uma sequência aleatória pode aproximar um limite. A Lei dos Grandes Números descreve a estabilização de médias, enquanto o Teorema Central do Limite descreve suas flutuações padronizadas. O teorema do mapeamento contínuo e o lema de Slutsky permitem transformar e combinar sequências convergentes, e as ordens O_P e o_P registram de forma compacta a magnitude dos termos envolvidos.

No **Aprofundamento**, o método delta utiliza uma aproximação de Taylor para transportar distribuições assintóticas para funções de quantidades aleatórias. Sua versão multivariada realiza a mesma operação por meio da matriz jacobiana.

A estrutura assintótica do núcleo pode ser resumida por

Lei dos Grandes Números $\rightarrow$ convergência para uma constante

e

Teorema Central do Limite $\rightarrow$ distribuição das flutuações.

No aprofundamento, essas ferramentas se articulam segundo o esquema

distribuição assintótica + Taylor + Slutsky $\rightarrow$ método delta.

Os capítulos seguintes utilizarão essas ferramentas sem redefini-las. As interpretações e condições específicas serão retomadas no contexto de cada problema inferencial.

2.5 Exercícios de consolidação

2.5.1 Ferramentas matemáticas

i Exercício 1

Considere os valores $x_1 = 2$, $x_2 = 4$, $x_3 = 5$ e $x_4 = 9$.

- Calcule $\bar{x}$.
- Calcule $\sum_{i=1}^4 (x_i - \bar{x})$.
- Para $a = 3$, calcule os dois lados da identidade

$$\sum_{i=1}^4 (x_i - a)^2 = \sum_{i=1}^4 (x_i - \bar{x})^2 + 4(\bar{x} - a)^2$$

e verifique numericamente que os valores coincidem.

- Explique por que essa decomposição pode ser útil quando uma soma de quadrados é estudada em torno de valores diferentes.

i Exercício 2

Considere

$$\mathbf{A} = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} \quad \text{e} \quad \mathbf{x} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}.$$

- Verifique se $\mathbf{A}$ é simétrica.
- Calcule $\det(\mathbf{A})$.
- Determine se $\mathbf{A}$ é invertível e, em caso afirmativo, obtenha $\mathbf{A}^{-1}$.
- Calcule $\mathbf{Ax}$ e $\mathbf{x}^T \mathbf{Ax}$.

i Exercício 3

Considere

$$g(\theta_1, \theta_2) = \theta_1^2 + 2\theta_2^2 - 2\theta_1 + 4\theta_2.$$

- Obtenha $\nabla g(\theta_1, \theta_2)$.

- b. Obtenha a matriz hessiana.
- c. Determine o ponto em que o gradiente é nulo.
- d. A partir da hessiana, classifique esse ponto como máximo ou mínimo local.

i Exercício 4

Utilize aproximações de Taylor de primeira ordem para:

- a. aproximar $\log(1,08)$ em torno de 1;
- b. aproximar $\sqrt{1,04}$ em torno de 1;
- c. comparar as aproximações com os valores calculados diretamente.

Em qual dos dois casos o erro absoluto foi maior?

i Exercício 5

Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

e $\mathbf{x} = (x_1, x_2)^\top$.

- a. Obtenha a expressão de $\mathbf{x}^\top \mathbf{A} \mathbf{x}$.
- b. Verifique que essa expressão pode ser escrita como

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = x_1^2 + x_2^2 + (x_1 + x_2)^2.$$

- c. A partir dessa expressão, classifique $\mathbf{A}$ quanto à definitude.
- d. Calcule a forma quadrática para $\mathbf{x} = (1, -1)^\top$ e para $\mathbf{x} = (1, 1)^\top$.

i Exercício 6

Considere

$$\mathbf{X} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

e

$$\mathbf{y} = \begin{pmatrix} 2 \\ 3 \\ 7 \\ 8 \end{pmatrix}.$$

- Obtenha $\mathbf{P}_{\mathbf{X}}$.
- Calcule $\hat{\mathbf{y}} = \mathbf{P}_{\mathbf{X}}\mathbf{y}$.
- Calcule $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$.
- Verifique numericamente que $\mathbf{X}^T \mathbf{e} = 0$.
- Relacione os elementos de $\hat{\mathbf{y}}$ com a média dos elementos de $\mathbf{y}$.

i Exercício 7

Considere X_1 e X_2 independentes e exponenciais com taxa λ . Defina

$$Y_1 = X_1, \quad Y_2 = X_1 + X_2.$$

- Obtenha a transformação inversa.
- Determine a matriz jacobiana da transformação inversa e seu determinante.
- Determine o suporte conjunto $\mathcal{Y}$ de (Y_1, Y_2) .
- Obtenha a densidade conjunta de (Y_1, Y_2) .
- Explique o papel do determinante jacobiano nesse cálculo.

2.5.2 Ferramentas assintóticas

i Exercício 8

Seja Z uma variável aleatória com $E(Z^2) < \infty$ e defina $X_n = Z/n$.

- Calcule $E(X_n^2)$.
- Identifique o limite de $E(X_n^2)$ quando $n \rightarrow \infty$.
- Qual modo de convergência pode ser concluído diretamente?
- Quais outros modos de convergência decorrem desse resultado?

Agora considere $Y_n \sim N(0, 1 + 1/n)$. Qual convergência em distribuição é esperada? É possível concluir, apenas dessa informação, que Y_n converge em probabilidade?

i Exercício 9

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(0,35)$$

e $R_n = \sum_{i=1}^n X_i$.

- Escreva R_n/n como uma média.
- Utilize a Lei Fraca dos Grandes Números para identificar o limite em probabilidade de R_n/n .
- Interprete o resultado no contexto de uma sequência de ensaios.
- O resultado afirma que R_n/n será exatamente igual a 0,35 para algum valor finito de n ? Explique.

i Exercício 10

Considere

$$X_1, \dots, X_{64} \stackrel{\text{iid}}{\sim} \text{Exp}(2).$$

- Determine $E(X_i)$ e $\text{Var}(X_i)$.
- Obtenha a aproximação normal fornecida pelo Teorema Central do Limite para $\bar{X}_{64}$.

c. Utilize essa aproximação para calcular aproximadamente

$$P(0,45 < \bar{X}_{64} < 0,55).$$

d. Explique por que a aproximação do item anterior não significa que cada X_i possui distribuição aproximadamente normal.

i Exercício 11

Considere uma sequência i.i.d. com média μ e variância finita e positiva. Compare as afirmações

$$\bar{X}_n \xrightarrow{P} \mu$$

e

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Em sua resposta, indique:

- a. qual resultado corresponde à Lei dos Grandes Números;
- b. qual corresponde ao Teorema Central do Limite;
- c. o que cada resultado informa sobre $\bar{X}_n$;
- d. por que um resultado não substitui o outro.

i Exercício 12

Suponha que $T_n \xrightarrow{P} \theta$, com $\theta > 0$.

Utilize o teorema do mapeamento contínuo para determinar os limites em probabilidade de:

- a. $\sqrt{T_n}$;
- b. $\log T_n$;
- c. T_n^2 ;
- d. $1/T_n$.

Explique por que a condição $\theta > 0$ garante que as transformações utilizadas nos itens (a), (b) e (d) estejam definidas e sejam contínuas em uma vizinhança de θ .

i Exercício 13

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, 4)$$

e que $S_n \xrightarrow{P} 2$.

Determine a distribuição limite de

$$\frac{\sqrt{n}(T_n - \theta)}{S_n}.$$

Indique explicitamente onde o lema de Slutsky é utilizado.

Aprofundamento

Os exercícios seguintes utilizam o método delta e integram o aprofundamento.

i Exercício 14

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \tau^2), \quad \theta > 0.$$

Utilize o método delta para obter a distribuição limite de:

- a. $\sqrt{n}\{\log(T_n) - \log(\theta)\}$;
- b. $\sqrt{n}(1/T_n - 1/\theta)$.

Compare as variâncias assintóticas obtidas.

i Exercício 15

Considere

$$\sqrt{n} \left[\begin{pmatrix} T_{1n} \\ T_{2n} \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \right] \xrightarrow{d} N_2 \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 4 & 1 \\ 1 & 9 \end{pmatrix} \right],$$

com $\theta_2 \neq 0$.

Para

$$g(\theta_1, \theta_2) = \frac{\theta_1}{\theta_2},$$

- a. obtenha o gradiente de g ;
- b. utilize o método delta multivariado para escrever a variância limite de

$$\sqrt{n} \left(\frac{T_{1n}}{T_{2n}} - \frac{\theta_1}{\theta_2} \right);$$

- c. calcule essa variância para $\theta_1 = 2$ e $\theta_2 = 4$.

i Exercício 16

Considere amostras de uma distribuição exponencial com taxa 1.

Utilizando R, simule repetidamente amostras de tamanhos $n = 10, 50$ e 200 e investigue três resultados deste capítulo:

1. **Lei dos Grandes Números:** compare a distribuição das médias amostrais com o valor $E(X) = 1$;
2. **Teorema Central do Limite:** examine a distribuição de $\sqrt{n}(\bar{X}_n - 1)$ e compare-a com $N(0, 1)$;
3. **Método delta:** examine a distribuição de $\sqrt{n} \log(\bar{X}_n)$ e compare-a com a distribuição limite prevista pelo método delta.

Apresente gráficos adequados e escreva uma interpretação curta para cada resultado. O objetivo é comparar estabilização, aproximação normal e transformação assintótica, e não apenas reproduzir o código.

3 Fundamentos da Inferência Estatística

A inferência estatística utiliza informações obtidas em uma amostra para estudar características desconhecidas de uma população ou de um processo que produz dados. Como diferentes amostras podem gerar resultados diferentes, as conclusões obtidas a partir dos dados estão associadas à variabilidade e à incerteza.

O desenvolvimento parte do problema inferencial, do processo gerador de dados, da população, dos parâmetros e da amostragem. Um experimento com uma urna permite observar diretamente a variabilidade produzida por diferentes amostras e fornece a base para distinguir estatística, estimador e estimativa e para introduzir o modelo estatístico e a função de verossimilhança.

Ao final do capítulo, o experimento da urna é reproduzido e ampliado computacionalmente.

3.1 O problema da inferência estatística

Em muitas situações, deseja-se conhecer uma característica de uma população sem observar todos os seus elementos. Pode haver interesse, por exemplo, na proporção de eleitores favoráveis a determinado candidato, no peso médio de um produto fabricado por uma empresa ou no tempo médio de funcionamento de determinado equipamento.

Quando a observação de toda a população não é possível ou conveniente, utiliza-se uma amostra. Os dados obtidos nessa amostra são analisados para produzir conclusões sobre a característica de interesse na população. A amostra observada corresponde a apenas um dos possíveis conjuntos de dados que poderiam ser obtidos. Se o procedimento de amostragem fosse repetido, outros elementos poderiam ser selecionados e os resultados calculados a partir deles poderiam ser diferentes. Assim, a inferência estatística envolve a variabilidade associada ao processo de obtenção dos dados.

! Inferência estatística

A inferência estatística utiliza dados observados para obter informação sobre características desconhecidas da população ou do processo que gerou os dados.

Para representar essa variabilidade e estabelecer procedimentos inferenciais, é necessário considerar como os dados são produzidos. Esse é o ponto de partida para o conceito de Processo Gerador de Dados.

3.2 Processo Gerador de Dados (PGD)

Os dados observados resultam de algum mecanismo que define as condições sob as quais determinados valores podem ocorrer e ser observados. Esse mecanismo será denominado **Processo Gerador de Dados (PGD)**.

O PGD pode envolver diferentes componentes, como características da população, seleção das unidades observadas, condições de medição, fontes de variabilidade e relações de dependência entre as observações. Em termos gerais, o PGD descreve como o fenômeno de interesse e o mecanismo de observação se combinam para produzir os dados observados.

Os dados constituem uma realização particular desse processo. Se o mecanismo fosse repetido sob condições semelhantes, outros conjuntos de dados poderiam ser observados.

O PGD real raramente é conhecido em todos os seus detalhes. Por essa razão, o **modelo estatístico** fornece uma representação probabilística simplificada dos aspectos do PGD considerados relevantes para o problema estudado.

i PGD e hipótese i.i.d.

Em muitos modelos estatísticos, as observações são representadas por

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

A condição i.i.d. (iid) estabelece que as variáveis aleatórias são independentes e identicamente distribuídas. Essa é uma hipótese sobre o mecanismo de geração dos dados e não uma condição que define todo Processo Gerador de Dados.

Outros mecanismos podem produzir observações dependentes, distribuições diferentes entre unidades ou estruturas amostrais determinadas pelo plano de coleta.

A adequação da hipótese i.i.d. depende do mecanismo que produz os dados. A condição de distribuições idênticas requer que as observações possam ser representadas pelo mesmo modelo probabilístico, enquanto a independência requer que o comportamento de uma observação não altere probabilisticamente o das demais.

Por exemplo, componentes selecionados aleatoriamente de uma produção mantida sob condições estáveis podem ser razoavelmente representados como i.i.d. Em contrapartida, medições sucessivas de uma mesma variável ao longo do tempo podem apresentar dependência e exigir outro modelo.

3.3 Conceitos fundamentais

Uma **população** é o conjunto de unidades sobre as quais se deseja obter informação. Dependendo do problema, pode ser formada por pessoas, animais, objetos, empresas, municípios, medições ou outras unidades de interesse.

A **unidade observacional** é o elemento da população sobre o qual uma ou mais características são observadas ou medidas. Por exemplo, pode corresponder a uma pessoa, um animal, uma embalagem, um município ou uma bola da urna utilizada no experimento deste capítulo.

Quando a população é finita, seu tamanho será representado por N .

Uma quantidade que caracteriza a população, o processo ou o modelo estatístico de interesse é denominada **parâmetro**. Na abordagem frequentista desenvolvida neste livro, o parâmetro é tratado como uma quantidade fixa. Em um problema inferencial, seu valor é, em geral, desconhecido e deve ser estudado a partir dos dados observados.

Os parâmetros são usualmente representados por letras gregas, como μ , σ^2 e θ . Algumas quantidades, entretanto, possuem notações convencionais próprias. Um exemplo é a proporção populacional, frequentemente representada pela letra p .

Por exemplo, podem constituir parâmetros:

- a média populacional μ ;
- a variância populacional σ^2 ;
- uma proporção populacional p .

Um **censo** consiste na observação de todas as unidades de uma população finita. Quando o censo é possível e as medições são obtidas sem erro, uma característica da população pode ser calculada diretamente. Em muitas aplicações, observar toda a população é inviável em razão de custo, tempo, disponibilidade das unidades ou do próprio processo de medição.

Uma **amostra** é uma coleção de unidades ou observações utilizada para obter informação sobre a população ou o processo de interesse. Seu tamanho será representado por n . A **amostragem** corresponde ao procedimento utilizado para selecionar ou obter essas unidades ou observações.

No experimento que será realizado em sala de aula, a população é formada por $N = 2400$ bolas de mesmo tamanho, das quais 900 são vermelhas e 1500 são brancas. A característica de interesse é a proporção populacional de bolas vermelhas,

$$p = \frac{900}{2400} = 0,375.$$

Conhecemos p nesse experimento porque a composição completa da urna é conhecida. Essa informação será utilizada como referência para estudar o que ocorre quando apenas uma amostra da urna é observada.

Se representarmos por Y o número de bolas vermelhas em uma amostra aleatória de tamanho n , a proporção amostral pode ser escrita como

$$\hat{p} = \frac{Y}{n}.$$

Como será formalizado adiante, $\hat{p}$ é uma **estatística**, pois é uma função da amostra. Quando utilizada para obter informação sobre o parâmetro populacional p , ela desempenha o papel de **estimador** de p . Depois que uma amostra específica é observada e Y assume um valor y , o valor numérico

$$\hat{p}(\mathbf{x}) = \frac{y}{n}$$

constitui uma **estimativa** de p .

Essa distinção entre estatística, estimador e estimativa será retomada adiante, após o experimento da urna, quando será possível observar diretamente como $\hat{p}$ varia entre diferentes amostras.

Mecanismo de seleção da amostra

A possibilidade de generalizar resultados da amostra para a população depende, entre outros aspectos, do mecanismo utilizado para selecionar as unidades.

Uma seleção que favoreça sistematicamente determinados elementos pode produzir **viés de seleção**. Por exemplo, se a retirada das bolas favorecer determinadas regiões da urna, as probabilidades de inclusão podem deixar de corresponder ao plano amostral pretendido.

O mecanismo de participação também pode afetar a composição da amostra. Em levantamentos de resposta voluntária, por exemplo, mesmo que o convite seja dirigido a toda a população, os indivíduos que respondem podem diferir sistematicamente dos que não respondem. Nesse caso, o conjunto de respondentes não constitui automaticamente uma representação adequada da população.

Na **amostragem aleatória**, a seleção das unidades é realizada segundo um mecanismo probabilístico conhecido. Em uma amostragem aleatória simples sem reposição, todas as amostras de tamanho n possuem a mesma probabilidade de seleção.

A aleatorização não garante que cada amostra observada reproduza exatamente a composição da população. Amostras diferentes apresentam variação natural. Sua função é estabelecer um mecanismo de seleção que permita caracterizar probabilisticamente essa variabilidade e sustentar a inferência para a população considerada.

3.4 Experimento em sala de aula

O objetivo do experimento é observar como amostras diferentes, obtidas da mesma população pelo mesmo procedimento, podem produzir valores diferentes para a proporção amostral.

A população é a urna com $N = 2400$ bolas, das quais 900 são vermelhas. Portanto, a proporção populacional conhecida é $p = 0,375$.

Cada grupo realizará uma amostragem seguindo o mesmo protocolo:

1. misturar cuidadosamente as bolas da urna;
2. retirar, com uma pá de amostragem com 50 espaços, $n = 50$ bolas, sem reposição durante a formação da amostra;
3. contar o número observado y de bolas vermelhas;
4. calcular a proporção observada $\hat{p} = y/50$;
5. registrar os valores de y e $\hat{p}$;
6. devolver todas as bolas à urna antes da amostragem do grupo seguinte e misturá-las novamente.

Cada grupo realiza uma amostragem separada. Dentro de cada amostra, as bolas são retiradas sem reposição; entre as amostragens dos grupos, todas as bolas são devolvidas à urna, restabelecendo a população original.

Os resultados dos grupos serão reunidos somente depois que todas as amostras tiverem sido obtidas.

Ao final, teremos valores

$$\hat{p}_1, \hat{p}_2, \dots, \hat{p}_m,$$

em que m corresponde ao número de grupos.

Essas proporções serão organizadas em uma tabela e representadas graficamente. A representação resultante mostra a **distribuição empírica dos valores de $\hat{p}$ obtidos pelos grupos** e permite observar a variabilidade produzida pela repetição da amostragem.

Mesmo que todos os grupos utilizem a mesma população, o mesmo tamanho amostral e o mesmo procedimento, os valores de $\hat{p}$ não precisam coincidir. Essa variação decorre da seleção de conjuntos diferentes de bolas em cada amostra.

O experimento fornece uma primeira representação empírica da variabilidade que será descrita probabilisticamente pela distribuição amostral de $\hat{p}$ no Capítulo 4.

Verificação de aprendizagem

1. Explique a função da mistura da urna antes de cada amostragem.
2. Explique por que diferentes grupos podem obter valores distintos de y e de $\hat{p}$, mesmo utilizando o mesmo tamanho amostral.
3. Compare os valores de $\hat{p}$ obtidos pelos grupos com a proporção populacional $p = 0,375$.
4. A partir dos resultados da turma, descreva o que permaneceu fixo e o que variou entre as diferentes amostras.

3.5 Estatísticas, estimadores e estimativas

Os resultados do experimento podem agora ser formalizados distinguindo a amostra antes da observação dos valores e a amostra efetivamente observada.

Antes da coleta, representamos a amostra pelo vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n).$$

Nesse caso, $X_1, \dots, X_n$ são variáveis aleatórias e seus valores ainda não foram observados. Depois da coleta, uma realização particular desse vetor é representada por

$$\mathbf{x} = (x_1, \dots, x_n),$$

em que $x_1, \dots, x_n$ são os valores efetivamente observados.

A convenção de utilizar letras maiúsculas para variáveis aleatórias e letras minúsculas para suas realizações permite distinguir uma quantidade definida antes da observação dos dados de seu valor em uma amostra particular (Cox, 2006, seq. 1.1; Ramachandran; Tsokos, 2021, seq. 5.2, pp. 180–182).

! Estatística

Uma **estatística** é uma função conhecida das variáveis aleatórias que compõem a amostra e cuja expressão não envolve parâmetros desconhecidos. De forma geral,

$$T = T(\mathbf{X}) = T(X_1, \dots, X_n).$$

Antes da observação da amostra, $T(\mathbf{X})$ é uma variável aleatória. Depois que a amostra $\mathbf{x} = (x_1, \dots, x_n)$ é observada, a estatística assume o valor

$$T(\mathbf{x}) = T(x_1, \dots, x_n).$$

A condição de que uma estatística não dependa de parâmetros desconhecidos refere-se à sua regra de cálculo. Sua distribuição de probabilidade, entretanto, pode depender dos parâmetros do modelo. A distribuição de probabilidade de uma estatística é denominada **distribuição amostral** e será estudada no Capítulo 4.

No experimento da urna, por exemplo, a quantidade Y , que representa o número de bolas vermelhas na amostra aleatória, é uma estatística. A proporção amostral

$$\hat{p} = \frac{Y}{n}$$

também é uma estatística, pois é calculada apenas a partir dos resultados da amostra e do tamanho amostral conhecido.

Uma estatística pode ser utilizada para estimar um parâmetro desconhecido. Considere inicialmente um parâmetro populacional θ . Se a estatística $T(\mathbf{X})$ é escolhida como regra para estimar θ , escrevemos

$$\hat{\theta} = T(\mathbf{X}),$$

e denominamos $\hat{\theta}$ **estimador de θ** .

Como o estimador é uma função da amostra aleatória, seu valor pode variar de uma amostra para outra. Na abordagem frequentista considerada neste livro, essa situação é distinta daquela do parâmetro. Aqui θ é tratado como uma quantidade fixa, embora desconhecida, enquanto $\hat{\theta}$ é uma variável aleatória.

Depois que uma amostra particular $\mathbf{x}$ é observada, o estimador assume o valor

$$\hat{\theta}(\mathbf{x}) = T(\mathbf{x}).$$

Esse valor é denominado **estimativa de θ** .

! Estimador e estimativa

Considere

$$\hat{\theta} = T(\mathbf{X}).$$

O **estimador** $\hat{\theta}$ é a regra, definida como uma função da amostra aleatória, utilizada para estimar o parâmetro θ .

Depois que a amostra $\mathbf{x}$ é observada,

$$\hat{\theta}(\mathbf{x}) = T(\mathbf{x})$$

é a **estimativa**, isto é, o valor assumido pelo estimador naquela amostra particular. Assim, o parâmetro θ é fixo e desconhecido, o estimador $\hat{\theta}$ é aleatório antes da observação da amostra e a estimativa é o valor obtido após a observação dos dados (Chihara; Hesterberg, 2022, definição 4.2, p. 79; Ramachandran; Tsokos, 2021, seq. 5.2, pp. 181–182).

No experimento da urna, o parâmetro de interesse é a proporção populacional p . A proporção amostral

$$\hat{p} = \frac{Y}{n}$$

é utilizada como estimador de p .

Por exemplo, se em uma amostra de $n = 50$ bolas for observado $y = 20$, a estimativa obtida é

$$\hat{p} = \frac{20}{50} = 0,40.$$

Nesse caso, $\hat{p} = Y/n$ representa o estimador de p , enquanto

$$\hat{p}(\mathbf{x}) = \frac{y}{n} = 0,40$$

é a estimativa produzida pela amostra observada.

Na notação estatística, é comum utilizar o mesmo símbolo, como $\hat{p}$ ou $\hat{\theta}$, tanto para o estimador quanto para seu valor observado. A distinção entre os dois é determinada pelo contexto. Quando for necessário explicitá-la, utilizaremos $T(\mathbf{X})$ para a estatística como variável aleatória e $T(\mathbf{x})$ para seu valor na amostra observada.

i Estimação de uma função do parâmetro

Em alguns problemas, a quantidade de interesse não é o próprio parâmetro θ , mas uma função desse parâmetro,

$$\tau(\theta).$$

Nesse caso, uma estatística $T(\mathbf{X})$ utilizada para estimar $\tau(\theta)$ pode ser representada por

$$\hat{\tau} = T(\mathbf{X}).$$

Depois da observação da amostra $\mathbf{x}$, o valor

$$\hat{\tau}(\mathbf{x}) = T(\mathbf{x})$$

é uma estimativa de $\tau(\theta)$.

Portanto, a definição de estimador permanece a mesma; o que se altera é a quantidade paramétrica que constitui o objeto da estimação.

Alguns exemplos usuais são apresentados a seguir.

Parâmetro de interesse	Estimador	Estimativa após a observação da amostra
média populacional μ	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
variância populacional σ^2	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
proporção populacional p	$\hat{p} = \frac{Y}{n}$	$\hat{p}(\mathbf{x}) = \frac{y}{n}$

Uma mesma expressão pode ser considerada inicialmente apenas como uma estatística e, quando associada a uma quantidade paramétrica que se deseja estimar, desempenhar o papel de estimador. Por exemplo, $\bar{X}$ é uma estatística por ser uma função da amostra que não envolve parâmetros desconhecidos. Quando é utilizada para estimar a média populacional μ , $\bar{X}$ é um estimador de μ (Chihara; Hesterberg, 2022, seq. 1.6 e definição 4.2; Ramachandran; Tsokos, 2021, seq. 5.2).

3.6 Exemplo-guia: modelo Bernoulli para a urna

O experimento realizado em sala de aula utiliza amostragem sem reposição. Nesse caso, a composição da urna se modifica a cada retirada e as observações realizadas dentro de uma mesma amostra não são independentes.

Para introduzir um modelo probabilístico simples que permita formalizar os conceitos de parâmetro, estatística e estimador, consideraremos agora um mecanismo de amostragem diferente: após cada retirada, a bola é devolvida à urna e as bolas são novamente misturadas antes da retirada seguinte.

Com a reposição, a composição da urna permanece a mesma em todas as retiradas. Se todas as bolas possuem a mesma probabilidade de seleção, a probabilidade de retirar uma bola vermelha é constante e igual à proporção de bolas vermelhas na urna.

Na urna utilizada em sala de aula,

$$p = \frac{900}{2400} = 0,375.$$

Esse valor é conhecido porque a composição da urna foi previamente estabelecida. Para formular um problema de inferência, passaremos agora da urna física para um **modelo Bernoulli paramétrico idealizado**, no qual p é desconhecido e deve ser estudado a partir da amostra.

Nesse modelo, p representa a probabilidade de obter uma bola vermelha em cada retirada e pode assumir qualquer valor no intervalo $[0, 1]$.

Defina

$$X_i = \begin{cases} 1, & \text{se a } i\text{-ésima bola é vermelha,} \\ 0, & \text{se a } i\text{-ésima bola é branca.} \end{cases}$$

Sob esse mecanismo de amostragem,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Cada variável X_i possui a mesma distribuição Bernoulli com parâmetro p , e a reposição permite tratar as retiradas como independentes.

A estatística que representa o número de bolas vermelhas na amostra é

$$Y = \sum_{i=1}^n X_i,$$

e a proporção amostral é

$$\hat{p} = \frac{Y}{n} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Assim, Y e $\hat{p}$ são estatísticas. Quando o objetivo é estimar a proporção populacional p , $\hat{p}$ é utilizado como estimador de p (Chihara; Hesterberg, 2022, seq. 1.5, seção 1.6 e apêndice B.1).

Amostragem com e sem reposição

O modelo Bernoulli i.i.d. apresentado nesta seção corresponde ao mecanismo de amostragem **com reposição** e, portanto, não descreve exatamente o experimento realizado anteriormente em sala de aula.

Na amostragem **sem reposição** em uma população finita, as retiradas realizadas dentro

de uma mesma amostra são dependentes e o número de bolas vermelhas possui distribuição hipergeométrica.

Os dois mecanismos permitem estudar a variabilidade decorrente da amostragem, mas produzem modelos probabilísticos diferentes. A amostragem sem reposição e a correção para população finita serão estudadas no Capítulo 4.

Considere uma urna com N bolas, das quais M são vermelhas.

Antes de qualquer retirada,

$$P(X_1 = 1) = \frac{M}{N}.$$

Se a primeira bola retirada for vermelha e não for devolvida à urna, restam $M - 1$ bolas vermelhas entre $N - 1$ bolas. Portanto,

$$P(X_2 = 1 \mid X_1 = 1) = \frac{M - 1}{N - 1}.$$

Em geral,

$$\frac{M - 1}{N - 1} \neq \frac{M}{N}.$$

Logo,

$$P(X_2 = 1 \mid X_1 = 1) \neq P(X_2 = 1),$$

e as retiradas não são independentes.

Na urna do experimento,

$$P(X_2 = 1) = \frac{900}{2400},$$

enquanto

$$P(X_2 = 1 \mid X_1 = 1) = \frac{899}{2399}.$$

A ausência de reposição modifica a composição da urna após cada retirada e, conseqüentemente, a probabilidade associada às retiradas seguintes.

3.7 Modelo estatístico e função de verossimilhança

No exemplo da urna, a representação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p)$$

especifica probabilisticamente como os dados podem ser produzidos para cada possível valor de p . Essa representação é um exemplo de **modelo estatístico**.

De forma mais geral, a análise inferencial requer uma representação probabilística para o vetor de observações

$$\mathbf{X} = (X_1, \dots, X_n).$$

Essa representação deve especificar quais distribuições de probabilidade são consideradas possíveis para $\mathbf{X}$ e quais quantidades desconhecidas distinguem essas distribuições.

Modelo estatístico

Considere um vetor aleatório $\mathbf{X}$ que assume valores em um espaço amostral $\mathcal{X}$. Um **modelo estatístico paramétrico** é uma família de distribuições de probabilidade

$$\mathcal{F} = \{F(\cdot \mid \theta) : \theta \in \Theta\},$$

em que:

- θ representa o parâmetro, ou vetor de parâmetros, do modelo;
- Θ é o **espaço paramétrico**, isto é, o conjunto dos valores possíveis de θ ;
- para cada $\theta \in \Theta$, $F(\cdot \mid \theta)$ representa uma possível distribuição conjunta para $\mathbf{X}$.

Na abordagem frequentista, admite-se que existe um valor fixo, porém desconhecido, de θ associado ao mecanismo que produziu os dados. O objetivo inferencial consiste em utilizar a amostra observada para obter informação sobre esse valor.

Quando a distribuição conjunta possui função de probabilidade ou densidade, ela pode ser representada por

$$f(\mathbf{x} \mid \theta), \quad \mathbf{x} \in \mathcal{X}, \quad \theta \in \Theta.$$

Para cada valor fixado de θ , a função $f(\mathbf{x} \mid \theta)$ descreve probabilisticamente os possíveis valores de $\mathbf{X}$.

i Processo Gerador de Dados e modelo estatístico

O **Processo Gerador de Dados (PGD)** corresponde ao mecanismo que produz os dados e pode envolver aspectos da população, seleção das unidades, condições de medição, dependência e outras fontes de variabilidade.

O **modelo estatístico** é uma representação probabilística dos aspectos desse processo considerados relevantes para a análise.

Assim, o modelo não precisa reproduzir todos os detalhes do PGD. Ele estabelece uma família de distribuições probabilísticas dentro da qual será realizada a inferência.

A expressão $f_{\mathbf{X}}(\mathbf{x} \mid \theta)$ representa a **função de probabilidade ou densidade conjunta da amostra**. Ela não precisa, em geral, ser escrita como produto das funções correspondentes às observações individuais.

Quando $X_1, \dots, X_n$ são independentes e identicamente distribuídas, com função de probabilidade ou densidade comum $f(\cdot \mid \theta)$, a independência permite escrever

$$f_{\mathbf{X}}(\mathbf{x} \mid \theta) = \prod_{i=1}^n f(x_i \mid \theta).$$

A forma em produto é, portanto, consequência da hipótese de independência. Para observações dependentes, a distribuição conjunta deve incorporar a estrutura de dependência existente.

Distribuição conjunta da amostra no modelo Bernoulli

No modelo Bernoulli da urna,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p),$$

o parâmetro do modelo é

$$\theta = p,$$

com espaço paramétrico

$$\Theta = [0, 1].$$

Como cada variável X_i assume os valores 0 ou 1, o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n)$$

assume valores no espaço amostral

$$\mathcal{X} = \{0, 1\}^n.$$

Para cada observação X_i , a função de probabilidade Bernoulli pode ser escrita como

$$f(x_i | p) = P(X = x_i | p) = p^{x_i}(1 - p)^{1-x_i}, \quad x_i \in \{0, 1\}.$$

Nesta notação, p é o parâmetro fixado do modelo. A barra vertical é utilizada para indicar que a função de probabilidade é especificada para determinado valor de p ; não estamos tratando p como uma variável aleatória.

Essa expressão representa simultaneamente as duas possibilidades. Se $x_i = 1$,

$$f(1 | p) = P(X = 1 | p) = p,$$

enquanto, se $x_i = 0$,

$$f(0 | p) = P(X = 0 | p) = 1 - p.$$

Considere agora o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n)$$

e uma possível realização

$$\mathbf{x} = (x_1, \dots, x_n) \in \{0, 1\}^n.$$

Como as variáveis $X_1, \dots, X_n$ são independentes, a função de probabilidade conjunta de $\mathbf{X}$ é o produto das funções de probabilidade individuais:

$$f_{\mathbf{X}}(\mathbf{x} | p) = \prod_{i=1}^n f(x_i | p).$$

Substituindo a função de probabilidade Bernoulli,

$$f_{\mathbf{X}}(\mathbf{x} | p) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}.$$

Agrupando os fatores que envolvem p e $1 - p$,

$$f_{\mathbf{X}}(\mathbf{x} \mid p) = p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n (1-x_i)}.$$

Retomando a estatística definida anteriormente,

$$Y = \sum_{i=1}^n X_i,$$

como cada X_i assume os valores 0 ou 1, Y representa o número de bolas vermelhas na amostra aleatória.

Depois que uma realização $\mathbf{x} = (x_1, \dots, x_n)$ é observada, Y assume o valor

$$y = \sum_{i=1}^n x_i,$$

que corresponde ao número efetivamente observado de bolas vermelhas.

Além disso,

$$\sum_{i=1}^n (1 - x_i) = n - \sum_{i=1}^n x_i = n - y,$$

de modo que $n - y$ é o número de bolas brancas na sequência observada.

Consequentemente, a função de probabilidade conjunta da amostra pode ser escrita como

$$f_{\mathbf{X}}(\mathbf{x} \mid p) = p^y (1-p)^{n-y}, \quad \mathbf{x} \in \{0, 1\}^n. \quad (3.1)$$

A Equação 3.1 fornece, para um valor fixado de p , a probabilidade associada a cada possível realização $\mathbf{x} = (x_1, \dots, x_n)$ do vetor aleatório $\mathbf{X}$. Antes da observação dos dados, $\mathbf{X}$ é aleatório e diferentes sequências podem ser observadas.

Por exemplo, para $n = 5$, as sequências

$$(1, 0, 1, 0, 0) \quad \text{e} \quad (0, 1, 0, 0, 1)$$

possuem, em ambos os casos, $v = 2$. Para um valor fixado de p , cada uma dessas sequências possui probabilidade

$$p^2 (1-p)^3.$$

Isso ocorre porque, nesse modelo, a função de probabilidade conjunta depende da sequência $\mathbf{x}$ por meio do número de ocorrências de 1 e de 0, e não da ordem em que esses valores aparecem.

i Sequência observada e número de sucessos

A probabilidade de uma sequência específica com y bolas vermelhas é

$$p^y(1-p)^{n-y}.$$

Essa expressão não deve ser confundida com a probabilidade de observar **exatamente y bolas vermelhas, independentemente da ordem em que aparecem na sequência.**

Como existem

$$\binom{n}{y}$$

sequências distintas com exatamente y ocorrências de 1, a distribuição da estatística

$$Y = \sum_{i=1}^n X_i$$

é

$$P(Y = y | p) = \binom{n}{y} p^y (1-p)^{n-y}, \quad y = 0, 1, \dots, n.$$

Assim,

$$Y \sim \text{Bin}(n, p).$$

Portanto, para cada valor $p \in [0, 1]$, o modelo especifica uma distribuição conjunta para $\mathbf{X}$. A amostra observada corresponde a uma realização particular dessa distribuição.

Função de verossimilhança

Depois que a amostra é observada, a perspectiva pode ser invertida. Os dados

$$\mathbf{x} = (x_1, \dots, x_n)$$

passam a ser conhecidos, enquanto o parâmetro θ permanece desconhecido.

A mesma expressão matemática $f_{\mathbf{X}}(\mathbf{x} | \theta)$ pode então ser examinada como função de θ , mantendo $\mathbf{x}$ fixado.

! Função de verossimilhança

Para uma amostra observada $\mathbf{x}$, a **função de verossimilhança** é definida por

$$L(\theta; \mathbf{x}) = f_{\mathbf{X}}(\mathbf{x} | \theta), \quad \theta \in \Theta,$$

considerada como função do parâmetro θ , com os dados $\mathbf{x}$ fixados.

A diferença entre a função de probabilidade ou densidade e a função de verossimilhança está, portanto, no elemento que é considerado variável.

Na função

$$f_{\mathbf{X}}(\mathbf{x} | \theta),$$

fixa-se θ e estudam-se os possíveis valores de $\mathbf{X}$.

Na função de verossimilhança

$$L(\theta; \mathbf{x}),$$

fixa-se a amostra observada $\mathbf{x}$ e comparam-se os diferentes valores de θ permitidos pelo modelo.

! Probabilidade e verossimilhança

A verossimilhança não é, em geral, uma distribuição de probabilidade para θ .

Na abordagem frequentista, θ é tratado como uma quantidade fixa e desconhecida. A função $L(\theta; \mathbf{x})$ permite comparar os diferentes valores de θ em relação aos dados observados.

Valores de θ que produzem maior verossimilhança apresentam maior compatibilidade com os dados observados dentro do modelo considerado. Essa comparação é relativa: a verossimilhança não representa a probabilidade de θ assumir determinado valor (Cox, 2006, seq. 2.1).

Verossimilhança no modelo Bernoulli

Na distribuição conjunta do modelo Bernoulli, obtivemos em Equação 3.1

$$f_{\mathbf{X}}(\mathbf{x} | p) = p^y (1 - p)^{n-y},$$

em que

$$y = \sum_{i=1}^n x_i$$

é o valor observado da estatística

$$Y = \sum_{i=1}^n X_i.$$

Na interpretação probabilística dessa expressão, p é fixado e consideram-se as diferentes realizações possíveis de $\mathbf{X}$.

Depois que uma realização específica

$$\mathbf{x} = (x_1, \dots, x_n)$$

é observada, ocorre uma mudança de perspectiva. Os valores $x_1, \dots, x_n$ e, conseqüentemente, y passam a ser fixos, enquanto p é a quantidade desconhecida.

A mesma expressão da Equação 3.1, considerada agora como função de p , define a função de verossimilhança:

$$L(p; \mathbf{x}) = f_{\mathbf{X}}(\mathbf{x} | p) = p^y (1 - p)^{n-y}, \quad 0 \leq p \leq 1.$$

Portanto, não estamos definindo uma nova distribuição de probabilidade. A expressão matemática é a mesma, mas sua interpretação é diferente:

- em $f_{\mathbf{X}}(\mathbf{x} | p)$, fixa-se p e consideram-se os possíveis valores de $\mathbf{X}$;
- em $L(p; \mathbf{x})$, fixa-se a realização observada $\mathbf{x}$ e comparam-se os possíveis valores de p .

Considere, por exemplo, uma amostra de tamanho $n = 50$ na qual foram observadas $y = 20$ bolas vermelhas. Nesse caso,

$$L(p; \mathbf{x}) = p^{20} (1 - p)^{30}.$$

Os dados permanecem fixos: foram observadas 20 bolas vermelhas e 30 bolas brancas. O que varia é p . A função de verossimilhança permite comparar os diferentes valores de $p \in [0, 1]$ em relação à mesma amostra observada.

A função pode ser visualizada diretamente na sua escala original.

```

library(ggplot2)

n <- 50
y <- 20

p_grade <- seq(0, 1, length.out = 1001)

dados_veross <- data.frame(
  p = p_grade
)

dados_veross$L <- with(
  dados_veross,
  p^y * (1 - p)^(n - y)
)

# Localização numérica do maior valor da verossimilhança
indice_max <- which.max(dados_veross$L)

p_max <- dados_veross$p[indice_max]
L_max <- dados_veross$L[indice_max]

ggplot(dados_veross, aes(x = p, y = L)) +
  geom_line(
    color = "#08519C",
    linewidth = 1.3
  ) +
  geom_vline(
    xintercept = p_max,
    linetype = "dashed",
    color = "#CB181D",
    linewidth = 0.9
  ) +
  geom_point(
    x = p_max,
    y = L_max,
    color = "#CB181D",
    size = 3
  ) +
  annotate(
    "label",
    x = 0.52,

```

```

    y = 0.92 * L_max,
    label = "maior valor em p = 0,40",
    color = "#A50F15",
    fill = "white",
    size = 4
) +
scale_x_continuous(
  limits = c(0, 1),
  breaks = seq(0, 1, by = 0.1),
  labels = scales::label_number(
    accuracy = 0.1,
    decimal.mark = ",",
  )
) +
scale_y_continuous(
  labels = scales::label_scientific()
) +
labs(
  x = "Valor de p",
  y = expression(L(p~";"~bold(x))),
  title = "Função de verossimilhança",
  subtitle = "Modelo Bernoulli: n = 50 e y = 20"
) +
theme_minimal(base_size = 13) +
theme(
  panel.grid.minor = element_blank(),
  plot.title.position = "plot"
)

```


Função de verossimilhança

Modelo Bernoulli: $n = 50$ e $y = 20$




Figura 3.1: Função de verossimilhança para o modelo Bernoulli com $n = 50$ e $y = 20$.

A altura da curva depende da escala da função de verossimilhança e, neste exemplo, seus valores são numericamente pequenos. O que interessa para a comparação entre valores de p é a forma da função e sua posição relativa. O gráfico mostra que valores próximos de 0,40 apresentam maior verossimilhança para a amostra observada, enquanto valores mais afastados produzem valores menores de $L(p; \mathbf{x})$.

Log-verossimilhança

Em muitos problemas, é conveniente trabalhar com o logaritmo da função de verossimilhança. Define-se a **função de log-verossimilhança** por

$$\ell(p; \mathbf{x}) = \log L(p; \mathbf{x}).$$

No modelo Bernoulli,

$$L(p; \mathbf{x}) = p^y(1-p)^{n-y},$$

de modo que

$$\ell(p; \mathbf{x}) = \log [p^y(1-p)^{n-y}].$$

Utilizando as propriedades do logaritmo,

$$\ell(p; \mathbf{x}) = y \log p + (n - y) \log(1 - p), \quad 0 < p < 1.$$

Para o exemplo com $n = 50$ e $y = 20$,

$$\ell(p; \mathbf{x}) = 20 \log p + 30 \log(1 - p).$$

O logaritmo transforma o produto presente na verossimilhança em uma soma, o que facilita manipulações algébricas e numéricas.

Além disso, como a função logaritmo é estritamente crescente, se

$$L(p_1; \mathbf{x}) > L(p_2; \mathbf{x}),$$

então

$$\ell(p_1; \mathbf{x}) > \ell(p_2; \mathbf{x}).$$

Consequentemente, a verossimilhança e a log-verossimilhança ordenam os valores de p da mesma forma e atingem seu máximo no mesmo ponto.

```
n <- 50
y <- 20

# Os extremos 0 e 1 são excluídos porque log(0) não é definido.
p_grade <- seq(0.001, 0.999, by = 0.001)

dados_logveross <- data.frame(
  p = p_grade
)

dados_logveross$logL <- with(
  dados_logveross,
```

```

  y * log(p) + (n - y) * log(1 - p)
)

indice_max <- which.max(dados_logveross$logL)

p_max <- dados_logveross$p[indice_max]
logL_max <- dados_logveross$logL[indice_max]

ggplot(dados_logveross, aes(x = p, y = logL)) +
  geom_line(
    color = "#54278F",
    linewidth = 1.2
  ) +
  geom_vline(
    xintercept = p_max,
    linetype = "dashed",
    color = "#CB181D",
    linewidth = 0.9
  ) +
  geom_point(
    x = p_max,
    y = logL_max,
    color = "#CB181D",
    size = 3
  ) +
  annotate(
    "label",
    x = 0.52,
    y = logL_max - 5,
    label = "p = 0,40",
    color = "#A50F15",
    fill = "white",
    label.size = 0.2,
    size = 4
  ) +
  scale_x_continuous(
    limits = c(0, 1),
    breaks = seq(0, 1, by = 0.1),
    labels = scales::label_number(
      accuracy = 0.1,
      decimal.mark = ",",
    )
  )

```

```

) +
labs(
  x = "Valor de p",
  y = expression(ell(p~";"~bold(x))),
  title = "Função de log-verossimilhança",
  subtitle = "Modelo Bernoulli: n = 50 e y = 20"
) +
theme_minimal(base_size = 13) +
theme(
  panel.grid.minor = element_blank(),
  plot.title.position = "plot"
)

```

Função de log-verossimilhança

Modelo Bernoulli: $n = 50$ e $y = 20$




Figura 3.2: Função de log-verossimilhança para o modelo Bernoulli com $n = 50$ e $y = 20$.

Os dois gráficos apresentam o maior valor no mesmo ponto. A diferença está na escala vertical: o primeiro representa diretamente $L(p; \mathbf{x})$, enquanto o segundo representa seu logaritmo.

Observe ainda que, na expressão

$$L(p; \mathbf{x}) = p^y(1-p)^{n-y},$$

a sequência completa

$$(x_1, \dots, x_n)$$

aparece apenas por meio de

$$y = \sum_{i=1}^n x_i.$$

Assim, duas sequências observadas com o mesmo número y de bolas vermelhas produzem a mesma função de verossimilhança para p , mesmo que as bolas vermelhas e brancas apareçam em ordens diferentes.

Essa propriedade será formalizada posteriormente por meio do conceito de **estatística suficiente**.

Verossimilhança e estimação

A função de verossimilhança permite comparar diferentes valores do parâmetro em relação à amostra observada. Uma forma de utilizar essa comparação para construir uma estimativa consiste em procurar o valor de θ que torna a verossimilhança tão grande quanto possível.

Considere uma amostra observada $\mathbf{x}$. Para cada valor $\theta \in \Theta$, podemos calcular

$$L(\theta; \mathbf{x}).$$

Entre os valores permitidos pelo espaço paramétrico Θ , procuramos aqueles para os quais a função de verossimilhança atinge seu maior valor.

Se existir um único valor θ^* tal que

$$L(\theta^*; \mathbf{x}) \geq L(\theta; \mathbf{x}) \quad \text{para todo } \theta \in \Theta,$$

então θ^* é o valor de θ que maximiza a função de verossimilhança para a amostra observada.

Esse valor é denominado **estimativa de máxima verossimilhança**.

Em alguns problemas, entretanto, mais de um valor de θ pode produzir o mesmo valor máximo da função de verossimilhança. Por essa razão, é conveniente representar o conjunto de todos os valores que maximizam a função.

A notação

$$\arg \max_{\theta \in \Theta} L(\theta; \mathbf{x})$$

representa o conjunto dos valores de θ em Θ nos quais a função $L(\theta; \mathbf{x})$ atinge seu máximo.

A expressão $\arg \max$ deve ser distinguida do próprio valor máximo da função. Enquanto

$$\max_{\theta \in \Theta} L(\theta; \mathbf{x})$$

representa o maior valor assumido pela função de verossimilhança,

$$\arg \max_{\theta \in \Theta} L(\theta; \mathbf{x})$$

representa o valor, ou os valores, de θ nos quais esse máximo é atingido.

Por exemplo, se uma função atinge seu maior valor em $\theta = 2$, então

$$\arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}) = \{2\}.$$

A estimativa de máxima verossimilhança é, portanto, qualquer valor pertencente a esse conjunto. Quando esse conjunto possui mais de um elemento, qualquer um de seus elementos pode ser considerado uma estimativa de máxima verossimilhança.

Para definir um estimador como uma função da amostra, entretanto, é necessário estabelecer uma regra de escolha quando houver mais de um maximizador. Quando o máximo é único, essa escolha não apresenta ambiguidade. Escrevemos

$$\hat{\theta}_{\text{MV}}(\mathbf{x}) \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}).$$

O símbolo $\in$ é utilizado porque, em geral, o lado direito representa um conjunto de valores que maximizam a verossimilhança. Quando o máximo é atingido em um único valor, podemos escrever, de forma equivalente,

$$\hat{\theta}_{\text{MV}}(\mathbf{x}) = \theta^*.$$

Assim, para uma amostra observada $\mathbf{x}$, a máxima verossimilhança fornece uma regra para selecionar um valor do parâmetro a partir dos dados.

Até aqui estamos tratando de uma **estimativa**, pois a amostra já foi observada. Para obter o correspondente estimador, consideramos a mesma regra para todas as possíveis realizações da amostra aleatória.

A cada possível realização $\mathbf{x}$ de $\mathbf{X}$, associamos um valor $\hat{\theta}_{\text{MV}}(\mathbf{x})$ que maximiza a função de verossimilhança. Essa regra define o **estimador de máxima verossimilhança**. Antes da observação dos dados, escrevemos

$$\hat{\theta}_{\text{MV}} = \hat{\theta}_{\text{MV}}(\mathbf{X}).$$

Portanto,

$$\hat{\theta}_{\text{MV}}(\mathbf{X})$$

é uma função da amostra aleatória e, por isso, é uma variável aleatória. Depois que a amostra assume o valor observado $\mathbf{x}$, obtemos

$$\hat{\theta}_{\text{MV}}(\mathbf{x}),$$

que é a estimativa de máxima verossimilhança correspondente.

Essa distinção é a mesma apresentada anteriormente para estimadores e estimativas: o **estimador de máxima verossimilhança** é a regra definida em função da amostra aleatória, enquanto a **estimativa de máxima verossimilhança** é o valor produzido por essa regra para uma amostra particular.

Verossimilhança e estimação no exemplo-guia

No modelo Bernoulli,

$$L(p; \mathbf{x}) = p^y (1 - p)^{n-y}.$$

Para determinar o valor de p que maximiza essa função, podemos trabalhar com a log-verossimilhança. Como a amostra observada $\mathbf{x}$ permanece fixa durante a maximização, escreveremos na derivação a seguir $\ell(p)$ como forma abreviada de $\ell(p; \mathbf{x})$.

Para $0 < y < n$, a log-verossimilhança é

$$\ell(p) = \log L(p; \mathbf{x}) = y \log p + (n - y) \log(1 - p).$$

Como o logaritmo é uma função estritamente crescente, maximizar $\ell(p)$ equivale a maximizar $L(p; \mathbf{x})$.

Derivando em relação a p ,

$$\ell'(p) = \frac{d\ell(p)}{dp} = \frac{y}{p} - \frac{n-y}{1-p} = \frac{y-np}{p(1-p)}.$$

O ponto crítico satisfaz

$$y - np = 0,$$

de modo que

$$\hat{p}_{\text{MV}}(\mathbf{x}) = \frac{y}{n}.$$

Além disso,

$$\ell''(p) = \frac{d^2\ell(p)}{dp^2} = -\frac{y}{p^2} - \frac{n-y}{(1-p)^2} < 0,$$

para $0 < p < 1$. Portanto, o ponto crítico corresponde a um máximo da verossimilhança.

Nos casos de fronteira, o máximo pode ser identificado diretamente pela forma da verossimilhança.

Se $y = 0$,

$$L(p; \mathbf{x}) = (1-p)^n,$$

que é máxima em $p = 0$. Portanto,

$$\hat{p}_{\text{MV}} = 0.$$

Se $y = n$,

$$L(p; \mathbf{x}) = p^n,$$

que é máxima em $p = 1$. Portanto,

$$\hat{p}_{\text{MV}} = 1.$$

Assim, em todos os casos,

$$\hat{p}_{\text{MV}} = \frac{Y}{n}.$$

A proporção amostral, que anteriormente foi apresentada como uma estatística e utilizada como estimador de p , surge agora também como estimador de máxima verossimilhança.

i Proporção amostral no modelo Bernoulli

No modelo Bernoulli,

$$\hat{p} = \frac{Y}{n}$$

pode ser considerada sob diferentes aspectos:

1. é uma **estatística**, pois é uma função da amostra;
2. é um **estimador de p** , quando utilizada para estimar a proporção populacional;
3. é o **estimador de máxima verossimilhança de p** , pois resulta da maximização da função de verossimilhança.

Depois que a amostra é observada e $Y = y$, o valor

$$\hat{p}(\mathbf{x}) = \frac{y}{n}$$

é a estimativa correspondente.

A máxima verossimilhança será desenvolvida como método geral de estimação no capítulo **Métodos de Estimação Pontual**. O conceito de suficiência, sugerido pelo fato de a verossimilhança Bernoulli depender dos dados apenas por meio do valor observado y da estatística

$$Y = \sum_{i=1}^n X_i,$$

será formalizado no capítulo **Avaliação de Estimadores e Princípios de Redução de Dados**.

Verificação de aprendizagem

1. O que constitui um modelo estatístico paramétrico?
2. No modelo $\mathcal{F} = \{F(\cdot | \theta) : \theta \in \Theta\}$, qual é o papel de θ e de Θ ?
3. Por que a distribuição conjunta da amostra não pode ser escrita, em geral, como $\prod_{i=1}^n f(x_i | \theta)$?

4. Explique a diferença entre considerar $f(\mathbf{x} \mid \theta)$ como função de probabilidade ou densidade conjunta, para θ fixado, e considerá-la como função de verossimilhança depois que $\mathbf{x}$ é observado.
5. Na função $L(\theta; \mathbf{x})$, o que permanece fixo e o que varia?
6. Por que a verossimilhança não deve ser interpretada como uma distribuição de probabilidade para θ ?
7. No modelo Bernoulli, por que a função de verossimilhança depende da sequência observada apenas por meio de $v = \sum_i x_i$, valor observado da estatística $Y = \sum_i X_i$?
8. Explique por que $\hat{p} = V/n$ pode ser considerada simultaneamente uma estatística, um estimador de p e o estimador de máxima verossimilhança de p .

3.8 Variabilidade dos estimadores

Um estimador é uma função da amostra aleatória. Se

$$\hat{\theta} = T(\mathbf{X}),$$

então seu valor depende dos resultados que compõem $\mathbf{X}$. Amostras diferentes, obtidas segundo o mesmo mecanismo, podem produzir valores diferentes de $\hat{\theta}$.

Fixados o modelo estatístico e um valor do parâmetro θ , a distribuição de probabilidade de $\mathbf{X}$ induz uma distribuição de probabilidade para $T(\mathbf{X})$. Essa distribuição é a **distribuição amostral** da estatística.

Assim, a variabilidade observada entre diferentes estimativas pode ser descrita probabilisticamente. Características da distribuição amostral, como posição e dispersão, permitem estudar o comportamento de uma estatística quando o mecanismo de amostragem é repetido.

No Capítulo 4, essa ideia será desenvolvida para estatísticas como $\bar{X}$, S^2 e $\hat{p}$, considerando também o efeito do tamanho amostral, a amostragem sem reposição, resultados exatos, aproximações e simulação.

A distribuição amostral estabelece, portanto, a ligação entre a variabilidade observada no experimento e sua representação probabilística.

3.9 Exploração computacional do experimento da urna

O experimento realizado em sala de aula pode ser reproduzido computacionalmente. O objetivo é repetir o mesmo mecanismo de amostragem um número maior de vezes e examinar com mais detalhes a variabilidade da proporção amostral.

Nesta seção, retomamos o **mecanismo físico sem reposição** utilizado no experimento em sala de aula. Portanto, essa exploração não corresponde ao modelo Bernoulli i.i.d. com reposição utilizado anteriormente para introduzir a função de verossimilhança.

Preparação do ambiente computacional

A exploração utiliza os pacotes `tidyverse` (Wickham et al., 2019) e `moderndive` (Kim; Ismay; Kuhn, 2021). O primeiro fornece ferramentas para manipulação e visualização de dados, enquanto o segundo contém a população virtual utilizada no experimento e a função de amostragem repetida.

```
library(tidyverse)
library(moderndive)
```

População virtual e uma amostra

O pacote `moderndive` contém o *data frame* `bowl`, que representa virtualmente a composição da urna utilizada no experimento.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
5       5 white
6       6 white
7       7 red
8       8 white
9       9 red
10      10 white
# i 2,390 more rows
```

Cada linha corresponde a uma bola. A variável `ball_ID` identifica a unidade e `color` informa sua cor.

Podemos obter a composição completa da população virtual por meio de um censo:

```
censo_virtual <- bowl %>%
  summarize(
    N = n(),
    N_vermelha = sum(color == "red"),
    p = N_vermelha / N
  )

censo_virtual
```

```
# A tibble: 1 x 3
      N N_vermelha      p
  <int>   <int> <dbl>
1  2400     900 0.375
```

O resultado fornece $N = 2400$ bolas, das quais 900 são vermelhas. Portanto,

$$p = \frac{900}{2400} = 0,375.$$

Como essa composição é conhecida, o experimento permite comparar as estimativas obtidas nas amostras com o valor populacional conhecido $p = 0,375$.

Para reproduzir computacionalmente uma amostra de $n = 50$ bolas sem reposição, utilizamos `rep_sample_n()`:

```
set.seed(2026)

pa_virtual <- bowl %>%
  rep_sample_n(
    size = 50,
    replace = FALSE
  )

pa_virtual
```

```
# A tibble: 50 x 3
# Groups:   replicate [1]
  replicate ball_ID color
      <int>   <int> <chr>
1         1     733 white
2         1     993 red
```

```

3          1      2342 red
4          1      1647 white
5          1      1883 red
6          1       164 red
7          1     1200 red
8          1       389 white
9          1       287 white
10         1     2362 red
# i 40 more rows

```

A função `set.seed()` fixa o estado inicial do gerador de números pseudoaleatórios e permite reproduzir a mesma amostra ao executar novamente o código.

A variável `replicate` identifica a repetição da amostragem. Como foi solicitada uma única amostra, seu valor é igual a 1 em todas as linhas.

Podemos identificar cada bola vermelha por meio da expressão lógica `color == "red"`:

```

pa_virtual <- pa_virtual %>%
  mutate(
    is_vermelha = color == "red"
  )

pa_virtual

```

```

# A tibble: 50 x 4
# Groups:   replicate [1]
  replicate ball_ID color is_vermelha
    <int>    <int> <chr> <lgl>
1         1      733 white FALSE
2         1      993 red  TRUE
3         1     2342 red  TRUE
4         1     1647 white FALSE
5         1     1883 red  TRUE
6         1      164 red  TRUE
7         1     1200 red  TRUE
8         1      389 white FALSE
9         1      287 white FALSE
10        1     2362 red  TRUE
# i 40 more rows

```

O R representa TRUE e FALSE como valores lógicos. Em operações de soma, TRUE é tratado como 1 e FALSE como 0. Dessa forma, a soma da variável `is_vermelha` fornece diretamente o número de bolas vermelhas da amostra.

```
resumo_amostra <- pa_virtual %>%
  summarize(
    Y = sum(is_vermelha),
    p_hat = Y / n()
  )

resumo_amostra
```

```
# A tibble: 1 x 3
  replicate      Y p_hat
  <int> <int> <dbl>
1         1    16  0.32
```

Nesta amostra, o valor observado da estatística Y foi $v = 16$. A proporção amostral observada foi 0,32.

Esse valor corresponde à estimativa

$$\hat{p}(\mathbf{x}) = \frac{y}{n}.$$

No código, a coluna V armazena o valor observado de Y em cada amostra.

Repetição da amostragem e variabilidade

Para examinar a variação entre amostras, repetiremos o procedimento 20 vezes. Cada repetição utiliza uma amostra de tamanho $n = 50$ sem reposição e começa novamente a partir da população completa.

```
set.seed(2026)

amostra_virtual <- bowl %>%
  rep_sample_n(
    size = 50,
    reps = 20,
    replace = FALSE
  )

amostra_virtual
```

```
# A tibble: 1,000 x 3
# Groups:   replicate [20]
  replicate ball_ID color
    <int>    <int> <chr>
1         1     733 white
2         1     993 red
3         1    2342 red
4         1    1647 white
5         1    1883 red
6         1     164 red
7         1    1200 red
8         1     389 white
9         1     287 white
10        1    2362 red
# i 990 more rows
```

O objeto possui $20 \times 50 = 1000$ linhas. A variável `replicate` identifica a amostra à qual cada linha pertence.

As 20 proporções amostrais são obtidas agrupando os dados por repetição:

```
virtual_prop_vermelha <- amostra_virtual %>%
  group_by(replicate) %>%
  summarize(
    Y = sum(color == "red"),
    p_hat = Y / n(),
    .groups = "drop"
  )

virtual_prop_vermelha
```


```
# A tibble: 20 x 3
  replicate      Y p_hat
    <int> <int> <dbl>
1         1     16 0.32
2         2     22 0.44
3         3     19 0.38
4         4     27 0.54
5         5     18 0.36
6         6     19 0.38
7         7     16 0.32
8         8     17 0.34
```

9	9	21	0.42
10	10	20	0.4
11	11	23	0.46
12	12	23	0.46
13	13	15	0.3
14	14	23	0.46
15	15	27	0.54
16	16	23	0.46
17	17	17	0.34
18	18	21	0.42
19	19	15	0.3
20	20	18	0.36

Cada linha corresponde agora a uma amostra e contém seu número de bolas vermelhas e sua proporção amostral.

A distribuição empírica desses 20 valores pode ser visualizada por meio de um histograma:

```
ggplot(
  virtual_prop_vermelha,
  aes(x = p_hat)
) +
  geom_histogram(
    binwidth = 0.05,
    boundary = 0.40,
    color = "white"
  ) +
  geom_vline(
    xintercept = 0.375,
    linetype = "dashed"
  ) +
  labs(
    x = "Proporção de bolas vermelhas",
    y = "Frequência",
    title = "Distribuição empírica das proporções amostrais"
  )
)
```

O argumento `binwidth = 0.05` estabelece classes de amplitude 0,05, enquanto `boundary = 0.40` posiciona um dos limites de classe em 0,40. Assim, o histograma utiliza limites como 0,30, 0,35, 0,40, 0,45 e 0,50.

O código utiliza ponto como separador decimal porque essa é a sintaxe do R; no texto matemático, os mesmos valores são escritos com vírgula.

O histograma mostra que as proporções obtidas não são iguais entre as repetições. O valor populacional $p = 0,375$ permanece fixo, enquanto $\hat{p}$ varia de uma amostra para outra.

Com apenas 20 repetições, o histograma apresenta uma distribuição empírica relativamente irregular. O aumento do número de repetições permite visualizar com maior clareza o comportamento da proporção amostral sob o mecanismo de amostragem considerado.

Verificação de aprendizagem

1. Compare o valor de $p = 0,375$ com os diferentes valores de $\hat{p}$ obtidos nas 20 amostras.
2. Identifique no código quais elementos permanecem fixos em todas as repetições e quais variam.
3. Explique por que uma única amostra não permite visualizar a variabilidade amostral de $\hat{p}$.
4. Compare conceitualmente o experimento computacional com o experimento realizado em sala de aula.

Atividade computacional de consolidação

1. Repita o experimento utilizando `rep_sample_n()` com `size = 50` e `reps = 1000`.
2. Para cada uma das 1000 amostras, calcule Y e $\hat{p}$.
3. Construa um histograma das 1000 proporções amostrais e acrescente uma linha vertical indicando $p = 0,375$.
4. Compare esse histograma com o obtido a partir de apenas 20 amostras.
5. Utilize as 1000 repetições para avaliar empiricamente a frequência com que $\hat{p} \leq 0,30$.
6. Avalie também a frequência com que $\hat{p} \leq 0,20$ e compare os dois resultados.
7. Escreva uma interpretação relacionando o resultado à variabilidade amostral.

O experimento físico e sua reprodução computacional mostram que o parâmetro populacional permanece fixo, enquanto as estatísticas calculadas a partir das amostras variam. A inferência estatística utiliza essa variabilidade, representada por modelos probabilísticos, para obter informação sobre quantidades desconhecidas. A passagem dessa variabilidade empírica para a distribuição de uma estatística constitui o objeto do Capítulo 4.

Questões de revisão

1. Uma indústria produziu 12.000 embalagens durante um turno. Para avaliar a qualidade da selagem, 240 embalagens foram selecionadas aleatoriamente e 18 apresentaram falha.
 - a. Identifique a população, a unidade observacional e a amostra.
 - b. Qual parâmetro populacional está sendo estudado?
 - c. Calcule uma estatística amostral adequada para obter informação sobre esse parâmetro.
2. Considere um lote com 800 recipientes.
 - a. Se todos os recipientes forem avaliados e sua massa média for calculada, essa média é um parâmetro ou uma estatística?
 - b. Se apenas 50 recipientes forem selecionados e sua massa média for calculada, como esse valor deve ser classificado?
 - c. Explique a diferença entre as duas situações.
3. Seja $X_1, \dots, X_n$ uma amostra e seja μ um parâmetro desconhecido. Determine quais expressões são estatísticas:

- a. $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$;
- b. $\max\{X_1, \dots, X_n\}$;
- c. $\bar{X} - \mu$;
- d. $\sum_{i=1}^n (X_i - \bar{X})^2$.

Justifique as respostas.

4. Para estimar a média populacional μ , utiliza-se

$$\hat{\mu} = \bar{X}.$$

Uma amostra apresentou os valores

$$7, \quad 8, \quad 8, \quad 9.$$

- a. Qual é o parâmetro?
 - b. Qual é o estimador?
 - c. Qual é a estimativa obtida?
5. Duas amostras de mesmo tamanho, obtidas da mesma população pelo mesmo procedimento, produziram médias iguais a 12,4 e 13,1.
- a. Por que as duas médias podem ser diferentes?
 - b. O que permanece fixo e o que varia entre as duas amostras?
6. Considere retiradas sucessivas de uma urna com bolas vermelhas e brancas.
- a. Em qual situação, com ou sem reposição, as observações podem ser representadas como i.i.d.?
 - b. Qual condição deixa de ser satisfeita na amostragem sem reposição?
 - c. Se $X_i = 1$ indicar uma bola vermelha e $X_i = 0$ uma bola branca, escreva o modelo Bernoulli para a situação em que as observações são i.i.d. e indique o significado de p .
7. Avalie se a representação por observações i.i.d. parece adequada em cada situação.
- a. Trinta componentes são produzidos sucessivamente por um processo mantido sob condições estáveis. Admita que não haja evidência de dependência entre os resultados de componentes consecutivos.

- b. A temperatura de um mesmo local é registrada a cada minuto durante duas horas.

Em cada caso, discuta separadamente a plausibilidade das hipóteses de distribuições idênticas e de independência.

8. Uma universidade envia um questionário a todos os seus estudantes, mas analisa apenas as respostas daqueles que decidiram participar.

- a. Os respondentes podem ser considerados automaticamente representativos de todos os estudantes? Justifique.
- b. Que aspecto do Processo Gerador de Dados deve ser considerado antes de realizar inferências para toda a população?

9. Considere o modelo

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

em que σ^2 é conhecida e μ é desconhecida.

- a. Qual é o parâmetro desconhecido do modelo?
- b. Qual é o espaço paramétrico usual de μ ?
- c. O que representa a família

$$\mathcal{F} = \{F(\cdot \mid \mu) : \mu \in \mathbb{R}\}?$$

- d. Para um valor fixado de μ , o que a distribuição $F(\cdot \mid \mu)$ descreve?

10. Considere uma função de probabilidade ou densidade conjunta

$$f(\mathbf{x} \mid \theta).$$

- a. Quando essa expressão é considerada como função dos possíveis valores de $\mathbf{X}$, o que permanece fixo?
- b. Depois que a amostra $\mathbf{x}$ é observada, como é definida a função de verossimilhança para θ ?
- c. Na função de verossimilhança, o que permanece fixo e o que varia?
- d. Explique por que $L(\theta; \mathbf{x})$ não deve, em geral, ser interpretada como uma distribuição de probabilidade para θ .

Referências

4 Distribuições Amostrais

4.1 Introdução

No Capítulo 3, o experimento da urna mostrou que diferentes amostras obtidas pelo mesmo mecanismo podem produzir valores distintos para uma mesma estatística. Essa variabilidade entre amostras constitui o ponto de partida para o estudo das distribuições amostrais.

Considere uma amostra aleatória

$$\mathbf{X} = (X_1, \dots, X_n)$$

e uma estatística

$$T = T(\mathbf{X}) = T(X_1, \dots, X_n).$$

Antes da observação dos dados, T é uma variável aleatória. Depois que a amostra observada $\mathbf{x} = (x_1, \dots, x_n)$ é obtida, o valor

$$T(\mathbf{x}) = T(x_1, \dots, x_n)$$

é uma realização dessa variável aleatória.

A **distribuição amostral** descreve probabilisticamente os valores que T pode assumir quando o mecanismo que gera a amostra é repetido. Ela permite estudar a variabilidade de estatísticas como a média, a proporção, a variância, o mínimo, o máximo e outras funções das observações (Ramachandran; Tsokos, 2021, cap. 4, seção 4.1, pp. 147–148; Rice, 2007, cap. 7, seção 7.3).

! Definição — Distribuição amostral

A **distribuição amostral** de uma estatística $T = T(X_1, \dots, X_n)$ é sua distribuição de probabilidade sob o mecanismo que gera a amostra (Casella; Berger, 2011, definição 5.2.1; Ramachandran; Tsokos, 2021, definição 4.1.4, p. 148; Chihara; Hesterberg, 2022, definição 4.1, pp. 78–79).

A distribuição populacional e a distribuição amostral descrevem objetos diferentes. A distribuição populacional caracteriza o comportamento de uma observação X . A distribuição amostral caracteriza o comportamento de uma função de várias observações. Em situações particulares, ambas podem pertencer à mesma família de distribuições, possivelmente com parâmetros diferentes.

Transformações e funções geradoras de momentos permitem obter distribuições amostrais exatas. A Lei dos Grandes Números, o Teorema Central do Limite, o teorema do mapeamento contínuo e o lema de Slutsky, apresentados no Capítulo 2, fornecem as ferramentas para estudar concentração e aproximações assintóticas quando o tamanho amostral aumenta.

Objetivos do capítulo

Ao final deste capítulo, o leitor deverá ser capaz de:

1. interpretar a distribuição amostral como a distribuição de uma estatística sob repetição do mecanismo que gera a amostra;
2. distinguir o modelo i.i.d. da amostragem aleatória simples sem reposição em uma população finita;
3. obter distribuições amostrais por enumeração, transformação, convolução e propriedades de distribuições conhecidas;
4. utilizar propriedades de somas e funções geradoras de momentos para identificar distribuições amostrais exatas;
5. determinar distribuições exatas e aproximações assintóticas para médias, diferenças de médias e proporções amostrais;
6. relacionar a variância amostral às distribuições derivadas do modelo normal;
7. obter distribuições de estatísticas de ordem;
8. aproximar e visualizar distribuições amostrais por simulação.

4.2 Amostra e estatística: recordação

No Capítulo 3 foram estabelecidas as distinções entre amostra aleatória e amostra observada, estatística, estimador e estimativa.

Se

$$\mathbf{X} = (X_1, \dots, X_n)$$

representa a amostra antes da observação dos dados, uma estatística é uma função

$$T = T(\mathbf{X}).$$

Como T é uma variável aleatória, seu valor pode mudar de uma amostra para outra. A distribuição de probabilidade de T é induzida pelo mecanismo que gera a amostra e, por isso, pode mudar quando esse mecanismo muda.

4.3 Dois referenciais para a geração da amostra

Duas estruturas de geração da amostra precisam ser tratadas separadamente: o modelo i.i.d. e a amostragem aleatória simples sem reposição em uma população finita. A distinção evita confundir independência probabilística com aleatorização de um plano amostral.

4.3.1 Amostragem no modelo i.i.d.

No modelo i.i.d., cada observação é gerada independentemente pela mesma distribuição. Esse referencial é apropriado para repetições independentes de um experimento, amostragem com reposição ou modelagem de uma população conceitualmente infinita (Casella; Berger, 2011, seq. 5.1; Ramachandran; Tsokos, 2021, seq. 4.1).

Se $f(x | \theta)$ representa a função de probabilidade ou densidade comum das observações, a independência permite escrever a função de probabilidade ou densidade conjunta da amostra como

$$f_{\mathbf{X}}(\mathbf{x} | \theta) = \prod_{i=1}^n f(x_i | \theta).$$

No Capítulo 3, vimos que, depois de observados os dados $\mathbf{x}$, essa mesma expressão pode ser considerada como função de θ , com $\mathbf{x}$ fixado, originando a função de verossimilhança (Casella; Berger, 2011, seq. 6.3.1; Cox, 2006, seq. 2.1):

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i | \theta).$$

Os dois objetos desempenham papéis diferentes. Para um valor fixado de θ , a distribuição amostral descreve probabilisticamente o comportamento de uma estatística sob repetição do mecanismo que gera a amostra. Na função de verossimilhança, os dados observados permanecem fixos e são comparados diferentes valores de θ . Portanto, distribuição amostral e verossimilhança estão relacionadas ao mesmo modelo probabilístico, mas não representam o mesmo objeto (Cox, 2006, seq. 1.3 e 2.1).

💡 Exemplo — Tempos de vida exponenciais

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\mu),$$

na parametrização pela média, ou seja, a densidade é

$$f(x | \mu) = \frac{1}{\mu} e^{-x/\mu} \mathbf{1}_{(0, \infty)}(x), \quad \mu > 0.$$

Neste caso,

$$E(X_i) = \mu.$$

A distribuição exponencial também pode ser parametrizada pela **taxa** λ , caso em que

$$f(x | \lambda) = \lambda e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x), \quad \lambda > 0.$$

As duas parametrizações estão relacionadas por

$$\lambda = \frac{1}{\mu} \quad \text{ou, equivalentemente,} \quad \mu = \frac{1}{\lambda}.$$

Obtenha:

1. a densidade conjunta da amostra;
2. a probabilidade

$$P(X_1 > 2, \dots, X_n > 2).$$

i Resolução — Densidade conjunta e probabilidade no modelo exponencial

Pela independência,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x} | \mu) &= \prod_{i=1}^n f(x_i | \mu) = \prod_{i=1}^n \frac{1}{\mu} e^{-x_i/\mu} \mathbf{1}_{(0, \infty)}(x_i) \\ &= \mu^{-n} \exp \left(-\frac{1}{\mu} \sum_{i=1}^n x_i \right) \prod_{i=1}^n \mathbf{1}_{(0, \infty)}(x_i). \end{aligned}$$

Para calcular a probabilidade do segundo item, primeiro obtemos a probabilidade de cauda de uma observação. Para $x > 0$,

$$\begin{aligned}
P(X_i > x) &= \int_x^{\infty} \frac{1}{\mu} e^{-t/\mu} dt \\
&= [-e^{-t/\mu}]_x^{\infty} \\
&= e^{-x/\mu}.
\end{aligned}$$

Consequentemente, a função de distribuição da exponencial parametrizada pela média é

$$F_X(x) = P(X_i \leq x) = 1 - e^{-x/\mu}, \quad x > 0,$$

com

$$F_X(x) = 0, \quad x \leq 0.$$

Em particular,

$$P(X_i > 2) = e^{-2/\mu}.$$

Como as observações são independentes,

$$\begin{aligned}
P(X_1 > 2, \dots, X_n > 2) &= \prod_{i=1}^n P(X_i > 2) \\
&= (e^{-2/\mu})^n \\
&= e^{-2n/\mu}.
\end{aligned}$$

4.3.2 Amostragem aleatória simples sem reposição

Considere uma população finita formada por N unidades, às quais estão associados os valores fixos

$$a_1, \dots, a_N.$$

O procedimento pode ser representado por n seleções sequenciais sem reposição, em que cada unidade ainda disponível possui a mesma probabilidade de ser escolhida em cada etapa. Essa representação ordenada permite definir as variáveis aleatórias $X_1, \dots, X_n$. As observações possuem a mesma distribuição marginal, mas não são independentes (Cox, 2006, seq. 9.2; Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, seq. 7.3.1).

Defina a média e a variância dessa população finita por

$$\mu_N = \frac{1}{N} \sum_{j=1}^N a_j$$

e

$$\sigma_N^2 = \frac{1}{N} \sum_{j=1}^N (a_j - \mu_N)^2.$$

Para descrever probabilisticamente a amostra, considere J_i como o índice da unidade selecionada na i -ésima posição e defina

$$X_i = a_{J_i}, \quad i = 1, \dots, n.$$

Na amostragem aleatória simples sem reposição,

$$P(J_i = r) = \frac{1}{N}, \quad r = 1, \dots, N.$$

Portanto, cada unidade possui a mesma probabilidade de ocupar qualquer posição da amostra. A variável aleatória X_i registra o valor associado à unidade selecionada nessa posição.

Como J_i é uniforme sobre os índices $1, \dots, N$, a distribuição marginal de X_i corresponde à distribuição dos valores da própria população finita. Para qualquer valor x ,

$$P(X_i = x) = \frac{1}{N} \# \{r : a_r = x\},$$

em que $\# \{r : a_r = x\}$ representa o número de unidades da população cujo valor é igual a x .

Em particular, se todos os valores $a_1, \dots, a_N$ forem distintos,

$$P(X_i = a_r) = \frac{1}{N}, \quad r = 1, \dots, N.$$

! Resultado — Momentos de cada posição da amostra

Para qualquer posição $i = 1, \dots, n$,

$$E(X_i) = \mu_N$$

e

$$\text{Var}(X_i) = \sigma_N^2.$$

Assim, cada posição da amostra possui a mesma média e a mesma variância da população finita.

i Demonstração — Momentos de cada posição da amostra

Na amostragem aleatória simples sem reposição, cada uma das N unidades da população possui a mesma probabilidade de ocupar a posição i . Portanto,

$$P(J_i = r) = \frac{1}{N}, \quad r = 1, \dots, N,$$

e, como

$$X_i = a_{J_i},$$

a variável X_i assume cada valor populacional a_r com a probabilidade correspondente à seleção da unidade r .

Assim,

$$\begin{aligned} E(X_i) &= \sum_{r=1}^N a_r P(J_i = r) \\ &= \frac{1}{N} \sum_{r=1}^N a_r \\ &= \mu_N. \end{aligned}$$

Para calcular a variância, utilizamos

$$\text{Var}(X_i) = E(X_i^2) - [E(X_i)]^2.$$

O segundo momento de X_i é

$$\begin{aligned} E(X_i^2) &= \sum_{r=1}^N a_r^2 P(J_i = r) \\ &= \frac{1}{N} \sum_{r=1}^N a_r^2. \end{aligned}$$

Por outro lado, pela definição da variância da população finita,

$$\sigma_N^2 = \frac{1}{N} \sum_{r=1}^N (a_r - \mu_N)^2.$$

Expandindo,

$$\begin{aligned}
\sigma_N^2 &= \frac{1}{N} \sum_{r=1}^N (a_r^2 - 2a_r\mu_N + \mu_N^2) \\
&= \frac{1}{N} \sum_{r=1}^N a_r^2 - 2\mu_N \left(\frac{1}{N} \sum_{r=1}^N a_r \right) + \mu_N^2 \\
&= \frac{1}{N} \sum_{r=1}^N a_r^2 - \mu_N^2.
\end{aligned}$$

Logo,

$$\frac{1}{N} \sum_{r=1}^N a_r^2 = \sigma_N^2 + \mu_N^2,$$

e, portanto,

$$E(X_i^2) = \sigma_N^2 + \mu_N^2.$$

Finalmente,

$$\begin{aligned}
\text{Var}(X_i) &= E(X_i^2) - [E(X_i)]^2 \\
&= \sigma_N^2 + \mu_N^2 - \mu_N^2 \\
&= \sigma_N^2.
\end{aligned}$$

Assim,

$$E(X_i) = \mu_N \quad \text{e} \quad \text{Var}(X_i) = \sigma_N^2.$$

Embora $X_1, \dots, X_n$ possuam a mesma distribuição marginal, essas variáveis não são independentes. Na amostragem sem reposição, a unidade selecionada em uma posição deixa de estar disponível para as demais. A covariância entre duas posições distintas permite quantificar essa dependência.

! Resultado — Covariância na amostragem sem reposição

Para duas posições distintas $i \neq j$,

$$\text{Cov}(X_i, X_j) = -\frac{\sigma_N^2}{N-1}.$$

Assim, se a população apresenta variabilidade, isto é, $\sigma_N^2 > 0$, a covariância entre duas posições distintas da amostra é negativa. Esse resultado expressa a dependência introduzida pela amostragem sem reposição: depois que uma unidade é selecionada, ela deixa de estar disponível para as seleções seguintes.

i Demonstração — Covariância entre posições distintas

Considere $i \neq j$. Como

$$E(X_i) = E(X_j) = \mu_N,$$

podemos escrever a covariância como

$$\text{Cov}(X_i, X_j) = E[(X_i - \mu_N)(X_j - \mu_N)].$$

Na amostragem aleatória simples sem reposição, qualquer par ordenado de **unidades distintas** da população possui a mesma probabilidade de ocupar as posições i e j .

Se J_i e J_j representam os índices das unidades selecionadas nessas posições, então, para $r \neq s$,

$$P(J_i = r, J_j = s) = \frac{1}{N} \frac{1}{N-1} = \frac{1}{N(N-1)}.$$

Como

$$X_i = a_{J_i} \quad \text{e} \quad X_j = a_{J_j},$$

temos

$$\begin{aligned} \text{Cov}(X_i, X_j) &= \sum_{r \neq s} (a_r - \mu_N)(a_s - \mu_N) P(J_i = r, J_j = s) \\ &= \frac{1}{N(N-1)} \sum_{r \neq s} (a_r - \mu_N)(a_s - \mu_N). \end{aligned}$$

Agora utilizamos a identidade

$$\left[\sum_{r=1}^N (a_r - \mu_N) \right]^2 = \sum_{r=1}^N (a_r - \mu_N)^2 + \sum_{r \neq s} (a_r - \mu_N)(a_s - \mu_N).$$

Pela definição de μ_N ,

$$\sum_{r=1}^N (a_r - \mu_N) = 0.$$

Portanto,

$$\sum_{r \neq s} (a_r - \mu_N)(a_s - \mu_N) = - \sum_{r=1}^N (a_r - \mu_N)^2.$$

Como

$$\sigma_N^2 = \frac{1}{N} \sum_{r=1}^N (a_r - \mu_N)^2,$$

segue que

$$\sum_{r=1}^N (a_r - \mu_N)^2 = N\sigma_N^2.$$

Substituindo na expressão da covariância,

$$\begin{aligned} \text{Cov}(X_i, X_j) &= \frac{1}{N(N-1)} (-N\sigma_N^2) \\ &= -\frac{\sigma_N^2}{N-1}. \end{aligned}$$

Logo,

$$\text{Cov}(X_i, X_j) = -\frac{\sigma_N^2}{N-1}, \quad i \neq j.$$

! Resultado — Momentos da média amostral

Na amostragem aleatória simples sem reposição,

$$E(\bar{X}) = \mu_N$$

e

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N-n}{N-1}.$$

O fator

$$\frac{N-n}{N-1}$$

é denominado **correção de população finita para a variância**. Para o erro-padrão, o fator correspondente é

$$\sqrt{\frac{N-n}{N-1}}.$$

(Rice, 2007, seq. 7.3.1, pp. 203–210; Cox, 2006, seq. 9.2, pp. 179–181)

i Demonstração — Momentos da média amostral

Pela definição da média amostral,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Usando a linearidade da esperança,

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i). \end{aligned}$$

Como, para qualquer posição da amostra,

$$E(X_i) = \mu_N,$$

segue que

$$\begin{aligned} E(\bar{X}) &= \frac{1}{n} \sum_{i=1}^n \mu_N \\ &= \frac{1}{n} n \mu_N \\ &= \mu_N. \end{aligned}$$

Para obter a variância, temos

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right).$$

A variância de uma soma pode ser escrita como

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

Dos resultados anteriores,

$$\text{Var}(X_i) = \sigma_N^2$$

e, para $i \neq j$,

$$\text{Cov}(X_i, X_j) = -\frac{\sigma_N^2}{N-1}.$$

Há

$$\binom{n}{2} = \frac{n(n-1)}{2}$$

pares de posições distintas com $i < j$. Portanto,

$$\begin{aligned}\text{Var}(\bar{X}) &= \frac{1}{n^2} \left[n\sigma_N^2 + 2\binom{n}{2} \left(-\frac{\sigma_N^2}{N-1} \right) \right] \\ &= \frac{1}{n^2} \left[n\sigma_N^2 - n(n-1)\frac{\sigma_N^2}{N-1} \right].\end{aligned}$$

Colocando $n\sigma_N^2$ em evidência,

$$\begin{aligned}\text{Var}(\bar{X}) &= \frac{n\sigma_N^2}{n^2} \left[1 - \frac{n-1}{N-1} \right] \\ &= \frac{\sigma_N^2}{n} \left[1 - \frac{n-1}{N-1} \right].\end{aligned}$$

Como

$$1 - \frac{n-1}{N-1} = \frac{N-n}{N-1},$$

obtemos

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N-n}{N-1}.$$

Portanto, a correção de população finita surge diretamente das covariâncias negativas entre posições distintas da amostra.

i Observação — Duas convenções para a variância da população finita

Neste capítulo, definimos

$$\sigma_N^2 = \frac{1}{N} \sum_{j=1}^N (a_j - \mu_N)^2.$$

Outra convenção encontrada na literatura utiliza o denominador $N-1$:

$$\sigma_F^2 = \frac{1}{N-1} \sum_{j=1}^N (a_j - \mu_N)^2.$$

As duas definições estão relacionadas por

$$\sigma_F^2 = \frac{N}{N-1} \sigma_N^2.$$

Com essa segunda convenção, a variância da média amostral pode ser escrita como

$$\text{Var}(\bar{X}) = \left(1 - \frac{n}{N}\right) \frac{\sigma_F^2}{n}.$$

Essa expressão é equivalente a

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N - n}{N - 1}.$$

Por isso, ao consultar diferentes referências, é importante verificar qual definição de variância da população finita está sendo utilizada (Cox, 2006, seq. 9.2; Rice, 2007, seq. 7.3.1).

i Interpretação — Fração amostral

Quando n/N é pequeno, a correção de população finita é próxima de 1, e o erro-padrão fica próximo de $\sigma_N/\sqrt{n}$. Quando uma fração apreciável da população é observada, a amostragem sem reposição reduz a incerteza em relação à amostragem com reposição (Cox, 2006, seq. 9.2; Rice, 2007, seq. 7.3.1).

i Modelo i.i.d. e amostragem sem reposição

Os dois referenciais produzem estruturas probabilísticas distintas.

No **modelo i.i.d.**, as observações possuem a mesma distribuição e são independentes. Para a média amostral,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Na **amostragem aleatória simples sem reposição** de uma população finita, as observações possuem a mesma distribuição marginal, mas são dependentes. Para $i \neq j$,

$$\text{Cov}(X_i, X_j) = -\frac{\sigma_N^2}{N - 1},$$

e

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N - n}{N - 1}.$$

Portanto, a distribuição amostral depende da estatística escolhida e do mecanismo que gera a amostra.

4.4 Construção de uma distribuição amostral por enumeração

Quando a população e o tamanho amostral são pequenos, a distribuição amostral pode ser obtida enumerando todas as amostras possíveis e calculando a estatística em cada uma delas (Ramachandran; Tsokos, 2021, seq. 4.1, pp. 148–151; Chihara; Hesterberg, 2022, seq. 4.2, pp. 82–85).

Exemplo — Qualidade da água em uma população finita

Uma equipe de monitoramento ambiental acompanha quatro reservatórios de uma determinada região. Em cada reservatório, foi registrada a concentração média de oxigênio dissolvido na água, em mg/L. Os valores que compõem essa população finita são

$$\mathcal{U} = \{3,8; 3,9; 4,0; 4,1\}.$$

Considere a seleção de amostras de tamanho

$$n = 2$$

a partir desses quatro reservatórios.

Para comparar dois mecanismos de amostragem, considere inicialmente a seleção **com reposição**, na qual um reservatório selecionado volta a ficar disponível para a segunda seleção. Em seguida, considere a seleção **sem reposição**, na qual um mesmo reservatório não pode aparecer duas vezes na amostra.

Determine:

1. a distribuição amostral de $\bar{X}$ no mecanismo com reposição;
2. $E(\bar{X})$ e $\text{Var}(\bar{X})$ nesse mecanismo;
3. a distribuição amostral de $\bar{X}$ no mecanismo sem reposição;
4. $E(\bar{X})$ e $\text{Var}(\bar{X})$ no mecanismo sem reposição;
5. o efeito da ausência de reposição sobre a variabilidade da média amostral.

Resolução — Distribuição de $\bar{X}$ com e sem reposição

A população é

$$\mathcal{U} = \{3,8; 3,9; 4,0; 4,1\},$$

com

$$N = 4 \quad \text{e} \quad n = 2.$$

A média e a variância populacionais são

$$\mu_N = \frac{3,8 + 3,9 + 4,0 + 4,1}{4} = 3,95$$

e

$$\begin{aligned}\sigma_N^2 &= \frac{1}{4} \sum_{r=1}^4 (a_r - \mu_N)^2 \\ &= 0,0125.\end{aligned}$$

Com reposição

Com reposição, cada uma das duas seleções pode resultar em qualquer um dos quatro reservatórios. Como a ordem das seleções é considerada, existem

$$4^2 = 16$$

amostras ordenadas equiprováveis.

As amostras possíveis e as respectivas médias são:

Primeira seleção	Segunda seleção	$\bar{x}$
3,8	3,8	3,80
3,8	3,9	3,85
3,8	4,0	3,90
3,8	4,1	3,95
3,9	3,8	3,85
3,9	3,9	3,90
3,9	4,0	3,95
3,9	4,1	4,00
4,0	3,8	3,90
4,0	3,9	3,95
4,0	4,0	4,00
4,0	4,1	4,05
4,1	3,8	3,95
4,1	3,9	4,00
4,1	4,0	4,05
4,1	4,1	4,10

Como cada amostra ordenada possui probabilidade $1/16$, basta contar quantas delas produzem cada valor de $\bar{X}$.

$\bar{x}$	3,80	3,85	3,90	3,95	4,00	4,05	4,10
Número de amos- tras	1	2	3	4	3	2	1
Probabilidade	$1/16$	$2/16$	$3/16$	$4/16$	$3/16$	$2/16$	$1/16$

Essa tabela constitui a distribuição amostral de $\bar{X}$ no mecanismo com reposição. Sua esperança é

$$E(\bar{X}) = \mu_N = 3,95,$$

e, como as duas seleções são independentes,

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} = \frac{0,0125}{2} = 0,00625.$$

Sem reposição

Sem reposição, um reservatório selecionado na primeira retirada não pode aparecer novamente na segunda.

Se considerássemos a ordem das seleções, haveria

$$4(3) = 12$$

amostras ordenadas equiprováveis.

Entretanto, a média amostral não depende da ordem. Por exemplo,

$$\frac{3,8 + 3,9}{2} = \frac{3,9 + 3,8}{2}.$$

Assim, cada par de sequências que difere apenas pela ordem produz o mesmo valor de $\bar{X}$. Podemos, portanto, enumerar diretamente os

$$\binom{4}{2} = 6$$

subconjuntos equiprováveis.

Os seis subconjuntos e suas médias são:

Amostra	$\bar{x}$
(3,8; 3,9)	3,85
(3,8; 4,0)	3,90
(3,8; 4,1)	3,95
(3,9; 4,0)	3,95
(3,9; 4,1)	4,00
(4,0; 4,1)	4,05

Como cada subconjunto possui probabilidade $1/6$, agrupando os valores iguais de $\bar{X}$ obtemos:

$\bar{x}$	3,85	3,90	3,95	4,00	4,05
Número de amostras	1	1	2	1	1
Probabilidade	$1/6$	$1/6$	$2/6$	$1/6$	$1/6$

A esperança permanece

$$E(\bar{X}) = \mu_N = 3,95.$$

Para a variância, utiliza-se a correção de população finita:

$$\begin{aligned} \text{Var}(\bar{X}) &= \frac{\sigma_N^2}{n} \frac{N-n}{N-1} \\ &= \frac{0,0125}{2} \frac{4-2}{4-1} \\ &= 0,004166 \dots \end{aligned}$$

Comparação dos mecanismos

Nos dois mecanismos,

$$E(\bar{X}) = 3,95.$$

A diferença aparece na variabilidade:

$$\text{Var}(\bar{X}) = \begin{cases} 0,00625, & \text{com reposição,} \\ 0,004166 \dots, & \text{sem reposição.} \end{cases}$$

A razão entre essas variâncias é

$$\frac{0,004166 \dots}{0,00625} = \frac{2}{3} = \frac{N-n}{N-1}.$$

Portanto, a ausência de reposição mantém a média da distribuição amostral, mas reduz sua variância. Nesse exemplo, a enumeração permite observar diretamente o efeito da correção de população finita.

i Interpretação — Papel da enumeração

A enumeração torna visível que a distribuição amostral é a distribuição dos valores de uma estatística sob repetição do plano amostral. Para populações grandes ou contínuas,

a enumeração exata é inviável, sendo substituída por resultados analíticos, aproximações assintóticas ou simulação.

4.5 Somas, transformações e funções geradoras de momentos

Muitas estatísticas de interesse podem ser expressas a partir de somas de variáveis aleatórias. A média amostral, por exemplo, é uma transformação da soma

$$Y = \sum_{i=1}^n X_i, \quad \bar{X} = \frac{Y}{n}.$$

Assim, conhecer a distribuição de Y permite obter a distribuição de $\bar{X}$ por uma transformação de variável.

No caso contínuo,

$$f_{\bar{X}}(u) = n f_Y(nu),$$

em que u representa um possível valor de $\bar{X}$.

i Derivação — Densidade de $\bar{X}$ por transformação de variável

Como

$$\bar{X} = \frac{Y}{n},$$

a transformação inversa é

$$Y = n\bar{X}.$$

Se u representa um possível valor de $\bar{X}$, o valor correspondente de Y é

$$y = nu.$$

Além disso,

$$\left| \frac{dy}{du} \right| = n.$$

Pela fórmula de transformação de uma variável contínua,

$$\begin{aligned} f_{\bar{X}}(u) &= f_Y(nu) \left| \frac{d(nu)}{du} \right| \\ &= n f_Y(nu). \end{aligned}$$

Portanto,

$$f_{\bar{X}}(u) = n f_Y(nu).$$

Uma forma de obter a distribuição de uma soma de variáveis independentes é a **convolução**.

Se X_1 e X_2 são variáveis aleatórias discretas independentes e

$$Y = X_1 + X_2,$$

então

$$P(Y = y) = \sum_x P(X_1 = x) P(X_2 = y - x).$$

No caso contínuo, se X_1 e X_2 possuem densidades f_{X_1} e f_{X_2} ,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X_1}(x) f_{X_2}(y - x) dx.$$

Para somas com mais de duas variáveis independentes, a convolução pode ser aplicada sucessivamente.

Outra possibilidade é utilizar funções geradoras de momentos. Quando a FGM existe em uma vizinhança de zero, ela determina unicamente a distribuição da variável aleatória. Além disso, para variáveis independentes, a FGM de uma soma é obtida pelo produto das FGMs individuais. Essas propriedades frequentemente permitem reconhecer diretamente a distribuição de uma soma (Larsen; Marx, 2012, seq. 3.8 e 3.12; Kerns, 2010, seq. 5.4; Rice, 2007, seq. 4.5).

💡 Exemplo — Convolução de duas variáveis Bernoulli

Considere

$$X_1, X_2 \stackrel{\text{iid}}{\sim} \text{Ber}(p)$$

e

$$Y = X_1 + X_2.$$

Obtenha a função de probabilidade de Y por convolução e identifique sua distribuição.

i Resolução — Soma de duas variáveis Bernoulli por convolução

Os valores possíveis de Y são 0, 1 e 2.

Para $Y = 0$,

$$\begin{aligned} P(Y = 0) &= P(X_1 = 0, X_2 = 0) \\ &= (1 - p)^2. \end{aligned}$$

Para $Y = 1$,

$$\begin{aligned} P(Y = 1) &= P(X_1 = 0, X_2 = 1) + P(X_1 = 1, X_2 = 0) \\ &= 2p(1 - p). \end{aligned}$$

Finalmente,

$$P(Y = 2) = P(X_1 = 1, X_2 = 1) = p^2.$$

Os três casos podem ser reunidos em uma única expressão. Para que $Y = y$, exatamente y das duas variáveis Bernoulli devem assumir o valor 1. Existem

$$\binom{2}{y}$$

formas de escolher quais posições correspondem a esses sucessos. Cada configuração possui probabilidade

$$p^y(1 - p)^{2-y}.$$

Portanto,

$$P(Y = y) = \binom{2}{y} p^y (1 - p)^{2-y}, \quad y = 0, 1, 2.$$

Portanto,

$$Y \sim \text{Bin}(2, p).$$

A convolução mostra diretamente como a distribuição binomial surge da soma de variáveis Bernoulli independentes.

i Propriedade — FGM da soma e da média

Para variáveis aleatórias independentes,

$$M_{\sum X_i}(t) = \prod_{i=1}^n M_{X_i}(t).$$

Se, adicionalmente, $X_1, \dots, X_n$ são identicamente distribuídas com FGM $M_X(t)$, então

$$M_{\bar{X}}(t) = \left[M_X \left(\frac{t}{n} \right) \right]^n.$$

Essas identidades permitem reconhecer distribuições amostrais exatas a partir das funções geradoras de momentos das variáveis que compõem a amostra. As propriedades gerais da FGM, de somas independentes e de identificação de distribuições são revisadas em Seção 1.5, Seção 1.5.3 e Seção 1.5.4.

💡 Exemplo — Média de variáveis Poisson

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda), \quad \lambda > 0.$$

A função de massa de probabilidade é

$$P(X_i = x) = e^{-\lambda} \frac{\lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

e defina

$$Y = \sum_{i=1}^n X_i.$$

Utilize a função geradora de momentos para obter a distribuição de Y e, a partir dela, caracterizar a distribuição da média amostral

$$\bar{X} = \frac{Y}{n}.$$

📌 Resolução — Soma Poisson e distribuição da média amostral

Para

$$X_i \sim \text{Poisson}(\lambda),$$

a função geradora de momentos é

$$M_X(t) = \exp \{ \lambda(e^t - 1) \}.$$

Como as observações são independentes,

$$\begin{aligned}
M_Y(t) &= \prod_{i=1}^n M_{X_i}(t) \\
&= [\exp \{ \lambda (e^t - 1) \}]^n \\
&= \exp \{ n \lambda (e^t - 1) \}.
\end{aligned}$$

Essa expressão coincide com a FGM de uma variável Poisson com parâmetro $n\lambda$. Portanto,

$$Y = \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda).$$

Como

$$\bar{X} = \frac{Y}{n},$$

a distribuição de $\bar{X}$ é obtida por uma mudança de escala da distribuição de Y . Seus valores possíveis são

$$0, \frac{1}{n}, \frac{2}{n}, \dots,$$

e

$$P\left(\bar{X} = \frac{k}{n}\right) = P(Y = k) = e^{-n\lambda} \frac{(n\lambda)^k}{k!}, \quad k = 0, 1, \dots$$

Assim, $\bar{X}$ não possui distribuição Poisson, embora seja uma transformação de uma variável Poisson.

Além disso,

$$E(\bar{X}) = \frac{1}{n} E(Y) = \lambda$$

e

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \text{Var}(Y) = \frac{\lambda}{n}.$$

A derivação utiliza as propriedades de FGM de somas independentes e de identificação de distribuições apresentadas em Seção 1.5.3 e Seção 1.5.4.

💡 Exemplo — Média de variáveis normais

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2), \quad \sigma^2 > 0.$$

Na notação adotada neste livro, o segundo parâmetro é a **variância**. A densidade de cada observação é

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right], \quad -\infty < x < \infty.$$

Utilize a função geradora de momentos para obter a distribuição exata de

$$\bar{X}.$$

Antes de abrir a resolução, tente identificar:

1. a FGM de cada X_i ;
2. a FGM de $\bar{X}$;
3. a distribuição reconhecida a partir da FGM obtida.

i Resolução — Distribuição de $\bar{X}$ pela FGM no modelo normal

Para uma variável normal,

$$M_X(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right).$$

Como

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

e as observações são independentes,

$$\begin{aligned} M_{\bar{X}}(t) &= \prod_{i=1}^n M_X \left(\frac{t}{n} \right) \\ &= \left[\exp \left(\frac{\mu t}{n} + \frac{\sigma^2 t^2}{2n^2} \right) \right]^n \\ &= \exp \left(\mu t + \frac{\sigma^2 t^2}{2n} \right). \end{aligned}$$

A FGM de uma variável normal com média m e variância v tem a forma

$$M(t) = \exp \left(mt + \frac{vt^2}{2} \right).$$

Comparando essa expressão com

$$M_{\bar{X}}(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2n} \right),$$

identificamos

$$m = \mu \quad \text{e} \quad v = \frac{\sigma^2}{n}.$$

Como a FGM, quando existe em uma vizinhança de zero, determina unicamente a distribuição, concluímos que

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Essa dedução por FGM é apresentada em tratamentos clássicos de transformações e somas de variáveis aleatórias (Larsen; Marx, 2012, seq. 3.12; Rice, 2007, cap. 4 e 6).

💡 Exemplo — Média de variáveis gama

Adote a parametrização da distribuição gama por **forma** α e **escala** β , com

$$\alpha > 0, \quad \beta > 0.$$

Sua densidade é

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad x > 0.$$

Nessa parametrização,

$$E(X) = \alpha\beta \quad \text{e} \quad \text{Var}(X) = \alpha\beta^2.$$

A distribuição gama também é frequentemente parametrizada por **forma** α e **taxa** λ , com

$$\lambda = \frac{1}{\beta}.$$

Nesse caso, a mesma densidade é escrita como

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x > 0.$$

Considere agora

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Gama}(\alpha, \beta),$$

na parametrização por forma e escala.

Utilize a função geradora de momentos para obter a distribuição de

$$\bar{X}.$$

i Resolução — Distribuição de $\bar{X}$ pela FGM no modelo gama

Para

$$X_i \sim \text{Gama}(\alpha, \beta),$$

a FGM é

$$M_X(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

Como

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

temos

$$\begin{aligned} M_{\bar{X}}(t) &= \left[M_X\left(\frac{t}{n}\right) \right]^n \\ &= \left[\left(1 - \frac{\beta t}{n}\right)^{-\alpha} \right]^n \\ &= \left(1 - \frac{\beta t}{n}\right)^{-n\alpha}. \end{aligned}$$

Essa é a FGM de uma distribuição gama com forma

$$n\alpha$$

e escala

$$\frac{\beta}{n}.$$

Logo,

$$\bar{X} \sim \text{Gama}\left(n\alpha, \frac{\beta}{n}\right).$$

Como verificação, para uma variável

$$X_i \sim \text{Gama}(\alpha, \beta),$$

temos

$$E(X_i) = \alpha\beta \quad \text{e} \quad \text{Var}(X_i) = \alpha\beta^2.$$

A distribuição obtida para $\bar{X}$ fornece

$$E(\bar{X}) = (n\alpha) \frac{\beta}{n} = \alpha\beta = E(X_i)$$

e

$$\text{Var}(\bar{X}) = (n\alpha) \left(\frac{\beta}{n} \right)^2 = \frac{\alpha\beta^2}{n} = \frac{\text{Var}(X_i)}{n}.$$

Portanto, a distribuição exata obtida pela FGM é coerente com os resultados gerais para a média amostral.

A conclusão usa a FGM da distribuição gama e a regra de escala (Larsen; Marx, 2012, seq. 3.12 e 4.6; Ramachandran; Tsokos, 2021, cap. 3–4).

Como caso particular, considere uma distribuição exponencial parametrizada pela média,

$$X_i \stackrel{\text{iid}}{\sim} \text{Exp}(\mu), \quad E(X_i) = \mu.$$

Como uma exponencial com média μ corresponde a uma distribuição gama com forma 1 e escala μ ,

$$\sum_{i=1}^n X_i \sim \text{Gama}(n, \mu)$$

e

$$\bar{X} \sim \text{Gama}\left(n, \frac{\mu}{n}\right).$$

4.6 Distribuição amostral da média

! Resultado — Média amostral

Para uma amostra i.i.d. com

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2 < \infty,$$

temos

$$E(\bar{X}) = \mu$$

e

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Consequentemente, o erro-padrão é

$$\text{EP}(\bar{X}) = \sqrt{\text{Var}(\bar{X})} = \frac{\sigma}{\sqrt{n}}.$$

Se a população é normal, então, para todo $n \geq 1$,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Os dois primeiros momentos são válidos para qualquer população com variância finita; a distribuição normal exata exige normalidade da população (Casella; Berger, 2011, teorema 5.2.6 e seção 5.3.1; Ramachandran; Tsokos, 2021, teorema 4.1.1; Chihara; Hestenberg, 2022, apêndices A.5–A.6; Kerns, 2010, seq. 8.2).

i Demonstração — Momentos e distribuição da média amostral

Pela definição,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Pela linearidade da esperança,

$$\begin{aligned} E(\bar{X}) &= \frac{1}{n} \sum_{i=1}^n E(X_i) \\ &= \frac{1}{n} (n\mu) \\ &= \mu. \end{aligned}$$

Observe que, até aqui, a independência não foi necessária: a igualdade

$$E(\bar{X}) = \mu$$

decorre apenas da linearidade da esperança e do fato de as observações possuírem a mesma média.

A independência torna-se importante no cálculo da variância, pois faz com que as covariâncias entre observações distintas sejam nulas. A expressão geral para a variância de combinações lineares é apresentada em Seção 1.4.8. Assim,

$$\begin{aligned}
\text{Var}(\bar{X}) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\
&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \\
&= \frac{1}{n^2} (n\sigma^2) \\
&= \frac{\sigma^2}{n}.
\end{aligned}$$

Portanto,

$$\text{EP}(\bar{X}) = \sqrt{\text{Var}(\bar{X})} = \frac{\sigma}{\sqrt{n}}.$$

Se, adicionalmente,

$$X_i \sim N(\mu, \sigma^2),$$

a média amostral é uma combinação linear de variáveis normais independentes. Logo, também é normal. Utilizando a média e a variância obtidas acima,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Interpretação — Efeito do tamanho amostral

O erro-padrão decresce à taxa $n^{-1/2}$. Para reduzir o erro-padrão pela metade, é necessário multiplicar o tamanho da amostra por quatro. O aumento de n reduz a variabilidade da média, mas não corrige viés de seleção, dependência não modelada ou erros sistemáticos de mensuração (Rice, 2007, seq. 7.3.1, pp. 206–207).

Exemplo — Variabilidade individual e média amostral dos níveis de colesterol

Um programa de acompanhamento em saúde registra os níveis de colesterol total de adultos de determinada população. Admita que o nível de colesterol de um indivíduo selecionado ao acaso possa ser modelado por

$$X \sim N(210, 36^2) \text{ mg/dL}.$$

A equipe pretende selecionar amostras aleatórias de

$$n = 16$$

indivíduos e utilizar a média amostral $\bar{X}$ para representar o nível médio de colesterol em cada amostra.

O objetivo é comparar a variabilidade observada entre os níveis de colesterol de **indivíduos** com a variabilidade esperada entre as **médias de diferentes amostras de 16 indivíduos**.

Determine:

1. a distribuição amostral de $\bar{X}$;
2. o erro-padrão de $\bar{X}$;
3. uma região que contenha os 95% centrais da distribuição dos níveis de colesterol individuais;
4. uma região que contenha os 95% centrais da distribuição das médias de amostras de 16 indivíduos;
5. compare as amplitudes das duas regiões e interprete a diferença.

i Resolução — Distribuição e erro-padrão da média no modelo normal

Como a população possui distribuição normal,

$$X \sim N(210, 36^2),$$

a distribuição amostral de $\bar{X}$ também é normal, independentemente do tamanho da amostra. Neste caso, portanto, a normalidade de $\bar{X}$ é um **resultado exato** e não uma aproximação obtida pelo Teorema Central do Limite.

Para uma amostra aleatória de tamanho n proveniente de uma população

$$X \sim N(\mu, \sigma^2),$$

temos

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Neste exemplo,

$$\mu = 210, \quad \sigma = 36 \quad \text{e} \quad n = 16.$$

Assim,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} = \frac{36^2}{16} = 81.$$

Portanto,

$$\bar{X} \sim N(210, 9^2).$$

O erro-padrão da média corresponde ao desvio-padrão de sua distribuição amostral:

$$\begin{aligned}\text{EP}(\bar{X}) &= \sqrt{\text{Var}(\bar{X})} \\ &= \frac{\sigma}{\sqrt{n}} = \frac{36}{\sqrt{16}} \\ &= \frac{36}{4} = 9 \text{ mg/dL}.\end{aligned}$$

Observe, portanto, a diferença entre as duas distribuições:

$$\text{DP}(X) = 36 \text{ mg/dL},$$

enquanto

$$\text{DP}(\bar{X}) = \text{EP}(\bar{X}) = 9 \text{ mg/dL}.$$

As duas distribuições possuem o mesmo centro, 210 mg/dL, mas a distribuição das médias amostrais apresenta menor dispersão.

Região central de 95% de uma distribuição normal

Tanto X quanto $\bar{X}$ possuem distribuição normal e, portanto, são simétricas em torno de suas respectivas médias.

Para construir uma região central que contenha 95% da probabilidade, os 5% restantes ficam fora dessa região. Pela simetria da distribuição normal, essa probabilidade é dividida igualmente entre as duas caudas:

$$\frac{0,05}{2} = 0,025.$$

Assim, buscamos na distribuição normal padrão o valor que deixa probabilidade 0,025 à sua direita, ou, equivalentemente,

$$1 - 0,025 = 0,975$$

à sua esquerda.

Se

$$Z \sim N(0, 1),$$

o quantil correspondente é

$$z_{0,975} \approx 1,96.$$

Portanto,

$$P(-1,96 < Z < 1,96) \approx 0,95.$$

Isso significa que aproximadamente 95% dos valores de uma variável normal encontram-se a até 1,96 desvios-padrão de sua média.

Para uma variável

$$Y \sim N(\mu_Y, \sigma_Y^2),$$

a região central de 95% é, portanto,

$$\mu_Y \pm 1,96\sigma_Y.$$

Região central dos níveis individuais

Para um indivíduo,

$$X \sim N(210, 36^2).$$

A média é

$$\mu = 210$$

e o desvio-padrão é

$$\sigma = 36.$$

Logo, os 95% centrais da distribuição dos níveis individuais estão na região

$$210 \pm 1,96(36).$$

Como

$$1,96(36) = 70,56,$$

temos

$$210 - 70,56 = 139,44$$

e

$$210 + 70,56 = 280,56.$$

Portanto,

$$139,44 < X < 280,56$$

corresponde aproximadamente aos 95% centrais da distribuição dos níveis individuais de colesterol.

A amplitude dessa região é

$$280,56 - 139,44 = 141,12 \text{ mg/dL.}$$

Região central das médias amostrais

Para amostras de tamanho 16, vimos que

$$\bar{X} \sim N(210, 9^2).$$

A distribuição de $\bar{X}$ também é simétrica em torno de 210, mas seu desvio-padrão é agora o erro-padrão

$$EP(\bar{X}) = 9.$$

Para obter os 95% centrais dessa distribuição, utilizamos novamente

$$z_{0,975} \approx 1,96,$$

pois o percentual central desejado continua sendo 95%.

Assim,

$$210 \pm 1,96(9).$$

Como

$$1,96(9) = 17,64,$$

temos

$$210 - 17,64 = 192,36$$

e

$$210 + 17,64 = 227,64.$$

Portanto,

$$192,36 < \bar{X} < 227,64$$

corresponde aproximadamente aos 95% centrais da distribuição das médias de amostras de 16 indivíduos.

A amplitude dessa região é

$$227,64 - 192,36 = 35,28 \text{ mg/dL.}$$

Comparação

As duas distribuições possuem a mesma média:

$$E(X) = E(\bar{X}) = 210.$$

A diferença está na variabilidade. Para os valores individuais,

$$DP(X) = 36,$$

enquanto, para as médias amostrais,

$$DP(\bar{X}) = EP(\bar{X}) = 9.$$

Como

$$9 = \frac{36}{4},$$

o desvio-padrão da distribuição das médias é quatro vezes menor que o desvio-padrão da distribuição dos valores individuais.

A mesma relação aparece nas amplitudes das regiões centrais:

$$141,12 \quad \text{e} \quad 35,28,$$

pois

$$\frac{35,28}{141,12} = \frac{1}{4}.$$

Isso ocorre porque

$$EP(\bar{X}) = \frac{\sigma}{\sqrt{n}} = \frac{36}{\sqrt{16}} = \frac{36}{4}.$$

Portanto, os níveis de colesterol de indivíduos podem apresentar uma dispersão relativamente grande em torno de 210 mg/dL. Já as médias calculadas a partir de amostras de 16 indivíduos tendem a ficar muito mais concentradas em torno desse mesmo valor.

Este exemplo evidencia duas propriedades importantes da média amostral: ela preserva o centro da distribuição populacional,

$$E(\bar{X}) = \mu,$$

e apresenta menor variabilidade,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

i Intervalo de probabilidade e intervalo de confiança

Os intervalos apresentados neste exemplo descrevem regiões centrais de distribuições conhecidas. Eles não são intervalos de confiança. Um intervalo de confiança é um procedimento inferencial aleatório cuja probabilidade de cobertura é definida sob repetição

amostral e, portanto, não se confunde com uma região central calculada para uma distribuição com parâmetros conhecidos.

4.6.1 Diferença de médias de duas amostras independentes

Considere duas amostras independentes entre si,

$$X_1, \dots, X_n$$

e

$$Y_1, \dots, Y_m,$$

em que, dentro de cada amostra, as observações são independentes e identicamente distribuídas. Suponha que

$$E(X_i) = \mu_1, \quad \text{Var}(X_i) = \sigma_1^2$$

e

$$E(Y_j) = \mu_2, \quad \text{Var}(Y_j) = \sigma_2^2.$$

A diferença entre as médias amostrais é a estatística

$$D = \bar{X} - \bar{Y}.$$

Suas esperança e variância são

$$E(D) = \mu_1 - \mu_2$$

e, pela independência entre as amostras,

$$\text{Var}(D) = \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}.$$

i Derivação — Média e variância da diferença de médias

Pela linearidade da esperança,

$$\begin{aligned} E(D) &= E(\bar{X} - \bar{Y}) \\ &= E(\bar{X}) - E(\bar{Y}) \\ &= \mu_1 - \mu_2. \end{aligned}$$

Para a variância,

$$\begin{aligned} \text{Var}(D) &= \text{Var}(\bar{X} - \bar{Y}) \\ &= \text{Var}(\bar{X}) + \text{Var}(\bar{Y}) - 2 \text{Cov}(\bar{X}, \bar{Y}). \end{aligned}$$

Como as duas amostras são independentes,

$$\text{Cov}(\bar{X}, \bar{Y}) = 0.$$

Além disso,

$$\text{Var}(\bar{X}) = \frac{\sigma_1^2}{n}$$

e

$$\text{Var}(\bar{Y}) = \frac{\sigma_2^2}{m}.$$

Portanto,

$$\text{Var}(D) = \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}.$$

! Resultado — Distribuição exata da diferença de médias

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu_1, \sigma_1^2)$$

e

$$Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} N(\mu_2, \sigma_2^2),$$

com as duas amostras independentes, então

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right).$$

A normalidade é exata porque $\bar{X}$ e $\bar{Y}$ são variáveis normais independentes.

4.7 Lei dos Grandes Números

A Lei dos Grandes Números descreve o comportamento da média amostral quando o tamanho da amostra aumenta. Uma formulação em contexto probabilístico mais geral é apresentada em Seção 2.3.3.

No estudo das distribuições amostrais, seu papel é mostrar como a distribuição de $\bar{X}_n = \sum_{i=1}^n X_i/n$ se concentra progressivamente em torno da média populacional μ à medida que n aumenta.

! Aplicação — Concentração da média amostral

Se $X_1, X_2, \dots$ são i.i.d.,

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2 < \infty,$$

então, para todo $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0,$$

isto é,

$$\bar{X}_n \xrightarrow{P} \mu.$$

Assim, à medida que n aumenta, a distribuição amostral de $\bar{X}_n$ concentra progressivamente sua massa em torno da média populacional (Rice, 2007, seq. 5.2, pp. 177–181).

i Demonstração — Lei Fraca via desigualdade de Chebyshev

Como

$$E(\bar{X}_n) = \mu$$

e

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n},$$

a desigualdade de Chebyshev fornece

$$P(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2}.$$

Portanto,

$$P(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

Logo,

$$\overline{X}_n \xrightarrow{P} \mu.$$

💡 Exemplo — Frequência relativa

Se

$$X_1, X_2, \dots \stackrel{\text{iid}}{\sim} \text{Ber}(p),$$

então

$$\hat{p}_n = \overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

é a frequência relativa de sucessos.

Como $E(X_i) = p$, a Lei dos Grandes Números implica

$$\hat{p}_n \xrightarrow{P} p.$$

Assim, a proporção amostral concentra-se em torno da proporção populacional conforme o tamanho amostral aumenta.

4.8 Teorema Central do Limite

O Teorema Central do Limite fornece uma aproximação para a forma da distribuição amostral de somas e médias quando o tamanho da amostra aumenta. Uma formulação em contexto probabilístico mais geral é apresentada em Seção 2.3.4.

Para uma amostra i.i.d. com

$$E(X_i) = \mu \quad \text{e} \quad 0 < \sigma^2 = \text{Var}(X_i) < \infty,$$

temos a convergência

$$Z_n = \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

A partir dessa convergência, para valores suficientemente grandes de n , a distribuição de $\overline{X}_n$ pode ser aproximada por uma distribuição normal com a mesma média e a mesma variância:

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Da mesma forma,

$$\sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2).$$

Diferença de médias em grandes amostras

O mesmo princípio pode ser aplicado à diferença de médias de duas amostras independentes.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F_1$$

e

$$Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} F_2,$$

com as duas amostras independentes e

$$E(X_i) = \mu_1, \quad \text{Var}(X_i) = \sigma_1^2 < \infty,$$

$$E(Y_j) = \mu_2, \quad \text{Var}(Y_j) = \sigma_2^2 < \infty.$$

Quando n e m aumentam, o Teorema Central do Limite fornece

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}} \xrightarrow{d} N(0, 1),$$

quando $\min(n, m) \rightarrow \infty$.

Consequentemente, para amostras suficientemente grandes,

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right).$$

Quando as duas distribuições são normais, a distribuição de $\bar{X} - \bar{Y}$ é normal, para quaisquer tamanhos amostrais. Quando não se assume normalidade, mas as variâncias são finitas, a distribuição de $\bar{X} - \bar{Y}$ pode ser aproximada por uma distribuição normal à medida que os tamanhos das duas amostras aumentam, como consequência do Teorema Central do Limite.

Neste texto, o símbolo

$$\overset{\sim}{\rightarrow}$$

significa “**tem distribuição aproximadamente igual a**”. Ele não representa convergência em distribuição. A convergência é indicada por

$$\xrightarrow{d}.$$

As expressões com $\overset{\sim}{\rightarrow}$ são formas operacionais de utilizar o TCL para aproximar distribuições amostrais em grandes amostras (Chihara; Hesterberg, 2022, seq. 4.3, pp. 85–93; Kerns, 2010, seq. 8.3; Rice, 2007, seq. 5.3).

⚠ Observação — Objeto da convergência no TCL

A variável que converge em distribuição é a versão **padronizada**,

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}.$$

Não se deve afirmar que $\bar{X}_n$ converge em distribuição para

$$N\left(\mu, \frac{\sigma^2}{n}\right),$$

pois essa distribuição também depende de n . Pela Lei dos Grandes Números,

$$\bar{X}_n \xrightarrow{P} \mu.$$

A distribuição normal com variância σ^2/n é uma **aproximação da distribuição de $\bar{X}_n$ para cada n suficientemente grande**, e não seu limite em distribuição.

i Lei dos Grandes Números e Teorema Central do Limite

A Lei dos Grandes Números e o Teorema Central do Limite descrevem aspectos diferentes do comportamento da média amostral.

A **Lei dos Grandes Números** estabelece que

$$\bar{X}_n \xrightarrow{P} \mu,$$

mostrando que a média amostral se concentra em torno da média populacional à medida que n aumenta.

O **Teorema Central do Limite** descreve a escala e a forma das flutuações de $\bar{X}_n$ em torno de μ . Depois de centralizar e multiplicar por $\sqrt{n}$,

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Assim, a LGN descreve a **concentração** da média amostral, enquanto o TCL descreve a **distribuição aproximada de seus desvios em relação a μ** , após a padronização adequada.

⚠ Observação — Não existe uma regra universal $n \geq 30$

A qualidade da aproximação normal depende da assimetria, do peso das caudas, da existência de momentos, da natureza discreta ou contínua da população e da precisão desejada. Distribuições fortemente assimétricas ou com caudas pesadas podem exigir amostras muito maiores. O diagnóstico deve considerar o modelo e, quando possível, simulações ou limites de erro (Chihara; Hesterberg, 2022, seq. 4.3.3, p. 92).

4.8.1 Padronização com variância estimada

A padronização fornecida diretamente pelo TCL utiliza o desvio-padrão populacional σ . Em problemas inferenciais, entretanto, σ frequentemente é desconhecido. Nesse caso, podemos examinar o que ocorre quando ele é substituído pelo desvio-padrão amostral S .

Para uma amostra i.i.d. com $0 < \sigma^2 < \infty$,

$$S^2 \xrightarrow{P} \sigma^2$$

e, conseqüentemente,

$$S \xrightarrow{P} \sigma.$$

i Derivação — Convergência de S^2 para σ^2

A variância amostral pode ser escrita como

$$S^2 = \frac{n}{n-1} \left[\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right].$$

Como $E(X_i^2) < \infty$, a Lei dos Grandes Números fornece

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X^2)$$

e

$$\bar{X}_n \xrightarrow{P} \mu.$$

Pelo teorema do mapeamento contínuo, apresentado em Seção 2.3.6,

$$\bar{X}_n^2 \xrightarrow{P} \mu^2.$$

Logo,

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \xrightarrow{P} E(X^2) - \mu^2 = \sigma^2.$$

Como

$$\frac{n}{n-1} \rightarrow 1,$$

o lema de Slutsky, apresentado em Seção 2.3.7, fornece

$$S^2 \xrightarrow{P} \sigma^2.$$

Finalmente, como $\sigma > 0$ e a função raiz quadrada é contínua,

$$S \xrightarrow{P} \sigma.$$

Combinando $S \xrightarrow{P} \sigma$ com o TCL, o lema de Slutsky fornece (Lauritzen, 2023, apêndice A.2.2)

$$\frac{\bar{X}_n - \mu}{S/\sqrt{n}} \xrightarrow{d} N(0, 1).$$

⚠ Observação — Resultado exato sob normalidade

O resultado acima é assintótico, isso significa que, quando o tamanho da amostra aumenta, a distribuição da estatística padronizada com S no denominador se aproxima da distribuição normal padrão.

Há, entretanto, um resultado mais específico quando a amostra provém de uma distribuição normal. Nesse caso,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

a estatística

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}$$

possui **exatamente** distribuição t de Student com $n - 1$ graus de liberdade:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Esse resultado não depende de n ser grande. Sua demonstração exige propriedades específicas do modelo normal, em particular a distribuição de S^2 e a independência entre $\bar{X}$ e S^2 . Essas propriedades serão desenvolvidas posteriormente e reunidas na derivação apresentada em Seção 4.11.4.

Portanto, é importante separar as duas afirmações:

- sob normalidade, a distribuição t_{n-1} é **exata**;
- sem a hipótese de normalidade, sob as condições do TCL e com variância finita, a distribuição da estatística acima se aproxima de $N(0, 1)$ quando n aumenta.

(Larsen; Marx, 2012, cap. 7; Rice, 2007, cap. 6)

4.9 Distribuição amostral da proporção

Retomando o modelo Bernoulli utilizado no Capítulo 3, considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p), \quad 0 < p < 1.$$

Para $x \in \{0, 1\}$, a função de massa de uma variável Bernoulli pode ser escrita como

$$P(X_i = x \mid p) = p^x(1 - p)^{1-x}.$$

Se

$$Y = \sum_{i=1}^n X_i,$$

então

$$Y \sim \text{Bin}(n, p).$$

Sua função de massa é

$$P(Y = y \mid p) = \binom{n}{y} p^y (1-p)^{n-y}, \quad y = 0, 1, \dots, n.$$

A proporção amostral pode ser escrita como

$$\hat{p} = \bar{X} = \frac{Y}{n}.$$

Como

$$E(Y) = np \quad \text{e} \quad \text{Var}(Y) = np(1-p),$$

segue que

$$E(\hat{p}) = p$$

e

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

A distribuição exata de $\hat{p}$ é discreta e é induzida pela distribuição binomial de Y :

$$P\left(\hat{p} = \frac{k}{n} \mid p\right) = P(Y = k \mid p) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

Proporção em uma população finita

Considere uma população finita de tamanho N , com M unidades que apresentam a característica de interesse. A proporção populacional é

$$p = \frac{M}{N}.$$

Se uma amostra aleatória simples de tamanho n é selecionada sem reposição e Y representa o número de unidades da amostra que apresentam essa característica, então

$$Y \sim \text{Hiper}(N, M, n).$$

Sua função de massa é

$$P(Y = y \mid N, M) = \frac{\binom{M}{y} \binom{N-M}{n-y}}{\binom{N}{n}},$$

para

$$\max\{0, n - (N - M)\} \leq y \leq \min\{n, M\}.$$

A proporção amostral é

$$\hat{p} = \frac{Y}{n}.$$

Além disso,

$$E(\hat{p}) = p$$

e

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \frac{N-n}{N-1}.$$

i Derivação — Função de massa hipergeométrica e momentos de $\hat{p}$

Para observar exatamente y unidades com a característica, precisamos escolher

$$y$$

das M unidades que possuem a característica e

$$n - y$$

das $N - M$ unidades restantes.

O número de amostras com essa composição é

$$\binom{M}{y} \binom{N-M}{n-y}.$$

Como uma amostragem aleatória simples atribui a mesma probabilidade às

$$\binom{N}{n}$$

amostras possíveis de tamanho n ,

$$P(Y = y \mid N, M) = \frac{\binom{M}{y} \binom{N-M}{n-y}}{\binom{N}{n}},$$

que é a função de probabilidade da distribuição hipergeométrica. Esse modelo é revisado em Seção 1.6.4.

Para obter os momentos de $\hat{p}$, não precisamos recalculá-los diretamente a partir da função de probabilidade hipergeométrica. Podemos utilizar o resultado para médias amostrais obtido em Seção 4.3.2.

A ideia é representar a presença ou ausência da característica por uma variável indicadora. Para a r -ésima unidade da população, defina

$$a_r = \begin{cases} 1, & \text{se possui a característica,} \\ 0, & \text{caso contrário.} \end{cases}$$

Nessa população binária,

$$\mu_N = p$$

e

$$\sigma_N^2 = p(1 - p).$$

A proporção amostral é exatamente a média amostral desses indicadores:

$$\hat{p} = \bar{X}.$$

Essa igualdade é a ponte entre os dois resultados: estudar a proporção amostral equivale a estudar a média amostral de uma população composta por zeros e uns.

Aplicando os resultados para a média sob amostragem aleatória simples sem reposição obtidos em Seção 4.3.2,

	$E(\hat{p}) = p$
e	
	$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \frac{N-n}{N-1}.$
Como	
	$Y = n\hat{p},$
segue também que	
	$E(Y) = np$
e	
	$\text{Var}(Y) = np(1-p) \frac{N-n}{N-1}.$

A estatística de contagem

$$Y = n\hat{p}$$

possui distribuições diferentes nos dois referenciais de geração da amostra.

No modelo Bernoulli i.i.d.,

$$Y \sim \text{Bin}(n, p),$$

enquanto, na amostragem aleatória simples sem reposição de uma população finita com M unidades que apresentam a característica,

$$Y \sim \text{Hiper}(N, M, n).$$

A diferença também aparece na variância de $\hat{p}$: no caso sem reposição, surge a correção de população finita

$$\frac{N-n}{N-1}.$$

💡 Exemplo — Urna do experimento físico

Na urna de Capítulo 3 há

$$N = 2400$$

bolas, das quais

$$M = 900$$

são vermelhas.

Para estudar teoricamente a distribuição amostral da proporção, suponha agora que a seleção de $n = 50$ bolas possa ser representada por uma **amostragem aleatória simples sem reposição**. Sob esse modelo probabilístico,

Determine:

1. a proporção populacional de bolas vermelhas;
2. $E(\hat{p})$;
3. $\text{Var}(\hat{p})$;
4. o erro-padrão de $\hat{p}$.

i Resolução — Proporção amostral em uma população finita

A proporção populacional é

$$p = \frac{900}{2400} = 0,375.$$

Na amostragem sem reposição,

$$E(\hat{p}) = p,$$

portanto

$$E(\hat{p}) = 0,375.$$

A variância é

$$\begin{aligned}\text{Var}(\hat{p}) &= \frac{p(1-p)}{n} \frac{N-n}{N-1} \\ &= \frac{0,375(0,625)}{50} \frac{2400-50}{2400-1} \\ &\approx 0,00459.\end{aligned}$$

Consequentemente,

$$EP(\hat{p}) = \sqrt{\text{Var}(\hat{p})} \approx 0,0678.$$

A correção de população finita reduz ligeiramente a variabilidade de $\hat{p}$ em relação ao modelo Bernoulli i.i.d. com o mesmo valor de p e o mesmo tamanho amostral.

No modelo Bernoulli i.i.d., para $0 < p < 1$,

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0, 1).$$

Como

$$\hat{p} = \frac{Y}{n},$$

em que

$$Y = \sum_{i=1}^n X_i \sim \text{Bin}(n, p),$$

o mesmo resultado pode ser escrito como

$$\frac{Y - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1).$$

4.9.1 Aproximação normal da binomial

A convergência acima fornece a justificativa assintótica para aproximar a distribuição binomial por uma distribuição normal. Para n suficientemente grande,

$$Y \dot{\sim} N(np, np(1-p)).$$

Essa expressão aproxima a distribuição de Y para valores grandes de n ; ela não afirma que Y converge em distribuição para uma normal cuja média e variância dependem de n .

i Derivação — Aproximação normal da binomial a partir do TCL

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Para cada observação,

$$E(X_i) = p$$

e

$$\text{Var}(X_i) = p(1 - p).$$

O Teorema Central do Limite fornece

$$\frac{\sqrt{n}(\bar{X}_n - p)}{\sqrt{p(1 - p)}} \xrightarrow{d} N(0, 1).$$

Como

$$Y = n\bar{X}_n,$$

temos

$$\sqrt{n}(\bar{X}_n - p) = \frac{Y - np}{\sqrt{n}}.$$

Portanto,

$$\frac{Y - np}{\sqrt{np(1 - p)}} \xrightarrow{d} N(0, 1).$$

Para grandes valores de n , isso permite aproximar a variável padronizada binomial por uma normal padrão:

$$\frac{Y - np}{\sqrt{np(1 - p)}} \sim N(0, 1).$$

Desfazendo a padronização, obtemos a forma operacional

$$Y \sim N(np, np(1 - p)).$$

Como a binomial é discreta e a normal é contínua, uma aproximação direta associa massas de probabilidade localizadas nos inteiros a áreas sob uma curva contínua. A **correção de continuidade** procura compensar essa diferença.

Por exemplo,

$$P(Y \leq k) \approx \Phi \left(\frac{k + 0,5 - np}{\sqrt{np(1 - p)}} \right),$$

e

$$P(Y \geq k) \approx 1 - \Phi \left(\frac{k - 0,5 - np}{\sqrt{np(1-p)}} \right).$$

i Origem da correção de continuidade

A variável binomial assume apenas valores inteiros. A probabilidade

$$P(Y = k)$$

corresponde a uma massa concentrada no ponto k .

Na aproximação contínua, essa massa é representada pela área de um intervalo de largura 1 centrado em k :

$$k - \frac{1}{2} < y < k + \frac{1}{2}.$$

Assim, o evento discreto

$$Y \leq k$$

é aproximado, na normal contínua, por

$$Y^* \leq k + \frac{1}{2},$$

em que

$$Y^* \sim N(np, np(1-p)).$$

Logo,

$$\begin{aligned} P(Y \leq k) &\approx P\left(Y^* \leq k + \frac{1}{2}\right) \\ &= \Phi\left(\frac{k + 0,5 - np}{\sqrt{np(1-p)}}\right). \end{aligned}$$

Da mesma forma,

$$Y \geq k$$

é aproximado pelo evento contínuo

$$Y^* \geq k - \frac{1}{2},$$

o que fornece

$$P(Y \geq k) \approx 1 - \Phi\left(\frac{k - 0,5 - np}{\sqrt{np(1-p)}}\right).$$

i Interpretação — Condições práticas

A aproximação é assintoticamente justificada quando p é fixado em

$$0 < p < 1$$

e n cresce. Em aplicações com tamanho amostral finito, sua qualidade depende principalmente de quão concentrada ou assimétrica é a distribuição binomial.

Condições como

$$np \geq 5 \quad \text{e} \quad n(1-p) \geq 5,$$

ou versões mais conservadoras com limite 10, são apenas diagnósticos heurísticos. Elas não constituem hipóteses do TCL nem garantem uma precisão fixa para todos os valores de p e todos os tipos de probabilidade de cauda (Chihara; Hesterberg, 2022, seq. 4.3.3, p. 92).

💡 Exemplo — Aproximação normal de uma probabilidade binomial

Sob um modelo Bernoulli i.i.d., suponha

$$p = 0,53 \quad \text{e} \quad n = 1000.$$

Se Y representa o número de sucessos na amostra, calcule aproximadamente

$$P(Y < 500)$$

utilizando a aproximação normal com correção de continuidade.

Antes de abrir a resolução, identifique:

1. a média e o desvio-padrão da distribuição binomial;
2. o limite contínuo correspondente ao evento $Y < 500$;
3. a padronização necessária para utilizar a normal padrão.

i Resolução — Aproximação normal com correção de continuidade

Temos

$$Y \sim \text{Bin}(1000, 0,53).$$

Logo,

$$E(Y) = np = 530$$

e

$$\begin{aligned} \text{DP}(Y) &= \sqrt{np(1-p)} \\ &= \sqrt{1000(0,53)(0,47)} \\ &\approx 15,78. \end{aligned}$$

Como

$$Y < 500$$

equivale, para uma variável inteira, a

$$Y \leq 499,$$

a correção de continuidade utiliza o limite

$$499,5.$$

Assim,

$$\begin{aligned} P(Y < 500) &= P(Y \leq 499) \\ &\approx P(Y^* \leq 499,5), \end{aligned}$$

em que

$$Y^* \sim N(530, 15,78^2).$$

Padronizando,

$$\begin{aligned} P(Y < 500) &\approx \Phi\left(\frac{499,5 - 530}{15,78}\right) \\ &\approx \Phi(-1,93) \\ &\approx 0,027. \end{aligned}$$

Portanto, pela aproximação normal com correção de continuidade,

$$P(Y < 500) \approx 0,0267.$$

Pela distribuição binomial exata,

$$P(Y < 500) = \sum_{y=0}^{499} \binom{1000}{y} (0,53)^y (0,47)^{1000-y} \approx 0,0267.$$

Assim, a aproximação normal com correção de continuidade produz um valor praticamente igual ao obtido pela distribuição binomial exata. Neste caso, a aproximação normal representa muito bem a probabilidade de observar menos de 500 sucessos.

4.9.2 Aproximação de Poisson para a binomial

A aproximação normal da distribuição binomial funciona melhor quando a distribuição não apresenta assimetria muito acentuada. Quando a probabilidade de sucesso é muito pequena, mesmo um valor elevado de n pode produzir uma distribuição binomial concentrada próxima de zero e fortemente assimétrica.

Nessa situação, outra aproximação pode ser mais adequada.

Se

$$Y \sim \text{Bin}(n, p)$$

e n é grande enquanto p é pequeno, de modo que

$$np \approx \lambda,$$

então a distribuição de Y pode ser aproximada por uma distribuição de Poisson:

$$Y \sim \text{Poisson}(\lambda), \quad \lambda = np.$$

A ideia é que a distribuição binomial descreve o número de sucessos em n tentativas independentes, enquanto a distribuição de Poisson fornece uma boa aproximação quando esses sucessos são **raros**, mas o número de oportunidades para que ocorram é grande.

i Derivação — Aproximação de Poisson para a binomial

Uma justificativa assintótica é obtida considerando uma sequência de distribuições binomiais em que

$$n \rightarrow \infty, \quad p_n \rightarrow 0$$

e

$$np_n \rightarrow \lambda, \quad 0 < \lambda < \infty.$$

Para simplificar a derivação, considere

$$p_n = \frac{\lambda}{n}.$$

Se

$$Y_n \sim \text{Bin}\left(n, \frac{\lambda}{n}\right),$$

então, para um valor inteiro fixo $k \geq 0$,

$$P(Y_n = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

Podemos escrever

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k = \frac{\lambda^k}{k!} \frac{n(n-1)\cdots(n-k+1)}{n^k}.$$

Assim,

$$P(Y_n = k) = \frac{\lambda^k}{k!} \frac{n(n-1)\cdots(n-k+1)}{n^k} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k}.$$

Quando $n \rightarrow \infty$,

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1,$$

$$\left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}$$

e

$$\left(1 - \frac{\lambda}{n}\right)^{-k} \rightarrow 1.$$

Portanto,

$$P(Y_n = k) \rightarrow e^{-\lambda} \frac{\lambda^k}{k!},$$

que é a função de massa de uma variável

$$Y \sim \text{Poisson}(\lambda).$$

Isso justifica a aproximação

$$\text{Bin}(n, p) \approx \text{Poisson}(np)$$

quando n é grande e p é pequeno.

Interpretação — Quando a aproximação de Poisson é útil

A aproximação de Poisson é particularmente útil quando o evento contado é raro. Nesse caso,

$$p \approx 0$$

e a média binomial

$$np$$

permanece relativamente pequena.

Nessas situações, a distribuição binomial pode ser bastante assimétrica. A aproximação normal, por ser baseada em uma distribuição contínua e simétrica, pode representar mal essa forma, especialmente nas probabilidades próximas de zero.

A distribuição de Poisson apresenta duas características importantes nesse contexto:

1. é uma distribuição discreta, assim como a binomial;
2. pode apresentar forte assimetria quando seu parâmetro λ é pequeno.

Condições como $p \leq 0,05$ acompanhadas de um valor moderado de np são frequentemente utilizadas como referência prática, mas não constituem condições matemáticas necessárias. A justificativa assintótica corresponde ao regime

$$n \rightarrow \infty, \quad p \rightarrow 0, \quad np \rightarrow \lambda.$$

Exemplo — Defeitos raros em uma grande produção

Uma indústria produz um lote com

$$n = 10000$$

componentes eletrônicos. Admita que cada componente apresente, independentemente, probabilidade

$$p = 0,0005$$

de possuir um defeito crítico.

Se Y representa o número de componentes defeituosos no lote, então

$$Y \sim \text{Bin}(10000, 0,0005).$$

A equipe de controle de qualidade deseja calcular a probabilidade de observar entre 4 e 10 componentes defeituosos:

$$P(4 \leq Y \leq 10).$$

Calcule essa probabilidade utilizando:

1. a distribuição binomial exata;
2. a aproximação de Poisson;
3. a aproximação normal com correção de continuidade.

Compare os resultados e avalie qual aproximação representa melhor a distribuição binomial neste caso.

i Resolução — Comparação entre as aproximações de Poisson e normal

Temos

$$Y \sim \text{Bin}(10000, 0,0005).$$

A média da distribuição binomial é

$$E(Y) = np = 10000(0,0005) = 5,$$

e sua variância é

$$\text{Var}(Y) = np(1 - p) = 10000(0,0005)(0,9995) = 4,9975.$$

Logo,

$$\text{DP}(Y) = \sqrt{4,9975} \approx 2,24.$$

Embora o número de ensaios seja muito grande,

$$n = 10000,$$

a probabilidade de defeito é muito pequena,

$$p = 0,0005,$$

e o número esperado de defeitos é apenas

$$np = 5.$$

Assim, a distribuição permanece assimétrica à direita e concentrada em valores relativamente pequenos de Y .

Probabilidade binomial exata

A probabilidade exata é

$$P(4 \leq Y \leq 10) = \sum_{y=4}^{10} \binom{10000}{y} (0,0005)^y (0,9995)^{10000-y}.$$

Esse cálculo é perfeitamente definido pela distribuição binomial, mas sua execução manual é pouco conveniente. Mesmo para valores pequenos de y , aparecem coeficientes combinatórios como

$$\binom{10000}{4}, \quad \binom{10000}{5}, \quad \dots, \quad \binom{10000}{10},$$

que produzem números muito grandes.

O valor exato é aproximadamente

$$P(4 \leq Y \leq 10) \approx 0,7214.$$

Aproximação de Poisson

Como n é grande e p é muito pequeno, utilizamos

$$\lambda = np = 5.$$

Assim,

$$Y \sim \text{Poisson}(5).$$

A probabilidade procurada é aproximada por

$$P(4 \leq Y \leq 10) \approx \sum_{y=4}^{10} e^{-5} \frac{5^y}{y!}.$$

Ou seja,

$$\begin{aligned} P(4 \leq Y \leq 10) &\approx e^{-5} \left[\frac{5^4}{4!} + \frac{5^5}{5!} + \dots + \frac{5^{10}}{10!} \right] \\ &\approx 0,7213. \end{aligned}$$

O valor é extremamente próximo da probabilidade binomial exata,

$$0,7214.$$

A vantagem operacional é clara: no lugar de vários coeficientes combinatórios envolvendo 10000, utilizamos apenas potências de 5 e fatoriais de números entre 4 e 10.

Aproximação normal

Para a aproximação normal,

$$Y^* \sim N(5, 4,9975).$$

Como queremos

$$4 \leq Y \leq 10,$$

a correção de continuidade utiliza

$$3,5 < Y^* < 10,5.$$

Portanto,

$$\begin{aligned} P(4 \leq Y \leq 10) &\approx P(3,5 < Y^* < 10,5) \\ &= P\left(\frac{3,5 - 5}{\sqrt{4,9975}} < Z < \frac{10,5 - 5}{\sqrt{4,9975}}\right). \end{aligned}$$

Como

$$\frac{3,5 - 5}{\sqrt{4,9975}} \approx -0,67$$

e

$$\frac{10,5 - 5}{\sqrt{4,9975}} \approx 2,46,$$

temos

$$P(4 \leq Y \leq 10) \approx \Phi(2,46) - \Phi(-0,67) \approx 0,7419.$$

Comparação

A probabilidade binomial exata é aproximadamente

$$0,7214.$$

A aproximação de Poisson fornece

$$0,7213,$$

enquanto a aproximação normal com correção de continuidade fornece

$$0,7419.$$

Neste exemplo, a aproximação de Poisson reproduz praticamente o mesmo valor da distribuição binomial exata.

A normal, mesmo com correção de continuidade, apresenta uma diferença maior porque sua forma simétrica não representa tão bem uma distribuição binomial com

$$np = 5$$

e probabilidade de sucesso muito pequena.

O exemplo mostra duas razões para utilizar a aproximação de Poisson nesse tipo de problema:

1. **adequação probabilística:** a distribuição de Poisson reproduz melhor a forma da binomial quando os eventos são raros;
2. **simplificação dos cálculos:** substitui coeficientes combinatórios envolvendo um valor muito grande de n por potências e fatoriais associados ao parâmetro

$$\lambda = np.$$

Assim, a aproximação de Poisson é útil em problemas com grande número de oportunidades e pequena probabilidade de ocorrência do evento em cada oportunidade.

4.10 Distribuição amostral da variância

Para $n \geq 2$, considere

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Se $X_1, \dots, X_n$ são i.i.d. e $\text{Var}(X_i) = \sigma^2 < \infty$, então

$$E(S^2) = \sigma^2.$$

Essa igualdade mostra que a distribuição amostral de S^2 está centrada em σ^2 (Casella; Berger, 2011, teorema 5.2.6; Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, cap. 6).

Demonstração — Esperança da variância amostral

Utilize a identidade

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2.$$

Tomando esperanças,

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = \sum_{i=1}^n E[(X_i - \mu)^2] - nE[(\bar{X} - \mu)^2].$$

Como

$$E[(X_i - \mu)^2] = \sigma^2$$

e

$$E[(\bar{X} - \mu)^2] = \text{Var}(\bar{X}) = \frac{\sigma^2}{n},$$

temos

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = n\sigma^2 - \sigma^2 = (n-1)\sigma^2.$$

Portanto, a soma dos quadrados dos desvios em relação à média amostral possui esperança

$$(n-1)\sigma^2.$$

Isso explica o papel do denominador $n-1$ na definição de S^2 : ao dividir essa soma por $n-1$, obtemos uma estatística cuja esperança é exatamente σ^2 .

Assim,

$$E(S^2) = \frac{1}{n-1}(n-1)\sigma^2 = \sigma^2.$$

4.10.1 Variância de S^2 sem hipótese de normalidade

Se o quarto momento central

$$\mu_4 = E[(X - \mu)^4]$$

é finito, então

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right].$$

i Demonstração — Variância de S^2 sem hipótese de normalidade

Como já sabemos que

$$E(S^2) = \sigma^2,$$

podemos escrever

$$\text{Var}(S^2) = E[(S^2)^2] - \sigma^4.$$

Portanto, o problema consiste em obter $E[(S^2)^2]$.

Para simplificar os cálculos, defina as variáveis centradas

$$Y_i = X_i - \mu.$$

Como $E(X_i) = \mu$, temos

$$E(Y_i) = 0, \quad E(Y_i^2) = \sigma^2$$

e, pela definição do quarto momento central,

$$E(Y_i^4) = E[(X_i - \mu)^4] = \mu_4.$$

Além disso, como $X_1, \dots, X_n$ são independentes, as variáveis $Y_1, \dots, Y_n$ também são independentes.

Considere agora

$$Q = \sum_{i=1}^n (X_i - \bar{X})^2.$$

Como

$$Q = (n-1)S^2,$$

temos

$$S^2 = \frac{Q}{n-1}$$

e, conseqüentemente,

$$E[(S^2)^2] = \frac{E(Q^2)}{(n-1)^2}.$$

Assim, basta calcular $E(Q^2)$.

1. Reescrevendo Q

Defina

$$A = \sum_{i=1}^n Y_i^2$$

e

$$T = \sum_{i=1}^n Y_i.$$

Como

$$\bar{X} - \mu = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{T}{n},$$

podemos usar a identidade

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2.$$

Logo,

$$Q = A - \frac{T^2}{n}.$$

Elevando ao quadrado,

$$Q^2 = A^2 - \frac{2}{n}AT^2 + \frac{1}{n^2}T^4.$$

Portanto,

$$E(Q^2) = E(A^2) - \frac{2}{n}E(AT^2) + \frac{1}{n^2}E(T^4).$$

Precisamos, então, calcular três esperanças:

$$E(A^2), \quad E(AT^2) \quad \text{e} \quad E(T^4).$$

2. Cálculo de $E(A^2)$

Como

$$A = \sum_{i=1}^n Y_i^2,$$

temos

$$A^2 = \left(\sum_{i=1}^n Y_i^2 \right)^2.$$

Expandindo,

$$A^2 = \sum_{i=1}^n Y_i^4 + 2 \sum_{i < j} Y_i^2 Y_j^2.$$

Tomando esperança,

$$E(A^2) = \sum_{i=1}^n E(Y_i^4) + 2 \sum_{i < j} E(Y_i^2 Y_j^2).$$

O primeiro somatório possui n termos, cada um com esperança μ_4 :

$$\sum_{i=1}^n E(Y_i^4) = n\mu_4.$$

Para $i \neq j$, a independência fornece

$$E(Y_i^2 Y_j^2) = E(Y_i^2) E(Y_j^2) = \sigma^4.$$

Como existem

$$\binom{n}{2}$$

pares distintos, segue que

$$\begin{aligned} E(A^2) &= n\mu_4 + 2 \binom{n}{2} \sigma^4 \\ &= n\mu_4 + n(n-1)\sigma^4. \end{aligned}$$

3. Cálculo de $E(AT^2)$

Como

$$T = \sum_{i=1}^n Y_i,$$

temos

$$T^2 = \sum_{i=1}^n Y_i^2 + 2 \sum_{i < j} Y_i Y_j.$$

Como o primeiro somatório é justamente A ,

$$T^2 = A + 2 \sum_{i < j} Y_i Y_j.$$

Multiplicando por A ,

$$AT^2 = A^2 + 2A \sum_{i < j} Y_i Y_j.$$

Agora observe o segundo termo. Como

$$A = \sum_{k=1}^n Y_k^2,$$

os produtos que aparecem em

$$A \sum_{i < j} Y_i Y_j$$

são da forma

$$Y_k^2 Y_i Y_j.$$

Como $i \neq j$, cada um desses produtos contém pelo menos uma variável aparecendo com potência 1. Como

$$E(Y_i) = 0,$$

e as variáveis são independentes, a esperança de cada um desses termos é zero. Por exemplo, se k , i e j são diferentes,

$$E(Y_k^2 Y_i Y_j) = E(Y_k^2) E(Y_i) E(Y_j) = 0.$$

Se $k = i$, temos

$$E(Y_i^3 Y_j) = E(Y_i^3) E(Y_j) = 0,$$

e o mesmo ocorre quando $k = j$. Portanto,

$$E \left(A \sum_{i < j} Y_i Y_j \right) = 0.$$

Assim,

$$E(AT^2) = E(A^2),$$

e, pelo resultado anterior,

$$E(AT^2) = n\mu_4 + n(n-1)\sigma^4.$$

4. Cálculo de $E(T^4)$

Agora,

$$T^4 = \left(\sum_{i=1}^n Y_i \right)^4.$$

À primeira vista, essa expansão produz muitos termos. Entretanto, a maior parte deles possui esperança igual a zero, pois

$$E(Y_i) = 0.$$

Para que um termo tenha esperança diferente de zero, os índices precisam aparecer de forma que nenhuma variável independente fique isolada com potência 1.

Existem apenas dois tipos de termos que permanecem.

Quatro fatores com o mesmo índice

Temos termos da forma

$$Y_i^4.$$

Existem n desses termos e

$$E(Y_i^4) = \mu_4.$$

Sua contribuição total é, portanto,

$$n\mu_4.$$

Dois pares de índices

Também permanecem termos da forma

$$Y_i^2 Y_j^2, \quad i \neq j.$$

Para cada par $\{i, j\}$, o produto $Y_i^2 Y_j^2$ pode ser formado escolhendo quais duas das quatro posições serão ocupadas por Y_i . Existem

$$\binom{4}{2} = 6$$

possibilidades.

Como existem

$$\binom{n}{2}$$

pares distintos de índices, a contribuição total desses termos é

$$6 \binom{n}{2} \sigma^4.$$

Portanto,

$$\begin{aligned} E(T^4) &= n\mu_4 + 6 \binom{n}{2} \sigma^4 \\ &= n\mu_4 + 3n(n-1)\sigma^4. \end{aligned}$$

5. Reunindo os resultados

Obtivemos

$$E(A^2) = n\mu_4 + n(n-1)\sigma^4,$$

$$E(AT^2) = n\mu_4 + n(n-1)\sigma^4$$

e

$$E(T^4) = n\mu_4 + 3n(n-1)\sigma^4.$$

Substituindo em

$$E(Q^2) = E(A^2) - \frac{2}{n}E(AT^2) + \frac{1}{n^2}E(T^4),$$

temos

$$\begin{aligned} E(Q^2) &= [n\mu_4 + n(n-1)\sigma^4] \\ &\quad - \frac{2}{n} [n\mu_4 + n(n-1)\sigma^4] \\ &\quad + \frac{1}{n^2} [n\mu_4 + 3n(n-1)\sigma^4]. \end{aligned}$$

Agrupando os termos que envolvem μ_4 ,

$$n\mu_4 - 2\mu_4 + \frac{\mu_4}{n} = \frac{(n-1)^2}{n}\mu_4.$$

Agrupando os termos que envolvem σ^4 ,

$$n(n-1)\sigma^4 - 2(n-1)\sigma^4 + \frac{3(n-1)}{n}\sigma^4,$$

obtemos

$$\frac{(n-1)(n^2 - 2n + 3)}{n}\sigma^4.$$

Logo,

$$E(Q^2) = \frac{(n-1)^2}{n}\mu_4 + \frac{(n-1)(n^2 - 2n + 3)}{n}\sigma^4.$$

Como

$$S^2 = \frac{Q}{n-1},$$

segue que

$$\begin{aligned} E[(S^2)^2] &= \frac{E(Q^2)}{(n-1)^2} \\ &= \frac{\mu_4}{n} + \frac{n^2 - 2n + 3}{n(n-1)}\sigma^4. \end{aligned}$$

Finalmente, como

$$E(S^2) = \sigma^2,$$

temos

$$\begin{aligned} \text{Var}(S^2) &= E[(S^2)^2] - [E(S^2)]^2 \\ &= \frac{\mu_4}{n} + \frac{n^2 - 2n + 3}{n(n-1)}\sigma^4 - \sigma^4 \\ &= \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1}\sigma^4 \right]. \end{aligned}$$

Portanto,

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1}\sigma^4 \right].$$

A expressão mostra que a variabilidade de S^2 depende não somente de σ^2 , mas também do quarto momento central μ_4 da distribuição.

Portanto, a variância de S^2 depende do quarto momento da população. No modelo normal,

$$\mu_4 = 3\sigma^4,$$

e a expressão geral se reduz a

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}.$$

Esse caso também pode ser obtido diretamente da distribuição qui-quadrado de $(n-1)S^2/\sigma^2$ (Casella; Berger, 2011, exercício 5.10).

Até aqui, estudamos propriedades de S^2 que não exigem normalidade, exceto quando essa hipótese foi explicitamente utilizada. Sob o modelo normal, é possível avançar além dos momentos e obter a **distribuição exata** de transformações envolvendo $\bar{X}$ e S^2 .

4.11 Distribuições derivadas do modelo normal

A **distribuição qui-quadrado**, a **distribuição t de Student** e a **distribuição F de Fisher-Snedecor**, denotadas respectivamente por χ^2 , t e F , surgem de transformações de variáveis normais e desempenham papel central na inferência exata para médias e variâncias (Larsen; Marx, 2012, cap. 7 e 9; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, cap. 6).

4.11.1 Distribuição qui-quadrado

! Definição — Distribuição qui-quadrado

Se

$$Z_1, \dots, Z_\nu$$

são variáveis aleatórias independentes com

$$Z_j \sim N(0, 1),$$

então a soma dos quadrados

$$W = \sum_{j=1}^{\nu} Z_j^2$$

possui distribuição qui-quadrado com ν graus de liberdade, o que escrevemos como

$$W \sim \chi_\nu^2.$$

O parâmetro ν representa o número de graus de liberdade (Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2).

Se

$$W \sim \chi_\nu^2,$$

sua função densidade é

$$f_W(w) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} w^{\nu/2-1} e^{-w/2} \mathbf{1}_{(0, \infty)}(w),$$

A distribuição qui-quadrado possui suporte apenas nos valores positivos. Sua forma depende do número de graus de liberdade ν : para valores pequenos de ν , a distribuição é bastante assimétrica à direita; à medida que ν aumenta, essa assimetria diminui.

Além disso,

$$E(W) = \nu, \quad \text{Var}(W) = 2\nu.$$

i Derivação — Média e variância da distribuição χ^2

Pela definição,

$$W = \sum_{j=1}^{\nu} Z_j^2,$$

em que

$$Z_j \stackrel{\text{iid}}{\sim} N(0, 1).$$

Como

$$E(Z_j^2) = 1,$$

temos

$$\begin{aligned} E(W) &= E\left(\sum_{j=1}^{\nu} Z_j^2\right) \\ &= \sum_{j=1}^{\nu} E(Z_j^2) \\ &= \nu. \end{aligned}$$

Para obter a variância, usamos

$$\text{Var}(Z_j^2) = E(Z_j^4) - [E(Z_j^2)]^2.$$

Para uma variável normal padrão,

$$E(Z_j^4) = 3,$$

e, portanto,

$$\text{Var}(Z_j^2) = 3 - 1 = 2.$$

Como as variáveis $Z_1, \dots, Z_{\nu}$ são independentes, seus quadrados também são independentes. Assim,

$$\begin{aligned}
\text{Var}(W) &= \text{Var} \left(\sum_{j=1}^{\nu} Z_j^2 \right) \\
&= \sum_{j=1}^{\nu} \text{Var}(Z_j^2) \\
&= 2\nu.
\end{aligned}$$

i Derivação — Momentos inversos da distribuição χ^2

Os momentos inversos da distribuição qui-quadrado serão utilizados posteriormente nas derivações de propriedades das distribuições t e F .

Se

$$W \sim \chi_{\nu}^2,$$

então, para

$$0 < r < \frac{\nu}{2},$$

temos

$$E(W^{-r}) = \int_0^{\infty} w^{-r} f_W(w) dw.$$

Substituindo a densidade da distribuição qui-quadrado,

$$\begin{aligned}
E(W^{-r}) &= \int_0^{\infty} w^{-r} \frac{1}{2^{\nu/2} \Gamma(\nu/2)} w^{\nu/2-1} e^{-w/2} dw \\
&= \frac{1}{2^{\nu/2} \Gamma(\nu/2)} \int_0^{\infty} w^{\nu/2-r-1} e^{-w/2} dw.
\end{aligned}$$

Reconhecendo a integral gama,

$$\int_0^{\infty} w^{a-1} e^{-w/2} dw = 2^a \Gamma(a),$$

com

$$a = \frac{\nu}{2} - r,$$

obtemos

$$E(W^{-r}) = 2^{-r} \frac{\Gamma(\nu/2 - r)}{\Gamma(\nu/2)}.$$

Para $r = 1$, se $\nu > 2$,

$$E\left(\frac{1}{W}\right) = \frac{1}{\nu - 2}.$$

Para $r = 2$, se $\nu > 4$,

$$E\left(\frac{1}{W^2}\right) = \frac{1}{(\nu - 2)(\nu - 4)}.$$

Esses dois resultados serão utilizados posteriormente no estudo das distribuições t e F .

4.11.2 Independência entre média e variância

! Teorema — Independência no modelo normal

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

então a média amostral $\bar{X}$ e a variância amostral S^2 são independentes:

$$\bar{X} \perp\!\!\!\perp S^2.$$

A notação

$$A \perp\!\!\!\perp B$$

será utilizada para indicar que as variáveis aleatórias ou estatísticas A e B são **independentes**.

A independência entre a média e a variância amostrais é uma propriedade particular do modelo normal (Casella; Berger, 2011, teorema 5.3.1; Larsen; Marx, 2012, apêndice 7.A.2; Rice, 2007, seq. 6.3).

i Demonstração — Independência entre $\bar{X}$ e S^2

A ideia da demonstração é mostrar que:

1. $\bar{X}$ é independente dos desvios das observações em relação à própria média amostral;
2. S^2 depende apenas desses desvios.

Se essas duas afirmações forem verdadeiras, então $\bar{X}$ será independente de S^2 .

1. Os resíduos em relação à média amostral

Considere os resíduos

$$R_i = X_i - \bar{X}.$$

Eles medem quanto cada observação se afasta da média amostral.
Como

$$\sum_{i=1}^n (X_i - \bar{X}) = 0,$$

os n resíduos não são livres entre si. Conhecendo $n-1$ deles, o último é automaticamente determinado.

Por isso, é suficiente trabalhar com

$$R_2, \dots, R_n.$$

De fato,

$$R_1 = -\sum_{i=2}^n R_i.$$

2. Relação entre $\bar{X}$ e cada resíduo

Queremos verificar se $\bar{X}$ possui alguma associação linear com cada R_i .

Para $i = 2, \dots, n$,

$$R_i = X_i - \bar{X}.$$

Assim,

$$\begin{aligned} \text{Cov}(\bar{X}, R_i) &= \text{Cov}(\bar{X}, X_i - \bar{X}) \\ &= \text{Cov}(\bar{X}, X_i) - \text{Var}(\bar{X}). \end{aligned}$$

Agora,

$$\bar{X} = \frac{1}{n} \sum_{j=1}^n X_j.$$

Portanto,

$$\begin{aligned} \text{Cov}(\bar{X}, X_i) &= \text{Cov}\left(\frac{1}{n} \sum_{j=1}^n X_j, X_i\right) \\ &= \frac{1}{n} \sum_{j=1}^n \text{Cov}(X_j, X_i). \end{aligned}$$

Como as observações são independentes,

$$\text{Cov}(X_j, X_i) = 0, \quad j \neq i,$$

e

$$\text{Cov}(X_i, X_i) = \text{Var}(X_i) = \sigma^2.$$

Logo,

$$\text{Cov}(\bar{X}, X_i) = \frac{\sigma^2}{n}.$$

Além disso,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Consequentemente,

$$\begin{aligned}\text{Cov}(\bar{X}, R_i) &= \frac{\sigma^2}{n} - \frac{\sigma^2}{n} \\ &= 0.\end{aligned}$$

Portanto,

$$\text{Cov}(\bar{X}, R_i) = 0, \quad i = 2, \dots, n.$$

3. Covariância zero implica independência neste caso

Em geral, covariância zero não é suficiente para garantir independência.

Aqui, entretanto, estamos no modelo normal.

A média

$$\bar{X}$$

e os resíduos

$$R_2, \dots, R_n$$

são combinações lineares das variáveis

$$X_1, \dots, X_n,$$

que são normais independentes.

Logo, o vetor

$$(\bar{X}, R_2, \dots, R_n)$$

possui distribuição normal multivariada.

Para variáveis conjuntamente normais, covariância zero implica independência. Como

$$\text{Cov}(\bar{X}, R_i) = 0$$

para todo

$$i = 2, \dots, n,$$

segue que

$$\overline{X} \perp\!\!\!\perp (R_2, \dots, R_n).$$

Ou seja, a média amostral é independente do vetor formado por esses $n - 1$ resíduos. As relações entre covariância e independência são revisadas em Seção 1.4.7, e as transformações lineares de variáveis normais em Seção 1.8.4.2.

4. A variância amostral depende apenas dos resíduos

Por definição,

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X})^2.$$

Em termos dos resíduos,

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n R_i^2.$$

Como

$$R_1 = - \sum_{i=2}^n R_i,$$

temos

$$R_1^2 = \left(\sum_{i=2}^n R_i \right)^2.$$

Portanto,

$$S^2 = \frac{1}{n-1} \left[\left(\sum_{i=2}^n R_i \right)^2 + \sum_{i=2}^n R_i^2 \right].$$

Assim, S^2 é completamente determinada por

$$R_2, \dots, R_n.$$

Mas já mostramos que

$$\overline{X} \perp\!\!\!\perp (R_2, \dots, R_n).$$

Como uma função de um vetor aleatório independente de $\bar{X}$ também é independente de $\bar{X}$, concluímos que

$$\bar{X} \perp\!\!\!\perp S^2.$$

⚠ Observação — Especificidade do modelo normal

O ponto decisivo da demonstração é a normalidade conjunta de

$$(\bar{X}, R_2, \dots, R_n).$$

Foi ela que permitiu passar de

$$\text{Cov}(\bar{X}, R_i) = 0$$

para independência.

Em outras distribuições, covariância zero não implica, em geral, independência. Por isso, a independência entre $\bar{X}$ e S^2 é uma propriedade particular do modelo normal.

4.11.3 Distribuição da variância amostral no modelo normal

! Resultado — Distribuição da variância amostral no modelo normal

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

então

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Portanto, no modelo normal, a distribuição da variância amostral está diretamente relacionada à distribuição qui-quadrado com $n - 1$ graus de liberdade.

Esse resultado é específico do modelo normal (Casella; Berger, 2011, teorema 5.3.1; Larsen; Marx, 2012, cap. 7; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2–6.3).

i Interpretação — Por que aparecem $n - 1$ graus de liberdade?

A variância amostral é calculada a partir dos desvios

$$X_1 - \bar{X}, \dots, X_n - \bar{X}.$$

Esses n desvios satisfazem necessariamente a restrição

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

Assim, depois que $n - 1$ desvios são conhecidos, o último fica determinado. Por exemplo,

$$X_n - \bar{X} = -\sum_{i=1}^{n-1} (X_i - \bar{X}).$$

Portanto, embora existam n desvios, apenas $n - 1$ deles podem variar livremente. É nesse sentido que a soma de quadrados associada à variância amostral possui $n - 1$ graus de liberdade.

Como

$$(n - 1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2,$$

no modelo normal obtemos

$$\frac{(n - 1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

A expressão “ $n - 1$ graus de liberdade” não significa que quaisquer $n - 1$ resíduos sejam variáveis aleatórias independentes. Ela indica que a restrição

$$\sum_{i=1}^n (X_i - \bar{X}) = 0$$

reduz em uma unidade o número de componentes livres de variação.

i Demonstração — Distribuição de S^2 no modelo normal

A demonstração será feita por indução sobre o tamanho da amostra.

A ideia é acompanhar o que acontece com a soma de quadrados quando uma nova observação é acrescentada. Veremos que cada nova observação acrescenta um novo componente independente com distribuição χ_1^2 . Assim, os graus de liberdade aumentam de um em um.

Etapla 1 — Soma de quadrados para as primeiras k observações

Denote por

$$\bar{X}_k = \frac{1}{k} \sum_{i=1}^k X_i$$

a média das primeiras k observações e por S_k^2 a correspondente variância amostral. Defina

$$Q_k = \sum_{i=1}^k (X_i - \bar{X}_k)^2.$$

Pela definição da variância amostral,

$$Q_k = (k-1)S_k^2.$$

Quando acrescentamos uma nova observação X_{k+1} , a média passa a ser

$$\bar{X}_{k+1} = \frac{k\bar{X}_k + X_{k+1}}{k+1}.$$

A nova soma de quadrados é

$$Q_{k+1} = \sum_{i=1}^{k+1} (X_i - \bar{X}_{k+1})^2.$$

Para as primeiras k observações,

$$X_i - \bar{X}_{k+1} = (X_i - \bar{X}_k) + (\bar{X}_k - \bar{X}_{k+1}).$$

Ao elevar ao quadrado e somar de $i = 1$ até k , o termo cruzado desaparece porque

$$\sum_{i=1}^k (X_i - \bar{X}_k) = 0.$$

Assim,

$$Q_{k+1} = Q_k + k(\bar{X}_k - \bar{X}_{k+1})^2 + (X_{k+1} - \bar{X}_{k+1})^2.$$

Agora, a partir da expressão de $\bar{X}_{k+1}$,

$$\bar{X}_k - \bar{X}_{k+1} = -\frac{X_{k+1} - \bar{X}_k}{k+1},$$

e

$$X_{k+1} - \bar{X}_{k+1} = \frac{k}{k+1}(X_{k+1} - \bar{X}_k).$$

Substituindo essas expressões em Q_{k+1} ,

$$\begin{aligned} Q_{k+1} &= Q_k + k \left[\frac{X_{k+1} - \bar{X}_k}{k+1} \right]^2 + \left[\frac{k}{k+1}(X_{k+1} - \bar{X}_k) \right]^2 \\ &= Q_k + \frac{k}{k+1}(X_{k+1} - \bar{X}_k)^2. \end{aligned}$$

Como

$$Q_k = (k-1)S_k^2$$

e

$$Q_{k+1} = kS_{k+1}^2,$$

obtemos a identidade

$$kS_{k+1}^2 = (k-1)S_k^2 + \frac{k}{k+1}(X_{k+1} - \bar{X}_k)^2.$$

Essa identidade mostra como a soma de quadrados se modifica quando uma nova observação é incorporada à amostra.

Etapas 2 — Caso inicial: amostra de tamanho 2

Para duas observações,

$$\bar{X}_2 = \frac{X_1 + X_2}{2}.$$

Como

$$S_2^2 = (X_1 - \bar{X}_2)^2 + (X_2 - \bar{X}_2)^2,$$

temos

$$X_1 - \bar{X}_2 = \frac{X_1 - X_2}{2}$$

e

$$X_2 - \bar{X}_2 = \frac{X_2 - X_1}{2}.$$

Logo,

$$S_2^2 = \frac{(X_2 - X_1)^2}{2}.$$

Como X_1 e X_2 são independentes e

$$X_1, X_2 \sim N(\mu, \sigma^2),$$

a diferença possui distribuição

$$X_2 - X_1 \sim N(0, 2\sigma^2).$$

Portanto,

$$Z = \frac{X_2 - X_1}{\sigma\sqrt{2}} \sim N(0, 1).$$

Elevando ao quadrado,

$$Z^2 = \frac{(X_2 - X_1)^2}{2\sigma^2} = \frac{S_2^2}{\sigma^2}.$$

Como o quadrado de uma variável normal padrão possui distribuição χ_1^2 ,

$$\frac{S_2^2}{\sigma^2} \sim \chi_1^2.$$

Assim, o resultado é válido para $n = 2$:

$$\frac{(2-1)S_2^2}{\sigma^2} \sim \chi_1^2.$$

Etapas 3 — Hipótese de indução

Suponha agora que o resultado seja válido para uma amostra de tamanho k . Isto é,

$$\frac{(k-1)S_k^2}{\sigma^2} \sim \chi_{k-1}^2.$$

Queremos mostrar que, ao acrescentarmos a observação X_{k+1} , teremos

$$\frac{kS_{k+1}^2}{\sigma^2} \sim \chi_k^2.$$

Etapas 4 — Distribuição do novo componente

O novo termo da identidade recursiva envolve

$$X_{k+1} - \bar{X}_k.$$

A observação X_{k+1} é independente das primeiras k observações. Portanto, é independente de $\bar{X}_k$.

Além disso,

$$X_{k+1} \sim N(\mu, \sigma^2)$$

e

$$\bar{X}_k \sim N\left(\mu, \frac{\sigma^2}{k}\right).$$

Como a diferença entre duas variáveis normais independentes também possui distribuição normal,

$$X_{k+1} - \bar{X}_k$$

é normal.
Sua média é

$$\begin{aligned} E(X_{k+1} - \bar{X}_k) &= E(X_{k+1}) - E(\bar{X}_k) \\ &= \mu - \mu \\ &= 0. \end{aligned}$$

Como X_{k+1} e $\bar{X}_k$ são independentes, sua variância é

$$\begin{aligned} \text{Var}(X_{k+1} - \bar{X}_k) &= \text{Var}(X_{k+1}) + \text{Var}(\bar{X}_k) \\ &= \sigma^2 + \frac{\sigma^2}{k} \\ &= \sigma^2 \frac{k+1}{k}. \end{aligned}$$

Portanto,

$$X_{k+1} - \bar{X}_k \sim N\left(0, \sigma^2 \frac{k+1}{k}\right).$$

Padronizando,

$$Z_{k+1} = \sqrt{\frac{k}{k+1}} \frac{X_{k+1} - \bar{X}_k}{\sigma} \sim N(0, 1).$$

Consequentemente,

$$Z_{k+1}^2 = \frac{k}{k+1} \frac{(X_{k+1} - \bar{X}_k)^2}{\sigma^2} \sim \chi_1^2.$$

Assim, o novo componente acrescentado à soma de quadrados padronizada possui distribuição qui-quadrado com um grau de liberdade.

Etapa 5 — Independência dos dois componentes

Pelo resultado de Seção 4.11.2,

$$S_k^2 \perp\!\!\!\perp \bar{X}_k.$$

Além disso, X_{k+1} é independente de todas as funções das primeiras k observações. Em particular, é independente de S_k^2 e de $\bar{X}_k$.

Consequentemente,

$$S_k^2 \perp\!\!\!\perp (\bar{X}_k, X_{k+1}).$$

Como

$$X_{k+1} - \bar{X}_k$$

é uma função de $(\bar{X}_k, X_{k+1})$, segue que

$$S_k^2 \perp\!\!\!\perp (X_{k+1} - \bar{X}_k).$$

Defina agora

$$U_k = \frac{(k-1)S_k^2}{\sigma^2}$$

e

$$V_{k+1} = \frac{k}{k+1} \frac{(X_{k+1} - \bar{X}_k)^2}{\sigma^2}.$$

Pela hipótese de indução,

$$U_k \sim \chi_{k-1}^2,$$

e, pelo resultado da etapa anterior,

$$V_{k+1} \sim \chi_1^2.$$

Além disso,

$$U_k \perp\!\!\!\perp V_{k+1}.$$

Etapa 6 — Soma dos componentes

Dividindo a identidade recursiva por σ^2 ,

$$\frac{kS_{k+1}^2}{\sigma^2} = U_k + V_{k+1}.$$

A soma de variáveis qui-quadrado independentes também possui distribuição qui-quadrado, com número de graus de liberdade igual à soma dos graus de liberdade.

Como

$$U_k \sim \chi_{k-1}^2$$

e

$$V_{k+1} \sim \chi_1^2,$$

temos

$$U_k + V_{k+1} \sim \chi_k^2.$$

Portanto,

$$\frac{kS_{k+1}^2}{\sigma^2} \sim \chi_k^2.$$

Mostramos que, se o resultado vale para uma amostra de tamanho k , também vale para uma amostra de tamanho $k + 1$.

Como o resultado foi verificado inicialmente para $n = 2$, concluímos por indução que, para qualquer $n \geq 2$,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

A demonstração também fornece uma interpretação dos graus de liberdade: ao acrescentar uma nova observação, acrescenta-se à soma de quadrados padronizada um novo componente independente com distribuição χ_1^2 . Por isso, os graus de liberdade aumentam de um em um.

i Aprofundamento — Graus de liberdade e restrições lineares

A interpretação apresentada anteriormente pode ser expressa de forma mais geral. O vetor de resíduos

$$(X_1 - \bar{X}, \dots, X_n - \bar{X})$$

possui n componentes, mas eles satisfazem a restrição linear

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

Essa única restrição reduz de n para $n - 1$ o número de componentes que podem variar livremente.

No modelo normal, essa estrutura está diretamente relacionada à distribuição qui-quadrado: após uma transformação linear apropriada, a variação residual pode ser representada por $n - 1$ componentes normais padrão independentes. A soma de seus quadrados possui, então, distribuição

$$\chi_{n-1}^2.$$

Essa interpretação por restrições lineares aparece em diversos procedimentos estatísticos. Entretanto, nem todo parâmetro denominado grau de liberdade deve ser interpretado literalmente como uma contagem de observações independentes. Em alguns métodos aproximados, os graus de liberdade funcionam como parâmetros de calibração da distribuição utilizada.

4.11.4 Distribuição t de Student

No modelo normal, quando o desvio-padrão populacional σ é conhecido, a média amostral pode ser padronizada por

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}},$$

e temos

$$Z \sim N(0, 1).$$

Na prática, entretanto, σ geralmente é desconhecido. Uma possibilidade natural é substituí-lo pelo desvio-padrão amostral S e considerar

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Essa substituição parece pequena, mas modifica a distribuição da estatística: o denominador deixa de ser uma constante e passa a ser uma variável aleatória. No modelo normal, a distribuição resultante é a **distribuição t de Student**.

! Definição — Distribuição t de Student

Se

$$Z \sim N(0, 1)$$

e

$$W \sim \chi^2_\nu$$

são independentes, então a variável

$$T = \frac{Z}{\sqrt{W/\nu}}$$

possui distribuição t de Student com ν graus de liberdade, o que escrevemos como

$$T \sim t_\nu.$$

O parâmetro ν é denominado **número de graus de liberdade**.

Essa construção define a distribuição t de Student (Casella; Berger, 2011, definição 5.3.4; Larsen; Marx, 2012, seq. 7.2–7.3; Rice, 2007, seq. 6.2).

A forma da variável

$$T = \frac{Z}{\sqrt{W/\nu}}$$

ajuda a compreender a distribuição t . O numerador possui distribuição normal padrão, enquanto o denominador é aleatório. Essa variabilidade adicional no denominador produz valores extremos com maior frequência do que na distribuição normal padrão. Por isso, a distribuição t apresenta **caudas mais pesadas**.

À medida que ν aumenta, a quantidade

$$\frac{W}{\nu}$$

tende a ficar mais concentrada em torno de 1. Consequentemente, o denominador

$$\sqrt{\frac{W}{\nu}}$$

fica mais próximo de 1, e a distribuição de T se aproxima da distribuição normal padrão. Esse resultado será formalizado adiante.

! Resultado — Média studentizada no modelo normal

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

então

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Esse resultado é exato para qualquer $n \geq 2$ sob normalidade.

i Derivação — Estatística t no modelo normal

Os resultados obtidos anteriormente fornecem exatamente os dois componentes necessários para construir uma variável com distribuição t .

Primeiro, como a amostra provém de uma distribuição normal,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Logo,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Segundo, por Seção 4.11.3,

$$W = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Além disso, por Seção 4.11.2,

$$\bar{X} \perp\!\!\!\perp S^2.$$

Como Z é função de $\bar{X}$ e W é função de S^2 , temos também

$$Z \perp\!\!\!\perp W.$$

Portanto, Z e W satisfazem exatamente as condições da definição da distribuição t . Com

$$\nu = n - 1,$$

temos

$$\frac{Z}{\sqrt{W/(n-1)}} \sim t_{n-1}.$$

Agora,

$$\frac{W}{n-1} = \frac{(n-1)S^2/\sigma^2}{n-1} = \frac{S^2}{\sigma^2}.$$

Assim,

$$\sqrt{\frac{W}{n-1}} = \frac{S}{\sigma}.$$

Substituindo no quociente,

$$\begin{aligned} \frac{Z}{\sqrt{W/(n-1)}} &= \frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{S/\sigma} \\ &= \frac{\bar{X} - \mu}{S/\sqrt{n}}. \end{aligned}$$

Portanto,

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

A passagem de

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

para

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}$$

é denominada **studentização**: o desvio-padrão populacional desconhecido σ é substituído por seu estimador amostral S .

Sob normalidade, essa substituição modifica a distribuição da estatística de $N(0, 1)$ para t_{n-1} .

4.11.4.1 Densidade e forma da distribuição t

Se

$$T \sim t_{\nu},$$

sua função densidade é

$$f_T(t) = \frac{\Gamma((\nu + 1)/2)}{\sqrt{\nu\pi} \Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}, \quad -\infty < t < \infty.$$

A densidade depende de t apenas por meio de t^2 . Portanto,

$$f_T(-t) = f_T(t),$$

e a distribuição é simétrica em torno de zero.

Sua forma depende dos graus de liberdade ν . Para valores pequenos de ν , as caudas são mais pesadas. À medida que ν aumenta, a distribuição se torna progressivamente mais próxima da normal padrão.

i Derivação — Densidade da distribuição t

Pela definição,

$$T = \frac{Z}{\sqrt{W/\nu}},$$

em que

$$Z \sim N(0, 1), \quad W \sim \chi_\nu^2,$$

e Z e W são independentes.

Para obter a densidade de T , aplicamos o método de transformação multivariada e jacobiano revisado em Seção 2.2.7.

Considere a transformação

$$T = \frac{Z}{\sqrt{W/\nu}}, \quad Q = W.$$

Mantemos W como segunda variável porque isso permite recuperar Z e W a partir de T e Q .

A transformação inversa é

$$Z = T\sqrt{\frac{Q}{\nu}}, \quad W = Q.$$

Ou seja,

$$z = t\sqrt{\frac{q}{\nu}}, \quad w = q.$$

A matriz jacobiana da transformação inversa é

$$\frac{\partial(z, w)}{\partial(t, q)} = \begin{pmatrix} \sqrt{q/\nu} & \frac{t}{2\sqrt{\nu q}} \\ 0 & 1 \end{pmatrix}.$$

Portanto,

$$\left| \frac{\partial(z, w)}{\partial(t, q)} \right| = \sqrt{\frac{q}{\nu}}.$$

Como Z e W são independentes, sua densidade conjunta é

$$f_{Z,W}(z, w) = f_Z(z)f_W(w).$$

Assim, pela mudança de variáveis,

$$f_{T,Q}(t, q) = f_Z \left(t \sqrt{\frac{q}{\nu}} \right) f_W(q) \sqrt{\frac{q}{\nu}}, \quad q > 0.$$

Para obter a densidade marginal de T , integramos em relação a q :

$$f_T(t) = \int_0^\infty f_Z \left(t \sqrt{\frac{q}{\nu}} \right) f_W(q) \sqrt{\frac{q}{\nu}} dq.$$

A densidade da normal padrão é

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2},$$

e a densidade da distribuição qui-quadrado é

$$f_W(q) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} q^{\nu/2-1} e^{-q/2}, \quad q > 0.$$

Substituindo essas expressões,

$$\begin{aligned} f_T(t) &= \frac{1}{\sqrt{2\pi} 2^{\nu/2} \Gamma(\nu/2) \sqrt{\nu}} \\ &\times \int_0^\infty q^{(\nu+1)/2-1} \exp \left[-\frac{q}{2} \left(1 + \frac{t^2}{\nu} \right) \right] dq. \end{aligned}$$

A integral possui a forma da integral gama

$$\int_0^\infty q^{a-1} e^{-bq} dq = \frac{\Gamma(a)}{b^a},$$

com

$$a = \frac{\nu+1}{2}$$

e

$$b = \frac{1}{2} \left(1 + \frac{t^2}{\nu} \right).$$

Logo,

$$\int_0^\infty q^{(\nu+1)/2-1} \exp \left[-\frac{q}{2} \left(1 + \frac{t^2}{\nu} \right) \right] dq$$

é igual a

$$\Gamma \left(\frac{\nu+1}{2} \right) \left[\frac{2}{1 + t^2/\nu} \right]^{(\nu+1)/2}.$$

Substituindo e simplificando,

$$f_T(t) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi} \Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}.$$

Como a expressão depende de t somente por meio de t^2 ,

$$f_T(-t) = f_T(t),$$

confirmando a simetria da distribuição em torno de zero.

A derivação segue a transformação utilizada em Casella; Berger (2011, seq. 5.3.2).

4.11.4.2 Média e variância

Para

$$T \sim t_\nu,$$

temos

$$E(T) = 0, \quad \nu > 1,$$

e

$$\text{Var}(T) = \frac{\nu}{\nu - 2}, \quad \nu > 2.$$

Quando

$$\nu \leq 1,$$

a média não existe.

Quando

$$\nu \leq 2,$$

a variância não existe.

Para $\nu > 2$,

$$\frac{\nu}{\nu - 2} > 1.$$

Assim, a distribuição t possui maior variabilidade que a normal padrão. À medida que ν aumenta,

$$\frac{\nu}{\nu - 2} \rightarrow 1,$$

em concordância com a aproximação da distribuição t pela normal padrão.

i Derivação — Média e variância da distribuição t

Como a distribuição t é simétrica em torno de zero, quando o primeiro momento existe,

$$E(T) = 0.$$

A existência desse momento exige

$$\nu > 1.$$

Para obter a variância, partimos da definição

$$T = \frac{Z}{\sqrt{W/\nu}},$$

com

$$Z \sim N(0, 1), \quad W \sim \chi^2_\nu,$$

independentes.

Elevando ao quadrado,

$$T^2 = \frac{Z^2}{W/\nu} = Z^2 \frac{\nu}{W}.$$

Pela independência entre Z e W ,

$$\begin{aligned} E(T^2) &= E\left(Z^2 \frac{\nu}{W}\right) \\ &= \nu E(Z^2) E\left(\frac{1}{W}\right). \end{aligned}$$

Como

$$E(Z^2) = 1$$

e, para

$$W \sim \chi_{\nu}^2,$$

vimos anteriormente que

$$E\left(\frac{1}{W}\right) = \frac{1}{\nu - 2}, \quad \nu > 2,$$

segue que

$$E(T^2) = \frac{\nu}{\nu - 2}.$$

Como

$$E(T) = 0,$$

temos

$$\begin{aligned} \text{Var}(T) &= E(T^2) - [E(T)]^2 \\ &= \frac{\nu}{\nu - 2}. \end{aligned}$$

Portanto,

$$\text{Var}(T) = \frac{\nu}{\nu - 2}, \quad \nu > 2.$$

! Resultado — Convergência da distribuição t para a normal padrão

Se

$$T_{\nu} \sim t_{\nu},$$

então, quando

$$\nu \rightarrow \infty,$$

temos

$$T_{\nu} \xrightarrow{d} N(0, 1).$$

i Demonstração — Convergência da distribuição t para a normal padrão

Para cada ν , escreva

$$T_{\nu} = \frac{Z_{\nu}}{\sqrt{W_{\nu}/\nu}},$$

em que

$$Z_\nu \sim N(0, 1), \quad W_\nu \sim \chi_\nu^2,$$

e Z_ν e W_ν são independentes.

Como

$$E(W_\nu) = \nu$$

e

$$\text{Var}(W_\nu) = 2\nu,$$

temos

$$E\left(\frac{W_\nu}{\nu}\right) = 1$$

e

$$\text{Var}\left(\frac{W_\nu}{\nu}\right) = \frac{2}{\nu}.$$

Pela desigualdade de Chebyshev, para todo $\varepsilon > 0$,

$$P\left(\left|\frac{W_\nu}{\nu} - 1\right| > \varepsilon\right) \leq \frac{2}{\nu\varepsilon^2}.$$

Quando

$$\nu \rightarrow \infty,$$

o lado direito converge para zero. Portanto,

$$\frac{W_\nu}{\nu} \xrightarrow{P} 1.$$

Pelo teorema do mapeamento contínuo, apresentado em Seção 2.3.6,

$$\sqrt{\frac{W_\nu}{\nu}} \xrightarrow{P} 1.$$

Por outro lado, como

$$Z_\nu \sim N(0, 1)$$

para todo ν , temos

$$Z_\nu \xrightarrow{d} Z, \quad Z \sim N(0, 1).$$

Aplicando o lema de Slutsky, apresentado em Seção 2.3.7,

$$\frac{Z_\nu}{\sqrt{W_\nu/\nu}} \xrightarrow{d} Z.$$

Logo,

$$T_\nu \xrightarrow{d} N(0, 1).$$

Esse resultado formaliza a interpretação apresentada anteriormente: à medida que os graus de liberdade aumentam,

$$\frac{W_\nu}{\nu}$$

fica cada vez mais concentrado em torno de 1, reduzindo a variabilidade adicional introduzida pelo denominador da estatística t .

Exemplo — Região central da distribuição t

Considere uma amostra aleatória de tamanho

$$n = 10$$

proveniente de uma população normal.

Nesse caso,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{10}} \sim t_9.$$

Determine uma região simétrica em torno de zero que contenha 95% da distribuição de T .

Compare o valor crítico obtido com o correspondente valor da distribuição normal padrão.

Resolução — Região central de uma distribuição t_9

A distribuição t_9 é simétrica em torno de zero.

Uma região central contendo

$$0,95$$

da probabilidade deixa

$$1 - 0,95 = 0,05$$

fora da região.

Pela simetria, essa probabilidade é dividida igualmente entre as duas caudas:

$$\frac{0,05}{2} = 0,025.$$

Portanto, o limite superior deve deixar probabilidade

$$0,025$$

à sua direita ou, equivalentemente,

$$0,975$$

à sua esquerda.

Denotamos esse quantil por

$$t_{0,975;9},$$

definido por

$$P(T \leq t_{0,975;9}) = 0,975.$$

Como

$$t_{0,975;9} \approx 2,262,$$

temos

$$P(-2,262 \leq T \leq 2,262) \approx 0,95.$$

Portanto, a região central de 95% é aproximadamente

$$(-2,262; 2,262).$$

Para comparação, na distribuição normal padrão,

$$P(-1,96 \leq Z \leq 1,96) \approx 0,95.$$

Observe que

$$2,262 > 1,96.$$

A região central da distribuição t_9 precisa, portanto, ser mais ampla que a correspondente região da normal padrão para conter os mesmos 95% de probabilidade.

Isso ocorre porque a distribuição t_9 possui caudas mais pesadas. Uma parcela maior de sua probabilidade encontra-se mais afastada de zero, exigindo valores críticos de maior magnitude.

À medida que os graus de liberdade aumentam, esses valores críticos se aproximam dos valores correspondentes da normal padrão, em concordância com

$$t_\nu \xrightarrow{d} N(0, 1).$$

(Larsen; Marx, 2012, seq. 7.2–7.3; Rice, 2007, cap. 6)

4.11.5 Distribuição F

Enquanto a distribuição t de Student surge da combinação entre uma variável normal padrão e uma variável qui-quadrado independente, a distribuição F surge da razão entre duas variáveis qui-quadrado independentes.

Mais especificamente, cada variável qui-quadrado é inicialmente dividida por seu respectivo número de graus de liberdade. Essa divisão é natural porque, se

$$W \sim \chi_\nu^2,$$

então

$$E\left(\frac{W}{\nu}\right) = 1.$$

Assim, a distribuição F compara duas quantidades qui-quadrado colocadas em uma mesma escala. Essa estrutura aparecerá diretamente na comparação entre duas variâncias amostrais de populações normais.

! Definição — Distribuição F

Se

$$W_1 \sim \chi_{\nu_1}^2 \quad \text{e} \quad W_2 \sim \chi_{\nu_2}^2$$

são independentes, então

$$F = \frac{W_1/\nu_1}{W_2/\nu_2}$$

possui distribuição F com ν_1 e ν_2 graus de liberdade, o que escrevemos como

$$F \sim F_{\nu_1, \nu_2}.$$

O parâmetro

$$\nu_1$$

corresponde aos graus de liberdade associados ao **numerador**, enquanto

$$\nu_2$$

corresponde aos graus de liberdade associados ao **denominador**.

Essa razão de qui-quadrados independentes define a distribuição F (Casella; Berger, 2011, definição 5.3.6; Larsen; Marx, 2012, seq. 9.3; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2).

! Resultado — Razão entre variâncias amostrais no modelo normal

Considere duas amostras normais independentes,

$$X_1, \dots, X_{n_1} \stackrel{\text{iid}}{\sim} N(\mu_1, \sigma_1^2)$$

e

$$Y_1, \dots, Y_{n_2} \stackrel{\text{iid}}{\sim} N(\mu_2, \sigma_2^2).$$

Se S_1^2 e S_2^2 são as respectivas variâncias amostrais, então

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}.$$

Em particular, se

$$\sigma_1^2 = \sigma_2^2,$$

então

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}.$$

i Derivação — Distribuição F da razão de variâncias

Pelo resultado de Seção 4.11.3, para a primeira amostra,

$$\frac{(n_1 - 1)S_1^2}{\sigma_1^2} \sim \chi_{n_1-1}^2.$$

Defina

$$W_1 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2}.$$

Então,

$$W_1 \sim \chi_{n_1-1}^2.$$

Da mesma forma, para a segunda amostra,

$$W_2 = \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \sim \chi_{n_2-1}^2.$$

Como as duas amostras são independentes, W_1 e W_2 também são independentes. Pela definição da distribuição F ,

$$\frac{W_1/(n_1 - 1)}{W_2/(n_2 - 1)} \sim F_{n_1-1, n_2-1}.$$

Agora,

$$\frac{W_1}{n_1 - 1} = \frac{S_1^2}{\sigma_1^2}$$

e

$$\frac{W_2}{n_2 - 1} = \frac{S_2^2}{\sigma_2^2}.$$

Portanto,

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}.$$

Se as variâncias populacionais são iguais,

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

então

$$\frac{S_1^2/\sigma^2}{S_2^2/\sigma^2} = \frac{S_1^2}{S_2^2}.$$

Logo,

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}.$$

Essa é a conexão entre a construção abstrata da distribuição F e a comparação de duas variâncias amostrais.

⚠ Observação — A ordem do numerador e do denominador importa

A distribuição

$$F_{\nu_1, \nu_2}$$

não é, em geral, a mesma que

$$F_{\nu_2, \nu_1}.$$

Os primeiros graus de liberdade estão associados ao numerador e os segundos ao denominador.

Assim, se

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1},$$

então a razão inversa possui distribuição

$$\frac{S_2^2}{S_1^2} \sim F_{n_2-1, n_1-1}.$$

Portanto, trocar numerador e denominador também troca a ordem dos graus de liberdade.

4.11.5.1 Densidade e forma da distribuição F

Se

$$F \sim F_{\nu_1, \nu_2},$$

sua função densidade é

$$f_F(x) = \frac{\Gamma\left(\frac{\nu_1 + \nu_2}{2}\right)}{\Gamma\left(\frac{\nu_1}{2}\right)\Gamma\left(\frac{\nu_2}{2}\right)} \left(\frac{\nu_1}{\nu_2}\right)^{\nu_1/2} x^{\nu_1/2-1} \left(1 + \frac{\nu_1}{\nu_2}x\right)^{-(\nu_1+\nu_2)/2}, \quad x > 0.$$

Além disso,

$$f_F(x) = 0, \quad x \leq 0.$$

O suporte positivo decorre diretamente de sua construção: tanto W_1 quanto W_2 são somas de quadrados e, portanto, não assumem valores negativos.

Diferentemente das distribuições normal e t , a distribuição F não é simétrica em torno de zero. Ela assume apenas valores positivos e, em geral, apresenta assimetria à direita.

Sua forma depende dos dois números de graus de liberdade,

$$\nu_1 \quad \text{e} \quad \nu_2.$$

Para valores pequenos dos graus de liberdade, a assimetria pode ser acentuada. À medida que ambos aumentam, a distribuição se concentra progressivamente em torno de 1.

i Derivação — Densidade da distribuição F

A densidade da distribuição F pode ser obtida a partir das duas variáveis qui-quadrado independentes que aparecem em sua definição.

Considere

$$W_1 \sim \chi_{\nu_1}^2, \quad W_2 \sim \chi_{\nu_2}^2,$$

independentes.

Defina

$$R = \frac{W_1/\nu_1}{W_2/\nu_2} = \frac{\nu_2 W_1}{\nu_1 W_2}$$

e mantenha W_2 como segunda variável:

$$Q = W_2.$$

Utilizamos, assim, a transformação

$$(R, Q) = \left(\frac{\nu_2 W_1}{\nu_1 W_2}, W_2 \right).$$

A transformação inversa é

$$W_1 = \frac{\nu_1}{\nu_2} RQ$$

e

$$W_2 = Q.$$

Em termos dos valores possíveis,

$$w_1 = \frac{\nu_1}{\nu_2} r q, \quad w_2 = q.$$

A matriz jacobiana da transformação inversa é

$$\frac{\partial(w_1, w_2)}{\partial(r, q)} = \begin{pmatrix} \frac{\nu_1}{\nu_2} q & \frac{\nu_1}{\nu_2} r \\ 0 & 1 \end{pmatrix}.$$

Portanto,

$$\left| \frac{\partial(w_1, w_2)}{\partial(r, q)} \right| = \frac{\nu_1}{\nu_2} q.$$

Como W_1 e W_2 são independentes,

$$f_{W_1, W_2}(w_1, w_2) = f_{W_1}(w_1) f_{W_2}(w_2).$$

Pela mudança de variáveis,

$$f_{R, Q}(r, q) = f_{W_1} \left(\frac{\nu_1}{\nu_2} r q \right) f_{W_2}(q) \frac{\nu_1}{\nu_2} q,$$

para

$$r > 0, \quad q > 0.$$

As densidades qui-quadrado são

$$f_{W_1}(w) = \frac{1}{2^{\nu_1/2} \Gamma(\nu_1/2)} w^{\nu_1/2-1} e^{-w/2}$$

e

$$f_{W_2}(w) = \frac{1}{2^{\nu_2/2} \Gamma(\nu_2/2)} w^{\nu_2/2-1} e^{-w/2}.$$

Substituindo essas densidades,

$$\begin{aligned} f_{R, Q}(r, q) &= \frac{\left(\frac{\nu_1}{\nu_2} \right)^{\nu_1/2}}{2^{(\nu_1+\nu_2)/2} \Gamma(\nu_1/2) \Gamma(\nu_2/2)} r^{\nu_1/2-1} q^{(\nu_1+\nu_2)/2-1} \\ &\times \exp \left[-\frac{q}{2} \left(1 + \frac{\nu_1}{\nu_2} r \right) \right]. \end{aligned}$$

Para obter a densidade marginal de R , integramos em relação a q :

$$f_R(r) = \int_0^\infty f_{R, Q}(r, q) dq.$$

A integral que aparece é do tipo gama,

$$\int_0^\infty q^{a-1} e^{-bq} dq = \frac{\Gamma(a)}{b^a}, \quad a > 0, \quad b > 0,$$

com

$$a = \frac{\nu_1 + \nu_2}{2}$$

e

$$b = \frac{1}{2} \left(1 + \frac{\nu_1}{\nu_2} r \right).$$

Substituindo o resultado da integral e simplificando,

$$f_R(r) = \frac{\Gamma\left(\frac{\nu_1 + \nu_2}{2}\right)}{\Gamma\left(\frac{\nu_1}{2}\right)\Gamma\left(\frac{\nu_2}{2}\right)} \left(\frac{\nu_1}{\nu_2}\right)^{\nu_1/2} r^{\nu_1/2-1} \left(1 + \frac{\nu_1}{\nu_2} r\right)^{-(\nu_1 + \nu_2)/2},$$

para

$$r > 0.$$

Essa é exatamente a densidade da distribuição

$$F_{\nu_1, \nu_2}.$$

Portanto,

$$R \sim F_{\nu_1, \nu_2}.$$

i Probabilidades e quantis da distribuição F

Como o suporte da distribuição F é

$$(0, \infty),$$

para $c > 0$,

$$P(F \leq c) = \int_0^c f_F(x) dx,$$

e

$$P(F > c) = 1 - P(F \leq c).$$

Em geral, essas probabilidades são obtidas por tabelas da distribuição F ou por métodos numéricos.

Denotaremos por

$$F_{q; \nu_1, \nu_2}$$

o quantil de ordem q da distribuição F_{ν_1, ν_2} , isto é, o valor que satisfaz

$$P(F \leq F_{q; \nu_1, \nu_2}) = q.$$

Como a distribuição F não é simétrica, os quantis inferiores e superiores não são obtidos simplesmente mudando o sinal, como ocorre nas distribuições normal e t .

A relação entre F e seu inverso, apresentada adiante, permite relacionar quantis das duas caudas.

4.11.5.2 Média e variância

Se

$$F \sim F_{\nu_1, \nu_2},$$

então sua média existe quando

$$\nu_2 > 2$$

e é dada por

$$E(F) = \frac{\nu_2}{\nu_2 - 2}.$$

Sua variância existe quando

$$\nu_2 > 4$$

e é

$$\text{Var}(F) = \frac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}.$$

Observe que

$$E(F) > 1$$

sempre que a média existe. Entretanto,

$$E(F) \rightarrow 1$$

quando ν_2 aumenta.

Quando ν_1 e ν_2 aumentam simultaneamente, a distribuição também se torna mais concentrada em torno de 1.

i Derivação — Média e variância da distribuição F

Pela definição,

$$F = \frac{W_1/\nu_1}{W_2/\nu_2} = \frac{W_1}{\nu_1} \frac{\nu_2}{W_2},$$

em que

$$W_1 \sim \chi_{\nu_1}^2, \quad W_2 \sim \chi_{\nu_2}^2,$$

são independentes.

Para obter a média, utilizamos a independência:

$$E(F) = E\left(\frac{W_1}{\nu_1}\right) E\left(\frac{\nu_2}{W_2}\right).$$

Como

$$E(W_1) = \nu_1,$$

temos

$$E\left(\frac{W_1}{\nu_1}\right) = 1.$$

Além disso, para $\nu_2 > 2$,

$$E\left(\frac{1}{W_2}\right) = \frac{1}{\nu_2 - 2}.$$

Portanto,

$$\begin{aligned} E(F) &= 1 \cdot \nu_2 E\left(\frac{1}{W_2}\right) \\ &= \frac{\nu_2}{\nu_2 - 2}. \end{aligned}$$

Logo,

$$E(F) = \frac{\nu_2}{\nu_2 - 2}, \quad \nu_2 > 2.$$

Para obter a variância, calculamos primeiro $E(F^2)$.
Como W_1 e W_2 são independentes,

$$E(F^2) = E \left[\left(\frac{W_1}{\nu_1} \right)^2 \right] E \left[\left(\frac{\nu_2}{W_2} \right)^2 \right].$$

Para uma variável

$$W_1 \sim \chi_{\nu_1}^2,$$

sabemos que

$$E(W_1) = \nu_1$$

e

$$\text{Var}(W_1) = 2\nu_1.$$

Logo,

$$\begin{aligned} E(W_1^2) &= \text{Var}(W_1) + [E(W_1)]^2 \\ &= 2\nu_1 + \nu_1^2 \\ &= \nu_1(\nu_1 + 2). \end{aligned}$$

Assim,

$$E \left[\left(\frac{W_1}{\nu_1} \right)^2 \right] = \frac{\nu_1 + 2}{\nu_1}.$$

Para $\nu_2 > 4$,

$$E(W_2^{-2}) = \frac{1}{(\nu_2 - 2)(\nu_2 - 4)}.$$

Portanto,

$$E \left[\left(\frac{\nu_2}{W_2} \right)^2 \right] = \frac{\nu_2^2}{(\nu_2 - 2)(\nu_2 - 4)}.$$

Consequentemente,

$$E(F^2) = \frac{\nu_1 + 2}{\nu_1} \frac{\nu_2^2}{(\nu_2 - 2)(\nu_2 - 4)}.$$

Finalmente,

$$\text{Var}(F) = E(F^2) - [E(F)]^2.$$

Substituindo os dois momentos,

$$\text{Var}(F) = \frac{\nu_1 + 2}{\nu_1} \frac{\nu_2^2}{(\nu_2 - 2)(\nu_2 - 4)} - \left(\frac{\nu_2}{\nu_2 - 2} \right)^2.$$

Colocando os termos sob o mesmo denominador e simplificando,

$$\text{Var}(F) = \frac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}, \quad \nu_2 > 4.$$

⚠ Observação — Sensibilidade à não normalidade

A distribuição

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}$$

é um resultado exato quando as duas amostras provêm de distribuições normais independentes.

A razão entre variâncias amostrais pode ser sensível a desvios importantes da normalidade, especialmente na presença de assimetria acentuada, caudas pesadas ou valores extremos. Por isso, procedimentos inferenciais baseados diretamente nessa razão exigem atenção às condições do modelo.

i Relações entre as distribuições t e F

As distribuições t e F estão diretamente relacionadas.

Se

$$T \sim t_\nu,$$

então

$$T^2 \sim F_{1, \nu}.$$

Além disso, se

$$F \sim F_{\nu_1, \nu_2},$$

então

$$\frac{1}{F} \sim F_{\nu_2, \nu_1}.$$

A segunda relação mostra novamente que inverter uma razão F troca os graus de liberdade associados ao numerador e ao denominador.

i Derivação — Relações entre as distribuições t e F

Considere primeiro

$$T \sim t_\nu.$$

Pela definição,

$$T = \frac{Z}{\sqrt{W/\nu}},$$

em que

$$Z \sim N(0, 1), \quad W \sim \chi_\nu^2,$$

e Z e W são independentes.

Elevando ao quadrado,

$$T^2 = \frac{Z^2}{W/\nu}.$$

Como

$$Z^2 \sim \chi_1^2,$$

podemos escrever

$$T^2 = \frac{Z^2/1}{W/\nu}.$$

Além disso, Z^2 permanece independente de W . Portanto, pela definição da distribuição F ,

$$T^2 \sim F_{1,\nu}.$$

Agora, considere

$$F = \frac{W_1/\nu_1}{W_2/\nu_2} \sim F_{\nu_1,\nu_2}.$$

Tomando o inverso,

$$\frac{1}{F} = \frac{W_2/\nu_2}{W_1/\nu_1}.$$

O numerador passa a envolver uma variável qui-quadrado com ν_2 graus de liberdade, enquanto o denominador passa a envolver uma variável qui-quadrado com ν_1 graus de liberdade.

Logo,

$$\frac{1}{F} \sim F_{\nu_2, \nu_1}.$$

4.12 Estatísticas de ordem

Até aqui, as principais estatísticas amostrais foram construídas por somas, médias, proporções ou somas de quadrados. Existe, entretanto, outra maneira importante de extrair informação de uma amostra: utilizar a **posição ocupada pelas observações depois que seus valores são colocados em ordem crescente**.

Por exemplo, considere uma amostra com cinco valores:

$$7,2, \quad 4,8, \quad 6,1, \quad 5,4, \quad 8,0.$$

Depois da ordenação,

$$4,8 < 5,4 < 6,1 < 7,2 < 8,0.$$

O primeiro valor ordenado é o mínimo da amostra, o último é o máximo e o terceiro ocupa a posição central. Assim, a posição de uma observação na amostra ordenada também pode definir uma estatística.

Estatísticas desse tipo permitem estudar mínimos, máximos, medianas e quantis amostrais. Suas distribuições são particularmente importantes quando a posição dos valores observados, especialmente dos extremos, contém informação direta sobre parâmetros do modelo, como ocorre em alguns modelos uniformes.

Seja

$$X_1, \dots, X_n$$

uma amostra i.i.d. de uma distribuição contínua com função de distribuição F e densidade f .

Depois de ordenar os valores da amostra, escrevemos

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}.$$

Os parênteses no índice indicam **posição na amostra ordenada**, e não o número da observação originalmente coletada.

Assim, $X_{(1)}$ não significa necessariamente X_1 . Ele representa o menor valor entre todas as observações.

De forma geral, a variável

$$X_{(k)}$$

é denominada **k -ésima estatística de ordem**.

Em particular,

$$X_{(1)} = \min(X_1, \dots, X_n)$$

e

$$X_{(n)} = \max(X_1, \dots, X_n).$$

A ideia central para obter a distribuição dessas estatísticas é relacionar a posição ordenada com eventos envolvendo as observações originais.

Para o mínimo e o máximo, essa relação é especialmente simples. Para uma posição intermediária $X_{(k)}$, será necessário contar quantas observações da amostra ficam abaixo de determinado valor x (Larsen; Marx, 2012, seq. 3.10, pp. 193–200; Ramachandran; Tsokos, 2021, seq. 4.3).

4.12.1 Mínimo e máximo

Começemos pelas duas posições extremas da amostra ordenada.

Para compreender a distribuição do mínimo, é útil pensar no evento

$$X_{(1)} > x.$$

Se o menor valor da amostra é maior que x , então **todas** as observações devem ser maiores que x .

Para o máximo, a relação é semelhante:

$$X_{(n)} \leq x$$

ocorre somente quando **todas** as observações são menores ou iguais a x .

Essas duas equivalências permitem obter diretamente as distribuições do mínimo e do máximo.

! Resultado — Distribuições do mínimo e do máximo

Se $X_1, \dots, X_n$ são i.i.d. de uma distribuição contínua com função de distribuição F e densidade f , então, para o mínimo,

$$F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n$$

e

$$f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1}f(x).$$

Para o máximo,

$$F_{X_{(n)}}(x) = [F(x)]^n$$

e

$$f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x).$$

i Demonstração — Distribuições do mínimo e do máximo

Distribuição do mínimo

Queremos obter

$$F_{X_{(1)}}(x) = P(X_{(1)} \leq x).$$

Trabalhar diretamente com esse evento exigiria considerar várias possibilidades: a primeira observação pode ser menor que x , ou a segunda, ou várias delas simultaneamente. É mais simples utilizar o evento complementar.

O evento

$$X_{(1)} > x$$

significa que até mesmo a menor observação da amostra é maior que x . Isso ocorre se, e somente se,

$$X_1 > x, \dots, X_n > x.$$

Portanto,

$$P(X_{(1)} > x) = P(X_1 > x, \dots, X_n > x).$$

Como as observações são independentes,

$$\begin{aligned} P(X_{(1)} > x) &= \prod_{i=1}^n P(X_i > x) \\ &= [1 - F(x)]^n. \end{aligned}$$

Agora utilizamos

$$P(X_{(1)} \leq x) = 1 - P(X_{(1)} > x).$$

Logo,

$$\begin{aligned} F_{X_{(1)}}(x) &= P(X_{(1)} \leq x) \\ &= 1 - [1 - F(x)]^n. \end{aligned}$$

Como a distribuição original é contínua, podemos derivar a função de distribuição em relação a x :

$$\begin{aligned} f_{X_{(1)}}(x) &= \frac{d}{dx} \{1 - [1 - F(x)]^n\} \\ &= n[1 - F(x)]^{n-1} f(x). \end{aligned}$$

Portanto,

$$f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1} f(x).$$

Distribuição do máximo

Para o máximo, podemos trabalhar diretamente com sua função de distribuição:

$$F_{X_{(n)}}(x) = P(X_{(n)} \leq x).$$

O evento

$$X_{(n)} \leq x$$

significa que até mesmo o maior valor da amostra não ultrapassa x . Portanto, todas as observações devem satisfazer

$$X_i \leq x.$$

Assim,

$$\begin{aligned} F_{X_{(n)}}(x) &= P(X_1 \leq x, \dots, X_n \leq x) \\ &= \prod_{i=1}^n P(X_i \leq x) \\ &= [F(x)]^n. \end{aligned}$$

Derivando,

$$\begin{aligned} f_{X_{(n)}}(x) &= \frac{d}{dx}[F(x)]^n \\ &= n[F(x)]^{n-1}f(x). \end{aligned}$$

Portanto,

$$f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x).$$

As duas demonstrações utilizam a mesma ideia: transformar um evento envolvendo uma posição extrema da amostra em um evento envolvendo simultaneamente todas as observações.

i Parâmetro no suporte

As fórmulas para o mínimo e o máximo também se aplicam quando o suporte da distribuição depende de um parâmetro.

Nessa situação, considera-se o parâmetro θ fixado e utiliza-se a função de distribuição

$$F(x \mid \theta)$$

correspondente ao modelo.

O ponto adicional é que o conjunto de valores possíveis da própria estatística de ordem também pode depender de θ .

Por exemplo, suponha

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0.$$

Nesse caso,

$$F(x \mid \theta) = \frac{x}{\theta}, \quad 0 < x < \theta.$$

Para o máximo,

$$F_{X_{(n)}}(x \mid \theta) = \left(\frac{x}{\theta}\right)^n, \quad 0 < x < \theta.$$

Observe que o suporte de $X_{(n)}$ continua dependendo de θ :

$$0 < X_{(n)} < \theta.$$

Isso explica por que estatísticas extremas podem ser particularmente informativas em modelos cujo parâmetro determina os limites do suporte.

4.12.2 k -ésima estatística de ordem

O mínimo e o máximo correspondem aos casos extremos

$$X_{(1)} \quad \text{e} \quad X_{(n)}.$$

Agora queremos estudar uma posição arbitrária

$$X_{(k)}, \quad k = 1, \dots, n.$$

A pergunta central é: o que precisa acontecer na amostra para que a k -ésima observação ordenada esteja próxima de um determinado valor x ?

Para que

$$X_{(k)}$$

esteja próximo de x , precisamos essencialmente de:

- $k - 1$ observações abaixo de x ;
- uma observação na vizinhança de x ;
- $n - k$ observações acima de x .

É exatamente essa estrutura que aparecerá na densidade da k -ésima estatística de ordem.

! Teorema — Densidade de $X_{(k)}$

Para

$$k = 1, \dots, n,$$

a densidade da k -ésima estatística de ordem é

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x).$$

(Casella; Berger, 2011, teorema 5.4.4; Larsen; Marx, 2012, teorema 3.10.2; Ramachandran; Tsokos, 2021, seq. 4.3)

i Interpretação — Como ler a densidade de $X_{(k)}$

Cada parte da expressão

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$$

possui uma interpretação.

O termo

$$[F(x)]^{k-1}$$

está associado às $k-1$ observações que ficam abaixo de x .

O termo

$$[1-F(x)]^{n-k}$$

está associado às $n-k$ observações que ficam acima de x .

O fator

$$f(x)$$

representa a contribuição da observação que ocupa a k -ésima posição e se encontra na vizinhança de x .

Por fim,

$$\frac{n!}{(k-1)!(n-k)!}$$

conta as diferentes maneiras de escolher, entre as n observações:

- qual delas ocupa a vizinhança de x ;
- quais $k-1$ ficam abaixo;
- quais $n-k$ ficam acima.

Assim, a fórmula combina **posição, probabilidade e contagem**.

i Demonstração — Distribuição da k -ésima estatística de ordem

Há duas etapas naturais:

1. obter primeiro a função de distribuição de $X_{(k)}$ por meio de uma contagem binomial;
2. derivar essa função para obter a densidade.

Etapla 1 — Contabilizar quantas observações estão abaixo de x

Fixe um valor x .

Para cada observação, defina o indicador

$$I_i(x) = \mathbf{1}_{\{X_i \leq x\}}.$$

Esse indicador vale 1 quando a observação X_i não ultrapassa x e vale 0 caso contrário. Como

$$P(X_i \leq x) = F(x),$$

temos

$$I_i(x) \sim \text{Ber}(F(x)).$$

Agora defina

$$N_x = \sum_{i=1}^n I_i(x) = \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

A variável N_x conta quantas observações da amostra são menores ou iguais a x . Como as observações são independentes,

$$N_x \sim \text{Bin}(n, F(x)).$$

Etapa 2 — Relacionando a contagem com $X_{(k)}$

Considere agora o evento

$$X_{(k)} \leq x.$$

Para que a k -ésima observação ordenada seja menor ou igual a x , é necessário que existam **pelo menos k observações** da amostra menores ou iguais a x . Portanto,

$$X_{(k)} \leq x \iff N_x \geq k.$$

Essa equivalência é o ponto central da demonstração.

Logo,

$$\begin{aligned} F_{X_{(k)}}(x) &= P(X_{(k)} \leq x) \\ &= P(N_x \geq k). \end{aligned}$$

Como

$$N_x \sim \text{Bin}(n, F(x)),$$

segue que

$$F_{X_{(k)}}(x) = \sum_{j=k}^n \binom{n}{j} [F(x)]^j [1 - F(x)]^{n-j}.$$

Essa expressão já fornece a função de distribuição da k -ésima estatística de ordem.

Etapa 3 — Obtendo a densidade

Para simplificar a derivação, escreva

$$u = F(x)$$

e defina

$$G(u) = \sum_{j=k}^n \binom{n}{j} u^j (1-u)^{n-j}.$$

Então,

$$F_{X_{(k)}}(x) = G(F(x)).$$

Derivando $G(u)$ em relação a u ,

$$\begin{aligned} G'(u) &= \sum_{j=k}^n \binom{n}{j} j u^{j-1} (1-u)^{n-j} \\ &\quad - \sum_{j=k}^n \binom{n}{j} (n-j) u^j (1-u)^{n-j-1}. \end{aligned}$$

Utilizamos agora as identidades combinatórias

$$j \binom{n}{j} = n \binom{n-1}{j-1}$$

e

$$(n-j) \binom{n}{j} = n \binom{n-1}{j}.$$

Na primeira soma,

$$\sum_{j=k}^n \binom{n}{j} j u^{j-1} (1-u)^{n-j} = n \sum_{j=k}^n \binom{n-1}{j-1} u^{j-1} (1-u)^{n-j}.$$

Fazendo

$$r = j - 1,$$

temos

$$n \sum_{r=k-1}^{n-1} \binom{n-1}{r} u^r (1-u)^{n-1-r}.$$

A segunda soma pode ser escrita como

$$n \sum_{j=k}^{n-1} \binom{n-1}{j} u^j (1-u)^{n-1-j},$$

pois o termo correspondente a $j = n$ é nulo.

Comparando as duas somas, os termos correspondentes aos índices

$$k, \dots, n-1$$

aparecem uma vez com sinal positivo e uma vez com sinal negativo. Portanto, cancelam-se.

Resta apenas o termo correspondente a

$$r = k - 1.$$

Assim,

$$G'(u) = n \binom{n-1}{k-1} u^{k-1} (1-u)^{n-k}.$$

Como

$$n \binom{n-1}{k-1} = \frac{n!}{(k-1)!(n-k)!},$$

obtemos

$$G'(u) = \frac{n!}{(k-1)!(n-k)!} u^{k-1} (1-u)^{n-k}.$$

Finalmente,

$$u = F(x)$$

e

$$\frac{du}{dx} = f(x).$$

Pela regra da cadeia,

$$\begin{aligned} f_{X_{(k)}}(x) &= \frac{d}{dx} F_{X_{(k)}}(x) \\ &= G'(F(x)) f(x) \\ &= \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x). \end{aligned}$$

Portanto,

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x).$$

A demonstração revela a ideia probabilística central: estudar a posição de $X_{(k)}$ equivale a estudar **quantas observações da amostra não ultrapassam determinado valor x** .

i Verificação — Mínimo e máximo como casos particulares

A fórmula geral deve reproduzir os resultados obtidos anteriormente.

Para

$$k = 1,$$

temos

$$\begin{aligned} f_{X_{(1)}}(x) &= \frac{n!}{0!(n-1)!} [F(x)]^0 [1-F(x)]^{n-1} f(x) \\ &= n[1-F(x)]^{n-1} f(x), \end{aligned}$$

que é exatamente a densidade do mínimo.

Para

$$k = n,$$

temos

$$\begin{aligned} f_{X_{(n)}}(x) &= \frac{n!}{(n-1)!0!} [F(x)]^{n-1} [1-F(x)]^0 f(x) \\ &= n[F(x)]^{n-1} f(x), \end{aligned}$$

que é a densidade do máximo.

Portanto, mínimo e máximo são realmente casos particulares da expressão geral.

4.12.3 Transformação pela função de distribuição

A fórmula da k -ésima estatística de ordem revela uma propriedade especialmente útil quando aplicamos a função de distribuição F às observações.

! Corolário — Transformação pela função de distribuição

Se F é contínua, então

$$F(X_{(k)}) \sim \text{Beta}(k, n - k + 1).$$

Antes de demonstrar o resultado, recordemos a distribuição Beta.

Se

$$U \sim \text{Beta}(\alpha, \beta), \quad \alpha > 0, \quad \beta > 0,$$

sua densidade é

$$f_U(u) = \frac{1}{B(\alpha, \beta)} u^{\alpha-1} (1-u)^{\beta-1}, \quad 0 < u < 1,$$

em que

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

Sua esperança é

$$E(U) = \frac{\alpha}{\alpha + \beta}.$$

i Demonstração — Distribuição de $F(X_{(k)})$

Pelo teorema da transformação integral de probabilidade, se F é contínua,

$$U_i = F(X_i) \sim \text{Unif}(0, 1).$$

Portanto,

$$U_1, \dots, U_n$$

formam uma amostra de uma distribuição uniforme no intervalo $(0, 1)$.

Como F é não decrescente, aplicar F às observações preserva sua ordenação. Assim,

$$U_{(k)} = F(X_{(k)}).$$

Agora utilizamos a fórmula geral da densidade da k -ésima estatística de ordem.

Para uma variável uniforme em $(0, 1)$,

$$F_U(u) = u$$

e

$$f_U(u) = 1, \quad 0 < u < 1.$$

Logo,

$$f_{U_{(k)}}(u) = \frac{n!}{(k-1)!(n-k)!} u^{k-1} (1-u)^{n-k}, \quad 0 < u < 1.$$

Compare essa expressão com a densidade Beta,

$$f(u) = \frac{1}{B(\alpha, \beta)} u^{\alpha-1} (1-u)^{\beta-1}.$$

Os expoentes fornecem

$$\alpha - 1 = k - 1$$

e

$$\beta - 1 = n - k.$$

Portanto,

$$\alpha = k$$

e

$$\beta = n - k + 1.$$

Assim,

$$U_{(k)} \sim \text{Beta}(k, n - k + 1).$$

Como

$$U_{(k)} = F(X_{(k)}),$$

concluimos que

$$F(X_{(k)}) \sim \text{Beta}(k, n - k + 1).$$

O resultado é geral: depois de transformarmos a k -ésima estatística de ordem pela função de distribuição do modelo original, obtemos uma distribuição Beta cujos parâmetros dependem apenas de k e de n .

 Exemplo — Estatísticas de ordem de uma amostra uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, 1).$$

Utilize a fórmula geral da k -ésima estatística de ordem para:

1. obter a densidade de $X_{(k)}$;
2. identificar sua distribuição;
3. calcular $E[X_{(k)}]$;
4. verificar o que o resultado fornece para o mínimo e para o máximo da amostra.

 Resolução — Estatísticas de ordem de uma amostra uniforme

Para

$$0 < x < 1,$$

a distribuição uniforme possui

$$F(x) = x$$

e

$$f(x) = 1.$$

A densidade geral da k -ésima estatística de ordem é

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x).$$

Substituindo

$$F(x) = x$$

e

$$f(x) = 1,$$

obtemos

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k}, \quad 0 < x < 1.$$

Queremos agora identificar essa densidade.

Uma variável

$$U \sim \text{Beta}(\alpha, \beta)$$

possui densidade

$$f_U(u) = \frac{1}{B(\alpha, \beta)} u^{\alpha-1} (1-u)^{\beta-1}.$$

Comparando os expoentes,

$$\alpha = k$$

e

$$\beta = n - k + 1.$$

Também podemos verificar que a constante de normalização coincide. De fato,

$$\begin{aligned} B(k, n - k + 1) &= \frac{\Gamma(k)\Gamma(n - k + 1)}{\Gamma(n + 1)} \\ &= \frac{(k-1)!(n-k)!}{n!}. \end{aligned}$$

Portanto,

$$\frac{1}{B(k, n - k + 1)} = \frac{n!}{(k-1)!(n-k)!}.$$

Logo,

$$X_{(k)} \sim \text{Beta}(k, n - k + 1).$$

A esperança de uma variável

$$U \sim \text{Beta}(\alpha, \beta)$$

é

$$E(U) = \frac{\alpha}{\alpha + \beta}.$$

Assim,

$$\begin{aligned} E[X_{(k)}] &= \frac{k}{k + (n - k + 1)} \\ &= \frac{k}{n + 1}. \end{aligned}$$

Portanto,

$$E[X_{(k)}] = \frac{k}{n+1}.$$

Esse resultado também possui uma interpretação natural. Em uma distribuição uniforme no intervalo $(0, 1)$, as posições esperadas das observações ordenadas ficam igualmente espaçadas:

$$\frac{1}{n+1}, \quad \frac{2}{n+1}, \quad \dots, \quad \frac{n}{n+1}.$$

Para o mínimo, $k = 1$:

$$X_{(1)} \sim \text{Beta}(1, n)$$

e

$$E[X_{(1)}] = \frac{1}{n+1}.$$

Para o máximo, $k = n$:

$$X_{(n)} \sim \text{Beta}(n, 1)$$

e

$$E[X_{(n)}] = \frac{n}{n+1}.$$

Esses resultados estão de acordo com a intuição: quando o tamanho da amostra aumenta, o mínimo tende a se aproximar de 0 e o máximo tende a se aproximar de 1.

Como caso adicional, se n é ímpar e

$$k = \frac{n+1}{2},$$

então $X_{(k)}$ é a mediana amostral e

$$E[X_{(k)}] = \frac{1}{2}.$$

O caso uniforme mostra, portanto, como a posição ocupada por uma observação na amostra se traduz diretamente nos parâmetros da distribuição Beta (Larsen; Marx, 2012, seq. 3.10).

💡 Exemplo — Estatísticas de ordem em uma amostra exponencial

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda), \quad \lambda > 0,$$

em que λ é a taxa.

Determine:

1. a distribuição do mínimo $X_{(1)}$;
2. a função de distribuição e a densidade do máximo $X_{(n)}$;
3. a densidade da k -ésima estatística de ordem $X_{(k)}$;
4. verifique que a expressão geral recupera os resultados do mínimo e do máximo quando $k = 1$ e $k = n$.

i Resolução — Estatísticas de ordem de uma amostra exponencial

Para uma variável exponencial com taxa λ ,

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0,$$

e sua função de sobrevivência é

$$1 - F(x) = e^{-\lambda x}.$$

A densidade é

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0.$$

Mínimo

Para estudar o mínimo, a função de sobrevivência é particularmente conveniente. Sabemos que

$$P(X_{(1)} > x) = [1 - F(x)]^n.$$

Isso ocorre porque

$$X_{(1)} > x$$

exige que todas as n observações sejam maiores que x .

Como, no modelo exponencial,

$$1 - F(x) = e^{-\lambda x},$$

temos

$$\begin{aligned} P(X_{(1)} > x) &= (e^{-\lambda x})^n \\ &= e^{-n\lambda x}. \end{aligned}$$

Essa é exatamente a função de sobrevivência de uma variável exponencial com taxa

$$n\lambda.$$

Portanto,

$$X_{(1)} \sim \text{Exp}(n\lambda).$$

Consequentemente,

$$E[X_{(1)}] = \frac{1}{n\lambda}.$$

Compare esse valor com a média de uma única observação:

$$E(X_i) = \frac{1}{\lambda}.$$

Temos

$$E[X_{(1)}] = \frac{1}{n}E(X_i).$$

Assim, quanto maior o número de observações, menor tende a ser o primeiro valor encontrado depois que a amostra é ordenada.

Máximo

Para o máximo, utilizamos diretamente

$$F_{X_{(n)}}(x) = [F(x)]^n.$$

Substituindo a função de distribuição exponencial,

$$F_{X_{(n)}}(x) = (1 - e^{-\lambda x})^n, \quad x \geq 0.$$

Derivando em relação a x ,

$$\begin{aligned} f_{X_{(n)}}(x) &= n(1 - e^{-\lambda x})^{n-1} \lambda e^{-\lambda x} \\ &= n\lambda e^{-\lambda x} (1 - e^{-\lambda x})^{n-1}, \quad x > 0. \end{aligned}$$

Portanto,

$$f_{X_{(n)}}(x) = n\lambda e^{-\lambda x} (1 - e^{-\lambda x})^{n-1}, \quad x > 0.$$

Observe uma diferença importante entre os dois extremos:

$$X_{(1)}$$

continua pertencendo à família exponencial, mas

$$X_{(n)}$$

não possui distribuição exponencial.

Assim, mínimo e máximo são construídos a partir da mesma amostra, mas possuem distribuições com formas diferentes.

k -ésima estatística de ordem

Para uma posição arbitrária k , utilizamos

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x).$$

No modelo exponencial,

$$F(x) = 1 - e^{-\lambda x},$$

$$1 - F(x) = e^{-\lambda x}$$

e

$$f(x) = \lambda e^{-\lambda x}.$$

Substituindo,

$$\begin{aligned} f_{X_{(k)}}(x) &= \frac{n!}{(k-1)!(n-k)!} (1 - e^{-\lambda x})^{k-1} (e^{-\lambda x})^{n-k} \lambda e^{-\lambda x} \\ &= \frac{n!}{(k-1)!(n-k)!} \lambda (1 - e^{-\lambda x})^{k-1} e^{-(n-k+1)\lambda x}, \end{aligned}$$

para

$$x > 0.$$

Portanto,

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} \lambda (1 - e^{-\lambda x})^{k-1} e^{-(n-k+1)\lambda x}, \quad x > 0.$$

Verificação para $k = 1$

Se

$$k = 1,$$

então

$$(1 - e^{-\lambda x})^{k-1} = 1$$

e

$$n - k + 1 = n.$$

Logo,

$$f_{X_{(1)}}(x) = n\lambda e^{-n\lambda x},$$

que é a densidade de uma variável

$$\text{Exp}(n\lambda).$$

Recuperamos, portanto,

$$X_{(1)} \sim \text{Exp}(n\lambda).$$

Verificação para $k = n$

Se

$$k = n,$$

então

$$n - k + 1 = 1.$$

Assim,

$$f_{X_{(n)}}(x) = n\lambda e^{-\lambda x} (1 - e^{-\lambda x})^{n-1},$$

que coincide com a densidade obtida anteriormente para o máximo.

O exemplo evidencia três aspectos importantes:

1. a fórmula geral da k -ésima estatística de ordem contém o mínimo e o máximo como casos particulares;
2. estatísticas construídas a partir da mesma amostra podem possuir distribuições amostrais bastante diferentes;
3. a forma da distribuição de $X_{(k)}$ depende tanto da posição k quanto da distribuição da população de origem.

4.13 Distribuições amostrais por simulação

Quando a distribuição exata de uma estatística é difícil de obter, pode-se aproximá-la por Monte Carlo: simula-se um grande número de amostras do modelo, calcula-se a estatística em cada amostra e analisa-se a distribuição empírica resultante (Chihara; Hesterberg, 2022, seq. 4.2, pp. 82–85; Kerns, 2010, seq. 8.5).

! Procedimento — Simulação de Monte Carlo

1. Especifique o modelo populacional e o tamanho amostral n .
2. Gere uma amostra de tamanho n .
3. Calcule a estatística T .
4. Repita os passos 2 e 3 um grande número B de vezes.
5. Use os valores $T^{(1)}, \dots, T^{(B)}$ para aproximar probabilidades, quantis, esperança, variância e forma da distribuição amostral.

Exemplo computacional: aproximação normal da média exponencial

O código abaixo compara as distribuições simuladas de médias de amostras exponenciais para diferentes tamanhos amostrais. Em cada painel, o histograma representa a distribuição amostral aproximada por Monte Carlo, enquanto a curva sobreposta corresponde à aproximação normal

$$N\left(1, \frac{1}{n}\right)$$

fornecida pelo Teorema Central do Limite em Seção 4.8.

```
set.seed(20262)

B <- 20000
ns <- c(2, 50, 100)

for (n in ns) {
  medias <- replicate(B, mean(rexp(n, rate = 1)))

  hist(
    medias,
    probability = TRUE,
    breaks = 40,
    main = "",
    xlab = expression(bar(X)),
    ylab = "Densidade"
  )

  box()
}
```

```

curva_x <- seq(min(medias), max(medias), length.out = 400)
lines(curva_x, dnorm(curva_x, mean = 1, sd = 1 / sqrt(n)), lwd = 2)
}

```




Figura 4.1: Distribuições simuladas da média de amostras exponenciais.

i Tamanho amostral e número de simulações

O tamanho amostral n e o número de repetições B desempenham papéis diferentes. O valor de n determina a distribuição amostral da estatística. Alterar n pode modificar sua variabilidade e sua forma.

O valor de B determina a precisão da aproximação de Monte Carlo. Para n fixado, aumentar B melhora a representação computacional da distribuição amostral, mas não altera a própria distribuição amostral.

i Distribuição exata e aproximação normal

Para observações exponenciais com taxa $\lambda = 1$, a média amostral possui distribuição exata

$$\bar{X} \sim \text{Gama}\left(n, \frac{1}{n}\right),$$

como obtido em Seção 4.5. Assim, os histogramas de Figura 4.1 aproximam por simulação essa distribuição amostral exata.

A curva sobreposta corresponde à aproximação

$$\bar{X} \sim N\left(1, \frac{1}{n}\right)$$

fornecida pelo Teorema Central do Limite. À medida que n aumenta, a distribuição da média torna-se mais próxima da normal e seu erro-padrão,

$$\text{EP}(\bar{X}) = \frac{1}{\sqrt{n}},$$

diminui à taxa $1/\sqrt{n}$.

i Parametrização da distribuição exponencial no exemplo

A função `rexp()` do R utiliza a parametrização por **taxa**. No código,

$$\lambda = 1.$$

Na parametrização pela média,

$$\mu = \frac{1}{\lambda}.$$

Portanto, neste exemplo,

$$\mu = 1.$$

A parametrização por taxa e a parametrização pela média coincidem numericamente apenas porque $\lambda = 1$.

Exemplo computacional: enumeração com e sem reposição

Retomamos computacionalmente a população estudada em Seção 4.4 para verificar as distribuições da média com e sem reposição.

```
populacao <- c(3.8, 3.9, 4.0, 4.1)

# Amostras ordenadas de tamanho 2, com reposição
amostras <- expand.grid(X1 = populacao, X2 = populacao)
amostras$media <- rowMeans(amostras)

prop.table(table(amostras$media))
```

```
      3.8    3.85    3.9    3.95      4    4.05    4.1
0.0625 0.1250 0.1875 0.2500 0.1875 0.1250 0.0625
```

```
mean(amostras$media)
```

```
[1] 3.95
```

```
var_pop <- mean((populacao - mean(populacao))^2)
mean((amostras$media - mean(amostras$media))^2)
```

```
[1] 0.00625
```

```
var_pop / 2
```

```
[1] 0.00625
```

Para verificar também o caso sem reposição, podemos enumerar os seis subconjuntos possíveis:

```
amostras_sem_reposicao <- combn(
  populacao,
  2,
  simplify = FALSE
)

medias_sem_reposicao <- sapply(
  amostras_sem_reposicao,
  mean
)

medias_sem_reposicao
```

```
[1] 3.85 3.90 3.95 3.95 4.00 4.05
```

```
prop.table(
  table(medias_sem_reposicao)
)
```

```
medias_sem_reposicao
      3.85      3.9      3.95      4      4.05
0.1666667 0.1666667 0.3333333 0.1666667 0.1666667
```

```
mean(medias_sem_reposicao)
```

```
[1] 3.95
```



```
mean(
  (medias_sem_reposicao -
    mean(medias_sem_reposicao))^2
)
```

```
[1] 0.004166667
```

A variância teórica é

```
N <- length(populacao)
n <- 2

var_pop / n * (N - n) / (N - 1)
```

```
[1] 0.004166667
```

A enumeração e a expressão teórica produzem a mesma variância, reproduzindo computacionalmente a correção de população finita obtida em Seção 4.3.2.

4.14 Quadro-síntese

Situação	Estatística	Distribuição ou resultado principal
Amostra i.i.d., $E(X) = \mu$, $\text{Var}(X) = \sigma^2 < \infty$	$\bar{X}$	$E(\bar{X}) = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$
População normal	$\bar{X}$	$\bar{X} \sim N(\mu, \sigma^2/n)$, exatamente
Amostra i.i.d., $E(X) = \mu$, $0 < \text{Var}(X) = \sigma^2 < \infty$	$\sqrt{n}(\bar{X}_n - \mu)/\sigma$	converge em distribuição para $N(0, 1)$
Duas amostras i.i.d. independentes entre si, com variâncias finitas e positivas	$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}}$	converge em distribuição para $N(0, 1)$ quando $\min(n, m) \rightarrow \infty$
Duas amostras normais independentes	$\bar{X} - \bar{Y}$	$N(\mu_1 - \mu_2, \sigma_1^2/n + \sigma_2^2/m)$, exatamente
Poisson i.i.d.	$\sum X_i$	Poisson($n\lambda$)
Ber(p) i.i.d.	$Y = \sum X_i$	$Y \sim \text{Bin}(n, p)$
Ber(p) i.i.d.	$\hat{p} = Y/n$	$E(\hat{p}) = p$, $\text{Var}(\hat{p}) = p(1 - p)/n$

Situação	Estatística	Distribuição ou resultado principal
Binomial, com n grande e distribuição suficientemente pouco assimétrica	$Y \sim \text{Bin}(n, p)$	$Y \sim N(np, np(1-p))$; para probabilidades, pode-se utilizar correção de continuidade
Binomial no regime de eventos raros, com n grande, p pequeno e $np \approx \lambda$	$Y \sim \text{Bin}(n, p)$	$Y \sim \text{Poisson}(\lambda)$, com $\lambda = np$
População finita com M unidades que apresentam a característica, AAS sem reposição	$Y = n\hat{p}$	$Y \sim \text{Hiper}(N, M, n)$
Proporção em população finita, AAS sem reposição	$\hat{p}$	$E(\hat{p}) = p,$ $\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \frac{N-n}{N-1}$
População finita, AAS sem reposição	$\bar{X}$	$E(\bar{X}) = \mu_N,$ $\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N-n}{N-1}$
Amostra i.i.d., $\text{Var}(X) = \sigma^2 < \infty$	S^2	$E(S^2) = \sigma^2$
Amostra i.i.d., $\mu_4 < \infty$	S^2	$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right]$
População normal	$(n-1)S^2/\sigma^2$	χ_{n-1}^2 , exatamente
População normal	$(\bar{X} - \mu)/(S/\sqrt{n})$	t_{n-1} , exatamente
Duas amostras normais independentes	$(S_1^2/\sigma_1^2)/(S_2^2/\sigma_2^2)$	F_{n_1-1, n_2-1} , exatamente
Exponencial i.i.d., parametrizada pela média	$\bar{X}$	$\text{Gama}(n, \mu/n)$
Amostra i.i.d. de uma distribuição contínua	$X_{(k)}$	$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$

As distribuições e propriedades reunidas nesta unidade fornecem a base probabilística para a avaliação de estimadores. No Capítulo 5, elas fundamentam o estudo de viés, variância, erro quadrático médio, consistência e eficiência.

4.15 Exercícios

Exercícios conceituais

1. **População e distribuição amostral.** Explique a diferença entre a distribuição de X e a distribuição de $\bar{X}$. Em que situação as duas distribuições pertencem à mesma família normal?
2. **Estatística ou parâmetro.** Classifique cada quantidade como parâmetro ou estatística: μ , σ^2 , $\bar{X}$, S^2 , p , $\hat{p}$ e $X_{(n)}$.
3. **Dois referenciais.** Explique por que as observações de uma amostra aleatória simples sem reposição de uma população finita não são independentes. Mostre que elas possuem a mesma distribuição marginal.
4. **Lei dos Grandes Números e TCL.** Compare as conclusões dos dois teoremas. Qual deles descreve concentração? Qual descreve a distribuição padronizada do erro?
5. **Normalidade.** Identifique quais resultados deste capítulo exigem normalidade para serem exatos e quais permanecem válidos sem essa hipótese, sob as condições de existência de momentos indicadas em cada resultado.

Exercícios de cálculo

6. **População finita.** Considere a população $\{1, 3, 6, 10\}$ e amostras de tamanho 2.
 - a. Obtenha a distribuição de $\bar{X}$ com reposição.
 - b. Calcule $E(\bar{X})$ e $\text{Var}(\bar{X})$.
 - c. Repita sem reposição e verifique a correção de população finita.
7. **Média exponencial.** Seja

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\mu), \quad E(X_i) = \mu,$$

na parametrização pela média.

- a. Obtenha a distribuição de $\sum X_i$.
 - b. Obtenha a distribuição de $\bar{X}$.
 - c. Calcule $P(\bar{X} > c)$ em termos da função de distribuição gama.
8. **Média Poisson.** Seja

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda).$$

- a. Obtenha a distribuição de

$$Y = \sum_{i=1}^n X_i.$$

- b. A partir desse resultado, obtenha a distribuição de $\bar{X}$.

- c. Determine $E(\bar{X})$ e $\text{Var}(\bar{X})$.

9. **Média normal.** Uma variável tem distribuição $N(50, 12^2)$. Para uma amostra de tamanho 36:

- a. determine a distribuição de $\bar{X}$;
 b. calcule $P(48 < \bar{X} < 53)$;
 c. encontre c tal que $P(|\bar{X} - 50| < c) = 0,95$.

10. **Diferença de médias.** Considere duas amostras independentes,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu_1, \sigma_1^2)$$

e

$$Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} N(\mu_2, \sigma_2^2).$$

- a. Determine as distribuições de $\bar{X}$ e $\bar{Y}$.

- b. Obtenha a distribuição de

$$\bar{X} - \bar{Y}.$$

- c. Determine $E(\bar{X} - \bar{Y})$ e $\text{Var}(\bar{X} - \bar{Y})$.

- d. Suponha agora que as duas populações não sejam necessariamente normais, mas possuam médias μ_1, μ_2 e variâncias finitas σ_1^2, σ_2^2 . Explique sob que regime a distribuição de $\bar{X} - \bar{Y}$ pode ser aproximada por

$$N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right)$$

e indique a diferença entre esse resultado e o obtido nos itens anteriores.

11. **TCL para uma população não normal.** Seja $X_1, \dots, X_{64} \stackrel{\text{iid}}{\sim} \text{Exp}(1)$, na parametrização por taxa. Use o TCL para aproximar $P(0,8 < \bar{X} < 1,2)$.
12. **Proporção.** Considere inicialmente

$$X_1, \dots, X_{200} \stackrel{\text{iid}}{\sim} \text{Ber}(0,12).$$

- a. Determine $E(\hat{p})$ e $\text{EP}(\hat{p})$.
 - b. Aproxime $P(\hat{p} \leq 0,09)$ utilizando o TCL.
 - c. Compare a aproximação com a probabilidade binomial exata no R.
 - d. Considere agora uma população finita com $N = 1000$ unidades, das quais $M = 120$ apresentam a característica de interesse, e uma amostra aleatória simples sem reposição de tamanho $n = 200$. Identifique a distribuição exata de $Y = n\hat{p}$ e calcule $\text{EP}(\hat{p})$.
 - e. Compare o erro-padrão obtido no item anterior com aquele do modelo $\text{Ber}(0,12)$ i.i.d. e explique a origem da diferença.
13. **Correção de continuidade.** Seja

$$Y \sim \text{Bin}(150, 0,5).$$

Utilizando a aproximação normal com correção de continuidade, calcule aproximadamente:

- a. $P(Y \geq 90)$;
 - b. $P(65 \leq Y \leq 85)$.
14. **Aproximação de Poisson para a binomial.** Em determinado processo de inspeção, cada uma de 2000 unidades apresenta, independentemente, probabilidade 0,002 de possuir um defeito específico. Seja Y o número de unidades com esse defeito.
- a. Identifique a distribuição exata de Y .
 - b. Determine o parâmetro da distribuição de Poisson que pode ser utilizada para aproximar a distribuição de Y .
 - c. Utilize a aproximação de Poisson para calcular $P(2 \leq Y \leq 7)$.
 - d. Escreva a expressão correspondente à probabilidade binomial exata.

- e. Explique por que, nesse caso, a aproximação de Poisson é mais natural que a aproximação normal.

15. **Variância amostral normal.** Se

$$X_1, \dots, X_{20} \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2), \quad \sigma^2 = 4,$$

calcule:

- a. $P(S^2 > 6)$;
b. os quantis a e b tais que $P(a < S^2 < b) = 0,95$ com caudas iguais.

16. **Distribuição t .** Se uma amostra normal possui $n = 16$, determine c tal que

$$P\left(\left|\frac{\bar{X} - \mu}{S/4}\right| < c\right) = 0,95.$$

17. **Razão de variâncias.** Duas amostras normais independentes possuem tamanhos $n_1 = 12$ e $n_2 = 18$.

- a. determine a distribuição de $(S_1^2/\sigma_1^2)/(S_2^2/\sigma_2^2)$;
b. sob $\sigma_1^2 = \sigma_2^2$, calcule $P(S_1^2/S_2^2 > 2)$.

18. **Estatísticas de ordem.** Seja $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta)$.

- a. obtenha a função de distribuição de $X_{(n)}$;
b. obtenha sua densidade;
c. calcule $E[X_{(n)}]$;
d. proponha uma transformação, $T(\cdot)$, de $X_{(n)}$ tal que $E[T(X_{(n)})] = \theta$.

19. **Parâmetro no suporte.** Seja $X_1, \dots, X_n$ uma amostra i.i.d. de uma distribuição com densidade

$$f(x \mid \theta) = \frac{ax^{a-1}}{\theta^a}, \quad 0 < x < \theta,$$

em que $a > 0$ é conhecido e $\theta > 0$,

e $f(x \mid \theta) = 0$ fora desse intervalo.

- a. Obtenha a função de distribuição de X_i .

- b. Obtenha a função de distribuição de $X_{(n)}$.
- c. Obtenha a densidade de $X_{(n)}$.
- d. Obtenha a distribuição de

$$\frac{X_{(n)}}{\theta}.$$

Adaptado de Casella; Berger (2011), cap. 5.

20. **Mínimo exponencial.** Se $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda)$ na parametrização por taxa, mostre que

$$X_{(1)} \sim \text{Exp}(n\lambda).$$

Exercícios teóricos e computacionais

21. **Variância de S^2 .** Usando a fórmula geral demonstrada neste capítulo,

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right],$$

verifique que, para uma população normal, $\text{Var}(S^2) = 2\sigma^4/(n-1)$.

22. **Simulação e condições do TCL.** Repita a simulação de Seção 4.13 para populações uniforme, Bernoulli, lognormal e Cauchy padrão.

- a. Compare $n = 5, 30$ e 200 .
- b. Explique por que o comportamento da média da distribuição de Cauchy é qualitativamente diferente.
- c. Relacione o resultado às hipóteses do TCL.

23. **Studentização em uma população não normal.** Para

$$X_i \sim \text{Beta}(2, 5)$$

e $n = 15$, estime por simulação a distribuição de

$$T = \frac{\bar{X} - E(X)}{S/\sqrt{n}}.$$

- a. Compare o histograma da distribuição simulada de T com as densidades $N(0, 1)$ e t_{14} .
 - b. Explique por que a distribuição t_{14} não constitui a distribuição exata de T neste caso.
 - c. Avalie, a partir da simulação, qual das duas distribuições de referência descreve melhor a forma da distribuição de T para $n = 15$.
24. **Demonstração por FGM.** Demonstre que, se $X_i \sim N(\mu, \sigma^2)$ são independentes, então $\bar{X} \sim N(\mu, \sigma^2/n)$.
 25. **Demonstração da Lei Fraca.** Use a desigualdade de Chebyshev para demonstrar a Lei Fraca dos Grandes Números sob variância finita.
 26. **Distribuição da estatística de ordem.** Obtenha a fórmula da densidade de $X_{(k)}$ a partir de

$$P(x < X_{(k)} \leq x + h), \quad h > 0.$$

Considere a contribuição de primeira ordem correspondente a $k - 1$ observações que não ultrapassam x , uma observação no intervalo $(x, x + h]$ e $n - k$ observações maiores que $x + h$. Divida a expressão obtida por h e tome o limite quando $h \downarrow 0$.

Referências

5 Avaliação de Estimadores e Princípios de Redução de Dados

Em Capítulo 3, um estimador foi definido como uma estatística utilizada para estimar uma função paramétrica $\tau(\theta)$. No Capítulo 4, a distribuição dessas estatísticas permitiu descrever sua variabilidade sob repetição do mecanismo amostral.

Conhecida essa variabilidade, surgem duas questões complementares. A primeira é **como avaliar a qualidade de um estimador**: seu erro, sua dispersão, seu comportamento quando o tamanho amostral aumenta e os limites de desempenho impostos pelo modelo. A segunda é **como identificar quais aspectos da amostra concentram a informação relevante sobre o parâmetro**, permitindo reduzir os dados sem perda inferencial.

A primeira questão conduz aos conceitos de risco, viés, erro quadrático médio, consistência e eficiência e integra o percurso comum do capítulo. A segunda, apresentada como aprofundamento, conduz à suficiência, à suficiência minimal, às famílias exponenciais, à completude, ao ENVVUM, aos teoremas de Rao–Blackwell e Lehmann–Scheffé e à relação entre ancilaridade e o teorema de Basu. As duas linhas voltam a se encontrar quando a redução dos dados é utilizada para melhorar e caracterizar estimadores (Rice, 2007, chap. 8; Lauritzen, 2023, chaps. 4–5; Cox, 2006, secs. 2.2 and 4.3).

Objetivos do capítulo

Ao final do percurso principal deste capítulo, o leitor deverá ser capaz de:

- interpretar risco, erro quadrático médio, viés, variância e erro-padrão como critérios de avaliação de estimadores;
- comparar estimadores utilizando EQM, variância e eficiência relativa;
- distinguir propriedades de amostra finita, como não viés, de propriedades assintóticas, como consistência;
- interpretar a função escore e a informação de Fisher como medidas da sensibilidade do modelo a alterações no parâmetro;
- utilizar a desigualdade de Cramér–Rao para estabelecer limites de precisão sob condições de regularidade;
- distinguir eficiência de Cramér–Rao em amostras finitas de eficiência assintótica.

No aprofundamento sobre redução de dados, o leitor deverá também ser capaz de:

- identificar estatísticas suficientes e suficientes minimais;
- reconhecer a estrutura de famílias exponenciais e suas estatísticas canônicas;
- compreender o papel da completude na unicidade de funções não viesadas;
- utilizar os teoremas de Rao–Blackwell e Lehmann–Scheffé na construção e caracterização de estimadores;
- interpretar ancilaridade e sua relação com suficiência e completude por meio do teorema de Basu.

5.1 Avaliação de estimadores

Função de perda, risco e erro quadrático médio

Um estimador pode apresentar diferentes tipos de erro. Por isso, antes de comparar dois estimadores, é necessário estabelecer **qual critério será utilizado para avaliar seu desempenho**.

Considere um estimador

$$T = T(\mathbf{X})$$

de uma função paramétrica

$$\tau(\theta).$$

Uma forma geral de avaliar as consequências de utilizar determinado valor como estimativa consiste em definir uma **função de perda**

$$\mathcal{L}(\tau(\theta), a),$$

em que a representa uma possível ação ou estimativa. Essa função quantifica a perda associada a utilizar a quando o verdadeiro valor do alvo é $\tau(\theta)$.

Como o estimador $T(\mathbf{X})$ depende da amostra, seu valor varia de uma amostra para outra. O **risco** é a perda média produzida pelo procedimento de estimação:

$$R(\theta, T) = E_{\theta} [\mathcal{L}(\tau(\theta), T(\mathbf{X}))].$$

A esperança é calculada em relação à distribuição amostral de T , para um valor fixado de θ . Assim, o risco mede o desempenho médio do estimador sob repetição do mecanismo amostral.

Essa formulação pertence ao quadro da teoria da decisão estatística (Rasch; Schott, 2018, secs. 1.5 and 2.4; Bickel; Doksum, 2016, chap. 1).

Um caso especialmente importante é a **perda quadrática**,

$$\mathcal{L}(\tau(\theta), a) = [a - \tau(\theta)]^2.$$

Nesse caso, erros maiores recebem penalização proporcional ao quadrado de sua magnitude.

Substituindo a ação a pelo estimador T , o risco passa a ser

$$R(\theta, T) = E_{\theta} \left[(T - \tau(\theta))^2 \right].$$

Essa quantidade é denominada **erro quadrático médio** (EQM):

$$\text{EQM}_{\theta}(T) = E_{\theta} \left[(T - \tau(\theta))^2 \right].$$

i Interpretação — Erro quadrático médio

O EQM mede o afastamento quadrático médio entre o estimador e o valor que se pretende estimar.

Um estimador pode apresentar EQM elevado porque varia muito entre diferentes amostras, porque tende sistematicamente a se afastar do alvo ou pela combinação desses dois efeitos.

Por isso, o EQM permite comparar estimadores viesados e não viesados utilizando uma única medida de desempenho.

A perda quadrática é particularmente conveniente por permitir resultados analíticos simples e por penalizar mais intensamente erros de maior magnitude. Entretanto, sua escolha depende do problema. Quando erros positivos e negativos possuem consequências diferentes, ou quando grandes erros devem receber outro tipo de penalização, outras funções de perda podem ser mais adequadas (Rasch; Schott, 2018, secs. 1.5 and 2.4; Lauritzen, 2023, sec. 4.1).

Viés, variância e erro-padrão

O EQM pode ser compreendido a partir de duas características da distribuição amostral do estimador: sua posição em relação ao alvo e sua dispersão.

A primeira é descrita pelo **viés**.

! Definição — Viés

Se T é um estimador de $\tau(\theta)$, seu viés é

$$B_{\theta}(T) = E_{\theta}(T) - \tau(\theta).$$

O estimador T é **não viesado** para $\tau(\theta)$ quando

$$E_{\theta}(T) = \tau(\theta)$$

para todo

$$\theta \in \Theta.$$

O viés compara o centro da distribuição amostral do estimador com o valor que se deseja estimar.

Se

$$B_{\theta}(T) > 0,$$

o estimador tende a **superestimar o alvo em média**. Se

$$B_{\theta}(T) < 0,$$

ele tende a **subestimá-lo em média**.

Essa interpretação refere-se ao comportamento do estimador ao longo de amostras repetidas. Um viés positivo, por exemplo, não significa que o estimador produzirá uma superestimação em toda amostra particular.

A segunda característica é a dispersão da distribuição amostral. A variância de T é

$$\text{Var}_{\theta}(T) = E_{\theta} \left[(T - E_{\theta}(T))^2 \right],$$

e seu erro-padrão é

$$\text{EP}_{\theta}(T) = \sqrt{\text{Var}_{\theta}(T)}.$$

O erro-padrão mede quanto o valor do estimador tende a variar entre diferentes amostras produzidas pelo mesmo mecanismo amostral.

Assim como no Capítulo 4, o erro-padrão de uma estatística não deve ser confundido com o desvio-padrão das observações individuais. O primeiro descreve a variabilidade da **distribuição amostral do estimador**.

Viés e variância aparecem conjuntamente na decomposição do erro quadrático médio.

! Resultado — Decomposição viés-variância

Para qualquer estimador T com segundo momento finito,

$$\text{EQM}_\theta(T) = \text{Var}_\theta(T) + B_\theta(T)^2.$$

A decomposição mostra que o EQM reúne duas fontes de erro:

- a **variabilidade** do estimador entre diferentes amostras, medida por $\text{Var}_\theta(T)$;
- o **afastamento sistemático** entre o centro de sua distribuição amostral e o alvo, medido por $B_\theta(T)^2$.

i Demonstração — Decomposição viés-variância

Partimos da definição

$$\text{EQM}_\theta(T) = E_\theta \left[(T - \tau(\theta))^2 \right].$$

Para separar o erro em uma componente de variabilidade e outra de viés, somamos e subtraímos $E_\theta(T)$:

$$T - \tau(\theta) = [T - E_\theta(T)] + [E_\theta(T) - \tau(\theta)].$$

Elevando ao quadrado,

$$\begin{aligned} [T - \tau(\theta)]^2 &= [T - E_\theta(T)]^2 \\ &\quad + [E_\theta(T) - \tau(\theta)]^2 \\ &\quad + 2[T - E_\theta(T)][E_\theta(T) - \tau(\theta)]. \end{aligned}$$

Agora tomamos a esperança dos dois lados.

O primeiro termo fornece

$$E_\theta \left[(T - E_\theta(T))^2 \right] = \text{Var}_\theta(T).$$

O segundo termo não depende da amostra e, portanto,

$$E_\theta \left[(E_\theta(T) - \tau(\theta))^2 \right] = [E_\theta(T) - \tau(\theta)]^2 = B_\theta(T)^2.$$

Para o termo cruzado,

$$E_{\theta} [T - E_{\theta}(T)] = 0.$$

Logo,

$$\begin{aligned} E_{\theta} [2(T - E_{\theta}(T))(E_{\theta}(T) - \tau(\theta))] \\ = 2(E_{\theta}(T) - \tau(\theta))E_{\theta} [T - E_{\theta}(T)] \\ = 0. \end{aligned}$$

Reunindo os termos,

$$\text{EQM}_{\theta}(T) = \text{Var}_{\theta}(T) + B_{\theta}(T)^2.$$

⚠ Observação — Compromisso entre viés e variância

Não existe uma regra geral segundo a qual reduzir o viés necessariamente aumente a variância, ou vice-versa.

Em algumas situações, aceitar um pequeno viés pode produzir uma redução de variância suficientemente grande para diminuir o EQM. Em outras, isso não ocorre.

Por essa razão, comparar estimadores apenas por seus vieses pode ser insuficiente. Quando a perda quadrática é o critério adotado, a comparação deve considerar o EQM, que incorpora simultaneamente viés e variância.

As definições de viés, variância e EQM, bem como a decomposição viés-variância, seguem as formulações de Lauritzen (2023, sec. 4.1), Rice (2007, sec. 8.3) e Rasch; Schott (2018, sec. 2.4).

Exemplo-guia — Estimação do limite de uma distribuição uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0.$$

Nesse modelo, θ determina o limite superior do suporte:

$$0 < X_i < \theta.$$

Considere três estimadores de θ :

$$T_1 = 2\bar{X}, \quad T_2 = X_{(n)} = \max(X_1, \dots, X_n), \quad T_3 = \frac{n+1}{n}X_{(n)}.$$

Os três estimadores utilizam características diferentes da amostra.

Como

$$E_{\theta}(X_i) = \frac{\theta}{2},$$

temos

$$E_{\theta}(\bar{X}) = \frac{\theta}{2},$$

o que sugere utilizar $2\bar{X}$ para estimar θ .

O máximo amostral,

$$X_{(n)},$$

explora outra característica do modelo: nenhuma observação pode ultrapassar o limite θ . Assim, valores elevados de $X_{(n)}$ fornecem informação direta sobre esse limite.

O máximo amostral $X_{(n)}$ é viesado para θ . O terceiro estimador,

$$\frac{n+1}{n}X_{(n)},$$

aplica uma correção multiplicativa destinada a eliminar esse viés.

Para cada estimador, determine:

1. sua esperança e seu viés;
2. sua variância;
3. seu EQM;
4. qual dos três apresenta menor EQM.

i Resolução — Comparação dos três estimadores

Estimador $T_1 = 2\bar{X}$

Como

$$E_{\theta}(\bar{X}) = \frac{\theta}{2},$$

temos

$$\begin{aligned} E_{\theta}(T_1) &= 2E_{\theta}(\bar{X}) \\ &= \theta. \end{aligned}$$

Portanto,

$$B_{\theta}(T_1) = 0,$$

e T_1 é não viesado para θ .

Para uma variável uniforme em $(0, \theta)$,

$$\text{Var}_{\theta}(X_i) = \frac{\theta^2}{12}.$$

Logo,

$$\begin{aligned} \text{Var}_{\theta}(T_1) &= 4 \text{Var}_{\theta}(\bar{X}) \\ &= 4 \frac{\theta^2/12}{n} \\ &= \frac{\theta^2}{3n}. \end{aligned}$$

Como seu viés é nulo,

$$\text{EQM}_{\theta}(T_1) = \text{Var}_{\theta}(T_1) = \frac{\theta^2}{3n}.$$

Estimador $T_2 = X_{(n)}$

No Capítulo 4 vimos que, para o máximo amostral,

$$F_{X_{(n)}}(x) = [F(x)]^n.$$

No modelo uniforme,

$$F(x | \theta) = \frac{x}{\theta}, \quad 0 \leq x \leq \theta.$$

Portanto,

$$P_{\theta}(X_{(n)} \leq x) = \left(\frac{x}{\theta}\right)^n, \quad 0 \leq x \leq \theta.$$

Os dois primeiros momentos são

$$E_{\theta}(X_{(n)}) = \frac{n}{n+1} \theta$$

e

$$\text{Var}_{\theta}(X_{(n)}) = \frac{n\theta^2}{(n+1)^2(n+2)}.$$

Derivação — Momentos de $X_{(n)}$

Derivando a função de distribuição,

$$f_{X_{(n)}}(x) = \frac{nx^{n-1}}{\theta^n}, \quad 0 < x < \theta.$$

Assim,

$$\begin{aligned} E_{\theta}(X_{(n)}) &= \int_0^{\theta} x \frac{nx^{n-1}}{\theta^n} dx \\ &= \frac{n}{\theta^n} \int_0^{\theta} x^n dx \\ &= \frac{n}{n+1} \theta. \end{aligned}$$

Para o segundo momento,

$$\begin{aligned} E_{\theta}(X_{(n)}^2) &= \int_0^{\theta} x^2 \frac{nx^{n-1}}{\theta^n} dx \\ &= \frac{n}{\theta^n} \int_0^{\theta} x^{n+1} dx \\ &= \frac{n}{n+2} \theta^2. \end{aligned}$$

Consequentemente,

$$\begin{aligned} \text{Var}_{\theta}(X_{(n)}) &= E_{\theta}(X_{(n)}^2) - [E_{\theta}(X_{(n)})]^2 \\ &= \frac{n}{n+2} \theta^2 - \left(\frac{n}{n+1} \theta \right)^2 \\ &= \frac{n\theta^2}{(n+1)^2(n+2)}. \end{aligned}$$

O viés de T_2 é

$$\begin{aligned} B_{\theta}(T_2) &= E_{\theta}(T_2) - \theta \\ &= \frac{n}{n+1} \theta - \theta \\ &= -\frac{\theta}{n+1}. \end{aligned}$$

Portanto, T_2 tende a subestimar θ em média.

Pela decomposição viés-variância,

$$\begin{aligned}
\text{EQM}_\theta(T_2) &= \text{Var}_\theta(T_2) + B_\theta(T_2)^2 \\
&= \frac{n\theta^2}{(n+1)^2(n+2)} + \frac{\theta^2}{(n+1)^2} \\
&= \frac{2\theta^2}{(n+1)(n+2)}.
\end{aligned}$$

Estimador $T_3 = \frac{n+1}{n}X_{(n)}$

O terceiro estimador corrige o viés do máximo amostral:

$$\begin{aligned}
E_\theta(T_3) &= \frac{n+1}{n}E_\theta(X_{(n)}) \\
&= \frac{n+1}{n} \frac{n}{n+1} \theta \\
&= \theta.
\end{aligned}$$

Logo,

$$B_\theta(T_3) = 0.$$

Sua variância é

$$\begin{aligned}
\text{Var}_\theta(T_3) &= \left(\frac{n+1}{n}\right)^2 \text{Var}_\theta(X_{(n)}) \\
&= \left(\frac{n+1}{n}\right)^2 \frac{n\theta^2}{(n+1)^2(n+2)} \\
&= \frac{\theta^2}{n(n+2)}.
\end{aligned}$$

Como T_3 é não viesado,

$$\text{EQM}_\theta(T_3) = \frac{\theta^2}{n(n+2)}.$$

Podemos reunir os resultados:

Estimador	Viés	EQM
$T_1 = 2\bar{X}$	0	$\frac{\theta^2}{3n}$
$T_2 = X_{(n)}$	$-\frac{\theta}{n+1}$	$\frac{2\theta^2}{(n+1)(n+2)}$
$T_3 = \frac{n+1}{n}X_{(n)}$	0	$\frac{\theta^2}{n(n+2)}$

Para $n > 1$,

$$\text{EQM}_\theta(T_3) < \text{EQM}_\theta(T_2)$$

e

$$\text{EQM}_\theta(T_3) < \text{EQM}_\theta(T_1).$$

Além disso, para $n > 2$,

$$\text{EQM}_\theta(T_2) < \text{EQM}_\theta(T_1).$$

Portanto, para $n > 2$, a ordenação dos três estimadores segundo o EQM é

$$\text{EQM}_\theta(T_3) < \text{EQM}_\theta(T_2) < \text{EQM}_\theta(T_1).$$

Um aspecto importante é que T_2 é viesado, enquanto T_1 é não viesado. Mesmo assim, para $n > 2$,

$$\text{EQM}_\theta(T_2) < \text{EQM}_\theta(T_1).$$

Esse resultado mostra concretamente por que o não viés, isoladamente, não é suficiente para ordenar estimadores segundo sua qualidade quando o critério adotado é o erro quadrático médio.

O exemplo também mostra como a estrutura do modelo pode orientar a construção de um estimador. Como θ determina o limite superior do suporte, o máximo amostral utiliza diretamente uma característica da distribuição que está relacionada ao parâmetro.

Esses mesmos estimadores serão utilizados a seguir para distinguir propriedades de amostra finita de propriedades assintóticas. A construção e a comparação foram adaptadas de Lauritzen (2023, ex. 4.2); a interpretação em termos de não viés e EQM também é discutida por Chihara; Hesterberg (2022, secs. 6.3.1–6.3.3).

Consistência

Viés, variância e EQM podem ser avaliados para um tamanho amostral fixado. Entretanto, muitos procedimentos estatísticos também são avaliados pelo que acontece quando a quantidade de informação aumenta.

Para isso, consideramos uma sequência de estimadores

$$T_1, T_2, \dots,$$

em que T_n é construído a partir de uma amostra de tamanho n .

A **consistência** avalia se T_n se concentra progressivamente em torno de $\tau(\theta)$ quando o tamanho amostral aumenta.

! Definição — Consistência em probabilidade

Uma sequência de estimadores $\{T_n\}$ é **consistente em probabilidade** para $\tau(\theta)$ se, para todo $\varepsilon > 0$ e todo $\theta \in \Theta$,

$$P_\theta(|T_n - \tau(\theta)| > \varepsilon) \rightarrow 0$$

quando

$$n \rightarrow \infty.$$

Equivalentemente,

$$T_n \xrightarrow{P} \tau(\theta).$$

A quantidade

$$P_\theta(|T_n - \tau(\theta)| > \varepsilon)$$

é a probabilidade de o erro absoluto do estimador ultrapassar uma margem fixa ε .

A consistência exige que essa probabilidade se torne arbitrariamente pequena quando o tamanho amostral cresce.

Portanto, consistência e não viés descrevem propriedades diferentes:

- o **não viés** compara a esperança de T_n com o alvo para um tamanho amostral determinado;
- a **consistência** descreve o comportamento de toda a sequência $\{T_n\}$ quando $n \rightarrow \infty$.

Um estimador pode ser viesado para todo n e ainda assim ser consistente, desde que esse viés e sua variabilidade desapareçam adequadamente quando a amostra cresce.

! Definição — Consistência em erro quadrático médio

Uma sequência de estimadores $\{T_n\}$ é **consistente em erro quadrático médio** para $\tau(\theta)$ se

$$\text{EQM}_\theta(T_n) \rightarrow 0$$

quando

$$n \rightarrow \infty.$$

A consistência em EQM implica consistência em probabilidade.

i Demonstração — Consistência em EQM implica consistência em probabilidade

Para provar o resultado, basta mostrar que

$$\text{EQM}_\theta(T_n) \rightarrow 0$$

implica

$$P_\theta(|T_n - \tau(\theta)| > \varepsilon) \rightarrow 0.$$

Como

$$|T_n - \tau(\theta)| > \varepsilon$$

é equivalente a

$$[T_n - \tau(\theta)]^2 > \varepsilon^2,$$

temos

$$P_\theta(|T_n - \tau(\theta)| > \varepsilon) = P_\theta([T_n - \tau(\theta)]^2 > \varepsilon^2).$$

A variável

$$[T_n - \tau(\theta)]^2$$

é não negativa. Pela desigualdade de Markov,

$$\begin{aligned} P_\theta([T_n - \tau(\theta)]^2 > \varepsilon^2) &\leq \frac{E_\theta[(T_n - \tau(\theta))^2]}{\varepsilon^2} \\ &= \frac{\text{EQM}_\theta(T_n)}{\varepsilon^2}. \end{aligned}$$

Se

$$\text{EQM}_\theta(T_n) \rightarrow 0,$$

então, para qualquer $\varepsilon > 0$,

$$\frac{\text{EQM}_\theta(T_n)}{\varepsilon^2} \rightarrow 0.$$

Consequentemente,

$$P_{\theta} (|T_n - \tau(\theta)| > \varepsilon) \longrightarrow 0.$$

Logo,

$$T_n \xrightarrow{P} \tau(\theta).$$

A decomposição viés–variância fornece um critério simples para verificar consistência em EQM.

! Resultado — Critério suficiente para consistência

Se

$$B_{\theta}(T_n) \longrightarrow 0$$

e

$$\text{Var}_{\theta}(T_n) \longrightarrow 0,$$

então

$$\text{EQM}_{\theta}(T_n) \longrightarrow 0.$$

Consequentemente,

$$T_n \xrightarrow{P} \tau(\theta).$$

(Rice, 2007, sec. 8.5; Lauritzen, 2023, sec. 5.1)

De fato,

$$\text{EQM}_{\theta}(T_n) = \text{Var}_{\theta}(T_n) + B_{\theta}(T_n)^2.$$

Assim, se a variância e o viés tendem a zero, o EQM também tende a zero.

Observe que **não é necessário que T_n seja não viesado para todo n** . Para esse critério, basta que

$$B_{\theta}(T_n) \longrightarrow 0.$$

Retomando o modelo uniforme

Retome os seguintes estimadores de θ no modelo

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta) :$$

$$2\overline{X}, \quad 2X_1, \quad X_{(n)}, \quad \frac{X_1}{2}.$$

Classifique cada estimador quanto a:

1. não viés;
2. consistência.

A comparação é útil porque as duas propriedades respondem a perguntas diferentes. O não viés é avaliado para cada tamanho amostral, enquanto a consistência exige estudar o comportamento do estimador quando n aumenta.

i Resolução — Não viés e consistência no modelo uniforme

Estimador	Não viesado?	Consistente?
$2\overline{X}$	Sim	Sim
$2X_1$	Sim	Não
$X_{(n)}$	Não	Sim
$X_1/2$	Não	Não

Estimador $2\bar{X}$

Como

$$E_{\theta}(\bar{X}) = \frac{\theta}{2},$$

temos

$$E_{\theta}(2\bar{X}) = \theta.$$

Portanto, $2\bar{X}$ é não viesado.

Além disso, pela Lei dos Grandes Números,

$$\bar{X} \xrightarrow{P} \frac{\theta}{2}.$$

Multiplicando por 2,

$$2\bar{X} \xrightarrow{P} \theta.$$

Logo, $2\bar{X}$ é também consistente.

Estimador $2X_1$

Temos

$$E_{\theta}(2X_1) = 2\frac{\theta}{2} = \theta.$$

Portanto, $2X_1$ é não viesado.

Entretanto, aumentar o tamanho da amostra não modifica esse estimador: ele continua utilizando somente a primeira observação.

Podemos tornar essa afirmação explícita. Como

$$X_1 \sim \text{Unif}(0, \theta),$$

temos

$$2X_1 \sim \text{Unif}(0, 2\theta).$$

Para

$$0 < \varepsilon < \theta,$$

a probabilidade de $2X_1$ estar a uma distância de no máximo ε de θ é

$$P_{\theta}(|2X_1 - \theta| \leq \varepsilon) = \frac{2\varepsilon}{2\theta} = \frac{\varepsilon}{\theta}.$$

Consequentemente,

$$P_{\theta}(|2X_1 - \theta| > \varepsilon) = 1 - \frac{\varepsilon}{\theta}.$$

Essa probabilidade não depende de n e, portanto, não converge para zero quando o tamanho amostral aumenta.

Logo, $2X_1$ não é consistente.

Estimador $X_{(n)}$

Para cada n ,

$$E_{\theta}(X_{(n)}) = \frac{n}{n+1}\theta < \theta.$$

Assim,

$$B_{\theta}(X_{(n)}) = -\frac{\theta}{n+1},$$

e o máximo amostral é viesado.

Observe, entretanto, que

$$B_{\theta}(X_{(n)}) \rightarrow 0.$$

Além disso, sua distribuição se concentra progressivamente próximo do limite superior θ .

Verificação — Consistência de $X_{(n)}$

Como

$$X_{(n)} \leq \theta,$$

para

$$0 < \varepsilon < \theta$$

temos

$$|X_{(n)} - \theta| = \theta - X_{(n)}.$$

Assim,

$$P_{\theta}(|X_{(n)} - \theta| > \varepsilon) = P_{\theta}(X_{(n)} < \theta - \varepsilon).$$

No modelo uniforme,

$$P_{\theta}(X_{(n)} \leq x) = \left(\frac{x}{\theta}\right)^n, \quad 0 \leq x \leq \theta.$$

Portanto,

$$\begin{aligned} P_{\theta}(|X_{(n)} - \theta| > \varepsilon) &= \left(\frac{\theta - \varepsilon}{\theta}\right)^n \\ &= \left(1 - \frac{\varepsilon}{\theta}\right)^n. \end{aligned}$$

Como

$$0 < 1 - \frac{\varepsilon}{\theta} < 1,$$

segue que

$$\left(1 - \frac{\varepsilon}{\theta}\right)^n \rightarrow 0.$$

Logo,

$$X_{(n)} \xrightarrow{P} \theta.$$

Portanto, $X_{(n)}$ é viesado para cada n finito, mas é consistente para θ .

Estimador $\frac{X_1}{2}$
Sua esperança é

$$E_{\theta}\left(\frac{X_1}{2}\right) = \frac{\theta}{4},$$

de modo que

$$B_{\theta}\left(\frac{X_1}{2}\right) = -\frac{3\theta}{4}.$$

Portanto, o estimador é viesado.

Além disso,

$$0 < \frac{X_1}{2} < \frac{\theta}{2}.$$

Assim, para qualquer

$$0 < \varepsilon < \frac{\theta}{2},$$

temos necessariamente

$$\left|\frac{X_1}{2} - \theta\right| > \varepsilon.$$

Logo,

$$P_{\theta}\left(\left|\frac{X_1}{2} - \theta\right| > \varepsilon\right) = 1$$

para todo n .
Portanto, $X_1/2$ não é consistente.

i Interpretação — Não viés e consistência

Os quatro estimadores mostram que não viés e consistência são propriedades distintas:

- $2\bar{X}$ é não viesado e consistente;
- $2X_1$ é não viesado, mas não é consistente;
- $X_{(n)}$ é viesado para todo n , mas é consistente;
- $X_1/2$ é viesado e não é consistente.

O não viés descreve a posição da distribuição amostral para um tamanho amostral fixado. A consistência descreve o comportamento de uma sequência de estimadores à medida que a quantidade de informação amostral aumenta.

Em geral, nenhuma dessas propriedades implica a outra.

A distinção entre não viés e consistência, assim como os critérios anteriores, é apresentada por Larsen; Marx (2012, sec. 5.7), Rice (2007, sec. 8.5) e Lauritzen (2023, sec. 5.1).

i Recordação — Operações com convergência em probabilidade

As propriedades de convergência estudadas em Capítulo 2 podem ser aplicadas diretamente à verificação de consistência.

Se

$$A_n \xrightarrow{P} a \quad \text{e} \quad B_n \xrightarrow{P} b,$$

então

$$A_n + B_n \xrightarrow{P} a + b, \quad A_n B_n \xrightarrow{P} ab,$$

e, se $b \neq 0$,

$$\frac{A_n}{B_n} \xrightarrow{P} \frac{a}{b}.$$

Se g é contínua em a ,

$$g(A_n) \xrightarrow{P} g(a).$$

Essas propriedades permitem transferir a consistência para estimadores construídos por transformações, somas, produtos e quocientes de estatísticas consistentes (Lauritzen, 2023, app. A.2).

Comparação por variância entre estimadores não viesados

Quando dois estimadores são não viesados para o mesmo alvo $\tau(\theta)$, seus vieses são nulos. Pela decomposição viés-variância,

$$\text{EQM}_\theta(T) = \text{Var}_\theta(T).$$

Nesse caso, comparar os EQMs equivale a comparar diretamente as variâncias das distribuições amostrais.

Considere dois estimadores não viesados,

$$T_1 \quad \text{e} \quad T_2,$$

do mesmo alvo $\tau(\theta)$.

Neste texto, definiremos a **eficiência relativa de T_1 em relação a T_2** por

$$e_\theta(T_1; T_2) = \frac{\text{Var}_\theta(T_2)}{\text{Var}_\theta(T_1)}.$$

Com essa convenção:

- se $e_\theta(T_1; T_2) > 1$, então T_1 possui menor variância;
- se $e_\theta(T_1; T_2) = 1$, os dois estimadores possuem a mesma variância;
- se $e_\theta(T_1; T_2) < 1$, então T_2 possui menor variância.

Portanto, valores maiores que 1 favorecem o estimador que aparece na primeira posição do quociente,

$$T_1.$$

Como também se encontra na literatura a convenção inversa, a orientação do quociente deve sempre ser explicitada (Rasch; Schott, 2018, sec. 2.4.1).

A eficiência relativa compara estimadores previamente escolhidos, mas não estabelece a menor variância possível dentro do modelo. Mesmo que T_1 tenha menor variância que T_2 , pode existir um terceiro estimador com variância ainda menor.

Uma comparação global requer uma cota determinada pelo próprio modelo. Para estimadores não viesados de um alvo $\tau(\theta)$, considere uma quantidade $B(\theta)$ tal que

$$\text{Var}_\theta(T) \geq B(\theta)$$

para todos os estimadores de uma classe considerada.

Se um estimador atingir essa cota, teremos uma referência objetiva para avaliar sua precisão sem precisar compará-lo, um a um, com todos os demais candidatos.

Para construir uma cota desse tipo, é necessário quantificar **quanto o modelo probabilístico muda quando o parâmetro varia**. Essa ideia conduz à função escore, à informação de Fisher e, em seguida, à desigualdade de Cramér–Rao.

Posteriormente, suficiência, completude, Rao–Blackwell e Lehmann–Scheffé fornecerão outra perspectiva para identificar estimadores de variância mínima.

Informação de Fisher

O objetivo é obter do próprio modelo uma medida de sua capacidade de distinguir valores próximos do parâmetro.

Se pequenas alterações em θ quase não modificam a distribuição das observações, os dados fornecem pouca capacidade para distinguir valores próximos desse parâmetro. Se a distribuição se altera mais intensamente, os dados podem carregar mais informação para essa distinção.

A função escore formaliza essa sensibilidade local.

Considere um modelo dominado com densidade ou função de probabilidade

$$f(x \mid \theta).$$

Para entender como o modelo reage a uma pequena alteração no parâmetro, fixe um valor observado x e considere a log-verossimilhança

$$\ell_x(\theta) = \log f(x \mid \theta).$$

Se substituirmos θ por um valor próximo $\theta + h$, uma aproximação de primeira ordem fornece

$$\ell_x(\theta + h) - \ell_x(\theta) \approx h\ell'_x(\theta).$$

Assim, a derivada

$$\ell'_x(\theta) = \frac{\partial}{\partial \theta} \log f(x \mid \theta)$$

mede a **variação local da log-verossimilhança** quando o parâmetro é ligeiramente modificado.

Essa derivada é denominada **função escore**. Para a variável aleatória X ,

$$U_{\theta}(X) = \frac{\partial}{\partial \theta} \log f(X | \theta).$$

Para um valor observado x :

- $U_{\theta}(x) > 0$ indica que, localmente, aumentar θ aumenta a log-verossimilhança;
- $U_{\theta}(x) < 0$ indica que, localmente, aumentar θ diminui a log-verossimilhança;
- valores de maior magnitude indicam maior sensibilidade local da log-verossimilhança a alterações no parâmetro.

O uso do **logaritmo** é particularmente conveniente para amostras independentes. Como

$$f(\mathbf{X} | \theta) = \prod_{i=1}^n f(X_i | \theta),$$

temos

$$\log f(\mathbf{X} | \theta) = \sum_{i=1}^n \log f(X_i | \theta).$$

Consequentemente, o escore da amostra será a soma dos escores individuais. Essa propriedade permitirá que a informação fornecida por observações independentes também se acumule de forma aditiva.

Observação — Condições de regularidade

As identidades utilizadas a seguir não são válidas automaticamente para qualquer modelo. Em particular, precisamos de condições que permitam diferenciar em relação a θ e intercalar diferenciação com integração ou soma. Uma condição importante na forma regular utilizada nesta seção é que o suporte da distribuição não dependa de θ . Por isso, modelos como

$$\text{Unif}(0, \theta),$$

nos quais o suporte varia com o parâmetro, exigem tratamento separado. As condições utilizadas na desigualdade de Cramér–Rao serão explicitadas na próxima subseção.

Sob essas condições de regularidade,

$$E_{\theta}[U_{\theta}(X)] = 0.$$

Portanto, a média do escore não distingue modelos com maior ou menor sensibilidade ao parâmetro.

O que pode variar é a **magnitude do escore de uma observação para outra**. Se os valores do escore tendem a ficar próximos de zero, pequenas alterações em θ modificam pouco a log-verossimilhança. Se apresentam maior magnitude, a distribuição reage mais intensamente a essas alterações.

Essa ideia conduz à informação de Fisher.

! Definição — Informação de Fisher

A **informação de Fisher** de uma observação sobre o parâmetro θ é

$$I_1(\theta) = E_{\theta} [U_{\theta}(X)^2] .$$

Como, sob as condições de regularidade,

$$E_{\theta}[U_{\theta}(X)] = 0,$$

podemos escrever

$$I_1(\theta) = \text{Var}_{\theta}(U_{\theta}(X)).$$

Assim, a informação de Fisher mede a magnitude quadrática média da sensibilidade local da log-verossimilhança ao parâmetro.

Sob condições adicionais de regularidade, uma forma equivalente é

$$I_1(\theta) = -E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right] .$$

Para uma amostra i.i.d. de tamanho n ,

$$I_n(\theta) = nI_1(\theta).$$

Portanto, nesse contexto, a informação cresce linearmente com o número de observações independentes (Lauritzen, 2023, sec. 1.2.2; Rasch; Schott, 2018, sec. 1.4).

i Derivação — Identidades da informação de Fisher

Considere primeiro uma única observação.

Pela definição,

$$U_{\theta}(X) = \frac{\partial}{\partial \theta} \log f(X | \theta).$$

Utilizando

$$\frac{\partial}{\partial \theta} \log f(x | \theta) = \frac{\frac{\partial}{\partial \theta} f(x | \theta)}{f(x | \theta)},$$

temos

$$\begin{aligned} E_{\theta}[U_{\theta}(X)] &= \int \frac{\frac{\partial}{\partial \theta} f(x | \theta)}{f(x | \theta)} f(x | \theta) dx \\ &= \int \frac{\partial}{\partial \theta} f(x | \theta) dx. \end{aligned}$$

Sob as condições que permitem trocar diferenciação e integração,

$$\begin{aligned} E_{\theta}[U_{\theta}(X)] &= \frac{\partial}{\partial \theta} \int f(x | \theta) dx \\ &= \frac{\partial}{\partial \theta} (1) \\ &= 0. \end{aligned}$$

No caso discreto, o mesmo argumento é obtido substituindo a integral pela soma. Portanto,

$$E_{\theta}[U_{\theta}(X)] = 0.$$

Como consequência,

$$I_1(\theta) = E_{\theta}[U_{\theta}(X)^2] = \text{Var}_{\theta}(U_{\theta}(X)).$$

Para obter a segunda expressão da informação de Fisher, diferenciamos a identidade

$$E_{\theta}[U_{\theta}(X)] = 0$$

em relação a θ .

Sob as condições de regularidade,

$$0 = \frac{d}{d\theta} E_{\theta}[U_{\theta}(X)].$$

Ao derivar uma esperança cuja distribuição também depende de θ , surgem dois termos:

$$0 = E_{\theta} \left[\frac{\partial}{\partial \theta} U_{\theta}(X) \right] + E_{\theta} [U_{\theta}(X)^2].$$

Como

$$\frac{\partial}{\partial \theta} U_{\theta}(X) = \frac{\partial^2}{\partial \theta^2} \log f(X | \theta),$$

obtemos

$$E_{\theta} [U_{\theta}(X)^2] = -E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right].$$

Portanto,

$$I_1(\theta) = -E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right].$$

Considere agora uma amostra i.i.d.

$$X_1, \dots, X_n.$$

A densidade ou função de probabilidade conjunta é

$$f(\mathbf{X} | \theta) = \prod_{i=1}^n f(X_i | \theta).$$

Logo,

$$\log f(\mathbf{X} | \theta) = \sum_{i=1}^n \log f(X_i | \theta),$$

e o escore da amostra é

$$\begin{aligned} U_n(\theta) &= \frac{\partial}{\partial \theta} \log f(\mathbf{X} | \theta) \\ &= \sum_{i=1}^n U_{\theta}(X_i). \end{aligned}$$

Os escores individuais são independentes e possuem esperança zero. Portanto,

$$\begin{aligned} I_n(\theta) &= \text{Var}_{\theta} [U_n(\theta)] \\ &= \text{Var}_{\theta} \left[\sum_{i=1}^n U_{\theta}(X_i) \right] \\ &= \sum_{i=1}^n \text{Var}_{\theta} [U_{\theta}(X_i)] \\ &= nI_1(\theta). \end{aligned}$$

Assim, para observações i.i.d., a informação de Fisher cresce linearmente com o tamanho da amostra.

A informação de Fisher quantifica quão sensível é a distribuição dos dados a mudanças no parâmetro. Quanto maior $I_n(\theta)$, maior é, nesse sentido, a capacidade do modelo amostral de

distinguir valores próximos de θ .

Sua utilidade para avaliar estimadores surge de uma relação fundamental entre o estimador e o escore da amostra.

Se

$$E_{\theta}(T) = g(\theta),$$

então, sob condições de regularidade,

$$\text{Cov}_{\theta}(T, U_n(\theta)) = g'(\theta).$$

No caso de um estimador não viesado para $\tau(\theta)$,

$$g(\theta) = \tau(\theta),$$

e portanto

$$\text{Cov}_{\theta}(T, U_n(\theta)) = \tau'(\theta).$$

Essa identidade liga três elementos:

- o alvo que se pretende estimar, por meio de $\tau'(\theta)$;
- a variabilidade do estimador T ;
- a variabilidade do escore, que é precisamente $I_n(\theta)$.

A desigualdade de Cauchy–Schwarz permitirá transformar essa relação em um limite inferior para $\text{Var}_{\theta}(T)$. É nesse sentido que a informação de Fisher fornece uma referência de precisão para estimadores (Cox, 2006, sec. 2.1; Lauritzen, 2023, sec. 1.2.2).

Desigualdade de Cramér–Rao

A desigualdade de Cramér–Rao formaliza essa relação.

A desigualdade de Cramér–Rao estabelece, sob condições de regularidade, uma cota inferior para a variância de estimadores. A cota depende do alvo $\tau(\theta)$ e da informação de Fisher do modelo, e não de uma comparação entre dois estimadores previamente escolhidos.

A forma utilizada nesta seção exige condições de regularidade. Entre as condições usuais que sustentam o argumento apresentado estão:

- o suporte da distribuição não depende de θ ;

- $f(x | \theta)$ é diferenciável em relação a θ ;
- a diferenciação pode ser intercambiada com a integração ou soma, tanto na normalização da distribuição quanto no cálculo de $E_\theta(T)$;
- $\text{Var}_\theta(T) < \infty$;
- $0 < I_n(\theta) < \infty$.

Essas condições permitem, em particular, que o escore tenha esperança zero e que a derivada de $E_\theta(T)$ seja relacionada à covariância entre o estimador e o escore.

! Teorema — Desigualdade de Cramér–Rao

Se $T = T(\mathbf{X})$ possui esperança

$$E_\theta(T) = g(\theta),$$

então, sob as condições de regularidade,

$$\text{Var}_\theta(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Em particular, se T é não viesado para $\tau(\theta)$, então

$$E_\theta(T) = \tau(\theta)$$

e, portanto,

$$\text{Var}_\theta(T) \geq \frac{[\tau'(\theta)]^2}{I_n(\theta)}.$$

No caso especial em que o alvo é o próprio parâmetro,

$$\tau(\theta) = \theta,$$

temos

$$\tau'(\theta) = 1,$$

e o limite assume a forma

$$\text{Var}_\theta(T) \geq \frac{1}{I_n(\theta)}.$$

O termo

$$\frac{[\tau'(\theta)]^2}{I_n(\theta)}$$

é denominado **limite inferior de Cramér–Rao** para a variância de estimadores não viesados de $\tau(\theta)$, sob as condições de regularidade consideradas.

Quanto maior a informação de Fisher, menor pode ser esse limite. Assim, a relação entre informação e precisão aparece diretamente na desigualdade.

i Demonstração — Desigualdade de Cramér–Rao

Considere o escore da amostra,

$$U_n(\theta) = \frac{\partial}{\partial \theta} \log f(\mathbf{X} \mid \theta).$$

Sob as condições de regularidade,

$$E_\theta[U_n(\theta)] = 0$$

e

$$\text{Var}_\theta[U_n(\theta)] = E_\theta[U_n(\theta)^2] = I_n(\theta).$$

Se

$$E_\theta(T) = g(\theta),$$

então

$$g(\theta) = \int T(\mathbf{x}) f(\mathbf{x} \mid \theta) d\mathbf{x}$$

no caso contínuo.

Derivando em relação a θ e utilizando a condição que permite trocar diferenciação e integração,

$$g'(\theta) = \int T(\mathbf{x}) \frac{\partial}{\partial \theta} f(\mathbf{x} \mid \theta) d\mathbf{x}.$$

Como

$$\frac{\partial}{\partial \theta} f(\mathbf{x} \mid \theta) = f(\mathbf{x} \mid \theta) \frac{\partial}{\partial \theta} \log f(\mathbf{x} \mid \theta),$$

segue que

$$\begin{aligned} g'(\theta) &= \int T(\mathbf{x}) f(\mathbf{x} \mid \theta) \frac{\partial}{\partial \theta} \log f(\mathbf{x} \mid \theta) d\mathbf{x} \\ &= E_\theta [T U_n(\theta)]. \end{aligned}$$

No caso discreto, o mesmo argumento é obtido substituindo a integral por uma soma. Como

$$E_{\theta}[U_n(\theta)] = 0,$$

temos

$$\begin{aligned}\text{Cov}_{\theta}(T, U_n(\theta)) &= E_{\theta}[TU_n(\theta)] - E_{\theta}(T)E_{\theta}[U_n(\theta)] \\ &= g'(\theta).\end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\text{Cov}_{\theta}(T, U_n(\theta))^2 \leq \text{Var}_{\theta}(T) \text{Var}_{\theta}(U_n(\theta)).$$

Substituindo

$$\text{Cov}_{\theta}(T, U_n(\theta)) = g'(\theta)$$

e

$$\text{Var}_{\theta}(U_n(\theta)) = I_n(\theta),$$

obtemos

$$[g'(\theta)]^2 \leq \text{Var}_{\theta}(T) I_n(\theta).$$

Como

$$I_n(\theta) > 0,$$

podemos dividir os dois lados por $I_n(\theta)$:

$$\text{Var}_{\theta}(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Essa é a desigualdade de Cramér–Rao.

Um estimador não viesado que atinge o limite de Cramér–Rao para todo θ é denominado **eficiente no sentido de Cramér–Rao**.

Para um estimador não viesado de $\tau(\theta)$, definimos sua eficiência por

$$\text{ef}_{\theta}(T) = \frac{[\tau'(\theta)]^2}{I_n(\theta) \text{Var}_{\theta}(T)}.$$

Pela desigualdade de Cramér–Rao,

$$0 \leq \text{ef}_{\theta}(T) \leq 1.$$

Quando

$$\tau'(\theta) \neq 0$$

e a variância de T é positiva e finita, a eficiência é positiva.

Quando

$$\text{ef}_\theta(T) = 1,$$

o estimador atinge o limite de Cramér–Rao.

 Observações — Alcance do limite de Cramér–Rao

1. O limite estabelece uma restrição inferior para a variância, mas não garante a existência de um estimador que o atinja.
2. Um ENVVUM pode não atingir o limite de Cramér–Rao. Portanto, variância uniformemente mínima entre estimadores não viesados e eficiência de Cramér–Rao são conceitos relacionados, mas não equivalentes.
3. A forma do resultado apresentada nesta seção não deve ser aplicada quando o suporte depende do parâmetro. Em particular,

$$X \sim \text{Unif}(0, \theta)$$

não satisfaz a condição de suporte comum.

4. Se T é viesado e

$$E_\theta(T) = g(\theta),$$

com viés

$$b(\theta) = g(\theta) - \tau(\theta),$$

a desigualdade fornece

$$\text{Var}_\theta(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Consequentemente,

$$\text{EQM}_\theta(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)} + b(\theta)^2.$$

Portanto, não é correto utilizar automaticamente

$$\frac{1}{I_n(\theta)}$$

como limite inferior para o EQM de um estimador viesado.

A formulação geral, a demonstração e as condições do resultado podem ser encontradas em Casella; Berger (2011, teorema 7.3.9), Lauritzen (2023, thm. 4.4), Rice (2007, sec. 8.7) e Rasch; Schott (2018, secs. 1.4 and 2.4.1).

Exemplo — Média de uma distribuição normal com variância conhecida

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida.

Considere

$$T = \bar{X}$$

como estimador de μ . Verifique se sua variância atinge o limite de Cramér–Rao:

1. obtenha a função escore;
2. calcule $I_1(\mu)$ e $I_n(\mu)$;
3. determine o limite de Cramér–Rao;
4. compare esse limite com $\text{Var}_\mu(\bar{X})$.

i Resolução — Eficiência da média no modelo normal

Para uma observação,

$$f(x \mid \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

Portanto,

$$\log f(X \mid \mu) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(X - \mu)^2}{2\sigma^2}.$$

Derivando em relação a μ ,

$$\begin{aligned} U_\mu(X) &= \frac{\partial}{\partial \mu} \log f(X | \mu) \\ &= \frac{X - \mu}{\sigma^2}. \end{aligned}$$

Como

$$E_\mu(X) = \mu,$$

temos

$$E_\mu[U_\mu(X)] = 0.$$

A informação de Fisher de uma observação é

$$\begin{aligned} I_1(\mu) &= E_\mu [U_\mu(X)^2] \\ &= E_\mu \left[\frac{(X - \mu)^2}{\sigma^4} \right] \\ &= \frac{\text{Var}_\mu(X)}{\sigma^4} \\ &= \frac{1}{\sigma^2}. \end{aligned}$$

Como as observações são i.i.d.,

$$I_n(\mu) = nI_1(\mu) = \frac{n}{\sigma^2}.$$

O alvo é

$$\tau(\mu) = \mu,$$

de modo que

$$\tau'(\mu) = 1.$$

Portanto, o limite de Cramér–Rao para qualquer estimador não viesado regular de μ é

$$\frac{[\tau'(\mu)]^2}{I_n(\mu)} = \frac{1}{I_n(\mu)} = \frac{\sigma^2}{n}.$$

A média amostral é não viesada, pois

$$E_\mu(\bar{X}) = \mu.$$

Além disso,

$$\text{Var}_\mu(\bar{X}) = \frac{\sigma^2}{n}.$$

Assim,

$$\text{Var}_\mu(\bar{X}) = \frac{1}{I_n(\mu)}.$$

Logo, $\bar{X}$ atinge exatamente o limite de Cramér–Rao e é eficiente no sentido de Cramér–Rao para μ .

Neste modelo, a média amostral atinge a cota inferior de Cramér–Rao.

Exemplo — Parâmetro de uma distribuição de Poisson

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\theta), \quad \theta > 0.$$

Considere

$$T = \bar{X}$$

como estimador de θ . Verifique:

1. obtenha a função escore;
2. calcule $I_1(\theta)$ e $I_n(\theta)$;
3. determine o limite de Cramér–Rao;
4. verifique se $\bar{X}$ atinge esse limite.

Resolução — Eficiência da média no modelo Poisson

Para uma observação,

$$f(x \mid \theta) = e^{-\theta} \frac{\theta^x}{x!}, \quad x = 0, 1, 2, \dots$$

Logo,

$$\log f(X \mid \theta) = -\theta + X \log \theta - \log(X!).$$

Derivando em relação a θ ,

$$\begin{aligned} U_{\theta}(X) &= \frac{\partial}{\partial \theta} \log f(X | \theta) \\ &= -1 + \frac{X}{\theta}. \end{aligned}$$

Como

$$E_{\theta}(X) = \theta,$$

temos

$$\begin{aligned} E_{\theta}[U_{\theta}(X)] &= -1 + \frac{E_{\theta}(X)}{\theta} \\ &= 0. \end{aligned}$$

A informação de Fisher de uma observação pode ser obtida pela variância do escore:

$$\begin{aligned} I_1(\theta) &= \text{Var}_{\theta} \left(-1 + \frac{X}{\theta} \right) \\ &= \frac{\text{Var}_{\theta}(X)}{\theta^2}. \end{aligned}$$

Como, no modelo Poisson,

$$\text{Var}_{\theta}(X) = \theta,$$

segue que

$$I_1(\theta) = \frac{1}{\theta}.$$

Para uma amostra i.i.d.,

$$I_n(\theta) = nI_1(\theta) = \frac{n}{\theta}.$$

Como o alvo é

$$\tau(\theta) = \theta,$$

temos

$$\tau'(\theta) = 1.$$

Portanto, o limite de Cramér–Rao é

$$\frac{1}{I_n(\theta)} = \frac{\theta}{n}.$$

A média amostral é não viesada:

$$E_{\theta}(\bar{X}) = \theta.$$

Sua variância é

$$\text{Var}_{\theta}(\bar{X}) = \frac{\text{Var}_{\theta}(X)}{n} = \frac{\theta}{n}.$$

Logo,

$$\text{Var}_{\theta}(\bar{X}) = \frac{1}{I_n(\theta)}.$$

Portanto, $\bar{X}$ também atinge exatamente o limite de Cramér–Rao e é eficiente no sentido de Cramér–Rao para θ (Rice, 2007, sec. 8.7; Lauritzen, 2023, thm. 4.4).

💡 Procedimento — Verificação da eficiência de Cramér–Rao

Nos dois exemplos anteriores, a análise seguiu a mesma sequência:

1. obter a função escore;
2. calcular a informação de Fisher;
3. identificar o alvo $\tau(\theta)$ e calcular $\tau'(\theta)$;
4. obter o limite de Cramér–Rao;
5. verificar se o estimador é não viesado;
6. calcular sua variância;
7. comparar a variância com o limite.

Se

$$\text{Var}_{\theta}(T) = \frac{[\tau'(\theta)]^2}{I_n(\theta)},$$

então o estimador atinge o limite e é eficiente no sentido de Cramér–Rao.

Eficiência assintótica

A eficiência de Cramér–Rao estudada anteriormente é uma propriedade de amostra finita: para cada tamanho amostral n , compara-se a variância do estimador com o limite inferior correspondente.

Essa comparação é especialmente informativa quando a distribuição amostral e a variância do estimador podem ser obtidas exatamente. Em muitos problemas, porém, essas quantidades são difíceis de determinar para cada n , ou o estimador não atinge exatamente a cota de Cramér–Rao em amostras finitas.

Em grandes amostras, interessa verificar se o estimador atinge, em primeira ordem, a melhor precisão permitida pelo modelo. Essa propriedade é denominada **eficiência assintótica**.

Consideramos uma sequência de estimadores

$$T_1, T_2, \dots$$

e estudamos sua distribuição quando

$$n \rightarrow \infty.$$

Suponha que T_n estime $\tau(\theta)$ e que

$$\sqrt{n} [T_n - \tau(\theta)] \xrightarrow{d} N(0, V(\theta)).$$

A quantidade

$$V(\theta)$$

é a variância da distribuição normal limite na escala $\sqrt{n}$ e é usualmente denominada **variância assintótica na escala $\sqrt{n}$** .

Ela permite comparar, em grandes amostras, a precisão de estimadores que possuem a mesma taxa de convergência. Quanto menor $V(\theta)$, mais concentrada é a distribuição limite em torno do alvo.

Sob condições adicionais que permitam transferir esse comportamento para os segundos momentos, a variância de T_n possui, em primeira ordem, a escala

$$\frac{V(\theta)}{n}.$$

Em um modelo regular com observações i.i.d.,

$$I_n(\theta) = nI_1(\theta).$$

Para um estimador não viesado de $\tau(\theta)$, a cota de Cramér–Rao é

$$\frac{[\tau'(\theta)]^2}{I_n(\theta)} = \frac{[\tau'(\theta)]^2}{nI_1(\theta)}.$$

Assim, na escala $\sqrt{n}$, a quantidade correspondente ao limite de informação do modelo é

$$\frac{[\tau'(\theta)]^2}{I_1(\theta)}.$$

Nesse contexto, a sequência $\{T_n\}$ é denominada **assintoticamente eficiente** quando sua distribuição limite satisfaz

$$V(\theta) = \frac{[\tau'(\theta)]^2}{I_1(\theta)}.$$

No caso particular em que

$$\tau(\theta) = \theta,$$

temos

$$\tau'(\theta) = 1,$$

e a condição se reduz a

$$V(\theta) = \frac{1}{I_1(\theta)}.$$

A eficiência de Cramér–Rao em amostras finitas e a eficiência assintótica respondem, portanto, a perguntas diferentes.

Na primeira, verifica-se se

$$\text{Var}_\theta(T_n)$$

atinge exatamente a cota de Cramér–Rao para determinado tamanho amostral.

Na segunda, verifica-se se a distribuição limite de

$$\sqrt{n}[T_n - \tau(\theta)]$$

atinge, em primeira ordem, a precisão associada ao limite de informação do modelo regular.

Assim, um estimador pode não atingir a cota de Cramér–Rao para cada tamanho amostral e ainda ser assintoticamente eficiente.

Essa distinção será particularmente útil no estudo dos métodos de estimação pontual. Sob condições de regularidade apropriadas, estimadores de máxima verossimilhança frequentemente

apresentam distribuição assintótica cuja variância coincide com o limite determinado pela informação de Fisher.

Essa conclusão exige condições próprias e não se estende automaticamente a modelos irregulares, parâmetros na fronteira do espaço paramétrico ou situações em que a taxa de convergência difere de $\sqrt{n}$ (Casella; Berger, 2011, def. 10.1.11; Lauritzen, 2023, thm. 5.11).

5.2 Aprofundamento: Princípios de redução de dados

A avaliação anterior partiu de estimadores já construídos e estudou propriedades como viés, variância, erro quadrático médio, consistência e eficiência.

A redução de dados parte da própria amostra e procura identificar se sua informação sobre θ pode ser concentrada em uma estatística de dimensão menor.

Considere uma amostra

$$\mathbf{X} = (X_1, \dots, X_n).$$

Uma estatística

$$T = T(\mathbf{X})$$

é uma função dos dados. Em alguns modelos, conhecer T é suficiente para preservar toda a informação da amostra sobre o parâmetro, de modo que os demais aspectos dos dados não acrescentam informação sobre θ .

Essa ideia fornece uma ligação direta com a avaliação de estimadores. Se um estimador utiliza aspectos da amostra que não acrescentam informação sobre o parâmetro, pode ser possível substituí-lo por uma função de uma estatística suficiente e reduzir sua variabilidade.

A noção que formaliza essa redução é a **suficiência** (Cox, 2006, secs. 2.2 and 4.3.1; Casella; Berger, 2011, chap. 6).

i Recordação — Função de verossimilhança

Em Capítulo 3, para dados observados

$$\mathbf{x} = (x_1, \dots, x_n),$$

a função de verossimilhança foi definida por

$$L(\theta; \mathbf{x}) = f(\mathbf{x} \mid \theta), \quad \theta \in \Theta.$$

Na redução de dados, utilizaremos a verossimilhança para identificar **por meio de quais características de $\mathbf{x}$ ocorre sua dependência em θ** .

Se toda essa dependência puder ser expressa por meio de uma estatística $T(\mathbf{x})$, isso indicará que T pode desempenhar o papel de resumo da informação amostral sobre o parâmetro.

A maximização da verossimilhança possui outra finalidade e será desenvolvida no Capítulo 6.

Estatística suficiente

A definição de suficiência é formulada em termos da distribuição da amostra depois que o valor de uma estatística é conhecido.

! Definição — Suficiência

Uma estatística

$$T = T(\mathbf{X})$$

é **suficiente** para θ se a distribuição condicional de $\mathbf{X}$ dado

$$T = t$$

não depende de θ (Casella; Berger, 2011, def. 6.2.1; Cox, 2006, sec. 2.2; Rice, 2007, sec. 8.8).

A interpretação é a seguinte. Antes de observar T , a distribuição da amostra depende de θ . Depois que o valor

$$T = t$$

é conhecido, se a distribuição condicional da amostra restante já não depende de θ , então os aspectos dos dados que não estão representados por T não acrescentam informação sobre esse parâmetro.

Em outras palavras, a informação da amostra sobre θ foi concentrada em T .

i Observação — Condicionamento quando T é contínua

Quando T possui distribuição contínua, o evento

$$T = t$$

tem probabilidade zero.

Nesse caso, uma construção formal da distribuição condicional exige ferramentas de probabilidade condicional mais avançadas do que as desenvolvidas neste livro.

Nos modelos dominados tratados neste capítulo, não será necessário construir essa distribuição diretamente. O teorema da fatoração de Neyman–Fisher fornecerá uma forma mais conveniente de verificar suficiência a partir da densidade ou função de probabilidade conjunta da amostra (Casella; Berger, 2011, sec. 6.2.1).

⚠ Observação — Suficiência depende do modelo

Suficiência é uma propriedade relativa ao modelo probabilístico considerado.

Uma estatística pode ser suficiente quando determinado parâmetro é o único desconhecido e deixar de ser suficiente se outros parâmetros também forem tratados como desconhecidos ou se a família de distribuições for ampliada.

Portanto, não se deve afirmar simplesmente que uma estatística é suficiente: é necessário especificar **para qual parâmetro e em qual modelo**.

Teorema da fatoração de Neyman–Fisher

A definição de suficiência é conceitualmente simples, mas verificar diretamente uma distribuição condicional pode ser trabalhoso. O teorema da fatoração permite reconhecer suficiência examinando apenas a forma da distribuição conjunta da amostra.

! Teorema — Fatoração de Neyman–Fisher

Considere uma família dominada por uma medida comum, com densidade ou função de probabilidade conjunta

$$f(\mathbf{x} \mid \theta).$$

A estatística $T(\mathbf{X})$ é suficiente para θ se, e somente se, existem funções não negativas g e h tais que

$$f(\mathbf{x} \mid \theta) = g(T(\mathbf{x}) \mid \theta)h(\mathbf{x}),$$

em que $h(\mathbf{x})$ não depende de θ .

A fatoração separa a função conjunta em duas partes:

$$g(T(\mathbf{x}) \mid \theta),$$

que contém toda a dependência simultânea nos dados e no parâmetro, e

$$h(\mathbf{x}),$$

que pode depender da amostra, mas não de θ .

Portanto, se a dependência da distribuição amostral em θ ocorre por meio dos dados somente através de

$$T(\mathbf{x}),$$

então T é suficiente.

Esse é o procedimento mais utilizado para identificar estatísticas suficientes em modelos dominados (Rice, 2007, sec. 8.8.1; Ramachandran; Tsokos, 2021, sec. 5.3.2; Casella; Berger, 2011, sec. 6.2.1).

i Demonstração — Ideia do teorema da fatoração

A ideia central pode ser apresentada diretamente no caso discreto.

Da fatoração para a suficiência

Suponha que

$$f(\mathbf{x} \mid \theta) = g(T(\mathbf{x}) \mid \theta)h(\mathbf{x}).$$

Fixe um valor

$$T = t.$$

Para qualquer $\mathbf{x}$ que satisfaça

$$T(\mathbf{x}) = t,$$

a probabilidade condicional é

$$P_{\theta}(\mathbf{X} = \mathbf{x} \mid T = t) = \frac{P_{\theta}(\mathbf{X} = \mathbf{x})}{P_{\theta}(T = t)}.$$

Pela fatoração, o numerador é

$$P_{\theta}(\mathbf{X} = \mathbf{x}) = g(t \mid \theta)h(\mathbf{x}).$$

O denominador é obtido somando as probabilidades de todos os pontos amostrais $\mathbf{y}$ que satisfazem

$$T(\mathbf{y}) = t :$$

$$P_{\theta}(T = t) = \sum_{\mathbf{y}: T(\mathbf{y})=t} g(t \mid \theta) h(\mathbf{y}).$$

Como $g(t \mid \theta)$ não depende de $\mathbf{y}$,

$$P_{\theta}(T = t) = g(t \mid \theta) \sum_{\mathbf{y}: T(\mathbf{y})=t} h(\mathbf{y}).$$

Portanto,

$$\begin{aligned} P_{\theta}(\mathbf{X} = \mathbf{x} \mid T = t) &= \frac{g(t \mid \theta) h(\mathbf{x})}{g(t \mid \theta) \sum_{\mathbf{y}: T(\mathbf{y})=t} h(\mathbf{y})} \\ &= \frac{h(\mathbf{x})}{\sum_{\mathbf{y}: T(\mathbf{y})=t} h(\mathbf{y})}. \end{aligned}$$

O parâmetro θ desaparece da expressão.

Logo, a distribuição condicional de $\mathbf{X}$ dado $T = t$ não depende de θ e, pela definição, T é suficiente.

Da suficiência para a fatoração

Suponha agora que T seja suficiente.

Defina

$$q(t \mid \theta) = P_{\theta}(T = t).$$

Pela regra do produto,

$$\begin{aligned} f(\mathbf{x} \mid \theta) &= P_{\theta}(\mathbf{X} = \mathbf{x}) \\ &= P_{\theta}(T = T(\mathbf{x})) P_{\theta}(\mathbf{X} = \mathbf{x} \mid T = T(\mathbf{x})). \end{aligned}$$

O primeiro fator pode ser escrito como

$$q(T(\mathbf{x}) \mid \theta).$$

Como T é suficiente, o segundo fator não depende de θ . Portanto, podemos definir

$$g(T(\mathbf{x}) \mid \theta) = q(T(\mathbf{x}) \mid \theta)$$

e

$$h(\mathbf{x}) = P_{\theta}(\mathbf{X} = \mathbf{x} \mid T = T(\mathbf{x})).$$

Embora a última expressão seja escrita com P_{θ} , pela suficiência seu valor não depende de θ .

Assim,

$$f(\mathbf{x} \mid \theta) = g(T(\mathbf{x}) \mid \theta)h(\mathbf{x}).$$

No caso contínuo, o argumento correspondente utiliza densidades condicionais. Para famílias dominadas, essa ideia conduz à forma geral do teorema da fatoração.

Exemplo — Suficiência no modelo Bernoulli

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p), \quad 0 < p < 1.$$

A amostra completa registra não só quantos sucessos ocorreram, mas também **em quais posições** eles apareceram.

Por exemplo, as amostras

$$(1, 0, 1, 0, 0)$$

e

$$(0, 1, 0, 0, 1)$$

são diferentes, mas ambas possuem dois sucessos.

A questão é verificar se, para inferir sobre p , é necessário conservar também a posição dos sucessos ou se o número total de sucessos já concentra toda a informação relevante.

Considere

$$T(\mathbf{X}) = \sum_{i=1}^n X_i.$$

Utilize o teorema da fatoração para verificar se T é suficiente para p .

i Resolução — Aplicação do teorema da fatoração

Como as observações são independentes,

$$f(\mathbf{x} \mid p) = \prod_{i=1}^n f(x_i \mid p).$$

Para uma variável Bernoulli,

$$f(x_i | p) = p^{x_i} (1 - p)^{1-x_i}.$$

Portanto,

$$\begin{aligned} f(\mathbf{x} | p) &= \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}. \end{aligned}$$

Definindo

$$T(\mathbf{X}) = \sum_{i=1}^n X_i,$$

temos

$$T(\mathbf{x}) = \sum_{i=1}^n x_i.$$

Assim, a função de probabilidade conjunta pode ser escrita como

$$f(\mathbf{x} | p) = g(T(\mathbf{x}) | p) h(\mathbf{x}),$$

em que

$$g(t | p) = p^t (1 - p)^{n-t}$$

e, no espaço amostral Bernoulli,

$$h(\mathbf{x}) = 1.$$

Toda a dependência em p ocorre, portanto, por meio de

$$T(\mathbf{x}) = \sum_{i=1}^n x_i.$$

Pelo teorema da fatoração,

$$T(\mathbf{X}) = \sum_{i=1}^n X_i$$

é suficiente para p .

A interpretação é direta: uma vez conhecido o número total de sucessos, saber **em quais posições** eles ocorreram não acrescenta informação sobre p .

Podemos verificar essa conclusão diretamente pela definição de suficiência.

i Verificação — Distribuição condicional dado o total de sucessos

Suponha que

$$T = t.$$

Para qualquer sequência $\mathbf{x}$ com exatamente t sucessos,

$$P_p(\mathbf{X} = \mathbf{x}) = p^t(1-p)^{n-t}.$$

Além disso,

$$T \sim \text{Bin}(n, p),$$

de modo que

$$P_p(T = t) = \binom{n}{t} p^t (1-p)^{n-t}.$$

Portanto,

$$\begin{aligned} P_p(\mathbf{X} = \mathbf{x} \mid T = t) &= \frac{P_p(\mathbf{X} = \mathbf{x})}{P_p(T = t)} \\ &= \frac{p^t(1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \frac{1}{\binom{n}{t}}. \end{aligned}$$

A expressão final não depende de p .

Além disso, todas as

$$\binom{n}{t}$$

sequências com exatamente t sucessos possuem a mesma probabilidade condicional.

Assim, depois de conhecido $T = t$, a disposição dos sucessos e fracassos na amostra não contém informação adicional sobre p . Isso confirma diretamente a suficiência de T .

A suficiência estabelece que determinada estatística preserva a informação da amostra sobre o parâmetro. Ainda permanecem, porém, questões mais refinadas.

Uma estatística suficiente pode conter componentes redundantes. Podemos então perguntar se existe uma redução suficiente ainda menor.

Além disso, determinadas classes de modelos permitem identificar estatísticas suficientes de forma sistemática, e a suficiência pode ser utilizada para construir estimadores com menor variabilidade.

Essas questões conduzem, respectivamente, à **suficiência minimal**, às **famílias exponenciais**, ao **teorema de Rao–Blackwell** e ao **teorema de Lehmann–Scheffé**. Posteriormente, ancilaridade e o teorema de Basu completam essa estrutura.

Suficiência minimal

Uma estatística suficiente preserva toda a informação da amostra sobre o parâmetro. Isso, entretanto, não significa que ela seja a forma mais reduzida possível de representar essa informação.

Por exemplo, se T é suficiente para θ , então a estatística

$$(T, W)$$

também é suficiente para qualquer outra estatística W . O componente W pode, porém, acrescentar dados sem acrescentar informação sobre θ .

A **suficiência minimal** procura eliminar esse tipo de redundância.

! Definição — Estatística suficiente minimal

Uma estatística T é **suficiente minimal** para θ se é suficiente e, para toda estatística suficiente S , existe uma função mensurável r tal que

$$T = r(S)$$

quase certamente, para todo θ .

A condição

$$T = r(S)$$

significa que qualquer estatística suficiente S contém informação suficiente para determinar T .

Assim, uma estatística suficiente minimal representa a informação sobre θ que deve estar presente em **qualquer** outra estatística suficiente.

A palavra *minimal* refere-se, portanto, à informação preservada, e não simplesmente ao número de componentes da estatística.

! Critério — Razão de verossimilhanças

Considere uma família dominada com densidade ou função de probabilidade

$$f(\mathbf{x} \mid \theta).$$

Para pontos $\mathbf{x}$ e $\mathbf{y}$ do espaço amostral efetivo, uma condição suficiente para que T seja suficiente minimal é que

$$T(\mathbf{x}) = T(\mathbf{y})$$

se, e somente se, exista uma constante

$$c(\mathbf{x}, \mathbf{y}) > 0,$$

independente de θ , tal que

$$f(\mathbf{x} \mid \theta) = c(\mathbf{x}, \mathbf{y})f(\mathbf{y} \mid \theta)$$

para todo θ .

Quando o quociente

$$\frac{f(\mathbf{x} \mid \theta)}{f(\mathbf{y} \mid \theta)}$$

está bem definido, o critério pode ser expresso de forma equivalente:

$$\frac{f(\mathbf{x} \mid \theta)}{f(\mathbf{y} \mid \theta)}$$

é independente de θ se, e somente se,

$$T(\mathbf{x}) = T(\mathbf{y}).$$

(Casella; Berger, 2011, sec. 6.2.2; Ramachandran; Tsokos, 2009, sec. 5.5.3)

O critério compara dois pontos amostrais e pergunta se suas verossimilhanças possuem **a mesma dependência em θ** .

Se isso acontece exatamente quando os dois pontos produzem o mesmo valor de T , então T reúne em uma mesma classe precisamente as amostras que são indistinguíveis quanto à forma como informam sobre θ .

i Demonstração — Ideia do critério de suficiência minimal

A demonstração possui duas partes: primeiro verificamos que o critério produz uma estatística suficiente; depois mostramos por que essa estatística é minimal.

Suficiência

Fixe um valor t da estatística T e escolha um representante

$$\mathbf{x}_t$$

entre os pontos amostrais que satisfazem

$$T(\mathbf{x}) = t.$$

Se

$$T(\mathbf{x}) = t,$$

então

$$T(\mathbf{x}) = T(\mathbf{x}_t).$$

Pelo critério, existe uma constante

$$c(\mathbf{x}, \mathbf{x}_t) > 0,$$

que não depende de θ , tal que

$$f(\mathbf{x} \mid \theta) = c(\mathbf{x}, \mathbf{x}_t)f(\mathbf{x}_t \mid \theta).$$

Defina

$$h(\mathbf{x}) = c(\mathbf{x}, \mathbf{x}_t)$$

e

$$g(t \mid \theta) = f(\mathbf{x}_t \mid \theta).$$

Então,

$$f(\mathbf{x} \mid \theta) = g(T(\mathbf{x}) \mid \theta)h(\mathbf{x}).$$

O fator

$$h(\mathbf{x})$$

não depende de θ . Portanto, pelo teorema da fatoração de Neyman–Fisher, T é suficiente.

Minimalidade

Considere agora qualquer outra estatística suficiente S .

Se

$$S(\mathbf{x}) = S(\mathbf{y}),$$

a fatoração associada a S implica que as verossimilhanças de $\mathbf{x}$ e $\mathbf{y}$ possuem a mesma dependência em θ . Em outras palavras, elas são proporcionais por um fator que não depende do parâmetro.

Pelo critério da razão de verossimilhanças,

$$T(\mathbf{x}) = T(\mathbf{y}).$$

Portanto, sempre que dois pontos possuem o mesmo valor de S , também possuem o mesmo valor de T .

Isso significa que T é constante em cada conjunto de nível de S . Consequentemente, existe uma função r tal que

$$T = r(S).$$

Logo, qualquer estatística suficiente determina T , caracterizando a suficiência minimal. O argumento acima apresenta a ideia do resultado. Uma formulação completa exige cuidados adicionais com conjuntos nulos e mensurabilidade.

Exemplo — Suficiência minimal no modelo Bernoulli

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p), \quad 0 < p < 1.$$

No modelo Bernoulli,

$$T(\mathbf{X}) = \sum_{i=1}^n X_i$$

já foi identificada como estatística suficiente para p .

O próximo passo é verificar se o total de sucessos também é suficiente minimal.

Considere dois pontos amostrais

$$\mathbf{x} = (x_1, \dots, x_n)$$

e

$$\mathbf{y} = (y_1, \dots, y_n).$$

Utilize o critério da razão de verossimilhanças.

i Resolução — Suficiência minimal no modelo Bernoulli

Para o modelo Bernoulli,

$$f(\mathbf{x} \mid p) = p^{\sum_i x_i} (1 - p)^{n - \sum_i x_i}.$$

Da mesma forma,

$$f(\mathbf{y} \mid p) = p^{\sum_i y_i} (1 - p)^{n - \sum_i y_i}.$$

Como

$$0 < p < 1,$$

essas probabilidades são positivas para todos os pontos do espaço amostral, e podemos formar o quociente:

$$\begin{aligned} \frac{f(\mathbf{x} \mid p)}{f(\mathbf{y} \mid p)} &= \frac{p^{\sum_i x_i} (1 - p)^{n - \sum_i x_i}}{p^{\sum_i y_i} (1 - p)^{n - \sum_i y_i}} \\ &= \left(\frac{p}{1 - p} \right)^{\sum_i x_i - \sum_i y_i}. \end{aligned}$$

Se

$$\sum_{i=1}^n x_i = \sum_{i=1}^n y_i,$$

o expoente é zero e

$$\frac{f(\mathbf{x} \mid p)}{f(\mathbf{y} \mid p)} = 1,$$

que não depende de p .

Se, por outro lado,

$$\sum_{i=1}^n x_i \neq \sum_{i=1}^n y_i,$$

o quociente contém o fator

$$\left(\frac{p}{1-p}\right)^c, \quad c \neq 0,$$

e depende de p .

Portanto,

$$\frac{f(\mathbf{x} \mid p)}{f(\mathbf{y} \mid p)}$$

é independente de p se, e somente se,

$$\sum_{i=1}^n x_i = \sum_{i=1}^n y_i.$$

Mas essa igualdade equivale a

$$T(\mathbf{x}) = T(\mathbf{y}).$$

Pelo critério da razão de verossimilhanças,

$$T(\mathbf{X}) = \sum_{i=1}^n X_i$$

é suficiente minimal para p .

O resultado complementa a análise anterior. O total de sucessos preserva toda a informação sobre p e elimina a informação redundante associada às posições em que os sucessos ocorreram.

Exemplo — Suficiência minimal no modelo uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0.$$

No espaço amostral efetivo, considere amostras com valores não negativos.

Verifique se

$$T(\mathbf{X}) = X_{(n)}$$

é suficiente minimal para θ .

Este exemplo exige um cuidado adicional: dependendo do valor de θ , a verossimilhança de uma das amostras pode ser zero. Por isso, utilizaremos a forma do critério baseada em **proporcionalidade**, em vez de dividir diretamente duas verossimilhanças.

i Resolução — Suficiência minimal no modelo uniforme

Para uma amostra $\mathbf{x}$ com valores não negativos,

$$f(\mathbf{x} \mid \theta) = \theta^{-n} \mathbf{1} \{x_{(n)} \leq \theta\}.$$

Considere duas amostras

$$\mathbf{x} \quad \text{e} \quad \mathbf{y}.$$

Caso 1 — Os máximos são iguais

Se

$$x_{(n)} = y_{(n)},$$

então

$$\mathbf{1} \{x_{(n)} \leq \theta\} = \mathbf{1} \{y_{(n)} \leq \theta\}$$

para todo θ .

Consequentemente,

$$f(\mathbf{x} \mid \theta) = f(\mathbf{y} \mid \theta)$$

para todo θ .

As duas verossimilhanças são, portanto, proporcionais com constante

$$c(\mathbf{x}, \mathbf{y}) = 1,$$

independente de θ .

Caso 2 — Os máximos são diferentes

Suponha, sem perda de generalidade, que

$$x_{(n)} < y_{(n)}.$$

Podemos escolher um valor de θ tal que

$$x_{(n)} < \theta < y_{(n)}.$$

Para esse valor,

$$x_{(n)} \leq \theta,$$

e portanto

$$f(\mathbf{x} \mid \theta) = \theta^{-n} > 0.$$

Por outro lado,

$$y_{(n)} > \theta,$$

de modo que

$$f(\mathbf{y} \mid \theta) = 0.$$

Não pode existir uma constante positiva

$$c(\mathbf{x}, \mathbf{y})$$

independente de θ que satisfaça

$$f(\mathbf{x} \mid \theta) = c(\mathbf{x}, \mathbf{y})f(\mathbf{y} \mid \theta)$$

para todo θ .

Assim, as verossimilhanças são proporcionais por uma constante positiva independente de θ se, e somente se,

$$x_{(n)} = y_{(n)}.$$

Essa condição equivale a

$$T(\mathbf{x}) = T(\mathbf{y}).$$

Pelo critério da razão de verossimilhanças,

$$T(\mathbf{X}) = X_{(n)}$$

é suficiente minimal para θ (Ramachandran; Tsokos, 2009, sec. 5.5.3; Casella; Berger, 2011, sec. 6.2.2).

O exemplo também mostra por que a formulação por proporcionalidade é mais geral que o uso direto do quociente de verossimilhanças: quando uma das verossimilhanças pode ser zero, o quociente pode não estar definido.

Famílias exponenciais

Nos exemplos anteriores, identificamos estatísticas suficientes examinando separadamente a distribuição conjunta ou a verossimilhança de cada modelo.

Entretanto, existe uma classe ampla de distribuições em que essa estrutura aparece de forma sistemática: as **famílias exponenciais**.

Sua importância para redução de dados decorre do fato de que a dependência da distribuição em relação ao parâmetro pode ser concentrada em determinadas funções das observações. Para uma amostra i.i.d., essas funções originam naturalmente uma estatística suficiente cuja dimensão não cresce com o tamanho da amostra.

! Definição — Forma exponencial canônica

Uma família de distribuições possui forma exponencial k -paramétrica quando sua densidade ou função de probabilidade pode ser escrita como

$$f(x \mid \eta) = h(x) \exp \{ \eta^\top t(x) - A(\eta) \},$$

em que

$$\eta \in \mathcal{H} \subseteq \mathbb{R}^k$$

é o **parâmetro natural**,

$$t(x)$$

é a **estatística canônica de uma observação**,

$$h(x)$$

não depende de η , e o suporte da distribuição não depende do parâmetro natural.

A expressão pode ser lida separando quatro componentes:

- η contém os parâmetros naturais;
- $t(x)$ contém as funções dos dados que interagem diretamente com esses parâmetros;
- $h(x)$ reúne os termos que dependem apenas da observação;
- $A(\eta)$ garante a normalização da distribuição.

No caso contínuo, a condição

$$\int f(x \mid \eta) dx = 1$$

implica

$$\exp\{A(\eta)\} = \int h(x) \exp \{ \eta^\top t(x) \} dx.$$

Portanto,

$$A(\eta) = \log \int h(x) \exp \{ \eta^\top t(x) \} dx,$$

quando a integral é finita.

No caso discreto, a integral é substituída pela soma correspondente.

O conjunto dos valores de η para os quais essa normalização é finita constitui o **espaço natural de parâmetros**,

$$\mathcal{H}.$$

Quando $\mathcal{H}$ é aberto em $\mathbb{R}^k$, a família exponencial é denominada **regular**.

Uma subfamília pode impor relações entre os componentes de η e restringir o parâmetro natural a um conjunto de dimensão menor. Essas **famílias exponenciais curvas** exigem cuidados adicionais, especialmente em resultados de completude que dependem da dimensão do espaço natural.

! Resultado — Estatística suficiente em uma família exponencial

Considere uma amostra i.i.d.

$$X_1, \dots, X_n$$

de uma distribuição cuja densidade ou função de probabilidade possui a forma

$$f(x \mid \eta) = h(x) \exp \{ \eta^\top t(x) - A(\eta) \}.$$

Então,

$$T(\mathbf{X}) = \sum_{i=1}^n t(X_i)$$

é suficiente para η .

i Demonstração — Suficiência pela forma exponencial

Como as observações são independentes, a densidade ou função de probabilidade conjunta é

$$f(\mathbf{x} \mid \eta) = \prod_{i=1}^n f(x_i \mid \eta).$$

Substituindo a forma exponencial,

$$\begin{aligned} f(\mathbf{x} \mid \eta) &= \prod_{i=1}^n h(x_i) \exp \{ \eta^\top t(x_i) - A(\eta) \} \\ &= \left[\prod_{i=1}^n h(x_i) \right] \exp \left\{ \sum_{i=1}^n [\eta^\top t(x_i) - A(\eta)] \right\}. \end{aligned}$$

Como $A(\eta)$ não depende de i ,

$$\sum_{i=1}^n A(\eta) = nA(\eta).$$

Além disso,

$$\sum_{i=1}^n \eta^\top t(x_i) = \eta^\top \sum_{i=1}^n t(x_i).$$

Portanto,

$$f(\mathbf{x} \mid \eta) = \left[\prod_{i=1}^n h(x_i) \right] \exp \left\{ \eta^\top \sum_{i=1}^n t(x_i) - nA(\eta) \right\}.$$

Defina

$$T(\mathbf{X}) = \sum_{i=1}^n t(X_i).$$

Então podemos escrever

$$f(\mathbf{x} \mid \eta) = g(T(\mathbf{x}) \mid \eta) h_n(\mathbf{x}),$$

em que

$$g(t \mid \eta) = \exp \{ \eta^\top t - nA(\eta) \}$$

e

$$h_n(\mathbf{x}) = \prod_{i=1}^n h(x_i).$$

O fator $h_n(\mathbf{x})$ não depende de η , e toda a dependência simultânea nos dados e no parâmetro ocorre por meio de

$$T(\mathbf{x}).$$

Pelo teorema da fatoração de Neyman–Fisher,

$$T(\mathbf{X}) = \sum_{i=1}^n t(X_i)$$

é suficiente para η .

i Interpretação — Redução de dimensão

A amostra original contém

$$n$$

observações. Na representação exponencial canônica, a estatística suficiente

$$T(\mathbf{X})$$

possui k componentes, correspondentes aos componentes de $t(x)$.

Assim, para k fixado, a dimensão dessa estatística não aumenta com n .

Essa é uma das razões para a importância das famílias exponenciais em inferência: a estrutura do modelo identifica diretamente quais combinações das observações concentram a dependência da amostra no parâmetro.

Exemplo — Modelo Bernoulli

Retomemos

$$X \sim \text{Ber}(p), \quad 0 < p < 1.$$

A representação exponencial do modelo conduz à mesma estatística suficiente obtida pelo teorema da fatoração.

Identifique:

1. o parâmetro natural;
2. a estatística canônica de uma observação;
3. a estatística suficiente resultante para uma amostra.

i Resolução — Forma exponencial do modelo Bernoulli

A função de probabilidade de uma observação é

$$f(x | p) = p^x (1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

Podemos reorganizá-la como

$$\begin{aligned}
f(x | p) &= p^x(1-p)^{1-x} \\
&= \exp \{x \log p + (1-x) \log(1-p)\} \\
&= \exp \left\{ x \log \left(\frac{p}{1-p} \right) + \log(1-p) \right\}.
\end{aligned}$$

A expressão que multiplica x sugere definir o parâmetro natural

$$\eta = \log \left(\frac{p}{1-p} \right).$$

Como

$$0 < p < 1,$$

temos

$$\eta \in \mathbb{R}.$$

Resolvendo a relação anterior para p ,

$$p = \frac{e^\eta}{1 + e^\eta}.$$

Consequentemente,

$$1 - p = \frac{1}{1 + e^\eta}.$$

Logo,

$$\log(1-p) = -\log(1+e^\eta).$$

A função de probabilidade pode então ser escrita como

$$f(x | \eta) = \exp \{ \eta x - \log(1 + e^\eta) \}.$$

Comparando com a forma canônica

$$f(x | \eta) = h(x) \exp \{ \eta t(x) - A(\eta) \},$$

identificamos

$$h(x) = 1,$$

$$t(x) = x$$

e

$$A(\eta) = \log(1 + e^\eta).$$

Para uma amostra i.i.d., a estatística canônica suficiente é

$$T(\mathbf{X}) = \sum_{i=1}^n X_i.$$

Portanto, a estrutura exponencial recupera exatamente o **número total de sucessos** como estatística suficiente para p .

O teorema da fatoração também conduz a essa estatística suficiente. Na representação exponencial, ela é identificada diretamente a partir de

$$t(x) = x.$$

Exemplo — Modelo Poisson

Considere

$$X \sim \text{Poisson}(\lambda), \quad \lambda > 0.$$

Identifique:

1. o parâmetro natural;
2. a estatística canônica de uma observação;
3. a função $A(\eta)$;
4. a estatística suficiente correspondente a uma amostra.

i Resolução — Forma exponencial do modelo Poisson

A função de probabilidade é

$$f(x \mid \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

Reescrevendo,

$$\begin{aligned} f(x \mid \lambda) &= \frac{e^{-\lambda} \lambda^x}{x!} \\ &= \frac{1}{x!} \exp \{x \log \lambda - \lambda\}. \end{aligned}$$

Defina

$$\eta = \log \lambda.$$

Como

$$\lambda > 0,$$

temos

$$\eta \in \mathbb{R}.$$

Além disso,

$$\lambda = e^\eta.$$

Substituindo,

$$f(x \mid \eta) = \frac{1}{x!} \exp \{ \eta x - e^\eta \}.$$

Comparando com a forma canônica,

$$f(x \mid \eta) = h(x) \exp \{ \eta t(x) - A(\eta) \},$$

identificamos

$$h(x) = \frac{1}{x!},$$

$$t(x) = x$$

e

$$A(\eta) = e^\eta.$$

Para uma amostra i.i.d., a estatística canônica suficiente é

$$T(\mathbf{X}) = \sum_{i=1}^n X_i.$$

Como

$$\lambda = e^\eta$$

estabelece uma correspondência biunívoca entre $\lambda > 0$ e $\eta \in \mathbb{R}$, a mesma estatística é suficiente para λ .

Bernoulli e Poisson são modelos diferentes, mas ambos apresentam

$$t(x) = x.$$

Por isso, nos dois casos, a estatística canônica suficiente para uma amostra é a soma das observações.

i Verificação — Modelo geométrico como família exponencial

Considere a parametrização geométrica

$$f(x | p) = p(1 - p)^{x-1}, \quad x = 1, 2, \dots, \quad 0 < p < 1.$$

Escreva a função de probabilidade na forma exponencial canônica.

Defina

$$\eta = \log(1 - p).$$

Como

$$0 < 1 - p < 1,$$

segue que

$$\eta < 0.$$

Além disso,

$$1 - p = e^\eta$$

e, portanto,

$$p = 1 - e^\eta.$$

Substituindo na função de probabilidade,

$$\begin{aligned} f(x | \eta) &= (1 - e^\eta)(e^\eta)^{x-1} \\ &= (1 - e^\eta)e^{\eta(x-1)} \\ &= \exp \{ \eta(x - 1) + \log(1 - e^\eta) \}. \end{aligned}$$

Assim,

$$f(x | \eta) = \exp \{ \eta t(x) - A(\eta) \},$$

com

$$t(x) = x - 1$$

e

$$A(\eta) = -\log(1 - e^\eta).$$

O espaço natural de parâmetros é

$$\mathcal{H} = (-\infty, 0),$$

que é um conjunto aberto em $\mathbb{R}$.

Para uma amostra i.i.d., a estatística canônica suficiente é

$$T(\mathbf{X}) = \sum_{i=1}^n (X_i - 1).$$

Como

$$\sum_{i=1}^n (X_i - 1) = \sum_{i=1}^n X_i - n$$

e n é fixado, conhecer uma dessas estatísticas determina exatamente a outra. Portanto,

$$\sum_{i=1}^n (X_i - 1)$$

e

$$\sum_{i=1}^n X_i$$

são representações equivalentes da mesma redução dos dados.

Exemplo — Modelo normal com média e variância desconhecidas

Considere

$$X \sim N(\mu, \sigma^2), \quad \mu \in \mathbb{R}, \quad \sigma^2 > 0,$$

com ambos os parâmetros desconhecidos.

Este exemplo difere dos anteriores porque o modelo possui **dois parâmetros desconhecidos**. Consequentemente, sua representação exponencial envolverá um vetor de parâmetros naturais e uma estatística canônica com dois componentes.

Identifique:

1. a estatística canônica de uma observação;
2. os parâmetros naturais;
3. o espaço natural de parâmetros;
4. uma estatística suficiente para (μ, σ^2) ;
5. uma representação equivalente em termos de $\bar{X}$ e S^2 .

i Resolução — Forma exponencial do modelo normal

A densidade de uma observação é

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}, \quad x \in \mathbb{R}.$$

Expandindo o termo quadrático,

$$-\frac{(x - \mu)^2}{2\sigma^2} = -\frac{x^2}{2\sigma^2} + \frac{\mu}{\sigma^2}x - \frac{\mu^2}{2\sigma^2}.$$

Portanto,

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ \frac{\mu}{\sigma^2}x - \frac{1}{2\sigma^2}x^2 - \frac{\mu^2}{2\sigma^2} \right\}.$$

Os termos envolvendo simultaneamente os dados e os parâmetros são

$$\frac{\mu}{\sigma^2}x$$

e

$$-\frac{1}{2\sigma^2}x^2.$$

Assim, podemos definir

$$t(x) = \begin{pmatrix} x \\ x^2 \end{pmatrix}$$

e o vetor de parâmetros naturais

$$\eta = \begin{pmatrix} \eta_1 \\ \eta_2 \end{pmatrix},$$

com

$$\eta_1 = \frac{\mu}{\sigma^2}$$

e

$$\eta_2 = -\frac{1}{2\sigma^2}.$$

Como

$$\mu \in \mathbb{R}$$

e

$$\sigma^2 > 0,$$

temos

$$\eta_1 \in \mathbb{R} \quad \text{e} \quad \eta_2 < 0.$$

Portanto, o espaço natural de parâmetros é

$$\mathcal{H} = \{(\eta_1, \eta_2) \in \mathbb{R}^2 : \eta_2 < 0\}.$$

Esse conjunto é aberto em $\mathbb{R}^2$, de modo que o modelo normal com média e variância desconhecidas constitui uma família exponencial regular de dimensão 2.

Para uma amostra i.i.d., a estatística canônica suficiente é

$$T(\mathbf{X}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right).$$

Assim, embora a amostra contenha n observações, toda a dependência da distribuição conjunta em (μ, σ^2) pode ser concentrada em duas quantidades.

Para $n \geq 2$, podemos representar a mesma informação por

$$(\bar{X}, S^2).$$

De fato,

$$\sum_{i=1}^n X_i = n\bar{X}$$

e, pela identidade de decomposição da soma de quadrados,

$$\sum_{i=1}^n X_i^2 = (n-1)S^2 + n\bar{X}^2.$$

Logo, conhecer

$$(\bar{X}, S^2)$$

permite determinar

$$\left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right).$$

Reciprocamente,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

e

$$S^2 = \frac{1}{n-1} \left[\sum_{i=1}^n X_i^2 - \frac{1}{n} \left(\sum_{i=1}^n X_i \right)^2 \right].$$

Portanto, as duas representações determinam uma à outra e contêm a mesma informação sobre (μ, σ^2) .

Verificação — Identificação da forma exponencial

O logaritmo da densidade é

$$\begin{aligned} \log f(x \mid \mu, \sigma^2) = & -\frac{1}{2} \log(2\pi\sigma^2) \\ & - \frac{(x - \mu)^2}{2\sigma^2}. \end{aligned}$$

Expandindo,

$$\begin{aligned} \log f(x \mid \mu, \sigma^2) = & \frac{\mu}{\sigma^2} x - \frac{1}{2\sigma^2} x^2 \\ & - \frac{\mu^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2). \end{aligned}$$

Os únicos termos que envolvem x são

$$\frac{\mu}{\sigma^2} x$$

e

$$-\frac{1}{2\sigma^2} x^2.$$

Isso identifica diretamente

$$t_1(x) = x \quad \text{e} \quad t_2(x) = x^2,$$

com parâmetros naturais

$$\eta_1 = \frac{\mu}{\sigma^2} \quad \text{e} \quad \eta_2 = -\frac{1}{2\sigma^2}.$$

Os demais termos dependem dos parâmetros, mas não de x , e são incorporados à função de normalização $A(\eta)$.

Os exemplos mostram que a forma exponencial pode produzir estatísticas suficientes de dimensão fixa mesmo quando o tamanho da amostra aumenta.

Isso não significa, entretanto, que uma distribuição precise pertencer a uma família exponencial regular para admitir redução suficiente.

O modelo

$$\text{Unif}(0, \theta)$$

é um exemplo importante. Como seu suporte depende de θ , ele não possui a forma exponencial regular definida nesta seção. Ainda assim,

$$X_{(n)}$$

é suficiente e suficiente minimal para θ .

A vantagem das famílias exponenciais é que sua própria estrutura fornece um procedimento sistemático para identificar estatísticas suficientes.

Além disso, sob condições adicionais sobre o espaço natural de parâmetros, a estatística canônica pode apresentar uma propriedade ainda mais forte: a **completude**.

A apresentação de famílias exponenciais e de suas estatísticas canônicas segue Lauritzen (2023, chap. 3) e Ramachandran; Tsokos (2021, sec. 5.3.2).

Completude

A suficiência responde se uma estatística preserva toda a informação da amostra sobre o parâmetro. Ela não garante, entretanto, que uma função não viesada dessa estatística seja única.

Para entender essa diferença, suponha que duas funções de uma estatística suficiente T ,

$$\phi_1(T) \quad \text{e} \quad \phi_2(T),$$

sejam não viesadas para o mesmo alvo $\tau(\theta)$. Então

$$E_\theta[\phi_1(T)] = \tau(\theta)$$

e

$$E_\theta[\phi_2(T)] = \tau(\theta).$$

Subtraindo,

$$E_{\theta} [\phi_1(T) - \phi_2(T)] = 0$$

para todo θ .

Se a família de distribuições de T possui a propriedade de que **nenhuma função não nula de T pode ter esperança zero para todos os valores do parâmetro**, então necessariamente

$$\phi_1(T) - \phi_2(T) = 0$$

quase certamente.

Nesse caso,

$$\phi_1(T) = \phi_2(T)$$

quase certamente.

Essa propriedade de unicidade é denominada **completude**.

! Definição — Completude

Uma estatística T é **completa** para a família

$$\{P_{\theta} : \theta \in \Theta\}$$

se, para toda função mensurável a tal que

$$E_{\theta}|a(T)| < \infty,$$

a condição

$$E_{\theta}[a(T)] = 0 \quad \text{para todo } \theta \in \Theta$$

implica

$$P_{\theta}(a(T) = 0) = 1 \quad \text{para todo } \theta \in \Theta.$$

Essa é a definição usual de completude para a família de distribuições induzida por T (Bickel; Doksum, 2016, def. 8.2.2; Casella; Berger, 2011, sec. 6.2.4).

A definição deve ser lida com atenção. Não basta que

$$E_{\theta}[a(T)] = 0$$

para um valor particular de θ . A igualdade precisa valer para **todos os valores do parâmetro** no espaço paramétrico.

A completude então força

$$a(T) = 0$$

quase certamente.

Por isso, completude será útil para garantir a **unicidade** de estimadores não viesados que são funções de uma estatística suficiente.

! Teorema — Completude em famílias exponenciais

Considere uma família exponencial na forma canônica

$$f(x \mid \eta) = h(x) \exp \{ \eta^{\top} t(x) - A(\eta) \},$$

e, para uma amostra i.i.d., a estatística canônica

$$T(\mathbf{X}) = \sum_{i=1}^n t(X_i).$$

Se o espaço natural de parâmetros contém um conjunto aberto não vazio de $\mathbb{R}^k$, então T é completa para a família.

Esse resultado fornece uma **condição suficiente** para completude. Reconhecer uma distribuição como pertencente a uma família exponencial não é suficiente, por si só, para concluir que sua estatística canônica é completa. A condição sobre o espaço natural de parâmetros também precisa ser verificada (Casella; Berger, 2011, thm. 6.2.25; Lauritzen, 2023, chap. 3; Bickel; Doksum, 2016, sec. 8.2).

i Ideia da demonstração — Completude em famílias exponenciais

A demonstração geral utiliza um resultado de unicidade para transformadas de Laplace e não será desenvolvida integralmente aqui. Essa é também a estratégia utilizada por Casella e Berger na apresentação do resultado (Casella; Berger, 2011, teorema 6.2.25). Considere uma função a da estatística canônica

$$T = \sum_{i=1}^n t(X_i)$$

e suponha que

$$E_{\eta}[a(T)] = 0$$

para todo η no espaço natural de parâmetros.

A distribuição de T herda a estrutura exponencial do modelo. Por isso, a esperança anterior pode ser expressa como uma transformada envolvendo

$$a(T)$$

e o parâmetro natural η .

Quando o espaço natural contém um conjunto aberto, o teorema de unicidade dessa transformada implica que uma transformada identicamente nula só pode ocorrer quando

$$a(T) = 0$$

quase certamente.

Esse é o mecanismo matemático que produz a completude.

A condição sobre o espaço natural é essencial: é necessário dispor de uma região suficientemente rica de valores de η para que o resultado de unicidade possa ser aplicado.

No modelo Poisson, essa ideia pode ser verificada diretamente sem recorrer à teoria geral de transformadas.

i Demonstração direta — Completude no modelo Poisson

Considere uma amostra

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda), \quad \lambda > 0.$$

Como a soma de variáveis Poisson independentes também possui distribuição Poisson,

$$T = \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda).$$

A completude de T pode ser verificada diretamente.

Suponha que uma função a satisfaça

$$E_{\lambda}[a(T)] = 0$$

para todo $\lambda > 0$.

Utilizando a função de probabilidade de T ,

$$\sum_{t=0}^{\infty} a(t) e^{-n\lambda} \frac{(n\lambda)^t}{t!} = 0$$

para todo $\lambda > 0$.

Como

$$e^{n\lambda} > 0,$$

podemos multiplicar os dois lados por esse fator:

$$\sum_{t=0}^{\infty} a(t) \frac{(n\lambda)^t}{t!} = 0$$

para todo $\lambda > 0$.

O lado esquerdo é uma série de potências em λ que é identicamente nula em um intervalo aberto.

Pela unicidade dos coeficientes de uma série de potências, todos os coeficientes devem ser nulos. Portanto,

$$a(t) \frac{n^t}{t!} = 0, \quad t = 0, 1, 2, \dots$$

e, como

$$\frac{n^t}{t!} > 0,$$

segue que

$$a(t) = 0, \quad t = 0, 1, 2, \dots$$

Logo,

$$P_{\lambda}(a(T) = 0) = 1$$

para todo $\lambda > 0$.

Portanto, T é completa.

O argumento mostra concretamente o significado da definição: não existe uma função não trivial de T cuja esperança seja zero para todos os valores de λ .

Observação — Completude e espaço paramétrico

A completude é uma propriedade da **família de distribuições considerada**, incluindo seu espaço paramétrico.

Portanto, ela não depende somente da expressão funcional da densidade ou da função de probabilidade.

Uma restrição do espaço paramétrico pode destruir a completude de uma família que era completa no espaço original. Em particular, antes de utilizar o teorema anterior para uma família exponencial, é necessário verificar se o espaço do parâmetro natural contém

um conjunto aberto não vazio de $\mathbb{R}^k$.

Essa conclusão também não deve ser transferida automaticamente para famílias exponenciais curvas. Nelas, o parâmetro natural pode estar restrito a um subconjunto de dimensão menor e, portanto, não conter um conjunto aberto de $\mathbb{R}^k$ (Bickel; Doksum, 2016, sec. 8.2; Lauritzen, 2023, sec. 3.6).

A suficiência e a completude desempenham papéis diferentes:

- **suficiência** está relacionada à preservação da informação da amostra sobre o parâmetro;
- **completude** está relacionada à unicidade de funções não viesadas de uma estatística.

A combinação das duas propriedades permite identificar estimadores não viesados de variância uniformemente mínima.

Estimadores não viesados de variância uniformemente mínima

A eficiência relativa permite comparar dois estimadores escolhidos previamente. Uma questão mais forte consiste em comparar um estimador com **todos os estimadores não viesados do mesmo alvo**.

Essa ideia conduz ao estimador não viesado de variância uniformemente mínima.

! Definição — ENVVUM

Um estimador não viesado W_{ENVVUM} de $\tau(\theta)$, com variância finita para todo $\theta \in \Theta$, é denominado **estimador não viesado de variância uniformemente mínima** (ENVVUM; em inglês, UMVU) quando

$$\text{Var}_{\theta}(W_{\text{ENVVUM}}) \leq \text{Var}_{\theta}(W)$$

para todo

$$\theta \in \Theta$$

e para todo estimador não viesado W de $\tau(\theta)$ com variância finita (Casella; Berger, 2011, def. 7.3.7; Bickel; Doksum, 2016, sec. 8.2.3; Rasch; Schott, 2018, sec. 2.4).

A palavra **uniformemente** indica que a desigualdade deve valer para todos os valores de θ , e não apenas para um valor particular do parâmetro.

Assim, um ENVVUM possui, em cada ponto do espaço paramétrico, variância não superior à de qualquer outro estimador não viesado do mesmo alvo.

A definição estabelece o objetivo, mas não mostra diretamente como encontrar tal estimador.

A primeira ferramenta para isso é o teorema de Rao–Blackwell: a partir de um estimador inicial, podemos condicioná-lo em uma estatística suficiente e obter um novo estimador que preserva sua esperança e não aumenta seu EQM.

Teorema de Rao–Blackwell

Considere uma estatística suficiente

$$T = T(\mathbf{X})$$

para θ e um estimador inicial

$$W = W(\mathbf{X})$$

de $\tau(\theta)$.

A ideia de Rao–Blackwell é substituir W por sua esperança condicional dado T .

! Teorema — Rao–Blackwell

Seja T uma estatística suficiente para θ e seja $W(\mathbf{X})$ um estimador de $\tau(\theta)$ com segundo momento finito.

Defina

$$W^*(T) = E_\theta[W(\mathbf{X}) \mid T].$$

A suficiência garante que se pode escolher uma versão dessa esperança condicional que seja função apenas de T , sem depender do valor desconhecido de θ .

Então,

$$E_\theta[W^*(T)] = E_\theta(W)$$

e

$$\text{EQM}_\theta(W^*) \leq \text{EQM}_\theta(W).$$

Para cada θ , a igualdade ocorre se, e somente se,

$$\text{Var}_\theta(W \mid T) = 0$$

P_θ -quase certamente.

Equivalentemente,

$$W = E_\theta(W \mid T)$$

P_θ -quase certamente.

Assim, não existe melhoria estrita quando W já é, a menos de equivalência quase certa, uma função de T (Rice, 2007, sec. 8.8.2; Bickel; Doksum, 2016, thm. 8.2.6).

O resultado possui duas consequências principais.

Primeiro, W e W^* têm a mesma esperança. Portanto, Rao–Blackwell não altera o viés do estimador.

Segundo, o condicionamento em T não aumenta sua variabilidade. A diferença entre os dois EQMs pode ser escrita como

$$\text{EQM}_\theta(W) = \text{EQM}_\theta(W^*) + E_\theta [\text{Var}_\theta(W \mid T)].$$

Como

$$E_\theta [\text{Var}_\theta(W \mid T)] \geq 0,$$

temos

$$\text{EQM}_\theta(W^*) \leq \text{EQM}_\theta(W).$$

i Demonstração — Redução do EQM por condicionamento

Defina

$$W^*(T) = E_\theta(W \mid T).$$

Preservação da esperança

Pela propriedade da esperança iterada,

$$\begin{aligned} E_\theta[W^*(T)] &= E_\theta [E_\theta(W \mid T)] \\ &= E_\theta(W). \end{aligned}$$

Portanto, W e W^* possuem a mesma esperança.

Como ambos estimam o mesmo alvo $\tau(\theta)$, seus vieses também são iguais:

$$B_\theta(W^*) = B_\theta(W).$$

Redução da variância

Pela decomposição da variância total,

$$\text{Var}_\theta(W) = \text{Var}_\theta [E_\theta(W \mid T)] + E_\theta [\text{Var}_\theta(W \mid T)].$$

Como

$$E_{\theta}(W \mid T) = W^*(T),$$

segue que

$$\text{Var}_{\theta}(W) = \text{Var}_{\theta}(W^*) + E_{\theta}[\text{Var}_{\theta}(W \mid T)].$$

Portanto,

$$\text{Var}_{\theta}(W) - \text{Var}_{\theta}(W^*) = E_{\theta}[\text{Var}_{\theta}(W \mid T)] \geq 0.$$

Logo,

$$\text{Var}_{\theta}(W^*) \leq \text{Var}_{\theta}(W).$$

Redução do EQM

Pela decomposição viés–variância,

$$\text{EQM}_{\theta}(W) = \text{Var}_{\theta}(W) + B_{\theta}(W)^2$$

e

$$\text{EQM}_{\theta}(W^*) = \text{Var}_{\theta}(W^*) + B_{\theta}(W^*)^2.$$

Como

$$B_{\theta}(W^*) = B_{\theta}(W),$$

a diferença entre os EQMs é exatamente a diferença entre as variâncias:

$$\begin{aligned} \text{EQM}_{\theta}(W) - \text{EQM}_{\theta}(W^*) &= \text{Var}_{\theta}(W) - \text{Var}_{\theta}(W^*) \\ &= E_{\theta}[\text{Var}_{\theta}(W \mid T)] \\ &\geq 0. \end{aligned}$$

Portanto,

$$\text{EQM}_{\theta}(W^*) \leq \text{EQM}_{\theta}(W).$$

A igualdade ocorre quando

$$\text{Var}_{\theta}(W \mid T) = 0$$

quase certamente, isto é, quando não resta variabilidade em W depois que T é conhecido.

Se W é não viesado para $\tau(\theta)$, então

$$E_{\theta}(W) = \tau(\theta).$$

Como Rao–Blackwell preserva a esperança,

$$E_{\theta}[W^*(T)] = \tau(\theta).$$

Assim, W^* também é não viesado e possui variância não superior à de W .

O condicionamento em uma estatística suficiente pode, portanto, remover variabilidade associada a aspectos dos dados que não acrescentam informação sobre o parâmetro (Rice, 2007, sec. 8.8.2; Bickel; Doksum, 2016, thm. 8.2.6).

Exemplo adaptado — Estimação no modelo de Poisson

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\theta), \quad n \geq 2.$$

O alvo é a probabilidade de uma nova variável com distribuição Poisson (θ) assumir o valor zero:

$$\tau(\theta) = P_{\theta}(X = 0) = e^{-\theta}.$$

Um estimador simples pode ser construído utilizando somente a primeira observação:

$$W = \mathbf{1}\{X_1 = 0\}.$$

Utilize o teorema de Rao–Blackwell com a estatística suficiente

$$T = \sum_{i=1}^n X_i$$

e obtenha

$$W^*(T) = E_{\theta}(W \mid T).$$

Verificação do não viés do estimador inicial

Como

$$W = \mathbf{1}\{X_1 = 0\},$$

temos

$$\begin{aligned} E_\theta(W) &= P_\theta(X_1 = 0) \\ &= e^{-\theta}. \end{aligned}$$

Portanto, W é não viesado para

$$\tau(\theta) = e^{-\theta}.$$

Entretanto, W utiliza apenas X_1 e ignora as demais observações da amostra.

Estatística suficiente

Para o modelo Poisson,

$$T = \sum_{i=1}^n X_i$$

é suficiente para θ .

Além disso,

$$T \sim \text{Poisson}(n\theta)$$

e T é completa.

Para aplicar Rao–Blackwell, calculamos

$$W^*(T) = E_\theta(W \mid T).$$

Como W é um indicador,

$$\begin{aligned} W^*(T) &= E_\theta[\mathbf{1}\{X_1 = 0\} \mid T] \\ &= P_\theta(X_1 = 0 \mid T). \end{aligned}$$

Condicionalmente a

$$T = t,$$

temos

$$(X_1, \dots, X_n) \mid T = t \sim \text{Multinomial}\left(t; \frac{1}{n}, \dots, \frac{1}{n}\right).$$

Em particular,

$$X_1 \mid T = t \sim \text{Bin} \left(t, \frac{1}{n} \right).$$

Logo,

$$P_\theta(X_1 = 0 \mid T = t) = \left(1 - \frac{1}{n} \right)^t.$$

Substituindo t pela variável aleatória T ,

$$W^*(T) = \left(1 - \frac{1}{n} \right)^T.$$

Como

$$T = \sum_{i=1}^n X_i,$$

também podemos escrever

$$W^*(T) = \left(1 - \frac{1}{n} \right)^{\sum_{i=1}^n X_i}.$$

Derivação — Distribuição condicional dado $T = t$

Considere valores

$$x_1, \dots, x_n$$

tais que

$$\sum_{i=1}^n x_i = t.$$

Pela independência das observações,

$$\begin{aligned} P_\theta(X_1 = x_1, \dots, X_n = x_n) \\ &= \prod_{i=1}^n \left[e^{-\theta} \frac{\theta^{x_i}}{x_i!} \right] \\ &= e^{-n\theta} \frac{\theta^t}{x_1! \cdots x_n!}. \end{aligned}$$

Além disso,

$$T = \sum_{i=1}^n X_i \sim \text{Poisson}(n\theta).$$

Portanto,

$$P_{\theta}(T = t) = e^{-n\theta} \frac{(n\theta)^t}{t!}.$$

A probabilidade condicional é

$$\begin{aligned} P_{\theta}(X_1 = x_1, \dots, X_n = x_n \mid T = t) \\ &= \frac{e^{-n\theta} \frac{\theta^t}{x_1! \cdots x_n!}}{e^{-n\theta} \frac{(n\theta)^t}{t!}} \\ &= \frac{t!}{x_1! \cdots x_n!} \left(\frac{1}{n} \right)^t. \end{aligned}$$

Observe que θ desaparece completamente da expressão.

Essa é a função de probabilidade de uma distribuição multinomial:

$$(X_1, \dots, X_n) \mid T = t \sim \text{Multinomial} \left(t; \frac{1}{n}, \dots, \frac{1}{n} \right).$$

Consequentemente, a distribuição marginal condicional de X_1 é

$$X_1 \mid T = t \sim \text{Bin} \left(t, \frac{1}{n} \right).$$

Assim,

$$\begin{aligned} P_{\theta}(X_1 = 0 \mid T = t) &= \binom{t}{0} \left(\frac{1}{n} \right)^0 \left(1 - \frac{1}{n} \right)^t \\ &= \left(1 - \frac{1}{n} \right)^t. \end{aligned}$$

Pelo teorema de Rao–Blackwell,

$$E_{\theta}[W^*(T)] = E_{\theta}(W) = e^{-\theta},$$

de modo que W^* continua sendo não viesado.

Além disso,

$$\text{Var}_{\theta}(W^*) \leq \text{Var}_{\theta}(W).$$

Portanto,

$$W^*(T) = \left(1 - \frac{1}{n} \right)^{\sum_{i=1}^n X_i}$$

é uma versão Rao–Blackwellizada do estimador inicial.

O estimador inicial

$$W = \mathbf{1}\{X_1 = 0\}$$

utiliza apenas uma observação, enquanto

$$W^*(T)$$

depende da amostra por meio de uma estatística suficiente.

Rao–Blackwell garante que essa substituição preserva o não viés e não aumenta a variância.

Para concluir que $W^*(T)$ possui variância mínima entre **todos** os estimadores não viesados de $e^{-\theta}$, precisamos utilizar uma propriedade adicional de T : sua completude. Essa é precisamente a função do teorema de Lehmann–Scheffé.

Teorema de Lehmann–Scheffé

Rao–Blackwell mostra como melhorar um estimador por condicionamento em uma estatística suficiente. A suficiência, entretanto, não garante por si só que a função não viesada resultante seja única.

É nesse ponto que a completude se torna decisiva.

! Teorema — Lehmann–Scheffé

Se T é suficiente e completa para θ e $\phi(T)$ é uma função de T que satisfaz

$$E_{\theta}[\phi(T)] = \tau(\theta)$$

para todo $\theta \in \Theta$, com segundo momento finito, então $\phi(T)$ é o ENVVUM de $\tau(\theta)$.

Além disso, $\phi(T)$ é única, a menos de equivalência P_{θ} -quase certa, para todo θ (Casella; Berger, 2011, thm. 7.3.23; Bickel; Doksum, 2016, cor. 8.2.2).

O resultado combina diretamente as duas propriedades estudadas anteriormente:

- a **suficiência** permite reduzir a variabilidade por meio do teorema de Rao–Blackwell;
- a **completude** garante que não existem duas funções distintas de T que sejam não viesadas para o mesmo alvo.

Essa combinação transforma uma propriedade de melhoria em uma propriedade de optimalidade e unicidade.

i Demonstração — Teorema de Lehmann–Scheffé

Suponha que

$$\phi(T)$$

seja não viesado para $\tau(\theta)$.

Para provar o resultado, basta mostrar que sua variância não pode ser superada por nenhum outro estimador não viesado.

Comparação com um estimador não viesado arbitrário

Seja

$$W = W(\mathbf{X})$$

qualquer estimador não viesado de $\tau(\theta)$, com variância finita.

Como T é suficiente, o teorema de Rao–Blackwell permite construir

$$W^*(T) = E_\theta(W \mid T).$$

Esse novo estimador é função de T , continua sendo não viesado e satisfaz

$$\text{Var}_\theta(W^*) \leq \text{Var}_\theta(W).$$

Uso da completude

Tanto

$$\phi(T)$$

quanto

$$W^*(T)$$

são funções de T e são não viesadas para o mesmo alvo $\tau(\theta)$.

Portanto,

$$E_\theta[\phi(T)] = \tau(\theta)$$

e

$$E_\theta[W^*(T)] = \tau(\theta).$$

Subtraindo,

$$E_\theta[\phi(T) - W^*(T)] = 0$$

para todo θ .

Como T é completa, a única função de T cuja esperança é zero para todos os valores de θ é a função nula. Assim,

$$\phi(T) - W^*(T) = 0$$

P_θ -quase certamente.

Logo,

$$\phi(T) = W^*(T)$$

P_θ -quase certamente.

Consequentemente,

$$\text{Var}_\theta[\phi(T)] = \text{Var}_\theta(W^*) \leq \text{Var}_\theta(W).$$

Como W foi escolhido arbitrariamente entre os estimadores não viesados de $\tau(\theta)$, concluímos que

$$\phi(T)$$

possui variância não superior à de qualquer estimador não viesado do mesmo alvo.

Portanto, $\phi(T)$ é o ENVVUM.

A completude também mostra que qualquer outra função não viesada de T para o mesmo alvo deve coincidir com $\phi(T)$ quase certamente. Isso estabelece a unicidade.

No exemplo de Poisson desenvolvido anteriormente,

$$T = \sum_{i=1}^n X_i$$

é suficiente e completa para θ , e

$$W^*(T) = \left(1 - \frac{1}{n}\right)^T$$

é não viesado para

$$e^{-\theta}.$$

Portanto, pelo teorema de Lehmann–Scheffé,

$$W^*(T) = \left(1 - \frac{1}{n}\right)^{\sum_{i=1}^n X_i}$$

é o único ENVVUM de $e^{-\theta}$, a menos de equivalência quase certa.

💡 Procedimento — Como utilizar Lehmann–Scheffé

Para aplicar o teorema, podemos seguir dois caminhos:

1. identificar uma estatística T suficiente e completa e encontrar diretamente uma função $\phi(T)$ tal que

$$E_{\theta}[\phi(T)] = \tau(\theta);$$

2. partir de qualquer estimador não viesado W e utilizar Rao–Blackwell para obter

$$W^*(T) = E_{\theta}(W \mid T).$$

Nos dois casos, se a estatística T é suficiente e completa, a função não viesada obtida é o ENVVUM do alvo.

A suficiência permite a redução por condicionamento; a completude garante a unicidade da função não viesada resultante (Bickel; Doksum, 2016, cor. 8.2.2).

Exemplo — ENVVUM da taxa exponencial

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\theta), \quad \theta > 0,$$

em que θ representa a **taxa** da distribuição exponencial.

Assim,

$$f(x \mid \theta) = \theta e^{-\theta x} \mathbf{1}\{x > 0\}.$$

Considere $n > 2$ e determine:

1. uma estatística suficiente e completa para θ ;
2. uma função não viesada dessa estatística para estimar θ ;
3. o ENVVUM de θ ;
4. sua variância;
5. se esse estimador atinge o limite de Cramér–Rao.

Suficiência

Como as observações são independentes, a densidade conjunta é

$$\begin{aligned} f(\mathbf{x} \mid \theta) &= \prod_{i=1}^n [\theta e^{-\theta x_i} \mathbf{1}\{x_i > 0\}] \\ &= \theta^n \exp \left\{ -\theta \sum_{i=1}^n x_i \right\} \prod_{i=1}^n \mathbf{1}\{x_i > 0\}. \end{aligned}$$

Toda a dependência simultânea nos dados e em θ ocorre por meio de

$$T = \sum_{i=1}^n X_i.$$

Pelo teorema da fatoração de Neyman–Fisher, T é suficiente para θ .

Completeness

A densidade de uma observação pode ser escrita como

$$f(x \mid \theta) = \mathbf{1}\{x > 0\} \exp \{-\theta x + \log \theta\}.$$

Tomando

$$\eta = -\theta,$$

temos

$$\eta \in (-\infty, 0).$$

Esse conjunto é um intervalo aberto de $\mathbb{R}$.

Portanto, o modelo constitui uma família exponencial regular de um parâmetro e a estatística canônica

$$T = \sum_{i=1}^n X_i$$

é também completa.

Assim, T é **suficiente e completa** para θ .

Distribuição de T

Como θ é a taxa exponencial e, neste livro, a distribuição gama é parametrizada por forma e escala,

$$T \sim \text{Gama} \left(n, \frac{1}{\theta} \right).$$

Portanto, a densidade de T é

$$f_T(t) = \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t}, \quad t > 0.$$

Construção de uma função não viesada de T

Para aplicar Lehmann–Scheffé, precisamos encontrar uma função de T cuja esperança seja θ .

Para $n > 1$,

$$E_\theta(T^{-1}) = \frac{\theta}{n-1}.$$

Logo,

$$E_\theta \left[\frac{n-1}{T} \right] = \theta.$$

Portanto,

$$\hat{\theta} = \frac{n-1}{T} = \frac{n-1}{\sum_{i=1}^n X_i}$$

é não viesado para θ .

Como $\hat{\theta}$ é uma função não viesada da estatística suficiente e completa T , o teorema de Lehmann–Scheffé garante que

$$\hat{\theta}_{\text{ENVVUM}} = \frac{n-1}{\sum_{i=1}^n X_i}$$

é o ENVVUM de θ .

Variância do ENVVUM

Para $n > 2$,

$$E_\theta(T^{-2}) = \frac{\theta^2}{(n-1)(n-2)}.$$

Assim,

$$\begin{aligned} \text{Var}_\theta(\hat{\theta}_{\text{ENVVUM}}) &= \text{Var}_\theta \left(\frac{n-1}{T} \right) \\ &= (n-1)^2 [E_\theta(T^{-2}) - E_\theta(T^{-1})^2] \\ &= (n-1)^2 \left[\frac{\theta^2}{(n-1)(n-2)} - \frac{\theta^2}{(n-1)^2} \right] \\ &= \frac{\theta^2}{n-2}. \end{aligned}$$

Derivação — Momentos negativos de T

Como

$$T \sim \text{Gama} \left(n, \frac{1}{\theta} \right),$$

sua densidade é

$$f_T(t) = \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t}, \quad t > 0.$$

Para calcular

$$E_\theta(T^{-1}),$$

temos, para $n > 1$,

$$\begin{aligned} E_\theta(T^{-1}) &= \int_0^\infty \frac{1}{t} f_T(t) dt \\ &= \frac{\theta^n}{\Gamma(n)} \int_0^\infty t^{n-2} e^{-\theta t} dt. \end{aligned}$$

Utilizando

$$\int_0^\infty t^{a-1} e^{-\theta t} dt = \frac{\Gamma(a)}{\theta^a},$$

com

$$a = n - 1,$$

obtemos

$$\begin{aligned} E_\theta(T^{-1}) &= \frac{\theta^n}{\Gamma(n)} \frac{\Gamma(n-1)}{\theta^{n-1}} \\ &= \theta \frac{\Gamma(n-1)}{\Gamma(n)}. \end{aligned}$$

Como

$$\Gamma(n) = (n-1)\Gamma(n-1),$$

segue que

$$E_\theta(T^{-1}) = \frac{\theta}{n-1}.$$

Para o segundo momento negativo, quando $n > 2$,

$$\begin{aligned} E_{\theta}(T^{-2}) &= \frac{\theta^n}{\Gamma(n)} \int_0^{\infty} t^{n-3} e^{-\theta t} dt \\ &= \frac{\theta^n}{\Gamma(n)} \frac{\Gamma(n-2)}{\theta^{n-2}} \\ &= \theta^2 \frac{\Gamma(n-2)}{\Gamma(n)}. \end{aligned}$$

Como

$$\Gamma(n) = (n-1)(n-2)\Gamma(n-2),$$

temos

$$E_{\theta}(T^{-2}) = \frac{\theta^2}{(n-1)(n-2)}.$$

Esses dois momentos produzem diretamente a variância do ENVVUM.

Comparação com o limite de Cramér–Rao

Para uma observação,

$$\log f(X \mid \theta) = \log \theta - \theta X.$$

O escore é

$$U_{\theta}(X) = \frac{\partial}{\partial \theta} \log f(X \mid \theta) = \frac{1}{\theta} - X.$$

Como

$$\text{Var}_{\theta}(X) = \frac{1}{\theta^2},$$

a informação de Fisher de uma observação é

$$I_1(\theta) = \text{Var}_{\theta}[U_{\theta}(X)] = \frac{1}{\theta^2}.$$

Para uma amostra i.i.d.,

$$I_n(\theta) = \frac{n}{\theta^2}.$$

Como o alvo é

$$\tau(\theta) = \theta,$$

o limite de Cramér–Rao para estimadores não viesados é

$$\frac{1}{I_n(\theta)} = \frac{\theta^2}{n}.$$

Por outro lado,

$$\text{Var}_\theta(\hat{\theta}_{\text{ENVVUM}}) = \frac{\theta^2}{n-2}.$$

Como, para $n > 2$,

$$\frac{1}{n-2} > \frac{1}{n},$$

temos

$$\frac{\theta^2}{n-2} > \frac{\theta^2}{n}.$$

Portanto, o ENVVUM **não atinge** o limite de Cramér–Rao.

Este exemplo evidencia que Lehmann–Scheffé e Cramér–Rao descrevem formas diferentes de optimalidade.

O teorema de Lehmann–Scheffé garante que

$$\hat{\theta}_{\text{ENVVUM}} = \frac{n-1}{\sum_{i=1}^n X_i}$$

possui a menor variância entre **todos os estimadores não viesados** de θ .

A desigualdade de Cramér–Rao estabelece uma cota inferior para essa variância sob condições de regularidade, mas não garante que exista um estimador não viesado capaz de atingir a cota.

Assim, um estimador pode ser ENVVUM e, ainda assim, não ser eficiente no sentido de Cramér–Rao.

Estatísticas ancilares e teorema de Basu

A suficiência identifica estatísticas que concentram a informação da amostra sobre o parâmetro. Existe também uma classe de estatísticas com uma propriedade complementar: sua distribuição permanece a mesma quando o valor do parâmetro varia.

Essas estatísticas são denominadas **ancilares**.

! Definição — Ancilaridade

Uma estatística

$$A = A(\mathbf{X})$$

é **ancilar** para θ quando sua distribuição não depende de θ .

A definição não significa que A seja uma constante. A estatística pode variar de uma amostra para outra; o que não varia com θ é sua **distribuição amostral**.

Assim, uma estatística ancilar não informa diretamente sobre o valor de θ . Ela pode, entretanto, descrever aspectos da configuração da amostra, de sua variabilidade ou do mecanismo amostral. Em argumentos condicionais, essa informação pode ser relevante para a inferência (Cox, 2006, sec. 4.3.1).

A relação entre ancilaridade e suficiência torna-se especialmente forte quando a estatística suficiente também é completa.

! Teorema — Basu

Se T é suficiente e completa para θ e A é ancilar para θ , então

$$T \perp A.$$

Isto é, T e A são independentes (Bickel; Doksum, 2016, thm. 8.2.3; Casella; Berger, 2011, teoremas 6.2.24 e 6.2.28).

O teorema estabelece uma consequência importante: uma estatística que concentra toda a informação sobre θ e possui a propriedade de completude é independente de qualquer estatística cuja distribuição seja livre de θ .

i Demonstração — Ideia do teorema de Basu no caso discreto

Considere o caso discreto e fixe um valor possível a da estatística ancilar A .

Ancilaridade

Como A é ancilar,

$$P_{\theta}(A = a)$$

não depende de θ .

Podemos, portanto, escrever

$$c_a = P_{\theta}(A = a),$$

em que c_a é constante em relação a θ .

Suficiência

Como T é suficiente, a distribuição condicional da amostra dado $T = t$ não depende de θ .

Como A é uma função da amostra, segue que

$$P_\theta(A = a \mid T = t)$$

também não depende de θ .

Defina

$$g_a(t) = P_\theta(A = a \mid T = t) - c_a.$$

A função g_a depende de t , mas não de θ .

Esperança de $g_a(T)$

Pela fórmula da probabilidade total,

$$P_\theta(A = a) = \sum_t P_\theta(A = a \mid T = t) P_\theta(T = t).$$

Como

$$P_\theta(A = a) = c_a,$$

também temos

$$c_a = \sum_t c_a P_\theta(T = t).$$

Subtraindo as duas expressões,

$$\sum_t [P_\theta(A = a \mid T = t) - c_a] P_\theta(T = t) = 0.$$

Pela definição de g_a ,

$$\sum_t g_a(t) P_\theta(T = t) = 0.$$

Logo,

$$E_\theta[g_a(T)] = 0$$

para todo θ .

Uso da completude

Como T é completa e

$$E_\theta[g_a(T)] = 0$$

para todo θ , segue que

$$g_a(T) = 0$$

P_θ -quase certamente.

Portanto,

$$P_\theta(A = a \mid T = t) = c_a = P_\theta(A = a)$$

para os valores relevantes de t .

Essa igualdade mostra que conhecer T não modifica a distribuição de A . Portanto,

$$A \perp T.$$

O argumento mostra o papel de cada hipótese:

- a **ancilaridade** torna a distribuição marginal de A livre de θ ;
- a **suficiência** torna a distribuição condicional de A dado T livre de θ ;
- a **completude** força essas duas distribuições a coincidirem.

No caso contínuo, o mesmo princípio é formulado por meio das distribuições condicionais correspondentes.

Exemplo — Basu no modelo normal de localização

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com

$$n \geq 2,$$

σ^2 conhecida e μ desconhecida.

O teorema de Basu permite justificar a independência entre

$$\bar{X}$$

e

$$S^2.$$

A aplicação requer duas propriedades:

1. $\bar{X}$ é suficiente e completa para μ ;
2. S^2 é ancilar para μ .

i Resolução — Aplicação do teorema de Basu

Suficiência e completude de $\bar{X}$

Para σ^2 conhecida, a densidade conjunta da amostra pode ser escrita de modo que toda a dependência nos dados e em μ ocorra por meio de

$$T = \sum_{i=1}^n X_i.$$

Portanto, T é suficiente para μ .

Como

$$T = n\bar{X},$$

conhecer T equivale a conhecer $\bar{X}$. Assim, $\bar{X}$ também é suficiente para μ .

Além disso, com σ^2 conhecida, o modelo normal de localização constitui uma família exponencial regular de um parâmetro cujo espaço natural é aberto. Portanto, sua estatística canônica é completa.

Consequentemente,

$$\bar{X}$$

é suficiente e completa para μ .

Ancilaridade de S^2

Considere

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

No Capítulo 4, para uma amostra normal, foi obtido

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Como σ^2 é conhecida, a distribuição de S^2 depende de σ^2 , mas não depende de μ .

Portanto,

$$S^2$$

é ancilar para o parâmetro de interesse μ .

Temos, assim,

$\bar{X}$ suficiente e completa para μ

e

S^2 ancilar para μ .

Pelo teorema de Basu,

$$\bar{X} \perp S^2.$$

No Capítulo 4, a independência entre $\bar{X}$ e S^2 foi obtida a partir da estrutura específica da amostra normal. O teorema de Basu fornece outra interpretação: a independência decorre da relação entre **suficiência, completude e ancilaridade**.

 **Observação** — Ancilaridade depende do parâmetro de interesse

Neste exemplo, S^2 é ancilar **para** μ , porque σ^2 é conhecida e a distribuição de S^2 não depende de μ .

Se σ^2 também for desconhecida e o parâmetro do modelo for

$$(\mu, \sigma^2),$$

então S^2 não será ancilar para esse vetor, pois sua distribuição depende de σ^2 .

Assim como a suficiência, a ancilaridade deve sempre ser especificada em relação ao parâmetro e ao modelo considerados.

A definição de ancilaridade e o teorema de Basu são apresentados em Bickel; Doksum (2016, def. 8.2.3 and thm. 8.2.3) e Casella; Berger (2011, secs. 6.2.3–6.2.4).

Exemplo integrado — Avaliação e redução no modelo gama

Os resultados desenvolvidos ao longo do capítulo podem ser combinados para estudar um mesmo procedimento inferencial sob diferentes perspectivas.

No modelo gama, utilizaremos:

- suficiência e completude para construir um ENVVUM;
- a Lei dos Grandes Números para verificar consistência;
- a informação de Fisher e a desigualdade de Cramér–Rao para avaliar sua eficiência.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Gama}(\alpha, \beta),$$

em que $\alpha > 0$ é conhecido e $\beta > 0$ é o parâmetro de **escala**.

Na parametrização adotada neste livro,

$$E_{\beta}(X_i) = \alpha\beta$$

e

$$\text{Var}_{\beta}(X_i) = \alpha\beta^2.$$

A densidade de uma observação é

$$f(x | \beta) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha)\beta^{\alpha}}, \quad x > 0.$$

Analise o modelo em quatro etapas:

1. identifique uma estatística suficiente e completa para β ;
2. obtenha o ENVVUM de β ;
3. verifique sua consistência;
4. calcule a informação de Fisher e verifique a eficiência de Cramér–Rao.

Redução por suficiência e completude

i Resolução — Suficiência, completude e ENVVUM

Suficiência

Como as observações são independentes,

$$f(\mathbf{x} | \beta) = \prod_{i=1}^n f(x_i | \beta).$$

Portanto,

$$\begin{aligned} f(\mathbf{x} | \beta) &= \prod_{i=1}^n \frac{x_i^{\alpha-1} e^{-x_i/\beta}}{\Gamma(\alpha)\beta^{\alpha}} \\ &= \frac{\prod_{i=1}^n x_i^{\alpha-1}}{\Gamma(\alpha)^n} \beta^{-n\alpha} \exp \left\{ -\frac{1}{\beta} \sum_{i=1}^n x_i \right\}. \end{aligned}$$

Toda a dependência simultânea nos dados e em β ocorre por meio de

$$T = \sum_{i=1}^n X_i.$$

Pelo teorema da fatoração de Neyman–Fisher, T é suficiente para β .

Completude

A densidade também pode ser reconhecida como pertencente a uma família exponencial de um parâmetro.

Tomando

$$\eta = -\frac{1}{\beta},$$

e utilizando

$$\beta > 0,$$

temos

$$\eta \in (-\infty, 0).$$

Esse espaço natural é um intervalo aberto de $\mathbb{R}$.

Portanto, pela condição de completude para famílias exponenciais,

$$T = \sum_{i=1}^n X_i$$

é também completa para β .

Assim, T é suficiente e completa.

Construção de uma função não viesada de T

Como a soma de variáveis gama independentes com a mesma escala permanece gama,

$$T \sim \text{Gama}(n\alpha, \beta).$$

Consequentemente,

$$E_{\beta}(T) = n\alpha\beta.$$

Logo,

$$E_{\beta}\left(\frac{T}{n\alpha}\right) = \beta.$$

Portanto,

$$\hat{\beta} = \frac{T}{n\alpha} = \frac{\bar{X}}{\alpha}$$

é não viesado para β .

Como $\hat{\beta}$ é uma função não viesada da estatística suficiente e completa T , o teorema de Lehmann–Scheffé garante que

$$\hat{\beta} = \frac{\overline{X}}{\alpha}$$

é o ENVVUM de β .

Consistência

O fato de $\hat{\beta}$ ser ENVVUM é uma propriedade de optimalidade dentro da classe dos estimadores não viesados. A consistência avalia se o estimador se concentra em β quando o tamanho amostral aumenta.

Resolução — Consistência

Como

$$E_{\beta}(X_i) = \alpha\beta,$$

a Lei dos Grandes Números fornece

$$\overline{X} \xrightarrow{P} \alpha\beta.$$

A função

$$g(x) = \frac{x}{\alpha}$$

é contínua, pois $\alpha > 0$ é uma constante conhecida.

Pelo teorema do mapeamento contínuo,

$$g(\overline{X}) \xrightarrow{P} g(\alpha\beta).$$

Logo,

$$\frac{\overline{X}}{\alpha} \xrightarrow{P} \beta.$$

Portanto,

$$\hat{\beta} \xrightarrow{P} \beta,$$

e o estimador é consistente.

Eficiência de Cramér–Rao

Finalmente, podemos comparar a variância de $\hat{\beta}$ com o limite inferior permitido pelo modelo para estimadores não viesados regulares.

Resolução — Informação de Fisher e eficiência

Para uma observação,

$$\begin{aligned}\log f(X | \beta) &= (\alpha - 1) \log X - \frac{X}{\beta} \\ &\quad - \alpha \log \beta - \log \Gamma(\alpha).\end{aligned}$$

Derivando em relação a β ,

$$\begin{aligned}U_{\beta}(X) &= \frac{\partial}{\partial \beta} \log f(X | \beta) \\ &= \frac{X}{\beta^2} - \frac{\alpha}{\beta}.\end{aligned}$$

Como

$$E_{\beta}(X) = \alpha\beta,$$

temos

$$E_{\beta}[U_{\beta}(X)] = 0.$$

A informação de Fisher de uma observação pode ser obtida pela variância do escore:

$$\begin{aligned}I_1(\beta) &= \text{Var}_{\beta}[U_{\beta}(X)] \\ &= \text{Var}_{\beta}\left(\frac{X}{\beta^2} - \frac{\alpha}{\beta}\right) \\ &= \frac{\text{Var}_{\beta}(X)}{\beta^4}.\end{aligned}$$

Como

$$\text{Var}_{\beta}(X) = \alpha\beta^2,$$

segue que

$$I_1(\beta) = \frac{\alpha}{\beta^2}.$$

Para uma amostra i.i.d.,

$$I_n(\beta) = nI_1(\beta) = \frac{n\alpha}{\beta^2}.$$

Como o alvo é

$$\tau(\beta) = \beta,$$

temos

$$\tau'(\beta) = 1.$$

Assim, o limite de Cramér–Rao para estimadores não viesados de β é

$$\frac{1}{I_n(\beta)} = \frac{\beta^2}{n\alpha}.$$

Agora calculamos a variância do estimador:

$$\begin{aligned} \text{Var}_\beta(\hat{\beta}) &= \text{Var}_\beta\left(\frac{\bar{X}}{\alpha}\right) \\ &= \frac{\text{Var}_\beta(\bar{X})}{\alpha^2} \\ &= \frac{\alpha\beta^2/n}{\alpha^2} \\ &= \frac{\beta^2}{n\alpha}. \end{aligned}$$

Portanto,

$$\text{Var}_\beta(\hat{\beta}) = \frac{1}{I_n(\beta)}.$$

Logo, $\hat{\beta}$ atinge o limite de Cramér–Rao e é eficiente no sentido de Cramér–Rao.

i Integração dos resultados

Para o mesmo estimador,

$$\hat{\beta} = \frac{\bar{X}}{\alpha},$$

obtivemos quatro propriedades:

não viés + consistência + ENVVUM + eficiência de Cramér–Rao.

Cada conclusão utiliza uma parte diferente da teoria desenvolvida no capítulo:

- o cálculo da esperança estabelece o **não viés**;
- a Lei dos Grandes Números e o teorema do mapeamento contínuo estabelecem a **consistência**;
- suficiência, completude e o teorema de Lehmann–Scheffé estabelecem que o estimador é **ENVVUM**;
- a informação de Fisher e a desigualdade de Cramér–Rao estabelecem a **eficiência de Cramér–Rao**.

Essas propriedades não são sinônimas. Cada uma responde a uma questão diferente sobre o procedimento inferencial.

Neste exemplo, todas elas são satisfeitas pelo mesmo estimador.

A estrutura do exemplo utiliza resultados de suficiência, completude e eficiência apresentados por Ramachandran; Tsokos (2021, chap. 5) e Lauritzen (2023, chaps. 3–5).

5.3 Síntese conceitual

A avaliação de estimadores reúne critérios de amostra finita e critérios assintóticos. Sob perda quadrática, o risco coincide com o erro quadrático médio, que se decompõe em

$$\text{EQM}_\theta(T) = \text{Var}_\theta(T) + B_\theta(T)^2.$$

O não viés e a variância descrevem propriedades para um tamanho amostral fixado. A consistência estuda a concentração de uma sequência de estimadores no alvo quando n aumenta. A eficiência assintótica compara a precisão das distribuições limite.

A informação de Fisher relaciona a sensibilidade do modelo ao parâmetro com limites de precisão:

$$\text{escore} \longrightarrow \text{informação de Fisher} \longrightarrow \text{limite de Cramér–Rao}.$$

Na redução de dados, a suficiência concentra a informação da amostra sobre o parâmetro, enquanto a suficiência minimal elimina redundâncias. As famílias exponenciais fornecem uma estrutura sistemática para identificar estatísticas suficientes e, sob condições adicionais, completas.

A suficiência permite melhorar um estimador por Rao–Blackwell:

$$W \xrightarrow{\text{Rao–Blackwell}} W^*(T) = E_\theta(W \mid T).$$

Quando T é suficiente e completa, Lehmann–Scheffé caracteriza a função não viesada de T como ENVVUM. O teorema de Basu relaciona completude e suficiência à ancilaridade por meio da independência.

Esses resultados fornecem os critérios que serão utilizados na construção e na avaliação de estimadores nos capítulos seguintes.

5.4 Exercícios

i Orientação

Quando pertinente, explicita o modelo, o parâmetro de interesse, o estimador e o critério utilizado para avaliá-lo. Ao aplicar a desigualdade de Cramér–Rao, verifique as condições de regularidade e identifique o alvo $\tau(\theta)$ antes de calcular o limite.

1. **Viés e EQM.** Sejam $X_1, \dots, X_n$ i.i.d. com

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2.$$

Para constantes a e b , considere o estimador

$$T_n = a\bar{X} + b$$

de μ .

- a. Calcule $B_\mu(T_n)$.
- b. Calcule $\text{Var}_\mu(T_n)$.
- c. Obtenha $\text{EQM}_\mu(T_n)$.
- d. Determine as condições sobre a e b para que T_n seja não viesado para μ , para todo μ .
- e. Determine as condições sobre a e b para que

$$T_n \xrightarrow{P} \mu$$

para todo μ .

2. **Uniforme e compromisso viés–variância.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0.$$

Compare os estimadores

$$T_1 = 2\bar{X}, \quad T_2 = X_{(n)}, \quad T_3 = \frac{n+1}{n}X_{(n)}.$$

- Calcule o viés e o EQM de cada estimador.
- Determine qual estimador possui menor EQM para $n > 1$.
- Para $n > 2$, estabeleça a ordenação dos três estimadores segundo o EQM.
- O suporte da distribuição depende de θ . Explique por que a forma clássica da desigualdade de Cramér–Rao apresentada no capítulo não pode ser aplicada diretamente a esse modelo.

3. **Consistência por EQM.** Considere uma sequência de estimadores $\{T_n\}$ tal que

$$E_\theta(T_n) = \theta + \frac{1}{n}$$

e

$$\text{Var}_\theta(T_n) = \frac{4}{n}.$$

- Determine o viés de T_n .
- Calcule $\text{EQM}_\theta(T_n)$.
- Mostre que T_n é consistente em EQM para θ .
- Conclua que

$$T_n \xrightarrow{P} \theta.$$

4. **Cramér–Rao no modelo exponencial.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}\left(\frac{1}{\mu}\right), \quad \mu > 0,$$

em que μ representa a média e a taxa é $1/\mu$. Assim,

$$E_{\mu}(X_i) = \mu.$$

Equivalentemente,

$$f(x | \mu) = \frac{1}{\mu} \exp\left(-\frac{x}{\mu}\right) \mathbf{1}\{x > 0\}.$$

- Obtenha a função escore de uma observação.
- Calcule $I_1(\mu)$ e $I_n(\mu)$.
- Determine o limite de Cramér–Rao para estimadores não viesados de μ .
- Mostre que $\bar{X}$ é não viesado para μ .
- Compare $\text{Var}_{\mu}(\bar{X})$ com o limite de Cramér–Rao e conclua se $\bar{X}$ é eficiente no sentido de Cramér–Rao.

Exercícios — Aprofundamento

5. **Suficiência no modelo normal.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2).$$

Utilize o teorema da fatoração para identificar uma estatística suficiente para:

- μ , quando σ^2 é conhecida;
- σ^2 , quando μ é conhecida;
- (μ, σ^2) , quando ambos são desconhecidos.

6. **Suficiência minimal.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0.$$

Utilize o critério da razão de verossimilhanças, na forma baseada em proporcionalidade, para mostrar que

$$T = X_{(n)}$$

é suficiente minimal para θ . Explique por que o uso direto do quociente de verossimilhanças exige cuidado nesse modelo.

7. Suficiência e completude no modelo geométrico. Seja

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Geo}(p), \quad 0 < p < 1,$$

com função de probabilidade

$$f(x | p) = p(1 - p)^{x-1}, \quad x = 1, 2, \dots$$

a. Mostre, pelo teorema da fatoração, que

$$T = \sum_{i=1}^n X_i$$

é suficiente para p .

b. Determine a distribuição de T .

c. Escreva o modelo na forma exponencial canônica e identifique seu espaço natural de parâmetros.

d. Utilize a condição de completude para famílias exponenciais para concluir que T é completa.

Adaptado de Casella; Berger (2011), cap. 6.

8. Rao–Blackwell no modelo Poisson. Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\theta), \quad \theta > 0,$$

e o estimador

$$W = \mathbf{1}\{X_1 = 1\}$$

de

$$\tau(\theta) = \theta e^{-\theta}.$$

- a. Verifique que W é não viesado para $\tau(\theta)$.
- b. Mostre que

$$T = \sum_{i=1}^n X_i$$

é suficiente para θ .

- c. Calcule

$$W^*(T) = E_{\theta}(W \mid T).$$

- d. Explique, utilizando o teorema de Rao–Blackwell, a relação entre os EQMs de W e $W^*(T)$.

9. Lehmann–Scheffé no modelo binomial. Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bin}(m, p),$$

com m conhecido e $0 < p < 1$.

- a. Mostre que

$$T = \sum_{i=1}^n X_i$$

é suficiente e completa para p .

- b. Verifique que

$$\hat{p} = \frac{T}{nm}$$

é não viesado para p .

- c. Utilize o teorema de Lehmann–Scheffé para concluir que $\hat{p}$ é o ENVVUM de p .
- d. Calcule a informação de Fisher e verifique se $\hat{p}$ atinge o limite de Cramér–Rao.

10. **ENVVUM da taxa exponencial.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\theta), \quad \theta > 0,$$

em que θ é a **taxa**, e suponha $n > 2$.

- a. Mostre que

$$T = \sum_{i=1}^n X_i$$

é suficiente e completa para θ .

- b. Mostre que

$$\hat{\theta} = \frac{n-1}{T}$$

é não viesado para θ .

- c. Utilize Lehmann–Scheffé para concluir que $\hat{\theta}$ é o ENVVUM de θ .
- d. Calcule sua variância.
- e. Obtenha o limite de Cramér–Rao e explique por que o ENVVUM não o atinge.

11. **Ancilaridade e Basu.** Considere uma amostra

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida e μ desconhecida.

- a. Mostre que $\bar{X}$ é suficiente e completa para μ .
- b. Mostre que S^2 é ancilar para μ .

- c. Utilize o teorema de Basu para justificar

$$\overline{X} \perp S^2.$$

- d. Explique por que S^2 deixaria de ser ancilar se o parâmetro de interesse fosse o vetor (μ, σ^2) .

12. Família exponencial curva. Considere

$$X \sim N(\mu, \mu^2), \quad \mu > 0.$$

- Identifique os dois parâmetros naturais da família normal geral com média e variância desconhecidas.
- Mostre que, sob a restrição $\sigma^2 = \mu^2$, esses parâmetros naturais satisfazem uma relação entre si.
- Explique por que o conjunto resultante constitui uma subfamília curva da família normal de dois parâmetros.
- Discuta por que a completude da estatística canônica da família normal completa não pode ser transferida automaticamente para essa subfamília.

13. Comparação integrada. Para cada procedimento abaixo, determine, quando aplicável:

- se o estimador é não viesado;
- se é consistente;
- se é ENVVUM;
- se atinge o limite de Cramér–Rao.

Justifique cada conclusão e indique quando a forma clássica da desigualdade de Cramér–Rao não é aplicável.

- a. $\overline{X}$ para μ em

$$X_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida;

- b. $X_{(n)}$ para θ em

$$X_i \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta);$$

- c.

$$\frac{n+1}{n}X_{(n)}$$

para θ no mesmo modelo uniforme;

d.

$$\frac{n-1}{\sum_{i=1}^n X_i}$$

para a taxa θ em

$$X_i \stackrel{\text{iid}}{\sim} \text{Exp}(\theta).$$

Os exercícios foram elaborados ou adaptados a partir das discussões e listas de problemas de Lauritzen (2023, chaps. 4–5), Rice (2007, chap. 8), Ramachandran; Tsokos (2021, chap. 5), Larsen; Marx (2012, chap. 5), Bickel; Doksum (2016, chap. 8) e Casella; Berger (2011, chaps. 6–7).

Exercícios extras

14. **Eficiência e ENVVUM no modelo Bernoulli.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p), \quad 0 < p < 1.$$

a. Mostre que

$$\hat{p} = \bar{X}$$

é não viesado para p .

b. Calcule $\text{Var}_p(\hat{p})$.

c. Obtenha a informação de Fisher de uma observação e da amostra.

d. Determine o limite de Cramér–Rao para estimadores não viesados de p e verifique se $\hat{p}$ atinge esse limite.

e. Mostre que

$$T = \sum_{i=1}^n X_i$$

é suficiente e completa para p e utilize Lehmann–Scheffé para concluir que $\hat{p}$ é o ENVVUM de p .

f. Para $n \geq 4$, considere

$$U = X_1 X_2 X_3 X_4.$$

Mostre que U é não viesado para p^4 e utilize Rao–Blackwell e Lehmann–Scheffé para obter o ENVVUM de p^4 .

Adaptado de Casella; Berger (2011), cap. 7.

15. ENVVUM sem atingir Cramér–Rao. Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\theta, 1).$$

a. Mostre que

$$\widehat{\theta^2} = \bar{X}^2 - \frac{1}{n}$$

é não viesado para θ^2 .

b. Mostre que

$$T = \bar{X}$$

é suficiente e completa para θ .

c. Utilize Lehmann–Scheffé para concluir que $\widehat{\theta^2}$ é o ENVVUM de θ^2 .

d. Calcule

$$\text{Var}_{\theta}(\widehat{\theta^2}).$$

e. Obtenha o limite de Cramér–Rao para estimadores não viesados de

$$\tau(\theta) = \theta^2.$$

- f. Compare a variância do ENVVUM com o limite e explique por que, neste exemplo, ser ENVVUM não implica atingir a cota de Cramér–Rao.

Adaptado de Casella; Berger (2011), cap. 7.

16. Melhoria de um estimador no modelo exponencial. Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}\left(\frac{1}{\mu}\right), \quad \mu > 0,$$

em que μ representa a média e a taxa é

$$\frac{1}{\mu}.$$

Assim,

$$E_{\mu}(X_i) = \mu.$$

Defina

$$Y = X_{(1)} = \min\{X_1, \dots, X_n\}.$$

- Determine a distribuição de Y .
- Encontre uma função de Y que seja não viesada para μ .
- Calcule a variância desse estimador.
- Calcule a variância de $\bar{X}$ e compare os dois estimadores.
- Mostre que $\bar{X}$ possui menor variância.
- Identifique uma estatística suficiente para μ e relacione a redução de variância observada ao princípio de Rao–Blackwell.

Adaptado de Casella; Berger (2011), cap. 7.

17. Completude e espaço paramétrico. Considere

$$X \sim \text{Poisson}(\lambda),$$

mas suponha que o espaço paramétrico seja restrito a

$$\lambda \in \{0, 1\}.$$

- a. Construa uma função g não identicamente nula tal que

$$E_{\lambda}[g(X)] = 0$$

para ambos os valores possíveis de λ .

- b. Conclua que essa família não é completa.
c. Explique por que esse resultado mostra que a completude depende da forma da distribuição **e do espaço paramétrico considerado**.

Adaptado de Casella; Berger (2011), cap. 6.

18. **Completude no modelo Poisson.** Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda), \quad \lambda > 0,$$

e

$$T = \sum_{i=1}^n X_i.$$

- a. Determine a distribuição de T .
b. Seja g uma função tal que

$$E_{\lambda}[g(T)] = 0$$

para todo $\lambda > 0$. Escreva essa esperança utilizando a função de probabilidade de T .

- c. Multiplique a expressão obtida por $e^{n\lambda}$ e interprete o resultado como uma série de potências em λ .
d. Utilize a unicidade dos coeficientes de uma série de potências para mostrar que

$$g(t) = 0, \quad t = 0, 1, 2, \dots$$

e conclua que

$$g(T) = 0$$

quase certamente.

- e. Conclua que a família de distribuições de T é completa.
- f. Compare esse resultado com o exercício anterior, em que o espaço paramétrico foi restrito a

$$\lambda \in \{0, 1\}.$$

Adaptado de Casella; Berger (2011), cap. 6.

19. Ancilaridade em uma família de locação–escala. Seja

$$X_1, \dots, X_n, \quad n \geq 2,$$

uma amostra de uma família de locação–escala para a qual

$$P(S > 0) = 1.$$

Considere a representação

$$X_i = a + bZ_i, \quad a \in \mathbb{R}, \quad b > 0,$$

em que a distribuição de Z_i não depende de a nem de b .

Sejam

$$R = X_{(n)} - X_{(1)}$$

a amplitude amostral e S o desvio-padrão amostral.

- a. Mostre que

$$X_{(1)} = a + bZ_{(1)}$$

e

$$X_{(n)} = a + bZ_{(n)}.$$

- b. Conclua que

$$R_X = bR_Z.$$

c. Mostre que

$$S_X = bS_Z.$$

d. Mostre que

$$\frac{R_X}{S_X} = \frac{R_Z}{S_Z}.$$

e. Explique por que a distribuição de

$$\frac{R}{S}$$

não depende de a nem de b e conclua que R/S é ancilar para os parâmetros de localização e escala.

Adaptado de Casella; Berger (2011), cap. 6.

No próximo capítulo, os critérios desenvolvidos neste capítulo serão utilizados para estudar estimadores construídos pelo método dos momentos, pela máxima verossimilhança e por mínimos quadrados.

Referências

6 Métodos de Estimação Pontual

Na Capítulo 5, foram estabelecidos os principais critérios para avaliar estimadores, incluindo viés, erro quadrático médio, consistência, informação de Fisher e eficiência. Nesta unidade, o foco passa da avaliação para a **construção de estimadores**: dado um modelo estatístico e um parâmetro de interesse, como obter uma regra de estimação a partir da amostra?

No percurso principal, serão estudados três métodos de estimação: o **método dos momentos**, a **máxima verossimilhança** e os **mínimos quadrados**. As propriedades apresentadas anteriormente serão retomadas apenas quando forem necessárias para compreender ou comparar os estimadores obtidos.

Os tópicos de **Aprofundamento** incluem critérios minimax e equivariância, distribuição assintótica de estimadores, aplicações do método delta e o algoritmo EM. Esses desenvolvimentos utilizam resultados anteriores sobre risco, convergência e informação de Fisher e podem ser omitidos em uma primeira leitura sem interromper o percurso principal da unidade.

Quando resultados assintóticos fornecerem aproximações para a distribuição ou para o erro-padrão de um estimador, essas propriedades serão registradas nesta unidade. A construção e a interpretação de intervalos de confiança, incluindo o intervalo de Wald, serão desenvolvidas na unidade seguinte.

6.1 Método dos Momentos

O **método dos momentos** estima os parâmetros de um modelo igualando momentos populacionais, escritos como funções dos parâmetros, aos momentos correspondentes calculados na amostra. Em muitos modelos, as equações resultantes podem ser resolvidas diretamente e também podem fornecer valores iniciais para métodos numéricos. A definição do método não depende da Lei dos Grandes Números; essa lei, juntamente com condições de identificabilidade e continuidade, é utilizada para estabelecer a consistência dos estimadores obtidos (Casella; Berger, 2011, sec. 7.2.1; Rice, 2007, sec. 8.4; Ramachandran; Tsokos, 2021, sec. 5.2.1; Chihara; Hesterberg, 2022, sec. 6.2).

Momentos populacionais e amostrais

! Definição — momentos populacionais

Seja X uma variável aleatória. Quando a esperança existe, o k -ésimo **momento em torno da origem** é

$$\mu'_k = E(X^k).$$

O k -ésimo **momento em torno de** $c \in \mathbb{R}$ é

$$E[(X - c)^k].$$

Em particular,

$$\mu = E(X)$$

e

$$\sigma^2 = E[(X - \mu)^2].$$

! Definição — momentos amostrais

Para uma amostra $X_1, \dots, X_n$, o k -ésimo momento amostral em torno da origem é

$$m'_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

O momento amostral em torno de c é

$$\frac{1}{n} \sum_{i=1}^n (X_i - c)^k.$$

Assim, $m'_1 = \bar{X}$. O segundo momento amostral em torno de $\bar{X}$ é

$$\tilde{S}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = m'_2 - (m'_1)^2.$$

! Observação — duas noções de variância amostral

A quantidade $\tilde{S}_n^2$ utiliza divisor n e é o segundo momento empírico central. Ela não deve ser confundida com a variância amostral não viesada

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

No método dos momentos, utiliza-se $\tilde{S}_n^2$, porque os momentos amostrais são definidos com divisor n (Rice, 2007, sec. 8.4).

Fundamentação probabilística

Considere uma amostra i.i.d. de uma distribuição indexada pelo verdadeiro valor θ_0 . Se

$$E_{\theta_0}(|X|^j) < \infty, \quad j = 1, \dots, d,$$

a Lei dos Grandes Números fornece, para cada j ,

$$m'_j = \frac{1}{n} \sum_{i=1}^n X_i^j \xrightarrow{p} E_{\theta_0}(X^j) = \mu'_j.$$

Defina o vetor de momentos populacionais

$$\mathbf{k}(\theta) = \begin{pmatrix} k_1(\theta) \\ \vdots \\ k_d(\theta) \end{pmatrix}$$

e o vetor correspondente de momentos amostrais

$$\mathbf{m}_n = \begin{pmatrix} m'_1 \\ \vdots \\ m'_d \end{pmatrix}.$$

Então,

$$\mathbf{m}_n \xrightarrow{p} \mathbf{k}(\theta_0).$$

! Resultado — consistência do estimador de momentos

Suponha que $\mathbf{k}$ seja injetiva no espaço paramétrico considerado e que sua inversa

$$\mathbf{g} = \mathbf{k}^{-1}$$

seja contínua em $\mathbf{k}(\theta_0)$. Se

$$\hat{\theta}^{\text{MM}} = \mathbf{g}(\mathbf{m}_n),$$

então, pelo teorema do mapeamento contínuo,

$$\hat{\theta}^{\text{MM}} \xrightarrow{p} \theta_0.$$

Essas condições são suficientes para o resultado anterior. Se as equações de momentos admitem várias soluções, deve-se especificar uma regra de seleção; a consistência dependerá também das propriedades dessa regra (Rice, 2007, secs. 5.2 e 8.4; Lauritzen, 2023, sec. 5.2).

Procedimento geral

Considere um modelo com vetor paramétrico

$$\theta = (\theta_1, \dots, \theta_d) \in \Theta \subseteq \mathbb{R}^d.$$

Suponha que os primeiros d momentos populacionais existam e possam ser escritos como

$$\mu'_j = k_j(\theta), \quad j = 1, \dots, d.$$

O método dos momentos substitui esses momentos populacionais pelos momentos correspondentes calculados na amostra.

! Definição — estimador pelo método dos momentos

Um estimador de momentos $\hat{\theta}^{\text{MM}}$ é uma solução admissível do sistema

$$m'_j = k_j\left(\hat{\theta}^{\text{MM}}\right), \quad j = 1, \dots, d.$$

Assim, o procedimento pode ser organizado em três etapas:

1. calcular d momentos populacionais como funções de θ ;
2. calcular os momentos amostrais correspondentes;
3. resolver o sistema obtido ao igualar momentos populacionais e amostrais.

Quando a transformação

$$\mathbf{k}(\theta) = \begin{pmatrix} k_1(\theta) \\ \vdots \\ k_d(\theta) \end{pmatrix}$$

possui inversa $\mathbf{g}$, o estimador pode ser escrito diretamente como

$$\hat{\theta}^{\text{MM}} = \mathbf{g}(\mathbf{m}_n).$$

A existência dessa representação explícita não é necessária para definir o método. O sistema pode não possuir solução, possuir várias soluções ou produzir valores fora do espaço paramétrico. Nesses casos, a regra de seleção, restrição ou projeção adotada deve fazer parte da especificação do estimador (Rice, 2007, sec. 8.4; Larsen; Marx, 2012, sec. 5.6; Ramachandran; Tsokos, 2021, sec. 5.2.1).

Exemplo — distribuição de Pareto

A distribuição $\text{Pareto}(1, \theta)$ está definida para $\theta > 0$. Entretanto, o método de momentos utilizado neste exemplo depende da existência do primeiro momento. Por isso, consideramos a subfamília

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Pareto}(1, \theta), \quad \theta > 1,$$

com densidade

$$f(x \mid \theta) = \theta x^{-(\theta+1)}, \quad x \geq 1.$$

Nesse espaço paramétrico,

$$E(X) = \frac{\theta}{\theta - 1}.$$

Igualando $E(X)$ a $\overline{X}$,

$$\overline{X} = \frac{\hat{\theta}}{\hat{\theta} - 1},$$

e, portanto,

$$\hat{\theta}^{\text{MM}} = \frac{\bar{X}}{\bar{X} - 1}.$$

Como $\bar{X} > 1$ quase certamente, a expressão está bem definida. Além disso, $\bar{X} \xrightarrow{p} \theta/(\theta - 1)$ e a função $g(u) = u/(u - 1)$ é contínua para $u > 1$; logo,

$$\hat{\theta}^{\text{MM}} \xrightarrow{p} \theta.$$

i Aprofundamento

A distribuição assintótica deste estimador é obtida em Seção 6.4.2.1 por meio do método delta.

Exemplo — distribuição uniforme contínua

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0,$$

então

$$E(X) = \frac{\theta}{2}, \quad \text{Var}(X) = \frac{\theta^2}{12}.$$

Igualando o primeiro momento,

$$\hat{\theta}^{\text{MM}} = 2\bar{X}.$$

O estimador é não viesado,

$$E(\hat{\theta}^{\text{MM}}) = \theta,$$

possui variância

$$\text{Var}(\hat{\theta}^{\text{MM}}) = \frac{\theta^2}{3n},$$

e é consistente pela Lei dos Grandes Números. Para o mesmo modelo, o estimador de máxima verossimilhança é $X_{(n)}$; os dois métodos produzem estimadores distintos neste modelo não regular (Chihara; Hesterberg, 2022, secs. 6.1.2 e 6.2).

Exemplo — distribuição uniforme discreta

Considere

$$P_{\theta}(X = x) = \frac{1}{\theta}, \quad x \in \{1, \dots, \theta\}, \quad \theta \in \mathbb{N}.$$

Como

$$E_{\theta}(X) = \frac{\theta + 1}{2},$$

a solução formal da equação de momentos é

$$\tilde{\theta}^{\text{MM}} = 2\bar{X} - 1.$$

Ela é não viesada e possui

$$\text{Var}(\tilde{\theta}^{\text{MM}}) = \frac{\theta^2 - 1}{3n}.$$

Entretanto, $2\bar{X} - 1$ pode não ser inteiro e pode ser menor que $X_{(n)}$. Portanto, ele é uma **solução irrestrita da equação de momentos**, mas não necessariamente uma estimativa admissível em Θ . Uma versão ajustada requer uma regra explícita de projeção para os inteiros compatíveis com a amostra; essa projeção altera, em geral, o viés e a variância.

A verossimilhança é

$$L(\theta; x) = \theta^{-n} I\{\theta \geq x_{(n)}\},$$

e o estimador de máxima verossimilhança é

$$\hat{\theta}^{\text{MV}} = X_{(n)}.$$

Este exemplo mostra que uma equação de momentos pode produzir uma solução fora do espaço paramétrico, enquanto a maximização da verossimilhança incorpora diretamente as restrições do modelo.

Exemplo — distribuição exponencial

Adote a parametrização pela taxa:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\theta), \quad f(x; \theta) = \theta e^{-\theta x} \mathbf{1}\{x \geq 0\}.$$

Como

$$E(X) = \frac{1}{\theta},$$

o estimador de momentos é

$$\boxed{\hat{\theta}^{\text{MM}} = \frac{1}{\bar{X}}}.$$

Se $S = \sum_i X_i$, então, utilizando a parametrização consolidada por forma e escala,

$$S \sim \text{Gama}\left(n, \frac{1}{\theta}\right).$$

Consequentemente, $\hat{\theta}^{\text{MM}} = n/S$ possui distribuição gama inversa, na parametrização por forma n e escala $n\theta$. Para $n > 1$,

$$E(\hat{\theta}^{\text{MM}}) = \frac{n\theta}{n-1},$$

e, para $n > 2$,

$$\text{Var}(\hat{\theta}^{\text{MM}}) = \frac{n^2\theta^2}{(n-1)^2(n-2)}.$$

O estimador é viesado para cima, mas consistente, pois $\bar{X} \xrightarrow{p} 1/\theta$ e $u \mapsto 1/u$ é contínua em $1/\theta > 0$ (Chihara; Hesterberg, 2022, secs. 6.1.2 e 6.2).

Exemplo — distribuição gama

Considere a parametrização adotada no livro, com forma $\alpha > 0$ e escala $\beta > 0$:

$$X \sim \text{Gama}(\alpha, \beta).$$

Nesse caso,

$$E(X) = \alpha\beta$$

e

$$E(X^2) = \alpha(\alpha + 1)\beta^2.$$

Como

$$\text{Var}(X) = \mu'_2 - (\mu'_1)^2 = \alpha\beta^2,$$

temos

$$\alpha = \frac{(\mu'_1)^2}{\mu'_2 - (\mu'_1)^2}$$

e

$$\beta = \frac{\mu'_2 - (\mu'_1)^2}{\mu'_1}.$$

Substituindo os momentos populacionais pelos momentos amostrais,

$$\hat{\alpha}^{\text{MM}} = \frac{\bar{X}^2}{\tilde{S}_n^2}$$

e

$$\hat{\beta}^{\text{MM}} = \frac{\tilde{S}_n^2}{\bar{X}},$$

em que

$$\tilde{S}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Para $n \geq 2$, como a distribuição gama é contínua, a probabilidade de todas as observações serem iguais é zero. Assim,

$$\tilde{S}_n^2 > 0$$

quase certamente, e os dois estimadores estão bem definidos. Eles são obtidos pela correspondência entre os dois primeiros momentos populacionais e amostrais (Rice, 2007, sec. 8.4, exemplo C).

Exercícios

1. **Distribuição angular.** Considere uma variável angular T com densidade

$$f(t | \alpha) = \frac{1}{2\pi} (1 + \alpha \cos t), \quad 0 \leq t \leq 2\pi,$$

em que $\alpha \in [-1/3, 1/3]$. Como $E(T) = \pi$ para todo α , utilize o segundo momento para obter um estimador de momentos de α .

2. **Modelo normal.** Se $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$, obtenha os estimadores de momentos de μ e σ^2 . Determine o viés e a variância de cada estimador.
3. **Consistência no modelo gama.** Demonstre, utilizando a Lei dos Grandes Números e o teorema do mapeamento contínuo, que $\hat{\alpha}^{\text{MM}}$ e $\hat{\beta}^{\text{MM}}$ são consistentes quando $\text{Var}(X) > 0$.

6.2 Máxima Verossimilhança

A função de verossimilhança foi introduzida em Capítulo 3 como uma forma de comparar valores do parâmetro à luz dos dados observados. Nesta seção, essa ideia é utilizada para **construir estimadores**: o estimador de máxima verossimilhança é obtido selecionando, entre os valores admissíveis do parâmetro, aqueles que maximizam a verossimilhança.

O método aplica-se a modelos discretos, contínuos e multiparamétricos. A maximização pode envolver soluções interiores, pontos de fronteira, múltiplos máximos ou situações em que o supremo não é atingido. Por isso, a obtenção do estimador exige examinar a função objetivo juntamente com o espaço paramétrico (Casella; Berger, 2011, sec. 7.2.2; Rice, 2007, sec. 8.5; Larsen; Marx, 2012, sec. 5.2; Ramachandran; Tsokos, 2009, sec. 5.2.2; Chihara; Hesterberg, 2022, sec. 6.1).

No percurso principal, o foco está na construção do estimador e nas ferramentas utilizadas para localizar e verificar o máximo. As condições de regularidade e as propriedades assintóticas específicas do EMV estão em Seção 6.4.2.

Ao final desta seção, o leitor deverá ser capaz de:

1. obter o estimador de máxima verossimilhança a partir de uma função de verossimilhança;
2. utilizar a log-verossimilhança e a função escore na determinação de candidatos ao máximo;
3. verificar a existência do máximo, considerar pontos de fronteira e distinguir máximos locais e globais;
4. utilizar a propriedade de invariância do EMV para estimar funções do parâmetro;
5. reconhecer situações em que a maximização requer procedimentos numéricos ou tratamento não regular.

Exemplo motivacional — moeda com probabilidade desconhecida

O exemplo é adaptado de Chihara; Hesterberg (2022, pp. 148–149).

Considere uma moeda cuja probabilidade de produzir cara é desconhecida e denotada por p . A moeda é lançada oito vezes, produzindo a sequência

$$C, C, C, K, C, K, C, K,$$

em que C representa cara e K representa coroa. Foram observadas cinco caras e três coroas. Supondo que os lançamentos sejam independentes, a probabilidade de observar exatamente essa sequência, para um valor fixado de p , é

$$p^5(1-p)^3.$$

Os dados já foram observados. Portanto, a expressão anterior pode ser examinada como uma função do parâmetro p :

$$L(p) = p^5(1-p)^3, \quad 0 \leq p \leq 1.$$

Essa função mede a verossimilhança dos diferentes valores de p em relação à sequência observada. O método de máxima verossimilhança seleciona o valor que maximiza $L(p)$.

Como o logaritmo é uma função estritamente crescente, maximizar $L(p)$ é equivalente a maximizar a log-verossimilhança

$$\ell(p) = \log(L(p)) = 5 \log(p) + 3 \log(1 - p).$$

Derivando em relação a p ,

$$\ell'(p) = \frac{5}{p} - \frac{3}{1-p}.$$

A equação $\ell'(p) = 0$ implica

$$\frac{5}{p} = \frac{3}{1-p},$$

de modo que

$$5(1-p) = 3p$$

e, conseqüentemente,

$$\hat{p} = \frac{5}{8}.$$

Além disso,

$$\ell''(p) = -\frac{5}{p^2} - \frac{3}{(1-p)^2} < 0, \quad 0 < p < 1.$$

Logo, $\hat{p} = 5/8$ é o ponto de máximo da log-verossimilhança e, portanto, da própria verossimilhança.

Interpretação

A estimativa $\hat{p} = 5/8$ indica que, entre os valores possíveis de p , o valor $5/8$ torna a sequência observada mais verossímil.

Essa afirmação não significa que a probabilidade de p ser igual a $5/8$ seja máxima. Na abordagem frequentista, p é considerado fixo, embora desconhecido, e não uma variável aleatória.

Probabilidade e verossimilhança

Na função de probabilidade ou densidade $f(x; \theta)$, considera-se o parâmetro θ fixado e o resultado x variável. Na função de verossimilhança $L(\theta; \mathbf{x})$, os dados observados $\mathbf{x}$ são

mantidos fixos, enquanto θ varia no espaço paramétrico. Consequentemente, a função de verossimilhança não é, em geral, uma distribuição de probabilidade sobre o parâmetro. Em particular, não é necessário que

$$\int_{\Theta} L(\theta; \mathbf{x}) d\theta = 1.$$

6.2.1 Definição formal

Retomando Capítulo 3, para os dados observados $\mathbf{x}$ a função

$$L_n(\theta; \mathbf{x})$$

é considerada como função de $\theta \in \Theta$, com $\mathbf{x}$ fixado. Nesta unidade, o interesse está em utilizar essa função para definir uma regra de estimação.

! Definição — estimador de máxima verossimilhança

Um **estimador de máxima verossimilhança** de θ é uma estatística $\hat{\theta}_n$ tal que

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} L_n(\theta).$$

Equivalentemente,

$$L_n(\hat{\theta}_n) \geq L_n(\theta)$$

para todo $\theta \in \Theta$.

O símbolo $\arg \max$ representa o conjunto dos valores do parâmetro nos quais a função atinge seu máximo. Por isso, a definição admite a possibilidade de existirem vários maximizadores.

Quando o máximo é único, escrevemos simplesmente

$$\hat{\theta}_{\text{MV}} = \arg \max_{\theta \in \Theta} L_n(\theta).$$

6.2.2 Existência e unicidade

A definição não garante que o estimador exista ou seja único. Podem ocorrer as seguintes situações:

- o máximo é atingido em um único ponto;
- a função possui vários máximos;
- o máximo ocorre na fronteira de Θ ;
- existe apenas um supremo que não é atingido;
- a função de verossimilhança é ilimitada;
- existem vários máximos locais.

Portanto, resolver uma equação obtida por diferenciação não é suficiente para identificar o estimador de máxima verossimilhança. Também devem ser examinados o espaço paramétrico, os pontos de fronteira e o comportamento global da função.

6.2.3 Log-verossimilhança

A log-verossimilhança é definida por

$$\ell_n(\theta) = \log L_n(\theta).$$

Para uma amostra aleatória,

$$\ell_n(\theta) = \sum_{i=1}^n \log f(X_i; \theta).$$

Como o logaritmo é estritamente crescente,

$$\arg \max_{\theta \in \Theta} L_n(\theta) = \arg \max_{\theta \in \Theta} \ell_n(\theta).$$

A log-verossimilhança é geralmente mais conveniente, pois transforma produtos em somas e reduz problemas numéricos causados pelo produto de probabilidades ou densidades muito pequenas (Ramachandran; Tsokos, 2009, sec. 5.2.2; Chihara; Hesterberg, 2022, sec. 6.1).

i Observação

A função de verossimilhança é definida a menos de um fator positivo que não dependa do parâmetro. Se

$$\tilde{L}_n(\theta) = c(\mathbf{x})L_n(\theta), \quad c(\mathbf{x}) > 0,$$

então L_n e $\tilde{L}_n$ possuem os mesmos maximizadores.

6.2.4 Invariância

! Propriedade — invariância

Se $\hat{\theta}$ maximiza $L(\theta)$ e $\eta = g(\theta)$, então

$$\hat{\eta} = g(\hat{\theta})$$

é um estimador de máxima verossimilhança de η . Quando g não é injetiva, a verossimilhança induzida de η é definida por

$$L^*(\eta) = \sup_{\theta: g(\theta)=\eta} L(\theta).$$

Por exemplo, se $\hat{\lambda}$ é o estimador da taxa de uma distribuição exponencial, o estimador de máxima verossimilhança da escala

$$\beta = \frac{1}{\lambda}$$

é

$$\hat{\beta} = \frac{1}{\hat{\lambda}}.$$

A propriedade de invariância é apresentada por Casella; Berger (2011, sec. 7.2.2), Chihara; Hesterberg (2022, pp. 171–173) e Ramachandran; Tsokos (2009, pp. 243–244).

6.2.5 Função escore e informação

6.2.5.1 Função escore

Supondo que a log-verossimilhança seja diferenciável, define-se o vetor escore por

$$\mathbf{U}_n(\theta) = \nabla_{\theta} \ell_n(\theta).$$

Se o parâmetro for escalar,

$$U_n(\theta) = \frac{\partial}{\partial \theta} \ell_n(\theta).$$

Quando o máximo ocorre no interior do espaço paramétrico, uma condição necessária para um máximo diferenciável é

$$\mathbf{U}_n(\hat{\theta}_n) = \mathbf{0}.$$

Essa expressão é denominada **equação de verossimilhança**.

Observação

Uma solução da equação de verossimilhança pode ser um máximo, um mínimo ou um ponto de sela. Em modelos multiparamétricos, também podem existir múltiplas soluções. A classificação da solução pode exigir o exame da matriz Hessiana ou a comparação direta dos valores da função de verossimilhança.

6.2.5.2 Informação observada

A matriz de informação observada é definida por

$$\mathbf{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

No caso escalar,

$$J_n(\theta) = -\frac{\partial^2}{\partial \theta^2} \ell_n(\theta).$$

A informação observada mede a curvatura local negativa da log-verossimilhança. Avaliada no máximo, uma curvatura maior corresponde, na aproximação assintótica regular, a uma menor variância estimada para o EMV, pois essa variância é obtida a partir da inversa da informação.

6.2.5.3 Informação de Fisher

A informação de Fisher e sua relação com o escore, a desigualdade de Cramér–Rao e a eficiência foram desenvolvidas em Capítulo 5. Na máxima verossimilhança, a informação aparece na descrição da curvatura da log-verossimilhança e na distribuição assintótica do EMV.

Para uma única observação e um parâmetro vetorial, utilizaremos a extensão matricial

$$\mathbf{I}_1(\theta) = E_{\theta} [\mathbf{U}_1(\theta) \mathbf{U}_1(\theta)^{\top}].$$

Sob as condições de regularidade pertinentes,

$$\mathbf{I}_1(\theta) = -E_\theta [\nabla_\theta^2 \log f(X; \theta)].$$

Para uma amostra i.i.d. de tamanho n ,

$$\mathbf{I}_n(\theta) = n\mathbf{I}_1(\theta).$$

A informação observada

$$\mathbf{J}_n(\theta) = -\nabla_\theta^2 \ell_n(\theta)$$

depende da amostra observada, enquanto $\mathbf{I}_n(\theta)$ é sua contraparte esperada sob o modelo. Essa distinção será utilizada no aprofundamento ao estudar a distribuição assintótica e a estimação do erro-padrão do EMV (Ramachandran; Tsokos, 2009, sec. 5.2.2; Chihara; Hesterberg, 2022, sec. 6.1).

Exemplos

Os exemplos desta subseção mostram a construção do EMV em modelos regulares e não regulares. Resultados sobre informação, distribuição assintótica e erro-padrão aparecem em blocos recolhíveis; sua fundamentação está em Seção 6.4.2.

Os exemplos são adaptados de Larsen; Marx (2012, sec. 5.2), Chihara; Hesterberg (2022, sec. 6.1) e Ramachandran; Tsokos (2009, sec. 5.2.2).

6.2.5.1 Exemplo — distribuição Bernoulli

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p), \quad 0 \leq p \leq 1.$$

A função de probabilidade é

$$f(x; p) = p^x (1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

A função de verossimilhança é

$$\begin{aligned} L(p) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}. \end{aligned}$$

Definindo

$$T = \sum_{i=1}^n x_i,$$

obtém-se

$$L(p) = p^T (1-p)^{n-T}.$$

A log-verossimilhança é

$$\ell(p) = T \log p + (n-T) \log(1-p).$$

O escore é

$$U(p) = \frac{T}{p} - \frac{n-T}{1-p}.$$

Para $0 < T < n$, a equação $U(p) = 0$ fornece

$$\hat{p} = \frac{T}{n} = \bar{X}.$$

Se $T = 0$, o máximo ocorre em $\hat{p} = 0$. Se $T = n$, o máximo ocorre em $\hat{p} = 1$.

i Aprofundamento — informação e comportamento assintótico

A informação de Fisher por observação é

$$I_1(p) = \frac{1}{p(1-p)}.$$

Para $0 < p < 1$, a teoria regular fornece

$$\sqrt{n}(\hat{p} - p) \xrightarrow{d} N(0, p(1-p)),$$

ou, aproximadamente,

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right).$$

Além disso,

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n},$$

que coincide com o limite inferior de Cramér–Rao para $0 < p < 1$.

Nos pontos de fronteira $p = 0$ e $p = 1$, a formulação regular baseada em um parâmetro interior não se aplica diretamente. As condições que justificam esses resultados são discutidas em Seção 6.4.2.2 e Seção 6.4.2.3.

6.2.5.2 Exemplo — distribuição de Poisson

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda), \quad \lambda > 0.$$

A função de probabilidade é

$$f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

A verossimilhança é

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \\ &= e^{-n\lambda} \lambda^{\sum_{i=1}^n x_i} \prod_{i=1}^n \frac{1}{x_i!}. \end{aligned}$$

A log-verossimilhança é

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i\right) \log \lambda - \sum_{i=1}^n \log(x_i!).$$

O escore é

$$U(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda}.$$

Defina

$$T = \sum_{i=1}^n x_i.$$

Se $T > 0$, a equação de verossimilhança fornece

$$\hat{\lambda} = \frac{T}{n} = \bar{X}.$$

Além disso,

$$\ell''(\lambda) = -\frac{T}{\lambda^2} < 0,$$

de modo que a log-verossimilhança é estritamente côncava e essa solução é o máximo único.

Se $T = 0$, entretanto,

$$\ell(\lambda) = -n\lambda, \quad \lambda > 0,$$

é estritamente decrescente. Nesse caso,

$$\sup_{\lambda > 0} L(\lambda)$$

é obtido no limite $\lambda \downarrow 0$, mas não é atingido em $\Theta = (0, \infty)$. Portanto, com esse espaço paramétrico, o EMV não existe quando todas as observações são zero.

i Observação

Se o modelo for estendido para permitir $\lambda = 0$, interpretando $\text{Poisson}(0)$ como a distribuição degenerada em zero, então

$$\hat{\lambda} = \bar{X}$$

vale para todas as amostras.

i Aprofundamento — informação e comportamento assintótico

A informação de Fisher por observação é

$$I_1(\lambda) = \frac{1}{\lambda}.$$

Sob as condições de regularidade,

$$\sqrt{n}(\hat{\lambda} - \lambda) \xrightarrow{d} N(0, \lambda).$$

Consequentemente, o erro-padrão assintótico pode ser estimado por

$$\widehat{\text{EP}}(\hat{\lambda}) = \sqrt{\frac{\hat{\lambda}}{n}}.$$

A justificativa geral desses resultados é apresentada em Seção [6.4.2.3](#).

6.2.5.3 Exemplo — distribuição exponencial

Considere a parametrização da distribuição exponencial pela taxa:

$$f(x; \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0, \quad \lambda > 0.$$

Para uma amostra aleatória,

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n \lambda e^{-\lambda x_i} \\ &= \lambda^n \exp \left(-\lambda \sum_{i=1}^n x_i \right). \end{aligned}$$

A log-verossimilhança é

$$\ell(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n x_i.$$

O escore é

$$U(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n x_i.$$

Se

$$\sum_{i=1}^n x_i > 0,$$

a equação de verossimilhança fornece

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n X_i} = \frac{1}{\bar{X}}.$$

Como

$$\ell''(\lambda) = -\frac{n}{\lambda^2} < 0,$$

essa solução é o máximo único.

Sob uma distribuição exponencial contínua com $\lambda > 0$,

$$P_{\lambda} \left(\sum_{i=1}^n X_i > 0 \right) = 1,$$

de modo que o EMV anterior existe quase certamente. Se todas as observações forem exatamente zero, evento de probabilidade zero sob o modelo, a verossimilhança cresce sem limite quando $\lambda \rightarrow \infty$ e não existe um máximo finito.

i Aprofundamento — informação e comportamento assintótico

A informação de Fisher por observação é

$$I_1(\lambda) = \frac{1}{\lambda^2}.$$

Sob as condições de regularidade,

$$\sqrt{n}(\hat{\lambda} - \lambda) \xrightarrow{d} N(0, \lambda^2),$$

e o erro-padrão assintótico pode ser estimado por

$$\widehat{\text{EP}}(\hat{\lambda}) = \frac{\hat{\lambda}}{\sqrt{n}}.$$

A fundamentação geral é apresentada em Seção 6.4.2.3.

Se a distribuição for parametrizada pela escala

$$\beta = \frac{1}{\lambda},$$

a propriedade de invariância fornece

$$\hat{\beta} = \frac{1}{\hat{\lambda}} = \overline{X}.$$

6.2.5.4 Exemplo — distribuição normal com média e variância desconhecidas

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

em que

$$-\infty < \mu < \infty \quad \text{e} \quad \sigma^2 > 0.$$

A função de verossimilhança é

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right].$$

A log-verossimilhança é

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Derivando em relação a μ ,

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu).$$

Assim,

$$\hat{\mu} = \overline{X}.$$

Derivando em relação a σ^2 ,

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2.$$

Substituindo $\hat{\mu} = \overline{X}$ e supondo que $\sum_i (X_i - \overline{X})^2 > 0$,

$$\hat{\sigma}_{\text{MV}}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

i Observação — existência e viés

Se todas as observações forem iguais, a verossimilhança cresce quando μ se aproxima desse valor e $\sigma^2 \downarrow 0$; como o espaço paramétrico exige $\sigma^2 > 0$, o supremo não é atingido. Fora desse caso degenerado, o estimador de máxima verossimilhança de σ^2 utiliza o divisor n , e não $n - 1$. Em amostras finitas,

$$E[\hat{\sigma}_{\text{MV}}^2] = \frac{n-1}{n} \sigma^2.$$

Portanto, ele é viesado. Entretanto,

$$\hat{\sigma}_{\text{MV}}^2 \xrightarrow{p} \sigma^2,$$

de modo que o estimador é consistente.

i Aprofundamento — informação e comportamento assintótico

Para

$$\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix},$$

a informação de Fisher por observação é

$$\mathbf{I}_1(\theta) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 1/(2\sigma^4) \end{pmatrix}.$$

Sob as condições de regularidade,

$$\sqrt{n} \begin{pmatrix} \hat{\mu} - \mu \\ \hat{\sigma}_{\text{MV}}^2 - \sigma^2 \end{pmatrix} \xrightarrow{d} N_2 \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma^2 & 0 \\ 0 & 2\sigma^4 \end{pmatrix} \right].$$

Este é um exemplo multiparamétrico da normalidade assintótica apresentada em Seção 6.4.2.3.

6.2.5.5 Exemplo não regular — distribuição uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0.$$

A densidade é

$$f(x; \theta) = \frac{1}{\theta} \mathbf{1}\{0 \leq x \leq \theta\}.$$

A verossimilhança é

$$L(\theta) = \theta^{-n} \mathbf{1}\{\theta \geq X_{(n)}\}.$$

em que

$$X_{(n)} = \max\{X_1, \dots, X_n\}.$$

Para $\theta \geq X_{(n)}$, a função θ^{-n} é decrescente. Portanto, seu maior valor é obtido no menor valor admissível de θ :

$$\hat{\theta} = X_{(n)}.$$

Nesse modelo, o suporte

$$[0, \theta]$$

depende do parâmetro. Portanto, não se deve aplicar mecanicamente a teoria regular baseada na diferenciação da log-verossimilhança.

i Aprofundamento — comportamento assintótico não regular

Apesar de o modelo não satisfazer a estrutura regular utilizada para a teoria usual do EMV, o estimador

$$\hat{\theta} = X_{(n)}$$

é consistente.

Além disso, sua distribuição limite não é normal na escala $\sqrt{n}$. De fato,

$$\frac{n(\theta - X_{(n)})}{\theta} \xrightarrow{d} \text{Exp}(1).$$

Para verificar esse resultado, considere $t > 0$. Então,

$$\begin{aligned}
 P_\theta \left[\frac{n(\theta - X_{(n)})}{\theta} > t \right] &= P_\theta \left[X_{(n)} < \theta \left(1 - \frac{t}{n} \right) \right] \\
 &= \left(1 - \frac{t}{n} \right)^n \\
 &\rightarrow e^{-t}.
 \end{aligned}$$

Portanto, neste modelo,

$$\theta - X_{(n)} = O_p(n^{-1}),$$

em contraste com a escala $n^{-1/2}$ típica dos modelos regulares. O limite é exponencial, e não normal.

Este exemplo ilustra concretamente por que a teoria de Seção 6.4.2.2 não deve ser aplicada quando o suporte depende do parâmetro.

6.2.6 Procedimento geral de obtenção do estimador

A obtenção de um estimador de máxima verossimilhança pode ser organizada pelo seguinte roteiro:

1. especificar o modelo estatístico e o espaço paramétrico Θ ;
2. escrever a função de verossimilhança para os dados observados;
3. eliminar, quando conveniente, fatores positivos que não dependem do parâmetro;
4. utilizar a log-verossimilhança quando ela simplificar a maximização;
5. obter candidatos ao máximo por diferenciação, pela função escore ou por um método de otimização compatível com a função objetivo e as restrições do problema;
6. verificar se os candidatos pertencem ao espaço paramétrico;
7. examinar pontos de fronteira e outros casos que não sejam obtidos pelas condições de primeira ordem;
8. classificar os candidatos e comparar os valores da função objetivo para identificar o máximo global.

 A equação de verossimilhança não é o método

Resolver

$$\mathbf{U}_n(\theta) = \mathbf{0}$$

é apenas uma forma de localizar candidatos a máximos interiores quando a log-verossimilhança é diferenciável. O estimador de máxima verossimilhança é definido pela **maximização da verossimilhança**, e não pela solução da equação de escore. Modelos com suporte dependente do parâmetro, máximos na fronteira ou funções não diferenciáveis podem exigir outros argumentos.

Quando não existe solução analítica, a maximização pode ser realizada numericamente. Métodos como Newton–Raphson, escore de Fisher e algoritmos quase-Newton são alternativas usuais. Para dados incompletos ou variáveis latentes, Seção 6.4.3 apresenta o algoritmo EM (Ramachandran; Tsokos, 2009).

Aprofundamento

Depois de construído o EMV, podem-se investigar suas propriedades estatísticas. As condições de regularidade, a consistência, a distribuição assintótica e a estimação do erro-padrão são tratadas em Seção 6.4.2.3. A construção de intervalos de confiança a partir dessas aproximações pertence à unidade de estimação intervalar.

6.2.7 Exercícios

Exercício 1 — Modelo Bernoulli

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

1. Obtenha a função de verossimilhança.
2. Mostre que

$$\hat{p} = \bar{X}.$$

3. Examine separadamente os casos $\sum X_i = 0$ e $\sum X_i = n$.
4. Calcule a informação de Fisher.
5. Mostre que $\hat{p}$ atinge o limite inferior de Cramér–Rao.
6. Obtenha a distribuição assintótica de $\hat{p}$.

Fonte: exercício adaptado de Chihara; Hesterberg (2022, p. 176) e Ramachandran; Tsokos (2009, pp. 244, 275–276).

💡 Exercício 2 — Contagens de Poisson

O número diário de falhas de um equipamento é modelado por uma distribuição de Poisson com parâmetro λ . Em dez dias, foram observadas as contagens

2, 0, 1, 3, 2, 4, 1, 0, 2, 5.

1. Obtenha o estimador de máxima verossimilhança de λ .
2. Calcule a estimativa correspondente.
3. Calcule a informação de Fisher.
4. Estime o erro-padrão assintótico de $\hat{\lambda}$.
5. Escreva a distribuição normal aproximada de $\hat{\lambda}$ utilizando a estimativa obtida para λ .
6. Discuta por que a aproximação normal pode exigir cautela quando o tamanho amostral é pequeno ou quando a taxa é baixa.

Fonte: elaboração própria, com base em Chihara; Hesterberg (2022, pp. 150–151) e Ramachandran; Tsokos (2009, pp. 238–239, 275).

💡 Exercício 3 — Distribuição exponencial

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

na parametrização pela taxa.

1. Mostre que

$$\hat{\lambda} = \frac{1}{\bar{X}}.$$

2. Determine o viés exato de $\hat{\lambda}$, supondo $n > 1$.
3. Verifique que $\hat{\lambda}$ é consistente.
4. Calcule a informação de Fisher.
5. Obtenha a distribuição assintótica de $\hat{\lambda}$.
6. Use a propriedade de invariância para obter o estimador da média da distribuição.

Fonte: exercício adaptado de Chihara; Hesterberg (2022, pp. 151–152) e Ramachandran; Tsokos (2009, p. 244).

💡 Exercício 4 — Família de potências

Considere a família de densidades

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0.$$

1. Obtenha a função de verossimilhança.
2. Mostre que

$$\hat{\theta} = -\frac{n}{\sum_{i=1}^n \log X_i}.$$

3. Verifique que a solução corresponde a um máximo.
4. Calcule $I_1(\theta)$.
5. Determine a distribuição assintótica de $\hat{\theta}$.
6. Obtenha uma estimativa do erro-padrão assintótico de $\hat{\theta}$ substituindo θ por $\hat{\theta}$ na expressão correspondente.

Fonte: exercício adaptado de Chihara; Hesterberg (2022, pp. 152, 173–174) e Larsen; Marx (2012, p. 292).

💡 Exercício 5 — Modelo normal

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com ambos os parâmetros desconhecidos.

1. Derive os estimadores de máxima verossimilhança de μ e σ^2 .
2. Mostre que o estimador de σ^2 é viesado.
3. Demonstre que ele é consistente.
4. Calcule a matriz de informação de Fisher.
5. Obtenha a matriz de covariâncias assintótica dos estimadores.
6. Utilize a propriedade de invariância para obter o estimador de máxima verossimilhança de σ .
7. Compare o estimador de σ^2 com a variância amostral não viesada.

Fonte: exercício adaptado de Chihara; Hesterberg (2022, pp. 155–157, 176–177) e Larsen; Marx (2012, pp. 290–291).

💡 Exercício 6 — Suporte dependente do parâmetro

Sejam

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Unif}(\theta, \theta + 1), \quad \theta \in \mathbb{R}.$$

1. Escreva a função de verossimilhança.
2. Mostre que a verossimilhança é positiva se, e somente se,

$$X_{(n)} - 1 \leq \theta \leq X_{(1)}.$$

3. Determine o conjunto dos estimadores de máxima verossimilhança.
4. Verifique se o estimador é único.
5. Identifique as condições de regularidade que não são satisfeitas.
6. Explique por que a diferenciação da log-verossimilhança não resolve o problema.

Fonte: elaboração própria, com base em Chihara; Hesterberg (2022, pp. 152–154).

💡 Exercício 7 — Existência do estimador

Considere a densidade

$$f(x; \theta) = e^{\theta - x}, \quad x > \theta > 0.$$

1. Escreva a função de verossimilhança.
2. Determine os valores de θ para os quais a verossimilhança é positiva.
3. Mostre que, se o suporte for definido por $x > \theta$, o supremo da verossimilhança não é atingido.
4. Conclua que o estimador de máxima verossimilhança não existe.
5. Repita a análise substituindo a restrição $x > \theta$ por $x \geq \theta$.
6. Explique a diferença entre máximo e supremo nesse problema.

Fonte: exercício adaptado de Chihara; Hesterberg (2022, p. 177).

💡 Exercício 8 — Invariância

Suponha que $\hat{\lambda}$ seja o estimador de máxima verossimilhança da taxa $\lambda > 0$ de uma distribuição exponencial.

Obtenha os estimadores de máxima verossimilhança de:

$$\beta = \frac{1}{\lambda},$$

$$m = \frac{\log 2}{\lambda},$$

e

$$v = \frac{1}{\lambda^2},$$

em que β é a escala, m é a mediana e v é a variância da distribuição.

Em seguida, utilize o método delta para obter as distribuições assintóticas dos três estimadores.

Fonte: elaboração própria, com base em Chihara; Hesterberg (2022, pp. 171–173) e Ramachandran; Tsokos (2009, pp. 243–244).

💡 Exercício 9 — Padronização e erro-padrão assintóticos

Seja $\hat{\theta}_n$ o estimador de máxima verossimilhança de um parâmetro escalar θ , e suponha que

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, I_1(\theta)^{-1}).$$

1. Mostre que, sob as condições que permitem substituir θ por um estimador consistente,

$$\frac{\hat{\theta}_n - \theta}{\sqrt{1/[nI_1(\hat{\theta}_n)]}} \xrightarrow{d} N(0, 1).$$

2. Mostre que

$$\widehat{\text{EP}}(\hat{\theta}_n) = \sqrt{\frac{1}{nI_1(\hat{\theta}_n)}}$$

é a estimativa do erro-padrão assintótico baseada na informação de Fisher.

3. Aplique o resultado ao parâmetro p de uma distribuição Bernoulli.
4. Aplique o resultado ao parâmetro de escala de uma distribuição exponencial.
5. Explique quais condições do modelo devem ser verificadas antes de utilizar essa aproximação normal.

Fonte: exercício adaptado de Ramachandran; Tsokos (2009, pp. 334–336).

💡 Exercício 10 — Otimização numérica

Considere uma amostra $X_1, \dots, X_n$ de uma distribuição gama com densidade

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha) \beta^\alpha}, \quad x > 0,$$

em que $\alpha > 0$ e $\beta > 0$ são desconhecidos.

1. Escreva a log-verossimilhança.
2. Obtenha as duas equações de verossimilhança.
3. Mostre que a equação referente a α envolve a função digama.
4. Explique por que não há, em geral, solução algébrica fechada.
5. Descreva como o método de Newton–Raphson poderia ser empregado.
6. Indique quais verificações devem ser realizadas para confirmar que a solução numérica é um máximo global.

Fonte: elaboração própria, com base em Ramachandran; Tsokos (2009, pp. 243, 285–289) e Shao (2005, pp. 175–182).

6.2.8 Síntese

i Síntese da seção

A estimação por máxima verossimilhança transforma a verossimilhança em uma função objetivo e seleciona os valores paramétricos que a maximizam:

$$\hat{\theta}_{MV} \in \arg \max_{\theta \in \Theta} L_n(\theta).$$

A log-verossimilhança e a função escore são ferramentas para localizar candidatos ao máximo, mas não substituem a verificação do espaço paramétrico, das fronteiras e do comportamento global da função.

A propriedade de invariância permite transportar o EMV para funções do parâmetro. Quando a maximização não possui solução analítica, métodos numéricos ou algoritmos específicos podem ser empregados.

Depois de construído o estimador, uma segunda questão é estudar seu comportamento estatístico. As condições sob as quais o EMV é consistente, assintoticamente normal e assintoticamente eficiente são examinadas em Seção 6.4.2.3. Modelos não regulares mostram por que essas propriedades não devem ser pressupostas apenas porque o estimador foi obtido por máxima verossimilhança.

6.3 Mínimos Quadrados

O método dos mínimos quadrados estima parâmetros minimizando a soma dos quadrados das discrepâncias entre valores observados e valores previstos. O critério é usado em regressão linear, modelos polinomiais e problemas não lineares. Sua interpretação inferencial depende das hipóteses adotadas para os erros (Casella; Berger, 2011, secs. 11.3.1–11.3.4; Rice, 2007, chap. 14; Ramachandran; Tsokos, 2021, sec. 7.2.1).

A perda quadrática atribui peso crescente a resíduos de maior magnitude. Por exemplo, um resíduo igual a 4 contribui com 16 para a função objetivo, enquanto um resíduo igual a 2 contribui com 4. Essa forma quadrática simplifica a otimização e torna o ajuste sensível a observações atípicas (Diez; Barr; Çetinkaya-Rundel, 2014, p. 229; Rice, 2007, p. 556).

i Observação

O critério de mínimos quadrados, isoladamente, é um problema de otimização. Para interpretar os estimadores probabilisticamente, calcular erros-padrão ou realizar testes de hipóteses, é necessário especificar um modelo estatístico para os erros.

Ao final desta seção, o leitor deverá ser capaz de:

1. definir formalmente um estimador de mínimos quadrados;
2. obter as equações normais de um modelo linear;
3. interpretar geometricamente o ajuste de mínimos quadrados;
4. derivar os estimadores da regressão linear simples;
5. estabelecer a relação entre mínimos quadrados e máxima verossimilhança;
6. reconhecer situações em que mínimos quadrados ponderados são apropriados.

6.3.1 Exemplo motivacional — renda familiar e auxílio financeiro

Considere um estudo no qual se deseja investigar a relação entre a renda familiar de estudantes e o valor do auxílio financeiro concedido por uma universidade.

Para uma amostra de 50 estudantes, sejam:

- X : renda familiar, em milhares de dólares;
- Y : auxílio financeiro, em milhares de dólares.

As estatísticas amostrais foram:

$$\bar{x} = 101,8, \quad s_x = 63,2,$$

$$\bar{y} = 19,94, \quad s_y = 5,46,$$

e

$$r = -0,499,$$

em que r é o coeficiente de correlação amostral.

O objetivo é construir uma reta

$$\hat{y} = b_0 + b_1x$$

que represente a tendência linear dos dados. Para cada observação (x_i, y_i) , define-se o valor ajustado

$$\hat{y}_i = b_0 + b_1x_i$$

e o respectivo resíduo

$$e_i = y_i - \hat{y}_i.$$

O método dos mínimos quadrados escolhe b_0 e b_1 de modo a minimizar

$$\text{SQRes}(b_0, b_1) = \sum_{i=1}^n [y_i - (b_0 + b_1x_i)]^2.$$

Na regressão linear simples, o coeficiente angular pode ser calculado por

$$b_1 = r \frac{s_y}{s_x}.$$

Portanto,

$$\begin{aligned} b_1 &= -0,499 \left(\frac{5,46}{63,2} \right) \\ &\approx -0,0431. \end{aligned}$$

Como a reta de mínimos quadrados passa pelo ponto $(\bar{x}, \bar{y})$,

$$b_0 = \bar{y} - b_1 \bar{x}.$$

Assim,

$$\begin{aligned} b_0 &= 19,94 - (-0,0431)(101,8) \\ &\approx 24,3. \end{aligned}$$

A reta ajustada é, portanto,

$$\hat{y} = 24,3 - 0,0431x.$$

Interpretação

Como as duas variáveis estão expressas em milhares de dólares, um aumento de mil dólares na renda familiar está associado, segundo o modelo ajustado, a uma redução média estimada de aproximadamente

$$0,0431 \times 1000 = 43,10$$

dólares no auxílio financeiro.

Essa interpretação descreve uma associação linear amostral. Ela não estabelece, por si só, uma relação causal.

Extrapolação

A equação ajustada deve ser interpretada no intervalo de rendas representado pelos dados. Para rendas muito superiores às observadas, a reta pode produzir valores negativos de auxílio, incompatíveis com a variável analisada.

Um bom ajuste dentro da região observada não garante que a relação linear continue válida fora dela.

Fonte: exemplo adaptado de Diez; Barr; Çetinkaya-Rundel (2014, pp. 227–233).

6.3.2 Definição formal

6.3.2.1 Formulação geral

Considere observações

$$(x_1, y_1), \dots, (x_n, y_n),$$

em que x_i representa o valor da variável explicativa e y_i o valor observado da resposta. Um modelo paramétrico para a variável aleatória resposta pode ser escrito como

$$Y_i = m(x_i; \theta) + \varepsilon_i, \quad i = 1, \dots, n,$$

em que:

- $m(x_i; \theta)$ é a componente sistemática do modelo;
- $\theta \in \Theta$ é um vetor de parâmetros;
- ε_i representa o erro aleatório associado à observação i .

Para os dados observados e um valor particular de θ , define-se o resíduo por

$$e_i(\theta) = y_i - m(x_i; \theta).$$

! Definição — estimador de mínimos quadrados

Um estimador de mínimos quadrados de θ é qualquer solução de

$$\hat{\theta}_{\text{MQ}} \in \arg \min_{\theta \in \Theta} Q_n(\theta),$$

em que

$$Q_n(\theta) = \sum_{i=1}^n [y_i - m(x_i; \theta)]^2.$$

A função $Q_n(\theta)$ é denominada soma de quadrados dos resíduos (Rice, 2007, chap. 14; Ramachandran; Tsokos, 2021, sec. 7.2.1).

A definição não exige que $m(x_i; \theta)$ seja linear em x_i . Um modelo é linear nos parâmetros quando θ aparece linearmente na função m , mesmo que a relação com as variáveis explicativas seja não linear.

6.3.2.2 Modelos lineares nos parâmetros

Um modelo é linear nos parâmetros quando pode ser escrito como

$$Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{i,p-1} + \varepsilon_i.$$

Em notação matricial,

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

em que

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_{p-1} \end{pmatrix},$$

e $\mathbf{X}$ é a matriz de planejamento de dimensão $n \times p$.

O critério de mínimos quadrados ordinários é

$$Q(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2.$$

Equivalentemente,

$$Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

Derivando em relação a β ,

$$\nabla_\beta Q(\beta) = -2\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\hat{\beta}) = \mathbf{0}.$$

Portanto,

$$\mathbf{X}^\top \mathbf{X}\hat{\beta} = \mathbf{X}^\top \mathbf{Y}.$$

! Definição — equações normais

As equações

$$\mathbf{X}^\top \mathbf{X}\hat{\beta} = \mathbf{X}^\top \mathbf{Y}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se $\mathbf{X}$ possui posto completo, isto é,

$$\text{posto}(\mathbf{X}) = p,$$

então $\mathbf{X}^\top \mathbf{X}$ é não singular e a solução é única:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Essa é a expressão matricial do estimador de mínimos quadrados ordinários (Rice, 2007, pp. 565–567).

⚠ Observação computacional

A expressão

$$(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

é útil para o desenvolvimento teórico, mas não se recomenda calcular explicitamente a inversa de $\mathbf{X}^\top \mathbf{X}$ em aplicações computacionais.

A decomposição QR permite resolver o problema de mínimos quadrados sem formar explicitamente essa inversa e tende a apresentar melhor estabilidade numérica. A decomposição de Cholesky pode ser eficiente quando $\mathbf{X}^\top \mathbf{X}$ é positiva definida e o problema é bem condicionado. Quando há forte dependência linear entre as colunas de $\mathbf{X}$, métodos baseados em QR ou na decomposição em valores singulares são preferíveis.

6.3.2.3 Interpretação geométrica

O vetor ajustado é

$$\hat{\mathbf{Y}} = \mathbf{X} \hat{\beta}.$$

Quando $\mathbf{X}$ possui posto completo,

$$\hat{\mathbf{Y}} = \mathbf{P}_X \mathbf{Y},$$

em que

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

é a matriz de projeção sobre o espaço gerado pelas colunas de $\mathbf{X}$.

O vetor de resíduos é

$$\hat{\varepsilon} = \mathbf{Y} - \hat{\mathbf{Y}}.$$

Das equações normais,

$$\mathbf{X}^T \hat{\varepsilon} = \mathbf{0}.$$

Logo, o vetor de resíduos é ortogonal a todas as colunas de $\mathbf{X}$. Geometricamente, $\hat{\mathbf{Y}}$ é a projeção ortogonal de $\mathbf{Y}$ no espaço dos valores que podem ser produzidos pelo modelo linear (Cox, 2006, pp. 10–11; Rice, 2007, pp. 565–567).

i Consequência

Quando o modelo contém intercepto, uma das colunas de $\mathbf{X}$ é formada exclusivamente por valores iguais a 1. Nesse caso,

$$\sum_{i=1}^n \hat{\varepsilon}_i = 0.$$

Consequentemente,

$$\overline{\hat{Y}} = \bar{Y}.$$

6.3.2.4 Regressão linear simples

Considere o modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

O critério é

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2.$$

As equações normais são

$$\sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i$$

e

$$\sum_{i=1}^n x_i Y_i = \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2.$$

Defina

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})$$

e

$$S_{yy} = \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

Se $S_{xx} > 0$, os estimadores são

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

e

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}.$$

Utilizando o coeficiente de correlação amostral,

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}},$$

também se obtém

$$\hat{\beta}_1 = r \frac{s_Y}{s_X}.$$

A identidade

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

mostra que a reta de mínimos quadrados sempre passa pelo ponto

$$(\bar{x}, \bar{Y}).$$

6.3.3 Relação com o método de máxima verossimilhança

6.3.3.1 Modelo normal homoscedástico

Considere o modelo linear

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

com

$$\varepsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

Equivalentemente,

$$Y_i \mid \mathbf{x}_i \sim N(\mathbf{x}_i^\top \beta, \sigma^2),$$

independentemente para $i = 1, \dots, n$.

A função de verossimilhança é

$$L(\beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta) \right].$$

A log-verossimilhança é

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} Q(\beta),$$

em que

$$Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

Para um valor fixado de σ^2 , os dois primeiros termos não dependem de β . Além disso,

$$-\frac{1}{2\sigma^2} < 0.$$

Portanto, para todo $\sigma^2 > 0$ fixado,

$$\arg \max_{\beta} \ell(\beta, \sigma^2) = \arg \min_{\beta} Q(\beta).$$

Assim, sempre que o estimador de máxima verossimilhança conjunto de (β, σ^2) existir, sua componente correspondente a β satisfaz

$$\hat{\beta}_{\text{MV}} = \hat{\beta}_{\text{MQ}}.$$

Em um modelo com erros normais, independentes e de variância constante, a maximização da verossimilhança em relação aos coeficientes da média conduz, portanto, ao mesmo problema de otimização definido pelos mínimos quadrados ordinários (Hastie; Tibshirani; Friedman, 2009, pp. 30–31).

! Resultado

A equivalência ocorre porque, no modelo normal, maximizar a verossimilhança em relação aos parâmetros da média é equivalente a minimizar

$$\sum_{i=1}^n [Y_i - m(x_i; \theta)]^2.$$

6.3.3.2 Estimação da variância

Substituindo $\hat{\beta}$ na log-verossimilhança, defina

$$\text{SQRes} = \|\mathbf{Y} - \mathbf{X}\hat{\beta}\|^2.$$

A log-verossimilhança perfilada em σ^2 é

$$\ell_p(\sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\text{SQRes}}{2\sigma^2}.$$

Se

$$\text{SQRes} > 0,$$

a condição de primeira ordem fornece

$$-\frac{n}{2\sigma^2} + \frac{\text{SQRes}}{2\sigma^4} = 0,$$

e, portanto,

$$\hat{\sigma}_{\text{MV}}^2 = \frac{\text{SQRes}}{n}.$$

Se $\text{SQRes} = 0$, por outro lado,

$$\ell_p(\sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2),$$

que cresce sem limite quando $\sigma^2 \downarrow 0$. Como o espaço paramétrico exige $\sigma^2 > 0$, nesse caso o estimador de máxima verossimilhança conjunto não existe.

No modelo normal com $\mathbf{X}$ de posto p e $n > p$,

$$\frac{\text{SQRes}}{\sigma^2} \sim \chi_{n-p}^2.$$

Consequentemente,

$$E(\text{SQRes}) = (n - p)\sigma^2.$$

Assim,

$$\hat{\sigma}_{\text{MV}}^2 = \frac{\text{SQRes}}{n}$$

é viesado em amostras finitas, enquanto

$$s^2 = \frac{\text{SQRes}}{n - p}$$

é não viesado para σ^2 .

i Observação

No modelo de regressão linear simples com intercepto e inclinação,

$$p = 2,$$

de modo que

$$s^2 = \frac{\text{SQRes}}{n - 2}.$$

Quando $n > p$, sob o modelo normal contínuo e com $\mathbf{X}$ de posto completo,

$$P(\text{SQRes} > 0) = 1.$$

Assim, o caso de inexistência associado a $\text{SQRes} = 0$ possui probabilidade zero nesse cenário.

A diferença entre os divisores n e $n - p$ ilustra que a estimação por máxima verossimilhança não produz necessariamente estimadores não viesados em amostras finitas (Cox, 2006, pp. 145–146; Rice, 2007, pp. 575–576).

6.3.3.3 Quando a equivalência não ocorre

A coincidência entre mínimos quadrados ordinários e máxima verossimilhança depende da distribuição dos erros.

Observação

Se os erros não possuem distribuição normal, o estimador de mínimos quadrados continua definido, mas não é necessariamente o estimador de máxima verossimilhança. Por exemplo, para determinados modelos com erros de caudas mais pesadas, o critério de máxima verossimilhança pode penalizar os resíduos de maneira diferente da função quadrática.

Aprofundamento — teorema de Gauss–Markov

A normalidade não é necessária para calcular o estimador de mínimos quadrados. Sob as condições

$$E(\varepsilon \mid \mathbf{X}) = \mathbf{0}$$

e

$$\text{Var}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n,$$

e supondo que $\mathbf{X}$ tenha posto completo, o teorema de Gauss–Markov estabelece que $\hat{\beta}$ é o melhor estimador linear não viesado.

Mais precisamente, para qualquer outro estimador linear não viesado $\tilde{\beta}$,

$$\text{Cov}(\tilde{\beta} \mid \mathbf{X}) - \text{Cov}(\hat{\beta} \mid \mathbf{X})$$

é positiva semidefinida.

A normalidade não é necessária para o resultado de Gauss–Markov. Sob normalidade, contudo, a log-verossimilhança possui forma quadrática nos resíduos e a equivalência entre mínimos quadrados e máxima verossimilhança decorre diretamente. Sem normalidade, o estimador de mínimos quadrados continua definido e pode conservar a propriedade de Gauss–Markov sob as condições anteriores, mas não coincide necessariamente com o estimador de máxima verossimilhança (Rice, 2007, sec. 14.4).

6.3.3.4 Mínimos quadrados ponderados

Considere erros independentes com variâncias conhecidas e não constantes:

$$\text{Var}(\varepsilon_i) = \sigma_i^2.$$

Se

$$\varepsilon_i \sim N(0, \sigma_i^2),$$

a log-verossimilhança contém o termo

$$-\frac{1}{2} \sum_{i=1}^n \frac{(Y_i - \mathbf{x}_i^\top \beta)^2}{\sigma_i^2}.$$

Portanto, a maximização da verossimilhança equivale à minimização de

$$Q_P(\beta) = \sum_{i=1}^n w_i (Y_i - \mathbf{x}_i^\top \beta)^2,$$

em que

$$w_i = \frac{1}{\sigma_i^2}.$$

! Definição — mínimos quadrados ponderados

O estimador de mínimos quadrados ponderados é

$$\hat{\beta}_{\text{MQP}} \in \arg \min_{\beta} (\mathbf{Y} - \mathbf{X}\beta)^{\top} \mathbf{W} (\mathbf{Y} - \mathbf{X}\beta),$$

em que

$$\mathbf{W} = \text{diag}(w_1, \dots, w_n).$$

Se $\mathbf{X}^{\top} \mathbf{W} \mathbf{X}$ é não singular,

$$\hat{\beta}_{\text{MQP}} = (\mathbf{X}^{\top} \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{W} \mathbf{Y}.$$

Observações com maior variância recebem menor peso.

Mais geralmente, se

$$\text{Cov}(\varepsilon) = \Sigma,$$

em que Σ é conhecida e positiva definida, o critério de **mínimos quadrados generalizados** é

$$Q_G(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^{\top} \Sigma^{-1} (\mathbf{Y} - \mathbf{X}\beta).$$

Quando

$$\mathbf{X}^{\top} \Sigma^{-1} \mathbf{X}$$

é não singular, o estimador é

$$\hat{\beta}_{\text{MQG}} = (\mathbf{X}^{\top} \Sigma^{-1} \mathbf{X})^{-1} \mathbf{X}^{\top} \Sigma^{-1} \mathbf{Y}.$$

Os mínimos quadrados ponderados correspondem ao caso particular em que Σ é diagonal (Rice, 2007, pp. 593–594; Cox, 2006, pp. 157–158).

6.3.4 Exemplos

6.3.4.1 Exemplo — estimação de uma média

Considere o modelo

$$Y_i = \mu + \varepsilon_i, \quad i = 1, \dots, n.$$

Nesse caso, todos os valores são aproximados por uma mesma constante μ . O critério de mínimos quadrados é

$$Q(\mu) = \sum_{i=1}^n (Y_i - \mu)^2.$$

Derivando,

$$Q'(\mu) = -2 \sum_{i=1}^n (Y_i - \mu).$$

A condição $Q'(\hat{\mu}) = 0$ fornece

$$\sum_{i=1}^n (Y_i - \hat{\mu}) = 0.$$

Logo,

$$\sum_{i=1}^n Y_i - n\hat{\mu} = 0$$

e

$$\boxed{\hat{\mu}_{\text{MQ}} = \bar{Y}}.$$

A segunda derivada é

$$Q''(\mu) = 2n > 0,$$

confirmando que a solução corresponde ao mínimo global.

i Interpretação

A média amostral é a constante que minimiza a soma dos quadrados das distâncias entre as observações e um valor central.

Essa caracterização é específica da perda quadrática. A mediana, por sua vez, minimiza a soma dos valores absolutos dos desvios.

Fonte: elaboração própria, com base em Ramachandran; Tsokos (2021, sec. 7.2.1).

6.3.4.2 Exemplo — ajuste de uma reta

Considere os dados:

x_i	y_i
1	2
2	3
3	5
4	4

As médias são

$$\bar{x} = \frac{1 + 2 + 3 + 4}{4} = 2,5$$

e

$$\bar{y} = \frac{2 + 3 + 5 + 4}{4} = 3,5.$$

Calculando S_{xx} ,

$$\begin{aligned} S_{xx} &= (1 - 2,5)^2 + (2 - 2,5)^2 \\ &\quad + (3 - 2,5)^2 + (4 - 2,5)^2 \\ &= 5. \end{aligned}$$

Calculando S_{xy} ,

$$\begin{aligned} S_{xy} &= (1 - 2,5)(2 - 3,5) + (2 - 2,5)(3 - 3,5) \\ &\quad + (3 - 2,5)(5 - 3,5) + (4 - 2,5)(4 - 3,5) \\ &= 4. \end{aligned}$$

Portanto,

$$\hat{\beta}_1 = \frac{4}{5} = 0,8$$

e

$$\hat{\beta}_0 = 3,5 - (0,8)(2,5) = 1,5.$$

A reta ajustada é

$$\boxed{\hat{y} = 1,5 + 0,8x}.$$

Os valores ajustados e resíduos são:

x_i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$
1	2	2,3	-0,3
2	3	3,1	-0,1
3	5	3,9	1,1
4	4	4,7	-0,7

A soma de quadrados dos resíduos é

$$\begin{aligned}\text{SQRes} &= (-0,3)^2 + (-0,1)^2 + (1,1)^2 + (-0,7)^2 \\ &= 1,8.\end{aligned}$$

Além disso,

$$\sum_{i=1}^4 e_i = 0,$$

como esperado para um modelo que contém intercepto.

Fonte: elaboração própria, com base em Rice (2007, pp. 565–567) e Ramachandran; Tsokos (2021, sec. 7.2.1).

6.3.4.3 Exemplo — regressão polinomial

Considere o modelo quadrático

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \varepsilon_i.$$

Embora a resposta seja uma função quadrática de x_i , o modelo é linear nos parâmetros β_0 , β_1 e β_2 .

Para os dados

x_i	y_i
-1	2
0	1
1	2
2	5

a matriz de planejamento é

$$\mathbf{X} = \begin{pmatrix} 1 & -1 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix},$$

e

$$\mathbf{Y} = \begin{pmatrix} 2 \\ 1 \\ 2 \\ 5 \end{pmatrix}.$$

Observa-se que

$$\mathbf{Y} = \mathbf{X} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}.$$

Consequentemente,

$$\hat{\beta} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

e a curva ajustada é

$$\hat{y} = 1 + x^2.$$

Nesse exemplo,

$$\text{SQRes} = 0.$$

i Observação

Um modelo polinomial é um modelo linear quando é linear nos parâmetros, mesmo que seja não linear na variável explicativa.

Em contraste, um modelo como

$$m(x; \theta_1, \theta_2) = \theta_1 e^{-\theta_2 x}$$

é não linear nos parâmetros e, em geral, requer métodos numéricos.

Fonte: elaboração própria, com base na formulação matricial de Rice (2007, pp. 565–567).

6.3.4.4 Exemplo — mínimos quadrados ponderados

Considere os dados

x_i	y_i	$\text{Var}(\varepsilon_i)$
0	1	1
1	2	1
2	2	1/4

Como a terceira observação possui menor variância, ela deve receber maior peso. Os pesos são

$$w_i = \frac{1}{\text{Var}(\varepsilon_i)},$$

de modo que

$$(w_1, w_2, w_3) = (1, 1, 4).$$

O critério ponderado é

$$\begin{aligned} Q_P(\beta_0, \beta_1) = & (1 - \beta_0)^2 \\ & + (2 - \beta_0 - \beta_1)^2 \\ & + 4(2 - \beta_0 - 2\beta_1)^2. \end{aligned}$$

A solução das equações ponderadas fornece

$$\hat{\beta}_0 = \frac{25}{21}$$

e

$$\hat{\beta}_1 = \frac{3}{7}.$$

Portanto,

$$\hat{y} = \frac{25}{21} + \frac{3}{7}x.$$

A terceira observação exerce maior influência sobre o ajuste porque é considerada mais precisa.

Fonte: elaboração própria, com base em Rice (2007, pp. 593–594).

6.3.5 Exercícios

Exercício 1 — Derivação da reta de mínimos quadrados

Considere o modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

1. Escreva a soma de quadrados dos resíduos.
2. Diferencie-a em relação a β_0 e β_1 .
3. Obtenha as duas equações normais.
4. Mostre que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

5. Mostre que

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}.$$

6. Conclua que a reta ajustada passa pelo ponto $(\bar{x}, \bar{Y})$.

Fonte: exercício adaptado de Ramachandran; Tsokos (2021, sec. 7.2.1) e Rice (2007, p. 594).

💡 Exercício 2 — Ajuste numérico

Considere os dados:

x_i	0	1	2	3	4
y_i	1	2	2	4	5

1. Calcule $\bar{x}$ e $\bar{y}$.
2. Calcule S_{xx} e S_{xy} .
3. Obtenha $\hat{\beta}_0$ e $\hat{\beta}_1$.
4. Calcule os valores ajustados.
5. Calcule os resíduos.
6. Verifique que a soma dos resíduos é zero.
7. Calcule a soma de quadrados dos resíduos.
8. Interprete o coeficiente angular.

Fonte: elaboração própria, com base nos exercícios de regressão de Diez; Barr; Çetinkaya-Rundel (2014, pp. 244–249).

💡 Exercício 3 — Mínimos quadrados como estimador de localização

Considere

$$Q(a) = \sum_{i=1}^n (Y_i - a)^2.$$

1. Mostre que o valor de a que minimiza $Q(a)$ é $\bar{Y}$.
2. Mostre que

$$\sum_{i=1}^n (Y_i - a)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 + n(\bar{Y} - a)^2.$$

3. Utilize a identidade anterior para provar que o mínimo é global e único.
4. Compare esse resultado com o estimador que minimiza

$$\sum_{i=1}^n |Y_i - a|.$$

Fonte: elaboração própria, com base no princípio de projeção apresentado por Cox (2006, pp. 10–11).

💡 Exercício 4 — Equivalência com máxima verossimilhança

Suponha que

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

com

$$\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2).$$

1. Escreva a função de verossimilhança de $(\beta_0, \beta_1, \sigma^2)$.
2. Obtenha a log-verossimilhança.
3. Mostre que, para σ^2 fixado, maximizar a log-verossimilhança em relação a β_0 e β_1 equivale a minimizar a soma de quadrados dos resíduos.
4. Obtenha os estimadores de máxima verossimilhança de β_0 e β_1 .
5. Supondo que $\text{SQRes} > 0$, obtenha o estimador de máxima verossimilhança de σ^2 . Explique o que ocorre quando $\text{SQRes} = 0$.
6. Compare esse estimador com o estimador não viesado da variância.

Fonte: exercício adaptado de Rice (2007, pp. 595–596) e Hastie; Tibshirani; Friedman (2009, pp. 30–31).

💡 Exercício 5 — Formulação matricial

Considere o modelo

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon.$$

1. Expanda

$$Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

2. Calcule o gradiente de $Q(\beta)$.
3. Obtenha as equações normais.
4. Mostre que, se $\mathbf{X}$ possui posto completo,

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

5. Mostre que

$$\mathbf{X}^\top \hat{\varepsilon} = \mathbf{0}.$$

6. Interprete geometricamente o resultado.

Fonte: exercício adaptado de Rice (2007, pp. 565–567, 595–596).

Exercício 6 — Falta de posto completo

Considere a matriz

$$\mathbf{X} = \begin{pmatrix} 1 & 2 & 4 \\ 1 & 3 & 6 \\ 1 & 4 & 8 \\ 1 & 5 & 10 \end{pmatrix}.$$

1. Determine o posto de $\mathbf{X}$.
2. Explique por que $\mathbf{X}^\top \mathbf{X}$ é singular.
3. Identifique a relação linear entre as colunas de $\mathbf{X}$.
4. Discuta a unicidade de $\hat{\beta}$.
5. Verifique se o vetor de valores ajustados pode ser único mesmo quando o vetor de coeficientes não é.
6. Relacione o problema ao conceito de multicolinearidade perfeita.

Fonte: elaboração própria, com base no critério de existência e unicidade de Rice (2007, pp. 566–567).

💡 Exercício 7 — Mínimos quadrados ponderados

Considere o modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que os erros são independentes e

$$\text{Var}(\varepsilon_i) = \rho_i^2 \sigma^2,$$

com ρ_i conhecido.

1. Defina

$$Z_i = \frac{Y_i}{\rho_i}, \quad u_i = \frac{1}{\rho_i}, \quad v_i = \frac{x_i}{\rho_i}.$$

2. Mostre que o modelo transformado possui erros com variância constante.
3. Mostre que aplicar mínimos quadrados ordinários ao modelo transformado equivale a minimizar

$$\sum_{i=1}^n \frac{(Y_i - \beta_0 - \beta_1 x_i)^2}{\rho_i^2}.$$

4. Identifique os pesos das observações.
5. Explique por que observações de maior variância recebem menor peso.
6. Relacione o estimador obtido ao método de máxima verossimilhança sob normalidade.

Fonte: exercício adaptado de Rice (2007, pp. 593–594).

💡 Exercício 8 — Mínimos quadrados não lineares

Considere o modelo

$$Y_i = \alpha e^{-\beta x_i} + \varepsilon_i, \quad \alpha > 0, \quad \beta > 0.$$

1. Escreva a função de mínimos quadrados

$$Q(\alpha, \beta) = \sum_{i=1}^n (Y_i - \alpha e^{-\beta x_i})^2.$$

2. Calcule as derivadas parciais de Q .
3. Obtenha as equações de mínimos quadrados não lineares.
4. Explique por que essas equações não possuem, em geral, solução algébrica fechada.
5. Descreva como um método iterativo poderia ser utilizado.
6. Mostre que, sob erros normais independentes com variância constante, maximizar a verossimilhança em relação a α e β , para σ^2 fixado, equivale a minimizar $Q(\alpha, \beta)$. Conclua que, sempre que o máximo conjunto existir, as estimativas de máxima verossimilhança de α e β coincidem com as estimativas de mínimos quadrados não lineares.
7. Discuta a possibilidade de existirem mínimos locais.

Fonte: exercício adaptado da discussão de regressão não linear de Cox (2006, pp. 10–12) e Hastie; Tibshirani; Friedman (2009, pp. 30–31).

6.3.6 Síntese

i Síntese da seção

O método dos mínimos quadrados estima os parâmetros minimizando a soma dos quadrados dos resíduos:

$$\hat{\theta}_{\text{MQ}} \in \arg \min_{\theta} \sum_{i=1}^n [Y_i - m(x_i; \theta)]^2.$$

No modelo linear,

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

as equações normais são

$$\mathbf{X}^T \mathbf{X} \hat{\beta} = \mathbf{X}^T \mathbf{Y}.$$

Quando $\mathbf{X}$ possui posto completo,

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Geometricamente, o vetor ajustado é a projeção ortogonal de $\mathbf{Y}$ no espaço gerado pelas colunas de $\mathbf{X}$.

Sob erros normais, independentes e homoscedásticos, os estimadores dos coeficientes obtidos por mínimos quadrados coincidem com os estimadores de máxima verossimilhança.

Se as variâncias são diferentes e conhecidas, a máxima verossimilhança conduz ao método dos mínimos quadrados ponderados.

6.4 Aprofundamento

Os tópicos desta seção ampliam os métodos de estimação apresentados no percurso principal. Eles utilizam conceitos desenvolvidos anteriormente sobre risco, convergência e informação de Fisher e os aplicam a problemas de optimalidade, distribuição assintótica e otimização da verossimilhança.

O bloco reúne três direções complementares. A primeira utiliza **minimax e equivariância** como critérios adicionais para construir ou restringir estimadores a partir do risco e das simetrias do problema estatístico. A segunda estuda a **distribuição assintótica dos estimadores**, incluindo aplicações do método delta e as propriedades assintóticas dos estimadores de máxima verossimilhança. A terceira apresenta o **algoritmo EM** como procedimento computacional para problemas de máxima verossimilhança envolvendo dados incompletos ou variáveis latentes.

Os três blocos utilizam conhecimentos anteriores distintos. Minimax e equivariância retomam função de perda e risco; a distribuição assintótica utiliza resultados de convergência, informação de Fisher e eficiência; o algoritmo EM retoma máxima verossimilhança e esperança condicional. Esses tópicos podem ser omitidos em uma primeira leitura sem interromper o percurso principal da unidade.

6.4.1 Minimax e equivariância

Em Capítulo 5, a função de risco foi utilizada para avaliar o desempenho de estimadores. Nesta seção, essa mesma função passa a ser utilizada como critério de construção e escolha. A equivariância restringe os estimadores de acordo com as transformações que preservam a estrutura do modelo; o critério minimax compara os procedimentos pelo maior risco que podem apresentar no espaço paramétrico.

Equivariância e minimaxidade respondem a perguntas diferentes. A equivariância restringe a classe de estimadores por transformações que preservam o problema estatístico; a minimaxidade compara procedimentos pelo maior valor de sua função de risco (Casella; Berger, 2011, secs. 6.4 e 7.3.4; Shao, 2003, secs. 4.2–4.3).

6.4.1.1 Equivariância e problemas invariantes

Considere uma família de distribuições

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$$

definida no espaço amostral $\mathcal{X}$, e seja $\mathcal{G}$ um grupo de transformações

$$g : \mathcal{X} \longrightarrow \mathcal{X}.$$

A transformação dos dados deve ser acompanhada por uma transformação correspondente do parâmetro.

! Definição — modelo invariante

A família $\mathcal{P}$ é **invariante** sob $\mathcal{G}$ se, para cada $g \in \mathcal{G}$ e cada $\theta \in \Theta$, existe um valor transformado

$$\bar{g}(\theta) \in \Theta$$

tal que

$$\mathbf{X} \sim P_\theta \implies g(\mathbf{X}) \sim P_{\bar{g}(\theta)}.$$

Em um modelo identificável, o valor $\bar{g}(\theta)$ é determinado de forma única pela distribuição transformada.

A condição estabelece que a transformação dos dados não leva a uma classe probabilística diferente: ela apenas modifica o valor do parâmetro dentro da mesma família.

Casella e Berger apresentam o Princípio da Equivariância a partir de duas exigências: a inferência não deve depender da escala usada para representar as mesmas medições, e problemas com a mesma estrutura formal devem receber procedimentos compatíveis (Casella; Berger, 2011, sec. 6.4).

Para um problema de estimação de θ , a transformação que atua no espaço paramétrico determina a transformação esperada para o estimador.

! Definição — estimador equivariante

Um estimador δ de θ é **equivariante** em relação a $\mathcal{G}$ quando

$$\delta(g(\mathbf{X})) = \bar{g}(\delta(\mathbf{X}))$$

para todo $g \in \mathcal{G}$.

Assim, transformar os dados e depois estimar produz o mesmo resultado que estimar primeiro e aplicar ao resultado a transformação correspondente do parâmetro.

6.4.1.2 Exemplo — família normal de localização

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\theta, \sigma^2), \quad \theta \in \mathbb{R},$$

com σ^2 conhecida.

Para $a \in \mathbb{R}$, defina a transformação

$$g_a(\mathbf{x}) = \mathbf{x} + a\mathbf{1}.$$

Se

$$\mathbf{X} \sim P_\theta,$$

então

$$g_a(\mathbf{X}) \sim P_{\theta+a}.$$

Logo, a transformação induzida no espaço paramétrico é

$$\bar{g}_a(\theta) = \theta + a,$$

e a família normal de localização é invariante sob o grupo de translações.

Considere agora

$$\delta(\mathbf{X}) = \bar{X}.$$

Temos

$$\begin{aligned} \delta(g_a(\mathbf{X})) &= \frac{1}{n} \sum_{i=1}^n (X_i + a) \\ &= \bar{X} + a \\ &= \bar{g}_a(\delta(\mathbf{X})). \end{aligned}$$

Portanto,

$$\overline{X} \text{ é equivariante por translação.}$$

Esse exemplo é um caso particular da estrutura de localização discutida em Casella; Berger (2011, sec. 6.4) e Shao (2003, sec. 4.2.1).

6.4.1.3 Equivariância e função de risco

A equivariância pode simplificar a forma da função de risco quando a função de perda também respeita as transformações do problema.

Considere novamente uma família de localização,

$$X_i = \theta + \varepsilon_i,$$

em que a distribuição de ε_i não depende de θ , e uma função de perda da forma

$$\mathcal{L}(\theta, a) = \rho(a - \theta).$$

! Proposição — risco de um estimador equivariante de localização

Se δ é equivariante por translação,

$$\delta(\mathbf{X} + a\mathbf{1}) = \delta(\mathbf{X}) + a,$$

então sua função de risco não depende de θ :

$$R(\theta, \delta) = R(0, \delta).$$

i Demonstração

Escreva

$$\mathbf{X} = \theta\mathbf{1} + \varepsilon,$$

em que a distribuição de ε não depende de θ .

Pela equivariância,

$$\delta(\theta\mathbf{1} + \varepsilon) = \delta(\varepsilon) + \theta.$$

Logo,

$$\delta(\mathbf{X}) - \theta = \delta(\varepsilon).$$

Como a perda depende apenas do erro de estimação,

$$\begin{aligned} R(\theta, \delta) &= E_{\theta} [\rho\{\delta(\mathbf{X}) - \theta\}] \\ &= E [\rho\{\delta(\varepsilon)\}], \end{aligned}$$

e a última expressão não depende de θ . Portanto,

$$R(\theta, \delta) = R(0, \delta).$$

No modelo normal anterior, sob perda quadrática,

$$\mathcal{L}(\theta, a) = (a - \theta)^2,$$

o risco da média amostral é

$$\begin{aligned} R(\theta, \bar{X}) &= E_{\theta} [(\bar{X} - \theta)^2] \\ &= \text{Var}_{\theta}(\bar{X}) \\ &= \frac{\sigma^2}{n}. \end{aligned}$$

Portanto,

$$R(\theta, \bar{X}) = \frac{\sigma^2}{n}$$

para todo $\theta \in \mathbb{R}$.

No modelo anterior, a estrutura de localização, a perda quadrática e a equivariância da média amostral fazem com que o risco seja constante. A minimaxidade ainda exige comparar esse valor com uma cota inferior para o risco máximo.

6.4.1.4 Critério minimax

Retome a função de risco

$$R(\theta, \delta)$$

definida em Capítulo 5. Seja $\mathcal{D}$ a classe de estimadores que se deseja comparar. Quando nenhuma restrição adicional for indicada, $\mathcal{D}$ será entendida como a classe de todos os estimadores para os quais os riscos considerados estão bem definidos.

Para $\delta \in \mathcal{D}$, defina o **risco máximo** por

$$R_{\max}(\delta) = \sup_{\theta \in \Theta} R(\theta, \delta).$$

O menor risco máximo que pode ser obtido dentro de $\mathcal{D}$ é

$$r^* = \inf_{\delta \in \mathcal{D}} R_{\max}(\delta) = \inf_{\delta \in \mathcal{D}} \sup_{\theta \in \Theta} R(\theta, \delta).$$

! Definição — estimador minimax

Um estimador $\delta^* \in \mathcal{D}$ é **minimax** na classe $\mathcal{D}$ se

$$\sup_{\theta \in \Theta} R(\theta, \delta^*) = \inf_{\delta \in \mathcal{D}} \sup_{\theta \in \Theta} R(\theta, \delta).$$

Equivalentemente,

$$R_{\max}(\delta^*) = r^*.$$

O critério minimax não exige que δ^* minimize o risco separadamente para cada valor de θ . A comparação é feita pelo pior risco de cada procedimento ao longo de todo o espaço paramétrico. Assim, δ^* é minimax quando nenhum estimador de $\mathcal{D}$ possui risco máximo estritamente menor (Shao, 2003, sec. 4.3).

6.4.1.5 Uma cota inferior para o risco minimax

A definição anterior fornece o critério de comparação, mas não determina diretamente r^* . Uma forma de identificá-lo é construir uma cota inferior para o risco minimax.

Seja π uma distribuição de probabilidade sobre Θ . Para um estimador $\delta \in \mathcal{D}$, defina seu **risco médio em relação a π** por

$$r_{\pi}(\delta) = \int_{\Theta} R(\theta, \delta) \pi(d\theta).$$

O menor risco médio alcançável na classe $\mathcal{D}$ é

$$r_{\pi}^* = \inf_{\delta \in \mathcal{D}} r_{\pi}(\delta).$$

! Proposição — cota inferior para o risco minimax

Para qualquer distribuição de probabilidade π sobre Θ ,

$$r_{\pi}^{\star} \leq r^{\star}.$$

Além disso, suponha que exista uma sequência de distribuições $\{\pi_m\}$ tal que

$$r_{\pi_m}^{\star} \longrightarrow c$$

e um estimador $\delta^{\star} \in \mathcal{D}$ satisfazendo

$$R_{\max}(\delta^{\star}) \leq c.$$

Então,

$$R_{\max}(\delta^{\star}) = r^{\star} = c,$$

e $\delta^{\star}$ é minimax em $\mathcal{D}$.

i Demonstração

Para qualquer $\delta \in \mathcal{D}$,

$$R(\theta, \delta) \leq \sup_{\vartheta \in \Theta} R(\vartheta, \delta)$$

para todo θ . Portanto,

$$\int_{\Theta} R(\theta, \delta) \pi(d\theta) \leq \sup_{\theta \in \Theta} R(\theta, \delta).$$

Tomando o ínfimo em $\delta \in \mathcal{D}$ dos dois lados,

$$r_{\pi}^{\star} \leq r^{\star}.$$

Agora suponha que

$$r_{\pi_m}^{\star} \longrightarrow c.$$

Como

$$r_{\pi_m}^{\star} \leq r^{\star}$$

para todo m , segue que

$$c \leq r^{\star}.$$

Por outro lado, se

$$R_{\max}(\delta^*) \leq c,$$

então, pela definição de r^* ,

$$r^* \leq R_{\max}(\delta^*) \leq c.$$

Assim,

$$c \leq r^* \leq R_{\max}(\delta^*) \leq c,$$

de onde

$$R_{\max}(\delta^*) = r^* = c.$$

Logo, δ^* é minimax.

A distribuição π é utilizada aqui como instrumento matemático para produzir uma cota inferior para o risco minimax. Para cada π , calcula-se o menor risco médio possível,

$$r_{\pi}^* = \inf_{\delta \in \mathcal{D}} r_{\pi}(\delta),$$

e esse valor necessariamente fornece uma cota inferior para r^* .

Quando o ínfimo é atingido, o estimador correspondente é uma regra de Bayes para a priori π . Aqui, essa construção é usada para obter uma cota inferior e provar minimaxidade; a comparação final continua sendo feita pela função de risco $R(\theta, \delta)$ (Casella; Berger, 2011, sec. 7.3.4; Shao, 2003, sec. 4.3).

6.4.1.6 Exemplo — média normal como estimador minimax

Retome o modelo

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\theta, \sigma^2), \quad \theta \in \mathbb{R},$$

com σ^2 conhecida e perda quadrática.

Já foi obtido que

$$R(\theta, \bar{X}) = \frac{\sigma^2}{n}$$

para todo θ . Portanto,

$$R_{\max}(\bar{X}) = \frac{\sigma^2}{n}.$$

Para obter uma cota inferior para o risco minimax, considere a sequência de distribuições auxiliares

$$\pi_\tau : \quad \theta \sim N(0, \tau^2), \quad \tau^2 > 0.$$

Sob perda quadrática, podemos determinar explicitamente o estimador que minimiza o risco médio correspondente.

Como

$$\bar{X} \mid \theta \sim N\left(\theta, \frac{\sigma^2}{n}\right)$$

e

$$\theta \sim N(0, \tau^2),$$

a distribuição condicional de θ dado $\bar{X}$ é normal, com variância

$$V_\tau = \left(\frac{1}{\tau^2} + \frac{n}{\sigma^2}\right)^{-1} = \frac{\sigma^2 \tau^2}{\sigma^2 + n\tau^2}$$

e média

$$m_\tau(\bar{X}) = V_\tau \frac{n\bar{X}}{\sigma^2} = \frac{n\tau^2}{\sigma^2 + n\tau^2} \bar{X}.$$

Sob perda quadrática, a ação que minimiza a perda condicional esperada é a média condicional. Portanto,

$$\boxed{\delta_\tau(\mathbf{X}) = \frac{n\tau^2}{\sigma^2 + n\tau^2} \bar{X}}.$$

i Por que a média condicional minimiza a perda quadrática?

Para qualquer ação a ,

$$E[(\theta - a)^2 \mid \mathbf{X}] = \text{Var}(\theta \mid \mathbf{X}) + [E(\theta \mid \mathbf{X}) - a]^2.$$

O primeiro termo não depende de a . O segundo é minimizado quando

$$a = E(\theta \mid \mathbf{X}).$$

O risco médio mínimo é, portanto,

$$r_{\pi_\tau}^* = E[\text{Var}(\theta \mid \mathbf{X})].$$

Neste modelo, a variância condicional não depende dos dados, de modo que

$$r_{\pi_\tau}^* = \frac{\sigma^2 \tau^2}{\sigma^2 + n \tau^2}.$$

Quando

$$\tau^2 \longrightarrow \infty,$$

temos

$$r_{\pi_\tau}^* \longrightarrow \frac{\sigma^2}{n}.$$

Pela proposição anterior,

$$r^* \geq \frac{\sigma^2}{n}.$$

Como

$$R_{\max}(\bar{X}) = \frac{\sigma^2}{n},$$

também temos

$$r^* \leq \frac{\sigma^2}{n}.$$

Consequentemente,

$$r^{\star} = \frac{\sigma^2}{n}$$

e

$$\bar{X} \text{ é minimax para } \theta$$

sob perda quadrática, na classe $\mathcal{D}$ considerada. Em particular, tomando $\mathcal{D}$ como a classe de todos os estimadores com risco bem definido, a conclusão estabelece a minimaxidade global de $\bar{X}$ para esse problema.

O risco constante simplifica a comparação, mas não prova minimaxidade. Ainda é necessário obter uma cota inferior que exclua a existência de outro estimador com risco máximo menor (Shao, 2005 [pp. 175–182]).

6.4.1.7 Equivariância e invariância do EMV

A equivariância definida nesta seção é distinta da propriedade de invariância do estimador de máxima verossimilhança apresentada em Seção 6.2.

Na invariância do EMV, considera-se uma reparametrização

$$\eta = h(\theta)$$

mantendo os dados observados fixos. Se $\hat{\theta}_{\text{MV}}$ é o EMV de θ , então, sob as condições pertinentes,

$$\hat{\eta}_{\text{MV}} = h(\hat{\theta}_{\text{MV}}).$$

Na equivariância, transforma-se o próprio problema estatístico:

$$\mathbf{X} \mapsto g(\mathbf{X})$$

e, simultaneamente,

$$\theta \mapsto \bar{g}(\theta).$$

A condição exigida do estimador é

$$\delta(g(\mathbf{X})) = \bar{g}(\delta(\mathbf{X})).$$

Portanto,

invariância do EMV : reparametrização do alvo,
equivariância : coerência sob transformações do modelo.

i Síntese

A equivariância restringe a classe de estimadores às regras que acompanham as transformações do modelo. No caso de localização demonstrado acima, quando a perda depende apenas do erro de estimação, essa propriedade faz com que o risco não dependa de θ . O critério minimax utiliza outra ideia: comparar os procedimentos por seu maior risco no espaço paramétrico. Risco constante pode facilitar a demonstração de minimaxidade, mas não é suficiente por si só. É necessário mostrar também que nenhum outro estimador pode possuir risco máximo inferior.

6.4.2 Distribuição assintótica de estimadores e método delta

Enquanto minimax e equivariância fornecem critérios para avaliar ou restringir procedimentos de estimação, a análise assintótica descreve seu comportamento quando o tamanho amostral aumenta.

O método delta, apresentado anteriormente como ferramenta assintótica, permite transportar uma distribuição limite conhecida para funções diferenciáveis de estimadores. Nesta unidade, seu papel é aplicado: parte-se de um estimador já construído e utiliza-se o método para caracterizar aproximadamente sua distribuição quando o tamanho amostral cresce.

6.4.2.1 Aplicação ao estimador de momentos de Pareto

Retomando o exemplo da distribuição de Pareto em Seção 6.1,

$$\hat{\theta}^{\text{MM}} = \frac{\bar{X}}{\bar{X} - 1},$$

de modo que

$$\hat{\theta}^{\text{MM}} = g(\bar{X}), \quad g(u) = \frac{u}{u - 1}.$$

Se $\theta > 2$, então

$$\text{Var}(X) = \frac{\theta}{(\theta - 1)^2(\theta - 2)}.$$

Como

$$g'(u) = -\frac{1}{(u - 1)^2},$$

temos

$$g'\left(\frac{\theta}{\theta - 1}\right) = -(\theta - 1)^2.$$

Pelo método delta,

$$\sqrt{n}(\hat{\theta}^{\text{MM}} - \theta) \xrightarrow{d} N\left(0, \frac{\theta(\theta - 1)^2}{\theta - 2}\right).$$

Assim, para amostras grandes, a aproximação normal de primeira ordem é

$$\hat{\theta}^{\text{MM}} \sim N\left(\theta, \frac{\theta(\theta - 1)^2}{n(\theta - 2)}\right).$$

A quantidade

$$\frac{\theta(\theta - 1)^2}{n(\theta - 2)}$$

é, portanto, a variância associada a essa aproximação assintótica.

O requisito $\theta > 2$ é essencial para esta aplicação, pois a variância de X é infinita quando $1 < \theta \leq 2$ (Lauritzen, 2023, app. A.2.3; Chihara; Hesterberg, 2022, sec. 7.7).

Para $\theta = 3$ e $n = 100$, a variância da aproximação normal é

$$\frac{3(3 - 1)^2}{100(3 - 2)} = 0,12,$$

de modo que o erro-padrão assintótico correspondente é

$$\sqrt{0,12} \approx 0,346.$$

Simulação em R


O exemplo numérico e o código abaixo são autorais. A geração utiliza a transformação inversa: se $U \sim \text{Unif}(0, 1)$, então $U^{-1/\theta}$ possui a distribuição de Pareto adotada.

```
set.seed(14)

B <- 1000
n <- 100
theta <- 3

estimativas <- replicate(B, {
  x <- runif(n)^(-1 / theta)
  x_barra <- mean(x)
  x_barra / (x_barra - 1)
})

hist(
  estimativas,
  probability = TRUE,
  breaks = 35,
  xlab = expression(hat(theta)[MM]),
  main = ""
)
```



```
mean(estimativas)
```

```
[1] 3.054922
```

```
sd(estimativas)
```

```
[1] 0.3213791
```

i Interpretação

A função

$$g(u) = \frac{u}{u-1}$$

é estritamente convexa para $u > 1$, pois

$$g''(u) = \frac{2}{(u-1)^3} > 0.$$

Como

$$\hat{\theta}^{\text{MM}} = g(\bar{X})$$

e

$$g\{E(\bar{X})\} = g\left(\frac{\theta}{\theta-1}\right) = \theta,$$

a desigualdade de Jensen implica, sempre que $E[g(\bar{X})]$ for finita,

$$E(\hat{\theta}^{\text{MM}}) \geq \theta.$$

Para uma amostra não degenerada, a desigualdade é estrita. Assim, a convexidade explica o viés positivo de amostra finita. Esse viés não impede a consistência do estimador.

A aplicação anterior partiu de um estimador obtido pelo método dos momentos. Passamos agora aos estimadores de máxima verossimilhança. Nesse caso, a distribuição assintótica decorre da estrutura específica da função de verossimilhança e exige condições adicionais sobre o modelo.

6.4.2.2 Condições de regularidade para o EMV

As propriedades assintóticas dos estimadores de máxima verossimilhança não são consequências automáticas da maximização da verossimilhança. Elas dependem de hipóteses sobre a estrutura e a suavidade do modelo.

⚠ Observação — não existe uma lista universal de condições

As condições de regularidade dependem do teorema e da classe de modelos considerados. A lista a seguir reúne hipóteses suficientes recorrentes e deve ser interpretada como um roteiro de verificação, não como um enunciado universal. O resultado formal adotado como referência deve sempre ser declarado; por exemplo, Lauritzen (2023, thm. 5.11) estabelece a normalidade assintótica em famílias exponenciais mínimas e regulares.

Identificabilidade

O modelo deve ser identificável:

$$P_{\theta_1} = P_{\theta_2} \implies \theta_1 = \theta_2.$$

Equivalentemente, valores paramétricos distintos devem produzir distribuições distintas.

Sem identificabilidade, dois ou mais valores do parâmetro geram exatamente a mesma distribuição dos dados e não podem ser distinguidos por qualquer procedimento estatístico.

Parâmetro verdadeiro interior

O verdadeiro valor θ_0 deve pertencer ao interior de Θ . Em particular, deve existir uma vizinhança aberta de θ_0 inteiramente contida no espaço paramétrico.

Quando o parâmetro verdadeiro está na fronteira, a distribuição limite do estimador pode ser assimétrica, truncada ou constituída por uma mistura de distribuições.

Suporte localmente independente do parâmetro

Uma condição suficiente frequentemente adotada é que o suporte

$$\mathcal{X}_\theta = \{x : f(x; \theta) > 0\}$$

não dependa de θ em uma vizinhança do verdadeiro valor.

Quando o suporte depende do parâmetro, a diferenciação de

$$\int f(x; \theta) dx = 1$$

pode produzir termos adicionais de fronteira. Nesses casos, identidades envolvendo o escore e a informação de Fisher podem não ser válidas.

Diferenciabilidade

A função

$$\theta \mapsto \log f(x; \theta)$$

deve possuir derivadas de ordem suficiente em uma vizinhança de θ_0 . A demonstração usual da normalidade assintótica emprega uma expansão de Taylor da função escore e requer controle das derivadas de segunda e, frequentemente, de terceira ordem.

Diferenciação sob o sinal de integração

Deve ser possível permutar diferenciação e integração, por exemplo,

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx.$$

Uma condição suficiente consiste na existência de funções integráveis que dominem as derivadas de $f(x; \theta)$ em uma vizinhança do verdadeiro parâmetro.

Informação de Fisher finita e não singular

A matriz

$$\mathbf{I}_1(\theta_0)$$

deve existir, possuir elementos finitos e ser positiva definida. Para um parâmetro escalar,

$$0 < I_1(\theta_0) < \infty.$$

Se a informação for nula ou singular, algumas componentes do parâmetro podem não ser estimáveis à taxa usual $\sqrt{n}$.

Convergência uniforme da função objetivo

Para demonstrar a consistência do estimador como um maximizador, é usual exigir que a log-verossimilhança média

$$\frac{1}{n}\ell_n(\theta)$$

convirja uniformemente para uma função determinística que tenha máximo único em θ_0 .

Condições adicionais de compacidade, continuidade ou controle do comportamento da verossimilhança fora de vizinhanças compactas podem ser necessárias.

i Modelos não regulares

Exemplos de situações em que a teoria regular pode falhar incluem:

- suporte dependente do parâmetro;
- parâmetro verdadeiro na fronteira;
- falta de identificabilidade;
- informação de Fisher singular;
- máximos não únicos;
- verossimilhança ilimitada;
- certos modelos de mistura, especialmente em pontos de não identificabilidade, fronteiras ou componentes degenerados;
- separação completa em regressão logística.

Nesses casos, o estimador pode continuar sendo consistente, mas sua taxa de convergência ou sua distribuição limite pode ser diferente da usual.

6.4.2.3 Propriedades assintóticas do EMV

Considere uma amostra aleatória $X_1, \dots, X_n$ proveniente de uma distribuição $f(x; \theta_0)$, em que θ_0 representa o verdadeiro valor do parâmetro.

Consistência

Defina a log-verossimilhança média amostral por

$$M_n(\theta) = \frac{1}{n}\ell_n(\theta)$$

e sua contraparte populacional por

$$M(\theta) = E_{\theta_0} [\log f(X; \theta)],$$

sempre que essa esperança estiver bem definida.

A relação com a divergência de Kullback–Leibler é

$$\begin{aligned} M(\theta) - M(\theta_0) &= E_{\theta_0} \left[\log \frac{f(X; \theta)}{f(X; \theta_0)} \right] \\ &= -D_{\text{KL}} (f_{\theta_0} \| f_{\theta}) \leq 0. \end{aligned}$$

Logo, θ_0 maximiza M . Sob identificabilidade, a igualdade

$$M(\theta) = M(\theta_0)$$

ocorre apenas quando

$$\theta = \theta_0,$$

desde que as distribuições envolvidas satisfaçam as condições necessárias para a identidade anterior.

! Resultado — consistência do EMV

Suponha que θ_0 seja um máximo bem separado de M , no sentido de que, para todo $\varepsilon > 0$,

$$\sup_{\|\theta - \theta_0\| \geq \varepsilon} M(\theta) < M(\theta_0).$$

Suponha ainda que

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{p} 0$$

e que $\hat{\theta}_n$ seja um maximizador exato ou aproximado de M_n , satisfazendo

$$M_n(\hat{\theta}_n) \geq \sup_{\theta \in \Theta} M_n(\theta) - o_p(1).$$

Então,

$$\hat{\theta}_n \xrightarrow{p} \theta_0.$$

Esse resultado expressa a lógica dos estimadores obtidos por maximização: a função objetivo amostral deve se aproximar uniformemente de uma função populacional cujo máximo identifica o verdadeiro parâmetro.

As hipóteses anteriores constituem condições suficientes. Dependendo do espaço paramétrico e do modelo, podem ser substituídas por condições locais, compacidade ou argumentos específicos de controle fora de vizinhanças de θ_0 (Lauritzen, 2023, sec. 5.3.1).

Normalidade assintótica: parâmetro escalar

Suponha que $\hat{\theta}_n$ seja uma solução consistente da equação de verossimilhança. Expandindo $U_n(\hat{\theta}_n)$ em torno de θ_0 ,

$$0 = U_n(\hat{\theta}_n) = U_n(\theta_0) + \ell_n''(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0),$$

em que $\tilde{\theta}_n$ está entre $\hat{\theta}_n$ e θ_0 . Logo,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \left[-\frac{1}{n} \ell_n''(\tilde{\theta}_n) \right]^{-1} \frac{U_n(\theta_0)}{\sqrt{n}}.$$

Para uma amostra i.i.d., o escore pode ser escrito como

$$U_n(\theta_0) = \sum_{i=1}^n U_i(\theta_0),$$

em que

$$U_i(\theta_0) = \left. \frac{\partial}{\partial \theta} \log f(X_i; \theta) \right|_{\theta=\theta_0}.$$

Sob as condições de regularidade,

$$E_{\theta_0} [U_i(\theta_0)] = 0$$

e

$$\text{Var}_{\theta_0} [U_i(\theta_0)] = I_1(\theta_0).$$

Portanto, pelo Teorema Central do Limite,

$$\frac{U_n(\theta_0)}{\sqrt{n}} \xrightarrow{d} N(0, I_1(\theta_0)).$$

Por outro lado, como $\hat{\theta}_n \xrightarrow{p} \theta_0$, também

$$\tilde{\theta}_n \xrightarrow{p} \theta_0.$$

Sob as condições que garantem a convergência uniforme apropriada da segunda derivada,

$$-\frac{1}{n} \ell_n''(\tilde{\theta}_n) \xrightarrow{p} I_1(\theta_0).$$

Aplicando o teorema de Slutsky (Lauritzen, 2023, app. A.2.2),

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I_1(\theta_0)^{-1}).$$

Consequentemente, a aproximação normal de primeira ordem é

$$\hat{\theta}_n \dot{\sim} N\left(\theta_0, \frac{1}{nI_1(\theta_0)}\right).$$

A quantidade

$$\frac{1}{nI_1(\theta_0)}$$

é a variância associada a essa aproximação assintótica. A convergência em distribuição, isoladamente, não implica convergência das variâncias; para interpretar essa expressão como aproximação da variância finita de $\hat{\theta}_n$, são necessárias condições adicionais sobre seus momentos.

Essa aproximação e sua relação com a informação de Fisher são apresentadas por Chihara; Hesterberg (2022, pp. 173–174), Lauritzen (2023, thm. 5.11) e Ramachandran; Tsokos (2009, pp. 334–336).

Normalidade assintótica: parâmetro vetorial

Se $\theta \in \mathbb{R}^q$, então, sob condições análogas,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N_q(\mathbf{0}, \mathbf{I}_1(\theta_0)^{-1}).$$

A aproximação normal vetorial de primeira ordem pode ser escrita como

$$\hat{\theta}_n \sim N_q\left[\theta_0, \frac{1}{n}\mathbf{I}_1(\theta_0)^{-1}\right].$$

Assim, a matriz de covariâncias associada à aproximação assintótica é

$$\frac{1}{n}\mathbf{I}_1(\theta_0)^{-1}.$$

Como

$$\mathbf{I}_n(\theta_0) = n\mathbf{I}_1(\theta_0),$$

essa matriz também pode ser escrita como

$$\mathbf{I}_n(\theta_0)^{-1}.$$

Novamente, essa é uma afirmação de primeira ordem derivada da distribuição limite; a convergência das matrizes de covariâncias finitas requer condições adicionais.

Eficiência assintótica

A eficiência assintótica foi definida em Capítulo 5 pela comparação entre a variância da distribuição limite de um estimador e a informação de Fisher.

No caso do EMV regular, o resultado anterior fornece

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N_q[\mathbf{0}, \mathbf{I}_1(\theta_0)^{-1}].$$

Portanto, a matriz de covariâncias da distribuição limite é

$$\boxed{\mathbf{I}_1(\theta_0)^{-1}}.$$

A matriz $\mathbf{I}_1(\theta_0)^{-1}$ é a matriz de covariâncias que aparece na cota assintótica para estimadores regulares nesse modelo. Portanto, o EMV é assintoticamente eficiente na classe regular à qual o resultado se aplica.

A afirmação é assintótica e depende das condições de regularidade. Ela não estabelece optimalidade para amostras finitas nem para procedimentos não regulares (Ramachandran; Tsokos, 2009, pp. 273–276).

Interpretação

Eficiência assintótica não implica que o estimador de máxima verossimilhança:

- seja não viesado em amostras finitas;
- tenha variância mínima para todo tamanho amostral;
- tenha distribuição aproximadamente normal em amostras pequenas;
- seja robusto contra valores atípicos;
- seja robusto contra erros de especificação do modelo.

Chihara; Hesterberg (2022, p. 173) observam explicitamente que, em amostras finitas, a variância pode ser maior do que a aproximação assintótica e a distribuição pode ser não normal.

Estimação do erro-padrão

Sob as condições de regularidade,

$$\frac{1}{n} \mathbf{J}_n(\hat{\theta}_n) \xrightarrow{p} \mathbf{I}_1(\theta_0).$$

Assim, quando a informação observada avaliada no EMV é não singular, uma estimativa da matriz de covariâncias da aproximação assintótica é

$$\widehat{\mathbf{V}}_n = \mathbf{J}_n(\hat{\theta}_n)^{-1}.$$

Outra possibilidade é utilizar a informação esperada avaliada no estimador:

$$\widehat{\mathbf{V}}_n = [n\mathbf{I}_1(\hat{\theta}_n)]^{-1}.$$

Em modelos regulares, ambas são aproximações de primeira ordem para

$$\frac{1}{n} \mathbf{I}_1(\theta_0)^{-1}.$$

Para um parâmetro escalar, a estimativa baseada na informação observada fornece

$$\widehat{\text{EP}}(\hat{\theta}_n) = [J_n(\hat{\theta}_n)]^{-1/2},$$

desde que

$$J_n(\hat{\theta}_n) > 0.$$

i Ponte para a estimação intervalar

A normalidade assintótica e a estimativa do erro-padrão fornecem os elementos necessários para construir intervalos de confiança aproximados. A construção dos intervalos assintóticos, incluindo o intervalo de Wald, e a análise de cobertura e limitações pertencem à unidade de estimação intervalar.

6.4.3 Algoritmo Expectation-Maximization (EM)

O algoritmo *Expectation-Maximization* (EM) é um procedimento iterativo para maximizar a verossimilhança em problemas nos quais a introdução de dados ausentes, censurados ou latentes torna a maximização mais simples do que trabalhar diretamente com a verossimilhança observada.

O EM não define um novo princípio de estimação: ele fornece uma estratégia computacional para obter estimadores de máxima verossimilhança quando a otimização direta é difícil. As garantias computacionais do algoritmo e as propriedades estatísticas do estimador obtido são questões distintas.

A apresentação adotada utiliza Casella; Berger (2011, sec. 7.2.4) e Gupta; Chen (2011, secs. 1–2) para a formulação do algoritmo, Hastie; Tibshirani; Friedman (2009, secs. 6.8 e 8.5) para modelos de mistura, Ramachandran; Tsokos (2021, sec. 13.4) para dados incompletos e Chihara; Hesterberg (2022, sec. 13.8) para exemplos didáticos.

6.4.3.1 Exemplo motivacional — mistura de duas populações normais

Considere uma amostra $Y_1, \dots, Y_n$ obtida de uma população heterogênea formada por duas subpopulações. Condicionalmente à subpopulação de origem, suponha que

$$Y_i \mid Z_i = 1 \sim N(\mu_1, \sigma_1^2)$$

e

$$Y_i \mid Z_i = 2 \sim N(\mu_2, \sigma_2^2),$$

em que $Z_i \in \{1, 2\}$ identifica o componente responsável pela geração da observação. Se

$$P(Z_i = 1) = \pi \quad \text{e} \quad P(Z_i = 2) = 1 - \pi,$$

a densidade marginal de Y_i é

$$f(y_i \mid \theta) = \pi \phi(y_i; \mu_1, \sigma_1^2) + (1 - \pi) \phi(y_i; \mu_2, \sigma_2^2),$$

onde

$$\theta = (\pi, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2)$$

e $\phi(y; \mu, \sigma^2)$ denota a densidade normal com média μ e variância σ^2 .

A log-verossimilhança observada é

$$\ell(\theta; y) = \sum_{i=1}^n \log [\pi \phi(y_i; \mu_1, \sigma_1^2) + (1 - \pi) \phi(y_i; \mu_2, \sigma_2^2)].$$

A presença do logaritmo de uma soma impede a separação imediata dos termos associados aos dois componentes. Em geral, as equações de máxima verossimilhança não fornecem expressões fechadas simultâneas para todos os parâmetros.

Suponha, porém, que os indicadores de pertencimento fossem observados. Defina

$$Z_{ij} = \begin{cases} 1, & \text{se a observação } i \text{ pertence ao componente } j, \\ 0, & \text{caso contrário,} \end{cases}$$

com $Z_{i1} + Z_{i2} = 1$. A log-verossimilhança dos dados completos seria

$$\ell_c(\theta) = \sum_{i=1}^n \sum_{j=1}^2 Z_{ij} [\log(\pi_j) + \log \phi(y_i; \mu_j, \sigma_j^2)],$$

onde $\pi_1 = \pi$ e $\pi_2 = 1 - \pi$.

Essa expressão é simples de maximizar quando Z_{ij} é conhecido. O EM explora exatamente essa diferença: em cada iteração, substitui os indicadores não observados por suas esperanças condicionais, isto é, pelas probabilidades atuais de pertencimento aos componentes, e atualiza

os parâmetros por médias e variâncias ponderadas (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

i Interpretação

O EM não realiza uma classificação rígida das observações durante as iterações. Cada observação recebe uma responsabilidade probabilística para cada componente. Essa característica distingue o ajuste de misturas gaussianas por EM de métodos de agrupamento com atribuição exclusiva, como o k -means (Gupta; Chen, 2011, sec. 3.2).

6.4.3.2 Definição formal

Dados observados, dados latentes e dados completos

Seja Y o vetor de dados observados e seja Z um vetor de variáveis não observadas, ausentes ou latentes. O vetor

$$X = (Y, Z)$$

é denominado vetor de **dados completos**.

Considere um modelo paramétrico indexado por

$$\theta \in \Theta.$$

A densidade conjunta dos dados completos é

$$f_c(y, z | \theta),$$

enquanto a densidade observada é obtida por marginalização:

$$f(y | \theta) = \int_{\mathcal{Z}} f_c(y, z | \theta) dz.$$

No caso discreto,

$$f(y | \theta) = \sum_{z \in \mathcal{Z}} f_c(y, z | \theta).$$

O objetivo é maximizar a log-verossimilhança observada

$$\ell(\theta) = \log f(y \mid \theta).$$

O princípio do EM consiste em escolher uma representação por dados completos para a qual

$$\ell_c(\theta; y, z) = \log f_c(y, z \mid \theta)$$

seja mais simples de trabalhar do que $\ell(\theta)$ (Gupta; Chen, 2011, secs. 1.1 e 2.1).

Relação entre dados completos e dados observados

Gupta; Chen (2011) formulam a relação estrutural do EM pela cadeia de Markov

$$\theta \longrightarrow X \longrightarrow Y,$$

o que equivale a exigir

$$f(y \mid x, \theta) = f(y \mid x).$$

Essa condição afirma que, conhecidos os dados completos, o mecanismo que produz os dados observados não contém informação adicional sobre θ . Quando $Y = T(X)$ para alguma transformação determinística T , a condição é automaticamente satisfeita.

Função auxiliar

! Definição — função Q

Dado o valor corrente $\theta^{(t)}$, define-se

$$Q(\theta \mid \theta^{(t)}) = E_{\theta^{(t)}} [\ell_c(\theta; Y, Z) \mid Y = y].$$

Equivalentemente,

$$Q(\theta \mid \theta^{(t)}) = \int_z \log f_c(y, z \mid \theta) f(z \mid y, \theta^{(t)}) dz.$$

A esperança é calculada com respeito à distribuição condicional das variáveis latentes sob o valor corrente $\theta^{(t)}$. O argumento θ permanece livre dentro da log-verossimilhança completa; o valor corrente é utilizado somente para determinar a distribuição condicional empregada na esperança (Ramachandran; Tsokos, 2021, sec. 13.4).

Etapas do algoritmo

! Definição — algoritmo EM

Escolha um valor inicial $\theta^{(0)}$. Para $t = 0, 1, 2, \dots$, execute:

Etapas E — Expectation

Calcule

$$Q(\theta \mid \theta^{(t)}) = E_{\theta^{(t)}} [\ell_c(\theta; Y, Z) \mid Y = y].$$

Etapas M — Maximization

Determine

$$\theta^{(t+1)} \in \arg \max_{\theta \in \Theta} Q(\theta \mid \theta^{(t)}).$$

Repita as duas etapas até que um critério de convergência seja satisfeito (Gupta; Chen, 2011, sec. 1.1; Ramachandran; Tsokos, 2021, sec. 13.4).

Critérios usuais de parada incluem

$$\left| \ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) \right| < \varepsilon$$

ou

$$\left\| \theta^{(t+1)} - \theta^{(t)} \right\| < \varepsilon.$$

Uma forma relativa, mais estável quando a escala da log-verossimilhança é grande, é

$$\frac{\left| \ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) \right|}{1 + \left| \ell(\theta^{(t)}) \right|} < \varepsilon.$$

O critério de parada é uma escolha computacional; ele não altera a definição das etapas E e M. O valor de ε deve ser definido de acordo com a precisão numérica requerida e o custo computacional aceitável (Gupta; Chen, 2011; Ramachandran; Tsokos, 2021).

i Aprofundamento — interpretação do EM por limite inferior

Defina

$$q_t(z) = f(z \mid y, \theta^{(t)}).$$

Para qualquer densidade $q(z)$ para a qual as esperanças e a divergência abaixo estejam bem definidas,

$$\ell(\theta) = \mathcal{F}(q, \theta) + D_{\text{KL}}[q(z) \parallel f(z \mid y, \theta)].$$

onde

$$\mathcal{F}(q, \theta) = E_q[\log f_c(y, Z \mid \theta)] + \mathcal{H}(q),$$

$\mathcal{H}(q)$ é a entropia de q e

$$D_{\text{KL}}(q \parallel p) = E_q \left[\log \frac{q(Z)}{p(Z)} \right] \geq 0.$$

Consequentemente,

$$\mathcal{F}(q, \theta) \leq \ell(\theta).$$

Na etapa E, escolhe-se a distribuição condicional corrente das variáveis latentes, fazendo com que o limite inferior coincida com a log-verossimilhança no valor atual. Na etapa M, maximiza-se esse limite inferior em relação a θ .

Essa representação fornece uma interpretação adicional da monotonicidade do algoritmo e aproxima o EM dos procedimentos de *minorization-maximization* ou maximização sucessiva (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

6.4.3.3 Condições para aplicação do EM

As condições abaixo têm dois papéis: tornar as etapas E e M calculáveis e estabelecer as hipóteses utilizadas nas propriedades do algoritmo.

Escolha da representação por dados completos

Deve ser possível introduzir dados latentes Z tais que

$$f(y \mid \theta) = \int f_c(y, z \mid \theta) dz.$$

A ampliação dos dados não é única. Duas representações corretas podem produzir algoritmos com custos e velocidades de convergência diferentes. Na prática, a escolha deve tornar a etapa E e, principalmente, a etapa M mais simples do que a maximização direta da verossimilhança observada (Gupta; Chen, 2011).

Etapa E calculável

Deve ser possível calcular

$$f(z \mid y, \theta^{(t)})$$

ou, ao menos, as esperanças condicionais das estatísticas que aparecem na log-verossimilhança completa.

Quando o modelo completo pertence a uma família exponencial, a etapa E frequentemente se reduz ao cálculo da esperança condicional de estatísticas suficientes (Ramachandran; Tsokos, 2021, sec. 13.4).

Se a esperança condicional não puder ser calculada analiticamente, uma possibilidade é aproximá-la por simulação, originando o algoritmo Monte Carlo EM, ou MCEM (Gupta; Chen, 2011, sec. 5; Ramachandran; Tsokos, 2021, sec. 13.4).

Etapa M calculável

O problema

$$\max_{\theta \in \Theta} Q(\theta \mid \theta^{(t)})$$

deve possuir solução fechada ou ser numericamente mais simples do que a maximização da log-verossimilhança observada.

Quando a maximização exata é difícil, pode-se empregar o **EM generalizado**. Nesse caso, basta obter $\theta^{(t+1)}$ tal que

$$Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)}).$$

Essa modificação preserva a propriedade de monotonicidade, embora a etapa M não seja resolvida exatamente (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

Compatibilidade dos suportes

A demonstração da monotonicidade pressupõe que a distribuição condicional utilizada na etapa E, a função Q e as divergências envolvidas estejam bem definidas ao longo das atualizações.

Uma condição suficiente simples é que o suporte dos dados completos não dependa de θ . Essa hipótese garante que a comparação entre

$$f_c(y, z \mid \theta^{(t)})$$

e

$$f_c(y, z \mid \theta)$$

seja realizada sobre um suporte comum.

Entretanto, suporte independente do parâmetro não é uma condição necessária para todo algoritmo EM. Quando o suporte varia com θ , é necessário verificar diretamente se as esperanças condicionais, a função Q e a identidade utilizada na prova da monotonicidade permanecem válidas (Gupta; Chen, 2011).

Identificabilidade e existência do máximo

O modelo deve ser identificável, ao menos após a imposição das restrições necessárias. Em misturas, a permutação dos rótulos dos componentes produz a mesma densidade, fenômeno conhecido como invariância por troca de rótulos.

Além disso, a verossimilhança pode ser ilimitada. Em uma mistura gaussiana irrestrita, um componente pode concentrar-se em uma única observação com variância tendendo a zero, fazendo a log-verossimilhança divergir para infinito. Nessa situação, o problema de máxima verossimilhança não possui um máximo finito no espaço paramétrico irrestrito (Gupta; Chen, 2011).

Para tornar o problema de estimação bem definido, podem ser impostas restrições como:

- um limite inferior positivo para variâncias ou autovalores das matrizes de covariâncias;
- estruturas restritas para as matrizes de covariâncias;
- penalizações que impeçam a degenerescência da verossimilhança.

Essas modificações alteram explicitamente o espaço paramétrico ou o critério de otimização e devem ser declaradas como parte do modelo ajustado.

Múltiplas inicializações e a remoção de componentes com peso numericamente desprezível são estratégias computacionais úteis, mas não eliminam, por si sós, a possibilidade de a verossimilhança irrestrita ser ilimitada.

Valores iniciais

Como a log-verossimilhança observada pode ser não côncava, diferentes valores iniciais podem conduzir a diferentes pontos estacionários. Para misturas gaussianas, inicializações baseadas em k -means, quantis, partições aleatórias ou conhecimento prévio são alternativas usuais (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

⚠ Observação — escopo das garantias

A monotonicidade da log-verossimilhança não garante convergência ao máximo global. Também não garante, por si só, a convergência da sequência de parâmetros. Teoremas mais fortes exigem hipóteses adicionais sobre continuidade, compacidade de conjuntos de nível, regularidade da aplicação de atualização e comportamento na fronteira do espaço paramétrico. A formulação precisa dessas hipóteses deve ser verificada em uma referência especializada para o modelo considerado.

6.4.3.4 Propriedades computacionais

Monotonicidade da log-verossimilhança

! Propriedade — monotonicidade

Sob as condições usuais do EM, se

$$Q(\theta^{(t+1)} | \theta^{(t)}) \geq Q(\theta^{(t)} | \theta^{(t)}),$$

então

$$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

i Demonstração

Seja

$$q_t(z) = f(z | y, \theta^{(t)}).$$

Então,

$$\ell(\theta) - \ell(\theta^{(t)}) = Q(\theta | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)}) + D_{\text{KL}}[q_t \| f(z | y, \theta)].$$

Como a divergência de Kullback–Leibler é não negativa,

$$\ell(\theta) - \ell(\theta^{(t)}) \geq Q(\theta | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)}).$$

Tomando

$$\theta = \theta^{(t+1)}$$

e utilizando a definição da etapa M,

$$Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)}),$$

segue que

$$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

Portanto, a log-verossimilhança observada não diminui ao longo das iterações do EM (Gupta; Chen, 2011, secs. 1.1 e 2.1).

Convergência dos valores da log-verossimilhança

Se a sequência

$$\ell(\theta^{(0)}), \ell(\theta^{(1)}), \dots$$

for limitada superiormente, sua monotonicidade implica a existência de ℓ^* tal que

$$\ell(\theta^{(t)}) \longrightarrow \ell^*.$$

Isso não implica necessariamente

$$\theta^{(t)} \longrightarrow \theta^*.$$

A sequência de parâmetros pode possuir múltiplos pontos de acumulação associados ao mesmo valor da log-verossimilhança (Gupta; Chen, 2011).

Pontos de acumulação e estacionariedade

A monotonicidade da log-verossimilhança não é suficiente, por si só, para concluir que a sequência

$$\theta^{(t)}$$

converge ou que todos os seus pontos de acumulação sejam máximos.

Sob condições adicionais sobre continuidade da aplicação de atualização, diferenciabilidade da log-verossimilhança e comportamento da sequência no espaço paramétrico, um ponto de acumulação interior θ^* pode ser caracterizado como ponto estacionário:

$$\nabla \ell(\theta^*) = 0.$$

Essa condição apenas caracteriza um ponto crítico. Ela não implica que θ^* seja o máximo global e, isoladamente, nem sequer garante que seja um máximo local.

Em problemas com restrições ou pontos na fronteira, a condição

$$\nabla \ell(\theta^*) = 0$$

também pode deixar de caracterizar um ótimo. A convergência numérica do EM, portanto, não demonstra que a solução obtida maximize a verossimilhança observada (Gupta; Chen, 2011).

Dependência da inicialização

Em problemas não côncavos, especialmente misturas gaussianas e modelos ocultos de Markov, o resultado pode depender fortemente de $\theta^{(0)}$. Recomenda-se executar o algoritmo a partir de diferentes valores iniciais e comparar as log-verossimilhanças finais (Gupta; Chen, 2011).

Velocidade de convergência

O EM pode convergir lentamente em comparação com métodos que utilizam derivadas de segunda ordem, como Newton–Raphson. A lentidão tende a ser mais pronunciada quando os dados observados contêm pouca informação sobre as variáveis latentes, por exemplo, quando componentes de uma mistura apresentam forte sobreposição. Variantes aceleradas podem reduzir o número de iterações, mas frequentemente aumentam o custo e a complexidade de cada passo (Gupta; Chen, 2011).

Relação com as propriedades do EMV

O EM é um algoritmo de otimização, e não uma definição distinta de estimador. Se o algoritmo converge para um ponto que corresponde ao estimador de máxima verossimilhança do modelo, suas propriedades estatísticas são as propriedades desse EMV.

Assim, consistência, normalidade assintótica, eficiência assintótica e estimação do erro-padrão devem ser analisadas pelas condições apresentadas em Seção 6.4.2.2 e pelos resultados de Seção 6.4.2.3. A utilização do EM para localizar o máximo não torna essas propriedades automaticamente válidas.

Em particular, é necessário distinguir duas sequências conceitualmente diferentes:

i Distinção conceitual

- **Convergência computacional:** comportamento de $\theta^{(t)}$ quando $t \rightarrow \infty$, mantendo a amostra observada fixa.
- **Convergência estatística:** comportamento de $\hat{\theta}_n$ quando $n \rightarrow \infty$ sob repetição do mecanismo amostral.

A convergência computacional do EM não implica, por si só, consistência ou normalidade assintótica do estimador. Da mesma forma, as propriedades assintóticas do EMV não garantem que uma execução particular do algoritmo tenha atingido um máximo global da verossimilhança observada.

i Aprofundamento adicional — extensões computacionais do EM

Duas extensões preservam diretamente a lógica de máxima verossimilhança utilizada nesta unidade.

EM generalizado (GEM). Em vez de maximizar completamente Q em cada iteração, basta escolher $\theta^{(t+1)}$ de modo que

$$Q(\theta^{(t+1)} | \theta^{(t)}) \geq Q(\theta^{(t)} | \theta^{(t)}).$$

Assim, a etapa M é substituída por uma etapa que apenas aumenta a função auxiliar.

Monte Carlo EM (MCEM). Quando a esperança da etapa E não pode ser calculada analiticamente, ela pode ser aproximada por simulação. Se

$$Z^{(t,1)}, \dots, Z^{(t,M)} \sim f(z | y, \theta^{(t)}),$$

então uma aproximação de Q é

$$\widehat{Q}_M(\theta | \theta^{(t)}) = \frac{1}{M} \sum_{m=1}^M \log f_c(y, Z^{(t,m)} | \theta).$$

O GEM e o MCEM são discutidos por Gupta; Chen (2011), e o MCEM também é apresentado por Ramachandran; Tsokos (2021, sec. 13.4).

Formulações penalizadas e extensões baseadas em distribuições a priori também existem, mas não são desenvolvidas aqui porque ultrapassam o escopo frequentista adotado nesta unidade.

6.4.3.5 Exemplos

A mistura gaussiana é o exemplo central porque permite calcular diretamente as etapas E e M a partir do problema motivador da seção. Os exemplos adicionais tratam de informação agregada, censura e dados ausentes.

i Exemplo adicional — informação agregada em um modelo multinomial

Fonte do exemplo

Este exemplo é adaptado da apresentação de Chihara; Hesterberg (2022, sec. 13.8) e Gupta; Chen (2011, sec. 1.5), que discutem o exemplo clássico de dados multinomiais incompletos.

Considere

$$(X_1, X_2, X_3, X_4, X_5) \sim \text{Multinomial} \left[n, \left(\frac{1}{2}, \frac{\theta}{4}, \frac{1-\theta}{4}, \frac{1-\theta}{4}, \frac{\theta}{4} \right) \right],$$

com $0 < \theta < 1$. Suponha que X_1 e X_2 não sejam observados separadamente; observa-se apenas

$$Y_1 = X_1 + X_2,$$

além de $Y_2 = X_3$, $Y_3 = X_4$ e $Y_4 = X_5$.

Condicionalmente a $Y_1 = y_1$ e ao valor corrente $\theta^{(t)}$,

$$E(X_2 | Y_1 = y_1, \theta^{(t)}) = \frac{\theta^{(t)}}{2 + \theta^{(t)}} y_1$$

e

$$E(X_1 | Y_1 = y_1, \theta^{(t)}) = \frac{2}{2 + \theta^{(t)}} y_1.$$

A etapa M produz

$$\theta^{(t+1)} = \frac{\frac{\theta^{(t)}}{2 + \theta^{(t)}} y_1 + y_4}{\frac{\theta^{(t)}}{2 + \theta^{(t)}} y_1 + y_2 + y_3 + y_4}.$$

O exemplo ilustra que a etapa E não precisa reconstruir valores individuais dos dados ausentes. Basta calcular as esperanças condicionais das contagens necessárias para a maximização.

Exemplo central — mistura gaussiana

O exemplo retoma o modelo de mistura usado na motivação inicial. A variável indicadora do componente simplifica a verossimilhança dos dados completos e permite obter as etapas E e M.

💡 Exemplo — mistura de k distribuições normais

A derivação segue Hastie; Tibshirani; Friedman (2009, sec. 8.5) e Gupta; Chen (2011, sec. 3.2).

Considere observações independentes $y_1, \dots, y_n \in \mathbb{R}^p$ provenientes de

$$f(y_i | \theta) = \sum_{j=1}^k \pi_j \phi_p(y_i; \mu_j, \Sigma_j),$$

com

$$\pi_j > 0, \quad \sum_{j=1}^k \pi_j = 1.$$

Introduza Z_{ij} como indicador de pertencimento ao componente j .

Etapas E

As responsabilidades são

$$\gamma_{ij}^{(t)} = P(Z_{ij} = 1 | Y_i = y_i, \theta^{(t)})$$

com

$$\gamma_{ij}^{(t)} = \frac{\pi_j^{(t)} \phi_p(y_i; \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{\ell=1}^k \pi_{\ell}^{(t)} \phi_p(y_i; \mu_{\ell}^{(t)}, \Sigma_{\ell}^{(t)})}.$$

Etapa M

Defina

$$n_j^{(t)} = \sum_{i=1}^n \gamma_{ij}^{(t)}.$$

As atualizações são

$$\pi_j^{(t+1)} = \frac{n_j^{(t)}}{n},$$

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ij}^{(t)} y_i}{n_j^{(t)}},$$

e

$$\Sigma_j^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ij}^{(t)} (y_i - \mu_j^{(t+1)})(y_i - \mu_j^{(t+1)})^\top}{n_j^{(t)}}.$$

Degenerescência da verossimilhança

As atualizações anteriores descrevem a etapa M enquanto as matrizes de covariâncias permanecem admissíveis. No modelo de mistura gaussiana irrestrito, contudo, a verossimilhança pode ser ilimitada: um componente pode concentrar-se em torno de uma observação enquanto sua matriz de covariâncias se aproxima da singularidade.

Assim, uma sequência produzida pelo EM pode se aproximar de uma solução degenerada em vez de um máximo finito da verossimilhança irrestrita. Restrições sobre as covariâncias ou outras formas explícitas de regularização modificam o problema de estimação e devem ser declaradas.

Implementação em R

O código a seguir implementa uma mistura normal univariada. As atualizações seguem as expressões anteriores, mas é imposta a restrição numérica

$$\sigma_j^2 \geq \text{variancia_minima}.$$

Portanto, a implementação corresponde a uma versão **restrita** do problema, utilizada para impedir a degenerescência das variâncias. Essa restrição deve ser interpretada como parte do procedimento computacional, e não como uma propriedade do modelo gaussiano irrestrito.

```
em_normal_1d <- function(y,
                          k = 2L,
                          tol = 1e-8,
                          max_iter = 1000L,
                          variancia_minima = 1e-8,
                          seed = 123L) {
  y <- as.numeric(y)

  if (length(y) < k) {
    stop("O número de observações deve ser pelo menos igual a k.")
  }
  if (any(!is.finite(y))) {
    stop("Todas as observações devem ser finitas.")
  }
  if (k < 1L || k != as.integer(k)) {
    stop("k deve ser um inteiro positivo.")
  }

  set.seed(seed)
  n <- length(y)

  medias <- as.numeric(
    quantile(y, probs = seq(0.1, 0.9, length.out = k), names = FALSE)
  )
  variancias <- rep(max(var(y), variancia_minima), k)
  proporcoes <- rep(1 / k, k)

  loglik_anterior <- -Inf
  responsabilidades <- matrix(NA_real_, nrow = n, ncol = k)
  convergiu <- FALSE

  etapa_e <- function(medias, variancias, proporcoes) {
    log_componentes <- vapply(
      seq_len(k),
      function(j) {
        log(proporcoes[j]) +
          dnorm(
            y,
            mean = medias[j],
```

```

        sd = sqrt(variancias[j]),
        log = TRUE
    )
},
numeric(n)
)

max_linha <- apply(log_componentes, 1L, max)
exp_centrado <- exp(log_componentes - max_linha)
soma_exp <- rowSums(exp_centrado)

list(
  responsabilidades = exp_centrado / soma_exp,
  loglik = sum(max_linha + log(soma_exp))
)
}

for (iteracao in seq_len(max_iter)) {
  resultado_e <- etapa_e(
    medias,
    variancias,
    proporcoes
  )

  responsabilidades <- resultado_e$responsabilidades
  loglik <- resultado_e$loglik

  if (is.finite(loglik_anterior)) {
    erro_relativo <- abs(loglik - loglik_anterior) /
      (1 + abs(loglik_anterior))

    if (erro_relativo < tol) {
      convergiu <- TRUE
      break
    }
  }
}

tamanhos <- colSums(responsabilidades)

if (any(tamanhos <= .Machine$double.eps)) {
  stop("Um componente recebeu peso efetivo numericamente nulo.")
}

```



```

proporcoes <- tamanhos / n
medias <- colSums(responsabilidades * y) / tamanhos

for (j in seq_len(k)) {
  variancias[j] <- sum(
    responsabilidades[, j] * (y - medias[j])^2
  ) / tamanhos[j]
}

variancias <- pmax(
  variancias,
  variancia_minima
)

loglik_anterior <- loglik
}

resultado_final <- etapa_e(
  medias,
  variancias,
  proporcoes
)

responsabilidades <- resultado_final$responsabilidades
loglik <- resultado_final$loglik

list(
  proporcoes = proporcoes,
  medias = medias,
  variancias = variancias,
  responsabilidades = responsabilidades,
  log_verossimilhanca = loglik,
  iteracoes = iteracao,
  convergiu = convergiu
)
}

```

i Observação computacional

O cálculo das responsabilidades foi realizado na escala logarítmica, com centralização pelo maior logaritmo em cada linha. Essa transformação reduz problemas de subfluxo

numérico quando densidades gaussianas são muito pequenas. Trata-se de uma decisão de implementação autoral baseada na forma matemática das responsabilidades.

i Exemplo adicional — distribuição exponencial com censura à direita

Fonte do exemplo

O exemplo é baseado em Ramachandran; Tsokos (2021, sec. 13.4).

Sejam $X_1, \dots, X_n$ tempos independentes com distribuição exponencial de taxa $\lambda > 0$:

$$f(x_i | \lambda) = \lambda e^{-\lambda x_i}, \quad x_i > 0.$$

Suponha que os limites de censura c_i sejam fixados ou gerados por um mecanismo de censura não informativo para λ .

Para cada indivíduo, observam-se

$$Y_i = \min(X_i, c_i)$$

e

$$\Delta_i = \mathbf{1}\{X_i \leq c_i\}.$$

Se todos os tempos fossem observados,

$$\ell_c(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n X_i.$$

Na etapa E,

$$E(X_i | Y_i, \Delta_i = 1, \lambda^{(t)}) = Y_i,$$

enquanto a falta de memória da distribuição exponencial fornece

$$E(X_i | X_i > c_i, \lambda^{(t)}) = c_i + \frac{1}{\lambda^{(t)}}.$$

Logo,

$$\tilde{T}^{(t)} = \sum_{i=1}^n \left[\Delta_i Y_i + (1 - \Delta_i) \left(c_i + \frac{1}{\lambda^{(t)}} \right) \right].$$

A etapa M produz

$$\lambda^{(t+1)} = \frac{n}{\tilde{T}^{(t)}}.$$

No ponto fixo, seja

$$d = \sum_{i=1}^n \Delta_i$$

o número de falhas observadas.

Se $d > 0$, a equação de ponto fixo fornece

$$\hat{\lambda} = \frac{d}{\sum_{i=1}^n Y_i}.$$

Esse é também o estimador obtido diretamente da verossimilhança observada, pois, desconsiderando fatores que não dependem de λ ,

$$L(\lambda) \propto \lambda^d \exp \left(-\lambda \sum_{i=1}^n Y_i \right).$$

Se $d = 0$, a log-verossimilhança observada é

$$\ell(\lambda) = -\lambda \sum_{i=1}^n Y_i + \text{constante},$$

e seu supremo ocorre quando

$$\lambda \downarrow 0.$$

Como o espaço paramétrico adotado é $\lambda > 0$, nesse caso não existe um EMV finito pertencente a Θ .

i Exemplo adicional — dados normais ausentes e estatísticas suficientes

Fonte do exemplo

O exemplo computacional é adaptado da formulação de Ramachandran; Tsoukos (2021, sec. 13.4).

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

e suponha que algumas respostas não sejam observadas. Neste exemplo, o mecanismo que determina quais observações estão ausentes é tratado como **ignorável para a verossimilhança de** (μ, σ^2) ; isto é, a análise utiliza apenas o modelo normal para os valores observados e ausentes.

AA log-verossimilhança dos dados completos depende da amostra por meio de

$$T_1 = \sum_{i=1}^n X_i \quad \text{e} \quad T_2 = \sum_{i=1}^n X_i^2.$$

Na iteração t , para cada observação ausente,

$$E(X_i \mid \mu^{(t)}, \sigma^{2(t)}) = \mu^{(t)}$$

e

$$E(X_i^2 \mid \mu^{(t)}, \sigma^{2(t)}) = \mu^{2(t)} + \sigma^{2(t)}.$$

As atualizações são

$$\mu^{(t+1)} = \frac{E(T_1 \mid Y, \theta^{(t)})}{n}$$

e

$$\sigma^{2(t+1)} = \frac{E(T_2 \mid Y, \theta^{(t)})}{n} - (\mu^{(t+1)})^2.$$

Se r valores são observados e $m = n - r$ estão ausentes, um ponto fixo da primeira atualização satisfaz

$$\mu = \frac{\sum_{\text{obs}} x_i + m\mu}{n},$$

de onde

$$\boxed{\hat{\mu} = \bar{X}_{\text{obs}}}.$$

Substituindo esse resultado na atualização da variância, obtém-se

$$\boxed{\hat{\sigma}^2 = \frac{1}{r} \sum_{\text{obs}} (X_i - \bar{X}_{\text{obs}})^2},$$

desde que esse máximo interior exista.

Portanto, neste exemplo simples, o EM converge para o mesmo EMV que seria obtido maximizando diretamente a verossimilhança das observações disponíveis. Os valores completamente ausentes não acrescentam informação sobre (μ, σ^2) ; eles apenas fornecem uma representação de dados completos para o algoritmo.

Se os valores observados forem todos iguais, a verossimilhança normal é ilimitada quando $\sigma^2 \downarrow 0$, e não existe um máximo interior para $\sigma^2 > 0$.

```

em_normal_ausentes <- function(y,
                                mu_inicial = NULL,
                                variancia_inicial = NULL,
                                tol = 1e-8,
                                max_iter = 1000L) {

  y <- as.numeric(y)
  observados <- y[!is.na(y)]

  if (length(observados) == 0L) {
    stop("É necessária ao menos uma observação disponível.")
  }

  n <- length(y)
  r <- length(observados)
  m <- n - r

  mu <- if (is.null(mu_inicial)) mean(observados) else mu_inicial
  variancia <- if (is.null(variancia_inicial)) {
    if (r > 1L) var(observados) else 1
  } else {
    variancia_inicial
  }

  if (!is.finite(mu) || !is.finite(variancia) || variancia <= 0) {
    stop("Valores iniciais inválidos.")
  }

  loglik_observada <- function(mu, variancia) {
    sum(dnorm(observados,
              mean = mu,
              sd = sqrt(variancia),
              log = TRUE))
  }

  historico <- data.frame(
    iteracao = integer(),
    mu = numeric(),
    variancia = numeric(),
    loglik = numeric()
  )

  loglik_anterior <- loglik_observada(mu, variancia)
  convergiu <- FALSE

  for (iteracao in seq_len(max_iter)) {
    esperanca_t1 <- sum(observados) / n * mu
    esperanca_t2 <- sum(observados^2) / n - m * (mu^2 + variancia)

    mu_novo <- esperanca_t1 / n
    variancia_nova <- esperanca_t2 / n - mu_novo^2

    if (!is.finite(variancia_nova) || variancia_nova <= 0) {
      stop("A atualização produziu variância inválida.")
    }
  }
}

```

Interpretação do exemplo

O exemplo anterior utiliza um mecanismo de ausência que pode ser ignorado na verossimilhança de (μ, σ^2) . Essa hipótese é parte do modelo e não decorre do algoritmo EM.

Se o mecanismo de ausência não é ignorável para (μ, σ^2) , a verossimilhança baseada apenas nos valores observados não representa o modelo conjunto. Nesse caso, o mecanismo de ausência deve ser especificado e incorporado à análise. A teoria geral de mecanismos de ausência não é desenvolvida nesta unidade.

6.4.3.6 Exercícios

Os exercícios são autorais ou adaptados das estruturas de problemas apresentadas nas fontes indicadas. Quando um enunciado deriva diretamente de uma fonte, isso é explicitado.

i Exercício 1 — dados observados e dados completos

Considere

$$f(y | \theta) = \pi f_1(y; \eta_1) + (1 - \pi) f_2(y; \eta_2).$$

1. Defina uma variável latente que identifique o componente de origem.
2. Escreva a densidade conjunta dos dados completos.
3. Obtenha a log-verossimilhança completa.
4. Explique por que essa expressão pode ser mais simples de maximizar do que a log-verossimilhança observada.

Fonte: elaborado com base em Hastie; Tibshirani; Friedman (2009) e Gupta; Chen (2011).

i Exercício 2 — uma iteração para mistura normal

Considere

$$y = (0, 1, 4, 5)$$

e uma mistura de duas normais com variâncias conhecidas e iguais a 1. Utilize

$$\pi^{(0)} = 0,5, \quad \mu_1^{(0)} = 0, \quad \mu_2^{(0)} = 5.$$

1. Calcule as responsabilidades $\gamma_{i1}^{(0)}$ e $\gamma_{i2}^{(0)}$.

2. Calcule $\pi^{(1)}$, $\mu_1^{(1)}$ e $\mu_2^{(1)}$.
3. Interprete os valores obtidos.

Fonte: exercício autoral baseado nas atualizações de Hastie; Tibshirani; Friedman (2009) e Gupta; Chen (2011).

i Exercício 3 — restrição sobre os pesos

Mostre que

$$\pi_j^{(t+1)} = \frac{1}{n} \sum_{i=1}^n \gamma_{ij}^{(t)}$$

satisfaz

$$\sum_{j=1}^k \pi_j^{(t+1)} = 1.$$

Em seguida, derive a atualização por multiplicadores de Lagrange, maximizando

$$\sum_{j=1}^k n_j^{(t)} \log \pi_j$$

sob a restrição $\sum_j \pi_j = 1$.

Fonte: elaborado com base em Gupta; Chen (2011).

i Exercício 4 — monotonicidade

Demonstre que

$$\ell(\theta) - \ell(\theta^{(t)}) = Q(\theta \mid \theta^{(t)}) - Q(\theta^{(t)} \mid \theta^{(t)}) + D_{\text{KL}}[q_t \parallel f(z \mid y, \theta)].$$

Conclua que uma atualização que não diminui Q também não diminui a log-verossimilhança observada.

Fonte: adaptado da demonstração de Gupta; Chen (2011).

i Exercício 5 — exemplo multinomial clássico

Considere o modelo multinomial do exemplo adicional de informação agregada apresentado anteriormente e os dados observados

$$(y_1, y_2, y_3, y_4) = (125, 18, 20, 34).$$

1. Inicie o algoritmo em $\theta^{(0)} = 0,5$.
2. Calcule as cinco primeiras atualizações.
3. Obtenha numericamente o máximo direto da log-verossimilhança observada.
4. Compare o resultado direto com o limite do EM.

Fonte: adaptado das apresentações de Chihara; Hesterberg (2022, sec. 13.8) e Gupta; Chen (2011, sec. 1.5).

i Exercício 6 — censura exponencial

Considere

$$(y_i, \delta_i) = (2, 1), (3, 0), (4, 1), (5, 0), (6, 1).$$

1. Inicie em $\lambda^{(0)} = 0,5$.
2. Calcule $\lambda^{(1)}$, $\lambda^{(2)}$ e $\lambda^{(3)}$.
3. Determine diretamente o estimador de máxima verossimilhança.
4. Compare o limite das iterações com o resultado analítico.

Fonte: exercício autoral baseado no exemplo de censura de Ramachandran; Tsokos (2021, sec. 13.4).

i Exercício 7 — inicializações múltiplas

Simule uma amostra de uma mistura de duas normais e execute o EM com pelo menos vinte inicializações.

1. Registre a log-verossimilhança final de cada execução.
2. Verifique se todas as execuções convergem para a mesma solução.
3. Compare médias, variâncias e pesos estimados.
4. Discuta por que a maior log-verossimilhança encontrada não constitui prova de otimalidade global.

Fonte: elaborado com base nas recomendações práticas de Gupta; Chen (2011).

i Exercício 8 — singularidade em misturas gaussianas

Fixe $\mu_1 = y_r$, mantenha $\pi_1 > 0$ e faça

$$\sigma_1^2 \rightarrow 0.$$

Mostre que a contribuição da observação y_r para a log-verossimilhança tende ao infinito. Explique por que esse resultado implica que o problema irrestrito pode não possuir estimador de máxima verossimilhança finito.

Fonte: adaptado da demonstração de Gupta; Chen (2011).

i Exercício 9 — GEM e MCEM

1. Mostre que o GEM preserva a monotonicidade quando aumenta a função Q em cada iteração.
2. Descreva como aproximar a etapa E por uma média de Monte Carlo.
3. Explique por que uma aproximação Monte Carlo com tamanho fixo pode introduzir oscilações na sequência de log-verossimilhanças.
4. Proponha uma estratégia em que o número de simulações aumente ao longo das iterações.

Fonte: elaborado com base em Gupta; Chen (2011) e Ramachandran; Tsokos (2021).

i Exercício 10 — propriedades do estimador e do algoritmo

Avalie as afirmações seguintes.

1. Se a log-verossimilhança aumenta em todas as iterações, o EM converge necessariamente para o máximo global.
2. Se a sequência de log-verossimilhanças converge, a sequência de parâmetros também converge.
3. Se o EM alcança um estimador regular de máxima verossimilhança, aplicam-se as propriedades assintóticas usuais desse estimador.
4. Duas inicializações diferentes sempre produzem a mesma estimativa.
5. A convergência computacional do EM implica consistência estatística.

Fonte: elaborado com base em Gupta; Chen (2011) e Lauritzen (2023).

6.4.3.7 Síntese

O algoritmo EM reorganiza um problema de máxima verossimilhança com dados incompletos em duas operações alternadas:

calcular esperanças condicionais associadas aos dados latentes

e

maximizar a log-verossimilhança completa esperada.

Sua principal garantia geral é a monotonicidade da log-verossimilhança observada:

$$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

Essa propriedade não implica, por si só, convergência da sequência de parâmetros, estacionariedade de todos os seus pontos de acumulação ou obtenção do máximo global. Resultados mais fortes exigem condições adicionais sobre o modelo e sobre a aplicação de atualização do EM.

Entre as vantagens do algoritmo estão a simplicidade de muitas atualizações e sua aplicabilidade a modelos de mistura, censura, dados ausentes e estados latentes. Entre as limitações estão a dependência da inicialização, a convergência potencialmente lenta, a possibilidade de soluções locais e, em alguns modelos, a degenerescência ou inexistência do máximo da verossimilhança.

O EM deve ser interpretado como um algoritmo de otimização para problemas de máxima verossimilhança em que uma representação por dados completos torna as etapas de cálculo mais simples. O princípio de estimação continua sendo a máxima verossimilhança; o EM fornece uma estratégia iterativa para realizar sua otimização.

Exercícios Complementares

1. Considere $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\mu^{-1})$. Defina $T = X_{(1)} = \min\{X_1, \dots, X_n\}$.
 - a. Determine o viés $B(T, \mu)$ e o erro quadrático médio $\text{EQM}(T)$.
 - b. Verifique se T é um estimador consistente para μ .
 - c. No caso de amostras grandes, você sugere a utilização de T como estimador de μ ? Caso contrário, proponha um estimador melhor e justifique.

Dica: Lembre-se que $f_T(t) = n[1 - F_X(t)]^{n-1}f_X(t)$ e $F_X(x) = 1 - e^{-\frac{x}{\mu}}$.

2. Seja $X_1, \dots, X_n$ uma amostra aleatória de tamanho n de uma distribuição de Bernoulli com parâmetro $\theta \in (0, 1)$. Seja $T(X) = \bar{X}_n^2$ o estimador de máxima verossimilhança de θ^2 . Considere o estimador Jackknife de θ^2 dado por:

$$T_J(X) = nT - \frac{n-1}{n} \sum_{i=1}^n T_{(i)},$$

em que $T_{(i)}$ representa o estimador T calculado com a amostra original excluindo a i -ésima observação.

- a. Mostre que o EMV de θ^2 é viesado.
- b. Mostre que $T_J(X)$ é não viesado.

Dica: Use o fato que $T_{(i)} = \left(\frac{n\bar{X} - X_i}{n-1} \right)^2$.

3. Sejam $Y_1, \dots, Y_n$ variáveis aleatórias independentes tais que $Y_i \sim N(\alpha + \beta x_i, \sigma^2)$, em que os valores x_i são não estocásticos e satisfazem $\sum_{i=1}^n (x_i - \bar{x}_n)^2 > 0$. Mostre que

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}$$

e

$$\hat{\alpha} = \bar{Y}_n - \hat{\beta} \bar{x}_n$$

são estimadores não viesados de β e α , respectivamente.

4. Sejam $X_1, \dots, X_n$ uma amostra aleatória de uma variável com distribuição Rayleigh, cuja densidade é dada por:

$$f_X(x) = \frac{x}{\theta} \exp\left(-\frac{x^2}{2\theta}\right) I_{(0,\infty)}(x), \quad \theta > 0.$$

- a. Determine um estimador não viesado e consistente para θ .
- b. Estime θ a partir da seguinte amostra (força vibratória de uma palheta de turbina):

16.88, 10.23, 4.59, 6.66, 13.68, 14.23, 19.87, 9.40, 6.51, 9.24, 12.20, 10.95.

5. Considere $X_1, \dots, X_n$ uma amostra aleatória de uma variável X com função densidade de probabilidade dada por:

$$f_X(x) = e^{-(x-\theta)} \mathbf{1}\{x \geq \theta\}.$$

- a. Determine um estimador não viesado de θ que seja função de $X_{(1)} = \min\{X_1, \dots, X_n\}$.
- b. Mostre que $X_{(1)}$ é um estimador consistente de θ .

Referências

7 Estimação intervalar

A estimação pontual associa a cada amostra um único valor para representar um parâmetro desconhecido. Embora esse valor seja informativo, ele não expressa, por si só, a variabilidade amostral nem a precisão do procedimento de estimação. A estimação intervalar complementa a estimativa pontual por meio de um conjunto de valores compatíveis com os dados e com o modelo estatístico adotado.

No paradigma frequentista, o parâmetro é considerado fixo e desconhecido, enquanto os limites do intervalo são estatísticas e, portanto, variam de amostra para amostra. Essa distinção determina como os intervalos de confiança são definidos e interpretados (Cox, 2006, pp. 66–69; Rice, 2007, sec. 8.5.3).

! Observação — por que a estimativa pontual não é suficiente?

Em modelos contínuos, frequentemente ocorre $P_{\theta}(\hat{\theta} = \theta) = 0$. Em problemas discretos, um estimador pode coincidir com o parâmetro com probabilidade positiva. A estimação intervalar é motivada pela necessidade de quantificar a incerteza associada ao procedimento de estimação.

Objetivos do capítulo

Ao final deste capítulo, o leitor deverá ser capaz de:

1. definir conjuntos e intervalos de confiança por meio de sua função de cobertura;
2. interpretar corretamente o nível de confiança no paradigma frequentista;
3. construir intervalos exatos a partir de quantidades pivotais;
4. distinguir procedimentos exatos, conservadores e assintóticos;
5. aplicar intervalos normais, t , qui-quadrado, de Wilson e de Clopper–Pearson;
6. reconhecer as limitações dos intervalos de Wald e dos métodos bootstrap;
7. relacionar intervalos de confiança, testes de hipóteses, precisão e tamanho amostral.

7.1 Definição formal

Considere uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ cuja distribuição pertence a uma família $\{P_\theta : \theta \in \Theta\}$. Uma regra de confiança C associa cada possível amostra $\mathbf{x}$ a um subconjunto $C(\mathbf{x}) \subseteq \Theta$. Antes da observação dos dados, $C(\mathbf{X})$ é, portanto, um conjunto aleatório.

Definição — conjunto de confiança e cobertura

Para um conjunto aleatório $C(\mathbf{X}) \subseteq \Theta$, a **função de cobertura** é

$$c(\theta) = P_\theta\{\theta \in C(\mathbf{X})\}, \quad \theta \in \Theta.$$

O **coeficiente de confiança** do procedimento é

$$\gamma(C) = \inf_{\theta \in \Theta} c(\theta).$$

O conjunto $C(\mathbf{X})$ é um conjunto de confiança de nível **pelo menos** $1 - \alpha$ quando

$$\gamma(C) \geq 1 - \alpha,$$

ou, equivalentemente,

$$P_\theta\{\theta \in C(\mathbf{X})\} \geq 1 - \alpha, \quad \text{para todo } \theta \in \Theta.$$

Quando

$$c(\theta) = 1 - \alpha \quad \text{para todo } \theta \in \Theta,$$

o procedimento possui **cobertura exata no nível nominal**. Quando a garantia decorre apenas de uma aproximação ou de um resultado limite, o procedimento é **aproximado** ou **assintótico**. Se a cobertura é de pelo menos $1 - \alpha$, mas excede o nível nominal para alguns valores de θ , o procedimento é **conservador** (Casella; Berger, 2011, sec. 9.1; Lauritzen, 2023, sec. 6.2; Cox, 2006, sec. 5.4).

Para um parâmetro escalar, é comum escrever

$$C(\mathbf{X}) = [L(\mathbf{X}), U(\mathbf{X})],$$

em que L e U são, respectivamente, os limites inferior e superior de confiança.

Procedimento exato e cobertura exata

A expressão **intervalo exato** também é usada para procedimentos construídos a partir da distribuição amostral finita, sem recorrer a uma aproximação assintótica. Esse uso

não implica que

$$c(\theta) = 1 - \alpha$$

para todo θ .

Em modelos discretos, um procedimento exato pode garantir

$$c(\theta) \geq 1 - \alpha$$

e ainda ser conservador. O intervalo de Clopper–Pearson apresentado adiante é um exemplo dessa situação (Casella; Berger, 2011, sec. 9.5.2; Rasch; Schott, 2018, pp. 144–146).

7.2 Interpretação frequentista

No paradigma frequentista, θ é fixo e desconhecido. Antes da observação da amostra, o conjunto $C(\mathbf{X})$ é aleatório porque depende de $\mathbf{X}$. O nível de confiança descreve o comportamento desse procedimento sob repetições do processo amostral.

Interpretação correta

Se

$$c(\theta) = 0,95,$$

então, sob repetições independentes do mesmo processo amostral com esse valor de θ , a proporção de intervalos que contêm θ converge para 0,95. Em um procedimento conservador de nível 95%, a cobertura é de pelo menos 0,95. Essas afirmações pressupõem o modelo e o plano amostral especificados para o procedimento.

Depois de observar $\mathbf{X} = \mathbf{x}$, obtém-se um conjunto numérico

$$C(\mathbf{x}) = [l, u].$$

O intervalo observado já não é aleatório, e θ continua sendo um parâmetro fixo e desconhecido. Portanto, ou

$$\theta \in [l, u]$$

ou

$$\theta \notin [l, u].$$

No sentido frequentista estrito, não se deve afirmar

“A probabilidade de θ pertencer ao intervalo observado é 0,95.”

A expressão “estamos 95% confiantes” é uma forma abreviada de se referir à propriedade de cobertura do procedimento que produziu o intervalo, e não a uma distribuição de probabilidade atribuída a θ (Casella; Berger, 2011, sec. 9.1; Cox, 2006, secs. 5.3–5.4).



Intervalo de confiança e intervalo de credibilidade

Um intervalo de credibilidade bayesiano é construído a partir da distribuição posterior do parâmetro e admite uma interpretação probabilística condicional aos dados e ao modelo bayesiano. Um intervalo de confiança frequentista é definido por sua cobertura sob amostragens repetidas. Os dois conceitos não são intercambiáveis, ainda que possam produzir limites numericamente semelhantes em alguns modelos.

7.3 Quantis e valores críticos

Se $Z \sim N(0, 1)$ e z_q denota o quantil de ordem q , então

$$P(Z \leq z_q) = q.$$

Pela simetria da distribuição normal padrão,

$$z_{\alpha/2} = -z_{1-\alpha/2}$$

e, portanto,

$$P(-z_{1-\alpha/2} \leq Z \leq z_{1-\alpha/2}) = 1 - \alpha.$$

Para $1 - \alpha = 0,95$, tem-se $z_{0,975} \approx 1,96$.

7.4 Construção por quantidade pivotal

Uma estratégia para construir conjuntos de confiança consiste em encontrar uma quantidade cuja distribuição não dependa de parâmetros desconhecidos.




Figura 7.1: Região central de 95% da distribuição normal padrão.

i Definição — quantidade pivotal

Uma função dos dados e do parâmetro

$$Q = Q(\mathbf{X}, \theta)$$

é uma **quantidade pivotal** quando sua distribuição, sob P_θ , não depende de θ nem de outros parâmetros desconhecidos. Como Q depende de θ , ela não é, em geral, uma estatística no sentido estrito (Casella; Berger, 2011, sec. 9.2.2).

Seja A um conjunto de valores possíveis do pivô escolhido de modo que

$$P_\theta\{Q(\mathbf{X}, \theta) \in A\} \geq 1 - \alpha.$$

Como a distribuição de Q não depende de parâmetros desconhecidos, essa probabilidade pode ser determinada sem conhecer θ . O conjunto

$$C(\mathbf{X}) = \{\theta \in \Theta : Q(\mathbf{X}, \theta) \in A\}$$

satisfaz

$$P_{\theta}\{\theta \in C(\mathbf{X})\} \geq 1 - \alpha.$$

No caso contínuo, uma escolha bilateral de caudas iguais é

$$A = [q_{\alpha/2}, q_{1-\alpha/2}],$$

para a qual

$$P_{\theta}(q_{\alpha/2} \leq Q(\mathbf{X}, \theta) \leq q_{1-\alpha/2}) = 1 - \alpha.$$

Em distribuições discretas, a mesma construção por quantis pode produzir probabilidade superior a $1 - \alpha$.

Quando a condição

$$Q(\mathbf{X}, \theta) \in A$$

pode ser invertida em relação a θ , obtêm-se os limites ou, mais geralmente, o conjunto de confiança. O conjunto resultante não precisa ser simétrico, não precisa estar centrado em $\hat{\theta}$ e, em certos problemas, nem sequer precisa conter o estimador de máxima verossimilhança (Casella; Berger, 2011, sec. 9.2.2; Lauritzen, 2023, sec. 6.2; Ramachandran; Tsokos, 2021, pp. 215–219).

7.4.1 Procedimento geral

1. Especifique o modelo e o parâmetro de interesse θ .
2. Encontre uma quantidade pivotal $Q(\mathbf{X}, \theta)$.
3. Escolha um conjunto A de valores do pivô cuja probabilidade seja $1 - \alpha$ ou, quando a estrutura do problema impedir igualdade exata, pelo menos $1 - \alpha$.
4. Inverta a condição

$$Q(\mathbf{X}, \theta) \in A$$

em relação a θ .

5. Verifique se o conjunto obtido pertence ao espaço paramétrico Θ .
6. Identifique se a cobertura resultante é exata no nível nominal ou conservadora.
7. Declare as hipóteses necessárias e interprete o resultado no contexto do problema.

7.5 Intervalos para parâmetros da distribuição normal

7.5.1 Média com variância conhecida

Suponha que

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida. Como

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

segue que

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Logo, um intervalo exato de nível $1 - \alpha$ para μ é

$$\boxed{\bar{X} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}}.$$

Sob o modelo normal especificado acima, esse intervalo possui cobertura exatamente igual a $1 - \alpha$.

Se a hipótese de normalidade for retirada, mas $X_1, \dots, X_n$ forem i.i.d. com

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2 < \infty,$$

a mesma expressão pode ser utilizada como intervalo aproximado quando a distribuição de $\bar{X}$ estiver bem aproximada pela normal, conforme o Teorema Central do Limite. Não existe um valor universal de n que garanta boa aproximação: sua qualidade depende da distribuição da população, em particular de sua assimetria e do comportamento das caudas (Casella; Berger, 2011, sec. 9.2.2; Rice, 2007, sec. 8.5.3; Chihara; Hesterberg, 2022, sec. 4.3.3).

i Exemplo — média com variância conhecida

Considere os dados

12, 15, 14, 10, 13, 16, 14, 15

provenientes de uma população normal com desvio-padrão conhecido $\sigma = 2,5$. Tem-se $n = 8$ e $\bar{x} = 13,625$. Para um intervalo de 95%,

$$13,625 \pm 1,96 \frac{2,5}{\sqrt{8}} = 13,625 \pm 1,732.$$

Portanto,

$$IC_{95\%}(\mu) = [11,893; 15,357].$$

Interpretação: o método utilizado tem cobertura de 95% sob o modelo normal com $\sigma = 2,5$.

Base metodológica: (Rice, 2007, pp. 279–281; Larsen; Marx, 2012, pp. 297–311).

```
import numpy as np
from scipy.stats import norm

x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
sigma = 2.5
alpha = 0.05

n = len(x)
xbar = x.mean()
z = norm.ppf(1 - alpha / 2)
me = z * sigma / np.sqrt(n)
intervalo = (xbar - me, xbar + me)

print(f"média = {xbar:.3f}")
print(f"IC 95% = ({intervalo[0]:.3f}, {intervalo[1]:.3f})")
```

média = 13.625

IC 95% = (11.893, 15.357)

7.5.2 Média com variância desconhecida

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$$

com μ e σ^2 desconhecidos, então

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1},$$

em que

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Assim,

$$\boxed{\bar{X} \pm t_{1-\alpha/2, n-1} \frac{S}{\sqrt{n}}}$$

é um intervalo exato para μ sob normalidade (Casella; Berger, 2011, sec. 9.2.2; Lauritzen, 2023, ex. 6.5; Rice, 2007, pp. 279–280).

! Observação — não há regra universal como $n > 30$ ou $n > 200$

Para dados normais, o intervalo t é exato para qualquer $n \geq 2$.

Se $X_1, \dots, X_n$ forem i.i.d., com média μ e variância finita e positiva, a estatística studentizada

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}$$

converge em distribuição para $N(0, 1)$. Assim, para populações não normais, o intervalo t pode ter validade assintótica, mas deixa de ser um procedimento exato.

Não existe um tamanho amostral universal que assegure boa aproximação. Além disso, aumentar n não corrige problemas como seleção da amostra, dependência ignorada ou especificação inadequada do modelo.

i Exemplo — média com variância desconhecida

Para os mesmos oito valores, $\bar{x} = 13,625$, $s = 1,923$ e $t_{0,975;7} = 2,365$. Logo,

$$IC_{95\%}(\mu) = 13,625 \pm 2,365 \frac{1,923}{\sqrt{8}} = [12,018; 15,232].$$

Base metodológica: (Lauritzen, 2023, ex. 6.5).

```
import numpy as np
from scipy.stats import t

x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
alpha = 0.05

n = len(x)
xbar = x.mean()
s = x.std(ddof=1)
tcrit = t.ppf(1 - alpha / 2, df=n - 1)
me = tcrit * s / np.sqrt(n)

print(f"IC 95% = ({xbar - me:.3f}, {xbar + me:.3f})")
```

IC 95% = (12.018, 15.232)

7.5.3 Variância de uma população normal

Sob normalidade,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Consequentemente, um intervalo bilateral de **caudas iguais**, com cobertura exata $1 - \alpha$, para σ^2 é

$$\left[\frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2} \right].$$

O intervalo para σ é obtido pela raiz quadrada dos limites. Como a distribuição qui-quadrado é assimétrica, esses intervalos não são simétricos em torno de S^2 e S , respectivamente (Casella; Berger, 2011, sec. 9.2.2; Rice, 2007, pp. 280–281).

i Observação — caudas iguais

A condição de cobertura não determina um único intervalo. Para a distribuição qui-quadrado, a escolha de probabilidades $\alpha/2$ em cada cauda produz o intervalo de caudas iguais apresentado acima, mas não decorre disso que ele minimize o comprimento entre todos os intervalos com a mesma cobertura.

⚠ Condição de uso

O intervalo qui-quadrado para a variância é sensível a desvios de normalidade. Em aplicações, essa hipótese deve ser examinada com atenção; amostras grandes não tornam automaticamente esse procedimento robusto a caudas pesadas ou valores discrepantes.

i Exemplo — intervalo para a variância

Para os oito valores anteriores, $s^2 = 3,696$ e $n - 1 = 7$. O intervalo de 95% para σ^2 é

$$IC_{95\%}(\sigma^2) = [1,616; 15,312].$$

Assim,

$$IC_{95\%}(\sigma) = [1,271; 3,913].$$

A assimetria dos limites reflete a assimetria da distribuição qui-quadrado.

Base metodológica: (Rice, 2007, pp. 280–281).

```
import numpy as np
from scipy.stats import chi2

x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
alpha = 0.05

n = len(x)
s2 = x.var(ddof=1)
df = n - 1

lim_inf = df * s2 / chi2.ppf(1 - alpha / 2, df)
lim_sup = df * s2 / chi2.ppf(alpha / 2, df)

print(f"IC 95% para sigma^2 = ({lim_inf:.3f}, {lim_sup:.3f})")
print(f"IC 95% para sigma   = ({np.sqrt(lim_inf):.3f}, {np.sqrt(lim_sup):.3f})")
```

```
IC 95% para sigma^2 = (1.616, 15.312)
```

```
IC 95% para sigma   = (1.271, 3.913)
```

7.6 Exemplo de intervalo exato por pivô — distribuição exponencial

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

na parametrização por taxa, com densidade

$$f(x \mid \lambda) = \lambda e^{-\lambda x}, \quad x > 0.$$

Defina

$$T = \sum_{i=1}^n X_i.$$

Na parametrização forma–escala adotada neste livro,

$$T \sim \text{Gama}\left(n, \frac{1}{\lambda}\right).$$

Consequentemente,

$$2\lambda T = 2\lambda \sum_{i=1}^n X_i \sim \chi_{2n}^2.$$

Portanto, um intervalo de caudas iguais com cobertura exata $1 - \alpha$ para λ é

$$\left[\frac{\chi_{\alpha/2, 2n}^2}{2 \sum_{i=1}^n X_i}, \frac{\chi_{1-\alpha/2, 2n}^2}{2 \sum_{i=1}^n X_i} \right].$$

i Exemplo adaptado — taxa exponencial

Para a amostra 2, 2,5, 3, 4 e 9, tem-se $n = 5$ e $\sum x_i = 20,5$. O intervalo exato de 95% é

$$IC_{95\%}(\lambda) = [0,079; 0,500].$$

Se o parâmetro de interesse for a média

$$\theta = \frac{1}{\lambda},$$

a transformação $g(\lambda) = 1/\lambda$ é biunívoca e estritamente decrescente para $\lambda > 0$. Portanto, se

$$L \leq \lambda \leq U,$$

então

$$\frac{1}{U} \leq \theta \leq \frac{1}{L}.$$

Assim,

$$IC_{95\%}(\theta) = \left[\frac{1}{0,500}, \frac{1}{0,079} \right] \approx [2,002; 12,627].$$

A transformação dos limites preserva a cobertura porque os eventos

$$\{L \leq \lambda \leq U\}$$

e

$$\left\{ \frac{1}{U} \leq \theta \leq \frac{1}{L} \right\}$$

são equivalentes.

Base metodológica: (Chihara; Hesterberg, 2022, sec. 7.2; Lauritzen, 2023, ex. 6.7).

7.7 Intervalos assintóticos e método de Wald

A normalidade assintótica e a estimação do erro-padrão dos estimadores de máxima verossimilhança regulares foram desenvolvidas em Seção 6.4.2.3.

Mais geralmente, suponha que um estimador satisfaça

$$\frac{\hat{\theta} - \theta}{\widehat{\text{EP}}(\hat{\theta})} \xrightarrow{d} N(0, 1).$$

Então, um intervalo de Wald com cobertura assintótica $1 - \alpha$ é

$$\left[\hat{\theta} \pm z_{1-\alpha/2} \widehat{\text{EP}}(\hat{\theta}) \right].$$

Para um EMV regular de um parâmetro escalar, uma estimativa de primeira ordem do erro-padrão pode ser obtida pela informação esperada:

$$\widehat{\text{EP}}(\hat{\theta}) = \left[nI_1(\hat{\theta}) \right]^{-1/2},$$

ou, quando apropriado, pela informação observada:

$$\widehat{\text{EP}}(\hat{\theta}) = [J_n(\hat{\theta})]^{-1/2}.$$

A validade do intervalo depende das condições que sustentam a aproximação normal assintótica, entre elas interioridade do parâmetro, identificabilidade e informação de Fisher finita e positiva (Rice, 2007, secs. 8.5.2–8.5.3; Lauritzen, 2023, sec. 6.4.3).

⚠ Limitações do intervalo de Wald

O intervalo de Wald pode apresentar cobertura insatisfatória em amostras pequenas, perto das fronteiras do espaço paramétrico, para distribuições muito assimétricas ou quando o erro-padrão varia fortemente com o parâmetro. Além disso, ele não é invariável a reparametrizações não lineares: construir um intervalo para θ e transformá-lo pode produzir resultado diferente de construir diretamente um intervalo para $g(\theta)$. Intervalos de razão de verossimilhanças, de escore ou baseados em transformações podem ser preferíveis.

7.7.1 Exemplo — média de uma distribuição de Poisson

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda),$$

então $\hat{\lambda} = \bar{X}$ e

$$\text{Var}(\hat{\lambda}) = \frac{\lambda}{n}.$$

Substituindo λ por $\hat{\lambda}$, obtém-se

$$\bar{X} \pm z_{1-\alpha/2} \sqrt{\frac{\bar{X}}{n}}.$$

Esse é um intervalo assintótico. Quando $\bar{X}$ é pequeno, a aproximação normal pode ser inadequada. Em particular, se

$$\bar{X} = 0,$$

o erro-padrão estimado é zero e o intervalo de Wald degenera em

$$[0, 0].$$

Se o limite inferior calculado for negativo, truncá-lo em zero respeita o espaço paramétrico, mas não restaura, por si só, a cobertura nominal. Para contagens pequenas, procedimentos exatos ou métodos baseados na verossimilhança devem ser considerados porque a aproximação normal de Wald pode apresentar cobertura insatisfatória (Rice, 2007, pp. 282–283).

7.8 Intervalos para uma proporção binomial

Se $X \sim \text{Binom}(n, p)$, então

$$\hat{p} = \frac{X}{n}.$$

7.8.1 Intervalo de Wald

A substituição de p por $\hat{p}$ no erro-padrão produz

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

Embora simples, esse intervalo pode apresentar cobertura muito inferior à nominal, produzir limites fora de $[0, 1]$ e degenerar quando $x = 0$ ou $x = n$. Regras como $n\hat{p} \geq 5$ e $n(1-\hat{p}) \geq 5$ são apenas diagnósticos aproximados e não garantem boa cobertura, sobretudo quando p está próximo de 0 ou 1 (Ramachandran; Tsokos, 2009, pp. 302–304; Chihara; Hesterberg, 2022, pp. 211–215).

7.8.2 Intervalo de Wilson ou de escore

Se $z = z_{1-\alpha/2}$, o intervalo de Wilson é

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}.$$

Esse intervalo pode ser obtido pela inversão do procedimento de escore para p . A teoria formal de testes que sustenta essa interpretação será desenvolvida na unidade seguinte.

Em comparação com o intervalo de Wald, Wilson costuma apresentar cobertura mais próxima do nível nominal, especialmente em amostras pequenas ou quando p está próximo das fronteiras do espaço paramétrico. Seu centro não coincide exatamente com $\hat{p}$ (Chihara; Hesterberg, 2022, sec. 7.4; Wilson, 1927).

7.8.3 Intervalo exato de Clopper–Pearson

Para $0 < x < n$, o intervalo bilateral de caudas iguais pode ser escrito por quantis beta:

$$L = B_{\alpha/2}^{-1}(x, n - x + 1)$$

e

$$U = B_{1-\alpha/2}^{-1}(x + 1, n - x),$$

em que $B_q^{-1}(a, b)$ é o quantil de ordem q da distribuição beta com parâmetros a e b .

Nos casos de fronteira:

$$x = 0 \implies L = 0, \quad U = 1 - \left(\frac{\alpha}{2}\right)^{1/n},$$

e

$$x = n \implies L = \left(\frac{\alpha}{2}\right)^{1/n}, \quad U = 1.$$

O procedimento de Clopper–Pearson é obtido por inversão de probabilidades binomiais exatas, sem aproximação normal. Sua cobertura é de pelo menos $1 - \alpha$, mas, devido à natureza discreta da distribuição binomial, geralmente excede o nível nominal para alguns valores de p . Nesse sentido, é um procedimento exato e conservador (Casella; Berger, 2011, sec. 9.5.2; Clopper; Pearson, 1934; Rosner, 2011, pp. 186–188).

i Exemplo — comparação de intervalos para uma proporção

Considere $x = 12$ sucessos em $n = 50$ ensaios, de modo que $\hat{p} = 0,24$. Para 95% de confiança:

- Wald: $[0,122; 0,358]$;
- Wilson: $[0,143; 0,374]$;
- Clopper–Pearson: $[0,131; 0,382]$.

Os resultados ilustram que métodos diferentes podem ter centros, amplitudes e proprie-

dades de cobertura distintos.

Base metodológica: (Chihara; Hesterberg, 2022, sec. 7.4; Rasch; Schott, 2018, pp. 145–146; Rosner, 2011, pp. 186–188).

```
from statsmodels.stats.proportion import proportion_confint

x = 12
n = 50
alpha = 0.05

for metodo in ["normal", "wilson", "beta"]:
    li, ls = proportion_confint(
        x,
        n,
        alpha=alpha,
        method=metodo
    )
    print(
        f"{metodo:14s}: "
        f"({li:.3f}, {ls:.3f})"
    )
```

```
normal      : (0.122, 0.358)
wilson      : (0.143, 0.374)
beta        : (0.131, 0.382)
```

7.9 Intervalos unilaterais

Em algumas aplicações, a pergunta de interesse exige apenas um limite inferior ou superior para o parâmetro.

Um **limite inferior de confiança de nível pelo menos $1 - \alpha$** é uma estatística $L(\mathbf{X})$ tal que

$$P_{\theta}\{L(\mathbf{X}) \leq \theta\} \geq 1 - \alpha, \quad \theta \in \Theta.$$

Analogamente, um **limite superior de confiança de nível pelo menos $1 - \alpha$** é uma estatística $U(\mathbf{X})$ tal que

$$P_{\theta}\{\theta \leq U(\mathbf{X})\} \geq 1 - \alpha.$$

Para uma amostra de uma população normal com variância desconhecida, os intervalos unilaterais

$$\left[\bar{X} - t_{1-\alpha, n-1} \frac{S}{\sqrt{n}}, \infty \right)$$

e

$$\left(-\infty, \bar{X} + t_{1-\alpha, n-1} \frac{S}{\sqrt{n}} \right]$$

possuem cobertura exatamente igual a $1 - \alpha$ para μ .

A escolha entre um procedimento bilateral e unilateral deve decorrer da pergunta científica e ser feita antes da inspeção dos dados. Escolher a direção depois de observar a amostra altera as propriedades de cobertura do procedimento originalmente especificado (Chihara; Hesterberg, 2022, pp. 209–211).

7.10 Dualidade entre intervalos de confiança e testes de hipóteses

Considere, para cada valor $\theta_0 \in \Theta$, um teste de nível α para

$$H_0 : \theta = \theta_0.$$

Defina

$$C(\mathbf{X}) = \{\theta_0 \in \Theta : H_0 : \theta = \theta_0 \text{ não é rejeitada}\}.$$

Para o verdadeiro valor θ ,

$$\begin{aligned} P_\theta\{\theta \in C(\mathbf{X})\} &= P_\theta\{H_0 : \theta = \theta \text{ não é rejeitada}\} \\ &= 1 - P_\theta\{H_0 : \theta = \theta \text{ é rejeitada}\} \\ &\geq 1 - \alpha. \end{aligned}$$

Portanto, $C(\mathbf{X})$ é um conjunto de confiança de nível pelo menos $1 - \alpha$. Se a probabilidade de rejeição sob cada hipótese nula simples for exatamente α , a cobertura correspondente é exatamente $1 - \alpha$.

Essa construção é denominada **inversão de testes**.

No caso da média normal com variância conhecida, considere o procedimento bilateral que rejeita

$$H_0 : \mu = \mu_0$$

quando

$$\left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| > z_{1-\alpha/2}.$$

Os valores de μ_0 que não são rejeitados satisfazem

$$\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu_0 \leq \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}},$$

que é precisamente o intervalo de confiança obtido anteriormente (Rice, 2007, sec. 9.3).

! Consequência

Quando um teste e um conjunto de confiança são construídos pela inversão da **mesma família de procedimentos**, vale a equivalência

$$H_0 : \theta = \theta_0 \text{ é rejeitada ao nível } \alpha$$

se, e somente se,

$$\theta_0 \notin C(\mathbf{x}).$$

A teoria formal de testes, incluindo nível, tamanho, erros e poder, será desenvolvida na unidade seguinte. Aqui, a inversão é utilizada como princípio de construção de conjuntos de confiança.

7.11 Amplitude, precisão e tamanho amostral

Para um intervalo simétrico da forma

$$\hat{\theta} \pm c \widehat{\text{EP}}(\hat{\theta}),$$

a **margem de erro** é

$$M = c \widehat{\text{EP}}(\hat{\theta}),$$

e a amplitude total do intervalo é

$$2M = 2c \widehat{\text{EP}}(\hat{\theta}).$$

Nos procedimentos em que o erro-padrão apresenta a ordem usual $n^{-1/2}$, três relações ajudam a interpretar a precisão:

- aumentar o nível de confiança aumenta o valor crítico e, em geral, amplia o intervalo;
- maior variabilidade produz maior erro-padrão e intervalos mais amplos;
- mantendo as demais condições, aumentar o tamanho da amostra reduz o erro-padrão aproximadamente na ordem de $n^{-1/2}$.

Para a média com σ conhecida, se a margem de erro desejada é no máximo E , então

$$E \geq z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

implica

$$\boxed{n \geq \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2}.$$

O resultado deve ser arredondado para o inteiro imediatamente superior (Larsen; Marx, 2012, pp. 310–311).

Para uma proporção, a aproximação de Wald fornece a margem

$$E = z_{1-\alpha/2} \sqrt{\frac{p(1-p)}{n}}.$$

Assim, exigir uma margem de erro de no máximo E conduz a

$$n \geq \frac{z_{1-\alpha/2}^2 p(1-p)}{E^2}.$$

Como o valor de p é desconhecido no planejamento, pode-se utilizar uma estimativa preliminar obtida de informação anterior ou de um estudo-piloto. Na ausência dessa informação,

$$p = 0,5$$

maximiza

$$p(1 - p)$$

e fornece o maior tamanho amostral segundo esse critério (Ramachandran; Tsokos, 2021, sec. 5.5.2.1).

Alcance da fórmula

Esse cálculo é baseado na aproximação de Wald. Ele não garante que procedimentos como Wilson ou Clopper–Pearson produzam exatamente a mesma margem de erro para o tamanho amostral obtido.

Precisão não elimina viés

Sob um plano amostral e um modelo em que o erro-padrão diminui com o tamanho da amostra, aumentar n reduz a incerteza associada à variabilidade amostral. Isso não corrige amostragem não representativa, não resposta informativa, mensuração enviesada, dependência ignorada ou especificação inadequada do modelo. Um intervalo estreito pode, portanto, estar centrado em uma estimativa sistematicamente inadequada.

7.12 Cobertura por simulação

A interpretação frequentista pode ser visualizada repetindo-se o mesmo processo de amostragem e construção do intervalo.

Para a repetição b , defina o indicador

$$I_b = \mathbf{1}\{\mu \in C_b\},$$

em que C_b é o intervalo obtido naquela amostra. No exemplo abaixo, o procedimento possui cobertura

$$P(I_b = 1) = 0,95.$$

Após B repetições independentes, a **cobertura empírica** é

$$\hat{c}_B = \frac{1}{B} \sum_{b=1}^B I_b.$$

Por isso, $\hat{c}_B$ não precisa ser exatamente 0,95 em uma simulação finita. Pela Lei dos Grandes Números,

$$\hat{c}_B \xrightarrow{p} 0,95$$

quando o número de repetições aumenta.

Na figura a seguir são gerados 100 intervalos de 95% para a média de uma população normal com variância conhecida (Rice, 2007, p. 281).




Figura 7.2: Simulação de intervalos de 95% para uma média normal.

7.13 Métodos bootstrap

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F,$$

e um estimador

$$\hat{\theta} = s(X_1, \dots, X_n).$$

Quando a distribuição amostral de $\hat{\theta}$ é difícil de obter analiticamente, o **bootstrap não paramétrico** utiliza a distribuição empírica da amostra como aproximação de F . As amostras bootstrap são obtidas por reamostragem com reposição dos valores observados.

Entre os procedimentos para construção de intervalos estão:

- o intervalo percentil, cujos limites são quantis das estimativas bootstrap;
- o intervalo baseado no erro-padrão bootstrap;
- o intervalo bootstrap- t , baseado na distribuição bootstrap de uma estatística studentizada.

O intervalo percentil é simples, mas sua cobertura pode ser afetada por viés e assimetria da distribuição do estimador. Em problemas regulares, a studentização pode melhorar a aproximação, mas o bootstrap- t exige estimar o erro-padrão em cada reamostra e não é superior em todas as situações.

O procedimento de reamostragem individual descrito aqui pressupõe a estrutura i.i.d. Se as observações possuem dependência, o esquema de reamostragem deve preservar essa estrutura. Além disso, amostras muito pequenas podem representar mal características da população que determinam a distribuição do estimador (Chihara; Hesterberg, 2022, secs. 7.5.1–7.5.3).

i Algoritmo — intervalo percentil bootstrap

Para estimar θ por

$$\hat{\theta} = s(X_1, \dots, X_n),$$

o intervalo percentil bootstrap pode ser obtido da seguinte forma:

1. a partir da amostra observada $x_1, \dots, x_n$, obtenha uma amostra bootstrap

$$X_1^*, \dots, X_n^*$$

de tamanho n , sorteando com reposição entre os valores observados;

2. calcule a estimativa bootstrap

$$\hat{\theta}^* = s(X_1^*, \dots, X_n^*);$$

3. repita as etapas anteriores B vezes, obtendo

$$\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)};$$

4. utilize os quantis empíricos de ordens $\alpha/2$ e $1 - \alpha/2$ dessas B estimativas como limites do intervalo percentil.

i Exemplo — intervalo percentil bootstrap para a mediana

Considere novamente a amostra

12, 15, 14, 10, 13, 16, 14, 15.

Sua mediana amostral é

$$\hat{\theta} = 14.$$

O código abaixo obtém $B = 10\,000$ reamostras bootstrap e utiliza os quantis empíricos de ordens 0,025 e 0,975 das medianas bootstrap.

```
import numpy as np

rng = np.random.default_rng(2026)
x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
B = 10000
alpha = 0.05

medianas_boot = np.empty(B)
for b in range(B):
    xb = rng.choice(x, size=len(x), replace=True)
    medianas_boot[b] = np.median(xb)

li, ls = np.quantile(medianas_boot, [alpha / 2, 1 - alpha / 2])
print(f"IC percentil bootstrap para a mediana: ({li:.3f}, {ls:.3f})")
```

IC percentil bootstrap para a mediana: (12.000, 15.000)

7.14 Intervalo de confiança não é intervalo de predição

Um intervalo de confiança para μ quantifica a incerteza sobre a **média da população**. Um intervalo de predição tem outro alvo: uma **nova observação** da população.

Suponha

$$X_1, \dots, X_n, X_{n+1} \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com μ e σ^2 desconhecidos. Um intervalo de predição bilateral de nível $1 - \alpha$ para X_{n+1} é

$$\bar{X} \pm t_{1-\alpha/2, n-1} S \sqrt{1 + \frac{1}{n}}.$$

O termo

$$S \sqrt{1 + \frac{1}{n}}$$

incorpora a variabilidade de uma nova observação e a incerteza associada à estimação de μ . Por isso, o intervalo de predição é mais amplo que o intervalo de confiança para a média,

$$\bar{X} \pm t_{1-\alpha/2, n-1} \frac{S}{\sqrt{n}}.$$

Usar o intervalo de confiança da média como se fosse um intervalo para uma nova observação subestima a variabilidade preditiva (Ramachandran; Tsokos, 2021, sec. 5.10.11).

7.15 Roteiro para construção e apresentação

Ao apresentar um intervalo de confiança, recomenda-se informar:

1. o parâmetro e a população de interesse;
2. o estimador e o método de construção;
3. o nível de confiança;
4. as hipóteses do modelo e do plano amostral;
5. os limites numéricos e, quando pertinente, a margem de erro;
6. uma interpretação contextual;
7. limitações que afetem a validade ou a cobertura do procedimento, como pequena amostra, assimetria, dependência ou proximidade de fronteiras paramétricas.

💡 Modelo de redação

“O intervalo t bilateral de 95% para a média populacional foi [12,02; 15,23]. Esse procedimento pressupõe observações independentes e o modelo normal adotado para a população. O nível de 95% refere-se à cobertura do procedimento em repetições do processo amostral.”

7.16 Síntese dos principais procedimentos

Parâmetro	Hipóteses principais	Procedimento	Natureza
μ, σ conhecida	amostra normal	normal padrão	exato
μ, σ desconhecida	amostra normal	t de Student	exato
σ^2	amostra normal	qui-quadrado de caudas iguais	exato
taxa exponencial λ	amostra exponencial i.i.d.	pivô qui-quadrado	exato
proporção p	amostra binomial	Wilson	aproximado
proporção p	amostra binomial	Clopper–Pearson	exato e conservador
parâmetro regular θ	normalidade assintótica e EP consistente	Wald	assintótico
parâmetro $\theta = s(F)$	amostra i.i.d. e bootstrap não paramétrico aplicável	bootstrap	computacional e aproximado

7.17 Exercícios

i Exercício 1 — interpretação

Um pesquisador obteve o intervalo [18,4; 22,7] para uma média populacional com nível de confiança de 95%.

1. Explique por que a frase “há 95% de probabilidade de a média estar no intervalo” não é uma interpretação frequentista estrita.
2. Escreva uma interpretação adequada do procedimento.
3. Explique quais aspectos da conclusão dependem do modelo e do plano amostral.

Exercício baseado em: (Cox, 2006, pp. 66–69).

i Exercício 2 — média com variância conhecida

Uma amostra normal de tamanho $n = 36$ apresentou média $\bar{x} = 50$. Suponha $\sigma = 9$ conhecida.

1. Construa intervalos de 90%, 95% e 99% para μ .
2. Compare suas amplitudes.
3. Determine o tamanho amostral necessário para uma margem de erro máxima de 2 unidades em um intervalo de 95%.

Exercício baseado em: (Larsen; Marx, 2012, pp. 297–311).

i Exercício 3 — média com variância desconhecida

Considere uma amostra normal com $n = 25$, $\bar{x} = 4,2$ e $s^2 = 1,44$.

1. Construa um intervalo de 95% para μ .
2. Compare-o com o intervalo que seria obtido substituindo o quantil t por 1,96.
3. Explique por que o intervalo normal é mais estreito.

Exercício baseado em: (Lauritzen, 2023, ex. 6.5; Rice, 2007, pp. 279–280).

i Exercício 4 — variância normal

Uma amostra normal de tamanho $n = 20$ apresentou variância amostral $s^2 = 16$.

1. Construa um intervalo de 95% para σ^2 .
2. Obtenha o intervalo correspondente para σ .
3. Verifique que o intervalo para σ^2 não é simétrico em torno de s^2 .
4. Discuta a sensibilidade do procedimento à hipótese de normalidade.

Base metodológica: (Rice, 2007, pp. 280–281).

i Exercício 5 — quantidade pivotal exponencial

Sejam $X_1, \dots, X_n$ iid com distribuição exponencial de taxa λ .

1. Demonstre que $2\lambda \sum_i X_i$ é uma quantidade pivotal.
2. Derive um intervalo bilateral de nível $1 - \alpha$ para λ .
3. Transforme o intervalo para a média $\theta = 1/\lambda$.
4. Aplique o resultado à amostra 1,1, 0,8, 2,4, 0,6, 1,5 e 3,0.

Exercício baseado em: (Lauritzen, 2023, ex. 6.7).

i Exercício 6 — intervalo de Wald para Poisson

Considere as contagens 4, 6, 7, 9, 10 e 13, modeladas como iid $\text{Poisson}(\lambda)$.

1. Calcule $\hat{\lambda}$ e seu erro-padrão estimado.
2. Construa um intervalo de Wald de 95%.
3. Discuta se a aproximação normal parece razoável.
4. Explique por que a simples truncagem de um limite negativo em zero não garante cobertura nominal.

Exercício baseado em: (Rice, 2007, pp. 282–283).

i Exercício 7 — proporção binomial

Em $n = 40$ ensaios, foram observados $x = 4$ sucessos.

1. Calcule o intervalo de Wald de 95%.
2. Calcule os intervalos de Wilson e Clopper–Pearson com auxílio de software.
3. Compare os limites e as amplitudes.
4. Justifique qual método você reportaria e quais limitações registraria.

Base metodológica: (Chihara; Hesterberg, 2022, sec. 7.4; Rasch; Schott, 2018, pp. 145–146; Rosner, 2011, pp. 186–188).

i Exercício 8 — intervalo unilateral

Uma amostra normal de tamanho $n = 15$ apresentou $\bar{x} = 120$ e $s = 18$. Construa um limite superior de confiança de 99% para μ . Explique em que tipo de pergunta científica um limite unilateral seria mais apropriado que um intervalo bilateral.

Exercício baseado em: (Chihara; Hesterberg, 2022, pp. 209–211).

i Exercício 9 — dualidade

Considere o teste bilateral de $H_0 : \mu = \mu_0$ para uma amostra normal com variância conhecida.

1. Escreva a região de não rejeição a nível α .
2. Inverta a região para obter o conjunto dos valores de μ_0 não rejeitados.
3. Mostre que o conjunto coincide com o intervalo normal de nível $1 - \alpha$.

Exercício baseado em: (Rice, 2007, sec. 9.3).

i Exercício 10 — cobertura por simulação

Implemente uma simulação com 10 000 repetições para estimar a cobertura dos seguintes procedimentos:

1. intervalo t para a média quando os dados são normais;
2. intervalo t para a média quando os dados são exponenciais, para $n = 10, 30$ e 100 ;
3. intervalos de Wald e Wilson para uma proporção com $n = 20$ e $p \in \{0,05, 0,20, 0,50\}$.

Compare a cobertura estimada com o nível nominal de 95% e interprete os resultados.

Exercício baseado em: (Ramachandran; Tsokos, 2021, pp. 248–250).

7.18 Gabarito sucinto

1. No paradigma frequentista, o parâmetro é fixo e desconhecido. Antes da observação, o intervalo é aleatório porque depende da amostra; depois de observados os dados, o intervalo também fica determinado. O nível de confiança é uma propriedade de cobertura do procedimento.
2. Use $\bar{x} \pm z_{1-\alpha/2}\sigma/\sqrt{n}$; para a parte 3, arredonde para cima $n \geq (z_{0,975}9/2)^2$.
3. Use $t_{0,975;24}$ e $s = 1,2$. O intervalo que substitui o quantil t por 1,96 é mais estreito porque $1,96 < t_{0,975;24}$. Sob normalidade com σ desconhecida, a estatística studentizada possui distribuição t_{24} , e não normal padrão.
4. Use os quantis $\chi_{0,025;19}^2$ e $\chi_{0,975;19}^2$; obtenha o intervalo para σ tomando raízes quadradas.
5. Use $2\lambda \sum_i X_i \sim \chi_{2n}^2$ e inverta os limites para $\theta = 1/\lambda$.
6. $\hat{\lambda} = \bar{x}$ e $\widehat{\text{EP}} = \sqrt{\bar{x}/n}$.
7. Com $x = 4$ em $n = 40$, o intervalo de Wald merece cautela por haver poucos sucessos. Wilson tende a apresentar cobertura mais próxima do nível nominal sem o conservadorismo de Clopper–Pearson e é uma escolha justificável para reporte. Clopper–Pearson é apropriado quando se deseja a garantia de cobertura de pelo menos o nível nominal, ao custo de maior conservadorismo. A escolha deve ser acompanhada da identificação do procedimento utilizado.
8. Use $\bar{x} + t_{0,99;14}s/\sqrt{n}$ como limite superior.
9. A inversão produz $\bar{X} \pm z_{1-\alpha/2}\sigma/\sqrt{n}$.
10. Espera-se boa cobertura do intervalo t sob normalidade; assimetria e fronteiras podem degradar a cobertura de métodos aproximados, especialmente para amostras pequenas.

Referências

8 Testes de Hipóteses e Análise de Dados Categóricos

Os testes de hipóteses fornecem regras para avaliar a compatibilidade entre os dados e afirmações sobre um modelo estatístico. No paradigma frequentista, seu comportamento é avaliado sob repetições do processo amostral: o nível limita a probabilidade de rejeição incorreta sob a hipótese nula, enquanto a função poder descreve a probabilidade de rejeição ao longo dos diferentes valores do parâmetro. Este capítulo articula a formulação frequentista dos testes, os princípios de optimalidade de Neyman–Pearson, os testes da razão de verossimilhanças, os procedimentos usuais para parâmetros populacionais e a análise de contagens categóricas (Casella; Berger, 2002, cap. 8; Lauritzen, 2023, cap. 7; Rice, 2007, cap. 9).

8.1 Objetivos de aprendizagem

Ao final deste capítulo, o leitor deverá ser capaz de:

1. formular hipóteses estatísticas simples e compostas;
2. definir formalmente região crítica, função de teste, tamanho, nível, função poder e erros dos tipos I e II;
3. calcular e interpretar corretamente o valor- p ;
4. aplicar o lema de Neyman–Pearson na construção de testes mais poderosos;
5. caracterizar testes uniformemente mais poderosos em famílias com razão de verossimilhanças monótona;
6. construir e interpretar testes da razão de verossimilhanças;
7. selecionar testes para médias, proporções e comparações entre duas populações;
8. aplicar testes qui-quadrado de aderência, homogeneidade e independência;
9. reconhecer situações em que testes exatos, de permutação ou procedimentos robustos são preferíveis;
10. distinguir significância estatística, magnitude do efeito e relevância científica.

8.2 Motivação: uma moeda aparentemente honesta

Considere 100 lançamentos independentes de uma moeda. Seja X o número de caras observadas. Sob a hipótese de que a moeda é honesta,

$$H_0 : p = 0,5,$$

tem-se

$$X \sim \text{Binom}(100, 0,5).$$

Suponha que tenham sido observadas 99 caras.

i Interpretação unilateral

Quando a suspeita científica é especificamente de favorecimento de caras,

$$H_1 : p > 0,5,$$

o resultado observado é avaliado pela cauda superior:

$$P_{0,5}(X \geq 99) = \frac{101}{2^{100}} \approx 7,97 \times 10^{-29}.$$

i Interpretação bilateral

Quando a hipótese alternativa é apenas que a moeda não é honesta,

$$H_1 : p \neq 0,5,$$

devem ser considerados desvios nas duas direções. Pela simetria da distribuição binomial,

$$P_{0,5}(X \geq 99 \text{ ou } X \leq 1) = \frac{202}{2^{100}} \approx 1,59 \times 10^{-28}.$$

Em ambos os casos, o resultado é extremamente incompatível com o modelo de moeda honesta. A conclusão não decorre de uma “prova” de que H_0 seja falsa, mas da aplicação de uma regra inferencial cujo comportamento é avaliado sob repetições do experimento. Em particular, em um teste de nível α , a probabilidade de rejeitar H_0 quando ela é verdadeira é limitada superiormente por α (Casella; Berger, 2002, secs. 8.1 e 8.3.1; Cox, 2006, secs. 3.2 e 5.4; Lauritzen, 2023, secs. 7.1–7.4).

8.3 Formulação estatística do problema

Considere um modelo estatístico

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\},$$

em que θ é um parâmetro desconhecido. Um problema de teste de hipóteses divide o espaço paramétrico em dois subconjuntos disjuntos (Casella; Berger, 2002, sec. 8.1; Lauritzen, 2023, sec. 7.2):

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta_1,$$

com $\Theta_1 = \Theta \setminus \Theta_0$.

i Definição: hipóteses simples e compostas

Uma hipótese é **simples** quando determina completamente a distribuição dos dados. Por exemplo,

$$H_0 : p = 0,5$$

é simples no modelo binomial com n conhecido.

Uma hipótese é **composta** quando contém mais de uma distribuição possível. Por exemplo,

$$H_1 : p > 0,5$$

é composta, pois inclui todos os valores $p \in (0,5, 1]$.

A escolha de qual afirmação deve ocupar o papel de hipótese nula não é puramente algébrica. Ela depende do objetivo científico, das consequências das decisões e da estrutura do modelo. Em muitos estudos, H_0 representa ausência de efeito, um modelo mais restritivo ou uma afirmação cuja rejeição incorreta deve ser controlada (Casella; Berger, 2002, sec. 8.1; Rice, 2007, secs. 9.1–9.2.2).

8.3.1 Função de teste e região crítica

i Definição: função de teste

Uma função de teste é uma função mensurável

$$\varphi : \mathcal{X} \longrightarrow [0, 1].$$

Para uma amostra observada $X = x$:

- $\varphi(x) = 1$ significa rejeitar H_0 ;

- $\varphi(x) = 0$ significa não rejeitar H_0 ;
- $0 < \varphi(x) < 1$ representa um teste aleatorizado, no qual H_0 é rejeitada com probabilidade $\varphi(x)$.

Nos testes não aleatorizados, $\varphi(x) \in \{0, 1\}$ e a **região crítica** é

$$C = \{x \in \mathcal{X} : \varphi(x) = 1\}.$$

Testes aleatorizados aparecem naturalmente em modelos discretos quando não é possível obter exatamente um tamanho prescrito apenas com uma região crítica determinística. Em aplicações, costuma-se preferir testes não aleatorizados e reportar o tamanho efetivamente alcançado (Casella; Berger, 2002, secs. 8.2–8.3; Rasch; Schott, 2018, secs. 3.1–3.3).

8.3.2 Função poder, tamanho e nível

i Definição: função poder

A função poder de um teste φ é

$$\pi_{\varphi}(\theta) = E_{\theta}[\varphi(X)] = P_{\theta}(\text{rejeitar } H_0).$$

O comportamento desejável é:

- $\pi_{\varphi}(\theta)$ pequena para $\theta \in \Theta_0$;
- $\pi_{\varphi}(\theta)$ grande para $\theta \in \Theta_1$.

i Definição: tamanho e nível

O **tamanho** do teste é

$$\alpha_{\varphi} = \sup_{\theta \in \Theta_0} \pi_{\varphi}(\theta).$$

Dizemos que φ é um teste de **nível** α quando

$$\sup_{\theta \in \Theta_0} \pi_{\varphi}(\theta) \leq \alpha.$$

Quando a igualdade é satisfeita, o teste tem tamanho α .

Essa distinção é relevante em hipóteses nulas compostas: o nível α constitui um limite superior uniforme para a probabilidade de rejeição incorreta em todos os valores de θ permitidos por H_0 (Casella; Berger, 2002, sec. 8.3.1; Lauritzen, 2023, sec. 7.4).

8.3.3 Erros dos tipos I e II

Estado verdadeiro	Não rejeitar H_0	Rejeitar H_0
$\theta \in \Theta_0$	decisão correta	erro do tipo I
$\theta \in \Theta_1$	erro do tipo II	decisão correta

A probabilidade do erro do tipo I, em um ponto $\theta \in \Theta_0$, é

$$P_\theta(\text{rejeitar } H_0) = \pi_\varphi(\theta).$$

Para $\theta \in \Theta_1$, a probabilidade do erro do tipo II é

$$\beta_\varphi(\theta) = P_\theta(\text{não rejeitar } H_0) = 1 - \pi_\varphi(\theta).$$

Portanto, o poder no ponto $\theta \in \Theta_1$ é $1 - \beta_\varphi(\theta)$.

Observação

O valor β não é, em geral, uma constante única. Ele depende do valor verdadeiro do parâmetro sob a alternativa. Por isso, o planejamento amostral deve especificar uma diferença mínima ou um valor alternativo de interesse.

8.4 Valor- p

Considere uma estatística de teste $T = T(X)$ construída de modo que valores grandes sejam mais incompatíveis com H_0 . Para uma hipótese nula simples $H_0 : \theta = \theta_0$, o valor- p observado é

$$p(x) = P_{\theta_0}\{T(X) \geq T(x)\}.$$

Para uma hipótese nula composta, uma construção que garante validade uniforme é

$$p(x) = \sup_{\theta \in \Theta_0} P_\theta\{T(X) \geq T(x)\}.$$

Outras construções de valores- p são possíveis, especialmente quando existe uma estatística condicionante, um parâmetro de perturbação ou uma estrutura discreta. Em todos os casos, a propriedade essencial de validade é

$$P_{\theta}\{p(X) \leq u\} \leq u, \quad 0 \leq u \leq 1, \quad \theta \in \Theta_0.$$

Em testes bilaterais, a noção de resultado “tão ou mais extremo” deve ser determinada pela estatística bilateral escolhida, como $|Z|$, T^2 ou $-2 \log \Lambda$.

i Interpretação

O valor- p quantifica a incompatibilidade dos dados com H_0 segundo um procedimento de teste especificado. Valores pequenos indicam que a estatística observada se encontra em uma região rara da distribuição nula.

! O que o valor- p não representa

O valor- p não é:

- a probabilidade de H_0 ser verdadeira;
- a probabilidade de a decisão estar errada;
- uma medida da magnitude do efeito;
- uma garantia de relevância científica, clínica ou prática.

Sob uma hipótese nula simples, se a estatística de teste possui distribuição contínua e o valor- p é calculado pela cauda exata correspondente, então

$$p(X) \sim \text{Unif}(0, 1).$$

Consequentemente,

$$P_{\theta_0}\{p(X) \leq u\} = u, \quad 0 \leq u \leq 1.$$

Em problemas discretos ou sob hipóteses nulas compostas, um valor- p válido pode ser **superuniforme**:

$$P_{\theta}\{p(X) \leq u\} \leq u, \quad 0 \leq u \leq 1, \quad \theta \in \Theta_0.$$

Quando a desigualdade é estrita para alguns valores de u , a regra baseada nesses pontos de corte é conservadora. Essa propriedade conecta diretamente a validade do valor- p ao controle do nível do teste (Casella; Berger, 2011, sec. 8.3.4; Cox, 2006, sec. 3.2; Rice, 2007, sec. 9.2.1; Lauritzen, 2023, secs. 7.3 e 7.7).

8.4.1 Regra de decisão

Para um valor- p válido e qualquer $\theta \in \Theta_0$,

$$P_\theta\{p(X) \leq \alpha\} \leq \alpha.$$

Portanto, após fixar α antes de examinar os resultados, a regra

$$\begin{cases} p \leq \alpha & \implies \text{rejeitar } H_0, \\ p > \alpha & \implies \text{não rejeitar } H_0 \end{cases}$$

define um teste de nível α .

A forma “não rejeitar H_0 ” é preferível a “aceitar H_0 ”, pois um resultado não significativo pode decorrer de baixo poder, grande variabilidade ou tamanho amostral insuficiente. Em procedimentos discretos, a convenção de igualdade no ponto de corte deve ser compatível com a definição do valor- p e com a região crítica.

8.5 Procedimento recomendado

Um teste de hipóteses deve ser conduzido na seguinte ordem:

1. definir a população, o modelo e o parâmetro de interesse;
2. formular H_0 e H_1 antes de examinar os resultados;
3. escolher uma estatística cuja distribuição sob H_0 seja conhecida ou aproximável;
4. fixar o nível α e, no planejamento, o poder desejado;
5. verificar pressupostos e o delineamento amostral;
6. calcular a estatística, o valor- p e uma estimativa do efeito;
7. apresentar a conclusão no contexto científico;
8. reportar limitações, incerteza e sensibilidade a pressupostos.

8.6 Exemplo motivacional

Considere um programa educacional fictício. A média de referência é $\mu_0 = 662$, o desvio-padrão populacional é tratado como conhecido, $\sigma = 131$, e uma amostra aleatória de $n = 100$ participantes apresentou média $\bar{x} = 696$. Deseja-se testar

$$H_0 : \mu \leq 662 \quad \text{versus} \quad H_1 : \mu > 662.$$

A estatística é

$$Z = \frac{\bar{X} - 662}{131/\sqrt{100}}.$$

Para os dados observados,

$$z_{\text{obs}} = \frac{696 - 662}{13,1} \approx 2,595.$$

Para um valor qualquer $\mu \leq 662$,

$$Z = \frac{\bar{X} - 662}{131/\sqrt{100}} \sim N\left(\frac{\mu - 662}{131/\sqrt{100}}, 1\right).$$

A probabilidade

$$P_{\mu}\{Z \geq z_{\text{obs}}\}$$

é crescente em μ . Portanto, dentro de

$$H_0 : \mu \leq 662,$$

o supremo é atingido na fronteira $\mu = 662$. Assim,

$$\begin{aligned} p &= \sup_{\mu \leq 662} P_{\mu}\{Z \geq z_{\text{obs}}\} \\ &= P_{662}\{Z \geq 2,595\} \\ &\approx 0,0047. \end{aligned}$$

Ao nível de 5%, rejeita-se H_0 . Os dados fornecem evidência de que a média dos participantes excede 662 no modelo adotado.

 Limitação causal

Esse teste compara médias, mas não estabelece por si só que o programa causou o aumento. Uma conclusão causal exige delineamento adequado, como randomização, grupo de controle e controle de perdas e confundimento.

8.7 Aprofundamento

8.7.1 Lema de Neyman–Pearson

Quando H_0 e H_1 são simples, o lema de Neyman–Pearson fornece um critério ótimo para a construção da região crítica.

Considere

$$H_0 : \theta = \theta_0 \quad \text{versus} \quad H_1 : \theta = \theta_1,$$

com densidades ou funções de probabilidade $f_{\theta_0}(x)$ e $f_{\theta_1}(x)$.

i Definição: teste mais poderoso

Um teste φ^* de nível α é **mais poderoso** para θ_1 quando, para todo teste φ de nível no máximo α ,

$$E_{\theta_1}[\varphi^*(X)] \geq E_{\theta_1}[\varphi(X)].$$

💡 Teorema: lema de Neyman–Pearson

Considere o teste

$$H_0 : \theta = \theta_0 \quad \text{versus} \quad H_1 : \theta = \theta_1.$$

Entre todos os testes de nível α , um teste mais poderoso pode ser definido por

$$\varphi^*(x) = \begin{cases} 1, & \frac{f_{\theta_1}(x)}{f_{\theta_0}(x)} > k, \\ \gamma, & \frac{f_{\theta_1}(x)}{f_{\theta_0}(x)} = k, \\ 0, & \frac{f_{\theta_1}(x)}{f_{\theta_0}(x)} < k, \end{cases}$$

em que $k \geq 0$ e, quando necessária, a probabilidade de aleatorização $\gamma \in [0, 1]$ são escolhidas de modo que

$$E_{\theta_0}[\varphi^*(X)] = \alpha.$$

Equivalentemente, o teste rejeita H_0 quando

$$\frac{f_{\theta_0}(x)}{f_{\theta_1}(x)}$$

é suficientemente pequeno.

Em modelos discretos, pode não existir uma região crítica não aleatorizada com tamanho exatamente α . Nesse caso, a aleatorização na fronteira permite obter o tamanho prescrito; se a análise for restrita a testes não aleatorizados, utiliza-se uma região cuja probabilidade sob H_0 não exceda α (Casella; Berger, 2002, sec. 8.3.2; Hogg; Craig, 1978, cap. 7; Ramachandran; Tsokos, 2021, sec. 6.2; Rice, 2007, sec. 9.2).

8.7.1.1 Exemplo — média normal, alternativa simples

O exemplo aplica diretamente o lema de Neyman–Pearson ao modelo normal (Casella; Berger, 2002, sec. 8.3.2; Hogg; Craig, 1978, cap. 7; Rasch; Schott, 2018, sec. 3.2).

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida, considere

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu = \mu_1,$$

em que $\mu_1 > \mu_0$. A razão de verossimilhanças é uma função crescente de $\bar{X}$. Portanto, o teste mais poderoso rejeita H_0 para valores grandes de $\bar{X}$:

$$\bar{X} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}.$$

Equivalentemente,

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}.$$

O ponto de corte não depende do valor específico μ_1 , desde que $\mu_1 > \mu_0$. Portanto, o mesmo teste que é mais poderoso contra um valor particular $\mu_1 > \mu_0$ permanece mais poderoso para todos os valores dessa região da alternativa. Essa é a ideia que conduz aos testes uniformemente mais poderosos.

8.7.2 Testes uniformemente mais poderosos

i Definição: teste UMP

Um teste φ^* de nível α é **uniformemente mais poderoso** — UMP, de *uniformly most powerful* — para

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta_1$$

quando, para todo teste φ de nível no máximo α ,

$$E_\theta[\varphi^*(X)] \geq E_\theta[\varphi(X)] \quad \text{para todo } \theta \in \Theta_1.$$

A palavra “uniformemente” indica que o mesmo teste maximiza o poder simultaneamente em todos os pontos da hipótese alternativa. Assim,

mais poderoso $\implies$ optimalidade em uma alternativa especificada,

enquanto

UMP $\implies$ optimalidade simultânea em toda Θ_1 .

8.7.2.1 Razão de verossimilhanças monótona

i Definição

Seja $T = T(X)$ uma estatística real cuja densidade ou função de probabilidade, sob o parâmetro θ , é denotada por

$$g(t \mid \theta).$$

A família

$$\{g(t \mid \theta) : \theta \in \Theta \subseteq \mathbb{R}\}$$

possui **razão de verossimilhanças monótona** em T quando, para todo

$$\theta_2 > \theta_1,$$

a razão

$$\frac{g(t \mid \theta_2)}{g(t \mid \theta_1)}$$

é uma função não decrescente de t nos pontos em que a razão está definida.

Em famílias com essa propriedade, valores grandes de T favorecem sistematicamente valores maiores do parâmetro.

💡 Teorema: resultado de Karlin–Rubin

Suponha que $T = T(X)$ seja uma estatística suficiente para θ e que a família de distribuições de T ,

$$\{g(t \mid \theta) : \theta \in \Theta \subseteq \mathbb{R}\},$$

possua razão de verossimilhanças monótona não decrescente em t .
Então o teste

$$\varphi(x) = \begin{cases} 1, & T(x) > c, \\ \gamma, & T(x) = c, \\ 0, & T(x) < c, \end{cases}$$

em que c e γ são escolhidos de modo que

$$P_{\theta_0}\{T(X) > c\} + \gamma P_{\theta_0}\{T(X) = c\} = \alpha,$$

é UMP de nível α para

$$H_0 : \theta \leq \theta_0 \quad \text{versus} \quad H_1 : \theta > \theta_0.$$

A propriedade de razão de verossimilhanças monótona implica que a probabilidade de rejeição é não decrescente em θ . Portanto,

$$\sup_{\theta \leq \theta_0} \pi_{\varphi}(\theta) = \pi_{\varphi}(\theta_0) = \alpha.$$

A versão análoga com rejeição para valores pequenos de T aplica-se à alternativa à esquerda. Em modelos contínuos, se

$$P_{\theta_0}\{T = c\} = 0,$$

a aleatorização na fronteira não é necessária (Casella; Berger, 2002, sec. 8.3.2; Borovkov, 1998, cap. 3; Rasch; Schott, 2018, sec. 3.3.1).

8.7.2.2 Exemplos importantes

Média normal com variância conhecida

Para

$$X_i \sim N(\mu, \sigma^2),$$

com σ^2 conhecida, a família possui razão de verossimilhanças monótona em $T = \sum_i X_i$, ou equivalentemente em $\bar{X}$. Assim,

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}$$

é UMP para

$$H_0 : \mu \leq \mu_0 \quad \text{versus} \quad H_1 : \mu > \mu_0.$$

Proporção binomial

Se $X \sim \text{Binom}(n, p)$, a família possui razão de verossimilhanças monótona em X . Portanto, para

$$H_0 : p \leq p_0 \quad \text{versus} \quad H_1 : p > p_0,$$

o teste UMP rejeita para valores suficientemente grandes de X . O ponto de corte e, se admitida, a aleatorização na fronteira são escolhidos para controlar o nível em $p = p_0$.

Como X é discreta, um teste não aleatorizado pode não atingir exatamente o nível nominal α ; nesse caso, escolhe-se uma região crítica cuja probabilidade sob p_0 não exceda α .

Média de Poisson

Se $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$, a estatística

$$T = \sum_{i=1}^n X_i$$

possui razão de verossimilhanças monótona. Para

$$H_0 : \lambda \leq \lambda_0 \quad \text{versus} \quad H_1 : \lambda > \lambda_0,$$

o teste UMP rejeita para valores suficientemente grandes de T . Como T é discreta, a determinação do ponto de corte apresenta a mesma questão de calibração encontrada no caso binomial.

8.7.2.3 Por que geralmente não existe UMP bilateral?

No modelo normal com variância conhecida, o teste mais poderoso contra $\mu_1 > \mu_0$ rejeita para valores grandes de $\bar{X}$. Contra $\mu_1 < \mu_0$, o teste mais poderoso rejeita para valores pequenos de $\bar{X}$. Não existe, em geral, uma única região de nível α que seja simultaneamente mais poderosa em ambas as direções. Por isso, testes UMP são mais comuns em problemas unilaterais; problemas bilaterais frequentemente exigem restrições adicionais de optimalidade ou o teste da razão de verossimilhanças (Casella; Berger, 2002, secs. 8.3.2–8.3.3; Borovkov, 1998, cap. 3; Ramachandran; Tsokos, 2021, secs. 6.2–6.3; Rice, 2007, sec. 9.2.3).

i Observação: testes não viesados e UMPU

Um teste é **não viesado** quando sua função poder satisfaz

$$\pi_{\varphi}(\theta_1) \geq \pi_{\varphi}(\theta_0)$$

para todo

$$\theta_1 \in \Theta_1 \quad \text{e} \quad \theta_0 \in \Theta_0.$$

Assim, o teste é pelo menos tão propenso a rejeitar H_0 quando a alternativa é verdadeira quanto quando o parâmetro pertence à hipótese nula.

Para um teste de tamanho α , essa condição implica

$$\pi_{\varphi}(\theta) \geq \alpha, \quad \theta \in \Theta_1.$$

Restringindo a comparação à classe dos testes não viesados de nível α , pode existir um teste **uniformemente mais poderoso não viesado** (UMPU), mesmo quando não existe teste UMP na classe de todos os testes de nível α . O desenvolvimento completo dessa teoria exige condições adicionais e não deve ser confundido com uma propriedade geral dos testes da razão de verossimilhanças (Casella; Berger, 2002, secs. 8.3.2–8.3.3; Borovkov, 1998, cap. 3).

8.7.3 Teste da razão de verossimilhanças

O teste da razão de verossimilhanças — TRV — fornece um procedimento geral para hipóteses simples ou compostas. Diferentemente do lema de Neyman–Pearson, o TRV generalizado não é, em geral, ótimo em amostras finitas; sua importância decorre da aplicabilidade ampla e de propriedades assintóticas favoráveis. A estatística Λ é preservada por reparametrizações biunívocas do modelo (Casella; Berger, 2002, sec. 8.2.1; Hogg; Craig, 1978, sec. 7.4; Rice, 2007, sec. 9.4; Chihara; Hesterberg, 2022, sec. 8.6).

Considere

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta \setminus \Theta_0.$$

i Definição: razão de verossimilhanças generalizada

A estatística é

$$\Lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta; x)}{\sup_{\theta \in \Theta} L(\theta; x)}.$$

Como $\Theta_0 \subseteq \Theta$,

$$0 \leq \Lambda(x) \leq 1.$$

Valores pequenos de Λ indicam que o melhor ajuste permitido por H_0 é muito inferior ao melhor ajuste no modelo completo.

O TRV rejeita H_0 para valores pequenos de Λ , ou, equivalentemente, para valores grandes de

$$W = -2 \log \Lambda.$$

i Relação com Neyman–Pearson

No problema simples contra simples,

$$H_0 : \theta = \theta_0 \quad \text{versus} \quad H_1 : \theta = \theta_1,$$

a comparação de Λ com um ponto de corte é equivalente à comparação da razão

$$\frac{f_{\theta_1}(x)}{f_{\theta_0}(x)}$$

com um ponto de corte. Portanto, nesse caso, o TRV possui a mesma forma do teste mais poderoso fornecido pelo lema de Neyman–Pearson. Para hipóteses compostas, essa propriedade de optimalidade não é garantida (Casella; Berger, 2002, secs. 8.2.1 e 8.3.2; Hogg; Craig, 1978, sec. 7.4).

8.7.3.1 Resultado assintótico de Wilks

Sob condições de regularidade, suponha que o verdadeiro valor do parâmetro pertença ao interior do espaço paramétrico, que o modelo seja identificável e diferenciável e que Θ_0 seja

definido localmente por q restrições independentes e regulares. Então, sob H_0 ,

$$-2 \log \Lambda \xrightarrow{d} \chi_q^2.$$

No caso regular em que os espaços possuem dimensões bem definidas,

$$q = \dim(\Theta) - \dim(\Theta_0),$$

isto é, q corresponde ao número de restrições independentes impostas por H_0 (Casella; Berger, 2011, sec. 10.3.1; Rice, 2007, sec. 9.4).



Condições e limitações

Há duas fontes distintas de dificuldade na utilização do resultado de Wilks.

Falha das condições de regularidade. A distribuição limite pode não ser χ_q^2 quando, por exemplo:

- o verdadeiro parâmetro está na fronteira do espaço paramétrico;
- há parâmetros não identificáveis sob H_0 ;
- o suporte da distribuição depende do parâmetro;
- o modelo apresenta outras irregularidades que invalidam a expansão assintótica usual.

Qualidade da aproximação em amostras finitas. Mesmo em um modelo regular, a aproximação qui-quadrado pode ser inadequada quando a amostra é pequena ou quando a informação disponível é muito esparsa.

Nessas situações, conforme o problema, podem ser necessárias distribuições exatas, calibração por simulação de Monte Carlo ou *bootstrap* paramétrico.

8.7.3.2 Exemplo — média normal com variância conhecida

Neste caso, a estatística do TRV possui distribuição nula exata. A distribuição limite assintótica não é necessária para calibrar o teste (Casella; Berger, 2011, secs. 8.2.1 e 10.3.1; Rice, 2007, sec. 9.4; Hogg; Craig, 1978, sec. 7.4).

Considere

$$X_i \sim N(\mu, \sigma^2),$$

com σ^2 conhecida, e

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu \neq \mu_0.$$

No modelo completo, o estimador de máxima verossimilhança é $\hat{\mu} = \bar{X}$. Sob H_0 , o parâmetro é fixado em μ_0 . Após simplificação,

$$\Lambda = \exp \left\{ -\frac{n(\bar{X} - \mu_0)^2}{2\sigma^2} \right\},$$

portanto,

$$-2 \log \Lambda = \frac{n(\bar{X} - \mu_0)^2}{\sigma^2} = Z^2.$$

Como $Z \sim N(0, 1)$ sob H_0 ,

$$Z^2 \sim \chi_1^2.$$

Logo, o TRV é exatamente equivalente ao teste bilateral Z .

8.7.3.3 Exemplo — proporção binomial

A expressão abaixo é a estatística da razão de verossimilhanças, também denominada *deviance* binomial neste contexto (Casella; Berger, 2011, sec. 8.2.1; Rice, 2007, secs. 9.4–9.5; Ramachandran; Tsokos, 2021, sec. 6.3).

Se

$$X \sim \text{Binom}(n, p),$$

com $0 < p_0 < 1$, e deseja-se testar

$$H_0 : p = p_0 \quad \text{versus} \quad H_1 : p \neq p_0,$$

o estimador irrestrito é

$$\hat{p} = \frac{X}{n}.$$

A estatística do TRV é

$$-2 \log \Lambda = 2 \left[X \log \left(\frac{X}{np_0} \right) + (n - X) \log \left(\frac{n - X}{n(1 - p_0)} \right) \right],$$

com a convenção

$$0 \log 0 = 0.$$

Essa convenção permite utilizar a expressão também nos casos $X = 0$ e $X = n$.

Sob H_0 e nas condições regulares do resultado de Wilks,

$$-2 \log \Lambda \xrightarrow{d} \chi_1^2.$$

Assim, a comparação com a distribuição χ_1^2 fornece um teste assintótico. Para amostras pequenas ou quando a aproximação assintótica é inadequada, deve-se considerar o teste binomial exato desenvolvido adiante.

8.8 Testes usuais para parâmetros populacionais

8.8.1 Uma média com variância conhecida

Suponha

$$X_1, \dots, X_n \sim N(\mu, \sigma^2),$$

com σ^2 conhecida. Sob $H_0 : \mu = \mu_0$,

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Alternativa	Região crítica	Valor- p
$\mu > \mu_0$	$Z > z_{1-\alpha}$	$1 - \Phi(z_{\text{obs}})$
$\mu < \mu_0$	$Z < z_\alpha$	$\Phi(z_{\text{obs}})$
$\mu \neq \mu_0$	$ Z > z_{1-\alpha/2}$	$2\{1 - \Phi(z_{\text{obs}})\}$

Esses testes são exatos sob o modelo normal com variância conhecida (Chihara; Hesterberg, 2022, sec. 8.1; Larsen; Marx, 2012, cap. 6; Ramachandran; Tsokos, 2021, sec. 6.4.2).

8.8.2 Uma média com variância desconhecida

Se a população é normal e σ^2 é desconhecida,

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$$

sob H_0 . As regiões críticas seguem o mesmo padrão do teste Z , substituindo os quantis normais pelos quantis da distribuição t com $n - 1$ graus de liberdade (Lauritzen, 2023, sec. 7.6.2.2; Larsen; Marx, 2012, cap. 7).

Pressuposto

Sob uma população normal, a distribuição t_{n-1} da estatística é exata para qualquer $n \geq 2$.

Se a normalidade for retirada, mas $X_1, \dots, X_n$ forem i.i.d. com média μ e variância finita e positiva, a estatística studentizada

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}$$

converge em distribuição para $N(0, 1)$. Como os quantis da distribuição t_{n-1} convergem para os quantis normais, o teste t possui validade assintótica nessas condições.

Essa aproximação pode ser inadequada em amostras pequenas ou moderadas quando a distribuição apresenta forte assimetria, caudas pesadas ou valores extremos.

8.8.3 Uma proporção

Se

$$X \sim \text{Binom}(n, p),$$

e deseja-se testar

$$H_0 : p = p_0,$$

com $0 < p_0 < 1$, então

$$\hat{p} = \frac{X}{n}$$

e, sob H_0 ,

$$\text{Var}_{p_0}(\hat{p}) = \frac{p_0(1-p_0)}{n}.$$

Assim, a estatística normal de escore é

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}.$$

Sob H_0 ,

$$Z \xrightarrow{d} N(0, 1)$$

quando a aproximação normal à distribuição binomial é adequada.

Observe que o erro-padrão é calculado com p_0 , isto é, sob a hipótese nula. Essa estatística difere da estatística de Wald, que substituiria p_0 por $\hat{p}$ no denominador.

A aproximação normal pode apresentar desempenho inadequado quando a distribuição binomial sob H_0 é muito assimétrica ou quando as contagens esperadas de sucessos ou fracassos são pequenas. Regras baseadas apenas em np_0 e $n(1-p_0)$ são heurísticas, e não garantias da qualidade da aproximação. Nessas situações, deve-se considerar o teste binomial exato (Chihara; Hesterberg, 2022, sec. 8.1.2; Ramachandran; Tsokos, 2021, sec. 6.4.2).

8.8.3.1 Teste binomial exato

Para uma alternativa unilateral à direita,

$$p = P_{p_0}(X \geq x_{\text{obs}}).$$

Para uma alternativa unilateral à esquerda,

$$p = P_{p_0}(X \leq x_{\text{obs}}).$$

Em testes bilaterais discretos, há mais de uma convenção possível. Uma definição amplamente utilizada soma as probabilidades dos resultados cuja probabilidade sob H_0 é menor ou igual à probabilidade do resultado observado:

$$p = \sum_{k: P_{p_0}(X=k) \leq P_{p_0}(X=x_{\text{obs}})} P_{p_0}(X=k).$$

O método bilateral adotado deve ser explicitado, pois dobrar mecanicamente uma cauda nem sempre coincide com essa definição.

Como a distribuição binomial é discreta, os valores- p exatos não precisam possuir distribuição uniforme sob H_0 . A regra

$$p \leq \alpha$$

mantém o nível em no máximo α , mas pode ser conservadora para alguns valores de α (Chihara; Hesterberg, 2022, sec. 8.1; Rasch; Schott, 2018, cap. 3).

8.8.4 Duas médias independentes: teste de Welch

Considere duas amostras independentes, com médias $\bar{X}_1$ e $\bar{X}_2$, variâncias S_1^2 e S_2^2 e tamanhos n_1 e n_2 . Para testar

$$H_0 : \mu_1 - \mu_2 = \Delta_0,$$

a estatística de Welch é

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}.$$

Os graus de liberdade são aproximados por

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1 - 1} + \frac{(S_2^2/n_2)^2}{n_2 - 1}}.$$

Sob duas amostras independentes provenientes de populações normais, a distribuição t_ν utilizada pelo teste de Welch é uma aproximação de Satterthwaite, e não uma distribuição exata em geral.

Para amostras independentes suficientemente grandes, a diferença entre médias também admite fundamentação assintótica sob condições mais gerais, desde que as variâncias populacionais sejam finitas.

O procedimento de Welch não exige a hipótese

$$\sigma_1^2 = \sigma_2^2$$

e é uma escolha apropriada quando o modelo ou o conhecimento do problema não sustentam a hipótese de variância comum (Ramachandran; Tsokos, 2021, sec. 6.5.1.2; Chihara; Hesterberg, 2022, sec. 8.3).

8.8.5 Duas médias independentes com variância comum

Quando o modelo científico justifica

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

utiliza-se

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

e

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{S_p \sqrt{1/n_1 + 1/n_2}},$$

com $n_1 + n_2 - 2$ graus de liberdade. Essa distribuição é exata quando as duas populações são normais, independentes e possuem uma variância comum (Larsen; Marx, 2012, cap. 9; Ramachandran; Tsokos, 2021, sec. 6.5.1.1).

Observação

A decisão de agrupar variâncias não deve ser baseada apenas em um teste preliminar de igualdade de variâncias. Ela deve refletir o modelo e o delineamento do estudo.

8.8.6 Amostras pareadas

Considere n pares

$$(X_i, Y_i), \quad i = 1, \dots, n,$$

e defina a diferença dentro de cada par por

$$D_i = X_i - Y_i.$$

O parâmetro de interesse passa a ser a média populacional das diferenças,

$$\mu_D = E(D_i).$$

Para testar

$$H_0 : \mu_D = \Delta_0,$$

utiliza-se

$$T = \frac{\bar{D} - \Delta_0}{S_D / \sqrt{n}}.$$

Se as diferenças

$$D_1, \dots, D_n$$

forem independentes entre pares e normalmente distribuídas, então, sob H_0 ,

$$T \sim t_{n-1}.$$

Portanto, a condição de normalidade relevante para a validade exata do teste é a distribuição das **diferenças**, e não a normalidade marginal de X e Y separadamente.

Ignorar o pareamento também ignora a covariância entre as duas observações do mesmo par e, em geral, produz um erro-padrão inadequado. Quando a correlação intrapar é positiva, situação comum em delineamentos pareados, a análise pareada costuma proporcionar maior precisão (Chihara; Hesterberg, 2022, sec. 8.3; Larsen; Marx, 2012, cap. 9).

8.8.7 Duas proporções independentes

Considere amostras independentes com

$$X_j \sim \text{Binom}(n_j, p_j), \quad j = 1, 2,$$

e o teste

$$H_0 : p_1 = p_2.$$

Sob H_0 , existe uma única proporção comum,

$$p_1 = p_2 = p.$$

Sua estimativa combinada é

$$\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}.$$

Portanto, a estatística normal de escore para a diferença entre as proporções é

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}.$$

Sob H_0 e quando a aproximação normal é adequada,

$$Z \xrightarrow{d} N(0, 1).$$

A proporção combinada é utilizada especificamente porque a hipótese nula impõe uma proporção populacional comum aos dois grupos.

Para tabelas 2×2 com contagens pequenas ou estrutura esparsa, a aproximação normal pode ser inadequada, e o teste exato de Fisher constitui uma alternativa importante. O procedimento pressupõe independência entre os dois grupos (Chihara; Hesterberg, 2022, secs. 8.3 e 10.3.3; Rosner, 2011, cap. 10).

8.9 Testes exatos, de permutação e robustez

Um teste é denominado **exato** quando sua calibração utiliza a distribuição nula em amostras finitas, sem substituir essa distribuição por uma aproximação assintótica. Exemplos incluem o teste binomial exato e o teste exato de Fisher.

O termo “exato” refere-se ao uso da distribuição nula finita e não implica que a probabilidade de erro do tipo I seja exatamente igual a α . Em problemas discretos, pode não existir uma região crítica não aleatorizada com probabilidade exatamente α sob H_0 . Nesse caso, o procedimento pode ter tamanho inferior ao nível nominal e ser conservador.

8.9.1 Testes de permutação

Um teste de permutação constrói a distribuição nula aplicando aos dados transformações que são admissíveis sob H_0 .

Em uma comparação entre grupos independentes, a permutação dos rótulos é justificada quando, sob a hipótese nula, a distribuição conjunta dos dados é invariante a essas permutações. Essa propriedade pode decorrer, por exemplo, do mecanismo de randomização de um experimento ou da permutabilidade das observações sob uma hipótese de igualdade de distribuições. A ausência de normalidade, por si só, não justifica a permutação.

Em dados pareados, o esquema de permutação deve preservar os pares. Dependendo do delineamento e da hipótese nula, podem ser trocados os rótulos das condições dentro de cada par ou utilizados sinais das diferenças. A validade de cada procedimento depende da invariância correspondente sob H_0 (Chihara; Hesterberg, 2022, cap. 3 e sec. 9.5.1).

Se todas as permutações admissíveis forem enumeradas, a distribuição de permutação é obtida exatamente. Quando apenas uma amostra aleatória das permutações é utilizada, o valor- p resultante constitui uma aproximação de Monte Carlo à distribuição de permutação completa.

Hipótese testada

Um teste de permutação baseado na diferença de médias não se transforma automaticamente em um teste exato apenas para

$$H_0 : \mu_1 = \mu_2.$$

Sob permutabilidade decorrente da igualdade das distribuições, a hipótese nula é mais forte que a simples igualdade das médias. Em experimentos randomizados, a interpretação depende da hipótese definida pelo mecanismo de randomização. A hipótese efetivamente testada e o conjunto de permutações admissíveis devem ser especificados.

8.9.2 Robustez

A robustez de um procedimento refere-se à estabilidade de suas propriedades inferenciais diante de desvios das condições utilizadas em sua derivação.

Testes t baseados em médias podem apresentar comportamento satisfatório diante de desvios moderados de normalidade, especialmente quando não há forte assimetria, caudas muito pesadas ou observações extremas. Essa estabilidade, contudo, não é universal.

Problemas distintos exigem respostas distintas:

- para duas amostras independentes com variâncias diferentes, o teste de Welch evita a imposição de uma variância populacional comum;

- caudas pesadas e *outliers* podem comprometer procedimentos baseados em médias e variâncias amostrais, mesmo quando Welch é utilizado;
- nesses casos, procedimentos baseados em médias aparadas ou outros estimadores robustos de localização podem ser considerados;
- métodos de reamostragem também precisam respeitar o delineamento e a estrutura de dependência dos dados e não corrigem automaticamente violações do modelo.

Assim, “robusto” não significa “livre de pressupostos”; é necessário identificar a perturbação do modelo em relação à qual o procedimento mantém desempenho adequado (Wilcox, 2022, caps. 4–7).

8.10 Planejamento amostral e poder

8.10.1 Uma média com variância conhecida

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

com σ conhecida, e o teste unilateral

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu > \mu_0.$$

A região crítica de nível α é

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}.$$

Se o verdadeiro valor da média for $\mu_1 > \mu_0$, o poder é

$$\begin{aligned} \pi(\mu_1) &= P_{\mu_1} \left\{ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha} \right\} \\ &= 1 - \Phi \left[z_{1-\alpha} - \frac{\sqrt{n}(\mu_1 - \mu_0)}{\sigma} \right]. \end{aligned}$$

Para exigir

$$\pi(\mu_1) \geq 1 - \beta,$$

é suficiente e necessário que

$$n \geq \left[\frac{(z_{1-\alpha} + z_{1-\beta})\sigma}{\mu_1 - \mu_0} \right]^2.$$

Portanto, o menor tamanho amostral inteiro que satisfaz essa condição é

$$n = \left\lceil \left[\frac{(z_{1-\alpha} + z_{1-\beta})\sigma}{\mu_1 - \mu_0} \right]^2 \right\rceil.$$

Sob o modelo normal com variância conhecida, essa expressão decorre da função poder exata do teste unilateral; não se trata de uma aproximação assintótica (Casella; Berger, 2002, sec. 8.3.1; Ramachandran; Tsokos, 2021, sec. 6.1.1; Chihara; Hesterberg, 2022, sec. 8.4.2).

Para o teste bilateral, a função poder em um valor $\mu_1 > \mu_0$ é

$$\pi(\mu_1) = 1 - \Phi \left[z_{1-\alpha/2} - \frac{\sqrt{n}(\mu_1 - \mu_0)}{\sigma} \right] + \Phi \left[-z_{1-\alpha/2} - \frac{\sqrt{n}(\mu_1 - \mu_0)}{\sigma} \right].$$

Substituir $z_{1-\alpha}$ por $z_{1-\alpha/2}$ na expressão fechada do caso unilateral fornece um planejamento conservador, pois considera apenas a cauda na direção de μ_1 e desconsidera o poder adicional proveniente da cauda oposta. Quando se deseja o menor n para o teste bilateral, a função poder acima pode ser avaliada diretamente para valores inteiros de n .

8.10.2 Uma proporção

Considere inicialmente o teste unilateral

$$H_0 : p = p_0 \quad \text{versus} \quad H_1 : p > p_0,$$

e suponha que se deseje poder $1 - \beta$ quando

$$p = p_1 > p_0.$$

Utilizando a aproximação normal para a proporção amostral, obtém-se

$$n \approx \frac{\left[z_{1-\alpha} \sqrt{p_0(1-p_0)} + z_{1-\beta} \sqrt{p_1(1-p_1)} \right]^2}{(p_1 - p_0)^2}.$$

Para uma alternativa unilateral à esquerda, com $p_1 < p_0$, utiliza-se a mesma expressão com a diferença em módulo,

$$|p_1 - p_0|.$$

Para um teste bilateral,

$$H_0 : p = p_0 \quad \text{versus} \quad H_1 : p \neq p_0,$$

uma aproximação usual é substituir $z_{1-\alpha}$ por

$$z_{1-\alpha/2}.$$

Diferentemente do caso normal com variância conhecida, essas expressões dependem de aproximações normais à distribuição binomial. Depois de arredondar n para cima, é recomendável calcular o poder efetivo utilizando

$$X \sim \text{Binom}(n, p_1)$$

e a região crítica que será realmente adotada no teste. Essa verificação é especialmente importante quando p_0 ou p_1 está próximo de 0 ou 1 ou quando o tamanho amostral obtido é moderado (Chihara; Hesterberg, 2022, sec. 8.4.2; Ramachandran; Tsokos, 2021, sec. 6.1.1).

i Precisão e poder respondem a perguntas diferentes

Na estimação intervalar, o tamanho amostral foi relacionado à **precisão**, por exemplo por meio de uma margem de erro desejada.

No planejamento de um teste de hipóteses, a pergunta é diferente: escolhe-se n para obter determinado **poder** contra uma alternativa cientificamente relevante, mantendo especificado o controle do erro do tipo I.

Assim,

$$\text{U5: margem de erro} \quad \text{e} \quad \text{U6: poder}$$

correspondem a critérios distintos de dimensionamento amostral.

! Significância prática

O valor alternativo utilizado no planejamento deve representar uma diferença cientificamente relevante. Com amostras muito grandes, diferenças muito pequenas podem produzir valores- p pequenos, sem que isso implique relevância prática.

8.11 Análise de dados categóricos

Os procedimentos anteriores foram formulados principalmente em termos de médias, proporções ou parâmetros de distribuições específicas. Quando as observações são classificadas em categorias mutuamente exclusivas, os dados podem ser representados por **contagens**.

Se uma amostra de tamanho n é classificada em k categorias com probabilidades

$$p_1, \dots, p_k, \quad \sum_{i=1}^k p_i = 1,$$

então o vetor de contagens

$$(O_1, \dots, O_k)$$

pode ser modelado por uma distribuição multinomial.

Essa estrutura fornece a base para o teste de aderência. Em tabelas de contingência, o modelo probabilístico depende também do delineamento: uma única amostra classificada segundo duas variáveis categóricas pode ser representada por um modelo multinomial, enquanto a comparação de distribuições categóricas entre grupos independentes conduz naturalmente a um produto de distribuições multinomiais.

Apesar dessas diferenças de delineamento, os testes de Pearson resultantes possuem formas algébricas estreitamente relacionadas (Rice, 2007, sec. 9.5; Lauritzen, 2023, secs. 8.1 e 8.3; Chihara; Hesterberg, 2022, cap. 10; Larsen; Marx, 2012, cap. 10).

8.11.1 Estatística qui-quadrado de Pearson

Para contagens observadas $O_1, \dots, O_k$ e frequências esperadas positivas $E_1, \dots, E_k$ sob H_0 , a estatística de Pearson é

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

Cada termo mede a discrepância entre uma contagem observada e sua frequência esperada, em escala relativa à variabilidade esperada sob o modelo nulo. Valores grandes de X^2 fornecem evidência contra H_0 .

A comparação com uma distribuição qui-quadrado é, em geral, **assintótica**. Seus graus de liberdade dependem das restrições impostas pelo modelo nulo e de eventuais parâmetros estimados a partir dos dados.

8.11.2 Estatística da razão de verossimilhanças

A estatística correspondente ao teste da razão de verossimilhanças é

$$G^2 = 2 \sum_{i=1}^k O_i \log \left(\frac{O_i}{E_i} \right),$$

com a convenção de que o termo correspondente a $O_i = 0$ é igual a zero.

Sob condições de regularidade, X^2 e G^2 são estatísticas assintoticamente equivalentes para testar o mesmo modelo nulo e possuem a mesma distribuição qui-quadrado limite.

Isso não significa que seus valores observados devam ser numericamente próximos em qualquer amostra. Diferenças entre X^2 e G^2 podem ser relevantes em amostras pequenas ou em tabelas esparsas, justamente situações em que a aproximação assintótica também merece maior cautela (Rice, 2007, sec. 9.5; Lauritzen, 2023, secs. 8.1 e 8.3; Chihara; Hesterberg, 2022, sec. 10.6).

8.12 Teste qui-quadrado de aderência

Considere uma variável com k categorias e probabilidades especificadas por H_0 :

$$H_0 : (p_1, \dots, p_k) = (p_1^{(0)}, \dots, p_k^{(0)}).$$

As frequências esperadas são

$$E_i = np_i^{(0)}.$$

Quando as probabilidades

$$p_1^{(0)}, \dots, p_k^{(0)}$$

são completamente especificadas antes da observação dos dados, existe apenas a restrição

$$\sum_{i=1}^k O_i = n,$$

e os graus de liberdade são

$$\nu = k - 1.$$

Se as probabilidades esperadas pertencem a um modelo paramétrico com q parâmetros livres estimados a partir da própria amostra, então, sob condições regulares e com estimação compatível com o modelo utilizado no teste,

$$\nu = k - 1 - q.$$

Essa redução pressupõe que os parâmetros sejam identificáveis e que as q direções paramétricas correspondam a restrições localmente independentes. Assim, a simples presença de q quantidades calculadas a partir dos dados não é suficiente, por si só, para justificar a subtração de q graus de liberdade (Larsen; Marx, 2012, secs. 10.3–10.4; Chihara; Hesterberg, 2022, sec. 10.5).

8.12.1 Exemplo — dado de seis faces

Em 120 lançamentos de um dado, foram observadas as contagens

$$(14, 18, 20, 22, 21, 25).$$

Sob a hipótese de equilíbrio,

$$E_i = 120 \times \frac{1}{6} = 20.$$

Logo,

$$X^2 = \frac{(14 - 20)^2}{20} + \dots + \frac{(25 - 20)^2}{20} = 3,50.$$

Com $\nu = 5$, o valor- p é aproximadamente

$$p = 0,623.$$

Ao nível usual de 5%, não se rejeita a hipótese de probabilidades iguais. Esse resultado indica que as discrepâncias observadas são compatíveis com a variabilidade esperada sob o modelo de dado equilibrado; ele não demonstra que as seis probabilidades sejam exatamente iguais.

```
import numpy as np
from scipy.stats import chisquare

observado = np.array([14, 18, 20, 22, 21, 25])
esperado = np.repeat(20, 6)

estatistica, p_valor = chisquare(observado, f_exp=esperado)
print(f"X² = {estatistica:.3f}; valor-p = {p_valor:.4f}")
```

X² = 3.500; valor-p = 0.6234

8.13 Tabelas de contingência

Considere uma tabela com r linhas e c colunas. Seja O_{ij} a frequência observada na célula (i, j) , $O_{i.}$ o total da linha, $O_{.j}$ o total da coluna e n o total geral.

No **teste de independência**, uma única amostra é classificada segundo duas variáveis categóricas. Sob

H_0 : as duas variáveis são independentes,

a probabilidade conjunta fatoriza como

$$p_{ij} = p_{i.}p_{.j}.$$

Estimando as probabilidades marginais pelas proporções amostrais, obtém-se

$$E_{ij} = n \frac{O_{i.}}{n} \frac{O_{.j}}{n} = \frac{O_{i.}O_{.j}}{n}.$$

No **teste de homogeneidade**, existem amostras independentes provenientes de diferentes populações. Sob a hipótese de que todas possuem a mesma distribuição categórica, estima-se a probabilidade comum da coluna j por

$$\hat{p}_j = \frac{O_{.j}}{n}.$$

Assim, para uma amostra de tamanho $O_{i.}$,

$$E_{ij} = O_i \hat{p}_j = \frac{O_{i\cdot} O_{\cdot j}}{n}.$$

Portanto, os dois problemas conduzem à mesma fórmula de frequências esperadas e à mesma estatística de Pearson,

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Sob as condições assintóticas usuais,

$$X^2 \xrightarrow{d} \chi^2_{(r-1)(c-1)}$$

sob H_0 (Lauritzen, 2023, sec. 8.3; Chihara; Hesterberg, 2022, secs. 10.1–10.3; Larsen; Marx, 2012, sec. 10.5).

8.13.1 Homogeneidade e independência

Os dois testes utilizam a mesma estatística, mas respondem a perguntas distintas.

Teste	Delineamento	Hipótese nula
Homogeneidade	amostras independentes de diferentes populações	a distribuição categórica é a mesma nas populações
Independência	uma amostra, com duas variáveis categóricas medidas em cada unidade	as variáveis são independentes

A interpretação correta depende do esquema amostral; a tabela numérica, isoladamente, não determina o problema inferencial.

No teste de **homogeneidade**, a inferência compara distribuições categóricas entre populações ou grupos. No teste de **independência**, a inferência avalia a associação entre duas variáveis categóricas medidas nas mesmas unidades amostrais.

Portanto, uma mesma tabela de contagens pode produzir o mesmo valor de X^2 e o mesmo valor- p em ambos os enquadramentos, mas a população-alvo, o mecanismo amostral e a interpretação do resultado não são os mesmos.

i Conexão com o teste de duas proporções

Em uma tabela 2×2 formada por duas amostras binomiais independentes, o teste

$$H_0 : p_1 = p_2$$

pode ser formulado tanto como comparação de duas proporções quanto como teste qui-quadrado de homogeneidade.

Sem correção de continuidade, a estatística normal baseada na proporção combinada satisfaz

$$Z^2 = X^2,$$

em que X^2 é a estatística de Pearson da tabela 2×2 .

Como

$$Z \sim N(0, 1) \implies Z^2 \sim \chi_1^2,$$

os dois procedimentos fornecem o mesmo valor- p bilateral quando construídos dessa forma. Essa equivalência algébrica não elimina a necessidade de identificar corretamente o delineamento e a hipótese de interesse (Casella; Berger, 2002, ex. 8.59).

8.13.2 Exemplo — renda e hipertensão

Considere os dados hipotéticos:

Renda	Hipertensão: sim	Hipertensão: não	Total
Baixa	60	40	100
Média	45	55	100
Alta	20	80	100
Total	125	175	300

Sob independência, as frequências esperadas em cada linha são 41,67 e 58,33. A estatística é

$$X^2 = 33,60,$$

com $\nu = 2$ e

$$p \approx 5,06 \times 10^{-8}.$$

Rejeita-se a hipótese de independência. O resultado indica associação, mas não demonstra causalidade.

```
import numpy as np
from scipy.stats import chi2_contingency

observado = np.array([
    [60, 40],
    [45, 55],
    [20, 80]
])

x2, p_valor, gl, esperado = chi2_contingency(
    observado,
    correction=False
)

print(f"X² = {x2:.3f}; gl = {gl}; valor-p = {p_valor:.4g}")
print(esperado)
```

```
X² = 33.600; gl = 2; valor-p = 5.057e-08
[[41.66666667 58.33333333]
 [41.66666667 58.33333333]
 [41.66666667 58.33333333]]
```

8.14 Diagnóstico por resíduos

A rejeição do teste global indica discrepância em relação ao modelo nulo, mas não identifica quais células estão mais diretamente associadas a essa discrepância.

O **resíduo de Pearson** da célula (i, j) é

$$r_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}.$$

Ele preserva o sinal da diferença:

$$r_{ij} > 0 \implies O_{ij} > E_{ij},$$

enquanto

$$r_{ij} < 0 \implies O_{ij} < E_{ij}.$$

Em tabelas de contingência, a estimação das margens afeta a variabilidade desses resíduos. Uma padronização que incorpora esse efeito é o **resíduo ajustado**,

$$r_{ij}^{\text{aj}} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij} \left(1 - \frac{O_{i\cdot}}{n}\right) \left(1 - \frac{O_{\cdot j}}{n}\right)}}.$$

Sob o modelo nulo e em condições assintóticas adequadas, cada resíduo ajustado possui distribuição aproximadamente normal padrão. Assim, valores positivos ou negativos de grande magnitude ajudam a localizar células com discrepâncias relevantes.

Os resíduos de uma mesma tabela, entretanto, são dependentes. Além disso, quando muitas células são examinadas simultaneamente, interpretar cada uma isoladamente por comparação com quantis normais aumenta o problema de multiplicidade. A análise deve considerar o padrão conjunto dos resíduos e o contexto da aplicação (Lauritzen, 2023, sec. 8.1.3).

8.15 Condições e tabelas esparsas

A validade da análise envolve dois grupos de condições.

Condições do modelo e do delineamento:

1. as unidades amostrais devem possuir a estrutura de independência assumida pelo modelo;
2. as categorias utilizadas em uma mesma classificação devem ser mutuamente exclusivas;
3. o esquema amostral deve ser compatível com o modelo multinomial, produto de multinomiais ou outro modelo utilizado para as contagens.

Condições para a aproximação qui-quadrado:

as frequências esperadas precisam ser suficientemente informativas para que a distribuição finita da estatística seja bem aproximada pela distribuição qui-quadrado assintótica.

A regra pedagógica

$$E_{ij} \geq 5$$

é uma heurística, e não um teorema universal. A qualidade da aproximação depende do conjunto das frequências esperadas, do número de células e do grau de desequilíbrio da tabela.

Quando a aproximação assintótica é inadequada, podem ser considerados:

- agrupamento de categorias, desde que seja justificado pelo significado das categorias e compatível com a pergunta de interesse;
- teste exato de Fisher em tabelas 2×2 ;
- outros testes exatos condicionais;
- valores- p obtidos por simulação de Monte Carlo;
- modelos multinomiais ou log-lineares apropriados.

A adequação de critérios numéricos específicos para frequências esperadas deve ser avaliada considerando o número de células, o grau de desequilíbrio e a precisão desejada; a regra 5 não constitui garantia universal (Chihara; Hesterberg, 2022, cap. 10; Rosner, 2011, cap. 10).

i Correção de continuidade em tabelas 2×2

A estatística de Pearson utiliza uma distribuição qui-quadrado contínua para aproximar a distribuição de uma estatística construída a partir de contagens discretas. Em tabelas 2×2 , uma modificação clássica é a **correção de continuidade de Yates**,

$$X_{\text{Yates}}^2 = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(|O_{ij} - E_{ij}| - 0,5)^2}{E_{ij}},$$

quando as discrepâncias consideradas são maiores que 0,5.

A correção reduz a estatística de Pearson e tende a produzir valores- p maiores. Seu objetivo é melhorar a aproximação contínua em situações discretas, mas ela pode produzir um procedimento conservador. Portanto, não constitui substituto geral para procedimentos exatos quando a aproximação qui-quadrado é inadequada.

8.16 Teste exato de Fisher

Considere uma tabela 2×2 . Sob a hipótese nula de ausência de associação — equivalentemente, razão de chances populacional igual a 1 — e condicionando aos totais marginais, a contagem de uma das células possui distribuição hipergeométrica.

O teste exato de Fisher calcula as probabilidades das tabelas admissíveis diretamente dessa distribuição condicional. Portanto, sua calibração não depende da aproximação qui-quadrado e permanece disponível em tabelas com frequências pequenas.

O termo **exato** refere-se ao uso da distribuição condicional finita. Como essa distribuição é discreta, o tamanho de um teste não aleatorizado não precisa ser exatamente igual ao nível nominal.

Para alternativas bilaterais, existem diferentes critérios para ordenar as tabelas consideradas tão ou mais extremas que a observada. Por isso, a convenção utilizada pelo software deve ser

identificada quando essa diferença for relevante (Lauritzen, 2023, sec. 8.3.5; Chihara; Hesterberg, 2022, sec. 10.3.3; Rosner, 2011, sec. 10.3).

```
import numpy as np
from scipy.stats import fisher_exact

tabela = np.array([
    [8, 2],
    [1, 5]
])

razao_chances, p_valor = fisher_exact(
    tabela,
    alternative="two-sided"
)

print(f"Razão de chances = {razao_chances:.3f}")
print(f"Valor-p exato = {p_valor:.4f}")
```

```
Razão de chances = 20.000
Valor-p exato = 0.0350
```

8.17 Medidas de tamanho do efeito em tabelas

Para uma tabela 2×2 , a magnitude do coeficiente ϕ pode ser escrita como

$$|\phi| = \sqrt{\frac{X^2}{n}}.$$

O sinal de ϕ depende da codificação e da orientação das linhas e colunas; a expressão baseada em X^2 recupera apenas sua magnitude.

Para uma tabela $r \times c$, o V de Cramér é

$$V = \sqrt{\frac{X^2}{n \min(r-1, c-1)}}.$$

Em uma tabela 2×2 ,

$$\min(r-1, c-1) = 1,$$

de modo que

$$V = |\phi|.$$

O V de Cramér fornece uma medida não negativa da intensidade da associação. Ele não informa, por si só, quais categorias apresentam frequências acima ou abaixo do esperado nem o padrão que produz a associação.

No exemplo de renda e hipertensão,

$$V = \sqrt{\frac{33,60}{300}} \approx 0,335.$$

A interpretação de V deve considerar o contexto, o delineamento, as proporções observadas e o padrão dos resíduos. Pontos de corte universais para classificar automaticamente valores de V como “pequenos”, “médios” ou “grandes” não substituem essa análise contextual.

8.18 Poder e tamanho amostral em testes qui-quadrado

No teste de aderência com probabilidades nulas completamente especificadas,

$$H_0 : (p_1, \dots, p_k) = (p_1^{(0)}, \dots, p_k^{(0)}),$$

considere uma alternativa de planejamento

$$(p_1, \dots, p_k).$$

O tamanho do efeito de Pearson associado a essa alternativa é

$$w = \sqrt{\sum_{i=1}^k \frac{(p_i - p_i^{(0)})^2}{p_i^{(0)}}}.$$

Assim, w não é uma característica apenas de H_0 : seu valor depende da alternativa contra a qual se deseja obter determinado poder.

Na aproximação baseada na distribuição qui-quadrado não central, utiliza-se o parâmetro de não centralidade

$$\lambda = nw^2.$$

Para ν graus de liberdade e nível α , o poder aproximado é

$$1 - \beta \approx P\{\chi_{\nu}^2(\lambda) > \chi_{\nu, 1-\alpha}^2\}.$$

Consequentemente, o tamanho amostral pode ser obtido numericamente procurando o menor inteiro n para o qual o poder aproximado atinge o valor planejado.

Em tabelas de contingência, a medida correspondente deve ser construída a partir das probabilidades conjuntas especificadas sob a alternativa e das probabilidades que satisfazem o modelo nulo. A fórmula de aderência não deve ser reutilizada mecanicamente sem definir essas probabilidades.

i Aproximação de planejamento

A relação

$$\lambda = nw^2$$

é utilizada aqui como aproximação para planejamento de poder. Depois de obter n , convém verificar:

1. o poder sob o modelo probabilístico efetivamente utilizado;
2. as frequências esperadas previstas para esse tamanho amostral;
3. se a aproximação qui-quadrado é adequada no cenário planejado.

Fórmulas de planejamento que utilizam apenas w , sem considerar os graus de liberdade e a distribuição de referência, podem produzir resultados inadequados.

```
from math import ceil
from scipy.optimize import brentq
from scipy.stats import chi2, ncx2

alpha = 0.05
poder_alvo = 0.80
w = 0.30
gl = 2

critico = chi2.ppf(1 - alpha, df=gl)

def poder(n):
    nao_centralidade = n * w**2
    return ncx2.sf(critico, df=gl, nc=nao_centralidade)
```

```

raiz = brentq(lambda n: poder(n) - poder_alvo, 2, 100000)
n_minimo = ceil(raiz)

print(f"n mínimo aproximado = {n_minimo}")
print(f"poder recalculado = {poder(n_minimo):.4f}")

```

```

n mínimo aproximado = 108
poder recalculado = 0.8037

```

8.19 Relação entre testes e intervalos de confiança

Como desenvolvido em Seção 7.10, considere, para cada valor θ_0 , um teste de nível α para

$$H_0 : \theta = \theta_0.$$

O conjunto obtido pela inversão dessa mesma família de testes é

$$C(\mathbf{X}) = \{\theta_0 : H_0 : \theta = \theta_0 \text{ não é rejeitada}\}.$$

Como cada teste possui probabilidade de rejeição de no máximo α quando sua hipótese nula é verdadeira,

$$P_{\theta}\{\theta \in C(\mathbf{X})\} \geq 1 - \alpha.$$

Portanto, a inversão produz um conjunto de confiança de nível pelo menos $1 - \alpha$.

Para uma amostra observada $\mathbf{x}$, vale diretamente, pela construção,

$$H_0 : \theta = \theta_0 \text{ não é rejeitada}$$

se, e somente se,

$$\theta_0 \in C(\mathbf{x}).$$

Se a probabilidade de rejeição sob cada hipótese nula simples for exatamente α , a cobertura correspondente é exatamente $1 - \alpha$ (Rice, 2007, sec. 9.3; Chihara; Hesterberg, 2022, sec. 8.4.4).

i Interpretação

O conjunto de confiança complementa o valor- p ao mostrar quais valores do parâmetro permanecem compatíveis com o procedimento inferencial utilizado e ao informar a precisão da estimação. A equivalência entre rejeição e exclusão do conjunto exige que teste e conjunto de confiança sejam construídos pela **mesma família de procedimentos**.

8.20 Boas práticas de apresentação

Um relatório de teste deve incluir, conforme o problema:

- parâmetro ou comparação de interesse;
- hipóteses e direção do teste;
- nível α adotado quando houver uma regra de decisão previamente especificada;
- estatística de teste e distribuição de referência;
- graus de liberdade, quando aplicável;
- valor- p , com precisão adequada;
- estimativa pontual e intervalo de confiança correspondente;
- medida de tamanho do efeito, quando aplicável;
- avaliação das condições que sustentam o procedimento;
- interpretação contextual, sem linguagem causal incompatível com o delineamento.

8.20.1 Modelo de redação

A diferença média estimada foi de 4,2 unidades, com intervalo de confiança de 95% de [1,03; 7,37]. O teste de Welch forneceu $t = 2,68$, $\nu = 37,4$ e $p = 0,011$. Há evidência de diferença entre as médias no modelo adotado. A magnitude e a relevância prática devem ser avaliadas à luz da escala da variável e do delineamento do estudo.

8.21 Erros frequentes de interpretação

1. **Confundir valor- p** com $P(H_0 \mid \text{dados})$. O valor- p é calculado sob H_0 e não atribui probabilidade posterior à hipótese.
2. **Escolher unilateralidade após observar os dados**. A direção deve ser definida previamente.
3. **Concluir ausência de efeito a partir de $p \geq \alpha$** . Um teste não significativo pode ter baixo poder.
4. **Ignorar tamanho do efeito**. Significância estatística não implica relevância prática.

5. **Usar teste t pareado** como se as amostras fossem independentes. O pareamento deve ser incorporado pelas diferenças.
6. **Aplicar qui-quadrado em células extremamente esparsas sem diagnóstico.** Métodos exatos ou de simulação podem ser necessários.
7. **Interpretar associação como causalidade.** Testes de independência não eliminam confundimento nem estabelecem mecanismo causal.
8. **Realizar muitos testes sem controlar multiplicidade.** A probabilidade de ao menos uma rejeição falsa cresce com o número de comparações.

8.22 Quadro-síntese

Problema	Estatística principal	Referência sob H_0	Natureza/condições
uma média, σ conhecida	Z	$N(0, 1)$	exato sob normalidade
uma média, σ desconhecida	T	t_{n-1}	exato sob normalidade; validade assintótica sob condições mais gerais
duas médias independentes, variâncias não necessariamente iguais	T de Welch	t_ν aproximada	aproximação de Welch–Satterthwaite
duas médias independentes, variância comum	T agrupado	$t_{n_1+n_2-2}$	exato sob normalidade, independência e variância comum
médias pareadas	T nas diferenças	t_{n-1}	exato sob normalidade das diferenças e independência entre pares
uma proporção	Z de escore	$N(0, 1)$ assintótica	variância calculada sob H_0
uma proporção	binomial exato	distribuição binomial finita	pode ser conservador devido à discretização

Problema	Estatística principal	Referência sob H_0	Natureza/condições
duas proporções	Z com proporção combinada	$N(0, 1)$ assintótica	proporção combinada decorre de
aderência	X^2 ou G^2	χ^2_{k-1-q} assintótica	$H_0 : p_1 = p_2$ descontar parâmetros estimados quando aplicável
homogeneidade/independência	X^2 ou G^2	$\chi^2_{(r-1)(c-1)}$ assintótica	mesma álgebra, delineamentos distintos
tabela 2×2	Fisher exato	distribuição hipergeométrica condicional	não depende da aproximação qui-quadrado
hipótese paramétrica geral	$-2 \log \Lambda$	χ^2_q assintótica	resultado de Wilks sob regularidade

8.23 Exercícios

Os exercícios a seguir são autorais ou foram adaptados conceitualmente das fontes teóricas e aplicadas utilizadas no capítulo (Borovkov, 1998; Casella; Berger, 2002; Chihara; Hesterberg, 2022; Hogg; Craig, 1978; Lauritzen, 2023; Ramachandran; Tsokos, 2021; Rasch; Schott, 2018; Rice, 2007; Shao, 2005).

8.23.1 Exercícios conceituais

i Exercício 1

Explique por que um valor- p igual a 0,03 não significa que existe probabilidade de 3% de H_0 ser verdadeira.

i Exercício 2

Considere um teste de nível 0,05 cujo poder em θ_1 é 0,80. Determine as probabilidades dos erros dos tipos I e II quando o verdadeiro parâmetro é, respectivamente, um ponto de fronteira de H_0 em que o tamanho é alcançado e o ponto θ_1 .

i Exercício 3

Mostre que, se o valor- p de um teste contínuo é uniforme em $(0, 1)$ sob H_0 , então a regra “rejeitar quando $p \leq \alpha$ ” possui tamanho α .

8.23.2 Neyman–Pearson e testes UMP

i Exercício 4

Sejam $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, com σ^2 conhecida. Use o lema de Neyman–Pearson para obter o teste mais poderoso de nível α para

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu = \mu_1,$$

nos casos $\mu_1 > \mu_0$ e $\mu_1 < \mu_0$.

i Exercício 5

Sejam $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$. Mostre que a razão de verossimilhanças é monótona em $T = \sum_i X_i$ e construa um teste UMP de nível α para

$$H_0 : \lambda \leq \lambda_0 \quad \text{versus} \quad H_1 : \lambda > \lambda_0.$$

i Exercício 6

Considere $X \sim \text{Binom}(n, p)$. Determine a região crítica não aleatorizada UMP para

$$H_0 : p \leq p_0 \quad \text{versus} \quad H_1 : p > p_0,$$

e calcule o nível efetivamente alcançado. Discuta como um teste aleatorizado poderia atingir tamanho exatamente α .

i Exercício 7

No modelo normal com variância conhecida, explique formalmente por que o teste bilateral de $H_0 : \mu = \mu_0$ contra $H_1 : \mu \neq \mu_0$ não é, em geral, UMP.

8.23.3 Razão de verossimilhanças

i Exercício 8

Derive o TRV para

$$X_1, \dots, X_n \sim N(\mu, \sigma^2),$$

com σ^2 conhecida, e mostre que $-2 \log \Lambda = Z^2$.

i Exercício 9

Para $X \sim \text{Binom}(n, p)$, derive a expressão de $-2 \log \Lambda$ para testar $H_0 : p = p_0$. Compare numericamente o valor- p assintótico com o valor- p binomial exato para $n = 20$, $p_0 = 0,5$ e $x = 15$.

i Exercício 10

Explique por que o resultado de Wilks pode falhar quando o parâmetro sob H_0 está na fronteira do espaço paramétrico. Indique uma estratégia computacional para estimar a distribuição nula de $-2 \log \Lambda$.

8.23.4 Testes para médias e proporções

i Exercício 11

Uma amostra de 25 observações apresentou $\bar{x} = 52$ e $s = 8$. Teste $H_0 : \mu = 50$ contra $H_1 : \mu \neq 50$ ao nível de 5%, supondo normalidade. Calcule também o intervalo de confiança de 95%.

i Exercício 12

Duas amostras independentes produziram:

$$(n_1, \bar{x}_1, s_1) = (18, 14, 2, 3, 1),$$

$$(n_2, \bar{x}_2, s_2) = (22, 12, 5, 4, 0).$$

Aplique o teste de Welch para $H_0 : \mu_1 = \mu_2$ contra uma alternativa bilateral. Reporte estatística, graus de liberdade, valor- p e intervalo de confiança.

i Exercício 13

Em 40 pares antes-depois, a média das diferenças foi $-2,4$ e o desvio-padrão das diferenças foi $5,8$. Teste se a média da diferença é menor que zero e interprete o sinal adotado na definição de D_i .

i Exercício 14

Em 30 ensaios Bernoulli, foram observados 23 sucessos. Teste $H_0 : p = 0,5$ contra $H_1 : p > 0,5$ pelos métodos exato e normal. Compare os resultados e discuta a adequação da aproximação.

8.23.5 Dados categóricos

i Exercício 15

Uma variável categórica com quatro níveis apresentou contagens $(48, 31, 15, 6)$ em uma amostra de tamanho 100. Teste a aderência às probabilidades $(0,40, 0,30, 0,20, 0,10)$ usando X^2 e G^2 . Compare as estatísticas.

i Exercício 16

Considere a tabela:

Grupo	Sucesso	Fracasso
A	32	18
B	21	29
C	15	35

Teste a homogeneidade das proporções, calcule os resíduos ajustados e o V de Cramér. Identifique as células que mais contribuem para a rejeição.

i Exercício 17

Em uma tabela 2×2 com contagens $(8, 2; 1, 5)$, compare o teste qui-quadrado de Pearson, o teste com correção de continuidade e o teste exato de Fisher. Justifique qual resultado deve receber maior ênfase.

i Exercício 18

Para um teste qui-quadrado com $\nu = 3$, $\alpha = 0,05$, poder desejado de 0,90 e tamanho do efeito $w = 0,25$, determine numericamente o menor tamanho amostral usando a distribuição qui-quadrado não central.

8.23.6 Reamostragem e robustez

i Exercício 19

Em um experimento completamente randomizado, dois grupos independentes apresentam tamanhos $n_1 = 12$ e $n_2 = 15$. Descreva um teste de permutação para a diferença de médias, explicando qual hipótese nula é garantida pelo mecanismo de randomização e como calcular um valor- p Monte Carlo.

i Exercício 20

Construa um exemplo numérico em que o teste t com variâncias agrupadas e o teste de Welch produzam conclusões distintas. Investigue o papel do desbalanceamento amostral e da heteroscedasticidade.

Referências

9 Projetos Aplicados

9.1 Objetivo

O objetivo deste trabalho é aplicar os principais conceitos estudados na disciplina de Análise Inferencial em um problema real. Os estudantes deverão planejar uma pesquisa, definir um tamanho amostral adequado (usando as fórmulas dadas em sala de aula), coletar dados e realizar procedimentos de estimação (pontual e intervalar) e testes de hipóteses, apresentando e interpretando os resultados obtidos.

9.2 Descrição Geral

O trabalho deverá ser desenvolvido em grupos de até **3 integrantes**.

Cada grupo deverá escolher um tema de interesse e definir uma população-alvo para investigação. A variável de interesse poderá ser quantitativa ou qualitativa, desde que permita a aplicação dos métodos inferenciais estudados ao longo da disciplina.

9.2.1 Exemplos de Temas e Variáveis de Interesse

A seguir são apresentados alguns exemplos de temas e possíveis variáveis que podem ser investigadas. Os grupos não precisam se limitar às sugestões apresentadas.

1. Hábitos de Estudo dos Estudantes da UFC

Possíveis variáveis:

- Número de horas de estudo por semana;
- Número de disciplinas cursadas no semestre;
- Frequência às aulas (%);
- Tempo médio dedicado à resolução de exercícios;
- Número de reprovações acumuladas;
- Utilização de ferramentas de inteligência artificial para estudos (sim/não);
- Grau de satisfação com o próprio desempenho acadêmico (escala de 1 a 10);
- Coeficiente de rendimento acadêmico (IRA).

Exemplos de perguntas inferenciais:

- Qual é o número médio de horas de estudo dos estudantes?
- A média de horas de estudo é superior a 10 horas semanais?
- Mais de 50% dos estudantes utilizam ferramentas de inteligência artificial nos estudos?

2. Tempo de Deslocamento até a Universidade

Possíveis variáveis:

- Tempo diário de deslocamento (em minutos);
- Distância entre residência e universidade (em quilômetros);
- Número de meios de transporte utilizados;
- Gasto mensal com transporte;
- Frequência de atrasos devido ao deslocamento;
- Meio de transporte principal (ônibus, carro, bicicleta, moto, caminhada etc.).

Exemplos de perguntas inferenciais:

- Qual é o tempo médio de deslocamento dos estudantes?
- O tempo médio de deslocamento é superior a 40 minutos?
- Qual a proporção de estudantes que utilizam transporte público?

3. Consumo de Redes Sociais

Possíveis variáveis:

- Tempo diário gasto em redes sociais (horas);
- Número de redes sociais utilizadas regularmente;
- Rede social mais utilizada;
- Frequência de acesso às redes sociais;
- Tempo de uso durante atividades acadêmicas;
- Percepção sobre impacto das redes sociais no rendimento acadêmico.

Exemplos de perguntas inferenciais:

- Qual é o tempo médio diário de uso das redes sociais?
- Mais de 70% dos estudantes utilizam redes sociais por mais de 2 horas por dia?
- Existe evidência de que o tempo médio de uso seja superior a 3 horas diárias?

4. Prática de Atividades Físicas

Possíveis variáveis:

- Número de dias por semana em que pratica atividade física;
- Tempo semanal dedicado à atividade física;
- Tipo de atividade praticada;

- Frequência de participação em academias;
- Índice de Massa Corporal (IMC);
- Percepção do próprio condicionamento físico.

Exemplos de perguntas inferenciais:

- Qual é o tempo médio semanal dedicado à atividade física?
- Menos da metade dos estudantes pratica atividade física regularmente?
- Qual a proporção de estudantes que realizam exercícios pelo menos três vezes por semana?

5. Hábitos Alimentares

Possíveis variáveis:

- Número de refeições diárias;
- Consumo semanal de frutas;
- Consumo semanal de refrigerantes;
- Frequência de refeições no Restaurante Universitário; Gasto mensal com alimentação;
- Consumo diário de água (litros).

Exemplos de perguntas inferenciais:

- Qual é o consumo médio diário de água?
- Qual a proporção de estudantes que consomem frutas diariamente?
- O número médio de refeições por dia é igual a três?

6. Outros Temas

Os grupos poderão propor outros temas relacionados à realidade universitária ou a problemas de interesse social, desde que a proposta permita a aplicação dos métodos de inferência estatística estudados na disciplina.

Exemplos:

- Qualidade do sono;
- Uso de aplicativos de transporte;
- Educação financeira;
- Hábitos de leitura;
- Uso de plataformas de streaming;
- Saúde mental e bem-estar;
- Sustentabilidade e reciclagem;
- Consumo de café ou bebidas energéticas.

A escolha final deverá ser aprovada.

9.2.2 Etapas do Trabalho

9.2.2.1 Definição do Problema

O grupo deverá apresentar:

1. Tema escolhido;
2. Justificativa da pesquisa;
3. Objetivos do estudo;
4. População de interesse;
5. Variável ou variáveis analisadas.

9.2.2.2 Planejamento Amostral

O grupo deverá definir:

1. Nível de confiança adotado;
2. Margem de erro desejada;
3. Método de amostragem utilizado;
4. Justificativa dos parâmetros empregados no cálculo.

Em seguida, deverá ser realizado o cálculo do tamanho amostral adequado ao estudo. Quando necessário, valores preliminares poderão ser obtidos por meio de:

- Estudos anteriores;
- Literatura especializada;
- Estudo piloto

9.2.2.3 Coleta de Dados

O grupo deverá coletar uma amostra com tamanho igual ou superior ao valor calculado na etapa anterior. Devem ser descritos:

1. Procedimento de coleta;
2. Instrumento utilizado (questionário/formulário, medição etc.);
3. Período de coleta;
4. Possíveis limitações do processo.

9.2.2.4 Análise Descritiva dos Dados

Apresentar:

1. Tabelas de frequências (quando apropriado);
2. Gráficos adequados ao tipo de variável;
3. Medidas descritivas relevantes;
4. Comentários sobre os resultados observados.

9.2.2.5 Estimação Pontual

Identificar o parâmetro populacional de interesse e calcular sua estimativa pontual. Exemplos:

- Média populacional;
- Proporção populacional;
- Variância populacional.

O grupo deverá interpretar o significado da estimativa obtida no contexto do estudo.

9.2.2.6 Estimação Intervalar

Construir um intervalo de confiança para o parâmetro de interesse. A apresentação deverá conter:

- Nível de confiança utilizado;
- Fórmula empregada;
- Cálculos realizados;
- Interpretação do intervalo obtido.

9.2.2.7 Teste de Hipóteses

Formular um problema de decisão estatística relacionado ao estudo realizado. O relatório deverá conter:

- Hipótese nula (H_0);
- Hipótese alternativa (H_1);
- Nível de significância;
- Estatística de teste;
- p -valor (nível descritivo);
- Decisão final;
- Interpretação prática dos resultados.

9.2.2.8 Verificação das Condições de Aplicação

Os estudantes deverão discutir as condições necessárias para aplicação dos métodos utilizados. Quando pertinente, comentar aspectos como:

- Independência das observações;
- Normalidade;
- Tamanho amostral;
- Aproximações assintóticas;
- Possíveis fontes de viés.

9.2.2.9 Conclusões

Apresentar uma síntese dos principais resultados obtidos e responder aos objetivos definidos inicialmente. Também deverão ser discutidas possíveis limitações do estudo e sugestões para trabalhos futuros.

9.2.2.10 Estrutura do Relatório

O relatório final deverá conter:

- Introdução;
- Metodologia;
- Resultados;
- Discussão;
- Conclusões;
- Referências.

9.2.2.11 Entrega

A entrega deverá ser realizada em formato PDF por meio do SIGAA. Além do relatório, deverá ser entregue:

- Base de dados utilizada;
- Código utilizado nas análises (R, Python ou outro software estatístico).

9.2.3 Critérios de Avaliação

Critério	Pontuação
Definição do problema e planejamento amostral	2,0
Coleta e organização dos dados	1,0
Análise descritiva	1,5
Estimação pontual e intervalar	2,0
Teste de hipóteses	2,0
Qualidade do relatório e interpretação dos resultados	1,5
Total	10,0

9.2.4 Observações

- A simples apresentação de resultados computacionais não será suficiente para obtenção da pontuação máxima.
- As interpretações devem ser realizadas no contexto do problema estudado.
- Dúvidas poderão ser discutidas durante as aulas ou nos horários de atendimento ([Agendar Atendimento](#)).

10 Exemplos Aplicados

10.0.1 Exemplo Aplicado

Nesta seção, com o conjunto de dados dos estudantes disponível em [SOGA-Py](#). Você pode carregá-lo diretamente como um recurso da *web*. Vamos importar o conjunto de dados para o Python como um objeto **DataFrame** do pandas utilizando o método `read_csv`:

```
import pandas as pd
import numpy as np

estudantes = pd.read_csv("dados/students.csv")

estudantes.head()
```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
1	833917	Gonzales, Christina	Female	19	160	64.8	Muslim	1.91	1st	Political
2	898539	Lozano, T'Hani	Female	19	172	73.0	Other	1.56	2nd	Social S
3	379678	Williams, Hanh	Female	22	168	70.6	Protestant	1.24	3rd	Social S
4	807564	Nem, Denzel	Male	19	183	79.7	Other	1.37	2nd	Environ
5	383291	Powell, Heather	Female	21	175	71.4	Catholic	1.46	1st	Environ

O conjunto de dados **estudantes** consiste em 8.239 linhas, cada uma representando um estudante específico, e 16 colunas, cada uma correspondendo a uma variável/característica relacionada a esse estudante. Neste estudo, considera-se o conjunto completo de estudantes disponível na base de dados como a população de interesse. Além disso, a variável de interesse é o peso (massa corporal).

Aqui iremos considerar a variância conhecida, ou seja, iremos calcular diretamente a partir dos dados completos.

10.0.2 Variância e desvio-padrão populacionais

Como a base contém todos os 8.239 estudantes considerados neste estudo, a variância calculada corresponde à variância populacional.

```

N = len(estudantes)
sigma2 = estudantes["weight"].var(ddof=0) # variância populacional
sigma = estudantes["weight"].std(ddof=0) # desvio-padrão populacional

print(f"Tamanho da população: {N}")
print(f"Variância populacional: {sigma2:.2f}")
print(f"Desvio-padrão populacional: {sigma:.2f} kg")

```

Tamanho da população: 8239
 Variância populacional: 74.56
 Desvio-padrão populacional: 8.63 kg

10.0.3 Objetivo

Avaliar se a massa corporal média dos estudantes difere da massa corporal média da população adulta europeia, reportada por [Walpole et al. \(2012\)](#) como 70,8 kg. As hipóteses são:

$$H_0 : \mu = 70,8$$

e

$$H_A : \mu \neq 70,8$$

em que μ representa a massa corporal média dos estudantes.

10.0.4 Cálculo do tamanho mínimo de amostra

Foi adotada uma diferença mínima detectável de 2 kg em relação à média de referência de 70,8 kg. O tamanho amostral foi calculado para garantir poder estatístico de 80% e nível de significância de 5%, ou seja,

1. nível de confiança = 95%;
2. poder do teste = 80%;
3. diferença mínima detectável = 2 kg.

```

from scipy.stats import norm

alpha = 0.05
power = 0.80
delta = 2.0

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = ((z_alpha + z_beta) * sigma / delta)**2

print(f"Tamanho inicial da amostra: {np.ceil(n0):.0f}")

```

Tamanho inicial da amostra: 147

Como a população possui apenas 8.239 indivíduos, aplicaremos uma correção para população finita:

```

n = (n0 * N)/(n0 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho corrigido da amostra: {n}")

```

Tamanho corrigido da amostra: 144

10.0.5 Seleção da amostra aleatória

```

amostra = estudantes.sample(n=n, replace=False, random_state=123 )

amostra.head()

```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
3165	802420	Stravia, Kelly	Female	23	158	67.2	Catholic	3.85	1st	Political S
7715	307406	Ha, Edmond	Male	21	185	80.5	Catholic	2.21	5th	Social Sci
614	786879	Benson, Joseph	Male	22	174	75.2	Catholic	1.05	5th	Environm
1458	807680	Johnson, Xin	Male	24	187	83.4	Orthodox	1.64	3rd	Mathemat
4657	142413	Ward, Sendy	Female	23	155	61.6	Muslim	2.07	1st	Social Sci

10.0.6 Teste Z para uma média com variância conhecida

```
mu0 = 70.8

xbar = amostra["weight"].mean()

z = (xbar - mu0)/(sigma/np.sqrt(n))

print(f"Média amostral: {xbar:.2f}")
print(f"Estatística Z: {z:.4f}")
```

Média amostral: 72.84
Estatística Z: 2.8413

10.0.7 Cálculo do p-valor

```
from scipy.stats import norm

p_value = 2 * (1 - norm.cdf(abs(z)))

print(f"Valor-p: {p_value:.6f}")
```

Valor-p: 0.004493

10.0.8 Regra de Decisão

```
alpha = 0.05

if p_value < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

10.0.9 Intervalo de confiança de 95%

```
z_crit = norm.ppf(0.975)

erro = z_crit * sigma/np.sqrt(n)

li = xbar - erro
ls = xbar + erro

print(f"IC95%: ({li:.2f}, {ls:.2f})")
```

IC95%: (71.43, 74.25)

10.0.10 Conclusão

Como o p -valor calculado (0,004493) é consideravelmente inferior ao nível de significância adotado (0,05), a decisão estatística é rejeitar a hipótese nula, ou seja, de que a massa corporal média dos estudantes é igual a massa corporal média da população adulta europeia. Sendo assim, existe evidência estatisticamente significativa de que a média populacional é diferente do valor inicialmente suposto.

Note que a média populacional é:

```
mu_pop = estudantes["weight"].mean()

print(f"Média populacional: {mu_pop:.2f} kg")
```

Média populacional: 73.00 kg

10.1 Exemplo Aplicado

Agora iremos considerar a situação mais realista que é quando a variância populacional é desconhecida. Para calcular o tamanho mínimo de amostra iremos precisar estimar a variância populacional. Para isto, iremos usar uma amostra piloto.

10.1.1 Amostra piloto

```

amostra_piloto = estudantes.sample(n=50, replace=False, random_state=123 )

n_piloto = len(amostra_piloto)
s2 = amostra_piloto["weight"].var(ddof=1) # variância amostral
s = amostra_piloto["weight"].std(ddof=1) # desvio-padrão amostral

print(f"Tamanho da amostra piloto: {n_piloto}")
print(f"Variância amostral: {s2:.2f}")
print(f"Desvio-padrão amostral: {s:.2f} kg")

amostra_piloto.head()

```

Tamanho da amostra piloto: 50
 Variância amostral: 67.82
 Desvio-padrão amostral: 8.24 kg

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
3165	802420	Stravia, Kelly	Female	23	158	67.2	Catholic	3.85	1st	Political S
7715	307406	Ha, Edmond	Male	21	185	80.5	Catholic	2.21	5th	Social Sci
614	786879	Benson, Joseph	Male	22	174	75.2	Catholic	1.05	5th	Environm
1458	807680	Johnson, Xin	Male	24	187	83.4	Orthodox	1.64	3rd	Mathemat
4657	142413	Ward, Sendy	Female	23	155	61.6	Muslim	2.07	1st	Social Sci

10.1.2 Cálculo do tamanho mínimo de amostra

```

from scipy.stats import t

alpha = 0.05
power = 0.80
delta = 2.0

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)

n0 = ((z_alpha + z_beta) * s/delta)**2

print(f"Tamanho inicial da amostra (usando quantil da normal padrão): {np.ceil(n0):.0f}")

```

```
t_alpha = t.ppf(1 - alpha/2, df = n0-1)
t_beta = t.ppf(power, df = n0-1)
n1 = ((t_alpha + t_beta) * s/delta)**2

print(f"Tamanho inicial da amostra (usando quantil da t-student): {np.ceil(n1):.0f}")
```

Tamanho inicial da amostra (usando quantil da normal padrão): 134
Tamanho inicial da amostra (usando quantil da t-student): 136

Como a população possui apenas 8.239 indivíduos, aplicaremos uma correção para população finita:

```
n = (n1 * N)/(n1 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho corrigido da amostra: {n}")
```

Tamanho corrigido da amostra: 133

10.1.3 Seleção da amostra aleatória

Iremos considerar os estudantes coletados na amostra piloto na amostra final considerada para o estudo. Assim, iremos selecionar mais 81 estudantes. Como a semente aleatória é a mesma da amostra piloto, basta selecionar normalmente os 131 estudantes.

```
amostra = estudantes.sample(n=n, replace=False, random_state=123 )

amostra.head()
```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
3165	802420	Stravia, Kelly	Female	23	158	67.2	Catholic	3.85	1st	Political S
7715	307406	Ha, Edmond	Male	21	185	80.5	Catholic	2.21	5th	Social Sci
614	786879	Benson, Joseph	Male	22	174	75.2	Catholic	1.05	5th	Environm
1458	807680	Johnson, Xin	Male	24	187	83.4	Orthodox	1.64	3rd	Mathemat
4657	142413	Ward, Sendy	Female	23	155	61.6	Muslim	2.07	1st	Social Sci

10.1.4 Verificando normalidade dos dados

Agora, vamos testar a suposição de normalidade plotando um gráfico de probabilidade normal, frequentemente chamado de QQ plot. Se a variável tiver distribuição normal, o gráfico de probabilidade normal deverá ser aproximadamente linear.


```
import matplotlib.pyplot as plt
import scipy.stats as stats

fig, ax = plt.subplots()

stats.probplot(amostra["weight"], dist="norm", plot=ax)


ax.set_title("Q-Q plot (amostra)")
ax.set_ylabel("Quantis amostrais")
ax.set_xlabel("Quantis teóricos")

plt.show()
```



Observamos que os dados da amostra apresentam algum ruído, os desvios da linha reta na parte inferior sugerem que a distribuição dos dados é ligeiramente assimétrica, como pode ser visto no histograma abaixo.

```
plt.hist(amostra["weight"], bins=20)
plt.title("Histograma da variável weight")
plt.xlabel("Weight")
plt.ylabel("Frequência")
plt.show()
```



Podemos usar algum teste de hipótese para teste a normalidade dos dados. As hipóteses do teste são:

- Hipótese Nula: Os dados vem de uma distribuição normal.
- Hipótese Alternativa: Os dados observados não vêm da distribuição normal.

```
from statsmodels.stats.diagnostic import lilliefors
lilliefors(amostra["weight"], dist='norm')
```

```
(np.float64(0.0914358012704492), np.float64(0.014990422036609632))
```

```
from scipy.stats import anderson
anderson(amostra["weight"], dist='norm')
```

```
C:\Users\Rafael Farias\AppData\Local\Temp\ipykernel_13252\1331499744.py:3: FutureWarning: As
    anderson(amostra["weight"], dist='norm')
```

```
AndersonResult(statistic=np.float64(1.25076662006623), critical_values=array([0.558, 0.627, 0.675]),
    success: True
    message: '`anderson` successfully fit the distribution to the data.')
```

```
from scipy.stats import jarque_bera

jarque_bera(amostra["weight"])
```

```
SignificanceResult(statistic=np.float64(6.044887782508762), pvalue=np.float64(0.048682099107123))
```

```
from scipy.stats import normaltest

normaltest(amostra["weight"]) #teste de D'Agostino-Pearson
```

```
NormaltestResult(statistic=np.float64(6.212974555746504), pvalue=np.float64(0.044757901595882))
```

Se considerarmos um nível de significância de 1%, temos que a maioria dos testes não rejeita a hipótese de que os dados são provenientes de uma população normal. No entanto, ao considerarmos um nível de 5% temos que o resultado se inverte.

10.1.5 Teste t para uma média com variância desconhecida

```
mu0 = 70.8

xbar = amostra["weight"].mean()
s_amostral = amostra["weight"].std(ddof=1)

tc = (xbar - mu0)/(s_amostral/np.sqrt(n))

print(f"Desvio-Padrão amostral: {s_amostral:.2f}")
print(f"Média amostral: {xbar:.2f}")
print(f"Estatística t: {tc:.4f}")
```

```
Desvio-Padrão amostral: 8.28
Média amostral: 72.68
Estatística t: 2.6115
```

10.1.6 Cálculo do p-valor

```
from scipy.stats import t
gl = n-1

p_value = 2 * (1 - t.cdf(x=abs(tc), df = gl))

print(f"Valor-p: {p_value:.6f}")
```

Valor-p: 0.010058

```
from statsmodels.stats.weightstats import DescrStatsW

d = DescrStatsW(amostra["weight"])

t_stat, p_value, gl = d.ttest_mean(mu0)

print(d)
print(f"t = {t_stat:.4f}")
print(f"p = {p_value:.6f}")
print(f"gl = {gl:.0f}")
```

```
<statsmodels.stats.weightstats.DescrStatsW object at 0x0000015BC43E9BE0>
t = 2.6115
p = 0.010058
gl = 132
```

10.1.7 Regra de Decisão

```
alpha = 0.05

if p_value < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

10.1.8 Intervalo de confiança de 95%

```
t_crit = t.ppf(1-alpha/2, df = gl)

erro = t_crit * s_amostral/np.sqrt(n)

li = xbar - erro
ls = xbar + erro

print(f"IC95%: ({li:.2f}, {ls:.2f})")
```

IC95%: (71.25, 74.10)

10.1.9 Exemplo Aplicado

Segundo a *Deutsche Bischofskonferenz (Conferência Episcopal Alemã, DBK)*, aproximadamente 24% da população alemã se declara católica. Neste estudo, pretende-se investigar se a proporção de estudantes católicos difere da proporção observada na população geral da Alemanha.

Para isso, será obtida uma amostra aleatória de estudantes, a partir da qual será realizada uma inferência estatística sobre a proporção populacional. Em particular, o objetivo é testar a hipótese de igualdade entre a proporção de católicos no grupo de estudantes e o valor de referência de 0,24. Iremos considerar a seguintes hipótese:

$$H_0 : p = 0,24$$

e

$$H_A : p \neq 0,24$$

em que p representa a proporção dos estudantes que são católicos.

10.1.9.1 Cálculo do tamanho mínimo de amostra

Desejamos ter 80% de poder para detectar diferenças de pelo menos 2 pontos percentuais em relação ao valor de referência. Além disso, o valor de $p = 0.5$ maximiza a variância $p(1 - p)$ e, portanto, produz o maior tamanho amostral possível.

```

from scipy.stats import norm

alpha = 0.05
power = 0.80
delta = 0.02
p0 = 0.5
p1 = np.abs(p0-delta)

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = ((z_alpha*np.sqrt(p0*(1-p0)) + z_beta*np.sqrt(p1*(1-p1)) )/delta)**2

print(f"Tamanho inicial da amostra: {np.ceil(n0):.0f}")

```

Tamanho inicial da amostra: 4904

Como a população possui apenas 8.239 indivíduos, aplicaremos uma correção para população finita:

```

n = (n0 * N)/(n0 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho corrigido da amostra: {n}")

```

Tamanho corrigido da amostra: 3075

Agora iremos retirar uma amostra piloto para estimar a proporção de estudantes que são católicos.

```

amostra_piloto = estudantes.sample(n=50, replace=False, random_state=2026)

proporcao_catolica = (amostra_piloto["religion"] == "Catholic").mean()

print(f"Proporção de Católicos na amostra piloto: {proporcao_catolica}")

```

Proporção de Católicos na amostra piloto: 0.36

Agora, o tamanho de amostra mínimo será:

```

from scipy.stats import norm

alpha = 0.05
power = 0.80
delta = 0.02
p0 = proporcao_catolica
p1 = np.abs(p0-delta)

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = n0 = ((z_alpha*np.sqrt(p0*(1-p0)) + z_beta*np.sqrt(p1*(1-p1)) )/delta)**2

n = (n0 * N)/(n0 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho da amostra : {np.ceil(n0):.0f}")
print(f"Tamanho da amostra corrigido: {np.ceil(n):.0f}")

```

Tamanho da amostra : 4486
Tamanho da amostra corrigido: 2905

10.1.9.2 Seleção da amostra aleatória

Agora iremos selecionar aleatoriamente os 2905 estudantes.

```

amostra = estudantes.sample(n=n, replace=False, random_state=2026)

amostra.head()

```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
5101	529136	Gill, Lakota	Male	20	183	80.1	Other	1.71	>6th	Math
1885	776233	Martinez, Keyana	Female	22	160	59.7	Protestant	1.64	3rd	Social
6380	566509	Maryland, Travis	Male	24	169	66.7	Catholic	2.32	2nd	Math
1216	900121	Gallegos, Anthony	Male	22	178	76.2	Other	1.82	6th	Math
1290	610212	Aragon, Samantha	Female	23	167	64.1	Protestant	1.07	3rd	Social

10.1.9.3 Teste Z para uma proporção

```
p0 = 0.24

p_amostral = (amostra["religion"] == "Catholic").mean()

z = (p_amostral - p0)/(np.sqrt(p0*(1-p0)/n))

print(f"Proporção amostral: {p_amostral:.2f}")
print(f"Estatística Z: {z:.4f}")
```

Proporção amostral: 0.33
Estatística Z: 11.7642

10.1.9.4 Cálculo do p_{valor}

```
from scipy.stats import norm

p_value = 2 * (1 - norm.cdf(abs(z)))

print(f"Valor-p: {p_value:.6f}")
```

Valor-p: 0.000000

```
from statsmodels.stats.proportion import proportions_ztest

x = (amostra["religion"] == "Catholic").sum()

stat, p_value = proportions_ztest(
    count=x,
    nobs=n,
    value=0.24,
    prop_var = p0, #por padrao usa a proporcao amostral
    alternative='two-sided'
)

print(f"Estatística Z: {stat:.4f}")
print(f"Valor-p: {p_value:.6f}")
```


Estatística Z: 11.7642

Valor-p: 0.000000

Observação

A função `proportions_ztest()` do pacote `statsmodels` utiliza, por padrão, a proporção amostral para estimar a variância da estatística de teste.

10.1.9.5 Regra de Decisão

```
alpha = 0.05

if p_value < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

10.1.9.6 Intervalo de confiança de 95%

```
z_crit = norm.ppf(1-alpha/2)

erro = z_crit * np.sqrt(p_amostral*(1-p_amostral)/n)

li = p_amostral - erro
ls = p_amostral + erro

print(f"IC95%: ({li:.2f}, {ls:.2f})")
```

IC95%: (0.32, 0.35)

10.1.9.7 Conclusão

Ao nível de significância de 5%, os dados fornecem evidências suficientes para concluir que a proporção de estudantes católicos difere da proporção de 24% observada na população alemã segundo a DBK. O resultado sugere que a composição religiosa da população estudantil não reflete exatamente a composição religiosa da população geral.

10.1.10 Exemplo Prático

O Python permite realizar um teste t com variâncias combinadas utilizando a função `ttest_ind_from_stats()`, disponível no módulo `stats` do pacote `scipy`.

No exemplo, assumiremos que as variâncias das duas amostras são iguais. Portanto, o argumento `equal_var` da função será definido como `True`.

Para praticar a aplicação do teste t com variâncias combinadas, utilizaremos o conjunto de dados *estudantes*.

10.1.10.1 Hipóteses

Queremos verificar se existe diferença entre os ganhos de homens e mulheres graduados. Desta forma, queremos testar as seguintes hipóteses:

$$H_0 : \mu_1 = \mu_2$$

e

$$H_A : \mu_1 \neq \mu_2$$

em que μ_1 e μ_2 representam as médias salariais dos estudantes graduados do sexo masculino e feminino, respectivamente.

10.1.10.2 Preparação dos dados

Começamos com a preparação dos dados, que inclui as seguintes etapas:

1. Subdividimos o conjunto de dados com base na variável binária **graduated**, que indica se o estudante já se formou. O valor 1 representa “formado”, enquanto 0 indica “não formado”.
2. Em seguida, dividimos o conjunto de dados por gênero (masculino e feminino).
3. Depois, selecionamos aleatoriamente uma amostra de 50 estudantes do sexo feminino e 50 do sexo masculino de cada subconjunto e extraímos a média do salário anual (em euros) como variável de interesse.

Armazenaremos as informações de salário dos grupos masculino e feminino em variáveis separadas chamadas `amostra_homens` e `amostra_mulheres`. A informação relevante está armazenada na coluna `salary`.

```
estudantes_graduados = estudantes.loc[estudantes.graduated == 1] #filtra estudantes formados

homens_graduados = estudantes_graduados.loc[estudantes.gender == "Male"] #separa homens formados

mulheres_graduadas = estudantes_graduados.loc[estudantes.gender == "Female"] #separa mulheres formadas

n_piloto = 30

amostra_homens_piloto = homens_graduados.sample(n_piloto, random_state = 24, replace = False)

amostra_mulheres_piloto = mulheres_graduadas.sample(n_piloto, random_state = 24, replace = False)

s21_piloto = np.var(amostra_homens_piloto, ddof = 1)
s22_piloto = np.var(amostra_mulheres_piloto, ddof = 1)

n1 = n2 = n_piloto

alpha = 0.05
power = 0.90
delta = 5000

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = (((z_alpha + z_beta)/ delta)**2)*(s21_piloto + s22_piloto)

print(f"Razão entre as variâncias da amostra piloto: {np.sqrt(s21_piloto)/np.sqrt(s22_piloto)}")
print(f"Tamanho inicial da amostra: {np.ceil(n0):.0f}")
```

Razão entre as variâncias da amostra piloto: 1.34
Tamanho inicial da amostra: 62

A razão entre os desvios-padrão é aproximadamente 1,34 e, portanto, nota-se que a suposição de igualdade dos desvios-padrão populacionais parece razoável.

```
tol = 1
max_iter = 100
n0 = np.ceil(n0)
```

```

for i in range(max_iter):

    gl = 2*n0 - 2

    t_alpha = t.ppf(1 - alpha/2, df=gl)
    t_beta = t.ppf(power, df=gl)

    n_novo = (((t_alpha + t_beta)/delta)**2) * (s21_piloto + s22_piloto)

    # normalmente arredondamos para cima
    n_novo = np.ceil(n_novo)

    if n_novo == n0:
        break

    n0 = n_novo

n = int(np.ceil(n0))

print(f"Convergiu em {i+1} iterações")
print(f"n por grupo = {int(n)}")

```

Convergiu em 2 iterações
n por grupo = 63

10.1.11 Seleção da amostra

```

amostra_homens = homens_graduados.sample(n, random_state = 24, replace = False)["salary"] #S
amostra_mulheres = mulheres_graduadas.sample(n, random_state = 24, replace = False)["salary"]

```

```

import matplotlib.pyplot as plt
import scipy.stats as stats

plt.figure(figsize=(12,5))


ax = plt.subplot(1, 2, 1)
qq = stats.probplot(amostra_homens, dist="norm", plot = plt)
ax.set_title("Q-Q plot para homens (amostra)")

```

```
ax.set_ylabel("Quantis Amostrais")

ax = plt.subplot(1, 2, 2)
qq = stats.probplot(amostra_mulheres, dist="norm", plot = plt)
ax.set_title("Q-Q plot para mulheres (amostra)")
ax.set_ylabel("Quantis Amostrais")
```

```
Text(0, 0.5, 'Quantis Amostrais')
```



Observamos que os dados da amostra apresentam certo nível de ruído, mas ainda seguem aproximadamente uma distribuição normal. Além disso, verificamos se os desvios-padrão das duas populações são aproximadamente iguais. Como regra prática, a condição de igualdade dos desvios-padrão populacionais é considerada satisfeita se a razão entre o maior e o menor desvio-padrão amostral for inferior a 2.

```
s1 = np.std(amostra_homens, ddof = 1)
s2 = np.std(amostra_mulheres, ddof = 1)

n1 = n2 = n

sc = np.sqrt(((n1 - 1) * s1**2 + (n2 - 1) * s2**2) / (n1 + n2 - 2))

print(f"Razão entre os desvios-padrão: {s1/s2:.2f}")
```

```
Razão entre os desvios-padrão: 1.36
```

Podemos analisar a suposição de igualdade das variâncias, fazendo um boxplot por gênero.


```
import seaborn as sns

plt.figure(figsize=(11,5))

amostra = pd.melt(pd.DataFrame({'Homens': amostra_homens.values, 'Mulheres': amostra_mulheres.values}),
                  id_vars=['Gênero'],
                  value_vars=amostra_homens.columns + amostra_mulheres.columns)

amostra.columns = ["Gênero", "Salário Anual em Euros"]

sns.boxplot(x='Gênero',
            y='Salário Anual em Euros',
            hue='Gênero',
            data=amostra).set(title='Dados Amostrais')
```



10.1.11.1 Estatística de Teste

```
gl = 2*n-2
xbar1 = np.mean(amostra_homens)
xbar2 = np.mean(amostra_mulheres)

t_cal = (xbar1 - xbar2) / (sc * np.sqrt((1/n1) + (1/n2)))
```

```

p_valor = 1 - t.cdf(t_cal, df = gl)
p_valor

print(f"Graus de Liberdade: {gl: 0f}")
print(f"Estatística de Teste: {t_cal:.2f}")
print(f"P-valor: {p_valor:.4f}")

```

```

Graus de Liberdade: 124.000000
Estatística de Teste: 8.40
P-valor: 0.0000

```

10.1.11.2 Regra de Decisão

```

alpha = 0.05

if p_valor < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")

```

```

Rejeita H0

```

10.1.11.3 Usando scipy

```

from scipy import stats

resultado_teste = stats.ttest_ind(amostra_homens, amostra_mulheres,
                                  equal_var = True,
                                  alternative = "two-sided")

resultado_teste

```

```

TtestResult(statistic=np.float64(8.402219821394947), pvalue=np.float64(8.59668283081678e-14))

```

10.1.11.4 Conclusão

Ao nível de significância de 1%, os dados fornecem evidências muito fortes para concluir que o salário médio dos graduados do sexo masculino é diferente do salário médio das graduadas do sexo feminino.

10.2 Inferências para duas médias populacionais com amostras independentes e variâncias desiguais

No exemplo, anterior poderíamos aplicar o teste de maneira prática e fácil usando a função `stats.ttest_ind()` com o argumento `equal_var = False`.

```
resultado_teste_Welch = stats.ttest_ind(amostra_homens, amostra_mulheres,
                                       equal_var = False,
                                       alternative = "two-sided")

resultado_teste_Welch
```

```
TtestResult(statistic=np.float64(8.402219821394947), pvalue=np.float64(1.3950391891186315e-16))
```

10.2.1 Exemplo Prático

Para ilustrar a aplicação do teste t pareado para amostras dependentes, estamos interessados em verificar se um tutorial online de Estatística auxilia os estudantes a melhorar seu desempenho acadêmico.

Existem três variáveis de interesse no conjunto de dados dos estudantes:

1. A variável `online.tutorial` é uma variável binária que assume valor 1 se o estudante concluiu o tutorial online de Estatística e 0 caso contrário.
2. As variáveis `score1` e `score2` representam as notas (de 0 a 100) obtidas em duas avaliações de Matemática e Estatística. Quanto maior a nota, melhor o desempenho do estudante.
3. Observe que a primeira avaliação ocorre antes da participação dos estudantes no tutorial online de Estatística. A participação no tutorial é opcional, mas as duas avaliações são obrigatórias para todos os estudantes. A primeira prova (`score1`) é realizada no início do terceiro semestre, enquanto a segunda prova (`score2`) é realizada ao final do terceiro semestre.

Neste contexto, há duas questões de pesquisa de interesse:

- Verificar se o grupo de estudantes que participou do tutorial online de Estatística apresentou melhor desempenho na segunda avaliação em comparação com a primeira avaliação.
- Avaliar o desempenho do grupo de estudantes que não participou do tutorial online, comparando os resultados obtidos na primeira e na segunda avaliação.

10.2.2 Hipóteses

A hipótese nula afirma que não há diferença entre as médias das notas dos dois exames:

$$H_0 : \mu_1 = \mu_2$$

A hipótese alternativa indica que os alunos têm melhor desempenho no segundo exame:

$$H_A : \mu_1 < \mu_2$$

Isso caracteriza um teste de hipótese unilateral à esquerda

10.2.3 Preparação dos Dados e Amostra Piloto

```
subconjunto = estudantes.loc[estudantes["online.tutorial"] == 1]

n_piloto = 50

amostra_piloto = subconjunto.sample(n_piloto, random_state = 24)[["score1", "score2"]]

d_piloto = (amostra_piloto["score1"] - amostra_piloto["score2"]).to_frame(name="diferenca")

sd_piloto = np.std(d_piloto["diferenca"])

print(f"Desvio-padrão da diferença (amostra piloto) : {sd_piloto:.2f}")
```

Desvio-padrão da diferença (amostra piloto) : 6.75

10.3 Cálculo do tamanho amostral

```

from scipy.stats import t

alpha = 0.01
power = 0.80
delta = 2.0

z_alpha = norm.ppf(1 - alpha)
z_beta = norm.ppf(power)

n0 = ((z_alpha + z_beta) * sd_piloto/delta)**2

print(f"Tamanho inicial da amostra (usando quantil da normal padrão): {np.ceil(n0):.0f}")

t_alpha = t.ppf(1 - alpha, df = n0-1)
t_beta = t.ppf(power, df = n0-1)
n1 = ((t_alpha + t_beta) * s/delta)**2
N = 3182
n = (n1 * N)/(n1 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho mínimo da amostra (usando quantil da t-student): {n:.0f}")

```

Tamanho inicial da amostra (usando quantil da normal padrão): 115
Tamanho mínimo da amostra (usando quantil da t-student): 166

10.3.1 Seleção da Amostra

```
amostra = subconjunto.sample(n, random_state = 24)[["score1", "score2"]]
```

10.3.2 Estatística de Teste

```

d = (amostra["score1"] - amostra["score2"]).to_frame(name="diferenca")

diff_mean = np.mean(d)
diff_std = np.sqrt((np.sum(d**2) - ((np.sum(d)**2) / n)) / (n - 1))

```

```

t_value = diff_mean / (diff_std / np.sqrt(n))

p = t.cdf(t_value, df = n-1)

print(f"EGraus de Liberdade: {n-1: 0f}")
print(f"Estatística de Teste: {t_value:.2f}")
print(f"P-valor: {p:.4f}")

```

```

EGraus de Liberdade: 165.000000
Estatística de Teste: -3.47
P-valor: 0.0003

```

10.3.2.1 Regra de Decisão

```

alpha = 0.01

if p < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")

```

```
Rejeita H0
```

10.3.2.2 Usando funções do Python

```

test_result = stats.ttest_rel(amostra["score1"], amostra["score2"], alternative = "less")

test_result

```

```
TtestResult(statistic=np.float64(-3.4665474965475522), pvalue=np.float64(0.00033609430208778))
```

10.3.2.3 Conclusão

Ao nível de significância de 1%, os dados fornecem evidência forte para concluir que as notas dos estudantes em exames melhoram após realizarem um tutorial online de aprendizagem de estatística.

10.4 Referências

11 Demonstrações

Este capítulo reúne 26 demonstrações consideradas relevantes para o desenvolvimento e o aprofundamento dos principais resultados de Inferência Estatística apresentados ao longo do livro. A organização segue seis blocos: resultados fundamentais de probabilidade; distribuições amostrais; redução de dados e estimação; verossimilhança e teoria assintótica; testes e intervalos; e inferência computacional e moderna.

Alguns resultados também são demonstrados nos capítulos em que aparecem originalmente. Sua retomada aqui é intencional: este capítulo pode apresentar demonstrações alternativas, mais detalhadas, mais formais ou desenvolvidas sob outra perspectiva, funcionando também como material de consulta transversal. A repetição de um resultado, portanto, não implica que uma das versões deva ser eliminada, desde que cada apresentação cumpra função própria e não haja incompatibilidade entre elas.

As demonstrações foram reescritas em notação uniforme e com nível de detalhe adequado ao texto didático. Cada resultado contém uma indicação explícita da fonte principal, da localização aproximada na obra e do grau de adaptação realizado.

Escopo bibliográfico

As provas abaixo são adaptações didáticas das fontes indicadas. Quando a fonte apresenta apenas uma versão restrita do resultado, o enunciado preserva essa restrição. Generalizações não demonstradas nas obras consultadas são identificadas como observações que exigem verificação bibliográfica adicional.

Mapa das demonstrações e fontes

Nº	Demonstração	Fonte principal auditada
1	Lei fraca dos grandes números	Ramachandran; Tsokos (2009, seq. 3.5, Teorema 3.5.2)
2	Teorema Central do Limite por FGM	Larsen; Marx (2012, Apêndice 4.A.2)

Nº	Demonstração	Fonte principal auditada
3	Distribuições de $\bar{X}$ e S^2 no modelo normal	Larsen; Marx (2012, seq. 7.1–7.3 e Apêndice 7.A.2)
4	Independência entre $\bar{X}$ e S^2	Larsen; Marx (2012, Apêndice 7.A.2, Teorema 7.A.2.1)
5	Derivação da distribuição t	Larsen; Marx (2012, seq. 7.2–7.3)
6	Fatoração de Fisher–Neyman, versão discreta	Rice (2007, seq. 8.8.1)
7	Teorema de Rao–Blackwell	Rice (2007, seq. 8.8.2)
8	Teorema de Lehmann–Scheffé	Hogg; Craig (1978, cap. 10)
9	Desigualdade de Cramér–Rao	Hogg; Craig (1978, seq. 11.1)
10	Invariância do EMV sob transformação invertível	Chihara; Hesterberg (2022, seq. 6.3.5, Proposição 6.6)
11	Lema de Neyman–Pearson	Rice (2007, seq. 9.2)
12	Teorema de Karlin–Rubin	Rasch; Schott (2018, seq. 3.3.1, Teoremas 3.7–3.8)
13	Dualidade entre testes e regiões de confiança	Rice (2007, seq. 9.3)
14	Teorema de Gauss–Markov	Rasch; Schott (2018, Teorema 4.3)
15	Teste t de uma amostra como TRVG	Larsen; Marx (2012, Apêndice 7.A.3)
16	Consistência do EMV em famílias exponenciais regulares	Lauritzen (2023, seq. 5.3.1, Teorema 5.9)
17	Normalidade assintótica do EMV	Lauritzen (2023, seq. 5.3.2, Teorema 5.11)
18	Método delta univariado e multivariado	Lauritzen (2023, Apêndice A.2.3, Teorema A.19)
19	Equivalência assintótica de Wald, escore e razão de verossimilhanças	Cox (2006) [Capítulo 6]; Lauritzen (2023, seq. 5.3.3 e 5.4.4)
20	Teorema de Wilks em famílias exponenciais curvas	Lauritzen (2023, Teorema 5.39)

Nº	Demonstração	Fonte principal auditada
21	Monotonicidade do algoritmo EM	Gupta; Chen (2011, seq. 1.1 e 2.1)
22	Estimadores de Bayes sob três perdas	Ramachandran; Tsokos (2021, seq. 10.2.1, para perdas quadrática e absoluta)
23	Consistência de minimizadores convexos	Bickel; Doksum (2016, Proposição 9.2.1)
24	Função de influência e eficiência semiparamétrica	Bickel; Doksum (2016) [Seções 7.2.1 e 9.3, Proposição 9.3.3]; Wilcox (2022, seq. 2.1–2.2)
25	Validade exata de testes de permutação	Chihara; Hesterberg (2022, seq. 3.3)
26	Princípio <i>plug-in</i> e bootstrap da média	Chihara; Hesterberg (2022, seq. 5.2)

Resultados fundamentais de probabilidade

Demonstração 1 — Lei fraca dos grandes números para a média amostral

Enunciado

Sejam $X_1, \dots, X_n$ variáveis aleatórias independentes, com

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2 < \infty.$$

Então, para todo $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \rightarrow 0,$$

isto é, $\bar{X}_n \xrightarrow{P} \mu$.

Demonstração

Pela independência,

$$E(\bar{X}_n) = \mu$$

e

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

Aplicando a desigualdade de Chebyshev,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Como $\sigma^2/(n\varepsilon^2) \rightarrow 0$, o teorema do confronto fornece

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \rightarrow 0.$$

Portanto, $\bar{X}_n \xrightarrow{P} \mu$.

Interpretação

A variância da média decresce à taxa $1/n$. A lei fraca não afirma que cada observação se aproxima de μ ; afirma que a média de um número crescente de observações se concentra probabilisticamente em torno de μ .

Fonte da demonstração

Fonte principal: Ramachandran; Tsokos (2009, seq. 3.5, Teorema 3.5.2).

Adaptação: notação modernizada e formulação direta em termos de convergência em probabilidade.

Demonstração 2 — Teorema Central do Limite por funções geradoras de momentos

Enunciado

Sejam $X_1, X_2, \dots$ variáveis aleatórias i.i.d., com $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 > 0$, e suponha que a função geradora de momentos exista em uma vizinhança de zero. Então

$$Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Demonstração

Defina

$$Y_i = \frac{X_i - \mu}{\sigma}.$$

Temos $E(Y_i) = 0$, $\text{Var}(Y_i) = 1$ e

$$Z_n = \frac{Y_1 + \cdots + Y_n}{\sqrt{n}}.$$

Se $M_Y(t)$ é a FGM de Y_i , então, pela independência,

$$M_{Z_n}(t) = \left[M_Y\left(\frac{t}{\sqrt{n}}\right) \right]^n.$$

Como $M_Y(0) = 1$, $M'_Y(0) = 0$ e $M''_Y(0) = 1$, a expansão de Taylor em torno de zero fornece

$$M_Y(s) = 1 + \frac{s^2}{2} + o(s^2), \quad s \rightarrow 0.$$

Tomando $s = t/\sqrt{n}$,

$$M_Y\left(\frac{t}{\sqrt{n}}\right) = 1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

Logo,

$$M_{Z_n}(t) = \left[1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n \rightarrow \exp\left(\frac{t^2}{2}\right).$$

A função $\exp(t^2/2)$ é a FGM da distribuição normal padrão. Pelo teorema de continuidade para funções geradoras de momentos,

$$Z_n \xrightarrow{d} N(0, 1).$$

⚠ Condição importante

Esta demonstração exige a existência da FGM em uma vizinhança de zero. O Teorema Central do Limite de Lindeberg–Lévy requer apenas variância finita, mas sua prova geral não é esta. A extensão precisa deve ser verificada bibliograficamente antes de se retirar a hipótese sobre a FGM.

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, Apêndice 4.A.2).

Fonte complementar: Rice (2007, seq. 5.3).

Adaptação: uso da notação $o(n^{-1})$ para condensar a expansão apresentada nas fontes.

Distribuições amostrais

Demonstração 3 — Distribuições de $\bar{X}$ e S^2 no modelo normal

Enunciado

Se $X_1, \dots, X_n$ são i.i.d. $N(\mu, \sigma^2)$ e

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

então

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

e

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Demonstração

A média amostral é uma combinação linear de variáveis normais independentes. Portanto, é normal, com

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Para a segunda afirmação, padronize as observações:

$$Y_i = \frac{X_i - \mu}{\sigma}.$$

O vetor $Y = (Y_1, \dots, Y_n)^\top$ tem distribuição $N_n(0, I_n)$. Escolha uma matriz ortogonal A cuja última linha seja

$$\frac{1}{\sqrt{n}}(1, \dots, 1).$$

Defina $Z = AY$. Como transformações ortogonais preservam a distribuição normal padrão multivariada,

$$Z_1, \dots, Z_n$$

são independentes e $N(0, 1)$. Além disso,

$$Z_n = \sqrt{n} \bar{Y} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}.$$

A preservação da norma pela transformação ortogonal implica

$$\sum_{i=1}^n Y_i^2 = \sum_{j=1}^n Z_j^2.$$

Usando a decomposição

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2,$$

obtemos

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{j=1}^{n-1} Z_j^2.$$

O lado direito é soma dos quadrados de $n - 1$ normais padrão independentes. Assim,

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 \sim \chi_{n-1}^2.$$

Como

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{(n-1)S^2}{\sigma^2},$$

segue o resultado.

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, seq. 7.1–7.3 e Apêndice 7.A.2).

Adaptação: a normalidade de $\bar{X}$ é obtida por fechamento da família normal sob combinações lineares; a parte referente a S^2 segue a transformação ortogonal do Apêndice 7.A.2.

Demonstração 4 — Independência entre $\bar{X}$ e S^2

Enunciado

Sob as condições da demonstração anterior, $\bar{X}$ e S^2 são independentes.

Demonstração

Na transformação ortogonal anterior,

$$Z_n = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$$

e

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{j=1}^{n-1} Z_j^2.$$

O vetor Z possui componentes normais padrão independentes. Portanto, Z_n é independente do vetor

$$(Z_1, \dots, Z_{n-1}).$$

Como $\bar{X}$ é função apenas de Z_n e S^2 é função apenas de $(Z_1, \dots, Z_{n-1})$, segue que $\bar{X}$ e S^2 são independentes.

💡 Interpretação

No modelo normal, a informação amostral sobre posição, representada por $\bar{X}$, separa-se exatamente da informação residual sobre escala, representada por S^2 . Essa propriedade é

especial da distribuição normal e fundamenta a inferência exata baseada na distribuição t .

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, Apêndice 7.A.2, Teorema 7.A.2.1).

Adaptação: separação da conclusão de independência em uma demonstração própria para destacar sua função inferencial.

Demonstração 5 — Derivação da distribuição t de Student

Enunciado

Se $X_1, \dots, X_n$ são i.i.d. $N(\mu, \sigma^2)$, então

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Demonstração

Pelos resultados anteriores,

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$$

e

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

com Z e U independentes. Reescrevendo T ,

$$T = \frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{S/\sigma} = \frac{Z}{\sqrt{U/(n-1)}}.$$

Por definição, se $Z \sim N(0, 1)$ e $U \sim \chi_{\nu}^2$ são independentes, então

$$\frac{Z}{\sqrt{U/\nu}} \sim t_{\nu}.$$

Tomando $\nu = n - 1$, obtemos

$$T \sim t_{n-1}.$$

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, seq. 7.2–7.3 e Apêndice 7.A.2).

Adaptação: derivação apresentada como consequência direta dos dois resultados normais fundamentais.

Redução de dados e estimação

Demonstração 6 — Teorema da fatoração de Fisher–Neyman: versão discreta

Enunciado

Considere uma família de funções de probabilidade $\{f_\theta : \theta \in \Theta\}$ em um espaço amostral contável, com suporte comum $\mathcal{X}_0$. Uma estatística $T(X)$ é suficiente para θ se, e somente se, existem funções não negativas g_θ e h tais que

$$f_\theta(x) = g_\theta\{T(x)\}h(x), \quad x \in \mathcal{X}_0,$$

em que h não depende de θ .

Demonstração

Suponha primeiro que a fatoração seja válida. Para qualquer t pertencente à imagem de T no suporte comum,

$$P_\theta(T = t) = \sum_{x: T(x)=t} f_\theta(x) = g_\theta(t) \sum_{x: T(x)=t} h(x).$$

Logo, para $T(x) = t$,

$$P_\theta(X = x \mid T = t) = \frac{g_\theta(t)h(x)}{g_\theta(t) \sum_{u: T(u)=t} h(u)} = \frac{h(x)}{\sum_{u: T(u)=t} h(u)}.$$

Essa distribuição condicional não depende de θ . Portanto, T é suficiente.

Reciprocamente, suponha que T seja suficiente. Então existe uma função condicional comum, independente de θ , que denotaremos por

$$h(x) = P_\theta\{X = x \mid T = T(x)\},$$

bem definida no suporte comum pela suficiência. Defina ainda

$$g_{\theta}(t) = P_{\theta}(T = t).$$

Pela regra do produto,

$$f_{\theta}(x) = P_{\theta}(T = T(x))P(X = x \mid T = T(x)) = g_{\theta}(T(x))h(x).$$

Portanto, a fatoração é necessária e suficiente.

Extensão a famílias dominadas

A forma geral do teorema vale para famílias dominadas por uma medida comum. A demonstração acima foi deliberadamente restrita ao caso discreto com suporte comum; no caso geral, a necessidade da fatoração exige uma formulação cuidadosa por densidades e distribuições condicionais regulares.

Fonte da demonstração

Fonte principal: Rice (2007, seq. 8.8.1).

Adaptação: prova completa da versão discreta, com explicitação da hipótese de suporte comum; a versão dominada geral é apenas enunciada na observação.

Demonstração 7 — Teorema de Rao–Blackwell

Enunciado

Se T é suficiente para θ e W é um estimador não viesado de $g(\theta)$ com $E_{\theta}(W^2) < \infty$, então

$$W^* = E(W \mid T)$$

é não viesado e satisfaz

$$\text{Var}_{\theta}(W^*) \leq \text{Var}_{\theta}(W).$$

Demonstração

Pela propriedade da esperança iterada,

$$E_{\theta}(W^*) = E_{\theta}\{E_{\theta}(W \mid T)\} = E_{\theta}(W) = g(\theta).$$

Logo, W^* é não viesado. Como T é suficiente, a esperança condicional pode ser escolhida como uma função da amostra que não depende do parâmetro desconhecido.

Pela decomposição da variância total,

$$\text{Var}_{\theta}(W) = \text{Var}_{\theta}\{E_{\theta}(W \mid T)\} + E_{\theta}\{\text{Var}_{\theta}(W \mid T)\}.$$

O segundo termo é não negativo. Assim,

$$\text{Var}_{\theta}(W) \geq \text{Var}_{\theta}(W^*).$$

Além disso, há igualdade se, e somente se,

$$W = E_{\theta}(W \mid T)$$

quase certamente, isto é, se W já é uma função de T salvo em um conjunto nulo.

Interpretação

Condicionar em uma estatística suficiente remove a variabilidade de W que não carrega informação adicional sobre θ . O procedimento preserva o alvo e não aumenta o erro quadrático entre estimadores não viesados.

Fonte da demonstração

Fonte principal: Rice (2007, seq. 8.8.2).

Fonte complementar: Hogg; Craig (1978, seq. 10.2).

Adaptação: uso explícito da lei da variância total.

Demonstração 8 — Teorema de Lehmann–Scheffé

Enunciado

Se T é suficiente e completa para θ , e $\delta(T)$ é quadrado-integrável e não viesado para $g(\theta)$, então $\delta(T)$ é, a menos de igualdade quase certa, o único estimador não viesado de variância uniformemente mínima de $g(\theta)$.

Demonstração

Seja W qualquer estimador quadrado-integrável e não viesado de $g(\theta)$. Pelo teorema de Rao–Blackwell,

$$W^* = E(W \mid T)$$

é uma função de T , é não viesado e satisfaz

$$\text{Var}_\theta(W^*) \leq \text{Var}_\theta(W).$$

Como W^* e $\delta(T)$ são ambos não viesados,

$$E_\theta\{W^* - \delta(T)\} = 0$$

para todo θ . A completude de T implica

$$P_\theta\{W^* = \delta(T)\} = 1$$

para todo θ . Portanto,

$$\text{Var}_\theta\{\delta(T)\} = \text{Var}_\theta(W^*) \leq \text{Var}_\theta(W).$$

Como W era arbitrário, $\delta(T)$ é ENVVUM.

Para provar unicidade, sejam $\delta_1(T)$ e $\delta_2(T)$ duas funções não viesadas de T para o mesmo alvo. Então

$$E_\theta\{\delta_1(T) - \delta_2(T)\} = 0$$

para todo θ . Pela completude,

$$\delta_1(T) = \delta_2(T)$$

quase certamente.

i Fonte da demonstração

Fonte principal: Hogg; Craig (1978, cap. 10, sequência entre Rao–Blackwell, completude e Lehmann–Scheffé).

Adaptação: prova reorganizada na forma moderna “existência por Rao–Blackwell e unicidade por completude”.

Demonstração 9 — Desigualdade de Cramér–Rao

Enunciado

Considere uma amostra i.i.d. de densidade $f(x; \theta)$ e um estimador quadrado-integrável W tal que

$$E_\theta(W) = g(\theta),$$

em que g é diferenciável. Sob condições que permitem diferenciar sob o sinal de integral, com suporte independente de θ e informação de Fisher finita e positiva,

$$\text{Var}_\theta(W) \geq \frac{[g'(\theta)]^2}{I_n(\theta)},$$

onde

$$I_n(\theta) = E_\theta \left[\left(\frac{\partial}{\partial \theta} \ell_n(\theta) \right)^2 \right].$$

Demonstração

Defina o escore

$$U_n(\theta) = \frac{\partial}{\partial \theta} \ell_n(\theta).$$

Pelas condições de regularidade,

$$E_\theta\{U_n(\theta)\} = 0.$$

Diferenciando $E_\theta(W) = g(\theta)$ em relação a θ ,

$$g'(\theta) = \int W(x) \frac{\partial}{\partial \theta} f_\theta(x) dx.$$

Como

$$\frac{\partial}{\partial \theta} f_\theta(x) = f_\theta(x) U_n(\theta; x),$$

segue que

$$g'(\theta) = E_\theta\{W U_n(\theta)\}.$$

Usando $E(U_n) = 0$,

$$g'(\theta) = E_\theta\{[W - g(\theta)] U_n(\theta)\} = \text{Cov}_\theta(W, U_n).$$

Pela desigualdade de Cauchy–Schwarz,

$$[g'(\theta)]^2 \leq \text{Var}_\theta(W) \text{Var}_\theta(U_n).$$

Como $\text{Var}(U_n) = I_n(\theta)$,

$$\text{Var}_\theta(W) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Regularidade

A prova falha quando o suporte depende de θ ou quando não se pode permutar diferenciação e integração. Modelos uniformes com extremo desconhecido são exemplos clássicos em que a forma regular da desigualdade não deve ser aplicada mecanicamente.

Fonte da demonstração

Fonte principal: Hogg; Craig (1978, seq. 11.1).

Fonte complementar: Larsen; Marx (2012, seq. 5.5, para a interpretação como limite inferior).

Adaptação: formulação para um alvo geral $g(\theta)$.

Demonstração 10 — Invariância do estimador de máxima verossimilhança

Enunciado

Se $\hat{\theta}$ maximiza $L(\theta; x)$ e $\eta = h(\theta)$ é uma transformação bijetiva, então o EMV de η é

$$\hat{\eta} = h(\hat{\theta}).$$

Demonstração

Escreva a verossimilhança na parametrização η como

$$L_{\eta}(\eta; x) = L_{\theta}(h^{-1}(\eta); x).$$

Como h é bijetiva, maximizar sobre η equivale a maximizar sobre θ . Para qualquer η existe exatamente um $\theta = h^{-1}(\eta)$ e

$$L_{\eta}(\eta; x) = L_{\theta}(\theta; x) \leq L_{\theta}(\hat{\theta}; x) = L_{\eta}(h(\hat{\theta}); x).$$

Portanto, $h(\hat{\theta})$ maximiza a verossimilhança na nova parametrização.

⚠ Transformações não injetivas

A fonte demonstra a propriedade para transformações invertíveis. A versão frequentemente citada para transformações não injetivas exige definir cuidadosamente a verossimilhança do parâmetro transformado, em geral por maximização sobre as fibras $\{\theta : h(\theta) = \eta\}$. Essa generalização precisa de verificação bibliográfica antes de ser apresentada como automática.

i Fonte da demonstração

Fonte principal: Chihara; Hesterberg (2022, seq. 6.3.5, Proposição 6.6).

Adaptação: escrita explícita da verossimilhança reparametrizada.

Demonstração 11 — Teorema de Gauss–Markov

Enunciado

No modelo linear

$$Y = X\beta + \varepsilon,$$

suponha que X tenha posto completo, $E(\varepsilon) = 0$ e

$$\text{Var}(\varepsilon) = \sigma^2 I_n.$$

Então, para qualquer combinação estimável $a^\top \beta$, o estimador de mínimos quadrados

$$a^\top \hat{\beta}, \quad \hat{\beta} = (X^\top X)^{-1} X^\top Y,$$

é o estimador linear não viesado de variância mínima.

Demonstração

Um estimador linear de $a^\top \beta$ tem a forma $c^\top Y$. Ele é não viesado se

$$E(c^\top Y) = c^\top X\beta = a^\top \beta$$

para todo β , ou seja,

$$X^\top c = a.$$

Defina

$$c_0 = X(X^\top X)^{-1}a.$$

Então $X^\top c_0 = a$, e

$$c_0^\top Y = a^\top \hat{\beta}.$$

Qualquer outro vetor c que satisfaça $X^\top c = a$ pode ser escrito como

$$c = c_0 + d,$$

com

$$X^\top d = 0.$$

Como c_0 pertence ao espaço coluna de X e d é ortogonal a esse espaço,

$$c_0^\top d = 0.$$

Assim,

$$\text{Var}(c^\top Y) = \sigma^2 c^\top c = \sigma^2 (c_0 + d)^\top (c_0 + d) = \sigma^2 c_0^\top c_0 + \sigma^2 d^\top d.$$

Logo,

$$\text{Var}(c^\top Y) \geq \text{Var}(c_0^\top Y),$$

com igualdade somente se $d = 0$. Portanto, $a^\top \hat{\beta}$ é BLUE.

i Fonte da demonstração

Fonte principal: Rasch; Schott (2018, Teorema 4.3).

Adaptação: prova reescrita na parametrização matricial usual $Y = X\beta + \varepsilon$ e em termos de projeções ortogonais.

Demonstração 12 — Estimadores de Bayes sob perdas quadrática, absoluta e 0–1

Seja $\pi(\theta \mid x)$ a distribuição posterior e

$$r(a \mid x) = E\{L(\theta, a) \mid x\}$$

o risco posterior de escolher a ação a .

Perda quadrática

Para

$$L(\theta, a) = (a - \theta)^2,$$

escreva $m = E(\theta \mid x)$. Então

$$E\{(a - \theta)^2 \mid x\} = E\{[(a - m) + (m - \theta)]^2 \mid x\}.$$

O termo cruzado é zero, pois $E(m - \theta \mid x) = 0$. Logo,

$$r(a \mid x) = (a - m)^2 + \text{Var}(\theta \mid x),$$

que é minimizado em

$$a^* = E(\theta \mid x).$$

Perda absoluta

Para

$$L(\theta, a) = |a - \theta|,$$

suponha uma posterior contínua. O risco pode ser escrito como

$$r(a \mid x) = \int_{-\infty}^a (a - \theta)\pi(\theta \mid x) d\theta + \int_a^{\infty} (\theta - a)\pi(\theta \mid x) d\theta.$$

Derivando em relação a a ,

$$\frac{d}{da}r(a | x) = P(\theta \leq a | x) - P(\theta > a | x) = 2F(a | x) - 1.$$

O mínimo ocorre quando

$$F(a | x) = \frac{1}{2}.$$

Portanto, qualquer mediana posterior é uma ação de Bayes.

Perda 0–1 no caso discreto

Se

$$L(\theta, a) = \begin{cases} 0, & a = \theta, \\ 1, & a \neq \theta, \end{cases}$$

então

$$r(a | x) = P(\theta \neq a | x) = 1 - P(\theta = a | x).$$

Minimizar o risco equivale a maximizar $P(\theta = a | x)$. Logo, a ação de Bayes é uma moda posterior.

Parâmetro contínuo e perda 0–1

Para posteriores contínuas, $P(\theta = a | x) = 0$ para todo ponto a , de modo que a perda pontual 0–1 não seleciona uma ação. A identificação da moda pode ser justificada por uma perda de vizinhança que tende à perda 0–1, mas essa passagem exige formulação adicional.

Fonte da demonstração

Fonte principal: Ramachandran; Tsokos (2021, seq. 10.2.1) para as perdas quadrática e absoluta.

Complemento autoral: o argumento para a perda 0–1 discreta é uma derivação direta do risco posterior e não foi localizado na seção citada da fonte principal.

Adaptação: a prova quadrática foi reescrita por decomposição em torno da média posterior; a prova da perda absoluta explicita a derivada do risco.

Verossimilhança e teoria assintótica

Demonstração 13 — Consistência do EMV em famílias exponenciais regulares

Enunciado

Considere uma família exponencial mínima e regular em forma canônica,

$$f_{\theta}(x) = h(x) \exp\{\theta^{\top} t(x) - \psi(\theta)\},$$

com θ em um conjunto aberto. O EMV é assintoticamente bem definido — isto é, existe com probabilidade tendendo a um — e

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

Demonstração

A log-verossimilhança média é

$$\frac{1}{n} \ell_n(\theta) = \theta^{\top} \bar{T}_n - \psi(\theta) + C(x),$$

onde

$$\bar{T}_n = \frac{1}{n} \sum_{i=1}^n t(X_i).$$

A equação de escore é

$$\nabla \psi(\hat{\theta}_n) = \bar{T}_n.$$

Defina o parâmetro de média

$$\tau(\theta) = E_{\theta}\{t(X)\} = \nabla\psi(\theta).$$

Em uma família mínima e regular,

$$D\tau(\theta) = \nabla^2\psi(\theta) = \text{Var}_{\theta}\{t(X)\}$$

é positiva definida. Consequentemente, τ é localmente invertível e, na parametrização mínima, injetiva. Como a imagem de τ é aberta, a lei dos grandes números implica que $\bar{T}_n$ pertence a essa imagem com probabilidade tendendo a um. Nesse evento,

$$\hat{\theta}_n = \tau^{-1}(\bar{T}_n).$$

Pela lei dos grandes números,

$$\bar{T}_n \xrightarrow{P} \tau(\theta).$$

Pela continuidade de τ^{-1} ,

$$\hat{\theta}_n = \tau^{-1}(\bar{T}_n) \xrightarrow{P} \tau^{-1}\{\tau(\theta)\} = \theta.$$



Escopo do resultado

Esta é uma prova para famílias exponenciais mínimas e regulares. Ela não constitui uma prova geral da consistência do EMV em modelos paramétricos arbitrários. Em modelos não regulares, com parâmetros incidentais ou suporte dependente do parâmetro, o EMV pode ser inconsistente.



Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema 5.9).

Adaptação: explicitação da equação de escore e do uso do mapa entre parâmetro canônico e parâmetro de média.

Demonstração 14 — Normalidade assintótica do EMV

Enunciado

Nas condições da demonstração anterior,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N_k\{0, I(\theta)^{-1}\},$$

onde

$$I(\theta) = \text{Var}_{\theta}\{t(X)\}$$

é a informação de Fisher por observação.

Demonstração

Pelo Teorema Central do Limite multivariado,

$$\sqrt{n}\{\bar{T}_n - \tau(\theta)\} \xrightarrow{d} N_k\{0, \kappa(\theta)\},$$

onde

$$\kappa(\theta) = \text{Var}_{\theta}\{t(X)\} = I(\theta).$$

Como

$$\hat{\theta}_n = \tau^{-1}(\bar{T}_n),$$

aplicamos o método delta à função τ^{-1} . Pelo teorema da função inversa,

$$D\tau^{-1}\{\tau(\theta)\} = [D\tau(\theta)]^{-1} = \kappa(\theta)^{-1}.$$

Portanto,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N_k(0, \kappa^{-1}\kappa\kappa^{-1}),$$

isto é,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N_k\{0, I(\theta)^{-1}\}.$$

💡 Interpretação

A matriz de covariância assintótica coincide com o inverso da informação de Fisher. Nesse sentido regular, o EMV alcança assintoticamente o limite informacional.

📘 Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema 5.11).

Adaptação: apresentação explícita como aplicação do TCL multivariado e do método delta ao mapa inverso.

Demonstração 15 — Método delta univariado e multivariado

Enunciado

Suponha que

$$\sqrt{n}(X_n - \xi) \xrightarrow{d} N_k(0, \Sigma)$$

e que $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ seja diferenciável em ξ . Então

$$\sqrt{n}\{g(X_n) - g(\xi)\} \xrightarrow{d} N_m\{0, Dg(\xi)\Sigma Dg(\xi)^\top\}.$$

Demonstração

Pela diferenciabilidade,

$$g(X_n) - g(\xi) = Dg(\xi)(X_n - \xi) + r(X_n - \xi),$$

com

$$\frac{\|r(h)\|}{\|h\|} \rightarrow 0 \quad \text{quando } h \rightarrow 0.$$

Como a convergência em distribuição da sequência escalada implica $X_n \xrightarrow{P} \xi$, temos

$$r(X_n - \xi) = o_P(\|X_n - \xi\|).$$

Multiplicando por $\sqrt{n}$,

$$\sqrt{n}\{g(X_n) - g(\xi)\} = Dg(\xi)\sqrt{n}(X_n - \xi) + o_P\{\sqrt{n}\|X_n - \xi\|\}.$$

A sequência $\sqrt{n}(X_n - \xi)$ é limitada em probabilidade, de modo que o termo de resto é $o_P(1)$. Assim,

$$\sqrt{n}\{g(X_n) - g(\xi)\} = Dg(\xi)\sqrt{n}(X_n - \xi) + o_P(1).$$

Pelo teorema de Slutsky,

$$\sqrt{n}\{g(X_n) - g(\xi)\} \xrightarrow{d} Dg(\xi)Z,$$

onde $Z \sim N_k(0, \Sigma)$. Como uma transformação linear de um vetor normal é normal,

$$Dg(\xi)Z \sim N_m\{0, Dg(\xi)\Sigma Dg(\xi)^\top\}.$$

No caso univariado,

$$\sqrt{n}\{g(X_n) - g(\xi)\} \xrightarrow{d} N(0, [g'(\xi)]^2 \sigma^2).$$

i Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema A.19).

Adaptação: notação de resto vetorial e explicitação do passo $o_P(1)$.

Demonstração 16 — Equivalência assintótica entre Wald, escore e razão de verossimilhanças

Enunciado

Considere um modelo regular uniparamétrico e o teste de

$$H_0 : \theta = \theta_0.$$

Defina

$$W_n = I_n(\theta_0)(\hat{\theta} - \theta_0)^2,$$

$$S_n = \frac{U_n(\theta_0)^2}{I_n(\theta_0)}$$

e

$$R_n = 2\{\ell_n(\hat{\theta}) - \ell_n(\theta_0)\}.$$

Sob H_0 e condições de regularidade,

$$W_n = S_n + o_P(1) = R_n + o_P(1),$$

e cada estatística converge para χ_1^2 .

Demonstração

A equação de escore no EMV é

$$U_n(\hat{\theta}) = 0.$$

Expandamos em torno de θ_0 :

$$0 = U_n(\theta_0) + \ell_n''(\tilde{\theta})(\hat{\theta} - \theta_0),$$

onde $\tilde{\theta}$ está entre $\hat{\theta}$ e θ_0 . Sob regularidade,

$$-\ell_n''(\tilde{\theta}) = I_n(\theta_0) + o_P(n).$$

Logo,

$$\hat{\theta} - \theta_0 = \frac{U_n(\theta_0)}{I_n(\theta_0)} + o_P(n^{-1/2}).$$

Substituindo no estatístico de Wald,

$$W_n = I_n(\theta_0) \left[\frac{U_n(\theta_0)}{I_n(\theta_0)} + o_P(n^{-1/2}) \right]^2 = \frac{U_n(\theta_0)^2}{I_n(\theta_0)} + o_P(1) = S_n + o_P(1).$$

Agora expanda a log-verossimilhança em torno de $\hat{\theta}$:

$$\ell_n(\theta_0) = \ell_n(\hat{\theta}) + \frac{1}{2} \ell_n''(\bar{\theta})(\theta_0 - \hat{\theta})^2,$$

pois $U_n(\hat{\theta}) = 0$. Assim,

$$R_n = -\ell_n''(\bar{\theta})(\hat{\theta} - \theta_0)^2 = I_n(\theta_0)(\hat{\theta} - \theta_0)^2 + o_P(1) = W_n + o_P(1).$$

Por fim,

$$\frac{U_n(\theta_0)}{\sqrt{I_n(\theta_0)}} \xrightarrow{d} N(0, 1),$$

portanto

$$S_n \xrightarrow{d} \chi_1^2,$$

e o mesmo vale para W_n e R_n .

i Fonte da demonstração

Fontes principais: Cox (2006) [Capítulo 6, aproximação quadrática da log-verossimilhança]; Lauritzen (2023, seq. 5.3.3 e 5.4.4).

Adaptação: prova escalar unificada por duas expansões de Taylor.

Demonstração 17 — Teorema de Wilks para uma subfamília exponencial curva

Enunciado

Considere uma família exponencial curva regular de dimensão m contendo uma subfamília curva regular de dimensão d . Sob a hipótese de que o parâmetro verdadeiro pertence à subfamília,

$$-2 \log \Lambda_n = 2\{\ell_n(\hat{\theta}) - \ell_n(\tilde{\theta})\} \xrightarrow{d} \chi_{m-d}^2,$$

onde $\hat{\theta}$ é o EMV irrestrito e $\tilde{\theta}$ é o EMV sob a restrição.

Demonstração

Sob regularidade, a log-verossimilhança admite uma aproximação quadrática local. Em coordenadas padronizadas pela informação de Fisher, escreva

$$h = \sqrt{n} I(\theta_0)^{1/2} (\theta - \theta_0).$$

Uniformemente em conjuntos limitados de h ,

$$\ell_n \left(\theta_0 + \frac{I(\theta_0)^{-1/2} h}{\sqrt{n}} \right) - \ell_n(\theta_0) = h^\top Z_n - \frac{1}{2} h^\top h + o_P(1),$$

com

$$Z_n \xrightarrow{d} N_m(0, I_m).$$

No modelo irrestrito, a função quadrática é maximizada em $h = Z_n$, com máximo

$$\frac{1}{2} \|Z_n\|^2.$$

Localmente, a hipótese restrita corresponde a um subespaço tangente $\mathcal{T}$ de dimensão d . O máximo restrito ocorre na projeção ortogonal $\Pi_{\mathcal{T}} Z_n$, com valor

$$\frac{1}{2} \|\Pi_{\mathcal{T}} Z_n\|^2.$$

Consequentemente,

$$-2 \log \Lambda_n = \|Z_n\|^2 - \|\Pi_{\mathcal{T}} Z_n\|^2 + o_P(1) = \|\Pi_{\mathcal{T}^\perp} Z_n\|^2 + o_P(1).$$

O complemento ortogonal $\mathcal{T}^\perp$ tem dimensão $m - d$. A projeção de um vetor $N_m(0, I_m)$ sobre esse espaço tem $m - d$ componentes normais padrão independentes. Portanto,

$$\|\Pi_{\mathcal{T}^\perp} Z_n\|^2 \sim \chi_{m-d}^2,$$

e o resultado segue por Slutsky.

Escopo e generalização

Esta é a versão demonstrada por Lauritzen para subfamílias curvas de famílias exponenciais curvas. Uma formulação para modelos paramétricos regulares mais gerais exige hipóteses adicionais de diferenciabilidade quadrática, identificabilidade, existência e consistência dos estimadores e controle uniforme do resto. Não se deve usar a aproximação χ^2 automaticamente em problemas de fronteira ou não identificáveis.

Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema 5.39 e resultados geométricos imediatamente anteriores).

Adaptação: apresentação em coordenadas informacionais e por projeção no espaço tangente, preservando o escopo de família exponencial curva da fonte.

Testes de hipóteses e intervalos de confiança

Demonstração 18 — Lema de Neyman–Pearson

Enunciado

Para testar duas hipóteses simples

$$H_0 : f = f_0 \quad \text{contra} \quad H_1 : f = f_1,$$

o teste que rejeita H_0 quando

$$\frac{f_1(x)}{f_0(x)} > k$$

é o teste mais poderoso entre todos os testes de nível no máximo α , escolhendo-se k e eventual randomização na fronteira para obter o nível desejado.

Demonstração

Seja φ o teste da razão de verossimilhanças e ψ qualquer outro teste com

$$E_0(\psi) \leq E_0(\varphi) = \alpha.$$

Pela construção de φ ,

$$[\varphi(x) - \psi(x)][f_1(x) - kf_0(x)] \geq 0$$

para todo x : na região em que $f_1 - kf_0 > 0$, φ toma o maior valor possível; fora dela, toma o menor.

Integrando,

$$\int (\varphi - \psi)f_1 \geq k \int (\varphi - \psi)f_0.$$

O lado direito é não negativo, pois

$$\int \varphi f_0 - \int \psi f_0 = E_0(\varphi) - E_0(\psi) \geq 0.$$

Logo,

$$E_1(\varphi) - E_1(\psi) \geq 0.$$

Portanto, a potência de φ é pelo menos tão grande quanto a de qualquer teste concorrente de nível não superior a α .

i Fonte da demonstração

Fonte principal: Rice (2007, seq. 9.2).

Fonte complementar: Ramachandran; Tsokos (2021, capítulo de testes de hipóteses).

Adaptação: razão escrita como f_1/f_0 e prova expressa por funções de teste.

Demonstração 19 — Teorema de Karlin–Rubin

Enunciado

Suponha que a família de distribuições da estatística suficiente T tenha razão de verossimilhanças monótona crescente em T . Para testar

$$H_0 : \theta \leq \theta_0 \quad \text{contra} \quad H_1 : \theta > \theta_0,$$

o teste que rejeita para valores grandes de T e tem tamanho α em θ_0 é uniformemente mais poderoso de nível α .

Demonstração

Escolha c e, se necessário, uma probabilidade de randomização γ tais que

$$E_{\theta_0} \{\varphi(T)\} = \alpha,$$

onde

$$\varphi(t) = \begin{cases} 1, & t > c, \\ \gamma, & t = c, \\ 0, & t < c. \end{cases}$$

Fixe uma alternativa $\theta_1 > \theta_0$. A razão

$$\frac{f_T(t; \theta_1)}{f_T(t; \theta_0)}$$

é crescente em t . Pelo lema de Neyman–Pearson, o teste mais poderoso para

$$H_0 : \theta = \theta_0 \quad \text{contra} \quad H_1 : \theta = \theta_1$$

rejeita para valores grandes de T . A região crítica é a mesma para qualquer $\theta_1 > \theta_0$, pois o ponto de corte é determinado pela distribuição em θ_0 e pelo nível α .

Além disso, a propriedade de razão de verossimilhanças monótona implica que

$$E_\theta\{\varphi(T)\}$$

é não decrescente em θ . Consequentemente,

$$\sup_{\theta \leq \theta_0} E_\theta\{\varphi(T)\} = E_{\theta_0}\{\varphi(T)\} = \alpha.$$

Logo, φ é um teste de nível α para a hipótese composta. Como ele é mais poderoso para cada alternativa simples $\theta_1 > \theta_0$, é uniformemente mais poderoso contra toda a alternativa unilateral.

i Fonte da demonstração

Fonte principal: Rasch; Schott (2018, seq. 3.3.1, Teoremas 3.6–3.8 e Corolário 3.3).

Adaptação: o resultado é apresentado sob o nome usual de Karlin–Rubin, combinando o argumento de monotonicidade da potência com Neyman–Pearson.

Demonstração 20 — Dualidade entre testes e regiões de confiança

Enunciado

Para cada θ_0 , suponha que $A(\theta_0)$ seja a região de não rejeição de um teste de nível α de

$$H_0 : \theta = \theta_0,$$

de modo que

$$P_{\theta_0}\{X \notin A(\theta_0)\} \leq \alpha.$$

Então

$$C(X) = \{\theta_0 : X \in A(\theta_0)\}$$

é uma região de confiança com cobertura pelo menos $1 - \alpha$:

$$P_{\theta_0}\{\theta_0 \in C(X)\} \geq 1 - \alpha.$$

Se cada teste possui tamanho exatamente α em θ_0 , a cobertura é exatamente $1 - \alpha$.

Demonstração

Pela definição de $C(X)$,

$$\{\theta_0 \in C(X)\} = \{X \in A(\theta_0)\}.$$

Portanto,

$$\begin{aligned} P_{\theta_0}\{\theta_0 \in C(X)\} &= P_{\theta_0}\{X \in A(\theta_0)\} \\ &= 1 - P_{\theta_0}\{X \notin A(\theta_0)\} \\ &\geq 1 - \alpha. \end{aligned}$$

Quando $P_{\theta_0}\{X \notin A(\theta_0)\} = \alpha$, todas as desigualdades anteriores tornam-se igualdades.

Reciprocamente, se $C(X)$ satisfaz

$$P_{\theta_0}\{\theta_0 \in C(X)\} \geq 1 - \alpha$$

para todo θ_0 , então

$$A(\theta_0) = \{x : \theta_0 \in C(x)\}$$

é a região de não rejeição de um teste de nível no máximo α de $H_0 : \theta = \theta_0$.

Interpretação

Uma região de confiança é o conjunto dos valores do parâmetro que não seriam rejeitados por uma família coerente de testes. Essa equivalência é matemática; ela não transforma a cobertura frequentista em probabilidade posterior do parâmetro.

Fonte da demonstração

Fonte principal: Rice (2007, seq. 9.3, Teoremas A e B).

Demonstração 21 — Teste t de uma amostra como teste da razão de verossimilhanças generalizada

Enunciado

Para uma amostra i.i.d. $N(\mu, \sigma^2)$, o teste bilateral de

$$H_0 : \mu = \mu_0 \quad \text{contra} \quad H_1 : \mu \neq \mu_0$$

baseado na razão de verossimilhanças generalizada rejeita para valores grandes de

$$|T| = \left| \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \right|.$$

Demonstração

A verossimilhança é

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \right\}.$$

No modelo irrestrito,

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Sob H_0 ,

$$\tilde{\mu} = \mu_0, \quad \tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2.$$

Após substituir esses estimadores, a razão é

$$\Lambda = \left[\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sum_{i=1}^n (X_i - \mu_0)^2} \right]^{n/2}.$$

Pela identidade

$$\sum_{i=1}^n (X_i - \mu_0)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu_0)^2,$$

obtemos

$$\Lambda = \left[1 + \frac{n(\bar{X} - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]^{-n/2}.$$

Como

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

segue que

$$\Lambda = \left(1 + \frac{T^2}{n-1} \right)^{-n/2}.$$

Essa expressão é estritamente decrescente em T^2 . Portanto, rejeitar para valores pequenos de Λ equivale a rejeitar para valores grandes de $|T|$. Sob H_0 , $T \sim t_{n-1}$, produzindo o teste t bilateral usual.

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, Apêndice 7.A.3).

Adaptação: notação de razão de verossimilhanças e simplificação algébrica preservadas da fonte.

Inferência computacional, reamostragem e métodos modernos

Demonstração 22 — Monotonicidade do algoritmo EM

Definição

Se Y é o dado observado, Z é o dado latente e $X = (Y, Z)$ é o dado completo, suponha que as distribuições envolvidas sejam dominadas por medidas comuns, que os suportes relevantes não variem com θ e que as esperanças abaixo sejam finitas. Defina

$$Q(\theta \mid \theta^{(m)}) = E_{\theta^{(m)}} \{\log p(Y, Z \mid \theta) \mid Y = y\}.$$

O passo M escolhe $\theta^{(m+1)}$ de modo que

$$Q(\theta^{(m+1)} \mid \theta^{(m)}) \geq Q(\theta^{(m)} \mid \theta^{(m)}).$$

Demonstração

Seja

$$q_m(z) = p(z \mid y, \theta^{(m)}).$$

Para qualquer θ ,

$$\log p(y \mid \theta) = \log p(y, z \mid \theta) - \log p(z \mid y, \theta).$$

Tomando esperança em relação a q_m ,

$$\ell(\theta) = Q(\theta \mid \theta^{(m)}) - E_{q_m} \{\log p(Z \mid y, \theta)\}.$$

Adicione e subtraia $E_{q_m} \{\log q_m(Z)\}$. Pela definição da divergência de Kullback–Leibler,

$$D_{\text{KL}}\{q_m \| p(\cdot \mid y, \theta)\} = E_{q_m} \left[\log \frac{q_m(Z)}{p(Z \mid y, \theta)} \right].$$

Logo,

$$\ell(\theta) = Q(\theta \mid \theta^{(m)}) - E_{q_m} \{\log q_m(Z)\} + D_{\text{KL}}\{q_m \| p(\cdot \mid y, \theta)\}.$$

Ao tomar $\theta = \theta^{(m)}$, a divergência é zero. Portanto,

$$\ell(\theta) - \ell(\theta^{(m)}) = Q(\theta \mid \theta^{(m)}) - Q(\theta^{(m)} \mid \theta^{(m)}) + D_{\text{KL}}\{q_m \| p(\cdot \mid y, \theta)\}.$$

Como a divergência KL é não negativa,

$$\ell(\theta) - \ell(\theta^{(m)}) \geq Q(\theta \mid \theta^{(m)}) - Q(\theta^{(m)} \mid \theta^{(m)}).$$

Aplicando essa desigualdade a $\theta^{(m+1)}$,

$$\ell(\theta^{(m+1)}) \geq \ell(\theta^{(m)}).$$

⚠ O que a monotonicidade não garante

O aumento da log-verossimilhança não garante convergência ao máximo global. O algoritmo pode convergir para um máximo local, ponto estacionário ou fronteira, e a sequência de parâmetros exige hipóteses adicionais para convergir. Além disso, a demonstração pode falhar quando o suporte do dado completo depende do parâmetro.

i Fonte da demonstração

Fonte principal: Gupta; Chen (2011, seq. 1.1 e 2.1).

Adaptação: prova escrita pela decomposição da log-verossimilhança em Q e divergência KL.

Demonstração 23 — Consistência de minimizadores convexos

Enunciado

Sejam $Q_n : \mathbb{R}^d \rightarrow \mathbb{R}$ funções aleatórias convexas e Q uma função determinística. Suponha que:

1. $Q_n \rightarrow Q$ uniformemente em probabilidade em todo compacto;
2. Q é contínua, estritamente convexa e coerciva;
3. $\hat{t}_n \in \operatorname{argmin} Q_n$ e $t_0 = \operatorname{argmin} Q$.

Então

$$\hat{t}_n \xrightarrow{P} t_0.$$

Demonstração

A estrita convexidade e a coercividade de Q garantem que t_0 existe e é único. Fixe $\varepsilon > 0$. Pela continuidade e unicidade do mínimo,

$$\delta_\varepsilon = \inf_{\|t-t_0\|=\varepsilon} \{Q(t) - Q(t_0)\} > 0.$$

A convergência uniforme em probabilidade na esfera compacta e em uma vizinhança de t_0 implica que, com probabilidade tendendo a um,

$$\inf_{\|t-t_0\|=\varepsilon} Q_n(t) > Q_n(t_0).$$

Suponha, por contradição, que $\|\hat{t}_n - t_0\| > \varepsilon$. Pela convexidade, existe $\lambda \in (0, 1)$ tal que

$$t_1 = \lambda \hat{t}_n + (1 - \lambda)t_0$$

satisfaz $\|t_1 - t_0\| = \varepsilon$. Como $\hat{t}_n$ minimiza Q_n ,

$$Q_n(t_1) \leq \lambda Q_n(\hat{t}_n) + (1 - \lambda)Q_n(t_0) \leq Q_n(t_0).$$

Isso contradiz a desigualdade anterior na esfera. Logo,

$$P(\|\hat{t}_n - t_0\| > \varepsilon) \rightarrow 0.$$

Interpretação

O resultado é um princípio geral de consistência para M -estimadores: se a função-objetivo amostral aproxima uniformemente uma função populacional com mínimo bem separado, os minimizadores amostrais aproximam o minimizador populacional.

Fonte da demonstração

Fonte principal: Bickel; Doksum (2016, Proposição 9.2.1).

Adaptação: preservação do argumento geométrico na esfera de raio ε .

Demonstração 24 — Função de influência e eficiência semiparamétrica

Função de influência de um funcional

Para um funcional estatístico $T(P)$, a função de influência sob contaminação pontual é, quando a derivada existe,

$$\text{IF}(x; T, P) = \left. \frac{d}{d\varepsilon} T\{(1 - \varepsilon)P + \varepsilon\Delta_x\} \right|_{\varepsilon=0}.$$

Ela mede a sensibilidade local de primeira ordem do funcional a uma contaminação infinitesimal no ponto x .

Duas noções relacionadas

A função de influência de um **funcional**, definida por derivada de contaminação, e a função de influência de um **estimador regular assintoticamente linear** são conceitos relacionados, mas não idênticos por definição. Sob condições adequadas de diferenciabilidade, a expansão do funcional avaliado na distribuição empírica produz a função de influência assintótica do estimador *plug-in*. A projeção eficiente abaixo refere-se à segunda noção.

Resultado de eficiência semiparamétrica

Considere um modelo semiparamétrico em P cujo espaço tangente $\dot{\mathcal{P}}$ seja um subespaço linear fechado de $L_2^0(P)$. Suponha que exista um estimador regular e assintoticamente linear do parâmetro, com função de influência $\psi \in L_2^0(P)$. Então a função de influência eficiente é

$$\psi_{\text{ef}} = \Pi(\psi \mid \dot{\mathcal{P}}),$$

isto é, a projeção ortogonal de ψ sobre o espaço tangente.

Demonstração

Pela decomposição ortogonal de Hilbert,

$$\psi = \Pi(\psi \mid \dot{\mathcal{P}}) + \Pi(\psi \mid \dot{\mathcal{P}}^\perp).$$

As equações que caracterizam uma função de influência regular envolvem seus produtos internos com os escores dos submodelos paramétricos regulares. Esses escores pertencem a $\dot{\mathcal{P}}$. Para qualquer escore $s \in \dot{\mathcal{P}}$,

$$\langle \psi, s \rangle = \langle \Pi(\psi \mid \dot{\mathcal{P}}), s \rangle,$$

pois o componente em $\dot{\mathcal{P}}^\perp$ é ortogonal a s . Portanto, a projeção preserva as equações de derivada que definem uma função de influência regular.

Pelo teorema de Pitágoras,

$$\|\psi\|_2^2 = \|\Pi(\psi \mid \dot{\mathcal{P}})\|_2^2 + \|\Pi(\psi \mid \dot{\mathcal{P}}^\perp)\|_2^2.$$

Consequentemente,

$$E_P(\psi_{\text{ef}}^2) \leq E_P(\psi^2).$$

Como a variância assintótica de um estimador regular assintoticamente linear é determinada por $E_P(\psi^2)$, a projeção possui a menor variância entre as funções de influência regulares admissíveis e é eficiente.

i Robustez

Eficiência semiparamétrica e robustez local são critérios distintos. Em análise robusta, uma função de influência limitada controla o efeito local de contaminações extremas. A função de influência eficiente no modelo semiparamétrico pode ser não limitada.

i Fonte da demonstração

Fonte principal: Bickel; Doksum (2016) [Seção 7.2.1, para funções de influência e derivadas funcionais; Seção 9.3 e Proposição 9.3.3, para projeção eficiente].

Fonte complementar: Wilcox (2022, seq. 2.1–2.2, para a interpretação robusta).

Demonstração 25 — Validade exata de um teste de permutação

Enunciado

Suponha que, sob H_0 , as observações sejam permutáveis em relação aos rótulos dos grupos. Seja $\mathcal{G}$ o conjunto finito das permutações admissíveis e T uma estatística em que valores grandes contradizem H_0 . Defina

$$p(x) = \frac{1}{|\mathcal{G}|} \sum_{g \in \mathcal{G}} \mathbf{1}\{T(gx) \geq T(x)\}.$$

Então

$$P_{H_0}\{p(X) \leq \alpha\} \leq \alpha.$$

Se não há empates e os níveis possíveis são compatíveis com $|\mathcal{G}|$, a igualdade é exata.

Demonstração

Condicione na órbita

$$\mathcal{O}(x) = \{gx : g \in \mathcal{G}\}.$$

Sob a hipótese nula de permutabilidade, todos os elementos da órbita são equiprováveis. Portanto, a posição de $T(X)$ entre os valores

$$\{T(gx) : g \in \mathcal{G}\}$$

é uniforme, na ausência de empates.

Se os valores forem ordenados do maior para o menor, $p(X)$ é a proporção de valores da órbita que são pelo menos tão extremos quanto o valor observado. Assim, a condição $p(X) \leq \alpha$ só

pode ocorrer quando $T(X)$ está entre os no máximo $\alpha|\mathcal{G}|$ valores mais extremos da órbita. Condicionalmente à órbita,

$$P_{H_0}\{p(X) \leq \alpha \mid \mathcal{O}(X)\} \leq \frac{\lfloor \alpha|\mathcal{G}| \rfloor}{|\mathcal{G}|} \leq \alpha.$$

Tomando esperança sobre a órbita,

$$P_{H_0}\{p(X) \leq \alpha\} \leq \alpha.$$

Empates tornam o teste conservador quando se usa a desigualdade $\geq$.

⚠ Condição essencial

A validade exata exige permutabilidade ou uma atribuição aleatória conhecida. Igualdade de médias, isoladamente, não garante que todos os rearranjos dos dados sejam equiprováveis. Em estudos observacionais, a interpretação causal também não decorre do teste de permutação.

i Fonte da demonstração

Fonte principal: Chihara; Hesterberg (2022, seq. 3.3, argumento de equiprobabilidade das divisões sob H_0).

Adaptação: a obra apresenta a justificativa por equiprobabilidade; a formulação acima explicita o mesmo argumento em termos de órbitas de um grupo finito.

Demonstração 26 — Princípio *plug-in* e bootstrap da média

Definição

Dada uma amostra $X_1, \dots, X_n$, a distribuição empírica é

$$\widehat{F}_n = \frac{1}{n} \sum_{i=1}^n \Delta_{X_i}.$$

Uma amostra bootstrap $X_1^*, \dots, X_n^*$ é obtida condicionalmente aos dados por amostragem i.i.d. de $\widehat{F}_n$.

Demonstração para a média

Sob a distribuição empírica,

$$E_*(X_1^*) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Logo,

$$E_*(\bar{X}^*) = \bar{X}.$$

A variância de uma observação bootstrap é

$$\text{Var}_*(X_1^*) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Como as observações bootstrap são condicionalmente independentes,

$$\text{Var}_*(\bar{X}^*) = \frac{1}{n} \text{Var}_*(X_1^*) = \frac{1}{n^2} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Usando

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

obtemos

$$\text{Var}_*(\bar{X}^*) = \frac{n-1}{n^2} S^2.$$

Portanto, o erro-padrão bootstrap ideal da média é

$$\text{se}_*(\bar{X}^*) = \frac{S}{\sqrt{n}} \sqrt{\frac{n-1}{n}},$$

que é assintoticamente equivalente ao erro-padrão usual $S/\sqrt{n}$.

Esse cálculo ilustra o princípio *plug-in*: a população desconhecida F é substituída por $\widehat{F}_n$, e a distribuição amostral de $\bar{X}$ sob F é aproximada pela distribuição condicional de $\bar{X}^*$ sob $\widehat{F}_n$.

Limite da demonstração

O cálculo de média e variância não prova a validade geral do bootstrap para qualquer estatística. Consistência bootstrap depende da regularidade do funcional e pode falhar, por exemplo, em problemas de fronteira, extremos amostrais e funcionais não suaves. Essas extensões precisam de verificação bibliográfica específica.

Fonte da demonstração

Fonte principal: Chihara; Hesterberg (2022, seq. 5.2, princípio *plug-in* e distribuição empírica).

Adaptação: inclusão da derivação exata dos dois primeiros momentos condicionais da média bootstrap.

Síntese conceitual

As 26 demonstrações formam uma cadeia lógica:

1. a lei dos grandes números e o TCL justificam a estabilidade e a aproximação normal de estatísticas;
2. os resultados exatos do modelo normal produzem as distribuições χ^2 e t ;
3. suficiência, Rao–Blackwell, completude e Cramér–Rao organizam a comparação de estimadores;
4. verossimilhança, método delta, equivalências assintóticas e Wilks estruturam a inferência regular em grandes amostras;
5. Neyman–Pearson, Karlin–Rubin e a dualidade com regiões de confiança organizam a teoria dos testes;
6. EM, minimização, funções de influência, permutação e bootstrap ampliam a teoria para métodos computacionais, robustos e semiparamétricos.

! Percursos de leitura

O capítulo não precisa ser lido integralmente e em sequência. As demonstrações podem ser consultadas conforme os resultados utilizados nos capítulos anteriores, os objetivos da disciplina e o interesse do leitor.

Quando um resultado também possuir demonstração em outro capítulo, as duas apresentações devem ser entendidas como complementares. A versão apresentada aqui pode desenvolver etapas omitidas, utilizar outra estratégia de prova ou explorar condições e generalizações com maior detalhe.

As demonstrações que exigem ferramentas matemáticas adicionais podem ser consultadas como aprofundamento, sem constituírem pré-requisito para o percurso principal do livro.

Referências

BICKEL, Peter J.; DOKSUM, Kjell A. **Mathematical Statistics: Basic Ideas and Selected Topics: Volume II**. Boca Raton, FL: CRC Press, 2016. v. 2

BOROVKOV, A. A. **Mathematical Statistics**. Amsterdam: Gordon; Breach Science Publishers, 1998.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury Press, 2002.

CASELLA, George; BERGER, Roger L. **Inferência Estatística**. Tradução: Solange Aparecida Visconte. São Paulo: Cengage Learning, 2011.

CHIHARA, Laura M.; HESTERBERG, Tim C. **Mathematical Statistics with Resampling and R**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2022.

CLOPPER, C. J.; PEARSON, E. S. [The Use of Confidence or Fiducial Limits Illustrated in the Case of the Binomial](#). **Biometrika**, v. 26, n. 4, p. 404–413, 1934.

COX, D. R. **Principles of Statistical Inference**. Cambridge: Cambridge University Press, 2006.

DANTAS, Carlos Alberto Barbosa. **Probabilidade: um curso introdutório**. São Paulo: EDUSP, 1997.

DIEZ, David M.; BARR, Christopher D.; ÇETINKAYA-RUNDEL, Mine. [Introductory Statistics with Randomization and Simulation](#). 1. ed. [S.l.]: OpenIntro, Inc., 2014.

GUPTA, Maya R.; CHEN, Yihua. [Theory and Use of the EM Algorithm](#). **Foundations and Trends in Signal Processing**, v. 4, n. 3, p. 223–296, 2011.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.

HOGG, Robert V.; CRAIG, Allen T. **Introduction to Mathematical Statistics**. 4. ed.

New York: Macmillan Publishing Co., 1978.

KERNS, G. Jay. **Introduction to Probability and Statistics Using R**. 1. ed. [*S.l.*: *S.n.*].

KIM, Albert Y.; ISMAY, Chester; KUHN, Max. **Take a modern dive into Introductory Linear Regression with R**. **The Journal of Open Source Education**, v. 4, n. 41, p. 115, 2021.

LARSEN, Richard J.; MARX, Morris L. **An Introduction to Mathematical Statistics and Its Applications**. 5. ed. Boston: Prentice Hall, 2012.

LAURITZEN, Steffen. **Fundamentals of Mathematical Statistics**. 1. ed. Boca Raton, FL: CRC Press, 2023.

MAGALHÃES, Marcos Nascimento. **Probabilidade e Variáveis Aleatórias**. 2. ed. São Paulo: EDUSP, 2006.

MEYER, Paul L. **Probabilidade e Aplicações à Estatística**. 2. ed. Rio de Janeiro: Livros Técnicos e Científicos, 1983.

RAMACHANDRAN, Kandethody M.; TSOKOS, Chris P. **Mathematical Statistics with Applications**. Burlington, MA: Academic Press, 2009.

RAMACHANDRAN, Kandethody M.; TSOKOS, Chris P. **Mathematical Statistics with Applications in R**. 3. ed. London: Academic Press, 2021.

RASCH, Dieter; SCHOTT, Dieter. **Mathematical Statistics**. Chichester: John Wiley & Sons, 2018.

RICE, John A. **Mathematical Statistics and Data Analysis**. 3. ed. Belmont, CA: Duxbury Press, 2007.

ROSNER, Bernard. **Fundamentals of Biostatistics**. 7. ed. Boston: Brooks/Cole, Cengage Learning, 2011.

ROSS, Sheldon M. **A First Course in Probability**. 7. ed. Upper Saddle River, NJ: Prentice Hall, 2006.

SHAO, Jun. **Mathematical Statistics**. 2. ed. New York: Springer, 2003.

SHAO, Jun. **Mathematical Statistics: Exercises and Solutions**. New York: Springer Science+Business Media, 2005.

WICKHAM, Hadley *et al.* **Welcome to the tidyverse**. **Journal of Open Source Software**,

v. 4, n. 43, p. 1686, 2019.

WILCOX, Rand R. **Introduction to Robust Estimation and Hypothesis Testing**. 5. ed. London: Academic Press, 2022.

WILSON, Edwin B. [Probable Inference, the Law of Succession, and Statistical Inference](#). **Journal of the American Statistical Association**, v. 22, n. 158, p. 209–212, 1927.