Análise Inferencial

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa Modelos de Sobrevivência e Aplicações.

Versão Preliminar
- Em Elaboração -

Índice

Informações Legais e Declaração de Uso de Inteligência Artificial **3**
Direitos Autorais e Uso da Obra . . . 3
Declaração sobre o Uso de Ferramentas de Inteligência Artificial . . . 3

Prefácio **4**

Identificação da Disciplina **5**
EMENTA . . . 5
OBJETIVO GERAL . . . 5
OBJETIVOS ESPECÍFICOS . . . 6
CONTEÚDO PROGRAMÁTICO . . . 6
Unidade I – Fundamentos da Inferência Estatística . . . 6
Unidade II – Distribuições Amostrais . . . 6
Unidade III – Estimação Pontual . . . 7
Unidade IV – Estimação Intervalar . . . 7
Unidade V – Testes de Hipóteses . . . 7
Unidade VI – Testes de Homogeneidade e Independência . . . 7
Unidade VII – Inferência Estatística e Ciência de Dados . . . 8
METODOLOGIA . . . 8
AVALIAÇÃO . . . 8
CRITÉRIOS DE AVALIAÇÃO . . . 8
BIBLIOGRAFIA BÁSICA . . . 9
BIBLIOGRAFIA COMPLEMENTAR . . . 9
Observações Finais . . . 9

1 Fundamentos da Inferência Estatística **10**
1.1 Processo Gerador de Dados (PGD) . . . 10
1.2 Pacote Necessários . . . 11
1.3 Experimento em Sala de Aula . . . 11
Verificação de aprendizagem . . . 12
1.4 Experimento Virtual . . . 12
Verificação de aprendizagem . . . 19
Lista Semanal Obrigatória . . . 19
1.5 Conceitos Importantes . . . 19

2 Distribuições Amostrais **24**
2.1 Introdução 24
2.1.1 O que é a Estatística Matemática? 24
2.2 Distribuições Amostrais 25
2.2.1 Distribuição Amostral da Média ($\overline{X}$) 26
2.2.2 Distribuição Amostral da Variância (S^2) 28
2.2.3 Distribuição Amostral de $\frac{\overline{X}-\mu}{S/\sqrt{n}}$ 29
2.2.4 Distribuição Amostral do Razão de Variâncias 31
2.2.5 Exemplo 32
2.3 Prova do Teorema Central do Limite (TCL) 32
2.3.1 Roteiro da Prova: 33
2.4 Lista 34

3 Estimação Pontual **36**
3.1 Estimador de Momentos 36
3.2 Método de Mínimos Quadrados 46

4 Estimação Intervalar **61**

5 Testes de Hipóteses **62**

6 Testes de Homogeneidade e Independência **63**

7 Inferência Estatística e Ciência de Dados **64**

Referências **65**

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro resulta da experiência acumulada no ensino, na orientação de estudantes e no desenvolvimento de pesquisas em modelos de regressão. Somos docentes pesquisadores do Departamento de Estatística e Matemática Aplicada da Universidade Federal do Ceará (DEMA/UFC), com atuação contínua em regressão linear, modelagem estatística e inferência. Integramos o Laboratório de Inovação em Estatística — StatLab/UFC (https://statlab.quarto.pub/) e o Grupo de Pesquisa *Modelos de Sobrevivência e Aplicações* do CNPq (http://dgp.cnpq.br/dgp/espelhogrupo/9639095385610769), espaços nos quais articulamos ensino, pesquisa e aplicação a problemas reais.

O material tem como base as disciplinas Inferência Estatística I (CC0288) e Análise Inferencial (CC0448). Ao longo dos anos, consolidamos a convicção de que ensinar regressão exige equilíbrio entre rigor teórico e clareza interpretativa.

O livro desenvolve os conceitos de Inferência Estatística de forma progressiva, enfatizando interpretação e propriedades. A implementação é realizada integralmente no **R**, utilizado como ambiente de experimentação conceitual e não apenas como ferramenta computacional.

Os fundamentos matemáticos mais densos são apresentados em apêndices específicos, preservando o fluxo didático do texto principal e permitindo diferentes níveis de aprofundamento. Acreditamos que inferência deve ser ensinada como base para tomada de decisão, com atenção às suas suposições, limitações e implicações práticas.

Esperamos que este livro contribua para a formação de profissionais capazes tomar decisões com rigor técnico, pensamento estatístico crítico e responsabilidade analítica.

Identificação da Disciplina

- Curso: Bacharelado em Ciência de Dados
- Disciplina: Análise Inferencial
- Carga Horária: 96 horas
- Créditos: 6
- Regime: Semestral
- Pré-requisitos: Modelos Probabilísticos (CC0446)
- Período Letivo: 2026.1
- Professor(a): Dr. Manoel Santos-Neto

EMENTA

Conceitos de população e amostra; parâmetros, estatísticas, estimadores e suas propriedades; distribuições amostrais; métodos de estimação pontual: método dos momentos, máxima verossimilhança e mínimos quadrados; estimação intervalar; testes de hipóteses; testes de homogeneidade e independência.

OBJETIVO GERAL

Apresentar os fundamentos da inferência estatística, capacitando o estudante a formular, analisar e interpretar problemas inferenciais em contextos de Ciência de Dados, com ênfase na quantificação da incerteza, validação de modelos e capacidade de generalização.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- compreender a diferença entre população, amostra, parâmetro e estatística;
- interpretar estatísticas como variáveis aleatórias;
- compreender e utilizar distribuições amostrais;
- aplicar métodos de estimação pontual e intervalar;
- formular e testar hipóteses estatísticas de forma adequada;
- interpretar corretamente p-valores, intervalos de confiança e decisões inferenciais;
- relacionar conceitos de inferência estatística com validação cruzada, generalização e avaliação de modelos de Machine Learning;
- analisar criticamente resultados estatísticos obtidos a partir de dados reais.

CONTEÚDO PROGRAMÁTICO

Unidade I – Fundamentos da Inferência Estatística

- População e amostra
- Processo gerador de dados
- Parâmetros e estatísticas
- Variabilidade amostral

Unidade II – Distribuições Amostrais

- Estatísticas como variáveis aleatórias
- Distribuição amostral da média e da proporção
- Lei dos Grandes Números
- Teorema Central do Limite

Unidade III – Estimação Pontual

- Estimadores e estimativas
- Propriedades dos estimadores (viés, variância, erro quadrático médio, consistência)
- Método dos momentos
- Máxima verossimilhança
- Mínimos quadrados

Unidade IV – Estimação Intervalar

- Intervalos de confiança
- Interpretação correta
- Intervalos baseados em aproximações assintóticas
- Bootstrap

Unidade V – Testes de Hipóteses

- Formulação de hipóteses
- Estatísticas de teste
- p-valor
- Erros tipo I e tipo II
- Poder do teste

Unidade VI – Testes de Homogeneidade e Independência

- Testes qui-quadrado
- Tabelas de contingência
- Associação entre variáveis categóricas

Unidade VII – Inferência Estatística e Ciência de Dados

- Relação entre inferência estatística e Machine Learning
- Validação cruzada
- Generalização e overfitting
- Interpretação inferencial de modelos preditivos

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, articuladas com atividades práticas computacionais. O conteúdo teórico será constantemente ilustrado por simulações e análises de dados reais, utilizando ferramentas computacionais (R ou Python).

Serão propostas listas semanais obrigatórias, com foco em experimentação, interpretação estatística e conexão com problemas de Machine Learning, validação de modelos e generalização. O uso de simulação, reamostragem e análise empírica será empregado como ferramenta pedagógica para construção da intuição inferencial.

AVALIAÇÃO

A avaliação será contínua e composta por:

- Listas semanais obrigatórias (atividades computacionais com interpretação estatística): 50%
- Projeto final inferencial aplicado a dados reais: 30%
- Avaliação conceitual individual (prova ou atividade equivalente): 20%

A aprovação na disciplina seguirá os critérios estabelecidos pelas normas vigentes da UFC.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados nos trabalhos e atividades:

- correção conceitual;
- adequação metodológica;
- clareza na formulação do problema inferencial;

- interpretação estatística correta dos resultados;
- organização, clareza e reprodutibilidade das análises.

BIBLIOGRAFIA BÁSICA

1. Bussab, W. O.; Morettin, P. A. Estatística Básica. 6ª ed. São Paulo: Saraiva, 2010.
2. Casella, G.; Berger, R. L. Statistical Inference. 2nd ed. New York: Duxbury Press, 2001.
3. Casella, G.; Berger, R. L. Inferência Estatística. Tradução da 2ª edição. São Paulo: Cengage Learning, 2011.

BIBLIOGRAFIA COMPLEMENTAR

1. Devore, J. L. Probabilidade e Estatística para Engenharia e Ciências. São Paulo: Thomson, 2006.
2. Mood, A. M.; Graybill, F.; Boes, D. C. Introduction to the Theory of Statistics. 3rd ed. New York: McGraw-Hill, 1974.
3. Bolfarine, H.; Sandoval, M. C. Introdução à Inferência Estatística. Rio de Janeiro: SBM, 2001.
4. Bickel, P. J.; Doksum, K. A. Mathematical Statistics. Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.
5. Dudewicz, E. J.; Mishra, S. N. Modern Mathematical Statistics. New York: John Wiley, 1988.

Observações Finais

A disciplina enfatiza a inferência estatística como base conceitual da Ciência de Dados, destacando a importância da quantificação da incerteza, da validação de modelos e da interpretação crítica dos resultados em contextos reais.

1 Fundamentos da Inferência Estatística

Neste capítulo, iniciamos a primeira parte sobre inferência estatística aprendendo um pouco sobre amostragem. Os conceitos por trás da amostram são a base para intervalos de confiança e testes de hipóteses, por exemplo. Além disso, veremos que ferramentas já aprendidas durante o curso de Ciência de Dados, em particular visualização de dados e manipulação (organização) de dados, são importantes no desenvolvimento do seu entendimento. Esperamos que os conceitos apresentados ao longo deste texto se articulam e se acumulam, culminando na capacidade de "contar sua história com dados".

1.1 Processo Gerador de Dados (PGD)

O PGD é o mecanismo teórico, físico ou biológico que produz os dados que observamos. Imagine que o mundo é uma "caixa preta" que segue certas regras (leis da física, comportamento humano, algoritmos de mercado), portanto o PGD são essas regras em funcionamento.

Realidade vs. Observação

- O PGD (A causa): É a distribuição de probabilidade teórica e os parâmetros fixos (mas desconhecidos) que regem um fenômeno.
- Os Dados (O Efeito): É a amostra específica que coletamos. É apenas uma realização de infinitas possibilidades que o PGD poderia ter gerado.

Representação Matemática

O PGD pode ser definido pela distribuição de probabilidade conjunta desconhecida $P(X, Y)$ (ou simplemente $P(Z)$).
Dizemos que nossa amostra $\mathcal{D} = \{z_1, z_2, \dots, z_n\}$ é composta por variáveis aleatórias independentes e identicamentes distribuídas (i.i.d) retiradas desse processo:

$$z_i \sim P(Z).$$

Nesta visão, o PGD é o "mecanismo" que dita:

1. A Região de Suporte: Quais valores são possíveis de ocorrer?
2. A Densidade: Com que frequência cada valor ocorre?
3. As Dependências: Como o corrência de X altera a probabilidade de Y?

1.2 Pacote Necessários

Neste capítulo iremos utilizar os pacotes `R` `tidyverse`(Wickham et al., 2019) e `moderndive` (Kim; Ismay; Kuhn, 2021). Por exemplo, para instalar o pacote basta usar `install.packages("tidyverse")` e podemos carregar o pacote por meio do comando `library(tidyverse)`. São carregados, de uma só vez, os seguinte pacotes amplamente utilizados em ciência de dados:

- `ggplot2` para visualização de dados;
- `dplyr` para manipulação de dados;
- `tidyr` para converter dados para o formato "tidy";
- `readr` para importar dados de planilhas para o `R`,

além dos pacotes mais avançados `purrr`, `tibble`, `stringr` e `forcats`.

```
library(tidyverse)
library(moderndive)
```

1.3 Experimento em Sala de Aula

Iremos realizar o seguinte experimento em sala de aula:

1. Organização

- A turma é dividida em grupos independentes (por exemplo, 20 grupos).
- Cada grupo realiza uma única amostragem.

2. Protocolo experimental (por grupo)

- A urna é misturada cuidadosamente, garantindo aleatoriedade.
- O grupo retira uma amostra de tamanho fixo n (por exemplo, $n = 50$) sem reposição durante a retirada.
- As bolas retiradas são observadas e classificadas por cor.

- O grupo registra:
  - R : o número de bolas vermelhas na amostra;
  - $\hat{p} = R/n$: proporção amostral de bolas vermelhas.
- Todas as bolas são devolvidas à urna.
- A urna é novamente misturada antes da próxima amostragem.

Cada grupo deve atuar de forma independente, sem acesso aos resultados dos demais.

3. Coleta e organização dos dados

- Cada grupo fornece sua estimativa de $\hat{p}$.
- O conjunto de estimativas é reunido em uma tabela ou planilha.
- A proporções são representadas graficamente por meio de um histograma.

Esse histograma representa a distribuição amostral da proporção para uma tamanho de amostra fixo n.

Verificação de aprendizagem

1. Por que foi importante misturar a tigela antes de retirarmos as bolas?
2. Por que os 20 grupos de amigos não obtiveram todos o mesmo número de bolas vermelhas entre as 50 retiradas e, consequentemente, proporções diferentes de bolas vermelhas?

1.4 Experimento Virtual

No pacote `moderndive` existe um *data frame* chamado `bowl`. As linhas de `bowl` correspondem exatamente ao conteúdo da urna real apresentada em sala de aula.

```
bowl
```

```
# A tibble: 2,400 x 2
   ball_ID color
     <int> <chr>
 1       1 white
 2       2 white
 3       3 white
 4       4 red
```

```
 5        5 white
 6        6 white
 7        7 red
 8        8 white
 9        9 red
10       10 white
# i 2,390 more rows
```

Observe que `bowl` possui 2400 linhas, o que nos indica que a urna contém 2400 bolas de mesmo tamanho. A primeira variável, `ball_ID`, é usada como uma variável de identificação, conforme discutido em sala de aula, nenhuma das bolas da urna real possui números marcados. A segunda variável, `color`, indica se uma determinada bola virtual é **vermelha** ou **branca**. Visualize o conteúdo de `bowl` no **visualizador de dados do RStudio** e percorra as linhas para se convencer de que `bowl` é, de fato, um **análogo virtual** da urna real apresentada em sala.

Agora precisamos de um **análogo virtual da pá** para gerar **amostras virtuais de 50 bolas**. Para isso, vamos utilizar a função `rep_sample_n()`, incluída no pacote `moderndive`. Essa função permite realizar **amostragens repetidas (ou replicadas)** de tamanho (n).

```r
set.seed(2026) #fixando semente
pa_virtual <- bowl %>%
rep_sample_n(size = 50)

pa_virtual
```

```
# A tibble: 50 x 3
# Groups:   replicate [1]
   replicate ball_ID color
       <int>   <int> <chr>
 1         1     733 white
 2         1     993 red
 3         1    2342 red
 4         1    1647 white
 5         1    1883 red
 6         1     164 red
 7         1    1200 red
 8         1     389 white
 9         1     287 white
10         1    2362 red
# i 40 more rows
```

A variável `ball_ID` identifica quais das 2400 bolas do objeto `bowl` foram incluídas na nossa amostra de 50 bolas, enquanto `color` indica a cor de cada bola. No entanto, o que indica a variável `replicate`?

No caso de `pa_virtual`, a variável `replicate` é igual a 1 em todas as 50 linhas. Isso nos informa que essas 50 linhas correspondem à nossa primeira amostra. Veremos em breve que, quando realizarmos 20 amostragens virtuais, a variável `replicate` assumirá valores entre 1 e 20.

Vamos agora calcular a **proporção de bolas vermelhas** em nossa amostra virtual utilizando os verbos de manipulação de dados do `dplyr`. Primeiro, para cada uma das 50 bolas amostradas, vamos identificar se ela é vermelha ou não, utilizando um teste de igualdade com `==`. Em seguida, criaremos uma nova variável booleana `is_red` usando a função `mutate()`:

```
pa_virtual <- pa_virtual %>%
mutate(is_red = (color == "red"))

pa_virtual
```

```
# A tibble: 50 x 4
# Groups:   replicate [1]
   replicate ball_ID color is_red
       <int>   <int> <chr> <lgl>
 1         1     733 white FALSE
 2         1     993 red   TRUE
 3         1    2342 red   TRUE
 4         1    1647 white FALSE
 5         1    1883 red   TRUE
 6         1     164 red   TRUE
 7         1    1200 red   TRUE
 8         1     389 white FALSE
 9         1     287 white FALSE
10         1    2362 red   TRUE
# i 40 more rows
```

Observe que, para cada linha em que `color == "red"`, é retornado o valor lógico (booleano) `TRUE`, e para cada linha em que `color` não é igual a `"red"`, é retornado o valor lógico `FALSE`.

Em seguida, vamos calcular o número de bolas vermelhas, dentre as 50, utilizando a função `summarize()`. Note que `summarize()` recebe um *data frame* com várias linhas e retorna um *data frame* com **uma única linha**, contendo estatísticas-resumo, como `mean()` ou `median()`. Neste caso, utilizaremos a função `sum()`:

```r
n_red <- pa_virtual %>%
mutate(is_red = (color == "red")) %>%
summarize(num_red = sum(is_red))

n_red
```

```
# A tibble: 1 x 2
  replicate num_red
      <int>   <int>
1         1      16
```

Por que isso funciona? Porque o `R` trata `TRUE` como o número 1 e `FALSE` como o número 0. Assim, somar valores `TRUE` e `FALSE` é equivalente a somar 1's e 0's. Ao final, essa operação conta o número de bolas para as quais a variável color é igual a "red". No nosso caso, XX das 50 bolas eram vermelhas. No entanto, você pode ter obtido um número diferente de bolas vermelhas devido ao caráter aleatório da amostragem virtual.

Por fim, vamos calcular a proporção das 50 bolas amostradas que são vermelhas, dividindo num_red por 50:

```r
n_prop_red <- pa_virtual %>%
mutate(is_red = color == "red") %>%
summarize(num_red = sum(is_red)) %>%
mutate(prop_red = num_red / 50)

n_prop_red
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
      <int>   <int>    <dbl>
1         1      16     0.32
```

Em outras palavras, 16 das bolas dessa amostra virtual eram vermelhas. Vamos tornar esse código um pouco mais **compacto e conciso**, combinando as etapas de `mutate()` e `summarize()` da seguinte forma:

```r
n_prop_red <- pa_virtual %>%
summarize(num_red = sum(color == "red")) %>%
mutate(prop_red = num_red / 50)

n_prop_red
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
      <int>   <int>    <dbl>
1         1      16     0.32
```

Ótimo! 16 das 50 bolas da pá virtual eram vermelhas! Assim, com base nessa amostra específica de 50 bolas, nossa estimativa da proporção de bolas vermelhas na urna é 0.32. Porém, lembre-se da atividade de amostragem realizada em sala de aula: se repetirmos essa amostragem, não necessariamente obteremos novamente o valor de 0.32. É provável que haja alguma variação. De fato, nossos 20 grupos de amigos calcularam 20 proporções desse tipo, cuja distribuição visualizamos em sala de aula, e vimos que essas estimativas variaram.

Vamos agora realizar o **análogo virtual** de ter 20 grupos de estudantes usando a pá de amostragem!

Lembre-se de que, no exercício de amostragem realizada em sala de aula, tivemos **20 grupos de estudantes**, cada um utilizando a pá, o que resultou em **20 amostras de tamanho 50**. Em seguida, usamos essas 20 amostras para calcular **20 proporções**. Em outras palavras, **repetimos/replicamos o uso da pá 20 vezes**.

Podemos realizar essa amostragem repetida/replicada de forma virtual utilizando novamente a função `rep_sample_n()`, mas agora adicionando o argumento `reps = 20`. Isso indica ao `R` que desejamos repetir a amostragem 20 vezes.

Vamos salvar esses resultados em um `data frame` chamado `virtual_samples`. Embora apresentemos a seguir uma prévia das primeiras 10 linhas de `virtual_samples`, recomendamos fortemente que você explore todo o seu conteúdo utilizando o visualizador de planilhas do `RStudio`, executando o comando `View(virtual_samples)`.

```r
set.seed(2026)
amostra_virtual <- bowl %>%
rep_sample_n(size = 50, reps = 20)

amostra_virtual
```

```
# A tibble: 1,000 x 3
# Groups:   replicate [20]
   replicate ball_ID color
       <int>   <int> <chr>
 1         1     733 white
 2         1     993 red
 3         1    2342 red
 4         1    1647 white
 5         1    1883 red
```

```
 6          1     164 red
 7          1    1200 red
 8          1     389 white
 9          1     287 white
10          1    2362 red
# i 990 more rows
```

Observe, no visualizador de planilhas, que as primeiras 50 linhas da variável `replicate` são iguais a 1, enquanto as 50 linhas seguintes de `replicate` são iguais a 2. Isso nos indica que as primeiras 50 linhas correspondem à primeira amostra de 50 bolas, enquanto as próximas 50 linhas correspondem à segunda amostra de 50 bolas. Esse padrão se repete para todas as 20 replicações (`reps = 20`) e, portanto, o `data frame amostra_virtual` possui ($20 \times 50 = 1000$) linhas.

Vamos agora usar `amostra_virtual` para calcular as 20 proporções de bolas vermelhas resultantes. Utilizaremos os mesmos verbos do `dplyr` de antes, mas agora com um `group_by()` adicional na variável `replicate`. Ao definir previamente a variável de agrupamento como *metadado* antes de aplicar `summarize()`, obteremos 20 proporções diferentes de bolas vermelhas. A seguir, exibimos uma prévia das primeiras 10 das 20 linhas resultantes:

```r
virtual_prop_red <- amostra_virtual %>%
group_by(replicate) %>%
summarize(red = sum(color == "red")) %>%
mutate(prop_red = red / 50)

virtual_prop_red
```

```
# A tibble: 20 x 3
   replicate   red prop_red
       <int> <int>    <dbl>
 1         1    16     0.32
 2         2    22     0.44
 3         3    19     0.38
 4         4    27     0.54
 5         5    18     0.36
 6         6    19     0.38
 7         7    16     0.32
 8         8    17     0.34
 9         9    21     0.42
10        10    20     0.4
11        11    23     0.46
12        12    23     0.46
```

```
13          13     15      0.3
14          14     23      0.46
15          15     27      0.54
16          16     23      0.46
17          17     17      0.34
18          18     21      0.42
19          19     15      0.3
20          20     18      0.36
```

Assim como ocorreu com as 20 amostras coletadas em sala de aula, há variação nas 20 proporções de bolas vermelhas obtidas virtualmente. Vamos visualizar essa variação por meio de um histograma. Note que também adicionamos os argumentos `binwidth = 0.05` e `boundary = 0.4`.

Lembre-se de que definir `boundary = 0.4` garante um esquema de classes em que um dos limites dos intervalos esteja em 0,4. Como o `binwidth = 0.05` também foi especificado, isso criará intervalos com limites em **0,30, 0,35, 0,40, 0,45, 0,50**, entre outros.

```
ggplot(virtual_prop_red, aes(x = prop_red)) +
geom_histogram(binwidth = 0.05, boundary = 0.4, color = "white") +
labs(x = "Proporção das 50 bolas que são vermelhas", y = "Frequência",
title = "Disttribuição das proporções")
```

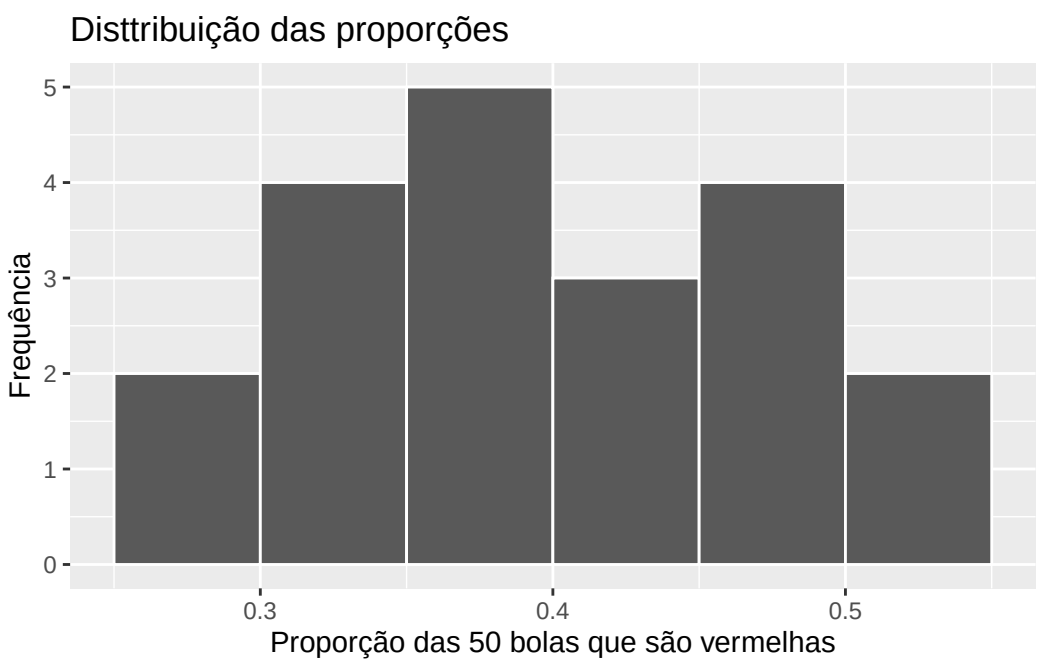

Observe que, ocasionalmente, obtivemos proporções de bolas vermelhas inferiores a 30%. Por outro lado, em alguns casos, obtivemos proporções superiores a 50%. No entanto, as proporções que ocorreram com maior frequência ficaram entre 35% e 40% (em **5 das 20 amostras**). Por que temos essas diferenças nas proporções de bolas vermelhas? **Por causa da variação amostral**.

Verificação de aprendizagem

1. Por que não foi possível estudar os efeitos da variação amostral quando utilizamos a pá virtual apenas uma vez? Por que foi necessário coletar **mais de uma amostra virtual** (no nosso caso, **20 amostras virtuais**)?

Lista Semanal Obrigatória

1. Agora suponha que queiramos estudar os efeitos da variação amostral não para 20 amostras, mas para um número maior, digamos 1000 amostras. Vamos novamente utilizar a função `rep_sample_n()`, com o tamanho da amostra definido como 50, mas agora com o número de repetições `reps` definido como 1000.
2. Temos 1000 réplicas de `prop_red`, a proporção de bolas vermelhas em amostras de 50 bolas. Utilizando o mesmo código de antes, vamos agora visualizar a distribuição dessas 1000 réplicas de `prop_red` por meio de um histograma.
3. Observando o histograma produzido no item 2), você diria que amostrar 50 bolas em que 30% são vermelhas é provável ou improvável? E quanto a amostrar 50 bolas em que 10% são vermelhas?

1.5 Conceitos Importantes

Primeiramente, uma **população** é um conjunto de indivíduos ou observações de interesse. Isso também é comumente denominado **população de estudo**. Denotamos matematicamente o tamanho da população utilizando a letra maiúscula N.

Um **parâmetro populacional** é algum resumo numérico sobre a população que é desconhecido, mas que você gostaria de saber. Por exemplo, quando essa quantidade é uma média, como a altura média de todos os canadenses, o parâmetro populacional de interesse é a média populacional.

Um **censo** é uma enumeração exaustiva ou contagem de todos os N indivíduos da população. Fazemos isso para calcular o valor exato do parâmetro populacional. Vale notar que, à medida que o número N de indivíduos em nossa população aumenta, a realização de um censo se torna mais cara (em termos de tempo, energia e dinheiro).

Na nossa atividade de amostragem, a **população (de estudo)** é o conjunto de $N = 2400$ bolas vermelhas e brancas, todas de mesmo tamanho, contidas na urna. Lembre-se de que também representamos a urna "virtualmente" no data frame `bowl`.

```
bowl
```

```
# A tibble: 2,400 x 2
   ball_ID color
     <int> <chr>
 1       1 white
 2       2 white
 3       3 white
 4       4 red
 5       5 white
 6       6 white
 7       7 red
 8       8 white
 9       9 red
10      10 white
# i 2,390 more rows
```

O **parâmetro populacional** aqui é a proporção de bolas na urna que são vermelhas. Sempre que estamos interessados em uma proporção de algum valor em uma população, o parâmetro populacional tem um nome específico: a proporção populacional. Comumente denotamos as proporções populacionais com a letra p.

Para calcular essa proporção populacional p de forma exata, precisamos primeiro realizar um censo, analisando todos os $N = 2400$ e contando o número de bolas vermelhas. Em seguida, dividimos essa contagem por 2400 para obter a proporção de vermelhas.

Você pode estar se perguntando agora: "Espere. Eu entendo que realizar um censo na urna real levaria muito tempo. Mas não podemos realizar um censo"virtual" usando a urna virtual?" Você está absolutamente correto! De fato, quando os autores do pacote `moderndive` criaram o data frame `bowl`, eles fizeram com que seu conteúdo correspondesse ao da urna real não fazendo um censo, mas lendo o conteúdo escrito na caixa em que a urna veio! Vamos realizar este censo "virtual" usando os mesmos códigos do pacote `dplyr` que você usou anteriormente para contar o número de bolas que são vermelhas:

```
bowl %>%
  summarize(red = sum(color == "red"))
```

```
# A tibble: 1 x 1
```

```
    red
  <int>
1   900
```

Como 900 das 2400 são vermelhas, a proporção é 900/2400 = 0,375 = 37,5%. Portanto, sabemos o valor do parâmetro populacional: em nosso caso, a proporção populacional p é igual a 0,375.

Neste ponto, você pode estar se perguntando: *"Se tínhamos uma maneira de saber que a proporção de bolas vermelhas é de 37,5%, então por que fizemos alguma amostragem?"* Ótima pergunta! Normalmente, você não faria amostragem alguma! No entanto, as atividades de amostragem que fizemos neste capítulo são meras simulações de como a amostragem é feita na vida real! Realizamos essas simulações a fim de estudar:

1. O efeito da variação amostral (ou variabilidade de amostragem) em nossas estimativas.
2. O efeito do tamanho da amostra na variação amostral.

Como veremos adiante em pesquisas de opinião, na amostragem da vida real não apenas o tamanho da população N será muito grande, tornando um censo caro, mas, às vezes, nem sequer saberemos qual é o tamanho da população! Por enquanto, no entanto, prosseguiremos com nosso próximo conjunto de termos e notação.

Amostragem é o ato de coletar uma amostra da população, o que geralmente fazemos apenas quando não podemos realizar um censo. Denotamos matematicamente o tamanho da amostra usando o n minúsculo, em oposição ao N maiúsculo, que denota o tamanho da população. Normalmente, o tamanho da amostra n é muito menor que o tamanho da população N. Assim, a amostragem é uma alternativa muito mais barata do que a realização de um censo.

Uma **estimativa pontual**, também conhecida como estatística (ou estatística amostral), é uma estatística calculada a partir de uma amostra que estima o parâmetro populacional desconhecido.

Então, em sala de aula, realizamos a amostragem usando uma pá com 50 espaços para extrair amostras de tamanho $n = 50$. Para realizar o análogo virtual desta amostragem, lembre-se de que usamos a função `rep_sample_n()` da seguinte maneira:

```r
set.seed(2026)
pa_virtual <- bowl %>%
  rep_sample_n(size = 50)
```

Usando a amostra de 50 bolas contidas em `pa_virtual`, geramos uma estimativa da proporção de bolas na urna que são vermelhas, `prop_red`.

```r
pa_virtual %>%
  summarize(num_red = sum(color == "red")) %>%
  mutate(prop_red = num_red / 50)
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
      <int>   <int>    <dbl>
1         1      16     0.32
```

Então, em nosso caso, o valor de `prop_red` é a estimativa pontual da proporção populacional p, pois ela estima o valor desta última. Além disso, essa estimativa pontual tem um nome específico quando se considera proporções: **a proporção amostral**. Ela é denotada usando $\hat{p}$, porque é uma convenção comum em estatística usar um símbolo de "chapéu" para denotar estimativas pontuais.

Iremos observa ao longo desta disciplina que a maneira como você coleta as amostras influencia diretamente a qualidade delas.

- Diz-se que uma amostra é **representativa** se ela "se parecer" aproximadamente com a população. Em outras palavras, se as características da amostra forem uma "boa" representação das características da população.
- Dizemos que uma amostra é **generalizável** se quaisquer resultados baseados na amostra puderem ser generalizados para a população. Em outras palavras, se pudermos fazer "bons" palpites sobre a população usando a amostra.
- Dizemos que um procedimento de amostragem é **viesado** (ou tendencioso) se certos indivíduos em uma população tiverem uma chance maior de serem incluídos em uma amostra do que outros. Dizemos que um procedimento de amostragem é **não viesado** (ou imparcial) se cada indivíduo em uma população tiver chances iguais de ser amostrado.

Dizemos que uma amostra de n bolas extraídas usando nossa pá é **representativa** da população se o seu conteúdo "se assemelhar aproximadamente" ao conteúdo da urna. Se sim, então a proporção de bolas vermelhas da pá pode ser **generalizada** para a proporção das $N = 2400$ bolas da urna que são vermelhas. Ou expresso de forma diferente, $\hat{p}$ é um "bom palpite" de p. Agora digamos que trapaceamos ao usar a pá e removemos um número de bolas brancas em favor de bolas vermelhas. Então, essa amostra seria viesada em relação às bolas vermelhas e, portanto, a amostra não seria mais representativa da urna.

Uma maneira de garantir que uma amostra seja não viesada e representativa da população é usar a **amostragem aleatória**. Temos que **Inferência** é o ato de "dar um palpite" sobre algo desconhecido. Portanto, **Inferência estatística** é o ato de fazer um palpite sobre uma população usando uma amostra.

Em nosso caso, como a função `rep_sample_n()` usa o gerador de números aleatórios do seu computador, estávamos, de fato, realizando "amostragem aleatória".

2 Distribuições Amostrais

2.1 Introdução

O que é a estatística? Consiste em três grandes áreas:

- **Coleta de Dados:** planos amostrais e desenhos experimentais.
- **Estatística Descritiva:** resumos numéricos e gráficos dos dados coletados a partir de uma amostra.
- **Estatística Inferencial:** estimação, intervalos de confiança e testes de hipóteses sobre parâmetros de interesse.

Os procedimentos estatísticos fazem parte (passos 2 a 5 abaixo) do Método Científico, inicialmente defendido por Sir Francis Bacon (1561-1626), que escreveu *"aprender os segredos da natureza envolve coletar dados e realizar experimentos"*.

A metodologia moderna:

1. Observar algum fenômeno.
2. Formular uma hipótese que explique o fenômeno.
3. Coletar dados.
4. Testar: Os dados suportam a hipótese?
5. Conclusão. Se o teste falhar, volte ao passo 2.

> *"As estatísticas não mentem, mas os mentirosos usam estatísticas."* — Mark Twain.

2.1.1 O que é a Estatística Matemática?

É o estudo dos fundamentos teóricos da estatística.

O que é uma estatística?

Seja $X_1, X_2, ..., X_n$ um conjunto de variáveis aleatórias observáveis (como, por exemplo, uma amostra aleatória de n indivíduos de uma população de interesse). Uma estatística T é uma função aplicada a essa amostra:

$$T = \mathcal{T}(X_1, X_2, ..., X_n)$$

População vs. Amostra

- **População:** O grupo inteiro de indivíduos (sujeitos ou unidades), que pode ser existente ou conceitual, sobre o qual pretendemos obter informação.
- **Amostra:** Uma parte da população a partir da qual os dados são recolhidos.

Parâmetro vs. Estatística

Parâmetro: Um valor numérico calculado a partir de *todos* os indivíduos na população. *(Discreta / Contínua)*

- **Média populacional:** $\mu = \sum xP(x)$ ou $\int xf(x)dx$.
- **Variância populacional:** $\sigma^2 = \sum(x-\mu)^2P(x)$ ou $\int(x-\mu)^2f(x)dx$.
- **Proporção populacional:** p é a verdadeira proporção de 1s na população.
- **Mediana populacional:** $\phi_{.5}$ é o valor tal que $P(X \leq \phi_{.5}) \geq .5$ e $P(X \geq \phi_{.5}) \geq .5$.

Estatística: Um valor numérico calculado a partir de uma *amostra* $X_1, ..., X_n$.

- **Média amostral:** $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$.
- **Variância amostral:** $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$.
- **Proporção amostral:** $\hat{p} = \frac{\text{número de 1s}}{n}$.
- **Mediana amostral:** $\hat{\phi}_{.5}$ = valor central (ou média dos centrais).

2.2 Distribuições Amostrais

O valor de uma estatística varia de amostra para amostra. Por outras palavras, amostras diferentes resultarão em valores diferentes para uma estatística. Portanto, uma estatística é uma variável aleatória com uma distribuição!

Distribuição Amostral: A distribuição dos valores da estatística provenientes de todas as amostras possíveis de tamanho n.

O Método de 'Força Bruta' para construir uma Distribuição Amostral

Para entender a origem de uma distribuição amostral, imagine o seguinte processo exato (ou de "força bruta"):

1. **Retirar todas as amostras possíveis** de tamanho n da população.
2. **Calcular o valor da estatística** (por exemplo, a média $\overline{X}$) para cada uma dessas amostras.

3. **Exibir a distribuição** dos valores dessa estatística na forma de uma tabela, de um gráfico (histograma) ou de uma equação.

Na prática, como as populações costumam ser imensas (ou infinitas), é impossível calcular *todas* as amostras possíveis. É por isso que dependemos de teoremas matemáticos (como o Teorema Central do Limite) para deduzir o formato dessa distribuição sem precisarmos usar a força bruta!

2.2.1 Distribuição Amostral da Média ($\overline{X}$)

Na estatística inferencial, é comum utilizar a estatística $\overline{X}$ para estimar μ.

Média e Variância: Para qualquer tamanho de amostra n e uma Amostra Aleatória Simples (AAS) proveniente de qualquer distribuição populacional com média μ_x e variância σ_x^2:

$$E(\overline{X}) = \mu_x \left(E\left(\sum_{i=1}^{n} X_i\right) = n\mu_x \right) \quad \text{e} \quad Var(\overline{X}) = \frac{\sigma_x^2}{n} \left(E\left(\sum_{i=1}^{n} X_i\right) = n\sigma_x^2 \right).$$

Para compreendermos como a média amostral se comporta, utilizamos as seguintes propriedades das combinações lineares:

Teorema 1: Combinações Lineares

Sejam a_i para $i = 1, 2, ..., k$ constantes e sejam X_i para $i = 1, 2, ..., k$ variáveis aleatórias. Então:

1. **Esperança:** $E\left(\sum_{i=1}^{k} a_i X_i\right) = \sum_{i=1}^{k} a_i E(X_i)$
2. **Variância:** $Var\left(\sum_{i=1}^{k} a_i X_i\right) = \sum_{i=1}^{k} a_i^2 Var(X_i)$ (se $X_1, ..., X_k$ forem mutuamente independentes).

Quando os dados são normais: Para uma AAS proveniente de uma distribuição normal $N(\mu_x, \sigma_x^2)$:

$$\overline{X} \sim N\left(\mu_x, \frac{\sigma_x^2}{n}\right).$$

Exemplo: Suponha que os níveis de colesterol de homens adultos sigam uma distribuição $N(210\,\text{mg/dL}, (37\,\text{mg/dL})^2)$.

1. Indique um intervalo centrado na média μ que capture os 95% centrais de todos os valores de colesterol.
2. Indique a distribuição amostral de $\overline{X}$, a média amostral dos valores de colesterol obtidos a partir de AAS (Amostras Aleatórias Simples) de tamanho $n = 10$.

3. Indique um intervalo centrado na média μ que capture os 95% centrais de todos os valores de média amostral de colesterol obtidos a partir de AAS de tamanho $n = 10$.

Para amostras de grandes dimensões (Teorema Central do Limite):

Para um grande tamanho de amostra n e uma AAS proveniente de *qualquer* distribuição populacional com variância finita $\sigma_x^2 < \infty$, as distribuições amostrais aproximadas são:

$$\overline{X} \dot{\sim} N\left(\mu_x, \frac{\sigma_x^2}{n}\right) \quad \text{e} \quad \sum_{i=1}^{n} X_i \dot{\sim} N\left(n\mu_x, n\sigma_x^2\right).$$

Este último resultado é consequência do famoso Teorema Central do Limite.

Sejam $X_1, \ldots, X_n$ uma AAS de uma distribuição com média μ_x e variância $\sigma_x^2 < \infty$. Então a distribuição de

$$U_n = \frac{\overline{X} - \mu_x}{\sigma_x/\sqrt{n}},$$

converge para $N(0,1)$ a medida que $n \to \infty$. Provaremos esse teorema mais à frente.

Exemplo Importante (Ensaios de Bernoulli):

Seja $X = \begin{cases} 1 & \text{se } _____ \text{ com probabilidade } p: _____ \\ 0 & \text{se } _____ \text{ com probabilidade } 1-p: _____ \end{cases}$

Então, dizemos que X segue uma distribuição de Bernoulli:

$$X \sim \text{Bern}(p) = \text{Bin}(n = 1, p).$$

(a) Desenhe uma representação gráfica da função de massa de probabilidade de X.

(b) Encontre $E(X)$ e $Var(X)$.

(c) Suponha que foi recolhida uma Amostra Aleatória Simples (AAS) $X_1, X_2, \ldots, X_{40}$. Indique a distribuição amostral aproximada de $\overline{X}$ (geralmente denotada por $\hat{p} = \overline{X}$, o que indica que $\overline{X}$ é uma proporção amostral).

2.2.1.1 Aproximação Normal da Binomial

No exemplo anterior, consideramos a variável aleatória $X \sim \text{Bern}(p) = \text{Bin}(n = 1, p)$. Suponha que uma Amostra Aleatória Simples (AAS) $X_1, X_2, \ldots, X_n$ foi coletada com $n > 1$.

(a) Apresente a distribuição de $Y = \sum_{i=1}^{n} X_i$, de modo que Y seja o número de sucessos em n tentativas (que é uma distribuição discreta que você aprendeu em Métodos Probabilísticos).

(b) Desenhe um gráfico da função de probabilidade (pdf) de $Y = \sum_{i=1}^{n} X_i$.

(c) Forneça o valor de $E(Y)$ e $Var(Y)$:

$$\begin{cases} E(Y) = _____ \\ Var(Y) = _____ \end{cases}$$

(d) No Exemplo #1c, o Teorema Central do Limite (TCL) mostrou que para qualquer tamanho de amostra n, quando $X \sim \text{Bern}(p)$, então:

$$\hat{p} = \bar{X} \dot{\sim} N(_____, _____).$$

(e) Além das médias $\bar{X}$, o Teorema Central do Limite também fornece a distribuição amostral aproximada de uma soma $\sum X_i$. Use o TCL para fornecer a distribuição amostral aproximada de $Y = \sum_{i=1}^{n} X_i$:

$$Y \dot{\sim} N(_____, _____).$$

(f) Se a proporção real de apoiadores da reforma da saúde na população de Fortaleza é $p = 0,53$, então, em uma AAS de cidadãos de Fortaleza de tamanho $n = 1000$, qual é a probabilidade de que menos de 500 prometam apoio?

2.2.2 Distribuição Amostral da Variância (S^2)

Um parâmetro populacional de interesse comum é a variância populacional σ^2. Na estatística inferencial, é comum usar a estatística S^2 para estimar σ^2. Portanto, a distribuição amostral de S^2 é de grande interesse.

Distribuição Qui-quadrado (χ^2)

A soma dos quadrados de variáveis normais padrão independentes é distribuída como uma variável aleatória χ^2. Mais formalmente:

- Se $Z_1, \dots, Z_\nu$ são independentes e distribuídos como $N(0,1)$, então:

$$\sum_{i=1}^{\nu} Z_i^2 \sim \chi^2(\nu),$$

em que $\chi^2(\nu)$ é chamada de **distribuição qui-quadrado com ν graus de liberdade**.

- Para qualquer tamanho de amostra n e uma AAS $X_1, X_2, \dots, X_n$ de uma

distribuição normal $N(\mu_x, \sigma_x^2)$:

$$\sum_{i=1}^{n} \left(\frac{X_i - \mu_x}{\sigma_x} \right)^2 \sim \chi^2(n)$$

Nota: Use a Tabela do SIGAA para cálculos de probabilidade.

2.2.2.1 Média e Variância

Se $C \sim \chi^2(\nu)$, então:

$$\begin{cases} E(C) = \nu; \\ Var(C) = 2\nu. \end{cases}$$

Para qualquer tamanho de amostra $n > 1$ e uma AAS $X_1, X_2, \dots, X_n$ de qualquer distribuição populacional com média μ_x e variância σ_x^2:

- $E(S^2) = \sigma_x^2$.
- $Var(S^2) = \frac{2\sigma_x^4}{n-1}$.

2.2.2.2 Distribuição Amostral quando os dados são Normais

Para qualquer tamanho de amostra $n > 1$ e uma AAS $X_1, X_2, \dots, X_n$ originada de uma distribuição normal $N(\mu_x, \sigma_x^2)$:

$$\frac{(n-1)S^2}{\sigma_x^2} \sim \chi^2(n-1).$$

2.2.3 Distribuição Amostral de $\frac{\overline{X}-\mu}{S/\sqrt{n}}$

Na estatística inferencial, a estatística de teste $\frac{\bar{X}-\mu}{S/\sqrt{n}}$ é frequentemente utilizada para determinar a quantos erros padrões $(S/\sqrt{n})$ a média amostral $\bar{X}$ está de um valor hipotético μ. Portanto, a distribuição amostral desta razão é de extrema importância.

Distribuição t de Student

Definição 2.1: Se $Z \sim N(0,1)$, $W \sim \chi^2(\nu)$, e Z e W são independentes, então:

$$T = \frac{Z}{\sqrt{W/\nu}} \sim t(\nu),$$

em que $t(\nu)$ é chamada de **distribuição t com ν graus de liberdade**.
Se $T \sim t(\nu)$, então:

- $E(T) = 0$ para $\nu > 1$.
- $Var(T) = \frac{\nu}{\nu-2}$ para $\nu > 2$.

2.2.3.1 Distribuição Amostral quando os dados são Normais

Para qualquer tamanho de amostra $n > 1$ e uma AAS $X_1, X_2, \dots, X_n$ de uma $N(\mu, \sigma^2)$:

- $\bar{X}$ e S^2 são independentes.
- Pelos Teoremas 2.1, 2.3 e Definição 2.1:

$$\frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

2.2.3.2 Distribuição Amostral para Grandes Amostras

Para um tamanho de amostra **GRANDE** n e uma AAS $X_1, X_2, \dots, X_n$ de qualquer distribuição populacional com média μ_x e variância $\sigma_x^2 < \infty$:

$$T = \frac{\bar{X} - \mu_x}{S/\sqrt{n}} \dot{\sim} t(n-1).$$

Fatos Úteis

- **PDF de T:** A função densidade de probabilidade é dada por:

$$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})\sqrt{\nu\pi}} \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}.$$

- A distribuição t é simétrica em torno de 0 e possui formato de sino como a $N(0,1)$, porém com **caudas mais pesadas** (mais grossas).
- Conforme $\nu \to \infty$, a distribuição $t(\nu)$ aproxima-se da distribuição normal padrão.
- Use a Tabela do SIGAA para cálculos de probabilidade.

2.2.3.3 Exemplos

Suponha que os níveis de colesterol em homens adultos sejam distribuídos como $N(210 \text{ mg/dL}, \sigma^2)$.

1. Forneça a distribuição amostral de $\frac{\bar{X}-\mu}{S/\sqrt{n}}$, onde as estatísticas $\bar{X}$ e S^2 são calculadas a partir de uma AAS de tamanho $n = 10$.
2. Se $S^2 = 36,5^2$, forneça um intervalo centrado na média μ que capture os 95% centrais de todos os valores de médias amostrais de colesterol obtidos de AAS de tamanho $n = 10$.

2.2.4 Distribuição Amostral do Razão de Variâncias

Na estatística inferencial, frequentemente o interesse recai sobre a comparação das variâncias σ_1^2 e σ_2^2 de duas populações distintas para determinar se são diferentes. Com base em duas Amostras Aleatórias Simples (AAS), uma de tamanho n_1 com variância amostral S_1^2 e outra de tamanho n_2 com variância amostral S_2^2, a estatística $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$ é utilizada.

Distribuição F

Definição 2.2: Se $W_1 \sim \chi^2(\nu_1)$ e $W_2 \sim \chi^2(\nu_2)$ são independentes, então:

$$F = \frac{W_1/\nu_1}{W_2/\nu_2} \sim F(\nu_1, \nu_2).$$

A distribuição $F(\nu_1, \nu_2)$ possui ν_1 **graus de liberdade no numerador** e ν_2 **graus de liberdade no denominador**.
Se $F \sim F(\nu_1, \nu_2)$, então:

$$\begin{cases} E(F) = \dfrac{\nu_2}{\nu_2 - 2}, & \text{para } \nu_2 > 2; \\ Var(F) = \dfrac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}, & \text{para } \nu_2 > 4. \end{cases}$$

2.2.4.1 Distribuição Amostral quando os dados são Normais

Se $X_1, \dots, X_{n_1}$ é uma AAS de $N(\mu_1, \sigma_1^2)$ e $Y_1, \dots, Y_{n_2}$ é uma AAS independente de $N(\mu_2, \sigma_2^2)$, então as variáveis qui-quadrado são independentes:

$$W_1 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1 - 1) \quad \text{e} \quad W_2 = \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2 - 1).$$

Portanto,

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

2.2.5 Exemplo

A variância do tempo de reação de mulheres é diferente da variância do tempo de reação de homens? Jason Paulak (Universidade de Cincinnati) realizou um experimento *web* para responder a isso.

- **Mulheres** ($n_1 = 398$)**:** $\bar{X}_1 = 517$ ms, $S_1 = 899$ ms.
- **Homens** ($n_2 = 469$)**:** $\bar{X}_2 = 383,2$ ms, $S_2 = 335,7$ ms.

1. Forneça a distribuição amostral de $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$:
2. Se as duas variâncias populacionais forem de fato iguais ($\sigma_1^2 = \sigma_2^2$), qual é a probabilidade de observar uma razão de variâncias amostrais igual ou maior que a encontrada?

2.3 Prova do Teorema Central do Limite (TCL)

! Teorema do Limite Central

Seja $X_1, X_2, ..., X_n$ uma AAS de uma distribuição com média μ_x e variância $\sigma_x^2 < \infty$. Então:

$$\lim_{n\to\infty} U_n = \lim_{n\to\infty} \frac{\overline{X} - \mu_x}{\sigma_x/\sqrt{n}} = U \sim N(0,1).$$

2.3.0.1 A Prova do TCL

A demonstração baseia-se nas **Funções Geradoras de Momentos (FGM)**. O Teorema XX afirma que cada variável aleatória possui uma FGM única, $M(t)$, que a identifica. Para uma variável contínua Y com densidade $f(y)$, a FGM é:

$$M(t) = E(e^{tY}) = \int_{-\infty}^{\infty} e^{ty} f(y) dy.$$

2.3.1 Roteiro da Prova:

1. Usar a série de Taylor para encontrar a FGM de $Z_i = \frac{X_i - \mu}{\sigma}$.
2. Encontrar a FGM de $U_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$.
3. Mostrar que, conforme $n \to \infty$, a FGM de U_n converge para $e^{t^2/2}$.
4. Identificar $e^{t^2/2}$ como a FGM da Normal Padrão $N(0, 1)$.

2.3.1.1 Passo 1: A variável padronizada Z_i

Seja $Z_i = \frac{X_i - \mu}{\sigma}$. Aqui, a suposição de variância finita ($\sigma^2 < \infty$) é crucial.

(a) **Propriedades:** Mostre que $E(Z) = 0$ e $Var(Z) = E(Z^2) = 1$. *(Dica: Z é uma função linear de X).*

(b) **Momentos na Origem:** Mostre que:

- $M_Z(0) = 1$
- $M'_Z(0) = E(Z) = 0$
- $M''_Z(0) = E(Z^2) = 1$

(c) **Expansão de Taylor:** Expandindo $M_Z(t)$ em torno de $t = 0$ e avaliando em $t/\sqrt{n}$:

$$M_Z\left(\frac{t}{\sqrt{n}}\right) = 1 + \frac{(t/\sqrt{n})^2}{2!} + R\left(\frac{t}{\sqrt{n}}\right) = 1 + \frac{t^2}{2n} + R\left(\frac{t}{\sqrt{n}}\right).$$

em que $R\left(\frac{t}{\sqrt{n}}\right)$ representa o resto de termos cúbicos e de ordem superior.

(d) **Resto:** Mostre que o resto $\lim_{n\to\infty} \frac{R(t/\sqrt{n})}{(t/\sqrt{n})^2} = n \lim_{n\to\infty} R(t/\sqrt{n}) = 0$.

2.3.1.2 Passo 2: A FGM de U_n

Podemos escrever U_n como:

$$U_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} Z_i.$$

Como os X_i são uma AAS (independentes), a FGM da soma é o produto das FGMs:

$$M_{U_n}(t) = \prod_{i=1}^{n} M_{Z_i}\left(\frac{t}{\sqrt{n}}\right) = \left[M_Z\left(\frac{t}{\sqrt{n}}\right)\right]^n.$$

2.3.1.3 Passo 3: O Limite

Substituindo a expansão de Taylor:

$$M_{U_n}(t) = \left[1 + \frac{t^2}{2n} + R\left(\frac{t}{\sqrt{n}}\right)\right]^n.$$

Aplicando o limite $n \to \infty$ e usando o fato de que $\lim_{n\to\infty}(1 + \frac{a}{n})^n = e^a$, então:

$$\lim_{n\to\infty} M_{U_n}(t) = e^{t^2/2}.$$

(Use o fato que $\lim_{n\to\infty} \frac{R(t/\sqrt{n})}{(t/\sqrt{n})^2} = n \lim_{n\to\infty} R(t/\sqrt{n}) = 0$..

2.3.1.4 Passo 4: Reconhecimento da Distribuição

Se $U \sim N(0,1)$, então sua FGM é $M_U(t) = e^{t^2/2}$.

Prova rápida:

$$E(e^{tU}) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{tu} e^{-u^2/2} du.$$

Completando o quadrado no expoente: $tu - \frac{u^2}{2} = -\frac{1}{2}(u-t)^2 + \frac{t^2}{2}$.

$$E(e^{tU}) = e^{t^2/2} \underbrace{\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{(u-t)^2}{2}} du}_{1 \text{ (integral de uma FDP Normal)}} = e^{t^2/2}.$$

2.4 Lista

1. Considere que $Y \sim \text{Bin}(n = 5, p = 0,1)$.

(a) Use a função `pbinom()` do R para calcular $P(Y < 1)$.

(b) Qual distribuição normal aproxima esta distribuição binomial?

(c) Use a função `pnorm()` do R para utilizar a aproximação normal da binomial e calcular $P(Y < 1)$.

2. Suponha que $Y \sim \text{Bin}(n, p = 0,1)$. Encontre o menor tamanho de amostra n para que a probabilidade binomial exata $P(Y < 1)$ e a aproximação normal difiram por menos de $0,01$.

3.

(a) Enuncie o Teorema Central do Limite.
(b) Demonstre o Teorema Central do Limite.

4. Enuncie a Lei Fraca dos Grandes Números. Certifique-se de declarar todas as suposições e apresentar uma conclusão adequada.

3 Estimação Pontual

3.1 Estimador de Momentos

Este método de estimação é um dos métodos mais antigos de estimação. Ele é utilizado desde o século XVIII. A ideia é bem simples. Vamos inicialmente definir para o caso uniparamétrico:

Seja X uma variável aleatória com a seguinte f.d.p. ou f.p. , $f(x\ |\theta)$, suporte A , espaço paramétrico Θ e $E_\theta(X^r) < \infty,\ r = 1, 2, ...$

Seja a amostra aleatória $X_1, X_2, \dots, X_n$ de X . Vamos igualar o primeiro populacional ao primeiro momento amostral, isto é,

$$E_\theta(X) = \bar{X}.$$

Vamos fazer alguns exemplos para fixar o conceito calculando também sua variância amostral.

Exemplo 1: Considere $X \sim U((0, \theta)$ com

$$E_\theta(X) = \frac{\theta}{2} \quad \text{e} \quad V(X) = \frac{\theta^2}{12}.$$

Assim,

$$E_\theta(X) = \frac{\theta}{2} = \bar{X}.$$

O valor de θ é:

$$\theta = 2\bar{X}.$$

Assim o estimador pelo m?todo dos momentos de θ é dado por:

$$\hat{\theta} = T_1 = 2\bar{X}.$$

Note que:

$$E(\bar{X}) = \mu = \frac{\theta}{2}.$$

Assim

$$E(T_1) = E(2\bar{X}) = 2\ E(\bar{X}) = 2\ \frac{\theta}{2} = \theta,$$

T_1 é um estimador não viciado de θ.

Note que:

$$Var(\bar{X}) = \frac{\frac{\theta^2}{12}}{n} = \frac{\theta^2}{12n}.$$

Assim,

$$Var(T_1) = Var(2\bar{X}) = 4\ Var(\bar{X}) = 4\ \frac{\theta^2}{12n} = \frac{\theta^2}{3n}.$$

Exemplo 2: Considere $X \sim U_d(A), \quad A = \{1, 2, ..., \theta\}$

O espaço paramétrico é dado por:

$$\Theta = \{1, 2, ...\}.$$

Sabemos que:

$$E_\theta(X) = \frac{1+\theta}{2} \quad ; \ V(X) = \frac{\theta^2 - 1}{12}.$$

Assim,

$$E_\theta(X) = \frac{1+\theta}{2} = \bar{X}.$$

O valor de θ é:

$$\theta = 2\bar{X} - 1.$$

Assim o estimador pelo m?todo dos momentos de θ é dado por:

$$\hat{\theta} = T_2 = 2\bar{X} - 1.$$

Note que:

$$E(\bar{X}) = \mu = \frac{1+\theta}{2}.$$

Assim

$$E(T_2) = E(2\bar{X} - 1) = 2\ E(\bar{X}) - 1 = 2\ \frac{1+\theta}{2} - 1 = \theta,$$

T_2 é um estimador não viciado de θ.

Note que:

$$Var(\bar{X}) = \frac{\frac{\theta^2-1}{12}}{n} = \frac{\theta^2-1}{12n}.$$

Assim

$$Var(T_2) = Var(2\bar{X} - 1) = 4\ Var(\bar{X}) = 4\ \frac{\theta^2-1}{12n} = \frac{\theta^2-1}{3n}.$$

Exemplo 3: Seja $X \sim Normal(\mu, 9)$.

Sabemos que:

$$A = (-\infty, \infty)\ \ ;\ \ \Theta = (-\infty, \infty).$$

Além disso:

$$E_\mu = \mu\ \ ;\ \ V(X) = 9.$$

Logo,

$$E_\mu = \mu = \bar{X}.$$

Assim

$$\hat{\mu} = T_3 = \bar{X}$$

é o estimador pelo método dos momentos para μ.

Note que

$$E(T_3) = \mu \quad Var(T_3) = \frac{9}{n}.$$

Exemplo 4: Agora considere $X \sim Exponencial(\lambda)$.

Sabemos que:

$$A = (0, \infty) \ ; \ \Theta = (0, \infty).$$

Além disso:

$$E_\lambda = \frac{1}{\lambda} \ ; \ V(X) = \frac{1}{\lambda^2}.$$

O estimador pelo método dos momentos é dado por:

$$E_\lambda = \frac{1}{\lambda} = \bar{X}.$$

Logo,

$$\hat{\lambda} = T_4 = \frac{1}{\bar{X}}.$$

Sabemos que

$$S \sim Gama(n, \lambda).$$

Note que:

$$M_S(t) = \left[\frac{\lambda}{\lambda - t}\right]^n, \ t < \lambda.$$

A função geradora de momentos de $\bar{X}$ é dada por:

$$M_{\bar{X}}(t) = M_S(t/n) = \left[\frac{\lambda}{\lambda - t/n}\right]^n, \ t/n < \lambda.$$

$$M_{\bar{X}}(t) = \left[\frac{n\lambda}{n\lambda - t}\right]^n, \ t < n\lambda.$$

Assim

$$V = \bar{X} \sim Gama(n, n\lambda).$$

A densidade de V é dada por:

$$f_V(v) = \frac{(n\lambda)^n}{\Gamma(n)} v^{n-1}\ e^{-n\lambda v}\ \ I_A(v),\ A = (0, \infty).$$

Note que:

$$T_4 = \frac{1}{\bar{X}} = \frac{1}{V}.$$

Logo

$$E(T_4) = \int_0^\infty \frac{1}{v}\ \frac{(n\lambda)^n}{\Gamma(n)} v^{n-1}\ e^{-n\lambda v}\ dv$$

$$E(T_4) = \frac{(n\lambda)^n}{\Gamma(n)} \int_0^\infty v^{(n-1)-1}\ e^{-n\lambda v}\ dv.$$

$$E(T_4) = \frac{(n\lambda)^n}{\Gamma(n)}\ IGG(a = n-1, b = n\lambda, c = 1),$$

com $a = n - 1 > 0$ ou $n > 1$.

$$E(T_4) = \frac{(n\lambda)^n}{\Gamma(n)}\ \frac{\Gamma(n-1)}{(n\lambda)^{n-1}} = \frac{n\lambda}{n-1} = \frac{n}{n-1}\ \lambda \neq \lambda$$

Logo T_4 é um estimador viciado de λ. Mas ele é assintoticamente não viciado para λ.

Vamos calcular a variância de T_4:

$$E(T_4^2) = \int_0^\infty \frac{1}{v^2}\ \frac{(n\lambda)^n}{\Gamma(n)} v^{n-1}\ e^{-n\lambda v}\ dv$$

$$E(T_4^2) = \frac{(n\lambda)^n}{\Gamma(n)} \int_0^\infty v^{(n-2)-1}\ e^{-n\lambda v}\ dv.$$

$$E(T_4^2) = \frac{(n\lambda)^n}{\Gamma(n)}\ IGG(a = n-2, b = n\lambda, c = 1),$$

com $a = n - 2 > 0$ ou $n > 2$.

$$E(T_4^2) = \frac{(n\lambda)^n}{\Gamma(n)} \frac{\Gamma(n-2)}{(n\lambda)^{n-2}} = \frac{n^2\lambda^2}{(n-1)(n-2)} = \frac{n^2}{(n-1)(n-2)} \lambda^2$$

A variância de T_4 ? dada por:

$$Var(T_4) = \frac{n^2}{(n-1)(n-2)} \lambda^2 - \frac{n^2}{(n-1)^2} \lambda^2$$

$$Var(T_4) = \frac{n^2}{(n-1)^2(n-2)} \lambda^2$$

Note que

$$\lim_{n\to\infty} V(T_4) = 0,$$

assim T_4 é um estimador consistente para λ.

O próximo exemplo mostrará uma situação distinta das anteriores.

Exemplo 5: Seja $Y_i \sim Normal\left(\mu_i = \beta X_i, \sigma^2\right), i = 1, 2, \ldots, n,$; independentes com $X_i, i = 1, 2, \ldots, n$ constantes conhecidas.

Note que:

$$E(Y_i) = \beta X_i, i = 1, 2, \ldots, n.$$

Quando as variáveis não são identicamente distribuídas precisamos de uma definição alternativa para o estimador pelo método dos momentos:

$$\frac{\sum_{i=1}^{n} E(Y_i)}{n} = \bar{Y}.$$

Logo

$$\frac{\sum_{i=1}^{n} \beta X_i}{n} = \bar{Y}.$$

$$\beta \ \frac{\sum_{i=1}^{n} X_i}{n} = \bar{Y}.$$

$$\beta \bar{X} = \bar{Y}.$$

$$\hat{\beta} = \frac{\bar{Y}}{\bar{X}} = \frac{1}{n\bar{X}} \ \sum_{i=1}^{n} Y_i.$$

O estimador pelo método dos momentos é uma combinação linear de $Y_1, Y_2, \ldots, Y_n$.

Vamos mostrar que ele é não viciado.

$$E\left(\hat{\beta}\right) = \ \frac{1}{n\bar{X}} \ \sum_{i=1}^{n} E(Y_i) = \ \frac{1}{n\bar{X}} \ \sum_{i=1}^{n} \ \beta X_i.$$

$$E\left(\hat{\beta}\right) = \ \beta \ \frac{1}{n\bar{X}} \ \sum_{i=1}^{n} \ X_i = \beta.$$

Vamos calcular agora a variância:

$$Var\left(\hat{\beta}\right) = \ \frac{1}{n^2 \ \bar{X}^2} \ \sum_{i=1}^{n} V(Y_i) = \ \frac{1}{n^2 \ \bar{X}^2} \ n \ \sigma^2 = \frac{\sigma^2}{n \ \bar{X}^2}.$$

Exemplo 6 Seja $X \sim N(0, \sigma^2)$. Qual o estimador T pelo método dos momentos para σ^2?

Note que:

$$E(X) = 0 \ \ E(X^2) = \sigma^2.$$

$$T = \frac{\sum_{i=1}^{n} \ X_i^2}{n}.$$

Note que:

$$E(T) = \sigma^2.$$

$$Var(T) = \frac{1}{n^2} \sum_{i=1}^{n} V(X_i^2) = \frac{nV(X^2)}{n^2} = \frac{V(X^2)}{n}.$$

Mas

$$Var(X^2) = E(X^4) - E^2(X^2).$$

Sabemos que

$$Z^4 = \left[\frac{X-\mu}{\sigma}\right]^4 = \frac{X^4}{\sigma^4}.$$

A curtose da normal vale 3 logo:

$$E(Z^4) = 3.$$

$$E(X^4) = 3\sigma^4.$$

$$V(X^2) = 3\sigma^4 - \sigma^4 = 2\sigma^4.$$

Logo,

$$Var(T) = \frac{2\sigma^4}{n}.$$

Agora vamos estudar o caso biparamétrico:

Seja $X \sim N(\mu, \sigma^2)$. Calcule os estimadores pelo método dos momentos para μ e σ^2.

Como

$$E(X) = \mu \quad \text{e} \quad E(X^2) = \sigma^2 + \mu^2.$$

Assim vamos igualar os dois primeiros momentos populacionais aos dois primeiros momentos amostrais:

$$E(X) = \mu = \bar{X}.$$

$$\hat{\mu} = \bar{X}.$$

$$E(X^2) = \sigma^2 + \mu^2 = \frac{\sum_{i=1}^{n} X_i^2}{n}.$$

Logo,

$$\widehat{\sigma^2} + \hat{\mu^2} = \frac{\sum_{i=1}^{n} X_i^2}{n}.$$

$$\widehat{\sigma^2} = \frac{\sum_{i=1}^{n} X_i^2}{n} - \bar{X}^2 = \frac{\sum_{i=1}^{n} X_i^2 - n\,\bar{X}^2}{n}$$

$$\widehat{\sigma^2} = \frac{\sum_{i=1}^{n} \left(X_i - \bar{X}\right)^2}{n} = \frac{(n-1)S^2}{n}.$$

Note que

$$E\left(\widehat{\sigma^2}\right) = \frac{n-1}{n} E(S^2) = \frac{n-1}{n}\,\sigma^2,$$

que é viciado mas assintoticamente não viciado.

Por outro lado temos:

$$Var\left(\widehat{\sigma^2}\right) = \frac{(n-1)^2}{n^2} Var(S^2) = \frac{(n-1)^2}{n^2}\,\frac{2\sigma^4}{n-1} = \frac{2(n-1)}{n^2}\sigma^4.$$

Note que $\widehat{\sigma^2}$ é um estimador consistente para σ^2.

Exemplo 7: Seja $X \sim Gama(\alpha > 0, \beta > 0)$. A f.d.p. de X é dada por:

$$f(x|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)}\, x^{\alpha-1}\, e^{-\beta\, x}\, I_A(x), \quad A = (0, \infty).$$

Note que

$$E(X) = \frac{\alpha}{\beta} \quad , V(X) = \frac{\alpha}{\beta^2} \qquad ; \; E(X^2) = \frac{\alpha}{\beta^2} + \frac{\alpha^2}{\beta^2}.$$

Sejam $\hat{\alpha}$ e $\hat{\beta}$ os estimadores pelo método dos momentos:

Assim

$$\frac{\hat{\alpha}}{\hat{\beta}} = \bar{X}$$

Assim,

$$\hat{\alpha} = \bar{X} \; \hat{\beta}.$$

$$\frac{\hat{\alpha}}{\hat{\beta}^2} + \frac{\hat{\alpha}^2}{\hat{\beta}^2} = \frac{1}{n} \sum_{i=1}^{n} X_i^2.$$

Note que:

$$\frac{\hat{\alpha}}{\hat{\beta}} \; \frac{1}{\hat{\beta}} + \frac{\hat{\alpha}^2}{\hat{\beta}^2} = \frac{1}{n} \sum_{i=1}^{n} X_i^2.$$

$$\bar{X} \; \frac{1}{\hat{\beta}} + \bar{X}^2 = \frac{1}{n} \sum_{i=1}^{n} X_i^2$$

$$\bar{X} \; \frac{1}{\hat{\beta}} = \frac{\sum_{i=1}^{n} X_i^2 - n\bar{X}^2}{n} = \hat{\sigma^2}$$

logo,

$$\hat{\beta} = \frac{\bar{X}}{\hat{\sigma^2}}.$$

$$\hat{\alpha} = \bar{X} \; \hat{\beta} = \frac{\bar{X}^2}{\widehat{\sigma^2}}.$$

Uma maneira mais rápida de achar este estimadores é notar que:

$$\frac{E(X)}{V(X)} = \beta$$

logo

$$\widehat{\beta} = \frac{\bar{X}}{\widehat{\sigma^2}}.$$

Note que podemos usar tantos os momentos em relação é origem como os centrais.

3.2 Método de Mínimos Quadrados

Vamos analisar a seção 11.4 do livro do Bussab e Morettin.

Um dos procedimentos mais usados para obter estimadores é aquele que se baseia no princípio dos mínimos quadrados, introduzido por Gauss em 1794, mas que primeiro apareceu com esse nome no apêndice do tratado de Legendre, Nouvelles Méthodes pour la Determination des Orbites des Comètes, publicado em Paris em 1806. Gauss somente viria a publicar seus resultados em 1809, em Hamburgo. Ambos utilizaram o princípio em conexão com problemas de Astronomia e Física.

Vejamos o procedimento por meio de um exemplo simples.

**Exemplo* Um engenheiro está estudando a resistência Y de uma fibra em função de seu diâmetro X e notou que as variáveis são aproximadamente proporcionais, isto é, elas obedecem à relação

$$Y \approx \theta X, \qquad (11.25).$$

em que θ é o coeficiente de proporcionalidade. Agora ele deseja estimar o parâmetro θ , baseado numa amostra de cinco unidades, que, submetidas a mensuração e testes, produziram os resultados:

	1	2	3	4	5	Média
X	1,2	1,5	1,7	2,0	2,6	$\bar{X} = 1,8$
Y	3,9	4,7	5,6	5,8	7,0	$\bar{Y} = 5,4$

Vamos fazer um diagrama de dispersão :

Foi feito um pequeno programa no **R**:

```r
X=c(12,15,17,20,26)/10;X
```

```
[1] 1.2 1.5 1.7 2.0 2.6
```

```r
Y=c(39,47,56,58,70)/10;Y
```

```
[1] 3.9 4.7 5.6 5.8 7.0
```

```r
n=length(Y);n
```

```
[1] 5
```

```r
Xb=mean(X);Xb
```

```
[1] 1.8
```

```r
Yb=mean(Y);Yb
```

```
[1] 5.4
```

```r
plot(X,Y,xlim=c(0,3),ylim=c(0,8))
abline(a=0,b=3,col="red")
```

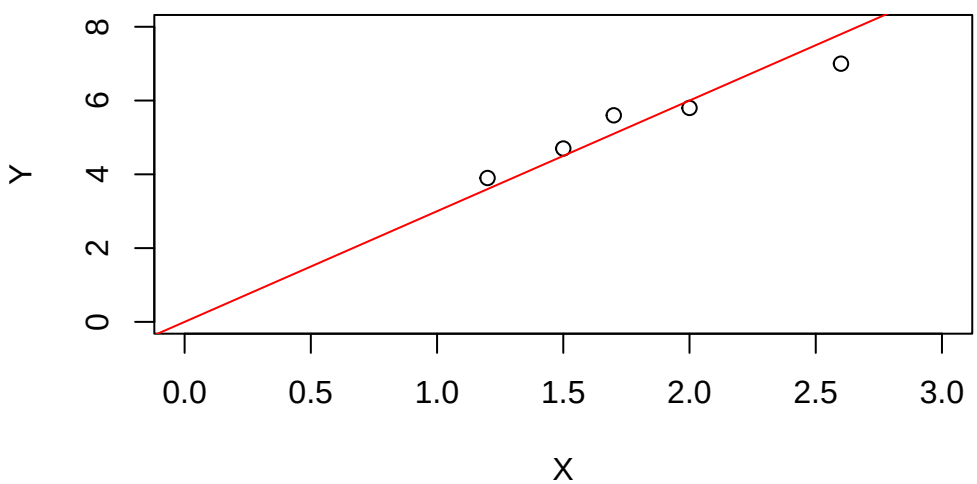

O valor a é o coeficiente linear e o valor b o coeficiente angular da reta que passa pela origem.

Inspecionando os resultados, conclui-se que $\hat{\theta} = 3$ parece ser um valor razoável.

Como verificar a qualidade dessa estimativa? Podemos utilizar o modelo

$$\hat{Y} = 3X$$

e ver como esse prevê os valores de Y, para os dados valores de X, e como são as discrepâncias entre os valores observados e os estimados pelo modelo.

Essa análise está resumida na Tabela abaixo:

X	Y	$\hat{Y} = 3X$	$e = Y - \hat{Y}$	e^2
1,2	3,9	3,6	0,3	0,09
1,5	4,7	4,5	0,2	0,04
1,7	5,6	5,1	0,5	0,25
2,0	5,8	6,0	−0,2	0,04
2,6	7,0	7,8	−0,8	0,64
		Total	**0**	**1,06**

Os valores da coluna $(Y-3X) = (Y-\bar{Y})$ medem a inadequação do modelo para cada observação da amostra, enquanto o valor é uma tentativa de medir o erro quadrático total da amostra?. Como em situações anteriores, elevou-se ao quadrado para evitar o problema do sinal.

Quanto menor for o erro quadrático total, melhor será a estimativa.

Isso nos sugere procurar a estimativa que torne mínima essa soma de quadrados. Matematicamente, o problema passa a ser o de encontrar o valor de θ que minimize a função

$$S(\theta) = \sum_{i=1}^{5} (Y_i - \theta X_i)^2.$$

O mínimo da função é obtido derivando-a em relação a θ, e igualando o resultado a zero (ver Morettin et al., 2005), o que resulta

$$S'(\theta) = 2 \sum_{i=1}^{5} (Y_i - \theta X_i)(-X_i),$$

$$S'(\theta) = -2 \sum_{i=1}^{5} (X_i\, Y_i - \theta X_i^2) = 0$$

$$S'(\theta) = -2 \sum_{i=1}^{5} X_i \, Y_i + 2\theta \sum_{i=1}^{5} X_i^2.$$

A derivada segunda de S é dada por:

$$S''(\theta) = 2 \sum_{i=1}^{5} X_i^2 > 0$$

Igualando a derivada primeira a zero temos:

$$\sum_{i=1}^{5} X_i \, Y_i - \theta \sum_{i=1}^{5} X_i^2 = 0$$

Assim

$$\theta = \frac{\sum_{i=1}^{5} X_i \, Y_i}{\sum_{i=1}^{5} X_i^2},$$

que é ponto de mínimo relativo pois a derivada segunda é sempre positiva.

O estimador de mínimos quadrados de θ é dado por:

$$\widehat{\theta}_{MQ} = \frac{\sum_{i=1}^{5} X_i \, Y_i}{\sum_{i=1}^{5} X_i^2}.$$

Usando os dados acima encontramos $\widehat{\theta}_{MQ} = 2,94$, que conduz a um valor mínimo para $S(\theta)$ de \$ 0,94\$. Observe que esse valor é realmente menor do que o observado para $\theta = 3$, ou seja, $1,06$.

Vamos utilizar o `R` para calcular a estimativa de mínimos quadrados de θ bem como os valores previstos pelo modelo.

```
X=c(12,15,17,20,26)/10;X
```

```
[1] 1.2 1.5 1.7 2.0 2.6
```

```r
Y=c(39,47,56,58,70)/10;Y
```

```
[1] 3.9 4.7 5.6 5.8 7.0
```

```r
n=length(Y);n
```

```
[1] 5
```

```r
SX=sum(X);SX
```

```
[1] 9
```

```r
X2=X^2
SX2=sum(X2);SX2
```

```
[1] 17.34
```

```r
XY=X*Y
SXY=sum(XY);SXY
```

```
[1] 51.05
```

```r
teta_est=SXY/SX2;teta_est
```

```
[1] 2.94406
```

```r
round(teta_est,2)  ##Estimativa de mínimos quadrados.
```

```
[1] 2.94
```

```r
Y_est=teta_est*X;Y_est
```

```
[1] 3.532872 4.416090 5.004902 5.888120 7.654556
```

```r
e=Y-Y_est
e2=e^2
sum(e2)
```

```
[1] 1.005738
```

```r
tabela=cbind(X,Y,X2,XY,Y_est,e,e2);tabela
```

```
       X   Y   X2    XY    Y_est           e          e2
[1,] 1.2 3.9 1.44  4.68 3.532872  0.36712803 0.134782989
[2,] 1.5 4.7 2.25  7.05 4.416090  0.28391003 0.080604908
[3,] 1.7 5.6 2.89  9.52 5.004902  0.59509804 0.354141676
[4,] 2.0 5.8 4.00 11.60 5.888120 -0.08811995 0.007765126
[5,] 2.6 7.0 6.76 18.20 7.654556 -0.65455594 0.428443479
```

Vamos fazer agora com uma função direta do R:

```r
mod1=lm(Y~X -1);mod1
```

```
Call:
lm(formula = Y ~ X - 1)

Coefficients:
    X
2.944
```

```r
predict(mod1)
```

```
       1        2        3        4        5
3.532872 4.416090 5.004902 5.888120 7.654556
```

```r
summary(mod1)
```

```
Call:
lm(formula = Y ~ X - 1)
```

```
Residuals:
       1        2        3        4        5 
 0.36713  0.28391  0.59510 -0.08812 -0.65456 

Coefficients:
  Estimate Std. Error t value Pr(>|t|)    
X   2.9441     0.1204   24.45 1.66e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5014 on 4 degrees of freedom
Multiple R-squared:  0.9934,	Adjusted R-squared:  0.9917 
F-statistic: 597.7 on 1 and 4 DF,  p-value: 1.661e-05
```

```r
anova(mod1)
```

```
Analysis of Variance Table

Response: Y
          Df  Sum Sq Mean Sq F value    Pr(>F)    
X          1 150.294 150.294  597.75 1.661e-05 ***
Residuals  4   1.006   0.251                      
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
SY2=sum(Y^2);SY2
```

```
[1] 151.3
```

```r
###Observe que:
150.294 + 1.006
```

```
[1] 151.3
```

Como foi dito, não esperávamos uma relação perfeita entre as duas variáveis, já que o diâmetro da fibra não é o único responsável pela resistência; outros fatores não controlados afetam o resultado.

Desse modo, duas amostras obtidas do mesmo diâmetro X não teriam obrigatoriamente que apresentar o mesmo resultado Y, mas valores em torno de um valor esperado θX.

Em outras palavras, estamos supondo que, para um dado valor da variável explicativa $ X$, os valores da variável resposta $ Y$ seguem uma distribuição de probabilidade $ f_Y(y)$, centrada em θX.

Isso equivale a afirmar que, para cada X, o desvio

$$\epsilon = Y - \theta X$$

segue uma distribuição centrada no zero.

Para melhor entendimento dessa proposição, veja o Capítulo 16. Podemos, então, escrever

$$E(Y|x) = \theta x, \text{ para todo valor } x.$$

É comum supor que ϵ tem a mesma distribuição, para todo valor $ x$ da variável explicativa X.

Desse modo, é comum escrever

$$Y = \theta\, x + \epsilon,$$

com ϵ seguindo a distribuição $f_\epsilon(.)$, com média zero. Como ilustração, poderíamos supor que

$$\epsilon \sim N(0, \sigma^2), \quad \text{para todo } x.$$

Quanto menor for a variância σ^2 , melhor será a previsão de Y como função de $ x$. Assim, parece razoável escolher $ $ que torna mínima a soma dos quadrados do erros:

O modelo acima pode ser generalizado, de modo a envolver outras funções do parâmetro, resultando no modelo

$$Y = g(X; \theta) + \epsilon, \qquad (11.27)$$

Note que

$$E(Y) = g(X; \theta),$$

e devemos procurar o valor de θ que minimize a função

$$S(\theta) = \sum_{i=1}^{n} \epsilon_i^2 = \sum_{i=1}^{n} (Y_i - E(Y_i))^2 = \sum_{i=1}^{n} (Y_i - g(X_i; \theta))^2, \qquad (11.28)$$

Para uma amostra $(X_1, Y_1), \ldots, (X_n, Y_n)$ das variáveis X e Y. A solução MQ é chamada de estimador de mínimos quadrados (EMQ) de θ.

Nos Capítulos 15 e 16, voltaremos a esse tópico e trataremos com mais detalhes os chamados modelos lineares.

Suponha que

$$Y_i | X_i = \theta X_i + \epsilon_i, \quad i = 1, 2, \ldots, n$$

com

$$\epsilon_i \sim N(0, \sigma^2), \quad i = 1, 2, \ldots, n$$

Na prática usamos:

$$Y_i = \theta X_i + \epsilon_i, \quad i = 1, 2, \ldots, n.$$

Aplicando o operador esperança temos:

$$E\left(Y_i\right) = \theta X_i + E(\epsilon_i) = \theta X_i + 0 = \theta X_i.$$

Calculando a variância temos:

$$Var\left(Y_i\right) = Var\left(\theta X_i + \epsilon_i\right) = Var(\epsilon_i) = \sigma^2.$$

Considere o estimador de MQ de θ dado por:

$$\widehat{\theta}_{MQ} = \frac{\displaystyle\sum_{i=1}^{n} X_i \, Y_i}{\displaystyle\sum_{i=1}^{n} X_i^2} = \sum_{i=1}^{n} w_i \, Y_i,$$

com

$$w_i = \frac{X_i}{\sum_{i=1}^{n} X_i^2}.$$

Inicialmente mostre que:

$$\sum_{i=1}^{n} w_i \; X_i = 1.$$

Prova

Temos que :

$$\sum_{i=1}^{n} w_i \; X_i = \sum_{i=1}^{n} \; \frac{X_i}{\sum_{i=1}^{n} \; X_i^2} \times X_i.$$

$$\sum_{i=1}^{n} w_i \; X_i = \frac{1}{\sum_{i=1}^{n} \; X_i^2} \; \sum_{i=1}^{n} \; X_i^2 = 1.$$

Agora mostre que $\widehat{\theta}_{MQ}$ é um estimador não viciado de θ.

$$E\left(\widehat{\theta}_{MQ}\right) = E\left(\sum_{i=1}^{n} \; w_i Y_i\right),$$

$$E\left(\widehat{\theta}_{MQ}\right) = \sum_{i=1}^{n} \; E(w_i \; Y_i) = \sum_{i=1}^{n} \; w_i \; E(\; Y_i)$$

$$E\left(\widehat{\theta}_{MQ}\right) = \sum_{i=1}^{n} \; w_i \; \theta \; X_i = \theta \; \sum_{i=1}^{n} \; X_i w_i$$

$$E\left(\widehat{\theta}_{MQ}\right) = \theta \times 1 = \theta.$$

Agora mostre que:

$$\sum_{i=1}^{n} \; w_i^2 \; = \frac{1}{\sum\limits_{i=1}^{n} \; X_i^2}.$$

Prova:

Seja

$$A = \sum_{i=1}^{n} \; X_i^2$$

.

Assim

$$w_i = \frac{X_i}{A} \quad , w_i^2 = \frac{X_i^2}{A^2}$$

$$\sum_{i=1}^{n} w_i^2 = \sum_{i=1}^{n} \frac{X_i^2}{A^2} = \frac{1}{A^2} \sum_{i=1}^{n} X_i^2$$

$$\sum_{i=1}^{n} w_i^2 = \frac{1}{A^2} A = \frac{1}{A} = \frac{1}{\sum_{i=1}^{n} X_i^2}$$

Agora mostre que a variância do estimador de mínimos quadrados de θ é dada por:

$$Var\left(\hat{\theta}_{MQ}\right) = \frac{\sigma^2}{\sum_{i=1}^{n} X_i^2}.$$

Prova:

$$Var\left(\hat{\theta}_{MQ}\right) = Var\left(\sum_{i=1}^{n} w_i Y_i\right) = \sum_{i=1}^{n} Var(w_i Y_i),$$

$$Var\left(\hat{\theta}_{MQ}\right) = \sum_{i=1}^{n} w_i^2 \, V(Y_i) = \sum_{i=1}^{n} w_i^2 \, \sigma^2,$$

$$Var\left(\hat{\theta}_{MQ}\right) = \sigma^2 \sum_{i=1}^{n} w_i^2 = \frac{\sigma^2}{\sum_{i=1}^{n} X_i^2}.$$

Qual a distribuição Amostral do estimador de mínimos quadrados $V = \hat{\theta}_{MQ}$?

Prova: Sabemos que

$$Y_i \sim N(\theta X_i, \sigma^2)$$

e sua função geradora de momentos é dada por:

$$M_{Y_i}(t) = \exp(\theta X_i \, t + \frac{1}{2}\sigma^2 \, t^2)$$

A função de momentos de V é dada por:

$$M_V(t) = E\left(e^{tV}\right) = E\left(e^{t\sum_{i=1}^{n} w_i Y_i}\right)$$

$$M_V(t) = E\left(e^{\sum_{i=1}^{n} w_i\ t\ Y_i}\right)$$

$$M_V(t) = \prod_{i=1}^{n} E\left(e^{wi\ t\ Y_i}\right),$$

$$M_V(t) = \prod_{i=1}^{n} M_{Y_i}(w_i t)$$

$$M_V(t) = \prod_{i=1}^{n} \exp(\theta X_i\ w_i\ t + \frac{1}{2}\sigma^2\ w_i^2\ t^2)$$

$$M_V(t) = \exp\left(\theta\ t\ \sum_{i=1}^{n} X_i\ w_i\ + \frac{1}{2}\sigma^2\ \sum_{i=1}^{n} w_i^2\ t^2\right)$$

$$M_V(t) = \exp\left(\theta\ t\ \times 1 + \frac{1}{2} \times \sigma^2 \times \frac{1}{\sum_{i=1}^{n} X_i^2}\ t^2\right)$$

$$M_V(t) = \exp\left(\theta\ t\ + \frac{1}{2} \times \frac{\sigma^2}{\sum_{i=1}^{n} X_i^2}\ t^2\right)$$

Assim

$$V = \hat{\theta}_{MQ} \sim N\left(\theta, \frac{\sigma^2}{\sum_{i=1}^{n} X_i^2}\right)$$

Qual o estimador de mínimos quadrados baseado em uma amostra aleatória de tamanho n, $X_1, X_2, \dots, X_n$), de uma variável X com distribuição:

- $X \sim Poisson(\theta)$.
- $X \sim N(\mu, 1)$.
- $X \sim Ber(p)$.

Solução: Devemos minimizar

`Sabemos que`

$$E(X_i) = \theta, \quad i = 1, 2, \dots, n.$$

$$S(\theta) = \sum_{i=1}^{n} (X_i - E(X_i))^2 = \sum_{i=1}^{n} (X_i - \theta)^2$$

$$S(\theta) = \sum_{i=1}^{n} X_i^2 - 2\sum_{i=1}^{n} X_i\, \theta + n\theta^2 = a\theta^2 + b\theta + c$$

Como $a > 0$ temos

$$\theta_{min} = \frac{-b}{2a} = \frac{2\sum_{i=1}^{n} X_i}{2n} = \bar{X}$$

que é o nosso estimador de mínimos quadrados.

No caso da normal temos:

Sabemos que

$$E(X_i) = \mu, \quad i = 1, 2, \dots, n.$$

$$S(\mu) = \sum_{i=1}^{n} (X_i - E(X_i))^2 = \sum_{i=1}^{n} (X_i - \mu)^2$$

$$\mu_{min} = \bar{X},$$

que é o nosso estimador de mínimos quadrados.

No caso da Bernouli temos

$$E(X_i) = p, \quad i = 1, 2, \ldots, n.$$

$$S(p) = \sum_{i=1}^{n} (X_i - E(X_i))^2 = \sum_{i=1}^{n} (X_i - p)^2$$

$$S(p) = np^2 - 2\sum_{i=1}^{n} X_i\, p + \sum_{i=1}^{n} X_i^2$$

$$S'(p) = 2pn - 2\sum_{i=1}^{n} X_i$$

$$S''(p) = 2n > 0$$

De $S'(p) = 0$ temos

$$p_{min} = \bar{X},$$

que é o nosso estimador de mínimos quadrados.

Problemas

1. Estamos estudando o modelo $y_t = \mu + \epsilon_t$, para o qual uma amostra de cinco elementos produziu os seguintes valores para $y_t : 3, 5, 6, 8, 16$.

(a) Calcule os valores de

$$S(\mu) = \sum_t (y_t - \mu)^2$$

para $\mu = 6, 7, 8, 9, 10$, e faça o gráfico de $S(\mu)$ em relação a μ.

Qual o valor que parece tornar mínimo $S(\mu)$?

(b) Derivando $S(\mu)$ em relação a μ , e igualando o resultado a zero, você encontrará o EMQ de μ. Usando os dados acima, encontre a estimativa para μ e compare com o resultado do item anterior.

2. Os dados abaixo referem-se ao índice de inflação (y_t) de 1967 a 1979.

Ano (t)	1967	1969	1971	1973	1975	1977	1979
Inflação (y_t)	128	192	277	373	613	1236	2639

(a) Faça o gráfico de y_t contra t.

(b) Considere ajustar o modelo

$$y_t = \alpha + \beta t + \epsilon_t$$

aos dados. Encontre as estimativas de mínimos quadrados de α e β.

(c) Qual seria a inflação em 1981?

(d) Você teria alguma restrição em adotar o modelo linear nesse caso ?

3. No Problema 7, determinamos os estimadores de mínimos quadrados para o modelo

$$y_t = f(t) + \epsilon_t,$$

no qual

$$f(t) = \alpha + \beta\, t$$

.

Suponha agora que

$$f(t) = \alpha + \beta\, x_t,\ t = 1, 2, \dots, n,$$

ou seja, temos n valores fixos $x_1, x_2, \dots, x_n$ uma variável fixa (não aleatória) x. Obtenha os EMQ de α e β para esse modelo.

4. Aplique os resultados do Problema 3 para os dados a seguir:

t	1	2	3	4	5	6	7	8	9	10
x_t	1,5	1,8	1,6	2,5	4,0	3,8	4,5	5,1	6,5	6,0
y_t	66,8	67,0	66,9	67,6	68,9	68,7	69,3	69,8	71,0	70,6

4 Estimação Intervalar

5 Testes de Hipóteses

6 Testes de Homogeneidade e Independência

7 Inferência Estatística e Ciência de Dados

Referências

KIM, Albert Y.; ISMAY, Chester; KUHN, Max. Take a moderndive into introductory linear regression with R. **The Journal of Open Source Education**, v. 4, n. 41, 115, 2021.

WICKHAM, Hadley *et al.* Welcome to the tidyverse. **Journal of Open Source Software**, v. 4, n. 43, p. 1686, 2019.