

Métodos Inferenciais

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa Modelos de Sobrevida e Aplicações.

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	13
Direitos Autorais e Uso da Obra	13
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	13
Prefácio	14
Identificação da(s) Disciplina(s)	15
EMENTA	15
OBJETIVO GERAL	16
OBJETIVOS ESPECÍFICOS	16
CONTEÚDO PROGRAMÁTICO	17
Unidade I – Fundamentos da Inferência Estatística	17
Unidade II – Distribuições Amostrais	17
Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados	17
Unidade IV – Métodos de Estimação Pontual	18
Unidade V – Estimação Intervalar	18
Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos	18
METODOLOGIA	18
AVALIAÇÃO	19
CRITÉRIOS DE AVALIAÇÃO	19
BIBLIOGRAFIA BÁSICA	20
BIBLIOGRAFIA COMPLEMENTAR	20
Revisão de Probabilidade e Modelos Probabilísticos	22
Probabilidade e condicionamento	22
Experimentos aleatórios, espaço amostral e eventos	22
Probabilidade	23
Revisão de combinatória	24
Probabilidade condicional	25
Lei da probabilidade total	26
Teorema de Bayes	26
Independência de eventos	27
Variáveis aleatórias e distribuições	28
Função de distribuição, suporte e quantis	28
Variáveis discretas e absolutamente contínuas	29

Função indicadora	30
Funções de variáveis aleatórias	30
Esperança, variância e momentos	31
Esperança e momentos	31
Modelos probabilísticos discretos	32
Distribuição uniforme discreta	32
Distribuição de Bernoulli	33
Distribuição binomial	34
Distribuição hipergeométrica	35
Binomial e hipergeométrica	37
Distribuição geométrica	37
Distribuição binomial negativa	38
Distribuição de Poisson	39
Relação entre binomial e Poisson	41
Soma de variáveis Poisson independentes	41
Distribuição multinomial	42
Relações entre os modelos discretos	44
Modelos probabilísticos contínuos	45
Distribuição uniforme contínua	45
Distribuição exponencial	46
Distribuição gama	47
Relação entre exponencial e gama	49
Distribuição normal	50
Transformações lineares da distribuição normal	51
Distribuição beta	52
Relações entre gama e beta	53
Escolha entre alguns modelos contínuos	54
Distribuições conjuntas e dependência	55
Distribuição conjunta	55
Distribuições marginais	56
Distribuições condicionais	57
Independência de variáveis aleatórias	59
Independência de várias variáveis	60
Covariância e correlação	61
Esperança condicional	63
Variância condicional	64
Vetores de médias e matrizes de covariâncias	66
Síntese das relações conjuntas	67
Transformações e função geradora de momentos	68
Transformações de variáveis aleatórias	68
Função geradora de momentos	70
Algumas funções geradoras de momentos	74
Quadro-síntese dos modelos probabilísticos	74

Síntese	76
Exercícios de consolidação	77
Da Probabilidade à Inferência Estatística	81
Referências	82
Resultados Matemáticos e Assintóticos para Inferência	83
Mapa de dependências	83
Notação e ferramentas matemáticas	84
Somatórios, produtos e funções indicadoras	84
Diferenciação	86
Fórmula de Taylor	87
Vetores e matrizes	89
Matrizes	89
Formas quadráticas	91
Projeções	92
Gradiente, jacobiana e hessiana	93
Transformações multivariadas e jacobiano	94
Ferramentas assintóticas	96
Modos de convergência	96
Relações entre os modos de convergência	97
Teorema do mapeamento contínuo	98
Lema de Slutsky	99
Lei dos Grandes Números	101
Teorema Central do Limite	102
Lei dos Grandes Números e Teorema Central do Limite	103
Método delta univariado	103
Método delta multivariado	105
Ordens estocásticas	106
Síntese	109
Exercícios de consolidação	110
Referências	114
1 Fundamentos da Inferência Estatística	115
1.1 O problema da inferência estatística	115
1.2 Processo Gerador de Dados (PGD)	116
1.3 Pacote Necessários	117
1.4 Experimento em Sala de Aula	117
Verificação de aprendizagem	118
1.5 Experimento Virtual	118
Verificação de aprendizagem	125
Lista Semanal Obrigatória	125
1.6 Conceitos Importantes	125

1.7	Estatísticas, estimadores e estimativas	128
	Exemplos básicos	129
1.8	Exemplo-guia: experimento da urna	130
1.9	A variabilidade dos estimadores: uma antecipação	131
1.10	Crerios para avaliar estimadores: vis3o panor3mica	131
1.11	Modelo estatístico e funç3o de verossimilhança	132
	Funç3o de verossimilhança	132
	Verossimilhança no experimento da urna	133
	Verificaç3o de aprendizagem	134
	Referências	134
2	Distribuiç3es Amostras	135
2.1	Introduç3o	135
	Objetivos do capítulo	136
2.2	Populaç3o, parâmetro, amostra e estatística	136
2.3	Dois referenciais de amostragem	137
	2.3.1 Amostragem no modelo i.i.d.	137
	2.3.2 Amostragem aleat3ria simples sem reposiç3o	138
2.4	Construç3o de uma distribuiç3o amostral por enumeraç3o	140
2.5	Somas, transformaç3es e funç3es geradoras de momentos	141
2.6	Distribuiç3o amostral da média	142
2.7	Lei dos Grandes Números	144
2.8	Teorema Central do Limite	145
	2.8.1 Padronizaç3o com variância estimada	146
2.9	Distribuiç3o amostral da proporç3o	146
	2.9.1 Aproximaç3o normal da binomial	147
2.10	Distribuiç3o amostral da variância	148
	2.10.1 Variância de S^2 em uma populaç3o geral	148
2.11	Distribuiç3es derivadas do modelo normal	149
	2.11.1 Distribuiç3o qui-quadrado	150
	2.11.2 Independência entre média e variância	152
	2.11.3 Distribuiç3o t de Student	152
	2.11.4 Distribuiç3o F	154
2.12	Estatísticas de ordem	155
	2.12.1 Mínimo e máximo	155
	2.12.2 k -ésima estatística de ordem	156
2.13	Distribuiç3es amostrais por simulaç3o	157
	Exemplo computacional: manifestaç3o do TCL	157
	Exemplo computacional: distribuiç3o exata em populaç3o finita	158
2.14	Quadro-síntese	159
2.15	Exercícios	159
	Exercícios conceituais	159
	Exercícios de cálculo	160

Exercícios teóricos e computacionais	162
Referências	162
3 Avaliação de Estimadores e Princípios de Redução de Dados	163
3.1 Avaliação de estimadores	163
Função de perda, risco e erro quadrático médio	163
Viés, variância e erro-padrão	164
Exemplo adaptado — Estimação do limite de uma distribuição uniforme	165
Consistência	167
Resultados operacionais para convergência em probabilidade	169
Eficiência em amostras finitas	169
Informação de Fisher	170
Desigualdade de Cramér–Rao	171
Exemplo — Média de uma distribuição normal com variância conhecida	172
Exemplo — Parâmetro de uma distribuição de Poisson	173
Eficiência assintótica	174
3.2 Princípios de redução de dados	174
Estatística suficiente	174
Teorema da fatoração de Neyman–Fisher	175
Exemplo — Amostra Bernoulli	175
Suficiência mínima	176
Famílias exponenciais	177
Compleitude	178
Teorema de Rao–Blackwell	179
Exemplo adaptado — Estimação no modelo de Poisson	179
Teorema de Lehmann–Scheffé	180
Exemplo autoral — Estimação da taxa exponencial	181
Estatísticas ancilares e teorema de Basu	182
3.3 Exemplo integrado adaptado — Distribuição gama com forma conhecida	183
Redução por suficiência e completude	183
Eficiência	184
3.4 Síntese conceitual	185
3.5 Exercícios	185
Referências	187
4 Métodos de Estimação Pontual	188
4.1 Método dos Momentos	188
Momentos populacionais e amostrais	188
Fundamentação probabilística	189
Procedimento geral	190
Exemplo — distribuição de Pareto	191
Exemplo — distribuição uniforme contínua	194
Exemplo — distribuição uniforme discreta	195

	Exemplo — distribuição exponencial	196
	Exemplo — distribuição gama	197
	Exercícios	198
4.2	Máxima Verossimilhança	198
	Exemplo motivacional — moeda com probabilidade desconhecida	199
4.2.1	Definição formal	200
4.2.2	Existência e unicidade	202
4.2.3	Log-verossimilhança	202
4.2.4	Função escore e informação	203
4.2.5	Propriedades assintóticas	208
	Exemplos	212
4.2.6	Procedimento geral de obtenção do estimador	220
4.2.7	Exercícios	220
4.2.8	Síntese	225
4.3	Mínimos Quadrados	225
4.3.1	Exemplo motivacional: renda familiar e auxílio financeiro	226
4.3.2	Definição formal	228
4.3.3	Relação com o método de máxima verossimilhança	234
4.3.4	Exemplos	238
4.3.5	Exercícios	243
4.3.6	Síntese	248
4.4	Algoritmo Expectation-Maximization (EM)	249
4.4.1	Exemplo motivacional: mistura de duas populações normais	250
4.4.2	Definição formal	251
4.4.3	Condições de uso	255
4.4.4	Propriedades importantes	257
4.4.5	Exemplos	260
4.4.6	Exercícios	269
4.4.7	Síntese	273
	Exercícios Complementares	274
	Referências	275
5	Estimação intervalar	276
	Objetivos do capítulo	276
5.1	Definição formal	277
5.2	Interpretação frequentista	277
5.3	Quantis e valores críticos	278
5.4	Construção por quantidade pivotal	279
5.4.1	Procedimento geral	280
5.5	Intervalos para parâmetros da distribuição normal	280
5.5.1	Média com variância conhecida	280
5.5.2	Média com variância desconhecida	281

5.5.3	Variância de uma população normal	283
5.6	Exemplo de intervalo exato por pivô: distribuição exponencial	284
5.7	Intervalos assintóticos e método de Wald	285
5.7.1	Exemplo: média de uma distribuição de Poisson	286
5.8	Intervalos para uma proporção binomial	286
5.8.1	Intervalo de Wald	287
5.8.2	Intervalo de Wilson ou de escore	287
5.8.3	Intervalo exato de Clopper–Pearson	287
5.9	Intervalos unilaterais	288
5.10	Dualidade entre intervalos de confiança e testes de hipóteses	289
5.11	Amplitude, precisão e tamanho amostral	290
5.12	Cobertura por simulação	291
5.13	Métodos bootstrap	291
5.14	Intervalo de confiança não é intervalo de predição	293
5.15	Roteiro para construção e apresentação	294
5.16	Síntese dos principais procedimentos	294
5.17	Exercícios	295
5.18	Gabarito sucinto	297
	Referências	298
6	Testes de Hipóteses e Análise de Dados Categóricos	299
6.1	Objetivos de aprendizagem	299
6.2	Motivação: uma moeda aparentemente honesta	299
6.3	Formulação estatística do problema	300
6.3.1	Função de teste e região crítica	301
6.3.2	Função poder, tamanho e nível	302
6.3.3	Erros dos tipos I e II	302
6.4	Valor- p	303
6.4.1	Regra de decisão	304
6.5	Procedimento recomendado	305
6.6	Exemplo motivacional	305
6.7	Lema de Neyman–Pearson	306
6.7.1	Exemplo: média normal, alternativa simples	307
6.8	Testes uniformemente mais poderosos	307
6.8.1	Razão de verossimilhanças monótona	308
6.8.2	Exemplos importantes	309
6.8.3	Por que geralmente não existe UMP bilateral?	310
6.9	Teste da razão de verossimilhanças	310
6.9.1	Resultado assintótico de Wilks	311
6.9.2	Exemplo: média normal com variância conhecida	312
6.9.3	Exemplo: proporção binomial	313
6.10	Testes usuais para parâmetros populacionais	313
6.10.1	Uma média com variância conhecida	313

6.10.2	Uma média com variância desconhecida	314
6.10.3	Uma proporção	314
6.10.4	Duas médias independentes: teste de Welch	315
6.10.5	Duas médias independentes com variância comum	316
6.10.6	Amostras pareadas	316
6.10.7	Duas proporções independentes	317
6.11	Testes exatos, de permutação e robustez	317
6.11.1	Testes de permutação	317
6.11.2	Robustez	318
6.12	Planejamento amostral e poder	318
6.12.1	Uma média com variância conhecida	318
6.12.2	Uma proporção	319
6.13	Análise de dados categóricos	319
6.13.1	Estatística qui-quadrado de Pearson	319
6.13.2	Estatística da razão de verossimilhanças	320
6.14	Teste qui-quadrado de aderência	320
6.14.1	Exemplo: dado de seis faces	321
6.15	Tabelas de contingência	321
6.15.1	Homogeneidade e independência	322
6.15.2	Exemplo: renda e hipertensão	322
6.16	Diagnóstico por resíduos	323
6.17	Pressupostos e tabelas esparsas	324
6.18	Teste exato de Fisher	324
6.19	Medidas de tamanho do efeito em tabelas	325
6.20	Poder e tamanho amostral em testes qui-quadrado	326
6.21	Relação entre testes e intervalos de confiança	327
6.22	Boas práticas de apresentação	327
6.22.1	Modelo de redação	328
6.23	Erros frequentes de interpretação	328
6.24	Quadro-síntese	328
6.25	Exercícios	329
6.25.1	Exercícios conceituais	329
6.25.2	Neyman–Pearson e testes UMP	330
6.25.3	Razão de verossimilhanças	331
6.25.4	Testes para médias e proporções	331
6.25.5	Dados categóricos	332
6.25.6	Reamostragem e robustez	333
	Referências	333
7	Projetos Aplicados	334
7.1	Objetivo	334
7.2	Descrição Geral	334
7.2.1	Exemplos de Temas e Variáveis de Interesse	334

7.2.2	Etapas do Trabalho	337
7.2.3	Cr�terios de Avalia��o	339
7.2.4	Observa��es	340
8	Exemplos Aplicados	341
8.0.1	Exemplo Aplicado	341
8.0.2	Vari�ncia e desvio-padr�o populacionais	341
8.0.3	Objetivo	342
8.0.4	C�culo do tamanho m�nimo de amostra	342
8.0.5	Sele��o da amostra aleat�ria	343
8.0.6	Teste Z para uma m�dia com vari�ncia conhecida	344
8.0.7	C�culo do p-valor	344
8.0.8	Regra de Decis�o	344
8.0.9	Intervalo de confian�a de 95%	345
8.0.10	Conclus�o	345
8.1	Exemplo Aplicado	345
8.1.1	Amostra piloto	345
8.1.2	C�culo do tamanho m�nimo de amostra	346
8.1.3	Sele��o da amostra aleat�ria	347
8.1.4	Verificando normalidade dos dados	348
8.1.5	Teste t para uma m�dia com vari�ncia desconhecida	350
8.1.6	C�culo do p-valor	351
8.1.7	Regra de Decis�o	351
8.1.8	Intervalo de confian�a de 95%	352
8.1.9	Exemplo Aplicado	352
8.1.10	Exemplo Pr�tico	357
8.1.11	Sele��o da amostra	359
8.2	Infer�ncias para duas m�dias populacionais com amostras independentes e vari�ncias desiguais	363
8.2.1	Exemplo Pr�tico	363
8.2.2	Hip�teses	364
8.2.3	Prepara��o dos Dados e Amostra Piloto	364
8.3	C�culo do tamanho amostral	364
8.3.1	Sele��o da Amostra	365
8.3.2	Estat�stica de Teste	365
8.4	Refer�ncias	366
9	Demonstra��es	367
	Mapa das demonstra��es e fontes	367
	Resultados fundamentais de probabilidade	370
	Demonstra��o 1 — Lei fraca dos grandes n�meros para a m�dia amostral	370
	Enunciado	370

Demonstração	370
Demonstração 2 — Teorema Central do Limite por funções geradoras de momentos	371
Enunciado	371
Demonstração	371
Distribuições amostrais	373
Demonstração 3 — Distribuições de $\bar{X}$ e S^2 no modelo normal	373
Enunciado	373
Demonstração	373
Demonstração 4 — Independência entre $\bar{X}$ e S^2	375
Enunciado	375
Demonstração	375
Demonstração 5 — Derivação da distribuição t de Student	376
Enunciado	376
Demonstração	376
Redução de dados e estimação	378
Demonstração 6 — Teorema da fatoração de Fisher–Neyman: versão discreta	378
Enunciado	378
Demonstração	378
Demonstração 7 — Teorema de Rao–Blackwell	379
Enunciado	379
Demonstração	380
Demonstração 8 — Teorema de Lehmann–Scheffé	381
Enunciado	381
Demonstração	381
Demonstração 9 — Desigualdade de Cramér–Rao	382
Enunciado	382
Demonstração	383
Demonstração 10 — Invariância do estimador de máxima verossimilhança	384
Enunciado	384
Demonstração	384
Demonstração 14 — Teorema de Gauss–Markov	385
Enunciado	385
Demonstração	385
Demonstração 22 — Estimadores de Bayes sob perdas quadrática, absoluta e 0–1	387
Perda quadrática	387
Perda absoluta	387
Perda 0–1 no caso discreto	388
Verossimilhança e teoria assintótica	389
Demonstração 16 — Consistência do EMV em famílias exponenciais regulares	389
Enunciado	389

Demonstração	389
Demonstração 17 — Normalidade assintótica do EMV	391
Enunciado	391
Demonstração	391
Demonstração 18 — Método delta univariado e multivariado	392
Enunciado	392
Demonstração	392
Demonstração 19 — Equivalência assintótica entre Wald, escore e razão de verossimilhanças	394
Enunciado	394
Demonstração	394
Demonstração 20 — Teorema de Wilks para uma subfamília exponencial curva	396
Enunciado	396
Demonstração	396
Testes de hipóteses e intervalos de confiança	398
Demonstração 11 — Lema de Neyman–Pearson	398
Enunciado	398
Demonstração	398
Demonstração 12 — Teorema de Karlin–Rubin	399
Enunciado	399
Demonstração	399
Demonstração 13 — Dualidade entre testes e regiões de confiança	401
Enunciado	401
Demonstração	401
Demonstração 15 — Teste t de uma amostra como teste da razão de verossimilhanças generalizada	402
Enunciado	402
Demonstração	402
Inferência computacional, reamostragem e métodos modernos	405
Demonstração 21 — Monotonicidade do algoritmo EM	405
Definição	405
Demonstração	405
Demonstração 23 — Consistência de minimizadores convexos	407
Enunciado	407
Demonstração	407
Demonstração 24 — Função de influência e eficiência semiparamétrica	408
Função de influência de um funcional	408
Resultado de eficiência semiparamétrica	408
Demonstração	409
Demonstração 25 — Validade exata de um teste de permutação	410
Enunciado	410

Demonstração	410
Demonstração 26 — Princípio <i>plug-in</i> e bootstrap da média	411
Definição	411
Demonstração para a média	412
Síntese conceitual	414
Referências	415

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro resulta da experiência acumulada no ensino, na orientação de estudantes e no desenvolvimento de pesquisas em modelos de regressão. Somos docentes pesquisadores do Departamento de Estatística e Matemática Aplicada da Universidade Federal do Ceará (DEMA/UFC), com atuação contínua em regressão linear, modelagem estatística e inferência. Integramos o Laboratório de Inovação em Estatística — StatLab/UFC (<https://statlab.quarto.pub/>) e o Grupo de Pesquisa *Modelos de Sobrevivência e Aplicações* do CNPq (<http://dgp.cnpq.br/dgp/espelhogrupo/9639095385610769>), espaços nos quais articulamos ensino, pesquisa e aplicação a problemas reais.

O material tem como base as disciplinas Inferência Estatística I (CC0288), Análise Inferencial (CC0448) e Inferência Estatística (CCPXXX). Ao longo dos anos, consolidamos a convicção de que ensinar regressão exige equilíbrio entre rigor teórico e clareza interpretativa.

O livro desenvolve os conceitos de Inferência Estatística de forma progressiva, enfatizando interpretação e propriedades. A implementação é realizada integralmente no **R** (ou **Python**), utilizado como ambiente de experimentação conceitual e não apenas como ferramenta computacional.

Os fundamentos matemáticos mais densos são apresentados em apêndices específicos, preservando o fluxo didático do texto principal e permitindo diferentes níveis de aprofundamento. Acreditamos que inferência deve ser ensinada como base para tomada de decisão, com atenção às suas suposições, limitações e implicações práticas.

Esperamos que este livro contribua para a formação de profissionais capazes tomar decisões com rigor técnico, pensamento estatístico crítico e responsabilidade analítica.

Identificação da(s) Disciplina(s)

- Curso: Bacharelado em Ciência de Dados e Mestrado em Modelagem e Métodos Quantitativos (PPGMMQ)
- Disciplina: Análise Inferencial (Graduação) e Inferência Estatística (Mestrado)
- Carga Horária: 96 horas (Graduação) e 64 horas (Mestrado)
- Créditos: 6 (Graduação) e 4 (Mestrado)
- Regime: Semestral
- Pré-requisitos: Modelos Probabilísticos (CC0446) (Graduação)
- Período Letivo: 2026.2
- Professor(a): Dr. Manoel Santos-Neto (Graduação) e Dr. Rafael Bráz (Mestrado)

EMENTA

Nível	Ementa
Graduação	Conceitos de população e amostra; parâmetros, estatísticas, estimadores e suas propriedades; distribuições amostrais; métodos de estimação pontual: método dos momentos, máxima verossimilhança e mínimos quadrados; estimação intervalar; testes de hipóteses; testes de homogeneidade e independência.

Nível	Ementa
Mestrado	Conceitos de inferência. Avaliação de estimadores. Princípios da suficiência e completividade. Função de verossimilhança. Estimação pontual: método dos momentos, máxima verossimilhança, mínimos quadrados, minimax e equivariância. Distribuição assintótica dos estimadores. Método delta. Algoritmo EM. Estimação intervalar. Testes de hipóteses. Testes mais poderosos. Teste da razão de verossimilhança. Testes assintóticos. Testes de aderência. Testes de independência.

OBJETIVO GERAL

Apresentar os fundamentos da inferência estatística, capacitando o discente a formular, analisar e interpretar problemas inferenciais em contextos de análise de dados, com ênfase na quantificação da incerteza, validação de modelos e capacidade de generalização.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- compreender a diferença entre população, amostra, parâmetro e estatística;
- interpretar estatísticas como variáveis aleatórias;
- compreender e utilizar distribuições amostrais;
- aplicar métodos de estimação pontual e intervalar;
- formular e testar hipóteses estatísticas de forma adequada;
- interpretar corretamente p-valores, intervalos de confiança e decisões inferenciais;
- analisar criticamente resultados estatísticos obtidos a partir de dados reais.

CONTEÚDO PROGRAMÁTICO

Unidade I – Fundamentos da Inferência Estatística

- Motivação para a inferência: conceitos de população, amostra e parâmetros
- Estatísticas e estimadores como funções da amostra
- Função de verossimilhança: definição e papel central na inferência clássica

Unidade II – Distribuições Amostrais

- Estatísticas como variáveis aleatórias e suas distribuições amostrais
- Distribuição amostral da média e da proporção
- Lei dos Grandes Números
- Teorema Central do Limite

Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados

- Propriedades de pequenas amostras: viés, variância e erro quadrático médio
- Propriedades assintóticas: consistência e eficiência assintótica
- Princípio da Suficiência: definições formais, Critério de Fatoração de Neyman-Fisher e suficiência minimal
- Princípio da Completividade e Unicidade
- Família Exponencial: formas canônicas, posto completo e estatísticas completas e suficientes
- Teorema de Rao-Blackwell e Teorema de Lehmann-Scheffé: construção do Estimador Não-Viesado de Variância Uniformemente Mínima (ENVVUM)

Unidade IV – Métodos de Estimação Pontual

- Método dos momentos e suas aplicações
- Máxima verossimilhança: procedimentos, propriedades de invariância e otimalidade
- Mínimos quadrados: derivação, propriedades e relação com máxima verossimilhança
- Estimadores Minimax e Equivariância: critérios de risco e simetrias (locação e escala)
- Método Delta e Distribuição assintótica dos estimadores
- Algoritmo EM: estimação com dados ausentes ou não observáveis

Unidade V – Estimação Intervalar

- Conceitos e interpretação correta dos intervalos de confiança
- Métodos de construção: Método da Quantidade Pivotal e Inversão de Testes
- Intervalos baseados em aproximações assintóticas (Grandes amostras)

Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos

- Fundamentos: hipóteses nula/alternativa, estatísticas de teste, p-valor e decisões
- Teoria de erros (Tipo I e II) e Poder do teste
- Testes mais poderosos: Lema de Neyman-Pearson e Testes Uniformemente Mais Poderosos
- Teste da razão de verossimilhança e sua versão generalizada
- Análise de Variáveis Categóricas: Testes qui-quadrado, testes de aderência, independência e homogeneidade em tabelas de contingência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, articuladas com atividades práticas computacionais. O conteúdo teórico será constantemente ilustrado por simulações e análises de dados reais, utilizando ferramentas computacionais (R ou Python).

AVALIAÇÃO

A avaliação será contínua e composta por:

Nível	Atividades
Graduação	• Listas obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.
Mestrado	• Listas semanais obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.

A aprovação na disciplina seguirá os critérios estabelecidos pelas normas vigentes da UFC.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados nos trabalhos e atividades:

Nível	Critérios
Graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.
Mestrado	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.

BIBLIOGRAFIA BÁSICA

Nível	Bibliografias
Graduação	1. Bussab, W. O.; Morettin, P. A. <i>Estatística Básica</i> . 6ª ed. São Paulo: Saraiva, 2010.2. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. New York: Duxbury Press, 2001.3. Casella, G.; Berger, R. L. <i>Inferência Estatística</i> . Tradução da 2ª edição. São Paulo: Cengage Learning, 2011.
Mestrado	1. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.2. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Coleção Matemática Aplicada. Rio de Janeiro: SBM, 2001.3. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. New York: Duxbury Press, 2001.

BIBLIOGRAFIA COMPLEMENTAR

Nível	Bibliografias
Graduação	1. Devore, J. L. <i>Probabilidade e Estatística para Engenharia e Ciências</i> . São Paulo: Thomson, 2006.2. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i> . 3rd ed. New York: McGraw-Hill, 1974.3. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Rio de Janeiro: SBM, 2001.4. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.5. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i> . New York: John Wiley, 1988.

Nível	Bibliografias
Mestrado	1. Casella, G.; Berger, R. L. <i>Inferência Estatística</i>. Tradução da 2^a edição norte-americana. São Paulo: Cengage Learning, 2001.2. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i>. New York: John Wiley, 1988.3. Lehmann, E. L.; Casella, G. <i>Theory of Point Estimation</i>. 2nd ed. New York: Springer, 2003.4. Lehmann, E. L.; Romano, J. P. <i>Testing Statistical Hypotheses</i>. 3rd ed. New York: Springer, 2010.5. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i>. 3rd ed. New York: McGraw-Hill, 1974.6. Rohatgi, V. K. <i>Statistical Inference</i>. New York: Dover, 2003.7. Shao, J. <i>Mathematical Statistics</i>. 2nd ed. New York: Springer, 2004.

Revisão de Probabilidade e Modelos Probabilísticos

Este capítulo revisa conceitos de Probabilidade e modelos probabilísticos que serão utilizados ao longo do estudo de Inferência Estatística. O conteúdo pressupõe uma formação anterior em Probabilidade e concentra-se nas definições, propriedades e relações que serão retomadas nos capítulos seguintes.

A revisão abrange probabilidade condicional, independência, variáveis aleatórias, distribuições, esperança, variância, modelos probabilísticos discretos e contínuos e distribuições conjuntas. Alguns resultados são apresentados de forma resumida, pois o objetivo é recuperar a linguagem probabilística necessária à inferência, e não desenvolver novamente um curso completo de Probabilidade (Dantas, 1997; Magalhães, 2006; Meyer, 1983).

Delimitação do capítulo

Neste capítulo, os modelos probabilísticos são tratados como objetos conhecidos da teoria da Probabilidade. Conceitos propriamente inferenciais, como parâmetro desconhecido, modelo estatístico, verossimilhança, estimação e testes de hipóteses, serão introduzidos posteriormente.

Resultados sobre convergência, Lei dos Grandes Números, Teorema Central do Limite, lema de Slutsky, método delta e ordens estocásticas serão reunidos no capítulo **Resultados Matemáticos e Assintóticos para Inferência**.

Probabilidade e condicionamento

Experimentos aleatórios, espaço amostral e eventos

Um **experimento aleatório** é um procedimento cujo resultado não pode ser determinado antecipadamente, embora seja possível especificar o conjunto de resultados que podem ocorrer.

O **espaço amostral**, denotado por Ω , é o conjunto dos resultados possíveis do experimento. Um **evento** é um subconjunto de Ω .

Por exemplo, no lançamento de um dado de seis faces,

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

O evento

$$A = \{2, 4, 6\}$$

representa a ocorrência de um resultado par.

As operações entre eventos seguem as operações usuais entre conjuntos. Para eventos A e B :

- $A \cup B$ representa a ocorrência de pelo menos um dos eventos;
- $A \cap B$ representa a ocorrência simultânea de A e B ;
- A^c representa a não ocorrência de A ;
- $A \setminus B$ representa a ocorrência de A sem a ocorrência de B .

Dois eventos são **mutuamente exclusivos** quando

$$A \cap B = \emptyset.$$

Probabilidade

Uma medida de probabilidade P associa a cada evento A um número $P(A)$ que representa sua probabilidade de ocorrência. As propriedades básicas são

$$P(A) \geq 0,$$

$$P(\Omega) = 1$$

e, para uma sequência de eventos mutuamente exclusivos $A_1, A_2, \dots$,

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Dessas propriedades decorrem relações utilizadas com frequência:

$$P(A^c) = 1 - P(A),$$

e

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Se $A \subseteq B$, então

$$P(A) \leq P(B).$$

Em espaços amostrais finitos com resultados equiprováveis, a probabilidade de um evento pode ser calculada por

$$P(A) = \frac{|A|}{|\Omega|},$$

em que $|A|$ e $|\Omega|$ representam, respectivamente, o número de elementos de A e de Ω (Dantas, 1997; Meyer, 1983).

Revisão de combinatória

Em problemas com resultados equiprováveis, o cálculo de probabilidades depende frequentemente da contagem dos resultados possíveis. Para esta revisão, serão utilizados principalmente o princípio multiplicativo, os coeficientes binomiais e os coeficientes multinomiais.

Se um procedimento pode ser realizado em n_1 formas em uma primeira etapa e, para cada uma delas, em n_2 formas em uma segunda etapa, o número de resultados possíveis é

$$n_1 n_2.$$

Para n objetos distintos, o número de ordenações possíveis é

$$n!.$$

O número de maneiras de escolher k elementos dentre n , sem considerar a ordem, é

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad k = 0, 1, \dots, n.$$

Se n elementos devem ser distribuídos em m grupos de tamanhos $n_1, \dots, n_m$, com

$$n_1 + \dots + n_m = n,$$

o número de configurações é dado pelo coeficiente multinomial

$$\binom{n}{n_1, \dots, n_m} = \frac{n!}{n_1! \dots n_m!}.$$

💡 Uso posterior

Os coeficientes binomial e multinomial aparecem diretamente nas funções de probabilidade das distribuições binomial, hipergeométrica e multinomial. Nesta revisão, a combinatoria será utilizada como ferramenta para descrever esses modelos, sem retomar técnicas de contagem mais específicas.

Probabilidade condicional

A ocorrência de um evento pode alterar a probabilidade atribuída a outro evento.

Se $P(B) > 0$, a **probabilidade condicional** de A (ocorrer) dado B (ocorreu) é definida por

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

A expressão representa a probabilidade de A quando a informação disponível restringe o espaço de possibilidades ao evento B .

Da definição decorre a regra do produto:

$$P(A \cap B) = P(A | B)P(B).$$

Também podemos escrever

$$P(A \cap B) = P(B | A)P(A),$$

quando $P(A) > 0$.

Para uma sequência de eventos $A_1, \dots, A_n$, a regra pode ser estendida na forma

$$P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2 | A_1) \dots P(A_n | A_1 \cap \dots \cap A_{n-1}),$$

desde que as probabilidades condicionais envolvidas estejam definidas (Magalhães, 2006; Ross, 2006).

Lei da probabilidade total

Considere uma partição do espaço amostral formada pelos eventos

$$B_1, \dots, B_k,$$

tais que

$$B_i \cap B_j = \emptyset, \quad i \neq j,$$

e

$$\bigcup_{j=1}^k B_j = \Omega.$$

Se $P(B_j) > 0$, então, para qualquer evento A ,

$$P(A) = \sum_{j=1}^k P(A \mid B_j)P(B_j).$$

A expressão decompõe a probabilidade de A segundo os diferentes eventos que formam a partição.

Teorema de Bayes

Com a mesma partição $B_1, \dots, B_k$, se $P(A) > 0$, então

$$P(B_j \mid A) = \frac{P(A \mid B_j)P(B_j)}{\sum_{\ell=1}^k P(A \mid B_\ell)P(B_\ell)}.$$

O teorema de Bayes permite inverter o condicionamento quando são conhecidas as probabilidades $P(B_j)$ e $P(A \mid B_j)$.

Considere uma condição presente em 2% de uma população. Um teste apresenta sensibilidade de 95% e produz resultado positivo em 5% das pessoas que não apresentam a condição.

Se D representa a presença da condição e H um resultado positivo, então

$$P(D) = 0,02, \quad P(H \mid D) = 0,95$$

e

$$P(H \mid D^c) = 0,05.$$

Pela lei da probabilidade total,

$$P(H) = 0,95(0,02) + 0,05(0,98) = 0,068.$$

Assim,

$$P(D \mid H) = \frac{0,95(0,02)}{0,068} \approx 0,279.$$

A probabilidade condicional $P(D \mid H)$ não coincide com $P(H \mid D)$. A diferença decorre da frequência da condição na população e das duas probabilidades condicionais associadas ao teste.

Independência de eventos

Dois eventos A e B são **independentes** quando

$$P(A \cap B) = P(A)P(B).$$

Se $P(B) > 0$, essa condição equivale a

$$P(A \mid B) = P(A).$$

Nesse caso, saber que B ocorreu não altera a probabilidade atribuída a A .

Independência não deve ser confundida com exclusão mútua. Se A e B são mutuamente exclusivos e ambos possuem probabilidade positiva, então

$$P(A \cap B) = 0,$$

enquanto

$$P(A)P(B) > 0.$$

Portanto, eventos mutuamente exclusivos com probabilidades positivas não são independentes.

Para eventos $A_1, \dots, A_n$, independência conjunta requer que, para todo subconjunto de índices $\{i_1, \dots, i_r\}$,

$$P(A_{i_1} \cap \dots \cap A_{i_r}) = \prod_{j=1}^r P(A_{i_j}).$$

A independência aos pares, isoladamente, não garante independência conjunta (Dantas, 1997; Magalhães, 2006).

Variáveis aleatórias e distribuições

Uma **variável aleatória** associa um valor numérico a cada resultado de um experimento aleatório. Sua distribuição descreve os valores que podem ocorrer e as probabilidades associadas a esses valores ou conjuntos de valores.

Ao longo do livro, letras maiúsculas, como X , Y e Z , representarão variáveis aleatórias. Letras minúsculas, como x , y e z , representarão valores possíveis ou observados dessas variáveis.

Função de distribuição, suporte e quantis

A função de distribuição de uma variável aleatória X é

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Toda função de distribuição satisfaz:

1. F_X é não decrescente;
2. F_X é contínua à direita;
3. $F_X(x) \rightarrow 0$ quando $x \rightarrow -\infty$;
4. $F_X(x) \rightarrow 1$ quando $x \rightarrow +\infty$.

O **suporte** de uma variável aleatória será entendido, neste livro, como o conjunto de valores admissíveis para a variável sob a distribuição considerada. No caso discreto, corresponde aos valores aos quais a função de probabilidade atribui probabilidade positiva. No caso absolutamente contínuo, será representado pelo conjunto em que a densidade é positiva, desconsiderando diferenças em conjuntos de probabilidade nula.

Em modelos paramétricos, o suporte pode depender do parâmetro. Essa distinção será utilizada posteriormente, pois algumas condições de regularidade em Inferência Estatística pressupõem que o suporte seja comum a todos os valores do parâmetro.

O quantil de ordem $u \in (0, 1)$ pode ser definido por

$$F_X^{-1}(u) = \inf\{x : F_X(x) \geq u\}.$$

Essa definição funciona também para distribuições discretas (Rice, 2007, caps. 1–2; Ramachandran; Tsokos, 2021, sec. 3.1).

Variáveis discretas e absolutamente contínuas

Uma variável aleatória discreta possui função de probabilidade

$$p_X(x) = P(X = x),$$

com

$$p_X(x) \geq 0 \quad \text{e} \quad \sum_x p_X(x) = 1.$$

Uma variável aleatória é **absolutamente contínua** quando existe uma densidade f_X tal que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt,$$

com

$$f_X(x) \geq 0 \quad \text{e} \quad \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Nesse caso,

$$P(a < X \leq b) = \int_a^b f_X(x) dx$$

e

$$P(X = x) = 0$$

para todo ponto x . A probabilidade pontual é nula porque um conjunto unitário possui medida de comprimento zero, e não simplesmente porque a variável assume infinitos valores (Rice, 2007, cap. 2; Ramachandran; Tsokos, 2021, secs. 3.1–3.2).

Função indicadora

Para um conjunto A , a função indicadora de A é definida por

$$\mathbf{1}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

A função indicadora permite incorporar o conjunto de valores admissíveis de uma variável diretamente em sua função de probabilidade ou densidade. Por exemplo,

$$f_X(x) = g(x)\mathbf{1}_A(x)$$

indica que a densidade é dada por $g(x)$ para $x \in A$ e é nula fora desse conjunto.

Essa notação será utilizada na apresentação dos modelos probabilísticos deste capítulo.

Funções de variáveis aleatórias

Se X é uma variável aleatória e

$$Y = g(X),$$

então Y também é uma variável aleatória. Sua distribuição é determinada pela distribuição de X e pela transformação g .

Em alguns casos, a distribuição de Y pode ser obtida diretamente por meio de sua função de distribuição:

$$F_Y(y) = P\{g(X) \leq y\}.$$

Quando X é absolutamente contínua e g é estritamente monótona e diferenciável, uma expressão para a densidade de Y será retomada posteriormente neste capítulo.

Esperança, variância e momentos

Esperança e momentos

Para uma função g , a esperança de $g(X)$ é

$$E\{g(X)\} = \sum_x g(x)p_X(x)$$

no caso discreto, e

$$E\{g(X)\} = \int_{-\infty}^{\infty} g(x)f_X(x) dx$$

no caso absolutamente contínuo, desde que a soma ou a integral esteja bem definida.

A esperança é linear:

$$E\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i E(X_i) + b,$$

sem necessidade de independência.

O r -ésimo momento em torno da origem é

$$E(X^r),$$

e o r -ésimo momento central é

$$E\{[X - E(X)]^r\}.$$

Média e variância são determinadas pelos primeiros momentos da distribuição, enquanto medidas como assimetria e curtose são construídas a partir de momentos centrais padronizados. (Rice, 2007, sec. 4.1; Ramachandran; Tsokos, 2021, secs. 3.1 e 3.3).

Modelos probabilísticos discretos

Modelos probabilísticos discretos descrevem variáveis aleatórias que assumem valores em conjuntos finitos ou enumeráveis. A escolha de uma distribuição depende do mecanismo que produz a variável observada. Contagens de sucessos em ensaios independentes, amostragem sem reposição, número de tentativas até determinado evento e contagens em intervalos correspondem a estruturas probabilísticas distintas.

Nesta revisão, serão considerados os modelos Bernoulli, binomial, hipergeométrico, geométrico, binomial negativo, Poisson e multinomial. A distribuição uniforme discreta será apresentada de forma resumida. As parametrizações adotadas serão mantidas ao longo do livro (Dantas, 1997; Magalhães, 2006; Ross, 2006).

Distribuição uniforme discreta

Se X assume os valores distintos $x_1, \dots, x_m$ com a mesma probabilidade, então

$$p_X(x) = \frac{1}{m} \mathbf{1}_{\{x_1, \dots, x_m\}}(x).$$

Nesse caso, X possui distribuição **uniforme discreta** sobre o conjunto $\{x_1, \dots, x_m\}$.

Quando os valores possíveis são

$$1, 2, \dots, m,$$

temos

$$E(X) = \frac{m+1}{2}$$

e

$$\text{Var}(X) = \frac{m^2 - 1}{12}.$$

Esse modelo descreve situações em que um conjunto finito de resultados possui probabilidades iguais, como o resultado de um dado equilibrado ou a seleção aleatória de um elemento de uma população numerada.

Distribuição de Bernoulli

Um **ensaio de Bernoulli** é um experimento com dois resultados possíveis, representados por 1 e 0. Convencionalmente, esses resultados são denominados sucesso e fracasso.

Uma variável aleatória X possui distribuição de Bernoulli com parâmetro $p \in (0, 1)$ quando sua função de probabilidade é

$$p_X(x) = p^x(1-p)^{1-x}\mathbf{1}_{\{0,1\}}(x).$$

Escrevemos

$$X \sim \text{Bernoulli}(p).$$

A esperança e a variância são

$$E(X) = p$$

e

$$\text{Var}(X) = p(1-p).$$

Uma variável de Bernoulli pode ser utilizada para representar a presença ou ausência de uma característica. Se $X = 1$ indica que uma unidade apresenta determinada característica e $X = 0$ indica que não apresenta, então p representa a probabilidade de ocorrência dessa característica.

A função indicadora fornece uma representação direta desse modelo. Para um evento A ,

$$Y = \mathbf{1}_A$$

possui distribuição de Bernoulli com parâmetro

$$p = P(A).$$

Considere a seleção aleatória de uma unidade de uma população e defina

$$Y = \begin{cases} 1, & \text{se a unidade apresenta a característica de interesse,} \\ 0, & \text{caso contrário.} \end{cases}$$

Se a probabilidade de uma unidade apresentar a característica é p , então

$$Y \sim \text{Bernoulli}(p).$$

Distribuição binomial

Considere n ensaios de Bernoulli independentes, todos com a mesma probabilidade de sucesso p . Se

$$X_i \sim \text{Bernoulli}(p), \quad i = 1, \dots, n,$$

e $X_1, \dots, X_n$ são independentes, então o número total de sucessos

$$X = \sum_{i=1}^n X_i$$

possui distribuição binomial,

$$X \sim \text{Binomial}(n, p).$$

Sua função de probabilidade é

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x} \mathbf{1}_{\{0,1,\dots,n\}}(x).$$

O termo

$$\binom{n}{x}$$

corresponde ao número de maneiras de posicionar x sucessos entre os n ensaios.

Como X é uma soma de variáveis Bernoulli independentes,

$$E(X) = \sum_{i=1}^n E(X_i) = np$$

e

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(X_i) = np(1-p).$$

A variável

$$\frac{X}{n}$$

representa a proporção de sucessos nos n ensaios e possui esperança

$$E\left(\frac{X}{n}\right) = p$$

e variância

$$\text{Var}\left(\frac{X}{n}\right) = \frac{p(1-p)}{n}.$$

Essa relação será retomada no estudo da proporção amostral.

i Estrutura do modelo binomial

A distribuição binomial resulta de três condições:

1. o número de ensaios n é fixado;
2. os ensaios são independentes;
3. a probabilidade de sucesso p é a mesma em todos os ensaios.

Quando alguma dessas condições é alterada, outro modelo pode ser necessário.

Distribuição hipergeométrica

A distribuição hipergeométrica descreve contagens de sucessos em uma amostra retirada **sem reposição** de uma população finita.

Considere uma população com:

- N unidades;
- M unidades classificadas como sucesso;
- $N - M$ unidades classificadas como fracasso.

Seleciona-se uma amostra de tamanho n , sem reposição, e define-se X como o número de sucessos observados na amostra. Então

$$X \sim \text{Hipergeometrica}(N, M, n)$$

Defina

$$\mathcal{X} = \{\max\{0, n - N + M\}, \dots, \min\{n, M\}\}.$$

Então

$$p_X(x) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}} \mathbf{1}_{\mathcal{X}}(x).$$

Definindo

$$p = \frac{M}{N},$$

temos

$$E(X) = np$$

e

$$\text{Var}(X) = np(1-p) \frac{N-n}{N-1}.$$

O fator

$$\frac{N-n}{N-1}$$

é decorrente da amostragem sem reposição. As retiradas não são independentes, pois a composição da população disponível é alterada após cada unidade selecionada.

A distribuição hipergeométrica, e não a binomial, é o modelo exato para amostragem sem reposição em população finita (Ramachandran; Tsokos, 2021, secs. 3.2.1–3.2.4; Chihara; Hesterberg, 2022, aps. B.1–B.6).

Binomial e hipergeométrica

As distribuições binomial e hipergeométrica descrevem o número de sucessos em n observações, mas correspondem a mecanismos diferentes.

Característica	Binomial	Hipergeométrica
Número de observações	n	n
Número de sucessos	X	X
Probabilidade inicial de sucesso	p	$p = M/N$
Reposição	sim ou população conceitualmente ilimitada	não
Independência entre observações	sim	não
Esperança	np	np
Variância	$np(1-p)$	$np(1-p)\frac{N-n}{N-1}$

Quando N é grande em relação a n , o fator

$$\frac{N-n}{N-1}$$

fica próximo de 1. Nessas condições, a distribuição binomial pode fornecer uma aproximação para a distribuição hipergeométrica.

Relação com o experimento da urna

Essa distinção será utilizada no capítulo **Fundamentos da Inferência Estatística**. A retirada de bolas sem reposição corresponde a um modelo hipergeométrico, enquanto uma sequência de retiradas independentes com probabilidade constante de sucesso corresponde ao modelo Bernoulli/binomial.

Distribuição geométrica

Considere uma sequência de ensaios de Bernoulli independentes, com probabilidade de sucesso p em cada ensaio. Seja X o número de ensaios necessários até a ocorrência do primeiro sucesso.

Nesse caso,

$$X \sim \text{Geométrica}(p)$$

e

$$p_X(x) = p(1-p)^{x-1} \mathbf{1}_{\{1,2,\dots\}}(x).$$

A esperança e a variância são

$$E(X) = \frac{1}{p}$$

e

$$\text{Var}(X) = \frac{1-p}{p^2}.$$

Nesta parametrização, X conta o **número de ensaios até o primeiro sucesso**, incluindo o ensaio em que o sucesso ocorre.

A distribuição geométrica possui a propriedade de falta de memória. Para inteiros não negativos m e n ,

$$P(X > m+n \mid X > m) = P(X > n).$$

A expressão indica que, depois de m tentativas sem sucesso, a distribuição do número adicional de tentativas necessárias permanece a mesma.

i Parametrização

Outra convenção define a variável geométrica como o número de fracassos antes do primeiro sucesso, com suporte $\{0, 1, 2, \dots\}$. Neste livro será utilizada a parametrização em que X representa o número de ensaios até o primeiro sucesso.

Distribuição binomial negativa

A distribuição binomial negativa estende o modelo geométrico. Considere ensaios de Bernoulli independentes, cada um com probabilidade de sucesso p , e seja X o número de ensaios necessários para observar o r -ésimo sucesso.

Então

$$X \sim \text{BinomialNegativa}(r, p),$$

com

$$p_X(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r} \mathbf{1}_{\{r, r+1, \dots\}}(x).$$

Para que o r -ésimo sucesso ocorra no ensaio x , entre os primeiros $x-1$ ensaios devem ocorrer exatamente $r-1$ sucessos, e o último ensaio deve ser um sucesso.

A esperança e a variância são

$$E(X) = \frac{r}{p}$$

e

$$\text{Var}(X) = \frac{r(1-p)}{p^2}.$$

Quando $r = 1$, obtém-se a distribuição geométrica.

i Parametrização

A distribuição binomial negativa também pode ser definida em termos do número de fracassos observados antes do r -ésimo sucesso. Neste livro, X representará o número total de ensaios necessários para atingir r sucessos.

Distribuição de Poisson

A distribuição de Poisson é utilizada para modelar contagens de ocorrências em uma região de observação, como um intervalo de tempo, uma área, um comprimento ou um volume. Seu parâmetro $\lambda > 0$ representa o número esperado de ocorrências nessa região.

Quando o modelo decorre de uma taxa ρ por unidade de exposição e a exposição considerada é t , pode-se escrever

$$\lambda = \rho t.$$

Se

$$X \sim \text{Poisson}(\lambda), \quad \lambda > 0,$$

então

$$p_X(x) = e^{-\lambda} \frac{\lambda^x}{x!} \mathbf{1}_{\{0,1,2,\dots\}}(x).$$

A esperança e a variância coincidem:

$$E(X) = \lambda$$

e

$$\text{Var}(X) = \lambda.$$

O parâmetro λ representa o número médio de ocorrências na região de observação especificada.

Se a taxa de ocorrência por unidade de exposição é ρ e a exposição considerada é t , pode-se escrever

$$\lambda = \rho t.$$

Assim, o significado de λ depende da escala utilizada para definir a região de observação.

Se o número de chegadas a determinado serviço durante uma hora é modelado por

$$X \sim \text{Poisson}(12),$$

então o modelo atribui

$$E(X) = 12$$

e

$$\text{Var}(X) = 12.$$

O parâmetro refere-se ao intervalo de uma hora. Uma mudança na duração do intervalo requer uma correspondente alteração no valor esperado da contagem.

Relação entre binomial e Poisson

A distribuição de Poisson pode surgir como aproximação da distribuição binomial quando o número de ensaios é grande e a probabilidade de sucesso em cada ensaio é pequena.

Se

$$X_n \sim \text{Binomial}(n, p_n),$$

com

$$n \rightarrow \infty, \quad p_n \rightarrow 0$$

e

$$np_n \rightarrow \lambda,$$

então, para cada $x = 0, 1, 2, \dots$,

$$P(X_n = x) \longrightarrow e^{-\lambda} \frac{\lambda^x}{x!}.$$

Assim, uma contagem resultante de muitos ensaios com baixa probabilidade individual de sucesso pode, em determinadas situações, ser aproximada por uma distribuição de Poisson.

Soma de variáveis Poisson independentes

Se

$$X_1 \sim \text{Poisson}(\lambda_1), \quad X_2 \sim \text{Poisson}(\lambda_2),$$

e X_1 e X_2 são independentes, então

$$X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2).$$

Mais geralmente, se $X_1, \dots, X_k$ são independentes e

$$X_j \sim \text{Poisson}(\lambda_j),$$

então

$$\sum_{j=1}^k X_j \sim \text{Poisson} \left(\sum_{j=1}^k \lambda_j \right).$$

Essa propriedade relaciona a soma de contagens independentes à soma de suas taxas médias.

Distribuição multinomial

A distribuição multinomial estende a distribuição binomial para situações em que cada ensaio pode resultar em uma entre m categorias.

Considere n ensaios independentes. Em cada ensaio, uma observação é classificada em exatamente uma das categorias

$$1, \dots, m,$$

com probabilidades

$$p_1, \dots, p_m,$$

tais que

$$p_j \geq 0$$

e

$$\sum_{j=1}^m p_j = 1.$$

Se X_j representa o número de observações classificadas na categoria j , então

$$(X_1, \dots, X_m) \sim \text{Multinomial}(n; p_1, \dots, p_m).$$

Como cada uma das n observações pertence a uma única categoria,

$$\sum_{j=1}^m X_j = n.$$

Defina o conjunto

$$\mathcal{X}_n = \left\{ (x_1, \dots, x_m) \in \mathbb{N}_0^m : \sum_{j=1}^m x_j = n \right\}.$$

A função de probabilidade conjunta é

$$p_{\mathbf{X}}(\mathbf{x}) = \frac{n!}{x_1! \cdots x_m!} \prod_{j=1}^m p_j^{x_j} \mathbf{1}_{\mathcal{X}_n}(\mathbf{x}).$$

para

$$x_j \in \{0, 1, \dots, n\}, \quad \sum_{j=1}^m x_j = n.$$

Para cada categoria,

$$E(X_j) = np_j$$

e

$$\text{Var}(X_j) = np_j(1 - p_j).$$

Para categorias distintas,

$$\text{Cov}(X_j, X_k) = -np_j p_k, \quad j \neq k.$$

A covariância negativa decorre da restrição

$$X_1 + \cdots + X_m = n.$$

Com n fixo, um aumento na contagem de uma categoria reduz o número de observações disponível para as demais.

Quando $m = 2$, a distribuição multinomial reduz-se ao modelo binomial.

A distribuição multinomial será retomada posteriormente no estudo de dados categóricos (Rachandran; Tsokos, 2021, secs. 3.2.1–3.2.4; Chihara; Hesterberg, 2022, aps. B.1–B.6).

Relações entre os modelos discretos

Os modelos apresentados podem ser organizados segundo o mecanismo que define a variável aleatória.

Modelo	Variável modelada	Estrutura
Bernoulli(p)	resultado de um único ensaio	sucesso ou fracasso
Binomial(n, p)	número de sucessos em n ensaios	Bernoulli independentes
Hipergeométrica(N, M, n)	número de sucessos em uma amostra	população finita, sem reposição
Geométrica(p)	número de ensaios até o primeiro sucesso	Bernoulli sequenciais
Binomial negativa(r, p)	número de ensaios até o r -ésimo sucesso	extensão da geométrica
Poisson(λ)	número de ocorrências em uma região de observação	modelo de contagens
Multinomial($n; p_1, \dots, p_m$)	contagens em m categorias	extensão da binomial

As principais relações podem ser resumidas por

$$\text{Bernoulli} \longrightarrow \text{Binomial},$$

$$\text{Geométrica} \longrightarrow \text{BinomialNegativa},$$

e

$$\text{Binomial} \longrightarrow \text{Multinomial}.$$

A distribuição hipergeométrica fornece a correspondente estrutura de contagem quando a seleção ocorre sem reposição em uma população finita. A distribuição de Poisson descreve outra classe de problemas de contagem e também pode surgir como limite da distribuição binomial.

Modelos probabilísticos contínuos

Modelos probabilísticos contínuos descrevem variáveis aleatórias cujos valores pertencem a subconjuntos contínuos da reta real. Nesse caso, as probabilidades são obtidas a partir de uma função de densidade, e a probabilidade de um valor isolado é nula.

Nesta revisão, serão considerados os modelos uniforme, exponencial, gama, normal e beta. Esses modelos reaparecem em diferentes etapas da Inferência Estatística, seja na construção de distribuições amostrais, na estimação de parâmetros ou na formulação de procedimentos inferenciais (Dantas, 1997; Magalhães, 2006; Meyer, 1983).

Distribuição uniforme contínua

Uma variável aleatória X possui distribuição uniforme no intervalo (a, b) , com $a < b$, quando sua densidade é

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{(a,b)}(x).$$

Escrevemos

$$X \sim \text{Uniforme}(a, b).$$

A função de distribuição é

$$F_X(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b. \end{cases}$$

A esperança e a variância são

$$E(X) = \frac{a+b}{2}$$

e

$$\text{Var}(X) = \frac{(b-a)^2}{12}.$$

A densidade constante indica que intervalos de mesmo comprimento, contidos em (a, b) , recebem a mesma probabilidade.

Um caso que será utilizado posteriormente ocorre quando

$$X \sim \text{Uniforme}(0, \theta), \quad \theta > 0.$$

Nesse modelo,

$$f_X(x | \theta) = \frac{1}{\theta} \mathbf{1}_{(0, \theta)}(x).$$

O suporte depende, portanto, do parâmetro θ .

i Suporte dependente do parâmetro

No modelo $\text{Uniforme}(0, \theta)$, o conjunto de valores possíveis para X depende do parâmetro θ . Essa característica será retomada no estudo de máxima verossimilhança e das condições de regularidade.

Distribuição exponencial

Uma variável aleatória X possui distribuição exponencial com taxa $\lambda > 0$ quando

$$f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x).$$

Escrevemos

$$X \sim \text{Exponencial}(\lambda).$$

A função de distribuição é

$$F_X(x) = \begin{cases} 0, & x \leq 0, \\ 1 - e^{-\lambda x}, & x > 0. \end{cases}$$

Para $x \geq 0$, a função de sobrevivência é

$$P(X > x) = e^{-\lambda x}.$$

A esperança e a variância são

$$E(X) = \frac{1}{\lambda}$$

e

$$\text{Var}(X) = \frac{1}{\lambda^2}.$$

O modelo exponencial é utilizado para representar tempos de espera ou tempos até a ocorrência de determinado evento quando uma taxa constante é adequada ao fenômeno considerado.

Uma de suas propriedades é a falta de memória:

$$P(X > s + t \mid X > s) = P(X > t), \quad s, t > 0.$$

Assim, condicionada à sobrevivência até o instante s , a distribuição do tempo adicional de espera é a mesma distribuição exponencial original.

i Parametrização

Neste livro, a distribuição exponencial será parametrizada pela **taxa** λ . Nessa parametrização,

$$E(X) = \frac{1}{\lambda}.$$

Outra convenção utiliza diretamente a média ou escala como parâmetro. A parametrização adotada deve ser verificada ao comparar fórmulas entre diferentes referências.

Distribuição gama

A distribuição gama estende o modelo exponencial e permite representar uma variedade maior de formas para variáveis positivas.

Neste livro, será utilizada a parametrização por **forma** $\alpha > 0$ e **taxa** $\lambda > 0$. Escrevemos

$$X \sim \text{Gama}(\alpha, \lambda)$$

quando

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x).$$

em que

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt$$

é a função gama.

A esperança e a variância são

$$E(X) = \frac{\alpha}{\lambda}$$

e

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

Quando $\alpha = 1$,

$$X \sim \text{Gama}(1, \lambda)$$

reduz-se à distribuição exponencial com taxa λ .

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\lambda),$$

então

$$\sum_{i=1}^n X_i \sim \text{Gama}(n, \lambda).$$

Essa relação será utilizada posteriormente na obtenção de distribuições exatas associadas a amostras exponenciais.

i Forma e taxa

A literatura também utiliza a parametrização por forma α e escala β , com densidade

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \mathbf{1}_{(0,\infty)}(x).$$

em que

$$\beta = \frac{1}{\lambda}.$$

Neste livro será utilizada, salvo indicação contrária, a parametrização por forma e taxa.

Relação entre exponencial e gama

A relação entre os dois modelos pode ser resumida por

$$\text{Exponencial}(\lambda) = \text{Gama}(1, \lambda).$$

Além disso, somas de variáveis exponenciais independentes com a mesma taxa possuem distribuição gama.

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\lambda),$$

então

$$S_n = \sum_{i=1}^n X_i \sim \text{Gama}(n, \lambda).$$

Consequentemente,

$$E(S_n) = \frac{n}{\lambda}$$

e

$$\text{Var}(S_n) = \frac{n}{\lambda^2}.$$

Essa propriedade fornece uma ligação entre o modelo probabilístico de observações individuais e a distribuição de uma estatística construída a partir da amostra.

Distribuição normal

Uma variável aleatória X possui distribuição normal com média μ e variância $\sigma^2 > 0$ quando sua densidade é

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} \mathbf{1}_{\mathbb{R}}(x).$$

Escrevemos

$$X \sim N(\mu, \sigma^2).$$

A esperança e a variância são

$$E(X) = \mu$$

e

$$\text{Var}(X) = \sigma^2.$$

O parâmetro μ determina a localização da distribuição, enquanto σ determina sua dispersão.

A densidade é simétrica em torno de μ . Em particular,

$$P(X \leq \mu) = \frac{1}{2}.$$

Se

$$X \sim N(\mu, \sigma^2),$$

então a transformação

$$Z = \frac{X - \mu}{\sigma}$$

possui distribuição normal padrão,

$$Z \sim N(0, 1).$$

Consequentemente,

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right),$$

em que Φ representa a função de distribuição da normal padrão.

Se

$$X \sim N(100, 15^2),$$

então

$$P(X \leq 115) = P\left(\frac{X - 100}{15} \leq 1\right) = \Phi(1).$$

A padronização permite expressar probabilidades de qualquer distribuição normal em termos da distribuição $N(0, 1)$.

Transformações lineares da distribuição normal

Se

$$X \sim N(\mu, \sigma^2)$$

e

$$Y = aX + b,$$

com $a \neq 0$, então

$$Y \sim N(a\mu + b, a^2\sigma^2).$$

Além disso, se

$$X_1, \dots, X_n$$

são independentes e

$$X_i \sim N(\mu_i, \sigma_i^2),$$

então, para constantes $a_1, \dots, a_n$,

$$\sum_{i=1}^n a_i X_i \sim N \left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2 \right).$$

Em particular, se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

então

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

possui distribuição

$$\bar{X} \sim N \left(\mu, \frac{\sigma^2}{n} \right).$$

Esse resultado será retomado no estudo das distribuições amostrais.

Distribuição beta

Uma variável aleatória X possui distribuição beta com parâmetros $\alpha > 0$ e $\beta > 0$ quando

$$f_X(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} \mathbf{1}_{(0,1)}(x).$$

em que

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$$

é a função beta.

A função beta relaciona-se à função gama por

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

Escrevemos

$$X \sim \text{Beta}(\alpha, \beta).$$

A esperança e a variância são

$$E(X) = \frac{\alpha}{\alpha + \beta}$$

e

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

O suporte da distribuição beta é o intervalo $(0, 1)$, o que torna esse modelo adequado para representar variáveis contínuas restritas a esse intervalo.

Dependendo dos valores de α e β , a densidade pode apresentar formas distintas. Quando

$$\alpha = \beta = 1,$$

temos

$$X \sim \text{Uniforme}(0, 1).$$

Quando

$$\alpha = \beta,$$

a densidade é simétrica em torno de $1/2$.

Relações entre gama e beta

As distribuições gama e beta estão relacionadas por transformações de variáveis aleatórias independentes.

Se

$$X \sim \text{Gama}(\alpha, \lambda)$$

e

$$Y \sim \text{Gama}(\beta, \lambda),$$

independentes, então

$$\frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta).$$

Além disso,

$$X + Y \sim \text{Gama}(\alpha + \beta, \lambda).$$

Essas relações serão úteis para compreender algumas distribuições derivadas que aparecem posteriormente no estudo de estatísticas construídas a partir de amostras normais.

Escolha entre alguns modelos contínuos

Os modelos contínuos podem ser associados a diferentes estruturas probabilísticas.

Situação modelada	Distribuição possível
valores distribuídos uniformemente em um intervalo	Uniforme
tempo até um evento com taxa constante	Exponencial
soma de tempos exponenciais ou tempo até sucessivos eventos	Gama
variável contínua aproximadamente simétrica em torno de uma média	Normal
variável contínua limitada ao intervalo (0, 1)	Beta

A adequação de uma distribuição depende do mecanismo considerado, das propriedades da variável e das hipóteses adotadas. Esses modelos serão utilizados posteriormente como componentes de modelos estatísticos.

i Distribuições derivadas do modelo normal

As distribuições qui-quadrado, t de Student e F estão relacionadas a funções de variáveis normais. Elas serão apresentadas no estudo das distribuições amostrais, quando surgirem naturalmente a partir da média e da variância amostrais.

Distribuições conjuntas e dependência

Muitos problemas probabilísticos envolvem mais de uma variável aleatória observada simultaneamente. Nesses casos, além do comportamento individual de cada variável, é necessário descrever como elas se relacionam.

Considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top.$$

Sua distribuição conjunta determina as probabilidades associadas aos possíveis valores de todas as componentes. A partir dela podem ser obtidas as distribuições marginais e condicionais, assim como medidas de dependência entre as variáveis.

Distribuição conjunta

Para duas variáveis aleatórias X e Y , a função de distribuição conjunta é definida por

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y).$$

No caso discreto, a distribuição conjunta pode ser representada pela função de probabilidade

$$p_{X,Y}(x, y) = P(X = x, Y = y),$$

que satisfaz

$$p_{X,Y}(x, y) \geq 0$$

e

$$\sum_x \sum_y p_{X,Y}(x, y) = 1.$$

No caso absolutamente contínuo, a distribuição conjunta é caracterizada por uma função de densidade $f_{X,Y}$ tal que

$$f_{X,Y}(x, y) \geq 0$$

e

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx \, dy = 1.$$

Para uma região $A \subseteq \mathbb{R}^2$,

$$P\{(X, Y) \in A\} = \iint_A f_{X,Y}(x, y) \, dx \, dy.$$

A mesma ideia se estende a vetores com mais de duas componentes, utilizando uma função de probabilidade ou densidade conjunta definida no suporte do vetor aleatório.

Distribuições marginais

A distribuição marginal descreve o comportamento de uma componente do vetor aleatório sem condicionar aos valores das demais.

No caso discreto, a função de probabilidade marginal de X é obtida somando a função conjunta sobre todos os valores possíveis de Y :

$$p_X(x) = \sum_y p_{X,Y}(x, y).$$

Analogamente,

$$p_Y(y) = \sum_x p_{X,Y}(x, y).$$

No caso absolutamente contínuo,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dy$$

e

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx.$$

A operação de soma ou integração elimina da distribuição conjunta a variável que não aparece na distribuição marginal desejada.

Distribuições condicionais

A distribuição condicional descreve o comportamento de uma variável quando se conhece o valor assumido por outra.

No caso discreto, se $p_Y(y) > 0$,

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Para cada valor fixado de y ,

$$\sum_x p_{X|Y}(x | y) = 1.$$

No caso absolutamente contínuo, se $f_Y(y) > 0$,

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

com

$$\int_{-\infty}^{\infty} f_{X|Y}(x | y) dx = 1.$$

A distribuição conjunta pode ser recuperada a partir de uma distribuição marginal e da distribuição condicional correspondente:

$$p_{X,Y}(x, y) = p_{X|Y}(x | y)p_Y(y)$$

no caso discreto e

$$f_{X,Y}(x, y) = f_{X|Y}(x | y)f_Y(y)$$

no caso absolutamente contínuo.

Distribuições condicionais sustentam a esperança condicional, o teorema de Rao–Blackwell e a etapa E do algoritmo EM (Rice, 2007, secs. 3.2–3.5; Ramachandran; Tsokos, 2021, sec. 3.3).

Considere duas variáveis aleatórias X e Y com função de probabilidade conjunta dada por

X	$Y = 0$	$Y = 1$
0	0,20	0,10
1	0,30	0,40

A distribuição marginal de X é

$$P(X = 0) = 0,20 + 0,10 = 0,30$$

e

$$P(X = 1) = 0,30 + 0,40 = 0,70.$$

Para Y ,

$$P(Y = 0) = 0,20 + 0,30 = 0,50$$

e

$$P(Y = 1) = 0,10 + 0,40 = 0,50.$$

Condicionalizando em $Y = 1$,

$$P(X = 1 \mid Y = 1) = \frac{P(X = 1, Y = 1)}{P(Y = 1)} = \frac{0,40}{0,50} = 0,80.$$

Assim, a distribuição condicional de X pode diferir de sua distribuição marginal. Nesse exemplo,

$$P(X = 1) = 0,70,$$

enquanto

$$P(X = 1 \mid Y = 1) = 0,80.$$

Independência de variáveis aleatórias

As variáveis aleatórias X e Y são independentes quando

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

para todos os conjuntos mensuráveis A e B .

No caso discreto, a independência equivale a

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

para todos os valores possíveis de x e y .

No caso absolutamente contínuo, a fatoração correspondente é

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

quase sempre.

Se X e Y são independentes e as esperanças envolvidas existem, então

$$E\{g(X)h(Y)\} = E\{g(X)\}E\{h(Y)\}.$$

Em particular,

$$E(XY) = E(X)E(Y).$$

A recíproca não é verdadeira em geral. A igualdade entre determinados momentos não é suficiente para estabelecer independência (Rice, 2007, sec. 3.4; Ramachandran; Tsokos, 2021, secs. 2.4 e 3.3).

Independência de várias variáveis

As variáveis aleatórias

$$X_1, \dots, X_n$$

são mutuamente independentes quando, para quaisquer conjuntos mensuráveis $A_1, \dots, A_n$,

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n P(X_i \in A_i).$$

No caso discreto, essa condição equivale à fatoração

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i).$$

No caso absolutamente contínuo, corresponde a

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$$

quase sempre.

Se, além de independentes, todas as variáveis possuem a mesma distribuição P , escreve-se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

A sigla **i.i.d.** indica que as variáveis são **independentes e identicamente distribuídas**.

i Estrutura i.i.d.

A notação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} P$$

reúne duas condições distintas:

1. $X_1, \dots, X_n$ são independentes;
2. todas possuem a mesma distribuição P .

A estrutura i.i.d. será utilizada com frequência na representação probabilística de amostras aleatórias. Ela corresponde a uma hipótese sobre o mecanismo probabilístico adotado e não descreve todos os procedimentos de obtenção de dados.

Covariância e correlação

A covariância entre X e Y , definida anteriormente por

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y),$$

descreve a direção da associação linear entre duas variáveis.

Se X e Y são independentes e possuem segundos momentos finitos, então

$$E(XY) = E(X)E(Y),$$

e, portanto,

$$\text{Cov}(X, Y) = 0.$$

Assim,

$$X \perp Y \implies \text{Cov}(X, Y) = 0.$$

A recíproca não é válida em geral. Covariância nula não garante independência.

Considere

$$X \sim N(0, 1)$$

e

$$Y = X^2.$$

Como a distribuição de X é simétrica em torno de zero,

$$E(X) = 0$$

e

$$E(X^3) = 0.$$

Logo,

$$\text{Cov}(X, Y) = E(X^3) - E(X)E(X^2) = 0.$$

Entretanto, Y é completamente determinado por X , de modo que as variáveis não são independentes.

A covariância depende das unidades de medida. Para obter uma medida adimensional da associação linear, define-se o coeficiente de correlação por

$$\rho_{X,Y} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}},$$

desde que

$$\text{Var}(X) > 0 \quad \text{e} \quad \text{Var}(Y) > 0.$$

O coeficiente satisfaz

$$-1 \leq \rho_{X,Y} \leq 1.$$

Valores positivos indicam associação linear positiva e valores negativos indicam associação linear negativa. O valor

$$\rho_{X,Y} = 0$$

indica ausência de associação linear, mas não implica ausência de dependência.

i Independência e correlação

Independência implica correlação nula quando as variâncias existem. A implicação inversa não vale para distribuições arbitrárias.

Para variáveis conjuntamente normais, entretanto, correlação nula implica independência. Essa propriedade será retomada quando o modelo normal for utilizado em problemas inferenciais.

Esperança condicional

A distribuição condicional permite definir momentos condicionais.

No caso discreto,

$$E(X | Y = y) = \sum_x x p_{X|Y}(x | y),$$

desde que a soma esteja bem definida.

No caso absolutamente contínuo,

$$E(X | Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x | y) dx.$$

Ao permitir que Y varie, obtemos a variável aleatória

$$E(X | Y).$$

Mais geralmente, para uma função g ,

$$E\{g(X) | Y = y\}$$

é calculada utilizando a distribuição condicional de X dado $Y = y$.

Se X e Y são independentes e $E|X| < \infty$, então

$$E(X | Y) = E(X).$$

Nesse caso, conhecer Y não altera a média condicional de X .

! Lei da esperança total

Se $E|X| < \infty$, então

$$E(X) = E\{E(X | Y)\}.$$

A lei da esperança total permite calcular uma esperança em duas etapas: primeiro condicionando em Y e depois tomando a esperança em relação à distribuição de Y .

Considere uma variável Y que identifica dois grupos,

$$Y \in \{0, 1\},$$

com

$$P(Y = 0) = 0,6 \quad \text{e} \quad P(Y = 1) = 0,4.$$

Suponha que

$$E(X \mid Y = 0) = 10$$

e

$$E(X \mid Y = 1) = 20.$$

Então

$$E(X) = E\{E(X \mid Y)\}$$

e, portanto,

$$E(X) = 10(0,6) + 20(0,4) = 14.$$

Variância condicional

A variância condicional de X dado $Y = y$ é

$$\text{Var}(X \mid Y = y) = E[\{X - E(X \mid Y = y)\}^2 \mid Y = y].$$

Também pode ser escrita como

$$\text{Var}(X \mid Y = y) = E(X^2 \mid Y = y) - [E(X \mid Y = y)]^2.$$

Ao permitir que Y varie, obtém-se a variável aleatória

$$\text{Var}(X \mid Y).$$

! Lei da variância total

Se $E(X^2) < \infty$, então

$$\text{Var}(X) = E\{\text{Var}(X | Y)\} + \text{Var}\{E(X | Y)\}.$$

A primeira parcela,

$$E\{\text{Var}(X | Y)\},$$

representa a média das variâncias condicionais. A segunda,

$$\text{Var}\{E(X | Y)\},$$

representa a variabilidade entre as médias condicionais.

Essa decomposição separa a variabilidade total de X em uma componente associada à variação dentro das distribuições condicionais e outra associada à variação entre suas médias (Rice, 2007, sec. 4.4; Ramachandran; Tsokos, 2021, sec. 3.3).

Considere novamente

$$P(Y = 0) = 0,6, \quad P(Y = 1) = 0,4,$$

com

$$E(X | Y = 0) = 10, \quad E(X | Y = 1) = 20.$$

Suponha ainda que

$$\text{Var}(X | Y = 0) = 9$$

e

$$\text{Var}(X | Y = 1) = 16.$$

A primeira parcela da lei da variância total é

$$E\{\text{Var}(X | Y)\} = 9(0,6) + 16(0,4) = 11,8.$$

Como

$$E(X) = 14,$$

a variância das médias condicionais é

$$\text{Var}\{E(X | Y)\} = 0,6(10 - 14)^2 + 0,4(20 - 14)^2 = 24.$$

Portanto,

$$\text{Var}(X) = 11,8 + 24 = 35,8.$$

Vetores de médias e matrizes de covariâncias

Para o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top,$$

o vetor de médias é

$$E(\mathbf{X}) = \begin{pmatrix} E(X_1) \\ \vdots \\ E(X_k) \end{pmatrix}.$$

A matriz de covariâncias é

$$\Sigma = \text{Cov}(\mathbf{X}) = E [\{\mathbf{X} - E(\mathbf{X})\}\{\mathbf{X} - E(\mathbf{X})\}^\top].$$

Sua forma é

$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_k) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_k, X_1) & \text{Cov}(X_k, X_2) & \cdots & \text{Var}(X_k) \end{pmatrix}.$$

A diagonal contém as variâncias das componentes e os elementos fora da diagonal contêm as covariâncias entre pares de variáveis.

A matriz de covariâncias é simétrica e positiva semidefinida. Esses resultados serão utilizados posteriormente em parâmetros vetoriais, método delta multivariado e modelos lineares (Rice, 2007, secs. 4.2–4.3; Ramachandran; Tsokos, 2021, sec. 3.3.1).

Síntese das relações conjuntas

As principais relações desta seção podem ser organizadas na sequência

$$\text{distribuição conjunta} \longrightarrow \begin{cases} \text{distribuições marginais,} \\ \text{distribuições condicionais,} \end{cases}$$

seguida de

$$\text{distribuição conjunta} \longrightarrow \text{estrutura de dependência.}$$

Para variáveis independentes, a distribuição conjunta se fatora no produto das distribuições marginais. No caso discreto,

$$p_{X,Y}(x,y) = p_X(x)p_Y(y),$$

enquanto, no caso absolutamente contínuo,

$$f_{X,Y}(x,y) = f_X(x)f_Y(y)$$

quase sempre.

Covariância e a correlação descrevem apenas a associação linear.

O condicionamento também fornece as identidades

$$E(X) = E\{E(X | Y)\}$$

e

$$\text{Var}(X) = E\{\text{Var}(X | Y)\} + \text{Var}\{E(X | Y)\}.$$

A notação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} P$$

será utilizada posteriormente para representar uma sequência de variáveis independentes com a mesma distribuição.

Transformações e função geradora de momentos

Transformações de variáveis aleatórias permitem obter novas variáveis a partir de variáveis com distribuição conhecida. Se

$$Y = g(X),$$

a distribuição de Y depende da distribuição de X e da função g .

Nesta revisão, serão retomados o método da função de distribuição e a transformação de densidades no caso univariado. Transformações multivariadas e o uso do determinante jacobiano serão tratados no capítulo **Resultados Matemáticos e Assintóticos para Inferência**.

Transformações de variáveis aleatórias

Uma forma geral de obter a distribuição de

$$Y = g(X)$$

consiste em determinar sua função de distribuição:

$$F_Y(y) = P(Y \leq y) = P\{g(X) \leq y\}.$$

A partir de F_Y , pode-se obter a função de probabilidade, no caso discreto, ou a densidade, no caso absolutamente contínuo.

Transformação monótona

Se X é absolutamente contínua e g é estritamente monótona e diferenciável, então existe a função inversa

$$x = g^{-1}(y).$$

A densidade de

$$Y = g(X)$$

é

$$f_Y(y) = f_X\{g^{-1}(y)\} \left| \frac{d}{dy} g^{-1}(y) \right|,$$

para os valores de y pertencentes ao suporte de Y (Rice, 2007, secs. 2.3 e 3.6; Ramachandran; Tsokos, 2021, sec. 3.4).

O valor absoluto da derivada da transformação inversa ajusta a densidade à mudança de escala produzida por g .

Considere

$$Y = aX + b, \quad a \neq 0.$$

A transformação inversa é

$$x = \frac{y - b}{a}$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

Se, em particular,

$$X \sim N(\mu, \sigma^2),$$

então

$$Y = aX + b \sim N(a\mu + b, a^2\sigma^2),$$

resultado apresentado anteriormente para o modelo normal.

Transformações não monótonas

Quando g não é monotônica em todo o suporte de X , uma mesma realização de Y pode corresponder a mais de um valor de X . Nesse caso, o método da função de distribuição costuma fornecer uma forma direta de obter a distribuição resultante.

Considere, por exemplo,

$$Y = X^2.$$

Para $y \geq 0$,

$$F_Y(y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}).$$

Logo,

$$F_Y(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y}),$$

quando X é contínua. A densidade de Y , quando necessária, pode ser obtida derivando essa expressão em relação a y .

i Transformações multivariadas

Para transformações de vetores aleatórios, a mudança de variáveis envolve o determinante da matriz jacobiana da transformação inversa. Esse resultado será retomado no capítulo **Resultados Matemáticos e Assintóticos para Inferência**, quando for necessário para obter distribuições de funções de vetores aleatórios.

Função geradora de momentos

A **função geradora de momentos (FGM)** de uma variável aleatória X é definida por

$$M_X(t) = E(e^{tX}),$$

desde que essa esperança exista em uma vizinhança de $t = 0$.

No caso discreto,

$$M_X(t) = \sum_x e^{tx} p_X(x),$$

enquanto, no caso absolutamente contínuo,

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx.$$

Obtenção de momentos

Quando a FGM é finita em uma vizinhança de zero, a derivada de ordem r é denotada por

$$M_X^{(r)}(t) = \frac{d^r}{dt^r} M_X(t).$$

A derivada de ordem r avaliada em $t = 0$ fornece o momento de ordem r :

$$M_X^{(r)}(0) = E(X^r).$$

Em particular,

$$M_X'(0) = E(X)$$

e

$$M_X''(0) = E(X^2).$$

Consequentemente,

$$\text{Var}(X) = M_X''(0) - [M_X'(0)]^2.$$

Transformações lineares

Se

$$Y = aX + b,$$

então

$$M_Y(t) = E(e^{t(aX+b)}).$$

Assim,

$$M_Y(t) = e^{bt} M_X(at).$$

Essa relação permite obter a FGM de transformações lineares a partir da FGM da variável original.

Soma de variáveis independentes

Se $X_1, \dots, X_n$ são independentes e suas funções geradoras de momentos existem em uma vizinhança de zero, então

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n M_{X_i}(t).$$

Se, além disso,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} X,$$

então

$$M_{X_1 + \dots + X_n}(t) = [M_X(t)]^n.$$

Essa propriedade permite reconhecer a distribuição de somas de variáveis independentes quando a FGM resultante corresponde à de uma distribuição conhecida.

Se

$$X_1 \sim \text{Poisson}(\lambda_1)$$

e

$$X_2 \sim \text{Poisson}(\lambda_2),$$

independentes, suas funções geradoras de momentos são

$$M_{X_1}(t) = \exp\{\lambda_1(e^t - 1)\}$$

e

$$M_{X_2}(t) = \exp\{\lambda_2(e^t - 1)\}.$$

Logo,

$$M_{X_1+X_2}(t) = \exp\{(\lambda_1 + \lambda_2)(e^t - 1)\},$$

que corresponde à FGM de uma distribuição de Poisson com parâmetro $\lambda_1 + \lambda_2$. Portanto,

$$X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2).$$

Considere variáveis independentes

$$X_i \sim N(\mu_i, \sigma_i^2), \quad i = 1, \dots, n.$$

Como

$$M_{X_i}(t) = \exp\left(\mu_i t + \frac{\sigma_i^2 t^2}{2}\right),$$

temos

$$M_{\sum_{i=1}^n X_i}(t) = \prod_{i=1}^n \exp\left(\mu_i t + \frac{\sigma_i^2 t^2}{2}\right).$$

Portanto,

$$M_{\sum_{i=1}^n X_i}(t) = \exp\left[\left(\sum_{i=1}^n \mu_i\right)t + \frac{1}{2}\left(\sum_{i=1}^n \sigma_i^2\right)t^2\right].$$

Essa é a FGM da distribuição

$$N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Assim,

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Identificação de distribuições

Se duas variáveis aleatórias possuem funções geradoras de momentos que existem e coincidem em uma vizinhança de $t = 0$, então elas possuem a mesma distribuição.

Essa propriedade, combinada com a regra do produto para variáveis independentes, permite utilizar a FGM para identificar distribuições de somas (Rice, 2007, sec. 4.5; Chihara; Hestenberg, 2022, ap. A.8).

Nem toda distribuição possui função geradora de momentos. Portanto, a FGM é uma ferramenta disponível quando sua existência estiver garantida.

Algumas funções geradoras de momentos

Para referência, algumas das distribuições apresentadas neste capítulo possuem as seguintes funções geradoras de momentos:

Distribuição	Função geradora de momentos
Bernoulli(p)	$1 - p + pe^t$
Binomial(n, p)	$(1 - p + pe^t)^n$
Poisson(λ)	$\exp\{\lambda(e^t - 1)\}$
Exponencial(λ)	$\frac{\lambda}{\lambda - t}, t < \lambda$
Gama(α, λ)	$\left(\frac{\lambda}{\lambda - t}\right)^\alpha, t < \lambda$
Normal(μ, σ^2)	$\exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$

A tabela também evidencia algumas relações apresentadas anteriormente. A FGM da binomial é a n -ésima potência da FGM de Bernoulli, e a FGM da soma de variáveis exponenciais independentes com a mesma taxa corresponde à FGM de uma distribuição gama.

Quadro-síntese dos modelos probabilísticos

Os modelos apresentados neste capítulo podem ser comparados segundo a variável que descrevem, seu suporte, seus parâmetros e seus momentos.

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$	Estrutura
Bernoulli	$\{0, 1\}$	p	p	$p(1 - p)$	resultado binário

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$	Estrutura
Binomial	$\{0, \dots, n\}$	n, p	np	$np(1-p)$	número de sucessos em n ensaios independentes
Hipergeométrica	finito	N, M, n	np	$np(1-p)\frac{N-n}{N-1}$	número de sucessos em amostragem sem reposição
Geométrica	$\{1, 2, \dots\}$	p	$\frac{1}{p}$	$\frac{1-p}{p^2}$	número de ensaios até o primeiro sucesso
Binomial negativa	$\{r, r+1, \dots\}$	r, p	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$	número de ensaios até o r -ésimo sucesso
Poisson	$\{0, 1, 2, \dots\}$	λ	λ	λ	número de ocorrências em uma região de observação
Multinomial	$\sum_j x_j = n$	$n, p_1, \dots, p_m$	$E(X_j) = np_j$	$\text{Var}(X_j) = np_j(1-p_j)$	contagens em várias categorias
Uniforme	(a, b)	a, b	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	densidade constante em um intervalo
Exponencial	$(0, \infty)$	λ	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	tempo até um evento sob taxa constante
Gama	$(0, \infty)$	α, λ	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$	soma de tempos exponenciais e variáveis positivas

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$	Estrutura
Normal	$\mathbb{R}$	μ, σ^2	μ	σ^2	modelo de localização e dispersão
Beta	$(0, 1)$	α, β	$\frac{\alpha}{\alpha + \beta}$	$\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$	variável contínua limitada a $(0, 1)$

A tabela resume propriedades de cada distribuição, mas a escolha de um modelo depende do mecanismo considerado. Duas variáveis com o mesmo suporte podem exigir modelos distintos quando correspondem a formas diferentes de produção dos dados.

Síntese

A revisão deste capítulo pode ser organizada em quatro componentes.

1. **Probabilidade e condicionamento:** eventos, probabilidade condicional, lei da probabilidade total, teorema de Bayes e independência.
2. **Variáveis aleatórias e distribuições:** função de distribuição, suporte, variáveis discretas e absolutamente contínuas, esperança, variância e momentos.
3. **Distribuições conjuntas e dependência:** distribuições marginais e condicionais, independência de variáveis aleatórias, covariância, correlação, esperança condicional e variância condicional.
4. **Modelos e operações probabilísticas:** modelos discretos e contínuos, transformações de variáveis aleatórias e função geradora de momentos.

Esses elementos fornecem a linguagem probabilística utilizada nos capítulos seguintes. A partir deles, uma coleção de observações pode ser representada por variáveis aleatórias, e diferentes hipóteses probabilísticas podem ser utilizadas para descrever o mecanismo que produz os dados.

Exercícios de consolidação

i Exercício 1

Considere dois eventos A e B com

$$P(A) = 0,4, \quad P(B) = 0,5$$

e

$$P(A \cap B) = 0,2.$$

Calcule $P(A | B)$ e verifique se A e B são independentes.

i Exercício 2

Explique por que dois eventos mutuamente exclusivos com probabilidades positivas não podem ser independentes.

i Exercício 3

Uma condição ocorre em 1% de determinada população. Um teste apresenta sensibilidade de 90% e especificidade de 95%.

Calcule a probabilidade de um indivíduo apresentar a condição dado que seu teste foi positivo.

i Exercício 4

Para cada situação abaixo, indique uma distribuição probabilística plausível e identifique seus parâmetros.

- Presença ou ausência de determinada característica em uma unidade selecionada aleatoriamente.
- Número de unidades com essa característica em 50 observações independentes.
- Número de unidades com a característica em uma amostra de tamanho 50 retirada sem reposição de uma população finita.
- Número de chamadas recebidas por uma central durante uma hora.
- Número de tentativas necessárias até o primeiro sucesso.
- Tempo até a ocorrência de determinado evento sob taxa constante.

i Exercício 5

Considere

$$X \sim \text{Binomial}(20, 0,3).$$

Obtenha

$$E(X), \quad \text{Var}(X)$$

e

$$P(X \leq 4).$$

i Exercício 6

Uma urna contém $N = 100$ bolas, das quais $M = 30$ são vermelhas.
Considere uma amostra de $n = 10$ bolas.

- Especifique a distribuição do número de bolas vermelhas quando a seleção ocorre sem reposição.
- Especifique um modelo para o número de bolas vermelhas em 10 retiradas independentes, com probabilidade de sucesso $p = 0,3$.
- Compare as esperanças e variâncias dos dois modelos.
- Explique a origem da diferença entre as variâncias.

i Exercício 7

Se

$$X \sim \text{Geométrica}(p),$$

mostre que

$$P(X > m + n \mid X > m) = P(X > n).$$

i Exercício 8

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p),$$

use funções geradoras de momentos para identificar a distribuição de

$$S_n = \sum_{i=1}^n X_i.$$

i Exercício 9

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\lambda),$$

obtenha a distribuição de

$$S_n = \sum_{i=1}^n X_i.$$

Calcule também $E(S_n)$ e $\text{Var}(S_n)$.

i Exercício 10

Se

$$X \sim N(\mu, \sigma^2)$$

e

$$Y = aX + b,$$

com $a \neq 0$, obtenha a distribuição de Y .

i Exercício 11

Mostre que a distribuição

$$\text{Beta}(1, 1)$$

coincide com a distribuição uniforme em $(0, 1)$.

i Exercício 12

Considere a função de probabilidade conjunta

X	$Y = 0$	$Y = 1$
0	0,10	0,20
1	0,30	0,40

- Obtenha as distribuições marginais de X e Y .
- Obtenha $P(X = 1 \mid Y = 1)$.
- Verifique se X e Y são independentes.
- Calcule $\text{Cov}(X, Y)$.

i Exercício 13

Mostre que, se X e Y são independentes e possuem segundos momentos finitos, então

$$\text{Cov}(X, Y) = 0.$$

Apresente um exemplo mostrando que a recíproca não é válida em geral.

i Exercício 14

Se Y assume os valores 0 e 1, com

$$P(Y = 1) = p,$$

e

$$E(X \mid Y = 0) = \mu_0, \quad E(X \mid Y = 1) = \mu_1,$$

obtenha $E(X)$ utilizando a lei da esperança total.

i Exercício 15

Nas condições do exercício anterior, suponha ainda que

$$\text{Var}(X \mid Y = 0) = \sigma_0^2$$

e

$$\text{Var}(X \mid Y = 1) = \sigma_1^2.$$

Use a lei da variância total para obter $\text{Var}(X)$.

i Exercício 16

Se

$$X \sim N(0, 1)$$

e

$$Y = X^2,$$

obtenha a função de distribuição de Y utilizando

$$F_Y(y) = P(X^2 \leq y).$$

i Exercício 17

Se

$$X \sim \text{Exponencial}(\lambda)$$

e

$$Y = cX, \quad c > 0,$$

obtenha a densidade de Y pelo método da transformação e identifique sua distribuição.

i Exercício 18

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Gama}(\alpha, \lambda),$$

use funções geradoras de momentos para identificar a distribuição de

$$S_n = \sum_{i=1}^n X_i.$$

Da Probabilidade à Inferência Estatística

Neste capítulo, partimos de distribuições probabilísticas especificadas e revisamos propriedades das variáveis aleatórias associadas a esses modelos. Conhecida uma distribuição, podem ser obtidas probabilidades, esperanças, variâncias e distribuições de funções das variáveis envolvidas.

Na Inferência Estatística, observamos dados e buscamos obter informação sobre características desconhecidas da população ou do modelo probabilístico utilizado para representá-la. Essa passagem introduzirá conceitos como população, parâmetro, amostra, modelo estatístico e verossimilhança.

Antes desse desenvolvimento, o próximo capítulo reúne resultados matemáticos e assintóticos que serão utilizados ao longo do livro. Em seguida, o capítulo **Fundamentos da Inferência Estatística** inicia a construção inferencial a partir do Processo Gerador de Dados e da variabilidade associada à obtenção de diferentes amostras.

Referências

Resultados Matemáticos e Assintóticos para Inferência

Este capítulo reúne resultados matemáticos e assintóticos que serão utilizados nos desenvolvimentos posteriores de Inferência Estatística. O objetivo é estabelecer a notação e registrar ferramentas de cálculo, álgebra linear e teoria assintótica necessárias para estudar distribuições amostrais, propriedades de estimadores, métodos de estimação, intervalos de confiança e testes de hipóteses (Rice, 2007, caps. 1–6; Ramachandran; Tsokos, 2021, caps. 2–4; Lauritzen, 2023, ap. A).

Os conceitos e modelos probabilísticos necessários ao livro foram revisados no capítulo anterior. Aqui, a atenção se concentra nas ferramentas matemáticas utilizadas para manipular funções, vetores e matrizes e para estudar o comportamento de sequências de variáveis aleatórias e estatísticas quando o tamanho da amostra aumenta.

Delimitação do capítulo

Os resultados apresentados neste capítulo serão utilizados como ferramentas. Suas aplicações estatísticas serão desenvolvidas nos capítulos correspondentes. Em particular, a Lei dos Grandes Números e o Teorema Central do Limite serão enunciados aqui, enquanto suas consequências para distribuições amostrais serão estudadas no capítulo **Distribuições Amostrais**. De forma semelhante, o método delta será apresentado aqui e aplicado posteriormente a estimadores e funções de parâmetros.

Mapa de dependências

Ferramenta	Utilização posterior
Somatórios, produtos, logaritmos e diferenciação	verossimilhança, função escore, informação de Fisher e algoritmo EM
Expansões de Taylor	aproximações, método delta, propriedades assintóticas e expansão da log-verossimilhança

Ferramenta	Utilização posterior
Vetores e matrizes	parâmetros vetoriais, matrizes de covariâncias, informação de Fisher e modelos lineares
Formas quadráticas	distribuições associadas ao modelo normal, mínimos quadrados e estatísticas inferenciais
Projeções	mínimos quadrados e decomposição da variabilidade em modelos lineares
Transformações multivariadas e jacobiano	obtenção de distribuições e reparametrizações
Modos de convergência	consistência e aproximações assintóticas
Mapeamento contínuo e Slutsky	transformação e substituição de quantidades em resultados assintóticos
Lei dos Grandes Números	médias e momentos amostrais, consistência
Teorema Central do Limite	aproximações normais e normalidade assintótica
Método delta	distribuição assintótica de funções de estimadores
Ordens estocásticas	representação concisa de erros e expansões assintóticas

Notação e ferramentas matemáticas

Somatórios, produtos e funções indicadoras

Para uma sequência $a_1, \dots, a_n$, utilizaremos

$$\sum_{i=1}^n a_i = a_1 + \dots + a_n$$

e

$$\prod_{i=1}^n a_i = a_1 \cdots a_n.$$

Algumas propriedades dos somatórios serão utilizadas repetidamente. Para constantes a , b e c ,

$$\sum_{i=1}^n (ax_i + by_i) = a \sum_{i=1}^n x_i + b \sum_{i=1}^n y_i$$

e

$$\sum_{i=1}^n c = nc.$$

A média aritmética de $x_1, \dots, x_n$ será representada por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Uma identidade utilizada na decomposição de somas de quadrados é

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - a)^2.$$

Em particular,

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

Função indicadora

A função indicadora de um evento A é

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

Ela permite representar contagens por meio de somas. Se A_i representa a ocorrência de determinada característica na unidade i , então

$$R = \sum_{i=1}^n \mathbf{1}_{A_i}$$

é o número de unidades que apresentam essa característica e

$$\frac{R}{n} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{A_i}$$

é a proporção correspondente.

Essa representação será utilizada posteriormente para relacionar contagens, proporções amostrais e médias de variáveis Bernoulli.

Produtos e logaritmos

A transformação logarítmica converte produtos em somas:

$$\log \left(\prod_{i=1}^n a_i \right) = \sum_{i=1}^n \log a_i, \quad a_i > 0.$$

Da mesma forma,

$$\log(a^b) = b \log a.$$

Essas identidades serão utilizadas no estudo da função de verossimilhança. Para observações independentes, a verossimilhança geralmente assume a forma de um produto, enquanto sua transformação logarítmica pode ser escrita como uma soma.

Diferenciação

Diversos métodos inferenciais envolvem a maximização ou minimização de funções. Para uma função real diferenciável g , um ponto interior x_0 candidato a extremo satisfaz

$$g'(x_0) = 0.$$

Quando

$$g''(x_0) < 0,$$

o ponto é um máximo local; quando

$$g''(x_0) > 0,$$

é um mínimo local.

Para funções de vários argumentos,

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

as derivadas de primeira ordem são reunidas no vetor gradiente,

$$\nabla g(\theta) = \begin{pmatrix} \frac{\partial g}{\partial \theta_1} \\ \vdots \\ \frac{\partial g}{\partial \theta_k} \end{pmatrix},$$

e as derivadas de segunda ordem formam a matriz hessiana,

$$\nabla^2 g(\theta) = \left[\frac{\partial^2 g}{\partial \theta_i \partial \theta_j} \right]_{i,j=1}^k.$$

Esses objetos serão utilizados na função escore, na informação observada, na otimização de funções de verossimilhança e em aproximações quadráticas.

Fórmula de Taylor

Uma função possuir derivadas de todas as ordens não garante, por si só, que ela seja igual à sua série de Taylor. O resultado utilizado na inferência é a **aproximação de Taylor com termo de resto**.

Se g possui duas derivadas contínuas em uma vizinhança de a , então, para x nessa vizinhança,

$$g(x) = g(a) + g'(a)(x - a) + \frac{1}{2}g''(\tilde{x})(x - a)^2,$$

em que $\tilde{x}$ está entre a e x .

Em particular,

$$g(x) = g(a) + g'(a)(x - a) + o(|x - a|), \quad x \rightarrow a.$$

A aproximação de primeira ordem é, portanto,

$$g(x) \approx g(a) + g'(a)(x - a)$$

quando x está suficientemente próximo de a .

Considere

$$g(x) = \log x.$$

Em torno de $a = 1$,

$$g(1) = 0$$

e

$$g'(1) = 1.$$

Logo,

$$\log x = (x - 1) + o(|x - 1|), \quad x \rightarrow 1,$$

ou, em forma aproximada,

$$\log x \approx x - 1$$

para valores de x próximos de 1.

Taylor em várias dimensões

Para uma função diferenciável

$$g : \mathbb{R}^k \longrightarrow \mathbb{R}^m,$$

temos

$$g(\mathbf{x}) = g(\xi) + Dg(\xi)(\mathbf{x} - \xi) + o(\|\mathbf{x} - \xi\|),$$

em que $Dg(\xi)$ é a matriz de derivadas de primeira ordem de g avaliada em ξ .

Quando $g : \mathbb{R}^k \rightarrow \mathbb{R}$, a aproximação de primeira ordem pode ser escrita como

$$g(\mathbf{x}) = g(\xi) + \nabla g(\xi)^\top (\mathbf{x} - \xi) + o(\|\mathbf{x} - \xi\|).$$

Aproximações de segunda ordem para funções escalares utilizam a matriz hessiana. Esses resultados serão retomados no método delta e nas expansões da função de log-verossimilhança (Lauritzen, 2023, ap. A.3.2).

Vetores e matrizes

Um vetor coluna em $\mathbb{R}^k$ será representado por

$$\mathbf{x} = (x_1, \dots, x_k)^\top.$$

Seu transposto é

$$\mathbf{x}^\top = (x_1, \dots, x_k).$$

Para

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^k,$$

o produto interno é

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y} = \sum_{j=1}^k x_j y_j,$$

e a norma euclidiana é

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}}.$$

Matrizes

Uma matriz com m linhas e k colunas será representada por

$$\mathbf{A} = [a_{ij}] \in \mathbb{R}^{m \times k}.$$

Sua transposta,

$$\mathbf{A}^\top,$$

possui dimensão $k \times m$ e satisfaz

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

Uma matriz quadrada $\mathbf{A}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Quando existe uma matriz $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}^{-1} \mathbf{A} = \mathbf{A} \mathbf{A}^{-1} = \mathbf{I},$$

dizemos que $\mathbf{A}$ é invertível.

O **posto** de uma matriz corresponde ao número máximo de colunas, ou equivalentemente de linhas, linearmente independentes. Para uma matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a condição

$$\text{posto}(\mathbf{X}) = p$$

indica que suas colunas são linearmente independentes. Nesse caso, quando $n \geq p$,

$$\mathbf{X}^\top \mathbf{X}$$

é invertível.

Formas quadráticas

Para uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{k \times k}$$

e um vetor

$$\mathbf{x} \in \mathbb{R}^k,$$

a expressão

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

é denominada **forma quadrática**.

A matriz $\mathbf{A}$ é **positiva semidefinida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^k$.

Ela é **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Matrizes de covariâncias são positivas semidefinidas. Sob condições de regularidade e identificabilidade, matrizes de informação de Fisher também apresentam essa estrutura.

i Forma quadrática e soma de quadrados

Quando

$$\mathbf{A} = \mathbf{I},$$

a forma quadrática reduz-se a

$$\mathbf{x}^\top \mathbf{x} = \sum_{j=1}^k x_j^2.$$

Assim, somas de quadrados podem ser representadas por formas quadráticas. Essa representação será utilizada posteriormente no modelo normal e em mínimos quadrados.

Projeções

Uma matriz $\mathbf{P}$ é uma matriz de projeção ortogonal quando

$$\mathbf{P}^\top = \mathbf{P}$$

e

$$\mathbf{P}^2 = \mathbf{P}.$$

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

com posto completo nas colunas. A matriz

$$\mathbf{P}_\mathbf{X} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

é a projeção ortogonal sobre o espaço coluna de $\mathbf{X}$.

Para qualquer vetor

$$\mathbf{y} \in \mathbb{R}^n,$$

o vetor

$$\hat{\mathbf{y}} = \mathbf{P}_\mathbf{X} \mathbf{y}$$

pertence ao espaço coluna de $\mathbf{X}$.

O vetor residual

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{P}_\mathbf{X})\mathbf{y}$$

é ortogonal a esse espaço. Portanto,

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

Essa decomposição será utilizada no método de mínimos quadrados (Lauritzen, 2023, ap. A.1; Rice, 2007, secs. 14.3–14.4).

Gradiente, jacobiana e hessiana

Para uma função escalar

$$q : \mathbb{R}^k \longrightarrow \mathbb{R},$$

o gradiente é

$$\nabla q(\theta) = \left(\frac{\partial q}{\partial \theta_1}, \dots, \frac{\partial q}{\partial \theta_k} \right)^\top.$$

A matriz hessiana é

$$\nabla^2 q(\theta) = \left[\frac{\partial^2 q}{\partial \theta_i \partial \theta_j} \right]_{i,j=1}^k.$$

Para uma função vetorial

$$g : \mathbb{R}^k \longrightarrow \mathbb{R}^m,$$

com

$$g(\mathbf{x}) = \begin{pmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_m(\mathbf{x}) \end{pmatrix},$$

a matriz jacobiana é

$$Dg(\mathbf{x}) = \left[\frac{\partial g_i(\mathbf{x})}{\partial x_j} \right]_{\substack{i=1,\dots,m \\ j=1,\dots,k}}.$$

Quando $m = 1$, a jacobiana corresponde ao transposto do gradiente, de acordo com a convenção de orientação adotada.

Esses objetos aparecem em três situações distintas ao longo do livro:

1. o **gradiente** descreve derivadas de primeira ordem de funções escalares, como a log-verossimilhança;
2. a **hessiana** reúne derivadas de segunda ordem e será utilizada em aproximações e informação observada;
3. a **jacobiana** descreve derivadas de transformações vetoriais e será utilizada em mudanças de variáveis e no método delta multivariado.

Transformações multivariadas e jacobiano

Considere um vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top$$

com densidade conjunta $f_{\mathbf{X}}$ e uma transformação

$$\mathbf{Y} = g(\mathbf{X}),$$

em que

$$g : \mathbb{R}^k \longrightarrow \mathbb{R}^k.$$

Suponha que g seja bijetiva e diferenciável no domínio considerado, com inversa

$$\mathbf{x} = h(\mathbf{y}).$$

A densidade conjunta de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\{h(\mathbf{y})\} |\det Dh(\mathbf{y})|,$$

em que

$$Dh(\mathbf{y}) = \left[\frac{\partial h_i(\mathbf{y})}{\partial y_j} \right]_{i,j=1}^k$$

é a matriz jacobiana da transformação inversa.

O fator

$$|\det Dh(\mathbf{y})|$$

corrige a alteração de volume produzida pela transformação. Essa correção é a extensão multivariada do fator

$$\left| \frac{d}{dy} g^{-1}(y) \right|$$

utilizado no caso univariado (Rice, 2007, secs. 2.3 e 3.6; Ramachandran; Tsokos, 2021, sec. 3.4).

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que $\mathbf{A}$ é uma matriz 2×2 invertível.

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

Portanto,

$$Dh(\mathbf{y}) = \mathbf{A}^{-1}$$

e

$$|\det Dh(\mathbf{y})| = |\det(\mathbf{A}^{-1})| = \frac{1}{|\det(\mathbf{A})|}.$$

Assim,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\{\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})\} \frac{1}{|\det(\mathbf{A})|}.$$

Uso posterior

O método será utilizado quando a distribuição de uma estatística for obtida por transformação de um vetor aleatório. Na Unidade de Distribuições Amostrais, ele também fornecerá uma das ferramentas para derivar distribuições associadas ao modelo normal.

Ferramentas assintóticas

Resultados assintóticos descrevem o comportamento de sequências de variáveis aleatórias ou estatísticas quando

$$n \rightarrow \infty.$$

Na Inferência Estatística, esses resultados permitem estudar propriedades de estimadores e construir aproximações quando uma distribuição amostral exata não está disponível.

A linguagem utilizada para formular esses resultados começa pelos diferentes modos de convergência.

Modos de convergência

Sejam

$$X_1, X_2, \dots$$

uma sequência de variáveis aleatórias e X outra variável aleatória.

Convergência quase certa

Dizemos que X_n converge **quase certamente** para X quando

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

Escrevemos

$$X_n \xrightarrow{\text{q.c.}} X.$$

! Convergência em probabilidade

Dizemos que X_n converge **em probabilidade** para X quando, para todo $\varepsilon > 0$,

$$P(|X_n - X| > \varepsilon) \rightarrow 0.$$

Escrevemos

$$X_n \xrightarrow{P} X.$$

! Convergência em média quadrática

Dizemos que X_n converge **em média quadrática** para X quando

$$E[(X_n - X)^2] \rightarrow 0,$$

desde que essa esperança exista.

Escrevemos

$$X_n \xrightarrow{L^2} X.$$

! Convergência em distribuição

Dizemos que X_n converge **em distribuição** para X quando

$$F_{X_n}(x) \rightarrow F_X(x)$$

em todo ponto de continuidade de F_X .

Escrevemos

$$X_n \xrightarrow{d} X.$$

Relações entre os modos de convergência

As seguintes implicações serão utilizadas ao longo do livro:

$$X_n \xrightarrow{\text{q.c.}} X \implies X_n \xrightarrow{P} X,$$

$$X_n \xrightarrow{L^2} X \implies X_n \xrightarrow{P} X$$

e

$$X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X.$$

Portanto,

$$\begin{array}{ccc} X_n \xrightarrow{\text{q.c.}} X & \searrow & \\ & X_n \xrightarrow{P} X \longrightarrow X_n \xrightarrow{d} X & \\ X_n \xrightarrow{L^2} X & \nearrow & \end{array}$$

Em geral, não há implicação entre convergência quase certa e convergência em média quadrática. As demais implicações também não podem ser invertidas sem hipóteses adicionais.

Há uma exceção utilizada com frequência em Inferência Estatística. Se c é uma constante, então

$$X_n \xrightarrow{d} c$$

implica

$$X_n \xrightarrow{P} c.$$

Assim, quando o limite é constante, convergência em distribuição e convergência em probabilidade são equivalentes (Rice, 2007, cap. 5; Lauritzen, 2023, ap. A.2).

Teorema do mapeamento contínuo

O teorema do mapeamento contínuo permite transferir resultados de convergência para funções contínuas das variáveis envolvidas.

Se

$$X_n \xrightarrow{P} X$$

e g é contínua nos valores assumidos por X , então

$$g(X_n) \xrightarrow{P} g(X).$$

A versão correspondente para convergência em distribuição estabelece que

$$X_n \xrightarrow{d} X$$

implica

$$g(X_n) \xrightarrow{d} g(X),$$

quando g é contínua com probabilidade um sob a distribuição limite (Lauritzen, 2023, teorema A.11).

Se

$$T_n \xrightarrow{P} \theta,$$

com $\theta > 0$, então, pela continuidade do logaritmo em $(0, \infty)$,

$$\log T_n \xrightarrow{P} \log \theta.$$

Da mesma forma,

$$T_n^2 \xrightarrow{P} \theta^2.$$

O resultado permite obter a consistência de transformações contínuas de estimadores consistentes.

Lema de Slutsky

Considere

$$X_n \xrightarrow{d} X$$

e

$$Y_n \xrightarrow{P} c,$$

em que c é uma constante.

Então,

$$X_n + Y_n \xrightarrow{d} X + c,$$

$$X_n Y_n \xrightarrow{d} cX$$

e, se $c \neq 0$,

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}.$$

O lema permite combinar uma quantidade com distribuição limite não degenerada com outra que converge em probabilidade para uma constante (Lauritzen, 2023, corolário A.12).

Suponha que

$$\frac{\sqrt{n}(T_n - \theta)}{\sigma} \xrightarrow{d} N(0, 1)$$

e que

$$S_n \xrightarrow{P} \sigma, \quad \sigma > 0.$$

Podemos escrever

$$\frac{\sqrt{n}(T_n - \theta)}{S_n} = \frac{\sqrt{n}(T_n - \theta)}{\sigma} \frac{\sigma}{S_n}.$$

Como

$$\frac{\sigma}{S_n} \xrightarrow{P} 1,$$

o lema de Slutsky fornece

$$\frac{\sqrt{n}(T_n - \theta)}{S_n} \xrightarrow{d} N(0, 1).$$

Esse mecanismo permite substituir, em diversos resultados assintóticos, uma quantidade desconhecida por um estimador consistente.

Lei dos Grandes Números

Considere uma sequência

$$X_1, X_2, \dots$$

de variáveis aleatórias independentes e identicamente distribuídas, com

$$E|X_1| < \infty.$$

Então,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E(X_1).$$

Se

$$E(X_1) = \mu,$$

podemos escrever simplesmente

$$\bar{X}_n \xrightarrow{P} \mu.$$

A Lei dos Grandes Números descreve a estabilização da média amostral em torno da média da distribuição quando o tamanho da amostra aumenta (Rice, 2007, sec. 5.2; Ramachandran; Tsokos, 2021, sec. 3.5).

i Interpretação

A Lei dos Grandes Números é um resultado de **convergência**. Ela estabelece que

$$\bar{X}_n \xrightarrow{P} \mu,$$

mas não fornece diretamente a forma da distribuição de $\bar{X}_n$ para um valor fixado de n . A distribuição e a velocidade das flutuações de $\bar{X}_n$ em torno de μ são tratadas pelo Teorema Central do Limite.

Teorema Central do Limite

Considere

$$X_1, X_2, \dots$$

independentes e identicamente distribuídas, com

$$E(X_1) = \mu$$

e

$$0 < \text{Var}(X_1) = \sigma^2 < \infty.$$

Então,

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Equivalentemente,

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

O resultado descreve a distribuição limite das flutuações padronizadas da média ou da soma em torno de seus respectivos valores esperados (Rice, 2007, sec. 5.3; Ramachandran; Tsokos, 2021, sec. 3.5; Chihara; Hesterberg, 2022, sec. 4.3).

! O que o Teorema Central do Limite estabelece

O Teorema Central do Limite não afirma que as observações individuais se tornam normalmente distribuídas quando n aumenta.

A convergência refere-se à distribuição da quantidade padronizada

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}.$$

Para amostras suficientemente grandes, esse resultado permite aproximar a distribuição da média por

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

A qualidade dessa aproximação depende da distribuição das observações e do tamanho da amostra. Distribuições com forte assimetria ou caudas pesadas podem exigir valores maiores de n .

Lei dos Grandes Números e Teorema Central do Limite

Os dois resultados descrevem aspectos diferentes do comportamento da média amostral.

A Lei dos Grandes Números estabelece

$$\bar{X}_n \xrightarrow{P} \mu.$$

Seu foco é a aproximação de $\bar{X}_n$ ao valor μ .

O Teorema Central do Limite estabelece

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Seu foco é a distribuição das flutuações de $\bar{X}_n$ em torno de μ na escala $n^{-1/2}$.

Resultado	Questão descrita
Lei dos Grandes Números	$\bar{X}_n$ se aproxima de μ ?
Teorema Central do Limite	como $\bar{X}_n - \mu$ se distribui, após a padronização adequada?

Esses resultados serão utilizados de maneira distinta nos capítulos seguintes. A Lei dos Grandes Números sustentará resultados de consistência, enquanto o Teorema Central do Limite sustentará aproximações normais e resultados de normalidade assintótica.

Método delta univariado

O método delta permite obter a distribuição assintótica de uma função de uma estatística a partir da distribuição assintótica da própria estatística. O resultado decorre de uma aproximação de Taylor de primeira ordem.

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \tau^2)$$

e que g seja diferenciável em θ . Denotando por $g'(\theta)$ a primeira derivada de g avaliada em θ , temos

$$\sqrt{n}\{g(T_n) - g(\theta)\} \xrightarrow{d} N(0, [g'(\theta)]^2 \tau^2).$$

A aproximação de Taylor fornece

$$g(T_n) = g(\theta) + g'(\theta)(T_n - \theta) + o_P(|T_n - \theta|).$$

Assim, em primeira ordem,

$$g(T_n) - g(\theta) \approx g'(\theta)(T_n - \theta).$$

O método transfere, portanto, a distribuição assintótica de T_n para a função $g(T_n)$.

Suponha que

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2),$$

com $\mu \neq 0$, e considere

$$g(x) = x^2.$$

Como

$$g'(\mu) = 2\mu,$$

o método delta fornece

$$\sqrt{n}(\bar{X}_n^2 - \mu^2) \xrightarrow{d} N(0, 4\mu^2 \sigma^2).$$

Consequentemente, para valores grandes de n ,

$$\bar{X}_n^2$$

tem variância assintótica aproximadamente igual a

$$\frac{4\mu^2 \sigma^2}{n}.$$

i Quando a primeira derivada é nula

Se

$$g'(\theta) = 0,$$

o resultado de primeira ordem é degenerado. Nesse caso, pode ser necessário utilizar uma expansão de Taylor de ordem superior e uma normalização diferente.

Método delta multivariado

O método delta também se aplica quando o parâmetro e a estatística são vetoriais.

Suponha que

$$\sqrt{n}(\mathbf{T}_n - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Sigma),$$

e que

$$g : \mathbb{R}^k \longrightarrow \mathbb{R}^m$$

seja diferenciável em θ .

Se

$$Dg(\theta)$$

denota a matriz jacobiana de g avaliada em θ , então

$$\sqrt{n}\{g(\mathbf{T}_n) - g(\theta)\} \xrightarrow{d} N_m[\mathbf{0}, Dg(\theta)\Sigma Dg(\theta)^\top].$$

O resultado é a extensão vetorial da aproximação

$$g(\mathbf{T}_n) - g(\theta) \approx Dg(\theta)(\mathbf{T}_n - \theta).$$

Quando $m = 1$, a matriz jacobiana reduz-se a um vetor linha e a variância assintótica de $g(\mathbf{T}_n)$ é

$$\nabla g(\theta)^\top \Sigma \nabla g(\theta).$$

O método delta será utilizado posteriormente para obter variâncias assintóticas de funções de estimadores e erros-padrão associados a transformações de parâmetros (Lauritzen, 2023, teorema A.19; Chihara; Hesterberg, 2022, sec. 7.7).

Suponha que

$$\sqrt{n} \left[\begin{pmatrix} T_{1n} \\ T_{2n} \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \right] \xrightarrow{d} N_2(\mathbf{0}, \Sigma),$$

com $\theta_2 \neq 0$.

Considere

$$g(\theta_1, \theta_2) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla g(\theta_1, \theta_2) = \begin{pmatrix} \frac{1}{\theta_2} \\ -\frac{\theta_1}{\theta_2^2} \end{pmatrix}.$$

Portanto,

$$\sqrt{n} \left(\frac{T_{1n}}{T_{2n}} - \frac{\theta_1}{\theta_2} \right) \xrightarrow{d} N(0, \nabla g(\theta)^\top \Sigma \nabla g(\theta)).$$

Ordens estocásticas

As notações o_P e O_P permitem descrever a magnitude probabilística de sequências de variáveis aleatórias e tornam mais concisas as expansões assintóticas.

Seja $a_n > 0$ uma sequência determinística.

! Pequena ordem em probabilidade

Escrevemos

$$X_n = o_P(a_n)$$

quando

$$\frac{X_n}{a_n} \xrightarrow{P} 0.$$

Assim, X_n torna-se desprezível em relação a a_n em probabilidade.

! Ordem em probabilidade

Escrevemos

$$X_n = O_P(a_n)$$

quando

$$\frac{X_n}{a_n}$$

é limitado em probabilidade.

Formalmente, para todo $\varepsilon > 0$, existe $M > 0$ tal que, para n suficientemente grande,

$$P\left(\left|\frac{X_n}{a_n}\right| > M\right) < \varepsilon.$$

Em particular,

$$X_n = O_P(1)$$

indica que a sequência é limitada em probabilidade, enquanto

$$X_n = o_P(1)$$

equivale a

$$X_n \xrightarrow{P} 0.$$

Taxa de convergência

Suponha que T_n estime θ . A expressão

$$T_n - \theta = O_P(n^{-1/2})$$

indica que o erro de estimação possui ordem probabilística $n^{-1/2}$.

Por exemplo, sob as condições do Teorema Central do Limite,

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

Como uma sequência que converge em distribuição é limitada em probabilidade,

$$\sqrt{n}(\bar{X}_n - \mu) = O_P(1).$$

Consequentemente,

$$\bar{X}_n - \mu = O_P(n^{-1/2}).$$

Essa notação será utilizada posteriormente em expansões de Taylor da função escore e da log-verossimilhança (Lauritzen, 2023, sec. 5.5 e ap. A.2).

i Diferença entre O_P e o_P

As expressões

$$X_n = O_P(a_n)$$

e

$$X_n = o_P(a_n)$$

não têm o mesmo significado.

A primeira indica que X_n/a_n permanece limitado em probabilidade. A segunda estabelece a condição mais forte

$$\frac{X_n}{a_n} \xrightarrow{P} 0.$$

Portanto,

$$X_n = o_P(a_n)$$

implica

$$X_n = O_P(a_n).$$

Síntese

Os resultados deste capítulo podem ser organizados em duas partes.

A primeira reúne ferramentas de cálculo e álgebra linear:

- somatórios, produtos e funções indicadoras;
- diferenciação e expansões de Taylor;
- vetores e matrizes;
- formas quadráticas e projeções;
- gradientes, matrizes jacobianas e hessianas;
- transformações multivariadas.

A segunda reúne ferramentas para o estudo assintótico de estatísticas:

- convergência quase certa, em média quadrática, em probabilidade e em distribuição;
- teorema do mapeamento contínuo;
- lema de Slutsky;
- Lei dos Grandes Números;
- Teorema Central do Limite;
- método delta;
- ordens estocásticas.

As relações entre alguns desses resultados podem ser representadas por

$\text{LGN} \longrightarrow \text{convergência para uma constante} \longrightarrow \text{consistência},$

enquanto

$\text{TCL} \longrightarrow \text{distribuição limite} \longrightarrow \text{aproximação normal}.$

O método delta combina uma distribuição assintótica com uma expansão de Taylor:

distribuição assintótica de $T_n + \text{Taylor} \longrightarrow \text{distribuição assintótica de } g(T_n).$

O mapeamento contínuo e o lema de Slutsky permitem transformar e combinar sequências convergentes. As notações O_P e o_P fornecem uma forma compacta de registrar a magnitude dos termos que aparecem nessas aproximações.

Os capítulos seguintes utilizarão esses resultados sem redefini-los. As condições e interpretações específicas serão discutidas no contexto em que cada ferramenta for aplicada.

Exercícios de consolidação

i Exercício 1

Mostre que

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - a)^2.$$

Utilize a identidade

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

i Exercício 2

Obtenha a aproximação de Taylor de primeira ordem de

$$g(x) = \frac{1}{x}$$

em torno de $a = 1$.

Em seguida, obtenha a aproximação de segunda ordem.

i Exercício 3

Para

$$g(x, y) = x^2 + xy + y^2,$$

obtenha:

- o gradiente $\nabla g(x, y)$;
- a matriz hessiana $\nabla^2 g(x, y)$;
- a aproximação de Taylor de primeira ordem em torno de $(1, 1)$.

i Exercício 4

Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Mostre que $\mathbf{A}$ é positiva definida verificando que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

i Exercício 5

Se

$$\mathbf{P} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top,$$

com $\mathbf{X}$ de posto completo nas colunas, mostre que

$$\mathbf{P}^\top = \mathbf{P}$$

e

$$\mathbf{P}^2 = \mathbf{P}.$$

i Exercício 6

Considere a transformação

$$Y_1 = X_1 + X_2, \quad Y_2 = X_1 - X_2.$$

- Obtenha a transformação inversa.
- Determine sua matriz jacobiana.
- Calcule o valor absoluto do determinante jacobiano da transformação inversa.

i Exercício 7

Organize as seguintes formas de convergência de acordo com as implicações válidas em geral:

- convergência quase certa;
- convergência em média quadrática;
- convergência em probabilidade;
- convergência em distribuição.

Indique quais implicações não podem ser invertidas sem hipóteses adicionais.

i Exercício 8

Suponha que

$$T_n \xrightarrow{P} \theta, \quad \theta > 0.$$

Utilize o teorema do mapeamento contínuo para obter os limites em probabilidade de

$$T_n^2, \quad \sqrt{T_n}$$

e

$$\log T_n.$$

i Exercício 9

Suponha que

$$X_n \xrightarrow{d} N(0, 1)$$

e

$$Y_n \xrightarrow{P} 2.$$

Utilize o lema de Slutsky para obter as distribuições limites de

$$X_n + Y_n,$$

$$X_n Y_n$$

e

$$\frac{X_n}{Y_n}.$$

i Exercício 10

Se

$$X_1, X_2, \dots \stackrel{\text{iid}}{\sim} P,$$

com

$$E(X_i) = \mu$$

e

$$0 < \text{Var}(X_i) = \sigma^2 < \infty,$$

indique separadamente o que a Lei dos Grandes Números e o Teorema Central do Limite estabelecem sobre $\bar{X}_n$.

i Exercício 11

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \tau^2),$$

com $\theta > 0$.

Use o método delta para obter a distribuição assintótica de

$$\log T_n.$$

i Exercício 12

Nas condições do exercício anterior, obtenha a distribuição assintótica de

$$\frac{1}{T_n}.$$

i Exercício 13

Suponha que

$$\sqrt{n} \begin{bmatrix} T_{1n} \\ T_{2n} \end{bmatrix} - \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix} \xrightarrow{d} N_2(\mathbf{0}, \Sigma).$$

Utilize o método delta para obter a forma da variância assintótica de

$$g(\theta_1, \theta_2) = \theta_1 \theta_2.$$

i Exercício 14

Mostre que

$$X_n = o_P(a_n)$$

implica

$$X_n = O_P(a_n).$$

i Exercício 15

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} Z,$$

em que Z possui uma distribuição própria.

Mostre que

$$T_n - \theta = O_P(n^{-1/2}).$$

Referências

1 Fundamentos da Inferência Estatística

A inferência estatística utiliza informações obtidas em uma amostra para estudar características desconhecidas de uma população ou de um processo que produz dados. Como diferentes amostras podem gerar resultados diferentes, as conclusões obtidas a partir dos dados estão associadas à variabilidade e à incerteza.

Neste capítulo, serão apresentados os conceitos que estruturam esse processo. Inicialmente, serão discutidos o processo gerador de dados, a população, os parâmetros, a amostra e a variabilidade amostral. Em seguida, um experimento de amostragem será realizado em sala de aula e reproduzido computacionalmente para observar como os resultados variam entre diferentes amostras.

A partir dessas ideias, serão introduzidos os conceitos de estatística, estimador, estimativa, modelo estatístico e verossimilhança. Esses elementos fornecem a linguagem utilizada nos capítulos seguintes para estudar distribuições amostrais, propriedades de estimadores, métodos de estimação, intervalos de confiança e testes de hipóteses.

1.1 O problema da inferência estatística

Em muitas situações, deseja-se conhecer uma característica de uma população sem observar todos os seus elementos. Pode haver interesse, por exemplo, na proporção de eleitores favoráveis a determinado candidato, no peso médio de um produto fabricado por uma empresa ou no tempo médio de funcionamento de determinado equipamento.

Quando a observação de toda a população não é possível ou conveniente, utiliza-se uma amostra. As informações obtidas nessa amostra são utilizadas para estudar a característica de interesse na população. De forma geral, esse processo pode ser representado por

população $\longrightarrow$ amostra $\longrightarrow$ informação sobre a população.

! Inferência estatística

A inferência estatística utiliza dados observados para obter informação sobre características desconhecidas da população ou do processo que gerou os dados.

A amostra observada corresponde a apenas um dos possíveis conjuntos de dados que poderiam ser obtidos. Se o procedimento de amostragem fosse repetido, outros elementos poderiam ser selecionados e os resultados calculados a partir deles poderiam ser diferentes. Assim, a inferência estatística envolve a variabilidade associada aos dados observados.

Para representar essa variabilidade e estabelecer procedimentos inferenciais, é necessário considerar como os dados são produzidos. Esse é o ponto de partida para o conceito de Processo Gerador de Dados.

1.2 Processo Gerador de Dados (PGD)

O PGD é o mecanismo teórico, físico ou biológico que produz os dados que observamos. Imagine que o mundo é uma “caixa preta” que segue certas regras (leis da física, comportamento humano, algoritmos de mercado), portanto o PGD são essas regras em funcionamento.

Realidade vs. Observação

- O PGD (A causa): É a distribuição de probabilidade teórica e os parâmetros fixos (mas desconhecidos) que regem um fenômeno.
- Os Dados (O Efeito): É a amostra específica que coletamos. É apenas uma realização de infinitas possibilidades que o PGD poderia ter gerado.

Representação Matemática

O PGD pode ser definido pela distribuição de probabilidade conjunta desconhecida $P(X, Y)$ (ou simplesmente $P(Z)$).

Dizemos que nossa amostra $\mathcal{D} = \{z_1, z_2, \dots, z_n\}$ é composta por variáveis aleatórias independentes e identicamente distribuídas (i.i.d) retiradas desse processo:

$$z_i \sim P(Z).$$

Nesta visão, o PGD é o “mecanismo” que dita:

1. A Região de Suporte: Quais valores são possíveis de ocorrer?
2. A Densidade: Com que frequência cada valor ocorre?
3. As Dependências: Como a ocorrência de X altera a probabilidade de Y ?

1.3 Pacote Necessários

Neste capítulo iremos utilizar os pacotes R `tidyverse` (Wickham et al., 2019) e `moderndive` (Kim; Ismay; Kuhn, 2021). Por exemplo, para instalar o pacote basta usar `install.packages("tidyverse")` e podemos carregar o pacote por meio do comando `library(tidyverse)`. São carregados, de uma só vez, os seguintes pacotes amplamente utilizados em ciência de dados:

- `ggplot2` para visualização de dados;
- `dplyr` para manipulação de dados;
- `tidyr` para converter dados para o formato “tidy”;
- `readr` para importar dados de planilhas para o R,

além dos pacotes mais avançados `purrr`, `tibble`, `stringr` e `forcats`.

```
library(tidyverse)
library(moderndive)
```

1.4 Experimento em Sala de Aula

Iremos realizar o seguinte experimento em sala de aula:

1. Organização
 - A turma é dividida em grupos independentes (por exemplo, 20 grupos).
 - Cada grupo realiza uma única amostragem.
2. Protocolo experimental (por grupo)
 - A urna é misturada cuidadosamente, garantindo aleatoriedade.
 - O grupo retira uma amostra de tamanho fixo n (por exemplo, $n = 50$) sem reposição durante a retirada.
 - As bolas retiradas são observadas e classificadas por cor.
 - O grupo registra:
 - R : o número de bolas vermelhas na amostra;
 - $\hat{p} = R/n$: proporção amostral de bolas vermelhas.
 - Todas as bolas são devolvidas à urna.
 - A urna é novamente misturada antes da próxima amostragem.

Cada grupo deve atuar de forma independente, sem acesso aos resultados dos demais.

3. Coleta e organização dos dados

- Cada grupo fornece sua estimativa de $\hat{p}$.
- O conjunto de estimativas é reunido em uma tabela ou planilha.
- As proporções são representadas graficamente por meio de um histograma.

Esse histograma representa a distribuição amostral da proporção para um tamanho de amostra fixo n .

Verificação de aprendizagem

1. Por que foi importante misturar a tigela antes de retirarmos as bolas?
2. Por que os 20 grupos de amigos não obtiveram todos o mesmo número de bolas vermelhas entre as 50 retiradas e, conseqüentemente, proporções diferentes de bolas vermelhas?

1.5 Experimento Virtual

No pacote `moderndive` existe um *data frame* chamado `bowl`. As linhas de `bowl` correspondem exatamente ao conteúdo da urna real apresentada em sala de aula.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
5       5 white
6       6 white
7       7 red
8       8 white
9       9 red
10      10 white
# i 2,390 more rows
```

Observe que `bowl` possui 2400 linhas, o que nos indica que a urna contém 2400 bolas de mesmo tamanho. A primeira variável, `ball_ID`, é usada como uma variável de identificação, conforme discutido em sala de aula, nenhuma das bolas da urna real possui números marcados. A segunda variável, `color`, indica se uma determinada bola virtual é **vermelha** ou **branca**. Visualize o conteúdo de `bowl` no **visualizador de dados do RStudio** e percorra as linhas para se convencer de que `bowl` é, de fato, um **análogo virtual** da urna real apresentada em sala.

Agora precisamos de um **análogo virtual da pá** para gerar **amostras virtuais de 50 bolas**. Para isso, vamos utilizar a função `rep_sample_n()`, incluída no pacote `moderndive`. Essa função permite realizar **amostragens com reposição** de tamanho (`n`).

```
set.seed(2026) #fixando semente
pa_virtual <- bowl %>%
  rep_sample_n(size = 50)

pa_virtual
```

```
# A tibble: 50 x 3
# Groups:   replicate [1]
  replicate ball_ID color
    <int>    <int> <chr>
1         1     733 white
2         1     993 red
3         1    2342 red
4         1    1647 white
5         1    1883 red
6         1     164 red
7         1    1200 red
8         1     389 white
9         1     287 white
10        1    2362 red
# i 40 more rows
```

A variável `ball_ID` identifica quais das 2400 bolas do objeto `bowl` foram incluídas na nossa amostra de 50 bolas, enquanto `color` indica a cor de cada bola. No entanto, o que indica a variável `replicate`?

No caso de `pa_virtual`, a variável `replicate` é igual a 1 em todas as 50 linhas. Isso nos informa que essas 50 linhas correspondem à nossa primeira amostra. Veremos em breve que, quando realizarmos 20 amostragens virtuais, a variável `replicate` assumirá valores entre 1 e 20.

Vamos agora calcular a **proporção de bolas vermelhas** em nossa amostra virtual utilizando os verbos de manipulação de dados do `dplyr`. Primeiro, para cada uma das 50 bolas amostradas, vamos identificar se ela é vermelha ou não, utilizando um teste de igualdade com `==`. Em seguida, criaremos uma nova variável booleana `is_red` usando a função `mutate()`:

```
pa_virtual <- pa_virtual %>%
mutate(is_red = (color == "red"))

pa_virtual
```

```
# A tibble: 50 x 4
# Groups:   replicate [1]
  replicate ball_ID color is_red
    <int>    <int> <chr> <lgl>
1         1     733 white FALSE
2         1     993 red   TRUE
3         1    2342 red   TRUE
4         1    1647 white FALSE
5         1    1883 red   TRUE
6         1     164 red   TRUE
7         1    1200 red   TRUE
8         1     389 white FALSE
9         1     287 white FALSE
10        1    2362 red   TRUE
# i 40 more rows
```

Observe que, para cada linha em que `color == "red"`, é retornado o valor lógico (booleano) `TRUE`, e para cada linha em que `color` não é igual a `"red"`, é retornado o valor lógico `FALSE`.

Em seguida, vamos calcular o número de bolas vermelhas, dentre as 50, utilizando a função `summarize()`. Note que `summarize()` recebe um *data frame* com várias linhas e retorna um *data frame* com **uma única linha**, contendo estatísticas-resumo, como `mean()` ou `median()`. Neste caso, utilizaremos a função `sum()`:

```
n_red <- pa_virtual %>%
mutate(is_red = (color == "red")) %>%
summarize(num_red = sum(is_red))

n_red
```

```
# A tibble: 1 x 2
  replicate num_red
```

```

      <int>    <int>
1          1      16

```

Por que isso funciona? Porque o R trata `TRUE` como o número 1 e `FALSE` como o número 0. Assim, somar valores `TRUE` e `FALSE` é equivalente a somar 1's e 0's. Ao final, essa operação conta o número de bolas para as quais a variável `color` é igual a "red". No nosso caso, 16 das 50 bolas eram vermelhas. No entanto, você pode ter obtido um número diferente de bolas vermelhas devido ao caráter aleatório da amostragem virtual.

Por fim, vamos calcular a proporção das 50 bolas amostradas que são vermelhas, dividindo `num_red` por 50:

```

n_prop_red <- pa_virtual %>%
  mutate(is_red = color == "red") %>%
  summarize(num_red = sum(is_red)) %>%
  mutate(prop_red = num_red / 50)

n_prop_red

```

```

# A tibble: 1 x 3
  replicate num_red prop_red
      <int>    <int>    <dbl>
1          1      16    0.32

```

Em outras palavras, 16 das bolas dessa amostra virtual eram vermelhas. Vamos tornar esse código um pouco mais **compacto e conciso**, combinando as etapas de `mutate()` e `summarize()` da seguinte forma:

```

n_prop_red <- pa_virtual %>%
  summarize(num_red = sum(color == "red")) %>%
  mutate(prop_red = num_red / 50)

n_prop_red

```

```

# A tibble: 1 x 3
  replicate num_red prop_red
      <int>    <int>    <dbl>
1          1      16    0.32

```

Ótimo! 16 das 50 bolas da pá virtual eram vermelhas! Assim, com base nessa amostra específica de 50 bolas, nossa estimativa da proporção de bolas vermelhas na urna é 0.32. Porém, lembre-se da atividade de amostragem realizada em sala de aula: se repetirmos essa amostragem, não necessariamente obteremos novamente o valor de 0.32. É provável que haja alguma variação. De fato, nossos 20 grupos de amigos calcularam 20 proporções desse tipo, cuja distribuição visualizamos em sala de aula, e vimos que essas estimativas variaram.

Vamos agora realizar o **análogo virtual** de ter 20 grupos de estudantes usando a pá de amostragem!

Lembre-se de que, no exercício de amostragem realizada em sala de aula, tivemos **20 grupos de estudantes**, cada um utilizando a pá, o que resultou em **20 amostras de tamanho 50**. Em seguida, usamos essas 20 amostras para calcular **20 proporções**. Em outras palavras, **repetimos/replicamos o uso da pá 20 vezes**.

Podemos realizar essa amostragem repetida/replicada de forma virtual utilizando novamente a função `rep_sample_n()`, mas agora adicionando o argumento `reps = 20`. Isso indica ao R que desejamos repetir a amostragem 20 vezes.

Vamos salvar esses resultados em um **data frame** chamado `virtual_samples`. Embora apresentemos a seguir uma prévia das primeiras 10 linhas de `virtual_samples`, recomendamos fortemente que você explore todo o seu conteúdo utilizando o visualizador de planilhas do RStudio, executando o comando `View(virtual_samples)`.

```
set.seed(2026)
amostra_virtual <- bowl %>%
  rep_sample_n(size = 50, reps = 20)

amostra_virtual
```

```
# A tibble: 1,000 x 3
# Groups:   replicate [20]
  replicate ball_ID color
  <int>     <int> <chr>
1         1       733 white
2         1       993 red
3         1      2342 red
4         1      1647 white
5         1      1883 red
6         1       164 red
7         1      1200 red
8         1       389 white
9         1       287 white
10        1      2362 red
```

```
# i 990 more rows
```

Observe, no visualizador de planilhas, que as primeiras 50 linhas da variável `replicate` são iguais a 1, enquanto as 50 linhas seguintes de `replicate` são iguais a 2. Isso nos indica que as primeiras 50 linhas correspondem à primeira amostra de 50 bolas, enquanto as próximas 50 linhas correspondem à segunda amostra de 50 bolas. Esse padrão se repete para todas as 20 replicações (`reps = 20`) e, portanto, o data frame `amostra_virtual` possui ($20 \times 50 = 1000$) linhas.

Vamos agora usar `amostra_virtual` para calcular as 20 proporções de bolas vermelhas resultantes. Utilizaremos os mesmos verbos do `dplyr` de antes, mas agora com um `group_by()` adicional na variável `replicate`. Ao definir previamente a variável de agrupamento como `metadado` antes de aplicar `summarize()`, obteremos 20 proporções diferentes de bolas vermelhas. A seguir, exibimos uma prévia das primeiras 10 das 20 linhas resultantes:

```
virtual_prop_red <- amostra_virtual %>%  
  group_by(replicate) %>%  
  summarize(red = sum(color == "red")) %>%  
  mutate(prop_red = red / 50)  
  
virtual_prop_red
```


```
# A tibble: 20 x 3  
  replicate    red prop_red  
    <int> <int>    <dbl>  
1         1     16     0.32  
2         2     22     0.44  
3         3     19     0.38  
4         4     27     0.54  
5         5     18     0.36  
6         6     19     0.38  
7         7     16     0.32  
8         8     17     0.34  
9         9     21     0.42  
10        10     20     0.4  
11        11     23     0.46  
12        12     23     0.46  
13        13     15     0.3  
14        14     23     0.46  
15        15     27     0.54  
16        16     23     0.46  
17        17     17     0.34
```

18	18	21	0.42
19	19	15	0.3
20	20	18	0.36

Assim como ocorreu com as 20 amostras coletadas em sala de aula, há variação nas 20 proporções de bolas vermelhas obtidas virtualmente. Vamos visualizar essa variação por meio de um histograma. Note que também adicionamos os argumentos `binwidth = 0.05` e `boundary = 0.4`.

Lembre-se de que definir `boundary = 0.4` garante um esquema de classes em que um dos limites dos intervalos esteja em 0,4. Como o `binwidth = 0.05` também foi especificado, isso criará intervalos com limites em **0,30, 0,35, 0,40, 0,45, 0,50**, entre outros.

```
ggplot(virtual_prop_red, aes(x = prop_red)) +
  geom_histogram(binwidth = 0.05, boundary = 0.4, color = "white") +
  labs(x = "Proporção de bolas vermelhas", y = "Frequência",
  title = "Distribuição das proporções")
```



Observe que, ocasionalmente, obtivemos proporções de bolas vermelhas inferiores a 30%. Por outro lado, em alguns casos, obtivemos proporções superiores a 50%. No entanto, as proporções que ocorreram com maior frequência ficaram entre 35% e 40% (em **5 das 20 amostras**). Por que temos essas diferenças nas proporções de bolas vermelhas? **Por causa da variação amostral.**

Verificação de aprendizagem

1. Por que não foi possível estudar os efeitos da variação amostral quando utilizamos a pá virtual apenas uma vez? Por que foi necessário coletar **mais de uma amostra virtual** (no nosso caso, **20 amostras virtuais**)?

Lista Semanal Obrigatória

1. Agora suponha que queiramos estudar os efeitos da variação amostral não para 20 amostras, mas para um número maior, digamos 1000 amostras. Vamos novamente utilizar a função `rep_sample_n()`, com o tamanho da amostra definido como 50, mas agora com o número de repetições `reps` definido como 1000.
2. Temos 1000 réplicas de `prop_red`, a proporção de bolas vermelhas em amostras de 50 bolas. Utilizando o mesmo código de antes, vamos agora visualizar a distribuição dessas 1000 réplicas de `prop_red` por meio de um histograma.
3. Observando o histograma produzido no item 2), você diria que amostrar 50 bolas em que 30% são vermelhas é provável ou improvável? E quanto a amostrar 50 bolas em que 10% são vermelhas?

1.6 Conceitos Importantes

Primeiramente, uma **população** é um conjunto de indivíduos ou observações de interesse. Isso também é comumente denominado **população de estudo**. Denotamos matematicamente o tamanho da população utilizando a letra maiúscula N .

Um **parâmetro populacional** é algum resumo numérico sobre a população que é desconhecido, mas que você gostaria de saber. Por exemplo, quando essa quantidade é uma média, como a altura média de todos os canadenses, o parâmetro populacional de interesse é a média populacional.

Um **censo** é uma enumeração exaustiva ou contagem de todos os N indivíduos da população. Fazemos isso para calcular o valor exato do parâmetro populacional. Vale notar que, à medida que o número N de indivíduos em nossa população aumenta, a realização de um censo se torna mais cara (em termos de tempo, energia e dinheiro).

Na nossa atividade de amostragem, a **população (de estudo)** é o conjunto de $N = 2400$ bolas vermelhas e brancas, todas de mesmo tamanho, contidas na urna. Lembre-se de que também representamos a urna “virtualmente” no data frame `bowl`.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
5       5 white
6       6 white
7       7 red
8       8 white
9       9 red
10      10 white
# i 2,390 more rows
```

O **parâmetro populacional** aqui é a proporção de bolas na urna que são vermelhas. Sempre que estamos interessados em uma proporção de algum valor em uma população, o parâmetro populacional tem um nome específico: a proporção populacional. Comumente denotamos as proporções populacionais com a letra p .

Para calcular essa proporção populacional p de forma exata, precisamos primeiro realizar um censo, analisando todos os $N = 2400$ e contando o número de bolas vermelhas. Em seguida, dividimos essa contagem por 2400 para obter a proporção de vermelhas.

Você pode estar se perguntando agora: “Espere. Eu entendo que realizar um censo na urna real levaria muito tempo. Mas não podemos realizar um censo “virtual” usando a urna virtual?” Você está absolutamente correto! De fato, quando os autores do pacote `moderndive` criaram o data frame `bowl`, eles fizeram com que seu conteúdo correspondesse ao da urna real não fazendo um censo, mas lendo o conteúdo escrito na caixa em que a urna veio! Vamos realizar este censo “virtual” usando os mesmos códigos do pacote `dplyr` que você usou anteriormente para contar o número de bolas que são vermelhas:

```
bowl %>%
  summarize(red = sum(color == "red"))
```

```
# A tibble: 1 x 1
  red
  <int>
1   900
```

Como 900 das 2400 são vermelhas, a proporção é $900/2400 = 0,375 = 37,5\%$. Portanto, sabemos o valor do parâmetro populacional: em nosso caso, a proporção populacional p é igual a 0,375.

Neste ponto, você pode estar se perguntando: “*Se tínhamos uma maneira de saber que a proporção de bolas vermelhas é de 37,5%, então por que fizemos alguma amostragem?*” Ótima pergunta! Normalmente, você não faria amostragem alguma! No entanto, as atividades de amostragem que fizemos neste capítulo são meras simulações de como a amostragem é feita na vida real! Realizamos essas simulações a fim de estudar:

1. O efeito da variação amostral (ou variabilidade de amostragem) em nossas estimativas.
2. O efeito do tamanho da amostra na variação amostral.

Como veremos adiante em pesquisas de opinião, na amostragem da vida real não apenas o tamanho da população N será muito grande, tornando um censo caro, mas, às vezes, nem sequer saberemos qual é o tamanho da população! Por enquanto, no entanto, prosseguiremos com nosso próximo conjunto de termos e notação.

Amostragem é o ato de coletar uma amostra da população, o que geralmente fazemos apenas quando não podemos realizar um censo. Denotamos matematicamente o tamanho da amostra usando o n minúsculo, em oposição ao N maiúsculo, que denota o tamanho da população. Normalmente, o tamanho da amostra n é muito menor que o tamanho da população N . Assim, a amostragem é uma alternativa muito mais barata do que a realização de um censo.

Uma **estimativa pontual**, também conhecida como estatística (ou estatística amostral), é uma estatística calculada a partir de uma amostra que estima o parâmetro populacional desconhecido.

Então, em sala de aula, realizamos a amostragem usando uma pá com 50 espaços para extrair amostras de tamanho $n = 50$. Para realizar o análogo virtual desta amostragem, lembre-se de que usamos a função `rep_sample_n()` da seguinte maneira:

```
set.seed(2026)
pa_virtual <- bowl %>%
  rep_sample_n(size = 50)
```

Usando a amostra de 50 bolas contidas em `pa_virtual`, geramos uma estimativa da proporção de bolas na urna que são vermelhas, `prop_red`.

```
pa_virtual %>%
  summarize(num_red = sum(color == "red")) %>%
  mutate(prop_red = num_red / 50)
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
    <int>    <int>    <dbl>
1         1      16     0.32
```


Então, em nosso caso, o valor de `prop_red` é a estimativa pontual da proporção populacional p , pois ela estima o valor desta última. Além disso, essa estimativa pontual tem um nome específico quando se considera proporções: **a proporção amostral**. Ela é denotada usando $\hat{p}$, porque é uma convenção comum em estatística usar um símbolo de “chapéu” para denotar estimativas pontuais.

Iremos observar ao longo desta disciplina que a maneira como você coleta as amostras influencia diretamente a qualidade delas.

- Diz-se que uma amostra é **representativa** se ela “se parecer” aproximadamente com a população. Em outras palavras, se as características da amostra forem uma “boa” representação das características da população.
- Dizemos que uma amostra é **generalizável** se quaisquer resultados baseados na amostra puderem ser generalizados para a população. Em outras palavras, se pudermos fazer “bons” palpites sobre a população usando a amostra.
- Dizemos que um procedimento de amostragem é **viesado** (ou tendencioso) se certos indivíduos em uma população tiverem uma chance maior de serem incluídos em uma amostra do que outros. Dizemos que um procedimento de amostragem é **não viesado** (ou imparcial) se cada indivíduo em uma população tiver chances iguais de ser amostrado.

Dizemos que uma amostra de n bolas extraídas usando nossa pá é **representativa** da população se o seu conteúdo “se assemelhar aproximadamente” ao conteúdo da urna. Se sim, então a proporção de bolas vermelhas da pá pode ser **generalizada** para a proporção das $N = 2400$ bolas da urna que são vermelhas. Ou expresso de forma diferente, $\hat{p}$ é um “bom palpite” de p . Agora digamos que trapaceamos ao usar a pá e removemos um número de bolas brancas em favor de bolas vermelhas. Então, essa amostra seria viesada em relação às bolas vermelhas e, portanto, a amostra não seria mais representativa da urna.

Uma maneira de garantir que uma amostra seja não viesada e representativa da população é usar a **amostragem aleatória**. Temos que **Inferência** é o ato de “dar um palpite” sobre algo desconhecido. Portanto, **Inferência estatística** é o ato de fazer um palpite sobre uma população usando uma amostra.

Em nosso caso, como a função `rep_sample_n()` usa o gerador de números aleatórios do seu computador, estávamos, de fato, realizando “amostragem aleatória”.

1.7 Estatísticas, estimadores e estimativas

A inferência estatística começa pela distinção entre o mecanismo probabilístico postulado para os dados e a realização efetivamente observada. Antes da coleta, representamos a amostra por um vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n).$$

Depois da coleta, os valores observados são escritos como

$$\mathbf{x} = (x_1, \dots, x_n).$$

A convenção de usar letras maiúsculas para variáveis aleatórias e minúsculas para suas realizações permite separar o procedimento inferencial, definido antes de observar os dados, do resultado numérico obtido em uma amostra particular (Cox, 2006, seq. 1.1; Ramachandran; Tsokos, 2021, seq. 5.2, pp. 180–182).

! Distinção fundamental

Uma **estatística** é uma função da amostra que não depende de parâmetros desconhecidos:

$$T = g(X_1, \dots, X_n).$$

Quando uma estatística é utilizada para estimar uma quantidade populacional $\tau(\theta)$, ela recebe o nome de **estimador**. Antes da observação dos dados, o estimador $\hat{\tau} = T(\mathbf{X})$ é uma variável aleatória.

A **estimativa** é o valor observado do estimador:

$$\hat{\tau}(\mathbf{x}) = g(x_1, \dots, x_n).$$

Assim, o estimador é a regra inferencial; a estimativa é o número produzido pela regra em uma amostra específica (Chihara; Hesterberg, 2022, definição 4.2, p. 79; Ramachandran; Tsokos, 2021, seq. 5.2, pp. 181–182).

Exemplos básicos

Parâmetro de interesse	Estatística utilizada como estimador
média populacional μ	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
variância populacional σ^2	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
proporção populacional p	$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$, para $X_i \in \{0, 1\}$

O papel inferencial depende do objetivo. Por exemplo, $\bar{X}$ é sempre uma estatística, mas somente é um estimador de μ quando a média populacional é a quantidade de interesse. A mesma estatística pode ainda ser empregada para estimar outras funções do parâmetro, dependendo do modelo adotado (Chihara; Hesterberg, 2022, seq. 1.6 e definição 4.2; Ramachandran; Tsokos, 2021, seq. 5.2).

1.8 Exemplo-guia: experimento da urna

Considere inicialmente um experimento idealizado no qual cada retirada é realizada **com reposição**, ou de maneira equivalente, no qual os resultados sucessivos podem ser tratados como independentes. Defina

$$X_i = \begin{cases} 1, & \text{se a } i\text{-ésima bola é vermelha,} \\ 0, & \text{se a } i\text{-ésima bola é branca.} \end{cases}$$

Se a probabilidade de uma bola vermelha em cada retirada é p , então

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p).$$

O total de bolas vermelhas e a proporção correspondente são

$$R = \sum_{i=1}^n X_i \quad \text{e} \quad \hat{p} = \frac{R}{n}.$$

Nesse exemplo, R e $\hat{p}$ são estatísticas. Quando o objetivo é estimar p , a proporção amostral $\hat{p}$ funciona como estimador da proporção populacional (Chihara; Hesterberg, 2022, seq. 1.5, seção 1.6 e apêndice B.1).

Com ou sem reposição?

A representação i.i.d. de Bernoulli exige retiradas independentes, como ocorre na amostragem com reposição. Em uma urna finita amostrada **sem reposição**, as observações não são independentes e o total de bolas vermelhas possui distribuição hipergeométrica. A distinção entre esses dois planos amostrais e a correção para população finita são desenvolvidas no capítulo **Distribuições Amostrais** (Chihara; Hesterberg, 2022, seq. 1.5, pp. 5–6; Rice, 2007, seq. 7.3).

1.9 A variabilidade dos estimadores: uma antecipação

Como um estimador é uma função de variáveis aleatórias, amostras diferentes podem produzir estimativas diferentes. A distribuição de probabilidade do estimador sob repetições do mecanismo amostral é denominada **distribuição amostral** (Chihara; Hesterberg, 2022, definições 4.1–4.2, pp. 77–79; Ramachandran; Tsokos, 2021, seq. 4.1, pp. 147–151).

Neste capítulo, essa ideia é utilizada apenas para justificar por que uma estimativa deve ser acompanhada de uma avaliação de incerteza. O capítulo **Distribuições Amostrais** desenvolve formalmente:

- as distribuições de $\bar{X}$, S^2 e $\hat{p}$;
- esperança, variância e erro-padrão das estatísticas;
- o efeito do tamanho amostral;
- a amostragem sem reposição e a correção para população finita;
- resultados exatos, aproximações assintóticas e simulação.

Essa divisão evita repetir aqui as derivações probabilísticas que constituem o objeto central do capítulo seguinte.

1.10 Critérios para avaliar estimadores: visão panorâmica

Diferentes estimadores podem ser propostos para o mesmo parâmetro. A escolha entre eles exige critérios que descrevam tanto o desempenho em amostras finitas quanto o comportamento quando o tamanho amostral aumenta (Chihara; Hesterberg, 2022, seq. 6.3; Ramachandran; Tsokos, 2021, seq. 5.2).

Critério	Pergunta orientadora
viés	O estimador está centrado, em média, no parâmetro de interesse?
variância	Quanto o estimador varia entre amostras?
erro quadrático médio	Qual é o efeito conjunto do viés e da variabilidade?
consistência	O estimador se aproxima do parâmetro quando n aumenta?

Para um estimador $\hat{\tau}$ de $\tau(\theta)$, o viés e o erro quadrático médio são

$$B_{\theta}(\hat{\tau}) = E_{\theta}(\hat{\tau}) - \tau(\theta)$$

e

$$\text{EQM}_\theta(\hat{\tau}) = \text{Var}_\theta(\hat{\tau}) + B_\theta(\hat{\tau})^2.$$

Esses conceitos são apresentados aqui como um mapa da teoria. Sua análise detalhada, incluindo eficiência, suficiência e resultados de melhoria de estimadores, pertence ao capítulo dedicado à avaliação de estimadores.

1.11 Modelo estatístico e função de verossimilhança

O processo gerador de dados de um fenômeno real raramente é conhecido em todos os seus detalhes. A análise começa, portanto, com um **modelo estatístico**: uma família de distribuições que representa os aspectos do mecanismo considerados relevantes para a pergunta científica. Em um modelo paramétrico,

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\},$$

em que θ é o parâmetro, ou vetor de parâmetros, e Θ é o espaço paramétrico. Cada valor de θ determina uma distribuição possível para os dados. O modelo é uma representação deliberadamente simplificada e sua adequação deve ser examinada no contexto da aplicação (Casella; Berger, 2002, cap. 1; Cox, 2006, seq. 1.1).

Função de verossimilhança

Suponha que a distribuição conjunta da amostra possua densidade ou função de probabilidade $f_{\mathbf{X}}(\mathbf{x}; \theta)$. Depois de observados os dados $\mathbf{x}$, a **função de verossimilhança** é

$$L(\theta; \mathbf{x}) = f_{\mathbf{X}}(\mathbf{x}; \theta),$$

considerada como função de θ , com $\mathbf{x}$ fixado. Se as observações forem i.i.d., a densidade conjunta se fatoriza e

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

A forma em produto é consequência da independência, não parte da definição geral. Além disso, multiplicar $L(\theta; \mathbf{x})$ por uma função positiva dos dados que não dependa de θ não altera as comparações de verossimilhança nem seus maximizadores (Cox, 2006, seq. 2.1, pp. 17–18; Casella; Berger, 2002, seq. 6.3).

⚠ Probabilidade e verossimilhança

Na distribuição $f_{\mathbf{X}}(\mathbf{x}; \theta)$, fixa-se θ e estudam-se os possíveis valores de $\mathbf{X}$. Na verossimilhança $L(\theta; \mathbf{x})$, os dados observados são fixados e os valores de θ são comparados. Consequentemente, a verossimilhança não é, em geral, uma distribuição de probabilidade para θ . Ela expressa **compatibilidade relativa** entre valores paramétricos e os dados no modelo adotado, não a probabilidade de o parâmetro assumir determinado valor (Cox, 2006, seq. 2.1).

Verossimilhança no experimento da urna

No modelo de retiradas independentes,

$$f(x_i; p) = p^{x_i}(1-p)^{1-x_i}, \quad x_i \in \{0, 1\}.$$

Para uma sequência observada $\mathbf{x} = (x_1, \dots, x_n)$, com

$$r = \sum_{i=1}^n x_i,$$

a verossimilhança é

$$L(p; \mathbf{x}) = p^r(1-p)^{n-r}, \quad 0 \leq p \leq 1.$$

Se apenas o total $R = r$ for registrado, sua função de probabilidade é

$$P_p(R = r) = \binom{n}{r} p^r (1-p)^{n-r}.$$

O fator $\binom{n}{r}$ não depende de p . Portanto, a sequência completa e o total de sucessos produzem funções de verossimilhança proporcionais e conduzem ao mesmo estimador de máxima verossimilhança. A dependência dos dados em relação a p ocorre apenas por meio de r , antecipando a ideia de redução de dados por suficiência.

Para $0 < r < n$, a log-verossimilhança é

$$\ell(p) = r \log p + (n-r) \log(1-p),$$

cujo máximo ocorre em

$$\hat{p}_{\text{MV}} = \frac{r}{n}.$$

O mesmo resultado permanece válido nos casos de fronteira: se $r = 0$, então $\hat{p}_{\text{MV}} = 0$; se $r = n$, então $\hat{p}_{\text{MV}} = 1$ (Chihara; Hesterberg, 2022, seq. 6.1.1, pp. 148–150; Ramachandran; Tsokos, 2021, seq. 5.3).

i Três papéis da proporção amostral

No modelo de Bernoulli, $\hat{p} = R/n$ é simultaneamente:

1. uma estatística, porque é função da amostra;
2. um estimador, porque é utilizada para estimar p ;
3. o estimador de máxima verossimilhança de p .

Os três papéis são conceitualmente distintos, embora sejam desempenhados pela mesma expressão matemática.

Verificação de aprendizagem

1. Explique a diferença entre o estimador $\hat{p}$ e a estimativa obtida depois de observar os dados.
2. Por que $R = \sum_i X_i$ é uma estatística? Em que situação ele poderia ser tratado como estimador?
3. Qual hipótese do experimento da urna permite escrever $X_1, \dots, X_n$ como uma amostra i.i.d. de Bernoulli?
4. Por que a forma $\prod_i f(x_i; \theta)$ não é válida para qualquer plano amostral?
5. Na função $L(\theta; \mathbf{x})$, quais elementos permanecem fixos e quais variam?
6. Por que as verossimilhanças baseadas na sequência de retiradas e apenas no total R conduzem ao mesmo estimador de p ?

Referências

2 Distribuições Amostrais

2.1 Introdução

A inferência estatística utiliza dados amostrais para produzir afirmações sobre características desconhecidas de uma população ou de um modelo probabilístico. Como diferentes amostras, obtidas sob o mesmo mecanismo de amostragem, geralmente produzem diferentes valores para uma mesma estatística, é necessário descrever probabilisticamente essa variabilidade. A **distribuição amostral** fornece precisamente essa descrição e estabelece a ligação entre a teoria da probabilidade e os procedimentos de estimação e teste de hipóteses (Ramachandran; Tsokos, 2021, cap. 4, seção 4.1, pp. 147–148; Rice, 2007, cap. 7, seção 7.3).

Considere uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ e uma estatística

$$T = T(\mathbf{X}) = g(X_1, \dots, X_n).$$

Antes da observação dos dados, T é uma variável aleatória. Depois que a amostra observada $\mathbf{x} = (x_1, \dots, x_n)$ é obtida, a realização correspondente $t = g(x_1, \dots, x_n)$ é um número. A distribuição de probabilidade de T , induzida pelo modelo probabilístico e pelo plano amostral, é chamada de distribuição amostral de T .

! Definição — Distribuição amostral

A **distribuição amostral** de uma estatística $T = g(X_1, \dots, X_n)$ é a distribuição de probabilidade de T sob o mecanismo que gera a amostra (Ramachandran; Tsokos, 2021, definição 4.1.4, p. 148; Chihara; Hesterberg, 2022, definição 4.1, pp. 78–79).

i Interpretação

A distribuição populacional descreve a variabilidade de uma observação individual X . A distribuição amostral descreve a variabilidade de uma função de várias observações, como $\bar{X}$, S^2 , $\hat{p}$, uma mediana ou uma estatística de ordem. Essas distribuições, em geral, não são iguais (Ramachandran; Tsokos, 2021, seq. 4.1, pp. 147–148; Chihara; Hesterberg, 2022, seq. 4.1, pp. 77–82).

Objetivos do capítulo

Ao final deste capítulo, o leitor deverá ser capaz de:

1. distinguir população, amostra, parâmetro, estatística e distribuição amostral;
2. reconhecer a diferença entre o modelo i.i.d. e a amostragem sem reposição em população finita;
3. obter distribuições amostrais por enumeração, transformação, funções geradoras de momentos e resultados assintóticos;
4. determinar as distribuições da média e da proporção amostrais;
5. aplicar corretamente a Lei dos Grandes Números e o Teorema Central do Limite;
6. utilizar as distribuições χ^2 , t e F no modelo normal;
7. obter distribuições de estatísticas de ordem;
8. aproximar distribuições amostrais por simulação.

2.2 População, parâmetro, amostra e estatística

! Definição — Modelo estatístico e parâmetro

Um **modelo estatístico paramétrico** é uma família de distribuições

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\},$$

em que θ é um parâmetro desconhecido e Θ é o espaço paramétrico. Quando existem densidades ou funções de probabilidade, a família pode ser representada por $\{f(x; \theta) : \theta \in \Theta\}$ (Casella; Berger, 2002, cap. 1; Cox, 2006, seq. 1.7).

! Definição — Amostra aleatória no modelo i.i.d.

As variáveis aleatórias $X_1, \dots, X_n$ formam uma **amostra aleatória de tamanho n** da distribuição F quando são independentes e identicamente distribuídas, isto é,

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F.$$

Quando F possui densidade ou função de probabilidade f , a distribuição conjunta da amostra é

$$f_{\mathbf{X}}(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i).$$

Essa é a formulação usual de uma amostra aleatória no modelo i.i.d. (Casella; Berger, 2002, seq. 5.1; Kerns, 2010, seq. 8.1; Ramachandran; Tsokos, 2021, seq. 4.1).

! Definição — Estatística

Uma **estatística** é uma função mensurável da amostra que não depende de parâmetros desconhecidos:

$$T = g(X_1, \dots, X_n).$$

Exemplos incluem

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n I(X_i \in A) \quad \text{e} \quad X_{(1)} \leq \dots \leq X_{(n)}.$$

A definição e os exemplos seguem a apresentação usual de estatísticas como funções da amostra (Ramachandran; Tsokos, 2021, seq. 4.1; Chihara; Hesterberg, 2022, definições 4.1–4.2).

! Observação — Estatística e estimador

Toda estatística é uma variável aleatória, mas ela somente recebe a interpretação de **estimador** quando é utilizada para estimar uma quantidade populacional. Por exemplo, $\bar{X}$ é uma estatística e pode ser usada como estimador de $\mu = E(X)$ (Chihara; Hesterberg, 2022, definição 4.2, p. 79).

2.3 Dois referenciais de amostragem

A expressão *amostragem aleatória simples* é utilizada em dois contextos relacionados, mas matematicamente distintos. A distinção evita confundir independência probabilística com aleatorização de um plano amostral.

2.3.1 Amostragem no modelo i.i.d.

No modelo i.i.d., cada observação é gerada independentemente pela mesma distribuição. Esse referencial é apropriado para repetições independentes de um experimento, amostragem com reposição ou modelagem de uma população conceitualmente infinita (Casella; Berger, 2002, seq. 5.1; Ramachandran; Tsokos, 2021, seq. 4.1). Se $f(x; \theta)$ é a distribuição comum, a densidade conjunta é

$$f_{\mathbf{X}}(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta).$$

Para dados observados $\mathbf{x}$, a mesma expressão, considerada como função de θ , define a verossimilhança (Casella; Berger, 2002, seq. 6.3; Cox, 2006, seq. 2.1):

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

A distribuição amostral é uma distribuição de uma estatística sob P_θ ; a verossimilhança, por sua vez, mantém os dados fixos e compara valores de θ . Esses objetos são relacionados, mas não devem ser identificados (Cox, 2006, seq. 1.3 e 2.1).

💡 Exemplo — Tempos de vida exponenciais

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\beta)$, na parametrização por escala,

$$f(x; \beta) = \frac{1}{\beta} e^{-x/\beta} I(x > 0),$$

então

$$f_{\mathbf{X}}(\mathbf{x}; \beta) = \beta^{-n} \exp\left(-\frac{1}{\beta} \sum_{i=1}^n x_i\right) \prod_{i=1}^n I(x_i > 0).$$

A probabilidade de que todas as unidades durem mais de dois anos é

$$P(X_1 > 2, \dots, X_n > 2) = \prod_{i=1}^n P(X_i > 2) = e^{-2n/\beta}.$$

2.3.2 Amostragem aleatória simples sem reposição

Considere a população finita $\mathcal{U} = \{c_1, \dots, c_N\}$. Uma amostra aleatória simples sem reposição de tamanho n seleciona, com a mesma probabilidade, cada subconjunto de n unidades. As observações possuem a mesma distribuição marginal, mas não são independentes (Cox, 2006, seq. 9.2; Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, seq. 7.3.1).

Defina

$$\mu_N = \frac{1}{N} \sum_{j=1}^N c_j \quad \text{e} \quad \sigma_N^2 = \frac{1}{N} \sum_{j=1}^N (c_j - \mu_N)^2.$$

Então

$$E(\bar{X}) = \mu_N$$

e

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N-n}{N-1}.$$

O fator

$$\frac{N-n}{N-1}$$

é a correção de população finita para a variância. Para o erro-padrão, a correção correspondente é sua raiz quadrada (Rice, 2007, seq. 7.3.1, pp. 203–210; Cox, 2006, seq. 9.2, pp. 179–181).

⚠ Observação — Duas convenções para a variância finita

Se a variância da população finita for definida por

$$S_N^2 = \frac{1}{N-1} \sum_{j=1}^N (c_j - \mu_N)^2,$$

então a mesma fórmula pode ser escrita como

$$\text{Var}(\bar{X}) = \left(1 - \frac{n}{N}\right) \frac{S_N^2}{n}.$$

As duas expressões são equivalentes; é necessário apenas manter a convenção utilizada para a variância populacional (Cox, 2006, seq. 9.2; Rice, 2007, seq. 7.3.1).

i Interpretação — Fração amostral

Quando n/N é pequeno, a correção de população finita é próxima de 1, e o erro-padrão fica próximo de $\sigma_N/\sqrt{n}$. Quando uma fração apreciável da população é observada, a amostragem sem reposição reduz a incerteza em relação à amostragem com reposição (Cox, 2006, seq. 9.2; Rice, 2007, seq. 7.3.1).

2.4 Construção de uma distribuição amostral por enumeração

Quando a população e o tamanho amostral são pequenos, a distribuição amostral pode ser obtida enumerando todas as amostras possíveis e calculando a estatística em cada uma delas (Ramachandran; Tsokos, 2021, seq. 4.1, pp. 148–151; Chihara; Hesterberg, 2022, seq. 4.2, pp. 82–85).

Exemplo — Média de uma população finita

Considere a população

$$\mathcal{U} = \{3,8; 3,9; 4,0; 4,1\}$$

em km/L e amostras ordenadas de tamanho $n = 2$, com reposição. Existem $4^2 = 16$ amostras equiprováveis. A distribuição de $\bar{X}$ é

$\bar{x}$	3,80	3,85	3,90	3,95	4,00	4,05	4,10
Probabilidade	1/16	2/16	3/16	4/16	3/16	2/16	1/16

A média e a variância populacionais são

$$\mu_N = 3,95 \quad \text{e} \quad \sigma_N^2 = 0,0125.$$

Consequentemente,

$$E(\bar{X}) = 3,95 \quad \text{e} \quad \text{Var}(\bar{X}) = \frac{0,0125}{2} = 0,00625.$$

Sem reposição, existem $\binom{4}{2} = 6$ subconjuntos equiprováveis, e

$$\text{Var}(\bar{X}) = \frac{0,0125}{2} \frac{4-2}{4-1} = 0,004166 \dots$$

Interpretação

A enumeração torna visível que a distribuição amostral é a distribuição dos valores de uma estatística sob repetição do plano amostral. Para populações grandes ou contínuas, a enumeração exata é inviável, sendo substituída por resultados analíticos, aproximações assintóticas ou simulação.

2.5 Somas, transformações e funções geradoras de momentos

Se

$$Y = \sum_{i=1}^n X_i, \quad \bar{X} = \frac{Y}{n},$$

então, no caso contínuo,

$$f_{\bar{X}}(x) = n f_Y(nx).$$

A obtenção de f_Y pode exigir convoluções. Quando as funções geradoras de momentos existem em uma vizinhança de zero, elas fornecem uma alternativa conveniente (Larsen; Marx, 2012, seq. 3.8 e 3.12; Kerns, 2010, seq. 5.4; Rice, 2007, seq. 4.5).

! Teorema — FGM da soma e da média

Se $X_1, \dots, X_n$ são independentes e possuem funções geradoras de momentos $M_{X_i}(t)$, então

$$M_{\sum X_i}(t) = \prod_{i=1}^n M_{X_i}(t).$$

Se, adicionalmente, são identicamente distribuídas com FGM $M_X(t)$, então

$$M_{\bar{X}}(t) = \left[M_X\left(\frac{t}{n}\right) \right]^n.$$

O resultado decorre da independência e da propriedade de transformação da FGM (Larsen; Marx, 2012, seq. 3.12; Rice, 2007, seq. 4.5).

💡 Exemplo — Média de variáveis normais

Se $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, então

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

Logo,

$$M_{\bar{X}}(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2n}\right),$$

e, portanto,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Essa dedução por FGM é apresentada em tratamentos clássicos de transformações e somas de variáveis aleatórias (Larsen; Marx, 2012, seq. 3.12; Rice, 2007, cap. 4 e 6).

💡 Exemplo — Média de variáveis gama

Adote a parametrização por forma α e escala β :

$$X_i \stackrel{\text{i.i.d.}}{\sim} \text{Gama}(\alpha, \beta), \quad M_X(t) = (1 - \beta t)^{-\alpha}.$$

Então

$$M_{\bar{X}}(t) = \left(1 - \frac{\beta}{n}t\right)^{-n\alpha},$$

de modo que

$$\bar{X} \sim \text{Gama}\left(n\alpha, \frac{\beta}{n}\right).$$

A conclusão usa a FGM da distribuição gama e a regra de escala (Larsen; Marx, 2012, seq. 3.12 e 4.6; Ramachandran; Tsokos, 2021, cap. 3–4).

2.6 Distribuição amostral da média

Se $X_1, \dots, X_n$ são i.i.d., $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$, então (Ramachandran; Tsokos, 2021, teorema 4.1.1, p. 148; Kerns, 2010, seq. 8.1–8.2)

$$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$$

e

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

O desvio-padrão da distribuição amostral é

$$\text{EP}(\bar{X}) = \frac{\sigma}{\sqrt{n}},$$

e recebe o nome de **erro-padrão** de $\bar{X}$.

! Resultado — Média amostral

Para uma amostra i.i.d. com média μ e variância finita σ^2 ,

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Se a população é normal, então, para todo $n \geq 1$,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Esses resultados são exatos no modelo normal e, para os dois primeiros momentos, válidos para qualquer população com variância finita (Ramachandran; Tsokos, 2021, teorema 4.1.1; Kerns, 2010, seq. 8.2; Chihara; Hesterberg, 2022, apêndices A.5–A.6).

i Interpretação — Efeito do tamanho amostral

O erro-padrão decresce à taxa $n^{-1/2}$. Para reduzir o erro-padrão pela metade, é necessário multiplicar o tamanho da amostra por quatro. O aumento de n reduz a variabilidade da média, mas não corrige viés de seleção, dependência não modelada ou erros sistemáticos de mensuração (Rice, 2007, seq. 7.3.1, pp. 206–207).

💡 Exemplo — Níveis de colesterol

Suponha que os níveis de colesterol sejam distribuídos como

$$X \sim N(210, 37^2) \text{ mg/dL}.$$

Para $n = 10$,

$$\bar{X} \sim N\left(210, \frac{37^2}{10}\right), \quad \text{EP}(\bar{X}) = \frac{37}{\sqrt{10}} \approx 11,70.$$

Os 95% centrais da distribuição individual estão aproximadamente em

$$210 \pm 1,96(37) = (137,48; 282,52),$$

enquanto os 95% centrais da distribuição de $\bar{X}$ estão em

$$210 \pm 1,96 \frac{37}{\sqrt{10}} \approx (187,07; 232,93).$$

A menor amplitude do segundo intervalo reflete a menor variabilidade das médias amostrais.

2.7 Lei dos Grandes Números

A Lei dos Grandes Números descreve a convergência da média amostral para a média populacional. Ela trata da **concentração** de $\bar{X}_n$ em torno de μ , e não da forma da distribuição dos erros (Rice, 2007, seq. 5.2, pp. 177–181).

! Teorema — Lei Fraca dos Grandes Números

Se $X_1, X_2, \dots$ são i.i.d., $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$, então, para todo $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0,$$

isto é,

$$\bar{X}_n \xrightarrow{p} \mu.$$

A desigualdade de Chebyshev fornece uma demonstração direta:

$$P(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

! Teorema — Lei Forte dos Grandes Números

Sob condições usuais, por exemplo quando $X_1, X_2, \dots$ são i.i.d. e $E(|X_1|) < \infty$,

$$\bar{X}_n \xrightarrow{q.c.} \mu,$$

ou seja, a convergência ocorre com probabilidade 1 (Rice, 2007, seq. 5.2).

💡 Exemplo — Frequência relativa

Se $X_i = I(A_i)$ indica a ocorrência de um evento com probabilidade p , então $X_i \sim \text{Bernoulli}(p)$ e

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n I(A_i)$$

é a frequência relativa do evento. Pela Lei dos Grandes Números,

$$\bar{X}_n \xrightarrow{p} p$$

e, sob independência, também $\bar{X}_n \xrightarrow{q.c.} p$.

2.8 Teorema Central do Limite

A Lei dos Grandes Números afirma que $\bar{X}_n$ se aproxima de μ . O Teorema Central do Limite descreve a escala e a forma aproximada das flutuações de $\bar{X}_n$ em torno de μ (Chihara; Hesterberg, 2022, seq. 4.3, pp. 85–93; Kerns, 2010, seq. 8.3; Rice, 2007, seq. 5.3).

! Teorema — Teorema Central do Limite de Lindeberg–Lévy

Se $X_1, X_2, \dots$ são i.i.d., com

$$E(X_i) = \mu \quad \text{e} \quad 0 < \sigma^2 = \text{Var}(X_i) < \infty,$$

então

$$Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

Assim, para n suficientemente grande,

$$\bar{X}_n \dot{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$$

e

$$\sum_{i=1}^n X_i \dot{\sim} N(n\mu, n\sigma^2).$$

! Observação — O que converge

A formulação rigorosa do TCL é a convergência da variável **padronizada** Z_n para $N(0, 1)$. Não se deve dizer, sem qualificação, que $\bar{X}_n$ converge para uma normal com variância σ^2/n , pois essa variância depende de n e tende a zero. De fato, pela Lei dos Grandes Números, $\bar{X}_n$ converge para a constante μ .

! Observação — Não existe uma regra universal $n \geq 30$

A qualidade da aproximação normal depende da assimetria, do peso das caudas, da existência de momentos, da natureza discreta ou contínua da população e da precisão desejada. Distribuições fortemente assimétricas ou com caudas pesadas podem exigir amostras muito maiores. O diagnóstico deve considerar o modelo e, quando possível, simulações ou limites de erro (Chihara; Hesterberg, 2022, seq. 4.3.3, p. 92).

2.8.1 Padronização com variância estimada

Como $S \xrightarrow{p} \sigma$ sob condições usuais, o teorema de Slutsky implica (Lauritzen, 2023, apêndice A.2.2)

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{d} N(0, 1).$$

 Observação — Resultado exato e resultado assintótico

Para amostras normais, a estatística acima possui exatamente distribuição t_{n-1} . Para populações não normais, sua distribuição é apenas assintoticamente normal; não é, em geral, exatamente t_{n-1} (Larsen; Marx, 2012, cap. 7; Rice, 2007, cap. 6).

2.9 Distribuição amostral da proporção

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, então (Chihara; Hesterberg, 2022, seq. 4.1 e 4.3.1; Ramachandran; Tsokos, 2021, seq. 4.5)

$$Y = \sum_{i=1}^n X_i \sim \text{Binomial}(n, p)$$

e

$$\hat{p} = \bar{X} = \frac{Y}{n}.$$

Portanto,

$$E(\hat{p}) = p$$

e

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

A distribuição exata de $\hat{p}$ é discreta:

$$P\left(\hat{p} = \frac{k}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

Pelo TCL,

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0, 1).$$

2.9.1 Aproximação normal da binomial

Se $Y \sim \text{Binomial}(n, p)$, então

$$Y \dot{\sim} N(np, np(1-p)).$$

Como a binomial é discreta e a normal é contínua, a **correção de continuidade** costuma melhorar a aproximação (Chihara; Hesterberg, 2022, seq. 4.3.1–4.3.2; Ramachandran; Tsokos, 2021, seq. 4.5). Por exemplo,

$$P(Y \leq k) \approx \Phi\left(\frac{k + 0,5 - np}{\sqrt{np(1-p)}}\right),$$

e

$$P(Y \geq k) \approx 1 - \Phi\left(\frac{k - 0,5 - np}{\sqrt{np(1-p)}}\right).$$

Interpretação — Condições práticas

Condições como $np \geq 5$ e $n(1-p) \geq 5$, ou versões mais conservadoras com limite 10, são apenas diagnósticos heurísticos. Elas não garantem uma precisão fixa para todos os valores de p e todos os tipos de probabilidade de cauda (Chihara; Hesterberg, 2022, seq. 4.3.3, p. 92).

Exemplo — Apoio a uma política pública

Suponha $p = 0,53$ e $n = 1000$. Se Y é o número de apoiadores na amostra, então

$$Y \sim \text{Binomial}(1000, 0,53),$$

com

$$E(Y) = 530, \quad \text{DP}(Y) = \sqrt{1000(0,53)(0,47)} \approx 15,78.$$

Usando correção de continuidade,

$$P(Y < 500) = P(Y \leq 499) \approx \Phi\left(\frac{499,5 - 530}{15,78}\right) \approx \Phi(-1,93) \approx 0,027.$$

2.10 Distribuição amostral da variância

Considere

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Se $X_1, \dots, X_n$ são i.i.d. e $\text{Var}(X_i) = \sigma^2 < \infty$, então

$$E(S^2) = \sigma^2.$$

Logo, S^2 é um estimador não viesado de σ^2 (Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, cap. 6).

2.10.1 Variância de S^2 em uma população geral

Se o quarto momento central

$$\mu_4 = E[(X - \mu)^4]$$

é finito, então

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right].$$

i Demonstração — Variância de S^2

Defina $Y_i = X_i - \mu$ e

$$A = \sum_{i=1}^n Y_i^2, \quad B = \frac{1}{n} \left(\sum_{i=1}^n Y_i \right)^2.$$

Como

$$Q = \sum_{i=1}^n (X_i - \bar{X})^2 = A - B = (n-1)S^2,$$

basta calcular $E(Q^2)$. Pela independência, por $E(Y_i) = 0$, $E(Y_i^2) = \sigma^2$ e $E(Y_i^4) = \mu_4$,

$$E(A^2) = n\mu_4 + n(n-1)\sigma^4,$$

$$E(AB) = \mu_4 + (n-1)\sigma^4$$

e

$$E(B^2) = \frac{\mu_4}{n} + \frac{3(n-1)}{n}\sigma^4.$$

Consequentemente,

$$E(Q^2) = \frac{(n-1)^2}{n}\mu_4 + \frac{(n-1)(n^2-2n+3)}{n}\sigma^4.$$

Dividindo por $(n-1)^2$, obtemos

$$E[(S^2)^2] = \frac{\mu_4}{n} + \frac{n^2-2n+3}{n(n-1)}\sigma^4.$$

Como $E(S^2) = \sigma^2$, segue que

$$\text{Var}(S^2) = E[(S^2)^2] - \sigma^4 = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1}\sigma^4 \right].$$

Portanto, a variância de S^2 depende do quarto momento da população. A fórmula

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

é válida especificamente para a população normal, pois nesse caso $\mu_4 = 3\sigma^4$.

2.11 Distribuições derivadas do modelo normal

As distribuições χ^2 , t e F surgem de transformações de variáveis normais e desempenham papel central na inferência exata para médias e variâncias (Rice, 2007, cap. 6; Larsen; Marx, 2012, cap. 7 e 9; Ramachandran; Tsokos, 2021, seq. 4.2).

2.11.1 Distribuição qui-quadrado

! Definição — Distribuição χ^2

Se $Z_1, \dots, Z_\nu$ são independentes e $Z_j \sim N(0, 1)$, então

$$W = \sum_{j=1}^{\nu} Z_j^2 \sim \chi_\nu^2.$$

O parâmetro ν é o número de graus de liberdade (Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2).

Se $W \sim \chi_\nu^2$, então

$$E(W) = \nu, \quad \text{Var}(W) = 2\nu.$$

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, então

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi_n^2.$$

A decomposição

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2$$

separa a variabilidade residual da variabilidade da média. No modelo normal, os dois termos padronizados são independentes, resultando em

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Esse resultado e a independência usada em sua obtenção são específicos do modelo normal (Larsen; Marx, 2012, cap. 7; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2–6.3).

i Interpretação dos graus de liberdade

Os **graus de liberdade** representam o número de componentes independentes de variação que permanecem disponíveis depois que são consideradas as restrições impostas pelo problema ou os parâmetros estimados a partir dos dados.

Essa interpretação aparece naturalmente na distribuição qui-quadrado. Se

$$Z_1, \dots, Z_\nu \stackrel{\text{i.i.d.}}{\sim} N(0, 1),$$

então

$$\sum_{j=1}^{\nu} Z_j^2 \sim \chi_\nu^2.$$

Nesse caso, ν é o número de componentes normais independentes que contribuem para a soma de quadrados. Considere agora uma amostra $(X_1, \dots, X_n)$. Os desvios em relação à média amostral satisfazem

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

Logo, os n desvios não podem variar independentemente: depois que $(n - 1)$ deles são determinados, o último fica completamente definido pela restrição acima. Por essa razão, a soma de quadrados

$$\sum_{i=1}^n (X_i - \bar{X})^2$$

possui $(n - 1)$ graus de liberdade. No modelo normal,

$$\frac{(n - 1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

De maneira mais geral, os graus de liberdade podem ser interpretados como a dimensão do espaço de variação que resta após a imposição de restrições. Em modelos lineares com n observações e uma matriz de delineamento de posto p , por exemplo, os resíduos possuem

$$n - p$$

graus de liberdade. Em testes da razão de verossimilhanças, os graus de liberdade assintóticos correspondem à diferença entre as dimensões dos modelos irrestrito e restrito.

Essa interpretação deve ser usada com cautela em procedimentos aproximados. No teste de Welch, por exemplo, os graus de liberdade podem não ser inteiros: eles constituem uma aproximação de Satterthwaite utilizada para calibrar uma distribuição (t), e não uma contagem literal de observações independentes (Rice, 2007, secs. 6.2–6.3 and 9.5; Chihara; Hesterberg, 2022, sec. 7.1).

2.11.2 Independência entre média e variância

! Teorema — Independência no modelo normal

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, então

$$\bar{X} \perp\!\!\!\perp S^2.$$

A independência entre a média e a variância amostrais é um resultado característico da amostragem normal (Larsen; Marx, 2012, apêndice 7.A.2; Rice, 2007, seq. 6.3).

Além disso,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

e

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

! Observação — Caracterização da normalidade

A independência entre $\bar{X}$ e S^2 é uma propriedade especial da distribuição normal. Ela não vale, em geral, para outras populações.

2.11.3 Distribuição t de Student

! Definição — Distribuição t

Se

$$Z \sim N(0, 1), \quad W \sim \chi_\nu^2,$$

são independentes, então

$$T = \frac{Z}{\sqrt{W/\nu}} \sim t_\nu.$$

Essa construção define a distribuição t de Student (Larsen; Marx, 2012, seq. 7.2–7.3; Rice, 2007, seq. 6.2).

A densidade é

$$f_T(t) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi}\Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}, \quad -\infty < t < \infty.$$

A distribuição é simétrica em torno de zero e possui caudas mais pesadas que a normal padrão. Além disso,

$$E(T) = 0 \quad (\nu > 1)$$

e

$$\text{Var}(T) = \frac{\nu}{\nu-2} \quad (\nu > 2).$$

Quando $\nu \rightarrow \infty$,

$$t_\nu \xrightarrow{d} N(0, 1).$$

No modelo normal,

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

💡 Exemplo — Média normal com variância desconhecida

Para uma amostra normal de tamanho $n = 10$,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{10}} \sim t_9.$$

Como $P(-t_{0,975;9} \leq T \leq t_{0,975;9}) = 0,95$, a inversão dessa desigualdade produz o intervalo de confiança bilateral de 95% para μ :

$$\bar{X} \pm t_{0,975;9} \frac{S}{\sqrt{10}},$$

em que $t_{0,975;9} \approx 2,262$ (Larsen; Marx, 2012, seq. 7.4; Rice, 2007, cap. 6).

2.11.4 Distribuição F

! Definição — Distribuição F

Se $W_1 \sim \chi_{\nu_1}^2$ e $W_2 \sim \chi_{\nu_2}^2$ são independentes, então

$$F = \frac{W_1/\nu_1}{W_2/\nu_2} \sim F_{\nu_1, \nu_2}.$$

Essa razão de qui-quadrados independentes define a distribuição F (Larsen; Marx, 2012, seq. 9.3; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2).

Se $F \sim F_{\nu_1, \nu_2}$, então

$$E(F) = \frac{\nu_2}{\nu_2 - 2}, \quad \nu_2 > 2,$$

e

$$\text{Var}(F) = \frac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}, \quad \nu_2 > 4.$$

Se duas amostras normais são independentes,

$$X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} N(\mu_1, \sigma_1^2)$$

e

$$Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma_2^2),$$

então

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}.$$

Sob a hipótese $\sigma_1^2 = \sigma_2^2$,

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}.$$

⚠ Observação — Sensibilidade à não normalidade

A distribuição F da razão de variâncias amostrais é exata sob normalidade. Procedimentos baseados nessa razão podem ser sensíveis a assimetria, caudas pesadas e valores extremos; a validade deve ser avaliada no contexto da aplicação.

i Relações úteis

Se $T \sim t_\nu$, então

$$T^2 \sim F_{1,\nu}.$$

Se $F \sim F_{\nu_1,\nu_2}$, então

$$\frac{1}{F} \sim F_{\nu_2,\nu_1}.$$

2.12 Estatísticas de ordem

Seja $X_1, \dots, X_n$ uma amostra i.i.d. de uma distribuição contínua com função de distribuição F e densidade f . A notação e os resultados desta seção seguem a formulação clássica de estatísticas de ordem (Larsen; Marx, 2012, seq. 3.10, pp. 193–200; Ramachandran; Tsokos, 2021, seq. 4.3). As observações ordenadas são denotadas por

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}.$$

As variáveis $X_{(1)}$ e $X_{(n)}$ são, respectivamente, o mínimo e o máximo amostrais.

2.12.1 Mínimo e máximo

Para o mínimo,

$$P(X_{(1)} > x) = P(X_1 > x, \dots, X_n > x) = [1 - F(x)]^n,$$

logo

$$F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n$$

e

$$f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1}f(x).$$

Para o máximo,

$$F_{X_{(n)}}(x) = P(X_1 \leq x, \dots, X_n \leq x) = [F(x)]^n$$

e

$$f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x).$$

2.12.2 k -ésima estatística de ordem

! Teorema — Densidade de $X_{(k)}$

Para $k = 1, \dots, n$,

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x).$$

A fórmula resulta da contagem das posições relativas das observações em torno de x (Larsen; Marx, 2012, teorema 3.10.2; Ramachandran; Tsokos, 2021, seq. 4.3).

💡 Exemplo — Amostra uniforme

Se $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$, então $F(x) = x$ e $f(x) = 1$ para $0 < x < 1$. Assim,

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k},$$

o que implica

$$X_{(k)} \sim \text{Beta}(k, n - k + 1).$$

Em particular,

$$E[X_{(k)}] = \frac{k}{n+1}.$$

O caso uniforme é uma aplicação direta da densidade geral e identifica uma distribuição beta (Larsen; Marx, 2012, seq. 3.10; Hogg; Craig, 1978, seção sobre estatísticas de ordem).

2.13 Distribuições amostrais por simulação

Quando a distribuição exata de uma estatística é difícil de obter, pode-se aproximá-la por Monte Carlo: simula-se um grande número de amostras do modelo, calcula-se a estatística em cada amostra e analisa-se a distribuição empírica resultante (Chihara; Hesterberg, 2022, seq. 4.2, pp. 82–85; Kerns, 2010, seq. 8.5).

! Procedimento — Simulação de Monte Carlo

1. Especifique o modelo populacional e o tamanho amostral n .
2. Gere uma amostra de tamanho n .
3. Calcule a estatística T .
4. Repita os passos 2 e 3 um grande número B de vezes.
5. Use os valores $T^{(1)}, \dots, T^{(B)}$ para aproximar probabilidades, quantis, esperança, variância e forma da distribuição amostral.

Exemplo computacional: manifestação do TCL

O código abaixo compara as distribuições de médias de amostras exponenciais para diferentes tamanhos amostrais.

```
set.seed(20262)

B <- 20000
ns <- c(2, 50, 100)

for (n in ns) {
  medias <- replicate(B, mean(rexp(n, rate = 1)))

  hist(
    medias,
    probability = TRUE,
    breaks = 40,
    main = "",
    xlab = expression(bar(X)),
    ylab = "Densidade"
  )

  box()
}
```

```

curva_x <- seq(min(medias), max(medias), length.out = 400)
lines(curva_x, dnorm(curva_x, mean = 1, sd = 1 / sqrt(n)), lwd = 2)
}

```




Figura 2.1: Distribuições simuladas da média de amostras exponenciais.

i Interpretação

A distribuição exponencial é assimétrica, mas a distribuição de $\bar{X}$ torna-se progressivamente mais próxima da normal conforme n aumenta (ver Figura 2.1). Ao mesmo tempo, sua dispersão diminui de acordo com $1/\sqrt{n}$.

Exemplo computacional: distribuição exata em população finita

```

populacao <- c(3.8, 3.9, 4.0, 4.1)

# Amostras ordenadas de tamanho 2, com reposição
amostras <- expand.grid(X1 = populacao, X2 = populacao)
amostras$media <- rowMeans(amostras)

prop.table(table(amostras$media))

```

```

      3.8      3.85      3.9      3.95      4      4.05      4.1
0.0625 0.1250 0.1875 0.2500 0.1875 0.1250 0.0625

```

```
mean(amostras$media)
```

```
[1] 3.95
```

```
var_pop <- mean((populacao - mean(populacao))^2)
mean((amostras$media - mean(amostras$media))^2)
```

```
[1] 0.00625
```

```
var_pop / 2
```

```
[1] 0.00625
```

2.14 Quadro-síntese

Situação	Estatística	Distribuição ou aproximação
Amostra i.i.d., $E(X) = \mu$, $\text{Var}(X) = \sigma^2$	$\bar{X}$	$E(\bar{X}) = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$
População normal	$\bar{X}$	$N(\mu, \sigma^2/n)$, exatamente
População geral, variância finita	$\sqrt{n}(\bar{X} - \mu)/\sigma$	$N(0, 1)$, assintoticamente
Bernoulli	$Y = \sum X_i$	Binomial(n, p)
Bernoulli	$\hat{p} = Y/n$	$E(\hat{p}) = p$, $\text{Var}(\hat{p}) = p(1-p)/n$
População normal	$(n-1)S^2/\sigma^2$	χ_{n-1}^2
População normal	$(\bar{X} - \mu)/(S/\sqrt{n})$	t_{n-1}
Duas populações normais independentes	$(S_1^2/\sigma_1^2)/(S_2^2/\sigma_2^2)$	F_{n_1-1, n_2-1}
População contínua	$X_{(k)}$	densidade de estatística de ordem
População finita sem reposição	$\bar{X}$	variância com correção de população finita

2.15 Exercícios

Exercícios conceituais

1. **População e distribuição amostral.** Explique a diferença entre a distribuição de X e a distribuição de $\bar{X}$. Em que situação as duas distribuições pertencem à mesma família normal?

2. **Estatística ou parâmetro.** Classifique cada quantidade como parâmetro ou estatística: μ , σ^2 , $\bar{X}$, S^2 , p , $\hat{p}$ e $X_{(n)}$.
3. **Dois referenciais.** Explique por que as observações de uma amostra aleatória simples sem reposição de uma população finita não são independentes. Mostre que elas possuem a mesma distribuição marginal.
4. **Lei dos Grandes Números e TCL.** Compare as conclusões dos dois teoremas. Qual deles descreve concentração? Qual descreve a distribuição padronizada do erro?
5. **Normalidade.** Identifique quais resultados deste capítulo são exatos somente sob normalidade e quais permanecem válidos para uma população geral com momentos finitos.

Exercícios de cálculo

6. **População finita.** Considere a população $\{1, 3, 6, 10\}$ e amostras de tamanho 2.
 - a. Obtenha a distribuição de $\bar{X}$ com reposição.
 - b. Calcule $E(\bar{X})$ e $\text{Var}(\bar{X})$.
 - c. Repita sem reposição e verifique a correção de população finita.
7. **Média exponencial.** Seja $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\beta)$ na parametrização por escala.
 - a. Obtenha a distribuição de $\sum X_i$.
 - b. Obtenha a distribuição de $\bar{X}$.
 - c. Calcule $P(\bar{X} > c)$ em termos da função de distribuição gama.
8. **Média normal.** Uma variável tem distribuição $N(50, 12^2)$. Para uma amostra de tamanho 36:
 - a. determine a distribuição de $\bar{X}$;
 - b. calcule $P(48 < \bar{X} < 53)$;
 - c. encontre c tal que $P(|\bar{X} - 50| < c) = 0,95$.
9. **TCL para uma população não normal.** Seja $X_i \sim \text{Exp}(1)$ e $n = 64$. Use o TCL para aproximar $P(0,8 < \bar{X} < 1,2)$.
10. **Proporção.** Em uma população, $p = 0,12$. Para $n = 200$:
 - a. determine $E(\hat{p})$ e $\text{EP}(\hat{p})$;
 - b. aproxime $P(\hat{p} \leq 0,09)$;
 - c. compare a aproximação com a probabilidade binomial exata no R.

11. **Correção de continuidade.** Seja $Y \sim \text{Binomial}(150, 0,5)$. Calcule aproximadamente:

- a. $P(Y \geq 90)$;
- b. $P(65 \leq Y \leq 85)$;
- c. compare os resultados com `pbinom()`.

12. **Variância amostral normal.** Se $X_1, \dots, X_{20} \sim N(\mu, 4)$, calcule:

- a. $P(S^2 > 6)$;
- b. os quantis a e b tais que $P(a < S^2 < b) = 0,95$ com caudas iguais.

13. **Distribuição t .** Se uma amostra normal possui $n = 16$, determine c tal que

$$P\left(\left|\frac{\bar{X} - \mu}{S/4}\right| < c\right) = 0,95.$$

14. **Razão de variâncias.** Duas amostras normais independentes possuem tamanhos $n_1 = 12$ e $n_2 = 18$.

- a. determine a distribuição de $(S_1^2/\sigma_1^2)/(S_2^2/\sigma_2^2)$;
- b. sob $\sigma_1^2 = \sigma_2^2$, calcule $P(S_1^2/S_2^2 > 2)$.

15. **Estatísticas de ordem.** Seja $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$.

- a. obtenha a função de distribuição de $X_{(n)}$;
- b. obtenha sua densidade;
- c. calcule $E[X_{(n)}]$;
- d. proponha uma transformação de $X_{(n)}$ que seja não viesada para θ .

16. **Mínimo exponencial.** Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ na parametrização por taxa, mostre que

$$X_{(1)} \sim \text{Exp}(n\lambda).$$

Exercícios teóricos e computacionais

17. **Variância de S^2 .** Usando a fórmula geral demonstrada neste capítulo,

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right],$$

verifique que, para uma população normal, $\text{Var}(S^2) = 2\sigma^4/(n-1)$.

18. **Simulação do TCL.** Repita a simulação deste capítulo para populações uniforme, Bernoulli, lognormal e Cauchy.

- Compare $n = 5, 30$ e 200 .
- Explique por que o comportamento da média da distribuição de Cauchy é qualitativamente diferente.
- Relacione o resultado às hipóteses do TCL.

19. **Aproximação Monte Carlo.** Para $X_i \sim \text{Beta}(2, 5)$ e $n = 15$, estime por simulação a distribuição de

$$T = \frac{\bar{X} - E(X)}{S/\sqrt{n}}.$$

Compare o histograma com as densidades $N(0, 1)$ e t_{14} .

20. **Demonstração por FGM.** Demonstre que, se $X_i \sim N(\mu, \sigma^2)$ são independentes, então $\bar{X} \sim N(\mu, \sigma^2/n)$.

21. **Demonstração da Lei Fraca.** Use a desigualdade de Chebyshev para demonstrar a Lei Fraca dos Grandes Números sob variância finita.

22. **Distribuição da estatística de ordem.** Demonstre a fórmula da densidade de $X_{(k)}$ contando as maneiras de obter $k-1$ observações abaixo de x , uma observação em $(x, x+dx)$ e $n-k$ observações acima de $x+dx$.

Referências

3 Avaliação de Estimadores e Princípios de Redução de Dados

Considere um modelo estatístico parametrizado $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ e uma função paramétrica de interesse $\tau(\theta)$. Um **estimador** de $\tau(\theta)$ é uma estatística $\delta = \delta(\mathbf{X})$; após a observação de $\mathbf{X} = \mathbf{x}$, o número $\delta(\mathbf{x})$ é denominado **estimativa**.

A avaliação de um estimador exige distinguir propriedades de amostra finita, como viés e erro quadrático médio, de propriedades assintóticas, como consistência e eficiência assintótica. Paralelamente, os princípios de redução de dados procuram substituir a amostra completa por estatísticas que preservem a informação relevante sobre o parâmetro. Essa redução fundamenta resultados centrais, como os teoremas de Rao–Blackwell e de Lehmann–Scheffé (Rice, 2007, chap. 8; Lauritzen, 2023, chaps. 4–5; Cox, 2006, secs. 2.2 and 4.3).

3.1 Avaliação de estimadores

Função de perda, risco e erro quadrático médio

A comparação entre estimadores depende do critério adotado. Uma forma geral de formalizar esse critério consiste em especificar uma **função de perda** $L(\tau(\theta), a)$, que quantifica a consequência de utilizar a ação a quando o valor verdadeiro é $\tau(\theta)$. O risco do estimador δ é

$$R(\theta, \delta) = E_\theta [L(\tau(\theta), \delta(\mathbf{X}))].$$

Essa formulação pertence ao quadro da teoria da decisão estatística (Rasch; Schott, 2018, secs. 1.5 and 2.4; Bickel; Doksum, 2016, chap. 1).

Sob perda quadrática,

$$L(\tau(\theta), a) = (a - \tau(\theta))^2,$$

o risco coincide com o **erro quadrático médio** (EQM):

$$\text{EQM}_\theta(\delta) = E_\theta [(\delta - \tau(\theta))^2].$$

Interpretação

O EQM avalia simultaneamente a dispersão do estimador e seu afastamento sistemático do alvo. Portanto, ele permite comparar estimadores viesados e não viesados por meio de uma única medida de desempenho.

O uso da perda quadrática é particularmente conveniente devido à sua tratabilidade analítica, mas não é universalmente adequado. Em problemas nos quais erros de sinais ou magnitudes diferentes têm consequências assimétricas, outras funções de perda podem ser mais apropriadas (Rasch; Schott, 2018, secs. 1.5 and 2.4; Lauritzen, 2023, sec. 4.1).

Viés, variância e erro-padrão

Definição — Viés

O **viés** de δ como estimador de $\tau(\theta)$ é

$$B_{\theta}(\delta) = E_{\theta}(\delta) - \tau(\theta).$$

O estimador é **não viesado** quando

$$E_{\theta}(\delta) = \tau(\theta)$$

para todo $\theta \in \Theta$.

Um viés positivo significa que o estimador **superestima o parâmetro em média**; um viés negativo significa que o estimador **subestima o parâmetro em média**. Essa afirmação não descreve necessariamente o comportamento de uma realização particular da amostra.

A variância e o erro-padrão do estimador são

$$\text{Var}_{\theta}(\delta) = E_{\theta} \left[(\delta - E_{\theta}(\delta))^2 \right]$$

e

$$\text{EP}_{\theta}(\delta) = \sqrt{\text{Var}_{\theta}(\delta)}.$$

O erro-padrão mede a variabilidade da distribuição amostral de δ . Ele não deve ser confundido com o desvio-padrão da variável observada.

! Decomposição viés–variância

Para qualquer estimador com segundo momento finito,

$$\text{EQM}_\theta(\delta) = \text{Var}_\theta(\delta) + B_\theta(\delta)^2.$$

Demonstração. Somando e subtraindo $E_\theta(\delta)$,

$$\delta - \tau(\theta) = [\delta - E_\theta(\delta)] + [E_\theta(\delta) - \tau(\theta)].$$

Ao elevar ao quadrado e tomar esperança, o termo cruzado é nulo, pois

$$E_\theta[\delta - E_\theta(\delta)] = 0.$$

Logo, obtém-se a decomposição anterior.

! Observação — Compromisso entre viés e variância

Não existe uma lei geral segundo a qual a redução do viés sempre aumente a variância, ou vice-versa. O chamado compromisso viés–variância descreve situações frequentes de construção de estimadores, nas quais aceitar um pequeno viés pode reduzir suficientemente a variância e, conseqüentemente, o EQM. A comparação correta deve ser realizada por meio do risco ou do EQM, e não apenas pelo viés.

As definições de viés, variância e EQM, bem como a decomposição viés–variância, seguem as formulações de Lauritzen (2023) [sec. 4.1], Rice (2007, sec. 8.3) e Rasch; Schott (2018, sec. 2.4).

Exemplo adaptado — Estimação do limite de uma distribuição uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0,$$

e os estimadores

$$\delta_1 = 2\bar{X}, \quad \delta_2 = X_{(n)} = \max(X_1, \dots, X_n), \quad \delta_3 = \frac{n+1}{n}X_{(n)}.$$

Para δ_1 ,

$$E_{\theta}(\delta_1) = \theta$$

e

$$\text{Var}_{\theta}(\delta_1) = \frac{\theta^2}{3n}.$$

Portanto,

$$\text{EQM}_{\theta}(\delta_1) = \frac{\theta^2}{3n}.$$

A função de distribuição de $X_{(n)}$ é

$$P_{\theta}(X_{(n)} \leq x) = \left(\frac{x}{\theta}\right)^n, \quad 0 \leq x \leq \theta.$$

Consequentemente,

$$E_{\theta}(X_{(n)}) = \frac{n}{n+1}\theta$$

e

$$\text{Var}_{\theta}(X_{(n)}) = \frac{n\theta^2}{(n+1)^2(n+2)}.$$

Assim,

$$B_{\theta}(\delta_2) = -\frac{\theta}{n+1}$$

e

$$\text{EQM}_{\theta}(\delta_2) = \frac{2\theta^2}{(n+1)(n+2)}.$$

O estimador corrigido δ_3 é não viesado e possui

$$\text{Var}_{\theta}(\delta_3) = \frac{\theta^2}{n(n+2)}.$$

Para $n > 1$,

$$\frac{\theta^2}{n(n+2)} < \frac{\theta^2}{3n},$$

mostrando que δ_3 tem menor EQM do que δ_1 . Além disso, δ_2 , embora viesado, possui EQM de ordem n^{-2} , enquanto o EQM de δ_1 é de ordem n^{-1} . O exemplo mostra por que não se deve selecionar estimadores exclusivamente pelo não viés. A construção e a comparação dos estimadores foram adaptadas de Lauritzen (2023) [ex. 4.2]; a interpretação em termos de não viés, eficiência e EQM também é discutida por Chihara; Hesterberg (2022, secs. 6.3.1–6.3.3).

Consistência

! Definição — Consistência em probabilidade

Uma sequência de estimadores $\{\delta_n\}$ é **consistente em probabilidade** para $\tau(\theta)$ se, para todo $\varepsilon > 0$ e todo $\theta \in \Theta$,

$$P_\theta (|\delta_n - \tau(\theta)| > \varepsilon) \rightarrow 0$$

quando $n \rightarrow \infty$. Escreve-se

$$\delta_n \xrightarrow{p} \tau(\theta).$$

A consistência é uma propriedade assintótica: ela afirma que, à medida que o tamanho amostral cresce, o estimador se concentra arbitrariamente perto do valor verdadeiro. Ela não implica que o estimador seja não viesado para cada tamanho amostral finito.

! Definição — Consistência em erro quadrático médio

A sequência $\{\delta_n\}$ é **consistente em erro quadrático médio** para $\tau(\theta)$ se

$$\text{EQM}_\theta(\delta_n) \rightarrow 0.$$

A consistência em EQM implica consistência em probabilidade. De fato, pela desigualdade de Markov,

$$P_\theta (|\delta_n - \tau(\theta)| > \varepsilon) \leq \frac{\text{EQM}_\theta(\delta_n)}{\varepsilon^2}.$$

! Critério suficiente para consistência

Se

$$B_{\theta}(\delta_n) \rightarrow 0$$

e

$$\text{Var}_{\theta}(\delta_n) \rightarrow 0,$$

então

$$\text{EQM}_{\theta}(\delta_n) \rightarrow 0,$$

portanto δ_n é consistente em probabilidade (Rice, 2007, sec. 8.5; Lauritzen, 2023, sec. 5.1).

A hipótese de não viés para todo n é suficiente, mas não necessária: basta que o viés tenda a zero.

Comparação no modelo uniforme

No modelo $\text{Unif}(0, \theta)$:

1. $2\bar{X}$ é não viesado e consistente, pois $\bar{X} \xrightarrow{p} \theta/2$ pela lei dos grandes números;
2. $2X_1$ é não viesado, mas não é consistente, pois sua distribuição não se concentra com o crescimento de n ;
3. $X_{(n)}$ é viesado, mas consistente, pois, para $0 < \varepsilon < \theta$,

$$P_{\theta}(|X_{(n)} - \theta| > \varepsilon) = P_{\theta}(X_{(n)} < \theta - \varepsilon) = \left(1 - \frac{\varepsilon}{\theta}\right)^n \rightarrow 0;$$

4. $X_1/2$ é viesado e não consistente.

i Interpretação

Não viés é uma propriedade da esperança da distribuição amostral para um tamanho amostral fixado. Consistência é uma propriedade de uma sequência de estimadores quando n cresce. Nenhuma das duas propriedades implica, em geral, a outra.

A distinção entre não viés e consistência, assim como os critérios anteriores, é apresentada por Larsen; Marx (2012) [sec. 5.7], Rice (2007, sec. 8.5) e Lauritzen (2023, sec. 5.1).

Resultados operacionais para convergência em probabilidade

Se

$$A_n \xrightarrow{p} a \quad \text{e} \quad B_n \xrightarrow{p} b,$$

então:

$$A_n + B_n \xrightarrow{p} a + b,$$

$$A_n B_n \xrightarrow{p} ab,$$

e, se $b \neq 0$,

$$\frac{A_n}{B_n} \xrightarrow{p} \frac{a}{b}.$$

Além disso, se g é contínua em a , o teorema da aplicação contínua garante

$$g(A_n) \xrightarrow{p} g(a).$$

Esses resultados permitem estabelecer a consistência de estimadores construídos por transformações, somas, produtos e quocientes de estatísticas consistentes. Eles são consequências do teorema da aplicação contínua e das propriedades elementares da convergência em probabilidade (Lauritzen, 2023, app. A.2).

Eficiência em amostras finitas

A variância permite comparar estimadores não viesados de um mesmo alvo. Um estimador não viesado δ^* de $\tau(\theta)$ é denominado **estimador não viesado de variância uniformemente mínima** (ENVUM; em inglês, UMVU) quando

$$\text{Var}_\theta(\delta^*) \leq \text{Var}_\theta(\delta)$$

para todo $\theta \in \Theta$ e para todo estimador não viesado δ de $\tau(\theta)$ (Bickel; Doksum, 2016, sec. 8.2.3; Rasch; Schott, 2018, sec. 2.4).

Para dois estimadores não viesados, define-se, neste texto, a eficiência relativa de δ_1 em relação a δ_2 por

$$e_{\theta}(\delta_1; \delta_2) = \frac{\text{Var}_{\theta}(\delta_2)}{\text{Var}_{\theta}(\delta_1)}.$$

Valores maiores do que 1 indicam que δ_1 possui menor variância. Como existem convenções inversas na literatura, a orientação do quociente deve sempre ser explicitada (Rasch; Schott, 2018, sec. 2.4.1).

Informação de Fisher

Considere um modelo dominado com densidade ou função de probabilidade $f_{\theta}(x)$. A função escore de uma observação é

$$U_{\theta}(X) = \frac{\partial}{\partial \theta} \log f_{\theta}(X).$$

Sob condições de regularidade,

$$E_{\theta}[U_{\theta}(X)] = 0.$$

Definição: informação de Fisher

A informação de Fisher de uma observação é

$$I_1(\theta) = E_{\theta}[U_{\theta}(X)^2].$$

Quando é permitido intercambiar diferenciação e integração,

$$I_1(\theta) = -E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f_{\theta}(X) \right].$$

Para uma amostra i.i.d. de tamanho n ,

$$I_n(\theta) = nI_1(\theta).$$

Essas identidades pressupõem as condições de regularidade indicadas acima (Lauritzen, 2023, sec. 1.2.2; Rasch; Schott, 2018, sec. 1.4).

A informação de Fisher quantifica a curvatura média da log-verossimilhança e a capacidade do modelo de distinguir valores próximos do parâmetro. Uma informação maior está associada a limites inferiores menores para a variância de estimadores regulares (Cox, 2006, sec. 2.1; Lauritzen, 2023, sec. 1.2.2).

Desigualdade de Cramér–Rao

A forma clássica da desigualdade de Cramér–Rao utilizada nesta seção exige condições de regularidade. Um conjunto suficiente de condições usuais inclui:

- o suporte da distribuição é comum a todos os valores de θ ;
- $f_\theta(x)$ é diferenciável em θ ;
- a derivação pode ser intercambiada com a integração ou soma;
- $0 < I_n(\theta) < \infty$.

! Teorema — Desigualdade de Cramér–Rao

Se δ possui esperança

$$E_\theta(\delta) = g(\theta),$$

então, sob as condições de regularidade,

$$\text{Var}_\theta(\delta) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Em particular, se δ é não viesado para $\tau(\theta)$,

$$\text{Var}_\theta(\delta) \geq \frac{[\tau'(\theta)]^2}{I_n(\theta)}.$$

Para $\tau(\theta) = \theta$,

$$\text{Var}_\theta(\delta) \geq \frac{1}{I_n(\theta)}.$$

Um estimador não viesado que atinge o limite de Cramér–Rao para todo θ é denominado **eficiente no sentido de Cramér–Rao**. Sua eficiência é

$$\text{ef}_\theta(\delta) = \frac{[\tau'(\theta)]^2}{I_n(\theta) \text{Var}_\theta(\delta)} \leq 1.$$

! Observações

1. O limite não garante a existência de um estimador que o atinja.
2. Um ENVUM pode não atingir o limite de Cramér–Rao.
3. O resultado, em sua forma anterior, não deve ser aplicado a modelos cujo suporte depende do parâmetro. Em particular, o modelo $\text{Unif}(0, \theta)$ não satisfaz a condição

de suporte comum.

4. Para um estimador viesado, com $E_\theta(\delta) = g(\theta)$ e viés $b(\theta) = g(\theta) - \tau(\theta)$, a desigualdade limita a variância por $[g'(\theta)]^2/I_n(\theta)$; consequentemente, o EQM satisfaz $\text{EQM}_\theta(\delta) \geq [g'(\theta)]^2/I_n(\theta) + b(\theta)^2$. Não é correto aplicar automaticamente $1/I_n(\theta)$ ao EQM.

A formulação geral, a demonstração e as condições do resultado podem ser encontradas em Lauritzen (2023) [thm. 4.4], Rice (2007, sec. 8.7) e Rasch; Schott (2018, secs. 1.4 and 2.4.1).

Exemplo — Média de uma distribuição normal com variância conhecida

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida. Para uma observação,

$$U_\mu(X) = \frac{X - \mu}{\sigma^2}$$

e

$$I_1(\mu) = E_\mu \left[\left(\frac{X - \mu}{\sigma^2} \right)^2 \right] = \frac{1}{\sigma^2}.$$

Portanto,

$$I_n(\mu) = \frac{n}{\sigma^2}$$

e

$$\frac{1}{I_n(\mu)} = \frac{\sigma^2}{n}.$$

Como

$$E_\mu(\bar{X}) = \mu$$

e

$$\text{Var}_\mu(\bar{X}) = \frac{\sigma^2}{n},$$

$\bar{X}$ é eficiente para μ .

Exemplo — Parâmetro de uma distribuição de Poisson

Considere $n \geq 1$ e

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\theta).$$

A função escore de uma observação é

$$U_\theta(X) = \frac{X}{\theta} - 1,$$

portanto

$$I_1(\theta) = \frac{1}{\theta}.$$

Logo,

$$\frac{1}{I_n(\theta)} = \frac{\theta}{n}.$$

Como $\bar{X}$ é não viesado e

$$\text{Var}_\theta(\bar{X}) = \frac{\theta}{n},$$

a média amostral é eficiente para θ (Rice, 2007, sec. 8.7; Lauritzen, 2023, thm. 4.4).

Eficiência assintótica

A eficiência de Cramér–Rao descrita anteriormente é uma propriedade de amostra finita. Uma noção distinta é a **eficiência assintótica**. Se

$$\sqrt{n}(\delta_n - \theta) \xrightarrow{d} N(0, V(\theta)),$$

então, em modelos regulares, a variância assintótica é comparada com $I_1(\theta)^{-1}$. O estimador é assintoticamente eficiente quando

$$V(\theta) = I_1(\theta)^{-1}.$$

Sob condições regulares, estimadores de máxima verossimilhança frequentemente possuem essa propriedade. Essa afirmação não se estende automaticamente a modelos irregulares, a parâmetros na fronteira do espaço paramétrico ou a situações nas quais a taxa de convergência difere de $\sqrt{n}$ (Lauritzen, 2023, thm. 5.11).

3.2 Princípios de redução de dados

A amostra completa pode conter componentes irrelevantes para a inferência sobre θ . Um princípio de redução procura substituir $\mathbf{X}$ por uma estatística de menor dimensão sem eliminar informação pertinente ao parâmetro. Suficiência, suficiência mínima, completude e ancilaridade desempenham papéis distintos nesse processo (Cox, 2006, secs. 2.2 and 4.3.1; Casella; Berger, 2002, chap. 6).

Estatística suficiente

! Definição — Suficiência

Uma estatística $T = T(\mathbf{X})$ é **suficiente** para θ se a distribuição condicional de $\mathbf{X}$ dado $T = t$ não depende de θ (Cox, 2006, sec. 2.2; Rice, 2007, sec. 8.8).

A definição significa que, depois de conhecido T , a distribuição da parte restante dos dados não contém informação adicional sobre θ . Em termos inferenciais, procedimentos que dependem da amostra apenas por meio de T não perdem informação sobre o parâmetro dentro do modelo considerado (Cox, 2006, sec. 2.2; Rice, 2007, sec. 8.8).

⚠ Observação

Suficiência é uma propriedade relativa ao modelo. Uma estatística pode ser suficiente em um modelo e deixar de sê-lo quando novos parâmetros desconhecidos são introduzidos ou quando o modelo é ampliado.

Teorema da fatoração de Neyman–Fisher

! Teorema — Fatoração de Neyman–Fisher

Considere uma família dominada por uma medida comum, com densidade ou função de probabilidade conjunta $f_\theta(\mathbf{x})$. A estatística $T(\mathbf{X})$ é suficiente para θ se, e somente se, existem funções não negativas g_θ e h tais que

$$f_\theta(\mathbf{x}) = g_\theta(T(\mathbf{x}))h(\mathbf{x}),$$

em que h não depende de θ .

A dependência da verossimilhança em θ ocorre, portanto, apenas por meio de $T(\mathbf{x})$. O teorema é o método mais utilizado para identificar estatísticas suficientes (Rice, 2007, sec. 8.8.1; Ramachandran; Tsokos, 2021, sec. 5.3.2; Casella; Berger, 2002, sec. 6.2.1).

Exemplo — Amostra Bernoulli

Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p),$$

então

$$f_p(\mathbf{x}) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_i x_i} (1-p)^{n-\sum_i x_i}.$$

Logo,

$$T = \sum_{i=1}^n X_i$$

é suficiente para p .

A definição condicional produz a mesma conclusão. Dado $T = t$, todas as sequências binárias contendo exatamente t sucessos são equiprováveis, de modo que

$$P_p(\mathbf{X} = \mathbf{x} \mid T = t) = \frac{1}{\binom{n}{t}},$$

sempre que $\sum_i x_i = t$. Essa probabilidade não depende de p .

Suficiência mínima

Uma estatística suficiente pode conter redundâncias. Por exemplo, se T é suficiente, então (T, W) também é suficiente para qualquer estatística W , embora possa carregar informação desnecessária.

! Definição — Estatística minimal suficiente

Uma estatística T é **minimal suficiente** se é suficiente e, para toda estatística suficiente S , existe uma função mensurável r tal que

$$T = r(S)$$

quase certamente, para todo θ .

Assim, toda estatística suficiente determina a estatística minimal suficiente. A minimalidade refere-se à informação contida na estatística, e não apenas à sua dimensão numérica.

! Critério da razão de verossimilhanças

Considere uma família dominada com densidades f_θ . Para pontos $\mathbf{x}$ e $\mathbf{y}$ do espaço amostral efetivo — isto é, tais que $f_\theta(\mathbf{x}) + f_\theta(\mathbf{y}) > 0$ para algum θ —, uma estatística T é minimal suficiente quando existe uma constante $c(\mathbf{x}, \mathbf{y}) > 0$, independente de θ , tal que

$$f_\theta(\mathbf{x}) = c(\mathbf{x}, \mathbf{y}) f_\theta(\mathbf{y}) \quad \text{para todo } \theta$$

se, e somente se,

$$T(\mathbf{x}) = T(\mathbf{y}).$$

Quando o quociente $f_\theta(\mathbf{x})/f_\theta(\mathbf{y})$ está bem definido, essa condição equivale a exigir que o quociente seja independente de θ exatamente quando $T(\mathbf{x}) = T(\mathbf{y})$ (Casella; Berger, 2002, sec. 6.2.2; Ramachandran; Tsokos, 2009, sec. 5.5.3).

No modelo Bernoulli, a razão das verossimilhanças é independente de p exatamente quando

$$\sum_{i=1}^n x_i = \sum_{i=1}^n y_i.$$

Portanto, $\sum_i X_i$ é minimal suficiente. No modelo $\text{Unif}(0, \theta)$, a verossimilhança pode ser escrita como

$$L(\theta; \mathbf{x}) = \theta^{-n} I\{x_{(1)} \geq 0\} I\{x_{(n)} \leq \theta\}.$$

O primeiro indicador não depende de θ . Pelo teorema da fatoração, $X_{(n)}$ é suficiente; pelo critério da razão de verossimilhanças, é também minimal suficiente para θ (Ramachandran; Tsokos, 2009, sec. 5.5.3; Casella; Berger, 2002, sec. 6.2.2).

Famílias exponenciais

! Definição — Forma exponencial canônica

Uma família de distribuições possui forma exponencial k -paramétrica quando sua densidade ou função de probabilidade pode ser escrita como

$$f_{\eta}(x) = h(x) \exp \{ \eta^{\top} t(x) - A(\eta) \},$$

em que $\eta \in \mathcal{H} \subseteq \mathbb{R}^k$ é o parâmetro natural, $t(x)$ é a estatística canônica e o suporte não depende de η .

Para uma amostra i.i.d.,

$$f_{\eta}(\mathbf{x}) = \left[\prod_{i=1}^n h(x_i) \right] \exp \left\{ \eta^{\top} \sum_{i=1}^n t(x_i) - nA(\eta) \right\}.$$

Pelo teorema da fatoração,

$$T(\mathbf{X}) = \sum_{i=1}^n t(X_i)$$

é suficiente para η .

i Exemplos

- Bernoulli: $t(x) = x$ e $T = \sum_i X_i$;
- Poisson: $t(x) = x$ e $T = \sum_i X_i$;

- normal com média e variância desconhecidas: $t(x) = (x, x^2)^\top$ e

$$T(\mathbf{X}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right).$$

A família uniforme $\text{Unif}(0, \theta)$ não possui essa forma regular, pois seu suporte depende de θ . Ainda assim, ela possui uma estatística suficiente de dimensão um, $X_{(n)}$.

A apresentação de famílias exponenciais e de suas estatísticas canônicas segue Lauritzen (2023) [chap. 3] e Ramachandran; Tsokos (2021, sec. 5.3.2).

Completude

! Definição — Completude

Uma estatística T é **completa** para $\{P_\theta : \theta \in \Theta\}$ se, para toda função mensurável a tal que $E_\theta[a(T)] < \infty$,

$$E_\theta[a(T)] = 0 \quad \text{para todo } \theta \in \Theta$$

implica

$$P_\theta(a(T) = 0) = 1 \quad \text{para todo } \theta \in \Theta.$$

Essa é a definição usual de completude para a família de distribuições induzida por T (Bickel; Doksum, 2016, def. 8.2.2; Casella; Berger, 2002, sec. 6.2.4).

A completude impede a existência de duas funções distintas de T que sejam não viesadas para o mesmo alvo. Ela é, portanto, uma propriedade de unicidade, e não uma medida de quantidade de informação.

! Teorema — Completude em famílias exponenciais

Em uma família exponencial natural de posto completo, se o espaço do parâmetro natural contém um conjunto aberto de $\mathbb{R}^k$, a estatística canônica é completa, sob as condições usuais de integrabilidade (Bickel; Doksum, 2016, thm. 8.2.2).

Essa conclusão não deve ser estendida automaticamente a famílias exponenciais curvas, nas quais o parâmetro natural está restrito a uma subvariedade de dimensão menor. Nessas famílias, a estatística suficiente pode não ser completa (Bickel; Doksum, 2016, sec. 8.2; Lauritzen, 2023, sec. 3.6).

Teorema de Rao–Blackwell

! Teorema — Rao–Blackwell

Seja T uma estatística suficiente para θ e seja $\delta(\mathbf{X})$ um estimador de $\tau(\theta)$ com segundo momento finito. Defina

$$\delta^*(T) = E_\theta[\delta(\mathbf{X}) \mid T].$$

A suficiência garante que se pode escolher uma versão de δ^* que seja função de T e não dependa de θ . Então:

$$E_\theta(\delta^*) = E_\theta(\delta),$$

e

$$\text{EQM}_\theta(\delta^*) \leq \text{EQM}_\theta(\delta).$$

A igualdade ocorre se, e somente se, δ já é função de T quase certamente (Rice, 2007, sec. 8.8.2; Bickel; Doksum, 2016, thm. 8.2.6).

A identidade fundamental é

$$\text{EQM}_\theta(\delta) = \text{EQM}_\theta(\delta^*) + E_\theta[\text{Var}_\theta(\delta \mid T)].$$

Se δ é não viesado, δ^* também é não viesado e possui variância não superior. Assim, condicionar em uma estatística suficiente elimina variabilidade que não contribui para a estimação de θ (Rice, 2007, sec. 8.8.2; Bickel; Doksum, 2016, thm. 8.2.6).

Exemplo adaptado — Estimação no modelo de Poisson

Considere $n \geq 2$ e

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\theta).$$

Deseja-se estimar

$$P_\theta(X = 0) = e^{-\theta}.$$

O estimador

$$\delta = I\{X_1 = 0\}$$

é não viesado. A estatística

$$T = \sum_{i=1}^n X_i$$

é suficiente para θ . Condicionalmente a $T = t$, o vetor $(X_1, \dots, X_n)$ possui distribuição multinomial com total t e probabilidades $1/n$. Portanto,

$$\begin{aligned}\delta^*(T) &= E(\delta \mid T) \\ &= P(X_1 = 0 \mid T) \\ &= \left(1 - \frac{1}{n}\right)^T.\end{aligned}$$

Pelo teorema de Rao–Blackwell, δ^* possui variância não superior à de δ . Como T é também completa para a família de Poisson,

$$\delta^*(T) = \left(1 - \frac{1}{n}\right)^{\sum_{i=1}^n X_i}$$

é o ENVUM de $e^{-\theta}$. O exemplo é uma aplicação direta do método de Rao–Blackwell e do teorema de Lehmann–Scheffé discutidos por Bickel; Doksum (2016, sec. 8.2.3).

Teorema de Lehmann–Scheffé

! Teorema — Lehmann–Scheffé

Se T é suficiente e completa para θ e $\phi(T)$ é não viesado para $\tau(\theta)$, então $\phi(T)$ é o único ENVUM de $\tau(\theta)$ (Bickel; Doksum, 2016, cor. 8.2.2).

O teorema conduz a dois procedimentos práticos:

1. encontrar diretamente uma função $\phi(T)$ cuja esperança seja $\tau(\theta)$;
2. partir de qualquer estimador não viesado δ e calcular $E(\delta \mid T)$.

A suficiência produz a melhoria de Rao–Blackwell; a completude garante a unicidade da função não viesada resultante (Bickel; Doksum, 2016, cor. 8.2.2).

Exemplo autoral — Estimação da taxa exponencial

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\theta),$$

em que $\theta > 0$ é a taxa e

$$f_\theta(x) = \theta e^{-\theta x} I_{(0, \infty)}(x).$$

A estatística

$$T = \sum_{i=1}^n X_i$$

é suficiente e completa, e

$$T \sim \text{Gama}(n, \text{taxa } \theta).$$

Para $n > 1$,

$$E_\theta \left(\frac{1}{T} \right) = \frac{\theta}{n-1}.$$

Logo,

$$\hat{\theta}_{\text{ENVUM}} = \frac{n-1}{T}$$

é não viesado e, pelo teorema de Lehmann–Scheffé, é o ENVUM de θ . Para $n > 2$,

$$\text{Var}_\theta \left(\hat{\theta}_{\text{ENVUM}} \right) = \frac{\theta^2}{n-2}.$$

A informação de Fisher da amostra é

$$I_n(\theta) = \frac{n}{\theta^2},$$

portanto o limite de Cramér–Rao é θ^2/n . Como

$$\frac{\theta^2}{n-2} > \frac{\theta^2}{n},$$

o ENVUM não atinge o limite. Esse exemplo evidencia que ser ENVUM não implica ser eficiente no sentido de Cramér–Rao. A derivação utiliza a completude da soma em uma família gama de um parâmetro e os momentos negativos dessa distribuição (Bickel; Doksum, 2016, thm. 8.2.2 and sec. 8.2.3; Ramachandran; Tsokos, 2021, sec. 5.3.2).

Estatísticas ancilares e teorema de Basu

! Definição — Ancilaridade

Uma estatística $A = A(\mathbf{X})$ é **ancilar** para θ quando sua distribuição não depende de θ .

Uma estatística ancilar não informa diretamente sobre o parâmetro de interesse, mas pode descrever aspectos do desenho amostral, da precisão ou da configuração dos dados. Em argumentos condicionais, ela pode indicar uma forma relevante de comparar resultados observados (Cox, 2006, sec. 4.3.1).

! Teorema — Basu

Se T é suficiente e completa para θ e A é ancilar, então T e A são independentes (Bickel; Doksum, 2016, thm. 8.2.3; Casella; Berger, 2002, sec. 6.2.4).

Exemplo — Modelo normal de localização

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida. A média $\bar{X}$ é suficiente e completa para μ . A variância amostral

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

possui distribuição que não depende de μ ; portanto, é ancilar para μ . Pelo teorema de Basu, $\bar{X}$ e S^2 são independentes.

⚠ Observação

Se σ^2 também for desconhecida e fizer parte do parâmetro, S^2 não será ancilar para o vetor (μ, σ^2) , pois sua distribuição depende de σ^2 . A ancilaridade deve sempre ser especificada em relação ao parâmetro e ao modelo considerados.

A definição de ancilaridade e o teorema de Basu são apresentados em Bickel; Doksum (2016) [def. 8.2.3 and thm. 8.2.3] e Casella; Berger (2002, secs. 6.2.3–6.2.4).

3.3 Exemplo integrado adaptado — Distribuição gama com forma conhecida

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Gama}(\alpha, \theta),$$

em que $\alpha > 0$ é conhecido e $\theta > 0$ é o parâmetro de escala. A densidade é

$$f(x; \theta) = \frac{x^{\alpha-1} e^{-x/\theta}}{\Gamma(\alpha) \theta^\alpha}, \quad x > 0.$$

Redução por suficiência e completude

A densidade conjunta depende da amostra por meio de

$$T = \sum_{i=1}^n X_i.$$

A estatística T é suficiente. Além disso, essa é uma família exponencial regular de posto completo, e o espaço do parâmetro natural contém um intervalo aberto. Assim, T é completa.

Como

$$T \sim \text{Gama}(n\alpha, \theta),$$

temos

$$E_\theta(T) = n\alpha\theta$$

e

$$\text{Var}_\theta(T) = n\alpha\theta^2.$$

Portanto,

$$\hat{\theta} = \frac{T}{n\alpha} = \frac{\bar{X}}{\alpha}$$

é não viesado e possui

$$\text{Var}_\theta(\hat{\theta}) = \frac{\theta^2}{n\alpha}.$$

Pelo teorema de Lehmann–Scheffé, $\hat{\theta}$ é o ENVUM de θ .

Eficiência

A função escore de uma observação é

$$U_\theta(X) = -\frac{\alpha}{\theta} + \frac{X}{\theta^2}.$$

Logo,

$$I_1(\theta) = \frac{\alpha}{\theta^2}$$

e

$$\frac{1}{I_n(\theta)} = \frac{\theta^2}{n\alpha}.$$

Como a variância de $\hat{\theta}$ coincide com o limite de Cramér–Rao,

$$\boxed{\hat{\theta} = \frac{\bar{X}}{\alpha}}$$

é simultaneamente não viesado, consistente, eficiente e ENVUM. O exemplo integra resultados de suficiência, completude e eficiência apresentados por Ramachandran; Tsokos (2021) [chap. 5] e Lauritzen (2023, chaps. 3–5).

3.4 Síntese conceitual

Conceito	Natureza	Pergunta central
Viés	Amostra finita	O estimador está centrado no alvo?
Variância	Amostra finita	Quanto o estimador varia entre amostras?
EQM	Amostra finita	Qual é o erro quadrático médio total?
Consistência	Assintótica	O estimador se aproxima do alvo quando n cresce?
Eficiência de Cramér–Rao	Amostra finita e modelo regular	O estimador atinge o limite inferior de variância?
ENVUM	Amostra finita	O estimador tem variância mínima entre os não viesados?
Suficiência	Redução de dados	A estatística preserva toda a informação sobre θ ?
Suficiência mínima	Redução de dados	A estatística remove redundâncias entre estatísticas suficientes?
Completude	Unicidade	Funções não viesadas da estatística suficiente são únicas?
Ancilaridade	Condicionamento	A distribuição da estatística é livre de θ ?

3.5 Exercícios

i Orientação

Nos exercícios, explicita o modelo, o parâmetro de interesse, o estimador e o critério de comparação. Quando utilizar a desigualdade de Cramér–Rao, verifique previamente as condições de regularidade.

1. **Viés e EQM.** Sejam $X_1, \dots, X_n$ i.i.d. com $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$. Para constantes a e b , considere

$$\delta = a\bar{X} + b.$$

Calcule o viés, a variância e o EQM de δ como estimador de μ . Determine as condições sobre a e b para que δ seja não viesado e consistente.

2. **Uniforme e compromisso viés-variância.** No modelo $\text{Unif}(0, \theta)$, compare os EQM de

$$2\bar{X}, \quad X_{(n)}, \quad \frac{n+1}{n}X_{(n)}.$$

Determine qual estimador possui menor EQM para $n > 1$.

3. **Consistência por EQM.** Se $E_\theta(\delta_n) = \theta + n^{-1}$ e $\text{Var}_\theta(\delta_n) = 4/n$, mostre que δ_n é consistente para θ .
4. **Cramér-Rao no modelo exponencial.** Para uma amostra da distribuição exponencial com média θ , calcule a informação de Fisher e mostre que $\bar{X}$ atinge o limite de Cramér-Rao para a estimação de θ .
5. **Suficiência no modelo normal.** Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

identifique uma estatística suficiente para:

- μ , quando σ^2 é conhecida;
 - σ^2 , quando μ é conhecida;
 - (μ, σ^2) , quando ambos são desconhecidos.
6. **Suficiência mínima.** Utilize o critério da razão de verossimilhanças para mostrar que $X_{(n)}$ é minimal suficiente para θ no modelo $\text{Unif}(0, \theta)$.
7. **Rao-Blackwell.** Se $X_1, \dots, X_n$ são i.i.d. $\text{Poisson}(\theta)$, parta do estimador $I\{X_1 = 1\}$ de $\theta e^{-\theta}$ e calcule sua versão de Rao-Blackwell condicionando em $T = \sum_i X_i$.
8. **Lehmann-Scheffé no modelo binomial.** Se $X_1, \dots, X_n$ são i.i.d. $\text{Bin}(m, p)$, com m conhecido, mostre que

$$\hat{p} = \frac{\sum_{i=1}^n X_i}{nm}$$

é o ENVUM de p . Verifique também se o estimador é eficiente.

9. **Taxa exponencial.** No modelo $\text{Exp}(\theta)$ parametrizado pela taxa, mostre que $(n - 1)/\sum_i X_i$ é o ENVUM de θ . Calcule sua variância e explique por que ele não atinge o limite de Cramér–Rao.
10. **Ancilaridade e Basu.** No modelo normal com variância conhecida, mostre que S^2 é ancilar para μ . Use o teorema de Basu para justificar a independência entre $\bar{X}$ e S^2 .
11. **Família exponencial curva.** Considere uma família normal $N(\mu, \mu^2)$, com $\mu > 0$. Mostre que ela pode ser vista como uma subfamília curva da família normal de dois parâmetros. Discuta por que a completude da estatística canônica da família completa não pode ser transferida automaticamente para essa subfamília.
12. **Comparação integrada.** Para cada um dos estimadores abaixo, classifique as propriedades de não viés, consistência, eficiência de Cramér–Rao e condição de ENVUM, justificando cada resposta:
 - a. $\bar{X}$ para a média de uma distribuição normal com variância conhecida;
 - b. $X_{(n)}$ para θ em $\text{Unif}(0, \theta)$;
 - c. $(n + 1)X_{(n)}/n$ para θ em $\text{Unif}(0, \theta)$;
 - d. $(n - 1)/\sum_i X_i$ para a taxa de uma distribuição exponencial.

Os exercícios foram elaborados ou adaptados a partir das discussões e listas de problemas de Lauritzen (2023) [chaps. 4–5], Rice (2007, chap. 8), Ramachandran; Tsokos (2021) [chap. 5], Larsen; Marx (2012, chap. 5) e Bickel; Doksum (2016, chap. 8).

Referências

4 Métodos de Estimação Pontual

4.1 Método dos Momentos

O **método dos momentos** estima os parâmetros de um modelo igualando momentos populacionais, escritos como funções dos parâmetros, aos momentos correspondentes calculados na amostra. O procedimento costuma ser algebricamente simples e fornece estimadores úteis como valores iniciais para métodos numéricos. Sua definição não depende da Lei dos Grandes Números; essa lei, juntamente com condições de identificabilidade e continuidade, é utilizada para justificar a consistência dos estimadores obtidos (Rice, 2007, sec. 8.4; Ramachandran; Tsokos, 2021, sec. 5.2.1; Chihara; Hesterberg, 2022, sec. 6.2).

Momentos populacionais e amostrais

! Definição — momentos populacionais

Seja X uma variável aleatória. Quando a esperança existe, o k -ésimo **momento em torno da origem** é

$$\mu'_k = E(X^k).$$

O k -ésimo **momento em torno de** $c \in \mathbb{R}$ é

$$E[(X - c)^k].$$

Em particular,

$$\mu = E(X)$$

e

$$\sigma^2 = E[(X - \mu)^2].$$

! Definição — momentos amostrais

Para uma amostra $X_1, \dots, X_n$, o k -ésimo momento amostral em torno da origem é

$$m'_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

O momento amostral em torno de c é

$$\frac{1}{n} \sum_{i=1}^n (X_i - c)^k.$$

Assim, $m'_1 = \bar{X}$. O segundo momento amostral em torno de $\bar{X}$ é

$$\tilde{S}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = m'_2 - (m'_1)^2.$$

! Observação — duas noções de variância amostral

A quantidade $\tilde{S}_n^2$ utiliza divisor n e é o segundo momento empírico central. Ela não deve ser confundida com a variância amostral não viesada

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

No método dos momentos, utiliza-se naturalmente $\tilde{S}_n^2$, porque os momentos amostrais são definidos com divisor n (Rice, 2007, sec. 8.4).

Fundamentação probabilística

Se $E(|X|^k) < \infty$, a Lei dos Grandes Números implica

$$m'_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{p} E(X^k) = \mu'_k.$$

Portanto, os momentos amostrais aproximam os momentos populacionais para amostras grandes. Essa convergência fornece a principal justificativa assintótica do método, mas a consistência também exige que o sistema de equações identifique local ou globalmente o parâmetro de interesse (Rice, 2007, secs. 5.2 e 8.4; Lauritzen, 2023, sec. 5.2).

Procedimento geral

Considere um modelo com vetor paramétrico

$$\theta = (\theta_1, \dots, \theta_d) \in \Theta.$$

Suponha que os primeiros d momentos populacionais existam e possam ser escritos como

$$\mu'_j = k_j(\theta), \quad j = 1, \dots, d.$$

O método dos momentos pode ser descrito em quatro etapas:

1. calcular d momentos populacionais como funções de θ ;
2. resolver, quando possível, o sistema

$$\mu'_j = k_j(\theta), \quad j = 1, \dots, d,$$

obtendo

$$\theta_j = g_j(\mu'_1, \dots, \mu'_d);$$

3. calcular os momentos amostrais $m'_1, \dots, m'_d$;
4. substituir μ'_j por m'_j :

$$\hat{\theta}_j^{\text{MM}} = g_j(m'_1, \dots, m'_d), \quad j = 1, \dots, d.$$

De modo equivalente, os estimadores são soluções do sistema

$$m'_j = k_j(\hat{\theta}^{\text{MM}}), \quad j = 1, \dots, d.$$

O sistema pode não possuir solução, pode possuir várias soluções ou pode produzir valores fora do espaço paramétrico. Nesses casos, a regra de seleção ou projeção deve ser declarada explicitamente (Rice, 2007, sec. 8.4; Larsen; Marx, 2012, sec. 5.6; Ramachandran; Tsokos, 2021, sec. 5.2.1).

Exemplo — distribuição de Pareto

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Pareto}(1, \theta), \quad \theta > 0,$$

com densidade

$$f(x \mid \theta) = \theta x^{-(\theta+1)}, \quad x \geq 1.$$

Para $\theta > 1$,

$$E(X) = \frac{\theta}{\theta - 1}.$$

Igualando $E(X)$ a $\bar{X}$,

$$\bar{X} = \frac{\hat{\theta}}{\hat{\theta} - 1},$$

e, portanto,

$$\boxed{\hat{\theta}^{\text{MM}} = \frac{\bar{X}}{\bar{X} - 1}}.$$

Como $\bar{X} > 1$ quase certamente, a expressão está bem definida. Além disso, $\bar{X} \xrightarrow{p} \theta/(\theta - 1)$ e a função $g(u) = u/(u - 1)$ é contínua para $u > 1$; logo,

$$\hat{\theta}^{\text{MM}} \xrightarrow{p} \theta.$$

Variância assintótica pelo método delta

Se $\theta > 2$, então

$$\text{Var}(X) = \frac{\theta}{(\theta - 1)^2(\theta - 2)}.$$

Como

$$g'(u) = -\frac{1}{(u - 1)^2},$$

temos

$$g'\left(\frac{\theta}{\theta - 1}\right) = -(\theta - 1)^2.$$

Pelo método delta,

$$\sqrt{n}(\hat{\theta}^{\text{MM}} - \theta) \xrightarrow{d} N\left(0, \frac{\theta(\theta - 1)^2}{\theta - 2}\right),$$

e, conseqüentemente,

$$\text{Var}(\hat{\theta}^{\text{MM}}) \approx \frac{\theta(\theta - 1)^2}{n(\theta - 2)}.$$

O requisito $\theta > 2$ é essencial para esta aplicação, pois a variância da população é infinita quando $1 < \theta \leq 2$ (Lauritzen, 2023, app. A.2.3; Chihara; Hesterberg, 2022, sec. 7.7).

Para $\theta = 3$ e $n = 100$,

$$\text{Var}(\hat{\theta}^{\text{MM}}) \approx \frac{3(3 - 1)^2}{100(3 - 2)} = 0,12,$$

de modo que o desvio-padrão assintótico é aproximadamente 0,346.

Simulação em R


O exemplo numérico e o código abaixo são autorais. A geração utiliza a transformação inversa: se $U \sim \text{Unif}(0, 1)$, então $U^{-1/\theta}$ possui a distribuição de Pareto adotada.

```
set.seed(14)

B <- 1000
n <- 100
theta <- 3

estimativas <- replicate(B, {
  x <- runif(n)^(-1 / theta)
  x_barra <- mean(x)
  x_barra / (x_barra - 1)
})

hist(
  estimativas,
  probability = TRUE,
  breaks = 35,
  xlab = expression(hat(theta)[MM]),
  main = ""
)
```



```
mean(estimativas)
```

```
[1] 3.054922
```

`sd(estimativas)`

[1] 0.3213791

i Interpretação

A função $g(u) = u/(u - 1)$ é estritamente convexa para $u > 1$. Assim, quando as esperanças relevantes existem, a desigualdade de Jensen ajuda a explicar o viés positivo observado em amostras finitas. Esse viés não impede a consistência do estimador.

Exemplo — distribuição uniforme contínua

Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0,$$

então

$$E(X) = \frac{\theta}{2}, \quad \text{Var}(X) = \frac{\theta^2}{12}.$$

Igualando o primeiro momento,

$$\boxed{\hat{\theta}^{\text{MM}} = 2\bar{X}}.$$

O estimador é não viesado,

$$E(\hat{\theta}^{\text{MM}}) = \theta,$$

possui variância

$$\text{Var}(\hat{\theta}^{\text{MM}}) = \frac{\theta^2}{3n},$$

e é consistente pela Lei dos Grandes Números. O estimador de máxima verossimilhança, estudado adiante, é $X_{(n)}$; os dois métodos produzem estimadores distintos neste modelo não regular (Chihara; Hesterberg, 2022, secs. 6.1.2 e 6.2).

Exemplo — distribuição uniforme discreta

Considere

$$P_{\theta}(X = x) = \frac{1}{\theta}, \quad x \in \{1, \dots, \theta\}, \quad \theta \in \mathbb{N}.$$

Como

$$E_{\theta}(X) = \frac{\theta + 1}{2},$$

a solução formal da equação de momentos é

$$\tilde{\theta}^{\text{MM}} = 2\bar{X} - 1.$$

Ela é não viesada e possui

$$\text{Var}(\tilde{\theta}^{\text{MM}}) = \frac{\theta^2 - 1}{3n}.$$

Entretanto, $2\bar{X} - 1$ pode não ser inteiro e pode ser menor que $X_{(n)}$. Portanto, ele é uma **solução irrestrita da equação de momentos**, mas não necessariamente uma estimativa admissível em Θ . Uma versão ajustada requer uma regra explícita de projeção para os inteiros compatíveis com a amostra; essa projeção altera, em geral, o viés e a variância.

A verossimilhança é

$$L(\theta; x) = \theta^{-n} I\{\theta \geq x_{(n)}\},$$

e o estimador de máxima verossimilhança é

$$\hat{\theta}^{\text{MV}} = X_{(n)}.$$

Este exemplo mostra que uma equação de momentos pode produzir uma solução fora do espaço paramétrico, enquanto a maximização da verossimilhança incorpora diretamente as restrições do modelo.

Exemplo — distribuição exponencial

Adote a parametrização pela taxa:

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\theta), \quad f(x; \theta) = \theta e^{-\theta x} I(x \geq 0).$$

Como

$$E(X) = \frac{1}{\theta},$$

o estimador de momentos é

$$\boxed{\hat{\theta}^{\text{MM}} = \frac{1}{\bar{X}}}.$$

Se $S = \sum_i X_i$, então

$$S \sim \text{Gama}(n, \text{taxa } \theta),$$

e $\hat{\theta}^{\text{MM}} = n/S$ possui distribuição gama inversa, na parametrização por forma n e escala $n\theta$. Para $n > 1$,

$$E(\hat{\theta}^{\text{MM}}) = \frac{n\theta}{n-1},$$

e, para $n > 2$,

$$\text{Var}(\hat{\theta}^{\text{MM}}) = \frac{n^2\theta^2}{(n-1)^2(n-2)}.$$

O estimador é viesado para cima, mas consistente, pois $\bar{X} \xrightarrow{p} 1/\theta$ e $u \mapsto 1/u$ é contínua em $1/\theta > 0$ (Chihara; Hesterberg, 2022, secs. 6.1.2 e 6.2).

Exemplo — distribuição gama

Considere a parametrização por forma $\alpha > 0$ e taxa $\beta > 0$:

$$X \sim \text{Gama}(\alpha, \beta),$$

com

$$E(X) = \frac{\alpha}{\beta}, \quad E(X^2) = \frac{\alpha(\alpha + 1)}{\beta^2}.$$

Resolvendo em função dos dois primeiros momentos,

$$\alpha = \frac{(\mu'_1)^2}{\mu'_2 - (\mu'_1)^2}, \quad \beta = \frac{\mu'_1}{\mu'_2 - (\mu'_1)^2}.$$

Substituindo μ'_1 e μ'_2 pelos momentos amostrais,

$$\hat{\alpha}^{\text{MM}} = \frac{\bar{X}^2}{\widetilde{S}_n^2}$$

e

$$\hat{\beta}^{\text{MM}} = \frac{\bar{X}}{\widetilde{S}_n^2},$$

em que

$$\widetilde{S}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Essas fórmulas correspondem ao exemplo clássico de estimação dos parâmetros da distribuição gama pelo método dos momentos (Rice, 2007, sec. 8.4, exemplo C).

Exercícios

1. **Distribuição angular.** Considere uma variável angular T com densidade

$$f(t | \alpha) = \frac{1}{2\pi}(1 + \alpha \cos t), \quad 0 \leq t \leq 2\pi,$$

em que $\alpha \in [-1/3, 1/3]$. Como $E(T) = \pi$ para todo α , utilize o segundo momento para obter um estimador de momentos de α .

2. **Modelo normal.** Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, obtenha os estimadores de momentos de μ e σ^2 . Determine o viés e a variância de cada estimador.
3. **Consistência no modelo gama.** Demonstre, utilizando a Lei dos Grandes Números e o teorema da aplicação contínua, que $\hat{\alpha}^{\text{MM}}$ e $\hat{\beta}^{\text{MM}}$ são consistentes quando $\text{Var}(X) > 0$.

4.2 Máxima Verossimilhança

A estimação por máxima verossimilhança seleciona, entre os valores admissíveis do parâmetro, aqueles que tornam os dados observados mais verossímeis. O método aplica-se a modelos discretos, contínuos e multiparamétricos, mas a existência, a unicidade e a forma do maximizador devem ser verificadas em cada problema (Rice, 2007, sec. 8.5; Larsen; Marx, 2012, sec. 5.2; Ramachandran; Tsokos, 2009, sec. 5.2.2; Chihara; Hesterberg, 2022, sec. 6.1).

As propriedades assintóticas usuais — consistência, normalidade e eficiência — não decorrem apenas da maximização. Elas exigem hipóteses específicas sobre identificabilidade, suavidade, comportamento do suporte, informação e convergência da função objetivo. Em modelos não regulares, a taxa ou a distribuição limite pode ser diferente da teoria padrão (Lauritzen, 2023, secs. 5.3.1–5.3.2; Chihara; Hesterberg, 2022, sec. 6.3.6).

Ao final desta seção, o leitor deverá ser capaz de:

1. construir a função de verossimilhança de um modelo paramétrico;
2. distinguir probabilidade, densidade e verossimilhança; obter estimadores de máxima verossimilhança analítica ou numericamente;
3. calcular a função escore e a informação de Fisher; reconhecer as principais condições de regularidade;
4. utilizar as propriedades assintóticas dos estimadores de máxima verossimilhança;
5. identificar modelos nos quais a teoria assintótica regular não se aplica diretamente.

Exemplo motivacional — moeda com probabilidade desconhecida

O exemplo é adaptado de Chihara; Hesterberg (2022, pp. 148–149).

Considere uma moeda cuja probabilidade de produzir cara é desconhecida e denotada por p . A moeda é lançada oito vezes, produzindo a sequência

$$C, C, C, K, C, K, C, K,$$

em que C representa cara e K representa coroa. Foram observadas cinco caras e três coroas. Supondo que os lançamentos sejam independentes, a probabilidade de observar exatamente essa sequência, para um valor fixado de p , é

$$p^5(1-p)^3.$$

Os dados já foram observados. Portanto, a expressão anterior pode ser examinada como uma função do parâmetro p :

$$L(p) = p^5(1-p)^3, \quad 0 \leq p \leq 1.$$

Essa função mede a verossimilhança dos diferentes valores de p em relação à sequência observada. O método de máxima verossimilhança seleciona o valor que maximiza $L(p)$.

Como o logaritmo é uma função estritamente crescente, maximizar $L(p)$ é equivalente a maximizar a log-verossimilhança

$$\ell(p) = \log(L(p)) = 5 \log(p) + 3 \log(1-p).$$

Derivando em relação a p ,

$$\ell'(p) = \frac{5}{p} - \frac{3}{1-p}.$$

A equação $\ell'(p) = 0$ implica

$$\frac{5}{p} = \frac{3}{1-p},$$

de modo que

$$5(1-p) = 3p$$

e, conseqüentemente,

$$\hat{p} = \frac{5}{8}.$$

Além disso,

$$\ell''(p) = -\frac{5}{p^2} - \frac{3}{(1-p)^2} < 0, \quad 0 < p < 1.$$

Logo, $\hat{p} = 5/8$ é o ponto de máximo da log-verossimilhança e, portanto, da própria verossimilhança.

Interpretação

A estimativa $\hat{p} = 5/8$ indica que, entre os valores possíveis de p , o valor $5/8$ torna a sequência observada mais verossímil.

Essa afirmação não significa que a probabilidade de p ser igual a $5/8$ seja máxima. Na abordagem frequentista, p é considerado fixo, embora desconhecido, e não uma variável aleatória.

Probabilidade e verossimilhança

Na função de probabilidade ou densidade $f(x; \theta)$, considera-se o parâmetro θ fixado e o resultado x variável. Na função de verossimilhança $L(\theta; \mathbf{x})$, os dados observados $\mathbf{x}$ são mantidos fixos, enquanto θ varia no espaço paramétrico.

Consequentemente, a função de verossimilhança não é, em geral, uma distribuição de probabilidade sobre o parâmetro. Em particular, não é necessário que

$$\int_{\Theta} L(\theta; \mathbf{x}) d\theta = 1.$$

4.2.1 Definição formal

Considere um modelo estatístico paramétrico

$$\mathcal{P} = \{P_{\theta} : \theta \in \Theta\},$$

em que $\Theta \subseteq \mathbb{R}^q$ é o espaço paramétrico. Suponha que as distribuições do modelo possuam funções de probabilidade ou densidades $f(\mathbf{x}; \theta)$ relativamente a uma medida dominante comum.

! Definição: função de verossimilhança

Para uma realização observada $\mathbf{x}$, a função de verossimilhança é definida por

$$L(\theta; \mathbf{x}) = f(\mathbf{x}; \theta), \quad \theta \in \Theta,$$

considerada como uma função de θ , com os dados $\mathbf{x}$ mantidos fixos.

Se $X_1, \dots, X_n$ constituem uma amostra aleatória de uma distribuição com função de probabilidade ou densidade $f(x; \theta)$, então, pela independência,

$$L_n(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

Em modelos discretos, essa expressão representa a probabilidade conjunta dos valores observados. Em modelos contínuos, ela é construída a partir do produto das densidades avaliadas nos dados. A interpretação, entretanto, é a mesma: a expressão é examinada como uma função do parâmetro, e não dos dados (Larsen; Marx, 2012, sec. 5.2; Ramachandran; Tsokos, 2009, sec. 5.2.2).

! Definição: estimador de máxima verossimilhança

Um estimador de máxima verossimilhança de θ é uma estatística $\hat{\theta}_n$ que satisfaz

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} L_n(\theta).$$

Equivalentemente,

$$L_n(\hat{\theta}_n) \geq L_n(\theta)$$

para todo $\theta \in \Theta$.

O símbolo $\arg \max$ representa o conjunto dos pontos nos quais a função atinge seu máximo. Essa formulação contempla a possibilidade de existirem vários maximizadores.

i Estimador e estimativa

O **estimador** $\hat{\theta}_n$ é uma função das variáveis aleatórias $X_1, \dots, X_n$. A **estimativa** é o valor numérico obtido quando os dados observados são substituídos nessa função. Por exemplo,

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

é um estimador, enquanto $5/8$ é a estimativa obtida para a sequência do exemplo motivacional.

4.2.2 Existência e unicidade

A definição não garante que o estimador exista ou seja único. Podem ocorrer as seguintes situações:

- o máximo é atingido em um único ponto;
- a função possui vários máximos;
- o máximo ocorre na fronteira de Θ ;
- existe apenas um supremo que não é atingido;
- a função de verossimilhança é ilimitada;
- existem vários máximos locais.

Portanto, resolver uma equação obtida por diferenciação não é suficiente para identificar o estimador de máxima verossimilhança. Também devem ser examinados o espaço paramétrico, os pontos de fronteira e o comportamento global da função.

4.2.3 Log-verossimilhança

A log-verossimilhança é definida por

$$\ell_n(\theta) = \log L_n(\theta).$$

Para uma amostra aleatória,

$$\ell_n(\theta) = \sum_{i=1}^n \log f(X_i; \theta).$$

Como o logaritmo é estritamente crescente,

$$\arg \max_{\theta \in \Theta} L_n(\theta) = \arg \max_{\theta \in \Theta} \ell_n(\theta).$$

A log-verossimilhança é geralmente mais conveniente, pois transforma produtos em somas e reduz problemas numéricos causados pelo produto de probabilidades ou densidades muito pequenas (Ramachandran; Tsokos, 2009, sec. 5.2.2; Chihara; Hesterberg, 2022, sec. 6.1).

Observação

A função de verossimilhança é definida a menos de um fator positivo que não dependa do parâmetro. Se

$$\tilde{L}_n(\theta) = c(\mathbf{x})L_n(\theta), \quad c(\mathbf{x}) > 0,$$

então L_n e $\tilde{L}_n$ possuem os mesmos maximizadores.

4.2.4 Função escore e informação

4.2.4.1 Função escore

Supondo que a log-verossimilhança seja diferenciável, define-se o vetor escore por

$$\mathbf{U}_n(\theta) = \nabla_{\theta} \ell_n(\theta).$$

Se o parâmetro for escalar,

$$U_n(\theta) = \frac{\partial}{\partial \theta} \ell_n(\theta).$$

Quando o máximo ocorre no interior do espaço paramétrico, uma condição necessária para um máximo diferenciável é

$$\mathbf{U}_n(\hat{\theta}_n) = \mathbf{0}.$$

Essa expressão é denominada **equação de verossimilhança**.

Observação

Uma solução da equação de verossimilhança pode ser um máximo, um mínimo ou um ponto de sela. Em modelos multiparamétricos, também podem existir múltiplas soluções. A classificação da solução pode exigir o exame da matriz Hessiana ou a comparação direta dos valores da função de verossimilhança.

4.2.4.2 Informação observada

A matriz de informação observada é definida por

$$\mathbf{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

No caso escalar,

$$J_n(\theta) = -\frac{\partial^2}{\partial \theta^2} \ell_n(\theta).$$

A informação observada descreve a curvatura local da log-verossimilhança. Uma log-verossimilhança fortemente curvada em torno do máximo tende a produzir uma estimativa mais precisa do que uma log-verossimilhança relativamente plana.

4.2.4.3 Informação de Fisher

Para uma única observação, a matriz de informação de Fisher é

$$\mathbf{I}_1(\theta) = \mathbb{E}_{\theta} [\mathbf{U}_1(\theta) \mathbf{U}_1(\theta)^{\top}].$$

No caso escalar,

$$I_1(\theta) = \mathbb{E}_{\theta} \left[\left\{ \frac{\partial}{\partial \theta} \log f(X; \theta) \right\}^2 \right].$$

Sob condições que permitem a diferenciação sob o sinal de integração,

$$\mathbb{E}_{\theta}[U_1(\theta)] = 0$$

e

$$I_1(\theta) = -\mathbb{E}_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right].$$

Para uma amostra aleatória de tamanho n ,

$$\mathbf{I}_n(\theta) = n\mathbf{I}_1(\theta).$$

A informação de Fisher aparece tanto na desigualdade de Cramér–Rao quanto na distribuição assintótica dos estimadores de máxima verossimilhança (Ramachandran; Tsokos, 2009, sec. 5.2.2; Chihara; Hesterberg, 2022, sec. 6.1).

4.2.4.4 Condições de regularidade

As propriedades assintóticas dos estimadores de máxima verossimilhança não são consequências automáticas da maximização da verossimilhança. Elas dependem de hipóteses sobre a estrutura e a suavidade do modelo.

 Observação — não existe uma lista universal de condições

As condições de regularidade dependem do teorema e da classe de modelos considerados. A lista a seguir reúne hipóteses suficientes recorrentes e deve ser interpretada como um roteiro de verificação, não como um enunciado universal. O resultado formal adotado como referência deve sempre ser declarado; por exemplo, Lauritzen (2023, thm. 5.11) estabelece a normalidade assintótica em famílias exponenciais mínimas e regulares.

4.2.4.5 Identificabilidade

O modelo deve ser identificável:

$$P_{\theta_1} = P_{\theta_2} \implies \theta_1 = \theta_2.$$

Equivalentemente, valores paramétricos distintos devem produzir distribuições distintas.

Sem identificabilidade, dois ou mais valores do parâmetro geram exatamente a mesma distribuição dos dados e não podem ser distinguidos por qualquer procedimento estatístico.

4.2.4.6 Parâmetro verdadeiro interior

O verdadeiro valor θ_0 deve pertencer ao interior de Θ . Em particular, deve existir uma vizinhança aberta de θ_0 inteiramente contida no espaço paramétrico.

Quando o parâmetro verdadeiro está na fronteira, a distribuição limite do estimador pode ser assimétrica, truncada ou constituída por uma mistura de distribuições.

4.2.4.7 Suporte localmente independente do parâmetro

Uma condição suficiente frequentemente adotada é que o suporte

$$\mathcal{X}_\theta = \{x : f(x; \theta) > 0\}$$

não dependa de θ em uma vizinhança do verdadeiro valor.

Quando o suporte depende do parâmetro, a diferenciação de

$$\int f(x; \theta) dx = 1$$

pode produzir termos adicionais de fronteira. Nesses casos, identidades envolvendo o escore e a informação de Fisher podem não ser válidas.

4.2.4.8 Diferenciabilidade

A função

$$\theta \mapsto \log f(x; \theta)$$

deve possuir derivadas de ordem suficiente em uma vizinhança de θ_0 . A demonstração usual da normalidade assintótica emprega uma expansão de Taylor da função escore e requer controle das derivadas de segunda e, frequentemente, de terceira ordem.

4.2.4.9 Diferenciação sob o sinal de integração

Deve ser possível permutar diferenciação e integração, por exemplo,

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx.$$

Uma condição suficiente consiste na existência de funções integráveis que dominem as derivadas de $f(x; \theta)$ em uma vizinhança do verdadeiro parâmetro.

4.2.4.10 Informação de Fisher finita e não singular

A matriz

$$\mathbf{I}_1(\theta_0)$$

deve existir, possuir elementos finitos e ser positiva definida. Para um parâmetro escalar,

$$0 < I_1(\theta_0) < \infty.$$

Se a informação for nula ou singular, algumas componentes do parâmetro podem não ser estimáveis à taxa usual $\sqrt{n}$.

4.2.4.11 Convergência uniforme da função objetivo

Para demonstrar a consistência do estimador como um maximizador, é usual exigir que a log-verossimilhança média

$$\frac{1}{n}\ell_n(\theta)$$

convirja uniformemente para uma função determinística que tenha máximo único em θ_0 .

Condições adicionais de compacidade, continuidade ou controle do comportamento da verossimilhança fora de vizinhanças compactas podem ser necessárias.

i Modelos não regulares

Exemplos de situações em que a teoria regular pode falhar incluem:

- suporte dependente do parâmetro;
- parâmetro verdadeiro na fronteira;
- falta de identificabilidade;
- informação de Fisher singular;
- máximos não únicos;
- verossimilhança ilimitada;
- modelos de mistura;
- separação completa em regressão logística.

Nesses casos, o estimador pode continuar sendo consistente, mas sua taxa de convergência ou sua distribuição limite pode ser diferente da usual.

4.2.5 Propriedades assintóticas

Considere uma amostra aleatória $X_1, \dots, X_n$ proveniente de uma distribuição $f(x; \theta_0)$, em que θ_0 representa o verdadeiro valor do parâmetro.

4.2.5.1 Consistência

! Propriedade: consistência

Sob condições de identificabilidade, convergência uniforme e existência de um máximo adequadamente comportado,

$$\hat{\theta}_n \xrightarrow{p} \theta_0.$$

Uma justificativa conceitual pode ser obtida por meio da divergência de Kullback–Leibler. Defina

$$M(\theta) = E_{\theta_0} [\log f(X; \theta)].$$

Então,

$$\begin{aligned} M(\theta) - M(\theta_0) &= E_{\theta_0} \left[\log \frac{f(X; \theta)}{f(X; \theta_0)} \right] \\ &= -D_{\text{KL}}(f_{\theta_0} \| f_{\theta}) \leq 0. \end{aligned}$$

Portanto, a log-verossimilhança média populacional é maximizada em θ_0 . Quando o modelo é identificável, esse máximo é único. A convergência uniforme permite transferir essa propriedade para o máximo da log-verossimilhança amostral.

⚠ Observação — alcance do argumento

A identidade com a divergência de Kullback–Leibler identifica o máximo da função objetivo populacional. A consistência do maximizador amostral requer ainda uma lei uniforme dos grandes números, separação ou unicidade do máximo e controle da existência do estimador (Lauritzen, 2023, sec. 5.3.1).

4.2.5.2 Normalidade assintótica: parâmetro escalar

Suponha que $\hat{\theta}_n$ seja uma solução consistente da equação de verossimilhança. Expandindo $U_n(\hat{\theta}_n)$ em torno de θ_0 ,

$$0 = U_n(\hat{\theta}_n) = U_n(\theta_0) + \ell_n''(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0),$$

em que $\tilde{\theta}_n$ está entre $\hat{\theta}_n$ e θ_0 . Logo,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \left[-\frac{1}{n} \ell_n''(\tilde{\theta}_n) \right]^{-1} \frac{U_n(\theta_0)}{\sqrt{n}}.$$

Sob as condições de regularidade, o teorema central do limite fornece

$$\frac{U_n(\theta_0)}{\sqrt{n}} \xrightarrow{d} N(0, I_1(\theta_0)),$$

enquanto a lei dos grandes números implica

$$-\frac{1}{n} \ell_n''(\tilde{\theta}_n) \xrightarrow{p} I_1(\theta_0).$$

Pelo teorema de Slutsky (Lauritzen, 2023, app. A.2.2),

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I_1(\theta_0)^{-1}).$$

Equivalentemente, para n suficientemente grande,

$$\hat{\theta}_n \dot{\sim} N\left(\theta_0, \frac{1}{n I_1(\theta_0)}\right).$$

Essa aproximação e sua relação com a informação de Fisher são apresentadas por Chihara; Hesterberg (2022) [pp. 173–174], Lauritzen (2023, thm. 5.11) e Ramachandran; Tsokos (2009, pp. 334–336).

4.2.5.3 Normalidade assintótica: parâmetro vetorial

Se $\theta \in \mathbb{R}^q$, então, sob condições análogas,

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N_q(\mathbf{0}, \mathbf{I}_1(\theta_0)^{-1}).$$

Consequentemente,

$$\text{Cov}(\hat{\theta}_n) \approx \frac{1}{n} \mathbf{I}_1(\theta_0)^{-1}.$$

Como

$$\mathbf{I}_n(\theta_0) = n\mathbf{I}_1(\theta_0),$$

também se pode escrever

$$\text{Cov}(\hat{\theta}_n) \approx \mathbf{I}_n(\theta_0)^{-1}.$$

4.2.5.4 Eficiência assintótica

Em modelos paramétricos regulares, o estimador de máxima verossimilhança atinge assintoticamente o limite determinado pela informação de Fisher:

$$\text{Avar}[\sqrt{n}(\hat{\theta}_n - \theta_0)] = \mathbf{I}_1(\theta_0)^{-1}.$$

Nesse sentido, o estimador é assintoticamente eficiente na classe de estimadores regulares. A relação entre informação de Fisher, limite de Cramér–Rao e eficiência é discutida por Ramachandran; Tsokos (2009, pp. 273–276).

Interpretação

Eficiência assintótica não implica que o estimador de máxima verossimilhança:

- seja não viesado em amostras finitas;
- tenha variância mínima para todo tamanho amostral;
- tenha distribuição aproximadamente normal em amostras pequenas;
- seja robusto contra valores atípicos;
- seja robusto contra erros de especificação do modelo.

Chihara; Hesterberg (2022, p. 173) observam explicitamente que, em amostras finitas, a

variância pode ser maior do que a aproximação assintótica e a distribuição pode ser não normal.

4.2.5.5 Estimação do erro-padrão

A matriz de covariâncias assintótica pode ser estimada pela inversa da informação observada:

$$\widehat{\text{Cov}}(\hat{\theta}_n) = \mathbf{J}_n(\hat{\theta}_n)^{-1}.$$

Alternativamente, pode-se utilizar

$$\left[n\mathbf{I}_1(\hat{\theta}_n)\right]^{-1}.$$

Para um parâmetro escalar,

$$\widehat{\text{EP}}(\hat{\theta}_n) = \left[J_n(\hat{\theta}_n)\right]^{-1/2}.$$

4.2.5.6 Intervalo de Wald

A normalidade assintótica conduz ao intervalo aproximado

$$\hat{\theta}_n \pm z_{1-\alpha/2} \widehat{\text{EP}}(\hat{\theta}_n),$$

com nível de confiança assintótico $1 - \alpha$.

Observação

Intervalos de Wald podem apresentar desempenho inadequado quando:

- a amostra é pequena;
- a distribuição do estimador é assimétrica;
- o parâmetro está próximo da fronteira;
- existem restrições como $\theta > 0$ ou $0 < p < 1$;
- a log-verossimilhança é pouco curvada;
- o modelo é não regular.

Nessas situações, intervalos baseados no escore, na razão de verossimilhanças ou em reparametrizações podem ser mais adequados.

4.2.5.7 Invariância

! Propriedade — invariância

Se $\hat{\theta}$ maximiza $L(\theta)$ e $\eta = g(\theta)$, então

$$\hat{\eta} = g(\hat{\theta})$$

é um estimador de máxima verossimilhança de η . Quando g não é injetiva, a verossimilhança induzida de η é definida por

$$L^*(\eta) = \sup_{\theta: g(\theta)=\eta} L(\theta).$$

Por exemplo, se $\hat{\lambda}$ é o estimador da taxa de uma distribuição exponencial, o estimador de máxima verossimilhança da escala

$$\beta = \frac{1}{\lambda}$$

é

$$\hat{\beta} = \frac{1}{\hat{\lambda}}.$$

A propriedade de invariância é apresentada por Chihara; Hesterberg (2022) [pp. 171–173] e Ramachandran; Tsokos (2009, pp. 243–244).

Exemplos

Os exemplos desta subseção são adaptados de Larsen; Marx (2012) [sec. 5.2], Chihara; Hesterberg (2022, sec. 6.1) e Ramachandran; Tsokos (2009, sec. 5.2.2).

4.2.5.1 Exemplo: distribuição Bernoulli

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p), \quad 0 \leq p \leq 1.$$

A função de probabilidade é

$$f(x; p) = p^x (1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

A função de verossimilhança é

$$\begin{aligned} L(p) &= \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}. \end{aligned}$$

Definindo

$$T = \sum_{i=1}^n x_i,$$

obtém-se

$$L(p) = p^T (1 - p)^{n-T}.$$

A log-verossimilhança é

$$\ell(p) = T \log p + (n - T) \log(1 - p).$$

O escore é

$$U(p) = \frac{T}{p} - \frac{n - T}{1 - p}.$$

Para $0 < T < n$, a equação $U(p) = 0$ fornece

$$\hat{p} = \frac{T}{n} = \bar{X}.$$

Se $T = 0$, o máximo ocorre em $\hat{p} = 0$. Se $T = n$, o máximo ocorre em $\hat{p} = 1$.

A informação de Fisher por observação é

$$I_1(p) = \frac{1}{p(1 - p)}.$$

Portanto,

$$\sqrt{n}(\hat{p} - p) \xrightarrow{d} N(0, p(1-p)),$$

ou, aproximadamente,

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right).$$

Além disso,

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n},$$

que coincide com o limite de Cramér–Rao para $0 < p < 1$. Nos pontos de fronteira $p = 0$ e $p = 1$, a formulação regular baseada em informação interior não se aplica diretamente.

4.2.5.2 Exemplo: distribuição de Poisson

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda), \quad \lambda > 0.$$

A função de probabilidade é

$$f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

A verossimilhança é

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \\ &= e^{-n\lambda} \lambda^{\sum_{i=1}^n x_i} \prod_{i=1}^n \frac{1}{x_i!}. \end{aligned}$$

A log-verossimilhança é

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i\right) \log \lambda - \sum_{i=1}^n \log(x_i!).$$

O escore é

$$U(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda}.$$

A equação de verossimilhança fornece

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

A informação de Fisher por observação é

$$I_1(\lambda) = \frac{1}{\lambda}.$$

Logo,

$$\sqrt{n}(\hat{\lambda} - \lambda) \xrightarrow{d} N(0, \lambda),$$

e o erro-padrão assintótico pode ser estimado por

$$\widehat{\text{EP}}(\hat{\lambda}) = \sqrt{\frac{\hat{\lambda}}{n}}.$$

4.2.5.3 Exemplo: distribuição exponencial

Considere a parametrização da distribuição exponencial pela taxa:

$$f(x; \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0, \quad \lambda > 0.$$

Para uma amostra aleatória,

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n \lambda e^{-\lambda x_i} \\ &= \lambda^n \exp \left(-\lambda \sum_{i=1}^n x_i \right). \end{aligned}$$

A log-verossimilhança é

$$\ell(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n x_i.$$

O escore é

$$U(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n x_i.$$

Portanto,

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n X_i} = \frac{1}{\bar{X}}.$$

A informação de Fisher por observação é

$$I_1(\lambda) = \frac{1}{\lambda^2}.$$

Consequentemente,

$$\sqrt{n}(\hat{\lambda} - \lambda) \xrightarrow{d} N(0, \lambda^2),$$

e

$$\widehat{\text{EP}}(\hat{\lambda}) = \frac{\hat{\lambda}}{\sqrt{n}}.$$

Se a distribuição for parametrizada pela escala

$$\beta = \frac{1}{\lambda},$$

a propriedade de invariância fornece

$$\hat{\beta} = \frac{1}{\hat{\lambda}} = \bar{X}.$$

4.2.5.4 Exemplo: distribuição normal com média e variância desconhecidas

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

em que

$$-\infty < \mu < \infty \quad \text{e} \quad \sigma^2 > 0.$$

A função de verossimilhança é

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right].$$

A log-verossimilhança é

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Derivando em relação a μ ,

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu).$$

Assim,

$$\hat{\mu} = \bar{X}.$$

Derivando em relação a σ^2 ,

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2.$$

Substituindo $\hat{\mu} = \bar{X}$ e supondo que $\sum_i (X_i - \bar{X})^2 > 0$,

$$\hat{\sigma}_{\text{MV}}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

i Observação — existência e viés

Se todas as observações forem iguais, a verossimilhança cresce quando μ se aproxima desse valor e $\sigma^2 \downarrow 0$; como o espaço paramétrico exige $\sigma^2 > 0$, o supremo não é atingido. Fora desse caso degenerado, o estimador de máxima verossimilhança de σ^2 utiliza o divisor n , e não $n - 1$. Em amostras finitas,

$$E[\hat{\sigma}_{\text{MV}}^2] = \frac{n-1}{n}\sigma^2.$$

Portanto, ele é viesado. Entretanto,

$$\hat{\sigma}_{\text{MV}}^2 \xrightarrow{p} \sigma^2,$$

de modo que o estimador é consistente.

Para

$$\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix},$$

a informação de Fisher por observação é

$$\mathbf{I}_1(\theta) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 1/(2\sigma^4) \end{pmatrix}.$$

Logo,

$$\sqrt{n} \begin{pmatrix} \hat{\mu} - \mu \\ \hat{\sigma}_{\text{MV}}^2 - \sigma^2 \end{pmatrix} \xrightarrow{d} N_2 \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma^2 & 0 \\ 0 & 2\sigma^4 \end{pmatrix} \right].$$

4.2.5.5 Exemplo não regular: distribuição uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniforme}(0, \theta), \quad \theta > 0.$$

A densidade é

$$f(x; \theta) = \frac{1}{\theta} \mathbb{I}(0 \leq x \leq \theta).$$

A verossimilhança é

$$L(\theta) = \theta^{-n} \mathbb{I}(\theta \geq X_{(n)}),$$

em que

$$X_{(n)} = \max\{X_1, \dots, X_n\}.$$

Para $\theta \geq X_{(n)}$, a função θ^{-n} é decrescente. Portanto, seu maior valor é obtido no menor valor admissível de θ :

$$\hat{\theta} = X_{(n)}.$$

Nesse modelo, o suporte

$$[0, \theta]$$

depende do parâmetro. Portanto, não se deve aplicar mecanicamente a teoria regular baseada na diferenciação da log-verossimilhança.

Apesar disso, o estimador é consistente. Além disso, sua distribuição limite não é normal à taxa $\sqrt{n}$. De fato,

$$\frac{n(\theta - X_{(n)})}{\theta} \xrightarrow{d} \text{Exponencial}(1).$$

Para verificar esse resultado, considere $t > 0$. Então,

$$\begin{aligned} P_{\theta} \left[\frac{n(\theta - X_{(n)})}{\theta} > t \right] &= P_{\theta} \left[X_{(n)} < \theta \left(1 - \frac{t}{n} \right) \right] \\ &= \left(1 - \frac{t}{n} \right)^n \\ &\rightarrow e^{-t}. \end{aligned}$$

i Interpretação

Neste exemplo, o erro do estimador possui ordem $1/n$, e não $1/\sqrt{n}$. Portanto, o estimador converge mais rapidamente do que em modelos regulares, mas sua distribuição limite é exponencial, e não normal.

4.2.6 Procedimento geral de obtenção do estimador

Em problemas regulares, o seguinte roteiro pode ser utilizado:

1. especificar o modelo estatístico e o espaço paramétrico Θ ;
2. escrever a função de verossimilhança;
3. eliminar fatores positivos que não dependem do parâmetro;
4. calcular a log-verossimilhança;
5. obter a função escore;
6. resolver a equação de verossimilhança;
7. verificar se as soluções pertencem ao espaço paramétrico;
8. examinar a matriz Hessiana e os pontos de fronteira;
9. comparar eventuais máximos locais;
10. verificar as condições de regularidade;
11. calcular a informação observada ou esperada;
12. obter erros-padrão e intervalos assintóticos, quando justificável.

Quando a equação de verossimilhança não possui solução analítica, podem ser utilizados métodos numéricos, como Newton–Raphson, escore de Fisher e métodos quase-Newton. Em modelos com variáveis não observadas ou dados incompletos, o algoritmo EM constitui outra alternativa importante (Ramachandran; Tsokos, 2009).

4.2.7 Exercícios

Exercício 1 — Modelo Bernoulli

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p).$$

1. Obtenha a função de verossimilhança.
2. Mostre que

$$\hat{p} = \bar{X}.$$

3. Examine separadamente os casos $\sum X_i = 0$ e $\sum X_i = n$.
4. Calcule a informação de Fisher.
5. Mostre que $\hat{p}$ atinge o limite de Cramér–Rao.
6. Obtenha a distribuição assintótica de $\hat{p}$.

Fonte: exercício adaptado de Chihara; Hesterberg (2022) [p. 176] e Ramachandran; Tsokos (2009, pp. 244, 275–276).

💡 Exercício 2 — Contagens de Poisson

O número diário de falhas de um equipamento é modelado por uma distribuição de Poisson com parâmetro λ . Em dez dias, foram observadas as contagens

2, 0, 1, 3, 2, 4, 1, 0, 2, 5.

1. Obtenha o estimador de máxima verossimilhança de λ .
2. Calcule a estimativa correspondente.
3. Calcule a informação de Fisher.
4. Estime o erro-padrão assintótico de $\hat{\lambda}$.
5. Construa um intervalo de Wald com nível de confiança de 95%.
6. Discuta a possibilidade de o intervalo apresentar limite inferior negativo.

Fonte: elaboração própria, com base em Chihara; Hesterberg (2022) [pp. 150–151] e Ramachandran; Tsokos (2009, pp. 238–239, 275).

💡 Exercício 3 — Distribuição exponencial

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exponencial}(\lambda),$$

na parametrização pela taxa.

1. Mostre que

$$\hat{\lambda} = \frac{1}{\bar{X}}.$$

2. Determine o viés exato de $\hat{\lambda}$, supondo $n > 1$.
3. Verifique que $\hat{\lambda}$ é consistente.
4. Calcule a informação de Fisher.
5. Obtenha a distribuição assintótica de $\hat{\lambda}$.
6. Use a propriedade de invariância para obter o estimador da média da distribuição.

Fonte: exercício adaptado de Chihara; Hesterberg (2022) [pp. 151–152] e Ramachandran; Tsokos (2009, p. 244).

💡 Exercício 4 — Família de potências

Considere a família de densidades

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0.$$

1. Obtenha a função de verossimilhança.
2. Mostre que

$$\hat{\theta} = -\frac{n}{\sum_{i=1}^n \log X_i}.$$

3. Verifique que a solução corresponde a um máximo.
4. Calcule $I_1(\theta)$.
5. Determine a distribuição assintótica de $\hat{\theta}$.
6. Construa um intervalo de Wald para θ .

Fonte: exercício adaptado de Chihara; Hesterberg (2022) [pp. 152, 173–174] e Larsen; Marx (2012, p. 292).

💡 Exercício 5 — Modelo normal

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

com ambos os parâmetros desconhecidos.

1. Derive os estimadores de máxima verossimilhança de μ e σ^2 .
2. Mostre que o estimador de σ^2 é viesado.
3. Demonstre que ele é consistente.
4. Calcule a matriz de informação de Fisher.
5. Obtenha a matriz de covariâncias assintótica dos estimadores.
6. Utilize a propriedade de invariância para obter o estimador de máxima verossimilhança de σ .
7. Compare o estimador de σ^2 com a variância amostral não viesada.

Fonte: exercício adaptado de Chihara; Hesterberg (2022) [pp. 155–157, 176–177] e Larsen; Marx (2012, pp. 290–291).

💡 Exercício 6 — Suporte dependente do parâmetro

Sejam

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniforme}(\theta, \theta + 1), \quad \theta \in \mathbb{R}.$$

1. Escreva a função de verossimilhança.
2. Mostre que a verossimilhança é positiva se, e somente se,

$$X_{(n)} - 1 \leq \theta \leq X_{(1)}.$$

3. Determine o conjunto dos estimadores de máxima verossimilhança.
4. Verifique se o estimador é único.
5. Identifique as condições de regularidade que não são satisfeitas.
6. Explique por que a diferenciação da log-verossimilhança não resolve o problema.

Fonte: elaboração própria, com base em Chihara; Hesterberg (2022, pp. 152–154).

💡 Exercício 7 — Existência do estimador

Considere a densidade

$$f(x; \theta) = e^{\theta - x}, \quad x > \theta > 0.$$

1. Escreva a função de verossimilhança.
2. Determine os valores de θ para os quais a verossimilhança é positiva.
3. Mostre que, se o suporte for definido por $x > \theta$, o supremo da verossimilhança não é atingido.
4. Conclua que o estimador de máxima verossimilhança não existe.
5. Repita a análise substituindo a restrição $x > \theta$ por $x \geq \theta$.
6. Explique a diferença entre máximo e supremo nesse problema.

Fonte: exercício adaptado de Chihara; Hesterberg (2022, p. 177).

💡 Exercício 8 — Invariância

Suponha que $\hat{\lambda}$ seja o estimador de máxima verossimilhança da taxa $\lambda > 0$ de uma distribuição exponencial.

Obtenha os estimadores de máxima verossimilhança de:

$$\beta = \frac{1}{\lambda},$$

$$m = \frac{\log 2}{\lambda},$$

e

$$v = \frac{1}{\lambda^2},$$

em que β é a escala, m é a mediana e v é a variância da distribuição.

Em seguida, utilize o método delta para obter as distribuições assintóticas dos três estimadores.

Fonte: elaboração própria, com base em Chihara; Hesterberg (2022) [pp. 171–173] e Ramachandran; Tsokos (2009, pp. 243–244).

💡 Exercício 9 — Intervalos assintóticos

Seja $\hat{\theta}_n$ o estimador de máxima verossimilhança de um parâmetro escalar θ , e suponha que

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, I_1(\theta)^{-1}).$$

1. Mostre que

$$\frac{\hat{\theta}_n - \theta}{\sqrt{1/[nI_1(\hat{\theta}_n)]}} \xrightarrow{d} N(0, 1).$$

2. Obtenha o intervalo de Wald com nível assintótico $1 - \alpha$.

3. Aplique o resultado ao parâmetro p de uma distribuição Bernoulli.

4. Aplique o resultado ao parâmetro de escala de uma distribuição exponencial.

5. Discuta as limitações dos intervalos obtidos.

Fonte: exercício adaptado de Ramachandran; Tsokos (2009, pp. 334–336).

💡 Exercício 10 — Otimização numérica

Considere uma amostra $X_1, \dots, X_n$ de uma distribuição gama com densidade

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha) \beta^\alpha}, \quad x > 0,$$

em que $\alpha > 0$ e $\beta > 0$ são desconhecidos.

1. Escreva a log-verossimilhança.
2. Obtenha as duas equações de verossimilhança.
3. Mostre que a equação referente a α envolve a função digama.
4. Explique por que não há, em geral, solução algébrica fechada.
5. Descreva como o método de Newton–Raphson poderia ser empregado.
6. Indique quais verificações devem ser realizadas para confirmar que a solução numérica é um máximo global.

Fonte: elaboração própria, com base em Ramachandran; Tsokos (2009) [pp. 243, 285–289] e Shao (2005, pp. 175–182).

4.2.8 Síntese

i Síntese da seção

A estimação por máxima verossimilhança seleciona os valores paramétricos que maximizam a função de verossimilhança associada aos dados observados:

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} L_n(\theta).$$

Em modelos regulares, os estimadores de máxima verossimilhança são, sob condições adequadas, consistentes, assintoticamente normais e assintoticamente eficientes:

$$\sqrt{n} (\hat{\theta}_n - \theta_0) \xrightarrow{d} N_q(\mathbf{0}, \mathbf{I}_1(\theta_0)^{-1}).$$

Essas propriedades justificam o uso da informação de Fisher para estimar erros-padrão e construir procedimentos inferenciais. Contudo, a teoria não deve ser aplicada mecanicamente em modelos com fronteiras, suportes dependentes do parâmetro, falta de identificabilidade ou outras irregularidades.

4.3 Mínimos Quadrados

O método dos mínimos quadrados estima parâmetros minimizando a soma dos quadrados das discrepâncias entre valores observados e valores previstos. O critério aparece naturalmente em regressão linear, modelos polinomiais e problemas não lineares; sua interpretação inferencial

depende de hipóteses adicionais sobre os erros (Rice, 2007, chap. 14; Ramachandran; Tsokos, 2021, sec. 7.2.1).

A escolha da perda quadrática penaliza mais intensamente resíduos de grande magnitude. Por exemplo, um resíduo igual a 4 contribui com 16 para a função objetivo, enquanto um resíduo igual a 2 contribui com apenas 4. Essa característica facilita o tratamento matemático do problema, mas também torna o método sensível a observações atípicas (Diez; Barr; Çetinkaya-Rundel, 2014, p. 229; Rice, 2007, p. 556).

i Observação

O critério de mínimos quadrados, isoladamente, é um problema de otimização. Para interpretar os estimadores probabilisticamente, calcular erros-padrão ou realizar testes de hipóteses, é necessário especificar um modelo estatístico para os erros.

Ao final desta seção, o leitor deverá ser capaz de:

1. definir formalmente um estimador de mínimos quadrados;
2. obter as equações normais de um modelo linear;
3. interpretar geometricamente o ajuste de mínimos quadrados;
4. derivar os estimadores da regressão linear simples;
5. estabelecer a relação entre mínimos quadrados e máxima verossimilhança;
6. reconhecer situações em que mínimos quadrados ponderados são apropriados.

4.3.1 Exemplo motivacional: renda familiar e auxílio financeiro

Considere um estudo no qual se deseja investigar a relação entre a renda familiar de estudantes e o valor do auxílio financeiro concedido por uma universidade.

Para uma amostra de 50 estudantes, sejam:

- X : renda familiar, em milhares de dólares;
- Y : auxílio financeiro, em milhares de dólares.

As estatísticas amostrais foram:

$$\bar{x} = 101,8, \quad s_x = 63,2,$$

$$\bar{y} = 19,94, \quad s_y = 5,46,$$

e

$$r = -0,499,$$

em que r é o coeficiente de correlação amostral.

O objetivo é construir uma reta

$$\hat{y} = b_0 + b_1x$$

que represente a tendência linear dos dados. Para cada observação (x_i, y_i) , define-se o valor ajustado

$$\hat{y}_i = b_0 + b_1x_i$$

e o respectivo resíduo

$$e_i = y_i - \hat{y}_i.$$

O método dos mínimos quadrados escolhe b_0 e b_1 de modo a minimizar

$$\text{SQRes}(b_0, b_1) = \sum_{i=1}^n [y_i - (b_0 + b_1x_i)]^2.$$

Na regressão linear simples, o coeficiente angular pode ser calculado por

$$b_1 = r \frac{s_y}{s_x}.$$

Portanto,

$$\begin{aligned} b_1 &= -0,499 \left(\frac{5,46}{63,2} \right) \\ &\approx -0,0431. \end{aligned}$$

Como a reta de mínimos quadrados passa pelo ponto $(\bar{x}, \bar{y})$,

$$b_0 = \bar{y} - b_1\bar{x}.$$

Assim,

$$b_0 = 19,94 - (-0,0431)(101,8) \\ \approx 24,3.$$

A reta ajustada é, portanto,

$$\hat{y} = 24,3 - 0,0431x.$$

Interpretação

Como as duas variáveis estão expressas em milhares de dólares, um aumento de mil dólares na renda familiar está associado, segundo o modelo ajustado, a uma redução média estimada de aproximadamente

$$0,0431 \times 1000 = 43,10$$

dólares no auxílio financeiro.

Essa interpretação descreve uma associação linear amostral. Ela não estabelece, por si só, uma relação causal.

Extrapolação

A equação ajustada deve ser utilizada principalmente no intervalo de rendas representado pelos dados. Para rendas muito superiores às observadas, a reta pode produzir previsões negativas ou substantivamente impossíveis.

A adequação de um modelo linear dentro da região observada não garante sua validade fora dessa região.

Fonte: exemplo adaptado de Diez; Barr; Çetinkaya-Rundel (2014, pp. 227–233).

4.3.2 Definição formal

4.3.2.1 Formulação geral

Considere observações

$$(x_1, y_1), \dots, (x_n, y_n)$$

e um modelo paramétrico para a resposta dado por

$$y_i = m(x_i; \theta) + \varepsilon_i, \quad i = 1, \dots, n,$$

em que:

- $m(x_i; \theta)$ é a resposta sistemática prevista pelo modelo;
- $\theta \in \Theta$ é um vetor de parâmetros;
- ε_i representa o erro associado à observação i .

Para um valor particular de θ , define-se o resíduo

$$e_i(\theta) = y_i - m(x_i; \theta).$$

! Definição: estimador de mínimos quadrados

Um estimador de mínimos quadrados de θ é qualquer solução de

$$\hat{\theta}_{\text{MQ}} \in \arg \min_{\theta \in \Theta} Q_n(\theta),$$

em que

$$Q_n(\theta) = \sum_{i=1}^n [y_i - m(x_i; \theta)]^2.$$

A função $Q_n(\theta)$ é denominada soma de quadrados dos resíduos (Rice, 2007, chap. 14; Ramachandran; Tsokos, 2021, sec. 7.2.1).

A definição não exige que o modelo seja linear nos valores de x_i . O aspecto relevante é a forma como o vetor de parâmetros aparece em $m(x_i; \theta)$.

4.3.2.2 Modelos lineares nos parâmetros

Um modelo é linear nos parâmetros quando pode ser escrito como

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{p-1} x_{i,p-1} + \varepsilon_i.$$

Em notação matricial,

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

em que

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_{p-1} \end{pmatrix},$$

e $\mathbf{X}$ é a matriz de planejamento de dimensão $n \times p$.

O critério de mínimos quadrados ordinários é

$$Q(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2.$$

Equivalentemente,

$$Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

Derivando em relação a β ,

$$\nabla_{\beta} Q(\beta) = -2\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\hat{\beta}) = \mathbf{0}.$$

Portanto,

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{Y}.$$

! Definição: equações normais

As equações

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{Y}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se $\mathbf{X}$ possui posto completo, isto é,

$$\text{posto}(\mathbf{X}) = p,$$

então $\mathbf{X}^\top \mathbf{X}$ é não singular e a solução é única:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Essa é a expressão matricial do estimador de mínimos quadrados ordinários (Rice, 2007, pp. 565–567).

 Observação computacional

A expressão

$$(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

é útil para o desenvolvimento teórico. Em aplicações computacionais, não se recomenda calcular explicitamente a inversa de $\mathbf{X}^T \mathbf{X}$.

Métodos baseados nas decomposições QR ou de Cholesky tendem a apresentar maior estabilidade numérica, especialmente quando as colunas da matriz de planejamento são fortemente correlacionadas.

4.3.2.3 Interpretação geométrica

O vetor ajustado é

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}.$$

Quando $\mathbf{X}$ possui posto completo,

$$\hat{\mathbf{Y}} = \mathbf{P}_X \mathbf{Y},$$

em que

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

é a matriz de projeção sobre o espaço gerado pelas colunas de $\mathbf{X}$.

O vetor de resíduos é

$$\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \hat{\mathbf{Y}}.$$

Das equações normais,

$$\mathbf{X}^T \hat{\boldsymbol{\varepsilon}} = \mathbf{0}.$$

Logo, o vetor de resíduos é ortogonal a todas as colunas de $\mathbf{X}$. Geometricamente, $\hat{\mathbf{Y}}$ é a projeção ortogonal de $\mathbf{Y}$ no espaço dos valores que podem ser produzidos pelo modelo linear (Cox, 2006, pp. 10–11; Rice, 2007, pp. 565–567).

i Consequência

Quando o modelo contém intercepto, uma das colunas de $\mathbf{X}$ é formada exclusivamente por valores iguais a 1. Nesse caso,

$$\sum_{i=1}^n \hat{\varepsilon}_i = 0.$$

Consequentemente,

$$\widehat{\bar{Y}} = \bar{Y}.$$

4.3.2.4 Regressão linear simples

Considere o modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

O critério é

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2.$$

As equações normais são

$$\sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i$$

e

$$\sum_{i=1}^n x_i Y_i = \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2.$$

Defina

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

e

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y}).$$

Se $S_{xx} > 0$, os estimadores são

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

e

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}.$$

Utilizando o coeficiente de correlação amostral,

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}},$$

também se obtém

$$\hat{\beta}_1 = r \frac{s_Y}{s_X}.$$

A identidade

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

mostra que a reta de mínimos quadrados sempre passa pelo ponto

$$(\bar{x}, \bar{Y}).$$

4.3.3 Relação com o método de máxima verossimilhança

4.3.3.1 Modelo normal homoscedástico

Considere o modelo linear

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

com

$$\varepsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

Equivalentemente,

$$Y_i \mid \mathbf{x}_i \sim N(\mathbf{x}_i^\top \beta, \sigma^2),$$

independentemente para $i = 1, \dots, n$.

A função de verossimilhança é

$$L(\beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta) \right].$$

A log-verossimilhança é

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} Q(\beta),$$

em que

$$Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

Para um valor fixado de σ^2 , os dois primeiros termos não dependem de β . Além disso,

$$-\frac{1}{2\sigma^2} < 0.$$

Portanto,

$$\arg \max_{\beta} \ell(\beta, \sigma^2) = \arg \min_{\beta} Q(\beta).$$

Assim,

$$\hat{\beta}_{\text{MV}} = \hat{\beta}_{\text{MQ}}.$$

Em um modelo com erros normais, independentes e de variância constante, os estimadores de máxima verossimilhança dos coeficientes de regressão coincidem com os estimadores de mínimos quadrados ordinários (Hastie; Tibshirani; Friedman, 2009, pp. 30–31).

! Resultado

A equivalência ocorre porque, no modelo normal, maximizar a verossimilhança em relação aos parâmetros da média é equivalente a minimizar

$$\sum_{i=1}^n [Y_i - m(x_i; \theta)]^2.$$

4.3.3.2 Estimação da variância

Substituindo $\hat{\beta}$ na log-verossimilhança e maximizando em relação a σ^2 , obtém-se

$$\hat{\sigma}_{\text{MV}}^2 = \frac{\text{SQRes}}{n},$$

em que

$$\text{SQRes} = \|\mathbf{Y} - \mathbf{X}\hat{\beta}\|^2.$$

Entretanto,

$$E(\text{SQRes}) = (n - p)\sigma^2.$$

Consequentemente,

$$\hat{\sigma}_{\text{MV}}^2 = \frac{\text{SQRes}}{n}$$

é viesado em amostras finitas. O estimador não viesado usual é

$$s^2 = \frac{\text{SQRes}}{n - p}.$$

Observação

No modelo de regressão linear simples com intercepto e inclinação, $p = 2$. Portanto,

$$s^2 = \frac{\text{SQRes}}{n - 2}.$$

A diferença entre os divisores n e $n - p$ ilustra que a estimação por máxima verossimilhança não produz necessariamente estimadores não viesados em amostras finitas (Cox, 2006, pp. 145–146; Rice, 2007, pp. 575–576).

4.3.3.3 Quando a equivalência não ocorre

A coincidência entre mínimos quadrados ordinários e máxima verossimilhança depende da distribuição dos erros.

Observação

Se os erros não possuem distribuição normal, o estimador de mínimos quadrados continua definido, mas não é necessariamente o estimador de máxima verossimilhança.

Por exemplo, para determinados modelos com erros de caudas mais pesadas, o critério de máxima verossimilhança pode penalizar os resíduos de maneira diferente da função quadrática.

A normalidade não é necessária para calcular o estimador de mínimos quadrados. Sob as condições

$$E(\varepsilon \mid \mathbf{X}) = \mathbf{0}$$

e

$$\text{Var}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n,$$

e supondo que $\mathbf{X}$ tenha posto completo, o teorema de Gauss–Markov estabelece que $\hat{\beta}$ é o melhor estimador linear não viesado: para qualquer outro estimador linear não viesado $\tilde{\beta}$,

$$\text{Cov}(\tilde{\beta} \mid \mathbf{X}) - \text{Cov}(\hat{\beta} \mid \mathbf{X}),$$

é positiva semidefinida. A normalidade não é necessária para esse resultado, mas é necessária para certas distribuições amostrais exatas e para a equivalência direta com máxima verossimilhança (Rice, 2007, sec. 14.4).

4.3.3.4 Mínimos quadrados ponderados

Considere erros independentes com variâncias conhecidas e não constantes:

$$\text{Var}(\varepsilon_i) = \sigma_i^2.$$

Se

$$\varepsilon_i \sim N(0, \sigma_i^2),$$

a log-verossimilhança contém o termo

$$-\frac{1}{2} \sum_{i=1}^n \frac{(Y_i - \mathbf{x}_i^\top \beta)^2}{\sigma_i^2}.$$

Portanto, a maximização da verossimilhança equivale à minimização de

$$Q_P(\beta) = \sum_{i=1}^n w_i (Y_i - \mathbf{x}_i^\top \beta)^2,$$

em que

$$w_i = \frac{1}{\sigma_i^2}.$$

! Definição: mínimos quadrados ponderados

O estimador de mínimos quadrados ponderados é

$$\hat{\beta}_{\text{MQP}} \in \arg \min_{\beta} (\mathbf{Y} - \mathbf{X}\beta)^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\beta),$$

em que

$$\mathbf{W} = \text{diag}(w_1, \dots, w_n).$$

Se $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ é não singular,

$$\hat{\beta}_{\text{MQP}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{Y}.$$

Observações com maior variância recebem menor peso. A formulação é denominada mínimos quadrados generalizados quando a matriz de covariâncias dos erros possui forma não diagonal (Rice, 2007, pp. 593–594; Cox, 2006, pp. 157–158).

4.3.4 Exemplos

4.3.4.1 Exemplo: estimação de uma média

Considere o modelo

$$Y_i = \mu + \varepsilon_i, \quad i = 1, \dots, n.$$

Nesse caso, todos os valores são aproximados por uma mesma constante μ . O critério de mínimos quadrados é

$$Q(\mu) = \sum_{i=1}^n (Y_i - \mu)^2.$$

Derivando,

$$Q'(\mu) = -2 \sum_{i=1}^n (Y_i - \mu).$$

A condição $Q'(\hat{\mu}) = 0$ fornece

$$\sum_{i=1}^n (Y_i - \hat{\mu}) = 0.$$

Logo,

$$\sum_{i=1}^n Y_i - n\hat{\mu} = 0$$

e

$$\boxed{\hat{\mu}_{\text{MQ}} = \bar{Y}}.$$

A segunda derivada é

$$Q''(\mu) = 2n > 0,$$

confirmando que a solução corresponde ao mínimo global.

i Interpretação

A média amostral é a constante que minimiza a soma dos quadrados das distâncias entre as observações e um valor central.

Essa caracterização é específica da perda quadrática. A mediana, por sua vez, minimiza a soma dos valores absolutos dos desvios.

Fonte: elaboração própria, com base em Ramachandran; Tsokos (2021, sec. 7.2.1).

4.3.4.2 Exemplo: ajuste de uma reta

Considere os dados:

x_i	y_i
1	2
2	3
3	5
4	4

As médias são

$$\bar{x} = \frac{1 + 2 + 3 + 4}{4} = 2,5$$

e

$$\bar{y} = \frac{2 + 3 + 5 + 4}{4} = 3,5.$$

Calculando S_{xx} ,

$$\begin{aligned} S_{xx} &= (1 - 2,5)^2 + (2 - 2,5)^2 \\ &\quad + (3 - 2,5)^2 + (4 - 2,5)^2 \\ &= 5. \end{aligned}$$

Calculando S_{xy} ,

$$\begin{aligned}
S_{xy} &= (1 - 2,5)(2 - 3,5) + (2 - 2,5)(3 - 3,5) \\
&\quad + (3 - 2,5)(5 - 3,5) + (4 - 2,5)(4 - 3,5) \\
&= 4.
\end{aligned}$$

Portanto,

$$\hat{\beta}_1 = \frac{4}{5} = 0,8$$

e

$$\hat{\beta}_0 = 3,5 - (0,8)(2,5) = 1,5.$$

A reta ajustada é

$$\boxed{\hat{y} = 1,5 + 0,8x}.$$

Os valores ajustados e resíduos são:

x_i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$
1	2	2,3	-0,3
2	3	3,1	-0,1
3	5	3,9	1,1
4	4	4,7	-0,7

A soma de quadrados dos resíduos é

$$\begin{aligned}
\text{SQRes} &= (-0,3)^2 + (-0,1)^2 + (1,1)^2 + (-0,7)^2 \\
&= 1,8.
\end{aligned}$$

Além disso,

$$\sum_{i=1}^4 e_i = 0,$$

como esperado para um modelo que contém intercepto.

Fonte: elaboração própria, com base em Rice (2007) [pp. 565–567] e Ramachandran; Tsokos (2021, sec. 7.2.1).

4.3.4.3 Exemplo: regressão polinomial

Considere o modelo quadrático

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \varepsilon_i.$$

Embora a resposta seja uma função quadrática de x_i , o modelo é linear nos parâmetros β_0 , β_1 e β_2 .

Para os dados

x_i	y_i
-1	2
0	1
1	2
2	5

a matriz de planejamento é

$$\mathbf{X} = \begin{pmatrix} 1 & -1 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix},$$

e

$$\mathbf{Y} = \begin{pmatrix} 2 \\ 1 \\ 2 \\ 5 \end{pmatrix}.$$

Observa-se que

$$\mathbf{Y} = \mathbf{X} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}.$$

Consequentemente,

$$\hat{\beta} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

e a curva ajustada é

$$\hat{y} = 1 + x^2.$$

Nesse exemplo,

$$\text{SQRes} = 0.$$

i Observação

Um modelo polinomial é um modelo linear quando é linear nos parâmetros, mesmo que seja não linear na variável explicativa.

Em contraste, um modelo como

$$m(x; \theta_1, \theta_2) = \theta_1 e^{-\theta_2 x}$$

é não linear nos parâmetros e, em geral, requer métodos numéricos.

Fonte: elaboração própria, com base na formulação matricial de Rice (2007, pp. 565–567).

4.3.4.4 Exemplo: mínimos quadrados ponderados

Considere os dados

x_i	y_i	$\text{Var}(\varepsilon_i)$
0	1	1
1	2	1
2	2	1/4

Como a terceira observação possui menor variância, ela deve receber maior peso. Os pesos são

$$w_i = \frac{1}{\text{Var}(\varepsilon_i)},$$

de modo que

$$(w_1, w_2, w_3) = (1, 1, 4).$$

O critério ponderado é

$$\begin{aligned} Q_P(\beta_0, \beta_1) = & (1 - \beta_0)^2 \\ & + (2 - \beta_0 - \beta_1)^2 \\ & + 4(2 - \beta_0 - 2\beta_1)^2. \end{aligned}$$

A solução das equações ponderadas fornece

$$\hat{\beta}_0 = \frac{25}{21}$$

e

$$\hat{\beta}_1 = \frac{3}{7}.$$

Portanto,

$$\hat{y} = \frac{25}{21} + \frac{3}{7}x.$$

A terceira observação exerce maior influência sobre o ajuste porque é considerada mais precisa.

Fonte: elaboração própria, com base em Rice (2007, pp. 593–594).

4.3.5 Exercícios

Exercício 1 — Derivação da reta de mínimos quadrados

Considere o modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

1. Escreva a soma de quadrados dos resíduos.
2. Diferencie-a em relação a β_0 e β_1 .
3. Obtenha as duas equações normais.
4. Mostre que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

5. Mostre que

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}.$$

6. Conclua que a reta ajustada passa pelo ponto $(\bar{x}, \bar{Y})$.

Fonte: exercício adaptado de Ramachandran; Tsokos (2021) [sec. 7.2.1] e Rice (2007, p. 594).

💡 Exercício 2 — Ajuste numérico

Considere os dados:

x_i	0	1	2	3	4
y_i	1	2	2	4	5

1. Calcule $\bar{x}$ e $\bar{y}$.
2. Calcule S_{xx} e S_{xy} .
3. Obtenha $\hat{\beta}_0$ e $\hat{\beta}_1$.
4. Calcule os valores ajustados.
5. Calcule os resíduos.
6. Verifique que a soma dos resíduos é zero.
7. Calcule a soma de quadrados dos resíduos.
8. Interprete o coeficiente angular.

Fonte: elaboração própria, com base nos exercícios de regressão de Diez; Barr; Çetinkaya-Rundel (2014, pp. 244–249).

💡 Exercício 3 — Mínimos quadrados como estimador de localização

Considere

$$Q(a) = \sum_{i=1}^n (Y_i - a)^2.$$

1. Mostre que o valor de a que minimiza $Q(a)$ é $\bar{Y}$.
2. Mostre que

$$\sum_{i=1}^n (Y_i - a)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 + n(\bar{Y} - a)^2.$$

3. Utilize a identidade anterior para provar que o mínimo é global e único.
4. Compare esse resultado com o estimador que minimiza

$$\sum_{i=1}^n |Y_i - a|.$$

Fonte: elaboração própria, com base no princípio de projeção apresentado por Cox (2006, pp. 10–11).

💡 Exercício 4 — Equivalência com máxima verossimilhança

Suponha que

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

com

$$\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2).$$

1. Escreva a função de verossimilhança de $(\beta_0, \beta_1, \sigma^2)$.
2. Obtenha a log-verossimilhança.
3. Mostre que, para σ^2 fixado, maximizar a log-verossimilhança em relação a β_0 e β_1 equivale a minimizar a soma de quadrados dos resíduos.
4. Obtenha os estimadores de máxima verossimilhança de β_0 e β_1 .
5. Obtenha o estimador de máxima verossimilhança de σ^2 .
6. Compare esse estimador com o estimador não viesado da variância.

Fonte: exercício adaptado de Rice (2007) [pp. 595–596] e Hastie; Tibshirani; Friedman (2009, pp. 30–31).

💡 Exercício 5 — Formulação matricial

Considere o modelo

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon.$$

1. Expanda

$$Q(\beta) = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

2. Calcule o gradiente de $Q(\beta)$.
3. Obtenha as equações normais.
4. Mostre que, se $\mathbf{X}$ possui posto completo,

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

5. Mostre que

$$\mathbf{X}^\top \hat{\varepsilon} = \mathbf{0}.$$

6. Interprete geometricamente o resultado.

Fonte: exercício adaptado de Rice (2007, pp. 565–567, 595–596).

Exercício 6 — Falta de posto completo

Considere a matriz

$$\mathbf{X} = \begin{pmatrix} 1 & 2 & 4 \\ 1 & 3 & 6 \\ 1 & 4 & 8 \\ 1 & 5 & 10 \end{pmatrix}.$$

1. Determine o posto de $\mathbf{X}$.
2. Explique por que $\mathbf{X}^\top \mathbf{X}$ é singular.
3. Identifique a relação linear entre as colunas de $\mathbf{X}$.
4. Discuta a unicidade de $\hat{\beta}$.
5. Verifique se o vetor de valores ajustados pode ser único mesmo quando o vetor de coeficientes não é.
6. Relacione o problema ao conceito de multicolinearidade perfeita.

Fonte: elaboração própria, com base no critério de existência e unicidade de Rice (2007, pp. 566–567).

💡 Exercício 7 — Mínimos quadrados ponderados

Considere o modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que os erros são independentes e

$$\text{Var}(\varepsilon_i) = \rho_i^2 \sigma^2,$$

com ρ_i conhecido.

1. Defina

$$Z_i = \frac{Y_i}{\rho_i}, \quad u_i = \frac{1}{\rho_i}, \quad v_i = \frac{x_i}{\rho_i}.$$

2. Mostre que o modelo transformado possui erros com variância constante.
3. Mostre que aplicar mínimos quadrados ordinários ao modelo transformado equivale a minimizar

$$\sum_{i=1}^n \frac{(Y_i - \beta_0 - \beta_1 x_i)^2}{\rho_i^2}.$$

4. Identifique os pesos das observações.
5. Explique por que observações de maior variância recebem menor peso.
6. Relacione o estimador obtido ao método de máxima verossimilhança sob normalidade.

Fonte: exercício adaptado de Rice (2007, pp. 593–594).

💡 Exercício 8 — Mínimos quadrados não lineares

Considere o modelo

$$Y_i = \alpha e^{-\beta x_i} + \varepsilon_i, \quad \alpha > 0, \quad \beta > 0.$$

1. Escreva a função de mínimos quadrados

$$Q(\alpha, \beta) = \sum_{i=1}^n (Y_i - \alpha e^{-\beta x_i})^2.$$

2. Calcule as derivadas parciais de Q .
3. Obtenha as equações de mínimos quadrados não lineares.
4. Explique por que essas equações não possuem, em geral, solução algébrica fechada.
5. Descreva como um método iterativo poderia ser utilizado.
6. Mostre que, sob erros normais independentes com variância constante, o estimador de mínimos quadrados não lineares também é um estimador de máxima verossimilhança.
7. Discuta a possibilidade de existirem mínimos locais.

Fonte: exercício adaptado da discussão de regressão não linear de Cox (2006) [pp. 10–12] e Hastie; Tibshirani; Friedman (2009, pp. 30–31).

4.3.6 Síntese

i Síntese da seção

O método dos mínimos quadrados estima os parâmetros minimizando a soma dos quadrados dos resíduos:

$$\hat{\theta}_{\text{MQ}} \in \arg \min_{\theta} \sum_{i=1}^n [Y_i - m(x_i; \theta)]^2.$$

No modelo linear,

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

as equações normais são

$$\mathbf{X}^T \mathbf{X} \hat{\beta} = \mathbf{X}^T \mathbf{Y}.$$

Quando $\mathbf{X}$ possui posto completo,

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Geometricamente, o vetor ajustado é a projeção ortogonal de $\mathbf{Y}$ no espaço gerado pelas colunas de $\mathbf{X}$.

Sob erros normais, independentes e homoscedásticos, os estimadores dos coeficientes obtidos por mínimos quadrados coincidem com os estimadores de máxima verossimilhança. Se as variâncias são diferentes e conhecidas, a máxima verossimilhança conduz ao método dos mínimos quadrados ponderados.

4.4 Algoritmo Expectation-Maximization (EM)

O algoritmo *Expectation-Maximization* (EM) é um procedimento iterativo para maximização da verossimilhança — ou de uma versão penalizada/MAP — em problemas com dados ausentes, censura, variáveis latentes ou outra representação por dados incompletos. A apresentação adotada combina a formulação rigorosa e as propriedades computacionais de Gupta; Chen (2011) [secs. 1–2], as aplicações a misturas de Hastie; Tibshirani; Friedman (2009, secs. 6.8 e 8.5), a exposição de dados incompletos de Ramachandran; Tsokos (2021) [sec. 13.4] e o tratamento didático de Chihara; Hesterberg (2022, sec. 13.8).

A exposição técnica desta seção segue Gupta; Chen (2011), Hastie; Tibshirani; Friedman (2009), Ramachandran; Tsokos (2021) e Chihara; Hesterberg (2022). As propriedades assintóticas do estimador de máxima verossimilhança eventualmente alcançado pelo algoritmo são tratadas com base em Lauritzen (2023).

4.4.1 Exemplo motivacional: mistura de duas populações normais

Considere uma amostra $Y_1, \dots, Y_n$ obtida de uma população heterogênea formada por duas subpopulações. Condicionalmente à subpopulação de origem, suponha que

$$Y_i \mid Z_i = 1 \sim N(\mu_1, \sigma_1^2)$$

e

$$Y_i \mid Z_i = 2 \sim N(\mu_2, \sigma_2^2),$$

em que $Z_i \in \{1, 2\}$ identifica o componente responsável pela geração da observação. Se

$$P(Z_i = 1) = \pi \quad \text{e} \quad P(Z_i = 2) = 1 - \pi,$$

a densidade marginal de Y_i é

$$f(y_i \mid \theta) = \pi \phi(y_i; \mu_1, \sigma_1^2) + (1 - \pi) \phi(y_i; \mu_2, \sigma_2^2),$$

onde

$$\theta = (\pi, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2)$$

e $\phi(y; \mu, \sigma^2)$ denota a densidade normal com média μ e variância σ^2 .

A log-verossimilhança observada é

$$\ell(\theta; y) = \sum_{i=1}^n \log [\pi \phi(y_i; \mu_1, \sigma_1^2) + (1 - \pi) \phi(y_i; \mu_2, \sigma_2^2)].$$

A presença do logaritmo de uma soma impede a separação imediata dos termos associados aos dois componentes. Em geral, as equações de máxima verossimilhança não fornecem expressões fechadas simultâneas para todos os parâmetros.

Suponha, porém, que os indicadores de pertencimento fossem observados. Defina

$$Z_{ij} = \begin{cases} 1, & \text{se a observação } i \text{ pertence ao componente } j, \\ 0, & \text{caso contrário,} \end{cases}$$

com $Z_{i1} + Z_{i2} = 1$. A log-verossimilhança dos dados completos seria

$$\ell_c(\theta) = \sum_{i=1}^n \sum_{j=1}^2 Z_{ij} [\log(\pi_j) + \log \phi(y_i; \mu_j, \sigma_j^2)] ,$$

onde $\pi_1 = \pi$ e $\pi_2 = 1 - \pi$.

Essa expressão é simples de maximizar quando Z_{ij} é conhecido. O EM explora exatamente essa diferença: em cada iteração, substitui os indicadores não observados por suas esperanças condicionais, isto é, pelas probabilidades atuais de pertencimento aos componentes, e atualiza os parâmetros por médias e variâncias ponderadas (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

i Interpretação

O EM não realiza uma classificação rígida das observações durante as iterações. Cada observação recebe uma responsabilidade probabilística para cada componente. Essa característica distingue o ajuste de misturas gaussianas por EM de métodos de agrupamento com atribuição exclusiva, como o k -means (Gupta; Chen, 2011, sec. 3.2).

4.4.2 Definição formal

4.4.2.1 Dados observados, dados latentes e dados completos

Seja Y o vetor de dados observados e seja Z um vetor de variáveis não observadas, ausentes ou latentes. O vetor

$$X = (Y, Z)$$

é denominado vetor de **dados completos**.

Considere um modelo paramétrico indexado por

$$\theta \in \Theta.$$

A densidade conjunta dos dados completos é

$$f_c(y, z \mid \theta),$$

enquanto a densidade observada é obtida por marginalização:

$$f(y \mid \theta) = \int_{\mathcal{Z}} f_c(y, z \mid \theta) dz.$$

No caso discreto,

$$f(y \mid \theta) = \sum_{z \in \mathcal{Z}} f_c(y, z \mid \theta).$$

O objetivo é maximizar a log-verossimilhança observada

$$\ell(\theta) = \log f(y \mid \theta).$$

O princípio do EM consiste em escolher uma representação por dados completos para a qual

$$\ell_c(\theta; y, z) = \log f_c(y, z \mid \theta)$$

seja mais simples de trabalhar do que $\ell(\theta)$ (Gupta; Chen, 2011, secs. 1.1 e 2.1).

4.4.2.2 Relação entre dados completos e dados observados

Gupta; Chen (2011) formulam a relação estrutural do EM pela cadeia de Markov

$$\theta \longrightarrow X \longrightarrow Y,$$

o que equivale a exigir

$$f(y \mid x, \theta) = f(y \mid x).$$

Essa condição afirma que, conhecidos os dados completos, o mecanismo que produz os dados observados não contém informação adicional sobre θ . Quando $Y = T(X)$ para alguma transformação determinística T , a condição é automaticamente satisfeita.

4.4.2.3 Função auxiliar

! Definição — função Q

Dado o valor corrente $\theta^{(t)}$, define-se

$$Q(\theta \mid \theta^{(t)}) = E_{\theta^{(t)}} [\ell_c(\theta; Y, Z) \mid Y = y].$$

Equivalentemente,

$$Q(\theta \mid \theta^{(t)}) = \int_z \log f_c(y, z \mid \theta) f(z \mid y, \theta^{(t)}) dz.$$

A esperança é calculada com respeito à distribuição condicional das variáveis latentes sob o valor corrente $\theta^{(t)}$. O argumento θ permanece livre dentro da log-verossimilhança completa; o valor corrente é utilizado somente para determinar a distribuição condicional empregada na esperança (Ramachandran; Tsokos, 2021, sec. 13.4).

4.4.2.4 Etapas do algoritmo

! Definição — algoritmo EM

Escolha um valor inicial $\theta^{(0)}$. Para $t = 0, 1, 2, \dots$, execute:

Etapas E — Expectation

Calcule

$$Q(\theta \mid \theta^{(t)}) = E_{\theta^{(t)}} [\ell_c(\theta; Y, Z) \mid Y = y].$$

Etapas M — Maximization

Determine

$$\theta^{(t+1)} \in \arg \max_{\theta \in \Theta} Q(\theta \mid \theta^{(t)}).$$

Repita as duas etapas até que um critério de convergência seja satisfeito (Gupta; Chen, 2011, sec. 1.1; Ramachandran; Tsokos, 2021, sec. 13.4).

Critérios usuais de parada incluem

$$\left| \ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) \right| < \varepsilon$$

ou

$$\left\| \theta^{(t+1)} - \theta^{(t)} \right\| < \varepsilon.$$

Uma forma relativa, mais estável quando a escala da log-verossimilhança é grande, é

$$\frac{\left| \ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) \right|}{1 + \left| \ell(\theta^{(t)}) \right|} < \varepsilon.$$

O critério de parada não faz parte da definição matemática essencial do EM e deve ser escolhido de acordo com a precisão e o custo computacional desejados (Gupta; Chen, 2011; Ramachandran; Tsokos, 2021).

4.4.2.5 Interpretação por limite inferior

Defina

$$q_t(z) = f(z \mid y, \theta^{(t)}).$$

Para qualquer densidade $q(z)$,

$$\ell(\theta) = \mathcal{F}(q, \theta) + D_{\text{KL}}[q(z) \parallel f(z \mid y, \theta)],$$

onde

$$\mathcal{F}(q, \theta) = E_q[\log f_c(y, Z \mid \theta)] + \mathcal{H}(q),$$

$\mathcal{H}(q)$ é a entropia de q e

$$D_{\text{KL}}(q \parallel p) = E_q \left[\log \frac{q(Z)}{p(Z)} \right] \geq 0.$$

Portanto,

$$\mathcal{F}(q, \theta) \leq \ell(\theta).$$

Na etapa E, escolhe-se a distribuição condicional corrente das variáveis latentes, fazendo com que o limite inferior toque a log-verossimilhança no valor atual. Na etapa M, maximiza-se esse limite inferior em relação a θ . Essa interpretação aproxima o EM dos procedimentos de *minorization-maximization* ou maximização sucessiva (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

4.4.3 Condições de uso

É útil distinguir as condições que tornam o EM **computacionalmente conveniente** das condições matemáticas utilizadas para justificar suas propriedades.

4.4.3.1 Representação adequada por dados completos

Deve ser possível introduzir dados latentes Z tais que

$$f(y | \theta) = \int f_c(y, z | \theta) dz.$$

A ampliação dos dados não é única. Duas representações corretas podem produzir algoritmos com custos e velocidades de convergência diferentes. Na prática, a escolha deve tornar a etapa E e, principalmente, a etapa M mais simples do que a maximização direta da verossimilhança observada (Gupta; Chen, 2011).

4.4.3.2 Etapa E calculável

Deve ser possível calcular

$$f(z | y, \theta^{(t)})$$

ou, ao menos, as esperanças condicionais das estatísticas que aparecem na log-verossimilhança completa.

Quando o modelo completo pertence a uma família exponencial, a etapa E frequentemente se reduz ao cálculo da esperança condicional de estatísticas suficientes (Ramachandran; Tsokos, 2021, sec. 13.4).

Se a esperança condicional não puder ser calculada analiticamente, uma possibilidade é aproximá-la por simulação, originando o algoritmo Monte Carlo EM, ou MCEM (Gupta; Chen, 2011, sec. 5; Ramachandran; Tsokos, 2021, sec. 13.4).

4.4.3.3 Etapa M calculável

O problema

$$\max_{\theta \in \Theta} Q(\theta \mid \theta^{(t)})$$

deve possuir solução fechada ou ser numericamente mais simples do que a maximização da log-verossimilhança observada.

Quando a maximização exata é difícil, pode-se empregar o **EM generalizado**. Nesse caso, basta obter $\theta^{(t+1)}$ tal que

$$Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)}).$$

Essa modificação preserva a propriedade de monotonicidade, embora a etapa M não seja resolvida exatamente (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

4.4.3.4 Suporte independente do parâmetro

Uma condição suficiente importante na demonstração usual da monotonicidade é que o suporte dos dados completos não dependa de θ . Se o suporte variar com o parâmetro, como em modelos uniformes cujo limite depende de θ , o argumento padrão pode falhar (Gupta; Chen, 2011).

4.4.3.5 Identificabilidade e existência do máximo

O modelo deve ser identificável, ao menos após a imposição das restrições necessárias. Em misturas, a permutação dos rótulos dos componentes produz a mesma densidade, fenômeno conhecido como invariância por troca de rótulos.

Além disso, a verossimilhança pode ser ilimitada. Em uma mistura gaussiana irrestrita, um componente pode concentrar-se em uma única observação com variância tendendo a zero, fazendo a log-verossimilhança divergir para infinito. Nessa situação, o problema de máxima verossimilhança não possui um máximo finito no espaço paramétrico irrestrito (Gupta; Chen, 2011).

Estratégias práticas incluem:

- impor um limite inferior para variâncias ou autovalores das matrizes de covariâncias;
- restringir a estrutura das covariâncias;
- empregar penalização ou uma formulação MAP-EM;
- descartar componentes com peso numericamente desprezível;
- utilizar múltiplas inicializações.

4.4.3.6 Valores iniciais

Como a log-verossimilhança observada pode ser não côncava, diferentes valores iniciais podem conduzir a diferentes pontos estacionários. Para misturas gaussianas, inicializações baseadas em k -means, quantis, partições aleatórias ou conhecimento prévio são alternativas usuais (Gupta; Chen, 2011; Hastie; Tibshirani; Friedman, 2009).

⚠ Observação — escopo das garantias

A monotonicidade da log-verossimilhança não garante convergência ao máximo global. Também não garante, por si só, a convergência da sequência de parâmetros. Teoremas mais fortes exigem hipóteses adicionais sobre continuidade, compacidade de conjuntos de nível, regularidade da aplicação de atualização e comportamento na fronteira do espaço paramétrico. A formulação precisa dessas hipóteses deve ser verificada em uma referência especializada para o modelo considerado.

4.4.4 Propriedades importantes

4.4.4.1 Monotonicidade da log-verossimilhança

! Propriedade — monotonicidade

Sob as condições usuais do EM, se

$$Q(\theta^{(t+1)} | \theta^{(t)}) \geq Q(\theta^{(t)} | \theta^{(t)}),$$

então

$$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

Para demonstrar a propriedade, seja

$$q_t(z) = f(z | y, \theta^{(t)}).$$

Então,

$$\ell(\theta) - \ell(\theta^{(t)}) = Q(\theta | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)}) + D_{\text{KL}}[q_t \| f(z | y, \theta)].$$

Como a divergência de Kullback–Leibler é não negativa,

$$\ell(\theta) - \ell(\theta^{(t)}) \geq Q(\theta \mid \theta^{(t)}) - Q(\theta^{(t)} \mid \theta^{(t)}).$$

Tomando $\theta = \theta^{(t+1)}$, obtém-se a monotonicidade. Essa é a principal garantia geral do algoritmo (Gupta; Chen, 2011, secs. 1.1 e 2.1).

4.4.4.2 Convergência dos valores da log-verossimilhança

Se a sequência

$$\ell(\theta^{(0)}), \ell(\theta^{(1)}), \dots$$

for limitada superiormente, sua monotonicidade implica a existência de ℓ^* tal que

$$\ell(\theta^{(t)}) \longrightarrow \ell^*.$$

Isso não implica necessariamente

$$\theta^{(t)} \longrightarrow \theta^*.$$

A sequência de parâmetros pode possuir múltiplos pontos de acumulação associados ao mesmo valor da log-verossimilhança (Gupta; Chen, 2011).

4.4.4.3 Pontos estacionários

Sob condições adicionais de regularidade, os pontos limites do EM são pontos estacionários da log-verossimilhança observada:

$$\nabla \ell(\theta^*) = 0.$$

Um ponto estacionário pode ser um máximo local, um máximo global ou um ponto de sela. Portanto, a convergência numérica do algoritmo não prova que o máximo global foi encontrado (Gupta; Chen, 2011).

4.4.4.4 Dependência da inicialização

Em problemas não côncavos, especialmente misturas gaussianas e modelos ocultos de Markov, o resultado pode depender fortemente de $\theta^{(0)}$. Recomenda-se executar o algoritmo a partir de diferentes valores iniciais e comparar as log-verossimilhanças finais (Gupta; Chen, 2011).

4.4.4.5 Velocidade de convergência

O EM pode convergir lentamente em comparação com métodos que utilizam derivadas de segunda ordem, como Newton–Raphson. A lentidão tende a ser mais pronunciada quando os dados observados contêm pouca informação sobre as variáveis latentes, por exemplo, quando componentes de uma mistura apresentam forte sobreposição. Variantes aceleradas podem reduzir o número de iterações, mas frequentemente aumentam o custo e a complexidade de cada passo (Gupta; Chen, 2011).

4.4.4.6 Propriedades do estimador final

O EM é um algoritmo de otimização, não uma definição distinta de estimador. Se o procedimento alcança o estimador regular de máxima verossimilhança $\hat{\theta}_{\text{MV}}$, então as propriedades estatísticas são as do estimador de máxima verossimilhança.

Em famílias exponenciais regulares e sob as condições pertinentes,

$$\hat{\theta}_{\text{MV}} \xrightarrow{P} \theta_0$$

e

$$\sqrt{n} (\hat{\theta}_{\text{MV}} - \theta_0) \xrightarrow{D} N(0, \mathcal{I}(\theta_0)^{-1}),$$

onde $\mathcal{I}(\theta_0)$ é a informação de Fisher por observação. Essa conclusão não se aplica automaticamente quando o algoritmo converge para um máximo local inadequado, quando o modelo não é identificável, quando o máximo ocorre na fronteira ou quando a verossimilhança é ilimitada (Lauritzen, 2023, secs. 5.3.1–5.3.2).

i Distinção conceitual

- **Convergência computacional:** comportamento de $\theta^{(t)}$ quando $t \rightarrow \infty$ para uma amostra fixa.
- **Convergência estatística:** comportamento de $\hat{\theta}_n$ quando $n \rightarrow \infty$ sob repetição amostral.

Essas duas noções não devem ser confundidas.

4.4.4.7 Variantes relevantes

GEM: exige apenas aumento da função Q , sem maximização completa em cada iteração.

MAP-EM: acrescenta o logaritmo de uma densidade a priori à etapa M:

$$\theta^{(t+1)} \in \arg \max_{\theta} \left\{ Q(\theta \mid \theta^{(t)}) + \log p(\theta) \right\}.$$

MCEM: aproxima a etapa E por simulação. Se

$$Z^{(t,1)}, \dots, Z^{(t,M)} \sim f(z \mid y, \theta^{(t)}),$$

então

$$\widehat{Q}_M(\theta \mid \theta^{(t)}) = \frac{1}{M} \sum_{m=1}^M \log f_c(y, Z^{(t,m)} \mid \theta).$$

Essas variantes são discutidas por Gupta; Chen (2011), e o MCEM também é apresentado por Ramachandran; Tsokos (2021, sec. 13.4).

4.4.5 Exemplos

4.4.5.1 Exemplo multinomial com informação agregada

Exemplo 1 — informação incompleta em uma distribuição multinomial

Este exemplo é adaptado da apresentação de Chihara; Hesterberg (2022) [sec. 13.8] e Gupta; Chen (2011, sec. 1.5), que discutem o exemplo clássico de dados multinomiais incompletos.

Considere

$$(X_1, X_2, X_3, X_4, X_5) \sim \text{Multinomial} \left[n, \left(\frac{1}{2}, \frac{\theta}{4}, \frac{1-\theta}{4}, \frac{1-\theta}{4}, \frac{\theta}{4} \right) \right],$$

com $0 < \theta < 1$. Suponha que X_1 e X_2 não sejam observados separadamente; observa-se apenas

$$Y_1 = X_1 + X_2,$$

além de $Y_2 = X_3$, $Y_3 = X_4$ e $Y_4 = X_5$.

Condicionalmente a $Y_1 = y_1$ e ao valor corrente $\theta^{(t)}$,

$$E(X_2 \mid Y_1 = y_1, \theta^{(t)}) = \frac{\theta^{(t)}}{2 + \theta^{(t)}} y_1$$

e

$$E(X_1 \mid Y_1 = y_1, \theta^{(t)}) = \frac{2}{2 + \theta^{(t)}} y_1.$$

A etapa M produz

$$\theta^{(t+1)} = \frac{\frac{\theta^{(t)}}{2 + \theta^{(t)}} y_1 + y_4}{\frac{\theta^{(t)}}{2 + \theta^{(t)}} y_1 + y_2 + y_3 + y_4}.$$

O exemplo ilustra que a etapa E não precisa reconstruir valores individuais dos dados ausentes. Basta calcular as esperanças condicionais das contagens necessárias para a maximização.

4.4.5.2 Mistura gaussiana

Exemplo 2 — mistura de k distribuições normais

A derivação segue Hastie; Tibshirani; Friedman (2009) [sec. 8.5] e Gupta; Chen (2011, sec. 3.2).

Considere observações independentes $y_1, \dots, y_n \in \mathbb{R}^p$ provenientes de

$$f(y_i \mid \theta) = \sum_{j=1}^k \pi_j \phi_p(y_i; \mu_j, \Sigma_j),$$

com

$$\pi_j > 0, \quad \sum_{j=1}^k \pi_j = 1.$$

Introduza Z_{ij} como indicador de pertencimento ao componente j .

4.4.5.2.1 Etapa E

As responsabilidades são

$$\gamma_{ij}^{(t)} = P(Z_{ij} = 1 \mid Y_i = y_i, \theta^{(t)})$$

com

$$\gamma_{ij}^{(t)} = \frac{\pi_j^{(t)} \phi_p(y_i; \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{\ell=1}^k \pi_\ell^{(t)} \phi_p(y_i; \mu_\ell^{(t)}, \Sigma_\ell^{(t)})}.$$

4.4.5.2.2 Etapa M

Defina

$$n_j^{(t)} = \sum_{i=1}^n \gamma_{ij}^{(t)}.$$

As atualizações são

$$\pi_j^{(t+1)} = \frac{n_j^{(t)}}{n},$$

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ij}^{(t)} y_i}{n_j^{(t)}},$$

e

$$\Sigma_j^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ij}^{(t)} (y_i - \mu_j^{(t+1)})(y_i - \mu_j^{(t+1)})^\top}{n_j^{(t)}}.$$

4.4.5.2.3 Implementação em R

O código a seguir implementa uma mistura normal univariada. As atualizações são as anteriores; a regularização mínima das variâncias e as verificações numéricas são decisões de implementação.

```
em_normal_1d <- function(y,
                          k = 2L,
                          tol = 1e-8,
                          max_iter = 1000L,
                          variancia_minima = 1e-8,
                          seed = 123L) {
  y <- as.numeric(y)

  if (length(y) < k) {
    stop("0 número de observações deve ser pelo menos igual a k.")
  }
  if (any(!is.finite(y))) {
    stop("Todas as observações devem ser finitas.")
  }
  if (k < 1L || k != as.integer(k)) {
    stop("k deve ser um inteiro positivo.")
  }

  set.seed(seed)
  n <- length(y)

  medias <- as.numeric(
    quantile(y, probs = seq(0.1, 0.9, length.out = k), names = FALSE)
  )
  variancias <- rep(max(var(y), variancia_minima), k)
  proporcoes <- rep(1 / k, k)

  loglik_anterior <- -Inf
  responsabilidades <- matrix(NA_real_, nrow = n, ncol = k)

  for (iteracao in seq_len(max_iter)) {
    log_componentes <- vapply(
      seq_len(k),
      function(j) {
        log(proporcoes[j]) +
          dnorm(y,
                mean = medias[j],
```



```

        sd = sqrt(variancias[j]),
        log = TRUE)
    },
    numeric(n)
)

max_linha <- apply(log_componentes, 1L, max)
exp_centrado <- exp(log_componentes - max_linha)
soma_exp <- rowSums(exp_centrado)
responsabilidades <- exp_centrado / soma_exp

loglik <- sum(max_linha + log(soma_exp))

tamanhos <- colSums(responsabilidades)
if (any(tamanhos <= .Machine$double.eps)) {
  stop("Um componente recebeu peso efetivo numericamente nulo.")
}

proporcoes <- tamanhos / n
medias <- colSums(responsabilidades * y) / tamanhos

for (j in seq_len(k)) {
  variancias[j] <- sum(
    responsabilidades[, j] * (y - medias[j])^2
  ) / tamanhos[j]
}
variancias <- pmax(variancias, variancia_minima)

if (is.finite(loglik_anterior)) {
  erro_relativo <- abs(loglik - loglik_anterior) /
    (1 + abs(loglik_anterior))
  if (erro_relativo < tol) {
    break
  }
}
loglik_anterior <- loglik
}

list(
  proporcoes = proporcoes,
  medias = medias,
  variancias = variancias,

```

```

    responsabilidades = responsabilidades,
    log_verossimilhanca = loglik,
    iteracoes = iteracao,
    convergiu = iteracao < max_iter
)
}

```

Observação computacional

O cálculo das responsabilidades foi realizado na escala logarítmica, com centralização pelo maior logaritmo em cada linha. Essa transformação reduz problemas de subfluxo numérico quando densidades gaussianas são muito pequenas. Trata-se de uma decisão de implementação autoral baseada na forma matemática das responsabilidades.

4.4.5.3 Distribuição exponencial com censura à direita

Exemplo 3 — tempos censurados

O exemplo é baseado em Ramachandran; Tsokos (2021, sec. 13.4).

Sejam $X_1, \dots, X_n$ tempos independentes com distribuição exponencial de taxa $\lambda > 0$:

$$f(x_i | \lambda) = \lambda e^{-\lambda x_i}, \quad x_i > 0.$$

Para cada indivíduo, observam-se

$$Y_i = \min(X_i, c_i)$$

e

$$\Delta_i = I(X_i \leq c_i).$$

Se todos os tempos fossem observados,

$$\ell_c(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n X_i.$$

Na etapa E,

$$E(X_i \mid Y_i, \Delta_i = 1, \lambda^{(t)}) = Y_i,$$

enquanto a falta de memória da distribuição exponencial fornece

$$E(X_i \mid X_i > c_i, \lambda^{(t)}) = c_i + \frac{1}{\lambda^{(t)}}.$$

Logo,

$$\tilde{T}^{(t)} = \sum_{i=1}^n \left[\Delta_i Y_i + (1 - \Delta_i) \left(c_i + \frac{1}{\lambda^{(t)}} \right) \right].$$

A etapa M produz

$$\lambda^{(t+1)} = \frac{n}{\tilde{T}^{(t)}}.$$

No ponto fixo, se $d = \sum_i \Delta_i$ é o número de falhas observadas,

$$\hat{\lambda} = \frac{d}{\sum_{i=1}^n Y_i},$$

que coincide com o estimador obtido diretamente da verossimilhança observada.

4.4.5.4 Dados normais ausentes e estatísticas suficientes

💡 Exemplo 4 — média e variância com observações ausentes

O exemplo computacional é adaptado da formulação de Ramachandran; Tsokos (2021, sec. 13.4).

Se $X_i \sim N(\mu, \sigma^2)$ e algumas observações estão ausentes, as estatísticas completas relevantes são

$$T_1 = \sum_{i=1}^n X_i \quad \text{e} \quad T_2 = \sum_{i=1}^n X_i^2.$$

Na iteração t , para cada observação ausente,

$$E(X_i \mid \mu^{(t)}, \sigma^{2(t)}) = \mu^{(t)}$$

e

$$E(X_i^2 \mid \mu^{(t)}, \sigma^{2(t)}) = \mu^{2(t)} + \sigma^{2(t)}.$$

As atualizações são

$$\mu^{(t+1)} = \frac{E(T_1 \mid Y, \theta^{(t)})}{n}$$

e

$$\sigma^{2(t+1)} = \frac{E(T_2 \mid Y, \theta^{(t)})}{n} - (\mu^{(t+1)})^2.$$

```
em_normal_ausentes <- function(y,
                                mu_inicial = NULL,
                                variancia_inicial = NULL,
                                tol = 1e-8,
                                max_iter = 1000L) {
  y <- as.numeric(y)
  observados <- y[!is.na(y)]

  if (length(observados) == 0L) {
    stop("É necessária ao menos uma observação disponível.")
  }

  n <- length(y)
  r <- length(observados)
  m <- n - r

  mu <- if (is.null(mu_inicial)) mean(observados) else mu_inicial
  variancia <- if (is.null(variancia_inicial)) {
    if (r > 1L) var(observados) else 1
  } else {
    variancia_inicial
  }

  if (!is.finite(mu) || !is.finite(variancia) || variancia <= 0) {
    stop("Valores iniciais inválidos.")
  }

  loglik_observada <- function(mu, variancia) {
```

```

    sum(dnorm(observados,
              mean = mu,
              sd = sqrt(variancia),
              log = TRUE))
}

historico <- data.frame(
  iteracao = integer(),
  mu = numeric(),
  variancia = numeric(),
  loglik = numeric()
)

loglik_anterior <- loglik_observada(mu, variancia)

for (iteracao in seq_len(max_iter)) {
  esperanca_t1 <- sum(observados) + m * mu
  esperanca_t2 <- sum(observados^2) + m * (mu^2 + variancia)

  mu_novo <- esperanca_t1 / n
  variancia_nova <- esperanca_t2 / n - mu_novo^2

  if (!is.finite(variancia_nova) || variancia_nova <= 0) {
    stop("A atualização produziu variância inválida.")
  }

  loglik_nova <- loglik_observada(mu_novo, variancia_nova)

  historico <- rbind(
    historico,
    data.frame(
      iteracao = iteracao,
      mu = mu_novo,
      variancia = variancia_nova,
      loglik = loglik_nova
    )
  )

  erro_relativo <- abs(loglik_nova - loglik_anterior) /
    (1 + abs(loglik_anterior))

  mu <- mu_novo

```

```

    variancia <- variancia_nova

    if (erro_relativo < tol) {
      break
    }
    loglik_anterior <- loglik_nova
  }

  list(
    mu = mu,
    variancia = variancia,
    historico = historico,
    iteracoes = iteracao,
    convergiu = iteracao < max_iter
  )
}

```

⚠ Interpretação do exemplo

O exemplo acima considera um mecanismo de ausência compatível com a formulação utilizada pela fonte. Em aplicações reais, a validade da análise depende da modelagem do processo que gerou os dados ausentes. Uma discussão completa dos mecanismos de ausência exige bibliografia específica e não é desenvolvida nesta seção.

4.4.6 Exercícios

Os exercícios são autorais ou adaptados das estruturas de problemas apresentadas nas fontes indicadas. Quando um enunciado deriva diretamente de uma fonte, isso é explicitado.

i Exercício 1 — dados observados e dados completos

Considere

$$f(y \mid \theta) = \pi f_1(y; \eta_1) + (1 - \pi) f_2(y; \eta_2).$$

1. Defina uma variável latente que identifique o componente de origem.
2. Escreva a densidade conjunta dos dados completos.
3. Obtenha a log-verossimilhança completa.
4. Explique por que essa expressão pode ser mais simples de maximizar do que a log-verossimilhança observada.

Fonte: elaborado com base em Hastie; Tibshirani; Friedman (2009) e Gupta; Chen

(2011).

i Exercício 2 — uma iteração para mistura normal

Considere

$$y = (0, 1, 4, 5)$$

e uma mistura de duas normais com variâncias conhecidas e iguais a 1. Utilize

$$\pi^{(0)} = 0,5, \quad \mu_1^{(0)} = 0, \quad \mu_2^{(0)} = 5.$$

1. Calcule as responsabilidades $\gamma_{i1}^{(0)}$ e $\gamma_{i2}^{(0)}$.
2. Calcule $\pi^{(1)}$, $\mu_1^{(1)}$ e $\mu_2^{(1)}$.
3. Interprete os valores obtidos.

Fonte: exercício autoral baseado nas atualizações de Hastie; Tibshirani; Friedman (2009) e Gupta; Chen (2011).

i Exercício 3 — restrição sobre os pesos

Mostre que

$$\pi_j^{(t+1)} = \frac{1}{n} \sum_{i=1}^n \gamma_{ij}^{(t)}$$

satisfaz

$$\sum_{j=1}^k \pi_j^{(t+1)} = 1.$$

Em seguida, derive a atualização por multiplicadores de Lagrange, maximizando

$$\sum_{j=1}^k n_j^{(t)} \log \pi_j$$

sob a restrição $\sum_j \pi_j = 1$.

Fonte: elaborado com base em Gupta; Chen (2011).

i Exercício 4 — monotonicidade

Demonstre que

$$\ell(\theta) - \ell(\theta^{(t)}) = Q(\theta \mid \theta^{(t)}) - Q(\theta^{(t)} \mid \theta^{(t)}) + D_{\text{KL}}[q_t \parallel f(z \mid y, \theta)].$$

Conclua que uma atualização que não diminui Q também não diminui a log-verossimilhança observada.

Fonte: adaptado da demonstração de Gupta; Chen (2011).

i Exercício 5 — exemplo multinomial clássico

Considere o modelo multinomial da Seção 5.1 e os dados observados

$$(y_1, y_2, y_3, y_4) = (125, 18, 20, 34).$$

1. Inicie o algoritmo em $\theta^{(0)} = 0,5$.
2. Calcule as cinco primeiras atualizações.
3. Obtenha numericamente o máximo direto da log-verossimilhança observada.
4. Compare o resultado direto com o limite do EM.

Fonte: adaptado das apresentações de Chihara; Hesterberg (2022) [sec. 13.8] e Gupta; Chen (2011, sec. 1.5).

i Exercício 6 — censura exponencial

Considere

$$(y_i, \delta_i) = (2, 1), (3, 0), (4, 1), (5, 0), (6, 1).$$

1. Inicie em $\lambda^{(0)} = 0,5$.
2. Calcule $\lambda^{(1)}$, $\lambda^{(2)}$ e $\lambda^{(3)}$.
3. Determine diretamente o estimador de máxima verossimilhança.
4. Compare o limite das iterações com o resultado analítico.

Fonte: exercício autoral baseado no exemplo de censura de Ramachandran; Tsokos (2021, sec. 13.4).

i Exercício 7 — inicializações múltiplas

Simule uma amostra de uma mistura de duas normais e execute o EM com pelo menos vinte inicializações.

1. Registre a log-verossimilhança final de cada execução.
2. Verifique se todas as execuções convergem para a mesma solução.
3. Compare médias, variâncias e pesos estimados.
4. Discuta por que a maior log-verossimilhança encontrada não constitui prova de otimalidade global.

Fonte: elaborado com base nas recomendações práticas de Gupta; Chen (2011).

i Exercício 8 — singularidade em misturas gaussianas

Fixe $\mu_1 = y_r$, mantenha $\pi_1 > 0$ e faça

$$\sigma_1^2 \rightarrow 0.$$

Mostre que a contribuição da observação y_r para a log-verossimilhança tende ao infinito. Explique por que esse resultado implica que o problema irrestrito pode não possuir estimador de máxima verossimilhança finito.

Fonte: adaptado da demonstração de Gupta; Chen (2011).

i Exercício 9 — GEM e MCEM

1. Mostre que o GEM preserva a monotonicidade quando aumenta a função Q em cada iteração.
2. Descreva como aproximar a etapa E por uma média de Monte Carlo.
3. Explique por que uma aproximação Monte Carlo com tamanho fixo pode introduzir oscilações na sequência de log-verossimilhanças.
4. Proponha uma estratégia em que o número de simulações aumente ao longo das iterações.

Fonte: elaborado com base em Gupta; Chen (2011) e Ramachandran; Tsokos (2021).

i Exercício 10 — propriedades do estimador e do algoritmo

Avalie as afirmações seguintes.

1. Se a log-verossimilhança aumenta em todas as iterações, o EM converge necessariamente para o máximo global.
2. Se a sequência de log-verossimilhanças converge, a sequência de parâmetros também converge.
3. Se o EM alcança um estimador regular de máxima verossimilhança, aplicam-se as propriedades assintóticas usuais desse estimador.
4. Duas inicializações diferentes sempre produzem a mesma estimativa.

5. A convergência computacional do EM implica consistência estatística.

Fonte: elaborado com base em Gupta; Chen (2011) e Lauritzen (2023).

4.4.7 Síntese

O algoritmo EM reorganiza um problema de máxima verossimilhança com dados incompletos em duas operações alternadas:

calcular esperanças condicionais associadas aos dados latentes

e

maximizar a log-verossimilhança completa esperada.

Sua principal garantia geral é a monotonicidade da log-verossimilhança observada. Suas principais vantagens são a simplicidade de muitas atualizações, o tratamento natural de restrições probabilísticas e a aplicabilidade a modelos de mistura, censura, dados ausentes e estados latentes. Suas limitações incluem dependência da inicialização, convergência potencialmente lenta, ausência de garantia de máximo global e possibilidade de degenerescência da verossimilhança.

O EM deve ser interpretado simultaneamente como um método de estimação por máxima verossimilhança com dados aumentados e como um algoritmo local de otimização.

Exercícios Complementares

1. Considere $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\mu^{-1})$. Defina $T = X_{(1)} = \min\{X_1, \dots, X_n\}$.
 - a. Determine o viés $B(T, \mu)$ e o erro quadrático médio $\text{EQM}(T)$.
 - b. Verifique se T é um estimador consistente para μ .
 - c. No caso de amostras grandes, você sugere a utilização de T como estimador de μ ? Caso contrário, proponha um estimador melhor e justifique.

Dica: Lembre-se que $f_T(t) = n[1 - F_X(t)]^{n-1}f_X(t)$ e $F_X(x) = 1 - e^{-\frac{x}{\mu}}$.

2. Seja $X_1, \dots, X_n$ uma amostra aleatória de tamanho n de uma distribuição de Bernoulli com parâmetro $\theta \in (0, 1)$. Seja $T(X) = \bar{X}_n^2$ o estimador de máxima verossimilhança de θ^2 . Considere o estimador Jackknife de θ^2 dado por:

$$T_J(X) = nT - \frac{n-1}{n} \sum_{i=1}^n T_{(i)},$$

em que $T_{(i)}$ representa o estimador T calculado com a amostra original excluindo a i -ésima observação.

- a. Mostre que o EMV de θ^2 é viesado.
- b. Mostre que $T_J(X)$ é não viesado.

Dica: Use o fato que $T_{(i)} = \left(\frac{n\bar{X} - X_i}{n-1}\right)^2$.

3. Sejam $Y_1, \dots, Y_n$ variáveis aleatórias independentes tais que $Y_i \sim \mathcal{N}(\alpha + \beta x_i, \sigma^2)$, em que os valores x_i são não estocásticos e satisfazem $\sum_{i=1}^n (x_i - \bar{x}_n)^2 > 0$. Mostre que

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^n (x_i - \bar{x}_n)^2}$$

e

$$\hat{\alpha} = \bar{Y}_n - \hat{\beta} \bar{x}_n$$

são estimadores não viesados de β e α , respectivamente.

4. Sejam $X_1, \dots, X_n$ uma amostra aleatória de uma variável com distribuição Rayleigh, cuja densidade é dada por:

$$f_X(x) = \frac{x}{\theta} \exp\left(-\frac{x^2}{2\theta}\right) I_{(0,\infty)}(x), \quad \theta > 0.$$

- a. Determine um estimador não viesado e consistente para θ .
b. Estime θ a partir da seguinte amostra (força vibratória de uma palheta de turbina):

16.88, 10.23, 4.59, 6.66, 13.68, 14.23, 19.87, 9.40, 6.51, 9.24, 12.20, 10.95.

5. Considere $X_1, \dots, X_n$ uma amostra aleatória de uma variável X com função densidade de probabilidade dada por:

$$f_X(x) = e^{-(x-\theta)} I_{[\theta,\infty)}(x).$$

- a. Determine um estimador não viesado de θ que seja função de $X_{(1)} = \min\{X_1, \dots, X_n\}$.
b. Mostre que $X_{(1)}$ é um estimador consistente de θ .

Referências

5 Estimação intervalar

A estimação pontual associa a cada amostra um único valor para representar um parâmetro desconhecido. Embora esse valor seja informativo, ele não expressa, por si só, a variabilidade amostral nem a precisão do procedimento de estimação. A estimação intervalar complementa a estimativa pontual por meio de um conjunto de valores compatíveis com os dados e com o modelo estatístico adotado.

No paradigma frequentista, o parâmetro é considerado fixo e desconhecido, enquanto os limites do intervalo são estatísticas e, portanto, variam de amostra para amostra. Essa distinção é essencial para a definição e a interpretação de intervalos de confiança (Cox, 2006, pp. 66–69; Rice, 2007, sec. 8.5.3).

! Observação — por que a estimativa pontual não é suficiente?

Em modelos contínuos, frequentemente ocorre $P_{\theta}(\hat{\theta} = \theta) = 0$. Essa afirmação, contudo, não é universal: em problemas discretos, um estimador pode coincidir com o parâmetro com probabilidade positiva. A motivação geral para a estimação intervalar não é a impossibilidade de acerto exato, mas a necessidade de quantificar a incerteza associada ao procedimento de estimação.

Objetivos do capítulo

Ao final deste capítulo, o leitor deverá ser capaz de:

1. definir conjuntos e intervalos de confiança por meio de sua função de cobertura;
2. interpretar corretamente o nível de confiança no paradigma frequentista;
3. construir intervalos exatos a partir de quantidades pivotais;
4. distinguir procedimentos exatos, conservadores e assintóticos;
5. aplicar intervalos normais, t , qui-quadrado, de Wilson e de Clopper–Pearson;
6. reconhecer as limitações dos intervalos de Wald e dos métodos bootstrap;
7. relacionar intervalos de confiança, testes de hipóteses, precisão e tamanho amostral.

5.1 Definição formal

Considere uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ cuja distribuição pertence a uma família $\{P_\theta : \theta \in \Theta\}$. Um **conjunto de confiança** é uma função $C(\mathbf{X})$ que associa a cada amostra um subconjunto aleatório de Θ .

Definição — conjunto de confiança

O conjunto $C(\mathbf{X})$ é um conjunto de confiança de nível **pelo menos** $1 - \alpha$ para θ quando

$$P_\theta\{\theta \in C(\mathbf{X})\} \geq 1 - \alpha, \quad \text{para todo } \theta \in \Theta.$$

Quando a igualdade vale para todo $\theta \in \Theta$, diz-se que o procedimento possui **cobertura exata**. Quando a igualdade vale apenas assintoticamente ou por aproximação, o intervalo é denominado **aproximado** ou **assintótico**. Se a cobertura é maior ou igual ao nível nominal, mas não necessariamente igual, o procedimento é chamado **conservador** (Lauritzen, 2023, sec. 6.2; Cox, 2006, sec. 5.4).

Para um parâmetro escalar, é comum escrever

$$C(\mathbf{X}) = [L(\mathbf{X}), U(\mathbf{X})],$$

em que L e U são, respectivamente, os limites inferior e superior de confiança. A função

$$c(\theta) = P_\theta\{L(\mathbf{X}) \leq \theta \leq U(\mathbf{X})\}$$

é denominada **função de cobertura** do procedimento. Em problemas discretos, pode ser impossível construir intervalos não aleatorizados com cobertura exatamente constante; nesses casos, intervalos denominados exatos são usualmente construídos para garantir cobertura de pelo menos $1 - \alpha$ e tendem a ser conservadores (Rasch; Schott, 2018, pp. 144–146).

5.2 Interpretação frequentista

Antes da observação da amostra, $L(\mathbf{X})$ e $U(\mathbf{X})$ são variáveis aleatórias. O nível de confiança descreve o desempenho do procedimento em repetições hipotéticas do experimento.

Interpretação correta

Um procedimento com cobertura exata de 95% produz intervalos que contêm o verdadeiro parâmetro em 95% das repetições, no longo prazo. Em um procedimento conservador de nível 95%, essa proporção é de pelo menos 95%. Em ambos os casos, a interpretação

pressupõe que o modelo e o plano amostral estejam corretamente especificados.

Depois de observados os dados, obtém-se um intervalo numérico $[l, u]$. Nesse momento, tanto θ quanto $[l, u]$ são fixos: o parâmetro pertence ou não pertence ao intervalo. Assim, no sentido frequentista estrito, não se deve afirmar

“A probabilidade de θ pertencer ao intervalo observado é 0,95.”

A expressão “estamos 95% confiantes” é uma forma abreviada de se referir à propriedade de cobertura do método empregado, e não a uma distribuição de probabilidade atribuída ao parâmetro (Cox, 2006, secs. 5.3–5.4; Chihara; Hesterberg, 2022, pp. 201–205).

Intervalo de confiança e intervalo de credibilidade

Um intervalo de credibilidade bayesiano é construído a partir da distribuição posterior do parâmetro e admite uma interpretação probabilística condicional aos dados e ao modelo bayesiano. Um intervalo de confiança frequentista é definido por sua cobertura sob amostragens repetidas. Os dois conceitos não são intercambiáveis, ainda que possam produzir limites numericamente semelhantes em alguns modelos.

5.3 Quantis e valores críticos

Se $Z \sim N(0, 1)$ e z_q denota o quantil de ordem q , então

$$P(Z \leq z_q) = q.$$

Pela simetria da distribuição normal padrão,

$$z_{\alpha/2} = -z_{1-\alpha/2}$$

e, portanto,

$$P(-z_{1-\alpha/2} \leq Z \leq z_{1-\alpha/2}) = 1 - \alpha.$$

Para $1 - \alpha = 0,95$, tem-se $z_{0,975} \approx 1,96$.




Figura 5.1: Região central de 95% da distribuição normal padrão.

5.4 Construção por quantidade pivotal

Uma das estratégias mais importantes para construir intervalos de confiança consiste em encontrar uma quantidade cuja distribuição não dependa de parâmetros desconhecidos.

i Definição — quantidade pivotal

Uma função dos dados e do parâmetro

$$Q = Q(\mathbf{X}, \theta)$$

é uma **quantidade pivotal** quando sua distribuição, sob P_θ , não depende de θ nem de outros parâmetros desconhecidos. Como Q depende de θ , ela não é, em geral, uma estatística no sentido estrito.

Se $q_{\alpha/2}$ e $q_{1-\alpha/2}$ são quantis da distribuição de Q , então

$$P_\theta(q_{\alpha/2} \leq Q(\mathbf{X}, \theta) \leq q_{1-\alpha/2}) = 1 - \alpha.$$

Resolvendo as desigualdades em relação a θ , obtêm-se os limites de confiança. O intervalo resultante não precisa ser simétrico, não precisa estar centrado em $\hat{\theta}$ e, em certos problemas,

nem sequer precisa conter o estimador de máxima verossimilhança (Lauritzen, 2023, sec. 6.2; Ramachandran; Tsokos, 2021, pp. 215–219).

5.4.1 Procedimento geral

1. Identifique o parâmetro de interesse e um estimador adequado.
2. Encontre uma quantidade pivotal $Q(\mathbf{X}, \theta)$.
3. Selecione quantis que concentrem probabilidade $1 - \alpha$.
4. Inverta as desigualdades para isolar θ .
5. Verifique se os limites pertencem ao espaço paramétrico.
6. Declare as hipóteses necessárias e interprete o resultado em termos do problema.

5.5 Intervalos para parâmetros da distribuição normal

5.5.1 Média com variância conhecida

Suponha que

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida. Como

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

segue que

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Logo, um intervalo exato de nível $1 - \alpha$ para μ é

$$\boxed{\bar{X} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}}.$$

Esse intervalo é exato sob normalidade. Se a população não for normal, a mesma expressão pode ser usada como aproximação quando a distribuição de $\bar{X}$ for adequadamente aproximada pela normal. Não existe um valor universal de n que garanta essa aproximação: a qualidade depende, entre outros fatores, da assimetria, do peso das caudas e da independência das observações (Rice, 2007, sec. 8.5.3; Chihara; Hesterberg, 2022, sec. 4.3.3).

i Exemplo — média com variância conhecida

Considere os dados

12, 15, 14, 10, 13, 16, 14, 15

provenientes de uma população normal com desvio-padrão conhecido $\sigma = 2,5$. Tem-se $n = 8$ e $\bar{x} = 13,625$. Para um intervalo de 95%,

$$13,625 \pm 1,96 \frac{2,5}{\sqrt{8}} = 13,625 \pm 1,732.$$

Portanto,

$$IC_{95\%}(\mu) = [11,893; 15,357].$$

Interpretação: o método utilizado tem cobertura de 95% sob o modelo normal com $\sigma = 2,5$.

Base metodológica: (Rice, 2007, pp. 279–281; Larsen; Marx, 2012, pp. 297–311).

```
import numpy as np
from scipy.stats import norm

x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
sigma = 2.5
alpha = 0.05

n = len(x)
xbar = x.mean()
z = norm.ppf(1 - alpha / 2)
me = z * sigma / np.sqrt(n)
intervalo = (xbar - me, xbar + me)

print(f"média = {xbar:.3f}")
print(f"IC 95% = ({intervalo[0]:.3f}, {intervalo[1]:.3f})")
```

```
média = 13.625
IC 95% = (11.893, 15.357)
```

5.5.2 Média com variância desconhecida

Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$$

com μ e σ^2 desconhecidos, então

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1},$$

em que

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Assim,

$$\boxed{\bar{X} \pm t_{1-\alpha/2, n-1} \frac{S}{\sqrt{n}}}$$

é um intervalo exato para μ sob normalidade (Lauritzen, 2023, ex. 6.5; Rice, 2007, pp. 279–280).

! Observação — não há regra universal como $n > 30$ ou $n > 200$

Para dados normais, o intervalo t é exato para qualquer $n \geq 2$. Para dados não normais, sua validade é aproximada e depende da distribuição e do plano amostral. Amostras grandes melhoram a aproximação em muitas situações, mas não corrigem viés de seleção, dependência, heterogeneidade não modelada ou caudas extremamente pesadas.

i Exemplo — média com variância desconhecida

Para os mesmos oito valores, $\bar{x} = 13,625$, $s = 1,923$ e $t_{0,975;7} = 2,365$. Logo,

$$IC_{95\%}(\mu) = 13,625 \pm 2,365 \frac{1,923}{\sqrt{8}} = [12,018; 15,232].$$

Base metodológica: (Lauritzen, 2023, ex. 6.5).

```
import numpy as np
from scipy.stats import t

x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
alpha = 0.05
```

```

n = len(x)
xbar = x.mean()
s = x.std(ddof=1)
tcrit = t.ppf(1 - alpha / 2, df=n - 1)
me = tcrit * s / np.sqrt(n)

print(f"IC 95% = ({xbar - me:.3f}, {xbar + me:.3f})")

```

IC 95% = (12.018, 15.232)

5.5.3 Variância de uma população normal

Sob normalidade,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Consequentemente, um intervalo exato de nível $1 - \alpha$ para σ^2 é

$$\left[\frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2} \right].$$

O intervalo para σ é obtido pela raiz quadrada dos limites. Como a distribuição qui-quadrado é assimétrica, o intervalo não é simétrico em torno de S^2 (Rice, 2007, pp. 280–281).

Condição de uso

O intervalo qui-quadrado para a variância é sensível a desvios de normalidade. Em aplicações, essa hipótese deve ser examinada com atenção; amostras grandes não tornam automaticamente esse procedimento robusto a caudas pesadas ou valores discrepantes.

Exemplo — intervalo para a variância

Para os oito valores anteriores, $s^2 = 3,696$ e $n - 1 = 7$. O intervalo de 95% para σ^2 é

$$IC_{95\%}(\sigma^2) = [1,616; 15,312].$$

Assim,

$$IC_{95\%}(\sigma) = [1,271; 3,913].$$

A assimetria dos limites reflete a assimetria da distribuição qui-quadrado.
Base metodológica: (Rice, 2007, pp. 280–281).

```
import numpy as np
from scipy.stats import chi2

x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
alpha = 0.05

n = len(x)
s2 = x.var(ddof=1)
df = n - 1

lim_inf = df * s2 / chi2.ppf(1 - alpha / 2, df)
lim_sup = df * s2 / chi2.ppf(alpha / 2, df)

print(f"IC 95% para sigma^2 = ({lim_inf:.3f}, {lim_sup:.3f})")
print(f"IC 95% para sigma   = ({np.sqrt(lim_inf):.3f}, {np.sqrt(lim_sup):.3f})")
```

IC 95% para sigma^2 = (1.616, 15.312)

IC 95% para sigma = (1.271, 3.913)

5.6 Exemplo de intervalo exato por pivô: distribuição exponencial

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda),$$

na parametrização por taxa, com densidade

$$f(x \mid \lambda) = \lambda e^{-\lambda x}, \quad x > 0.$$

Como

$$2\lambda \sum_{i=1}^n X_i \sim \chi_{2n}^2,$$

um intervalo exato de nível $1 - \alpha$ para λ é

$$\left[\frac{\chi_{\alpha/2, 2n}^2}{2 \sum_{i=1}^n X_i}, \frac{\chi_{1-\alpha/2, 2n}^2}{2 \sum_{i=1}^n X_i} \right].$$

i Exemplo adaptado — taxa exponencial

Para a amostra 2, 2,5, 3, 4 e 9, tem-se $n = 5$ e $\sum x_i = 20,5$. O intervalo exato de 95% é

$$IC_{95\%}(\lambda) = [0,079; 0,500].$$

Se o parâmetro de interesse for a média $\theta = 1/\lambda$, basta inverter os limites e trocar sua ordem:

$$IC_{95\%}(\theta) = \left[\frac{1}{0,500}, \frac{1}{0,079} \right] \approx [2,002; 12,627].$$

Fonte do exemplo e base metodológica: (Chihara; Hesterberg, 2022, pp. 202–204; Lauritzen, 2023, ex. 6.7).

5.7 Intervalos assintóticos e método de Wald

Suponha que um estimador satisfaça

$$\frac{\hat{\theta} - \theta}{\widehat{\text{EP}}(\hat{\theta})} \xrightarrow{d} N(0, 1).$$

Então, um intervalo de Wald de nível aproximadamente $1 - \alpha$ é

$$\hat{\theta} \pm z_{1-\alpha/2} \widehat{\text{EP}}(\hat{\theta}).$$

Para estimadores de máxima verossimilhança regulares,

$$\widehat{\text{EP}}(\hat{\theta}) \approx \frac{1}{\sqrt{nI(\hat{\theta})}},$$

em que $I(\theta)$ é a informação de Fisher por observação. A validade dessa aproximação depende das condições de regularidade: o parâmetro deve estar no interior do espaço paramétrico, o modelo deve ser identificável, a informação deve ser finita e positiva e a aproximação normal deve ser adequada (Rice, 2007, secs. 8.5.2–8.5.3; Lauritzen, 2023, sec. 6.4.3).

⚠ Limitações do intervalo de Wald

O intervalo de Wald pode apresentar cobertura insatisfatória em amostras pequenas, perto das fronteiras do espaço paramétrico, para distribuições muito assimétricas ou quando o erro-padrão varia fortemente com o parâmetro. Além disso, ele não é invariável a reparametrizações não lineares: construir um intervalo para θ e transformá-lo pode produzir resultado diferente de construir diretamente um intervalo para $g(\theta)$. Intervalos de razão de verossimilhanças, de escore ou baseados em transformações podem ser preferíveis.

5.7.1 Exemplo: média de uma distribuição de Poisson

Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda),$$

então $\hat{\lambda} = \bar{X}$ e

$$\text{Var}(\hat{\lambda}) = \frac{\lambda}{n}.$$

Substituindo λ por $\hat{\lambda}$, obtém-se

$$\boxed{\bar{X} \pm z_{1-\alpha/2} \sqrt{\frac{\bar{X}}{n}}}.$$

Esse intervalo é aproximado. Se o limite inferior for negativo, truncá-lo em zero respeita o espaço paramétrico, mas não corrige necessariamente a função de cobertura. Para contagens pequenas, métodos exatos ou baseados na razão de verossimilhanças são mais apropriados (Rice, 2007, pp. 282–283).

5.8 Intervalos para uma proporção binomial

Se $X \sim \text{Binomial}(n, p)$, então

$$\hat{p} = \frac{X}{n}.$$

5.8.1 Intervalo de Wald

A substituição de p por $\hat{p}$ no erro-padrão produz

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

Embora simples, esse intervalo pode apresentar cobertura muito inferior à nominal, produzir limites fora de $[0, 1]$ e degenerar quando $x = 0$ ou $x = n$. Regras como $n\hat{p} \geq 5$ e $n(1-\hat{p}) \geq 5$ são apenas diagnósticos aproximados e não garantem boa cobertura, sobretudo quando p está próximo de 0 ou 1 (Ramachandran; Tsokos, 2009, pp. 302–304; Chihara; Hesterberg, 2022, pp. 211–215).

5.8.2 Intervalo de Wilson ou de escore

Se $z = z_{1-\alpha/2}$, o intervalo de Wilson é

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}.$$

Esse intervalo resulta da inversão do teste de escore e, em geral, apresenta desempenho de cobertura superior ao intervalo de Wald. Seu centro não é exatamente $\hat{p}$, especialmente em amostras pequenas (Chihara; Hesterberg, 2022, secs. 7.4–7.4.1).

5.8.3 Intervalo exato de Clopper–Pearson

Para $0 < x < n$, o intervalo bilateral de caudas iguais pode ser escrito por quantis beta:

$$L = B_{\alpha/2}^{-1}(x, n - x + 1)$$

e

$$U = B_{1-\alpha/2}^{-1}(x + 1, n - x),$$

em que $B_q^{-1}(a, b)$ é o quantil de ordem q da distribuição beta com parâmetros a e b . Para $x = 0$, define-se $L = 0$; para $x = n$, define-se $U = 1$.

O método garante cobertura de pelo menos $1 - \alpha$, mas, por causa da natureza discreta da distribuição binomial, costuma ser conservador e produzir intervalos mais longos (Rasch; Schott, 2018, pp. 145–146; Rosner, 2011, pp. 186–188).

i Exemplo — comparação de intervalos para uma proporção

Considere $x = 12$ sucessos em $n = 50$ ensaios, de modo que $\hat{p} = 0,24$. Para 95% de confiança:

- Wald: $[0,122; 0,358]$;
- Wilson: $[0,143; 0,374]$;
- Clopper–Pearson: $[0,131; 0,382]$.

Os resultados ilustram que métodos diferentes podem ter centros, amplitudes e propriedades de cobertura distintos.

Base metodológica: (Chihara; Hesterberg, 2022, secs. 7.4–7.4.1; Rasch; Schott, 2018, pp. 145–146; Rosner, 2011, pp. 186–188).

```
from statsmodels.stats.proportion import proportion_confint

x = 12
n = 50
alpha = 0.05

for metodo in ["normal", "wilson", "beta", "agresti_coull"]:
    li, ls = proportion_confint(x, n, alpha=alpha, method=metodo)
    print(f"{metodo:14s}: ({li:.3f}, {ls:.3f})")
```

```
normal          : (0.122, 0.358)
wilson          : (0.143, 0.374)
beta            : (0.131, 0.382)
agresti_coull   : (0.142, 0.376)
```

5.9 Intervalos unilaterais

Em algumas aplicações, interessa apenas estabelecer um limite superior ou inferior. Um limite inferior de confiança de nível $1 - \alpha$ é uma estatística $L(\mathbf{X})$ tal que

$$P_{\theta}\{L(\mathbf{X}) \leq \theta\} \geq 1 - \alpha.$$

Analogamente, um limite superior $U(\mathbf{X})$ satisfaz

$$P_{\theta}\{\theta \leq U(\mathbf{X})\} \geq 1 - \alpha.$$

Para a média normal com variância desconhecida, os intervalos unilaterais são

$$\left[\bar{X} - t_{1-\alpha, n-1} \frac{S}{\sqrt{n}}, \infty \right)$$

e

$$\left(-\infty, \bar{X} + t_{1-\alpha, n-1} \frac{S}{\sqrt{n}} \right].$$

Intervalos unilaterais devem ser escolhidos antes da inspeção dos dados, em consonância com a pergunta científica (Chihara; Hesterberg, 2022, pp. 209–211).

5.10 Dualidade entre intervalos de confiança e testes de hipóteses

Considere uma família de testes bilaterais de nível α para

$$H_0 : \theta = \theta_0.$$

O conjunto de todos os valores de θ_0 que não são rejeitados constitui um conjunto de confiança de nível $1 - \alpha$:

$$C(\mathbf{x}) = \{\theta_0 : H_0 : \theta = \theta_0 \text{ não é rejeitada}\}.$$

Essa operação é denominada **inversão de testes**. No caso da média normal com variância conhecida, o teste bilateral rejeita $H_0 : \mu = \mu_0$ quando

$$\left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| > z_{1-\alpha/2}.$$

Os valores não rejeitados de μ_0 satisfazem

$$\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu_0 \leq \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}},$$

que é precisamente o intervalo de confiança correspondente (Rice, 2007, sec. 9.3).

! Consequência

Para um teste bilateral e um intervalo obtidos pela inversão da mesma família de testes, $H_0 : \theta = \theta_0$ é rejeitada ao nível α se, e somente se, θ_0 não pertence ao conjunto de confiança de nível $1 - \alpha$.

5.11 Amplitude, precisão e tamanho amostral

Para um intervalo simétrico da forma

$$\hat{\theta} \pm c \widehat{\text{EP}}(\hat{\theta}),$$

sua amplitude é

$$2c \widehat{\text{EP}}(\hat{\theta}).$$

Três relações gerais são importantes:

- aumentando o nível de confiança, aumenta-se o valor crítico e, em geral, a amplitude;
- aumentando a variabilidade dos dados, aumenta-se o erro-padrão e a amplitude;
- aumentando o tamanho da amostra, o erro-padrão frequentemente diminui na ordem de $n^{-1/2}$.

Para a média com σ conhecida, se a margem de erro desejada é no máximo E , então

$$E \geq z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

implica

$$\boxed{n \geq \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2}.$$

O resultado deve ser arredondado para o inteiro imediatamente superior (Chihara; Hesterberg, 2022, p. 215; Larsen; Marx, 2012, pp. 310–311).

Para uma proporção, usando a aproximação de Wald,

$$n \geq \frac{z_{1-\alpha/2}^2 p(1-p)}{E^2}.$$

Quando não existe estimativa preliminar de p , utiliza-se $p = 0,5$, que maximiza $p(1 - p)$ e fornece o tamanho amostral mais conservador **dentro da aproximação de Wald** (Chihara; Hesterberg, 2022, p. 215).

 Precisão não elimina viés

Aumentar n reduz o erro aleatório, mas não corrige amostragem não representativa, não resposta informativa, mensuração enviesada, dependência ignorada ou especificação inadequada do modelo. Um intervalo estreito pode ser sistematicamente incorreto.

5.12 Cobertura por simulação

A interpretação frequentista pode ser visualizada repetindo-se a amostragem e a construção do intervalo. Na figura a seguir, são gerados 100 intervalos de 95% para a média de uma população normal. Em uma repetição particular, a proporção de cobertura não precisa ser exatamente 0,95, mas tende a se aproximar desse valor quando o número de repetições aumenta (Rice, 2007, p. 281; Chihara; Hesterberg, 2022, pp. 223–224).

5.13 Métodos bootstrap

Quando a distribuição amostral do estimador é difícil de obter, o bootstrap pode aproximá-la por reamostragem com reposição da distribuição empírica. Entre os procedimentos mais comuns estão:

- o intervalo percentil, cujos limites são quantis das estimativas bootstrap;
- o intervalo baseado em erro-padrão bootstrap;
- o intervalo bootstrap- t , que aproxima a distribuição de uma estatística studentizada.

O intervalo percentil é simples, mas pode apresentar problemas em presença de viés ou assimetria. Em muitos problemas regulares, o bootstrap- t apresenta melhor acurácia de cobertura, embora exija a estimação do erro-padrão em cada reamostra e possa ser computacionalmente mais oneroso. Essa superioridade não é universal. Em amostras muito pequenas, a distribuição empírica pode representar inadequadamente a população; o bootstrap não substitui condições de identificação, independência ou qualidade do plano amostral (Chihara; Hesterberg, 2022, secs. 7.5.1–7.5.3).

 Algoritmo — intervalo percentil bootstrap

Para estimar um parâmetro θ por $\hat{\theta} = s(\mathbf{X})$:




Figura 5.2: Simulação de intervalos de 95% para uma média normal.

1. obtenha B amostras bootstrap de tamanho n por reamostragem com reposição;
2. calcule $\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}$;
3. use os quantis empíricos de ordens $\alpha/2$ e $1 - \alpha/2$ como limites.

```
import numpy as np

rng = np.random.default_rng(2026)
x = np.array([12, 15, 14, 10, 13, 16, 14, 15])
B = 10000
alpha = 0.05

medianas_boot = np.empty(B)
for b in range(B):
    xb = rng.choice(x, size=len(x), replace=True)
    medianas_boot[b] = np.median(xb)

li, ls = np.quantile(medianas_boot, [alpha / 2, 1 - alpha / 2])
print(f"IC percentil bootstrap para a mediana: ({li:.3f}, {ls:.3f})")
```

IC percentil bootstrap para a mediana: (12.000, 15.000)

5.14 Intervalo de confiança não é intervalo de predição

Um intervalo de confiança para uma média descreve a incerteza sobre o parâmetro μ . Um intervalo de predição descreve a incerteza sobre uma nova observação X_{n+1} e, portanto, inclui tanto a incerteza na estimação de μ quanto a variabilidade individual.

Para uma amostra normal com σ^2 desconhecida, um intervalo de predição para uma nova observação é

$$\bar{X} \pm t_{1-\alpha/2, n-1} S \sqrt{1 + \frac{1}{n}},$$

que é mais amplo do que o intervalo de confiança para μ :

$$\bar{X} \pm t_{1-\alpha/2, n-1} \frac{S}{\sqrt{n}}.$$

Confundir os dois intervalos leva a subestimar a variabilidade de observações futuras (Larsen; Marx, 2012, sec. 11.3.8).

5.15 Roteiro para construção e apresentação

Ao apresentar um intervalo de confiança, recomenda-se informar:

1. o parâmetro e a população de interesse;
2. o estimador e o método de construção;
3. o nível de confiança;
4. as hipóteses do modelo e do plano amostral;
5. os limites numéricos e, quando pertinente, a margem de erro;
6. uma interpretação contextual;
7. limitações relevantes, como pequena amostra, assimetria, dependência ou proximidade de fronteiras paramétricas.

Modelo de redação

“Com base em um intervalo t bilateral de 95%, estima-se que a média populacional esteja entre 12,02 e 15,23. Essa conclusão pressupõe observações independentes e uma população aproximadamente normal. O nível de 95% refere-se à cobertura do procedimento em repetições do processo amostral.”

5.16 Síntese dos principais procedimentos

Parâmetro	Hipóteses principais	Procedimento	Natureza
μ, σ conhecida	amostra normal	normal padrão	exato
μ, σ desconhecida	amostra normal	t de Student	exato
σ^2	amostra normal	qui-quadrado	exato
taxa exponencial λ	amostra exponencial	pivô qui-quadrado	exato
	iid		
proporção p	amostra binomial	Wilson	aproximado, geralmente preferível ao Wald
proporção p	amostra binomial	Clopper–Pearson	exato conservador
parâmetro regular θ	condições assintóticas	Wald	aproximado
parâmetro geral	reamostragem representativa	bootstrap	aproximado

5.17 Exercícios

i Exercício 1 — interpretação

Um pesquisador obteve o intervalo $[18,4; 22,7]$ para uma média populacional com nível de confiança de 95%.

1. Explique por que a frase “há 95% de probabilidade de a média estar no intervalo” não é uma interpretação frequentista estrita.
2. Escreva uma interpretação adequada do procedimento.
3. Explique quais aspectos da conclusão dependem do modelo e do plano amostral.

Exercício baseado em: (Cox, 2006, pp. 66–69; Chihara; Hesterberg, 2022, pp. 201–205).

i Exercício 2 — média com variância conhecida

Uma amostra normal de tamanho $n = 36$ apresentou média $\bar{x} = 50$. Suponha $\sigma = 9$ conhecida.

1. Construa intervalos de 90%, 95% e 99% para μ .
2. Compare suas amplitudes.
3. Determine o tamanho amostral necessário para uma margem de erro máxima de 2 unidades em um intervalo de 95%.

Exercício baseado em: (Larsen; Marx, 2012, pp. 297–311).

i Exercício 3 — média com variância desconhecida

Considere uma amostra normal com $n = 25$, $\bar{x} = 4,2$ e $s^2 = 1,44$.

1. Construa um intervalo de 95% para μ .
2. Compare-o com o intervalo que seria obtido substituindo o quantil t por 1,96.
3. Explique por que o intervalo normal é mais estreito.

Exercício baseado em: (Lauritzen, 2023, ex. 6.5; Rice, 2007, pp. 279–280).

i Exercício 4 — variância normal

Uma amostra normal de tamanho $n = 20$ apresentou variância amostral $s^2 = 16$.

1. Construa um intervalo de 95% para σ^2 .

2. Obtenha o intervalo correspondente para σ .
3. Verifique que o intervalo para σ^2 não é simétrico em torno de s^2 .
4. Discuta a sensibilidade do procedimento à hipótese de normalidade.

Base metodológica: (Rice, 2007, pp. 280–281).

i Exercício 5 — quantidade pivotal exponencial

Sejam $X_1, \dots, X_n$ iid com distribuição exponencial de taxa λ .

1. Demonstre que $2\lambda \sum_i X_i$ é uma quantidade pivotal.
2. Derive um intervalo bilateral de nível $1 - \alpha$ para λ .
3. Transforme o intervalo para a média $\theta = 1/\lambda$.
4. Aplique o resultado à amostra 1,1, 0,8, 2,4, 0,6, 1,5 e 3,0.

Exercício baseado em: (Lauritzen, 2023, ex. 6.7).

i Exercício 6 — intervalo de Wald para Poisson

Considere as contagens 4, 6, 7, 9, 10 e 13, modeladas como iid $\text{Poisson}(\lambda)$.

1. Calcule $\hat{\lambda}$ e seu erro-padrão estimado.
2. Construa um intervalo de Wald de 95%.
3. Discuta se a aproximação normal parece razoável.
4. Explique por que a simples truncagem de um limite negativo em zero não garante cobertura nominal.

Exercício baseado em: (Rice, 2007, pp. 282–283).

i Exercício 7 — proporção binomial

Em $n = 40$ ensaios, foram observados $x = 4$ sucessos.

1. Calcule o intervalo de Wald de 95%.
2. Calcule os intervalos de Wilson e Clopper–Pearson com auxílio de software.
3. Compare os limites e as amplitudes.
4. Justifique qual método você reportaria e quais limitações registraria.

Base metodológica: (Chihara; Hesterberg, 2022, secs. 7.4–7.4.1; Rasch; Schott, 2018, pp. 145–146; Rosner, 2011, pp. 186–188).

i Exercício 8 — intervalo unilateral

Uma amostra normal de tamanho $n = 15$ apresentou $\bar{x} = 120$ e $s = 18$. Construa um limite superior de confiança de 99% para μ . Explique em que tipo de pergunta científica um limite unilateral seria mais apropriado que um intervalo bilateral.

Exercício baseado em: (Chihara; Hesterberg, 2022, pp. 209–211).

i Exercício 9 — dualidade

Considere o teste bilateral de $H_0 : \mu = \mu_0$ para uma amostra normal com variância conhecida.

1. Escreva a região de não rejeição a nível α .
2. Inverta a região para obter o conjunto dos valores de μ_0 não rejeitados.
3. Mostre que o conjunto coincide com o intervalo normal de nível $1 - \alpha$.

Exercício baseado em: (Rice, 2007, sec. 9.3).

i Exercício 10 — cobertura por simulação

Implemente uma simulação com 10 000 repetições para estimar a cobertura dos seguintes procedimentos:

1. intervalo t para a média quando os dados são normais;
2. intervalo t para a média quando os dados são exponenciais, para $n = 10, 30$ e 100 ;
3. intervalos de Wald e Wilson para uma proporção com $n = 20$ e $p \in \{0,05, 0,20, 0,50\}$.

Compare a cobertura estimada com o nível nominal de 95% e interprete os resultados.

Exercício baseado em: (Chihara; Hesterberg, 2022, pp. 223–224; Ramachandran; Tsokos, 2021, pp. 248–250).

5.18 Gabarito sucinto

1. O nível de confiança é propriedade do procedimento; após a amostra, o intervalo e o parâmetro são fixos.
2. Use $\bar{x} \pm z_{1-\alpha/2}\sigma/\sqrt{n}$; para a parte 3, arredonde para cima $n \geq (z_{0,975}9/2)^2$.
3. Use $t_{0,975;24}$ e $s = 1,2$; o intervalo z ignora a incerteza adicional da estimação de σ .
4. Use os quantis $\chi_{0,025;19}^2$ e $\chi_{0,975;19}^2$; obtenha o intervalo para σ tomando raízes quadradas.
5. Use $2\lambda \sum_i X_i \sim \chi_{2n}^2$ e inverta os limites para $\theta = 1/\lambda$.
6. $\hat{\lambda} = \bar{x}$ e $\widehat{\text{EP}} = \sqrt{\bar{x}/n}$.

7. O Wald tende a ser inadequado com poucos sucessos; Wilson e Clopper–Pearson respeitam melhor a estrutura binomial, com o último geralmente mais conservador.
8. Use $\bar{x} + t_{0,99;14}s/\sqrt{n}$ como limite superior.
9. A inversão produz $\bar{X} \pm z_{1-\alpha/2}\sigma/\sqrt{n}$.
10. Espera-se boa cobertura do intervalo t sob normalidade; assimetria e fronteiras podem degradar a cobertura de métodos aproximados, especialmente para amostras pequenas.

Referências

6 Testes de Hipóteses e Análise de Dados Categóricos

Os testes de hipóteses fornecem regras para avaliar a compatibilidade entre os dados e afirmações sobre um modelo estatístico, controlando probabilidades de erro previamente especificadas. Este capítulo articula a formulação frequentista dos testes, os princípios de optimalidade de Neyman–Pearson, os testes da razão de verossimilhanças, os procedimentos usuais para parâmetros populacionais e a análise de contagens categóricas (Casella; Berger, 2002, cap. 8; Lauritzen, 2023, cap. 7; Rice, 2007, cap. 9).

6.1 Objetivos de aprendizagem

Ao final deste capítulo, o leitor deverá ser capaz de:

1. formular hipóteses estatísticas simples e compostas;
2. definir formalmente região crítica, função de teste, tamanho, nível, função poder e erros dos tipos I e II;
3. calcular e interpretar corretamente o valor- p ;
4. aplicar o lema de Neyman–Pearson na construção de testes mais poderosos;
5. caracterizar testes uniformemente mais poderosos em famílias com razão de verossimilhanças monótona;
6. construir e interpretar testes da razão de verossimilhanças;
7. selecionar testes para médias, proporções e comparações entre duas populações;
8. aplicar testes qui-quadrado de aderência, homogeneidade e independência;
9. reconhecer situações em que testes exatos, de permutação ou procedimentos robustos são preferíveis;
10. distinguir significância estatística, magnitude do efeito e relevância científica.

6.2 Motivação: uma moeda aparentemente honesta

Considere 100 lançamentos independentes de uma moeda. Seja X o número de caras observadas. Sob a hipótese de que a moeda é honesta,

$$H_0 : p = 0,5,$$

tem-se

$$X \sim \text{Bin}(100, 0,5).$$

Suponha que tenham sido observadas 99 caras.

i Interpretação unilateral

Quando a suspeita científica é especificamente de favorecimento de caras,

$$H_1 : p > 0,5,$$

o resultado observado é avaliado pela cauda superior:

$$P_{0,5}(X \geq 99) = \frac{101}{2^{100}} \approx 7,97 \times 10^{-29}.$$

i Interpretação bilateral

Quando a hipótese alternativa é apenas que a moeda não é honesta,

$$H_1 : p \neq 0,5,$$

devem ser considerados desvios nas duas direções. Pela simetria da distribuição binomial,

$$P_{0,5}(X \geq 99 \text{ ou } X \leq 1) = \frac{202}{2^{100}} \approx 1,59 \times 10^{-28}.$$

Em ambos os casos, o resultado é extremamente incompatível com o modelo de moeda honesta. A conclusão não decorre de uma “prova” de que H_0 seja falsa, mas da aplicação de uma regra inferencial cujo comportamento é avaliado sob repetições do experimento. Em particular, o nível do teste controla a frequência de rejeições incorretas quando H_0 é verdadeira (Casella; Berger, 2002, secs. 8.1 e 8.3.1; Cox, 2006, secs. 3.2 e 5.4; Lauritzen, 2023, secs. 7.1–7.3).

6.3 Formulação estatística do problema

Considere um modelo estatístico

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\},$$

em que θ é um parâmetro desconhecido. Um problema de teste de hipóteses divide o espaço paramétrico em dois subconjuntos disjuntos (Casella; Berger, 2002, sec. 8.1; Lauritzen, 2023, sec. 7.2):

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta_1,$$

com $\Theta_1 = \Theta \setminus \Theta_0$.

i Definição: hipóteses simples e compostas

Uma hipótese é **simples** quando determina completamente a distribuição dos dados. Por exemplo,

$$H_0 : p = 0,5$$

é simples no modelo binomial com n conhecido.

Uma hipótese é **composta** quando contém mais de uma distribuição possível. Por exemplo,

$$H_1 : p > 0,5$$

é composta, pois inclui todos os valores $p \in (0,5, 1]$.

A escolha de qual afirmação deve ocupar o papel de hipótese nula não é puramente algébrica. Ela depende do objetivo científico, das consequências das decisões e da estrutura do modelo. Em muitos estudos, H_0 representa ausência de efeito, um modelo mais restritivo ou uma afirmação cuja rejeição incorreta deve ser controlada (Casella; Berger, 2002, sec. 8.1; Rice, 2007, secs. 9.1–9.2.2).

6.3.1 Função de teste e região crítica

i Definição: função de teste

Uma função de teste é uma função mensurável

$$\varphi : \mathcal{X} \longrightarrow [0, 1].$$

Para uma amostra observada $X = x$:

- $\varphi(x) = 1$ significa rejeitar H_0 ;
- $\varphi(x) = 0$ significa não rejeitar H_0 ;
- $0 < \varphi(x) < 1$ representa um teste aleatorizado, no qual H_0 é rejeitada com probabilidade $\varphi(x)$.

Nos testes não aleatorizados, $\varphi(x) \in \{0, 1\}$ e a **região crítica** é

$$C = \{x \in \mathcal{X} : \varphi(x) = 1\}.$$

Testes aleatorizados aparecem naturalmente em modelos discretos quando não é possível obter exatamente um tamanho prescrito apenas com uma região crítica determinística. Em aplicações, costuma-se preferir testes não aleatorizados e reportar o tamanho efetivamente alcançado (Casella; Berger, 2002, secs. 8.2–8.3; Rasch; Schott, 2018, secs. 3.1–3.3).

6.3.2 Função poder, tamanho e nível

i Definição: função poder

A função poder de um teste φ é

$$\pi_{\varphi}(\theta) = E_{\theta}[\varphi(X)] = P_{\theta}(\text{rejeitar } H_0).$$

O comportamento desejável é:

- $\pi_{\varphi}(\theta)$ pequena para $\theta \in \Theta_0$;
- $\pi_{\varphi}(\theta)$ grande para $\theta \in \Theta_1$.

i Definição: tamanho e nível

O **tamanho** do teste é

$$\alpha_{\varphi} = \sup_{\theta \in \Theta_0} \pi_{\varphi}(\theta).$$

Dizemos que φ é um teste de **nível** α quando

$$\sup_{\theta \in \Theta_0} \pi_{\varphi}(\theta) \leq \alpha.$$

Quando a igualdade é satisfeita, o teste tem tamanho α .

Essa distinção é relevante em hipóteses nulas compostas: o nível α constitui um limite superior uniforme para a probabilidade de rejeição incorreta em todos os valores de θ permitidos por H_0 (Casella; Berger, 2002, sec. 8.3.1; Lauritzen, 2023, secs. 7.1–7.3).

6.3.3 Erros dos tipos I e II

Estado verdadeiro	Não rejeitar H_0	Rejeitar H_0
$\theta \in \Theta_0$	decisão correta	erro do tipo I
$\theta \in \Theta_1$	erro do tipo II	decisão correta

A probabilidade do erro do tipo I, em um ponto $\theta \in \Theta_0$, é

$$P_\theta(\text{rejeitar } H_0) = \pi_\varphi(\theta).$$

Para $\theta \in \Theta_1$, a probabilidade do erro do tipo II é

$$\beta_\varphi(\theta) = P_\theta(\text{não rejeitar } H_0) = 1 - \pi_\varphi(\theta).$$

Portanto, o poder no ponto $\theta \in \Theta_1$ é $1 - \beta_\varphi(\theta)$.

Observação

O valor β não é, em geral, uma constante única. Ele depende do valor verdadeiro do parâmetro sob a alternativa. Por isso, o planejamento amostral deve especificar uma diferença mínima ou um valor alternativo de interesse.

6.4 Valor- p

Considere uma estatística de teste $T = T(X)$ construída de modo que valores grandes sejam mais incompatíveis com H_0 . Para uma hipótese nula simples $H_0 : \theta = \theta_0$, o valor- p observado é

$$p(x) = P_{\theta_0}\{T(X) \geq T(x)\}.$$

Para uma hipótese nula composta, uma construção conservadora que garante validade uniforme é

$$p(x) = \sup_{\theta \in \Theta_0} P_\theta\{T(X) \geq T(x)\}.$$

Outras construções de valores- p são possíveis, especialmente quando existe uma estatística condicionante, um parâmetro de perturbação ou uma estrutura discreta. Em todos os casos, a propriedade essencial de validade é

$$P_{\theta}\{p(X) \leq u\} \leq u, \quad 0 \leq u \leq 1, \quad \theta \in \Theta_0.$$

Em testes bilaterais, a noção de resultado “tão ou mais extremo” deve ser determinada pela estatística bilateral escolhida, como $|Z|$, T^2 ou $-2 \log \Lambda$.

i Interpretação

O valor- p quantifica a incompatibilidade dos dados com H_0 segundo um procedimento de teste especificado. Valores pequenos indicam que a estatística observada se encontra em uma região rara da distribuição nula.

! O que o valor- p não representa

O valor- p não é:

- a probabilidade de H_0 ser verdadeira;
- a probabilidade de a decisão estar errada;
- uma medida da magnitude do efeito;
- uma garantia de relevância científica, clínica ou prática.

Sob uma hipótese nula simples e para um teste contínuo exatamente calibrado, o valor- p possui distribuição uniforme em $(0, 1)$. Em problemas discretos ou sob hipóteses nulas compostas, ele pode ser apenas **superuniforme**, isto é,

$$P_{\theta}\{p(X) \leq \alpha\} \leq \alpha, \quad \theta \in \Theta_0.$$

A igualdade ocorre no caso contínuo exatamente calibrado; a desigualdade corresponde a um procedimento conservador. Essa propriedade conecta diretamente o valor- p à regra de decisão de nível α (Casella; Berger, 2002, sec. 8.3.4; Cox, 2006, sec. 3.2; Rice, 2007, sec. 9.2.1; Lauritzen, 2023, secs. 7.3 e 7.7).

6.4.1 Regra de decisão

Após fixar α antes de examinar os resultados:

$$\begin{cases} p \leq \alpha & \implies \text{rejeitar } H_0, \\ p > \alpha & \implies \text{não rejeitar } H_0. \end{cases}$$

A forma “não rejeitar H_0 ” é preferível a “aceitar H_0 ”, pois um resultado não significativo pode decorrer de baixo poder, grande variabilidade ou tamanho amostral insuficiente. Em

procedimentos discretos, a convenção de igualdade no ponto de corte deve ser compatível com a definição do valor- p e com a região crítica.

6.5 Procedimento recomendado

Um teste de hipóteses deve ser conduzido na seguinte ordem:

1. definir a população, o modelo e o parâmetro de interesse;
2. formular H_0 e H_1 antes de examinar os resultados;
3. escolher uma estatística cuja distribuição sob H_0 seja conhecida ou aproximável;
4. fixar o nível α e, no planejamento, o poder desejado;
5. verificar pressupostos e o delineamento amostral;
6. calcular a estatística, o valor- p e uma estimativa do efeito;
7. apresentar a conclusão no contexto científico;
8. reportar limitações, incerteza e sensibilidade a pressupostos.

6.6 Exemplo motivacional

Considere um programa educacional fictício. A média de referência é $\mu_0 = 662$, o desvio-padrão populacional é tratado como conhecido, $\sigma = 131$, e uma amostra aleatória de $n = 100$ participantes apresentou média $\bar{x} = 696$. Deseja-se testar

$$H_0 : \mu \leq 662 \quad \text{versus} \quad H_1 : \mu > 662.$$

A estatística é

$$Z = \frac{\bar{X} - 662}{131/\sqrt{100}}.$$

Para os dados observados,

$$z_{\text{obs}} = \frac{696 - 662}{13,1} \approx 2,595.$$

Como a probabilidade de rejeição é máxima na fronteira $\mu = 662$ da hipótese nula composta, o valor- p é

$$p = \sup_{\mu \leq 662} P_{\mu}(Z \geq z_{\text{obs}}) = P_{662}(Z \geq 2,595) \approx 0,0047.$$

Ao nível de 5%, rejeita-se H_0 . Os dados fornecem evidência de que a média dos participantes excede 662 no modelo adotado.

Limitação causal

Esse teste compara médias, mas não estabelece por si só que o programa causou o aumento. Uma conclusão causal exige delineamento adequado, como randomização, grupo de controle e controle de perdas e confundimento.

6.7 Lema de Neyman–Pearson

Quando H_0 e H_1 são simples, o lema de Neyman–Pearson fornece um critério ótimo para a construção da região crítica.

Considere

$$H_0 : \theta = \theta_0 \quad \text{versus} \quad H_1 : \theta = \theta_1,$$

com densidades ou funções de probabilidade $f_{\theta_0}(x)$ e $f_{\theta_1}(x)$.

Definição: teste mais poderoso

Um teste φ^* de nível α é **mais poderoso** para θ_1 quando, para todo teste φ de nível no máximo α ,

$$E_{\theta_1}[\varphi^*(X)] \geq E_{\theta_1}[\varphi(X)].$$

Teorema: lema de Neyman–Pearson

Entre todos os testes de nível α para hipóteses simples, um teste mais poderoso rejeita H_0 quando a razão

$$\frac{f_{\theta_1}(x)}{f_{\theta_0}(x)}$$

é suficientemente grande. Equivalentemente, rejeita-se H_0 quando

$$\frac{f_{\theta_0}(x)}{f_{\theta_1}(x)}$$

é suficientemente pequena. O ponto de corte — e, quando necessário, a probabilidade de aleatorização na fronteira — é escolhido para que o teste tenha tamanho α ou, na versão

não aleatorizada, tamanho no máximo α (Casella; Berger, 2002, sec. 8.3.2; Hogg; Craig, 1978, cap. 7; Rice, 2007, sec. 9.2; Ramachandran; Tsokos, 2021, sec. 6.2).

6.7.1 Exemplo: média normal, alternativa simples

O exemplo aplica diretamente o lema de Neyman–Pearson ao modelo normal (Casella; Berger, 2002, sec. 8.3.2; Hogg; Craig, 1978, cap. 7; Rasch; Schott, 2018, sec. 3.2).

Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida, considere

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu = \mu_1,$$

em que $\mu_1 > \mu_0$. A razão de verossimilhanças é uma função crescente de $\bar{X}$. Portanto, o teste mais poderoso rejeita H_0 para valores grandes de $\bar{X}$:

$$\bar{X} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}.$$

Equivalentemente,

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}.$$

O ponto de corte não depende do valor específico μ_1 , desde que $\mu_1 > \mu_0$. Essa propriedade conduz aos testes uniformemente mais poderosos.

6.8 Testes uniformemente mais poderosos

i Definição: teste UMP

Um teste φ^* de nível α é **uniformemente mais poderoso** — UMP, de *uniformly most powerful* — para

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta_1$$

quando, para todo teste φ de nível no máximo α ,

$$E_{\theta}[\varphi^*(X)] \geq E_{\theta}[\varphi(X)] \quad \text{para todo } \theta \in \Theta_1.$$

A palavra “uniformemente” significa que o mesmo teste maximiza o poder em todos os pontos da hipótese alternativa, e não apenas em um valor particular.

6.8.1 Razão de verossimilhanças monótona

Definição

Uma família dominada $\{f_{\theta} : \theta \in \Theta \subseteq \mathbb{R}\}$, com suporte comum, possui **razão de verossimilhanças monótona** em uma estatística $T(X)$ quando, para $\theta_2 > \theta_1$ e nos pontos em que o denominador é positivo,

$$\frac{f_{\theta_2}(x)}{f_{\theta_1}(x)}$$

é uma função não decrescente de $T(x)$.

Em famílias com essa propriedade, valores grandes de T favorecem sistematicamente valores maiores do parâmetro.

Teorema: resultado de Karlin–Rubin

Suponha que $\{f_{\theta} : \theta \in \Theta \subseteq \mathbb{R}\}$ possua razão de verossimilhanças monótona não decrescente em $T(X)$. Então o teste

$$\varphi(x) = \begin{cases} 1, & T(x) > c, \\ \gamma, & T(x) = c, \\ 0, & T(x) < c, \end{cases}$$

com c e γ determinados por

$$P_{\theta_0}\{T(X) > c\} + \gamma P_{\theta_0}\{T(X) = c\} = \alpha,$$

é UMP de nível α para

$$H_0 : \theta \leq \theta_0 \quad \text{versus} \quad H_1 : \theta > \theta_0.$$

A versão com rejeição para valores pequenos de T aplica-se quando a razão é não crescente ou quando a alternativa é à esquerda. Em modelos contínuos, normalmente $P_{\theta_0}\{T = c\} = 0$ e a aleatorização não é necessária (Casella; Berger, 2002, sec. 8.3.2; Borovkov, 1998, cap. 3; Rasch; Schott, 2018, sec. 3.3.1).

6.8.2 Exemplos importantes

6.8.2.1 Média normal com variância conhecida

Para

$$X_i \sim N(\mu, \sigma^2),$$

com σ^2 conhecida, a família possui razão de verossimilhanças monótona em $T = \sum_i X_i$, ou equivalentemente em $\bar{X}$. Assim,

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}$$

é UMP para

$$H_0 : \mu \leq \mu_0 \quad \text{versus} \quad H_1 : \mu > \mu_0.$$

6.8.2.2 Proporção binomial

Se $X \sim \text{Bin}(n, p)$, a família possui razão de verossimilhanças monótona em X . Portanto, testes que rejeitam para valores grandes de X são UMP para

$$H_0 : p \leq p_0 \quad \text{versus} \quad H_1 : p > p_0.$$

Como X é discreta, o tamanho exato pode ser menor que α em um teste não aleatorizado.

6.8.2.3 Média de Poisson

Se $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$, a estatística $T = \sum_i X_i$ possui razão de verossimilhanças monótona. A rejeição para valores grandes de T produz um teste UMP para

$$H_0 : \lambda \leq \lambda_0 \quad \text{versus} \quad H_1 : \lambda > \lambda_0.$$

6.8.3 Por que geralmente não existe UMP bilateral?

No modelo normal com variância conhecida, o teste mais poderoso contra $\mu_1 > \mu_0$ rejeita para valores grandes de $\bar{X}$. Contra $\mu_1 < \mu_0$, o teste mais poderoso rejeita para valores pequenos de $\bar{X}$. Não existe, em geral, uma única região de nível α que seja simultaneamente mais poderosa em ambas as direções. Por isso, testes UMP são mais comuns em problemas unilaterais; problemas bilaterais frequentemente exigem restrições adicionais de optimalidade ou o teste da razão de verossimilhanças (Casella; Berger, 2002, secs. 8.3.2–8.3.3; Borovkov, 1998, cap. 3; Rice, 2007, sec. 9.2.3; Ramachandran; Tsokos, 2021, secs. 6.2–6.3).

i Observação: testes não viesados e UMPU

Para um teste de tamanho α , uma condição de não viés é

$$\pi_{\varphi}(\theta) \geq \alpha, \quad \theta \in \Theta_1.$$

Restringindo a comparação à classe dos testes não viesados, pode existir um teste **uniformemente mais poderoso não viesado** (UMPU), mesmo quando não existe teste UMP entre todos os testes de nível α . O desenvolvimento completo dessa teoria exige condições adicionais e não deve ser confundido com a optimalidade geral do TRV (Casella; Berger, 2002, secs. 8.3.2–8.3.3; Borovkov, 1998, cap. 3).

6.9 Teste da razão de verossimilhanças

O teste da razão de verossimilhanças — TRV — fornece um procedimento geral para hipóteses simples ou compostas. Diferentemente do lema de Neyman–Pearson, o TRV generalizado não é, em geral, ótimo em amostras finitas; sua importância decorre da aplicabilidade ampla e de propriedades assintóticas favoráveis. A estatística Λ é preservada por reparametrizações biunívocas do modelo (Casella; Berger, 2002, sec. 8.2.1; Hogg; Craig, 1978, sec. 7.4; Rice, 2007, sec. 9.4; Chihara; Hesterberg, 2022, sec. 8.6).

Considere

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta \setminus \Theta_0.$$

i Definição: razão de verossimilhanças generalizada

A estatística é

$$\Lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta; x)}{\sup_{\theta \in \Theta} L(\theta; x)}.$$

Como $\Theta_0 \subseteq \Theta$,

$$0 \leq \Lambda(x) \leq 1.$$

Valores pequenos de Λ indicam que o melhor ajuste permitido por H_0 é muito inferior ao melhor ajuste no modelo completo.

O TRV rejeita H_0 para valores pequenos de Λ , ou, equivalentemente, para valores grandes de

$$W = -2 \log \Lambda.$$

i Relação com Neyman–Pearson

Quando ambas as hipóteses são simples, comparar Λ com um ponto de corte é equivalente a comparar $f_{\theta_1}(x)/f_{\theta_0}(x)$ com um ponto de corte. Portanto, o TRV coincide com a forma do teste mais poderoso fornecida pelo lema de Neyman–Pearson. Para hipóteses compostas, essa equivalência de optimalidade não é garantida (Casella; Berger, 2002, secs. 8.2.1 e 8.3.2; Hogg; Craig, 1978, sec. 7.4).

6.9.1 Resultado assintótico de Wilks

Suponha que o parâmetro verdadeiro seja um ponto interior, que o modelo seja identificável e diferenciável e que H_0 imponha q restrições independentes e regulares. Então, sob H_0 ,

$$-2 \log \Lambda \xrightarrow{d} \chi_q^2,$$

em que

$$q = \dim(\Theta) - \dim(\Theta_0)$$

é o número de restrições independentes impostas por H_0 (Casella; Berger, 2002, sec. 10.3; Rice, 2007, sec. 9.4).

⚠ Condições e exceções

A aproximação qui-quadrado pode falhar quando:

- o parâmetro verdadeiro está na fronteira do espaço paramétrico;
- há parâmetros não identificáveis sob H_0 ;
- o suporte da distribuição depende do parâmetro;
- a amostra é pequena;
- o modelo é irregular ou excessivamente esparso.

Nessas situações, devem ser consideradas distribuições exatas, simulação de Monte Carlo ou *bootstrap* paramétrico.

6.9.2 Exemplo: média normal com variância conhecida

Este exemplo mostra um caso em que o TRV possui distribuição nula exata, e não apenas assintótica (Casella; Berger, 2002, secs. 8.2.1 e 10.3; Rice, 2007, sec. 9.4; Hogg; Craig, 1978, sec. 7.4).

Considere

$$X_i \sim N(\mu, \sigma^2),$$

com σ^2 conhecida, e

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu \neq \mu_0.$$

No modelo completo, o estimador de máxima verossimilhança é $\hat{\mu} = \bar{X}$. Sob H_0 , o parâmetro é fixado em μ_0 . Após simplificação,

$$\Lambda = \exp \left\{ -\frac{n(\bar{X} - \mu_0)^2}{2\sigma^2} \right\},$$

portanto,

$$-2 \log \Lambda = \frac{n(\bar{X} - \mu_0)^2}{\sigma^2} = Z^2.$$

Como $Z \sim N(0, 1)$ sob H_0 ,

$$Z^2 \sim \chi_1^2.$$

Logo, o TRV é exatamente equivalente ao teste bilateral Z .

6.9.3 Exemplo: proporção binomial

A expressão abaixo é a deviance binomial para o teste de uma proporção (Casella; Berger, 2002, sec. 10.3; Rice, 2007, secs. 9.4–9.5; Ramachandran; Tsokos, 2021, sec. 6.3).

Se $X \sim \text{Bin}(n, p)$ e deseja-se testar

$$H_0 : p = p_0 \quad \text{versus} \quad H_1 : p \neq p_0,$$

o estimador irrestrito é $\hat{p} = X/n$. Para $0 < X < n$,

$$-2 \log \Lambda = 2 \left[X \log \left(\frac{X}{np_0} \right) + (n - X) \log \left(\frac{n - X}{n(1 - p_0)} \right) \right].$$

Adota-se a convenção $0 \log 0 = 0$. Para amostras grandes, essa estatística possui distribuição aproximadamente χ_1^2 sob H_0 . Em amostras pequenas, o teste binomial exato é preferível.

6.10 Testes usuais para parâmetros populacionais

6.10.1 Uma média com variância conhecida

Suponha

$$X_1, \dots, X_n \sim N(\mu, \sigma^2),$$

com σ^2 conhecida. Sob $H_0 : \mu = \mu_0$,

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Alternativa	Região crítica	Valor- p
$\mu > \mu_0$	$Z > z_{1-\alpha}$	$1 - \Phi(z_{\text{obs}})$
$\mu < \mu_0$	$Z < z_\alpha$	$\Phi(z_{\text{obs}})$
$\mu \neq \mu_0$	$ Z > z_{1-\alpha/2}$	$2\{1 - \Phi(z_{\text{obs}})\}$

Esses testes são exatos sob o modelo normal com variância conhecida (Chihara; Hesterberg, 2022, sec. 8.1; Larsen; Marx, 2012, cap. 6; Ramachandran; Tsokos, 2021, sec. 6.4.2).

6.10.2 Uma média com variância desconhecida

Se a população é normal e σ^2 é desconhecida,

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$$

sob H_0 . As regiões críticas seguem o mesmo padrão do teste Z , substituindo os quantis normais pelos quantis da distribuição t com $n-1$ graus de liberdade (Lauritzen, 2023, sec. 7.6.1; Larsen; Marx, 2012, cap. 6).



Pressuposto

Para amostras pequenas, a validade exata do teste depende da normalidade da população. Para amostras maiores, a aproximação costuma ser favorecida pelo comportamento assintótico da média, mas assimetria intensa e valores extremos podem comprometer a inferência.

6.10.3 Uma proporção

Se $X \sim \text{Bin}(n, p)$, a estatística aproximada sob $H_0 : p = p_0$ é

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}, \quad \hat{p} = \frac{X}{n}.$$

A aproximação normal deve ser usada apenas quando a distribuição binomial sob H_0 não for excessivamente assimétrica ou esparsa. Regras baseadas apenas em np_0 e $n(1-p_0)$ são heurísticas, não garantias de precisão. Caso contrário, utiliza-se o teste exato (Chihara; Hesterberg, 2022, secs. 8.1 e 8.4.3; Ramachandran; Tsokos, 2021, sec. 6.4.2).

6.10.3.1 Teste binomial exato

Para uma alternativa unilateral à direita,

$$p = P_{p_0}(X \geq x_{\text{obs}}).$$

Para uma alternativa unilateral à esquerda,

$$p = P_{p_0}(X \leq x_{\text{obs}}).$$

Em testes bilaterais discretos, há mais de uma convenção possível. Uma definição amplamente utilizada soma as probabilidades dos resultados cuja probabilidade sob H_0 é menor ou igual à probabilidade do resultado observado:

$$p = \sum_{k: P_{p_0}(X=k) \leq P_{p_0}(X=x_{\text{obs}})} P_{p_0}(X = k).$$

O método bilateral adotado deve ser explicitado, pois dobrar mecanicamente uma cauda nem sempre coincide com essa definição (Chihara; Hesterberg, 2022, sec. 8.1; Rasch; Schott, 2018, cap. 3).

6.10.4 Duas médias independentes: teste de Welch

Considere duas amostras independentes, com médias $\bar{X}_1$ e $\bar{X}_2$, variâncias S_1^2 e S_2^2 e tamanhos n_1 e n_2 . Para testar

$$H_0 : \mu_1 - \mu_2 = \Delta_0,$$

a estatística de Welch é

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}.$$

Os graus de liberdade são aproximados por

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1 - 1} + \frac{(S_2^2/n_2)^2}{n_2 - 1}}.$$

Sob populações normais independentes, a distribuição t_ν utilizada pelo teste de Welch é uma aproximação de Satterthwaite. O procedimento é uma escolha padrão quando não há justificativa substantiva para assumir variâncias iguais (Ramachandran; Tsokos, 2021, sec. 6.5.1.2; Chihara; Hesterberg, 2022, sec. 8.3).

6.10.5 Duas médias independentes com variância comum

Quando o modelo científico justifica

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

utiliza-se

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

e

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - \Delta_0}{S_p \sqrt{1/n_1 + 1/n_2}},$$

com $n_1 + n_2 - 2$ graus de liberdade. Essa distribuição é exata quando as duas populações são normais, independentes e possuem uma variância comum (Larsen; Marx, 2012, cap. 9; Ramachandran; Tsokos, 2021, sec. 6.5.1.1).

Observação

A decisão de agrupar variâncias não deve ser baseada apenas em um teste preliminar de igualdade de variâncias. Ela deve refletir o modelo e o delineamento do estudo.

6.10.6 Amostras pareadas

Para pares (X_i, Y_i) , defina

$$D_i = X_i - Y_i.$$

O teste pareado é simplesmente um teste para uma média aplicado às diferenças:

$$T = \frac{\bar{D} - \Delta_0}{S_D / \sqrt{n}} \sim t_{n-1}$$

sob normalidade das diferenças. O pareamento deve ser incorporado à análise; tratar observações pareadas como independentes desperdiça informação e produz erro-padrão inadequado (Chihara; Hesterberg, 2022, sec. 8.3; Larsen; Marx, 2012, cap. 9).

6.10.7 Duas proporções independentes

Se $X_j \sim \text{Bin}(n_j, p_j)$, $j = 1, 2$, e deseja-se testar

$$H_0 : p_1 = p_2,$$

a proporção combinada sob H_0 é

$$\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}.$$

A estatística aproximada é

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p})(1/n_1 + 1/n_2)}}.$$

Para tabelas 2×2 esparsas, o teste exato de Fisher é uma alternativa importante. A estatística normal acima é aproximada e requer independência entre os grupos e contagens esperadas compatíveis com a aproximação normal (Chihara; Hesterberg, 2022, secs. 8.3 e 10.3.3; Rosner, 2011, cap. 10).

6.11 Testes exatos, de permutação e robustez

Os testes paramétricos anteriores dependem de modelos probabilísticos específicos. Quando a distribuição exata sob H_0 é conhecida, um teste exato controla o nível sem recorrer a aproximações assintóticas. Exemplos são o teste binomial e o teste exato de Fisher.

6.11.1 Testes de permutação

Em problemas de comparação entre grupos, um teste de permutação constrói a distribuição nula recombina os rótulos das observações. A justificativa não é simplesmente “não assumir normalidade”: sob H_0 , é necessário que as observações sejam permutáveis, condição frequentemente derivada da randomização experimental ou da igualdade das distribuições sob a hipótese nula. Para dados pareados, permutam-se sinais ou condições dentro dos pares, preservando a estrutura do delineamento (Chihara; Hesterberg, 2022, cap. 3 e secs. 8.5 e 9.5.1).

Observação

Um teste de permutação baseado na diferença de médias pode testar igualdade de distribuições ou uma hipótese decorrente do mecanismo de randomização; ele não é automaticamente um teste exato apenas para igualdade de médias quando as distribuições diferem em outros aspectos. A hipótese efetivamente testada deve ser explicitada.

6.11.2 Robustez

O teste t pode ser relativamente estável diante de desvios moderados de normalidade, sobretudo em amostras equilibradas e sem observações extremas. Contudo, caudas pesadas, heteroscedasticidade, assimetria pronunciada e *outliers* podem alterar substancialmente o nível e o poder. Nessas situações, devem ser considerados o teste de Welch, métodos de reamostragem coerentes com o delineamento e procedimentos robustos baseados, por exemplo, em médias aparadas ou estimadores robustos de localização (Wilcox, 2022, caps. 4–7).

6.12 Planejamento amostral e poder

6.12.1 Uma média com variância conhecida

Para o teste unilateral

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu > \mu_0,$$

suponha que se deseje poder $1 - \beta$ para detectar $\mu_1 > \mu_0$. Uma aproximação para o tamanho amostral é

$$n = \left\lceil \left[\frac{(z_{1-\alpha} + z_{1-\beta})\sigma}{\mu_1 - \mu_0} \right]^2 \right\rceil.$$

Para o teste bilateral, a substituição de $z_{1-\alpha}$ por $z_{1-\alpha/2}$ fornece uma aproximação conservadora usual, pois o poder bilateral exato envolve as duas caudas. A expressão deve ser entendida como planejamento para uma diferença alternativa previamente especificada (Ramachandran; Tsokos, 2021, sec. 6.1.1; Chihara; Hesterberg, 2022, sec. 8.4.2).

6.12.2 Uma proporção

Para detectar $p_1 \neq p_0$, uma aproximação unilateral é

$$n \approx \frac{\left[z_{1-\alpha} \sqrt{p_0(1-p_0)} + z_{1-\beta} \sqrt{p_1(1-p_1)} \right]^2}{(p_1 - p_0)^2}.$$

No caso bilateral, usa-se $z_{1-\alpha/2}$. Trata-se de uma aproximação normal; após arredondar n para cima, recomenda-se recalcular o poder pela distribuição binomial exata, especialmente quando p_0 ou p_1 estiver próximo de 0 ou 1 (Chihara; Hesterberg, 2022, sec. 8.4.2; Ramachandran; Tsokos, 2021, sec. 6.1.1).

! Significância prática

O planejamento deve ser baseado na menor diferença cientificamente relevante, e não na menor diferença que possa se tornar estatisticamente significativa. Com amostras muito grandes, efeitos desprezíveis podem produzir valores- p pequenos.

6.13 Análise de dados categóricos

Dados categóricos são representados por contagens em categorias mutuamente exclusivas. O modelo multinomial fornece a base probabilística para testes de aderência e para tabelas de contingência (Rice, 2007, sec. 9.5; Lauritzen, 2023, secs. 8.2–8.3; Chihara; Hesterberg, 2022, cap. 10; Larsen; Marx, 2012, cap. 10).

6.13.1 Estatística qui-quadrado de Pearson

Para contagens observadas $O_1, \dots, O_k$ e esperadas $E_1, \dots, E_k$, a estatística de Pearson é

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

Valores grandes indicam discrepância entre os dados e o modelo nulo.

6.13.2 Estatística da razão de verossimilhanças

A estatística correspondente ao TRV é

$$G^2 = 2 \sum_{i=1}^k O_i \log \left(\frac{O_i}{E_i} \right),$$

com a convenção de que termos com $O_i = 0$ são iguais a zero. Sob condições regulares,

$$G^2 \approx X^2,$$

e ambas as estatísticas possuem a mesma distribuição qui-quadrado assintótica sob H_0 . Sob regularidade, sua diferença é assintoticamente desprezível, embora seus valores em uma amostra finita não precisem ser próximos quando existem células esparsas (Rice, 2007, sec. 9.5; Lauritzen, 2023, secs. 8.2–8.3; Chihara; Hesterberg, 2022, sec. 10.6).

6.14 Teste qui-quadrado de aderência

Considere uma variável com k categorias e probabilidades especificadas por H_0 :

$$H_0 : (p_1, \dots, p_k) = (p_1^{(0)}, \dots, p_k^{(0)}).$$

As frequências esperadas são

$$E_i = np_i^{(0)}.$$

Quando nenhuma quantidade é estimada a partir da própria amostra, os graus de liberdade são

$$\nu = k - 1.$$

Se q parâmetros livres forem estimados, sob condições regulares, a partir da mesma amostra para calcular as probabilidades esperadas, então

$$\nu = k - 1 - q.$$

Essa redução dos graus de liberdade pressupõe que os parâmetros sejam identificáveis e que o modelo ajustado possua posto local q (Larsen; Marx, 2012, secs. 10.3–10.4; Chihara; Hesterberg, 2022, sec. 10.5).

6.14.1 Exemplo: dado de seis faces

Em 120 lançamentos de um dado, foram observadas as contagens

$$(14, 18, 20, 22, 21, 25).$$

Sob a hipótese de equilíbrio,

$$E_i = 120 \times \frac{1}{6} = 20.$$

Logo,

$$X^2 = \frac{(14 - 20)^2}{20} + \dots + \frac{(25 - 20)^2}{20} = 3,50.$$

Com $\nu = 5$, o valor- p é aproximadamente 0,623. Não se rejeita a hipótese de probabilidades iguais.

```
import numpy as np
from scipy.stats import chisquare

observado = np.array([14, 18, 20, 22, 21, 25])
esperado = np.repeat(20, 6)

estatistica, p_valor = chisquare(observado, f_exp=esperado)
print(f"X² = {estatistica:.3f}; valor-p = {p_valor:.4f}")
```

X² = 3.500; valor-p = 0.6234

6.15 Tabelas de contingência

Considere uma tabela com r linhas e c colunas. Seja O_{ij} a frequência observada na célula (i, j) , $O_{i\cdot}$ o total da linha, $O_{\cdot j}$ o total da coluna e n o total geral.

Sob independência ou homogeneidade, a frequência esperada é

$$E_{ij} = \frac{O_{i\cdot} O_{\cdot j}}{n}.$$

A estatística de Pearson é

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

com

$$\nu = (r - 1)(c - 1).$$

Esses resultados decorrem do modelo de independência para contagens multinomiais ou produtos multinomiais (Lauritzen, 2023, sec. 8.3; Chihara; Hesterberg, 2022, secs. 10.1–10.3; Larsen; Marx, 2012, sec. 10.5).

6.15.1 Homogeneidade e independência

Os dois testes utilizam a mesma estatística, mas respondem a perguntas distintas.

Teste	Delineamento	Hipótese nula
Homogeneidade	amostras independentes de diferentes populações	a distribuição categórica é a mesma nas populações
Independência	uma amostra, com duas variáveis categóricas medidas em cada unidade	as variáveis são independentes

A interpretação correta depende do esquema amostral, não apenas da tabela numérica.

6.15.2 Exemplo: renda e hipertensão

Considere os dados hipotéticos:

Renda	Hipertensão: sim	Hipertensão: não	Total
Baixa	60	40	100
Média	45	55	100
Alta	20	80	100
Total	125	175	300

Sob independência, as frequências esperadas em cada linha são 41,67 e 58,33. A estatística é

$$X^2 = 33,60,$$

com $\nu = 2$ e

$$p \approx 5,06 \times 10^{-8}.$$

Rejeita-se a hipótese de independência. O resultado indica associação, mas não demonstra causalidade.

```
import numpy as np
from scipy.stats import chi2_contingency

observado = np.array([
    [60, 40],
    [45, 55],
    [20, 80]
])

x2, p_valor, gl, esperado = chi2_contingency(
    observado,
    correction=False
)

print(f"X² = {x2:.3f}; gl = {gl}; valor-p = {p_valor:.4g}")
print(esperado)
```

```
X² = 33.600; gl = 2; valor-p = 5.057e-08
[[41.66666667 58.33333333]
 [41.66666667 58.33333333]
 [41.66666667 58.33333333]]
```

6.16 Diagnóstico por resíduos

A rejeição global não identifica automaticamente quais células explicam a associação.

O resíduo de Pearson é

$$r_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}.$$

Um resíduo ajustado é

$$r_{ij}^{\text{aj}} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij} \left(1 - \frac{O_{i\cdot}}{n}\right) \left(1 - \frac{O_{\cdot j}}{n}\right)}}.$$

Valores absolutos grandes indicam células que contribuem de maneira relevante para a discrepância global. A aproximação normal de cada resíduo é assintótica, e os resíduos de uma mesma tabela são dependentes. Quando muitas células são examinadas, a interpretação deve considerar multiplicidade (Lauritzen, 2023, secs. 8.2–8.3).

6.17 Pressupostos e tabelas esparsas

Os testes qui-quadrado requerem:

1. observações independentes;
2. categorias mutuamente exclusivas;
3. frequências esperadas suficientemente grandes para justificar a aproximação assintótica;
4. um esquema amostral compatível com o modelo multinomial ou com o modelo de tabela de contingência.

A regra pedagógica $E_{ij} \geq 5$ é apenas uma heurística, não um teorema universal. Quando há muitas células com contagens esperadas pequenas, podem ser necessários:

- agrupamento de categorias cientificamente justificável;
- teste exato de Fisher em tabelas 2×2 ;
- testes exatos condicionais;
- valores- p por Monte Carlo;
- modelos multinomiais ou log-lineares apropriados.

A adequação de critérios numéricos específicos para frequências esperadas deve ser avaliada considerando o número de células, o grau de desequilíbrio e a precisão desejada; a regra 5 não constitui garantia universal (Chihara; Hesterberg, 2022, cap. 10; Rosner, 2011, cap. 10).

6.18 Teste exato de Fisher

Em uma tabela 2×2 , condicionando aos totais marginais, a contagem de uma célula segue distribuição hipergeométrica sob a hipótese nula. O teste exato de Fisher calcula probabilidades diretamente dessa distribuição e não depende da aproximação qui-quadrado. Para alternativas bilaterais, existem diferentes convenções de ordenação das tabelas; a convenção utilizada pelo

software deve ser declarada (Lauritzen, 2023, sec. 8.3.5; Chihara; Hesterberg, 2022, sec. 10.3.3; Rosner, 2011, sec. 10.3).

```
import numpy as np
from scipy.stats import fisher_exact

tabela = np.array([
    [8, 2],
    [1, 5]
])

razao_chances, p_valor = fisher_exact(
    tabela,
    alternative="two-sided"
)

print(f"Razão de chances = {razao_chances:.3f}")
print(f"Valor-p exato = {p_valor:.4f}")
```

Razão de chances = 20.000
Valor-p exato = 0.0350

6.19 Medidas de tamanho do efeito em tabelas

Para uma tabela 2×2 , a **magnitude** do coeficiente ϕ pode ser escrita como

$$|\phi| = \sqrt{\frac{X^2}{n}}.$$

O sinal de ϕ depende da codificação e da orientação das linhas e colunas; a expressão baseada em X^2 fornece apenas sua magnitude.

Para uma tabela $r \times c$, o V de Cramér é

$$V = \sqrt{\frac{X^2}{n \min(r-1, c-1)}}.$$

No exemplo de renda e hipertensão,

$$V = \sqrt{\frac{33,60}{300}} \approx 0,335.$$

A interpretação substantiva deve considerar o contexto, o delineamento e a direção observada nas proporções e nos resíduos. Pontos de corte universais para “efeito pequeno”, “médio” ou “grande” não substituem a análise contextual. Essas medidas são descritivas e não substituem a apresentação das proporções ou dos resíduos que determinam a direção da associação.

6.20 Poder e tamanho amostral em testes qui-quadrado

No teste de aderência com probabilidades nulas completamente especificadas, defina

$$w = \sqrt{\sum_i \frac{(p_i - p_i^{(0)})^2}{p_i^{(0)}}},$$

em que p_i representa uma alternativa cientificamente relevante. Sob a aproximação qui-quadrado não central, o parâmetro de não centralidade é

$$\lambda = nw^2.$$

Em tabelas de contingência, a definição correspondente deve ser construída a partir das probabilidades conjuntas sob a alternativa e das probabilidades ajustadas sob a hipótese de independência; não se deve reutilizar mecanicamente a fórmula de aderência.

Para ν graus de liberdade e nível α , o poder aproximado é

$$1 - \beta = P\{\chi_\nu^2(\lambda) > \chi_{\nu, 1-\alpha}^2\}.$$

O tamanho amostral deve ser obtido numericamente a partir dessa expressão. Fórmulas que ignoram os graus de liberdade podem produzir planejamento inadequado.

i Observação bibliográfica

A relação $\lambda = nw^2$ é uma aproximação de planejamento. Após obter n , recomenda-se recalcular o poder com o modelo probabilístico específico e verificar as frequências esperadas previstas.

```
from math import ceil
from scipy.optimize import brentq
from scipy.stats import chi2, ncx2

alpha = 0.05
poder_alvo = 0.80
```

```

w = 0.30
gl = 2

critico = chi2.ppf(1 - alpha, df=gl)

def poder(n):
    nao_centralidade = n * w**2
    return ncx2.sf(critico, df=gl, nc=nao_centralidade)

raiz = brentq(lambda n: poder(n) - poder_alvo, 2, 100000)
n_minimo = ceil(raiz)

print(f"n mínimo aproximado = {n_minimo}")
print(f"poder recalculado = {poder(n_minimo):.4f}")

```

```

n mínimo aproximado = 108
poder recalculado = 0.8037

```

6.21 Relação entre testes e intervalos de confiança

Há uma dualidade entre testes bilaterais e intervalos de confiança. Para um procedimento coerente de nível α ,

$$H_0 : \theta = \theta_0$$

não é rejeitada se, e somente se, θ_0 pertence ao conjunto de confiança de nível $1 - \alpha$ obtido pela inversão dessa mesma família de testes (Rice, 2007, sec. 9.3; Chihara; Hesterberg, 2022, sec. 8.4.4).

i Interpretação

O intervalo de confiança complementa o valor- p porque mostra a faixa de valores compatíveis com os dados e permite avaliar a magnitude e a precisão do efeito.

6.22 Boas práticas de apresentação

Um relatório de teste deve incluir:

- hipóteses e direção do teste;

- estatística de teste e distribuição de referência;
- graus de liberdade, quando aplicável;
- valor- p , preferencialmente com precisão adequada;
- estimativa pontual e intervalo de confiança;
- medida de tamanho do efeito;
- verificação dos pressupostos;
- interpretação contextual, sem linguagem causal indevida.

6.22.1 Modelo de redação

A diferença média estimada foi de 4,2 unidades, com intervalo de confiança de 95% de [1,1; 7,3]. O teste de Welch forneceu $t = 2,68$, $\nu = 37,4$ e $p = 0,011$. Há evidência de diferença entre as médias no modelo adotado. A magnitude e a relevância prática devem ser avaliadas à luz da escala da variável e do delineamento do estudo.

6.23 Erros frequentes de interpretação

1. **Confundir valor- p** com $P(H_0 \mid \text{dados})$. O valor- p é calculado sob H_0 e não atribui probabilidade posterior à hipótese.
2. **Escolher unilateralidade após observar os dados.** A direção deve ser definida previamente.
3. **Concluir ausência de efeito a partir de $p \geq \alpha$.** Um teste não significativo pode ter baixo poder.
4. **Ignorar tamanho do efeito.** Significância estatística não implica relevância prática.
5. **Usar teste t pareado** como se as amostras fossem independentes. O pareamento deve ser incorporado pelas diferenças.
6. **Aplicar qui-quadrado em células extremamente esparsas sem diagnóstico.** Métodos exatos ou de simulação podem ser necessários.
7. **Interpretar associação como causalidade.** Testes de independência não eliminam confundimento nem estabelecem mecanismo causal.
8. **Realizar muitos testes sem controlar multiplicidade.** A probabilidade de ao menos uma rejeição falsa cresce com o número de comparações.

6.24 Quadro-síntese

Problema	Estatística principal	Referência sob H_0	Observação
uma média, σ conhecida	Z	$N(0, 1)$	exato sob normalidade
uma média, σ desconhecida	T	t_{n-1}	exato sob normalidade
duas médias independentes	T de Welch	t_ν aproximada	não exige variâncias iguais
médias pareadas	T nas diferenças	t_{n-1}	analisa $D_i = X_i - Y_i$
uma proporção	Z ou binomial exato	normal ou binomial	preferir exato em amostras pequenas
duas proporções	Z combinado	normal aproximada	Fisher em 2×2 esparsa
aderência	X^2 ou G^2	χ^2_{k-1-q}	descontar parâmetros estimados
homogeneidade/independência	X^2 ou G^2	$\chi^2_{(r-1)(c-1)}$	mesma álgebra, delineamentos distintos
hipótese paramétrica geral	$-2 \log \Lambda$	χ^2_q assintótica	verificar regularidade

6.25 Exercícios

Os exercícios a seguir são autorais ou foram adaptados conceitualmente das fontes teóricas e aplicadas utilizadas no capítulo (Borovkov, 1998; Casella; Berger, 2002; Chihara; Hesterberg, 2022; Hogg; Craig, 1978; Lauritzen, 2023; Ramachandran; Tsokos, 2021; Rasch; Schott, 2018; Rice, 2007; Shao, 2005).

6.25.1 Exercícios conceituais

i Exercício 1

Explique por que um valor- p igual a 0,03 não significa que existe probabilidade de 3% de H_0 ser verdadeira.

i Exercício 2

Considere um teste de nível 0,05 cujo poder em θ_1 é 0,80. Determine as probabilidades dos erros dos tipos I e II quando o verdadeiro parâmetro é, respectivamente, um ponto

de fronteira de H_0 em que o tamanho é alcançado e o ponto θ_1 .

i Exercício 3

Mostre que, se o valor- p de um teste contínuo é uniforme em $(0, 1)$ sob H_0 , então a regra “rejeitar quando $p \leq \alpha$ ” possui tamanho α .

6.25.2 Neyman–Pearson e testes UMP

i Exercício 4

Sejam $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, com σ^2 conhecida. Use o lema de Neyman–Pearson para obter o teste mais poderoso de nível α para

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu = \mu_1,$$

nos casos $\mu_1 > \mu_0$ e $\mu_1 < \mu_0$.

i Exercício 5

Sejam $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$. Mostre que a razão de verossimilhanças é monótona em $T = \sum_i X_i$ e construa um teste UMP de nível α para

$$H_0 : \lambda \leq \lambda_0 \quad \text{versus} \quad H_1 : \lambda > \lambda_0.$$

i Exercício 6

Considere $X \sim \text{Bin}(n, p)$. Determine a região crítica não aleatorizada UMP para

$$H_0 : p \leq p_0 \quad \text{versus} \quad H_1 : p > p_0,$$

e calcule o nível efetivamente alcançado. Discuta como um teste aleatorizado poderia atingir tamanho exatamente α .

i Exercício 7

No modelo normal com variância conhecida, explique formalmente por que o teste bilateral de $H_0 : \mu = \mu_0$ contra $H_1 : \mu \neq \mu_0$ não é, em geral, UMP.

6.25.3 Razão de verossimilhanças

i Exercício 8

Derive o TRV para

$$X_1, \dots, X_n \sim N(\mu, \sigma^2),$$

com σ^2 conhecida, e mostre que $-2 \log \Lambda = Z^2$.

i Exercício 9

Para $X \sim \text{Bin}(n, p)$, derive a expressão de $-2 \log \Lambda$ para testar $H_0 : p = p_0$. Compare numericamente o valor- p assintótico com o valor- p binomial exato para $n = 20$, $p_0 = 0,5$ e $x = 15$.

i Exercício 10

Explique por que o resultado de Wilks pode falhar quando o parâmetro sob H_0 está na fronteira do espaço paramétrico. Indique uma estratégia computacional para estimar a distribuição nula de $-2 \log \Lambda$.

6.25.4 Testes para médias e proporções

i Exercício 11

Uma amostra de 25 observações apresentou $\bar{x} = 52$ e $s = 8$. Teste $H_0 : \mu = 50$ contra $H_1 : \mu \neq 50$ ao nível de 5%, supondo normalidade. Calcule também o intervalo de confiança de 95%.

i Exercício 12

Duas amostras independentes produziram:

$$(n_1, \bar{x}_1, s_1) = (18, 14, 2, 3, 1),$$

$$(n_2, \bar{x}_2, s_2) = (22, 12, 5, 4, 0).$$

Aplique o teste de Welch para $H_0 : \mu_1 = \mu_2$ contra uma alternativa bilateral. Reporte estatística, graus de liberdade, valor- p e intervalo de confiança.

i Exercício 13

Em 40 pares antes-depois, a média das diferenças foi $-2,4$ e o desvio-padrão das diferenças foi $5,8$. Teste se a média da diferença é menor que zero e interprete o sinal adotado na definição de D_i .

i Exercício 14

Em 30 ensaios Bernoulli, foram observados 23 sucessos. Teste $H_0 : p = 0,5$ contra $H_1 : p > 0,5$ pelos métodos exato e normal. Compare os resultados e discuta a adequação da aproximação.

6.25.5 Dados categóricos

i Exercício 15

Uma variável categórica com quatro níveis apresentou contagens $(48, 31, 15, 6)$ em uma amostra de tamanho 100. Teste a aderência às probabilidades $(0,40, 0,30, 0,20, 0,10)$ usando X^2 e G^2 . Compare as estatísticas.

i Exercício 16

Considere a tabela:

Grupo	Sucesso	Fracasso
A	32	18
B	21	29
C	15	35

Teste a homogeneidade das proporções, calcule os resíduos ajustados e o V de Cramér. Identifique as células que mais contribuem para a rejeição.

i Exercício 17

Em uma tabela 2×2 com contagens $(8, 2; 1, 5)$, compare o teste qui-quadrado de Pearson, o teste com correção de continuidade e o teste exato de Fisher. Justifique qual resultado deve receber maior ênfase.

i Exercício 18

Para um teste qui-quadrado com $\nu = 3$, $\alpha = 0,05$, poder desejado de 0,90 e tamanho do efeito $w = 0,25$, determine numericamente o menor tamanho amostral usando a distribuição qui-quadrado não central.

6.25.6 Reamostragem e robustez

i Exercício 19

Em um experimento completamente randomizado, dois grupos independentes apresentam tamanhos $n_1 = 12$ e $n_2 = 15$. Descreva um teste de permutação para a diferença de médias, explicando qual hipótese nula é garantida pelo mecanismo de randomização e como calcular um valor- p Monte Carlo.

i Exercício 20

Construa um exemplo numérico em que o teste t com variâncias agrupadas e o teste de Welch produzam conclusões distintas. Investigue o papel do desbalanceamento amostral e da heteroscedasticidade.

Referências

7 Projetos Aplicados

7.1 Objetivo

O objetivo deste trabalho é aplicar os principais conceitos estudados na disciplina de Análise Inferencial em um problema real. Os estudantes deverão planejar uma pesquisa, definir um tamanho amostral adequado (usando as fórmulas dadas em sala de aula), coletar dados e realizar procedimentos de estimação (pontual e intervalar) e testes de hipóteses, apresentando e interpretando os resultados obtidos.

7.2 Descrição Geral

O trabalho deverá ser desenvolvido em grupos de até **3 integrantes**.

Cada grupo deverá escolher um tema de interesse e definir uma população-alvo para investigação. A variável de interesse poderá ser quantitativa ou qualitativa, desde que permita a aplicação dos métodos inferenciais estudados ao longo da disciplina.

7.2.1 Exemplos de Temas e Variáveis de Interesse

A seguir são apresentados alguns exemplos de temas e possíveis variáveis que podem ser investigadas. Os grupos não precisam se limitar às sugestões apresentadas.

1. Hábitos de Estudo dos Estudantes da UFC

Possíveis variáveis:

- Número de horas de estudo por semana;
- Número de disciplinas cursadas no semestre;
- Frequência às aulas (%);
- Tempo médio dedicado à resolução de exercícios;
- Número de reprovações acumuladas;
- Utilização de ferramentas de inteligência artificial para estudos (sim/não);
- Grau de satisfação com o próprio desempenho acadêmico (escala de 1 a 10);
- Coeficiente de rendimento acadêmico (IRA).

Exemplos de perguntas inferenciais:

- Qual é o número médio de horas de estudo dos estudantes?
- A média de horas de estudo é superior a 10 horas semanais?
- Mais de 50% dos estudantes utilizam ferramentas de inteligência artificial nos estudos?

2. Tempo de Deslocamento até a Universidade

Possíveis variáveis:

- Tempo diário de deslocamento (em minutos);
- Distância entre residência e universidade (em quilômetros);
- Número de meios de transporte utilizados;
- Gasto mensal com transporte;
- Frequência de atrasos devido ao deslocamento;
- Meio de transporte principal (ônibus, carro, bicicleta, moto, caminhada etc.).

Exemplos de perguntas inferenciais:

- Qual é o tempo médio de deslocamento dos estudantes?
- O tempo médio de deslocamento é superior a 40 minutos?
- Qual a proporção de estudantes que utilizam transporte público?

3. Consumo de Redes Sociais

Possíveis variáveis:

- Tempo diário gasto em redes sociais (horas);
- Número de redes sociais utilizadas regularmente;
- Rede social mais utilizada;
- Frequência de acesso às redes sociais;
- Tempo de uso durante atividades acadêmicas;
- Percepção sobre impacto das redes sociais no rendimento acadêmico.

Exemplos de perguntas inferenciais:

- Qual é o tempo médio diário de uso das redes sociais?
- Mais de 70% dos estudantes utilizam redes sociais por mais de 2 horas por dia?
- Existe evidência de que o tempo médio de uso seja superior a 3 horas diárias?

4. Prática de Atividades Físicas

Possíveis variáveis:

- Número de dias por semana em que pratica atividade física;
- Tempo semanal dedicado à atividade física;
- Tipo de atividade praticada;

- Frequência de participação em academias;
- Índice de Massa Corporal (IMC);
- Percepção do próprio condicionamento físico.

Exemplos de perguntas inferenciais:

- Qual é o tempo médio semanal dedicado à atividade física?
- Menos da metade dos estudantes pratica atividade física regularmente?
- Qual a proporção de estudantes que realizam exercícios pelo menos três vezes por semana?

5. Hábitos Alimentares

Possíveis variáveis:

- Número de refeições diárias;
- Consumo semanal de frutas;
- Consumo semanal de refrigerantes;
- Frequência de refeições no Restaurante Universitário; Gasto mensal com alimentação;
- Consumo diário de água (litros).

Exemplos de perguntas inferenciais:

- Qual é o consumo médio diário de água?
- Qual a proporção de estudantes que consomem frutas diariamente?
- O número médio de refeições por dia é igual a três?

6. Outros Temas

Os grupos poderão propor outros temas relacionados à realidade universitária ou a problemas de interesse social, desde que a proposta permita a aplicação dos métodos de inferência estatística estudados na disciplina.

Exemplos:

- Qualidade do sono;
- Uso de aplicativos de transporte;
- Educação financeira;
- Hábitos de leitura;
- Uso de plataformas de streaming;
- Saúde mental e bem-estar;
- Sustentabilidade e reciclagem;
- Consumo de café ou bebidas energéticas.

A escolha final deverá ser aprovada.

7.2.2 Etapas do Trabalho

7.2.2.1 Definição do Problema

O grupo deverá apresentar:

1. Tema escolhido;
2. Justificativa da pesquisa;
3. Objetivos do estudo;
4. População de interesse;
5. Variável ou variáveis analisadas.

7.2.2.2 Planejamento Amostral

O grupo deverá definir:

1. Nível de confiança adotado;
2. Margem de erro desejada;
3. Método de amostragem utilizado;
4. Justificativa dos parâmetros empregados no cálculo.

Em seguida, deverá ser realizado o cálculo do tamanho amostral adequado ao estudo. Quando necessário, valores preliminares poderão ser obtidos por meio de:

- Estudos anteriores;
- Literatura especializada;
- Estudo piloto

7.2.2.3 Coleta de Dados

O grupo deverá coletar uma amostra com tamanho igual ou superior ao valor calculado na etapa anterior. Devem ser descritos:

1. Procedimento de coleta;
2. Instrumento utilizado (questionário/formulário, medição etc.);
3. Período de coleta;
4. Possíveis limitações do processo.

7.2.2.4 Análise Descritiva dos Dados

Apresentar:

1. Tabelas de frequências (quando apropriado);
2. Gráficos adequados ao tipo de variável;
3. Medidas descritivas relevantes;
4. Comentários sobre os resultados observados.

7.2.2.5 Estimação Pontual

Identificar o parâmetro populacional de interesse e calcular sua estimativa pontual. Exemplos:

- Média populacional;
- Proporção populacional;
- Variância populacional.

O grupo deverá interpretar o significado da estimativa obtida no contexto do estudo.

7.2.2.6 Estimação Intervalar

Construir um intervalo de confiança para o parâmetro de interesse. A apresentação deverá conter:

- Nível de confiança utilizado;
- Fórmula empregada;
- Cálculos realizados;
- Interpretação do intervalo obtido.

7.2.2.7 Teste de Hipóteses

Formular um problema de decisão estatística relacionado ao estudo realizado. O relatório deverá conter:

- Hipótese nula (H_0);
- Hipótese alternativa (H_1);
- Nível de significância;
- Estatística de teste;
- p -valor (nível descritivo);
- Decisão final;
- Interpretação prática dos resultados.

7.2.2.8 Verificação das Condições de Aplicação

Os estudantes deverão discutir as condições necessárias para aplicação dos métodos utilizados. Quando pertinente, comentar aspectos como:

- Independência das observações;
- Normalidade;
- Tamanho amostral;
- Aproximações assintóticas;
- Possíveis fontes de viés.

7.2.2.9 Conclusões

Apresentar uma síntese dos principais resultados obtidos e responder aos objetivos definidos inicialmente. Também deverão ser discutidas possíveis limitações do estudo e sugestões para trabalhos futuros.

7.2.2.10 Estrutura do Relatório

O relatório final deverá conter:

- Introdução;
- Metodologia;
- Resultados;
- Discussão;
- Conclusões;
- Referências.

7.2.2.11 Entrega

A entrega deverá ser realizada em formato PDF por meio do SIGAA. Além do relatório, deverá ser entregue:

- Base de dados utilizada;
- Código utilizado nas análises (R, Python ou outro software estatístico).

7.2.3 Critérios de Avaliação

Critério	Pontuação
Definição do problema e planejamento amostral	2,0
Coleta e organização dos dados	1,0
Análise descritiva	1,5
Estimação pontual e intervalar	2,0
Teste de hipóteses	2,0
Qualidade do relatório e interpretação dos resultados	1,5
Total	10,0

7.2.4 Observações

- A simples apresentação de resultados computacionais não será suficiente para obtenção da pontuação máxima.
- As interpretações devem ser realizadas no contexto do problema estudado.
- Dúvidas poderão ser discutidas durante as aulas ou nos horários de atendimento ([Agendar Atendimento](#)).

8 Exemplos Aplicados

8.0.1 Exemplo Aplicado

Nesta seção, com o conjunto de dados dos estudantes disponível em [SOGA-Py](https://userpage.fu-berlin.de/soga/data/raw-data/students.csv). Você pode carregá-lo diretamente como um recurso da *web*. Vamos importar o conjunto de dados para o Python como um objeto **DataFrame** do pandas utilizando o método `read_csv`:

```
import pandas as pd
import numpy as np

estudantes = pd.read_csv("https://userpage.fu-berlin.de/soga/data/raw-data/students.csv")

estudantes.head()
```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
1	833917	Gonzales, Christina	Female	19	160	64.8	Muslim	1.91	1st	Political
2	898539	Lozano, T'Hani	Female	19	172	73.0	Other	1.56	2nd	Social S
3	379678	Williams, Hanh	Female	22	168	70.6	Protestant	1.24	3rd	Social S
4	807564	Nem, Denzel	Male	19	183	79.7	Other	1.37	2nd	Environ
5	383291	Powell, Heather	Female	21	175	71.4	Catholic	1.46	1st	Environ

O conjunto de dados **estudantes** consiste em 8.239 linhas, cada uma representando um estudante específico, e 16 colunas, cada uma correspondendo a uma variável/característica relacionada a esse estudante. Neste estudo, considera-se o conjunto completo de estudantes disponível na base de dados como a população de interesse. Além disso, a variável de interesse é o peso (massa corporal).

Aqui iremos considerar a variância conhecida, ou seja, iremos calcular diretamente a partir dos dados completos.

8.0.2 Variância e desvio-padrão populacionais

Como a base contém todos os 8.239 estudantes considerados neste estudo, a variância calculada corresponde à variância populacional.

```

N = len(estudantes)
sigma2 = estudantes["weight"].var(ddof=0) # variância populacional
sigma = estudantes["weight"].std(ddof=0) # desvio-padrão populacional

print(f"Tamanho da população: {N}")
print(f"Variância populacional: {sigma2:.2f}")
print(f"Desvio-padrão populacional: {sigma:.2f} kg")

```

Tamanho da população: 8239
 Variância populacional: 74.56
 Desvio-padrão populacional: 8.63 kg

8.0.3 Objetivo

Avaliar se a massa corporal média dos estudantes difere da massa corporal média da população adulta europeia, reportada por [Walpole et al. \(2012\)](#) como 70,8 kg. As hipóteses são:

$$H_0 : \mu = 70,8$$

e

$$H_A : \mu \neq 70,8$$

em que μ representa a massa corporal média dos estudantes.

8.0.4 Cálculo do tamanho mínimo de amostra

Foi adotada uma diferença mínima detectável de 2 kg em relação à média de referência de 70,8 kg. O tamanho amostral foi calculado para garantir poder estatístico de 80% e nível de significância de 5%, ou seja,

1. nível de confiança = 95%;
2. poder do teste = 80%;
3. diferença mínima detectável = 2 kg.

```

from scipy.stats import norm

alpha = 0.05
power = 0.80
delta = 2.0

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = ((z_alpha + z_beta) * sigma / delta)**2

print(f"Tamanho inicial da amostra: {np.ceil(n0):.0f}")

```

Tamanho inicial da amostra: 147

Como a população possui apenas 8.239 indivíduos, aplicaremos uma correção para população finita:

```

n = (n0 * N)/(n0 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho corrigido da amostra: {n}")

```

Tamanho corrigido da amostra: 144

8.0.5 Seleção da amostra aleatória

```

amostra = estudantes.sample(n=n, replace=False, random_state=123 )

amostra.head()

```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
3165	802420	Stravia, Kelly	Female	23	158	67.2	Catholic	3.85	1st	Political S
7715	307406	Ha, Edmond	Male	21	185	80.5	Catholic	2.21	5th	Social Sci
614	786879	Benson, Joseph	Male	22	174	75.2	Catholic	1.05	5th	Environm
1458	807680	Johnson, Xin	Male	24	187	83.4	Orthodox	1.64	3rd	Mathemat
4657	142413	Ward, Sendy	Female	23	155	61.6	Muslim	2.07	1st	Social Sci

8.0.6 Teste Z para uma média com variância conhecida

```
mu0 = 70.8

xbar = amostra["weight"].mean()

z = (xbar - mu0)/(sigma/np.sqrt(n))

print(f"Média amostral: {xbar:.2f}")
print(f"Estatística Z: {z:.4f}")
```

Média amostral: 72.84
Estatística Z: 2.8413

8.0.7 Cálculo do p-valor

```
from scipy.stats import norm

p_value = 2 * (1 - norm.cdf(abs(z)))

print(f"Valor-p: {p_value:.6f}")
```

Valor-p: 0.004493

8.0.8 Regra de Decisão

```
alpha = 0.05

if p_value < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

8.0.9 Intervalo de confiança de 95%

```
z_crit = norm.ppf(0.975)

erro = z_crit * sigma/np.sqrt(n)

li = xbar - erro
ls = xbar + erro

print(f"IC95%: ({li:.2f}, {ls:.2f})")
```

IC95%: (71.43, 74.25)

8.0.10 Conclusão

Como o p -valor calculado (0,004493) é consideravelmente inferior ao nível de significância adotado (0,05), a decisão estatística é rejeitar a hipótese nula, ou seja, de que a massa corporal média dos estudantes é igual a massa corporal média da população adulta europeia. Sendo assim, existe evidência estatisticamente significativa de que a média populacional é diferente do valor inicialmente suposto.

Note que a média populacional é:

```
mu_pop = estudantes["weight"].mean()

print(f"Média populacional: {mu_pop:.2f} kg")
```

Média populacional: 73.00 kg

8.1 Exemplo Aplicado

Agora iremos considerar a situação mais realista que é quando a variância populacional é desconhecida. Para calcular o tamanho mínimo de amostra iremos precisar estimar a variância populacional. Para isto, iremos usar uma amostra piloto.

8.1.1 Amostra piloto

```

amostra_piloto = estudantes.sample(n=50, replace=False, random_state=123 )

n_piloto = len(amostra_piloto)
s2 = amostra_piloto["weight"].var(ddof=1) # variância amostral
s = amostra_piloto["weight"].std(ddof=1) # desvio-padrão amostral

print(f"Tamanho da amostra piloto: {n_piloto}")
print(f"Variância amostral: {s2:.2f}")
print(f"Desvio-padrão amostral: {s:.2f} kg")

amostra_piloto.head()

```

Tamanho da amostra piloto: 50
 Variância amostral: 67.82
 Desvio-padrão amostral: 8.24 kg

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
3165	802420	Stravia, Kelly	Female	23	158	67.2	Catholic	3.85	1st	Political S
7715	307406	Ha, Edmond	Male	21	185	80.5	Catholic	2.21	5th	Social Sci
614	786879	Benson, Joseph	Male	22	174	75.2	Catholic	1.05	5th	Environm
1458	807680	Johnson, Xin	Male	24	187	83.4	Orthodox	1.64	3rd	Mathemat
4657	142413	Ward, Sendy	Female	23	155	61.6	Muslim	2.07	1st	Social Sci

8.1.2 Cálculo do tamanho mínimo de amostra

```

from scipy.stats import t

alpha = 0.05
power = 0.80
delta = 2.0

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)

n0 = ((z_alpha + z_beta) * s/delta)**2

print(f"Tamanho inicial da amostra (usando quantil da normal padrão): {np.ceil(n0):.0f}")

```

```
t_alpha = t.ppf(1 - alpha/2, df = n0-1)
t_beta = t.ppf(power, df = n0-1)
n1 = ((t_alpha + t_beta) * s/delta)**2

print(f"Tamanho inicial da amostra (usando quantil da t-student): {np.ceil(n1):.0f}")
```

Tamanho inicial da amostra (usando quantil da normal padrão): 134
Tamanho inicial da amostra (usando quantil da t-student): 136

Como a população possui apenas 8.239 indivíduos, aplicaremos uma correção para população finita:

```
n = (n1 * N)/(n1 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho corrigido da amostra: {n}")
```

Tamanho corrigido da amostra: 133

8.1.3 Seleção da amostra aleatória

Iremos considerar os estudantes coletados na amostra piloto na amostra final considerada para o estudo. Assim, iremos selecionar mais 81 estudantes. Como a semente aleatória é a mesma da amostra piloto, basta selecionar normalmente os 131 estudantes.

```
amostra = estudantes.sample(n=n, replace=False, random_state=123 )

amostra.head()
```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
3165	802420	Stravia, Kelly	Female	23	158	67.2	Catholic	3.85	1st	Political S
7715	307406	Ha, Edmond	Male	21	185	80.5	Catholic	2.21	5th	Social Sci
614	786879	Benson, Joseph	Male	22	174	75.2	Catholic	1.05	5th	Environm
1458	807680	Johnson, Xin	Male	24	187	83.4	Orthodox	1.64	3rd	Mathemat
4657	142413	Ward, Sendy	Female	23	155	61.6	Muslim	2.07	1st	Social Sci

8.1.4 Verificando normalidade dos dados

Agora, vamos testar a suposição de normalidade plotando um gráfico de probabilidade normal, frequentemente chamado de QQ plot. Se a variável tiver distribuição normal, o gráfico de probabilidade normal deverá ser aproximadamente linear.


```
import matplotlib.pyplot as plt
import scipy.stats as stats

fig, ax = plt.subplots()

stats.probplot(amostra["weight"], dist="norm", plot=ax)


ax.set_title("Q-Q plot (amostra)")
ax.set_ylabel("Quantis amostrais")
ax.set_xlabel("Quantis teóricos")

plt.show()
```



Observamos que os dados da amostra apresentam algum ruído, os desvios da linha reta na parte inferior sugerem que a distribuição dos dados é ligeiramente assimétrica, como pode ser visto no histograma abaixo.

```
plt.hist(amostra["weight"], bins=20)
plt.title("Histograma da variável weight")
plt.xlabel("Weight")
plt.ylabel("Frequência")
plt.show()
```



Podemos usar algum teste de hipótese para teste a normalidade dos dados. As hipóteses do teste são:

- Hipótese Nula: Os dados vem de uma distribuição normal.
- Hipótese Alternativa: Os dados observados não vêm da distribuição normal.

```
from statsmodels.stats.diagnostic import lilliefors
lilliefors(amostra["weight"], dist='norm')
```

```
(np.float64(0.0914358012704492), np.float64(0.014990422036609632))
```

```
from scipy.stats import anderson
anderson(amostra["weight"], dist='norm')
```

```
/tmp/ipykernel_3430720/1331499744.py:3: FutureWarning: As of SciPy 1.17, users must choose a
    anderson(amostra["weight"], dist='norm')
```

```
AndersonResult(statistic=np.float64(1.25076662006623), critical_values=array([0.558, 0.627, 0.675]),
    success: True
    message: '`anderson` successfully fit the distribution to the data.')
```

```
from scipy.stats import jarque_bera

jarque_bera(amostra["weight"])
```

```
SignificanceResult(statistic=np.float64(6.044887782508762), pvalue=np.float64(0.048682099107123))
```

```
from scipy.stats import normaltest

normaltest(amostra["weight"]) #teste de D'Agostino-Pearson
```

```
NormaltestResult(statistic=np.float64(6.212974555746504), pvalue=np.float64(0.044757901595882))
```

Se considerarmos um nível de significância de 1%, temos que a maioria dos testes não rejeita a hipótese de que os dados são provenientes de uma população normal. No entanto, ao considerarmos um nível de 5% temos que o resultado se inverte.

8.1.5 Teste t para uma média com variância desconhecida

```
mu0 = 70.8

xbar = amostra["weight"].mean()
s_amostral = amostra["weight"].std(ddof=1)

tc = (xbar - mu0)/(s_amostral/np.sqrt(n))

print(f"Desvio-Padrão amostral: {s_amostral:.2f}")
print(f"Média amostral: {xbar:.2f}")
print(f"Estatística t: {tc:.4f}")
```

```
Desvio-Padrão amostral: 8.28
Média amostral: 72.68
Estatística t: 2.6115
```

8.1.6 Cálculo do p-valor

```
from scipy.stats import t
gl = n-1

p_value = 2 * (1 - t.cdf(x=abs(tc), df = gl))

print(f"Valor-p: {p_value:.6f}")
```

Valor-p: 0.010058

```
from statsmodels.stats.weightstats import DescrStatsW

d = DescrStatsW(amostra["weight"])

t_stat, p_value, gl = d.ttest_mean(mu0)

print(d)
print(f"t = {t_stat:.4f}")
print(f"p = {p_value:.6f}")
print(f"gl = {gl:.0f}")
```

```
<statsmodels.stats.weightstats.DescrStatsW object at 0x749f31a69a90>
t = 2.6115
p = 0.010058
gl = 132
```

8.1.7 Regra de Decisão

```
alpha = 0.05

if p_value < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

8.1.8 Intervalo de confiança de 95%

```
t_crit = t.ppf(1-alpha/2, df = gl)

erro = t_crit * s_amostral/np.sqrt(n)

li = xbar - erro
ls = xbar + erro

print(f"IC95%: ({li:.2f}, {ls:.2f})")
```

IC95%: (71.25, 74.10)

8.1.9 Exemplo Aplicado

Segundo a *Deutsche Bischofskonferenz (Conferência Episcopal Alemã, DBK)*, aproximadamente 24% da população alemã se declara católica. Neste estudo, pretende-se investigar se a proporção de estudantes católicos difere da proporção observada na população geral da Alemanha.

Para isso, será obtida uma amostra aleatória de estudantes, a partir da qual será realizada uma inferência estatística sobre a proporção populacional. Em particular, o objetivo é testar a hipótese de igualdade entre a proporção de católicos no grupo de estudantes e o valor de referência de 0,24. Iremos considerar a seguintes hipótese:

$$H_0 : p = 0,24$$

e

$$H_A : p \neq 0,24$$

em que p representa a proporção dos estudantes que são católicos.

8.1.9.1 Cálculo do tamanho mínimo de amostra

Desejamos ter 80% de poder para detectar diferenças de pelo menos 2 pontos percentuais em relação ao valor de referência. Além disso, o valor de $p = 0.5$ maximiza a variância $p(1 - p)$ e, portanto, produz o maior tamanho amostral possível.

```

from scipy.stats import norm

alpha = 0.05
power = 0.80
delta = 0.02
p0 = 0.5
p1 = np.abs(p0-delta)

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = ((z_alpha*np.sqrt(p0*(1-p0)) + z_beta*np.sqrt(p1*(1-p1)) )/delta)**2

print(f"Tamanho inicial da amostra: {np.ceil(n0):.0f}")

```

Tamanho inicial da amostra: 4904

Como a população possui apenas 8.239 indivíduos, aplicaremos uma correção para população finita:

```

n = (n0 * N)/(n0 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho corrigido da amostra: {n}")

```

Tamanho corrigido da amostra: 3075

Agora iremos retirar uma amostra piloto para estimar a proporção de estudantes que são católicos.

```

amostra_piloto = estudantes.sample(n=50, replace=False, random_state=2026)

proporcao_catolica = (amostra_piloto["religion"] == "Catholic").mean()

print(f"Proporção de Católicos na amostra piloto: {proporcao_catolica}")

```

Proporção de Católicos na amostra piloto: 0.36

Agora, o tamanho de amostra mínimo será:

```

from scipy.stats import norm

alpha = 0.05
power = 0.80
delta = 0.02
p0 = proporcao_catolica
p1 = np.abs(p0-delta)

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = n0 = ((z_alpha*np.sqrt(p0*(1-p0)) + z_beta*np.sqrt(p1*(1-p1)) )/delta)**2

n = (n0 * N)/(n0 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho da amostra : {np.ceil(n0):.0f}")
print(f"Tamanho da amostra corrigido: {np.ceil(n):.0f}")

```

Tamanho da amostra : 4486
Tamanho da amostra corrigido: 2905

8.1.9.2 Seleção da amostra aleatória

Agora iremos selecionar aleatoriamente os 2905 estudantes.

```

amostra = estudantes.sample(n=n, replace=False, random_state=2026)

amostra.head()

```

	stud.id	name	gender	age	height	weight	religion	nc.score	semester	major
5101	529136	Gill, Lakota	Male	20	183	80.1	Other	1.71	>6th	Math
1885	776233	Martinez, Keyana	Female	22	160	59.7	Protestant	1.64	3rd	Social
6380	566509	Maryland, Travis	Male	24	169	66.7	Catholic	2.32	2nd	Math
1216	900121	Gallegos, Anthony	Male	22	178	76.2	Other	1.82	6th	Math
1290	610212	Aragon, Samantha	Female	23	167	64.1	Protestant	1.07	3rd	Social

8.1.9.3 Teste Z para uma proporção

```
p0 = 0.24

p_amostral = (amostra["religion"] == "Catholic").mean()

z = (p_amostral - p0)/(np.sqrt(p0*(1-p0)/n))

print(f"Proporção amostral: {p_amostral:.2f}")
print(f"Estatística Z: {z:.4f}")
```

Proporção amostral: 0.33
Estatística Z: 11.7642

8.1.9.4 Cálculo do p_{valor}

```
from scipy.stats import norm

p_value = 2 * (1 - norm.cdf(abs(z)))

print(f"Valor-p: {p_value:.6f}")
```

Valor-p: 0.000000

```
from statsmodels.stats.proportion import proportions_ztest

x = (amostra["religion"] == "Catholic").sum()

stat, p_value = proportions_ztest(
    count=x,
    nobs=n,
    value=0.24,
    prop_var = p0, #por padrao usa a proporcao amostral
    alternative='two-sided'
)

print(f"Estatística Z: {stat:.4f}")
print(f"Valor-p: {p_value:.6f}")
```

Estatística Z: 11.7642

Valor-p: 0.000000

Observação

A função `proportions_ztest()` do pacote `statsmodels` utiliza, por padrão, a proporção amostral para estimar a variância da estatística de teste.

8.1.9.5 Regra de Decisão

```
alpha = 0.05

if p_value < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

8.1.9.6 Intervalo de confiança de 95%

```
z_crit = norm.ppf(1-alpha/2)

erro = z_crit * np.sqrt(p_amostral*(1-p_amostral)/n)

li = p_amostral - erro
ls = p_amostral + erro

print(f"IC95%: ({li:.2f}, {ls:.2f})")
```

IC95%: (0.32, 0.35)

8.1.9.7 Conclusão

Ao nível de significância de 5%, os dados fornecem evidências suficientes para concluir que a proporção de estudantes católicos difere da proporção de 24% observada na população alemã segundo a DBK. O resultado sugere que a composição religiosa da população estudantil não reflete exatamente a composição religiosa da população geral.

8.1.10 Exemplo Prático

O Python permite realizar um teste t com variâncias combinadas utilizando a função `ttest_ind_from_stats()`, disponível no módulo `stats` do pacote `scipy`.

No exemplo, assumiremos que as variâncias das duas amostras são iguais. Portanto, o argumento `equal_var` da função será definido como `True`.

Para praticar a aplicação do teste t com variâncias combinadas, utilizaremos o conjunto de dados *estudantes*.

8.1.10.1 Hipóteses

Queremos verificar se existe diferença entre os ganhos de homens e mulheres graduados. Desta forma, queremos testar as seguintes hipóteses:

$$H_0 : \mu_1 = \mu_2$$

e

$$H_A : \mu_1 \neq \mu_2$$

em que μ_1 e μ_2 representam as médias salariais dos estudantes graduados do sexo masculino e feminino, respectivamente.

8.1.10.2 Preparação dos dados

Começamos com a preparação dos dados, que inclui as seguintes etapas:

1. Subdividimos o conjunto de dados com base na variável binária `graduated`, que indica se o estudante já se formou. O valor 1 representa “formado”, enquanto 0 indica “não formado”.
2. Em seguida, dividimos o conjunto de dados por gênero (masculino e feminino).
3. Depois, selecionamos aleatoriamente uma amostra de 50 estudantes do sexo feminino e 50 do sexo masculino de cada subconjunto e extraímos a média do salário anual (em euros) como variável de interesse.

Armazenaremos as informações de salário dos grupos masculino e feminino em variáveis separadas chamadas `amostra_homens` e `amostra_mulheres`. A informação relevante está armazenada na coluna `salary`.

```
estudantes_graduados = estudantes.loc[estudantes.graduated == 1] #filtra estudantes formados

homens_graduados = estudantes_graduados.loc[estudantes.gender == "Male"] #separa homens formados

mulheres_graduadas = estudantes_graduados.loc[estudantes.gender == "Female"] #separa mulheres formadas

n_piloto = 30

amostra_homens_piloto = homens_graduados.sample(n_piloto, random_state = 24, replace = False)

amostra_mulheres_piloto = mulheres_graduadas.sample(n_piloto, random_state = 24, replace = False)

s21_piloto = np.var(amostra_homens_piloto, ddof = 1)
s22_piloto = np.var(amostra_mulheres_piloto, ddof = 1)

n1 = n2 = n_piloto

alpha = 0.05
power = 0.90
delta = 5000

z_alpha = norm.ppf(1 - alpha/2)
z_beta = norm.ppf(power)
n0 = (((z_alpha + z_beta)/ delta)**2)*(s21_piloto + s22_piloto)

print(f"Razão entre as variâncias da amostra piloto: {np.sqrt(s21_piloto)/np.sqrt(s22_piloto)}")
print(f"Tamanho inicial da amostra: {np.ceil(n0):.0f}")
```

Razão entre as variâncias da amostra piloto: 1.34
Tamanho inicial da amostra: 62

A razão entre os desvios-padrão é aproximadamente 1,34 e, portanto, nota-se que a suposição de igualdade dos desvios-padrão populacionais parece razoável.

```
tol = 1
max_iter = 100
n0 = np.ceil(n0)
```

```

for i in range(max_iter):

    gl = 2*n0 - 2

    t_alpha = t.ppf(1 - alpha/2, df=gl)
    t_beta = t.ppf(power, df=gl)

    n_novo = (((t_alpha + t_beta)/delta)**2) * (s21_piloto + s22_piloto)

    # normalmente arredondamos para cima
    n_novo = np.ceil(n_novo)

    if n_novo == n0:
        break

    n0 = n_novo

n = int(np.ceil(n0))

print(f"Convergiu em {i+1} iterações")
print(f"n por grupo = {int(n)}")

```

Convergiu em 2 iterações
n por grupo = 63

8.1.11 Seleção da amostra

```

amostra_homens = homens_graduados.sample(n, random_state = 24, replace = False)["salary"] #S
amostra_mulheres = mulheres_graduadas.sample(n, random_state = 24, replace = False)["salary"]

```

```

import matplotlib.pyplot as plt
import scipy.stats as stats

plt.figure(figsize=(12,5))


ax = plt.subplot(1, 2, 1)
qq = stats.probplot(amostra_homens, dist="norm", plot = plt)
ax.set_title("Q-Q plot para homens (amostra)")

```



```
ax.set_ylabel("Quantis Amostrais")

ax = plt.subplot(1, 2, 2)
qq = stats.probplot(amostra_mulheres, dist="norm", plot = plt)
ax.set_title("Q-Q plot para mulheres (amostra)")
ax.set_ylabel("Quantis Amostrais")
```



Observamos que os dados da amostra apresentam certo nível de ruído, mas ainda seguem aproximadamente uma distribuição normal. Além disso, verificamos se os desvios-padrão das duas populações são aproximadamente iguais. Como regra prática, a condição de igualdade dos desvios-padrão populacionais é considerada satisfeita se a razão entre o maior e o menor desvio-padrão amostral for inferior a 2.

```
s1 = np.std(amostra_homens, ddof = 1)
s2 = np.std(amostra_mulheres, ddof = 1)

n1 = n2 = n

sc = np.sqrt(((n1 - 1) * s1**2 + (n2 - 1) * s2**2) / (n1 + n2 - 2))

print(f"Razão entre os desvios-padrão: {s1/s2:.2f}")
```

Razão entre os desvios-padrão: 1.36

Podemos analisar a suposição de igualdade das variâncias, fazendo um boxplot por gênero.


```
import seaborn as sns

plt.figure(figsize=(11,5))

amostra = pd.melt(pd.DataFrame({'Homens': amostra_homens.values, 'Mulheres': amostra_mulheres.values}),
                  ['Homens', 'Mulheres'],
                  value_name='Salário Anual em Euros')

amostra.columns = ["Gênero", "Salário Anual em Euros"]

sns.boxplot(x='Gênero',
            y='Salário Anual em Euros',
            hue='Gênero',
            data=amostra).set(title='Dados Amostrais')
```



8.1.11.1 Estatística de Teste

```
gl = 2*n-2
xbar1 = np.mean(amostra_homens)
xbar2 = np.mean(amostra_mulheres)

t_cal = (xbar1 - xbar2) / (sc * np.sqrt((1/n1) + (1/n2)))

p_valor = 1 - t.cdf(t_cal, df = gl)
p_valor
```

```
print(f"EGraus de Liberdade: {gl: 0f}")
print(f"Estatística de Teste: {t_cal:.2f}")
print(f"P-valor: {p_valor:.4f}")
```

EGraus de Liberdade: 124.000000
Estatística de Teste: 8.40
P-valor: 0.0000

8.1.11.2 Regra de Decisão

```
alpha = 0.05

if p_valor < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

8.1.11.3 Usando scipy

```
from scipy import stats

resultado_teste = stats.ttest_ind(amostra_homens, amostra_mulheres,
                                  equal_var = True,
                                  alternative = "two-sided")

resultado_teste
```

TtestResult(statistic=np.float64(8.402219821394947), pvalue=np.float64(8.59668283081678e-14))

8.1.11.4 Conclusão

Ao nível de significância de 1%, os dados fornecem evidências muito fortes para concluir que o salário médio dos graduados do sexo masculino é diferente do salário médio das graduadas do sexo feminino.

8.2 Inferências para duas médias populacionais com amostras independentes e variâncias desiguais

No exemplo, anterior poderíamos aplicar o teste de maneira prática e fácil usando a função `stats.ttest_ind()` com o argumento `equal_var = False`.

```
resultado_teste_Welch = stats.ttest_ind(amostra_homens, amostra_mulheres,
                                         equal_var = False,
                                         alternative = "two-sided")

resultado_teste_Welch
```

```
TtestResult(statistic=np.float64(8.402219821394947), pvalue=np.float64(1.3950391891186315e-11))
```

8.2.1 Exemplo Prático

Para ilustrar a aplicação do teste t pareado para amostras dependentes, estamos interessados em verificar se um tutorial online de Estatística auxilia os estudantes a melhorar seu desempenho acadêmico.

Existem três variáveis de interesse no conjunto de dados dos estudantes:

1. A variável 'online.tutorial' é uma variável binária que assume valor 1 se o estudante concluiu o tutorial online de Estatística e 0 caso contrário.
2. As variáveis `score1` e `score2` representam as notas (de 0 a 100) obtidas em duas avaliações de Matemática e Estatística. Quanto maior a nota, melhor o desempenho do estudante.
3. Observe que a primeira avaliação ocorre antes da participação dos estudantes no tutorial online de Estatística. A participação no tutorial é opcional, mas as duas avaliações são obrigatórias para todos os estudantes. A primeira prova (`score1`) é realizada no início do terceiro semestre, enquanto a segunda prova (`score2`) é realizada ao final do terceiro semestre.

Neste contexto, há duas questões de pesquisa de interesse:

- Verificar se o grupo de estudantes que participou do tutorial online de Estatística apresentou melhor desempenho na segunda avaliação em comparação com a primeira avaliação.
- Avaliar o desempenho do grupo de estudantes que não participou do tutorial online, comparando os resultados obtidos na primeira e na segunda avaliação.

8.2.2 Hipóteses

A hipótese nula afirma que não há diferença entre as médias das notas dos dois exames:

$$H_0 : \mu_1 = \mu_2$$

A hipótese alternativa indica que os alunos têm melhor desempenho no segundo exame:

$$H_A : \mu_1 < \mu_2$$

Isso caracteriza um teste de hipótese unilateral à esquerda

8.2.3 Preparação dos Dados e Amostra Piloto

```
subconjunto = estudantes.loc[estudantes["online.tutorial"] == 1]
n_piloto = 50
amostra_piloto = subconjunto.sample(n_piloto, random_state = 24)[["score1", "score2"]]
d_piloto = (amostra_piloto["score1"] - amostra_piloto["score2"]).to_frame(name="diferenca")
sd_piloto = np.std(d_piloto["diferenca"])
print(f"Desvio-padrão da diferença (amostra piloto) : {sd_piloto:.2f}")
```

Desvio-padrão da diferença (amostra piloto) : 6.75

8.3 Cálculo do tamanho amostral

```
from scipy.stats import t
alpha = 0.01
power = 0.80
delta = 2.0
z_alpha = norm.ppf(1 - alpha)
```

```

z_beta = norm.ppf(power)

n0 = ((z_alpha + z_beta) * sd_piloto/delta)**2

print(f"Tamanho inicial da amostra (usando quantil da normal padrão): {np.ceil(n0):.0f}")

t_alpha = t.ppf(1 - alpha, df = n0-1)
t_beta = t.ppf(power, df = n0-1)
n1 = ((t_alpha + t_beta) * s/delta)**2
N = 3182
n = (n1 * N)/(n1 + N - 1)
n = int(np.ceil(n))

print(f"Tamanho mínimo da amostra (usando quantil da t-student): {n:.0f}")

```

Tamanho inicial da amostra (usando quantil da normal padrão): 115
Tamanho mínimo da amostra (usando quantil da t-student): 166

8.3.1 Seleção da Amostra

```

amostra = subconjunto.sample(n, random_state = 24)[["score1", "score2"]]

```

8.3.2 Estatística de Teste

```

d = (amostra["score1"] - amostra["score2"]).to_frame(name="diferenca")

diff_mean = np.mean(d)
diff_std = np.sqrt((np.sum(d**2) - ((np.sum(d)**2) / n)) / (n - 1))

t_value = diff_mean / (diff_std / np.sqrt(n))

p = t.cdf(t_value, df = n-1)

print(f"EGraus de Liberdade: {n-1: 0f}")

```

```
print(f"Estatística de Teste: {t_value:.2f}")
print(f"P-valor: {p:.4f}")
```

EGraus de Liberdade: 165.000000
Estatística de Teste: -3.47
P-valor: 0.0003

8.3.2.1 Regra de Decisão

```
alpha = 0.01

if p < alpha:
    print("Rejeita H0")
else:
    print("Não rejeita H0")
```

Rejeita H0

8.3.2.2 Usando funções do Python

```
test_result = stats.ttest_rel(amostra["score1"], amostra["score2"], alternative = "less")

test_result
```

TtestResult(statistic=np.float64(-3.4665474965475522), pvalue=np.float64(0.00033609430208778))

8.3.2.3 Conclusão

Ao nível de significância de 1%, os dados fornecem evidência forte para concluir que as notas dos estudantes em exames melhoram após realizarem um tutorial online de aprendizagem de estatística.

8.4 Referências

9 Demonstrações

Este capítulo reúne 26 demonstrações consideradas estruturantes para um livro de Inferência Estatística destinado à graduação e ao mestrado. A organização segue seis blocos: resultados fundamentais de probabilidade; distribuições amostrais; redução de dados e estimação; verossimilhança e teoria assintótica; testes e intervalos; e inferência computacional e moderna.

As demonstrações foram reescritas em notação uniforme e com nível de detalhe adequado ao texto didático. Cada resultado contém uma indicação explícita da fonte principal, da localização aproximada na obra e do grau de adaptação realizado.

Escopo bibliográfico

As provas abaixo são adaptações didáticas das fontes indicadas. Quando a fonte apresenta apenas uma versão restrita do resultado, o enunciado preserva essa restrição. Generalizações não demonstradas nas obras consultadas são identificadas como observações que exigem verificação bibliográfica adicional.

Mapa das demonstrações e fontes

Nº	Demonstração	Fonte principal auditada
1	Lei fraca dos grandes números	Ramachandran; Tsokos (2009, seq. 3.5, Teorema 3.5.2)
2	Teorema Central do Limite por FGM	Larsen; Marx (2012, Apêndice 4.A.2)
3	Distribuições de $\bar{X}$ e S^2 no modelo normal	Larsen; Marx (2012, seq. 7.1–7.3 e Apêndice 7.A.2)
4	Independência entre $\bar{X}$ e S^2	Larsen; Marx (2012, Apêndice 7.A.2, Teorema 7.A.2.1)
5	Derivação da distribuição t	Larsen; Marx (2012, seq. 7.2–7.3)

Nº	Demonstração	Fonte principal auditada
6	Fatoração de Fisher–Neyman, versão discreta	Rice (2007, seq. 8.8.1)
7	Teorema de Rao–Blackwell	Rice (2007, seq. 8.8.2)
8	Teorema de Lehmann–Scheffé	Hogg; Craig (1978, cap. 10)
9	Desigualdade de Cramér–Rao	Hogg; Craig (1978, seq. 11.1)
10	Invariância do EMV sob transformação invertível	Chihara; Hesterberg (2022, seq. 6.3.5, Proposição 6.6)
11	Lema de Neyman–Pearson	Rice (2007, seq. 9.2)
12	Teorema de Karlin–Rubin	Rasch; Schott (2018, seq. 3.3.1, Teoremas 3.7–3.8)
13	Dualidade entre testes e regiões de confiança	Rice (2007, seq. 9.3)
14	Teorema de Gauss–Markov	Rasch; Schott (2018, Teorema 4.3)
15	Teste t de uma amostra como TRVG	Larsen; Marx (2012, Apêndice 7.A.3)
16	Consistência do EMV em famílias exponenciais regulares	Lauritzen (2023, seq. 5.3.1, Teorema 5.9)
17	Normalidade assintótica do EMV	Lauritzen (2023, seq. 5.3.2, Teorema 5.11)
18	Método delta univariado e multivariado	Lauritzen (2023, Apêndice A.2.3, Teorema A.19)
19	Equivalência assintótica de Wald, escore e razão de verossimilhanças	Cox (2006) [Capítulo 6]; Lauritzen (2023, seq. 5.3.3 e 5.4.4)
20	Teorema de Wilks em famílias exponenciais curvas	Lauritzen (2023, Teorema 5.39)
21	Monotonicidade do algoritmo EM	Gupta; Chen (2011, seq. 1.1 e 2.1)
22	Estimadores de Bayes sob três perdas	Ramachandran; Tsokos (2021, seq. 10.2.1, para perdas quadrática e absoluta)

Nº	Demonstração	Fonte principal auditada
23	Consistência de minimizadores convexos	Bickel; Doksum (2016, Proposição 9.2.1)
24	Função de influência e eficiência semiparamétrica	Bickel; Doksum (2016) [Seções 7.2.1 e 9.3, Proposição 9.3.3]; Wilcox (2022, seq. 2.1–2.2)
25	Validade exata de testes de permutação	Chihara; Hesterberg (2022, seq. 3.3)
26	Princípio <i>plug-in</i> e bootstrap da média	Chihara; Hesterberg (2022, seq. 5.2)

Resultados fundamentais de probabilidade

Demonstração 1 — Lei fraca dos grandes números para a média amostral

Enunciado

Sejam $X_1, \dots, X_n$ variáveis aleatórias independentes, com

$$E(X_i) = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2 < \infty.$$

Então, para todo $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \rightarrow 0,$$

isto é, $\bar{X}_n \xrightarrow{P} \mu$.

Demonstração

Pela independência,

$$E(\bar{X}_n) = \mu$$

e

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

Aplicando a desigualdade de Chebyshev,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Como $\sigma^2/(n\varepsilon^2) \rightarrow 0$, o teorema do confronto fornece

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \rightarrow 0.$$

Portanto, $\bar{X}_n \xrightarrow{P} \mu$.

Interpretação

A variância da média decresce à taxa $1/n$. A lei fraca não afirma que cada observação se aproxima de μ ; afirma que a média de um número crescente de observações se concentra probabilisticamente em torno de μ .

Fonte da demonstração

Fonte principal: Ramachandran; Tsokos (2009, seq. 3.5, Teorema 3.5.2).

Adaptação: notação modernizada e formulação direta em termos de convergência em probabilidade.

Demonstração 2 — Teorema Central do Limite por funções geradoras de momentos

Enunciado

Sejam $X_1, X_2, \dots$ variáveis aleatórias i.i.d., com $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 > 0$, e suponha que a função geradora de momentos exista em uma vizinhança de zero. Então

$$Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Demonstração

Defina

$$Y_i = \frac{X_i - \mu}{\sigma}.$$

Temos $E(Y_i) = 0$, $\text{Var}(Y_i) = 1$ e

$$Z_n = \frac{Y_1 + \dots + Y_n}{\sqrt{n}}.$$

Se $M_Y(t)$ é a FGM de Y_i , então, pela independência,

$$M_{Z_n}(t) = \left[M_Y \left(\frac{t}{\sqrt{n}} \right) \right]^n.$$

Como $M_Y(0) = 1$, $M'_Y(0) = 0$ e $M''_Y(0) = 1$, a expansão de Taylor em torno de zero fornece

$$M_Y(s) = 1 + \frac{s^2}{2} + o(s^2), \quad s \rightarrow 0.$$

Tomando $s = t/\sqrt{n}$,

$$M_Y \left(\frac{t}{\sqrt{n}} \right) = 1 + \frac{t^2}{2n} + o \left(\frac{1}{n} \right).$$

Logo,

$$M_{Z_n}(t) = \left[1 + \frac{t^2}{2n} + o \left(\frac{1}{n} \right) \right]^n \rightarrow \exp \left(\frac{t^2}{2} \right).$$

A função $\exp(t^2/2)$ é a FGM da distribuição normal padrão. Pelo teorema de continuidade para funções geradoras de momentos,

$$Z_n \xrightarrow{d} N(0, 1).$$

⚠ Condição importante

Esta demonstração exige a existência da FGM em uma vizinhança de zero. O Teorema Central do Limite de Lindeberg–Lévy requer apenas variância finita, mas sua prova geral não é esta. A extensão precisa deve ser verificada bibliograficamente antes de se retirar a hipótese sobre a FGM.

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, Apêndice 4.A.2).

Fonte complementar: Rice (2007, seq. 5.3).

Adaptação: uso da notação $o(n^{-1})$ para condensar a expansão apresentada nas fontes.

Distribuições amostrais

Demonstração 3 — Distribuições de $\bar{X}$ e S^2 no modelo normal

Enunciado

Se $X_1, \dots, X_n$ são i.i.d. $N(\mu, \sigma^2)$ e

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

então

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

e

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Demonstração

A média amostral é uma combinação linear de variáveis normais independentes. Portanto, é normal, com

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Para a segunda afirmação, padronize as observações:

$$Y_i = \frac{X_i - \mu}{\sigma}.$$

O vetor $Y = (Y_1, \dots, Y_n)^\top$ tem distribuição $N_n(0, I_n)$. Escolha uma matriz ortogonal A cuja última linha seja

$$\frac{1}{\sqrt{n}}(1, \dots, 1).$$

Defina $Z = AY$. Como transformações ortogonais preservam a distribuição normal padrão multivariada,

$$Z_1, \dots, Z_n$$

são independentes e $N(0, 1)$. Além disso,

$$Z_n = \sqrt{n} \bar{Y} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}.$$

A preservação da norma pela transformação ortogonal implica

$$\sum_{i=1}^n Y_i^2 = \sum_{j=1}^n Z_j^2.$$

Usando a decomposição

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2,$$

obtemos

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{j=1}^{n-1} Z_j^2.$$

O lado direito é soma dos quadrados de $n - 1$ normais padrão independentes. Assim,

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 \sim \chi_{n-1}^2.$$

Como

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{(n-1)S^2}{\sigma^2},$$

segue o resultado.

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, seq. 7.1–7.3 e Apêndice 7.A.2).

Adaptação: a normalidade de $\bar{X}$ é obtida por fechamento da família normal sob combinações lineares; a parte referente a S^2 segue a transformação ortogonal do Apêndice 7.A.2.

Demonstração 4 — Independência entre $\bar{X}$ e S^2

Enunciado

Sob as condições da demonstração anterior, $\bar{X}$ e S^2 são independentes.

Demonstração

Na transformação ortogonal anterior,

$$Z_n = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$$

e

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{j=1}^{n-1} Z_j^2.$$

O vetor Z possui componentes normais padrão independentes. Portanto, Z_n é independente do vetor

$$(Z_1, \dots, Z_{n-1}).$$

Como $\bar{X}$ é função apenas de Z_n e S^2 é função apenas de $(Z_1, \dots, Z_{n-1})$, segue que $\bar{X}$ e S^2 são independentes.

💡 Interpretação

No modelo normal, a informação amostral sobre posição, representada por $\bar{X}$, separa-se exatamente da informação residual sobre escala, representada por S^2 . Essa propriedade é

especial da distribuição normal e fundamenta a inferência exata baseada na distribuição t .

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, Apêndice 7.A.2, Teorema 7.A.2.1).

Adaptação: separação da conclusão de independência em uma demonstração própria para destacar sua função inferencial.

Demonstração 5 — Derivação da distribuição t de Student

Enunciado

Se $X_1, \dots, X_n$ são i.i.d. $N(\mu, \sigma^2)$, então

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Demonstração

Pelos resultados anteriores,

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$$

e

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

com Z e U independentes. Reescrevendo T ,

$$T = \frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{S/\sigma} = \frac{Z}{\sqrt{U/(n-1)}}.$$

Por definição, se $Z \sim N(0, 1)$ e $U \sim \chi_\nu^2$ são independentes, então

$$\frac{Z}{\sqrt{U/\nu}} \sim t_\nu.$$

Tomando $\nu = n - 1$, obtemos

$$T \sim t_{n-1}.$$

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, seq. 7.2–7.3 e Apêndice 7.A.2).

Adaptação: derivação apresentada como consequência direta dos dois resultados normais fundamentais.

Redução de dados e estimação

Demonstração 6 — Teorema da fatoração de Fisher–Neyman: versão discreta

Enunciado

Considere uma família de funções de probabilidade $\{f_\theta : \theta \in \Theta\}$ em um espaço amostral contável, com suporte comum $\mathcal{X}_0$. Uma estatística $T(X)$ é suficiente para θ se, e somente se, existem funções não negativas g_θ e h tais que

$$f_\theta(x) = g_\theta\{T(x)\}h(x), \quad x \in \mathcal{X}_0,$$

em que h não depende de θ .

Demonstração

Suponha primeiro que a fatoração seja válida. Para qualquer t pertencente à imagem de T no suporte comum,

$$P_\theta(T = t) = \sum_{x: T(x)=t} f_\theta(x) = g_\theta(t) \sum_{x: T(x)=t} h(x).$$

Logo, para $T(x) = t$,

$$P_\theta(X = x \mid T = t) = \frac{g_\theta(t)h(x)}{g_\theta(t) \sum_{u: T(u)=t} h(u)} = \frac{h(x)}{\sum_{u: T(u)=t} h(u)}.$$

Essa distribuição condicional não depende de θ . Portanto, T é suficiente.

Reciprocamente, suponha que T seja suficiente. Então existe uma função condicional comum, independente de θ , que denotaremos por

$$h(x) = P_\theta\{X = x \mid T = T(x)\},$$

bem definida no suporte comum pela suficiência. Defina ainda

$$g_{\theta}(t) = P_{\theta}(T = t).$$

Pela regra do produto,

$$f_{\theta}(x) = P_{\theta}(T = T(x))P(X = x \mid T = T(x)) = g_{\theta}(T(x))h(x).$$

Portanto, a fatoração é necessária e suficiente.

Extensão a famílias dominadas

A forma geral do teorema vale para famílias dominadas por uma medida comum. A demonstração acima foi deliberadamente restrita ao caso discreto com suporte comum; no caso geral, a necessidade da fatoração exige uma formulação cuidadosa por densidades e distribuições condicionais regulares.

Fonte da demonstração

Fonte principal: Rice (2007, seq. 8.8.1).

Adaptação: prova completa da versão discreta, com explicitação da hipótese de suporte comum; a versão dominada geral é apenas enunciada na observação.

Demonstração 7 — Teorema de Rao–Blackwell

Enunciado

Se T é suficiente para θ e W é um estimador não viesado de $g(\theta)$ com $E_{\theta}(W^2) < \infty$, então

$$W^* = E(W \mid T)$$

é não viesado e satisfaz

$$\text{Var}_{\theta}(W^*) \leq \text{Var}_{\theta}(W).$$

Demonstração

Pela propriedade da esperança iterada,

$$E_{\theta}(W^*) = E_{\theta}\{E_{\theta}(W \mid T)\} = E_{\theta}(W) = g(\theta).$$

Logo, W^* é não viesado. Como T é suficiente, a esperança condicional pode ser escolhida como uma função da amostra que não depende do parâmetro desconhecido.

Pela decomposição da variância total,

$$\text{Var}_{\theta}(W) = \text{Var}_{\theta}\{E_{\theta}(W \mid T)\} + E_{\theta}\{\text{Var}_{\theta}(W \mid T)\}.$$

O segundo termo é não negativo. Assim,

$$\text{Var}_{\theta}(W) \geq \text{Var}_{\theta}(W^*).$$

Além disso, há igualdade se, e somente se,

$$W = E_{\theta}(W \mid T)$$

quase certamente, isto é, se W já é uma função de T salvo em um conjunto nulo.

Interpretação

Condicionar em uma estatística suficiente remove a variabilidade de W que não carrega informação adicional sobre θ . O procedimento preserva o alvo e não aumenta o erro quadrático entre estimadores não viesados.

Fonte da demonstração

Fonte principal: Rice (2007, seq. 8.8.2).

Fonte complementar: Hogg; Craig (1978, seq. 10.2).

Adaptação: uso explícito da lei da variância total.

Demonstração 8 — Teorema de Lehmann–Scheffé

Enunciado

Se T é suficiente e completa para θ , e $\delta(T)$ é quadrado-integrável e não viesado para $g(\theta)$, então $\delta(T)$ é, a menos de igualdade quase certa, o único estimador não viesado de variância uniformemente mínima de $g(\theta)$.

Demonstração

Seja W qualquer estimador quadrado-integrável e não viesado de $g(\theta)$. Pelo teorema de Rao–Blackwell,

$$W^* = E(W \mid T)$$

é uma função de T , é não viesado e satisfaz

$$\text{Var}_\theta(W^*) \leq \text{Var}_\theta(W).$$

Como W^* e $\delta(T)$ são ambos não viesados,

$$E_\theta\{W^* - \delta(T)\} = 0$$

para todo θ . A completude de T implica

$$P_\theta\{W^* = \delta(T)\} = 1$$

para todo θ . Portanto,

$$\text{Var}_\theta\{\delta(T)\} = \text{Var}_\theta(W^*) \leq \text{Var}_\theta(W).$$

Como W era arbitrário, $\delta(T)$ é ENVUM.

Para provar unicidade, sejam $\delta_1(T)$ e $\delta_2(T)$ duas funções não viesadas de T para o mesmo alvo. Então

$$E_\theta\{\delta_1(T) - \delta_2(T)\} = 0$$

para todo θ . Pela completude,

$$\delta_1(T) = \delta_2(T)$$

quase certamente.

i Fonte da demonstração

Fonte principal: Hogg; Craig (1978, cap. 10, sequência entre Rao–Blackwell, completude e Lehmann–Scheffé).

Adaptação: prova reorganizada na forma moderna “existência por Rao–Blackwell e unicidade por completude”.

Demonstração 9 — Desigualdade de Cramér–Rao

Enunciado

Considere uma amostra i.i.d. de densidade $f(x; \theta)$ e um estimador quadrado-integrável W tal que

$$E_\theta(W) = g(\theta),$$

em que g é diferenciável. Sob condições que permitem diferenciar sob o sinal de integral, com suporte independente de θ e informação de Fisher finita e positiva,

$$\text{Var}_\theta(W) \geq \frac{[g'(\theta)]^2}{I_n(\theta)},$$

onde

$$I_n(\theta) = E_\theta \left[\left(\frac{\partial}{\partial \theta} \ell_n(\theta) \right)^2 \right].$$

Demonstração

Defina o escore

$$U_n(\theta) = \frac{\partial}{\partial \theta} \ell_n(\theta).$$

Pelas condições de regularidade,

$$E_\theta\{U_n(\theta)\} = 0.$$

Diferenciando $E_\theta(W) = g(\theta)$ em relação a θ ,

$$g'(\theta) = \int W(x) \frac{\partial}{\partial \theta} f_\theta(x) dx.$$

Como

$$\frac{\partial}{\partial \theta} f_\theta(x) = f_\theta(x) U_n(\theta; x),$$

segue que

$$g'(\theta) = E_\theta\{W U_n(\theta)\}.$$

Usando $E(U_n) = 0$,

$$g'(\theta) = E_\theta\{[W - g(\theta)] U_n(\theta)\} = \text{Cov}_\theta(W, U_n).$$

Pela desigualdade de Cauchy–Schwarz,

$$[g'(\theta)]^2 \leq \text{Var}_\theta(W) \text{Var}_\theta(U_n).$$

Como $\text{Var}(U_n) = I_n(\theta)$,

$$\text{Var}_\theta(W) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Regularidade

A prova falha quando o suporte depende de θ ou quando não se pode permutar diferenciação e integração. Modelos uniformes com extremo desconhecido são exemplos clássicos em que a forma regular da desigualdade não deve ser aplicada mecanicamente.

Fonte da demonstração

Fonte principal: Hogg; Craig (1978, seq. 11.1).

Fonte complementar: Larsen; Marx (2012, seq. 5.5, para a interpretação como limite inferior).

Adaptação: formulação para um alvo geral $g(\theta)$.

Demonstração 10 — Invariância do estimador de máxima verossimilhança

Enunciado

Se $\hat{\theta}$ maximiza $L(\theta; x)$ e $\eta = h(\theta)$ é uma transformação bijetiva, então o EMV de η é

$$\hat{\eta} = h(\hat{\theta}).$$

Demonstração

Escreva a verossimilhança na parametrização η como

$$L_{\eta}(\eta; x) = L_{\theta}(h^{-1}(\eta); x).$$

Como h é bijetiva, maximizar sobre η equivale a maximizar sobre θ . Para qualquer η existe exatamente um $\theta = h^{-1}(\eta)$ e

$$L_{\eta}(\eta; x) = L_{\theta}(\theta; x) \leq L_{\theta}(\hat{\theta}; x) = L_{\eta}(h(\hat{\theta}); x).$$

Portanto, $h(\hat{\theta})$ maximiza a verossimilhança na nova parametrização.

⚠ Transformações não injetivas

A fonte demonstra a propriedade para transformações invertíveis. A versão frequentemente citada para transformações não injetivas exige definir cuidadosamente a verossimilhança do parâmetro transformado, em geral por maximização sobre as fibras $\{\theta : h(\theta) = \eta\}$. Essa generalização precisa de verificação bibliográfica antes de ser apresentada como automática.

i Fonte da demonstração

Fonte principal: Chihara; Hesterberg (2022, seq. 6.3.5, Proposição 6.6).

Adaptação: escrita explícita da verossimilhança reparametrizada.

Demonstração 14 — Teorema de Gauss–Markov

Enunciado

No modelo linear

$$Y = X\beta + \varepsilon,$$

suponha que X tenha posto completo, $E(\varepsilon) = 0$ e

$$\text{Var}(\varepsilon) = \sigma^2 I_n.$$

Então, para qualquer combinação estimável $a^\top \beta$, o estimador de mínimos quadrados

$$a^\top \hat{\beta}, \quad \hat{\beta} = (X^\top X)^{-1} X^\top Y,$$

é o estimador linear não viesado de variância mínima.

Demonstração

Um estimador linear de $a^\top \beta$ tem a forma $c^\top Y$. Ele é não viesado se

$$E(c^\top Y) = c^\top X\beta = a^\top \beta$$

para todo β , ou seja,

$$X^\top c = a.$$

Defina

$$c_0 = X(X^\top X)^{-1}a.$$

Então $X^\top c_0 = a$, e

$$c_0^\top Y = a^\top \hat{\beta}.$$

Qualquer outro vetor c que satisfaça $X^\top c = a$ pode ser escrito como

$$c = c_0 + d,$$

com

$$X^\top d = 0.$$

Como c_0 pertence ao espaço coluna de X e d é ortogonal a esse espaço,

$$c_0^\top d = 0.$$

Assim,

$$\text{Var}(c^\top Y) = \sigma^2 c^\top c = \sigma^2 (c_0 + d)^\top (c_0 + d) = \sigma^2 c_0^\top c_0 + \sigma^2 d^\top d.$$

Logo,

$$\text{Var}(c^\top Y) \geq \text{Var}(c_0^\top Y),$$

com igualdade somente se $d = 0$. Portanto, $a^\top \hat{\beta}$ é BLUE.

i Fonte da demonstração

Fonte principal: Rasch; Schott (2018, Teorema 4.3).

Adaptação: prova reescrita na parametrização matricial usual $Y = X\beta + \varepsilon$ e em termos de projeções ortogonais.

Demonstração 22 — Estimadores de Bayes sob perdas quadrática, absoluta e 0–1

Seja $\pi(\theta \mid x)$ a distribuição posterior e

$$r(a \mid x) = E\{L(\theta, a) \mid x\}$$

o risco posterior de escolher a ação a .

Perda quadrática

Para

$$L(\theta, a) = (a - \theta)^2,$$

escreva $m = E(\theta \mid x)$. Então

$$E\{(a - \theta)^2 \mid x\} = E\{[(a - m) + (m - \theta)]^2 \mid x\}.$$

O termo cruzado é zero, pois $E(m - \theta \mid x) = 0$. Logo,

$$r(a \mid x) = (a - m)^2 + \text{Var}(\theta \mid x),$$

que é minimizado em

$$a^* = E(\theta \mid x).$$

Perda absoluta

Para

$$L(\theta, a) = |a - \theta|,$$

suponha uma posterior contínua. O risco pode ser escrito como

$$r(a \mid x) = \int_{-\infty}^a (a - \theta)\pi(\theta \mid x) d\theta + \int_a^{\infty} (\theta - a)\pi(\theta \mid x) d\theta.$$

Derivando em relação a a ,

$$\frac{d}{da}r(a | x) = P(\theta \leq a | x) - P(\theta > a | x) = 2F(a | x) - 1.$$

O mínimo ocorre quando

$$F(a | x) = \frac{1}{2}.$$

Portanto, qualquer mediana posterior é uma ação de Bayes.

Perda 0–1 no caso discreto

Se

$$L(\theta, a) = \begin{cases} 0, & a = \theta, \\ 1, & a \neq \theta, \end{cases}$$

então

$$r(a | x) = P(\theta \neq a | x) = 1 - P(\theta = a | x).$$

Minimizar o risco equivale a maximizar $P(\theta = a | x)$. Logo, a ação de Bayes é uma moda posterior.

Parâmetro contínuo e perda 0–1

Para posteriores contínuas, $P(\theta = a | x) = 0$ para todo ponto a , de modo que a perda pontual 0–1 não seleciona uma ação. A identificação da moda pode ser justificada por uma perda de vizinhança que tende à perda 0–1, mas essa passagem exige formulação adicional.

Fonte da demonstração

Fonte principal: Ramachandran; Tsokos (2021, seq. 10.2.1) para as perdas quadrática e absoluta.

Complemento autoral: o argumento para a perda 0–1 discreta é uma derivação direta do risco posterior e não foi localizado na seção citada da fonte principal.

Adaptação: a prova quadrática foi reescrita por decomposição em torno da média posterior; a prova da perda absoluta explicita a derivada do risco.

Verossimilhança e teoria assintótica

Demonstração 16 — Consistência do EMV em famílias exponenciais regulares

Enunciado

Considere uma família exponencial mínima e regular em forma canônica,

$$f_{\theta}(x) = h(x) \exp\{\theta^{\top} t(x) - \psi(\theta)\},$$

com θ em um conjunto aberto. O EMV é assintoticamente bem definido — isto é, existe com probabilidade tendendo a um — e

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

Demonstração

A log-verossimilhança média é

$$\frac{1}{n} \ell_n(\theta) = \theta^{\top} \bar{T}_n - \psi(\theta) + C(x),$$

onde

$$\bar{T}_n = \frac{1}{n} \sum_{i=1}^n t(X_i).$$

A equação de escore é

$$\nabla \psi(\hat{\theta}_n) = \bar{T}_n.$$

Defina o parâmetro de média

$$\tau(\theta) = E_{\theta}\{t(X)\} = \nabla\psi(\theta).$$

Em uma família mínima e regular,

$$D\tau(\theta) = \nabla^2\psi(\theta) = \text{Var}_{\theta}\{t(X)\}$$

é positiva definida. Consequentemente, τ é localmente invertível e, na parametrização mínima, injetiva. Como a imagem de τ é aberta, a lei dos grandes números implica que $\bar{T}_n$ pertence a essa imagem com probabilidade tendendo a um. Nesse evento,

$$\hat{\theta}_n = \tau^{-1}(\bar{T}_n).$$

Pela lei dos grandes números,

$$\bar{T}_n \xrightarrow{P} \tau(\theta).$$

Pela continuidade de τ^{-1} ,

$$\hat{\theta}_n = \tau^{-1}(\bar{T}_n) \xrightarrow{P} \tau^{-1}\{\tau(\theta)\} = \theta.$$



Escopo do resultado

Esta é uma prova para famílias exponenciais mínimas e regulares. Ela não constitui uma prova geral da consistência do EMV em modelos paramétricos arbitrários. Em modelos não regulares, com parâmetros incidentais ou suporte dependente do parâmetro, o EMV pode ser inconsistente.



Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema 5.9).

Adaptação: explicitação da equação de escore e do uso do mapa entre parâmetro canônico e parâmetro de média.

Demonstração 17 — Normalidade assintótica do EMV

Enunciado

Nas condições da demonstração anterior,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N_k\{0, I(\theta)^{-1}\},$$

onde

$$I(\theta) = \text{Var}_{\theta}\{t(X)\}$$

é a informação de Fisher por observação.

Demonstração

Pelo Teorema Central do Limite multivariado,

$$\sqrt{n}\{\bar{T}_n - \tau(\theta)\} \xrightarrow{d} N_k\{0, \kappa(\theta)\},$$

onde

$$\kappa(\theta) = \text{Var}_{\theta}\{t(X)\} = I(\theta).$$

Como

$$\hat{\theta}_n = \tau^{-1}(\bar{T}_n),$$

aplicamos o método delta à função τ^{-1} . Pelo teorema da função inversa,

$$D\tau^{-1}\{\tau(\theta)\} = [D\tau(\theta)]^{-1} = \kappa(\theta)^{-1}.$$

Portanto,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N_k(0, \kappa^{-1}\kappa\kappa^{-1}),$$

isto é,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N_k\{0, I(\theta)^{-1}\}.$$

💡 Interpretação

A matriz de covariância assintótica coincide com o inverso da informação de Fisher. Nesse sentido regular, o EMV alcança assintoticamente o limite informacional.

📖 Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema 5.11).

Adaptação: apresentação explícita como aplicação do TCL multivariado e do método delta ao mapa inverso.

Demonstração 18 — Método delta univariado e multivariado

Enunciado

Suponha que

$$\sqrt{n}(X_n - \xi) \xrightarrow{d} N_k(0, \Sigma)$$

e que $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ seja diferenciável em ξ . Então

$$\sqrt{n}\{g(X_n) - g(\xi)\} \xrightarrow{d} N_m\{0, Dg(\xi)\Sigma Dg(\xi)^\top\}.$$

Demonstração

Pela diferenciabilidade,

$$g(X_n) - g(\xi) = Dg(\xi)(X_n - \xi) + r(X_n - \xi),$$

com

$$\frac{\|r(h)\|}{\|h\|} \rightarrow 0 \quad \text{quando } h \rightarrow 0.$$

Como a convergência em distribuição da sequência escalada implica $X_n \xrightarrow{P} \xi$, temos

$$r(X_n - \xi) = o_P(\|X_n - \xi\|).$$

Multiplicando por $\sqrt{n}$,

$$\sqrt{n}\{g(X_n) - g(\xi)\} = Dg(\xi)\sqrt{n}(X_n - \xi) + o_P\{\sqrt{n}\|X_n - \xi\|\}.$$

A sequência $\sqrt{n}(X_n - \xi)$ é limitada em probabilidade, de modo que o termo de resto é $o_P(1)$. Assim,

$$\sqrt{n}\{g(X_n) - g(\xi)\} = Dg(\xi)\sqrt{n}(X_n - \xi) + o_P(1).$$

Pelo teorema de Slutsky,

$$\sqrt{n}\{g(X_n) - g(\xi)\} \xrightarrow{d} Dg(\xi)Z,$$

onde $Z \sim N_k(0, \Sigma)$. Como uma transformação linear de um vetor normal é normal,

$$Dg(\xi)Z \sim N_m\{0, Dg(\xi)\Sigma Dg(\xi)^\top\}.$$

No caso univariado,

$$\sqrt{n}\{g(X_n) - g(\xi)\} \xrightarrow{d} N(0, [g'(\xi)]^2 \sigma^2).$$

i Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema A.19).

Adaptação: notação de resto vetorial e explicitação do passo $o_P(1)$.

Demonstração 19 — Equivalência assintótica entre Wald, escore e razão de verossimilhanças

Enunciado

Considere um modelo regular uniparamétrico e o teste de

$$H_0 : \theta = \theta_0.$$

Defina

$$W_n = I_n(\theta_0)(\hat{\theta} - \theta_0)^2,$$

$$S_n = \frac{U_n(\theta_0)^2}{I_n(\theta_0)}$$

e

$$R_n = 2\{\ell_n(\hat{\theta}) - \ell_n(\theta_0)\}.$$

Sob H_0 e condições de regularidade,

$$W_n = S_n + o_P(1) = R_n + o_P(1),$$

e cada estatística converge para χ_1^2 .

Demonstração

A equação de escore no EMV é

$$U_n(\hat{\theta}) = 0.$$

Expanda em torno de θ_0 :

$$0 = U_n(\theta_0) + \ell_n''(\tilde{\theta})(\hat{\theta} - \theta_0),$$

onde $\tilde{\theta}$ está entre $\hat{\theta}$ e θ_0 . Sob regularidade,

$$-\ell_n''(\tilde{\theta}) = I_n(\theta_0) + o_P(n).$$

Logo,

$$\hat{\theta} - \theta_0 = \frac{U_n(\theta_0)}{I_n(\theta_0)} + o_P(n^{-1/2}).$$

Substituindo no estatístico de Wald,

$$W_n = I_n(\theta_0) \left[\frac{U_n(\theta_0)}{I_n(\theta_0)} + o_P(n^{-1/2}) \right]^2 = \frac{U_n(\theta_0)^2}{I_n(\theta_0)} + o_P(1) = S_n + o_P(1).$$

Agora expanda a log-verossimilhança em torno de $\hat{\theta}$:

$$\ell_n(\theta_0) = \ell_n(\hat{\theta}) + \frac{1}{2} \ell_n''(\bar{\theta})(\theta_0 - \hat{\theta})^2,$$

pois $U_n(\hat{\theta}) = 0$. Assim,

$$R_n = -\ell_n''(\bar{\theta})(\hat{\theta} - \theta_0)^2 = I_n(\theta_0)(\hat{\theta} - \theta_0)^2 + o_P(1) = W_n + o_P(1).$$

Por fim,

$$\frac{U_n(\theta_0)}{\sqrt{I_n(\theta_0)}} \xrightarrow{d} N(0, 1),$$

portanto

$$S_n \xrightarrow{d} \chi_1^2,$$

e o mesmo vale para W_n e R_n .

i Fonte da demonstração

Fontes principais: Cox (2006) [Capítulo 6, aproximação quadrática da log-verossimilhança]; Lauritzen (2023, seq. 5.3.3 e 5.4.4).

Adaptação: prova escalar unificada por duas expansões de Taylor.

Demonstração 20 — Teorema de Wilks para uma subfamília exponencial curva

Enunciado

Considere uma família exponencial curva regular de dimensão m contendo uma subfamília curva regular de dimensão d . Sob a hipótese de que o parâmetro verdadeiro pertence à subfamília,

$$-2 \log \Lambda_n = 2\{\ell_n(\hat{\theta}) - \ell_n(\tilde{\theta})\} \xrightarrow{d} \chi_{m-d}^2,$$

onde $\hat{\theta}$ é o EMV irrestrito e $\tilde{\theta}$ é o EMV sob a restrição.

Demonstração

Sob regularidade, a log-verossimilhança admite uma aproximação quadrática local. Em coordenadas padronizadas pela informação de Fisher, escreva

$$h = \sqrt{n} I(\theta_0)^{1/2} (\theta - \theta_0).$$

Uniformemente em conjuntos limitados de h ,

$$\ell_n \left(\theta_0 + \frac{I(\theta_0)^{-1/2} h}{\sqrt{n}} \right) - \ell_n(\theta_0) = h^\top Z_n - \frac{1}{2} h^\top h + o_P(1),$$

com

$$Z_n \xrightarrow{d} N_m(0, I_m).$$

No modelo irrestrito, a função quadrática é maximizada em $h = Z_n$, com máximo

$$\frac{1}{2} \|Z_n\|^2.$$

Localmente, a hipótese restrita corresponde a um subespaço tangente $\mathcal{T}$ de dimensão d . O máximo restrito ocorre na projeção ortogonal $\Pi_{\mathcal{T}} Z_n$, com valor

$$\frac{1}{2} \|\Pi_{\mathcal{T}} Z_n\|^2.$$

Consequentemente,

$$-2 \log \Lambda_n = \|Z_n\|^2 - \|\Pi_{\mathcal{T}} Z_n\|^2 + o_P(1) = \|\Pi_{\mathcal{T}^\perp} Z_n\|^2 + o_P(1).$$

O complemento ortogonal $\mathcal{T}^\perp$ tem dimensão $m - d$. A projeção de um vetor $N_m(0, I_m)$ sobre esse espaço tem $m - d$ componentes normais padrão independentes. Portanto,

$$\|\Pi_{\mathcal{T}^\perp} Z_n\|^2 \sim \chi_{m-d}^2,$$

e o resultado segue por Slutsky.

Escopo e generalização

Esta é a versão demonstrada por Lauritzen para subfamílias curvas de famílias exponenciais curvas. Uma formulação para modelos paramétricos regulares mais gerais exige hipóteses adicionais de diferenciabilidade quadrática, identificabilidade, existência e consistência dos estimadores e controle uniforme do resto. Não se deve usar a aproximação χ^2 automaticamente em problemas de fronteira ou não identificáveis.

Fonte da demonstração

Fonte principal: Lauritzen (2023, Teorema 5.39 e resultados geométricos imediatamente anteriores).

Adaptação: apresentação em coordenadas informacionais e por projeção no espaço tangente, preservando o escopo de família exponencial curva da fonte.

Testes de hipóteses e intervalos de confiança

Demonstração 11 — Lema de Neyman–Pearson

Enunciado

Para testar duas hipóteses simples

$$H_0 : f = f_0 \quad \text{contra} \quad H_1 : f = f_1,$$

o teste que rejeita H_0 quando

$$\frac{f_1(x)}{f_0(x)} > k$$

é o teste mais poderoso entre todos os testes de nível no máximo α , escolhendo-se k e eventual randomização na fronteira para obter o nível desejado.

Demonstração

Seja φ o teste da razão de verossimilhanças e ψ qualquer outro teste com

$$E_0(\psi) \leq E_0(\varphi) = \alpha.$$

Pela construção de φ ,

$$[\varphi(x) - \psi(x)]\{f_1(x) - kf_0(x)\} \geq 0$$

para todo x : na região em que $f_1 - kf_0 > 0$, φ toma o maior valor possível; fora dela, toma o menor.

Integrando,

$$\int (\varphi - \psi)f_1 \geq k \int (\varphi - \psi)f_0.$$

O lado direito é não negativo, pois

$$\int \varphi f_0 - \int \psi f_0 = E_0(\varphi) - E_0(\psi) \geq 0.$$

Logo,

$$E_1(\varphi) - E_1(\psi) \geq 0.$$

Portanto, a potência de φ é pelo menos tão grande quanto a de qualquer teste concorrente de nível não superior a α .

i Fonte da demonstração

Fonte principal: Rice (2007, seq. 9.2).

Fonte complementar: Ramachandran; Tsokos (2021, capítulo de testes de hipóteses).

Adaptação: razão escrita como f_1/f_0 e prova expressa por funções de teste.

Demonstração 12 — Teorema de Karlin–Rubin

Enunciado

Suponha que a família de distribuições da estatística suficiente T tenha razão de verossimilhanças monótona crescente em T . Para testar

$$H_0 : \theta \leq \theta_0 \quad \text{contra} \quad H_1 : \theta > \theta_0,$$

o teste que rejeita para valores grandes de T e tem tamanho α em θ_0 é uniformemente mais poderoso de nível α .

Demonstração

Escolha c e, se necessário, uma probabilidade de randomização γ tais que

$$E_{\theta_0} \{\varphi(T)\} = \alpha,$$

onde

$$\varphi(t) = \begin{cases} 1, & t > c, \\ \gamma, & t = c, \\ 0, & t < c. \end{cases}$$

Fixe uma alternativa $\theta_1 > \theta_0$. A razão

$$\frac{f_T(t; \theta_1)}{f_T(t; \theta_0)}$$

é crescente em t . Pelo lema de Neyman–Pearson, o teste mais poderoso para

$$H_0 : \theta = \theta_0 \quad \text{contra} \quad H_1 : \theta = \theta_1$$

rejeita para valores grandes de T . A região crítica é a mesma para qualquer $\theta_1 > \theta_0$, pois o ponto de corte é determinado pela distribuição em θ_0 e pelo nível α .

Além disso, a propriedade de razão de verossimilhanças monótona implica que

$$E_\theta\{\varphi(T)\}$$

é não decrescente em θ . Consequentemente,

$$\sup_{\theta \leq \theta_0} E_\theta\{\varphi(T)\} = E_{\theta_0}\{\varphi(T)\} = \alpha.$$

Logo, φ é um teste de nível α para a hipótese composta. Como ele é mais poderoso para cada alternativa simples $\theta_1 > \theta_0$, é uniformemente mais poderoso contra toda a alternativa unilateral.

i Fonte da demonstração

Fonte principal: Rasch; Schott (2018, seq. 3.3.1, Teoremas 3.6–3.8 e Corolário 3.3).

Adaptação: o resultado é apresentado sob o nome usual de Karlin–Rubin, combinando o argumento de monotonicidade da potência com Neyman–Pearson.

Demonstração 13 — Dualidade entre testes e regiões de confiança

Enunciado

Para cada θ_0 , suponha que $A(\theta_0)$ seja a região de não rejeição de um teste de nível α de

$$H_0 : \theta = \theta_0,$$

de modo que

$$P_{\theta_0}\{X \notin A(\theta_0)\} \leq \alpha.$$

Então

$$C(X) = \{\theta_0 : X \in A(\theta_0)\}$$

é uma região de confiança com cobertura pelo menos $1 - \alpha$:

$$P_{\theta_0}\{\theta_0 \in C(X)\} \geq 1 - \alpha.$$

Se cada teste possui tamanho exatamente α em θ_0 , a cobertura é exatamente $1 - \alpha$.

Demonstração

Pela definição de $C(X)$,

$$\{\theta_0 \in C(X)\} = \{X \in A(\theta_0)\}.$$

Portanto,

$$\begin{aligned} P_{\theta_0}\{\theta_0 \in C(X)\} &= P_{\theta_0}\{X \in A(\theta_0)\} \\ &= 1 - P_{\theta_0}\{X \notin A(\theta_0)\} \\ &\geq 1 - \alpha. \end{aligned}$$

Quando $P_{\theta_0}\{X \notin A(\theta_0)\} = \alpha$, todas as desigualdades anteriores tornam-se igualdades.

Reciprocamente, se $C(X)$ satisfaz

$$P_{\theta_0}\{\theta_0 \in C(X)\} \geq 1 - \alpha$$

para todo θ_0 , então

$$A(\theta_0) = \{x : \theta_0 \in C(x)\}$$

é a região de não rejeição de um teste de nível no máximo α de $H_0 : \theta = \theta_0$.

Interpretação

Uma região de confiança é o conjunto dos valores do parâmetro que não seriam rejeitados por uma família coerente de testes. Essa equivalência é matemática; ela não transforma a cobertura frequentista em probabilidade posterior do parâmetro.

Fonte da demonstração

Fonte principal: Rice (2007, seq. 9.3, Teoremas A e B).

Demonstração 15 — Teste t de uma amostra como teste da razão de verossimilhanças generalizada

Enunciado

Para uma amostra i.i.d. $N(\mu, \sigma^2)$, o teste bilateral de

$$H_0 : \mu = \mu_0 \quad \text{contra} \quad H_1 : \mu \neq \mu_0$$

baseado na razão de verossimilhanças generalizada rejeita para valores grandes de

$$|T| = \left| \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \right|.$$

Demonstração

A verossimilhança é

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \right\}.$$

No modelo irrestrito,

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Sob H_0 ,

$$\tilde{\mu} = \mu_0, \quad \tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2.$$

Após substituir esses estimadores, a razão é

$$\Lambda = \left[\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sum_{i=1}^n (X_i - \mu_0)^2} \right]^{n/2}.$$

Pela identidade

$$\sum_{i=1}^n (X_i - \mu_0)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu_0)^2,$$

obtemos

$$\Lambda = \left[1 + \frac{n(\bar{X} - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]^{-n/2}.$$

Como

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

segue que

$$\Lambda = \left(1 + \frac{T^2}{n-1} \right)^{-n/2}.$$

Essa expressão é estritamente decrescente em T^2 . Portanto, rejeitar para valores pequenos de Λ equivale a rejeitar para valores grandes de $|T|$. Sob H_0 , $T \sim t_{n-1}$, produzindo o teste t bilateral usual.

i Fonte da demonstração

Fonte principal: Larsen; Marx (2012, Apêndice 7.A.3).

Adaptação: notação de razão de verossimilhanças e simplificação algébrica preservadas da fonte.

Inferência computacional, reamostragem e métodos modernos

Demonstração 21 — Monotonicidade do algoritmo EM

Definição

Se Y é o dado observado, Z é o dado latente e $X = (Y, Z)$ é o dado completo, suponha que as distribuições envolvidas sejam dominadas por medidas comuns, que os suportes relevantes não variem com θ e que as esperanças abaixo sejam finitas. Defina

$$Q(\theta \mid \theta^{(m)}) = E_{\theta^{(m)}}\{\log p(Y, Z \mid \theta) \mid Y = y\}.$$

O passo M escolhe $\theta^{(m+1)}$ de modo que

$$Q(\theta^{(m+1)} \mid \theta^{(m)}) \geq Q(\theta^{(m)} \mid \theta^{(m)}).$$

Demonstração

Seja

$$q_m(z) = p(z \mid y, \theta^{(m)}).$$

Para qualquer θ ,

$$\log p(y \mid \theta) = \log p(y, z \mid \theta) - \log p(z \mid y, \theta).$$

Tomando esperança em relação a q_m ,

$$\ell(\theta) = Q(\theta \mid \theta^{(m)}) - E_{q_m}\{\log p(Z \mid y, \theta)\}.$$

Adicione e subtraia $E_{q_m}\{\log q_m(Z)\}$. Pela definição da divergência de Kullback–Leibler,

$$D_{\text{KL}}\{q_m \| p(\cdot | y, \theta)\} = E_{q_m} \left[\log \frac{q_m(Z)}{p(Z | y, \theta)} \right].$$

Logo,

$$\ell(\theta) = Q(\theta | \theta^{(m)}) - E_{q_m} \{\log q_m(Z)\} + D_{\text{KL}}\{q_m \| p(\cdot | y, \theta)\}.$$

Ao tomar $\theta = \theta^{(m)}$, a divergência é zero. Portanto,

$$\ell(\theta) - \ell(\theta^{(m)}) = Q(\theta | \theta^{(m)}) - Q(\theta^{(m)} | \theta^{(m)}) + D_{\text{KL}}\{q_m \| p(\cdot | y, \theta)\}.$$

Como a divergência KL é não negativa,

$$\ell(\theta) - \ell(\theta^{(m)}) \geq Q(\theta | \theta^{(m)}) - Q(\theta^{(m)} | \theta^{(m)}).$$

Aplicando essa desigualdade a $\theta^{(m+1)}$,

$$\ell(\theta^{(m+1)}) \geq \ell(\theta^{(m)}).$$

⚠ O que a monotonicidade não garante

O aumento da log-verossimilhança não garante convergência ao máximo global. O algoritmo pode convergir para um máximo local, ponto estacionário ou fronteira, e a sequência de parâmetros exige hipóteses adicionais para convergir. Além disso, a demonstração pode falhar quando o suporte do dado completo depende do parâmetro.

i Fonte da demonstração

Fonte principal: Gupta; Chen (2011, seq. 1.1 e 2.1).

Adaptação: prova escrita pela decomposição da log-verossimilhança em Q e divergência KL.

Demonstração 23 — Consistência de minimizadores convexos

Enunciado

Sejam $Q_n : \mathbb{R}^d \rightarrow \mathbb{R}$ funções aleatórias convexas e Q uma função determinística. Suponha que:

1. $Q_n \rightarrow Q$ uniformemente em probabilidade em todo compacto;
2. Q é contínua, estritamente convexa e coerciva;
3. $\hat{t}_n \in \operatorname{argmin} Q_n$ e $t_0 = \operatorname{argmin} Q$.

Então

$$\hat{t}_n \xrightarrow{P} t_0.$$

Demonstração

A estrita convexidade e a coercividade de Q garantem que t_0 existe e é único. Fixe $\varepsilon > 0$. Pela continuidade e unicidade do mínimo,

$$\delta_\varepsilon = \inf_{\|t-t_0\|=\varepsilon} \{Q(t) - Q(t_0)\} > 0.$$

A convergência uniforme em probabilidade na esfera compacta e em uma vizinhança de t_0 implica que, com probabilidade tendendo a um,

$$\inf_{\|t-t_0\|=\varepsilon} Q_n(t) > Q_n(t_0).$$

Suponha, por contradição, que $\|\hat{t}_n - t_0\| > \varepsilon$. Pela convexidade, existe $\lambda \in (0, 1)$ tal que

$$t_1 = \lambda \hat{t}_n + (1 - \lambda)t_0$$

satisfaz $\|t_1 - t_0\| = \varepsilon$. Como $\hat{t}_n$ minimiza Q_n ,

$$Q_n(t_1) \leq \lambda Q_n(\hat{t}_n) + (1 - \lambda)Q_n(t_0) \leq Q_n(t_0).$$

Isso contradiz a desigualdade anterior na esfera. Logo,

$$P(\|\hat{t}_n - t_0\| > \varepsilon) \rightarrow 0.$$

Interpretação

O resultado é um princípio geral de consistência para M -estimadores: se a função-objetivo amostral aproxima uniformemente uma função populacional com mínimo bem separado, os minimizadores amostrais aproximam o minimizador populacional.

Fonte da demonstração

Fonte principal: Bickel; Doksum (2016, Proposição 9.2.1).

Adaptação: preservação do argumento geométrico na esfera de raio ε .

Demonstração 24 — Função de influência e eficiência semiparamétrica

Função de influência de um funcional

Para um funcional estatístico $T(P)$, a função de influência sob contaminação pontual é, quando a derivada existe,

$$\text{IF}(x; T, P) = \left. \frac{d}{d\varepsilon} T\{(1 - \varepsilon)P + \varepsilon\Delta_x\} \right|_{\varepsilon=0}.$$

Ela mede a sensibilidade local de primeira ordem do funcional a uma contaminação infinitesimal no ponto x .

Duas noções relacionadas

A função de influência de um **funcional**, definida por derivada de contaminação, e a função de influência de um **estimador regular assintoticamente linear** são conceitos relacionados, mas não idênticos por definição. Sob condições adequadas de diferenciabilidade, a expansão do funcional avaliado na distribuição empírica produz a função de influência assintótica do estimador *plug-in*. A projeção eficiente abaixo refere-se à segunda noção.

Resultado de eficiência semiparamétrica

Considere um modelo semiparamétrico em P cujo espaço tangente $\dot{\mathcal{P}}$ seja um subespaço linear fechado de $L_2^0(P)$. Suponha que exista um estimador regular e assintoticamente linear do parâmetro, com função de influência $\psi \in L_2^0(P)$. Então a função de influência eficiente é

$$\psi_{\text{ef}} = \Pi(\psi \mid \dot{\mathcal{P}}),$$

isto é, a projeção ortogonal de ψ sobre o espaço tangente.

Demonstração

Pela decomposição ortogonal de Hilbert,

$$\psi = \Pi(\psi \mid \dot{\mathcal{P}}) + \Pi(\psi \mid \dot{\mathcal{P}}^\perp).$$

As equações que caracterizam uma função de influência regular envolvem seus produtos internos com os escores dos submodelos paramétricos regulares. Esses escores pertencem a $\dot{\mathcal{P}}$. Para qualquer escore $s \in \dot{\mathcal{P}}$,

$$\langle \psi, s \rangle = \langle \Pi(\psi \mid \dot{\mathcal{P}}), s \rangle,$$

pois o componente em $\dot{\mathcal{P}}^\perp$ é ortogonal a s . Portanto, a projeção preserva as equações de derivada que definem uma função de influência regular.

Pelo teorema de Pitágoras,

$$\|\psi\|_2^2 = \|\Pi(\psi \mid \dot{\mathcal{P}})\|_2^2 + \|\Pi(\psi \mid \dot{\mathcal{P}}^\perp)\|_2^2.$$

Consequentemente,

$$E_P(\psi_{\text{ef}}^2) \leq E_P(\psi^2).$$

Como a variância assintótica de um estimador regular assintoticamente linear é determinada por $E_P(\psi^2)$, a projeção possui a menor variância entre as funções de influência regulares admissíveis e é eficiente.

i Robustez

Eficiência semiparamétrica e robustez local são critérios distintos. Em análise robusta, uma função de influência limitada controla o efeito local de contaminações extremas. A função de influência eficiente no modelo semiparamétrico pode ser não limitada.

i Fonte da demonstração

Fonte principal: Bickel; Doksum (2016) [Seção 7.2.1, para funções de influência e derivadas funcionais; Seção 9.3 e Proposição 9.3.3, para projeção eficiente].

Fonte complementar: Wilcox (2022, seq. 2.1–2.2, para a interpretação robusta).

Demonstração 25 — Validade exata de um teste de permutação

Enunciado

Suponha que, sob H_0 , as observações sejam permutáveis em relação aos rótulos dos grupos. Seja $\mathcal{G}$ o conjunto finito das permutações admissíveis e T uma estatística em que valores grandes contradizem H_0 . Defina

$$p(x) = \frac{1}{|\mathcal{G}|} \sum_{g \in \mathcal{G}} \mathbf{1}\{T(gx) \geq T(x)\}.$$

Então

$$P_{H_0}\{p(X) \leq \alpha\} \leq \alpha.$$

Se não há empates e os níveis possíveis são compatíveis com $|\mathcal{G}|$, a igualdade é exata.

Demonstração

Condicione na órbita

$$\mathcal{O}(x) = \{gx : g \in \mathcal{G}\}.$$

Sob a hipótese nula de permutabilidade, todos os elementos da órbita são equiprováveis. Portanto, a posição de $T(X)$ entre os valores

$$\{T(gx) : g \in \mathcal{G}\}$$

é uniforme, na ausência de empates.

Se os valores forem ordenados do maior para o menor, $p(X)$ é a proporção de valores da órbita que são pelo menos tão extremos quanto o valor observado. Assim, a condição $p(X) \leq \alpha$ só

pode ocorrer quando $T(X)$ está entre os no máximo $\alpha|\mathcal{G}|$ valores mais extremos da órbita. Condicionalmente à órbita,

$$P_{H_0}\{p(X) \leq \alpha \mid \mathcal{O}(X)\} \leq \frac{\lfloor \alpha|\mathcal{G}| \rfloor}{|\mathcal{G}|} \leq \alpha.$$

Tomando esperança sobre a órbita,

$$P_{H_0}\{p(X) \leq \alpha\} \leq \alpha.$$

Empates tornam o teste conservador quando se usa a desigualdade $\geq$.

⚠ Condição essencial

A validade exata exige permutabilidade ou uma atribuição aleatória conhecida. Igualdade de médias, isoladamente, não garante que todos os rearranjos dos dados sejam equiprováveis. Em estudos observacionais, a interpretação causal também não decorre do teste de permutação.

i Fonte da demonstração

Fonte principal: Chihara; Hesterberg (2022, seq. 3.3, argumento de equiprobabilidade das divisões sob H_0).

Adaptação: a obra apresenta a justificativa por equiprobabilidade; a formulação acima explicita o mesmo argumento em termos de órbitas de um grupo finito.

Demonstração 26 — Princípio *plug-in* e bootstrap da média

Definição

Dada uma amostra $X_1, \dots, X_n$, a distribuição empírica é

$$\widehat{F}_n = \frac{1}{n} \sum_{i=1}^n \Delta_{X_i}.$$

Uma amostra bootstrap $X_1^*, \dots, X_n^*$ é obtida condicionalmente aos dados por amostragem i.i.d. de $\widehat{F}_n$.

Demonstração para a média

Sob a distribuição empírica,

$$E_*(X_1^*) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Logo,

$$E_*(\bar{X}^*) = \bar{X}.$$

A variância de uma observação bootstrap é

$$\text{Var}_*(X_1^*) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Como as observações bootstrap são condicionalmente independentes,

$$\text{Var}_*(\bar{X}^*) = \frac{1}{n} \text{Var}_*(X_1^*) = \frac{1}{n^2} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Usando

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

obtemos

$$\text{Var}_*(\bar{X}^*) = \frac{n-1}{n^2} S^2.$$

Portanto, o erro-padrão bootstrap ideal da média é

$$\text{se}_*(\bar{X}^*) = \frac{S}{\sqrt{n}} \sqrt{\frac{n-1}{n}},$$

que é assintoticamente equivalente ao erro-padrão usual $S/\sqrt{n}$.

Esse cálculo ilustra o princípio *plug-in*: a população desconhecida F é substituída por $\widehat{F}_{\widehat{n}}$, e a distribuição amostral de $\bar{X}$ sob F é aproximada pela distribuição condicional de $\bar{X}^*$ sob $\widehat{F}_{\widehat{n}}$.

 Limite da demonstração

O cálculo de média e variância não prova a validade geral do bootstrap para qualquer estatística. Consistência bootstrap depende da regularidade do funcional e pode falhar, por exemplo, em problemas de fronteira, extremos amostrais e funcionais não suaves. Essas extensões precisam de verificação bibliográfica específica.

 Fonte da demonstração

Fonte principal: Chihara; Hesterberg (2022, seq. 5.2, princípio *plug-in* e distribuição empírica).

Adaptação: inclusão da derivação exata dos dois primeiros momentos condicionais da média bootstrap.

Síntese conceitual

As 26 demonstrações formam uma cadeia lógica:

1. a lei dos grandes números e o TCL justificam a estabilidade e a aproximação normal de estatísticas;
2. os resultados exatos do modelo normal produzem as distribuições χ^2 e t ;
3. suficiência, Rao–Blackwell, completude e Cramér–Rao organizam a comparação de estimadores;
4. verossimilhança, método delta, equivalências assintóticas e Wilks estruturam a inferência regular em grandes amostras;
5. Neyman–Pearson, Karlin–Rubin e a dualidade com regiões de confiança organizam a teoria dos testes;
6. EM, minimização, funções de influência, permutação e bootstrap ampliam a teoria para métodos computacionais, robustos e semiparamétricos.

! Observação editorial

Para uma versão de graduação avançada, um núcleo possível é formado pelas demonstrações 1–15, 18, 21–22 e 25–26. As demonstrações 16–20 e 23–24 podem ser desenvolvidas em disciplinas de mestrado ou em apêndices, com maior atenção às condições de regularidade, aos espaços tangentes e aos contraexemplos.

Referências

BICKEL, Peter J.; DOKSUM, Kjell A. **Mathematical Statistics: Basic Ideas and Selected Topics: Volume II**. Boca Raton, FL: CRC Press, 2016. v. 2

BOROVKOV, A. A. **Mathematical Statistics**. Amsterdam: Gordon; Breach Science Publishers, 1998.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury Press, 2002.

CHIHARA, Laura M.; HESTERBERG, Tim C. **Mathematical Statistics with Resampling and R**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2022.

COX, D. R. **Principles of Statistical Inference**. Cambridge: Cambridge University Press, 2006.

DANTAS, Carlos Alberto Barbosa. **Probabilidade: um curso introdutório**. São Paulo: EDUSP, 1997.

DIEZ, David M.; BARR, Christopher D.; ÇETINKAYA-RUNDEL, Mine. **Introductory Statistics with Randomization and Simulation**. 1. ed. *[S.l.]*: OpenIntro, Inc., 2014.

GUPTA, Maya R.; CHEN, Yihua. **Theory and Use of the EM Algorithm. Foundations and Trends in Signal Processing**, v. 4, n. 3, p. 223–296, 2011.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.

HOGG, Robert V.; CRAIG, Allen T. **Introduction to Mathematical Statistics**. 4. ed. New York: Macmillan Publishing Co., 1978.

KERNS, G. Jay. **Introduction to Probability and Statistics Using R**. 1. ed. *[S.l.: S.n.]*.

KIM, Albert Y.; ISMAY, Chester; KUHN, Max. **Take a modern dive into Introductory Linear Regression with R**. **The Journal of Open Source Education**, v. 4, n. 41, p. 115, 2021.

LARSEN, Richard J.; MARX, Morris L. **An Introduction to Mathematical Statistics and Its Applications**. 5. ed. Boston: Prentice Hall, 2012.

LAURITZEN, Steffen. **Fundamentals of Mathematical Statistics**. 1. ed. Boca Raton, FL: CRC Press, 2023.

MAGALHÃES, Marcos Nascimento. **Probabilidade e Variáveis Aleatórias**. São Paulo: EDUSP, 2006.

MEYER, Paul L. **Probabilidade e Aplicações à Estatística**. 2. ed. Rio de Janeiro: Livros Técnicos e Científicos, 1983.

RAMACHANDRAN, Kandethody M.; TSOKOS, Chris P. **Mathematical Statistics with Applications**. Burlington, MA: Academic Press, 2009.

RAMACHANDRAN, Kandethody M.; TSOKOS, Chris P. **Mathematical Statistics with Applications in R**. 3. ed. London: Academic Press, 2021.

RASCH, Dieter; SCHOTT, Dieter. **Mathematical Statistics**. Chichester: John Wiley & Sons, 2018.

RICE, John A. **Mathematical Statistics and Data Analysis**. 3. ed. Belmont, CA: Duxbury Press, 2007.

ROSNER, Bernard. **Fundamentals of Biostatistics**. 7. ed. Boston: Brooks/Cole, Cengage Learning, 2011.

ROSS, Sheldon M. **A First Course in Probability**. 7. ed. Upper Saddle River, NJ: Prentice Hall, 2006.

SHAO, Jun. **Mathematical Statistics: Exercises and Solutions**. New York: Springer Science+Business Media, 2005.

WICKHAM, Hadley *et al.* [Welcome to the tidyverse](#). **Journal of Open Source Software**, v. 4, n. 43, p. 1686, 2019.

WILCOX, Rand R. **Introduction to Robust Estimation and Hypothesis Testing**. 5. ed. London: Academic Press, 2022.