

Métodos Inferenciais

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa Modelos de Sobrevida e Aplicações.

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e das decisões dos autores ao longo da elaboração da obra.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro resulta da experiência acumulada no ensino, na orientação de estudantes e no desenvolvimento de pesquisas em Estatística. Somos docentes pesquisadores do Departamento de Estatística e Matemática Aplicada da Universidade Federal do Ceará (DEMA/UFC), com atuação em modelagem estatística, inferência e aplicações. Integramos o Laboratório de Inovação em Estatística — StatLab/UFC (<https://statlab.quarto.pub/>) e o Grupo de Pesquisa *Modelos de Sobrevivência e Aplicações* do CNPq (<http://dgp.cnpq.br/dgp/espelhogrupo/9639095385610769>), espaços nos quais articulamos ensino, pesquisa e aplicação a problemas reais.

O material tem como base disciplinas de Inferência Estatística oferecidas em cursos de graduação e pós-graduação. Ao longo dos anos, consolidamos a convicção de que o ensino de Inferência Estatística exige equilíbrio entre fundamentação teórica, clareza interpretativa e compreensão das condições que sustentam cada procedimento.

O livro desenvolve os conceitos de Inferência Estatística de forma progressiva, articulando propriedades, interpretação e aplicação. R e Python são utilizados ao longo do material como ambientes de experimentação conceitual, simulação e análise, de acordo com as necessidades de cada capítulo.

As ferramentas matemáticas necessárias são apresentadas de forma articulada ao desenvolvimento inferencial. Conteúdos que ampliam a fundamentação conceitual, matemática ou metodológica são identificados como **Aprofundamento** e podem ser consultados sem interromper o percurso principal do livro.

Acreditamos que a Inferência Estatística deve ser ensinada como fundamento para a análise e a tomada de decisões sob incerteza, com atenção às suposições dos modelos, às limitações dos procedimentos e às implicações das conclusões obtidas.

Esperamos que este livro contribua para a formação de profissionais capazes de tomar decisões com rigor técnico, pensamento estatístico crítico e responsabilidade analítica.

Identificação da(s) Disciplina(s)

- Curso: Bacharelado em Ciência de Dados e Pós-graduação em Modelagem e Métodos Quantitativos (PPGMMQ)
- Disciplina: Análise Inferencial (Graduação) e Inferência Estatística (Pós-graduação)
- Carga Horária: 96 horas (Graduação) e 64 horas (Pós-graduação)
- Créditos: 6 (Graduação) e 4 (Pós-graduação)
- Regime: Semestral
- Pré-requisitos: Modelos Probabilísticos (CC0446) (Graduação)
- Período Letivo: 2026.2
- Professor(a): Dr. Manoel Santos-Neto (Graduação) e Dr. Rafael Bráz (Pós-graduação)

EMENTA

Nível	Ementa
Graduação	Conceitos de população e amostra; parâmetros, estatísticas, estimadores e suas propriedades; distribuições amostrais; métodos de estimação pontual: método dos momentos, máxima verossimilhança e mínimos quadrados; estimação intervalar; testes de hipóteses; testes de homogeneidade e independência.

Nível	Ementa
Pós-graduação	Conceitos de inferência. Avaliação de estimadores. Princípios da suficiência e completude. Função de verossimilhança. Estimação pontual: método dos momentos, máxima verossimilhança, mínimos quadrados, minimax e equivariância. Distribuição assintótica dos estimadores. Método delta. Algoritmo EM. Estimação intervalar. Testes de hipóteses. Testes mais poderosos. Teste da razão de verossimilhanças. Testes assintóticos. Testes de aderência. Testes de independência.

OBJETIVO GERAL

Apresentar os fundamentos da inferência estatística, capacitando o discente a formular, analisar e interpretar problemas inferenciais em contextos de análise de dados, com ênfase na quantificação da incerteza, validação de modelos e capacidade de generalização.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- compreender a diferença entre população, amostra, parâmetro e estatística;
- interpretar estatísticas como variáveis aleatórias;
- compreender e utilizar distribuições amostrais;
- aplicar métodos de estimação pontual e intervalar;
- formular e testar hipóteses estatísticas de forma adequada;
- interpretar corretamente valores-p, intervalos de confiança e decisões inferenciais;
- analisar criticamente resultados estatísticos obtidos a partir de dados reais.

CONTEÚDO PROGRAMÁTICO

Unidade I – Fundamentos da Inferência Estatística

- Motivação para a inferência: conceitos de população, amostra e parâmetros
- Estatísticas e estimadores como funções da amostra
- Função de verossimilhança: definição e papel central na inferência clássica

Unidade II – Distribuições Amostrais

- Estatísticas como variáveis aleatórias e suas distribuições amostrais
- Distribuição amostral da média e da proporção
- Lei dos Grandes Números
- Teorema Central do Limite

Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados

- Propriedades de pequenas amostras: viés, variância e erro quadrático médio
- Propriedades assintóticas: consistência e eficiência assintótica
- Princípio da Suficiência: definições formais, Critério de Fatoração de Neyman-Fisher e suficiência minimal
- Princípio da Completude e Unicidade
- Família Exponencial: formas canônicas, posto completo e estatísticas completas e suficientes
- Teorema de Rao-Blackwell e Teorema de Lehmann-Scheffé: construção do Estimador Não-Viesado de Variância Uniformemente Mínima (ENVVUM)

Unidade IV – Métodos de Estimação Pontual

- Método dos momentos e suas aplicações
- Máxima verossimilhança: procedimentos, propriedades de invariância e otimalidade
- Mínimos quadrados: derivação, propriedades e relação com máxima verossimilhança
- Estimadores Minimax e Equivariância: critérios de risco e simetrias (locação e escala)
- Método Delta e Distribuição assintótica dos estimadores
- Algoritmo EM: estimação com dados ausentes ou não observáveis

Unidade V – Estimação Intervalar

- Conceitos e interpretação correta dos intervalos de confiança
- Métodos de construção: Método da Quantidade Pivotal e Inversão de Testes
- Intervalos baseados em aproximações assintóticas (Grandes amostras)

Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos

- Fundamentos: hipóteses nula/alternativa, estatísticas de teste, valor-p e decisões
- Teoria de erros (Tipo I e II) e Poder do teste
- Testes mais poderosos: Lema de Neyman-Pearson e Testes Uniformemente Mais Poderosos
- Teste da razão de verossimilhanças e sua versão generalizada
- Análise de Variáveis Categóricas: Testes qui-quadrado, testes de aderência, independência e homogeneidade em tabelas de contingência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, articuladas com atividades práticas computacionais. O conteúdo teórico será constantemente ilustrado por simulações e análises de dados reais, utilizando ferramentas computacionais (R ou Python).

AVALIAÇÃO

A avaliação será contínua e composta por:

Nível	Atividades
Graduação	• Listas obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.
Pós-graduação	• Listas semanais obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.

A aprovação na disciplina seguirá os critérios estabelecidos pelas normas vigentes da UFC.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados nos trabalhos e atividades:

Nível	CrITÉrios
Graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.
Pós-graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.

BIBLIOGRAFIA BÁSICA

Nível	Bibliografias
Graduação	1. Bussab, W. O.; Morettin, P. A. <i>Estatística Básica</i> . 6ª ed. São Paulo: Saraiva, 2010.2. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. Duxbury Press, 2002.3. Casella, G.; Berger, R. L. <i>Inferência Estatística</i> . Tradução da 2ª edição norte-americana. São Paulo: Cengage Learning, 2011.
Pós-graduação	1. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.2. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Coleção Matemática Aplicada. Rio de Janeiro: SBM, 2001.3. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. Duxbury Press, 2002.

BIBLIOGRAFIA COMPLEMENTAR

Nível	Bibliografias
Graduação	1. Devore, J. L. <i>Probabilidade e Estatística para Engenharia e Ciências</i> . São Paulo: Thomson, 2006.2. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i> . 3rd ed. New York: McGraw-Hill, 1974.3. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Rio de Janeiro: SBM, 2001.4. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.5. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i> . New York: John Wiley, 1988.

Nível	Bibliografias
Pós-graduação	1. Casella, G.; Berger, R. L. <i>Inferência Estatística</i>. Tradução da 2ª edição norte-americana. São Paulo: Cengage Learning, 2011.2. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i>. New York: John Wiley, 1988.3. Lehmann, E. L.; Casella, G. <i>Theory of Point Estimation</i>. 2nd ed. New York: Springer, 2003.4. Lehmann, E. L.; Romano, J. P. <i>Testing Statistical Hypotheses</i>. 3rd ed. New York: Springer, 2010.5. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i>. 3rd ed. New York: McGraw-Hill, 1974.6. Rohatgi, V. K. <i>Statistical Inference</i>. New York: Dover, 2003.7. Shao, J. <i>Mathematical Statistics</i>. 2nd ed. New York: Springer, 2003.

1 Revisão de Probabilidade e Modelos Probabilísticos

Este capítulo revisa conceitos de Probabilidade e modelos probabilísticos que serão utilizados ao longo do estudo de Inferência Estatística. O conteúdo pressupõe uma formação anterior em Probabilidade e concentra-se nas definições, propriedades e relações necessárias aos capítulos seguintes.

A revisão abrange probabilidade condicional, independência, variáveis aleatórias, distribuições, esperança, variância, distribuições conjuntas, função geradora de momentos e modelos probabilísticos discretos e contínuos. O objetivo é recuperar uma linguagem probabilística comum para o desenvolvimento da inferência, sem reproduzir integralmente os conteúdos de uma disciplina de Probabilidade (Dantas, 1997; Magalhães, 2006; Meyer, 1983).

Delimitação do capítulo

Neste capítulo, as distribuições e os modelos probabilísticos são tratados como objetos conhecidos da teoria da Probabilidade. Conceitos propriamente inferenciais, como parâmetro desconhecido, modelo estatístico, verossimilhança, estimação, intervalos de confiança e testes de hipóteses, serão introduzidos posteriormente.

Resultados sobre convergência, Lei dos Grandes Números, Teorema Central do Limite, lema de Slutsky, método delta e ordens estocásticas serão reunidos no capítulo **Resultados Matemáticos e Assintóticos para Inferência**.

1.1 Probabilidade e condicionamento

1.1.1 Experimentos aleatórios, espaço amostral e eventos

Um **experimento aleatório** é um procedimento cujo resultado não pode ser determinado antecipadamente, embora seja possível especificar o conjunto de resultados que podem ocorrer.

O **espaço amostral**, denotado por Ω , é o conjunto dos resultados possíveis do experimento. Um **evento** é um subconjunto de Ω .

Por exemplo, no lançamento de um dado de seis faces,

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

O evento

$$A = \{2, 4, 6\}$$

representa a ocorrência de um resultado par.

As operações entre eventos seguem as operações usuais entre conjuntos. Para eventos A e B :

- $A \cup B$ representa a ocorrência de pelo menos um dos eventos;
- $A \cap B$ representa a ocorrência simultânea de A e B ;
- A^c representa a não ocorrência de A ;
- $A \setminus B$ representa a ocorrência de A sem a ocorrência de B .

Dois eventos são **mutuamente exclusivos** quando

$$A \cap B = \emptyset.$$

1.1.2 Probabilidade

Uma medida de probabilidade P associa a cada evento A um número $P(A)$ que representa sua probabilidade de ocorrência. Suas propriedades básicas são

$$P(A) \geq 0,$$

$$P(\Omega) = 1$$

e, para uma sequência de eventos mutuamente exclusivos $A_1, A_2, \dots$,

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Dessas propriedades decorrem relações utilizadas com frequência, como

$$P(A^c) = 1 - P(A)$$

e

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Se

$$A \subseteq B,$$

então

$$P(A) \leq P(B).$$

Em espaços amostrais finitos com resultados equiprováveis,

$$P(A) = \frac{|A|}{|\Omega|},$$

em que $|A|$ e $|\Omega|$ representam, respectivamente, o número de elementos de A e de Ω (Dantas, 1997; Meyer, 1983).

1.1.3 Revisão de combinatória

Em problemas com resultados equiprováveis, o cálculo de probabilidades pode depender da contagem dos resultados possíveis. Nesta revisão, serão utilizados principalmente o princípio multiplicativo, o fatorial e os coeficientes binomial e multinomial.

Se um procedimento pode ser realizado de n_1 formas em uma primeira etapa e, para cada uma delas, de n_2 formas em uma segunda etapa, então o número de resultados possíveis é

$$n_1 n_2.$$

Para n objetos distintos, o número de ordenações possíveis é

$$n!.$$

O número de maneiras de selecionar k elementos dentre n , sem considerar a ordem, é

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad k = 0, 1, \dots, n.$$

Se n elementos são distribuídos em m categorias de tamanhos

$$n_1, \dots, n_m,$$

com

$$n_1 + \dots + n_m = n,$$

o número de configurações é dado pelo coeficiente multinomial

$$\binom{n}{n_1, \dots, n_m} = \frac{n!}{n_1! \dots n_m!}.$$

Uso posterior

Os coeficientes binomial e multinomial aparecem diretamente nas funções de probabilidade das distribuições binomial, hipergeométrica e multinomial. Nesta revisão, a combinatória será utilizada como ferramenta para descrever esses modelos, sem desenvolver novamente técnicas mais específicas de contagem.

1.1.4 Probabilidade condicional

A informação de que um evento ocorreu pode alterar a probabilidade atribuída a outro evento. Se $P(B) > 0$, a **probabilidade condicional** de A dado B é

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

A expressão representa a probabilidade de A quando o espaço de possibilidades é restringido pela ocorrência de B .

Da definição decorre a regra do produto:

$$P(A \cap B) = P(A | B)P(B).$$

Quando $P(A) > 0$, também podemos escrever

$$P(A \cap B) = P(B | A)P(A).$$

Para eventos $A_1, \dots, A_n$,

$$P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2 \mid A_1) \dots P(A_n \mid A_1 \cap \dots \cap A_{n-1}),$$

desde que as probabilidades condicionais envolvidas estejam definidas (Magalhães, 2006; Ross, 2006).

1.1.5 Lei da probabilidade total

Considere uma partição do espaço amostral formada pelos eventos

$$B_1, \dots, B_k,$$

tais que

$$B_i \cap B_j = \emptyset, \quad i \neq j,$$

e

$$\bigcup_{j=1}^k B_j = \Omega.$$

Se

$$P(B_j) > 0, \quad j = 1, \dots, k,$$

então, para qualquer evento A ,

$$P(A) = \sum_{j=1}^k P(A \mid B_j)P(B_j).$$

A probabilidade de A é decomposta segundo as diferentes partes do espaço amostral.

1.1.6 Teorema de Bayes

Considerando a mesma partição $B_1, \dots, B_k$, se $P(A) > 0$, então

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{\ell=1}^k P(A | B_\ell)P(B_\ell)}.$$

O teorema de Bayes permite inverter o condicionamento quando são conhecidas as probabilidades $P(B_j)$ e $P(A | B_j)$.

Considere uma condição genética presente em 2% de uma população. Um teste apresenta sensibilidade de 95% e produz resultado positivo em 5% das pessoas que não apresentam a condição.

Se G representa a presença da condição e T representa um resultado positivo no teste, então

$$P(G) = 0,02,$$

$$P(T | G) = 0,95$$

e

$$P(T | G^c) = 0,05.$$

Pela lei da probabilidade total,

$$P(T) = P(T | G)P(G) + P(T | G^c)P(G^c).$$

Logo,

$$P(T) = 0,95(0,02) + 0,05(0,98) = 0,068.$$

Aplicando o teorema de Bayes,

$$P(G | T) = \frac{P(T | G)P(G)}{P(T)}$$

e, portanto,

$$P(G | T) = \frac{0,95(0,02)}{0,068} \approx 0,279.$$

A probabilidade de uma pessoa apresentar a condição genética (G) dado que recebeu um resultado positivo no teste (T) não coincide com a sensibilidade do teste. O cálculo também depende da frequência da condição na população e da probabilidade de resultado positivo entre as pessoas que não apresentam a condição.

1.1.7 Independência de eventos

Dois eventos A e B são **independentes** quando

$$P(A \cap B) = P(A)P(B).$$

Se $P(B) > 0$, essa condição equivale a

$$P(A | B) = P(A).$$

Nesse caso, a informação de que B ocorreu não altera a probabilidade atribuída a A .

Independência não deve ser confundida com exclusão mútua. Se A e B são mutuamente exclusivos e ambos possuem probabilidade positiva,

$$P(A \cap B) = 0,$$

enquanto

$$P(A)P(B) > 0.$$

Portanto, eventos mutuamente exclusivos com probabilidades positivas não são independentes.

Para eventos

$$A_1, \dots, A_n,$$

a independência conjunta exige que, para todo subconjunto de índices

$$\{i_1, \dots, i_r\},$$

tenhamos

$$P(A_{i_1} \cap \cdots \cap A_{i_r}) = \prod_{j=1}^r P(A_{i_j}).$$

A independência aos pares, isoladamente, não garante independência conjunta (Dantas, 1997; Magalhães, 2006).

1.2 Variáveis aleatórias e distribuições

Uma variável aleatória associa valores numéricos aos resultados de um experimento aleatório. Sua distribuição descreve quais valores podem ocorrer e como a probabilidade é distribuída entre esses valores ou conjuntos de valores.

Ao longo do livro, letras maiúsculas, como X , Y e Z , representarão variáveis aleatórias. Letras minúsculas, como x , y e z , representarão valores possíveis ou observados dessas variáveis.

1.2.1 Função de distribuição

A **função de distribuição acumulada** de uma variável aleatória X é definida por

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Toda função de distribuição satisfaz:

1. F_X é não decrescente;
2. F_X é contínua à direita;
3. $F_X(x) \rightarrow 0$ quando $x \rightarrow -\infty$;
4. $F_X(x) \rightarrow 1$ quando $x \rightarrow +\infty$.

A função F_X caracteriza completamente a distribuição de X (Rice, 2007, caps. 1–2; Ramachandran; Tsokos, 2021, sec. 3.1).

1.2.2 Quantis

Para

$$u \in (0, 1),$$

o quantil de ordem u pode ser definido por

$$F_X^{-1}(u) = \inf\{x : F_X(x) \geq u\}.$$

Essa definição é válida tanto para distribuições contínuas quanto para distribuições discretas.

A mediana, por exemplo, está associada ao quantil de ordem

$$u = 0,5.$$

Quantis serão utilizados posteriormente na construção de intervalos e regiões associados a distribuições amostrais.

1.2.3 Variáveis aleatórias discretas

Uma variável aleatória X é **discreta** quando assume valores em um conjunto finito ou enumerável.

Sua distribuição pode ser descrita por uma **função de massa de probabilidade**,

$$p_X(x) = P(X = x),$$

que satisfaz

$$p_X(x) \geq 0$$

e

$$\sum_x p_X(x) = 1.$$

O **suporte** de X é o conjunto dos valores aos quais a função de massa de probabilidade atribui probabilidade positiva. Neste livro, o suporte de X será representado pela letra maiúscula caligráfica

$\mathcal{X}$.

Assim,

$$\mathcal{X} = \{x : p_X(x) > 0\}.$$

Por exemplo, se X é uma variável de contagem que pode assumir qualquer valor inteiro não negativo, então

$$\mathcal{X} = \{0, 1, 2, \dots\}.$$

A função de distribuição é obtida acumulando as probabilidades:

$$F_X(x) = \sum_{t \leq x} p_X(t).$$

Como consequência, a função de distribuição de uma variável discreta apresenta saltos nos valores que recebem probabilidade positiva.

1.2.4 Variáveis aleatórias absolutamente contínuas

Uma variável aleatória X é **absolutamente contínua** quando existe uma função de densidade f_X tal que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt,$$

com

$$f_X(x) \geq 0$$

e

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Também utilizaremos

$\mathcal{X}$

para representar o suporte de uma variável aleatória absolutamente contínua X . Neste caso, o suporte será entendido como o conjunto de valores admissíveis para X em que a densidade é positiva, desconsiderando diferenças em conjuntos de probabilidade nula.

Por exemplo, se X representa um tempo de espera estritamente positivo, então

$$\mathcal{X} = (0, \infty).$$

Nesse caso,

$$P(a < X \leq b) = \int_a^b f_X(x) dx.$$

Para qualquer valor isolado x ,

$$P(X = x) = 0.$$

A probabilidade pontual é nula porque conjuntos unitários possuem comprimento nulo, e não simplesmente porque uma variável contínua pode assumir infinitos valores (Ramachandran; Tsokos, 2021, secs. 3.1–3.2; Rice, 2007, cap. 2).

Em modelos paramétricos, o suporte pode depender do parâmetro. Quando for necessário explicitar essa dependência, utilizaremos uma notação como

$$\mathcal{X}_\theta.$$

Essa característica será retomada posteriormente, pois algumas condições de regularidade utilizadas em Inferência Estatística pressupõem que o suporte seja comum aos diferentes valores possíveis do parâmetro.

1.2.5 Função indicadora

Para um conjunto A , a **função indicadora** de A é definida por

$$\mathbf{1}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

Quando o conjunto considerado é o suporte $\mathcal{X}$ de uma variável aleatória X , escreveremos

$$\mathbf{1}_{\mathcal{X}}(x) = \begin{cases} 1, & x \in \mathcal{X}, \\ 0, & x \notin \mathcal{X}. \end{cases}$$

Essa notação permite incorporar diretamente o suporte à expressão de uma função de massa de probabilidade ou de uma densidade.

No caso discreto, uma função de massa de probabilidade poderá ser escrita na forma

$$p_X(x) = h(x)\mathbf{1}_{\mathcal{X}}(x),$$

indicando que

$$p_X(x) = \begin{cases} h(x), & x \in \mathcal{X}, \\ 0, & x \notin \mathcal{X}. \end{cases}$$

De forma análoga, para uma variável aleatória absolutamente contínua, uma densidade poderá ser escrita como

$$f_X(x) = h(x)\mathbf{1}_{\mathcal{X}}(x),$$

isto é,

$$f_X(x) = \begin{cases} h(x), & x \in \mathcal{X}, \\ 0, & x \notin \mathcal{X}. \end{cases}$$

A função indicadora permite, portanto, apresentar em uma única expressão a forma da função de massa ou da densidade e o suporte ao qual ela está associada. Essa notação será utilizada sistematicamente na apresentação dos modelos probabilísticos deste capítulo.

A função indicadora também permite representar contagens de ocorrências. Considere os eventos

$$A_1, \dots, A_n,$$

e defina

$$I_i = \mathbf{1}_{A_i}.$$

Então,

$$I_i = \begin{cases} 1, & \text{se } A_i \text{ ocorre,} \\ 0, & \text{caso contrário.} \end{cases}$$

A soma

$$R = \sum_{i=1}^n I_i = \sum_{i=1}^n \mathbf{1}_{A_i}$$

representa o número de ocorrências dos eventos considerados.

Consequentemente,

$$\frac{R}{n} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{A_i}$$

representa a proporção de ocorrências.

Essa representação será utilizada na distribuição binomial e, posteriormente, permitirá relacionar contagens, proporções e médias de variáveis Bernoulli.

1.2.6 Funções de variáveis aleatórias

Se X é uma variável aleatória e

$$Y = g(X),$$

então Y também é uma variável aleatória.

Sua distribuição depende da distribuição de X e da transformação g . Uma forma geral de obtê-la consiste em utilizar sua função de distribuição:

$$F_Y(y) = P(Y \leq y) = P\{g(X) \leq y\}.$$

Métodos específicos para transformações de variáveis aleatórias serão retomados posteriormente neste capítulo.

1.3 Esperança, variância e momentos

1.3.1 Esperança

A **esperança matemática** de uma variável aleatória representa uma média ponderada de seus possíveis valores segundo a distribuição de probabilidade.

No caso discreto,

$$E(X) = \sum_x x p_X(x),$$

desde que a soma esteja bem definida.

No caso absolutamente contínuo,

$$E(X) = \int_{-\infty}^{\infty} x f_X(x) dx,$$

desde que a integral esteja bem definida.

Mais geralmente, para uma função g ,

$$E\{g(X)\} = \sum_x g(x) p_X(x)$$

no caso discreto e

$$E\{g(X)\} = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

no caso absolutamente contínuo.

A esperança é linear. Para constantes $a_1, \dots, a_n$ e b ,

$$E\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i E(X_i) + b.$$

Essa propriedade não exige independência entre as variáveis.

1.3.2 Momentos

Para $r = 1, 2, \dots$, o **momento de ordem r em torno da origem** é

$$E(X^r),$$

quando existe.

O **momento centrado (na média) de ordem r** é

$$E[\{X - E(X)\}^r],$$

quando existe.

A média corresponde ao primeiro momento em torno da origem. A variância corresponde ao segundo momento centrado.

Medidas como assimetria e curtose são construídas a partir de momentos centrais padronizados (Casella; Berger, 2011, ex. 2.28; Ramachandran; Tsokos, 2021, secs. 3.1 e 3.3).

1.3.3 Variância

A **variância** de X é

$$\text{Var}(X) = E[\{X - E(X)\}^2].$$

Uma forma equivalente é

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

Para constantes a e b ,

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

A raiz quadrada da variância,

$$\text{DP}(X) = \sqrt{\text{Var}(X)},$$

é o desvio-padrão da distribuição.

1.4 Distribuições conjuntas e dependência

Muitos problemas probabilísticos envolvem mais de uma variável aleatória considerada simultaneamente. Nesses casos, além de descrever o comportamento individual de cada variável, é necessário estudar como elas se comportam conjuntamente e como se relacionam.

Variáveis aleatórias

$$X_1, \dots, X_k$$

consideradas conjuntamente podem ser reunidas no vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top.$$

A distribuição conjunta descreve o comportamento probabilístico de suas componentes consideradas simultaneamente. A partir dela, podem ser obtidas distribuições marginais e condicionais e estudadas relações de dependência entre as variáveis.

Quando forem consideradas apenas duas variáveis aleatórias, utilizaremos a notação X e Y .

1.4.1 Distribuição conjunta

Considere duas variáveis aleatórias X e Y , com suportes $\mathcal{X}$ e $\mathcal{Y}$, respectivamente. Os pares formados por seus valores pertencem ao produto cartesiano

$$\mathcal{X} \times \mathcal{Y}.$$

A distribuição conjunta descreve o comportamento probabilístico de X e Y consideradas simultaneamente. Sua função de distribuição conjunta é definida por

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y).$$

O **suporte conjunto** de (X, Y) é formado pelos pares

$$(x, y) \in \mathcal{X} \times \mathcal{Y}$$

admissíveis sob a distribuição conjunta considerada.

O suporte conjunto não precisa coincidir com todo o produto cartesiano

$$\mathcal{X} \times \mathcal{Y}.$$

Dependendo da relação entre X e Y , apenas parte das combinações entre seus valores individuais pode pertencer ao suporte conjunto.

No caso discreto, a distribuição conjunta pode ser descrita pela função de massa de probabilidade

$$p_{X,Y}(x, y) = P(X = x, Y = y),$$

que satisfaz

$$p_{X,Y}(x, y) \geq 0$$

e

$$\sum_x \sum_y p_{X,Y}(x, y) = 1.$$

No caso absolutamente contínuo, a distribuição conjunta é descrita por uma densidade

$$f_{X,Y}(x, y) \geq 0,$$

com

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx \, dy = 1.$$

Para uma região

$$A \subseteq \mathbb{R}^2,$$

temos

$$P\{(X, Y) \in A\} = \iint_A f_{X,Y}(x, y) \, dx \, dy.$$

A mesma ideia se estende a vetores aleatórios com mais de duas componentes.

1.4.2 Distribuições marginais

A distribuição marginal descreve o comportamento de uma componente do vetor sem condicionar aos valores das demais.

No caso discreto,

$$p_X(x) = \sum_y p_{X,Y}(x, y)$$

e

$$p_Y(y) = \sum_x p_{X,Y}(x, y).$$

No caso absolutamente contínuo,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$$

e

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

A soma ou integração elimina da distribuição conjunta a variável que não aparece na distribuição marginal desejada.

1.4.3 Distribuições condicionais

A distribuição condicional descreve o comportamento de uma variável quando o valor de outra é conhecido.

No caso discreto, se

$$p_Y(y) > 0,$$

então

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Para cada y fixado,

$$\sum_x p_{X|Y}(x | y) = 1.$$

No caso absolutamente contínuo, se

$$f_Y(y) > 0,$$

então

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

com

$$\int_{-\infty}^{\infty} f_{X|Y}(x | y) dx = 1.$$

A distribuição conjunta pode ser recuperada a partir de uma marginal e de uma condicional. No caso discreto,

$$p_{X,Y}(x, y) = p_{X|Y}(x | y)p_Y(y),$$

e, no caso absolutamente contínuo,

$$f_{X,Y}(x, y) = f_{X|Y}(x | y)f_Y(y).$$

A construção de distribuições marginais e condicionais a partir da distribuição conjunta é tratada, por exemplo, em (Rice, 2007, secs. 3.2–3.5; Ramachandran; Tsokos, 2021, sec. 3.3).

Distribuições condicionais serão utilizadas posteriormente em resultados como o teorema de Rao–Blackwell (Rice, 2007, sec. 8.8.2) e no algoritmo EM (Gupta; Chen, 2011).

Considere duas variáveis aleatórias X e Y com função de probabilidade conjunta dada por

X	$Y = 0$	$Y = 1$
0	0,20	0,10
1	0,30	0,40

A distribuição marginal de X é

$$P(X = 0) = 0,20 + 0,10 = 0,30$$

e

$$P(X = 1) = 0,30 + 0,40 = 0,70.$$

Para Y ,

$$P(Y = 0) = 0,20 + 0,30 = 0,50$$

e

$$P(Y = 1) = 0,10 + 0,40 = 0,50.$$

Condiccionando em $Y = 1$,

$$P(X = 1 \mid Y = 1) = \frac{P(X = 1, Y = 1)}{P(Y = 1)} = \frac{0,40}{0,50} = 0,80.$$

Portanto,

$$P(X = 1) = 0,70$$

e

$$P(X = 1 \mid Y = 1) = 0,80.$$

A informação de que $Y = 1$ altera a distribuição atribuída a X .

1.4.4 Independência de variáveis aleatórias

As variáveis aleatórias X e Y são **independentes** quando

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

para todos os conjuntos admissíveis A e B .

No caso discreto, essa condição equivale a

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

para todos os valores possíveis de x e y .

No caso absolutamente contínuo,

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

quase sempre.

Se X e Y são independentes e as esperanças envolvidas existem,

$$E\{g(X)h(Y)\} = E\{g(X)\}E\{h(Y)\}.$$

Em particular,

$$E(XY) = E(X)E(Y).$$

A recíproca não é válida em geral. A igualdade de determinados momentos não é suficiente para estabelecer independência (Rice, 2007, sec. 3.4; Ramachandran; Tsokos, 2021, secs. 2.4 e 3.3).

1.4.5 Independência de várias variáveis

As variáveis

$$X_1, \dots, X_n$$

são mutuamente independentes quando, para quaisquer conjuntos

$$A_1, \dots, A_n,$$

temos

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n P(X_i \in A_i).$$

No caso discreto,

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i).$$

No caso absolutamente contínuo,

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$$

quase sempre.

1.4.6 Variáveis independentes e identicamente distribuídas

Se, além de mutuamente independentes, as variáveis

$$X_1, \dots, X_n$$

possuem a mesma distribuição, dizemos que são **independentes e identicamente distribuídas**.

Formalmente, existe uma função de distribuição comum F tal que

$$F_{X_i}(x) = F(x), \quad i = 1, \dots, n.$$

Nesse caso, escrevemos

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

A sigla **i.i.d.** corresponde à expressão *independentes e identicamente distribuídas*.

i Estrutura i.i.d.

A notação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F$$

reúne duas condições distintas:

1. $X_1, \dots, X_n$ são mutuamente independentes;
2. todas possuem a mesma distribuição F .

Serem identicamente distribuídas não significa que as variáveis assumam os mesmos valores. Significa que todas são regidas pela mesma distribuição probabilística.

A estrutura i.i.d. será utilizada repetidamente ao longo do livro e, posteriormente, aparecerá na definição usual de uma amostra aleatória. Ela representa uma hipótese específica sobre o mecanismo probabilístico de geração das observações e não se aplica a todos os processos de obtenção de dados.

1.4.7 Covariância e correlação

Se X e Y possuem segundos momentos finitos, a **covariância** entre X e Y é

$$\text{Cov}(X, Y) = E[\{X - E(X)\}\{Y - E(Y)\}].$$

Equivalentemente,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

A covariância descreve a direção da associação linear entre as duas variáveis.

Se X e Y são independentes e possuem segundos momentos finitos,

$$E(XY) = E(X)E(Y)$$

e, portanto,

$$\text{Cov}(X, Y) = 0.$$

Assim,

$$X \perp Y \implies \text{Cov}(X, Y) = 0.$$

A implicação inversa não é válida em geral.

A covariância depende das unidades de medida. Uma medida adimensional da associação linear é o **coeficiente de correlação**,

$$\rho_{X,Y} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}},$$

desde que

$$\text{Var}(X) > 0$$

e

$$\text{Var}(Y) > 0.$$

O coeficiente satisfaz

$$-1 \leq \rho_{X,Y} \leq 1.$$

Valores positivos correspondem a associação linear positiva, valores negativos a associação linear negativa e

$$\rho_{X,Y} = 0$$

indica ausência de associação linear. Correlação nula, entretanto, não implica ausência de dependência.

i Independência e correlação

Independência implica covariância nula quando os segundos momentos são finitos. Se, além disso, ambas as variâncias são positivas, a correlação está definida e é igual a zero. A implicação inversa não vale para distribuições arbitrárias.

Para variáveis conjuntamente normais com variâncias positivas, correlação nula implica

independência.

1.4.8 Variância de combinações lineares

Para variáveis com segundos momentos finitos,

$$\text{Var} \left(\sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j).$$

Se as variáveis são independentes, as covariâncias cruzadas são nulas e

$$\text{Var} \left(\sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i).$$

Esse resultado será utilizado repetidamente na obtenção das variâncias de somas, médias e outras estatísticas construídas a partir de observações independentes (Rice, 2007, secs. 4.2–4.3; Ramachandran; Tsokos, 2021, sec. 3.3.1).

1.4.9 Esperança condicional

A distribuição condicional permite definir momentos condicionais.

No caso discreto,

$$E(X | Y = y) = \sum_x x p_{X|Y}(x | y),$$

desde que a soma esteja bem definida.

No caso absolutamente contínuo,

$$E(X | Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x | y) dx.$$

Ao permitir que Y varie, obtemos a variável aleatória

$$E(X | Y).$$

Mais geralmente,

$$E\{g(X) \mid Y = y\}$$

é calculada utilizando a distribuição condicional de X dado $Y = y$.

Se X e Y são independentes e

$$E|X| < \infty,$$

então

$$E(X \mid Y) = E(X).$$

! Lei da esperança total

Se $E|X| < \infty$, então

$$E(X) = E\{E(X \mid Y)\}.$$

A lei da esperança total permite obter a média não condicional a partir das médias condicionais.

Considere uma variável Y que identifica dois grupos,

$$Y \in \{0, 1\},$$

com

$$P(Y = 0) = 0,6$$

e

$$P(Y = 1) = 0,4.$$

Suponha que

$$E(X \mid Y = 0) = 10$$

e

$$E(X \mid Y = 1) = 20.$$

Então,

$$E(X) = E\{E(X \mid Y)\}$$

e

$$E(X) = 10(0,6) + 20(0,4) = 14.$$

1.4.10 Variância condicional

A variância condicional de X dado $Y = y$ é

$$\text{Var}(X \mid Y = y) = E[\{X - E(X \mid Y = y)\}^2 \mid Y = y].$$

Equivalentemente,

$$\text{Var}(X \mid Y = y) = E(X^2 \mid Y = y) - [E(X \mid Y = y)]^2.$$

Ao permitir que Y varie, obtém-se a variável aleatória

$$\text{Var}(X \mid Y).$$

! Lei da variância total

Se $E(X^2) < \infty$, então

$$\text{Var}(X) = E\{\text{Var}(X \mid Y)\} + \text{Var}\{E(X \mid Y)\}.$$

A primeira parcela,

$$E\{\text{Var}(X \mid Y)\},$$

representa a média das variâncias condicionais. A segunda,

$$\text{Var}\{E(X \mid Y)\},$$

representa a variabilidade entre as médias condicionais.

A decomposição separa, portanto, a variabilidade total de X em uma componente associada à variação dentro das distribuições condicionais e outra associada à variação entre suas médias (Rice, 2007, sec. 4.4; Ramachandran; Tsokos, 2021, sec. 3.3).

Considere novamente

$$P(Y = 0) = 0,6, \quad P(Y = 1) = 0,4,$$

com

$$E(X \mid Y = 0) = 10$$

e

$$E(X \mid Y = 1) = 20.$$

Suponha ainda que

$$\text{Var}(X \mid Y = 0) = 9$$

e

$$\text{Var}(X \mid Y = 1) = 16.$$

A primeira parcela da lei da variância total é

$$E\{\text{Var}(X \mid Y)\} = 9(0,6) + 16(0,4) = 11,8.$$

Como

$$E(X) = 14,$$

a variância das médias condicionais é

$$\text{Var}\{E(X \mid Y)\} = 0,6(10 - 14)^2 + 0,4(20 - 14)^2 = 24.$$

Portanto,

$$\text{Var}(X) = 11,8 + 24 = 35,8.$$

1.4.11 Vetores de médias e matrizes de covariâncias

Para um vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top,$$

o vetor de médias é

$$E(\mathbf{X}) = \begin{pmatrix} E(X_1) \\ \vdots \\ E(X_k) \end{pmatrix}.$$

A matriz de covariâncias é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[\{\mathbf{X} - E(\mathbf{X})\}\{\mathbf{X} - E(\mathbf{X})\}^\top].$$

Sua forma é

$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_k) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_k, X_1) & \text{Cov}(X_k, X_2) & \cdots & \text{Var}(X_k) \end{pmatrix}.$$

A diagonal contém as variâncias das componentes e os elementos fora da diagonal contêm as covariâncias entre pares de variáveis.

A matriz de covariâncias é simétrica e positiva semidefinida. Essa representação será retomada no estudo de parâmetros vetoriais, distribuições assintóticas multivariadas e modelos lineares (Rice, 2007, secs. 4.2–4.3; Ramachandran; Tsokos, 2021, sec. 3.3.1).

i Em síntese: distribuições conjuntas e dependência

Os principais resultados desta seção podem ser organizados a partir da distribuição conjunta.

A partir de uma distribuição conjunta, podem ser obtidas as **distribuições marginais** de cada componente e, quando as condições necessárias são satisfeitas, suas **distribuições condicionais**.

A independência corresponde à fatoração da distribuição conjunta. No caso discreto,

$$p_{X,Y}(x, y) = p_X(x)p_Y(y),$$

e, no caso absolutamente contínuo,

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

O condicionamento também permite decompor momentos. A lei da esperança total estabelece que

$$E(X) = E\{E(X | Y)\},$$

enquanto a lei da variância total fornece

$$\text{Var}(X) = E\{\text{Var}(X | Y)\} + \text{Var}\{E(X | Y)\}.$$

Quando várias variáveis são independentes e possuem a mesma distribuição, utilizamos a notação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

1.5 Função geradora de momentos

A **função geradora de momentos (fgm)** de uma variável aleatória X é definida por

$$M_X(t) = E(e^{tX}),$$

desde que essa esperança exista em uma vizinhança de $t = 0$.

No caso discreto,

$$M_X(t) = \sum_x e^{tx} p_X(x),$$

enquanto, no caso absolutamente contínuo,

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx.$$

A fgm será utilizada neste capítulo para três finalidades: obter momentos, estudar distribuições de somas de variáveis independentes e reconhecer distribuições a partir de sua forma funcional (Rice, 2007, sec. 4.5; Chihara; Hesterberg, 2022, ap. A.8).

1.5.1 Obtenção de momentos

Para $r = 1, 2, \dots$, quando a fgm é finita em uma vizinhança de zero, sua derivada de ordem r é

$$M_X^{(r)}(t) = \frac{d^r}{dt^r} M_X(t).$$

Avaliando em $t = 0$,

$$M_X^{(r)}(0) = E(X^r).$$

Em particular,

$$M_X'(0) = E(X)$$

e

$$M_X''(0) = E(X^2).$$

Consequentemente,

$$\text{Var}(X) = M_X''(0) - [M_X'(0)]^2.$$

Assim, quando a fgm possui uma expressão simples, ela fornece uma forma alternativa de obter os momentos da distribuição.

1.5.2 Transformações lineares

Se

$$Y = aX + b,$$

então

$$M_Y(t) = E(e^{t(aX+b)}).$$

Como

$$e^{t(aX+b)} = e^{bt}e^{atX},$$

segue que

$$M_Y(t) = e^{bt}M_X(at).$$

Essa relação permite obter a fgm de uma transformação linear a partir da FGM da variável original.

1.5.3 Soma de variáveis independentes

Se

$$X_1, \dots, X_n$$

são independentes e suas funções geradoras de momentos existem em uma vizinhança de zero, então

$$M_{X_1+\dots+X_n}(t) = \prod_{i=1}^n M_{X_i}(t).$$

Se, além disso, $X_1, \dots, X_n$ são i.i.d. e possuem a mesma distribuição de uma variável aleatória X , e

$$S_n = X_1 + \dots + X_n,$$

então

$$M_{S_n}(t) = M_{X_1+\dots+X_n}(t) = [M_X(t)]^n.$$

Essa propriedade será utilizada nas seções seguintes para estabelecer relações entre alguns modelos probabilísticos.

1.5.4 Identificação de distribuições

Se duas variáveis aleatórias possuem funções geradoras de momentos que existem e coincidem em uma vizinhança de $t = 0$, então elas possuem a mesma distribuição.

Assim, quando a fgm de uma variável ou de uma soma de variáveis coincide com a fgm de uma distribuição conhecida, essa igualdade pode ser utilizada para identificar sua distribuição.

i Existência da fgm

Nem toda distribuição possui função geradora de momentos. Neste capítulo, a FGM será apresentada junto aos modelos em que sua expressão é útil para os desenvolvimentos posteriores.

Não será introduzida uma expressão complicada apenas para completar uma tabela. Quando a FGM de determinado modelo envolver funções especiais que não serão utilizadas no livro, essa forma será omitida.

1.6 Modelos probabilísticos discretos

Modelos probabilísticos discretos descrevem variáveis aleatórias que assumem valores em conjuntos finitos ou enumeráveis. A escolha de uma distribuição depende do mecanismo que produz a variável observada. Um único resultado binário, uma contagem de sucessos, uma amostragem sem reposição, o número de tentativas até determinado evento e o número de ocorrências em um intervalo correspondem a estruturas probabilísticas distintas.

Nesta seção, serão revisadas as distribuições uniforme discreta, Bernoulli, binomial, hipergeométrica, geométrica, binomial negativa e Poisson. Para cada modelo serão apresentados seu mecanismo probabilístico, suporte, função de massa de probabilidade, esperança, variância, função geradora de momentos, situações que podem originar problemas inferenciais e o comportamento gráfico da função de massa e da função de distribuição acumulada (Dantas, 1997; Magalhães, 2006; Ross, 2006).

1.6.1 Distribuição uniforme discreta

A distribuição uniforme discreta descreve situações em que um número finito de resultados possui a mesma probabilidade de ocorrência.

Considere uma variável aleatória X que pode assumir os valores

$$x_1, \dots, x_m,$$

todos com a mesma probabilidade. Sua função de massa de probabilidade é

$$p_X(x) = \frac{1}{m} \mathbf{1}_{\{x_1, \dots, x_m\}}(x).$$

Um caso particular ocorre quando

$$X \in \{1, \dots, m\}.$$

Nesse caso, escrevemos

$$X \sim U\{1, \dots, m\}$$

e

$$p_X(x) = \frac{1}{m} \mathbf{1}_{\{1, \dots, m\}}(x).$$

A esperança é

$$E(X) = \frac{m+1}{2},$$

e a variância é

$$\text{Var}(X) = \frac{m^2 - 1}{12}.$$

A função geradora de momentos é

$$M_X(t) = \frac{1}{m} \sum_{x=1}^m e^{tx}.$$

Para $t \neq 0$, a soma geométrica fornece

$$M_X(t) = \frac{e^t(e^{mt} - 1)}{m(e^t - 1)},$$

enquanto

$$M_X(0) = 1.$$

Considere uma população cujos elementos são numerados consecutivamente de 1 até um valor máximo desconhecido m . Se um elemento é selecionado aleatoriamente e todos os números possuem a mesma probabilidade de seleção, então

$$X \sim U\{1, \dots, m\}.$$

Um exemplo ocorre quando números de série são atribuídos sequencialmente aos itens produzidos por uma empresa. Se apenas alguns números de série são observados, pode haver interesse em obter informação sobre o número total m de itens produzidos.

Nesse problema, o mecanismo probabilístico é uniforme discreto e a quantidade que assumirá posteriormente o papel de parâmetro desconhecido é m .

A Figura ?? mostra que todos os valores do suporte possuem a mesma massa de probabilidade. À medida que m aumenta, essa massa individual diminui, pois a probabilidade total igual a 1 é distribuída entre um número maior de valores. A função de distribuição apresenta saltos de mesma magnitude, iguais a $1/m$. Assim, quanto maior o número de valores possíveis, menores são os saltos da função de distribuição.

1.6.2 Distribuição de Bernoulli

Um **ensaio de Bernoulli** é um experimento com dois resultados possíveis, representados por 1 e 0. Convencionalmente, esses resultados são denominados sucesso e fracasso.

Uma variável aleatória X possui distribuição de Bernoulli com parâmetro

$$0 < p < 1$$

quando sua função de massa de probabilidade é

$$p_X(x) = p^x(1-p)^{1-x}\mathbf{1}_{\{0,1\}}(x).$$

Escrevemos

$$X \sim \text{Ber}(p).$$

O parâmetro p representa a probabilidade de sucesso:

$$P(X = 1) = p,$$

enquanto




Figura 1.1: Função de massa de probabilidade e função de distribuição acumulada da distribuição uniforme discreta para diferentes parâmetros.

$$P(X = 0) = 1 - p.$$

A esperança é

$$E(X) = p,$$

e a variância é

$$\text{Var}(X) = p(1 - p).$$

A função geradora de momentos é

$$M_X(t) = E(e^{tX}).$$

Como X assume apenas os valores 0 e 1,

$$M_X(t) = (1 - p)e^0 + pe^t,$$

de modo que

$$M_X(t) = 1 - p + pe^t.$$

A função indicadora fornece uma representação direta de uma variável Bernoulli. Para um evento A ,

$$X = \mathbf{1}_A$$

possui distribuição de Bernoulli com

$$p = P(A).$$

Considere uma pesquisa em que cada pessoa entrevistada responde se utiliza ou não determinado serviço público. Defina

$$X = \begin{cases} 1, & \text{se a pessoa utiliza o serviço,} \\ 0, & \text{caso contrário.} \end{cases}$$

Se p representa a probabilidade de uma pessoa da população utilizar o serviço, então

$$X \sim \text{Ber}(p).$$

Em uma situação inferencial, podem ser observadas respostas de várias pessoas com o objetivo de obter informação sobre a proporção populacional p de usuários do serviço.

A Figura ?? mostra que o parâmetro p redistribui a massa entre os dois valores possíveis. Quando p é pequeno, a maior massa está em $X = 0$; quando p é grande, concentra-se em $X = 1$. Para $p = 0,5$, os dois resultados possuem a mesma probabilidade. Na função de distribuição, o primeiro salto possui magnitude $1 - p$ e ocorre em $x = 0$; o segundo completa a probabilidade acumulada em $x = 1$.

1.6.3 Distribuição binomial

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

A variável

$$X = \sum_{i=1}^n X_i$$

representa o número de sucessos nos n ensaios.

Nesse caso,

$$X \sim \text{Binom}(n, p),$$

com

$$n \in \mathbb{N} \quad \text{e} \quad 0 < p < 1.$$

O suporte é

$$\mathcal{X} = \{0, 1, \dots, n\}.$$

Sua função de massa de probabilidade é

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x} \mathbf{1}_{\{0,1,\dots,n\}}(x).$$




Figura 1.2: Função de massa de probabilidade e função de distribuição acumulada da distribuição de Bernoulli para diferentes parâmetros.

Como X é uma soma de variáveis Bernoulli independentes,

$$E(X) = \sum_{i=1}^n E(X_i) = np$$

e

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(X_i) = np(1-p).$$

Além da contagem total de sucessos, a mesma representação permite considerar a **proporção de sucessos** nos n ensaios. Como

$$X = \sum_{i=1}^n X_i,$$

temos

$$\frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Assim, quando X_i indica a ocorrência de sucesso no i -ésimo ensaio, X/n representa a proporção de sucessos observada nos n ensaios.

Utilizando a linearidade da esperança,

$$E\left(\frac{X}{n}\right) = \frac{1}{n}E(X) = p.$$

Da mesma forma,

$$\text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) = \frac{p(1-p)}{n}.$$

Essa relação será retomada posteriormente no estudo da proporção amostral. Ela mostra que a proporção de sucessos pode ser escrita como a média de variáveis Bernoulli independentes.

A função geradora de momentos também decorre da representação como soma. Como

$$M_{X_i}(t) = 1 - p + pe^t,$$

temos

$$M_X(t) = \prod_{i=1}^n M_{X_i}(t),$$

e, portanto,

$$M_X(t) = (1 - p + pe^t)^n.$$

i Estrutura do modelo binomial

A distribuição binomial resulta das seguintes condições:

1. o número de ensaios n é fixado;
2. cada ensaio possui dois resultados possíveis;
3. os ensaios são independentes;
4. a probabilidade de sucesso p é a mesma em todos os ensaios.

A alteração dessas condições pode exigir outro modelo probabilístico.

Considere uma pesquisa de satisfação realizada com $n = 100$ usuários de determinado serviço. Cada pessoa é classificada como satisfeita ou não satisfeita.

Se as respostas puderem ser representadas por ensaios de Bernoulli independentes com probabilidade de satisfação p , o número total X de pessoas satisfeitas pode ser modelado por

$$X \sim \text{Binom}(100, p).$$

O interesse inferencial pode estar na proporção p de usuários satisfeitos na população. O valor de p é desconhecido, enquanto X é observado a partir da amostra.

A Figura ?? mostra como p modifica a localização e a forma da distribuição para um mesmo número de ensaios. Como

$$E(X) = np,$$

o aumento de p desloca a massa de probabilidade para valores maiores de x . Para $p = 0,5$, a distribuição é simétrica em torno de $x = 5$. Os casos $p = 0,2$ e $p = 0,8$ apresentam formas espelhadas, consequência da troca entre as probabilidades de sucesso e fracasso. Na função de distribuição, esse deslocamento aparece na posição em que a probabilidade acumulada cresce.




Figura 1.3: Função de massa de probabilidade e função de distribuição acumulada da distribuição binomial para diferentes parâmetros.

1.6.4 Distribuição hipergeométrica

A distribuição hipergeométrica descreve o número de sucessos em uma amostra retirada **sem reposição** de uma população finita.

Considere uma população formada por:

- N unidades;
- M unidades classificadas como sucesso;
- $N - M$ unidades classificadas como fracasso.

Seleciona-se uma amostra de tamanho n sem reposição e define-se X como o número de sucessos observados.

Então,

$$X \sim \text{Hiper}(N, M, n),$$

com

$$N \in \mathbb{N}, \quad 0 \leq M \leq N$$

e

$$0 \leq n \leq N.$$

Defina

$$\mathcal{X} = \{\max\{0, n - N + M\}, \dots, \min\{n, M\}\}.$$

A função de massa de probabilidade é

$$p_X(x) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}} \mathbf{1}_{\mathcal{X}}(x).$$

Definindo

$$p = \frac{M}{N},$$

a esperança é

$$E(X) = np.$$

Para $N > 1$, a variância é

$$\text{Var}(X) = np(1-p) \frac{N-n}{N-1}.$$

O fator

$$\frac{N-n}{N-1}$$

é denominado **correção para população finita**. Ele surge porque as retiradas sem reposição não são independentes.

No caso degenerado $N = 1$, a variável X é constante e, portanto,

$$\text{Var}(X) = 0.$$

A função geradora de momentos pode ser escrita como a soma finita

$$M_X(t) = \sum_{x \in \mathcal{X}} e^{tx} \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}.$$

Sua forma será suficiente para esta revisão; não será necessária uma representação adicional por funções especiais.

Considere um lote com $N = 500$ componentes eletrônicos. Uma quantidade desconhecida M desses componentes apresenta determinado defeito. Uma amostra de $n = 30$ componentes é selecionada sem reposição e X representa o número de itens defeituosos encontrados.

Condicionalmente ao número M de componentes defeituosos existentes no lote,

$$X \sim \text{Hiper}(500, M, 30).$$

Em um problema inferencial, a contagem observada X pode fornecer informação sobre M ou sobre a proporção

$$p = \frac{M}{500}$$

de componentes defeituosos no lote.




Figura 1.4: Função de massa de probabilidade e função de distribuição acumulada da distribuição hipergeométrica para diferentes parâmetros.

A Figura ?? mantém fixados o tamanho da população e o tamanho da amostra e altera o número M de sucessos existentes na população. Como

$$E(X) = n \frac{M}{N},$$

o aumento de M desloca a distribuição para contagens maiores. Os casos $M = 10$ e $M = 40$ apresentam comportamento aproximadamente espelhado, enquanto $M = 25$ corresponde a uma população com metade das unidades em cada categoria.

1.6.5 Binomial e hipergeométrica

As distribuições binomial e hipergeométrica podem descrever o número de sucessos em n observações, mas correspondem a mecanismos de obtenção dos dados diferentes.

	Característica	Binomial	Hipergeométrica
Número de observações		n	n
Número de sucessos		X	X
Probabilidade inicial de sucesso		p	$p = M/N$
Estrutura		ensaios independentes	amostragem sem reposição
População		conceitualmente ilimitada ou reposição	finita
Esperança		np	np
Variância		$np(1 - p)$	$np(1 - p) \frac{N - n}{N - 1}$

A diferença entre as variâncias decorre da dependência introduzida pela amostragem sem reposição.

Quando N é grande em relação a n ,

$$\frac{N - n}{N - 1}$$

fica próximo de 1. Nessa situação, a distribuição binomial pode fornecer uma aproximação para a distribuição hipergeométrica.

A distribuição hipergeométrica, e não a binomial, é o modelo exato para amostragem sem reposição em população finita (Ramachandran; Tsokos, 2021, secs. 3.2.1–3.2.4; Chihara; Hesterberg, 2022, aps. B.1–B.6).

💡 Relação com o experimento da urna

Essa distinção será utilizada posteriormente no estudo da amostragem.

Considere uma urna com N bolas, das quais M apresentam determinada característica, por exemplo, a cor vermelha. Se são realizadas n retiradas **sem reposição** e X representa o número de bolas vermelhas observadas, então

$$X \sim \text{Hiper}(N, M, n).$$

Nesse mecanismo, as retiradas não são independentes, pois a composição da urna é modificada após cada seleção.

Se, em vez disso, cada retirada for realizada **com reposição**, a probabilidade de observar uma bola vermelha permanece constante,

$$p = \frac{M}{N},$$

e as retiradas podem ser representadas por variáveis Bernoulli independentes:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Nesse caso,

$$X = \sum_{i=1}^n X_i \sim \text{Binom}(n, p).$$

Assim, mecanismos de amostragem diferentes podem produzir variáveis com interpretações semelhantes, mas distribuições probabilísticas distintas.

1.6.6 Distribuição geométrica

Considere uma sequência de ensaios de Bernoulli independentes, todos com probabilidade de sucesso

$$0 < p < 1.$$

Se X representa o **número de ensaios necessários até a ocorrência do primeiro sucesso**, então

$$X \sim \text{Geo}(p).$$

O suporte é

$$\mathcal{X} = \{1, 2, 3, \dots\},$$

e a função de massa de probabilidade é

$$p_X(x) = p(1-p)^{x-1}\mathbf{1}_{\{1,2,\dots\}}(x).$$

A esperança é

$$E(X) = \frac{1}{p},$$

e a variância é

$$\text{Var}(X) = \frac{1-p}{p^2}.$$

A função geradora de momentos é

$$M_X(t) = \sum_{x=1}^{\infty} e^{tx} p(1-p)^{x-1}.$$

Utilizando a soma de uma série geométrica,

$$M_X(t) = \frac{pe^t}{1 - (1-p)e^t},$$

para

$$t < -\log(1-p).$$

Considere ligações realizadas por uma central até que um cliente aceite participar de uma pesquisa. Suponha que cada ligação resulte em aceitação com probabilidade p e que os resultados possam ser tratados como independentes.

Se X representa o número de ligações necessárias até a primeira aceitação,

$$X \sim \text{Geo}(p).$$

Em um problema inferencial, os números de ligações necessários em diferentes sequências de contatos podem fornecer informação sobre a probabilidade p de aceitação de um convite.




Figura 1.5: Função de massa de probabilidade e função de distribuição acumulada da distribuição geométrica para diferentes parâmetros.

A Figura ?? mostra que a distribuição concentra sua maior massa em $x = 1$ e decresce à medida que o número de tentativas aumenta. Para valores maiores de p , o primeiro sucesso tende a ocorrer mais cedo. Essa relação também aparece em

$$E(X) = \frac{1}{p}.$$

Assim, para $p = 0,8$, a probabilidade acumulada aproxima-se rapidamente de 1, enquanto para $p = 0,2$ a distribuição apresenta uma cauda mais longa.

1.6.6.1 Falta de memória

A distribuição geométrica possui a propriedade de falta de memória. Para inteiros não negativos m e n ,

$$P(X > m + n \mid X > m) = P(X > n).$$

A expressão indica que, após m tentativas sem sucesso, o número adicional de tentativas necessário para observar o primeiro sucesso segue o mesmo mecanismo probabilístico do início da sequência.

i Parametrização

Outra convenção define a distribuição geométrica pelo número de fracassos observados antes do primeiro sucesso, resultando no suporte

$$\{0, 1, 2, \dots\}.$$

Neste livro, X representa o número total de ensaios até o primeiro sucesso e, portanto, seu suporte começa em 1.

1.6.7 Distribuição binomial negativa

A distribuição binomial negativa generaliza a distribuição geométrica.

Considere ensaios de Bernoulli independentes com probabilidade de sucesso

$$0 < p < 1.$$

Se X representa o número total de ensaios necessários para observar o r -ésimo sucesso, com

$$r \in \mathbb{N},$$

então

$$X \sim \text{BN}(r, p).$$

Seu suporte é

$$\mathcal{X} = \{r, r+1, r+2, \dots\}.$$

A função de massa de probabilidade é

$$p_X(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r} \mathbf{1}_{\{r, r+1, \dots\}}(x).$$

Para que o r -ésimo sucesso ocorra exatamente no ensaio x , entre os primeiros $x-1$ ensaios devem ocorrer $r-1$ sucessos, e o último ensaio deve ser um sucesso.

A esperança é

$$E(X) = \frac{r}{p},$$

e a variância é

$$\text{Var}(X) = \frac{r(1-p)}{p^2}.$$

Como uma variável binomial negativa pode ser representada como a soma de r variáveis geométricas independentes com parâmetro p , sua função geradora de momentos é

$$M_X(t) = \left[\frac{pe^t}{1 - (1-p)e^t} \right]^r,$$

para

$$t < -\log(1-p).$$

Quando

$$r = 1,$$

a distribuição binomial negativa reduz-se à distribuição geométrica.

Considere uma equipe de recrutamento que entra em contato com candidatos até obter $r = 5$ aceitações para determinada etapa de uma seleção.

Se cada contato resulta em aceitação com probabilidade p , sob condições que permitam tratar os resultados como independentes, o número total X de contatos necessários até a quinta aceitação pode ser modelado por

$$X \sim \text{BN}(5, p).$$

Os números de contatos necessários em diferentes processos podem ser utilizados para obter informação sobre a probabilidade p de aceitação.

A Figura ?? permite observar separadamente os efeitos de r e p . Mantendo $p = 0,4$, a passagem de $r = 2$ para $r = 5$ desloca a distribuição para valores maiores, pois mais sucessos precisam ser acumulados. Mantendo $r = 5$, o aumento de p de 0,4 para 0,7 desloca a distribuição para valores menores, pois os sucessos passam a ocorrer com maior frequência. Essas relações são compatíveis com

$$E(X) = \frac{r}{p}.$$

1.6.8 Distribuição de Poisson

A distribuição de Poisson é utilizada para modelar o número de ocorrências de determinado evento em uma região de observação, como um intervalo de tempo, uma área, um comprimento ou um volume.

Se

$$X \sim \text{Poisson}(\lambda), \quad \lambda > 0,$$

o suporte é

$$\mathcal{X} = \{0, 1, 2, \dots\},$$

e a função de massa de probabilidade é




Figura 1.6: Função de massa de probabilidade e função de distribuição acumulada da distribuição binomial negativa para diferentes parâmetros.

$$p_X(x) = e^{-\lambda} \frac{\lambda^x}{x!} \mathbf{1}_{\{0,1,2,\dots\}}(x).$$

O parâmetro λ representa o número esperado de ocorrências na região de observação considerada.

Quando o número esperado de ocorrências é determinado por uma taxa média por unidade de exposição, é útil distinguir a taxa da quantidade esperada no intervalo observado.

Se ρ representa a taxa média de ocorrências por unidade de exposição e t representa a exposição considerada, então

$$\lambda = \rho t.$$

Assim, ρ representa uma taxa por unidade de tempo, área, comprimento, volume ou outra medida de exposição, enquanto λ representa o número esperado de ocorrências na exposição específica t .

Por exemplo, se uma taxa média é de $\rho = 3$ ocorrências por hora e o período observado possui $t = 4$ horas, então

$$\lambda = 3(4) = 12.$$

Nesse período,

$$X \sim \text{Poisson}(12).$$

A esperança e a variância coincidem:

$$E(X) = \lambda$$

e

$$\text{Var}(X) = \lambda.$$

A função geradora de momentos é

$$M_X(t) = \sum_{x=0}^{\infty} e^{tx} e^{-\lambda} \frac{\lambda^x}{x!}.$$

Reorganizando os termos,

$$M_X(t) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!}.$$

Como

$$\sum_{x=0}^{\infty} \frac{a^x}{x!} = e^a,$$

segue que

$$M_X(t) = \exp \{ \lambda(e^t - 1) \}.$$

Considere uma agência bancária e seja X o número de clientes atendidos durante o turno da manhã, cuja duração é de t horas.

Suponha que ρ represente a taxa média de atendimentos por hora. Se a distribuição de Poisson fornecer uma representação adequada para essa contagem, então

$$X \sim \text{Poisson}(\lambda),$$

com

$$\lambda = \rho t.$$

Nesse caso, ρ representa o número médio de atendimentos por hora, enquanto λ representa o número médio de atendimentos durante todo o turno.

Ao observar as quantidades de clientes atendidos em vários turnos da manhã, pode haver interesse inferencial em obter informação sobre ρ ou, de forma equivalente quando t é conhecido, sobre λ . Também pode haver interesse em comparar as taxas médias de atendimento entre períodos ou avaliar se uma mudança no processo de trabalho modificou essa taxa.

Os procedimentos utilizados para realizar essas inferências serão desenvolvidos posteriormente.

Considere X como o número de defeitos encontrados em uma determinada área de uma chapa metálica. Se a distribuição de Poisson fornecer uma representação adequada para essas contagens, λ corresponde ao número esperado de defeitos na área considerada.

Observações realizadas em várias chapas podem ser utilizadas para obter informação sobre essa intensidade média de defeitos.




Figura 1.7: Função de massa de probabilidade e função de distribuição acumulada da distribuição de Poisson para diferentes parâmetros.

A Figura ?? mostra que o aumento de λ desloca a distribuição para contagens maiores e também aumenta sua dispersão. Isso decorre das relações

$$E(X) = \lambda$$

e

$$\text{Var}(X) = \lambda.$$

Para $\lambda = 1$, a distribuição apresenta maior concentração nos primeiros valores e assimetria à direita. À medida que λ aumenta, a massa se desloca para valores maiores e a forma da distribuição torna-se visualmente menos assimétrica.

1.6.9 Relação entre binomial e Poisson

A distribuição de Poisson pode surgir como limite da distribuição binomial em situações com grande número de ensaios e pequena probabilidade individual de sucesso.

Considere

$$X_n \sim \text{Binom}(n, p_n).$$

Se

$$n \rightarrow \infty,$$

$$p_n \rightarrow 0$$

e

$$np_n \rightarrow \lambda,$$

então, para cada

$$x = 0, 1, 2, \dots,$$

temos

$$P(X_n = x) \longrightarrow e^{-\lambda} \frac{\lambda^x}{x!}.$$

Assim, em determinadas situações, uma contagem resultante de muitos ensaios com baixa probabilidade individual de sucesso pode ser aproximada por uma distribuição de Poisson.

1.6.10 Soma de variáveis Poisson independentes

Considere variáveis independentes

$$X_1, \dots, X_k,$$

com

$$X_j \sim \text{Poisson}(\lambda_j).$$

A FGM de cada variável é

$$M_{X_j}(t) = \exp\{\lambda_j(e^t - 1)\}.$$

Pela independência,

$$M_{\sum_{j=1}^k X_j}(t) = \prod_{j=1}^k M_{X_j}(t).$$

Logo,

$$M_{\sum_{j=1}^k X_j}(t) = \exp\left\{\left(\sum_{j=1}^k \lambda_j\right)(e^t - 1)\right\}.$$

Essa é a função geradora de momentos de uma distribuição de Poisson com parâmetro

$$\sum_{j=1}^k \lambda_j.$$

Portanto,

$$\sum_{j=1}^k X_j \sim \text{Poisson} \left(\sum_{j=1}^k \lambda_j \right).$$

Esse resultado mostra uma das utilidades da função geradora de momentos: propriedades de fechamento de famílias probabilísticas podem ser obtidas pela identificação da FGM resultante.

1.6.11 Relações entre os modelos discretos

Os modelos discretos apresentados nesta seção correspondem a diferentes mecanismos de geração das observações.

Modelo	Variável modelada	Estrutura probabilística
Uniforme discreta	resultado entre valores equiprováveis	probabilidades iguais
Bernoulli(p)	resultado de um único ensaio	sucesso ou fracasso
Binomial(n, p)	número de sucessos em n ensaios	soma de Bernoulli independentes
Hipergeométrica(N, M, n)	número de sucessos em uma amostra	população finita, sem reposição
Geométrica(p)	número de ensaios até o primeiro sucesso	sequência de Bernoulli
Binomial negativa(r, p)	número de ensaios até o r -ésimo sucesso	soma de variáveis geométricas
Poisson(λ)	número de ocorrências em uma região	modelo de contagens

Algumas relações podem ser representadas por

$$\text{Ber} \longrightarrow \text{Binom},$$

pois a distribuição binomial resulta da soma de variáveis Bernoulli independentes, e por

$$\text{Geo} \longrightarrow \text{BN},$$

pois a binomial negativa pode ser representada pela soma dos tempos de espera entre sucessivos sucessos.

A distribuição hipergeométrica descreve uma estrutura semelhante à binomial quando a seleção ocorre sem reposição em uma população finita. A distribuição de Poisson, por sua vez, descreve outra classe de problemas de contagem e pode surgir como limite da distribuição binomial.

1.7 Modelo multinomial

1.7.1 Distribuição multinomial

A distribuição multinomial generaliza a distribuição binomial para situações em que cada ensaio pode resultar em uma entre m categorias mutuamente exclusivas.

Considere $n \in \mathbb{N}$ ensaios independentes. Em cada ensaio, o resultado pertence a exatamente uma entre $m \geq 2$ categorias,

$$1, \dots, m,$$

com probabilidades

$$p_1, \dots, p_m,$$

tais que

$$0 < p_j < 1, \quad j = 1, \dots, m,$$

e

$$\sum_{j=1}^m p_j = 1.$$

Com essa convenção, todas as categorias possuem probabilidade positiva de ocorrência.

Se X_j representa o número de observações classificadas na categoria j , então o vetor

$$\mathbf{X} = (X_1, \dots, X_m)^\top$$

satisfaz

$$\sum_{j=1}^m X_j = n.$$

Escrevemos

$$\mathbf{X} \sim \text{Multinomial}(n; p_1, \dots, p_m).$$

1.7.2 Suporte e função de massa conjunta

O suporte da distribuição multinomial é

$$\mathcal{X}_n = \left\{ (x_1, \dots, x_m) \in \mathbb{N}_0^m : \sum_{j=1}^m x_j = n \right\}.$$

A função de massa de probabilidade conjunta é

$$p_{\mathbf{X}}(\mathbf{x}) = \frac{n!}{x_1! \cdots x_m!} \prod_{j=1}^m p_j^{x_j} \mathbf{1}_{\mathcal{X}_n}(\mathbf{x}).$$

O coeficiente multinomial

$$\frac{n!}{x_1! \cdots x_m!}$$

representa o número de sequências de n ensaios que produzem as contagens

$$x_1, \dots, x_m.$$

Quando

$$m = 2,$$

temos

$$X_2 = n - X_1,$$

e o modelo multinomial reduz-se à distribuição binomial.

1.7.3 Esperanças, variâncias e covariâncias

Para cada categoria,

$$E(X_j) = np_j$$

e

$$\text{Var}(X_j) = np_j(1 - p_j).$$

Para categorias distintas,

$$\text{Cov}(X_j, X_k) = -np_j p_k, \quad j \neq k.$$

A covariância negativa decorre da restrição

$$X_1 + \cdots + X_m = n.$$

Como o total n é fixado, uma observação classificada em determinada categoria deixa de estar disponível para as demais.

O vetor de médias é

$$E(\mathbf{X}) = n \begin{pmatrix} p_1 \\ \vdots \\ p_m \end{pmatrix}.$$

A matriz de covariâncias possui elementos

$$\Sigma_{jj} = np_j(1 - p_j)$$

na diagonal e

$$\Sigma_{jk} = -np_j p_k, \quad j \neq k,$$

fora da diagonal.

1.7.4 Distribuições marginais

Embora as componentes de $\mathbf{X}$ não sejam independentes, cada contagem individual possui distribuição binomial.

Para

$$j = 1, \dots, m,$$

temos

$$X_j \sim \text{Binom}(n, p_j).$$

Portanto,

$$P(X_j = x) = \binom{n}{x} p_j^x (1 - p_j)^{n-x}, \quad x = 0, \dots, n.$$

Essa propriedade permite interpretar cada componente separadamente, embora a distribuição conjunta contenha informação adicional sobre a dependência entre as contagens.

1.7.5 Função geradora de momentos conjunta

Para um vetor

$$\mathbf{t} = (t_1, \dots, t_m)^\top,$$

a função geradora de momentos conjunta é

$$M_{\mathbf{X}}(\mathbf{t}) = E \left[\exp \left(\sum_{j=1}^m t_j X_j \right) \right].$$

Para uma distribuição multinomial,

$$M_{\mathbf{X}}(t_1, \dots, t_m) = \left(\sum_{j=1}^m p_j e^{t_j} \right)^n.$$

A partir dessa expressão podem ser obtidos os momentos individuais e cruzados por diferenciação em relação às componentes de $\mathbf{t}$.

Considere uma pesquisa sobre o principal meio de transporte utilizado para deslocamentos diários. Cada participante é classificado em uma entre três categorias:

1. transporte coletivo;
2. transporte individual;
3. deslocamento a pé ou por bicicleta.

Defina

$$\mathbf{X} = (X_1, X_2, X_3)^\top,$$

em que X_j representa o número de pessoas classificadas na categoria j em uma amostra de tamanho n .

Se as respostas forem representadas por ensaios independentes com probabilidades populacionais

$$p_1, p_2, p_3,$$

então

$$(X_1, X_2, X_3) \sim \text{Multinomial}(n; p_1, p_2, p_3).$$

Em um problema inferencial, as contagens observadas podem ser utilizadas para obter informação sobre o vetor de proporções populacionais

$$\mathbf{p} = (p_1, p_2, p_3)^\top.$$

O interesse pode estar em uma proporção específica, na comparação entre categorias ou no conjunto completo de proporções.

Considere um processo de controle de qualidade no qual cada produto inspecionado é classificado como

1. sem defeito;
2. defeito leve;
3. defeito grave.





Figura 1.8: Função de massa de probabilidade conjunta de uma distribuição multinomial com três categorias e funções de massa das respectivas distribuições marginais.

As contagens observadas em uma amostra podem ser representadas por uma distribuição multinomial quando as condições do modelo forem adequadas.

Nesse contexto, pode haver interesse em obter informação sobre as proporções populacionais de produtos pertencentes a cada categoria.

Na parte superior da Figura ??, cada posição representa uma combinação possível de contagens

$$(x_1, x_2, x_3)$$

satisfazendo

$$x_1 + x_2 + x_3 = 10.$$

Como apenas duas contagens podem variar livremente, o valor de x_3 é determinado por

$$x_3 = 10 - x_1 - x_2.$$

A intensidade do preenchimento representa a massa de probabilidade atribuída a cada combinação.

No painel inferior aparecem as três distribuições marginais. Como

$$X_j \sim \text{Binom}(n, p_j),$$

a categoria com maior probabilidade, $p_3 = 0,5$, apresenta sua massa concentrada em valores maiores do que as categorias com $p_1 = 0,2$ e $p_2 = 0,3$.

A representação também evidencia uma diferença em relação aos modelos discretos univariados: a distribuição multinomial descreve simultaneamente várias contagens relacionadas pela restrição de soma.

1.8 Modelos probabilísticos contínuos

Modelos probabilísticos contínuos descrevem variáveis aleatórias cujos valores pertencem a intervalos ou outros subconjuntos contínuos da reta real. Nesse caso, as probabilidades são determinadas por áreas sob uma função de densidade, enquanto a probabilidade atribuída a qualquer valor isolado é nula.

Nesta seção, serão revisadas as distribuições uniforme, exponencial, gama, normal e beta. Para cada modelo serão apresentados o mecanismo probabilístico, o suporte, a função densidade de probabilidade, a esperança, a variância, a função geradora de momentos quando sua expressão for útil, situações que podem originar problemas inferenciais e o comportamento gráfico da densidade e da função de distribuição acumulada (Dantas, 1997; Magalhães, 2006; Meyer, 1983).

1.8.1 Distribuição uniforme contínua

A distribuição uniforme contínua descreve uma variável cujos intervalos de mesmo comprimento, contidos em determinado intervalo (a, b) , possuem a mesma probabilidade.

Uma variável aleatória X possui distribuição uniforme no intervalo (a, b) , com

$$a < b,$$

quando

$$X \sim U(a, b)$$

e sua densidade é

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{(a,b)}(x).$$

O suporte é

$$\mathcal{X} = (a, b).$$

A função de distribuição é

$$F_X(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b. \end{cases}$$

A esperança é

$$E(X) = \frac{a+b}{2},$$

e a variância é

$$\text{Var}(X) = \frac{(b-a)^2}{12}.$$

A função geradora de momentos é

$$M_X(t) = E(e^{tX}) = \frac{1}{b-a} \int_a^b e^{tx} dx.$$

Para $t \neq 0$,

$$M_X(t) = \frac{e^{bt} - e^{at}}{t(b-a)},$$

enquanto

$$M_X(0) = 1.$$

A esperança depende da posição do intervalo, enquanto a variância depende apenas de seu comprimento

$$b-a.$$

Considere um instrumento de medição cujo erro X seja representado, de forma idealizada, por uma distribuição uniforme no intervalo

$$(-\theta, \theta),$$

com $\theta > 0$.

Nesse caso,

$$X \sim U(-\theta, \theta),$$

e θ determina o limite máximo da magnitude do erro.

Ao observar erros de medição obtidos em diferentes calibrações, pode haver interesse inferencial em obter informação sobre θ e, conseqüentemente, sobre a amplitude da variação produzida pelo instrumento.

Esse exemplo também ilustra uma característica que será retomada posteriormente: o suporte da distribuição depende do parâmetro desconhecido.

i Caso de referência: uniforme com extremo desconhecido

Um caso particular que será utilizado novamente nos capítulos posteriores é

$$X \sim U(0, \theta), \quad \theta > 0.$$

Sua densidade é

$$f_X(x | \theta) = \frac{1}{\theta} \mathbf{1}_{(0, \theta)}(x),$$

e seu suporte é

$$\mathcal{X}_\theta = (0, \theta).$$

Nesse modelo,

$$E(X) = \frac{\theta}{2}$$

e

$$\text{Var}(X) = \frac{\theta^2}{12}.$$

A característica que merece atenção é que o próprio conjunto de valores admissíveis para X depende de θ . Por exemplo, se $\theta = 2$, os valores possíveis pertencem a $(0, 2)$; se $\theta = 5$, pertencem a $(0, 5)$.

Essa dependência entre suporte e parâmetro fará com que o modelo $U(0, \theta)$ tenha comportamento diferente de modelos como normal, Poisson e exponencial em alguns resultados inferenciais. Por esse motivo, ele será retomado como caso de referência ao discutir máxima verossimilhança e condições de regularidade.

A Figura ?? mostra separadamente os efeitos da posição e do comprimento do intervalo. As distribuições $U(-2, 2)$ e $U(0, 4)$ possuem a mesma amplitude, igual a 4, e conseqüentemente a




Figura 1.9: Função densidade de probabilidade e função de distribuição acumulada da distribuição uniforme para diferentes intervalos.

mesma altura da densidade e a mesma variância. A segunda distribuição está apenas deslocada para a direita.

Para $U(-1, 1)$, a amplitude é menor. Como a área total sob a densidade deve permanecer igual a 1, a redução do comprimento do intervalo aumenta a altura da densidade. Na função de distribuição, intervalos menores produzem um crescimento mais rápido de 0 até 1.

1.8.2 Distribuição exponencial

A distribuição exponencial é utilizada para representar tempos até a ocorrência de determinado evento em situações nas quais uma taxa de ocorrência constante constitui uma descrição adequada do mecanismo considerado.

Uma variável aleatória X possui distribuição exponencial com taxa

$$\lambda > 0$$

quando

$$X \sim \text{Exp}(\lambda)$$

e sua densidade é

$$f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x).$$

O suporte é

$$\mathcal{X} = (0, \infty).$$

A função de distribuição é

$$F_X(x) = \begin{cases} 0, & x \leq 0, \\ 1 - e^{-\lambda x}, & x > 0. \end{cases}$$

Consequentemente, para $x \geq 0$,

$$P(X > x) = e^{-\lambda x}.$$

A esperança é

$$E(X) = \frac{1}{\lambda},$$

e a variância é

$$\text{Var}(X) = \frac{1}{\lambda^2}.$$

A função geradora de momentos é

$$M_X(t) = \int_0^\infty e^{tx} \lambda e^{-\lambda x} dx.$$

Para

$$t < \lambda,$$

temos

$$M_X(t) = \frac{\lambda}{\lambda - t}.$$

O parâmetro λ é uma taxa. Seu inverso,

$$\frac{1}{\lambda},$$

corresponde ao tempo médio representado pelo modelo.

Considere uma agência bancária e seja X o tempo transcorrido entre a chegada de um cliente e o início de seu atendimento.

Se uma distribuição exponencial fornecer uma representação adequada para esses tempos,

$$X \sim \text{Exp}(\lambda),$$

em que $\lambda > 0$ é o parâmetro de taxa da distribuição.

Sob esse modelo, o tempo médio de espera é

$$E(X) = \frac{1}{\lambda}.$$

Assim, valores maiores de λ correspondem a tempos médios de espera menores, enquanto valores menores de λ correspondem a tempos médios maiores.

Ao observar os tempos de espera de vários clientes, pode haver interesse inferencial em obter informação sobre λ ou, de forma equivalente, sobre o tempo médio $1/\lambda$. Também poderia haver interesse em comparar esses tempos entre diferentes turnos, dias ou formas de organização do atendimento.

A Figura ?? mostra que o aumento de λ concentra a distribuição em tempos menores. Essa relação decorre de

$$E(X) = \frac{1}{\lambda}.$$

Para $\lambda = 2$, a densidade decresce rapidamente e a função de distribuição aproxima-se de 1 em valores relativamente pequenos de x . Para $\lambda = 0,5$, tempos maiores recebem probabilidade mais elevada e a função de distribuição cresce mais lentamente.

1.8.2.1 Falta de memória

A distribuição exponencial possui a propriedade de falta de memória. Para

$$s, t > 0,$$

temos

$$P(X > s + t \mid X > s) = P(X > t).$$

Assim, condicionado ao fato de que o evento ainda não ocorreu até o instante s , o tempo adicional de espera possui a mesma distribuição do tempo de espera inicialmente considerado.

Essa propriedade é a versão contínua da falta de memória apresentada para a distribuição geométrica.

i Parametrização

Nesta seção, a distribuição exponencial está parametrizada pela **taxa** λ , de modo que

$$E(X) = \frac{1}{\lambda}.$$

Quando a distribuição exponencial for parametrizada diretamente pela média, utilizaremos o símbolo




Figura 1.10: Função densidade de probabilidade e função de distribuição acumulada da distribuição exponencial para diferentes parâmetros.

$$\mu > 0,$$

escrevendo

$$X \sim \text{Exp}(\mu),$$

com

$$E(X) = \mu$$

e densidade

$$f_X(x) = \frac{1}{\mu} e^{-x/\mu} \mathbf{1}_{(0,\infty)}(x).$$

As duas parametrizações descrevem a mesma família e estão relacionadas por

$$\lambda = \frac{1}{\mu}.$$

O uso de símbolos distintos permite identificar explicitamente qual parametrização está sendo adotada em cada contexto.

1.8.3 Distribuição gama

A distribuição gama generaliza a distribuição exponencial e permite representar diferentes formas para variáveis aleatórias positivas.

Como parametrização geral, utilizaremos a **forma**

$$\alpha > 0$$

e a **escala**

$$\beta > 0.$$

Escrevemos

$$X \sim \text{Gama}(\alpha, \beta)$$

quando sua densidade é

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \mathbf{1}_{(0,\infty)}(x),$$

em que

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt$$

é a função gama.

O suporte é

$$\mathcal{X} = (0, \infty).$$

A esperança é

$$E(X) = \alpha\beta,$$

e a variância é

$$\text{Var}(X) = \alpha\beta^2.$$

A função geradora de momentos é

$$M_X(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

Quando

$$\alpha = 1,$$

a distribuição gama coincide com uma distribuição exponencial cuja média satisfaz

$$\mu = \beta.$$

Assim,

$$X \sim \text{Gama}(1, \beta)$$

é equivalente a uma variável exponencial com média $\mu = \beta$.

Considere um procedimento bancário composto por três etapas sucessivas de atendimento. Suponha que os tempos necessários para completar cada etapa possam ser representados por variáveis exponenciais independentes com a mesma taxa λ .

Se

$$X_1, X_2, X_3 \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

o tempo total

$$T = X_1 + X_2 + X_3$$

possui distribuição gama. Como nesta seção a notação $\text{Gama}(\alpha, \beta)$ foi definida na parametrização forma-escala, a taxa λ corresponde à escala

$$\beta = \frac{1}{\lambda}.$$

Portanto,

$$T \sim \text{Gama}\left(3, \frac{1}{\lambda}\right).$$

Ao observar tempos totais de atendimento de vários clientes, pode haver interesse inferencial em obter informação sobre λ e, conseqüentemente, sobre

$$E(T) = \frac{3}{\lambda}.$$

A distribuição gama permite, portanto, modelar um tempo positivo resultante da soma de vários tempos de espera.

A distribuição gama também pode ser considerada para variáveis positivas que apresentam assimetria à direita. Considere, por exemplo, o custo associado à execução de determinado procedimento, desde que as características empíricas e o mecanismo considerado sejam compatíveis com esse modelo.

Nesse caso, observações de diferentes unidades podem ser utilizadas para obter informação sobre os parâmetros que determinam a média e a dispersão da distribuição.

A Figura ?? permite observar separadamente os efeitos dos parâmetros de forma e escala. Para

$$\alpha = 1 \quad \text{e} \quad \beta = 1,$$

a distribuição gama coincide com uma distribuição exponencial de média 1, e sua densidade é decrescente.




Figura 1.11: Função densidade de probabilidade e função de distribuição acumulada da distribuição gama para diferentes parâmetros.

Mantendo $\beta = 1$ e aumentando α de 1 para 3, a massa da distribuição desloca-se para valores maiores e a forma da densidade deixa de ser monotonicamente decrescente. Mantendo $\alpha = 3$ e reduzindo β de 1 para 0,5, a distribuição se concentra em valores menores, resultado compatível com

$$E(X) = \alpha\beta.$$

1.8.3.1 Relação entre exponencial e gama

Se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

então

$$S_n = \sum_{i=1}^n X_i$$

possui distribuição gama. Como a taxa exponencial λ corresponde à escala $1/\lambda$,

$$S_n \sim \text{Gama}\left(n, \frac{1}{\lambda}\right).$$

Esse resultado pode ser obtido diretamente pelas funções geradoras de momentos. Como

$$M_{X_i}(t) = \frac{\lambda}{\lambda - t},$$

pela independência,

$$M_{S_n}(t) = \left(\frac{\lambda}{\lambda - t}\right)^n.$$

Essa é a FGM de uma distribuição gama com forma n e escala $1/\lambda$.

Consequentemente,

$$E(S_n) = \frac{n}{\lambda}$$

e

$$\text{Var}(S_n) = \frac{n}{\lambda^2}.$$

i Forma, escala e taxa

Na parametrização adotada neste livro,

$$X \sim \text{Gama}(\alpha, \beta),$$

o primeiro parâmetro α representa a **forma** e o segundo parâmetro β representa a **escala**, em concordância com a parametrização utilizada por Casella e Berger.

Quando a distribuição gama surge a partir de variáveis exponenciais parametrizadas pela taxa λ , utilizamos a relação

$$\beta = \frac{1}{\lambda}.$$

Assim,

$$X \sim \text{Gama}\left(\alpha, \frac{1}{\lambda}\right)$$

possui

$$E(X) = \frac{\alpha}{\lambda}$$

e

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

Dessa forma, a notação $\text{Gama}(\alpha, \beta)$ mantém sempre o segundo parâmetro como escala, enquanto a taxa λ pode ser utilizada nos modelos exponenciais sem ambiguidade.

1.8.4 Distribuição normal

A distribuição normal é uma família de distribuições contínuas simétricas determinada por um parâmetro de localização e outro de dispersão.

Uma variável aleatória X possui distribuição normal com média

$$\mu \in \mathbb{R}$$

e variância

$$\sigma^2 > 0$$

quando

$$X \sim N(\mu, \sigma^2)$$

e sua densidade é

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} \mathbf{1}_{\mathbb{R}}(x).$$

O suporte é

$$\mathcal{X} = \mathbb{R}.$$

A esperança é

$$E(X) = \mu,$$

e a variância é

$$\text{Var}(X) = \sigma^2.$$

O parâmetro μ determina a localização da distribuição, enquanto σ determina sua dispersão.

A densidade é simétrica em torno de μ . Consequentemente,

$$P(X \leq \mu) = \frac{1}{2}.$$

A função geradora de momentos é

$$M_X(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right), \quad t \in \mathbb{R}.$$

Considere uma máquina utilizada para envasar determinado produto. Seja X o peso de uma unidade produzida.

Se uma distribuição normal fornecer uma representação adequada para os pesos,

$$X \sim N(\mu, \sigma^2),$$

então μ representa o peso médio do processo e σ representa sua dispersão.

Uma amostra de produtos pode ser utilizada para obter informação sobre μ , sobre σ^2 ou sobre ambos. Por exemplo, pode haver interesse em avaliar se o peso médio está próximo do valor nominal especificado para o produto ou em quantificar a variabilidade do processo produtivo.

Considere X como determinada medida morfológica em indivíduos de uma população, como comprimento ou peso, em uma situação na qual a distribuição normal seja adequada.

As observações obtidas em uma amostra podem ser utilizadas para estudar a média populacional μ e a variância σ^2 dessa característica.

A Figura ?? mostra separadamente os efeitos dos parâmetros μ e σ . Mantendo $\sigma = 1$, a alteração de μ desloca a distribuição ao longo do eixo horizontal sem modificar sua forma. Mantendo $\mu = 0$, o aumento de σ produz maior dispersão e reduz a altura máxima da densidade.

Na função de distribuição, mudanças em μ deslocam a curva horizontalmente, enquanto valores maiores de σ tornam a transição entre probabilidades próximas de 0 e de 1 mais gradual.

1.8.4.1 Padronização

Se

$$X \sim N(\mu, \sigma^2),$$

então

$$Z = \frac{X - \mu}{\sigma}$$

possui distribuição normal padrão,

$$Z \sim N(0, 1).$$

Consequentemente,

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right),$$

em que Φ representa a função de distribuição da normal padrão.

A transformação separa a posição e a escala da variável original e permite expressar probabilidades de qualquer distribuição normal em termos de uma única distribuição de referência.




Figura 1.12: Função densidade de probabilidade e função de distribuição acumulada da distribuição normal para diferentes parâmetros.

1.8.4.2 Transformações lineares da distribuição normal

Se

$$X \sim N(\mu, \sigma^2)$$

e

$$Y = aX + b,$$

com $a \neq 0$, então

$$Y \sim N(a\mu + b, a^2\sigma^2).$$

Além disso, se

$$X_1, \dots, X_n$$

são independentes e

$$X_i \sim N(\mu_i, \sigma_i^2),$$

então, para constantes $a_1, \dots, a_n$,

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right).$$

Em particular, se

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

então

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

possui distribuição

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Esse resultado será retomado no estudo das distribuições amostrais.

1.8.5 Distribuição beta

A distribuição beta forma uma família de distribuições contínuas definidas no intervalo $(0, 1)$. Seus dois parâmetros permitem representar diferentes padrões de simetria, assimetria e concentração.

Uma variável aleatória X possui distribuição beta com parâmetros

$$\alpha > 0 \quad \text{e} \quad \beta > 0$$

quando

$$X \sim \text{Beta}(\alpha, \beta)$$

e sua densidade é

$$f_X(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} \mathbf{1}_{(0,1)}(x),$$

em que

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx.$$

A função beta relaciona-se à função gama por

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

O suporte é

$$\mathcal{X} = (0, 1).$$

A esperança é

$$E(X) = \frac{\alpha}{\alpha + \beta},$$

e a variância é

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

A função geradora de momentos existe para todo

$$t \in \mathbb{R},$$

mas sua expressão geral envolve funções especiais. Como essa forma não será utilizada nos desenvolvimentos posteriores, ela não será apresentada nesta revisão.

i Valores nos extremos do intervalo

A distribuição beta apresentada nesta seção possui suporte

$$(0, 1).$$

Portanto, ela é adequada para variáveis contínuas que assumem valores estritamente entre 0 e 1.

Quando valores exatamente iguais a 0 ou 1 podem ocorrer com probabilidade positiva, a distribuição beta padrão não representa diretamente essa massa de probabilidade nos extremos. Nesses casos, pode ser necessário considerar outra especificação probabilística. Essa distinção deve ser considerada, por exemplo, ao modelar proporções que possam assumir exatamente 0% ou 100%.

Considere X como a proporção da área de uma parcela coberta por vegetação, expressa em escala de 0 a 1.

Se a distribuição beta fornecer uma representação adequada para a variação dessas proporções entre parcelas,

$$X \sim \text{Beta}(\alpha, \beta).$$

Observações realizadas em várias parcelas podem ser utilizadas para obter informação sobre α e β ou sobre quantidades derivadas desses parâmetros, como a média

$$E(X) = \frac{\alpha}{\alpha + \beta}.$$

Assim, o interesse pode estar na cobertura média da população de parcelas e na variabilidade existente entre elas.

A distribuição beta também pode ser considerada para índices contínuos naturalmente limitados ao intervalo $(0, 1)$, desde que sua forma seja compatível com os dados e com o mecanismo considerado.

Nesse contexto, diferentes combinações de α e β permitem representar distribuições simétricas ou assimétricas e diferentes níveis de concentração em determinadas regiões do intervalo.

A Figura ?? mostra a flexibilidade da distribuição beta. Para

$$\alpha = \beta = 2,$$

a distribuição é simétrica em torno de 0,5.

Quando

$$\alpha = 2 \quad \text{e} \quad \beta = 5,$$

a massa está concentrada em valores menores. Quando os parâmetros são invertidos,

$$\alpha = 5 \quad \text{e} \quad \beta = 2,$$

obtém-se uma distribuição espelhada, concentrada em valores maiores. Esse comportamento também aparece nas médias:

$$E(X) = \frac{2}{7}, \quad \frac{1}{2} \quad \text{e} \quad \frac{5}{7},$$

respectivamente.

1.8.5.1 Casos particulares e simetria

Quando

$$\alpha = \beta,$$

a distribuição beta é simétrica em torno de

$$\frac{1}{2}.$$




Figura 1.13: Função densidade de probabilidade e função de distribuição acumulada da distribuição beta para diferentes parâmetros.

Em particular,

$$\text{Beta}(1, 1) = \text{U}(0, 1).$$

Assim, a distribuição uniforme padrão aparece como um caso particular da família beta.

1.8.6 Relações entre gama e beta

As distribuições gama e beta estão relacionadas por transformações de variáveis aleatórias independentes.

Se

$$X \sim \text{Gama}(\alpha, \theta)$$

e

$$Y \sim \text{Gama}(\beta, \theta),$$

independentes, com o mesmo parâmetro de escala $\theta > 0$, então

$$X + Y \sim \text{Gama}(\alpha + \beta, \theta),$$

enquanto

$$\frac{X}{X + Y} \sim \text{Beta}(\alpha, \beta).$$

A primeira relação decorre diretamente da função geradora de momentos. A segunda mostra como uma variável limitada ao intervalo $(0, 1)$ pode ser construída a partir da razão entre duas variáveis gama positivas.

Essas relações serão úteis posteriormente para compreender algumas distribuições derivadas de funções de variáveis aleatórias.

1.8.7 Escolha entre alguns modelos contínuos

Os modelos contínuos apresentados correspondem a estruturas probabilísticas diferentes. A tabela resume alguns contextos que podem orientar sua interpretação.

Situação representada	Modelo possível	Característica
valores equiprováveis em um intervalo	Uniforme	densidade constante
tempo até um evento sob taxa constante	Exponencial	suporte positivo e falta de memória
soma de tempos exponenciais ou variável positiva assimétrica	Gama	suporte positivo e diferentes formas
variável aproximadamente simétrica em torno de uma média	Normal	localização e dispersão em $\mathbb{R}$
proporção ou índice contínuo em $(0, 1)$	Beta	formas flexíveis em intervalo limitado

A escolha de uma distribuição não depende apenas do suporte da variável. O mecanismo probabilístico, a forma da distribuição e as hipóteses utilizadas também precisam ser compatíveis com o fenômeno considerado.

i Distribuições derivadas do modelo normal

As distribuições qui-quadrado, t de Student e F estão relacionadas a funções de variáveis normais e gama. Elas não serão desenvolvidas nesta revisão. Sua apresentação será feita no capítulo **Distribuições Amostrais**, quando surgirem associadas a estatísticas construídas a partir de amostras normais.

1.9 Transformações de variáveis aleatórias

Transformações de variáveis aleatórias permitem construir novas variáveis a partir de variáveis cuja distribuição é conhecida.

Se

$$Y = g(X),$$

a distribuição de Y é determinada pela distribuição de X e pela transformação g .

Esse problema aparece em diferentes contextos. Uma estatística calculada a partir de observações é uma função de variáveis aleatórias, assim como muitas transformações utilizadas para alterar escala, estabilizar variância ou expressar uma quantidade de interesse de forma diferente.

Nesta revisão serão considerados o método da função de distribuição e a transformação de densidades no caso univariado. Transformações multivariadas e o determinante jacobiano serão retomados no capítulo **Resultados Matemáticos e Assintóticos para Inferência**.

1.9.1 Método da função de distribuição

Uma forma geral de determinar a distribuição de

$$Y = g(X)$$

consiste em obter sua função de distribuição:

$$F_Y(y) = P(Y \leq y).$$

Como

$$Y = g(X),$$

temos

$$F_Y(y) = P\{g(X) \leq y\}.$$

O problema é então reescrever o evento

$$\{g(X) \leq y\}$$

em termos dos valores assumidos por X .

Depois de obtida F_Y , a função de massa ou a densidade de Y pode ser determinada quando necessário.

1.9.2 Transformação monótona

Suponha que X seja absolutamente contínua e que

$$Y = g(X),$$

em que g é estritamente monótona no suporte de X . Suponha ainda que a função inversa

$$x = g^{-1}(y)$$

seja continuamente diferenciável no suporte da variável transformada.

Então, a densidade de Y é

$$f_Y(y) = f_X\{g^{-1}(y)\} \left| \frac{d}{dy} g^{-1}(y) \right|,$$

para y pertencente ao suporte da variável transformada (Casella; Berger, 2011, sec. 2.1; Rice, 2007, secs. 2.3 e 3.6; Ramachandran; Tsokos, 2021, sec. 3.4).

O termo

$$\left| \frac{d}{dy} g^{-1}(y) \right|$$

corrige a alteração de escala produzida pela transformação.

Considere

$$Y = aX + b, \quad a \neq 0.$$

A transformação inversa é

$$x = \frac{y - b}{a}.$$

Logo,

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y-b}{a}\right) \frac{1}{|a|}.$$

Se

$$X \sim N(\mu, \sigma^2),$$

essa transformação conduz a

$$Y \sim N(a\mu + b, a^2\sigma^2),$$

resultado já apresentado para a distribuição normal.

1.9.3 Exemplo de transformação entre modelos

Considere

$$X \sim U(0, 1)$$

e defina

$$Y = -\log X.$$

Como

$$0 < X < 1,$$

temos

$$Y > 0.$$

Para $y > 0$,

$$F_Y(y) = P(Y \leq y).$$

Substituindo a definição de Y ,

$$F_Y(y) = P(-\log X \leq y).$$

Como a função exponencial é crescente,

$$-\log X \leq y$$

equivale a

$$X \geq e^{-y}.$$

Portanto,

$$F_Y(y) = P(X \geq e^{-y}).$$

Como X possui distribuição uniforme em $(0, 1)$,

$$F_Y(y) = 1 - e^{-y}.$$

Para $y \leq 0$,

$$F_Y(y) = 0.$$

Assim,

$$F_Y(y) = \begin{cases} 0, & y \leq 0, \\ 1 - e^{-y}, & y > 0. \end{cases}$$

Essa é a função de distribuição de uma variável exponencial com taxa 1. Portanto,

$$-\log X \sim \text{Exp}(1).$$

O exemplo mostra que diferentes famílias probabilísticas podem estar relacionadas por transformações de variáveis aleatórias.

1.9.4 Transformações não monótonas

Quando g não é monotônica em todo o suporte de X , um mesmo valor de Y pode corresponder a mais de um valor de X .

Considere, por exemplo,

$$Y = X^2.$$

Para

$$y \geq 0,$$

temos

$$F_Y(y) = P(X^2 \leq y).$$

O evento

$$X^2 \leq y$$

equivale a

$$-\sqrt{y} \leq X \leq \sqrt{y}.$$

Logo,

$$F_Y(y) = P(-\sqrt{y} \leq X \leq \sqrt{y}).$$

Se X é contínua,

$$F_Y(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y}),$$

para

$$y \geq 0.$$

Para

$$y < 0,$$

temos

$$F_Y(y) = 0,$$

pois X^2 não pode assumir valores negativos.

A densidade de Y , quando necessária, pode ser obtida diferenciando $F_Y(y)$ em relação a y .

i Transformações multivariadas

Para transformações de vetores aleatórios, a mudança de variáveis envolve o determinante da matriz jacobiana da transformação inversa.

Esse resultado exige ferramentas de cálculo multivariado e será retomado no capítulo **Resultados Matemáticos e Assintóticos para Inferência**, quando for necessário obter distribuições de funções de vetores aleatórios.

1.9.5 Transformações em problemas inferenciais

Transformações também aparecem quando a quantidade de interesse é uma função de um parâmetro.

Por exemplo, em uma distribuição exponencial parametrizada pela taxa λ ,

$$E(X) = \frac{1}{\lambda}.$$

Um problema pode ser formulado em termos da taxa λ , enquanto outro pode ter como quantidade de interesse o tempo médio

$$\mu = \frac{1}{\lambda}.$$

Embora ambos descrevam o mesmo modelo probabilístico, a interpretação da quantidade desconhecida é diferente.

Posteriormente, métodos como a propriedade de invariância dos estimadores de máxima verossimilhança e o método delta permitirão estudar sistematicamente funções de parâmetros e de estimadores.

1.10 Quadro-síntese dos modelos probabilísticos

Os modelos apresentados ao longo deste capítulo diferem quanto ao suporte, aos parâmetros e ao mecanismo probabilístico utilizado para representar a variável observada. As tabelas seguintes reúnem suas principais características para consulta.

A escolha de uma distribuição não deve ser determinada apenas pela semelhança entre o formato de um gráfico e a forma de uma densidade ou função de massa conhecida. O suporte da variável, o mecanismo que produz os dados, as relações de dependência e o significado dos parâmetros também precisam ser considerados.

1.10.1 Modelos discretos univariados

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$
Uniforme discreta	$\{1, \dots, m\}$	m	$\frac{m+1}{2}$	$\frac{m^2-1}{12}$
Bernoulli	$\{0, 1\}$	p	p	$p(1-p)$
Binomial	$\{0, \dots, n\}$	n, p	np	$np(1-p)$
Hipergeométrica	$\{\max(0, n - N + M), \dots, \min(n, M)\}$	N, M, n	$np, p = M/N$	$np(1-p)\frac{N-n}{N-1},$ para $N > 1$; 0, para $N = 1$
Geométrica	$\{1, 2, \dots\}$	p	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Binomial negativa	$\{r, r+1, \dots\}$	r, p	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
Poisson	$\{0, 1, 2, \dots\}$	λ	λ	λ

1.10.2 Modelos contínuos univariados

Distribuição	Suporte	Parâmetro(s)	$E(X)$	$\text{Var}(X)$
Uniforme	(a, b)	a, b	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponencial	$(0, \infty)$	λ	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Gama	$(0, \infty)$	α, β	$\alpha\beta$	$\alpha\beta^2$
Normal	$\mathbb{R}$	μ, σ^2	μ	σ^2
Beta	$(0, 1)$	α, β	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

1.10.3 Funções geradoras de momentos

As funções geradoras de momentos apresentadas no capítulo podem ser reunidas em uma tabela de referência.

Distribuição	$M_X(t)$	Condição
Uniforme discreta em $\{1, \dots, m\}$	$\frac{1}{m} \sum_{x=1}^m e^{tx}$	$t \in \mathbb{R}$
Bernoulli(p)	$1 - p + pe^t$	$t \in \mathbb{R}$
Binomial(n, p)	$(1 - p + pe^t)^n$	$t \in \mathbb{R}$
Hipergeométrica(N, M, n)	$\sum_{x \in \mathcal{X}} e^{tx} p_X(x)$	$t \in \mathbb{R}$
Geométrica(p)	$\frac{pe^t}{1 - (1-p)e^t}$	$t < -\log(1-p)$
Binomial negativa(r, p)	$\left[\frac{pe^t}{1 - (1-p)e^t} \right]^r$	$t < -\log(1-p)$
Poisson(λ)	$\exp\{\lambda(e^t - 1)\}$	$t \in \mathbb{R}$
Uniforme(a, b)	$\frac{e^{bt} - e^{at}}{t(b-a)}$	$t \neq 0; M_X(0) = 1$
Exponencial(λ)	$\frac{\lambda}{\lambda - t}$	$t < \lambda$
Gama(α, β)	$(1 - \beta t)^{-\alpha}$	$t < 1/\beta$
Normal(μ, σ^2)	$\exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$	$t \in \mathbb{R}$

A distribuição beta não aparece nessa tabela porque sua função geradora de momentos, embora exista para todo $t \in \mathbb{R}$, envolve uma função especial que não será utilizada nos capítulos seguintes.

1.11 Relações entre os principais modelos

As relações desenvolvidas ao longo do capítulo podem ser reunidas em um mapa de referência. Elas decorrem de diferentes mecanismos: soma de variáveis independentes, mudança no esquema de amostragem, generalização de um modelo, transformação ou passagem ao limite.

1.11.1 Modelos discretos

Um ensaio Bernoulli representa um único resultado binário,

$$X_i \sim \text{Ber}(p).$$

A soma de ensaios Bernoulli independentes com a mesma probabilidade de sucesso produz a distribuição binomial:

$$\boxed{\text{Ber}(p) \xrightarrow{\text{soma de } n \text{ ensaios}} \text{Binom}(n, p)}$$

Quando a contagem de sucessos é realizada em uma amostra retirada sem reposição de uma população finita, o mecanismo muda:

$$\boxed{\text{contagem de sucessos sem reposição} \longrightarrow \text{Hiper}(N, M, n)}$$

A distribuição geométrica representa o número de ensaios até o primeiro sucesso, enquanto a binomial negativa estende esse mecanismo até o r -ésimo sucesso:

$$\boxed{\text{Geo}(p) = \text{BN}(1, p)}$$

e, de forma mais geral,

$$\boxed{\text{Geo}(p) \xrightarrow{r \text{ sucessos}} \text{BN}(r, p)}.$$

A distribuição de Poisson pode surgir como limite de distribuições binomiais quando o número de ensaios cresce, a probabilidade individual de sucesso diminui e o número esperado de sucessos converge para λ :

$$\boxed{\text{Binom}(n, p_n) \xrightarrow{n \rightarrow \infty, p_n \rightarrow 0, np_n \rightarrow \lambda} \text{Poisson}(\lambda)}.$$

A distribuição multinomial estende a estrutura binomial de duas categorias para m categorias:

$$\boxed{\text{Binom} \xrightarrow{\text{mais de duas categorias}} \text{Multinomial} .}$$

1.11.2 Modelos contínuos

Na relação entre a distribuição exponencial e a distribuição gama, lembramos que uma exponencial com taxa λ corresponde a uma gama com forma 1 e escala $1/\lambda$:

$$\text{Exp}(\lambda) = \text{Gama}\left(1, \frac{1}{\lambda}\right).$$

Além disso, a soma de variáveis exponenciais independentes com a mesma taxa produz uma variável gama:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda) \implies \sum_{i=1}^n X_i \sim \text{Gama}\left(n, \frac{1}{\lambda}\right).$$

A distribuição uniforme padrão é um caso particular da família beta:

$$\text{U}(0, 1) = \text{Beta}(1, 1).$$

Se

$$X \sim \text{Gama}(\alpha, \theta)$$

e

$$Y \sim \text{Gama}(\beta, \theta)$$

são independentes e possuem o mesmo parâmetro de escala $\theta > 0$, então

$$X + Y \sim \text{Gama}(\alpha + \beta, \theta)$$

e

$$\frac{X}{X + Y} \sim \text{Beta}(\alpha, \beta).$$

1.11.3 Leitura do mapa

As relações anteriores possuem naturezas diferentes:

Relação	Mecanismo
Bernoulli $\rightarrow$ Binomial	soma de ensaios independentes
Binomial $\leftrightarrow$ Hipergeométrica	alteração do mecanismo de amostragem
Geométrica $\rightarrow$ Binomial negativa	extensão do número de sucessos
Binomial $\rightarrow$ Poisson	resultado limite
Binomial $\rightarrow$ Multinomial	generalização do número de categorias
Exponencial $\rightarrow$ Gama	caso particular e soma de variáveis independentes
Uniforme $\rightarrow$ Beta	caso particular
Gama $\rightarrow$ Beta	transformação de variáveis independentes

O mapa mostra que os modelos probabilísticos não constituem uma coleção isolada de fórmulas. Suas relações decorrem dos mecanismos utilizados para produzir, combinar ou transformar variáveis aleatórias.

1.12 Síntese

O conteúdo deste capítulo pode ser organizado em seis componentes.

O primeiro corresponde à **estrutura básica da Probabilidade**. Eventos, probabilidade condicional, lei da probabilidade total, teorema de Bayes e independência permitem descrever relações entre acontecimentos aleatórios e incorporar informações condicionais.

O segundo reúne **variáveis aleatórias e suas distribuições**. A função de distribuição caracteriza a distribuição de uma variável aleatória, enquanto a função de massa de probabilidade e a densidade descrevem, respectivamente, variáveis discretas e absolutamente contínuas. O suporte, representado por $\mathcal{X}$ para uma variável X , identifica os valores admissíveis sob a distribuição considerada. A função indicadora permite incorporar esse suporte diretamente às expressões probabilísticas e também representar contagens e proporções.

O terceiro corresponde a **esperança, variância e momentos**. Essas quantidades descrevem características da distribuição de uma variável aleatória e permitem estudar transformações lineares, somas e combinações de variáveis.

O quarto reúne **distribuições conjuntas e dependência**. Distribuições marginais e condicionais descrevem diferentes aspectos de uma distribuição conjunta, enquanto covariância e correlação quantificam formas de associação. A independência estabelece uma condição probabilística mais forte e, quando várias variáveis são simultaneamente independentes e possuem a

mesma distribuição, obtém-se a estrutura i.i.d., que será utilizada posteriormente na definição usual de amostras aleatórias. Esperança e variância condicionais também permitem decompor momentos por meio das leis da esperança total e da variância total.

O quinto componente corresponde à **função geradora de momentos e às transformações de variáveis aleatórias**. Quando existe em uma vizinhança de zero, a função geradora de momentos permite obter momentos, identificar distribuições e estudar somas de variáveis independentes. As transformações permitem determinar a distribuição de novas variáveis construídas a partir de variáveis com distribuição conhecida.

O sexto reúne os **modelos probabilísticos** apresentados no capítulo. As distribuições uniforme discreta, Bernoulli, binomial, hipergeométrica, geométrica, binomial negativa, Poisson, uniforme contínua, exponencial, gama, normal, beta e multinomial representam diferentes mecanismos probabilísticos. Sua utilização depende do tipo de variável, de seu suporte, do mecanismo que produz os dados e da interpretação de seus parâmetros.

As situações inferenciais apresentadas ao longo do capítulo mostram como parâmetros desses modelos podem representar quantidades de interesse em problemas posteriores. Por exemplo:

- em um modelo Bernoulli ou binomial, p pode representar uma proporção populacional;
- em um modelo hipergeométrico, M pode representar uma quantidade desconhecida de unidades com determinada característica em uma população finita;
- em um modelo Poisson, λ representa o número esperado de ocorrências na exposição considerada e, quando $\lambda = \rho t$, ρ representa a taxa média por unidade de exposição;
- em um modelo exponencial parametrizado pela taxa λ , $1/\lambda$ representa o valor esperado da variável, podendo corresponder, por exemplo, a um tempo médio; quando a parametrização utiliza diretamente a média, essa quantidade é representada por μ ;
- em um modelo normal, μ e σ^2 descrevem localização e variabilidade;
- em um modelo multinomial, $p_1, \dots, p_m$ descrevem as probabilidades associadas às diferentes categorias.

Até este ponto, a direção predominante foi partir de um modelo probabilístico e estudar suas consequências:

modelo probabilístico $\longrightarrow$ comportamento das variáveis aleatórias.

Na Inferência Estatística, a questão será diferente. Os dados serão observados, enquanto uma ou mais características do modelo que os produziu serão desconhecidas. A direção do problema passa, então, a ser

dados observados $\longrightarrow$ informação sobre quantidades desconhecidas do modelo.

Essa passagem exigirá conceitos como população, parâmetro, amostra, estatística, estimador, modelo estatístico e verossimilhança. Antes de introduzi-los formalmente, o próximo capítulo reúne as ferramentas matemáticas e assintóticas utilizadas nos desenvolvimentos posteriores. Em seguida, o capítulo **Fundamentos da Inferência Estatística** formulará propriamente o problema inferencial.

1.13 Exercícios de consolidação

Exercício 1

Considere eventos A e B tais que $P(A) = 0,4$, $P(B) = 0,5$ e $P(A \cap B) = 0,2$.

- Calcule $P(A | B)$ e $P(B | A)$.
- Verifique se A e B são independentes.
- Explique a diferença entre **eventos independentes** e **eventos mutuamente exclusivos**.
- Mostre que dois eventos mutuamente exclusivos com probabilidades positivas não podem ser independentes.

Exercício 2

Uma condição ocorre em 1% de determinada população. Um teste apresenta sensibilidade de 90% e especificidade de 95%.

Calcule a probabilidade de uma pessoa apresentar a condição dado que recebeu resultado positivo no teste.

Identifique, no cálculo, o papel da prevalência da condição, da sensibilidade e da especificidade.

Exercício 3

Para cada situação abaixo:

- defina a variável aleatória;
- indique seu suporte $\mathcal{X}$;
- proponha uma distribuição probabilística plausível entre as estudadas neste capítulo;
- identifique o significado dos parâmetros;
- indique a característica do mecanismo que sustenta a escolha do modelo.

Considere:

- a. presença ou ausência de determinada característica em uma unidade selecionada;
- b. número de unidades com essa característica entre 50 observações independentes;
- c. número de unidades com a característica em uma amostra retirada sem reposição de uma população finita;
- d. número de chamadas recebidas por uma central durante uma hora;
- e. número de tentativas necessárias até o primeiro sucesso;
- f. número de tentativas necessárias até o quinto sucesso;
- g. tempo de espera até a ocorrência de determinado evento, admitindo uma taxa constante;
- h. duração total de várias etapas positivas e independentes com a mesma taxa;
- i. medida contínua aproximadamente simétrica em torno de um valor de localização;
- j. proporção contínua que assume valores estritamente entre 0 e 1.

Em cada caso, a distribuição proposta deve ser entendida como um modelo plausível, cuja adequação dependeria do fenômeno observado.

i Exercício 4

Considere $X \sim \text{Uniforme}(0, \theta)$, com $\theta > 0$.

- a. Escreva o suporte de X utilizando a notação $\mathcal{X}_\theta$.
- b. Determine $E(X)$ e $\text{Var}(X)$.
- c. Explique como o suporte se modifica quando θ varia.
- d. Suponha que tenha sido observado um valor $x_0 > 0$. Quais valores de θ são incompatíveis com essa observação? Justifique.

O objetivo é reconhecer uma característica particular desse modelo: o suporte depende do parâmetro.

i Exercício 5

Considere duas formas de retirar 20 bolas de uma urna contendo 100 bolas, das quais 30 são vermelhas:

1. cada bola retirada é devolvida à urna antes da retirada seguinte;
2. as bolas são retiradas sem reposição.

Defina X como o número de bolas vermelhas observadas.

- a. Especifique a distribuição de X em cada mecanismo.
- b. Compare $E(X)$ nos dois casos.
- c. Compare $\text{Var}(X)$ nos dois casos.
- d. Explique a origem da diferença entre as variâncias.
- e. Relacione essa diferença à independência, ou não, das retiradas.

i Exercício 6

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

- a. Explique separadamente o significado de **independentes** e **identicamente distribuídas**.
- b. Explique por que a condição i.i.d. não significa que $X_1 = \dots = X_n$.
- c. Suponha que a distribuição comum seja absolutamente contínua, com densidade f_X . Escreva a densidade conjunta de $(X_1, \dots, X_n)$.
- d. Suponha ainda que $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$, para todo i , e defina

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Obtenha $E(\bar{X}_n)$ e $\text{Var}(\bar{X}_n)$.

- e. Explique por que a estrutura i.i.d. será particularmente útil quando forem estudadas amostras aleatórias.

i Exercício 7

Considere a função de massa de probabilidade conjunta:

X	$Y = 0$	$Y = 1$
0	0,10	0,20
1	0,30	0,40

- Identifique o suporte conjunto de (X, Y) e os suportes marginais de X e Y .
- Obtenha as funções de massa marginais de X e Y .
- Calcule $P(X = 1 \mid Y = 1)$.
- Verifique se X e Y são independentes.
- Calcule $E(X)$, $E(Y)$ e $E(XY)$.
- Determine $\text{Cov}(X, Y)$.

i Exercício 8

Considere uma variável Y que assume os valores 0 e 1, com $P(Y = 1) = p$. Suponha que

$$E(X \mid Y = 0) = \mu_0, \quad E(X \mid Y = 1) = \mu_1$$

e

$$\text{Var}(X \mid Y = 0) = \sigma_0^2, \quad \text{Var}(X \mid Y = 1) = \sigma_1^2.$$

- Utilize a lei da esperança total para obter $E(X)$.
- Utilize a lei da variância total para obter $\text{Var}(X)$.
- Mostre que

$$\text{Var}(X) = (1 - p)\sigma_0^2 + p\sigma_1^2 + p(1 - p)(\mu_1 - \mu_0)^2.$$

- Interprete as duas fontes de variabilidade presentes nessa decomposição.

i Exercício 9

Mostre que, se X e Y são independentes e possuem segundos momentos finitos, então $\text{Cov}(X, Y) = 0$.

A recíproca é verdadeira? Apresente um exemplo de duas variáveis aleatórias com covariância zero que não sejam independentes.

i Exercício 10

Considere

$$(X_1, X_2, X_3) \sim \text{Multinomial}(20; 0,2, 0,3, 0,5).$$

- Obtenha $E(X_1)$, $E(X_2)$ e $E(X_3)$.
- Determine $\text{Var}(X_1)$, $\text{Var}(X_2)$ e $\text{Var}(X_3)$.
- Calcule $\text{Cov}(X_1, X_2)$.
- Determine a distribuição marginal de X_3 .
- Explique por que X_1 , X_2 e X_3 não são independentes.
- Relacione essa dependência à restrição $X_1 + X_2 + X_3 = 20$.

i Exercício 11

Efetue os seguintes cálculos utilizando as propriedades das distribuições estudadas no capítulo.

- Se $X \sim \text{Binom}(20, 0,3)$, obtenha $E(X)$, $\text{Var}(X)$ e $P(X \leq 4)$.
- Se $Y \sim \text{Poisson}(4)$, obtenha $P(Y = 0)$ e $P(Y > 5)$.
- Se $Z \sim N(100, 15^2)$, obtenha $P(85 < Z < 115)$ e o valor c tal que $P(Z \leq c) = 0,975$.

i Exercício 12

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

- Obtenha a função geradora de momentos de X_i .
- Utilize a função geradora de momentos para recuperar $E(X_i)$ e $\text{Var}(X_i)$.

- c. Defina $S_n = \sum_{i=1}^n X_i$. Utilize funções geradoras de momentos para identificar a distribuição de S_n .
- d. Mostre que $S_n/n = \bar{X}_n$ representa a proporção de sucessos.
- e. Obtenha $E(S_n/n)$ e $\text{Var}(S_n/n)$.

Esse resultado será retomado posteriormente no estudo da proporção amostral.

i Exercício 13

Utilize funções geradoras de momentos para estabelecer as seguintes relações.

- a. Se $X_1, \dots, X_k$ são independentes e $X_i \sim \text{Poisson}(\lambda_i)$, identifique a distribuição de

$$S = \sum_{i=1}^k X_i.$$

- b. Se

$$Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda),$$

identifique a distribuição de $T_n = \sum_{i=1}^n Y_i$.

- c. No item anterior, obtenha $E(T_n)$ e $\text{Var}(T_n)$.
- d. Compare os resultados dos itens (a) e (b): em ambos os casos estamos somando variáveis independentes, mas a família da distribuição resultante se comporta da mesma forma? Explique.
- e. Indique o papel da independência na propriedade multiplicativa das funções geradoras de momentos.

i Exercício 14

Considere $X \sim \text{Exp}(\lambda)$ e $Y = cX$, com $c > 0$.

- a. Determine o suporte $\mathcal{Y}$ de Y .
- b. Obtenha a função de distribuição de Y .
- c. Obtenha a densidade de Y pelo método da transformação.

d. Identifique a distribuição resultante e seu parâmetro.

i Exercício 15

Considere $X \sim N(0, 1)$ e defina $Y = X^2$.

- Determine o suporte $\mathcal{Y}$ de Y .
- Para $y > 0$, escreva o evento $\{Y \leq y\}$ em termos de X .
- Obtenha a função de distribuição de Y .
- Diferencie a expressão obtida para encontrar sua densidade.

A distribuição resultante será identificada posteriormente no estudo das distribuições amostrais associadas ao modelo normal.

i Exercício 16

Escolha uma situação aplicada de uma área de interesse e formule um modelo probabilístico para uma variável observável.

Em sua resposta:

- defina claramente a variável aleatória X ;
- indique seu suporte $\mathcal{X}$;
- proponha uma distribuição probabilística;
- descreva o mecanismo que justifica a escolha dessa distribuição;
- interprete os parâmetros do modelo no contexto do problema;
- indique qual parâmetro ou função dos parâmetros poderia constituir uma quantidade desconhecida de interesse;
- se várias observações da variável fossem obtidas, discuta se a hipótese de que sejam independentes e identicamente distribuídas seria plausível e justifique.

O objetivo é formular e interpretar a estrutura probabilística do problema. Os procedimentos utilizados para obter informação sobre as quantidades desconhecidas a partir dos dados serão desenvolvidos nos capítulos de Inferência Estatística.

2 Resultados Matemáticos e Assintóticos para Inferência

Este capítulo reúne ferramentas matemáticas e assintóticas que podem ser utilizadas nos desenvolvimentos posteriores de Inferência Estatística. O objetivo é estabelecer uma notação comum e registrar resultados de cálculo, álgebra linear e teoria assintótica importantes no estudo de distribuições amostrais, propriedades de estimadores, métodos de estimação, intervalos de confiança e testes de hipóteses (Rice, 2007, caps. 1–6; Ramachandran; Tsokos, 2021, caps. 2–4; Lauritzen, 2023, ap. A).

Os conceitos e modelos probabilísticos foram apresentados no capítulo anterior. Aqui, a atenção se concentra em duas classes de ferramentas. A primeira permite manipular funções, vetores, matrizes e transformações. A segunda permite estudar o comportamento de sequências de variáveis aleatórias quando o tamanho da amostra aumenta.

Delimitação do capítulo

Os resultados apresentados neste capítulo podem ser utilizados como ferramentas. O objetivo não é desenvolver novamente conteúdos de Cálculo ou Álgebra Linear nem apresentar demonstrações dos resultados assintóticos.

A Lei dos Grandes Números e o Teorema Central do Limite serão enunciados e interpretados aqui. Suas consequências para distribuições de estatísticas serão desenvolvidas no capítulo **Distribuições Amostrais**.

O método delta e sua versão multivariada também são estabelecidos neste capítulo como **Aprofundamento**. Esses resultados serão aplicados posteriormente nos desenvolvimentos inferenciais correspondentes.

2.1 Mapa de dependências

Ferramenta	Utilização posterior
Somatórios, produtos e logaritmos	verossimilhança, função escore e métodos de estimação

Ferramenta	Utilização posterior
Vetores e matrizes	parâmetros vetoriais, matrizes de covariâncias, informação de Fisher e modelos lineares
Diferenciação	otimização, função escore e informação observada
Expansões de Taylor	aproximações, método delta e resultados assintóticos
Formas quadráticas	distribuições associadas ao modelo normal, mínimos quadrados e estatísticas inferenciais
Projeções	mínimos quadrados e decomposição da variabilidade
Transformações multivariadas e jacobiano	obtenção de distribuições e reparametrizações
Modos de convergência	consistência e aproximações assintóticas
Lei dos Grandes Números	médias e momentos amostrais, consistência
Teorema Central do Limite	aproximações normais e normalidade assintótica
Mapeamento contínuo e Slutsky	transformação e combinação de sequências convergentes
Método delta	distribuições assintóticas de funções — Aprofundamento
Ordens estocásticas	representação da magnitude de erros e termos de aproximação

2.2 Ferramentas matemáticas

2.2.1 Somatórios, produtos e logaritmos

Para uma sequência $a_1, \dots, a_n$, utilizaremos

$$\sum_{i=1}^n a_i = a_1 + \dots + a_n$$

e

$$\prod_{i=1}^n a_i = a_1 \cdots a_n.$$

A linearidade dos somatórios permite escrever

$$\sum_{i=1}^n (ax_i + by_i) = a \sum_{i=1}^n x_i + b \sum_{i=1}^n y_i,$$

para constantes a e b .

A média aritmética de $x_1, \dots, x_n$ será representada por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Duas identidades serão utilizadas repetidamente:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

e

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - a)^2.$$

A transformação logarítmica converte produtos em somas:

$$\log \left(\prod_{i=1}^n a_i \right) = \sum_{i=1}^n \log a_i, \quad a_i > 0.$$

Também utilizaremos $\log(a^b) = b \log a$.

Essas identidades serão particularmente úteis quando uma função construída como produto puder ser estudada por meio de sua transformação logarítmica.

Considere

$$L(\theta) = \prod_{i=1}^n \theta e^{-\theta x_i}, \quad \theta > 0.$$

O produto pode ser escrito como

$$L(\theta) = \theta^n \exp \left(-\theta \sum_{i=1}^n x_i \right).$$

Aplicando o logaritmo,

$$\log L(\theta) = n \log \theta - \theta \sum_{i=1}^n x_i.$$

A transformação preserva a informação contida em $L(\theta)$ e produz uma expressão mais simples para diferenciação.

2.2.2 Vetores e matrizes

Um vetor coluna em $\mathbb{R}^k$ será representado por

$$\mathbf{x} = (x_1, \dots, x_k)^\top.$$

Seu transposto é $\mathbf{x}^\top = (x_1, \dots, x_k)$.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^k$, o produto interno é

$$\mathbf{x}^\top \mathbf{y} = \sum_{j=1}^k x_j y_j,$$

e a norma euclidiana é

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}}.$$

2.2.2.1 Matrizes

Uma matriz com m linhas e k colunas será representada por $\mathbf{A} = [a_{ij}] \in \mathbb{R}^{m \times k}$.

Sua transposta $\mathbf{A}^\top$ possui dimensão $k \times m$ e satisfaz

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

A matriz identidade de ordem k será representada por $\mathbf{I}_k$, ou simplesmente $\mathbf{I}$ quando sua dimensão estiver clara.

Uma matriz quadrada $\mathbf{A}$ é **simétrica** quando $\mathbf{A}^\top = \mathbf{A}$.

O **determinante**, representado por $\det(\mathbf{A})$, é um escalar associado a uma matriz quadrada. Uma matriz é invertível se, e somente se,

$$\det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível, existe $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}.$$

Além disso,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

O **posto** de uma matriz corresponde ao número máximo de colunas, ou equivalentemente de linhas, linearmente independentes.

Se $\mathbf{X} \in \mathbb{R}^{n \times p}$ possui posto p , suas colunas são linearmente independentes. Quando $n \geq p$, a matriz $\mathbf{X}^T \mathbf{X}$ é então invertível.

Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}.$$

A matriz é simétrica e

$$\det(\mathbf{A}) = 2(3) - 1(1) = 5.$$

Como o determinante é diferente de zero, $\mathbf{A}$ é invertível. Sua inversa é

$$\mathbf{A}^{-1} = \frac{1}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix}.$$

2.2.3 Diferenciação

Diversos procedimentos posteriores envolverão a maximização ou minimização de funções.

Para uma função real diferenciável g , todo ponto interior x_0 em que g apresente um extremo local satisfaz

$$g'(x_0) = 0.$$

Se, além disso, a segunda derivada existe em x_0 , então:

- se $g''(x_0) < 0$, o ponto corresponde a um máximo local;
- se $g''(x_0) > 0$, o ponto corresponde a um mínimo local;
- se $g''(x_0) = 0$, o teste da segunda derivada é inconclusivo.

2.2.3.1 Gradiente e hessiana

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

as derivadas de primeira ordem são reunidas no **gradiente**,

$$\nabla g(\theta) = \begin{pmatrix} \frac{\partial g}{\partial \theta_1} \\ \vdots \\ \frac{\partial g}{\partial \theta_k} \end{pmatrix}.$$

As derivadas de segunda ordem formam a **matriz hessiana**,

$$\nabla^2 g(\theta) = \left[\frac{\partial^2 g}{\partial \theta_i \partial \theta_j} \right]_{i,j=1}^k.$$

2.2.3.2 Matriz jacobiana

Para uma função vetorial

$$g : \mathbb{R}^k \longrightarrow \mathbb{R}^m,$$

com componentes $g_1, \dots, g_m$, a **matriz jacobiana** é

$$Dg(\mathbf{x}) = \left[\frac{\partial g_i(\mathbf{x})}{\partial x_j} \right]_{\substack{i=1,\dots,m \\ j=1,\dots,k}}.$$

Quando $m = 1$, a matriz jacobiana corresponde ao transposto do gradiente, de acordo com a convenção adotada.

O gradiente, a hessiana e a jacobiana aparecerão em contextos diferentes ao longo do livro:

- o gradiente será utilizado na diferenciação de funções escalares;
- a hessiana será utilizada em aproximações de segunda ordem;
- a jacobiana será utilizada em transformações vetoriais e no método delta multivariado.

Considere

$$g(\theta_1, \theta_2) = \theta_1^2 + \theta_1\theta_2 + 2\theta_2^2.$$

O gradiente é

$$\nabla g(\theta_1, \theta_2) = \begin{pmatrix} 2\theta_1 + \theta_2 \\ \theta_1 + 4\theta_2 \end{pmatrix},$$

e a hessiana é

$$\nabla^2 g(\theta_1, \theta_2) = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}.$$

2.2.4 Fórmula de Taylor

A fórmula de Taylor permite aproximar uma função em torno de um ponto conhecido. Essa ferramenta será utilizada posteriormente para estudar funções de estatísticas e para construir aproximações locais.

Se g é diferenciável em uma vizinhança de a , a aproximação de primeira ordem é

$$g(x) = g(a) + g'(a)(x - a) + o(|x - a|), \quad x \rightarrow a.$$

A notação $r(x) = o(|x - a|)$ significa que

$$\frac{r(x)}{|x - a|} \rightarrow 0$$

quando $x \rightarrow a$.

Quando g possui duas derivadas contínuas, a aproximação de segunda ordem pode ser escrita como

$$g(x) = g(a) + g'(a)(x - a) + \frac{1}{2}g''(a)(x - a)^2 + o\{(x - a)^2\}.$$

Considere $g(x) = \log x$. Em torno de $a = 1$, temos $g(1) = 0$ e $g'(1) = 1$.

Assim,

$$\log x = (x - 1) + o(|x - 1|), \quad x \rightarrow 1.$$

Para valores próximos de 1, podemos utilizar

$$\log x \approx x - 1.$$

Por exemplo, para $x = 1,05$, a aproximação fornece 0,05, enquanto $\log(1,05) \approx 0,0488$.

A aproximação linear pode ser comparada graficamente com a função original.

A Figura ?? mostra que a aproximação linear coincide com a função no ponto $x = 1$ e acompanha seu comportamento em uma vizinhança desse ponto. À medida que x se afasta de 1, a diferença entre a função e sua aproximação aumenta.

Esse caráter **local** da aproximação será utilizado nos resultados assintóticos: quando uma sequência de quantidades aleatórias se aproxima de determinado valor, uma função dessas quantidades pode ser aproximada por sua expansão de Taylor em torno do valor limite.

Aproximação de Taylor de primeira ordem




Figura 2.1: Função logarítmica e sua aproximação de Taylor de primeira ordem em torno de $a = 1$.

2.2.4.1 Taylor em várias dimensões

Se $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ é diferenciável em ξ , então

$$g(\mathbf{x}) = g(\xi) + Dg(\xi)(\mathbf{x} - \xi) + o(\|\mathbf{x} - \xi\|), \quad \mathbf{x} \rightarrow \xi.$$

Quando $g : \mathbb{R}^k \rightarrow \mathbb{R}$, a aproximação de primeira ordem pode ser escrita como

$$g(\mathbf{x}) = g(\xi) + \nabla g(\xi)^\top (\mathbf{x} - \xi) + o(\|\mathbf{x} - \xi\|), \quad \mathbf{x} \rightarrow \xi.$$

Se g possui derivadas de segunda ordem contínuas em uma vizinhança de ξ , a aproximação de segunda ordem utiliza a hessiana:

$$g(\mathbf{x}) \approx g(\xi) + \nabla g(\xi)^\top (\mathbf{x} - \xi) + \frac{1}{2}(\mathbf{x} - \xi)^\top \nabla^2 g(\xi)(\mathbf{x} - \xi).$$

2.2.5 Formas quadráticas

Para uma matriz simétrica $\mathbf{A} \in \mathbb{R}^{k \times k}$ e um vetor $\mathbf{x} \in \mathbb{R}^k$, a expressão

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

é denominada **forma quadrática**.

A matriz $\mathbf{A}$ é **positiva semidefinida** quando $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$ para todo $\mathbf{x}$.

Ela é **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Analogamente, $\mathbf{A}$ é **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Uma matriz simétrica é **indefinida** quando sua forma quadrática assume valores positivos para alguns vetores não nulos e valores negativos para outros.

Matrizes de covariâncias são positivas semidefinidas. Formas quadráticas também serão utilizadas na representação de somas de quadrados e em resultados associados ao modelo normal.

Quando $\mathbf{A} = \mathbf{I}$,

$$\mathbf{x}^T \mathbf{x} = \sum_{j=1}^k x_j^2.$$

Assim, para $\mathbf{x} = (2, -1, 3)^T$,

$$\mathbf{x}^T \mathbf{x} = 2^2 + (-1)^2 + 3^2 = 14.$$

2.2.5.1 Critério de segunda ordem

Considere uma função $g : \mathbb{R}^k \rightarrow \mathbb{R}$ com derivadas de segunda ordem contínuas em uma vizinhança de θ_0 e suponha que

$$\nabla g(\theta_0) = \mathbf{0}.$$

A matriz hessiana permite classificar o comportamento local da função:

- se $\nabla^2 g(\theta_0)$ é positiva definida, θ_0 é um mínimo local;
- se $\nabla^2 g(\theta_0)$ é negativa definida, θ_0 é um máximo local;
- se $\nabla^2 g(\theta_0)$ é indefinida, θ_0 é um ponto de sela;
- se $\nabla^2 g(\theta_0)$ é apenas positiva ou negativa semidefinida, sem ser definida, o critério de segunda ordem pode ser inconclusivo.

Esse critério será utilizado posteriormente na análise de funções que precisam ser maximizadas ou minimizadas.

2.2.6 Projeções

Uma matriz $\mathbf{P}$ é uma matriz de **projeção ortogonal** quando

$$\mathbf{P}^T = \mathbf{P} \quad \text{e} \quad \mathbf{P}^2 = \mathbf{P}.$$

Considere $\mathbf{X} \in \mathbb{R}^{n \times p}$ com posto completo nas colunas. A matriz

$$\mathbf{P}_{\mathbf{X}} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

projeta vetores de $\mathbb{R}^n$ sobre o espaço coluna de $\mathbf{X}$.

Para $\mathbf{y} \in \mathbb{R}^n$, definimos

$$\hat{\mathbf{y}} = \mathbf{P}_{\mathbf{X}}\mathbf{y}$$

e

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

O vetor $\hat{\mathbf{y}}$ pertence ao espaço coluna de $\mathbf{X}$, enquanto $\mathbf{e}$ é ortogonal a esse espaço. Em particular,

$$\mathbf{X}^T \mathbf{e} = \mathbf{0}.$$

Essa decomposição será utilizada posteriormente no método de mínimos quadrados (Lauritzen, 2023, ap. A.1; Rice, 2007, secs. 14.3–14.4).

Considere

$$\mathbf{y} = \begin{pmatrix} 1 \\ 2 \\ 6 \end{pmatrix}$$

e

$$\mathbf{X} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Nesse caso,

$$\mathbf{P}_{\mathbf{X}} = \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}.$$

A projeção é

$$\hat{\mathbf{y}} = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix},$$

pois 3 é a média dos elementos de $\mathbf{y}$.

O vetor residual é

$$\mathbf{e} = \begin{pmatrix} -2 \\ -1 \\ 3 \end{pmatrix},$$

e seus elementos somam zero. Essa é a forma mais simples da decomposição que aparecerá posteriormente em mínimos quadrados.

A interpretação geométrica da projeção pode ser visualizada na Figura ??.




Figura 2.2: Representação geométrica de uma projeção ortogonal: o vetor $\mathbf{y}$ é decomposto em sua projeção sobre um subespaço e em um resíduo ortogonal.

A Figura ?? representa geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

O vetor $\hat{\mathbf{y}}$ pertence ao espaço sobre o qual $\mathbf{y}$ é projetado, enquanto o resíduo $\mathbf{e}$ é ortogonal a esse espaço.

2.2.7 Transformações multivariadas e jacobiano

O capítulo anterior apresentou transformações de uma variável aleatória. Para vetores aleatórios, a mudança de variáveis requer considerar simultaneamente a transformação e a alteração de volume que ela produz.

Considere um vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_k)^\top$$

com suporte $\mathcal{X} \subseteq \mathbb{R}^k$ e densidade conjunta $f_{\mathbf{X}}$.

Seja

$$\mathbf{Y} = g(\mathbf{X}),$$

em que $g : \mathcal{X} \rightarrow \mathcal{Y}$ é uma transformação bijetiva e diferenciável no domínio considerado, com inversa diferenciável

$$\mathbf{X} = h(\mathbf{Y}).$$

Admitiremos que o determinante jacobiano da transformação inversa seja diferente de zero nos pontos considerados.

O suporte transformado é

$$\mathcal{Y} = g(\mathcal{X}).$$

A densidade conjunta de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\{h(\mathbf{y})\} |\det Dh(\mathbf{y})|, \quad \mathbf{y} \in \mathcal{Y}.$$

O fator

$$|\det Dh(\mathbf{y})|$$

é o valor absoluto do **determinante jacobiano da transformação inversa**. Ele ajusta a densidade à alteração de escala ou volume produzida pela transformação.

2.2.7.1 Transformação linear

Considere a transformação

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que $\mathbf{A} \in \mathbb{R}^{k \times k}$ é invertível e $\mathbf{b} \in \mathbb{R}^k$.

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

Nesse caso,

$$Dh(\mathbf{y}) = \mathbf{A}^{-1},$$

e, portanto,

$$|\det Dh(\mathbf{y})| = \frac{1}{|\det(\mathbf{A})|}.$$

Consequentemente,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}\{\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})\} \frac{1}{|\det(\mathbf{A})|}, \quad \mathbf{y} \in \mathcal{Y}.$$

A transformação linear é um caso particularmente simples de mudança multivariada, pois sua matriz jacobiana não depende de $\mathbf{y}$.

i Duas utilizações da matriz jacobiana

A matriz jacobiana aparecerá novamente no método delta multivariado.

Na mudança de variáveis, utiliza-se o **determinante da jacobiana da transformação inversa** para ajustar uma densidade.

No método delta, utiliza-se a **própria matriz jacobiana da transformação** para aproximar localmente uma função vetorial.

Considere X_1 e X_2 independentes, ambas com distribuição exponencial de taxa λ . Defina

$$Y_1 = X_1 + X_2, \quad Y_2 = X_2.$$

A transformação inversa é

$$X_1 = Y_1 - Y_2, \quad X_2 = Y_2.$$

Sua matriz jacobiana é

$$Dh(\mathbf{y}) = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix},$$

de modo que $|\det Dh(\mathbf{y})| = 1$.

Como $X_1 > 0$ e $X_2 > 0$, o suporte transformado é

$$\mathcal{Y} = \{(y_1, y_2) : 0 < y_2 < y_1\}.$$

A densidade conjunta transformada é

$$f_{Y_1, Y_2}(y_1, y_2) = \lambda^2 e^{-\lambda y_1}, \quad 0 < y_2 < y_1.$$

Integrando em relação a y_2 ,

$$f_{Y_1}(y_1) = \lambda^2 y_1 e^{-\lambda y_1}, \quad y_1 > 0.$$

Portanto, a soma de duas variáveis exponenciais independentes com a mesma taxa possui distribuição gama com forma 2 e escala $1/\lambda$,

$$Y_1 \sim \text{Gama}\left(2, \frac{1}{\lambda}\right),$$

em concordância com a parametrização forma-escala adotada no capítulo anterior.

2.3 Ferramentas assintóticas

Resultados exatos descrevem uma variável ou estatística para um tamanho amostral específico. Resultados assintóticos descrevem seu comportamento quando o tamanho da amostra cresce.

A teoria assintótica será utilizada quando uma distribuição exata for difícil de obter ou quando for necessário estudar propriedades que emergem à medida que n aumenta.

O ponto de partida é definir diferentes formas de convergência de sequências de variáveis aleatórias.

2.3.1 Modos de convergência

Considere uma sequência $X_1, X_2, \dots$ de variáveis aleatórias e uma variável aleatória X .

2.3.1.1 Convergência quase certa

Dizemos que X_n **converge quase certamente** para X , e escrevemos

$$X_n \xrightarrow{\text{q.c.}} X,$$

quando

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

2.3.1.2 Convergência em média quadrática

Dizemos que X_n **converge em média quadrática** para X , e escrevemos

$$X_n \xrightarrow{L^2} X,$$

quando

$$E[(X_n - X)^2] \rightarrow 0.$$

2.3.1.3 Convergência em probabilidade

Dizemos que X_n **converge em probabilidade** para X , e escrevemos

$$X_n \xrightarrow{P} X,$$

quando, para todo $\varepsilon > 0$,

$$P(|X_n - X| > \varepsilon) \rightarrow 0.$$

2.3.1.4 Convergência em distribuição

Dizemos que X_n **converge em distribuição** para X , e escrevemos

$$X_n \xrightarrow{d} X,$$

quando

$$F_{X_n}(x) \rightarrow F_X(x)$$

em todo ponto de continuidade de F_X .

A notação de convergência em distribuição também será utilizada para vetores aleatórios, especialmente no método delta multivariado.

2.3.2 Relações entre os modos de convergência

As principais implicações utilizadas neste livro são

$$X_n \xrightarrow{\text{q.c.}} X \implies X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X$$

e

$$X_n \xrightarrow{L^2} X \implies X_n \xrightarrow{P} X.$$

Em geral, não existe implicação entre convergência quase certa e convergência em média quadrática.

As implicações anteriores também não podem, em geral, ser invertidas. Uma exceção particularmente útil ocorre quando o limite é uma constante c :

$$X_n \xrightarrow{d} c \implies X_n \xrightarrow{P} c.$$

(Lauritzen, 2023, ap. A.2; Rice, 2007, cap. 5)

Se Z possui segundo momento finito e definimos $X_n = Z/n$, então

$$E(X_n^2) = \frac{E(Z^2)}{n^2} \rightarrow 0.$$

Logo,

$$X_n \xrightarrow{L^2} 0.$$

Consequentemente, também temos $X_n \xrightarrow{P} 0$ e $X_n \xrightarrow{d} 0$.

Considere

$$X_n \sim N\left(0, 1 + \frac{1}{n}\right).$$

À medida que n aumenta, sua distribuição se aproxima de $N(0, 1)$. Assim,

$$X_n \xrightarrow{d} N(0, 1).$$

Como o limite não é uma constante, a convergência em distribuição, isoladamente, não permite concluir convergência em probabilidade.

2.3.3 Lei Fraca dos Grandes Números

Considere uma sequência $X_1, X_2, \dots$ de variáveis aleatórias independentes e identicamente distribuídas, com $E|X_1| < \infty$.

Defina

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

A Lei Fraca dos Grandes Números estabelece

$$\overline{X}_n \xrightarrow{P} E(X_1).$$

Se $E(X_1) = \mu$, escrevemos

$$\overline{X}_n \xrightarrow{P} \mu.$$

O resultado descreve a estabilização da média amostral em torno da média da distribuição quando o tamanho da amostra aumenta (Rice, 2007, sec. 5.2; Ramachandran; Tsokos, 2021, sec. 3.5).

! Interpretação

A Lei dos Grandes Números responde a uma questão de **convergência**:

a média calculada a partir de muitas observações tende a se aproximar da média da distribuição?

O resultado não fornece, por si só, a forma da distribuição de $\overline{X}_n$ para um valor específico de n .

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Como $E(X_i) = p$,

$$\overline{X}_n \xrightarrow{P} p.$$

Como

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

é a proporção de sucessos observada, a Lei dos Grandes Números estabelece que essa proporção tende a se aproximar de p quando n aumenta.

Estabilização da média amostral

Trajectoria — 1 - - 2 ··· 3 · - 4 — 5




Figura 2.3: Trajetórias de médias acumuladas de amostras exponenciais com média 1.

2.3.3.1 Visualização da estabilização

A estabilização da média pode ser observada por meio de diferentes sequências de observações provenientes da mesma distribuição.

A Figura ?? apresenta diferentes trajetórias de médias acumuladas de observações exponenciais com $E(X) = 1$. Para valores pequenos de n , as médias apresentam maior variabilidade entre as trajetórias. À medida que n aumenta, tendem a permanecer mais próximas de $\mu = 1$.

A figura ilustra a **estabilização** descrita pela Lei Fraca dos Grandes Números. Ela não informa, porém, a forma da distribuição das flutuações em torno de μ .

2.3.4 Teorema Central do Limite

Considere $X_1, X_2, \dots$ independentes e identicamente distribuídas, com $E(X_1) = \mu$ e

$$0 < \text{Var}(X_1) = \sigma^2 < \infty.$$

O Teorema Central do Limite estabelece

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Equivalentemente,

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

O resultado descreve a distribuição limite das flutuações padronizadas da média ou da soma em torno de seus respectivos valores esperados (Rice, 2007, sec. 5.3; Ramachandran; Tsokos, 2021, sec. 3.5; Chihara; Hesterberg, 2022, sec. 4.3).

2.3.4.1 Centralização e mudança de escala

A quantidade $\bar{X}_n - \mu$ representa o desvio da média amostral em relação à média da distribuição.

Como

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n},$$

o desvio-padrão de $\bar{X}_n$ é $\sigma/\sqrt{n}$. Portanto,

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}.$$

A padronização utilizada no Teorema Central do Limite envolve, assim, duas operações: a **centralização**, obtida subtraindo μ , e a **mudança de escala**, obtida dividindo pelo desvio-padrão da média amostral.

O fator $\sqrt{n}$ surge porque a variância de $\bar{X}_n$ diminui à taxa $1/n$, enquanto seu desvio-padrão diminui à taxa $1/\sqrt{n}$.

Para valores suficientemente grandes de n , o resultado sugere a aproximação

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

A qualidade dessa aproximação depende da distribuição das observações e do tamanho da amostra.

! O que o Teorema Central do Limite estabelece

O Teorema Central do Limite não afirma que as observações individuais se tornam normais à medida que n aumenta.

A convergência refere-se à distribuição da **média ou soma padronizada**. Distribuições muito assimétricas ou com caudas pesadas podem exigir amostras maiores para que a aproximação normal seja satisfatória.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda).$$

Como

$$E(X_i) = \frac{1}{\lambda} \quad \text{e} \quad \text{Var}(X_i) = \frac{1}{\lambda^2},$$

o Teorema Central do Limite fornece

$$\lambda\sqrt{n}\left(\bar{X}_n - \frac{1}{\lambda}\right) \xrightarrow{d} N(0, 1).$$

Consequentemente, para amostras suficientemente grandes,

$$\bar{X}_n \approx N\left(\frac{1}{\lambda}, \frac{1}{n\lambda^2}\right).$$

2.3.4.2 Visualização da convergência

A aproximação produzida pelo Teorema Central do Limite pode ser visualizada partindo de uma distribuição que não é normal.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(1).$$

Nesse caso, $E(X_i) = 1$ e $\text{Var}(X_i) = 1$. Além disso,

$$S_n = \sum_{i=1}^n X_i \sim \text{Gama}(n, 1).$$

A média padronizada pode ser escrita como

$$Z_n = \sqrt{n}(\bar{X}_n - 1) = \frac{S_n - n}{\sqrt{n}}.$$

O Teorema Central do Limite estabelece $Z_n \xrightarrow{d} N(0, 1)$.

A Figura ?? parte de observações exponenciais, cuja distribuição é assimétrica. À medida que n aumenta, a densidade da média padronizada Z_n se aproxima da densidade da distribuição $N(0, 1)$.

A figura destaca que o objeto que se aproxima da distribuição normal é a **média padronizada**, e não a distribuição das observações individuais.

2.3.5 Lei dos Grandes Números e Teorema Central do Limite

Os dois resultados descrevem aspectos diferentes do comportamento da média amostral.

Resultado	Questão
Lei dos Grandes Números	$\bar{X}_n$ se aproxima de μ ?
Teorema Central do Limite	como as flutuações de $\bar{X}_n$ em torno de μ se distribuem após padronização?




Figura 2.4: Densidade da média exponencial padronizada para diferentes tamanhos de amostra e densidade da distribuição normal padrão.

A Lei dos Grandes Números estabelece

$$\overline{X}_n \xrightarrow{P} \mu,$$

enquanto o Teorema Central do Limite estabelece

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Assim, a Lei dos Grandes Números descreve **estabilização**, enquanto o Teorema Central do Limite descreve **flutuação em torno do limite**.

2.3.6 Teorema do mapeamento contínuo

O teorema do mapeamento contínuo permite transportar um resultado de convergência através de uma função contínua.

Se

$$X_n \xrightarrow{P} X$$

e g é contínua em todos os pontos de um conjunto C tal que

$$P(X \in C) = 1,$$

então

$$g(X_n) \xrightarrow{P} g(X).$$

De forma análoga, se

$$X_n \xrightarrow{d} X$$

e g é contínua em todos os pontos de um conjunto C tal que

$$P(X \in C) = 1,$$

então

$$g(X_n) \xrightarrow{d} g(X).$$

(Lauritzen, 2023, teorema A.11)

Suponha que $T_n \xrightarrow{P} \theta$, com $\theta > 0$.

Como as funções $g_1(x) = \sqrt{x}$, $g_2(x) = \log x$ e $g_3(x) = 1/x$ são contínuas em θ , temos

$$\sqrt{T_n} \xrightarrow{P} \sqrt{\theta},$$

$$\log T_n \xrightarrow{P} \log \theta$$

e

$$\frac{1}{T_n} \xrightarrow{P} \frac{1}{\theta}.$$

Como $\theta > 0$, a convergência implica também $P(T_n > 0) \rightarrow 1$, de modo que as transformações ficam bem definidas com probabilidade tendendo a um.

2.3.7 Lema de Slutsky

Se

$$X_n \xrightarrow{d} X \quad \text{e} \quad Y_n \xrightarrow{P} c,$$

em que c é uma constante, então

$$X_n + Y_n \xrightarrow{d} X + c,$$

$$X_n Y_n \xrightarrow{d} cX$$

e, se $c \neq 0$,

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}.$$

O lema permite combinar uma sequência com distribuição limite não degenerada com outra que converge em probabilidade para uma constante (Lauritzen, 2023, corolário A.12).

Suponha que

$$\frac{\sqrt{n}(T_n - \theta)}{\sigma} \xrightarrow{d} N(0, 1)$$

e que $S_n \xrightarrow{P} \sigma$, com $\sigma > 0$.

Então

$$\frac{\sqrt{n}(T_n - \theta)}{S_n} = \frac{\sqrt{n}(T_n - \theta)}{\sigma} \frac{\sigma}{S_n}.$$

Como $\sigma/S_n \xrightarrow{P} 1$, o lema de Slutsky fornece

$$\frac{\sqrt{n}(T_n - \theta)}{S_n} \xrightarrow{d} N(0, 1).$$

Esse mecanismo será utilizado posteriormente quando uma quantidade desconhecida presente em uma padronização for substituída por uma aproximação consistente.

2.3.8 Aprofundamento

As subseções seguintes apresentam o método delta em suas versões univariada e multivariada. Esse bloco utiliza conjuntamente expansão de Taylor, convergência em distribuição e o lema de Slutsky.

2.3.8.1 Método delta

O método delta permite obter a distribuição assintótica de uma transformação a partir da distribuição assintótica da quantidade original (Casella; Berger, 2011, sec. 5.5.4).

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \tau^2)$$

e que g seja diferenciável em θ , com

$$g'(\theta) \neq 0.$$

Então,

$$\sqrt{n}\{g(T_n) - g(\theta)\} \xrightarrow{d} N(0, [g'(\theta)]^2 \tau^2).$$

Essa é a forma usual do método delta de primeira ordem (Casella; Berger, 2011, sec. 5.5.4).

Quando $g'(\theta) = 0$, essa forma não fornece uma distribuição limite não degenerada. Nesse caso, uma expansão de Taylor de ordem superior e uma escala diferente podem ser necessárias (Chihara; Hesterberg, 2022, sec. 7.7).

i Relação com Taylor

O método delta utiliza localmente a aproximação

$$g(T_n) \approx g(\theta) + g'(\theta)(T_n - \theta).$$

Assim, uma transformação suave herda, em primeira ordem, a distribuição assintótica de T_n , ajustada pela derivada $g'(\theta)$.

Suponha que

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2), \quad \mu > 0.$$

Considere $g(x) = \log x$. Como $g'(\mu) = 1/\mu$, o método delta fornece

$$\sqrt{n}\{\log(\bar{X}_n) - \log(\mu)\} \xrightarrow{d} N\left(0, \frac{\sigma^2}{\mu^2}\right).$$

Esse resultado mostra como uma distribuição assintótica conhecida pode ser transportada para uma escala transformada.

Visualização do método delta

A aproximação fornecida pelo método delta pode ser observada no mesmo modelo exponencial utilizado para ilustrar o Teorema Central do Limite.

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(1).$$

Como $E(X_i) = 1$ e $\text{Var}(X_i) = 1$, o Teorema Central do Limite fornece

$$\sqrt{n}(\bar{X}_n - 1) \xrightarrow{d} N(0, 1).$$

Para $g(x) = \log x$, temos $g(1) = 0$ e $g'(1) = 1$. Portanto, pelo método delta,

$$\sqrt{n} \log \bar{X}_n \xrightarrow{d} N(0, 1).$$

A Figura ?? mostra que, para amostras pequenas, a distribuição de $\sqrt{n} \log \bar{X}_n$ ainda apresenta diferenças em relação à normal padrão. À medida que n aumenta, a distribuição simulada se aproxima de $N(0, 1)$, como previsto pelo método delta.

O resultado é assintótico. A qualidade da aproximação para um tamanho de amostra específico depende do modelo, da transformação e do valor de n .

2.3.8.2 Método delta multivariado

Considere um vetor $\mathbf{T}_n \in \mathbb{R}^k$ tal que

$$\sqrt{n}(\mathbf{T}_n - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Sigma).$$

Se $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ é diferenciável em θ , então

$$\sqrt{n}\{g(\mathbf{T}_n) - g(\theta)\} \xrightarrow{d} N_m[\mathbf{0}, Dg(\theta)\Sigma Dg(\theta)^\top].$$

A matriz jacobiana transforma a matriz de covariâncias assintótica da mesma forma que uma transformação linear atua sobre uma matriz de covariâncias.

Considere

$$g(\theta_1, \theta_2) = \frac{\theta_1}{\theta_2}, \quad \theta_2 \neq 0.$$

O gradiente é

$$\nabla g(\theta) = \begin{pmatrix} \frac{1}{\theta_2} \\ \frac{\theta_1}{\theta_2^2} \end{pmatrix}.$$

Se




Figura 2.5: Distribuição simulada da transformação da média amostral e densidade normal padrão prevista pelo método delta.

$$\sqrt{n}(\mathbf{T}_n - \theta) \xrightarrow{d} N_2(\mathbf{0}, \Sigma),$$

então

$$\sqrt{n} \left\{ \frac{T_{1n}}{T_{2n}} - \frac{\theta_1}{\theta_2} \right\} \xrightarrow{d} N(0, V),$$

em que

$$V = \nabla g(\theta)^\top \Sigma \nabla g(\theta).$$

2.3.9 Ordens estocásticas

As ordens estocásticas fornecem uma notação compacta para descrever a magnitude de sequências aleatórias.

Seja $a_n > 0$ uma sequência determinística.

Escrevemos

$$X_n = o_P(a_n)$$

quando

$$\frac{X_n}{a_n} \xrightarrow{P} 0.$$

Nesse caso, X_n é assintoticamente desprezível em relação a a_n .

Escrevemos

$$X_n = O_P(a_n)$$

quando X_n/a_n é **limitado em probabilidade**. Isso significa que, para todo $\varepsilon > 0$, existe $M > 0$ tal que, para valores suficientemente grandes de n ,

$$P \left(\left| \frac{X_n}{a_n} \right| > M \right) < \varepsilon.$$

As duas notações não possuem o mesmo significado. A relação

$$X_n = o_P(a_n)$$

é mais forte que

$$X_n = O_P(a_n).$$

Algumas consequências e regras que serão utilizadas posteriormente são:

- se $X_n \xrightarrow{P} 0$, então $X_n = o_P(1)$;
- se $X_n \xrightarrow{d} X$, então $X_n = O_P(1)$;
- se $X_n = O_P(a_n)$ e $Y_n = O_P(b_n)$, então $X_n Y_n = O_P(a_n b_n)$;
- se $X_n = o_P(a_n)$ e $Y_n = O_P(b_n)$, então $X_n Y_n = o_P(a_n b_n)$;
- se $X_n = O_P(a_n)$ e $Y_n = O_P(a_n)$, então $X_n + Y_n = O_P(a_n)$;
- se $X_n = o_P(a_n)$ e $Y_n = o_P(a_n)$, então $X_n + Y_n = o_P(a_n)$.

Essas regras permitem identificar quais parcelas possuem a mesma ordem e quais se tornam desprezíveis em expansões assintóticas.

Se

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2),$$

então

$$\sqrt{n}(\bar{X}_n - \mu) = O_P(1).$$

Consequentemente,

$$\bar{X}_n - \mu = O_P(n^{-1/2}).$$

A expressão indica que as flutuações da média em torno de μ possuem, sob as condições do Teorema Central do Limite, ordem $n^{-1/2}$.

2.4 Síntese

Os resultados deste capítulo podem ser organizados em dois componentes.

O primeiro reúne **ferramentas matemáticas**. Somatórios, produtos e logaritmos permitem reorganizar expressões; vetores e matrizes fornecem a linguagem necessária para parâmetros e estatísticas multidimensionais; diferenciação, gradientes, hessianas e expansões de Taylor permitem estudar localmente funções; formas quadráticas e projeções serão utilizadas principalmente em distribuições associadas ao modelo normal e em mínimos quadrados; e o jacobiano permite trabalhar com transformações multivariadas.

O segundo reúne **ferramentas assintóticas**. Os modos de convergência formalizam diferentes sentidos em que uma sequência aleatória pode aproximar um limite. A Lei dos Grandes Números descreve a estabilização de médias, enquanto o Teorema Central do Limite descreve suas flutuações padronizadas. O teorema do mapeamento contínuo e o lema de Slutsky permitem transformar e combinar sequências convergentes, e as ordens O_P e o_P registram de forma compacta a magnitude dos termos envolvidos.

No **Aprofundamento**, o método delta utiliza uma aproximação de Taylor para transportar distribuições assintóticas para funções de quantidades aleatórias. Sua versão multivariada realiza a mesma operação por meio da matriz jacobiana.

A estrutura assintótica do núcleo pode ser resumida por

Lei dos Grandes Números $\rightarrow$ convergência para uma constante

e

Teorema Central do Limite $\rightarrow$ distribuição das flutuações.

No aprofundamento, essas ferramentas se articulam segundo o esquema

distribuição assintótica + Taylor + Slutsky $\rightarrow$ método delta.

Os capítulos seguintes utilizarão essas ferramentas sem redefini-las. As interpretações e condições específicas serão retomadas no contexto de cada problema inferencial.

2.5 Exercícios de consolidação

2.5.1 Ferramentas matemáticas

Exercício 1

Considere os valores $x_1 = 2$, $x_2 = 4$, $x_3 = 5$ e $x_4 = 9$.

- Calcule $\bar{x}$.
- Calcule $\sum_{i=1}^4 (x_i - \bar{x})$.
- Para $a = 3$, calcule os dois lados da identidade

$$\sum_{i=1}^4 (x_i - a)^2 = \sum_{i=1}^4 (x_i - \bar{x})^2 + 4(\bar{x} - a)^2$$

e verifique numericamente que os valores coincidem.

- Explique por que essa decomposição pode ser útil quando uma soma de quadrados é estudada em torno de valores diferentes.

Exercício 2

Considere

$$\mathbf{A} = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} \quad \text{e} \quad \mathbf{x} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}.$$

- Verifique se $\mathbf{A}$ é simétrica.
- Calcule $\det(\mathbf{A})$.
- Determine se $\mathbf{A}$ é invertível e, em caso afirmativo, obtenha $\mathbf{A}^{-1}$.
- Calcule $\mathbf{Ax}$ e $\mathbf{x}^T \mathbf{Ax}$.

Exercício 3

Considere

$$g(\theta_1, \theta_2) = \theta_1^2 + 2\theta_2^2 - 2\theta_1 + 4\theta_2.$$

- Obtenha $\nabla g(\theta_1, \theta_2)$.

- b. Obtenha a matriz hessiana.
- c. Determine o ponto em que o gradiente é nulo.
- d. A partir da hessiana, classifique esse ponto como máximo ou mínimo local.

i Exercício 4

Utilize aproximações de Taylor de primeira ordem para:

- a. aproximar $\log(1,08)$ em torno de 1;
- b. aproximar $\sqrt{1,04}$ em torno de 1;
- c. comparar as aproximações com os valores calculados diretamente.

Em qual dos dois casos o erro absoluto foi maior?

i Exercício 5

Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

e $\mathbf{x} = (x_1, x_2)^\top$.

- a. Obtenha a expressão de $\mathbf{x}^\top \mathbf{A} \mathbf{x}$.
- b. Verifique que essa expressão pode ser escrita como

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = x_1^2 + x_2^2 + (x_1 + x_2)^2.$$

- c. A partir dessa expressão, classifique $\mathbf{A}$ quanto à definitude.
- d. Calcule a forma quadrática para $\mathbf{x} = (1, -1)^\top$ e para $\mathbf{x} = (1, 1)^\top$.

i Exercício 6

Considere

$$\mathbf{X} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

e

$$\mathbf{y} = \begin{pmatrix} 2 \\ 3 \\ 7 \\ 8 \end{pmatrix}.$$

- Obtenha $\mathbf{P}_{\mathbf{X}}$.
- Calcule $\hat{\mathbf{y}} = \mathbf{P}_{\mathbf{X}}\mathbf{y}$.
- Calcule $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$.
- Verifique numericamente que $\mathbf{X}^T \mathbf{e} = 0$.
- Relacione os elementos de $\hat{\mathbf{y}}$ com a média dos elementos de $\mathbf{y}$.

i Exercício 7

Considere X_1 e X_2 independentes e exponenciais com taxa λ . Defina

$$Y_1 = X_1, \quad Y_2 = X_1 + X_2.$$

- Obtenha a transformação inversa.
- Determine a matriz jacobiana da transformação inversa e seu determinante.
- Determine o suporte conjunto $\mathcal{Y}$ de (Y_1, Y_2) .
- Obtenha a densidade conjunta de (Y_1, Y_2) .
- Explique o papel do determinante jacobiano nesse cálculo.

2.5.2 Ferramentas assintóticas

i Exercício 8

Seja Z uma variável aleatória com $E(Z^2) < \infty$ e defina $X_n = Z/n$.

- Calcule $E(X_n^2)$.
- Identifique o limite de $E(X_n^2)$ quando $n \rightarrow \infty$.
- Qual modo de convergência pode ser concluído diretamente?
- Quais outros modos de convergência decorrem desse resultado?

Agora considere $Y_n \sim N(0, 1 + 1/n)$. Qual convergência em distribuição é esperada? É possível concluir, apenas dessa informação, que Y_n converge em probabilidade?

i Exercício 9

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(0,35)$$

e $R_n = \sum_{i=1}^n X_i$.

- Escreva R_n/n como uma média.
- Utilize a Lei Fraca dos Grandes Números para identificar o limite em probabilidade de R_n/n .
- Interprete o resultado no contexto de uma sequência de ensaios.
- O resultado afirma que R_n/n será exatamente igual a 0,35 para algum valor finito de n ? Explique.

i Exercício 10

Considere

$$X_1, \dots, X_{64} \stackrel{\text{iid}}{\sim} \text{Exp}(2).$$

- Determine $E(X_i)$ e $\text{Var}(X_i)$.
- Obtenha a aproximação normal fornecida pelo Teorema Central do Limite para $\bar{X}_{64}$.

c. Utilize essa aproximação para calcular aproximadamente

$$P(0,45 < \bar{X}_{64} < 0,55).$$

d. Explique por que a aproximação do item anterior não significa que cada X_i possui distribuição aproximadamente normal.

i Exercício 11

Considere uma sequência i.i.d. com média μ e variância finita e positiva. Compare as afirmações

$$\bar{X}_n \xrightarrow{P} \mu$$

e

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Em sua resposta, indique:

- qual resultado corresponde à Lei dos Grandes Números;
- qual corresponde ao Teorema Central do Limite;
- o que cada resultado informa sobre $\bar{X}_n$;
- por que um resultado não substitui o outro.

i Exercício 12

Suponha que $T_n \xrightarrow{P} \theta$, com $\theta > 0$.

Utilize o teorema do mapeamento contínuo para determinar os limites em probabilidade de:

- $\sqrt{T_n}$;
- $\log T_n$;
- T_n^2 ;
- $1/T_n$.

Explique por que a condição $\theta > 0$ garante que as transformações utilizadas nos itens (a), (b) e (d) estejam definidas e sejam contínuas em uma vizinhança de θ .

i Exercício 13

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, 4)$$

e que $S_n \xrightarrow{P} 2$.

Determine a distribuição limite de

$$\frac{\sqrt{n}(T_n - \theta)}{S_n}.$$

Indique explicitamente onde o lema de Slutsky é utilizado.

Aprofundamento

Os exercícios seguintes utilizam o método delta e integram o aprofundamento.

i Exercício 14

Suponha que

$$\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \tau^2), \quad \theta > 0.$$

Utilize o método delta para obter a distribuição limite de:

- a. $\sqrt{n}\{\log(T_n) - \log(\theta)\}$;
- b. $\sqrt{n}(1/T_n - 1/\theta)$.

Compare as variâncias assintóticas obtidas.

i Exercício 15

Considere

$$\sqrt{n} \left[\begin{pmatrix} T_{1n} \\ T_{2n} \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \right] \xrightarrow{d} N_2 \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 4 & 1 \\ 1 & 9 \end{pmatrix} \right],$$

com $\theta_2 \neq 0$.

Para

$$g(\theta_1, \theta_2) = \frac{\theta_1}{\theta_2},$$

- a. obtenha o gradiente de g ;
- b. utilize o método delta multivariado para escrever a variância limite de

$$\sqrt{n} \left(\frac{T_{1n}}{T_{2n}} - \frac{\theta_1}{\theta_2} \right);$$

- c. calcule essa variância para $\theta_1 = 2$ e $\theta_2 = 4$.

i Exercício 16

Considere amostras de uma distribuição exponencial com taxa 1.

Utilizando R, simule repetidamente amostras de tamanhos $n = 10, 50$ e 200 e investigue três resultados deste capítulo:

1. **Lei dos Grandes Números:** compare a distribuição das médias amostrais com o valor $E(X) = 1$;
2. **Teorema Central do Limite:** examine a distribuição de $\sqrt{n}(\bar{X}_n - 1)$ e compare-a com $N(0, 1)$;
3. **Método delta:** examine a distribuição de $\sqrt{n} \log(\bar{X}_n)$ e compare-a com a distribuição limite prevista pelo método delta.

Apresente gráficos adequados e escreva uma interpretação curta para cada resultado. O objetivo é comparar estabilização, aproximação normal e transformação assintótica, e não apenas reproduzir o código.

3 Fundamentos da Inferência Estatística

A inferência estatística utiliza informações obtidas em uma amostra para estudar características desconhecidas de uma população ou de um processo que produz dados. Como diferentes amostras podem gerar resultados diferentes, as conclusões obtidas a partir dos dados estão associadas à variabilidade e à incerteza.

O desenvolvimento parte do problema inferencial, do processo gerador de dados, da população, dos parâmetros e da amostragem. Um experimento com uma urna permite observar diretamente a variabilidade produzida por diferentes amostras e fornece a base para distinguir estatística, estimador e estimativa e para introduzir o modelo estatístico e a função de verossimilhança.

Ao final do capítulo, o experimento da urna é reproduzido e ampliado computacionalmente.

3.1 O problema da inferência estatística

Em muitas situações, deseja-se conhecer uma característica de uma população sem observar todos os seus elementos. Pode haver interesse, por exemplo, na proporção de eleitores favoráveis a determinado candidato, no peso médio de um produto fabricado por uma empresa ou no tempo médio de funcionamento de determinado equipamento.

Quando a observação de toda a população não é possível ou conveniente, utiliza-se uma amostra. Os dados obtidos nessa amostra são analisados para produzir conclusões sobre a característica de interesse na população. A amostra observada corresponde a apenas um dos possíveis conjuntos de dados que poderiam ser obtidos. Se o procedimento de amostragem fosse repetido, outros elementos poderiam ser selecionados e os resultados calculados a partir deles poderiam ser diferentes. Assim, a inferência estatística envolve a variabilidade associada ao processo de obtenção dos dados.

! Inferência estatística

A inferência estatística utiliza dados observados para obter informação sobre características desconhecidas da população ou do processo que gerou os dados.

Para representar essa variabilidade e estabelecer procedimentos inferenciais, é necessário considerar como os dados são produzidos. Esse é o ponto de partida para o conceito de Processo Gerador de Dados.

3.2 Processo Gerador de Dados (PGD)

Os dados observados resultam de algum mecanismo que define as condições sob as quais determinados valores podem ocorrer e ser observados. Esse mecanismo será denominado **Processo Gerador de Dados (PGD)**.

O PGD pode envolver diferentes componentes, como características da população, seleção das unidades observadas, condições de medição, fontes de variabilidade e relações de dependência entre as observações. Em termos gerais, o PGD descreve como o fenômeno de interesse e o mecanismo de observação se combinam para produzir os dados observados.

Os dados constituem uma realização particular desse processo. Se o mecanismo fosse repetido sob condições semelhantes, outros conjuntos de dados poderiam ser observados.

O PGD real raramente é conhecido em todos os seus detalhes. Por essa razão, o **modelo estatístico** fornece uma representação probabilística simplificada dos aspectos do PGD considerados relevantes para o problema estudado.

i PGD e hipótese i.i.d.

Em muitos modelos estatísticos, as observações são representadas por

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

A condição i.i.d. (iid) estabelece que as variáveis aleatórias são independentes e identicamente distribuídas. Essa é uma hipótese sobre o mecanismo de geração dos dados e não uma condição que define todo Processo Gerador de Dados.

Outros mecanismos podem produzir observações dependentes, distribuições diferentes entre unidades ou estruturas amostrais determinadas pelo plano de coleta.

A adequação da hipótese i.i.d. depende do mecanismo que produz os dados. A condição de distribuições idênticas requer que as observações possam ser representadas pelo mesmo modelo probabilístico, enquanto a independência requer que o comportamento de uma observação não altere probabilisticamente o das demais.

Por exemplo, componentes selecionados aleatoriamente de uma produção mantida sob condições estáveis podem ser razoavelmente representados como i.i.d. Em contrapartida, medições sucessivas de uma mesma variável ao longo do tempo podem apresentar dependência e exigir outro modelo.

3.3 Conceitos fundamentais

Uma **população** é o conjunto de unidades sobre as quais se deseja obter informação. Dependendo do problema, pode ser formada por pessoas, animais, objetos, empresas, municípios, medições ou outras unidades de interesse.

A **unidade observacional** é o elemento da população sobre o qual uma ou mais características são observadas ou medidas. Por exemplo, pode corresponder a uma pessoa, um animal, uma embalagem, um município ou uma bola da urna utilizada no experimento deste capítulo.

Quando a população é finita, seu tamanho será representado por N .

Uma quantidade que caracteriza a população, o processo ou o modelo estatístico de interesse é denominada **parâmetro**. Na abordagem frequentista desenvolvida neste livro, o parâmetro é tratado como uma quantidade fixa. Em um problema inferencial, seu valor é, em geral, desconhecido e deve ser estudado a partir dos dados observados.

Os parâmetros são usualmente representados por letras gregas, como μ , σ^2 e θ . Algumas quantidades, entretanto, possuem notações convencionais próprias. Um exemplo é a proporção populacional, frequentemente representada pela letra p .

Por exemplo, podem constituir parâmetros:

- a média populacional μ ;
- a variância populacional σ^2 ;
- uma proporção populacional p .

Um **censo** consiste na observação de todas as unidades de uma população finita. Quando o censo é possível e as medições são obtidas sem erro, uma característica da população pode ser calculada diretamente. Em muitas aplicações, observar toda a população é inviável em razão de custo, tempo, disponibilidade das unidades ou do próprio processo de medição.

Uma **amostra** é uma coleção de unidades ou observações utilizada para obter informação sobre a população ou o processo de interesse. Seu tamanho será representado por n . A **amostragem** corresponde ao procedimento utilizado para selecionar ou obter essas unidades ou observações.

No experimento que será realizado em sala de aula, a população é formada por $N = 2400$ bolas de mesmo tamanho, das quais 900 são vermelhas e 1500 são brancas. A característica de interesse é a proporção populacional de bolas vermelhas,

$$p = \frac{900}{2400} = 0,375.$$

Conhecemos p nesse experimento porque a composição completa da urna é conhecida. Essa informação será utilizada como referência para estudar o que ocorre quando apenas uma amostra da urna é observada.

Se representarmos por Y o número de bolas vermelhas em uma amostra aleatória de tamanho n , a proporção amostral pode ser escrita como

$$\hat{p} = \frac{Y}{n}.$$

Como será formalizado adiante, $\hat{p}$ é uma **estatística**, pois é uma função da amostra. Quando utilizada para obter informação sobre o parâmetro populacional p , ela desempenha o papel de **estimador** de p . Depois que uma amostra específica é observada e Y assume um valor y , o valor numérico

$$\hat{p}(\mathbf{x}) = \frac{y}{n}$$

constitui uma **estimativa** de p .

Essa distinção entre estatística, estimador e estimativa será retomada adiante, após o experimento da urna, quando será possível observar diretamente como $\hat{p}$ varia entre diferentes amostras.

Mecanismo de seleção da amostra

A possibilidade de generalizar resultados da amostra para a população depende, entre outros aspectos, do mecanismo utilizado para selecionar as unidades.

Uma seleção que favoreça sistematicamente determinados elementos pode produzir **viés de seleção**. Por exemplo, se a retirada das bolas favorecer determinadas regiões da urna, as probabilidades de inclusão podem deixar de corresponder ao plano amostral pretendido.

O mecanismo de participação também pode afetar a composição da amostra. Em levantamentos de resposta voluntária, por exemplo, mesmo que o convite seja dirigido a toda a população, os indivíduos que respondem podem diferir sistematicamente dos que não respondem. Nesse caso, o conjunto de respondentes não constitui automaticamente uma representação adequada da população.

Na **amostragem aleatória**, a seleção das unidades é realizada segundo um mecanismo probabilístico conhecido. Em uma amostragem aleatória simples sem reposição, todas as amostras de tamanho n possuem a mesma probabilidade de seleção.

A aleatorização não garante que cada amostra observada reproduza exatamente a composição da população. Amostras diferentes apresentam variação natural. Sua função é estabelecer um mecanismo de seleção que permita caracterizar probabilisticamente essa variabilidade e sustentar a inferência para a população considerada.

3.4 Experimento em sala de aula

O objetivo do experimento é observar como amostras diferentes, obtidas da mesma população pelo mesmo procedimento, podem produzir valores diferentes para a proporção amostral.

A população é a urna com $N = 2400$ bolas, das quais 900 são vermelhas. Portanto, a proporção populacional conhecida é $p = 0,375$.

Cada grupo realizará uma amostragem seguindo o mesmo protocolo:

1. misturar cuidadosamente as bolas da urna;
2. retirar, com uma pá de amostragem com 50 espaços, $n = 50$ bolas, sem reposição durante a formação da amostra;
3. contar o número observado y de bolas vermelhas;
4. calcular a proporção observada $\hat{p} = y/50$;
5. registrar os valores de y e $\hat{p}$;
6. devolver todas as bolas à urna antes da amostragem do grupo seguinte e misturá-las novamente.

Cada grupo realiza uma amostragem separada. Dentro de cada amostra, as bolas são retiradas sem reposição; entre as amostragens dos grupos, todas as bolas são devolvidas à urna, restabelecendo a população original.

Os resultados dos grupos serão reunidos somente depois que todas as amostras tiverem sido obtidas.

Ao final, teremos valores

$$\hat{p}_1, \hat{p}_2, \dots, \hat{p}_m,$$

em que m corresponde ao número de grupos.

Essas proporções serão organizadas em uma tabela e representadas graficamente. A representação resultante mostra a **distribuição empírica dos valores de $\hat{p}$ obtidos pelos grupos** e permite observar a variabilidade produzida pela repetição da amostragem.

Mesmo que todos os grupos utilizem a mesma população, o mesmo tamanho amostral e o mesmo procedimento, os valores de $\hat{p}$ não precisam coincidir. Essa variação decorre da seleção de conjuntos diferentes de bolas em cada amostra.

O experimento fornece uma primeira representação empírica da variabilidade que será descrita probabilisticamente pela distribuição amostral de $\hat{p}$ no Capítulo ??.

Verificação de aprendizagem

1. Explique a função da mistura da urna antes de cada amostragem.
2. Explique por que diferentes grupos podem obter valores distintos de y e de $\hat{p}$, mesmo utilizando o mesmo tamanho amostral.
3. Compare os valores de $\hat{p}$ obtidos pelos grupos com a proporção populacional $p = 0,375$.
4. A partir dos resultados da turma, descreva o que permaneceu fixo e o que variou entre as diferentes amostras.

3.5 Estatísticas, estimadores e estimativas

Os resultados do experimento podem agora ser formalizados distinguindo a amostra antes da observação dos valores e a amostra efetivamente observada.

Antes da coleta, representamos a amostra pelo vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n).$$

Nesse caso, $X_1, \dots, X_n$ são variáveis aleatórias e seus valores ainda não foram observados. Depois da coleta, uma realização particular desse vetor é representada por

$$\mathbf{x} = (x_1, \dots, x_n),$$

em que $x_1, \dots, x_n$ são os valores efetivamente observados.

A convenção de utilizar letras maiúsculas para variáveis aleatórias e letras minúsculas para suas realizações permite distinguir uma quantidade definida antes da observação dos dados de seu valor em uma amostra particular (Cox, 2006, seq. 1.1; Ramachandran; Tsokos, 2021, seq. 5.2, pp. 180–182).

! Estatística

Uma **estatística** é uma função conhecida das variáveis aleatórias que compõem a amostra e cuja expressão não envolve parâmetros desconhecidos. De forma geral,

$$T = T(\mathbf{X}) = T(X_1, \dots, X_n).$$

Antes da observação da amostra, $T(\mathbf{X})$ é uma variável aleatória. Depois que a amostra $\mathbf{x} = (x_1, \dots, x_n)$ é observada, a estatística assume o valor

$$T(\mathbf{x}) = T(x_1, \dots, x_n).$$

A condição de que uma estatística não dependa de parâmetros desconhecidos refere-se à sua regra de cálculo. Sua distribuição de probabilidade, entretanto, pode depender dos parâmetros do modelo. A distribuição de probabilidade de uma estatística é denominada **distribuição amostral** e será estudada no Capítulo ??.

No experimento da urna, por exemplo, a quantidade Y , que representa o número de bolas vermelhas na amostra aleatória, é uma estatística. A proporção amostral

$$\hat{p} = \frac{Y}{n}$$

também é uma estatística, pois é calculada apenas a partir dos resultados da amostra e do tamanho amostral conhecido.

Uma estatística pode ser utilizada para estimar um parâmetro desconhecido. Considere inicialmente um parâmetro populacional θ . Se a estatística $T(\mathbf{X})$ é escolhida como regra para estimar θ , escrevemos

$$\hat{\theta} = T(\mathbf{X}),$$

e denominamos $\hat{\theta}$ **estimador de θ** .

Como o estimador é uma função da amostra aleatória, seu valor pode variar de uma amostra para outra. Na abordagem frequentista considerada neste livro, essa situação é distinta daquela do parâmetro. Aqui θ é tratado como uma quantidade fixa, embora desconhecida, enquanto $\hat{\theta}$ é uma variável aleatória.

Depois que uma amostra particular $\mathbf{x}$ é observada, o estimador assume o valor

$$\hat{\theta}(\mathbf{x}) = T(\mathbf{x}).$$

Esse valor é denominado **estimativa de θ** .

! Estimador e estimativa

Considere

$$\hat{\theta} = T(\mathbf{X}).$$

O **estimador** $\hat{\theta}$ é a regra, definida como uma função da amostra aleatória, utilizada para estimar o parâmetro θ .

Depois que a amostra $\mathbf{x}$ é observada,

$$\hat{\theta}(\mathbf{x}) = T(\mathbf{x})$$

é a **estimativa**, isto é, o valor assumido pelo estimador naquela amostra particular. Assim, o parâmetro θ é fixo e desconhecido, o estimador $\hat{\theta}$ é aleatório antes da observação da amostra e a estimativa é o valor obtido após a observação dos dados (Chihara; Hesterberg, 2022, definição 4.2, p. 79; Ramachandran; Tsokos, 2021, seq. 5.2, pp. 181–182).

No experimento da urna, o parâmetro de interesse é a proporção populacional p . A proporção amostral

$$\hat{p} = \frac{Y}{n}$$

é utilizada como estimador de p .

Por exemplo, se em uma amostra de $n = 50$ bolas for observado $y = 20$, a estimativa obtida é

$$\hat{p} = \frac{20}{50} = 0,40.$$

Nesse caso, $\hat{p} = Y/n$ representa o estimador de p , enquanto

$$\hat{p}(\mathbf{x}) = \frac{y}{n} = 0,40$$

é a estimativa produzida pela amostra observada.

Na notação estatística, é comum utilizar o mesmo símbolo, como $\hat{p}$ ou $\hat{\theta}$, tanto para o estimador quanto para seu valor observado. A distinção entre os dois é determinada pelo contexto. Quando for necessário explicitá-la, utilizaremos $T(\mathbf{X})$ para a estatística como variável aleatória e $T(\mathbf{x})$ para seu valor na amostra observada.

i Estimação de uma função do parâmetro

Em alguns problemas, a quantidade de interesse não é o próprio parâmetro θ , mas uma função desse parâmetro,

$$\tau(\theta).$$

Nesse caso, uma estatística $T(\mathbf{X})$ utilizada para estimar $\tau(\theta)$ pode ser representada por

$$\hat{\tau} = T(\mathbf{X}).$$

Depois da observação da amostra $\mathbf{x}$, o valor

$$\hat{\tau}(\mathbf{x}) = T(\mathbf{x})$$

é uma estimativa de $\tau(\theta)$.

Portanto, a definição de estimador permanece a mesma; o que se altera é a quantidade paramétrica que constitui o objeto da estimação.

Alguns exemplos usuais são apresentados a seguir.

Parâmetro de interesse	Estimador	Estimativa após a observação da amostra
média populacional μ	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
variância populacional σ^2	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
proporção populacional p	$\hat{p} = \frac{Y}{n}$	$\hat{p}(\mathbf{x}) = \frac{y}{n}$

Uma mesma expressão pode ser considerada inicialmente apenas como uma estatística e, quando associada a uma quantidade paramétrica que se deseja estimar, desempenhar o papel de estimador. Por exemplo, $\bar{X}$ é uma estatística por ser uma função da amostra que não envolve parâmetros desconhecidos. Quando é utilizada para estimar a média populacional μ , $\bar{X}$ é um estimador de μ (Chihara; Hesterberg, 2022, seq. 1.6 e definição 4.2; Ramachandran; Tsokos, 2021, seq. 5.2).

3.6 Exemplo-guia: modelo Bernoulli para a urna

O experimento realizado em sala de aula utiliza amostragem sem reposição. Nesse caso, a composição da urna se modifica a cada retirada e as observações realizadas dentro de uma mesma amostra não são independentes.

Para introduzir um modelo probabilístico simples que permita formalizar os conceitos de parâmetro, estatística e estimador, consideraremos agora um mecanismo de amostragem diferente: após cada retirada, a bola é devolvida à urna e as bolas são novamente misturadas antes da retirada seguinte.

Com a reposição, a composição da urna permanece a mesma em todas as retiradas. Se todas as bolas possuem a mesma probabilidade de seleção, a probabilidade de retirar uma bola vermelha é constante e igual à proporção de bolas vermelhas na urna.

Na urna utilizada em sala de aula,

$$p = \frac{900}{2400} = 0,375.$$

Esse valor é conhecido porque a composição da urna foi previamente estabelecida. Para formular um problema de inferência, passaremos agora da urna física para um **modelo Bernoulli paramétrico idealizado**, no qual p é desconhecido e deve ser estudado a partir da amostra.

Nesse modelo, p representa a probabilidade de obter uma bola vermelha em cada retirada e pode assumir qualquer valor no intervalo $[0, 1]$.

Defina

$$X_i = \begin{cases} 1, & \text{se a } i\text{-ésima bola é vermelha,} \\ 0, & \text{se a } i\text{-ésima bola é branca.} \end{cases}$$

Sob esse mecanismo de amostragem,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p).$$

Cada variável X_i possui a mesma distribuição Bernoulli com parâmetro p , e a reposição permite tratar as retiradas como independentes.

A estatística que representa o número de bolas vermelhas na amostra é

$$Y = \sum_{i=1}^n X_i,$$

e a proporção amostral é

$$\hat{p} = \frac{Y}{n} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Assim, Y e $\hat{p}$ são estatísticas. Quando o objetivo é estimar a proporção populacional p , $\hat{p}$ é utilizado como estimador de p (Chihara; Hesterberg, 2022, seq. 1.5, seção 1.6 e apêndice B.1).

Amostragem com e sem reposição

O modelo Bernoulli i.i.d. apresentado nesta seção corresponde ao mecanismo de amostragem **com reposição** e, portanto, não descreve exatamente o experimento realizado anteriormente em sala de aula.

Na amostragem **sem reposição** em uma população finita, as retiradas realizadas dentro

de uma mesma amostra são dependentes e o número de bolas vermelhas possui distribuição hipergeométrica.

Os dois mecanismos permitem estudar a variabilidade decorrente da amostragem, mas produzem modelos probabilísticos diferentes. A amostragem sem reposição e a correção para população finita serão estudadas no Capítulo ??.

Considere uma urna com N bolas, das quais M são vermelhas.

Antes de qualquer retirada,

$$P(X_1 = 1) = \frac{M}{N}.$$

Se a primeira bola retirada for vermelha e não for devolvida à urna, restam $M - 1$ bolas vermelhas entre $N - 1$ bolas. Portanto,

$$P(X_2 = 1 \mid X_1 = 1) = \frac{M - 1}{N - 1}.$$

Em geral,

$$\frac{M - 1}{N - 1} \neq \frac{M}{N}.$$

Logo,

$$P(X_2 = 1 \mid X_1 = 1) \neq P(X_2 = 1),$$

e as retiradas não são independentes.

Na urna do experimento,

$$P(X_2 = 1) = \frac{900}{2400},$$

enquanto

$$P(X_2 = 1 \mid X_1 = 1) = \frac{899}{2399}.$$

A ausência de reposição modifica a composição da urna após cada retirada e, conseqüentemente, a probabilidade associada às retiradas seguintes.

3.7 Modelo estatístico e função de verossimilhança

No exemplo da urna, a representação

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p)$$

especifica probabilisticamente como os dados podem ser produzidos para cada possível valor de p . Essa representação é um exemplo de **modelo estatístico**.

De forma mais geral, a análise inferencial requer uma representação probabilística para o vetor de observações

$$\mathbf{X} = (X_1, \dots, X_n).$$

Essa representação deve especificar quais distribuições de probabilidade são consideradas possíveis para $\mathbf{X}$ e quais quantidades desconhecidas distinguem essas distribuições.

Modelo estatístico

Considere um vetor aleatório $\mathbf{X}$ que assume valores em um espaço amostral $\mathcal{X}$. Um **modelo estatístico paramétrico** é uma família de distribuições de probabilidade

$$\mathcal{F} = \{F(\cdot \mid \theta) : \theta \in \Theta\},$$

em que:

- θ representa o parâmetro, ou vetor de parâmetros, do modelo;
- Θ é o **espaço paramétrico**, isto é, o conjunto dos valores possíveis de θ ;
- para cada $\theta \in \Theta$, $F(\cdot \mid \theta)$ representa uma possível distribuição conjunta para $\mathbf{X}$.

Na abordagem frequentista, admite-se que existe um valor fixo, porém desconhecido, de θ associado ao mecanismo que produziu os dados. O objetivo inferencial consiste em utilizar a amostra observada para obter informação sobre esse valor.

Quando a distribuição conjunta possui função de probabilidade ou densidade, ela pode ser representada por

$$f(\mathbf{x} \mid \theta), \quad \mathbf{x} \in \mathcal{X}, \quad \theta \in \Theta.$$

Para cada valor fixado de θ , a função $f(\mathbf{x} \mid \theta)$ descreve probabilisticamente os possíveis valores de $\mathbf{X}$.

i Processo Gerador de Dados e modelo estatístico

O **Processo Gerador de Dados (PGD)** corresponde ao mecanismo que produz os dados e pode envolver aspectos da população, seleção das unidades, condições de medição, dependência e outras fontes de variabilidade.

O **modelo estatístico** é uma representação probabilística dos aspectos desse processo considerados relevantes para a análise.

Assim, o modelo não precisa reproduzir todos os detalhes do PGD. Ele estabelece uma família de distribuições probabilísticas dentro da qual será realizada a inferência.

A expressão $f_{\mathbf{X}}(\mathbf{x} \mid \theta)$ representa a **função de probabilidade ou densidade conjunta da amostra**. Ela não precisa, em geral, ser escrita como produto das funções correspondentes às observações individuais.

Quando $X_1, \dots, X_n$ são independentes e identicamente distribuídas, com função de probabilidade ou densidade comum $f(\cdot \mid \theta)$, a independência permite escrever

$$f_{\mathbf{X}}(\mathbf{x} \mid \theta) = \prod_{i=1}^n f(x_i \mid \theta).$$

A forma em produto é, portanto, consequência da hipótese de independência. Para observações dependentes, a distribuição conjunta deve incorporar a estrutura de dependência existente.

Distribuição conjunta da amostra no modelo Bernoulli

No modelo Bernoulli da urna,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Ber}(p),$$

o parâmetro do modelo é

$$\theta = p,$$

com espaço paramétrico

$$\Theta = [0, 1].$$

Como cada variável X_i assume os valores 0 ou 1, o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n)$$

assume valores no espaço amostral

$$\mathcal{X} = \{0, 1\}^n.$$

Para cada observação X_i , a função de probabilidade Bernoulli pode ser escrita como

$$f(x_i | p) = P(X = x_i | p) = p^{x_i}(1 - p)^{1-x_i}, \quad x_i \in \{0, 1\}.$$

Nesta notação, p é o parâmetro fixado do modelo. A barra vertical é utilizada para indicar que a função de probabilidade é especificada para determinado valor de p ; não estamos tratando p como uma variável aleatória.

Essa expressão representa simultaneamente as duas possibilidades. Se $x_i = 1$,

$$f(1 | p) = P(X = 1 | p) = p,$$

enquanto, se $x_i = 0$,

$$f(0 | p) = P(X = 0 | p) = 1 - p.$$

Considere agora o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_n)$$

e uma possível realização

$$\mathbf{x} = (x_1, \dots, x_n) \in \{0, 1\}^n.$$

Como as variáveis $X_1, \dots, X_n$ são independentes, a função de probabilidade conjunta de $\mathbf{X}$ é o produto das funções de probabilidade individuais:

$$f_{\mathbf{X}}(\mathbf{x} | p) = \prod_{i=1}^n f(x_i | p).$$

Substituindo a função de probabilidade Bernoulli,

$$f_{\mathbf{X}}(\mathbf{x} | p) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}.$$

Agrupando os fatores que envolvem p e $1 - p$,

$$f_{\mathbf{X}}(\mathbf{x} \mid p) = p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n (1-x_i)}.$$

Retomando a estatística definida anteriormente,

$$Y = \sum_{i=1}^n X_i,$$

como cada X_i assume os valores 0 ou 1, Y representa o número de bolas vermelhas na amostra aleatória.

Depois que uma realização $\mathbf{x} = (x_1, \dots, x_n)$ é observada, Y assume o valor

$$y = \sum_{i=1}^n x_i,$$

que corresponde ao número efetivamente observado de bolas vermelhas.

Além disso,

$$\sum_{i=1}^n (1 - x_i) = n - \sum_{i=1}^n x_i = n - y,$$

de modo que $n - y$ é o número de bolas brancas na sequência observada.

Consequentemente, a função de probabilidade conjunta da amostra pode ser escrita como

$$f_{\mathbf{X}}(\mathbf{x} \mid p) = p^y (1-p)^{n-y}, \quad \mathbf{x} \in \{0, 1\}^n. \quad (3.1)$$

A Equação ?? fornece, para um valor fixado de p , a probabilidade associada a cada possível realização $\mathbf{x} = (x_1, \dots, x_n)$ do vetor aleatório $\mathbf{X}$. Antes da observação dos dados, $\mathbf{X}$ é aleatório e diferentes sequências podem ser observadas.

Por exemplo, para $n = 5$, as sequências

$$(1, 0, 1, 0, 0) \quad \text{e} \quad (0, 1, 0, 0, 1)$$

possuem, em ambos os casos, $v = 2$. Para um valor fixado de p , cada uma dessas sequências possui probabilidade

$$p^2(1-p)^3.$$

Isso ocorre porque, nesse modelo, a função de probabilidade conjunta depende da sequência $\mathbf{x}$ por meio do número de ocorrências de 1 e de 0, e não da ordem em que esses valores aparecem.

i Sequência observada e número de sucessos

A probabilidade de uma sequência específica com y bolas vermelhas é

$$p^y(1-p)^{n-y}.$$

Essa expressão não deve ser confundida com a probabilidade de observar **exatamente y bolas vermelhas, independentemente da ordem em que aparecem na sequência.**

Como existem

$$\binom{n}{y}$$

sequências distintas com exatamente y ocorrências de 1, a distribuição da estatística

$$Y = \sum_{i=1}^n X_i$$

é

$$P(Y = y | p) = \binom{n}{y} p^y (1-p)^{n-y}, \quad y = 0, 1, \dots, n.$$

Assim,

$$Y \sim \text{Bin}(n, p).$$

Portanto, para cada valor $p \in [0, 1]$, o modelo especifica uma distribuição conjunta para $\mathbf{X}$. A amostra observada corresponde a uma realização particular dessa distribuição.

Função de verossimilhança

Depois que a amostra é observada, a perspectiva pode ser invertida. Os dados

$$\mathbf{x} = (x_1, \dots, x_n)$$

passam a ser conhecidos, enquanto o parâmetro θ permanece desconhecido.

A mesma expressão matemática $f_{\mathbf{X}}(\mathbf{x} | \theta)$ pode então ser examinada como função de θ , mantendo $\mathbf{x}$ fixado.

! Função de verossimilhança

Para uma amostra observada $\mathbf{x}$, a **função de verossimilhança** é definida por

$$L(\theta; \mathbf{x}) = f_{\mathbf{X}}(\mathbf{x} | \theta), \quad \theta \in \Theta,$$

considerada como função do parâmetro θ , com os dados $\mathbf{x}$ fixados.

A diferença entre a função de probabilidade ou densidade e a função de verossimilhança está, portanto, no elemento que é considerado variável.

Na função

$$f_{\mathbf{X}}(\mathbf{x} | \theta),$$

fixa-se θ e estudam-se os possíveis valores de $\mathbf{X}$.

Na função de verossimilhança

$$L(\theta; \mathbf{x}),$$

fixa-se a amostra observada $\mathbf{x}$ e comparam-se os diferentes valores de θ permitidos pelo modelo.

! Probabilidade e verossimilhança

A verossimilhança não é, em geral, uma distribuição de probabilidade para θ .

Na abordagem frequentista, θ é tratado como uma quantidade fixa e desconhecida. A função $L(\theta; \mathbf{x})$ permite comparar os diferentes valores de θ em relação aos dados observados.

Valores de θ que produzem maior verossimilhança apresentam maior compatibilidade com os dados observados dentro do modelo considerado. Essa comparação é relativa: a verossimilhança não representa a probabilidade de θ assumir determinado valor (Cox, 2006, seq. 2.1).

Verossimilhança no modelo Bernoulli

Na distribuição conjunta do modelo Bernoulli, obtivemos em Equação ??

$$f_{\mathbf{X}}(\mathbf{x} | p) = p^y (1 - p)^{n-y},$$

em que

$$y = \sum_{i=1}^n x_i$$

é o valor observado da estatística

$$Y = \sum_{i=1}^n X_i.$$

Na interpretação probabilística dessa expressão, p é fixado e consideram-se as diferentes realizações possíveis de $\mathbf{X}$.

Depois que uma realização específica

$$\mathbf{x} = (x_1, \dots, x_n)$$

é observada, ocorre uma mudança de perspectiva. Os valores $x_1, \dots, x_n$ e, conseqüentemente, y passam a ser fixos, enquanto p é a quantidade desconhecida.

A mesma expressão da Equação ??, considerada agora como função de p , define a função de verossimilhança:

$$L(p; \mathbf{x}) = f_{\mathbf{X}}(\mathbf{x} | p) = p^y (1 - p)^{n-y}, \quad 0 \leq p \leq 1.$$

Portanto, não estamos definindo uma nova distribuição de probabilidade. A expressão matemática é a mesma, mas sua interpretação é diferente:

- em $f_{\mathbf{X}}(\mathbf{x} | p)$, fixa-se p e consideram-se os possíveis valores de $\mathbf{X}$;
- em $L(p; \mathbf{x})$, fixa-se a realização observada $\mathbf{x}$ e comparam-se os possíveis valores de p .

Considere, por exemplo, uma amostra de tamanho $n = 50$ na qual foram observadas $y = 20$ bolas vermelhas. Nesse caso,

$$L(p; \mathbf{x}) = p^{20} (1 - p)^{30}.$$

Os dados permanecem fixos: foram observadas 20 bolas vermelhas e 30 bolas brancas. O que varia é p . A função de verossimilhança permite comparar os diferentes valores de $p \in [0, 1]$ em relação à mesma amostra observada.

A função pode ser visualizada diretamente na sua escala original.

```

library(ggplot2)

n <- 50
y <- 20

p_grade <- seq(0, 1, length.out = 1001)

dados_veross <- data.frame(
  p = p_grade
)

dados_veross$L <- with(
  dados_veross,
  p^y * (1 - p)^(n - y)
)

# Localização numérica do maior valor da verossimilhança
indice_max <- which.max(dados_veross$L)

p_max <- dados_veross$p[indice_max]
L_max <- dados_veross$L[indice_max]

ggplot(dados_veross, aes(x = p, y = L)) +
  geom_line(
    color = "#08519C",
    linewidth = 1.3
  ) +
  geom_vline(
    xintercept = p_max,
    linetype = "dashed",
    color = "#CB181D",
    linewidth = 0.9
  ) +
  geom_point(
    x = p_max,
    y = L_max,
    color = "#CB181D",
    size = 3
  ) +
  annotate(
    "label",
    x = 0.52,

```

```

    y = 0.92 * L_max,
    label = "maior valor em p = 0,40",
    color = "#A50F15",
    fill = "white",
    size = 4
) +
scale_x_continuous(
  limits = c(0, 1),
  breaks = seq(0, 1, by = 0.1),
  labels = scales::label_number(
    accuracy = 0.1,
    decimal.mark = ",",
  )
) +
scale_y_continuous(
  labels = scales::label_scientific()
) +
labs(
  x = "Valor de p",
  y = expression(L(p~";"~bold(x))),
  title = "Função de verossimilhança",
  subtitle = "Modelo Bernoulli: n = 50 e y = 20"
) +
theme_minimal(base_size = 13) +
theme(
  panel.grid.minor = element_blank(),
  plot.title.position = "plot"
)

```

Função de verossimilhança

Modelo Bernoulli: $n = 50$ e $y = 20$




Figura 3.1: Função de verossimilhança para o modelo Bernoulli com $n = 50$ e $y = 20$.

A altura da curva depende da escala da função de verossimilhança e, neste exemplo, seus valores são numericamente pequenos. O que interessa para a comparação entre valores de p é a forma da função e sua posição relativa. O gráfico mostra que valores próximos de 0,40 apresentam maior verossimilhança para a amostra observada, enquanto valores mais afastados produzem valores menores de $L(p; \mathbf{x})$.

Log-verossimilhança

Em muitos problemas, é conveniente trabalhar com o logaritmo da função de verossimilhança. Define-se a **função de log-verossimilhança** por

$$\ell(p; \mathbf{x}) = \log L(p; \mathbf{x}).$$

No modelo Bernoulli,

$$L(p; \mathbf{x}) = p^y(1-p)^{n-y},$$

de modo que

$$\ell(p; \mathbf{x}) = \log [p^y(1-p)^{n-y}].$$

Utilizando as propriedades do logaritmo,

$$\ell(p; \mathbf{x}) = y \log p + (n-y) \log(1-p), \quad 0 < p < 1.$$

Para o exemplo com $n = 50$ e $y = 20$,

$$\ell(p; \mathbf{x}) = 20 \log p + 30 \log(1-p).$$

O logaritmo transforma o produto presente na verossimilhança em uma soma, o que facilita manipulações algébricas e numéricas.

Além disso, como a função logaritmo é estritamente crescente, se

$$L(p_1; \mathbf{x}) > L(p_2; \mathbf{x}),$$

então

$$\ell(p_1; \mathbf{x}) > \ell(p_2; \mathbf{x}).$$

Consequentemente, a verossimilhança e a log-verossimilhança ordenam os valores de p da mesma forma e atingem seu máximo no mesmo ponto.

```
n <- 50
y <- 20

# Os extremos 0 e 1 são excluídos porque log(0) não é definido.
p_grade <- seq(0.001, 0.999, by = 0.001)

dados_logveross <- data.frame(
  p = p_grade
)

dados_logveross$logL <- with(
  dados_logveross,
```

```

  y * log(p) + (n - y) * log(1 - p)
)

indice_max <- which.max(dados_logveross$logL)

p_max <- dados_logveross$p[indice_max]
logL_max <- dados_logveross$logL[indice_max]

ggplot(dados_logveross, aes(x = p, y = logL)) +
  geom_line(
    color = "#54278F",
    linewidth = 1.2
  ) +
  geom_vline(
    xintercept = p_max,
    linetype = "dashed",
    color = "#CB181D",
    linewidth = 0.9
  ) +
  geom_point(
    x = p_max,
    y = logL_max,
    color = "#CB181D",
    size = 3
  ) +
  annotate(
    "label",
    x = 0.52,
    y = logL_max - 5,
    label = "p = 0,40",
    color = "#A50F15",
    fill = "white",
    label.size = 0.2,
    size = 4
  ) +
  scale_x_continuous(
    limits = c(0, 1),
    breaks = seq(0, 1, by = 0.1),
    labels = scales::label_number(
      accuracy = 0.1,
      decimal.mark = ",",
    )
  )

```

```

) +
labs(
  x = "Valor de p",
  y = expression(ell(p~";"~bold(x))),
  title = "Função de log-verossimilhança",
  subtitle = "Modelo Bernoulli: n = 50 e y = 20"
) +
theme_minimal(base_size = 13) +
theme(
  panel.grid.minor = element_blank(),
  plot.title.position = "plot"
)

```

Função de log-verossimilhança

Modelo Bernoulli: $n = 50$ e $y = 20$




Figura 3.2: Função de log-verossimilhança para o modelo Bernoulli com $n = 50$ e $y = 20$.

Os dois gráficos apresentam o maior valor no mesmo ponto. A diferença está na escala vertical: o primeiro representa diretamente $L(p; \mathbf{x})$, enquanto o segundo representa seu logaritmo.

Observe ainda que, na expressão

$$L(p; \mathbf{x}) = p^y(1-p)^{n-y},$$

a sequência completa

$$(x_1, \dots, x_n)$$

aparece apenas por meio de

$$y = \sum_{i=1}^n x_i.$$

Assim, duas sequências observadas com o mesmo número y de bolas vermelhas produzem a mesma função de verossimilhança para p , mesmo que as bolas vermelhas e brancas apareçam em ordens diferentes.

Essa propriedade será formalizada posteriormente por meio do conceito de **estatística suficiente**.

Verossimilhança e estimação

A função de verossimilhança permite comparar diferentes valores do parâmetro em relação à amostra observada. Uma forma de utilizar essa comparação para construir uma estimativa consiste em procurar o valor de θ que torna a verossimilhança tão grande quanto possível.

Considere uma amostra observada $\mathbf{x}$. Para cada valor $\theta \in \Theta$, podemos calcular

$$L(\theta; \mathbf{x}).$$

Entre os valores permitidos pelo espaço paramétrico Θ , procuramos aqueles para os quais a função de verossimilhança atinge seu maior valor.

Se existir um único valor θ^* tal que

$$L(\theta^*; \mathbf{x}) \geq L(\theta; \mathbf{x}) \quad \text{para todo } \theta \in \Theta,$$

então θ^* é o valor de θ que maximiza a função de verossimilhança para a amostra observada.

Esse valor é denominado **estimativa de máxima verossimilhança**.

Em alguns problemas, entretanto, mais de um valor de θ pode produzir o mesmo valor máximo da função de verossimilhança. Por essa razão, é conveniente representar o conjunto de todos os valores que maximizam a função.

A notação

$$\arg \max_{\theta \in \Theta} L(\theta; \mathbf{x})$$

representa o conjunto dos valores de θ em Θ nos quais a função $L(\theta; \mathbf{x})$ atinge seu máximo.

A expressão $\arg \max$ deve ser distinguida do próprio valor máximo da função. Enquanto

$$\max_{\theta \in \Theta} L(\theta; \mathbf{x})$$

representa o maior valor assumido pela função de verossimilhança,

$$\arg \max_{\theta \in \Theta} L(\theta; \mathbf{x})$$

representa o valor, ou os valores, de θ nos quais esse máximo é atingido.

Por exemplo, se uma função atinge seu maior valor em $\theta = 2$, então

$$\arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}) = \{2\}.$$

A estimativa de máxima verossimilhança é, portanto, qualquer valor pertencente a esse conjunto. Quando esse conjunto possui mais de um elemento, qualquer um de seus elementos pode ser considerado uma estimativa de máxima verossimilhança.

Para definir um estimador como uma função da amostra, entretanto, é necessário estabelecer uma regra de escolha quando houver mais de um maximizador. Quando o máximo é único, essa escolha não apresenta ambiguidade. Escrevemos

$$\hat{\theta}_{\text{MV}}(\mathbf{x}) \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}).$$

O símbolo $\in$ é utilizado porque, em geral, o lado direito representa um conjunto de valores que maximizam a verossimilhança. Quando o máximo é atingido em um único valor, podemos escrever, de forma equivalente,

$$\hat{\theta}_{\text{MV}}(\mathbf{x}) = \theta^*.$$

Assim, para uma amostra observada $\mathbf{x}$, a máxima verossimilhança fornece uma regra para selecionar um valor do parâmetro a partir dos dados.

Até aqui estamos tratando de uma **estimativa**, pois a amostra já foi observada. Para obter o correspondente estimador, consideramos a mesma regra para todas as possíveis realizações da amostra aleatória.

A cada possível realização $\mathbf{x}$ de $\mathbf{X}$, associamos um valor $\hat{\theta}_{\text{MV}}(\mathbf{x})$ que maximiza a função de verossimilhança. Essa regra define o **estimador de máxima verossimilhança**. Antes da observação dos dados, escrevemos

$$\hat{\theta}_{\text{MV}} = \hat{\theta}_{\text{MV}}(\mathbf{X}).$$

Portanto,

$$\hat{\theta}_{\text{MV}}(\mathbf{X})$$

é uma função da amostra aleatória e, por isso, é uma variável aleatória. Depois que a amostra assume o valor observado $\mathbf{x}$, obtemos

$$\hat{\theta}_{\text{MV}}(\mathbf{x}),$$

que é a estimativa de máxima verossimilhança correspondente.

Essa distinção é a mesma apresentada anteriormente para estimadores e estimativas: o **estimador de máxima verossimilhança** é a regra definida em função da amostra aleatória, enquanto a **estimativa de máxima verossimilhança** é o valor produzido por essa regra para uma amostra particular.

Verossimilhança e estimação no exemplo-guia

No modelo Bernoulli,

$$L(p; \mathbf{x}) = p^y (1 - p)^{n-y}.$$

Para determinar o valor de p que maximiza essa função, podemos trabalhar com a log-verossimilhança. Como a amostra observada $\mathbf{x}$ permanece fixa durante a maximização, escreveremos na derivação a seguir $\ell(p)$ como forma abreviada de $\ell(p; \mathbf{x})$.

Para $0 < y < n$, a log-verossimilhança é

$$\ell(p) = \log L(p; \mathbf{x}) = y \log p + (n - y) \log(1 - p).$$

Como o logaritmo é uma função estritamente crescente, maximizar $\ell(p)$ equivale a maximizar $L(p; \mathbf{x})$.

Derivando em relação a p ,

$$\ell'(p) = \frac{d\ell(p)}{dp} = \frac{y}{p} - \frac{n-y}{1-p} = \frac{y-np}{p(1-p)}.$$

O ponto crítico satisfaz

$$y - np = 0,$$

de modo que

$$\hat{p}_{\text{MV}}(\mathbf{x}) = \frac{y}{n}.$$

Além disso,

$$\ell''(p) = \frac{d^2\ell(p)}{dp^2} = -\frac{y}{p^2} - \frac{n-y}{(1-p)^2} < 0,$$

para $0 < p < 1$. Portanto, o ponto crítico corresponde a um máximo da verossimilhança.

Nos casos de fronteira, o máximo pode ser identificado diretamente pela forma da verossimilhança.

Se $y = 0$,

$$L(p; \mathbf{x}) = (1-p)^n,$$

que é máxima em $p = 0$. Portanto,

$$\hat{p}_{\text{MV}} = 0.$$

Se $y = n$,

$$L(p; \mathbf{x}) = p^n,$$

que é máxima em $p = 1$. Portanto,

$$\hat{p}_{\text{MV}} = 1.$$

Assim, em todos os casos,

$$\hat{p}_{\text{MV}} = \frac{Y}{n}.$$

A proporção amostral, que anteriormente foi apresentada como uma estatística e utilizada como estimador de p , surge agora também como estimador de máxima verossimilhança.

i Proporção amostral no modelo Bernoulli

No modelo Bernoulli,

$$\hat{p} = \frac{Y}{n}$$

pode ser considerada sob diferentes aspectos:

1. é uma **estatística**, pois é uma função da amostra;
2. é um **estimador de p** , quando utilizada para estimar a proporção populacional;
3. é o **estimador de máxima verossimilhança de p** , pois resulta da maximização da função de verossimilhança.

Depois que a amostra é observada e $Y = y$, o valor

$$\hat{p}(\mathbf{x}) = \frac{y}{n}$$

é a estimativa correspondente.

A máxima verossimilhança será desenvolvida como método geral de estimação no capítulo **Métodos de Estimação Pontual**. O conceito de suficiência, sugerido pelo fato de a verossimilhança Bernoulli depender dos dados apenas por meio do valor observado y da estatística

$$Y = \sum_{i=1}^n X_i,$$

será formalizado no capítulo **Avaliação de Estimadores e Princípios de Redução de Dados**.

Verificação de aprendizagem

1. O que constitui um modelo estatístico paramétrico?
2. No modelo $\mathcal{F} = \{F(\cdot | \theta) : \theta \in \Theta\}$, qual é o papel de θ e de Θ ?
3. Por que a distribuição conjunta da amostra não pode ser escrita, em geral, como $\prod_{i=1}^n f(x_i | \theta)$?

4. Explique a diferença entre considerar $f(\mathbf{x} \mid \theta)$ como função de probabilidade ou densidade conjunta, para θ fixado, e considerá-la como função de verossimilhança depois que $\mathbf{x}$ é observado.
5. Na função $L(\theta; \mathbf{x})$, o que permanece fixo e o que varia?
6. Por que a verossimilhança não deve ser interpretada como uma distribuição de probabilidade para θ ?
7. No modelo Bernoulli, por que a função de verossimilhança depende da sequência observada apenas por meio de $v = \sum_i x_i$, valor observado da estatística $Y = \sum_i X_i$?
8. Explique por que $\hat{p} = V/n$ pode ser considerada simultaneamente uma estatística, um estimador de p e o estimador de máxima verossimilhança de p .

3.8 Variabilidade dos estimadores

Um estimador é uma função da amostra aleatória. Se

$$\hat{\theta} = T(\mathbf{X}),$$

então seu valor depende dos resultados que compõem $\mathbf{X}$. Amostras diferentes, obtidas segundo o mesmo mecanismo, podem produzir valores diferentes de $\hat{\theta}$.

Fixados o modelo estatístico e um valor do parâmetro θ , a distribuição de probabilidade de $\mathbf{X}$ induz uma distribuição de probabilidade para $T(\mathbf{X})$. Essa distribuição é a **distribuição amostral** da estatística.

Assim, a variabilidade observada entre diferentes estimativas pode ser descrita probabilisticamente. Características da distribuição amostral, como posição e dispersão, permitem estudar o comportamento de uma estatística quando o mecanismo de amostragem é repetido.

No Capítulo ??, essa ideia será desenvolvida para estatísticas como $\bar{X}$, S^2 e $\hat{p}$, considerando também o efeito do tamanho amostral, a amostragem sem reposição, resultados exatos, aproximações e simulação.

A distribuição amostral estabelece, portanto, a ligação entre a variabilidade observada no experimento e sua representação probabilística.

3.9 Exploração computacional do experimento da urna

O experimento realizado em sala de aula pode ser reproduzido computacionalmente. O objetivo é repetir o mesmo mecanismo de amostragem um número maior de vezes e examinar com mais detalhes a variabilidade da proporção amostral.

Nesta seção, retomamos o **mecanismo físico sem reposição** utilizado no experimento em sala de aula. Portanto, essa exploração não corresponde ao modelo Bernoulli i.i.d. com reposição utilizado anteriormente para introduzir a função de verossimilhança.

Preparação do ambiente computacional

A exploração utiliza os pacotes `tidyverse` (Wickham et al., 2019) e `moderndive` (Kim; Ismay; Kuhn, 2021). O primeiro fornece ferramentas para manipulação e visualização de dados, enquanto o segundo contém a população virtual utilizada no experimento e a função de amostragem repetida.

```
library(tidyverse)
library(moderndive)
```

População virtual e uma amostra

O pacote `moderndive` contém o *data frame* `bowl`, que representa virtualmente a composição da urna utilizada no experimento.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
5       5 white
6       6 white
7       7 red
8       8 white
9       9 red
10      10 white
# i 2,390 more rows
```

Cada linha corresponde a uma bola. A variável `ball_ID` identifica a unidade e `color` informa sua cor.

Podemos obter a composição completa da população virtual por meio de um censo:

```
censo_virtual <- bowl %>%
  summarize(
    N = n(),
    N_vermelha = sum(color == "red"),
    p = N_vermelha / N
  )

censo_virtual
```

```
# A tibble: 1 x 3
      N N_vermelha      p
  <int>   <int> <dbl>
1  2400     900 0.375
```

O resultado fornece $N = 2400$ bolas, das quais 900 são vermelhas. Portanto,

$$p = \frac{900}{2400} = 0,375.$$

Como essa composição é conhecida, o experimento permite comparar as estimativas obtidas nas amostras com o valor populacional conhecido $p = 0,375$.

Para reproduzir computacionalmente uma amostra de $n = 50$ bolas sem reposição, utilizamos `rep_sample_n()`:

```
set.seed(2026)

pa_virtual <- bowl %>%
  rep_sample_n(
    size = 50,
    replace = FALSE
  )

pa_virtual
```

```
# A tibble: 50 x 3
# Groups:   replicate [1]
  replicate ball_ID color
      <int>   <int> <chr>
1         1     733 white
2         1     993 red
```

```

3          1      2342 red
4          1      1647 white
5          1      1883 red
6          1       164 red
7          1     1200 red
8          1       389 white
9          1       287 white
10         1     2362 red
# i 40 more rows

```

A função `set.seed()` fixa o estado inicial do gerador de números pseudoaleatórios e permite reproduzir a mesma amostra ao executar novamente o código.

A variável `replicate` identifica a repetição da amostragem. Como foi solicitada uma única amostra, seu valor é igual a 1 em todas as linhas.

Podemos identificar cada bola vermelha por meio da expressão lógica `color == "red"`:

```

pa_virtual <- pa_virtual %>%
  mutate(
    is_vermelha = color == "red"
  )

pa_virtual

```

```

# A tibble: 50 x 4
# Groups:   replicate [1]
  replicate ball_ID color is_vermelha
    <int>    <int> <chr> <lgl>
1         1      733 white FALSE
2         1      993 red  TRUE
3         1     2342 red  TRUE
4         1     1647 white FALSE
5         1     1883 red  TRUE
6         1      164 red  TRUE
7         1     1200 red  TRUE
8         1      389 white FALSE
9         1      287 white FALSE
10        1     2362 red  TRUE
# i 40 more rows

```

O R representa TRUE e FALSE como valores lógicos. Em operações de soma, TRUE é tratado como 1 e FALSE como 0. Dessa forma, a soma da variável `is_vermelha` fornece diretamente o número de bolas vermelhas da amostra.

```
resumo_amostra <- pa_virtual %>%
  summarize(
    Y = sum(is_vermelha),
    p_hat = Y / n()
  )

resumo_amostra
```

```
# A tibble: 1 x 3
  replicate      Y p_hat
  <int> <int> <dbl>
1         1    16  0.32
```

Nesta amostra, o valor observado da estatística Y foi $v = 16$. A proporção amostral observada foi 0,32.

Esse valor corresponde à estimativa

$$\hat{p}(\mathbf{x}) = \frac{y}{n}.$$

No código, a coluna V armazena o valor observado de Y em cada amostra.

Repetição da amostragem e variabilidade

Para examinar a variação entre amostras, repetiremos o procedimento 20 vezes. Cada repetição utiliza uma amostra de tamanho $n = 50$ sem reposição e começa novamente a partir da população completa.

```
set.seed(2026)

amostra_virtual <- bowl %>%
  rep_sample_n(
    size = 50,
    reps = 20,
    replace = FALSE
  )

amostra_virtual
```

```
# A tibble: 1,000 x 3
# Groups:   replicate [20]
  replicate ball_ID color
    <int>    <int> <chr>
1         1     733 white
2         1     993 red
3         1    2342 red
4         1    1647 white
5         1    1883 red
6         1     164 red
7         1    1200 red
8         1     389 white
9         1     287 white
10        1    2362 red
# i 990 more rows
```

O objeto possui $20 \times 50 = 1000$ linhas. A variável `replicate` identifica a amostra à qual cada linha pertence.

As 20 proporções amostrais são obtidas agrupando os dados por repetição:

```
virtual_prop_vermelha <- amostra_virtual %>%
  group_by(replicate) %>%
  summarize(
    Y = sum(color == "red"),
    p_hat = Y / n(),
    .groups = "drop"
  )

virtual_prop_vermelha
```


```
# A tibble: 20 x 3
  replicate      Y p_hat
    <int> <int> <dbl>
1         1     16  0.32
2         2     22  0.44
3         3     19  0.38
4         4     27  0.54
5         5     18  0.36
6         6     19  0.38
7         7     16  0.32
8         8     17  0.34
```

9	9	21	0.42
10	10	20	0.4
11	11	23	0.46
12	12	23	0.46
13	13	15	0.3
14	14	23	0.46
15	15	27	0.54
16	16	23	0.46
17	17	17	0.34
18	18	21	0.42
19	19	15	0.3
20	20	18	0.36

Cada linha corresponde agora a uma amostra e contém seu número de bolas vermelhas e sua proporção amostral.

A distribuição empírica desses 20 valores pode ser visualizada por meio de um histograma:

```
ggplot(
  virtual_prop_vermelha,
  aes(x = p_hat)
) +
  geom_histogram(
    binwidth = 0.05,
    boundary = 0.40,
    color = "white"
  ) +
  geom_vline(
    xintercept = 0.375,
    linetype = "dashed"
  ) +
  labs(
    x = "Proporção de bolas vermelhas",
    y = "Frequência",
    title = "Distribuição empírica das proporções amostrais"
  )
```



O argumento `binwidth = 0.05` estabelece classes de amplitude 0,05, enquanto `boundary = 0.40` posiciona um dos limites de classe em 0,40. Assim, o histograma utiliza limites como 0,30, 0,35, 0,40, 0,45 e 0,50.

O código utiliza ponto como separador decimal porque essa é a sintaxe do R; no texto matemático, os mesmos valores são escritos com vírgula.

O histograma mostra que as proporções obtidas não são iguais entre as repetições. O valor populacional $p = 0,375$ permanece fixo, enquanto $\hat{p}$ varia de uma amostra para outra.

Com apenas 20 repetições, o histograma apresenta uma distribuição empírica relativamente irregular. O aumento do número de repetições permite visualizar com maior clareza o comportamento da proporção amostral sob o mecanismo de amostragem considerado.

Verificação de aprendizagem

1. Compare o valor de $p = 0,375$ com os diferentes valores de $\hat{p}$ obtidos nas 20 amostras.
2. Identifique no código quais elementos permanecem fixos em todas as repetições e quais variam.
3. Explique por que uma única amostra não permite visualizar a variabilidade amostral de $\hat{p}$.
4. Compare conceitualmente o experimento computacional com o experimento realizado em sala de aula.

Atividade computacional de consolidação

1. Repita o experimento utilizando `rep_sample_n()` com `size = 50` e `reps = 1000`.
2. Para cada uma das 1000 amostras, calcule Y e $\hat{p}$.
3. Construa um histograma das 1000 proporções amostrais e acrescente uma linha vertical indicando $p = 0,375$.
4. Compare esse histograma com o obtido a partir de apenas 20 amostras.
5. Utilize as 1000 repetições para avaliar empiricamente a frequência com que $\hat{p} \leq 0,30$.
6. Avalie também a frequência com que $\hat{p} \leq 0,20$ e compare os dois resultados.
7. Escreva uma interpretação relacionando o resultado à variabilidade amostral.

O experimento físico e sua reprodução computacional mostram que o parâmetro populacional permanece fixo, enquanto as estatísticas calculadas a partir das amostras variam. A inferência estatística utiliza essa variabilidade, representada por modelos probabilísticos, para obter informação sobre quantidades desconhecidas. A passagem dessa variabilidade empírica para a distribuição de uma estatística constitui o objeto do Capítulo ??.

Questões de revisão

1. Uma indústria produziu 12.000 embalagens durante um turno. Para avaliar a qualidade da selagem, 240 embalagens foram selecionadas aleatoriamente e 18 apresentaram falha.
 - a. Identifique a população, a unidade observacional e a amostra.
 - b. Qual parâmetro populacional está sendo estudado?
 - c. Calcule uma estatística amostral adequada para obter informação sobre esse parâmetro.
2. Considere um lote com 800 recipientes.
 - a. Se todos os recipientes forem avaliados e sua massa média for calculada, essa média é um parâmetro ou uma estatística?
 - b. Se apenas 50 recipientes forem selecionados e sua massa média for calculada, como esse valor deve ser classificado?
 - c. Explique a diferença entre as duas situações.
3. Seja $X_1, \dots, X_n$ uma amostra e seja μ um parâmetro desconhecido. Determine quais expressões são estatísticas:

- a. $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$;
- b. $\max\{X_1, \dots, X_n\}$;
- c. $\bar{X} - \mu$;
- d. $\sum_{i=1}^n (X_i - \bar{X})^2$.

Justifique as respostas.

4. Para estimar a média populacional μ , utiliza-se

$$\hat{\mu} = \bar{X}.$$

Uma amostra apresentou os valores

$$7, \quad 8, \quad 8, \quad 9.$$

- a. Qual é o parâmetro?
 - b. Qual é o estimador?
 - c. Qual é a estimativa obtida?
5. Duas amostras de mesmo tamanho, obtidas da mesma população pelo mesmo procedimento, produziram médias iguais a 12,4 e 13,1.
- a. Por que as duas médias podem ser diferentes?
 - b. O que permanece fixo e o que varia entre as duas amostras?
6. Considere retiradas sucessivas de uma urna com bolas vermelhas e brancas.
- a. Em qual situação, com ou sem reposição, as observações podem ser representadas como i.i.d.?
 - b. Qual condição deixa de ser satisfeita na amostragem sem reposição?
 - c. Se $X_i = 1$ indicar uma bola vermelha e $X_i = 0$ uma bola branca, escreva o modelo Bernoulli para a situação em que as observações são i.i.d. e indique o significado de p .
7. Avalie se a representação por observações i.i.d. parece adequada em cada situação.
- a. Trinta componentes são produzidos sucessivamente por um processo mantido sob condições estáveis. Admita que não haja evidência de dependência entre os resultados de componentes consecutivos.

- b. A temperatura de um mesmo local é registrada a cada minuto durante duas horas.

Em cada caso, discuta separadamente a plausibilidade das hipóteses de distribuições idênticas e de independência.

8. Uma universidade envia um questionário a todos os seus estudantes, mas analisa apenas as respostas daqueles que decidiram participar.

- a. Os respondentes podem ser considerados automaticamente representativos de todos os estudantes? Justifique.
- b. Que aspecto do Processo Gerador de Dados deve ser considerado antes de realizar inferências para toda a população?

9. Considere o modelo

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

em que σ^2 é conhecida e μ é desconhecida.

- a. Qual é o parâmetro desconhecido do modelo?
- b. Qual é o espaço paramétrico usual de μ ?
- c. O que representa a família

$$\mathcal{F} = \{F(\cdot \mid \mu) : \mu \in \mathbb{R}\}?$$

- d. Para um valor fixado de μ , o que a distribuição $F(\cdot \mid \mu)$ descreve?

10. Considere uma função de probabilidade ou densidade conjunta

$$f(\mathbf{x} \mid \theta).$$

- a. Quando essa expressão é considerada como função dos possíveis valores de $\mathbf{X}$, o que permanece fixo?
- b. Depois que a amostra $\mathbf{x}$ é observada, como é definida a função de verossimilhança para θ ?
- c. Na função de verossimilhança, o que permanece fixo e o que varia?
- d. Explique por que $L(\theta; \mathbf{x})$ não deve, em geral, ser interpretada como uma distribuição de probabilidade para θ .

Referências

4 Distribuições Amostrais

4.1 Introdução

No Capítulo ??, o experimento da urna mostrou que diferentes amostras obtidas pelo mesmo mecanismo podem produzir valores distintos para uma mesma estatística. Essa variabilidade entre amostras constitui o ponto de partida para o estudo das distribuições amostrais.

Considere uma amostra aleatória

$$\mathbf{X} = (X_1, \dots, X_n)$$

e uma estatística

$$T = T(\mathbf{X}) = T(X_1, \dots, X_n).$$

Antes da observação dos dados, T é uma variável aleatória. Depois que a amostra observada $\mathbf{x} = (x_1, \dots, x_n)$ é obtida, o valor

$$T(\mathbf{x}) = T(x_1, \dots, x_n)$$

é uma realização dessa variável aleatória.

A **distribuição amostral** descreve probabilisticamente os valores que T pode assumir quando o mecanismo que gera a amostra é repetido. Ela permite estudar a variabilidade de estatísticas como a média, a proporção, a variância, o mínimo, o máximo e outras funções das observações (Ramachandran; Tsokos, 2021, cap. 4, seção 4.1, pp. 147–148; Rice, 2007, cap. 7, seção 7.3).

! Definição — Distribuição amostral

A **distribuição amostral** de uma estatística $T = T(X_1, \dots, X_n)$ é sua distribuição de probabilidade sob o mecanismo que gera a amostra (Casella; Berger, 2011, definição 5.2.1; Ramachandran; Tsokos, 2021, definição 4.1.4, p. 148; Chihara; Hesterberg, 2022, definição 4.1, pp. 78–79).

A distribuição populacional e a distribuição amostral descrevem objetos diferentes. A distribuição populacional caracteriza o comportamento de uma observação X . A distribuição amostral caracteriza o comportamento de uma função de várias observações. Em situações particulares, ambas podem pertencer à mesma família de distribuições, possivelmente com parâmetros diferentes.

Transformações e funções geradoras de momentos permitem obter distribuições amostrais exatas. A Lei dos Grandes Números, o Teorema Central do Limite, o teorema do mapeamento contínuo e o lema de Slutsky, apresentados no Capítulo ??, fornecem as ferramentas para estudar concentração e aproximações assintóticas quando o tamanho amostral aumenta.

Objetivos do capítulo

Ao final deste capítulo, o leitor deverá ser capaz de:

1. interpretar a distribuição amostral como a distribuição de uma estatística sob repetição do mecanismo que gera a amostra;
2. distinguir o modelo i.i.d. da amostragem aleatória simples sem reposição em uma população finita;
3. obter distribuições amostrais por enumeração, transformação, convolução e propriedades de distribuições conhecidas;
4. utilizar propriedades de somas e funções geradoras de momentos para identificar distribuições amostrais exatas;
5. determinar distribuições exatas e aproximações assintóticas para médias, diferenças de médias e proporções amostrais;
6. relacionar a variância amostral às distribuições derivadas do modelo normal;
7. obter distribuições de estatísticas de ordem;
8. aproximar e visualizar distribuições amostrais por simulação.

4.2 Amostra e estatística: recordação

No Capítulo ?? foram estabelecidas as distinções entre amostra aleatória e amostra observada, estatística, estimador e estimativa.

Se

$$\mathbf{X} = (X_1, \dots, X_n)$$

representa a amostra antes da observação dos dados, uma estatística é uma função

$$T = T(\mathbf{X}).$$

Como T é uma variável aleatória, seu valor pode mudar de uma amostra para outra. A distribuição de probabilidade de T é induzida pelo mecanismo que gera a amostra e, por isso, pode mudar quando esse mecanismo muda.

4.3 Dois referenciais para a geração da amostra

Duas estruturas de geração da amostra precisam ser tratadas separadamente: o modelo i.i.d. e a amostragem aleatória simples sem reposição em uma população finita. A distinção evita confundir independência probabilística com aleatorização de um plano amostral.

4.3.1 Amostragem no modelo i.i.d.

No modelo i.i.d., cada observação é gerada independentemente pela mesma distribuição. Esse referencial é apropriado para repetições independentes de um experimento, amostragem com reposição ou modelagem de uma população conceitualmente infinita (Casella; Berger, 2011, seq. 5.1; Ramachandran; Tsokos, 2021, seq. 4.1).

Se $f(x | \theta)$ representa a função de probabilidade ou densidade comum das observações, a independência permite escrever a função de probabilidade ou densidade conjunta da amostra como

$$f_{\mathbf{X}}(\mathbf{x} | \theta) = \prod_{i=1}^n f(x_i | \theta).$$

No Capítulo ??, vimos que, depois de observados os dados $\mathbf{x}$, essa mesma expressão pode ser considerada como função de θ , com $\mathbf{x}$ fixado, originando a função de verossimilhança (Casella; Berger, 2011, seq. 6.3.1; Cox, 2006, seq. 2.1):

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i | \theta).$$

Os dois objetos desempenham papéis diferentes. Para um valor fixado de θ , a distribuição amostral descreve probabilisticamente o comportamento de uma estatística sob repetição do mecanismo que gera a amostra. Na função de verossimilhança, os dados observados permanecem fixos e são comparados diferentes valores de θ . Portanto, distribuição amostral e verossimilhança estão relacionadas ao mesmo modelo probabilístico, mas não representam o mesmo objeto (Cox, 2006, seq. 1.3 e 2.1).

💡 Exemplo — Tempos de vida exponenciais

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\mu),$$

na parametrização pela média, de modo que

$$E(X_i) = \mu.$$

A distribuição exponencial também pode ser parametrizada pela taxa λ . As duas parametrizações estão relacionadas por

$$\lambda = \frac{1}{\mu} \quad \text{ou, equivalentemente,} \quad \mu = \frac{1}{\lambda}.$$

Obtenha:

1. a densidade conjunta da amostra;
2. a probabilidade

$$P(X_1 > 2, \dots, X_n > 2).$$

i Resolução

Para uma observação,

$$f(x \mid \mu) = \frac{1}{\mu} e^{-x/\mu} \mathbf{1}\{x > 0\}.$$

Pela independência,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x} \mid \mu) &= \prod_{i=1}^n f(x_i \mid \mu) \\ &= \mu^{-n} \exp\left(-\frac{1}{\mu} \sum_{i=1}^n x_i\right) \prod_{i=1}^n \mathbf{1}\{x_i > 0\}. \end{aligned}$$

Além disso,

$$\begin{aligned} P(X_1 > 2, \dots, X_n > 2) &= \prod_{i=1}^n P(X_i > 2) \\ &= \left(e^{-2/\mu}\right)^n \\ &= e^{-2n/\mu}. \end{aligned}$$

4.3.2 Amostragem aleatória simples sem reposição

Considere uma população finita formada por N unidades, às quais estão associados os valores fixos

$$a_1, \dots, a_N.$$

O procedimento pode ser representado por n seleções sequenciais sem reposição, em que cada unidade ainda disponível possui a mesma probabilidade de ser escolhida em cada etapa. Essa representação ordenada permite definir as variáveis aleatórias $X_1, \dots, X_n$. As observações possuem a mesma distribuição marginal, mas não são independentes (Cox, 2006, seq. 9.2; Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, seq. 7.3.1).

Defina a média e a variância dessa população finita por

$$\mu_N = \frac{1}{N} \sum_{j=1}^N a_j$$

e

$$\sigma_N^2 = \frac{1}{N} \sum_{j=1}^N (a_j - \mu_N)^2.$$

Para descrever probabilisticamente a amostra, considere J_i como o índice da unidade selecionada na i -ésima posição e defina

$$X_i = a_{J_i}, \quad i = 1, \dots, n.$$

Na amostragem aleatória simples sem reposição,

$$P(J_i = r) = \frac{1}{N}, \quad r = 1, \dots, N.$$

Portanto, cada unidade possui a mesma probabilidade de ocupar qualquer posição da amostra. A variável aleatória X_i registra o valor associado à unidade selecionada nessa posição.

Como J_i é uniforme sobre os índices $1, \dots, N$, a distribuição marginal de X_i corresponde à distribuição dos valores da própria população finita. Para qualquer valor x ,

$$P(X_i = x) = \frac{1}{N} \#\{r : a_r = x\},$$