

Métodos Inferenciais

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa Modelos de Sobrevida e Aplicações.

**Versão Preliminar
- Em Elaboração -**



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro resulta da experiência acumulada no ensino, na orientação de estudantes e no desenvolvimento de pesquisas em modelos de regressão. Somos docentes pesquisadores do Departamento de Estatística e Matemática Aplicada da Universidade Federal do Ceará (DEMA/UFC), com atuação contínua em regressão linear, modelagem estatística e inferência. Integramos o Laboratório de Inovação em Estatística — StatLab/UFC (<https://statlab.quarto.pub/>) e o Grupo de Pesquisa *Modelos de Sobrevivência e Aplicações* do CNPq (<http://dgp.cnpq.br/dgp/espelhogrupo/9639095385610769>), espaços nos quais articulamos ensino, pesquisa e aplicação a problemas reais.

O material tem como base as disciplinas Inferência Estatística I (CC0288), Análise Inferencial (CC0448) e Inferência Estatística (CCPXXX). Ao longo dos anos, consolidamos a convicção de que ensinar regressão exige equilíbrio entre rigor teórico e clareza interpretativa.

O livro desenvolve os conceitos de Inferência Estatística de forma progressiva, enfatizando interpretação e propriedades. A implementação é realizada integralmente no **R** (ou **Python**), utilizado como ambiente de experimentação conceitual e não apenas como ferramenta computacional.

Os fundamentos matemáticos mais densos são apresentados em apêndices específicos, preservando o fluxo didático do texto principal e permitindo diferentes níveis de aprofundamento. Acreditamos que inferência deve ser ensinada como base para tomada de decisão, com atenção às suas suposições, limitações e implicações práticas.

Esperamos que este livro contribua para a formação de profissionais capazes tomar decisões com rigor técnico, pensamento estatístico crítico e responsabilidade analítica.

Identificação da(s) Disciplina(s)

- Curso: Bacharelado em Ciência de Dados e Mestrado em Modelagem e Métodos Quantitativos (PPGMMQ)
- Disciplina: Análise Inferencial (Graduação) e Inferência Estatística (Mestrado)
- Carga Horária: 96 horas (Graduação) e 64 horas (Mestrado)
- Créditos: 6 (Graduação) e 4 (Mestrado)
- Regime: Semestral
- Pré-requisitos: Modelos Probabilísticos (CC0446) (Graduação)
- Período Letivo: 2026.2
- Professor(a): Dr. Manoel Santos-Neto (Graduação) e Dr. Rafael Bráz (Mestrado)

EMENTA

Nível	Ementa
Graduação	Conceitos de população e amostra; parâmetros, estatísticas, estimadores e suas propriedades; distribuições amostrais; métodos de estimação pontual: método dos momentos, máxima verossimilhança e mínimos quadrados; estimação intervalar; testes de hipóteses; testes de homogeneidade e independência.

Nível	Ementa
Mestrado	Conceitos de inferência. Avaliação de estimadores. Princípios da suficiência e completividade. Função de verossimilhança. Estimção pontual: método dos momentos, máxima verossimilhança, mínimos quadrados, minimax e equivariância. Distribuição assintótica dos estimadores. Método delta. Algoritmo EM. Estimção intervalar. Testes de hipóteses. Testes mais poderosos. Teste da razão de verossimilhança. Testes assintóticos. Testes de aderência. Testes de independência.

OBJETIVO GERAL

Apresentar os fundamentos da inferência estatística, capacitando o discente a formular, analisar e interpretar problemas inferenciais em contextos de análise de dados, com ênfase na quantificação da incerteza, validação de modelos e capacidade de generalização.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- compreender a diferença entre população, amostra, parâmetro e estatística;
- interpretar estatísticas como variáveis aleatórias;
- compreender e utilizar distribuições amostrais;
- aplicar métodos de estimção pontual e intervalar;
- formular e testar hipóteses estatísticas de forma adequada;
- interpretar corretamente p-valores, intervalos de confiança e decisões inferenciais;
- analisar criticamente resultados estatísticos obtidos a partir de dados reais.

CONTEÚDO PROGRAMÁTICO

Unidade I – Fundamentos da Inferência Estatística

- Motivação para a inferência: conceitos de população, amostra e parâmetros
- Estatísticas e estimadores como funções da amostra
- Função de verossimilhança: definição e papel central na inferência clássica

Unidade II – Distribuições Amostrais

- Estatísticas como variáveis aleatórias e suas distribuições amostrais
- Distribuição amostral da média e da proporção
- Lei dos Grandes Números
- Teorema Central do Limite

Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados

- Propriedades de pequenas amostras: viés, variância e erro quadrático médio
- Propriedades assintóticas: consistência e eficiência assintótica
- Princípio da Suficiência: definições formais, Critério de Fatoração de Neyman-Fisher e suficiência minimal
- Princípio da Completividade e Unicidade
- Família Exponencial: formas canônicas, posto completo e estatísticas completas e suficientes
- Teorema de Rao-Blackwell e Teorema de Lehmann-Scheffé: construção do Estimador Não-Viesado de Variância Uniformemente Mínima (ENVVUM)

Unidade IV – Métodos de Estimação Pontual

- Método dos momentos e suas aplicações
- Máxima verossimilhança: procedimentos, propriedades de invariância e otimalidade
- Mínimos quadrados: derivação, propriedades e relação com máxima verossimilhança
- Estimadores Minimax e Equivariância: critérios de risco e simetrias (locação e escala)
- Método Delta e Distribuição assintótica dos estimadores
- Algoritmo EM: estimação com dados ausentes ou não observáveis

Unidade V – Estimação Intervalar

- Conceitos e interpretação correta dos intervalos de confiança
- Métodos de construção: Método da Quantidade Pivotal e Inversão de Testes
- Intervalos baseados em aproximações assintóticas (Grandes amostras)

Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos

- Fundamentos: hipóteses nula/alternativa, estatísticas de teste, p-valor e decisões
- Teoria de erros (Tipo I e II) e Poder do teste
- Testes mais poderosos: Lema de Neyman-Pearson e Testes Uniformemente Mais Poderosos
- Teste da razão de verossimilhança e sua versão generalizada
- Análise de Variáveis Categóricas: Testes qui-quadrado, testes de aderência, independência e homogeneidade em tabelas de contingência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, articuladas com atividades práticas computacionais. O conteúdo teórico será constantemente ilustrado por simulações e análises de dados reais, utilizando ferramentas computacionais (R ou Python).

AVALIAÇÃO

A avaliação será contínua e composta por:

Nível	Atividades
Graduação	• Listas obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.
Mestrado	• Listas semanais obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.

A aprovação na disciplina seguirá os critérios estabelecidos pelas normas vigentes da UFC.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados nos trabalhos e atividades:

Nível	CrITÉrios
Graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.
Mestrado	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.

BIBLIOGRAFIA BÁSICA

Nível	Bibliografias
Graduação	1. Bussab, W. O.; Morettin, P. A. <i>Estatística Básica</i> . 6ª ed. São Paulo: Saraiva, 2010.2. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. New York: Duxbury Press, 2001.3. Casella, G.; Berger, R. L. <i>Inferência Estatística</i> . Tradução da 2ª edição. São Paulo: Cengage Learning, 2011.
Mestrado	1. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.2. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Coleção Matemática Aplicada. Rio de Janeiro: SBM, 2001.3. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. New York: Duxbury Press, 2001.

BIBLIOGRAFIA COMPLEMENTAR

Nível	Bibliografias
Graduação	1. Devore, J. L. <i>Probabilidade e Estatística para Engenharia e Ciências</i> . São Paulo: Thomson, 2006.2. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i> . 3rd ed. New York: McGraw-Hill, 1974.3. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Rio de Janeiro: SBM, 2001.4. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.5. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i> . New York: John Wiley, 1988.

Nível	Bibliografias
Mestrado	1. Casella, G.; Berger, R. L. <i>Inferência Estatística</i>. Tradução da 2^a edição norte-americana. São Paulo: Cengage Learning, 2001.2. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i>. New York: John Wiley, 1988.3. Lehmann, E. L.; Casella, G. <i>Theory of Point Estimation</i>. 2nd ed. New York: Springer, 2003.4. Lehmann, E. L.; Romano, J. P. <i>Testing Statistical Hypotheses</i>. 3rd ed. New York: Springer, 2010.5. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i>. 3rd ed. New York: McGraw-Hill, 1974.6. Rohatgi, V. K. <i>Statistical Inference</i>. New York: Dover, 2003.7. Shao, J. <i>Mathematical Statistics</i>. 2nd ed. New York: Springer, 2004.

1 Preliminares

Neste capítulo iremos apresentar parte da base necessária para o bom desenvolvimento da disciplina.

1.1 Alguns resultados matemáticos importantes

1.1.1 Soma de Potências e a Fórmula de Faulhaber

O estudo de somatórios é fundamental em diversas áreas da matemática, especialmente em Estatística, Análise Numérica e Ciência de Dados. Neste e-book, exploramos uma ferramenta poderosa: a Fórmula de Faulhaber, que permite calcular somas de potências de forma exata e eficiente.

Considere o seguinte problema:

$$1 + 2 + \cdots + 99 + 100.$$

Somar termo a termo pode ser trabalhoso. No entanto, existe uma fórmula fechada:

$$\sum_{i=1}^n i = \frac{n(n+1)}{2}.$$

Essa expressão mostra que podemos substituir uma soma por uma função simples.

Algumas somas importantes:

$$\sum_{k=1}^n k = \frac{n(n+1)}{2}$$

$$\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}$$

$$\sum_{k=1}^n k^3 = \left(\frac{n(n+1)}{2} \right)^2$$

Observe que todas resultam em polinômios em n . Podemos observar que:

- Soma de grau 1 $\rightarrow$ polinômio grau 2;
- Soma de grau 2 $\rightarrow$ polinômio grau 3;
- Soma de grau 3 $\rightarrow$ polinômio grau 4.

Isso sugere um padrão geral.

A fórmula geral para a soma de potências é:

$$\sum_{k=1}^n k^p = \frac{1}{p+1} \sum_{r=0}^p \binom{p+1}{r} B_r n^{p+1-r},$$

em que B_r são os números de [Bernoulli](#).

Essa fórmula mostra que qualquer soma desse tipo pode ser escrita como um polinômio.

1.1.2 Coeficiente Binomial

O coeficiente binomial é um dos conceitos mais importantes da Matemática Discreta, com aplicações em Estatística, Probabilidade, Combinatória e Ciência de Dados.

Ele responde a uma pergunta fundamental:

De quantas formas podemos escolher k elementos de um conjunto com n elementos?

O coeficiente binomial é definido como o número de subconjuntos de tamanho k que podem ser formados a partir de um conjunto com n elementos:

$$\binom{n}{k}.$$

O coeficiente binomial pode ser calculado por:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!},$$

em que $n!$ é o fatorial de n .

Essa fórmula permite cálculo direto e eficiente. A ideia por trás da fórmula:

- $n!$ $\rightarrow$ todas as permutações possíveis;
- $k!$ $\rightarrow$ remove a ordem dos elementos escolhidos;

- $(n - k)! \rightarrow$ remove a ordem dos elementos não escolhidos.

Resultado: número de combinações (ordem não importa).

! Exemplo

Escolher 2 elementos de um conjunto com 4:

$$\binom{4}{2} = 6.$$

1.1.2.1 Propriedades Importantes

1. Simetria

$$\binom{n}{k} = \binom{n}{n-k}.$$

Escolher k elementos é equivalente a excluir $n - k$.

2. Relação de Pascal

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}.$$

Essa propriedade é a base do Triângulo de Pascal. Os coeficientes binomiais podem ser organizados em uma estrutura triangular:

$$\begin{array}{ccccccc} & & & & 1 & & \\ & & & 1 & & 1 & \\ & & 1 & & 2 & & 1 \\ & 1 & & 3 & & 3 & & 1 \\ 1 & & 4 & & 6 & & 4 & & 1 \end{array}$$

Cada número é a soma dos dois acima. Os coeficientes aparecem na expansão de:

$$(x + y)^n = \sum_{k=0}^n \binom{n}{k} x^{n-k} y^k.$$

! Exemplo

$$(1+x)^4 = 1 + 4x + 6x^2 + 4x^3 + x^4.$$

1.1.3 Progressão Geométrica

A Progressão Geométrica (PG) é uma sequência numérica amplamente utilizada em Matemática, Estatística, Economia e Ciências Naturais. Ela descreve fenômenos que crescem ou decrescem de forma multiplicativa.

! Definição:

Uma PG é uma sequência em que cada termo, a partir do segundo, é obtido multiplicando o termo anterior por uma constante chamada razão.

$$a_n = a_1 \cdot q^{n-1},$$

em que a_1 é o primeiro termo, q é a razão e n é a posição do termo.

O termo geral de uma PG é dado por:

$$a_n = a_1 \cdot q^{n-1}.$$

Isso permite calcular qualquer termo diretamente.

1.1.3.1 Soma dos n primeiros termos ($q \neq 1$)

$$S_n = a_1 \cdot \frac{q^n - 1}{q - 1}.$$

ou

$$S_n = a_1 \cdot \frac{1 - q^n}{1 - q}.$$

1.1.3.2 Soma infinita ($|q| < 1$)

Quando a PG é convergente:

$$S = \frac{a_1}{1 - q}.$$

1.1.4 Série de Taylor

A Série de Taylor é uma ferramenta fundamental da Análise Matemática que permite representar funções como somas infinitas de potências.

 Definição:

A expansão em série de Taylor de uma função f em torno de $x = 0$ (Série de Maclaurin) é dada por:

$$f(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} x^k,$$

em que $f^{(k)}(0)$ representa a k -ésima derivada de f avaliada em 0.

1.1.4.1 Caso especial: Função exponencial

Um dos casos mais importantes é a expansão da função exponencial:

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}.$$

Essa igualdade é válida para todo $x \in \mathbb{R}$.

1.2 Função de Distribuição

Sendo X uma variável aleatória em $(\Omega, \mathcal{F}, \mathcal{P})$, sua função de distribuição é definida por:

$$F_X(x) = \Pr(X \leq x),$$

com x percorrendo todos os reais.

O conhecimento da função de distribuição permite obter qualquer informação sobre a variável. Importante destacar que, mesmo que a variável só assuma valores num subconjunto dos reais, a função de distribuição é definida em toda reta.

Uma função de distribuição de uma variável aleatória X em $(\Omega, \mathcal{F}, \mathcal{P})$ obedece às seguintes propriedades:

P1) $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.

P2) F é contínua à direita.

P3) F é não decrescente, isto é, $F_X(x) \leq F_X(y)$ sempre que $x \leq y, \forall x, y \in \mathbb{R}$.

1.3 Variável Aleatória Discreta e função de Probabilidade

Uma variável aleatória é classificada como *discreta*, se assume somente um número enumerável de valores (finito ou infinito). A função de probabilidade de uma variável aleatória discreta é a função que atribui probabilidade a cada um dos possíveis valores assumidos pela variável. Isto é, sendo X uma variável com valores $x_1, x_2, \dots, x_n, \dots$ temos para $i = 1, 2, \dots$

$$p(x_i) = \Pr(X = x_i) = \Pr(\{\omega \in \Omega : X(\omega) = x_i\}).$$

A função de probabilidade de X em $(\Omega, \mathcal{F}, \mathcal{P})$ satisfaz:

$$\text{P1)} \quad 0 \leq p(x_i) \leq 1, \forall i = 1, 2, \dots,$$

$$\text{P2)} \quad \sum_i p(x_i) = 1,$$

com a soma percorrendo todos os possíveis valores (eventualmente infinitos).

1.4 Variável Aleatória Contínua e função Densidade

Uma variável aleatória X em $(\Omega, \mathcal{F}, \mathcal{P})$, com função de distribuição F , será classificada como contínua, se existir uma função f tal que:

$$F_X(x) = \int_{-\infty}^x f_X(\omega) d\omega, \quad \text{para todo } x \in \mathbb{R}.$$

A função f é denominada *função densidade*.

A função densidade de X em $(\Omega, \mathcal{F}, \mathcal{P})$ satisfaz:

$$\text{P1)} \quad f(x) \geq 0, \forall x \in \mathbb{R}.$$

$$\text{P2)} \quad \int_{-\infty}^{+\infty} f_X(\omega) d\omega = 1.$$

1.5 Independência

Ver [Link!](#)

1.6 Valor Esperado

Ver [Link!](#)

1.7 Variância

Ver [Link!](#)

1.8 Covariância

O resultado a seguir mostra que a esperança de um produto de variáveis aleatórias independentes é igual ao produto de suas esperanças.

i Proposição 1:

Se X e Y são independentes, então, para quaisquer funções h e g ,

$$E[g(X)h(Y)] = E[g(X)]E[h(X)].$$

Demonstração: Suponha que X e Y sejam variáveis aleatórias conjuntamente contínuas com função densidade conjunta $f(x, y)$. Então,

$$\begin{aligned} E[g(X)h(Y)] &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x)h(y)f(x, y)dxdy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x)h(y)f(x)f(y)dxdy \\ &= \int_{-\infty}^{+\infty} g(x)f(x)dx \int_{-\infty}^{+\infty} h(y)f(y)dy \\ &= E[g(X)]E[h(Y)]. \end{aligned}$$

A demonstração para o caso discreto pode ser feita de maneira similar.

! Definição 1:

A covariância entre X e Y , representada como $Cov(X, Y)$, é definida como

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Desenvolvendo o lado direito da definição acima, temos que

$$\begin{aligned} Cov(X, Y) &= E[\text{_____} - \text{_____} - \text{_____} + \text{_____}] \\ &= \text{_____} - \text{_____} - \text{_____} + \text{_____} \\ &= E[XY] - E[X]E[Y]. \end{aligned}$$

Note que, se X e Y são independentes, então, pela Proposição 1, $Cov(X, Y) = 0$. No entanto, o inverso não é verdade.

i Proposição 2:

- i) $Cov(X, Y) = Cov(Y, X)$;
- ii) $Cov(X, X) = Var(X)$;
- iii) $Cov(aX, Y) = aCov(X, Y)$.
- iv) $Cov\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m Cov(X_i, Y_j)$.

Fazendo $Y_j = X_j$ e considerando as propriedades (ii) e (iv) da Proposição 2, temos que

$$\begin{aligned} Var\left(\sum_{i=1}^n X_i\right) &= Cov\left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\right) \\ &= \sum_{i=1}^n \sum_{j=1}^n Cov(X_i, X_j) \\ &= \sum_{i=1}^n Var(X_i) + \sum_{i \neq j} Cov(X_i, X_j) \\ &= \sum_{i=1}^n Var(X_i) + 2 \sum_{i < j} Cov(X_i, X_j). \end{aligned}$$

1.9 Função Geradora de Momentos

Ver [Link!](#)

1.10 Tipos de Convergência

Ver [Link!](#)

1.11 Método Delta

Uma questão natural que surge frequentemente é a seguinte: suponha que temos uma sequência de variáveis aleatórias X_n que converge em distribuição para uma distribuição Normal. Podemos então caracterizar a distribuição limite de $g(X_n)$, em que g é uma função suave (é uma função que possui derivadas de todas as ordens em todo o seu domínio)?

Podemos resolver isso utilizando o Teorema do Mapeamento Contínuo (ou teorema de Mann-Wald) (de fato, essa é a base da demonstração que apresentaremos).

Método Delta

Suponha que

$$\frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1),$$

e que g é uma função continuamente diferenciável tal que $g'(\mu) \neq 0$. Então,

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{\sigma} \xrightarrow{d} N(0, [g'(\mu)]^2).$$

Demonstração

A ideia básica é usar a aproximação de Taylor. Sabemos que

$$g(X_n) \approx g(\mu) + g'(\mu)(X_n - \mu),$$

logo,

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{\sigma} \approx g'(\mu) \frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} N(0, [g'(\mu)]^2).$$

Para sermos rigorosos, precisamos considerar os termos de resto. Aplicando o Teorema de Taylor de forma rigorosa, obtemos:

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{\sigma} = g'(\tilde{\mu}) \frac{\sqrt{n}(X_n - \mu)}{\sigma},$$

em que $\tilde{\mu}$ está entre μ e $\bar{X}_n$.

Sabemos, pela Lei Fraca dos Grandes Números (LGN), que $\bar{X}_n \xrightarrow{p} \mu$, e portanto $\tilde{\mu} \xrightarrow{p} \mu$. Como g é continuamente diferenciável, pelo Teorema do Mapeamento Contínuo,

$$g'(\tilde{\mu}) \xrightarrow{p} g'(\mu).$$

Agora, aplicando o Teorema de Slutsky, temos:

$$g'(\tilde{\mu}) \frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} g'(\mu) N(0, 1) \stackrel{d}{=} N(0, [g'(\mu)]^2).$$

Exemplo

Suponha que $X_1, \dots, X_n \sim P$, com $E[X] = \mu$ e $\text{Var}(X) = \sigma^2 < \infty$.

Suponha que estamos interessados na distribuição de

$$Y_n = \exp(\bar{X}_n).$$

Como $g'(\mu) = \exp(\mu)$, aplicando o Método Delta, obtemos:

$$\sqrt{n} \left(\frac{\exp(\bar{X}_n) - \exp(\mu)}{\sigma} \right) \xrightarrow{d} N(0, \exp(2\mu)).$$

1.12 Algumas das principais distribuições de probabilidade

1.12.1 Distribuições discretas

Distribuição de Bernoulli

- Seja $X = \{0, 1\}$, onde $x \in X$ representa sucesso ou fracasso, isto é, um experimento binário.

Exemplos:

- Lançamento de moeda (cara = 0, coroa = 1)
- Manufatura: defeituoso / não defeituoso

- Medicina: doença / ausência de doença
- Esporte: vitória / derrota (assumindo que não há empate)

- Dizemos que:

$$X \sim \text{Ber}(\theta),$$

quando X segue uma distribuição de Bernoulli com probabilidade de sucesso θ .

- O parâmetro $\theta \in [0, 1]$ representa a probabilidade de sucesso:
 - No lançamento de moeda, a moeda é justa se $\theta = 0,5$;
 - Em medicina, deseja-se que θ seja o menor possível (baixa probabilidade de doença).
- A função de probabilidade é dada por:

$$P(X = x \mid \theta) = p(x \mid \theta) = \theta^x (1 - \theta)^{1-x}.$$

- Pode parecer estranho multiplicar θ por $(1 - \theta)$, mas note que apenas um dos termos será diferente de 1:
 - * Se $x = 1$, então $p(1) = \theta$;
 - * Se $x = 0$, então $p(0) = 1 - \theta$.

- Momentos:

$$E[X] = \theta, \quad \text{Var}(X) = \theta(1 - \theta).$$

- Se $X \sim \text{Ber}(0,5)$, então a variável aleatória

$$Y = 2X - 1,$$

segue a **distribuição de Rademacher**. Nesse caso, Y assume valores em: $Y \in \{-1, +1\}$.

- Essa distribuição é bastante útil para modelar **caminhadas aleatórias (random walks)**, nas quais:
 - $Y = +1$ representa um passo para frente;
 - $Y = -1$ representa um passo para trás.
- Observe que não é permitido permanecer parado ($Y = 0$ não é possível).

Distribuição Binomial

- Considere n variáveis aleatórias binárias independentes:

$$X = (X_1, X_2, \dots, X_n), \quad \text{com } X_i \stackrel{iid}{\sim} \text{Ber}(\theta).$$

- Definimos o número de sucessos como:

$$M = \sum_{i=1}^n X_i.$$

- O espaço amostral de M é:

$$\mathcal{M} = \{0, 1, 2, \dots, n\}.$$

- Dizemos que:

$$M \sim \text{Bin}(n, \theta).$$

- A função de probabilidade é:

$$P(M = m \mid \theta) = \binom{n}{m} \theta^m (1 - \theta)^{n-m},$$

que representa a probabilidade de obter m sucessos em n ensaios.

- Momentos:

$$E[M] = n\theta, \quad \text{Var}(M) = n\theta(1 - \theta).$$

- **Propriedade da soma de binomiais:**

Se $M_1 \sim \text{Bin}(n_1, \theta)$ e $M_2 \sim \text{Bin}(n_2, \theta)$ são independentes, então:

$$M_1 + M_2 \sim \text{Bin}(n_1 + n_2, \theta).$$

Distribuição Multinomial

- A **distribuição multinomial** é uma generalização da distribuição binomial para experimentos independentes com mais de dois resultados possíveis.
- Seja $\mathbf{X} = (X_1, \dots, X_m)$ um vetor aleatório, e $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ o vetor de probabilidades, com:

$$\sum_{i=1}^m \theta_i = 1, \quad \theta_i \geq 0.$$

- Considere n repetições independentes do experimento, e seja k_i o número de ocorrências da categoria i , para $i = 1, \dots, m$. Então:

$$k_1 + k_2 + \dots + k_m = n.$$

- Dizemos que:

$$\mathbf{X} \sim \text{Mult}(n, \theta).$$

- A função de probabilidade é:

$$P(\mathbf{X} = (k_1, k_2, \dots, k_m)) = \binom{n}{k_1, k_2, \dots, k_m} \prod_{i=1}^m \theta_i^{k_i},$$

onde

$$\binom{n}{k_1, k_2, \dots, k_m} = \frac{n!}{k_1! k_2! \dots k_m!}.$$

- Interpretação: representa a probabilidade de observar k_1 ocorrências da categoria 1, k_2 da categoria 2, ..., e k_m da categoria m , em n experimentos independentes.

Distribuição Uniforme Discreta

- Seja $X = \{a, a + 1, \dots, b\}$, onde o espaço amostral é um intervalo de inteiros de a até b .
- Dizemos que:

$$X \sim \text{U}(a, b),$$

quando X segue uma distribuição uniforme discreta.

- A função de probabilidade é:

$$P(X = k \mid a, b) = \frac{1}{b - a + 1}, \quad k \in \{a, \dots, b\}.$$

- Momentos:

$$E[X] = \frac{a + b}{2},$$

que pode não ser um número inteiro,

$$\text{Var}(X) = \frac{(b - a + 1)^2 - 1}{12},$$

que também pode não ser um número inteiro.

Distribuição de Poisson

- Seja $\mathbb{Z}_+ = \{0, 1, 2, \dots\}$, o conjunto dos inteiros não negativos (de 0 até ∞).
- Dizemos que:

$$X \sim \text{Poi}(\lambda),$$

quando X segue uma distribuição de Poisson com taxa $\lambda > 0$.

- A função de probabilidade é:

$$P(X = k \mid \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \mathbb{Z}_+,$$

que representa a probabilidade de ocorrência de k eventos em um intervalo, dado uma taxa média λ .

- Momentos:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

- **Propriedade da soma de Poisson:**

Se $X_1 \sim \text{Poi}(\lambda_1)$ e $X_2 \sim \text{Poi}(\lambda_2)$ são independentes, então:

$$X_1 + X_2 \sim \text{Poi}(\lambda_1 + \lambda_2).$$

Distribuição Binomial Negativa

- Na distribuição binomial $\text{Bin}(n, \theta)$, a probabilidade $P(M = m \mid \theta)$ representa o número de sucessos em n ensaios.
- Já a **distribuição binomial negativa** modela o número de fracassos antes de ocorrer o r -ésimo sucesso.
- Dizemos que:

$$X \sim \text{BN}(r, \theta),$$

em que r é o número fixo de sucessos e θ é a probabilidade de sucesso em cada ensaio.

- A função de probabilidade é:

$$P(X = n \mid r, \theta) = \binom{n+r-1}{n} (1-\theta)^n \theta^r,$$

em que $n = 0, 1, 2, \dots$ representa o número de fracassos antes do r -ésimo sucesso.

Distribuição Geométrica

- Quando $r = 1$, a distribuição binomial negativa se reduz à **distribuição geométrica**:

$$X \sim \text{Geom}(\theta),$$

com função de probabilidade:

$$P(X = n) = (1 - \theta)^n \theta.$$

- Nesse caso, X representa o número de fracassos antes do primeiro sucesso.

1.13 Propriedade das Distribuições Contínuas: Probabilidade Pontual Nula

- Se uma variável aleatória X segue uma distribuição contínua, então a probabilidade de assumir um valor específico é sempre zero:

$$P(X = x \mid \theta) = 0, \quad \forall x.$$

- Exemplos:

$$P(X = 1) = P(X = 0) = P(X = -2) = P(X = e) = P(X = \pi) = 0.$$

- Isso ocorre porque o espaço amostral de uma variável contínua possui infinitos valores possíveis. Assim, a probabilidade de observar exatamente um único ponto é nula.

Consequência Importante

- Em distribuições contínuas, desigualdades estritas e não estritas são equivalentes:

$$P(X \leq a) = P(X < a).$$

- De fato:

$$P(X \leq a) = P(X < a \text{ ou } X = a)$$

$$= P(X < a) + P(X = a) \quad (\text{pela aditividade da probabilidade})$$

$$= P(X < a) + 0 = P(X < a).$$

Observação Importante

- Um fato que pode parecer contraintuitivo:

Embora

$$P(X = a) = 0,$$

isso **não significa** que o evento $X = a$ seja impossível.

- Significa apenas que ele tem probabilidade nula; o que é uma característica natural de distribuições contínuas.

1.13.1 Distribuições Contínuas

Distribuição Uniforme Contínua

- Seja $X \in [a, b]$, onde o espaço amostral é um intervalo de números reais de a até b .
- Dizemos que:

$$X \sim U(a, b),$$

quando X segue uma distribuição uniforme contínua.

- A função densidade de probabilidade é:

$$f(x; a, b) = \begin{cases} 0, & x < a, \\ \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & x > b. \end{cases}$$

- Interpretação: todos os valores no intervalo $[a, b]$ são igualmente prováveis (em termos de densidade).
- Momentos:

$$E[X] = \frac{a + b}{2},$$

$$\text{Var}(X) = \frac{(b - a)^2}{12}.$$

Distribuição Exponencial

- Seja $X \in [0, \infty)$, onde o espaço amostral é o conjunto dos números reais não negativos.
- Dizemos que:

$$X \sim \text{Exp}(\lambda),$$

quando X segue uma distribuição exponencial com taxa $\lambda > 0$.

- A função densidade de probabilidade pode ser escrita como:

$$f(x | \lambda) = \lambda e^{-\lambda x} \mathbf{1}_{\{x \geq 0\}}, \quad x \in \mathbb{R},$$

em que $\mathbf{1}_{\{x \geq 0\}}$ é a função indicadora do suporte.

- Momentos:

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

Exercícios

- 1) Use o resultado que diz que, para uma variável aleatória não negativa Y ,

$$E(Y) = \int_0^{\infty} \Pr(Y > t) dt,$$

para mostrar, que para uma variável aleatória não negativa X ,

$$E(X^n) = \int_0^{\infty} n x^{n-1} \Pr(X > x) dx.$$

Dica: Comece com

$$E(X^n) = \int_0^{\infty} \Pr(X^n > t) dt,$$

e faça a mudança de variável $t = x^n$.

2. Mostre que $\Gamma(1/2) = \sqrt{\pi}$.
3. Seja X uma variável aleatória contínua com função de distribuição F . Defina a variável aleatória Y como $Y = F_X(x)$. Mostre que Y é uniformemente distribuída no intervalo $(0, 1)$.

4. Suponha que tentativas independentes com mesma probabilidade de sucesso p . $0 < p < 1$, sejam realizadas até que se acumule um total de r sucessos. Se X for igual ao número de tentativas necessárias, então

$$\Pr(X = x) = \binom{n-1}{r-1} p^r (1-p)^{n-r}, \quad x = r, r+1, \dots$$

Encontre $E(X)$ e $Var(X)$.

5. Seja X uma variável aleatória tal que

$$E(X^n) = \begin{cases} \frac{n!}{(n/2)!}, & \text{se } n \text{ for par;} \\ 0 & \text{caso contrário.} \end{cases}$$

Determine a função geradora de momentos de X e identifique sua distribuição.

2 Fundamentos da Inferência Estatística

Neste capítulo, iniciamos a primeira parte sobre inferência estatística aprendendo um pouco sobre amostragem. Os conceitos por trás da amostragem são a base para intervalos de confiança e testes de hipóteses, por exemplo. Além disso, veremos que ferramentas já aprendidas durante o curso de Ciência de Dados, em particular visualização de dados e manipulação (organização) de dados, são importantes no desenvolvimento do seu entendimento. Esperamos que os conceitos apresentados ao longo deste texto se articulam e se acumulam, culminando na capacidade de “contar sua história com dados”.

2.1 Processo Gerador de Dados (PGD)

O PGD é o mecanismo teórico, físico ou biológico que produz os dados que observamos. Imagine que o mundo é uma “caixa preta” que segue certas regras (leis da física, comportamento humano, algoritmos de mercado), portanto o PGD são essas regras em funcionamento.

Realidade vs. Observação

- O PGD (A causa): É a distribuição de probabilidade teórica e os parâmetros fixos (mas desconhecidos) que regem um fenômeno.
- Os Dados (O Efeito): É a amostra específica que coletamos. É apenas uma realização de infinitas possibilidades que o PGD poderia ter gerado.

Representação Matemática

O PGD pode ser definido pela distribuição de probabilidade conjunta desconhecida $P(X, Y)$ (ou simplesmente $P(Z)$).

Dizemos que nossa amostra $\mathcal{D} = \{z_1, z_2, \dots, z_n\}$ é composta por variáveis aleatórias independentes e identicamente distribuídas (i.i.d) retiradas desse processo:

$$z_i \sim P(Z).$$

Nesta visão, o PGD é o “mecanismo” que dita:

1. A Região de Suporte: Quais valores são possíveis de ocorrer?
2. A Densidade: Com que frequência cada valor ocorre?
3. As Dependências: Como a ocorrência de X altera a probabilidade de Y ?

2.2 Pacote Necessários

Neste capítulo iremos utilizar os pacotes R `tidyverse` (Wickham, 2021) e `moderndive` (Ismay; Kim, 2021). Por exemplo, para instalar o pacote basta usar `install.packages("tidyverse")` e podemos carregar o pacote por meio do comando `library(tidyverse)`. São carregados, de uma só vez, os seguintes pacotes amplamente utilizados em ciência de dados:

- `ggplot2` para visualização de dados;
- `dplyr` para manipulação de dados;
- `tidyr` para converter dados para o formato “tidy”;
- `readr` para importar dados de planilhas para o R,

além dos pacotes mais avançados `purrr`, `tibble`, `stringr` e `forcats`.

```
library(tidyverse)
library(moderndive)
```

2.3 Experimento em Sala de Aula

Iremos realizar o seguinte experimento em sala de aula:

1. Organização
 - A turma é dividida em grupos independentes (por exemplo, 20 grupos).
 - Cada grupo realiza uma única amostragem.
2. Protocolo experimental (por grupo)
 - A urna é misturada cuidadosamente, garantindo aleatoriedade.
 - O grupo retira uma amostra de tamanho fixo n (por exemplo, $n = 50$) sem reposição durante a retirada.
 - As bolas retiradas são observadas e classificadas por cor.

- O grupo registra:
 - R : o número de bolas vermelhas na amostra;
 - $\hat{p} = R/n$: proporção amostral de bolas vermelhas.
- Todas as bolas são devolvidas à urna.
- A urna é novamente misturada antes da próxima amostragem.

Cada grupo deve atuar de forma independente, sem acesso aos resultados dos demais.

3. Coleta e organização dos dados

- Cada grupo fornece sua estimativa de $\hat{p}$.
- O conjunto de estimativas é reunido em uma tabela ou planilha.
- As proporções são representadas graficamente por meio de um histograma.

Esse histograma representa a distribuição amostral da proporção para um tamanho de amostra fixo n .

Verificação de aprendizagem

1. Por que foi importante misturar a tigela antes de retirarmos as bolas?
2. Por que os 20 grupos de amigos não obtiveram todos o mesmo número de bolas vermelhas entre as 50 retiradas e, conseqüentemente, proporções diferentes de bolas vermelhas?

2.4 Experimento Virtual

No pacote `moderndive` existe um *data frame* chamado `bowl`. As linhas de `bowl` correspondem exatamente ao conteúdo da urna real apresentada em sala de aula.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
```

```

5      5 white
6      6 white
7      7 red
8      8 white
9      9 red
10     10 white
# i 2,390 more rows

```

Observe que `bowl` possui 2400 linhas, o que nos indica que a urna contém 2400 bolas de mesmo tamanho. A primeira variável, `ball_ID`, é usada como uma variável de identificação, conforme discutido em sala de aula, nenhuma das bolas da urna real possui números marcados. A segunda variável, `color`, indica se uma determinada bola virtual é **vermelha** ou **branca**. Visualize o conteúdo de `bowl` no **visualizador de dados do RStudio** e percorra as linhas para se convencer de que `bowl` é, de fato, um **análogo virtual** da urna real apresentada em sala.

Agora precisamos de um **análogo virtual da pá** para gerar **amostras virtuais de 50 bolas**. Para isso, vamos utilizar a função `rep_sample_n()`, incluída no pacote `moderndive`. Essa função permite realizar **amostragens repetidas (ou replicadas)** de tamanho (`n`).

```

set.seed(2026) #fixando semente
pa_virtual <- bowl %>%
rep_sample_n(size = 50)

pa_virtual

```

```

# A tibble: 50 x 3
# Groups:   replicate [1]
  replicate ball_ID color
    <int>    <int> <chr>
1         1     733 white
2         1     993 red
3         1    2342 red
4         1    1647 white
5         1    1883 red
6         1     164 red
7         1    1200 red
8         1     389 white
9         1     287 white
10        1    2362 red
# i 40 more rows

```

A variável `ball_ID` identifica quais das 2400 bolas do objeto `bowl` foram incluídas na nossa amostra de 50 bolas, enquanto `color` indica a cor de cada bola. No entanto, o que indica a variável `replicate`?

No caso de `pa_virtual`, a variável `replicate` é igual a 1 em todas as 50 linhas. Isso nos informa que essas 50 linhas correspondem à nossa primeira amostra. Veremos em breve que, quando realizarmos 20 amostragens virtuais, a variável `replicate` assumirá valores entre 1 e 20.

Vamos agora calcular a **proporção de bolas vermelhas** em nossa amostra virtual utilizando os verbos de manipulação de dados do `dplyr`. Primeiro, para cada uma das 50 bolas amostradas, vamos identificar se ela é vermelha ou não, utilizando um teste de igualdade com `==`. Em seguida, criaremos uma nova variável booleana `is_red` usando a função `mutate()`:

```
pa_virtual <- pa_virtual %>%  
mutate(is_red = (color == "red"))
```

```
pa_virtual
```

```
# A tibble: 50 x 4  
# Groups:   replicate [1]  
  replicate ball_ID color is_red  
    <int>    <int> <chr> <lgl>  
1         1      733 white FALSE  
2         1      993 red   TRUE  
3         1     2342 red   TRUE  
4         1     1647 white FALSE  
5         1     1883 red   TRUE  
6         1      164 red   TRUE  
7         1     1200 red   TRUE  
8         1      389 white FALSE  
9         1      287 white FALSE  
10        1     2362 red   TRUE  
# i 40 more rows
```

Observe que, para cada linha em que `color == "red"`, é retornado o valor lógico (booleano) `TRUE`, e para cada linha em que `color` não é igual a `"red"`, é retornado o valor lógico `FALSE`.

Em seguida, vamos calcular o número de bolas vermelhas, dentre as 50, utilizando a função `summarize()`. Note que `summarize()` recebe um *data frame* com várias linhas e retorna um *data frame* com **uma única linha**, contendo estatísticas-resumo, como `mean()` ou `median()`. Neste caso, utilizaremos a função `sum()`:

```
n_red <- pa_virtual %>%
mutate(is_red = (color == "red")) %>%
summarize(num_red = sum(is_red))

n_red
```

```
# A tibble: 1 x 2
  replicate num_red
    <int>     <int>
1         1      16
```

Por que isso funciona? Porque o R trata **TRUE** como o número 1 e **FALSE** como o número 0. Assim, somar valores **TRUE** e **FALSE** é equivalente a somar 1's e 0's. Ao final, essa operação conta o número de bolas para as quais a variável `color` é igual a “red”. No nosso caso, XX das 50 bolas eram vermelhas. No entanto, você pode ter obtido um número diferente de bolas vermelhas devido ao caráter aleatório da amostragem virtual.

Por fim, vamos calcular a proporção das 50 bolas amostradas que são vermelhas, dividindo `num_red` por 50:

```
n_prop_red <- pa_virtual %>%
mutate(is_red = color == "red") %>%
summarize(num_red = sum(is_red)) %>%
mutate(prop_red = num_red / 50)

n_prop_red
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
    <int>     <int>     <dbl>
1         1      16      0.32
```

Em outras palavras, 16 das bolas dessa amostra virtual eram vermelhas. Vamos tornar esse código um pouco mais **compacto e conciso**, combinando as etapas de `mutate()` e `summarize()` da seguinte forma:

```
n_prop_red <- pa_virtual %>%
summarize(num_red = sum(color == "red")) %>%
mutate(prop_red = num_red / 50)

n_prop_red
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
  <int>    <int>    <dbl>
1         1      16     0.32
```

Ótimo! 16 das 50 bolas da pá virtual eram vermelhas! Assim, com base nessa amostra específica de 50 bolas, nossa estimativa da proporção de bolas vermelhas na urna é 0.32. Porém, lembre-se da atividade de amostragem realizada em sala de aula: se repetirmos essa amostragem, não necessariamente obteremos novamente o valor de 0.32. É provável que haja alguma variação. De fato, nossos 20 grupos de amigos calcularam 20 proporções desse tipo, cuja distribuição visualizamos em sala de aula, e vimos que essas estimativas variaram.

Vamos agora realizar o **análogo virtual** de ter 20 grupos de estudantes usando a pá de amostragem!

Lembre-se de que, no exercício de amostragem realizada em sala de aula, tivemos **20 grupos de estudantes**, cada um utilizando a pá, o que resultou em **20 amostras de tamanho 50**. Em seguida, usamos essas 20 amostras para calcular **20 proporções**. Em outras palavras, **repetimos/replicamos o uso da pá 20 vezes**.

Podemos realizar essa amostragem repetida/replicada de forma virtual utilizando novamente a função `rep_sample_n()`, mas agora adicionando o argumento `reps = 20`. Isso indica ao R que desejamos repetir a amostragem 20 vezes.

Vamos salvar esses resultados em um **data frame** chamado `virtual_samples`. Embora apresentemos a seguir uma prévia das primeiras 10 linhas de `virtual_samples`, recomendamos fortemente que você explore todo o seu conteúdo utilizando o visualizador de planilhas do RStudio, executando o comando `View(virtual_samples)`.

```
set.seed(2026)
amostra_virtual <- bowl %>%
  rep_sample_n(size = 50, reps = 20)

amostra_virtual
```

```
# A tibble: 1,000 x 3
# Groups:   replicate [20]
  replicate ball_ID color
  <int>    <int> <chr>
1         1      733 white
2         1      993 red
3         1     2342 red
4         1     1647 white
5         1     1883 red
```

```

6          1      164 red
7          1     1200 red
8          1      389 white
9          1      287 white
10         1     2362 red
# i 990 more rows

```

Observe, no visualizador de planilhas, que as primeiras 50 linhas da variável `replicate` são iguais a 1, enquanto as 50 linhas seguintes de `replicate` são iguais a 2. Isso nos indica que as primeiras 50 linhas correspondem à primeira amostra de 50 bolas, enquanto as próximas 50 linhas correspondem à segunda amostra de 50 bolas. Esse padrão se repete para todas as 20 replicações (`reps = 20`) e, portanto, o data frame `amostra_virtual` possui ($20 \times 50 = 1000$) linhas.

Vamos agora usar `amostra_virtual` para calcular as 20 proporções de bolas vermelhas resultantes. Utilizaremos os mesmos verbos do `dplyr` de antes, mas agora com um `group_by()` adicional na variável `replicate`. Ao definir previamente a variável de agrupamento como `metadado` antes de aplicar `summarize()`, obteremos 20 proporções diferentes de bolas vermelhas. A seguir, exibimos uma prévia das primeiras 10 das 20 linhas resultantes:

```

virtual_prop_red <- amostra_virtual %>%
  group_by(replicate) %>%
  summarize(red = sum(color == "red")) %>%
  mutate(prop_red = red / 50)

virtual_prop_red

```

```

# A tibble: 20 x 3
  replicate    red prop_red
    <int> <int>    <dbl>
1         1     16     0.32
2         2     22     0.44
3         3     19     0.38
4         4     27     0.54
5         5     18     0.36
6         6     19     0.38
7         7     16     0.32
8         8     17     0.34
9         9     21     0.42
10        10     20     0.4
11        11     23     0.46
12        12     23     0.46


```

13	13	15	0.3
14	14	23	0.46
15	15	27	0.54
16	16	23	0.46
17	17	17	0.34
18	18	21	0.42
19	19	15	0.3
20	20	18	0.36

Assim como ocorreu com as 20 amostras coletadas em sala de aula, há variação nas 20 proporções de bolas vermelhas obtidas virtualmente. Vamos visualizar essa variação por meio de um histograma. Note que também adicionamos os argumentos `binwidth = 0.05` e `boundary = 0.4`.

Lembre-se de que definir `boundary = 0.4` garante um esquema de classes em que um dos limites dos intervalos esteja em 0,4. Como o `binwidth = 0.05` também foi especificado, isso criará intervalos com limites em **0,30, 0,35, 0,40, 0,45, 0,50**, entre outros.

```
ggplot(virtual_prop_red, aes(x = prop_red)) +
  geom_histogram(binwidth = 0.05, boundary = 0.4, color = "white") +
  labs(x = "Proporção de bolas vermelhas", y = "Frequência",
  title = "Distribuição das proporções")
```



Observe que, ocasionalmente, obtivemos proporções de bolas vermelhas inferiores a 30%. Por outro lado, em alguns casos, obtivemos proporções superiores a 50%. No entanto, as proporções que ocorreram com maior frequência ficaram entre 35% e 40% (em **5 das 20 amostras**). Por que temos essas diferenças nas proporções de bolas vermelhas? **Por causa da variação amostral.**

Verificação de aprendizagem

1. Por que não foi possível estudar os efeitos da variação amostral quando utilizamos a pá virtual apenas uma vez? Por que foi necessário coletar **mais de uma amostra virtual** (no nosso caso, **20 amostras virtuais**)?

Lista Semanal Obrigatória

1. Agora suponha que queiramos estudar os efeitos da variação amostral não para 20 amostras, mas para um número maior, digamos 1000 amostras. Vamos novamente utilizar a função `rep_sample_n()`, com o tamanho da amostra definido como 50, mas agora com o número de repetições `reps` definido como 1000.
2. Temos 1000 réplicas de `prop_red`, a proporção de bolas vermelhas em amostras de 50 bolas. Utilizando o mesmo código de antes, vamos agora visualizar a distribuição dessas 1000 réplicas de `prop_red` por meio de um histograma.
3. Observando o histograma produzido no item 2), você diria que amostrar 50 bolas em que 30% são vermelhas é provável ou improvável? E quanto a amostrar 50 bolas em que 10% são vermelhas?

2.5 Conceitos Importantes

Primeiramente, uma **população** é um conjunto de indivíduos ou observações de interesse. Isso também é comumente denominado **população de estudo**. Denotamos matematicamente o tamanho da população utilizando a letra maiúscula N .

Um **parâmetro populacional** é algum resumo numérico sobre a população que é desconhecido, mas que você gostaria de saber. Por exemplo, quando essa quantidade é uma média, como a altura média de todos os canadenses, o parâmetro populacional de interesse é a média populacional.

Um **censo** é uma enumeração exaustiva ou contagem de todos os N indivíduos da população. Fazemos isso para calcular o valor exato do parâmetro populacional. Vale notar que, à medida que o número N de indivíduos em nossa população aumenta, a realização de um censo se torna mais cara (em termos de tempo, energia e dinheiro).

Na nossa atividade de amostragem, a **população (de estudo)** é o conjunto de $N = 2400$ bolas vermelhas e brancas, todas de mesmo tamanho, contidas na urna. Lembre-se de que também representamos a urna “virtualmente” no data frame `bowl`.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
5       5 white
6       6 white
7       7 red
8       8 white
9       9 red
10      10 white
# i 2,390 more rows
```

O **parâmetro populacional** aqui é a proporção de bolas na urna que são vermelhas. Sempre que estamos interessados em uma proporção de algum valor em uma população, o parâmetro populacional tem um nome específico: a proporção populacional. Comumente denotamos as proporções populacionais com a letra p .

Para calcular essa proporção populacional p de forma exata, precisamos primeiro realizar um censo, analisando todos os $N = 2400$ e contando o número de bolas vermelhas. Em seguida, dividimos essa contagem por 2400 para obter a proporção de vermelhas.

Você pode estar se perguntando agora: “Espere. Eu entendo que realizar um censo na urna real levaria muito tempo. Mas não podemos realizar um censo “virtual” usando a urna virtual?” Você está absolutamente correto! De fato, quando os autores do pacote `moderndive` criaram o data frame `bowl`, eles fizeram com que seu conteúdo correspondesse ao da urna real não fazendo um censo, mas lendo o conteúdo escrito na caixa em que a urna veio! Vamos realizar este censo “virtual” usando os mesmos códigos do pacote `dplyr` que você usou anteriormente para contar o número de bolas que são vermelhas:

```
bowl %>%
  summarize(red = sum(color == "red"))
```

```
# A tibble: 1 x 1
```

```
red
<int>
1 900
```

Como 900 das 2400 são vermelhas, a proporção é $900/2400 = 0,375 = 37,5\%$. Portanto, sabemos o valor do parâmetro populacional: em nosso caso, a proporção populacional p é igual a 0,375.

Neste ponto, você pode estar se perguntando: “*Se tínhamos uma maneira de saber que a proporção de bolas vermelhas é de 37,5%, então por que fizemos alguma amostragem?*” Ótima pergunta! Normalmente, você não faria amostragem alguma! No entanto, as atividades de amostragem que fizemos neste capítulo são meras simulações de como a amostragem é feita na vida real! Realizamos essas simulações a fim de estudar:

1. O efeito da variação amostral (ou variabilidade de amostragem) em nossas estimativas.
2. O efeito do tamanho da amostra na variação amostral.

Como veremos adiante em pesquisas de opinião, na amostragem da vida real não apenas o tamanho da população N será muito grande, tornando um censo caro, mas, às vezes, nem sequer saberemos qual é o tamanho da população! Por enquanto, no entanto, prosseguiremos com nosso próximo conjunto de termos e notação.

Amostragem é o ato de coletar uma amostra da população, o que geralmente fazemos apenas quando não podemos realizar um censo. Denotamos matematicamente o tamanho da amostra usando o n minúsculo, em oposição ao N maiúsculo, que denota o tamanho da população. Normalmente, o tamanho da amostra n é muito menor que o tamanho da população N . Assim, a amostragem é uma alternativa muito mais barata do que a realização de um censo.

Uma **estimativa pontual**, também conhecida como estatística (ou estatística amostral), é uma estatística calculada a partir de uma amostra que estima o parâmetro populacional desconhecido.

Então, em sala de aula, realizamos a amostragem usando uma pá com 50 espaços para extrair amostras de tamanho $n = 50$. Para realizar o análogo virtual desta amostragem, lembre-se de que usamos a função `rep_sample_n()` da seguinte maneira:

```
set.seed(2026)
pa_virtual <- bowl %>%
  rep_sample_n(size = 50)
```

Usando a amostra de 50 bolas contidas em `pa_virtual`, geramos uma estimativa da proporção de bolas na urna que são vermelhas, `prop_red`.

```
pa_virtual %>%
  summarize(num_red = sum(color == "red")) %>%
  mutate(prop_red = num_red / 50)
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
    <int>    <int>    <dbl>
1         1      16     0.32
```

Então, em nosso caso, o valor de **prop_red** é a estimativa pontual da proporção populacional p , pois ela estima o valor desta última. Além disso, essa estimativa pontual tem um nome específico quando se considera proporções: **a proporção amostral**. Ela é denotada usando $\hat{p}$, porque é uma convenção comum em estatística usar um símbolo de “chapéu” para denotar estimativas pontuais.

Iremos observar ao longo desta disciplina que a maneira como você coleta as amostras influencia diretamente a qualidade delas.

- Diz-se que uma amostra é **representativa** se ela “se parecer” aproximadamente com a população. Em outras palavras, se as características da amostra forem uma “boa” representação das características da população.
- Dizemos que uma amostra é **generalizável** se quaisquer resultados baseados na amostra puderem ser generalizados para a população. Em outras palavras, se pudermos fazer “bons” palpites sobre a população usando a amostra.
- Dizemos que um procedimento de amostragem é **viesado** (ou tendencioso) se certos indivíduos em uma população tiverem uma chance maior de serem incluídos em uma amostra do que outros. Dizemos que um procedimento de amostragem é **não viesado** (ou imparcial) se cada indivíduo em uma população tiver chances iguais de ser amostrado.

Dizemos que uma amostra de n bolas extraídas usando nossa pá é **representativa** da população se o seu conteúdo “se assemelhar aproximadamente” ao conteúdo da urna. Se sim, então a proporção de bolas vermelhas da pá pode ser **generalizada** para a proporção das $N = 2400$ bolas da urna que são vermelhas. Ou expresso de forma diferente, $\hat{p}$ é um “bom palpite” de p . Agora digamos que trapaceamos ao usar a pá e removemos um número de bolas brancas em favor de bolas vermelhas. Então, essa amostra seria viesada em relação às bolas vermelhas e, portanto, a amostra não seria mais representativa da urna.

Uma maneira de garantir que uma amostra seja não viesada e representativa da população é usar a **amostragem aleatória**. Temos que **Inferência** é o ato de “dar um palpite” sobre algo desconhecido. Portanto, **Inferência estatística** é o ato de fazer um palpite sobre uma população usando uma amostra.

Em nosso caso, como a função `rep_sample_n()` usa o gerador de números aleatórios do seu computador, estávamos, de fato, realizando “amostragem aleatória”.

2.6 Estatísticas, estimadores e estimativas

Para realizar inferências sobre uma população, partimos de uma amostra aleatória, que é um conjunto de n variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) retiradas de um PGD. Denotamos essa amostra antes da coleta por:

$$\mathbf{X} = (X_1, X_2, \dots, X_n).$$

Nesse estágio, $\mathbf{X}$ representa o “efeito” potencial de um mecanismo teórico (PGD) cujos parâmetros são fixos, mas desconhecidos. Após a coleta, observamos uma realização particular da amostra, denotada por letras minúsculas:

$$\mathbf{x} = (x_1, x_2, \dots, x_n).$$

Esta distinção é o pilar da inferência estatística: enquanto a amostra observada $\mathbf{x}$ é um conjunto de números fixos, a amostra aleatória $\mathbf{X}$ é um vetor de variáveis aleatórias.

1. Estatística: é qualquer função da amostra que não depende de parâmetros desconhecidos. Matematicamente, se T é uma estatística, então $T = g(X_1, \dots, X_n)$. Exemplos comuns incluem a média amostral ($\bar{X}$), a variância amostral (S^2) ou o máximo da amostra ($X_{(n)}$).
2. Estimador: é uma estatística utilizada especificamente com o objetivo de aproximar um parâmetro populacional desconhecido (θ). Como o estimador é uma função de variáveis aleatórias, ele próprio é uma variável aleatória. Portanto, cada estimador possui sua própria distribuição amostral, que descreve como seus valores variariam se extraíssemos infinitas amostras da mesma população.
3. Estimativa: é o valor numérico específico que o estimador assume ao ser calculado com os dados de uma amostra observada $\mathbf{x}$. Enquanto o estimador $\hat{\theta}$ é uma “regra” ou fórmula, a estimativa é o resultado final após a substituição dos valores medidos.

Essa hierarquia permite que a estatística utilize a teoria da probabilidade para quantificar quão próxima uma estimativa pontual está do verdadeiro parâmetro, frequentemente através do cálculo do erro padrão ou da construção de intervalos de confiança

2.7 Estatística como função da amostra

Um ponto fundamental é que, como os argumentos $X_1, \dots, X_n$ são variáveis aleatórias (antes da coleta), a estatística T é, ela própria, uma variável aleatória.

Exemplos Fundamentais

1. Média Amostral ($\bar{X}$): É a soma das observações dividida pelo tamanho da amostra, ou seja

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Sendo o estimador natural da média populacional μ .

2. Variância Amostral (S^2): Utiliza-se geralmente o divisor $n - 1$ para que o estimador seja não-viesado, compensando a perda de um grau de liberdade ao usar $\bar{X}$ no cálculo, ou seja,

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

3. Proporção Amostral ($\hat{p}$): Aplicada quando a população segue uma distribuição de Bernoulli, onde cada unidade é classificada binariamente (sucesso/fracasso), ou seja,

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i,$$

em que X_i assume o valor 1 para “sucesso” e 0 para “fracasso”.

2.8 O Experimento da Urna e Variáveis de Bernoulli

No contexto do experimento da urna, as bolas retiradas são modeladas como variáveis aleatórias independentes e identicamente distribuídas (i.i.d.). Ao definir:

- $X_i = 1$ (Vermelha) com probabilidade p ; e
- $X_i = 0$ (Branca) com probabilidade $(1 - p)$,

a estatística $R = \sum_{i=1}^n X_i$ representa o número total de sucessos e segue uma distribuição Binomial(n, p). A proporção amostral $\hat{p} = R/n$ é, portanto, a média aritmética dessas variáveis de Bernoulli, funcionando como um estimador não-viesado para a proporção populacional p .

2.9 Distribuição Amostral

O conceito de distribuição amostral é o elo entre a probabilidade e a inferência. Ela descreve o comportamento probabilístico do estimador, apresentando todos os valores que ele pode assumir e a frequência com que esses valores ocorrem quando o procedimento de amostragem é repetido infinitamente sob as mesmas condições.

No experimento virtual realizado, o histograma das proporções calculadas pelos grupos representa uma aproximação empírica da distribuição amostral de $\hat{p}$ para um tamanho de amostra fixo n . Vimos anteriormente que sob o modelo de Bernoulli independente, o número de sucessos R segue uma distribuição Binomial. Como $\hat{p} = R/n$, as propriedades da distribuição amostral de $\hat{p}$ são:

1. Esperança: $E(\hat{p}) = p$ (o que torna $\hat{p}$ um estimador não-viesado).
2. Variância: $\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$.
3. Erro-Padrão: É o desvio padrão da distribuição amostral, dado por $\text{EP}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$.

Estas expressões revelam que a variabilidade de $\hat{p}$ é inversamente proporcional à raiz quadrada de n . Assim, amostras maiores produzem estimativas mais precisas e concentradas em torno do verdadeiro parâmetro.

i Modelo exato para a urna

Quando a amostragem é realizada sem reposição em uma população finita de tamanho N (com M bolas vermelhas), as observações não são independentes. O número de sucessos segue, então, uma distribuição Hipergeométrica(N, M, n).

Nesse cenário, a variância do estimador incorpora a correção para população finita:

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \cdot \left(\frac{N-n}{N-1} \right).$$

O fator $\frac{N-n}{N-1}$ reduz a variabilidade do estimador, pois, em populações finitas, cada unidade amostrada reduz a incerteza sobre o que resta na população. Quando a fração amostral n/N é pequena (geralmente menor que 10%), esse fator aproxima-se de 1, e o modelo binomial torna-se uma aproximação excelente e simplificada.

2.10 Critérios básicos para avaliar estimadores

Diferentes estatísticas podem ser utilizadas para estimar um mesmo parâmetro populacional, tornando necessária a aplicação de critérios técnicos para compará-las.

1. O viés de um estimador é a diferença entre o seu valor esperado e o valor real do parâmetro, sendo definido por $E(\hat{\theta}) - \theta$. Um estimador é considerado não viesado quando, em média, seus valores coincidem com o parâmetro alvo, ou seja, $E(\hat{\theta}) = \theta$.
2. A variância, por sua vez, quantifica a dispersão ou incerteza do estimador entre diferentes amostras possíveis. Um critério abrangente que permite comparar estimadores viesados e não viesados é o Erro Quadrático Médio (EQM), que combina viés e variabilidade através da decomposição $EQM(\hat{\theta}) = Var(\hat{\theta}) + [Viés(\hat{\theta})]^2$.
3. Além dessas propriedades de pequenas amostras, um estimador é dito consistente se ele converge em probabilidade para o valor verdadeiro do parâmetro à medida que o tamanho da amostra n aumenta, garantindo que o erro de estimação tenda a zero no longo prazo.

Verificação de aprendizagem

1. Qual é a diferença entre $\hat{p}$ e o valor observado de $\hat{p}$?
2. Por que um estimador é considerado uma variável aleatória?
3. Qual é a relação entre o histograma das proporções obtidas nas amostras repetidas e a distribuição amostral de $\hat{p}$?
4. O que acontece com a variabilidade de $\hat{p}$ quando o tamanho da amostra aumenta?

2.11 Modelo estatístico e função de verossimilhança

Como a descrição probabilística exata do PGD raramente é conhecida, a inferência estatística utiliza uma família de modelos para representar, de maneira simplificada e aproximada, os aspectos fundamentais do fenômeno em estudo. Um modelo estatístico paramétrico é definido como uma coleção de distribuições de probabilidade indexadas por um parâmetro:

$$\mathcal{P} = \{P_{\theta} : \theta \in \Theta\},$$

em que θ representa o parâmetro (ou vetor de parâmetros) desconhecido que rege o mecanismo teórico, Θ é o espaço paramétrico, que compreende todos os valores possíveis que θ pode assumir. Cada valor de θ especifica uma distribuição de probabilidade distinta para os dados.

O objetivo central da inferência é utilizar a amostra observada para identificar quais valores de θ dentro do espaço paramétrico são mais compatíveis com a evidência empírica coletada.

2.12 Definição da função de verossimilhança

Considere uma amostra observada $\mathbf{x} = (x_1, x_2, \dots, x_n)$ proveniente de um PGD com função de probabilidade (ou densidade) $f(x; \theta)$. Sob a suposição de que as observações são i.i.d., a distribuição conjunta da amostra é dada pelo produto das densidades individuais:

$$f(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta).$$

Quando tratamos essa expressão como uma função de θ , mantendo os dados observados $\mathbf{x}$ fixos, ela é denominada função de verossimilhança:

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

A verossimilhança quantifica a compatibilidade relativa entre diferentes valores do parâmetro e os dados efetivamente coletados, servindo de base para métodos de estimativa e tomada de decisão.

⚠ Probabilidade e verossimilhança

É fundamental distinguir os dois conceitos:

1. Na probabilidade $f(\mathbf{x}; \theta)$, o parâmetro θ está fixo e variamos os dados $\mathbf{x}$ para prever possíveis resultados.
2. Na verossimilhança $L(\theta; \mathbf{x})$ os dados $\mathbf{x}$ estão fixos e variamos θ para avaliar qual modelo melhor explica o que foi observado.

Portanto, $L(\theta; \mathbf{x})$ não é uma distribuição de probabilidade para θ . Ela não indica a probabilidade de o parâmetro ser um determinado valor, mas sim o quão plausível é aquele valor dado o resultado da amostra.

2.13 Verossimilhança no experimento da urna

No experimento da urna, cada retirada pode ser modelada individualmente como uma variável de Bernoulli:

$$X_i \sim \text{Bernoulli}(p),$$

em que $X_i = 1$ indica uma bola vermelha e $X_i = 0$ uma bola branca. A função de probabilidade para uma única observação é $f(x_i; p) = p^{x_i}(1 - p)^{1-x_i}$ para $0 \leq p \leq 1$. Para uma amostra de n bolas, a função de verossimilhança é:

$$L(p; \mathbf{x}) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}.$$

Se definirmos $r = \sum_{i=1}^n x_i$ como o número total de bolas vermelhas, a expressão simplifica-se para:

$$L(p; r) = p^r(1 - p)^{n-r}.$$

Este resultado demonstra que, para inferir sobre a proporção p , a ordem das bolas é irrelevante, apenas o total r de sucessos importa.

Note que no exemplo da urna, a proporção amostral $\hat{p} = R/n$ desempenhou três papéis complementares: foi uma estatística calculada a partir da amostra, um estimador da proporção populacional p e o estimador de máxima verossimilhança sob o modelo de Bernoulli. Essa conexão ilustra como os conceitos introduzidos ao longo da unidade se articulam em uma estrutura inferencial única.

Verificação de aprendizagem

1. Na definição de $L(\theta; \mathbf{x})$, quais elementos são mantidos fixos e quais variam?
2. Por que a função de verossimilhança não deve ser interpretada como uma probabilidade para o parâmetro?
3. Mostre que, se nenhuma bola vermelha for observada, o estimador de máxima verossimilhança de p será igual a zero.
4. Mostre que, se todas as bolas observadas forem vermelhas, o estimador de máxima verossimilhança de p será igual a um.

Referências

3 Distribuições Amostrais

3.1 Introdução

O que é a estatística? A estatística é a ciência que se preocupa com a coleta, organização, análise e interpretação de dados para transformar dados em conhecimento. Ela fornece as ferramentas essenciais para quantificar a incerteza e reduzir as suposições em diversos contextos. Didaticamente, ela é dividida em três grandes áreas:

- **Coleta de Dados:** Planejamento de esquemas amostrais e desenhos experimentais para garantir que a amostra seja representativa da população.
- **Estatística Descritiva:** Uso de métodos numéricos e gráficos para resumir e apresentar as características de uma amostra observada.
- **Estatística Inferencial:** O uso da teoria das probabilidades para tirar conclusões, fazer estimativas e testar hipóteses sobre uma população maior com base apenas nos dados de uma amostra.

Os procedimentos estatísticos são partes integrantes do Método Científico, defendido inicialmente por Sir Francis Bacon (1561-1626), que afirmava que “aprender os segredos da natureza envolve coletar dados e realizar experimentos”.

A metodologia moderna:

1. Observação: Notar um fenômeno no mundo real.
2. Formulação de Hipótese: Criar uma explicação teórica para o fenômeno.
3. Coleta de Dados: Realizar amostragem ou experimentos controlados.
4. Teste Estatístico: Verificar se a evidência dos dados suporta a hipótese com o mínimo de risco.
5. Conclusão: Aceitar, rejeitar ou refinar a hipótese original.

“As estatísticas não mentem, mas os mentirosos usam estatísticas.” — Mark Twain.

3.2 O que é a Estatística Matemática?

É o estudo dos fundamentos teóricos que sustentam e justificam os métodos utilizados para descrever e analisar dados. Enquanto a prática estatística lida com a aplicação, a estatística matemática utiliza a teoria da probabilidade para provar por que certos procedimentos funcionam e quais são suas propriedades ideais.

O que é uma estatística?

Uma estatística é qualquer função real da amostra aleatória que não depende de parâmetros desconhecidos. Se $X_1, X_2, \dots, X_n$ representam as variáveis aleatórias da amostra, uma estatística T é denotada por:

$$T = g(X_1, X_2, \dots, X_n)$$

Como seus argumentos são variáveis aleatórias, a estatística T é, ela própria, uma variável aleatória antes de os dados serem coletados, possuindo assim sua própria distribuição de probabilidade, chamada de **distribuição amostral**.

População vs. Amostra

- **População:** O conjunto total de todos os indivíduos, objetos ou medidas de interesse que compartilham uma característica comum. Pode ser existente (ex: todos os brasileiros) ou conceitual (ex: todas as medições futuras de um sensor).
- **Amostra:** Um subconjunto da população selecionado para estudo. Geralmente, utilizamos amostras porque realizar um censo (contar toda a população) é caro demais em termos de tempo e dinheiro.

Parâmetro vs. Estatística

Parâmetro: Valor numérico fixo e geralmente desconhecido que descreve uma característica da população ou de um modelo teórico.

- **Média populacional:** $\mu = \sum xP(x)$ ou $\int xf(x)dx$ (O centro de massa da distribuição teórica).
- **Variância populacional:** $\sigma^2 = \sum (x - \mu)^2 P(x)$ ou $\int (x - \mu)^2 f(x)dx$ (Medida da dispersão dos dados na população).
- **Proporção populacional:** p é a verdadeira proporção de 1s na população (A fração real de sucessos na população total).
- **Mediana populacional:** $\phi_{.5}$ é o valor tal que $P(X \leq \phi_{.5}) \geq .5$ e $P(X \geq \phi_{.5}) \geq .5$.

Estatística: Valor numérico calculado a partir dos dados da amostra. É uma variável aleatória que varia de amostra para amostra.

- **Média amostral:** $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ (Principal estimador da média populacional).
- **Variância amostral:** $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ (Utiliza-se geralmente o divisor $(n-1)$ para ser um estimador não-viesado da variância populacional).
- **Proporção amostral:** $\hat{p} = \frac{\text{número de 1s}}{n}$.
- **Mediana amostral:** $\hat{\phi}_{.5}$ = valor central (ou média dos centrais).

Definição 2: Amostra Aleatória:

A variáveis aleatórias $X_1, X_2, \dots, X_n$ são chamadas de amostra aleatória e de tamanho n da população $f(x)$ se $X_1, X_2, \dots, X_n$ são variáveis aleatórias mutuamente independentes e a função densidade de probabilidade (FDP) (ou função de probabilidade (FP)) marginal de cada X_i é a mesma função $f(x)$. Alternativamente, $X_1, X_2, \dots, X_n$ são chamadas de variáveis aleatórias independentes e identicamente distribuídas com FDP (ou FP) $f(x)$. Sendo comumente abreviado para variáveis aleatórias i.i.d (Casella; Berger, 2002).

3.3 Amostragem Aleatória Simples (AAS)

Quando estudamos uma variável de interesse cuja distribuição de probabilidade populacional é descrita por $f(x)$, uma única observação X permite calcular probabilidades teóricas baseadas nessa função. No entanto, a inferência estatística baseia-se na repetição desse experimento para obter um conjunto de n observações, denotado por $\mathbf{X} = (X_1, X_2, \dots, X_n)$.

Para que as conclusões obtidas a partir desse conjunto sejam generalizáveis para a população, adotamos o modelo de AAS, que exige que as variáveis da amostra sejam i.i.d.:

1. **Mutuamente Independentes:** O valor assumido por uma observação não exerce qualquer influência ou relação com as demais. Matematicamente, a independência garante que a FDP conjunta (ou função de probabilidade conjunta, no caso discreto) seja o produto das densidades marginais:

$$f(x_1, x_2, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n) = \prod_{i=1}^n f(x_i).$$

2. **Identicamente Distribuídas:** Como cada X_i é extraído da mesma população (ou PGD), todas as densidades marginais $f(x_i)$ seguem a mesma regra funcional $f(x)$, possuindo, portanto, os mesmos parâmetros populacionais, como a média (μ) e variância (σ^2).

3.4 O Modelo Paramétrico e a Verossimilhança

Na maioria dos problemas inferenciais, a FDP da população pertence a uma família paramétrica $\{f(x; \theta) : \theta \in \Theta\}$, onde a forma da distribuição é conhecida, mas o parâmetro θ é desconhecido. Nesse contexto, a densidade conjunta da amostra é expressa como:

$$f(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

Quando os dados da amostra $\mathbf{x}$ são coletados e mantidos fixos, e passamos a tratar essa expressão como uma função do parâmetro θ , ela recebe o nome de função de verossimilhança ($L(\theta; \mathbf{x})$). A verossimilhança é o pilar central que permite identificar quais valores de θ são mais compatíveis com a realidade observada, servindo de base para a construção de estimadores e testes de hipóteses.

Exemplo 1

Sejam $X_1, \dots, X_n$ uma amostra aleatória de uma população exponencial(β). Especificamente, $X_1, \dots, X_n$ podem corresponder aos tempos até a falha (medidos em anos) de n placas de circuito idênticas que são colocadas em teste e usadas até falharem.

A função densidade conjunta da amostra é

$$f(x_1, \dots, x_n | \beta) = \prod_{i=1}^n f(x_i | \beta) = \prod_{i=1}^n \frac{1}{\beta} e^{-x_i/\beta} = \frac{1}{\beta^n} e^{-(x_1 + \dots + x_n)/\beta}.$$

Essa FDP pode ser usada para responder perguntas sobre a amostra. Por exemplo, qual é a probabilidade de que todas as placas durem mais de 2 anos?

 Resposta:

3.5 Diferentes maneiras de coletar uma amostra

O modelo de amostragem aleatória da Definição 1 é algumas vezes chamado de **amostragem de uma população infinita**. Pense em obter os valores de $X_1, \dots, X_n$ sequencialmente. Primeiro, o experimento é realizado e $X_1 = x_1$ é observado. Em seguida, o experimento é repetido e $X_2 = x_2$ é observado.

A suposição de independência na amostragem aleatória implica que a distribuição de probabilidade de X_2 não é afetada pelo fato de que $X_1 = x_1$ foi observado primeiro. “Remover” x_1 de uma população infinita não altera a população, de modo que $X_2 = x_2$ ainda é uma observação aleatória proveniente da mesma população.

Quando a amostragem é feita a partir de uma **população finita**, a Definição 1 pode ou não ser relevante, dependendo de como os dados são coletados. Uma população finita é um conjunto finito de números, $\{x_1, \dots, x_N\}$. Uma amostra $X_1, \dots, X_n$ deve ser extraída dessa população. Essas amostras podem ser obtidas de quatro maneiras diferentes. Podemos resumir as quatro situações na Tabela 1 a seguir:

Tipo de seleção	Sem reposição	Com reposição
Ordenado	$\frac{n!}{(n-r)!}$	n^r
Não ordenado	$\binom{n}{r}$	$\binom{n+r-1}{r}$

Tabela 1: Número de possíveis arranjos de tamanho r a partir de n objetos.

Neste material iremos considerar apenas dois casos: i) ordenado sem reposição e ii) Ordenado com reposição. Para maiores detalhes, ver Casella; Berger (2002).

Suponha que um valor seja escolhido da população de tal forma que cada um dos N valores tenha a mesma probabilidade ($1/N$) de ser selecionado (pense em retirar números de uma urna). Esse valor é registrado como $X_1 = x_1$. Em seguida, o processo é repetido. Novamente, cada um dos N valores tem a mesma probabilidade de ser escolhido. O segundo valor selecionado é registrado como $X_2 = x_2$ (Se o mesmo número for escolhido, então $x_1 = x_2$).

Esse processo de sorteio entre os N valores é repetido n vezes, produzindo a amostra $X_1, \dots, X_n$. Esse tipo de amostragem é chamado **com reposição**, porque o valor escolhido em qualquer etapa é “reposto” na população e fica disponível para ser escolhido novamente na etapa seguinte. Para esse tipo de amostragem, as condições da Definição 1 são satisfeitas.

Cada X_i é uma variável aleatória discreta que assume cada um dos valores $x_1, \dots, x_N$ com probabilidade igual. As variáveis aleatórias $X_1, \dots, X_n$ são independentes porque o processo de escolha de qualquer X_i é o mesmo, independentemente dos valores escolhidos para as outras variáveis (este tipo de amostragem é utilizado no **bootstrap**).

Um segundo método para extrair uma amostra aleatória de uma população finita é chamado de **amostragem sem reposição**. A amostragem sem reposição é feita da seguinte forma: um valor é escolhido de $\{x_1, \dots, x_N\}$ de tal modo que cada um dos N valores tenha probabilidade $1/N$ de ser escolhido. Este valor é registrado como $X_1 = x_1$. Agora, um segundo valor é escolhido dos $N - 1$ valores restantes. Cada um dos $N - 1$ valores tem probabilidade $1/(N - 1)$ de ser escolhido. O segundo valor escolhido é registrado como $X_2 = x_2$. A escolha dos valores restantes continua desta forma, resultando na amostra $X_1, \dots, X_n$. Contudo, uma vez que um valor é escolhido, ele torna-se indisponível para escolha em qualquer fase posterior.

Uma amostra extraída de uma população finita sem reposição não satisfaz todas as condições da Definição 1. As variáveis aleatórias $X_1, \dots, X_n$ não são mutuamente independentes. Para verificar isto, sejam x e y elementos distintos de $\{x_1, \dots, x_N\}$. Então $P(X_2 = y|X_1 = y) = 0$, visto que o valor y não pode ser escolhido na segunda fase se já tiver sido escolhido na primeira. No entanto, $P(X_2 = y|X_1 = x) = 1/(N - 1)$.

A distribuição de probabilidade para X_2 depende do valor observado de X_1 e, portanto, X_1 e X_2 não são independentes. Todavia, é interessante notar que $X_1, \dots, X_n$ são **identicamente distribuídas**. Isto é, a distribuição marginal de X_i é a mesma para cada $i = 1, \dots, n$. Para X_1 é claro que a distribuição marginal é $P(X_1 = x) = 1/N$ para cada $x \in \{x_1, \dots, x_N\}$. Para calcular a distribuição marginal de X_2 , utiliza-se o conceitos de probabilidade condicional para escrever:

$$P(X_2 = x) = \sum_{i=1}^N P(X_2 = x|X_1 = x_i)P(X_1 = x_i).$$

Para um valor do índice, digamos k , temos $x = x_k$ e $P(X_2 = x|X_1 = x_k) = 0$. Para todos os outros $j \neq k$, $P(X_2 = x|X_1 = x_j) = 1/(N - 1)$. Assim,

$$P(X_2 = x) = (N - 1) \left(\frac{1}{N - 1} \frac{1}{N} \right) = \frac{1}{N}.$$

Argumentos semelhantes podem ser usados para mostrar que cada um dos X_i tem a mesma distribuição marginal.

A amostragem sem reposição de uma população finita é por vezes chamada de **amostragem aleatória simples**. É importante perceber que esta não é a mesma situação de amostragem descrita na Definição 1. No entanto, se o tamanho da população N for grande em comparação com o tamanho da amostra n , $X_1, \dots, X_n$ são quase independentes e alguns cálculos aproximados de probabilidade podem ser feitos assumindo que são independentes. Ao dizer que são “quase independentes”, queremos simplesmente dizer que a distribuição condicional de X_i dado $X_1, \dots, X_{i-1}$ não é muito diferente da distribuição marginal de X_i . Por exemplo, a distribuição condicional de X_2 dado X_1 é

$$P(X_2 = x_1|X_1 = x_1) = 0 \quad \text{e} \quad P(X_2 = x|X_1 = x_1) = \frac{1}{N - 1} \quad \text{para } x \neq x_1.$$

Isto não é muito diferente da distribuição marginal de X_2 , dada em anteriormente, se N for grande. As probabilidades não nulas na distribuição condicional de X_i dados $X_1, \dots, X_{i-1}$ são $1/(N - i + 1)$, que são próximas de $1/N$ se $i \leq n$ for pequeno em comparação com N .

i Arranjos ou combinação ao contar amostras?

Ao contar o número de **amostras aleatórias simples** possíveis, o resultado depende de como definimos uma *amostra*.

1. Quando a ordem importa

Se a amostra é vista como uma sequência de observações

$$(X_1, X_2, \dots, X_n),$$

então a ordem das unidades selecionadas importa. Nesse caso,

$$(a, b) \neq (b, a).$$

A contagem utiliza **arranjos**):

$$A(N, n) = \frac{N!}{(N - n)!}.$$

Isso corresponde ao processo de seleção **sequencial**, no qual registramos a ordem em que as unidades são sorteadas.

2. Quando a ordem não importa

Se a amostra é tratada apenas como o **conjunto de unidades selecionadas**, então

$$\{a, b\} = \{b, a\}.$$

Nesse caso utilizamos **combinações**:

$$\binom{N}{n}.$$

Aqui interessa apenas **quais unidades foram escolhidas**, e não a ordem em que foram selecionadas.

Resumo

- sequência observada $\rightarrow$ **Arranjos**
- subconjunto da população $\rightarrow$ **Combinações**

Na teoria de inferência estatística, muitas vezes modelamos a amostra como o vetor aleatório $(X_1, \dots, X_n)$, enquanto na teoria de amostragem de populações finitas é comum tratar a amostra apenas como um subconjunto da população.

Exemplo 2 (Modelo de população finita)

Como um exemplo de um cálculo aproximado usando independência, suponha que $\{1, \dots, 1000\}$ é a população finita, logo $N = 1000$. Uma amostra de tamanho $n = 10$ é extraída sem

reposição. Qual é a probabilidade de que todos os dez valores da amostra sejam maiores que 200? Se $X_1, \dots, X_{10}$ fossem mutuamente independentes, teríamos:

$$\begin{aligned} P(X_1 > 200, \dots, X_{10} > 200) &= P(X_1 > 200) \cdots P(X_{10} > 200) \\ &= \left(\frac{800}{1000} \right)^{10} = 0,107374. \end{aligned}$$

Para calcular esta probabilidade exatamente, seja Y uma variável aleatória que conta o número de itens na amostra que são maiores que 200. Então Y tem uma distribuição hipergeométrica ($N = 1000, M = 800, K = 10$). Portanto,

$$\begin{aligned} P(X_1 > 200, \dots, X_{10} > 200) &= P(Y = 10) \\ &= \frac{\binom{800}{10} \binom{200}{0}}{\binom{1000}{10}} \\ &= 0,106164. \end{aligned}$$

Assim, o primeiro resultado é uma aproximação razoável para o valor real. Ao longo deste material, usaremos a Definição 1 como nossa definição de uma amostra aleatória de uma população.

3.6 Somas de Variáveis Aleatórias

O estudo da distribuição da soma de variáveis aleatórias é um passo intermediário crucial para compreendermos o comportamento da média amostral ($\bar{X}$), que é o estimador central de vários modelos estatísticos.

Relações Fundamentais entre Soma e Média

Seja uma amostra aleatória simples (i.i.d.) $X_1, \dots, X_n$ e considere a estatística de soma $Y = \sum_{i=1}^n X_i$. A média amostral é definida como uma transformação linear dessa soma: $\bar{X} = \frac{1}{n}Y$. Do ponto de vista funcional, se conhecermos a função de densidade de probabilidade (FDP) da soma, $f_Y(y)$, a FDP da média amostral pode ser obtida por uma simples mudança de escala:

$$f_{\bar{X}}(x) = n \cdot f_Y(nx).$$

Essa relação mostra que qualquer propriedade descoberta sobre a soma das observações pode ser transposta diretamente para a média amostral.

O Método da Função Geradora de Momentos (FGM)

A FGM de uma variável aleatória W é definida como $M_W(t) = E(e^{tW})$. Este método é extremamente poderoso na inferência devido a duas propriedades fundamentais extraídas das fontes:

1. Independência: A FGM da soma de variáveis independentes é o produto das FGMs individuais.
2. Unicidade: Se duas variáveis aleatórias possuem a mesma FGM, para t em um intervalo contendo zero, então elas possuem a mesma distribuição de probabilidade.

Derivação da FGM da Média Amostral

Dada a amostra i.i.d., onde cada X_i tem a mesma FGM, $M_X(t)$, a derivação para $\bar{X}$ segue a lógica:

$$M_{\bar{X}}(t) = E(e^{t\bar{X}}) = E(e^{t(X_1 + \dots + X_n)/n}).$$

Pela independência, a esperança do produto torna-se o produto das esperanças:

$$M_{\bar{X}}(t) = \prod_{i=1}^n E(e^{(t/n)X_i}) = \prod_{i=1}^n M_{X_i}(t/n).$$

Como as variáveis são identicamente distribuídas:

$$M_{\bar{X}}(t) = [M_X(t/n)]^n.$$

i Teorema 2

Seja $X_1, \dots, X_n$ uma amostra aleatória de uma população com FGM $M_X(t)$. Então a FGM da média amostral é dada por:

$$M_{\bar{X}}(t) = [M_X(t/n)]^n.$$

Utilidade e Aplicação

A grande vantagem deste teorema é que ele permite identificar a distribuição exata de $\bar{X}$ sem a necessidade de realizar integrais de convolução complexas. Os casos em que isso é verdade são um tanto limitados, mas o exemplo seguinte ilustra que, quando este método funciona, ele fornece uma derivação muito elegante da distribuição amostral de $\bar{X}$.

Exemplo 3 (Distribuição da média)

Seja $X_1, \dots, X_n$ uma amostra aleatória de uma população com distribuição $N(\mu, \sigma^2)$, sua FGM é $M_X(t) = \exp\{\mu t + \frac{\sigma^2 t^2}{2}\}$. Ao aplicarmos o teorema, então a FGM da média amostral é:

$$\begin{aligned} M_{\bar{X}}(t) &= \left[\exp \left(\mu \frac{t}{n} + \frac{\sigma^2 (t/n)^2}{2} \right) \right]^n \\ &= \exp \left(n \left(\mu \frac{t}{n} + \frac{\sigma^2 (t/n)^2}{2} \right) \right) = \exp \left(\mu t + \frac{(\sigma^2/n) t^2}{2} \right). \end{aligned}$$

Portanto, $\bar{X}$ tem uma distribuição $N(\mu, \sigma^2/n)$.

Este método fornece uma derivação elegante e rigorosa que serve de base para o Teorema Central do Limite, expandindo a utilidade dessas somas para casos onde o tamanho da amostra n é grande, mesmo que a distribuição original não seja normal.

Outro exemplo simples é dado por uma amostra aleatória de uma distribuição Gama(α, β). Aqui, também podemos derivar facilmente a distribuição da média amostral. A FGM da média amostral é

$$M_{\bar{X}}(t) = \left[\left(\frac{1}{1 - \beta(t/n)} \right)^\alpha \right]^n = \left(\frac{1}{1 - (\beta/n)t} \right)^{n\alpha},$$

a qual reconhecemos como a FGM de uma Gama($n\alpha, \beta/n$), que é a distribuição de $\bar{X}$.

3.7 Lei dos Grandes Números

O problema de obter empiricamente valores numéricos de probabilidades é um dos interesses da estatística. Inúmeras técnicas foram desenvolvidas para que fossem obtidas estimativas da probabilidade de eventos. As Leis dos Grandes Número fornecem a fundamentação teórica para a maioria dessas técnicas (Magalhães, 2006).

Em um certo espaço de probabilidade, considere um experimento em que o evento A tem probabilidade $P(A) = p$. A intuição, frequentemente aceita, indica que em um grande número de repetições do experimento, a frequência relativa de A se aproxima de p . Isto é $\frac{n_A}{n} \approx p$, em que n_A é a frequência de A e n o total de repetições. Essa concepção intuitiva, importante para o método científico, foi tomada como definição de probabilidade por muitos anos. De fato, essa definição pode ser considerada imprecisa, se o sentido do limite não é explicado (Magalhães, 2006).

A formalização axiomática de Kolmogorov em 1934, apresentada em Métodos Probabilísticos, permitiu colocar em bases matemáticas sólidas vários dos conceitos intuitivamente aceitos. Para experimentos aleatórios, a noção intuitiva de probabilidade, como frequência relativa para um grande número de repetições, torna-se um resultado matemático rigoroso, através da aplicação de um caso especial da Lei dos Grandes Números (Magalhães, 2006).

i Lei dos Grandes Números

Sejam $X_1, X_2, \dots$ variáveis aleatórias com esperanças finitas e seja $S_n = X_1 + X_2 + \dots + X_n$. A sequência $\{X_n : n \geq 1\}$ satisfaz a *Lei Fraca dos Grandes Números* se:

$$\frac{S_n}{n} - E\left(\frac{S_n}{n}\right) \xrightarrow{p} p;$$

em que $\xrightarrow{p}$ representa convergência em probabilidade, e a *Lei Forte dos Grandes Números* se:

$$\frac{S_n}{n} - E\left(\frac{S_n}{n}\right) \xrightarrow{qc} p,$$

em que $\xrightarrow{qc}$ indica convergência “quase certa”.

A Lei Franca dos Grandes Números pode ser demonstrada de uma forma simples, por meio da simulação do experimento de uma moeda não viciada. O código (adaptado de Campos; Rêgo; Mendoça (2017)) a seguir implementa a simulação de n lançamentos da moeda, retornando a frequência relativa do evento A que representa coroa como resultado (Campos; Rêgo; Mendoça, 2017).

```
library(ggplot2)

lei_dos_grandes_numeros_faixa <- function(n) {
  set.seed(42) # Para garantir que o gráfico seja o mesmo toda vez

  # Simulação
  lancamentos <- runif(n) > 0.5
  df <- data.frame(
    tentativa = 1:n,
    proporcao = cumsum(lancamentos) / (1:n)
  )


  # Gráfico
  ggplot(df, aes(x = tentativa, y = proporcao)) +
    # Adiciona a faixa de destaque entre 0.45 e 0.55
    annotate("rect", xmin = 0, xmax = n, ymin = 0.45, ymax = 0.55,
```

```

    fill = "gray80", alpha = 0.5) +
# Linha da proporção observada
geom_line(color = "steelblue", linewidth = 0.8) +
# Linha do valor esperado
geom_hline(yintercept = 0.5, linetype = "dashed", color = "red", linewidth = 0.5) +
scale_x_continuous(expand = c(0, 0)) +
# Formatação visual
coord_cartesian(ylim = c(0, 1)) +
labs(
  title = "Lei dos Grandes Números: Convergência",
  subtitle = paste("Destaque para a faixa de probabilidade [0.45, 0.55]"),
  x = "Número de Lançamentos (n)",
  y = "Proporção Acumulada",
  caption = "Note como as oscilações 'entram' na faixa cinza conforme n aumenta."
) +
theme_bw()
}

# Teste com 2000 lançamentos para ver a entrada na faixa
lei_dos_grandes_numeros_faixa(2000)

```



3.8 Teorema Central do Limite (TCL)

O TCL estabelece que, sob condições muito gerais, a distribuição da média amostral (ou da soma) de uma amostra aleatória grande aproxima-se de uma distribuição normal.

! Teorema Central do Limite

Seja $X_1, X_2, \dots, X_n$ uma AAS de tamanho n extraída de uma distribuição com média μ_x e variância $\sigma_x^2 < \infty$. À medida que o tamanho da amostra n aumenta ($n \rightarrow \infty$), a distribuição da média amostral $\bar{X}$ converge em distribuição para uma distribuição normal com média μ e variância σ^2/n .

Matematicamente, para a estatística padronizada Z_n :

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{D} N(0, 1),$$

em que $S_n = \sum_{i=1}^n X_i$ é a soma das observações, $\xrightarrow{D}$ representa convergência em distribuição e $N(0, 1)$ é denota a distribuição normal padrão.

3.8.1 Implicações e Observações Práticas

1. **Universalidade da Forma:** A característica mais notável do TCL é que ele não exige que a população original seja normal. Mesmo que a distribuição populacional seja fortemente assimétrica (como a Exponencial) ou discreta (como a Poisson ou Bernoulli), a distribuição de $\bar{X}$ se tornará cada vez mais próxima da curva “em sino” à medida que n cresce.
2. **Tamanho Amostral:** Em termos práticos, para a maioria das distribuições, amostras de tamanho $n > 30$ já fornecem uma aproximação normal razoável para a realização de cálculos de probabilidade. Se a população original for aproximadamente simétrica, a convergência ocorre ainda mais rapidamente (com n menor).
3. **Redução da Incerteza:** O teorema confirma que a variabilidade da média amostral (σ^2/n) diminui conforme n aumenta, concentrando as estimativas em torno do verdadeiro parâmetro populacional (μ).
4. **Aproximação de Distribuições Comuns:** O TCL permite aproximar outras distribuições importantes:
 - Binomial: Como a soma de variáveis de Bernoulli independentes, a Binomial se aproxima da Normal quando $np \geq 5$ e $n(1-p) \geq 5$.
 - Poisson: A soma de variáveis de Poisson independentes também converge para a normalidade para valores elevados do parâmetro λ .

Esta propriedade é o que viabiliza o uso de intervalos de confiança e testes de hipóteses em situações onde o Processo Gerador de Dados (PGD) é desconhecido, permitindo que cientistas de dados quantifiquem a incerteza de suas estimativas de forma rigorosa

3.9 Distribuições Amostrais

O valor de uma estatística varia de amostra para amostra. Por outras palavras, amostras diferentes resultarão em valores diferentes para uma estatística. Portanto, uma estatística é uma variável aleatória com uma distribuição!

Distribuição Amostral: A distribuição dos valores da estatística provenientes de todas as amostras possíveis de tamanho n .

💡 O Método de ‘Força Bruta’ para construir uma Distribuição Amostral

Para entender a origem de uma distribuição amostral, imagine o seguinte processo exato (ou de “força bruta”):

1. **Retirar todas as amostras possíveis** de tamanho n da população.
2. **Calcular o valor da estatística** (por exemplo, a média $\bar{X}$) para cada uma dessas amostras.
3. **Exibir a distribuição** dos valores dessa estatística na forma de uma tabela, de um gráfico (histograma) ou de uma equação.

Na prática, como as populações costumam ser imensas (ou infinitas), é impossível calcular *todas* as amostras possíveis. É por isso que dependemos de teoremas matemáticos (como o Teorema Central do Limite) para deduzir o formato dessa distribuição sem precisarmos usar a força bruta!

Exercícios

1. Considere um estudo sobre o consumo de combustível da população de quatro ônibus de uma pequena companhia de transporte urbano. O consumo dos ônibus (km/l), X , em condições padrões de teste, é: 3,8, 3,9, 4,0 e 4,1. Uma amostra de dois ônibus será sorteada, com reposição.
 - a) Calcule a média e a variância da população.
 - b) Construa a distribuição para o consumo médio da amostra.
 - c) Calcule o valor esperado e a variância da distribuição amostral.

- d) Aplique as seguintes expressões nos resultados do item (a) e confira com os resultados do item (c):

$$E(\bar{X}) = \mu \quad \text{e} \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

2. Refaça o Exercício 1 considerando amostragem sem reposição. A verificação da variância, item (d), deve ser com a expressão:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \frac{N-n}{N-1}.$$

3.10 Distribuição Amostral da Média ($\bar{X}$)

Na estatística inferencial, é comum utilizar a estatística $\bar{X}$ para estimar μ .

Média e Variância: Para qualquer tamanho de amostra n e uma amostra aleatória (AA) proveniente de qualquer distribuição populacional com média μ_x e variância σ_x^2 :

$$E(\bar{X}) = \mu_x \left(E \left(\sum_{i=1}^n X_i \right) = n\mu_x \right) \quad \text{e} \quad \text{Var}(\bar{X}) = \frac{\sigma_x^2}{n} \left(E \left(\sum_{i=1}^n X_i \right) = n\sigma_x^2 \right).$$

Para compreendermos como a média amostral se comporta, utilizamos as seguintes propriedades das combinações lineares:

i Teorema 1: Combinações Lineares

Sejam a_i para $i = 1, 2, \dots, k$ constantes e sejam X_i para $i = 1, 2, \dots, k$ variáveis aleatórias. Então:

1. **Esperança:** $E \left(\sum_{i=1}^k a_i X_i \right) = \sum_{i=1}^k a_i E(X_i)$
2. **Variância:** $\text{Var} \left(\sum_{i=1}^k a_i X_i \right) = \sum_{i=1}^k a_i^2 \text{Var}(X_i)$ (se $X_1, \dots, X_k$ forem mutuamente independentes).

Quando os dados são normais: Para uma AA proveniente de uma distribuição normal $N(\mu_x, \sigma_x^2)$:

$$\bar{X} \sim N \left(\mu_x, \frac{\sigma_x^2}{n} \right).$$

Exemplo 4

Suponha que os níveis de colesterol de homens adultos sigam uma distribuição $N(210 \text{ mg/dL}, (37 \text{ mg/dL})^2)$.

1. Indique um intervalo centrado na média μ que capture os 95% centrais de todos os valores de colesterol.
2. Indique a distribuição amostral de $\bar{X}$, a média amostral dos valores de colesterol obtidos a partir de AA de tamanho $n = 10$.
3. Indique um intervalo centrado na média μ que capture os 95% centrais de todos os valores de média amostral de colesterol obtidos a partir de AA de tamanho $n = 10$.

3.10.1 Para amostras de grandes dimensões (Teorema Central do Limite):

Para um grande tamanho de amostra n e uma AA proveniente de *qualquer* distribuição populacional com variância finita $\sigma_x^2 < \infty$, as distribuições amostrais aproximadas são:

$$\bar{X} \sim N\left(\mu_x, \frac{\sigma_x^2}{n}\right) \quad \text{e} \quad \sum_{i=1}^n X_i \sim N(n\mu_x, n\sigma_x^2).$$

Este último resultado é consequência do famoso Teorema Central do Limite.

Sejam $X_1, \dots, X_n$ uma AA de uma distribuição com média μ_x e variância $\sigma_x^2 < \infty$. Então a distribuição de

$$U_n = \frac{\bar{X} - \mu_x}{\sigma_x / \sqrt{n}},$$

converge para $N(0, 1)$ a medida que $n \rightarrow \infty$. Provaremos esse teorema mais à frente.

Exemplo 5 (Ensaio de Bernoulli)

Seja $X = \begin{cases} 1 & \text{se } ______ \text{ com probabilidade } p : ______ \\ 0 & \text{se } ______ \text{ com probabilidade } 1 - p : ______ \end{cases}$

Então, dizemos que X segue uma distribuição de Bernoulli:

$$X \sim \text{Bern}(p) = \text{Bin}(n = 1, p).$$

- (a) Desenhe uma representação gráfica da função de massa de probabilidade de X .
- (b) Encontre $E(X)$ e $Var(X)$.

- (c) Suponha que foi recolhida uma AA $X_1, X_2, \dots, X_{40}$. Indique a distribuição amostral aproximada de $\bar{X}$ (geralmente denotada por $\hat{p} = \bar{X}$, o que indica que $\bar{X}$ é uma proporção amostral).

3.11 Aproximação Normal da Binomial

No exemplo anterior, consideramos a variável aleatória $X \sim \text{Bern}(p) = \text{Bin}(n = 1, p)$. Suponha que uma AA $X_1, X_2, \dots, X_n$ foi coletada com $n > 1$.

- (a) Apresente a distribuição de $Y = \sum_{i=1}^n X_i$, de modo que Y seja o número de sucessos em n tentativas (que é uma distribuição discreta que você aprendeu em Métodos Probabilísticos).
- (b) Desenhe um gráfico da função de probabilidade (pdf) de $Y = \sum_{i=1}^n X_i$.
- (c) Forneça o valor de $E(Y)$ e $\text{Var}(Y)$:

$$\begin{cases} E(Y) = \underline{\hspace{2cm}} \\ \text{Var}(Y) = \underline{\hspace{2cm}} \end{cases}$$

- (d) No Exemplo #1c, o Teorema Central do Limite (TCL) mostrou que para qualquer tamanho de amostra n , quando $X \sim \text{Bern}(p)$, então:

$$\hat{p} = \bar{X} \sim N(\underline{\hspace{1cm}}, \underline{\hspace{1cm}}).$$

- (e) Além das médias $\bar{X}$, o Teorema Central do Limite também fornece a distribuição amostral aproximada de uma soma $\sum X_i$. Use o TCL para fornecer a distribuição amostral aproximada de $Y = \sum_{i=1}^n X_i$:

$$Y \sim N(\underline{\hspace{2cm}}, \underline{\hspace{2cm}}).$$

- (f) Se a proporção real de apoiadores da reforma da saúde na população de Fortaleza é $p = 0,53$, então, em uma AA de cidadãos de Fortaleza de tamanho $n = 1000$, qual é a probabilidade de que menos de 500 prometam apoio?

3.12 Distribuição Amostral da Variância (S^2)

Um parâmetro populacional de interesse comum é a variância populacional σ^2 . Na estatística inferencial, é comum usar a estatística S^2 para estimar σ^2 . Portanto, a distribuição amostral de S^2 é de grande interesse.

i Distribuição Qui-quadrado (χ^2)

A soma dos quadrados de variáveis normais padrão independentes é distribuída como uma variável aleatória χ^2 . Mais formalmente:

- Se $Z_1, \dots, Z_\nu$ são independentes e distribuídos como $N(0, 1)$, então:

$$\sum_{i=1}^{\nu} Z_i^2 \sim \chi^2(\nu),$$

em que $\chi^2(\nu)$ é chamada de **distribuição qui-quadrado com ν graus de liberdade**.

- Para qualquer tamanho de amostra n e uma AA $X_1, X_2, \dots, X_n$ de uma distribuição normal $N(\mu_x, \sigma_x^2)$:

$$\sum_{i=1}^n \left(\frac{X_i - \mu_x}{\sigma_x} \right)^2 \sim \chi^2(n)$$

Nota: Use a Tabela do SIGAA para cálculos de probabilidade.

3.12.1 Média e Variância

Se $C \sim \chi^2(\nu)$, então:

$$\begin{cases} E(C) = \nu; \\ Var(C) = 2\nu. \end{cases}$$

Para qualquer tamanho de amostra $n > 1$ e uma AA $X_1, X_2, \dots, X_n$ de qualquer distribuição populacional com média μ_x e variância σ_x^2 :

- $E(S^2) = \sigma_x^2$.
- $Var(S^2) = \frac{2\sigma_x^4}{n-1}$.

3.12.2 Distribuição Amostral quando os dados são Normais

Para qualquer tamanho de amostra $n > 1$ e uma AA $X_1, X_2, \dots, X_n$ originada de uma distribuição normal $N(\mu_x, \sigma_x^2)$:

$$\frac{(n-1)S^2}{\sigma_x^2} \sim \chi^2(n-1).$$

3.13 Distribuição Amostral de $\frac{\bar{X}-\mu}{S/\sqrt{n}}$

Na estatística inferencial, a estatística de teste $\frac{\bar{X}-\mu}{S/\sqrt{n}}$ é frequentemente utilizada para determinar a quantos erros padrões ($S/\sqrt{n}$) a média amostral $\bar{X}$ está de um valor hipotético μ . Portanto, a distribuição amostral desta razão é de extrema importância.

i Distribuição t de Student

Definição 2.1: Se $Z \sim N(0, 1)$, $W \sim \chi^2(\nu)$, e Z e W são independentes, então:

$$T = \frac{Z}{\sqrt{W/\nu}} \sim t(\nu),$$

em que $t(\nu)$ é chamada de **distribuição t com ν graus de liberdade**.
Se $T \sim t(\nu)$, então:

- $E(T) = 0$ para $\nu > 1$.
- $Var(T) = \frac{\nu}{\nu-2}$ para $\nu > 2$.

3.13.1 Distribuição Amostral quando os dados são Normais

Para qualquer tamanho de amostra $n > 1$ e uma AA $X_1, X_2, \dots, X_n$ de uma $N(\mu, \sigma^2)$:

- $\bar{X}$ e S^2 são independentes.
- Pelos Teoremas 2.1, 2.3 e Definição 2.1:

$$\frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

3.13.2 Distribuição Amostral para Grandes Amostras

Para um tamanho de amostra **GRANDE** n e uma AA $X_1, X_2, \dots, X_n$ de qualquer distribuição populacional com média μ_x e variância $\sigma_x^2 < \infty$:

$$T = \frac{\bar{X} - \mu_x}{S/\sqrt{n}} \sim t(n-1).$$

i Fatos Úteis

- **PDF de T:** A função densidade de probabilidade é dada por:

$$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})\sqrt{\nu\pi}} \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}.$$

- A distribuição t é simétrica em torno de 0 e possui formato de sino como a $N(0, 1)$, porém com **caudas mais pesadas** (mais grossas).
- Conforme $\nu \rightarrow \infty$, a distribuição $t(\nu)$ aproxima-se da distribuição normal padrão.
- Use a Tabela do SIGAA para cálculos de probabilidade.

Exemplos 6

Suponha que os níveis de colesterol em homens adultos sejam distribuídos como $N(210 \text{ mg/dL}, \sigma^2)$.

1. Forneça a distribuição amostral de $\frac{\bar{X}-\mu}{S/\sqrt{n}}$, onde as estatísticas $\bar{X}$ e S^2 são calculadas a partir de uma AA de tamanho $n = 10$.
2. Se $S^2 = 36, 5^2$, forneça um intervalo centrado na média μ que capture os 95% centrais de todos os valores de médias amostrais de colesterol obtidos de AAS de tamanho $n = 10$.

3.14 Distribuição Amostral da Razão de Variâncias

Na estatística inferencial, frequentemente o interesse recai sobre a comparação das variâncias σ_1^2 e σ_2^2 de duas populações distintas para determinar se são diferentes. Com base em duas AA, uma de tamanho n_1 com variância amostral S_1^2 e outra de tamanho n_2 com variância amostral S_2^2 , a estatística $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$ é utilizada.

i Distribuição F

Definição 2.2: Se $W_1 \sim \chi^2(\nu_1)$ e $W_2 \sim \chi^2(\nu_2)$ são independentes, então:

$$F = \frac{W_1/\nu_1}{W_2/\nu_2} \sim F(\nu_1, \nu_2).$$

A distribuição $F(\nu_1, \nu_2)$ possui ν_1 **graus de liberdade no numerador** e ν_2 **graus de liberdade no denominador**.

Se $F \sim F(\nu_1, \nu_2)$, então:

$$\begin{cases} E(F) = \frac{\nu_2}{\nu_2 - 2}, & \text{para } \nu_2 > 2; \\ Var(F) = \frac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}, & \text{para } \nu_2 > 4. \end{cases}$$

3.14.1 Distribuição Amostral quando os dados são Normais

Se $X_1, \dots, X_{n_1}$ é uma AA de $N(\mu_1, \sigma_1^2)$ e $Y_1, \dots, Y_{n_2}$ é uma AA independente de $N(\mu_2, \sigma_2^2)$, então as variáveis qui-quadrado são independentes:

$$W_1 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1 - 1) \quad \text{e} \quad W_2 = \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2 - 1).$$

Portanto,

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

Exemplo 7

A variância do tempo de reação de mulheres é diferente da variância do tempo de reação de homens? Jason Paulak (Universidade de Cincinnati) realizou um experimento *web* para responder a isso.

- **Mulheres** ($n_1 = 398$): $\bar{X}_1 = 517$ ms, $S_1 = 899$ ms.
- **Homens** ($n_2 = 469$): $\bar{X}_2 = 383,2$ ms, $S_2 = 335,7$ ms.

1. Forneça a distribuição amostral de $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$.
2. Se as duas variâncias populacionais forem de fato iguais ($\sigma_1^2 = \sigma_2^2$), qual é a probabilidade de observar uma razão de variâncias amostrais igual ou maior que a encontrada?

Lista

1. Considere que $Y \sim \text{Bin}(n = 5, p = 0,1)$.
 - (a) Use a função `pbinom()` do R para calcular $P(Y < 1)$.
 - (b) Qual distribuição normal aproxima esta distribuição binomial?
 - (c) Use a função `pnorm()` do R para utilizar a aproximação normal da binomial e calcular $P(Y < 1)$.
2. Suponha que $Y \sim \text{Bin}(n, p = 0,1)$. Encontre o menor tamanho de amostra n para que a probabilidade binomial exata $P(Y < 1)$ e a aproximação normal difiram por menos de 0,01.
3.
 - (a) Enuncie o Teorema Central do Limite.
 - (b) Demonstre o Teorema Central do Limite.
4. Enuncie a Lei Fraca dos Grandes Números. Certifique-se de declarar todas as suposições e apresentar uma conclusão adequada.

Referências

4 Avaliação de Estimadores e Princípios de Redução de Dados

4.1 Propriedades de Estimadores

Ao obter um estimador para um parâmetro desconhecido, é fundamental avaliar sua qualidade. Para isso, utilizamos algumas propriedades que permitem comparar estimadores e analisar seu comportamento, tanto em amostras finitas quanto assintoticamente. Seja $\hat{\theta}$ um estimador para o parâmetro θ .

Viés

A primeira propriedade de estimadores que abordaremos é o viés. O viés de um estimador mede se, em termos de valor esperado, o estimador é igual ao verdadeiro parâmetro.

Definição

Seja $\hat{\theta}$ um estimador para θ . O viés de $\hat{\theta}$ como estimador para θ é

$$B(\hat{\theta}, \theta) = E(\hat{\theta}) - \theta.$$

Se

- $B(\hat{\theta}, \theta) = 0$, ou equivalentemente $E(\hat{\theta}) = \theta$, então dizemos que $\hat{\theta}$ é um estimador não viesado de θ ;
- $B(\hat{\theta}, \theta) > 0$, então $\hat{\theta}$ superestima θ ;
- $B(\hat{\theta}, \theta) < 0$, então $\hat{\theta}$ subestima θ .

Um estimador não viesado, em média, acerta o valor do parâmetro.

Variância e Erro Quadrático Médio

Frequentemente, também estamos interessados em quanto um estimador varia (gostaríamos que ele fosse não viesado e tivesse pequena variância, para que seja mais preciso). Uma medida que captura essa propriedade dos estimadores é a variância do estimador.

A variância de um estimador $\hat{\theta}$ é dada por:

$$Var(\hat{\theta}) = E \left([\hat{\theta} - E(\hat{\theta})]^2 \right).$$

Essa é simplesmente a definição usual de variância aplicada à variável aleatória $\hat{\theta}$, não sendo uma nova definição.

No entanto, em vez de considerar apenas a variância, podemos querer uma medida que avalie diretamente o erro em relação ao verdadeiro parâmetro θ . Nesse caso, consideramos:

$$E [(\hat{\theta} - \theta)^2].$$

Essa quantidade é chamada de erro quadrático médio (EQM) e está relacionada tanto ao viés quanto à variância.

Observe que, se $\hat{\theta}$ for não viesado, então $E(\hat{\theta}) = \theta$, e, nesse caso, o EQM coincide com a variância.

Definição

O EQM de um estimador $\hat{\theta}$ de θ é

$$EQM(\hat{\theta}, \theta) = E [(\hat{\theta} - \theta)^2].$$

Se $\hat{\theta}$ é um estimador não viesado de θ (i.e. $E(\hat{\theta}) = \theta$), então podemos notar que $EQM(\hat{\theta}, \theta) = Var(\hat{\theta})$. De fato, em geral $EQM(\hat{\theta}, \theta) = Var(\hat{\theta}) + B(\hat{\theta}, \theta)^2$.

Isso leva ao que é conhecido como o “trade-off viés-variância” em aprendizado de máquina e estatística. Em geral, queremos minimizar o EQM, e essas duas quantidades costumam ser inversamente relacionadas. Ou seja, diminuir uma tende a aumentar a outra, e encontrar o equilíbrio entre elas é o que minimiza o EQM.

Pode ser difícil perceber por que isso acontece neste momento, já que ainda não estamos trabalhando com estimadores tão complexos (estamos apenas vendo os conceitos básicos!).

Consistência

Definição

Um estimador $\hat{\theta}_n$ (dependendo de n amostras iid) de θ é dito (fracamente) **consistente** se este converge (em probabilidade) para θ . Isto é, para qualquer $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \epsilon) = 0,$$

ou equivalentemente,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \epsilon) = 1.$$

Basicamente, quando $n \rightarrow \infty$, a probabilidade de $\hat{\theta}_n$ diferir de θ por mais de ϵ unidades é arbitrariamente pequena. A definição é um pouco abstrata, então analisamos o que ela significa no contexto de um exemplo. Lançamos uma moeda n vezes e seja $\hat{p}_n$ a proporção de caras obtidas, isto é, o número de caras dividido por n . Essa é uma proporção amostral que estima p , a probabilidade de a moeda resultar em cara. Suponha que $p = \frac{1}{2}$. Se $\hat{p}_n$ converge em probabilidade para $\frac{1}{2}$, então: i) $P(0,49 \leq \hat{p}_n \leq 0,51) \rightarrow 1$ quando $n \rightarrow \infty$; ii) $P(0,499 \leq \hat{p}_n \leq 0,501) \rightarrow 1$ quando $n \rightarrow \infty$; e assim por diante.

Dizemos que é consistente em erro quadrático médio (se um estimador é consistente em erro quadrático médio, então ele é fracamente consistente) se

$$\lim_{n \rightarrow \infty} EQM(\hat{\theta}, \theta) = 0.$$

Ambas essas noções referem-se ao comportamento assintótico de $\hat{\theta}$ e expressam que, à medida que os dados se acumulam, $\hat{\theta}$ se aproxima cada vez mais do verdadeiro valor de θ .

A consistência assintótica é uma propriedade desejável. No entanto, em um caso específico, para n fixo, ela pode ter relevância limitada.

Você pode estar se perguntando: qual é a diferença entre consistência e não-viés? De fato, existe uma diferença sutil, que podemos entender comparando estimadores para θ na distribuição contínua $\text{Unif}(0, \theta)$.

1. Estimador não viesado e consistente (MoM)

Um exemplo é o estimador de momentos:

$$\hat{\theta}_{n, \text{MoM}} = 2\bar{X}.$$

Ele é não viesado, isto é,

$$E[\hat{\theta}_{n, \text{MoM}}] = \theta,$$

e também consistente, pois sua variância tende a zero quando $n \rightarrow \infty$.

2. Não viesado, mas não consistente

Considere o estimador que utiliza apenas a primeira observação:

$$\hat{\theta} = 2X_1.$$

Ele é não viesado, pois

$$E[\hat{\theta}] = \theta.$$

No entanto, não é consistente, já que não melhora com o aumento de n , pois ignora as demais observações. A consistência exige que o estimador se aproxime de θ à medida que n cresce.

3. Viesado, mas consistente (EMV)

O estimador de máxima verossimilhança é:

$$\hat{\theta}_{n,\text{EMV}} = \max(X_1, \dots, X_n).$$

Sua esperança é dada por:

$$E[\hat{\theta}_{n,\text{EMV}}] = \frac{n}{n+1}\theta,$$

o que mostra que ele é viesado. No entanto,

$$\frac{n}{n+1}\theta \rightarrow \theta \quad \text{quando } n \rightarrow \infty,$$

ou seja, ele é assintoticamente não viesado e consistente.

4. Nem não viesado nem consistente

Um exemplo simples seria:

$$\hat{\theta} = \frac{1}{2}X_1,$$

que não é nem não viesado nem consistente.

Teorema (Resultados auxiliares para provar a consistência)

1. Se $\hat{\theta}_n$ é um estimador não viesado para θ e $\sigma_{\hat{\theta}_n}^2 \rightarrow 0$ quando $n \rightarrow \infty$, então $\hat{\theta}_n$ é consistente.
2. Suponha que o estimador $\hat{\theta}_n$ converge em probabilidade para θ e o estimador $\hat{\beta}_n$ converge em probabilidade para o parâmetro β . Então:
 - $\hat{\theta}_n + \hat{\beta}_n \xrightarrow{p} \theta + \beta$;
 - $\hat{\theta}_n \times \hat{\beta}_n \xrightarrow{p} \theta \times \beta$;
 - Se $\beta \neq 0$, $\hat{\theta}_n/\hat{\beta}_n \xrightarrow{p} \theta/\beta$;

- Se $g(x)$ é uma função contínua, então $g(\hat{\theta}_n) \xrightarrow{p} g(\theta)$.
- Para quaisquer sequências $\{a_n\}_{n \geq 1}$, $\{b_n\}_{n \geq 1}$, tal que $\lim_{n \rightarrow \infty} a_n = 1$ e $\lim_{n \rightarrow \infty} b_n = 0$, temos que

$$a_n \hat{\theta}_n + b_n \xrightarrow{p} \theta.$$

Eficiência

Para tratar do nosso último tópico, **eficiência**, precisamos primeiro definir a **Informação de Fisher**.

A eficiência está relacionada à ideia de que nosso estimador possui a menor variância possível. Quando essa propriedade é combinada com consistência e não-viés, temos um estimador que:

- está centrado no valor correto (*não viesado*);
- converge para o verdadeiro parâmetro (*consistente*);
- e faz isso da maneira mais rápida possível (*eficiente*).

💡 Informação de Fisher

Seja $\mathbf{x} = (x_1, \dots, x_n)$ uma amostra iid proveniente de uma distribuição discreta com função de massa de probabilidade $p_X(t \mid \theta)$, ou de uma distribuição contínua com função densidade $f_X(t \mid \theta)$, em que θ é um parâmetro (ou vetor de parâmetros).

A **Informação de Fisher** do parâmetro θ é definida por:

$$I(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \ln L(\mathbf{x} \mid \theta) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \ln L(\mathbf{x} \mid \theta) \right],$$

em que $L(\mathbf{x} \mid \theta)$ denota a função de verossimilhança dos dados dado o parâmetro θ (definida na Seção 4.3).

De acordo com a literatura, a Informação de Fisher “é uma forma de medir a quantidade de informação que uma variável aleatória observável carrega sobre um parâmetro desconhecido θ do qual depende a distribuição de probabilidade”.

A definição apresentada pode parecer bastante complicada à primeira vista, mas, se você analisá-la com calma, verá que não é tão difícil de trabalhar. De fato, ao verificar se o estimador de máxima verossimilhança é um ponto de máximo, já calculamos a segunda derivada da log-verossimilhança. Portanto, para obter a Informação de Fisher, basta dar um passo adicional: calcular a esperança dessa quantidade. No entanto, interpretar diretamente o valor esperado negativo da segunda derivada da log-verossimilhança não é nada intuitivo; trata-se de uma expressão pouco amigável e difícil de visualizar.

Limite Inferior de Cramér-Rao (CRLB) e Eficiência

Por que definimos essa “complicada” Informação de Fisher? (Na verdade, a situação fica ainda mais complexa quando θ é um vetor, pois a segunda derivada se torna uma matriz de derivadas parciais de segunda ordem.)

Seria ideal que o erro quadrático médio de um estimador $\hat{\theta}$ fosse o menor possível. O **Limite Inferior de Cramér-Rao (LICR)** fornece justamente um limite inferior para a variância de qualquer estimador não viesado de θ . Ou seja, se $\hat{\theta}$ é um estimador não viesado de θ , então existe uma variância mínima possível (lembrando que, para estimadores não viesados, variância = EQM). Se um estimador atinge essa menor variância possível, dizemos que ele é **eficiente**; uma propriedade altamente desejável em inferência estatística. Esse limite mínimo é conhecido como **Limite Inferior de Cramér-Rao**.

💡 Limite Inferior de Cramér-Rao

Seja $\mathbf{x} = (x_1, \dots, x_n)$ uma amostra iid proveniente de uma distribuição discreta com função de massa de probabilidade $p_X(t | \theta)$, ou de uma distribuição contínua com função densidade $f_X(t | \theta)$, em que θ é um parâmetro (ou vetor de parâmetros).

Se $\hat{\theta}$ é um estimador não viesado de θ , então:

$$\text{MSE}(\hat{\theta}, \theta) = \text{Var}(\hat{\theta}) \geq \frac{1}{I(\theta)},$$

em que $I(\theta)$ é a Informação de Fisher definida anteriormente.

O que esse resultado nos diz é que, para qualquer estimador não viesado $\hat{\theta}$ de θ , a variância (que, nesse caso, coincide com o EQM) é, no mínimo, $\frac{1}{I(\theta)}$.

Se atingimos esse limite inferior, isto é, se:

$$\text{Var}(\hat{\theta}) = \frac{1}{I(\theta)},$$

então temos a menor variância possível para o estimador. Nesse caso, dizemos que $\hat{\theta}$ é um **estimador não viesado de variância uniformemente mínima (ENVVUM)** para θ .

Como queremos encontrar a menor variância possível, podemos analisar esse problema sob a perspectiva da **eficiência do estimador**.

💡 Eficiência

Seja $\hat{\theta}$ um estimador não viesado de θ . A eficiência de $\hat{\theta}$ é definida por:

$$e(\hat{\theta}, \theta) = \frac{I(\theta)^{-1}}{\text{Var}(\hat{\theta})} \leq 1.$$

Esse valor estará sempre entre 0 e 1, pois, se a variância do estimador for igual ao LICR, então a eficiência será igual a 1. Caso a variância seja maior, a eficiência será menor que 1.

Assim, quanto maior a variância, menor a eficiência; e desejamos que a eficiência seja a maior possível (isto é, igual a 1).

Um estimador não viesado é dito **eficiente** se atinge o LICR, ou seja, quando:

$$e(\hat{\theta}, \theta) = 1.$$

Nesse caso, ele possui a menor variância possível entre todos os estimadores não viesados. Vale ressaltar que o LICR não é, em geral, garantido para estimadores viesados.

Estatística Suficiente

Suponha que temos uma amostra iid $\mathbf{x} = (x_1, \dots, x_n)$ proveniente de uma distribuição conhecida com parâmetro desconhecido θ . Imagine que temos duas pessoas:

- **Estatístico A:** conhece toda a amostra, ou seja, dispõe de n observações: $\mathbf{x} = (x_1, \dots, x_n)$.
- **Estatístico B:** conhece apenas $T(x_1, \dots, x_n) = t$, um único número que é função da amostra (por exemplo, a soma ou o máximo das observações).

Heuristicamente, $T(x_1, \dots, x_n)$ é uma **estatística suficiente** se o Estatístico B consegue fazer um trabalho tão bom quanto o Estatístico A, mesmo tendo “menos informação”. Por exemplo, se as observações seguem uma distribuição Bernoulli, conhecer

$$T(x_1, \dots, x_n) = \sum_{i=1}^n x_i,$$

(o número de sucessos) é tão informativo quanto conhecer todos os resultados individuais. Isso ocorre porque uma boa estimativa seria a proporção de sucessos, isto é, o número de sucessos dividido pelo número total de ensaios.

Assim, não nos importa a **ordem** dos resultados, mas apenas quantos sucessos ocorreram. A palavra “suficiente” sugere exatamente isso: uma quantidade de informação que é “suficiente” para inferência sobre o parâmetro.

💡 Estatística Suficiente

Uma estatística $T = T(X_1, \dots, X_n)$ é dita **suficiente** para o parâmetro θ se a distribuição condicional de $X_1, \dots, X_n$, dado $T = t$ e θ , não depende de θ . Isto é,

$$P(X_1 = x_1, \dots, X_n = x_n \mid T = t, \theta) = P(X_1 = x_1, \dots, X_n = x_n \mid T = t).$$

No caso em que $X_1, \dots, X_n$ são variáveis contínuas, substituímos a probabilidade por uma função densidade.

Para motivar a definição, retornamos ao exemplo anterior. Novamente, o Estatístico A possui toda a amostra $x_1, \dots, x_n$, enquanto o Estatístico B conhece apenas o número $t = T(x_1, \dots, x_n)$. A ideia é que o Estatístico B conhece apenas $T = t$, mas, como T é suficiente, ele não precisa conhecer θ para gerar novas amostras $X'_1, \dots, X'_n$ da distribuição.

Isso ocorre porque:

$$P(X_1 = x_1, \dots, X_n = x_n \mid T = t, \theta) = P(X_1 = x_1, \dots, X_n = x_n \mid T = t),$$

ou seja, a distribuição condicional não depende de θ . Como o Estatístico B conhece $T = t$, ele conhece essa distribuição condicional e pode gerar novas amostras.

Assim, o Estatístico B passa a ter n observações iid $X'_1, \dots, X'_n$ provenientes da mesma estrutura probabilística. Com essas novas observações, ele pode realizar inferência tão bem quanto o Estatístico A, que possui os dados originais $X_1, \dots, X_n$ (em média). Portanto, nenhum dos dois está em desvantagem. :)

Embora essa definição seja difícil de verificar diretamente, existe um critério que facilita a identificação de estatísticas suficientes:

❗ Critério da Fatoração de Neyman-Fisher

Sejam $x_1, \dots, x_n$ uma amostra iid com função de verossimilhança $L(x_1, \dots, x_n \mid \theta)$. Uma estatística $T = T(x_1, \dots, x_n)$ é suficiente para θ se, e somente se, existirem funções não negativas g e h tais que:

$$L(x_1, \dots, x_n \mid \theta) = g(x_1, \dots, x_n) \cdot h(T(x_1, \dots, x_n), \theta).$$

Ou seja, a verossimilhança dos dados pode ser fatorada como o produto de dois termos:

- o primeiro termo g pode depender de todos os dados, mas **não depende de θ** ;
- o segundo termo h pode depender de θ , mas depende dos dados **apenas por meio da estatística suficiente T** .

Em outras palavras, T é o único elemento que permite a interação entre os dados $x_1, \dots, x_n$ e o parâmetro θ . Assim, não precisamos acessar diretamente as n observações individuais, basta conhecer o valor de T .

Essas propriedades serão fundamentais para comparar métodos de estimação, como o método dos momentos e a máxima verossimilhança, discutidos ao longo deste capítulo.

Exemplo - Usando a Definição

Vamos analisar mais uma vez o exemplo do lançamento de moeda. Assim, $P(X_1 = 1) = \theta$, $P(X_1 = 0) = 1 - \theta$, e vamos considerar

$$T = n\bar{X} = X_1 + \cdots + X_n.$$

Afirmo que T é suficiente. Para verificar isso, recorde que

$$T \sim B(n, \theta),$$

de modo que

$$P(T = t) = \binom{n}{t} \theta^t (1 - \theta)^{n-t}.$$

Podemos focar no caso em que

$$x_1 + \cdots + x_n = t,$$

caso contrário, a probabilidade condicional $P(X_1 = x_1, \dots, X_n = x_n \mid T = t, \theta)$ será simplesmente igual a zero para todo θ . Sob essa hipótese adicional, a condição $T = t$ decorre de $X_1 = x_1, \dots, X_n = x_n$, de forma que a probabilidade de ambos os eventos ocorrerem é

$$P(X_1 = x_1, \dots, X_n = x_n) = \theta^{x_1 + \cdots + x_n} (1 - \theta)^{n - x_1 - \cdots - x_n},$$

e, como $x_1 + \cdots + x_n = t$,

$$= \theta^t (1 - \theta)^{n-t}.$$

Juntando tudo, obtemos

$$P(X_1 = x_1, \dots, X_n = x_n \mid T = t) = \frac{P(X_1 = x_1, \dots, X_n = x_n)}{P(T = t)}$$

$$= \frac{1}{\binom{n}{t}},$$

o que é independente de θ , como afirmado.

Esse resultado final poderia ter sido escrito imediatamente, sem qualquer cálculo: cada uma das $\binom{n}{t}$ sequências $x_1, \dots, x_n$ que contêm exatamente t uns é igualmente provável, dado que $T = t$.

Exemplo - Usando o Critério de Fatoração de Neyman–Fisher

Considere a distribuição Bernoulli de parâmetro θ . Então, temos que

$$\begin{aligned} L(x_1, x_2, \dots, x_n | \theta) &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \left(\prod_{i=1}^n \theta^{x_i} \right) \left(\prod_{i=1}^n (1 - \theta)^{1-x_i} \right) \\ &= \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} = \theta^{T(x_1, \dots, x_n)} (1 - \theta)^{n - T(x_1, \dots, x_n)}, \end{aligned}$$

Portanto,

$$g(x_1, \dots, x_n) = 1,$$

e

$$h(T(x_1, \dots, x_n), \theta) = \theta^{T(x_1, \dots, x_n)} (1 - \theta)^{n - T(x_1, \dots, x_n)}.$$

Pelo critério de Neyman-Fisher, $T(x_1, \dots, x_n) = \sum_{i=1}^n x_i$ é suficiente. A média

$$\hat{\theta}_{MV} = \frac{\sum_{i=1}^n x_i}{n},$$

também é, pois conhecer o número total de caras e a proporção amostral de caras é equivalente (já que conhecemos n !).

4.2 Completude

4.3 Família Exponencial

O modelo estatístico $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ forma uma **família exponencial s -dimensional** se cada função de probabilidade ou densidade pode ser escrita como:

$$f(x; \theta) = \exp \left\{ \sum_{j=1}^s c_j(\theta) T_j(x) + B(\theta) + h(x) \right\} I_A(x),$$

em que:

- $c_j(\theta)$ são funções do parâmetro;
- $T_j(x)$ são funções da observação;
- $B(\theta)$ está associado à constante de normalização;
- $h(x)$ depende somente da observação;
- o suporte A não depende de θ .

As famílias exponenciais são particularmente importantes porque incluem várias distribuições usuais e estão diretamente relacionadas à existência de estatísticas suficientes de dimensão fixa.

Se uma observação possui densidade

$$f(x; \theta) = \exp \left\{ \sum_{j=1}^s c_j(\theta) T_j(x) + B(\theta) + h(x) \right\} I_A(x),$$

então, para uma amostra iid $X_1, \dots, X_n$, a densidade conjunta é

$$\begin{aligned} f(\mathbf{x}; \theta) &= \prod_{i=1}^n f(x_i; \theta) \\ &= \exp \left\{ \sum_{j=1}^s c_j(\theta) \sum_{i=1}^n T_j(x_i) + nB(\theta) + \sum_{i=1}^n h(x_i) \right\} I_{A^n}(\mathbf{x}). \end{aligned}$$

Portanto,

$$T(\mathbf{X}) = \left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_s(X_i) \right)$$

é uma estatística suficiente para θ .

! Importante

Em uma família exponencial, a estatística suficiente natural para uma amostra é formada pelas somas das estatísticas componentes de cada observação.

Exemplo - Distribuição exponencial

Considere $X \sim \text{Exp}(\theta)$, $\theta > 0$, com θ representando a taxa. A fdp é

$$f(x; \theta) = \theta e^{-\theta x} I_{(0, \infty)}(x).$$

Podemos escrevê-la como

$$f(x; \theta) = \exp \{-\theta x + \log \theta\} I_{(0, \infty)}(x).$$

Assim,

$$c(\theta) = -\theta, \quad T(x) = x, \quad B(\theta) = \log \theta, \quad h(x) = 0, \quad A = (0, \infty).$$

Portanto, a distribuição exponencial forma uma família exponencial unidimensional.

Exemplo - Distribuição beta

Considere

$$X \sim \text{Beta}(\alpha, \beta), \quad \alpha, \beta > 0.$$

A densidade é

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)} I_{(0,1)}(x).$$

Uma representação exponencial é

$$f(x; \alpha, \beta) = \exp \left\{ \alpha \log x + \beta \log(1-x) - \log[x(1-x)] - \log B(\alpha, \beta) \right\} I_{(0,1)}(x).$$

Logo, trata-se de uma família exponencial bidimensional, com

$$c_1(\theta) = \alpha, \quad c_2(\theta) = \beta,$$

$$T_1(x) = \log x, \quad T_2(x) = \log(1 - x),$$

$$B(\theta) = -\log B(\alpha, \beta), \quad h(x) = -\log[x(1 - x)].$$

Exemplo - Distribuição Bernoulli

Considere

$$X \sim \text{Bernoulli}(\theta), \quad 0 < \theta < 1.$$

Sua função de probabilidade é

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x \in \{0, 1\}.$$

Como

$$\begin{aligned} f(x; \theta) &= \left(\frac{\theta}{1 - \theta} \right)^x (1 - \theta) \\ &= \exp \left\{ x \log \left(\frac{\theta}{1 - \theta} \right) + \log(1 - \theta) \right\}, \end{aligned}$$

temos uma família exponencial unidimensional com

$$c(\theta) = \log \left(\frac{\theta}{1 - \theta} \right), \quad T(x) = x,$$

$$B(\theta) = \log(1 - \theta), \quad h(x) = 0, \quad A = \{0, 1\}.$$

Exemplo - Distribuição normal com variância conhecida

Considere

$$X \sim N(\mu, 1), \quad \mu \in \mathbb{R}.$$

A densidade pode ser escrita como

$$\begin{aligned} f(x; \mu) &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{(x - \mu)^2}{2} \right\} \\ &= \exp \left\{ \mu x - \frac{\mu^2}{2} - \frac{x^2}{2} - \log \sqrt{2\pi} \right\}. \end{aligned}$$

Logo,

$$c(\mu) = \mu, \quad T(x) = x, \quad B(\mu) = -\frac{\mu^2}{2},$$

$$h(x) = -\frac{x^2}{2} - \log \sqrt{2\pi}, \quad A = \mathbb{R}.$$

Exemplo - Distribuição normal com variância desconhecida

Para

$$X \sim N(\mu, \sigma^2),$$

temos

$$f(x; \mu, \sigma^2) = \exp \left\{ -\frac{x^2}{2\sigma^2} + \frac{\mu}{\sigma^2} x - \frac{\mu^2}{2\sigma^2} - \frac{1}{2} \log \sigma^2 - \log \sqrt{2\pi} \right\}.$$

Essa é uma família exponencial bidimensional, com

$$T_1(x) = x, \quad T_2(x) = x^2,$$

$$c_1(\theta) = \frac{\mu}{\sigma^2}, \quad c_2(\theta) = -\frac{1}{2\sigma^2}.$$

Para uma amostra aleatória, as estatísticas

$$T_1(\mathbf{X}) = \sum_{i=1}^n X_i \quad \text{e} \quad T_2(\mathbf{X}) = \sum_{i=1}^n X_i^2$$

são conjuntamente suficientes para (μ, σ^2) .

4.4 Estimadores baseados em estatísticas suficientes

4.4.1 Teorema de Rao–Blackwell

Seja T uma estatística suficiente para θ e seja $S = S(\mathbf{X})$ um estimador de uma função $\tau(\theta)$. Defina

$$\tilde{\tau} = E_{\theta}(S \mid T).$$

Então $\tilde{\tau}$ é função de T e satisfaz

$$E_{\theta}(\tilde{\tau}) = E_{\theta}(S).$$

Além disso,

$$\text{Var}_{\theta}(\tilde{\tau}) \leq \text{Var}_{\theta}(S).$$

Consequentemente, quando S é não viesado para $\tau(\theta)$, o estimador $E(S \mid T)$ também é não viesado e possui variância não superior à de S .

4.4.2 Exemplo: estimação de $e^{-\theta}$ no modelo de Poisson

Considere

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\theta).$$

Queremos estimar

$$P_{\theta}(X = 0) = e^{-\theta}.$$

O estimador

$$S = I_{\{X_1=0\}}$$

é não viesado, pois

$$E_\theta(S) = P_\theta(X_1 = 0) = e^{-\theta}.$$

A estatística

$$T = \sum_{i=1}^n X_i$$

é suficiente para θ . Pelo teorema de Rao–Blackwell,

$$\tilde{\tau} = E(S \mid T) = P(X_1 = 0 \mid T).$$

Condicionalmente a $T = t$, o vetor $(X_1, \dots, X_n)$ possui distribuição multinomial com total t e probabilidades iguais a $1/n$. Assim,

$$P(X_1 = 0 \mid T = t) = \left(1 - \frac{1}{n}\right)^t.$$

Portanto,

$$\boxed{\tilde{\tau} = \left(1 - \frac{1}{n}\right)^{\sum_{i=1}^n X_i}}$$

é um estimador não viesado de $e^{-\theta}$, baseado na estatística suficiente T , e possui variância não superior à do estimador inicial S .

Exercícios

1. Considere a distribuição $N(0, \sigma)$ e seja $\theta = \sigma^2$. Encontre uma estatística suficiente.
2. Considere a distribuição $N(\theta, 1)$. Encontre uma estatística suficiente.
3. Considere a distribuição exponencial

$$f(x; \theta) = \theta e^{-\theta x}, \quad (x > 0).$$

Encontre uma estatística suficiente.

4. Considere a distribuição $U(0, \theta)$. Encontre uma estatística suficiente.
5. Considere a distribuição gama como ambos os parâmetros desconhecidos. Mostre que a soma e o produto formam uma estatística suficiente.

5 Métodos de Estimação Pontual

5.1 Método dos Momentos

A estimação por máxima verossimilhança (MV), como veremos nesse capítulo, possui uma intuição bastante elegante, mas pode ser matematicamente trabalhosa de resolver. Vamos aprender inicialmente uma técnica para estimar parâmetros, chamada método dos momentos (MoM).

As definições iniciais e a estratégia podem parecer confusas à primeira vista, mas apresentaremos vários exemplos que devem ajudar a tornar tudo mais claro.

Momentos (Revisão)

Seja X uma variável aleatória e $c \in \mathbb{R}$ um escalar. Então, o k -ésimo momento de X é:

$$E[X^k],$$

e o k -ésimo momento de X em torno de c é:

$$E[(X - c)^k].$$

Em geral, temos interesse especial no **primeiro momento** (média) de X : $\mu = E[X]$, e no **segundo momento em torno da média** (variância): $\text{Var}(X) = E[(X - \mu)^2]$.

Momentos Amostrais

Seja X uma variável aleatória e $x_1, \dots, x_n$ uma amostra i.i.d. de X . O k -ésimo momento amostral é:

$$\frac{1}{n} \sum_{i=1}^n x_i^k.$$

O k -ésimo momento amostral em torno de c é:

$$\frac{1}{n} \sum_{i=1}^n (x_i - c)^k.$$

Casos particulares importantes:

- O primeiro momento amostral é a **média amostral**;
- O segundo momento amostral em torno da média é a **variância amostral**.

5.1.1 Ideia por trás do método

A estimação pelo método dos momentos baseia-se exclusivamente na **Lei dos Grandes Números**, que relembramos a seguir:

Sejam $Y_1, Y_2, \dots$ variáveis aleatórias independentes com uma distribuição comum que possui média μ_Y . Então, as médias amostrais convergem para a média da distribuição à medida que o número de observações aumenta:

$$\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i \rightarrow \mu_Y \quad \text{quando } n \rightarrow \infty.$$

Para mostrar como o método dos momentos determina um estimador, consideramos inicialmente o caso de **um único parâmetro**.

Começamos com variáveis aleatórias independentes $X_1, X_2, \dots$, geradas segundo a função densidade de probabilidade $f_X(x | \theta)$, associada a um parâmetro desconhecido θ . A média comum das variáveis X_i , denotada por μ_X , é uma função $k(\theta)$ de θ . Por exemplo, se as X_i são variáveis aleatórias contínuas, então:

$$\mu_X = \int_{-\infty}^{\infty} x f_X(x | \theta) dx = k(\theta).$$

A Lei dos Grandes Números afirma que:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \mu_X \quad \text{quando } n \rightarrow \infty.$$

Assim, quando o número de observações n é grande, a média da distribuição $\mu = k(\theta)$ pode ser bem aproximada pela média amostral, isto é:

$$\bar{X} \approx k(\theta).$$

Essa relação pode ser transformada em um estimador $\hat{\theta}$, definindo:

$$\bar{X} = k(\hat{\theta}),$$

e resolvendo essa equação em relação a $\hat{\theta}$.

Na sequência, descreveremos o procedimento no caso de um **vetor de parâmetros** e apresentaremos diversos exemplos. Veremos também que o **método delta** pode ser utilizado para estimar a variância dos estimadores obtidos pelo método dos momentos.

5.1.2 Procedimento Geral do Método dos Momentos

De forma mais geral, para variáveis aleatórias independentes $X_1, X_2, \dots$, geradas segundo uma distribuição associada ao parâmetro θ , e sendo m uma função real, se $k(\theta) = E_\theta[m(X_1)]$, então

$$\frac{1}{n} \sum_{i=1}^n m(X_i) \rightarrow k(\theta) \quad \text{quando } n \rightarrow \infty.$$

O método dos momentos resulta das escolhas $m(x) = x^m$. Denotamos

$$\mu_m = E[X^m] = k_m(\theta). \quad (1)$$

para o m -ésimo momento.

Nosso procedimento de estimação segue os **4 passos** abaixo, que conectam os momentos amostrais aos parâmetros do modelo:

Passo 1

Se o modelo possui d parâmetros, calculamos as funções k_m na equação (1) para os primeiros d momentos:

$$\mu_1 = k_1(\theta_1, \theta_2, \dots, \theta_d), \quad \mu_2 = k_2(\theta_1, \theta_2, \dots, \theta_d), \quad \dots \quad \mu_d = k_d(\theta_1, \theta_2, \dots, \theta_d),$$

obtendo assim d equações em d incógnitas.

Passo 2

Resolvemos esse sistema para os d parâmetros como funções dos momentos:

$$\theta_1 = g_1(\mu_1, \mu_2, \dots, \mu_d), \quad \theta_2 = g_2(\mu_1, \mu_2, \dots, \mu_d), \quad \dots \quad \theta_d = g_d(\mu_1, \mu_2, \dots, \mu_d). \quad (2)$$

Passo 3

Com base nos dados $\mathbf{x} = (x_1, x_2, \dots, x_n)$, calculamos os primeiros d momentos amostrais:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \overline{x^2} = \frac{1}{n} \sum_{i=1}^n x_i^2, \quad \dots \quad \overline{x^d} = \frac{1}{n} \sum_{i=1}^n x_i^d.$$

Pela Lei dos Grandes Números, para cada momento $m = 1, \dots, d$, temos: $\mu_m \approx \overline{x^m}$.

Passo 4

Substituímos os momentos populacionais μ_m pelos momentos amostrais $\overline{x^m}$. Assim, as soluções em (2) fornecem as fórmulas dos estimadores de momentos $(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_d)$. Para os dados $\mathbf{x}$, esses estimadores são dados por:

$$\hat{\theta}_1(\mathbf{x}) = g_1(\bar{x}, \overline{x^2}, \dots, \overline{x^d}), \quad \hat{\theta}_2(\mathbf{x}) = g_2(\bar{x}, \overline{x^2}, \dots, \overline{x^d}), \quad \dots \quad \hat{\theta}_d(\mathbf{x}) = g_d(\bar{x}, \overline{x^2}, \dots, \overline{x^d}).$$

A forma como essa descrição abstrata funciona na prática é melhor compreendida por meio de exemplos.

Exemplo: Distribuição de Pareto

Sejam $X_1, X_2, \dots, X_n$ uma amostra aleatória simples de variáveis aleatórias com distribuição de Pareto, cuja densidade é dada por:

$$f_X(x | \theta) = \theta x^{-(\theta+1)}, \quad x > 1.$$

A função de distribuição acumulada é:

$$F_X(x) = 1 - x^{-\theta}, \quad x > 1.$$

A média e a variância são, respectivamente:

$$\mu = \frac{\theta}{\theta - 1}, \quad \sigma^2 = \frac{\theta}{(\theta - 1)^2(\theta - 2)}.$$

Neste caso, temos apenas **um parâmetro**, θ . Assim, no **Passo 1**, precisamos apenas do primeiro momento:

$$\mu_1 = \mu = k_1(\theta) = \frac{\theta}{\theta - 1}.$$

Passo 2

Resolvendo para θ em função da média μ :

$$\theta = g_1(\mu) = \frac{\mu}{\mu - 1}.$$

Passos 3 e 4

Substituindo a média populacional pela média amostral $\bar{X}$, obtemos o estimador de momentos:

$$\hat{\theta} = \frac{\bar{X}}{\bar{X} - 1}.$$

Variância via Método Delta

Um bom estimador deve ter variância pequena. Para estimar a variância de $\hat{\theta}$, utilizamos o **método delta**:

$$\sigma_{\hat{\theta}}^2 \approx [g'_1(\mu)]^2 \frac{\sigma^2}{n}.$$

Calculamos a derivada:

$$g'_1(\mu) = -\frac{1}{(\mu - 1)^2}.$$

Substituindo $\mu = \frac{\theta}{\theta - 1}$, obtemos:

$$g'_1(\mu) = -(\theta - 1)^2.$$

Assim, a variância aproximada é:

$$\sigma_{\hat{\theta}}^2 \approx \frac{(\theta - 1)^4}{n} \cdot \frac{\theta}{(\theta - 1)^2(\theta - 2)} = \frac{\theta(\theta - 1)^2}{n(\theta - 2)}.$$

Exemplo Numérico

Considere $\theta = 3$ e $n = 100$:

$$\sigma_{\hat{\theta}}^2 \approx \frac{3(3-1)^2}{100(3-2)} = \frac{12}{100} = \frac{3}{25}.$$

Logo, o desvio padrão aproximado é:

$$\sigma_{\hat{\theta}} \approx \sqrt{\frac{3}{25}} = 0,346.$$

Simulação em R

Para simular uma variável aleatória com distribuição de Pareto, usamos o método da transformação inversa. Se $U \sim \text{Uniforme}(0, 1)$, então:


$$X = (1 - U)^{-1/\theta}.$$

Código em R:


```
paretobar <- rep(0, 1000)

set.seed(14)
for (i in 1:1000){
  v <- runif(100)
  pareto <- 1 / v^(1/3)
  paretobar[i] <- mean(pareto)
}

hist(paretobar, xlab = expression(bar(X)), probability = TRUE, main = "")
```



```
betahat <- paretobar / (paretobar - 1)
hist(betahat, xlab = expression(hat(beta)), probability = TRUE, main = "")
```



```
mean(betahat)
```

```
[1] 3.054922
```

```
sd(betahat)
```

```
[1] 0.3213791
```

A média amostral do estimador de θ , igual a 3.0549, está próxima do valor verdadeiro do parâmetro considerado na simulação que foi 3. Neste exemplo, o estimador $\hat{\theta}$ apresenta **viés**

positivo. Em outras palavras, em média, a estimativa é maior que o verdadeiro valor do parâmetro, isto é: $E[\hat{\theta}] > \theta$. O desvio padrão amostral, igual a 0.3214, é próximo do valor **0.346** estimado pelo método delta. Quando estudarmos **estimadores não viesados**, veremos que esse viés já poderia ter sido antecipado.

Exemplo: Distribuição Uniforme Contínua

Considere $X \sim U(0, \theta)$. Sabemos que:

$$\mu = \frac{\theta}{2} \quad \text{e} \quad \sigma^2 = \frac{\theta^2}{12}.$$

Passo 1

Neste caso, também temos apenas **um parâmetro**, θ . Assim, no **Passo 1**, precisamos apenas do primeiro momento:

$$\mu_1 = \mu = k_1(\theta) = \frac{\theta}{2}.$$

Passo 2

Resolvendo para θ em função da média μ :

$$\theta = g_1(\mu) = 2\mu.$$

Passos 3 e 4

Substituindo a média populacional pela média amostral $\bar{X}$, obtemos o estimador de momentos:

$$\hat{\theta} = 2\bar{X}.$$

Esperança e Variância

Como o estimador obtido pelo MoM é função linear da média amostral, então é fácil obter seu valor esperado, basta usar propriedades de valores esperado e o fato de $E(\bar{X}) = \mu$. Assim, temos que

$$E(\hat{\theta}) = 2E(\bar{X}) = 2\left(\frac{\theta}{2}\right) = \theta.$$

portanto, $\hat{\theta}$ é um estimador não viciado. De maneira similar, podemos obter a expressão da variância de $\hat{\theta}$, usando propriedades de variância e o fato de $Var(\bar{X}) = \sigma^2/n$. Desta forma, temos que:

$$Var(\hat{\theta}) = 4Var(\bar{X}) = 4\left(\frac{\theta^2/12}{n}\right) = \frac{\theta^2}{3n}.$$

Além disso, pela Lei dos Grandes Números, temos que $\bar{X} \xrightarrow{p} \mu$ quando $n \rightarrow \infty$. Agora, usamos o fato de que a convergência em probabilidade é preservada por funções contínuas (no caso, multiplicar por 2):

$$\hat{\theta} = 2\bar{X} \xrightarrow{p} \theta,$$

mostrando que o estimador também é **consistente**.

Observação: Neste caso específico, o estimador de momentos coincide com um estimador simples baseado na média. No entanto, para a distribuição uniforme, o estimador de máxima verossimilhança é $\hat{\theta}_{MV} = \max(X_1, \dots, X_n)$, o que levanta uma interessante comparação entre métodos de estimação.

Exemplo: Distribuição Uniforme Discreta

Considere $X \sim U_d(A)$ com $A = 1, 2, \dots, \theta$ e $\theta \in \Theta = \{1, 2, \dots\}$. Sabemos que:

$$\mu = E_{\theta}(X) = \frac{1 + \theta}{2} \quad \text{e} \quad \sigma^2 = V(X) = \frac{\theta^2 - 1}{12}.$$

Passo 1

Neste caso, temos apenas um parâmetro, θ . Assim, utilizamos o primeiro momento:

$$\mu_1 = \mu = k_1(\theta) = \frac{1 + \theta}{2}.$$

Passo 2

Resolvendo para θ em função da média μ :

$$\theta = g_1(\mu) = 2\mu - 1.$$

Passos 3 e 4

Substituindo a média populacional pela média amostral $\bar{X}$, obtemos o estimador de momentos:

$$\hat{\theta} = 2\bar{X} - 1.$$

Esperança e Variância

Como o estimador obtido pelo método dos momentos é uma função linear da média amostral, podemos utilizar propriedades do valor esperado. Sabendo que $E(\bar{X}) = \mu$, temos:

$$E(\hat{\theta}) = 2E(\bar{X}) - 1 = 2\left(\frac{1 + \theta}{2}\right) - 1 = \theta.$$

Portanto, $\hat{\theta}$ é um estimador não viesado.

De maneira similar, utilizando o fato de que $Var(\bar{X}) = \sigma^2/n$, obtemos:

$$Var(\hat{\theta}) = 4Var(\bar{X}) = \frac{\theta^2 - 1}{3n}.$$

Além disso, como $\hat{\theta}$ é um estimador não viesado e sua variância é igual a zero, quando $n \rightarrow \infty$, logo $\hat{\theta}$ é um estimador consistente.

Comparação com o Estimador de Máxima Verossimilhança

Para a distribuição uniforme discreta, o estimador de máxima verossimilhança é dado por:

$$\hat{\theta}_{MV} = \max(X_1, X_2, \dots, X_n).$$

Esse resultado decorre do fato de que a função de verossimilhança é constante para $\theta \geq \max(X_i)$ e nula caso contrário, sendo maximizada no menor valor possível de θ que ainda torna a amostra observável.

Comparação entre os estimadores

- O estimador de momentos, $\hat{\theta}_{\text{MoM}} = 2\bar{X} - 1$, utiliza toda a informação da amostra, mas pode assumir valores não inteiros.
- O estimador de máxima verossimilhança, $\hat{\theta}_{MV} = \max(X_1, X_2, \dots, X_n)$, depende apenas do maior valor observado, mas sempre pertence ao espaço paramétrico.

Além disso:

- $\hat{\theta}_{\text{MoM}}$ é não viesado.
- $\hat{\theta}_{MV}$ é viesado (subestima o valor verdadeiro), pois $E(\max(X_1, X_2, \dots, X_n)) < \theta$, embora seja consistente.

Essa comparação ilustra uma diferença fundamental entre métodos de estimação: enquanto o método dos momentos busca reproduzir características médias da distribuição, o método de máxima verossimilhança está diretamente ligado à plausibilidade dos dados observados.

Exemplo: Distribuição Exponencial

Considere $X \sim \text{Exp}(\theta)$. Sabemos que:

$$\mu = E(X) = \frac{1}{\theta} \quad \text{e} \quad \sigma^2 = V(X) = \frac{1}{\theta^2}.$$

Passo 1

Neste caso, temos apenas um parâmetro, λ . Assim, utilizamos o primeiro momento:

$$\mu_1 = \mu = k_1(\theta) = \frac{1}{\theta}.$$

Passo 2

Resolvendo para θ em função da média μ :

$$\theta = g_1(\mu) = \frac{1}{\mu}.$$

Passos 3 e 4

Substituindo a média populacional pela média amostral $\bar{X}$, obtemos o estimador de momentos:

$$\hat{\theta} = \frac{1}{\bar{X}}.$$

Esperança e Variância

Note que o estimador $\hat{\theta}$ não é uma função linear da média amostral, o que torna a análise de suas propriedades um pouco mais envolvida. Sabemos que $S = \sum_{i=1}^n X_i \sim \text{Gama}(n, \theta)$, o que implica que:

$$\bar{X} \sim \text{Gama}(n, n\theta).$$

Além disso, é possível mostrar que $\hat{\theta} = 1/\bar{X}$ segue uma distribuição gama inversa (GI) de parâmetros n e $n\theta$, ou seja

$$\frac{1}{\bar{X}} \sim \text{GI}(n, n\theta).$$

Consequentemente, a média e a variância são:

$$E(\hat{\theta}) = \frac{n\theta}{n-1} \quad (n > 1) \quad \text{e} \quad \text{Var}(\hat{\theta}) = \frac{n^2\theta^2}{(n-1)^2(n-2)} \quad (n > 2).$$

Além disso, como $\bar{X} \xrightarrow{p} \mu = \frac{1}{\theta}$ quando $n \rightarrow \infty$, segue que:

$$\hat{\theta} = \frac{1}{\bar{X}} \xrightarrow{p} \theta,$$

pois a função $g(x) = 1/x$ é quase-certamente contínua, i.e., é contínua no suporte considerado, mostrando que o estimador é consistente.

Exemplo: Distribuição Gama

Considere $X \sim \text{Gama}(\theta_1, \theta_2)$, em que:

$$\mu = E[X] = \frac{\theta_1}{\theta_2}, \quad \text{e} \quad \sigma^2 = \text{Var}(X) = \frac{\theta_1}{\theta_2^2}.$$

Passo 1

Neste caso, temos dois parâmetros, α e β . Assim, utilizamos o primeiro e o segundo momento:

$$\mu_1 = k_1(\theta_1, \theta_2) = \frac{\theta_1}{\theta_2} \quad \text{e} \quad \mu_2 = k_2(\theta_1, \theta_2) = \frac{\theta_1(1 + \theta_1)}{\theta_2^2}.$$

Passo 2

Resolvendo para θ_1 e θ_2 em função de μ_1 e μ_2 :

$$\theta_1 = g(\mu_1, \mu_2) = \frac{\mu_1^2}{\mu_2 - \mu_1^2} \quad \text{e} \quad \theta_2 = g(\mu_1, \mu_2) = \frac{\mu_1}{\mu_2 - \mu_1^2}.$$

Passos 3 e 4

Substituindo a média populacional pela média amostral $\bar{X}$ e segundo momento populacional pelo segundo momento amostral, obtemos os seguintes estimadores de momentos:

$$\hat{\theta}_1 = \frac{\bar{X}^2}{\hat{\sigma}^2} \quad \text{e} \quad \hat{\theta}_2 = \frac{\bar{X}}{\hat{\sigma}^2}$$

em que:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

Exercícios

1. O **múon** é uma partícula elementar com carga elétrica -1 e spin (momento angular intrínseco) igual a $\frac{1}{2}$. Trata-se de uma partícula subatômica instável com tempo de

vida médio de $2,2 \mu s$.

Os múons possuem massa aproximadamente **200 vezes maior** que a massa do elétron. Como o múon tem a mesma carga e spin que o elétron, ele pode ser visto como uma versão muito mais pesada do elétron.

A colisão de um feixe de prótons (p) acelerados, com energia de 600 MeV (milhões de elétron-volts), com os núcleos de um alvo de produção gera píons positivos (π^+) por meio de uma das seguintes reações:

$$p + p \rightarrow p + n + \pi^+ \quad \text{ou} \quad p + n \rightarrow n + n + \pi^+.$$

A partir do decaimento subsequente dos píons (tempo de vida médio de 26,03 ns), múons positivos (μ^+) são formados via o decaimento de dois corpos:

$$\pi^+ \rightarrow \mu^+ + \nu_\mu,$$

em que ν_μ representa o **neutrino do múon**.

O decaimento do múon em um pósitron (e^+), um neutrino do elétron (ν_e) e um antineutrino do múon ($\bar{\nu}_\mu$):

$$\mu^+ \rightarrow e^+ + \nu_e + \bar{\nu}_\mu,$$

possui uma distribuição angular t com densidade dada por:

$$f(t | \alpha) = \frac{1}{2\pi}(1 + \alpha \cos t), \quad 0 \leq t \leq 2\pi,$$

em que t é o ângulo entre a trajetória do pósitron e o spin do μ^+ , e o parâmetro de anisotropia $\alpha \in [-1/3, 1/3]$ depende da polarização do feixe de múons e da energia do pósitron. Com base nas observações $t_1, \dots, t_n$, obtenha o estimador de momentos $\hat{\alpha}$ para α .

Observação: Neste caso, a média é igual a π para todos os valores de α . Portanto, será necessário utilizar o **segundo momento** para obter um estimador.

2. Sejam $x_1, x_2, \dots, x_n$ uma amostra i.i.d. de $X \sim N(\theta_1, \theta_2)$, em que θ_1 é a média e θ_2 é a variância. Queremos obter o estimador de momentos para o vetor de parâmetros: $\theta = (\theta_1, \theta_2)$. Verifique se o estimador é viesado e obtenha sua variância.
3. Verifique se os estimadores de momentos dos parâmetros que indexam a distribuição gama são consistentes.

5.2 Método de Máxima Verossimilhança

Nesta seção, apresentamos exemplos de estimação por máxima verossimilhança (MV). A ideia central é simples:

Encontrar o valor de θ que maximiza a verossimilhança dos dados observados.

Na Estimação por MV, utilizamos uma amostra iid $X_1, X_2, \dots, X_n$ de alguma distribuição com parâmetro(s) desconhecido(s) θ , com o objetivo de estimar θ .

$$\hat{\theta} = \arg \max_{\theta} L(\theta | x) = \arg \max_{\theta} \prod_{i=1}^n f_X(x_i | \theta).$$

Observação: Recorde que, na descrição em palavras, o que fizemos para encontrar $\hat{\theta}$ foi calcular a verossimilhança; que é a probabilidade de observar os dados dado o parâmetro θ ; e escolher o “melhor” θ , ou seja, aquele que maximiza essa verossimilhança.

Exemplo EMV (Poisson)

Suponha que $X_1, X_2, \dots, X_n$ sejam amostras iid de uma distribuição Poisson com parâmetro θ . Qual é o EMV de θ ?

Passo 1: Calcule a verossimilhança e a log-verossimilhança dos dados

Para fazer isso, tomamos o seguinte produto das funções de probabilidade (FP's) da Poisson em cada observação x_i , considerando todos os pontos de dados.

$$L(\theta | x) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!}.$$

Novamente, isso representa a probabilidade de observar x_1 , depois x_2 , e assim por diante. Essa função é bastante difícil de derivar, então, para facilitar, vamos calcular a log-verossimilhança, utilizando as seguintes identidades:

$$\ln(ab) = \ln(a) + \ln(b), \quad \ln(a/b) = \ln(a) - \ln(b), \quad \text{e} \quad \ln(a^b) = b \ln(a).$$

Na maioria dos casos, queremos otimizar a log-verossimilhança em vez da verossimilhança (pois não queremos utilizar a regra do produto do cálculo)!