

Métodos Inferenciais

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa Modelos de Sobrevida e Aplicações.

**Versão Preliminar
- Em Elaboração -**



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro resulta da experiência acumulada no ensino, na orientação de estudantes e no desenvolvimento de pesquisas em modelos de regressão. Somos docentes pesquisadores do Departamento de Estatística e Matemática Aplicada da Universidade Federal do Ceará (DEMA/UFC), com atuação contínua em regressão linear, modelagem estatística e inferência. Integramos o Laboratório de Inovação em Estatística — StatLab/UFC (<https://statlab.quarto.pub/>) e o Grupo de Pesquisa *Modelos de Sobrevivência e Aplicações* do CNPq (<http://dgp.cnpq.br/dgp/espelhogrupo/9639095385610769>), espaços nos quais articulamos ensino, pesquisa e aplicação a problemas reais.

O material tem como base as disciplinas Inferência Estatística I (CC0288), Análise Inferencial (CC0448) e Inferência Estatística (CCPXXX). Ao longo dos anos, consolidamos a convicção de que ensinar regressão exige equilíbrio entre rigor teórico e clareza interpretativa.

O livro desenvolve os conceitos de Inferência Estatística de forma progressiva, enfatizando interpretação e propriedades. A implementação é realizada integralmente no **R** (ou **Python**), utilizado como ambiente de experimentação conceitual e não apenas como ferramenta computacional.

Os fundamentos matemáticos mais densos são apresentados em apêndices específicos, preservando o fluxo didático do texto principal e permitindo diferentes níveis de aprofundamento. Acreditamos que inferência deve ser ensinada como base para tomada de decisão, com atenção às suas suposições, limitações e implicações práticas.

Esperamos que este livro contribua para a formação de profissionais capazes tomar decisões com rigor técnico, pensamento estatístico crítico e responsabilidade analítica.

Identificação da(s) Disciplina(s)

- Curso: Bacharelado em Ciência de Dados e Mestrado em Modelagem e Métodos Quantitativos (PPGMMQ)
- Disciplina: Análise Inferencial (Graduação) e Inferência Estatística (Mestrado)
- Carga Horária: 96 horas (Graduação) e 64 horas (Mestrado)
- Créditos: 6 (Graduação) e 4 (Mestrado)
- Regime: Semestral
- Pré-requisitos: Modelos Probabilísticos (CC0446) (Graduação)
- Período Letivo: 2026.2
- Professor(a): Dr. Manoel Santos-Neto (Graduação) e Dr. Rafael Bráz (Mestrado)

EMENTA

Nível	Ementa
Graduação	Conceitos de população e amostra; parâmetros, estatísticas, estimadores e suas propriedades; distribuições amostrais; métodos de estimação pontual: método dos momentos, máxima verossimilhança e mínimos quadrados; estimação intervalar; testes de hipóteses; testes de homogeneidade e independência.

Nível	Ementa
Mestrado	Conceitos de inferência. Avaliação de estimadores. Princípios da suficiência e completividade. Função de verossimilhança. Estimção pontual: método dos momentos, máxima verossimilhança, mínimos quadrados, minimax e equivariância. Distribuição assintótica dos estimadores. Método delta. Algoritmo EM. Estimção intervalar. Testes de hipóteses. Testes mais poderosos. Teste da razão de verossimilhança. Testes assintóticos. Testes de aderência. Testes de independência.

OBJETIVO GERAL

Apresentar os fundamentos da inferência estatística, capacitando o discente a formular, analisar e interpretar problemas inferenciais em contextos de análise de dados, com ênfase na quantificação da incerteza, validação de modelos e capacidade de generalização.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- compreender a diferença entre população, amostra, parâmetro e estatística;
- interpretar estatísticas como variáveis aleatórias;
- compreender e utilizar distribuições amostrais;
- aplicar métodos de estimção pontual e intervalar;
- formular e testar hipóteses estatísticas de forma adequada;
- interpretar corretamente p-valores, intervalos de confiança e decisões inferenciais;
- analisar criticamente resultados estatísticos obtidos a partir de dados reais.

CONTEÚDO PROGRAMÁTICO

Unidade I – Fundamentos da Inferência Estatística

- Motivação para a inferência: conceitos de população, amostra e parâmetros
- Estatísticas e estimadores como funções da amostra
- Função de verossimilhança: definição e papel central na inferência clássica

Unidade II – Distribuições Amostrais

- Estatísticas como variáveis aleatórias e suas distribuições amostrais
- Distribuição amostral da média e da proporção
- Lei dos Grandes Números
- Teorema Central do Limite

Unidade III – Avaliação de Estimadores e Princípios de Redução de Dados

- Propriedades de pequenas amostras: viés, variância e erro quadrático médio
- Propriedades assintóticas: consistência e eficiência assintótica
- Princípio da Suficiência: definições formais, Critério de Fatoração de Neyman-Fisher e suficiência minimal
- Princípio da Completividade e Unicidade
- Família Exponencial: formas canônicas, posto completo e estatísticas completas e suficientes
- Teorema de Rao-Blackwell e Teorema de Lehmann-Scheffé: construção do Estimador Não-Viesado de Variância Uniformemente Mínima (ENVVUM)

Unidade IV – Métodos de Estimação Pontual

- Método dos momentos e suas aplicações
- Máxima verossimilhança: procedimentos, propriedades de invariância e otimalidade
- Mínimos quadrados: derivação, propriedades e relação com máxima verossimilhança
- Estimadores Minimax e Equivariância: critérios de risco e simetrias (locação e escala)
- Método Delta e Distribuição assintótica dos estimadores
- Algoritmo EM: estimação com dados ausentes ou não observáveis

Unidade V – Estimação Intervalar

- Conceitos e interpretação correta dos intervalos de confiança
- Métodos de construção: Método da Quantidade Pivotal e Inversão de Testes
- Intervalos baseados em aproximações assintóticas (Grandes amostras)

Unidade VI – Testes de Hipóteses e Análise de Dados Categóricos

- Fundamentos: hipóteses nula/alternativa, estatísticas de teste, p-valor e decisões
- Teoria de erros (Tipo I e II) e Poder do teste
- Testes mais poderosos: Lema de Neyman-Pearson e Testes Uniformemente Mais Poderosos
- Teste da razão de verossimilhança e sua versão generalizada
- Análise de Variáveis Categóricas: Testes qui-quadrado, testes de aderência, independência e homogeneidade em tabelas de contingência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, articuladas com atividades práticas computacionais. O conteúdo teórico será constantemente ilustrado por simulações e análises de dados reais, utilizando ferramentas computacionais (R ou Python).

AVALIAÇÃO

A avaliação será contínua e composta por:

Nível	Atividades
Graduação	• Listas obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.
Mestrado	• Listas semanais obrigatórias, incluindo atividades computacionais com interpretação estatística: 30%. • Projeto final de inferência estatística aplicado a dados reais: 30%. • Avaliação conceitual individual, por meio de prova ou atividade equivalente: 40%.

A aprovação na disciplina seguirá os critérios estabelecidos pelas normas vigentes da UFC.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados nos trabalhos e atividades:

Nível	CrITÉrios
Graduação	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.
Mestrado	• Correção conceitual. • Adequação metodológica. • Clareza na formulação do problema inferencial. • Interpretação estatística correta dos resultados. • Organização, clareza e reprodutibilidade das análises.

BIBLIOGRAFIA BÁSICA

Nível	Bibliografias
Graduação	1. Bussab, W. O.; Morettin, P. A. <i>Estatística Básica</i> . 6 ^a ed. São Paulo: Saraiva, 2010.2. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. New York: Duxbury Press, 2001.3. Casella, G.; Berger, R. L. <i>Inferência Estatística</i> . Tradução da 2 ^a edição. São Paulo: Cengage Learning, 2011.
Mestrado	1. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.2. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Coleção Matemática Aplicada. Rio de Janeiro: SBM, 2001.3. Casella, G.; Berger, R. L. <i>Statistical Inference</i> . 2nd ed. New York: Duxbury Press, 2001.

BIBLIOGRAFIA COMPLEMENTAR

Nível	Bibliografias
Graduação	1. Devore, J. L. <i>Probabilidade e Estatística para Engenharia e Ciências</i> . São Paulo: Thomson, 2006.2. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i> . 3rd ed. New York: McGraw-Hill, 1974.3. Bolfarine, H.; Sandoval, M. C. <i>Introdução à Inferência Estatística</i> . Rio de Janeiro: SBM, 2001.4. Bickel, P. J.; Doksum, K. A. <i>Mathematical Statistics</i> . Vol. I, 2nd ed. New Jersey: Prentice Hall, 2007.5. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i> . New York: John Wiley, 1988.

Nível	Bibliografias
Mestrado	1. Casella, G.; Berger, R. L. <i>Inferência Estatística</i>. Tradução da 2^a edição norte-americana. São Paulo: Cengage Learning, 2001.2. Dudewicz, E. J.; Mishra, S. N. <i>Modern Mathematical Statistics</i>. New York: John Wiley, 1988.3. Lehmann, E. L.; Casella, G. <i>Theory of Point Estimation</i>. 2nd ed. New York: Springer, 2003.4. Lehmann, E. L.; Romano, J. P. <i>Testing Statistical Hypotheses</i>. 3rd ed. New York: Springer, 2010.5. Mood, A. M.; Graybill, F. A.; Boes, D. C. <i>Introduction to the Theory of Statistics</i>. 3rd ed. New York: McGraw-Hill, 1974.6. Rohatgi, V. K. <i>Statistical Inference</i>. New York: Dover, 2003.7. Shao, J. <i>Mathematical Statistics</i>. 2nd ed. New York: Springer, 2004.

1 Preliminares

Neste capítulo iremos apresentar parte da base necessária para o bom desenvolvimento da disciplina.

1.1 Alguns resultados matemáticos importantes

1.1.1 Soma de Potências e a Fórmula de Faulhaber

O estudo de somatórios é fundamental em diversas áreas da matemática, especialmente em Estatística, Análise Numérica e Ciência de Dados. Neste e-book, exploramos uma ferramenta poderosa: a Fórmula de Faulhaber, que permite calcular somas de potências de forma exata e eficiente.

Considere o seguinte problema:

$$1 + 2 + \cdots + 99 + 100.$$

Somar termo a termo pode ser trabalhoso. No entanto, existe uma fórmula fechada:

$$\sum_{i=1}^n i = \frac{n(n+1)}{2}.$$

Essa expressão mostra que podemos substituir uma soma por uma função simples.

Algumas somas importantes:

$$\sum_{k=1}^n k = \frac{n(n+1)}{2}$$

$$\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}$$

$$\sum_{k=1}^n k^3 = \left(\frac{n(n+1)}{2} \right)^2$$

Observe que todas resultam em polinômios em n . Podemos observar que:

- Soma de grau 1 $\rightarrow$ polinômio grau 2;
- Soma de grau 2 $\rightarrow$ polinômio grau 3;
- Soma de grau 3 $\rightarrow$ polinômio grau 4.

Isso sugere um padrão geral.

A fórmula geral para a soma de potências é:

$$\sum_{k=1}^n k^p = \frac{1}{p+1} \sum_{r=0}^p \binom{p+1}{r} B_r n^{p+1-r},$$

em que B_r são os números de [Bernoulli](#).

Essa fórmula mostra que qualquer soma desse tipo pode ser escrita como um polinômio.

1.1.2 Coeficiente Binomial

O coeficiente binomial é um dos conceitos mais importantes da Matemática Discreta, com aplicações em Estatística, Probabilidade, Combinatória e Ciência de Dados.

Ele responde a uma pergunta fundamental:

De quantas formas podemos escolher k elementos de um conjunto com n elementos?

O coeficiente binomial é definido como o número de subconjuntos de tamanho k que podem ser formados a partir de um conjunto com n elementos:

$$\binom{n}{k}.$$

O coeficiente binomial pode ser calculado por:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!},$$

em que $n!$ é o fatorial de n .

Essa fórmula permite cálculo direto e eficiente. A ideia por trás da fórmula:

- $n!$ $\rightarrow$ todas as permutações possíveis;
- $k!$ $\rightarrow$ remove a ordem dos elementos escolhidos;

- $(n - k)! \rightarrow$ remove a ordem dos elementos não escolhidos.

Resultado: número de combinações (ordem não importa).

! Exemplo

Escolher 2 elementos de um conjunto com 4:

$$\binom{4}{2} = 6.$$

1.1.2.1 Propriedades Importantes

1. Simetria

$$\binom{n}{k} = \binom{n}{n - k}.$$

Escolher k elementos é equivalente a excluir $n - k$.

2. Relação de Pascal

$$\binom{n}{k} = \binom{n - 1}{k - 1} + \binom{n - 1}{k}.$$

Essa propriedade é a base do Triângulo de Pascal. Os coeficientes binomiais podem ser organizados em uma estrutura triangular:

$$\begin{array}{ccccccc} & & & & & & 1 \\ & & & & & & 1 & 1 \\ & & & & & 1 & 2 & 1 \\ & & & 1 & 3 & 3 & 1 \\ & 1 & 4 & 6 & 4 & 1 \end{array}$$

Cada número é a soma dos dois acima. Os coeficientes aparecem na expansão de:

$$(x + y)^n = \sum_{k=0}^n \binom{n}{k} x^{n-k} y^k.$$

! Exemplo

$$(1 + x)^4 = 1 + 4x + 6x^2 + 4x^3 + x^4.$$

1.1.3 Progressão Geométrica

A Progressão Geométrica (PG) é uma sequência numérica amplamente utilizada em Matemática, Estatística, Economia e Ciências Naturais. Ela descreve fenômenos que crescem ou decrescem de forma multiplicativa.

! Definição:

Uma PG é uma sequência em que cada termo, a partir do segundo, é obtido multiplicando o termo anterior por uma constante chamada razão.

$$a_n = a_1 \cdot q^{n-1},$$

em que a_1 é o primeiro termo, q é a razão e n é a posição do termo.

O termo geral de uma PG é dado por:

$$a_n = a_1 \cdot q^{n-1}.$$

Isso permite calcular qualquer termo diretamente.

1.1.3.1 Soma dos n primeiros termos ($q \neq 1$)

$$S_n = a_1 \cdot \frac{q^n - 1}{q - 1}.$$

ou

$$S_n = a_1 \cdot \frac{1 - q^n}{1 - q}.$$

1.1.3.2 Soma infinita ($|q| < 1$)

Quando a PG é convergente:

$$S = \frac{a_1}{1 - q}.$$

1.1.4 Série de Taylor

A Série de Taylor é uma ferramenta fundamental da Análise Matemática que permite representar funções como somas infinitas de potências.

 Definição:

A expansão em série de Taylor de uma função f em torno de $x = 0$ (Série de Maclaurin) é dada por:

$$f(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} x^k,$$

em que $f^{(k)}(0)$ representa a k -ésima derivada de f avaliada em 0.

1.1.4.1 Caso especial: Função exponencial

Um dos casos mais importantes é a expansão da função exponencial:

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}.$$

Essa igualdade é válida para todo $x \in \mathbb{R}$.

1.2 Função de Distribuição

Sendo X uma variável aleatória em $(\Omega, \mathcal{F}, \mathcal{P})$, sua função de distribuição é definida por:

$$F_X(x) = \Pr(X \leq x),$$

com x percorrendo todos os reais.

O conhecimento da função de distribuição permite obter qualquer informação sobre a variável. Importante destacar que, mesmo que a variável só assuma valores num subconjunto dos reais, a função de distribuição é definida em toda reta.

Uma função de distribuição de uma variável aleatória X em $(\Omega, \mathcal{F}, \mathcal{P})$ obedece às seguintes propriedades:

P1) $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.

P2) F é contínua à direita.

P3) F é não decrescente, isto é, $F_X(x) \leq F_X(y)$ sempre que $x \leq y, \forall x, y \in \mathbb{R}$.

1.3 Variável Aleatória Discreta e função de Probabilidade

Uma variável aleatória é classificada como *discreta*, se assume somente um número enumerável de valores (finito ou infinito). A função de probabilidade de uma variável aleatória discreta é a função que atribui probabilidade a cada um dos possíveis valores assumidos pela variável. Isto é, sendo X uma variável com valores $x_1, x_2, \dots, x_n, \dots$ temos para $i = 1, 2, \dots$

$$p(x_i) = \Pr(X = x_i) = \Pr(\{\omega \in \Omega : X(\omega) = x_i\}).$$

A função de probabilidade de X em $(\Omega, \mathcal{F}, \mathcal{P})$ satisfaz:

$$\text{P1)} \quad 0 \leq p(x_i) \leq 1, \forall i = 1, 2, \dots,$$

$$\text{P2)} \quad \sum_i p(x_i) = 1,$$

com a soma percorrendo todos os possíveis valores (eventualmente infinitos).

1.4 Variável Aleatória Contínua e função Densidade

Uma variável aleatória X em $(\Omega, \mathcal{F}, \mathcal{P})$, com função de distribuição F , será classificada como contínua, se existir uma função f tal que:

$$F_X(x) = \int_{-\infty}^x f_X(\omega) d\omega, \quad \text{para todo } x \in \mathbb{R}.$$

A função f é denominada *função densidade*.

A função densidade de X em $(\Omega, \mathcal{F}, \mathcal{P})$ satisfaz:

$$\text{P1)} \quad f(x) \geq 0, \forall x \in \mathbb{R}.$$

$$\text{P2)} \quad \int_{-\infty}^{+\infty} f_X(\omega) d\omega = 1.$$

1.5 Independência

Ver [Link!](#)

1.6 Valor Esperado

Ver [Link!](#)

1.7 Variância

Ver [Link!](#)

1.8 Covariância

O resultado a seguir mostra que a esperança de um produto de variáveis aleatórias independentes é igual ao produto de suas esperanças.

i Proposição 1:

Se X e Y são independentes, então, para quaisquer funções h e g ,

$$E[g(X)h(Y)] = E[g(X)]E[h(X)].$$

Demonstração: Suponha que X e Y sejam variáveis aleatórias conjuntamente contínuas com função densidade conjunta $f(x, y)$. Então,

$$\begin{aligned} E[g(X)h(Y)] &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x)h(y)f(x, y)dxdy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x)h(y)f(x)f(y)dxdy \\ &= \int_{-\infty}^{+\infty} g(x)f(x)dx \int_{-\infty}^{+\infty} h(y)f(y)dy \\ &= E[g(X)]E[h(Y)]. \end{aligned}$$

A demonstração para o caso discreto pode ser feita de maneira similar.

! Definição 1:

A covariância entre X e Y , representada como $Cov(X, Y)$, é definida como

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Desenvolvendo o lado direito da definição acima, temos que

$$\begin{aligned} Cov(X, Y) &= E[\text{_____} - \text{_____} - \text{_____} + \text{_____}] \\ &= \text{_____} - \text{_____} - \text{_____} + \text{_____} \\ &= E[XY] - E[X]E[Y]. \end{aligned}$$

Note que, se X e Y são independentes, então, pela Proposição 1, $Cov(X, Y) = 0$. No entanto, o inverso não é verdade.

i Proposição 2:

- i) $Cov(X, Y) = Cov(Y, X)$;
- ii) $Cov(X, X) = Var(X)$;
- iii) $Cov(aX, Y) = aCov(X, Y)$.
- iv) $Cov\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m Cov(X_i, Y_j)$.

Fazendo $Y_j = X_j$ e considerando as propriedades (ii) e (iv) da Proposição 2, temos que

$$\begin{aligned} Var\left(\sum_{i=1}^n X_i\right) &= Cov\left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\right) \\ &= \sum_{i=1}^n \sum_{j=1}^n Cov(X_i, X_j) \\ &= \sum_{i=1}^n Var(X_i) + \sum_{i \neq j} Cov(X_i, X_j) \\ &= \sum_{i=1}^n Var(X_i) + 2 \sum_{i < j} Cov(X_i, X_j). \end{aligned}$$

1.9 Função Geradora de Momentos

Ver [Link!](#)

1.10 Tipos de Convergência

Ver [Link!](#)

1.11 Método Delta

Uma questão natural que surge frequentemente é a seguinte: suponha que temos uma sequência de variáveis aleatórias X_n que converge em distribuição para uma distribuição Normal. Podemos então caracterizar a distribuição limite de $g(X_n)$, em que g é uma função suave (é uma função que possui derivadas de todas as ordens em todo o seu domínio)?

Podemos resolver isso utilizando o Teorema do Mapeamento Contínuo (ou teorema de Mann-Wald) (de fato, essa é a base da demonstração que apresentaremos).

Método Delta

Suponha que

$$\frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1),$$

e que g é uma função continuamente diferenciável tal que $g'(\mu) \neq 0$. Então,

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{\sigma} \xrightarrow{d} N(0, [g'(\mu)]^2).$$

Demonstração

A ideia básica é usar a aproximação de Taylor. Sabemos que

$$g(X_n) \approx g(\mu) + g'(\mu)(X_n - \mu),$$

logo,

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{\sigma} \approx g'(\mu) \frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} N(0, [g'(\mu)]^2).$$

Para sermos rigorosos, precisamos considerar os termos de resto. Aplicando o Teorema de Taylor de forma rigorosa, obtemos:

$$\frac{\sqrt{n}(g(X_n) - g(\mu))}{\sigma} = g'(\tilde{\mu}) \frac{\sqrt{n}(X_n - \mu)}{\sigma},$$

em que $\tilde{\mu}$ está entre μ e $\bar{X}_n$.

Sabemos, pela Lei Fraca dos Grandes Números (LGN), que $\bar{X}_n \xrightarrow{p} \mu$, e portanto $\tilde{\mu} \xrightarrow{p} \mu$. Como g é continuamente diferenciável, pelo Teorema do Mapeamento Contínuo,

$$g'(\tilde{\mu}) \xrightarrow{p} g'(\mu).$$

Agora, aplicando o Teorema de Slutsky, temos:

$$g'(\tilde{\mu}) \frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} g'(\mu) N(0, 1) \stackrel{d}{=} N(0, [g'(\mu)]^2).$$

Exemplo

Suponha que $X_1, \dots, X_n \sim P$, com $E[X] = \mu$ e $\text{Var}(X) = \sigma^2 < \infty$.

Suponha que estamos interessados na distribuição de

$$Y_n = \exp(\bar{X}_n).$$

Como $g'(\mu) = \exp(\mu)$, aplicando o Método Delta, obtemos:

$$\sqrt{n} \left(\frac{\exp(\bar{X}_n) - \exp(\mu)}{\sigma} \right) \xrightarrow{d} N(0, \exp(2\mu)).$$

1.12 Algumas das principais distribuições de probabilidade

1.12.1 Distribuições discretas

Distribuição de Bernoulli

- Seja $X = \{0, 1\}$, onde $x \in X$ representa sucesso ou fracasso, isto é, um experimento binário.

Exemplos:

- Lançamento de moeda (cara = 0, coroa = 1)
- Manufatura: defeituoso / não defeituoso

- Medicina: doença / ausência de doença
- Esporte: vitória / derrota (assumindo que não há empate)

- Dizemos que:

$$X \sim \text{Ber}(\theta),$$

quando X segue uma distribuição de Bernoulli com probabilidade de sucesso θ .

- O parâmetro $\theta \in [0, 1]$ representa a probabilidade de sucesso:
 - No lançamento de moeda, a moeda é justa se $\theta = 0,5$;
 - Em medicina, deseja-se que θ seja o menor possível (baixa probabilidade de doença).
- A função de probabilidade é dada por:

$$P(X = x \mid \theta) = p(x \mid \theta) = \theta^x (1 - \theta)^{1-x}.$$

- Pode parecer estranho multiplicar θ por $(1 - \theta)$, mas note que apenas um dos termos será diferente de 1:
 - * Se $x = 1$, então $p(1) = \theta$;
 - * Se $x = 0$, então $p(0) = 1 - \theta$.

- Momentos:

$$E[X] = \theta, \quad \text{Var}(X) = \theta(1 - \theta).$$

- Se $X \sim \text{Ber}(0,5)$, então a variável aleatória

$$Y = 2X - 1,$$

segue a **distribuição de Rademacher**. Nesse caso, Y assume valores em: $Y \in \{-1, +1\}$.

- Essa distribuição é bastante útil para modelar **caminhadas aleatórias (random walks)**, nas quais:
 - $Y = +1$ representa um passo para frente;
 - $Y = -1$ representa um passo para trás.
- Observe que não é permitido permanecer parado ($Y = 0$ não é possível).

Distribuição Binomial

- Considere n variáveis aleatórias binárias independentes:

$$X = (X_1, X_2, \dots, X_n), \quad \text{com } X_i \stackrel{iid}{\sim} \text{Ber}(\theta).$$

- Definimos o número de sucessos como:

$$M = \sum_{i=1}^n X_i.$$

- O espaço amostral de M é:

$$\mathcal{M} = \{0, 1, 2, \dots, n\}.$$

- Dizemos que:

$$M \sim \text{Bin}(n, \theta).$$

- A função de probabilidade é:

$$P(M = m \mid \theta) = \binom{n}{m} \theta^m (1 - \theta)^{n-m},$$

que representa a probabilidade de obter m sucessos em n ensaios.

- Momentos:

$$E[M] = n\theta, \quad \text{Var}(M) = n\theta(1 - \theta).$$

- **Propriedade da soma de binomiais:**

Se $M_1 \sim \text{Bin}(n_1, \theta)$ e $M_2 \sim \text{Bin}(n_2, \theta)$ são independentes, então:

$$M_1 + M_2 \sim \text{Bin}(n_1 + n_2, \theta).$$

Distribuição Multinomial

- A **distribuição multinomial** é uma generalização da distribuição binomial para experimentos independentes com mais de dois resultados possíveis.
- Seja $\mathbf{X} = (X_1, \dots, X_m)$ um vetor aleatório, e $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ o vetor de probabilidades, com:

$$\sum_{i=1}^m \theta_i = 1, \quad \theta_i \geq 0.$$

- Considere n repetições independentes do experimento, e seja k_i o número de ocorrências da categoria i , para $i = 1, \dots, m$. Então:

$$k_1 + k_2 + \dots + k_m = n.$$

- Dizemos que:

$$\mathbf{X} \sim \text{Mult}(n, \theta).$$

- A função de probabilidade é:

$$P(\mathbf{X} = (k_1, k_2, \dots, k_m)) = \binom{n}{k_1, k_2, \dots, k_m} \prod_{i=1}^m \theta_i^{k_i},$$

onde

$$\binom{n}{k_1, k_2, \dots, k_m} = \frac{n!}{k_1! k_2! \dots k_m!}.$$

- Interpretação: representa a probabilidade de observar k_1 ocorrências da categoria 1, k_2 da categoria 2, ..., e k_m da categoria m , em n experimentos independentes.

Distribuição Uniforme Discreta

- Seja $X = \{a, a + 1, \dots, b\}$, onde o espaço amostral é um intervalo de inteiros de a até b .
- Dizemos que:

$$X \sim \text{U}(a, b),$$

quando X segue uma distribuição uniforme discreta.

- A função de probabilidade é:

$$P(X = k \mid a, b) = \frac{1}{b - a + 1}, \quad k \in \{a, \dots, b\}.$$

- Momentos:

$$E[X] = \frac{a + b}{2},$$

que pode não ser um número inteiro,

$$\text{Var}(X) = \frac{(b - a + 1)^2 - 1}{12},$$

que também pode não ser um número inteiro.

Distribuição de Poisson

- Seja $\mathbb{Z}_+ = \{0, 1, 2, \dots\}$, o conjunto dos inteiros não negativos (de 0 até ∞).
- Dizemos que:

$$X \sim \text{Poi}(\lambda),$$

quando X segue uma distribuição de Poisson com taxa $\lambda > 0$.

- A função de probabilidade é:

$$P(X = k \mid \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \mathbb{Z}_+,$$

que representa a probabilidade de ocorrência de k eventos em um intervalo, dado uma taxa média λ .

- Momentos:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

- **Propriedade da soma de Poisson:**

Se $X_1 \sim \text{Poi}(\lambda_1)$ e $X_2 \sim \text{Poi}(\lambda_2)$ são independentes, então:

$$X_1 + X_2 \sim \text{Poi}(\lambda_1 + \lambda_2).$$

Distribuição Binomial Negativa

- Na distribuição binomial $\text{Bin}(n, \theta)$, a probabilidade $P(M = m \mid \theta)$ representa o número de sucessos em n ensaios.
- Já a **distribuição binomial negativa** modela o número de fracassos antes de ocorrer o r -ésimo sucesso.
- Dizemos que:

$$X \sim \text{BN}(r, \theta),$$

em que r é o número fixo de sucessos e θ é a probabilidade de sucesso em cada ensaio.

- A função de probabilidade é:

$$P(X = n \mid r, \theta) = \binom{n+r-1}{n} (1-\theta)^n \theta^r,$$

em que $n = 0, 1, 2, \dots$ representa o número de fracassos antes do r -ésimo sucesso.

Distribuição Geométrica

- Quando $r = 1$, a distribuição binomial negativa se reduz à **distribuição geométrica**:

$$X \sim \text{Geom}(\theta),$$

com função de probabilidade:

$$P(X = n) = (1 - \theta)^n \theta.$$

- Nesse caso, X representa o número de fracassos antes do primeiro sucesso.

1.13 Propriedade das Distribuições Contínuas: Probabilidade Pontual Nula

- Se uma variável aleatória X segue uma distribuição contínua, então a probabilidade de assumir um valor específico é sempre zero:

$$P(X = x \mid \theta) = 0, \quad \forall x.$$

- Exemplos:

$$P(X = 1) = P(X = 0) = P(X = -2) = P(X = e) = P(X = \pi) = 0.$$

- Isso ocorre porque o espaço amostral de uma variável contínua possui infinitos valores possíveis. Assim, a probabilidade de observar exatamente um único ponto é nula.

Consequência Importante

- Em distribuições contínuas, desigualdades estritas e não estritas são equivalentes:

$$P(X \leq a) = P(X < a).$$

- De fato:

$$P(X \leq a) = P(X < a \text{ ou } X = a)$$

$$= P(X < a) + P(X = a) \quad (\text{pela aditividade da probabilidade})$$

$$= P(X < a) + 0 = P(X < a).$$

Observação Importante

- Um fato que pode parecer contraintuitivo:

Embora

$$P(X = a) = 0,$$

isso **não significa** que o evento $X = a$ seja impossível.

- Significa apenas que ele tem probabilidade nula; o que é uma característica natural de distribuições contínuas.

1.13.1 Distribuições Contínuas

Distribuição Uniforme Contínua

- Seja $X \in [a, b]$, onde o espaço amostral é um intervalo de números reais de a até b .
- Dizemos que:

$$X \sim U(a, b),$$

quando X segue uma distribuição uniforme contínua.

- A função densidade de probabilidade é:

$$f(x; a, b) = \begin{cases} 0, & x < a, \\ \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & x > b. \end{cases}$$

- Interpretação: todos os valores no intervalo $[a, b]$ são igualmente prováveis (em termos de densidade).
- Momentos:

$$E[X] = \frac{a + b}{2},$$

$$\text{Var}(X) = \frac{(b - a)^2}{12}.$$

Distribuição Exponencial

- Seja $X \in [0, \infty)$, onde o espaço amostral é o conjunto dos números reais não negativos.
- Dizemos que:

$$X \sim \text{Exp}(\lambda),$$

quando X segue uma distribuição exponencial com taxa $\lambda > 0$.

- A função densidade de probabilidade pode ser escrita como:

$$f(x | \lambda) = \lambda e^{-\lambda x} \mathbf{1}_{\{x \geq 0\}}, \quad x \in \mathbb{R},$$

em que $\mathbf{1}_{\{x \geq 0\}}$ é a função indicadora do suporte.

- Momentos:

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

Exercícios

- 1) Use o resultado que diz que, para uma variável aleatória não negativa Y ,

$$E(Y) = \int_0^{\infty} \Pr(Y > t) dt,$$

para mostrar, que para uma variável aleatória não negativa X ,

$$E(X^n) = \int_0^{\infty} n x^{n-1} \Pr(X > x) dx.$$

Dica: Comece com

$$E(X^n) = \int_0^{\infty} \Pr(X^n > t) dt,$$

e faça a mudança de variável $t = x^n$.

2. Mostre que $\Gamma(1/2) = \sqrt{\pi}$.
3. Seja X uma variável aleatória contínua com função de distribuição F . Defina a variável aleatória Y como $Y = F_X(x)$. Mostre que Y é uniformemente distribuída no intervalo $(0, 1)$.

4. Suponha que tentativas independentes com mesma probabilidade de sucesso p . $0 < p < 1$, sejam realizadas até que se acumule um total de r sucessos. Se X for igual ao número de tentativas necessárias, então

$$\Pr(X = x) = \binom{n-1}{r-1} p^r (1-p)^{n-r}, \quad x = r, r+1, \dots$$

Encontre $E(X)$ e $Var(X)$.

5. Seja X uma variável aleatória tal que

$$E(X^n) = \begin{cases} \frac{n!}{(n/2)!}, & \text{se } n \text{ for par;} \\ 0 & \text{caso contrário.} \end{cases}$$

Determine a função geradora de momentos de X e identifique sua distribuição.

2 Fundamentos da Inferência Estatística

Neste capítulo, iniciamos a primeira parte sobre inferência estatística aprendendo um pouco sobre amostragem. Os conceitos por trás da amostragem são a base para intervalos de confiança e testes de hipóteses, por exemplo. Além disso, veremos que ferramentas já aprendidas durante o curso de Ciência de Dados, em particular visualização de dados e manipulação (organização) de dados, são importantes no desenvolvimento do seu entendimento. Esperamos que os conceitos apresentados ao longo deste texto se articulam e se acumulam, culminando na capacidade de “contar sua história com dados”.

2.1 Processo Gerador de Dados (PGD)

O PGD é o mecanismo teórico, físico ou biológico que produz os dados que observamos. Imagine que o mundo é uma “caixa preta” que segue certas regras (leis da física, comportamento humano, algoritmos de mercado), portanto o PGD são essas regras em funcionamento.

Realidade vs. Observação

- O PGD (A causa): É a distribuição de probabilidade teórica e os parâmetros fixos (mas desconhecidos) que regem um fenômeno.
- Os Dados (O Efeito): É a amostra específica que coletamos. É apenas uma realização de infinitas possibilidades que o PGD poderia ter gerado.

Representação Matemática

O PGD pode ser definido pela distribuição de probabilidade conjunta desconhecida $P(X, Y)$ (ou simplesmente $P(Z)$).

Dizemos que nossa amostra $\mathcal{D} = \{z_1, z_2, \dots, z_n\}$ é composta por variáveis aleatórias independentes e identicamente distribuídas (i.i.d) retiradas desse processo:

$$z_i \sim P(Z).$$

Nesta visão, o PGD é o “mecanismo” que dita:

1. A Região de Suporte: Quais valores são possíveis de ocorrer?
2. A Densidade: Com que frequência cada valor ocorre?
3. As Dependências: Como a ocorrência de X altera a probabilidade de Y ?

2.2 Pacote Necessários

Neste capítulo iremos utilizar os pacotes R `tidyverse` (Wickham et al., 2019) e `moderndive` (Kim; Ismay; Kuhn, 2021). Por exemplo, para instalar o pacote basta usar `install.packages("tidyverse")` e podemos carregar o pacote por meio do comando `library(tidyverse)`. São carregados, de uma só vez, os seguintes pacotes amplamente utilizados em ciência de dados:

- `ggplot2` para visualização de dados;
- `dplyr` para manipulação de dados;
- `tidyr` para converter dados para o formato “tidy”;
- `readr` para importar dados de planilhas para o R,

além dos pacotes mais avançados `purrr`, `tibble`, `stringr` e `forcats`.

```
library(tidyverse)
library(moderndive)
```

2.3 Experimento em Sala de Aula

Iremos realizar o seguinte experimento em sala de aula:

1. Organização
 - A turma é dividida em grupos independentes (por exemplo, 20 grupos).
 - Cada grupo realiza uma única amostragem.
2. Protocolo experimental (por grupo)
 - A urna é misturada cuidadosamente, garantindo aleatoriedade.
 - O grupo retira uma amostra de tamanho fixo n (por exemplo, $n = 50$) sem reposição durante a retirada.
 - As bolas retiradas são observadas e classificadas por cor.

- O grupo registra:
 - R : o número de bolas vermelhas na amostra;
 - $\hat{p} = R/n$: proporção amostral de bolas vermelhas.
- Todas as bolas são devolvidas à urna.
- A urna é novamente misturada antes da próxima amostragem.

Cada grupo deve atuar de forma independente, sem acesso aos resultados dos demais.

3. Coleta e organização dos dados

- Cada grupo fornece sua estimativa de $\hat{p}$.
- O conjunto de estimativas é reunido em uma tabela ou planilha.
- As proporções são representadas graficamente por meio de um histograma.

Esse histograma representa a distribuição amostral da proporção para um tamanho de amostra fixo n .

Verificação de aprendizagem

1. Por que foi importante misturar a tigela antes de retirarmos as bolas?
2. Por que os 20 grupos de amigos não obtiveram todos o mesmo número de bolas vermelhas entre as 50 retiradas e, conseqüentemente, proporções diferentes de bolas vermelhas?

2.4 Experimento Virtual

No pacote `moderndive` existe um *data frame* chamado `bowl`. As linhas de `bowl` correspondem exatamente ao conteúdo da urna real apresentada em sala de aula.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
```



```

5      5 white
6      6 white
7      7 red
8      8 white
9      9 red
10     10 white
# i 2,390 more rows

```

Observe que `bowl` possui 2400 linhas, o que nos indica que a urna contém 2400 bolas de mesmo tamanho. A primeira variável, `ball_ID`, é usada como uma variável de identificação, conforme discutido em sala de aula, nenhuma das bolas da urna real possui números marcados. A segunda variável, `color`, indica se uma determinada bola virtual é **vermelha** ou **branca**. Visualize o conteúdo de `bowl` no **visualizador de dados do RStudio** e percorra as linhas para se convencer de que `bowl` é, de fato, um **análogo virtual** da urna real apresentada em sala.

Agora precisamos de um **análogo virtual da pá** para gerar **amostras virtuais de 50 bolas**. Para isso, vamos utilizar a função `rep_sample_n()`, incluída no pacote `moderndive`. Essa função permite realizar **amostragens repetidas (ou replicadas)** de tamanho (`n`).

```

set.seed(2026) #fixando semente
pa_virtual <- bowl %>%
  rep_sample_n(size = 50)

pa_virtual

```

```

# A tibble: 50 x 3
# Groups:   replicate [1]
  replicate ball_ID color
    <int>    <int> <chr>
1         1     733 white
2         1     993 red
3         1    2342 red
4         1    1647 white
5         1    1883 red
6         1     164 red
7         1    1200 red
8         1     389 white
9         1     287 white
10        1    2362 red
# i 40 more rows

```

A variável `ball_ID` identifica quais das 2400 bolas do objeto `bowl` foram incluídas na nossa amostra de 50 bolas, enquanto `color` indica a cor de cada bola. No entanto, o que indica a variável `replicate`?

No caso de `pa_virtual`, a variável `replicate` é igual a 1 em todas as 50 linhas. Isso nos informa que essas 50 linhas correspondem à nossa primeira amostra. Veremos em breve que, quando realizarmos 20 amostragens virtuais, a variável `replicate` assumirá valores entre 1 e 20.

Vamos agora calcular a **proporção de bolas vermelhas** em nossa amostra virtual utilizando os verbos de manipulação de dados do `dplyr`. Primeiro, para cada uma das 50 bolas amostradas, vamos identificar se ela é vermelha ou não, utilizando um teste de igualdade com `==`. Em seguida, criaremos uma nova variável booleana `is_red` usando a função `mutate()`:

```
pa_virtual <- pa_virtual %>%  
mutate(is_red = (color == "red"))
```

```
pa_virtual
```

```
# A tibble: 50 x 4  
# Groups:   replicate [1]  
  replicate ball_ID color is_red  
    <int>    <int> <chr> <lgl>  
1         1      733 white FALSE  
2         1      993 red   TRUE  
3         1     2342 red   TRUE  
4         1     1647 white FALSE  
5         1     1883 red   TRUE  
6         1      164 red   TRUE  
7         1     1200 red   TRUE  
8         1      389 white FALSE  
9         1      287 white FALSE  
10        1     2362 red   TRUE  
# i 40 more rows
```

Observe que, para cada linha em que `color == "red"`, é retornado o valor lógico (booleano) `TRUE`, e para cada linha em que `color` não é igual a `"red"`, é retornado o valor lógico `FALSE`.

Em seguida, vamos calcular o número de bolas vermelhas, dentre as 50, utilizando a função `summarize()`. Note que `summarize()` recebe um *data frame* com várias linhas e retorna um *data frame* com **uma única linha**, contendo estatísticas-resumo, como `mean()` ou `median()`. Neste caso, utilizaremos a função `sum()`:

```
n_red <- pa_virtual %>%
mutate(is_red = (color == "red")) %>%
summarize(num_red = sum(is_red))

n_red
```

```
# A tibble: 1 x 2
  replicate num_red
    <int>     <int>
1         1      16
```

Por que isso funciona? Porque o R trata **TRUE** como o número 1 e **FALSE** como o número 0. Assim, somar valores **TRUE** e **FALSE** é equivalente a somar 1's e 0's. Ao final, essa operação conta o número de bolas para as quais a variável `color` é igual a “red”. No nosso caso, XX das 50 bolas eram vermelhas. No entanto, você pode ter obtido um número diferente de bolas vermelhas devido ao caráter aleatório da amostragem virtual.

Por fim, vamos calcular a proporção das 50 bolas amostradas que são vermelhas, dividindo `num_red` por 50:

```
n_prop_red <- pa_virtual %>%
mutate(is_red = color == "red") %>%
summarize(num_red = sum(is_red)) %>%
mutate(prop_red = num_red / 50)

n_prop_red
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
    <int>     <int>     <dbl>
1         1      16      0.32
```

Em outras palavras, 16 das bolas dessa amostra virtual eram vermelhas. Vamos tornar esse código um pouco mais **compacto e conciso**, combinando as etapas de `mutate()` e `summarize()` da seguinte forma:

```
n_prop_red <- pa_virtual %>%
summarize(num_red = sum(color == "red")) %>%
mutate(prop_red = num_red / 50)

n_prop_red
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
  <int>    <int>    <dbl>
1         1      16     0.32
```

Ótimo! 16 das 50 bolas da pá virtual eram vermelhas! Assim, com base nessa amostra específica de 50 bolas, nossa estimativa da proporção de bolas vermelhas na urna é 0.32. Porém, lembre-se da atividade de amostragem realizada em sala de aula: se repetirmos essa amostragem, não necessariamente obteremos novamente o valor de 0.32. É provável que haja alguma variação. De fato, nossos 20 grupos de amigos calcularam 20 proporções desse tipo, cuja distribuição visualizamos em sala de aula, e vimos que essas estimativas variaram.

Vamos agora realizar o **análogo virtual** de ter 20 grupos de estudantes usando a pá de amostragem!

Lembre-se de que, no exercício de amostragem realizada em sala de aula, tivemos **20 grupos de estudantes**, cada um utilizando a pá, o que resultou em **20 amostras de tamanho 50**. Em seguida, usamos essas 20 amostras para calcular **20 proporções**. Em outras palavras, **repetimos/replicamos o uso da pá 20 vezes**.

Podemos realizar essa amostragem repetida/replicada de forma virtual utilizando novamente a função `rep_sample_n()`, mas agora adicionando o argumento `reps = 20`. Isso indica ao R que desejamos repetir a amostragem 20 vezes.

Vamos salvar esses resultados em um **data frame** chamado `virtual_samples`. Embora apresentemos a seguir uma prévia das primeiras 10 linhas de `virtual_samples`, recomendamos fortemente que você explore todo o seu conteúdo utilizando o visualizador de planilhas do RStudio, executando o comando `View(virtual_samples)`.

```
set.seed(2026)
amostra_virtual <- bowl %>%
  rep_sample_n(size = 50, reps = 20)

amostra_virtual
```

```
# A tibble: 1,000 x 3
# Groups:   replicate [20]
  replicate ball_ID color
  <int>    <int> <chr>
1         1      733 white
2         1      993 red
3         1     2342 red
4         1     1647 white
5         1     1883 red
```

```

6          1      164 red
7          1     1200 red
8          1      389 white
9          1      287 white
10         1     2362 red
# i 990 more rows

```

Observe, no visualizador de planilhas, que as primeiras 50 linhas da variável `replicate` são iguais a 1, enquanto as 50 linhas seguintes de `replicate` são iguais a 2. Isso nos indica que as primeiras 50 linhas correspondem à primeira amostra de 50 bolas, enquanto as próximas 50 linhas correspondem à segunda amostra de 50 bolas. Esse padrão se repete para todas as 20 replicações (`reps = 20`) e, portanto, o data frame `amostra_virtual` possui ($20 \times 50 = 1000$) linhas.

Vamos agora usar `amostra_virtual` para calcular as 20 proporções de bolas vermelhas resultantes. Utilizaremos os mesmos verbos do `dplyr` de antes, mas agora com um `group_by()` adicional na variável `replicate`. Ao definir previamente a variável de agrupamento como `metadado` antes de aplicar `summarize()`, obteremos 20 proporções diferentes de bolas vermelhas. A seguir, exibimos uma prévia das primeiras 10 das 20 linhas resultantes:

```

virtual_prop_red <- amostra_virtual %>%
  group_by(replicate) %>%
  summarize(red = sum(color == "red")) %>%
  mutate(prop_red = red / 50)

virtual_prop_red

```

```

# A tibble: 20 x 3
  replicate    red prop_red
    <int> <int>    <dbl>
1         1     16     0.32
2         2     22     0.44
3         3     19     0.38
4         4     27     0.54
5         5     18     0.36
6         6     19     0.38
7         7     16     0.32
8         8     17     0.34
9         9     21     0.42
10        10     20     0.4
11        11     23     0.46
12        12     23     0.46


```

13	13	15	0.3
14	14	23	0.46
15	15	27	0.54
16	16	23	0.46
17	17	17	0.34
18	18	21	0.42
19	19	15	0.3
20	20	18	0.36

Assim como ocorreu com as 20 amostras coletadas em sala de aula, há variação nas 20 proporções de bolas vermelhas obtidas virtualmente. Vamos visualizar essa variação por meio de um histograma. Note que também adicionamos os argumentos `binwidth = 0.05` e `boundary = 0.4`.

Lembre-se de que definir `boundary = 0.4` garante um esquema de classes em que um dos limites dos intervalos esteja em 0,4. Como o `binwidth = 0.05` também foi especificado, isso criará intervalos com limites em **0,30, 0,35, 0,40, 0,45, 0,50**, entre outros.

```
ggplot(virtual_prop_red, aes(x = prop_red)) +
  geom_histogram(binwidth = 0.05, boundary = 0.4, color = "white") +
  labs(x = "Proporção de bolas vermelhas", y = "Frequência",
  title = "Distribuição das proporções")
```



Observe que, ocasionalmente, obtivemos proporções de bolas vermelhas inferiores a 30%. Por outro lado, em alguns casos, obtivemos proporções superiores a 50%. No entanto, as proporções que ocorreram com maior frequência ficaram entre 35% e 40% (em **5 das 20 amostras**). Por que temos essas diferenças nas proporções de bolas vermelhas? **Por causa da variação amostral.**

Verificação de aprendizagem

1. Por que não foi possível estudar os efeitos da variação amostral quando utilizamos a pá virtual apenas uma vez? Por que foi necessário coletar **mais de uma amostra virtual** (no nosso caso, **20 amostras virtuais**)?

Lista Semanal Obrigatória

1. Agora suponha que queiramos estudar os efeitos da variação amostral não para 20 amostras, mas para um número maior, digamos 1000 amostras. Vamos novamente utilizar a função `rep_sample_n()`, com o tamanho da amostra definido como 50, mas agora com o número de repetições `reps` definido como 1000.
2. Temos 1000 réplicas de `prop_red`, a proporção de bolas vermelhas em amostras de 50 bolas. Utilizando o mesmo código de antes, vamos agora visualizar a distribuição dessas 1000 réplicas de `prop_red` por meio de um histograma.
3. Observando o histograma produzido no item 2), você diria que amostrar 50 bolas em que 30% são vermelhas é provável ou improvável? E quanto a amostrar 50 bolas em que 10% são vermelhas?

2.5 Conceitos Importantes

Primeiramente, uma **população** é um conjunto de indivíduos ou observações de interesse. Isso também é comumente denominado **população de estudo**. Denotamos matematicamente o tamanho da população utilizando a letra maiúscula N .

Um **parâmetro populacional** é algum resumo numérico sobre a população que é desconhecido, mas que você gostaria de saber. Por exemplo, quando essa quantidade é uma média, como a altura média de todos os canadenses, o parâmetro populacional de interesse é a média populacional.

Um **censo** é uma enumeração exaustiva ou contagem de todos os N indivíduos da população. Fazemos isso para calcular o valor exato do parâmetro populacional. Vale notar que, à medida que o número N de indivíduos em nossa população aumenta, a realização de um censo se torna mais cara (em termos de tempo, energia e dinheiro).

Na nossa atividade de amostragem, a **população (de estudo)** é o conjunto de $N = 2400$ bolas vermelhas e brancas, todas de mesmo tamanho, contidas na urna. Lembre-se de que também representamos a urna “virtualmente” no data frame `bowl`.

```
bowl
```

```
# A tibble: 2,400 x 2
  ball_ID color
  <int> <chr>
1       1 white
2       2 white
3       3 white
4       4 red
5       5 white
6       6 white
7       7 red
8       8 white
9       9 red
10      10 white
# i 2,390 more rows
```

O **parâmetro populacional** aqui é a proporção de bolas na urna que são vermelhas. Sempre que estamos interessados em uma proporção de algum valor em uma população, o parâmetro populacional tem um nome específico: a proporção populacional. Comumente denotamos as proporções populacionais com a letra p .

Para calcular essa proporção populacional p de forma exata, precisamos primeiro realizar um censo, analisando todos os $N = 2400$ e contando o número de bolas vermelhas. Em seguida, dividimos essa contagem por 2400 para obter a proporção de vermelhas.

Você pode estar se perguntando agora: “Espere. Eu entendo que realizar um censo na urna real levaria muito tempo. Mas não podemos realizar um censo “virtual” usando a urna virtual?” Você está absolutamente correto! De fato, quando os autores do pacote `moderndive` criaram o data frame `bowl`, eles fizeram com que seu conteúdo correspondesse ao da urna real não fazendo um censo, mas lendo o conteúdo escrito na caixa em que a urna veio! Vamos realizar este censo “virtual” usando os mesmos códigos do pacote `dplyr` que você usou anteriormente para contar o número de bolas que são vermelhas:

```
bowl %>%
  summarize(red = sum(color == "red"))
```

```
# A tibble: 1 x 1
```



```
red
<int>
1 900
```

Como 900 das 2400 são vermelhas, a proporção é $900/2400 = 0,375 = 37,5\%$. Portanto, sabemos o valor do parâmetro populacional: em nosso caso, a proporção populacional p é igual a 0,375.

Neste ponto, você pode estar se perguntando: “*Se tínhamos uma maneira de saber que a proporção de bolas vermelhas é de 37,5%, então por que fizemos alguma amostragem?*” Ótima pergunta! Normalmente, você não faria amostragem alguma! No entanto, as atividades de amostragem que fizemos neste capítulo são meras simulações de como a amostragem é feita na vida real! Realizamos essas simulações a fim de estudar:

1. O efeito da variação amostral (ou variabilidade de amostragem) em nossas estimativas.
2. O efeito do tamanho da amostra na variação amostral.

Como veremos adiante em pesquisas de opinião, na amostragem da vida real não apenas o tamanho da população N será muito grande, tornando um censo caro, mas, às vezes, nem sequer saberemos qual é o tamanho da população! Por enquanto, no entanto, prosseguiremos com nosso próximo conjunto de termos e notação.

Amostragem é o ato de coletar uma amostra da população, o que geralmente fazemos apenas quando não podemos realizar um censo. Denotamos matematicamente o tamanho da amostra usando o n minúsculo, em oposição ao N maiúsculo, que denota o tamanho da população. Normalmente, o tamanho da amostra n é muito menor que o tamanho da população N . Assim, a amostragem é uma alternativa muito mais barata do que a realização de um censo.

Uma **estimativa pontual**, também conhecida como estatística (ou estatística amostral), é uma estatística calculada a partir de uma amostra que estima o parâmetro populacional desconhecido.

Então, em sala de aula, realizamos a amostragem usando uma pá com 50 espaços para extrair amostras de tamanho $n = 50$. Para realizar o análogo virtual desta amostragem, lembre-se de que usamos a função `rep_sample_n()` da seguinte maneira:

```
set.seed(2026)
pa_virtual <- bowl %>%
  rep_sample_n(size = 50)
```

Usando a amostra de 50 bolas contidas em `pa_virtual`, geramos uma estimativa da proporção de bolas na urna que são vermelhas, `prop_red`.

```
pa_virtual %>%
  summarize(num_red = sum(color == "red")) %>%
  mutate(prop_red = num_red / 50)
```

```
# A tibble: 1 x 3
  replicate num_red prop_red
    <int>    <int>    <dbl>
1         1      16     0.32
```

Então, em nosso caso, o valor de **prop_red** é a estimativa pontual da proporção populacional p , pois ela estima o valor desta última. Além disso, essa estimativa pontual tem um nome específico quando se considera proporções: **a proporção amostral**. Ela é denotada usando $\hat{p}$, porque é uma convenção comum em estatística usar um símbolo de “chapéu” para denotar estimativas pontuais.

Iremos observar ao longo desta disciplina que a maneira como você coleta as amostras influencia diretamente a qualidade delas.

- Diz-se que uma amostra é **representativa** se ela “se parecer” aproximadamente com a população. Em outras palavras, se as características da amostra forem uma “boa” representação das características da população.
- Dizemos que uma amostra é **generalizável** se quaisquer resultados baseados na amostra puderem ser generalizados para a população. Em outras palavras, se pudermos fazer “bons” palpites sobre a população usando a amostra.
- Dizemos que um procedimento de amostragem é **viesado** (ou tendencioso) se certos indivíduos em uma população tiverem uma chance maior de serem incluídos em uma amostra do que outros. Dizemos que um procedimento de amostragem é **não viesado** (ou imparcial) se cada indivíduo em uma população tiver chances iguais de ser amostrado.

Dizemos que uma amostra de n bolas extraídas usando nossa pá é **representativa** da população se o seu conteúdo “se assemelhar aproximadamente” ao conteúdo da urna. Se sim, então a proporção de bolas vermelhas da pá pode ser **generalizada** para a proporção das $N = 2400$ bolas da urna que são vermelhas. Ou expresso de forma diferente, $\hat{p}$ é um “bom palpite” de p . Agora digamos que trapaceamos ao usar a pá e removemos um número de bolas brancas em favor de bolas vermelhas. Então, essa amostra seria viesada em relação às bolas vermelhas e, portanto, a amostra não seria mais representativa da urna.

Uma maneira de garantir que uma amostra seja não viesada e representativa da população é usar a **amostragem aleatória**. Temos que **Inferência** é o ato de “dar um palpite” sobre algo desconhecido. Portanto, **Inferência estatística** é o ato de fazer um palpite sobre uma população usando uma amostra.

Em nosso caso, como a função `rep_sample_n()` usa o gerador de números aleatórios do seu computador, estávamos, de fato, realizando “amostragem aleatória”.

2.6 Estatísticas, estimadores e estimativas

Para realizar inferências sobre uma população, partimos de uma amostra aleatória, que é um conjunto de n variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) retiradas de um PGD. Denotamos essa amostra antes da coleta por:

$$\mathbf{X} = (X_1, X_2, \dots, X_n).$$

Nesse estágio, $\mathbf{X}$ representa o “efeito” potencial de um mecanismo teórico (PGD) cujos parâmetros são fixos, mas desconhecidos. Após a coleta, observamos uma realização particular da amostra, denotada por letras minúsculas:

$$\mathbf{x} = (x_1, x_2, \dots, x_n).$$

Esta distinção é o pilar da inferência estatística: enquanto a amostra observada $\mathbf{x}$ é um conjunto de números fixos, a amostra aleatória $\mathbf{X}$ é um vetor de variáveis aleatórias.

1. Estatística: é qualquer função da amostra que não depende de parâmetros desconhecidos. Matematicamente, se T é uma estatística, então $T = g(X_1, \dots, X_n)$. Exemplos comuns incluem a média amostral ($\bar{X}$), a variância amostral (S^2) ou o máximo da amostra ($X_{(n)}$).
2. Estimador: é uma estatística utilizada especificamente com o objetivo de aproximar um parâmetro populacional desconhecido (θ). Como o estimador é uma função de variáveis aleatórias, ele próprio é uma variável aleatória. Portanto, cada estimador possui sua própria distribuição amostral, que descreve como seus valores variariam se extraíssemos infinitas amostras da mesma população.
3. Estimativa: é o valor numérico específico que o estimador assume ao ser calculado com os dados de uma amostra observada $\mathbf{x}$. Enquanto o estimador $\hat{\theta}$ é uma “regra” ou fórmula, a estimativa é o resultado final após a substituição dos valores medidos.

Essa hierarquia permite que a estatística utilize a teoria da probabilidade para quantificar quão próxima uma estimativa pontual está do verdadeiro parâmetro, frequentemente através do cálculo do erro padrão ou da construção de intervalos de confiança

2.7 Estatística como função da amostra

Um ponto fundamental é que, como os argumentos $X_1, \dots, X_n$ são variáveis aleatórias (antes da coleta), a estatística T é, ela própria, uma variável aleatória.

Exemplos Fundamentais

1. Média Amostral ($\bar{X}$): É a soma das observações dividida pelo tamanho da amostra, ou seja

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Sendo o estimador natural da média populacional μ .

2. Variância Amostral (S^2): Utiliza-se geralmente o divisor $n - 1$ para que o estimador seja não-viesado, compensando a perda de um grau de liberdade ao usar $\bar{X}$ no cálculo, ou seja,

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

3. Proporção Amostral ($\hat{p}$): Aplicada quando a população segue uma distribuição de Bernoulli, onde cada unidade é classificada binariamente (sucesso/fracasso), ou seja,

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i,$$

em que X_i assume o valor 1 para “sucesso” e 0 para “fracasso”.

2.8 O Experimento da Urna e Variáveis de Bernoulli

No contexto do experimento da urna, as bolas retiradas são modeladas como variáveis aleatórias independentes e identicamente distribuídas (i.i.d.). Ao definir:

- $X_i = 1$ (Vermelha) com probabilidade p ; e
- $X_i = 0$ (Branca) com probabilidade $(1 - p)$,

a estatística $R = \sum_{i=1}^n X_i$ representa o número total de sucessos e segue uma distribuição Binomial(n, p). A proporção amostral $\hat{p} = R/n$ é, portanto, a média aritmética dessas variáveis de Bernoulli, funcionando como um estimador não-viesado para a proporção populacional p .

2.9 Distribuição Amostral

O conceito de distribuição amostral é o elo entre a probabilidade e a inferência. Ela descreve o comportamento probabilístico do estimador, apresentando todos os valores que ele pode assumir e a frequência com que esses valores ocorrem quando o procedimento de amostragem é repetido infinitamente sob as mesmas condições.

No experimento virtual realizado, o histograma das proporções calculadas pelos grupos representa uma aproximação empírica da distribuição amostral de $\hat{p}$ para um tamanho de amostra fixo n . Vimos anteriormente que sob o modelo de Bernoulli independente, o número de sucessos R segue uma distribuição Binomial. Como $\hat{p} = R/n$, as propriedades da distribuição amostral de $\hat{p}$ são:

1. Esperança: $E(\hat{p}) = p$ (o que torna $\hat{p}$ um estimador não-viesado).
2. Variância: $\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$.
3. Erro-Padrão: É o desvio padrão da distribuição amostral, dado por $\text{EP}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$.

Estas expressões revelam que a variabilidade de $\hat{p}$ é inversamente proporcional à raiz quadrada de n . Assim, amostras maiores produzem estimativas mais precisas e concentradas em torno do verdadeiro parâmetro.

i Modelo exato para a urna

Quando a amostragem é realizada sem reposição em uma população finita de tamanho N (com M bolas vermelhas), as observações não são independentes. O número de sucessos segue, então, uma distribuição Hipergeométrica(N, M, n).

Nesse cenário, a variância do estimador incorpora a correção para população finita:

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \cdot \left(\frac{N-n}{N-1} \right).$$

O fator $\frac{N-n}{N-1}$ reduz a variabilidade do estimador, pois, em populações finitas, cada unidade amostrada reduz a incerteza sobre o que resta na população. Quando a fração amostral n/N é pequena (geralmente menor que 10%), esse fator aproxima-se de 1, e o modelo binomial torna-se uma aproximação excelente e simplificada.

2.10 Critérios básicos para avaliar estimadores

Diferentes estatísticas podem ser utilizadas para estimar um mesmo parâmetro populacional, tornando necessária a aplicação de critérios técnicos para compará-las.

1. O viés de um estimador é a diferença entre o seu valor esperado e o valor real do parâmetro, sendo definido por $E(\hat{\theta}) - \theta$. Um estimador é considerado não viesado quando, em média, seus valores coincidem com o parâmetro alvo, ou seja, $E(\hat{\theta}) = \theta$.
2. A variância, por sua vez, quantifica a dispersão ou incerteza do estimador entre diferentes amostras possíveis. Um critério abrangente que permite comparar estimadores viesados e não viesados é o Erro Quadrático Médio (EQM), que combina viés e variabilidade através da decomposição $EQM(\hat{\theta}) = Var(\hat{\theta}) + [Viés(\hat{\theta})]^2$.
3. Além dessas propriedades de pequenas amostras, um estimador é dito consistente se ele converge em probabilidade para o valor verdadeiro do parâmetro à medida que o tamanho da amostra n aumenta, garantindo que o erro de estimação tenda a zero no longo prazo.

Verificação de aprendizagem

1. Qual é a diferença entre $\hat{p}$ e o valor observado de $\hat{p}$?
2. Por que um estimador é considerado uma variável aleatória?
3. Qual é a relação entre o histograma das proporções obtidas nas amostras repetidas e a distribuição amostral de $\hat{p}$?
4. O que acontece com a variabilidade de $\hat{p}$ quando o tamanho da amostra aumenta?

2.11 Modelo estatístico e função de verossimilhança

Como a descrição probabilística exata do PGD raramente é conhecida, a inferência estatística utiliza uma família de modelos para representar, de maneira simplificada e aproximada, os aspectos fundamentais do fenômeno em estudo. Um modelo estatístico paramétrico é definido como uma coleção de distribuições de probabilidade indexadas por um parâmetro:

$$\mathcal{P} = \{P_{\theta} : \theta \in \Theta\},$$

em que θ representa o parâmetro (ou vetor de parâmetros) desconhecido que rege o mecanismo teórico, Θ é o espaço paramétrico, que compreende todos os valores possíveis que θ pode assumir. Cada valor de θ especifica uma distribuição de probabilidade distinta para os dados.

O objetivo central da inferência é utilizar a amostra observada para identificar quais valores de θ dentro do espaço paramétrico são mais compatíveis com a evidência empírica coletada.

2.12 Definição da função de verossimilhança

Considere uma amostra observada $\mathbf{x} = (x_1, x_2, \dots, x_n)$ proveniente de um PGD com função de probabilidade (ou densidade) $f(x; \theta)$. Sob a suposição de que as observações são i.i.d., a distribuição conjunta da amostra é dada pelo produto das densidades individuais:

$$f(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta).$$

Quando tratamos essa expressão como uma função de θ , mantendo os dados observados $\mathbf{x}$ fixos, ela é denominada função de verossimilhança:

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

A verossimilhança quantifica a compatibilidade relativa entre diferentes valores do parâmetro e os dados efetivamente coletados, servindo de base para métodos de estimativa e tomada de decisão.

⚠ Probabilidade e verossimilhança

É fundamental distinguir os dois conceitos:

1. Na probabilidade $f(\mathbf{x}; \theta)$, o parâmetro θ está fixo e variamos os dados $\mathbf{x}$ para prever possíveis resultados.
2. Na verossimilhança $L(\theta; \mathbf{x})$ os dados $\mathbf{x}$ estão fixos e variamos θ para avaliar qual modelo melhor explica o que foi observado.

Portanto, $L(\theta; \mathbf{x})$ não é uma distribuição de probabilidade para θ . Ela não indica a probabilidade de o parâmetro ser um determinado valor, mas sim o quão plausível é aquele valor dado o resultado da amostra.

2.13 Verossimilhança no experimento da urna

No experimento da urna, cada retirada pode ser modelada individualmente como uma variável de Bernoulli:

$$X_i \sim \text{Bernoulli}(p),$$

em que $X_i = 1$ indica uma bola vermelha e $X_i = 0$ uma bola branca. A função de probabilidade para uma única observação é $f(x_i; p) = p^{x_i}(1 - p)^{1-x_i}$ para $0 \leq p \leq 1$. Para uma amostra de n bolas, a função de verossimilhança é:

$$L(p; \mathbf{x}) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}.$$

Se definirmos $r = \sum_{i=1}^n x_i$ como o número total de bolas vermelhas, a expressão simplifica-se para:

$$L(p; r) = p^r(1 - p)^{n-r}.$$

Este resultado demonstra que, para inferir sobre a proporção p , a ordem das bolas é irrelevante, apenas o total r de sucessos importa.

Note que no exemplo da urna, a proporção amostral $\hat{p} = R/n$ desempenhou três papéis complementares: foi uma estatística calculada a partir da amostra, um estimador da proporção populacional p e o estimador de máxima verossimilhança sob o modelo de Bernoulli. Essa conexão ilustra como os conceitos introduzidos ao longo da unidade se articulam em uma estrutura inferencial única.

Verificação de aprendizagem

1. Na definição de $L(\theta; \mathbf{x})$, quais elementos são mantidos fixos e quais variam?
2. Por que a função de verossimilhança não deve ser interpretada como uma probabilidade para o parâmetro?
3. Mostre que, se nenhuma bola vermelha for observada, o estimador de máxima verossimilhança de p será igual a zero.
4. Mostre que, se todas as bolas observadas forem vermelhas, o estimador de máxima verossimilhança de p será igual a um.

Referências

3 Distribuições Amostrais

3.1 Introdução

A inferência estatística utiliza dados amostrais para produzir afirmações sobre características desconhecidas de uma população ou de um modelo probabilístico. Como diferentes amostras, obtidas sob o mesmo mecanismo de amostragem, geralmente produzem diferentes valores para uma mesma estatística, é necessário descrever probabilisticamente essa variabilidade. A **distribuição amostral** fornece precisamente essa descrição e estabelece a ligação entre a teoria da probabilidade e os procedimentos de estimação e teste de hipóteses (Ramachandran; Tsokos, 2021, cap. 4, seção 4.1, pp. 147–148; Rice, 2007, cap. 7, seção 7.3).

Considere uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ e uma estatística

$$T = T(\mathbf{X}) = g(X_1, \dots, X_n).$$

Antes da observação dos dados, T é uma variável aleatória. Depois que a amostra observada $\mathbf{x} = (x_1, \dots, x_n)$ é obtida, a realização correspondente $t = g(x_1, \dots, x_n)$ é um número. A distribuição de probabilidade de T , induzida pelo modelo probabilístico e pelo plano amostral, é chamada de distribuição amostral de T .

! Definição — Distribuição amostral

A **distribuição amostral** de uma estatística $T = g(X_1, \dots, X_n)$ é a distribuição de probabilidade de T sob o mecanismo que gera a amostra (Ramachandran; Tsokos, 2021, definição 4.1.4, p. 148; Chihara; Hesterberg, 2022, definição 4.1, pp. 78–79).

i Interpretação

A distribuição populacional descreve a variabilidade de uma observação individual X . A distribuição amostral descreve a variabilidade de uma função de várias observações, como $\bar{X}$, S^2 , $\hat{p}$, uma mediana ou uma estatística de ordem. Essas distribuições, em geral, não são iguais (Ramachandran; Tsokos, 2021, seq. 4.1, pp. 147–148; Chihara; Hesterberg, 2022, seq. 4.1, pp. 77–82).

Objetivos do capítulo

Ao final deste capítulo, o leitor deverá ser capaz de:

1. distinguir população, amostra, parâmetro, estatística e distribuição amostral;
2. reconhecer a diferença entre o modelo i.i.d. e a amostragem sem reposição em população finita;
3. obter distribuições amostrais por enumeração, transformação, funções geradoras de momentos e resultados assintóticos;
4. determinar as distribuições da média e da proporção amostrais;
5. aplicar corretamente a Lei dos Grandes Números e o Teorema Central do Limite;
6. utilizar as distribuições χ^2 , t e F no modelo normal;
7. obter distribuições de estatísticas de ordem;
8. aproximar distribuições amostrais por simulação.

3.2 População, parâmetro, amostra e estatística

! Definição — Modelo estatístico e parâmetro

Um **modelo estatístico paramétrico** é uma família de distribuições

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\},$$

em que θ é um parâmetro desconhecido e Θ é o espaço paramétrico. Quando existem densidades ou funções de probabilidade, a família pode ser representada por $\{f(x; \theta) : \theta \in \Theta\}$ (Casella; Berger, 2002, cap. 1; Cox, 2006, seq. 1.7).

! Definição — Amostra aleatória no modelo i.i.d.

As variáveis aleatórias $X_1, \dots, X_n$ formam uma **amostra aleatória de tamanho n** da distribuição F quando são independentes e identicamente distribuídas, isto é,

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F.$$

Quando F possui densidade ou função de probabilidade f , a distribuição conjunta da amostra é

$$f_{\mathbf{X}}(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i).$$

Essa é a formulação usual de uma amostra aleatória no modelo i.i.d. (Casella; Berger, 2002, seq. 5.1; Kerns, 2010, seq. 8.1; Ramachandran; Tsokos, 2021, seq. 4.1).

! Definição — Estatística

Uma **estatística** é uma função mensurável da amostra que não depende de parâmetros desconhecidos:

$$T = g(X_1, \dots, X_n).$$

Exemplos incluem

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n I(X_i \in A) \quad \text{e} \quad X_{(1)} \leq \dots \leq X_{(n)}.$$

A definição e os exemplos seguem a apresentação usual de estatísticas como funções da amostra (Chihara; Hesterberg, 2022, definições 4.1–4.2; Ramachandran; Tsokos, 2021, seq. 4.1).

! Observação — Estatística e estimador

Toda estatística é uma variável aleatória, mas ela somente recebe a interpretação de **estimador** quando é utilizada para estimar uma quantidade populacional. Por exemplo, $\bar{X}$ é uma estatística e pode ser usada como estimador de $\mu = E(X)$ (Chihara; Hesterberg, 2022, definição 4.2, p. 79).

3.3 Dois referenciais de amostragem

A expressão *amostragem aleatória simples* é utilizada em dois contextos relacionados, mas matematicamente distintos. A distinção evita confundir independência probabilística com aleatorização de um plano amostral.

3.3.1 Amostragem no modelo i.i.d.

No modelo i.i.d., cada observação é gerada independentemente pela mesma distribuição. Esse referencial é apropriado para repetições independentes de um experimento, amostragem com reposição ou modelagem de uma população conceitualmente infinita (Casella; Berger, 2002, seq. 5.1; Ramachandran; Tsokos, 2021, seq. 4.1). Se $f(x; \theta)$ é a distribuição comum, a densidade conjunta é

$$f_{\mathbf{X}}(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta).$$

Para dados observados $\mathbf{x}$, a mesma expressão, considerada como função de θ , define a verossimilhança (Casella; Berger, 2002, seq. 6.3; Cox, 2006, seq. 2.1):

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

A distribuição amostral é uma distribuição de uma estatística sob P_θ ; a verossimilhança, por sua vez, mantém os dados fixos e compara valores de θ . Esses objetos são relacionados, mas não devem ser identificados (Cox, 2006, seq. 1.3 e 2.1).

💡 Exemplo — Tempos de vida exponenciais

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\beta)$, na parametrização por escala,

$$f(x; \beta) = \frac{1}{\beta} e^{-x/\beta} I(x > 0),$$

então

$$f_{\mathbf{X}}(\mathbf{x}; \beta) = \beta^{-n} \exp\left(-\frac{1}{\beta} \sum_{i=1}^n x_i\right) \prod_{i=1}^n I(x_i > 0).$$

A probabilidade de que todas as unidades durem mais de dois anos é

$$P(X_1 > 2, \dots, X_n > 2) = \prod_{i=1}^n P(X_i > 2) = e^{-2n/\beta}.$$

3.3.2 Amostragem aleatória simples sem reposição

Considere a população finita $\mathcal{U} = \{c_1, \dots, c_N\}$. Uma amostra aleatória simples sem reposição de tamanho n seleciona, com a mesma probabilidade, cada subconjunto de n unidades. As observações possuem a mesma distribuição marginal, mas não são independentes (Cox, 2006, seq. 9.2; Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, seq. 7.3.1).

Defina

$$\mu_N = \frac{1}{N} \sum_{j=1}^N c_j \quad \text{e} \quad \sigma_N^2 = \frac{1}{N} \sum_{j=1}^N (c_j - \mu_N)^2.$$

Então

$$E(\bar{X}) = \mu_N$$

e

$$\text{Var}(\bar{X}) = \frac{\sigma_N^2}{n} \frac{N-n}{N-1}.$$

O fator

$$\frac{N-n}{N-1}$$

é a correção de população finita para a variância. Para o erro-padrão, a correção correspondente é sua raiz quadrada (Rice, 2007, seq. 7.3.1, pp. 203–210; Cox, 2006, seq. 9.2, pp. 179–181).

⚠ Observação — Duas convenções para a variância finita

Se a variância da população finita for definida por

$$S_N^2 = \frac{1}{N-1} \sum_{j=1}^N (c_j - \mu_N)^2,$$

então a mesma fórmula pode ser escrita como

$$\text{Var}(\bar{X}) = \left(1 - \frac{n}{N}\right) \frac{S_N^2}{n}.$$

As duas expressões são equivalentes; é necessário apenas manter a convenção utilizada para a variância populacional (Cox, 2006, seq. 9.2; Rice, 2007, seq. 7.3.1).

i Interpretação — Fração amostral

Quando n/N é pequeno, a correção de população finita é próxima de 1, e o erro-padrão fica próximo de $\sigma_N/\sqrt{n}$. Quando uma fração apreciável da população é observada, a amostragem sem reposição reduz a incerteza em relação à amostragem com reposição (Cox, 2006, seq. 9.2; Rice, 2007, seq. 7.3.1).

3.4 Construção de uma distribuição amostral por enumeração

Quando a população e o tamanho amostral são pequenos, a distribuição amostral pode ser obtida enumerando todas as amostras possíveis e calculando a estatística em cada uma delas (Ramachandran; Tsokos, 2021, seq. 4.1, pp. 148–151; Chihara; Hesterberg, 2022, seq. 4.2, pp. 82–85).

Exemplo — Média de uma população finita

Considere a população

$$\mathcal{U} = \{3,8; 3,9; 4,0; 4,1\}$$

em km/L e amostras ordenadas de tamanho $n = 2$, com reposição. Existem $4^2 = 16$ amostras equiprováveis. A distribuição de $\bar{X}$ é

$\bar{x}$	3,80	3,85	3,90	3,95	4,00	4,05	4,10
Probabilidade	1/16	2/16	3/16	4/16	3/16	2/16	1/16

A média e a variância populacionais são

$$\mu_N = 3,95 \quad \text{e} \quad \sigma_N^2 = 0,0125.$$

Consequentemente,

$$E(\bar{X}) = 3,95 \quad \text{e} \quad \text{Var}(\bar{X}) = \frac{0,0125}{2} = 0,00625.$$

Sem reposição, existem $\binom{4}{2} = 6$ subconjuntos equiprováveis, e

$$\text{Var}(\bar{X}) = \frac{0,0125}{2} \frac{4-2}{4-1} = 0,004166 \dots$$

Interpretação

A enumeração torna visível que a distribuição amostral é a distribuição dos valores de uma estatística sob repetição do plano amostral. Para populações grandes ou contínuas, a enumeração exata é inviável, sendo substituída por resultados analíticos, aproximações assintóticas ou simulação.

3.5 Somas, transformações e funções geradoras de momentos

Se

$$Y = \sum_{i=1}^n X_i, \quad \bar{X} = \frac{Y}{n},$$

então, no caso contínuo,

$$f_{\bar{X}}(x) = n f_Y(nx).$$

A obtenção de f_Y pode exigir convoluções. Quando as funções geradoras de momentos existem em uma vizinhança de zero, elas fornecem uma alternativa conveniente (Larsen; Marx, 2012, seq. 3.8 e 3.12; Kerns, 2010, seq. 5.4; Rice, 2007, seq. 4.5).

! Teorema — FGM da soma e da média

Se $X_1, \dots, X_n$ são independentes e possuem funções geradoras de momentos $M_{X_i}(t)$, então

$$M_{\sum X_i}(t) = \prod_{i=1}^n M_{X_i}(t).$$

Se, adicionalmente, são identicamente distribuídas com FGM $M_X(t)$, então

$$M_{\bar{X}}(t) = \left[M_X\left(\frac{t}{n}\right) \right]^n.$$

O resultado decorre da independência e da propriedade de transformação da FGM (Larsen; Marx, 2012, seq. 3.12; Rice, 2007, seq. 4.5).

💡 Exemplo — Média de variáveis normais

Se $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, então

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

Logo,

$$M_{\bar{X}}(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2n}\right),$$

e, portanto,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Essa dedução por FGM é apresentada em tratamentos clássicos de transformações e somas de variáveis aleatórias (Larsen; Marx, 2012, seq. 3.12; Rice, 2007, cap. 4 e 6).

💡 Exemplo — Média de variáveis gama

Adote a parametrização por forma α e escala β :

$$X_i \stackrel{\text{i.i.d.}}{\sim} \text{Gama}(\alpha, \beta), \quad M_X(t) = (1 - \beta t)^{-\alpha}.$$

Então

$$M_{\bar{X}}(t) = \left(1 - \frac{\beta}{n}t\right)^{-n\alpha},$$

de modo que

$$\bar{X} \sim \text{Gama}\left(n\alpha, \frac{\beta}{n}\right).$$

A conclusão usa a FGM da distribuição gama e a regra de escala (Larsen; Marx, 2012, seq. 3.12 e 4.6; Ramachandran; Tsokos, 2021, cap. 3–4).

3.6 Distribuição amostral da média

Se $X_1, \dots, X_n$ são i.i.d., $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$, então (Ramachandran; Tsokos, 2021, teorema 4.1.1, p. 148; Kerns, 2010, seq. 8.1–8.2)

$$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$$

e

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

O desvio-padrão da distribuição amostral é

$$\text{EP}(\bar{X}) = \frac{\sigma}{\sqrt{n}},$$

e recebe o nome de **erro-padrão** de $\bar{X}$.

! Resultado — Média amostral

Para uma amostra i.i.d. com média μ e variância finita σ^2 ,

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Se a população é normal, então, para todo $n \geq 1$,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Esses resultados são exatos no modelo normal e, para os dois primeiros momentos, válidos para qualquer população com variância finita (Ramachandran; Tsokos, 2021, teorema 4.1.1; Chihara; Hesterberg, 2022, apêndices A.5–A.6; Kerns, 2010, seq. 8.2).

i Interpretação — Efeito do tamanho amostral

O erro-padrão decresce à taxa $n^{-1/2}$. Para reduzir o erro-padrão pela metade, é necessário multiplicar o tamanho da amostra por quatro. O aumento de n reduz a variabilidade da média, mas não corrige viés de seleção, dependência não modelada ou erros sistemáticos de mensuração (Rice, 2007, seq. 7.3.1, pp. 206–207).

💡 Exemplo — Níveis de colesterol

Suponha que os níveis de colesterol sejam distribuídos como

$$X \sim N(210, 37^2) \text{ mg/dL}.$$

Para $n = 10$,

$$\bar{X} \sim N\left(210, \frac{37^2}{10}\right), \quad \text{EP}(\bar{X}) = \frac{37}{\sqrt{10}} \approx 11,70.$$

Os 95% centrais da distribuição individual estão aproximadamente em

$$210 \pm 1,96(37) = (137,48; 282,52),$$

enquanto os 95% centrais da distribuição de $\bar{X}$ estão em

$$210 \pm 1,96 \frac{37}{\sqrt{10}} \approx (187,07; 232,93).$$

A menor amplitude do segundo intervalo reflete a menor variabilidade das médias amostrais.

3.7 Lei dos Grandes Números

A Lei dos Grandes Números descreve a convergência da média amostral para a média populacional. Ela trata da **concentração** de $\bar{X}_n$ em torno de μ , e não da forma da distribuição dos erros (Rice, 2007, seq. 5.2, pp. 177–181).

! Teorema — Lei Fraca dos Grandes Números

Se $X_1, X_2, \dots$ são i.i.d., $E(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$, então, para todo $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0,$$

isto é,

$$\bar{X}_n \xrightarrow{p} \mu.$$

A desigualdade de Chebyshev fornece uma demonstração direta:

$$P(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

! Teorema — Lei Forte dos Grandes Números

Sob condições usuais, por exemplo quando $X_1, X_2, \dots$ são i.i.d. e $E(|X_1|) < \infty$,

$$\bar{X}_n \xrightarrow{q.c.} \mu,$$

ou seja, a convergência ocorre com probabilidade 1 (Rice, 2007, seq. 5.2).

💡 Exemplo — Frequência relativa

Se $X_i = I(A_i)$ indica a ocorrência de um evento com probabilidade p , então $X_i \sim \text{Bernoulli}(p)$ e

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n I(A_i)$$

é a frequência relativa do evento. Pela Lei dos Grandes Números,

$$\bar{X}_n \xrightarrow{p} p$$

e, sob independência, também $\bar{X}_n \xrightarrow{q.c.} p$.

3.8 Teorema Central do Limite

A Lei dos Grandes Números afirma que $\bar{X}_n$ se aproxima de μ . O Teorema Central do Limite descreve a escala e a forma aproximada das flutuações de $\bar{X}_n$ em torno de μ (Chihara; Hesterberg, 2022, seq. 4.3, pp. 85–93; Kerns, 2010, seq. 8.3; Rice, 2007, seq. 5.3).

! Teorema — Teorema Central do Limite de Lindeberg–Lévy

Se $X_1, X_2, \dots$ são i.i.d., com

$$E(X_i) = \mu \quad \text{e} \quad 0 < \sigma^2 = \text{Var}(X_i) < \infty,$$

então

$$Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

Assim, para n suficientemente grande,

$$\bar{X}_n \dot{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$$

e

$$\sum_{i=1}^n X_i \dot{\sim} N(n\mu, n\sigma^2).$$

! Observação — O que converge

A formulação rigorosa do TCL é a convergência da variável **padronizada** Z_n para $N(0, 1)$. Não se deve dizer, sem qualificação, que $\bar{X}_n$ converge para uma normal com variância σ^2/n , pois essa variância depende de n e tende a zero. De fato, pela Lei dos Grandes Números, $\bar{X}_n$ converge para a constante μ .

! Observação — Não existe uma regra universal $n \geq 30$

A qualidade da aproximação normal depende da assimetria, do peso das caudas, da existência de momentos, da natureza discreta ou contínua da população e da precisão desejada. Distribuições fortemente assimétricas ou com caudas pesadas podem exigir amostras muito maiores. O diagnóstico deve considerar o modelo e, quando possível, simulações ou limites de erro (Chihara; Hesterberg, 2022, seq. 4.3.3, p. 92).

3.8.1 Padronização com variância estimada

Como $S \xrightarrow{p} \sigma$ sob condições usuais, o teorema de Slutsky implica (Lauritzen, 2023, apêndice A.2.2)

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{d} N(0, 1).$$

 Observação — Resultado exato e resultado assintótico

Para amostras normais, a estatística acima possui exatamente distribuição t_{n-1} . Para populações não normais, sua distribuição é apenas assintoticamente normal; não é, em geral, exatamente t_{n-1} (Larsen; Marx, 2012, cap. 7; Rice, 2007, cap. 6).

3.9 Distribuição amostral da proporção

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, então (Chihara; Hesterberg, 2022, seq. 4.1 e 4.3.1; Ramachandran; Tsokos, 2021, seq. 4.5)

$$Y = \sum_{i=1}^n X_i \sim \text{Binomial}(n, p)$$

e

$$\hat{p} = \bar{X} = \frac{Y}{n}.$$

Portanto,

$$E(\hat{p}) = p$$

e

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

A distribuição exata de $\hat{p}$ é discreta:

$$P\left(\hat{p} = \frac{k}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

Pelo TCL,

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0, 1).$$

3.9.1 Aproximação normal da binomial

Se $Y \sim \text{Binomial}(n, p)$, então

$$Y \dot{\sim} N(np, np(1-p)).$$

Como a binomial é discreta e a normal é contínua, a **correção de continuidade** costuma melhorar a aproximação (Chihara; Hesterberg, 2022, seq. 4.3.1–4.3.2; Ramachandran; Tsokos, 2021, seq. 4.5). Por exemplo,

$$P(Y \leq k) \approx \Phi\left(\frac{k + 0,5 - np}{\sqrt{np(1-p)}}\right),$$

e

$$P(Y \geq k) \approx 1 - \Phi\left(\frac{k - 0,5 - np}{\sqrt{np(1-p)}}\right).$$

Interpretação — Condições práticas

Condições como $np \geq 5$ e $n(1-p) \geq 5$, ou versões mais conservadoras com limite 10, são apenas diagnósticos heurísticos. Elas não garantem uma precisão fixa para todos os valores de p e todos os tipos de probabilidade de cauda (Chihara; Hesterberg, 2022, seq. 4.3.3, p. 92).

Exemplo — Apoio a uma política pública

Suponha $p = 0,53$ e $n = 1000$. Se Y é o número de apoiadores na amostra, então

$$Y \sim \text{Binomial}(1000, 0,53),$$

com

$$E(Y) = 530, \quad \text{DP}(Y) = \sqrt{1000(0,53)(0,47)} \approx 15,78.$$

Usando correção de continuidade,

$$P(Y < 500) = P(Y \leq 499) \approx \Phi\left(\frac{499,5 - 530}{15,78}\right) \approx \Phi(-1,93) \approx 0,027.$$

3.10 Distribuição amostral da variância

Considere

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Se $X_1, \dots, X_n$ são i.i.d. e $\text{Var}(X_i) = \sigma^2 < \infty$, então

$$E(S^2) = \sigma^2.$$

Logo, S^2 é um estimador não viesado de σ^2 (Ramachandran; Tsokos, 2021, seq. 4.1; Rice, 2007, cap. 6).

3.10.1 Variância de S^2 em uma população geral

Se o quarto momento central

$$\mu_4 = E[(X - \mu)^4]$$

é finito, então

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right].$$

i Demonstração — Variância de S^2

Defina $Y_i = X_i - \mu$ e

$$A = \sum_{i=1}^n Y_i^2, \quad B = \frac{1}{n} \left(\sum_{i=1}^n Y_i \right)^2.$$

Como

$$Q = \sum_{i=1}^n (X_i - \bar{X})^2 = A - B = (n-1)S^2,$$

basta calcular $E(Q^2)$. Pela independência, por $E(Y_i) = 0$, $E(Y_i^2) = \sigma^2$ e $E(Y_i^4) = \mu_4$,

$$E(A^2) = n\mu_4 + n(n-1)\sigma^4,$$

$$E(AB) = \mu_4 + (n-1)\sigma^4$$

e

$$E(B^2) = \frac{\mu_4}{n} + \frac{3(n-1)}{n}\sigma^4.$$

Consequentemente,

$$E(Q^2) = \frac{(n-1)^2}{n}\mu_4 + \frac{(n-1)(n^2-2n+3)}{n}\sigma^4.$$

Dividindo por $(n-1)^2$, obtemos

$$E[(S^2)^2] = \frac{\mu_4}{n} + \frac{n^2-2n+3}{n(n-1)}\sigma^4.$$

Como $E(S^2) = \sigma^2$, segue que

$$\text{Var}(S^2) = E[(S^2)^2] - \sigma^4 = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1}\sigma^4 \right].$$

Portanto, a variância de S^2 depende do quarto momento da população. A fórmula

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

é válida especificamente para a população normal, pois nesse caso $\mu_4 = 3\sigma^4$.

3.11 Distribuições derivadas do modelo normal

As distribuições χ^2 , t e F surgem de transformações de variáveis normais e desempenham papel central na inferência exata para médias e variâncias (Larsen; Marx, 2012, cap. 7 e 9; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, cap. 6).

3.11.1 Distribuição qui-quadrado

! Definição — Distribuição χ^2

Se $Z_1, \dots, Z_\nu$ são independentes e $Z_j \sim N(0, 1)$, então

$$W = \sum_{j=1}^{\nu} Z_j^2 \sim \chi_\nu^2.$$

O parâmetro ν é o número de graus de liberdade (Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2).

Se $W \sim \chi_\nu^2$, então

$$E(W) = \nu, \quad \text{Var}(W) = 2\nu.$$

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, então

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi_n^2.$$

A decomposição

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2$$

separa a variabilidade residual da variabilidade da média. No modelo normal, os dois termos padronizados são independentes, resultando em

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Esse resultado e a independência usada em sua obtenção são específicos do modelo normal (Larsen; Marx, 2012, cap. 7; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2–6.3).

i Interpretação — Graus de liberdade

A soma $\sum (X_i - \bar{X})^2$ possui $n - 1$ graus de liberdade porque os n desvios satisfazem a restrição

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

3.11.2 Independência entre média e variância

! Teorema — Independência no modelo normal

Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, então

$$\bar{X} \perp\!\!\!\perp S^2.$$

A independência entre a média e a variância amostrais é um resultado característico da amostragem normal (Larsen; Marx, 2012, apêndice 7.A.2; Rice, 2007, seq. 6.3).

Além disso,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

e

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

! Observação — Caracterização da normalidade

A independência entre $\bar{X}$ e S^2 é uma propriedade especial da distribuição normal. Ela não vale, em geral, para outras populações.

3.11.3 Distribuição t de Student

! Definição — Distribuição t

Se

$$Z \sim N(0, 1), \quad W \sim \chi_{\nu}^2,$$

são independentes, então

$$T = \frac{Z}{\sqrt{W/\nu}} \sim t_{\nu}.$$

Essa construção define a distribuição t de Student (Larsen; Marx, 2012, seq. 7.2–7.3; Rice, 2007, seq. 6.2).

A densidade é

$$f_T(t) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi} \Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}, \quad -\infty < t < \infty.$$

A distribuição é simétrica em torno de zero e possui caudas mais pesadas que a normal padrão. Além disso,

$$E(T) = 0 \quad (\nu > 1)$$

e

$$\text{Var}(T) = \frac{\nu}{\nu-2} \quad (\nu > 2).$$

Quando $\nu \rightarrow \infty$,

$$t_\nu \xrightarrow{d} N(0, 1).$$

No modelo normal,

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

💡 Exemplo — Média normal com variância desconhecida

Para uma amostra normal de tamanho $n = 10$,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{10}} \sim t_9.$$

Como $P(-t_{0,975;9} \leq T \leq t_{0,975;9}) = 0,95$, a inversão dessa desigualdade produz o intervalo de confiança bilateral de 95% para μ :

$$\bar{X} \pm t_{0,975;9} \frac{S}{\sqrt{10}},$$

em que $t_{0,975;9} \approx 2,262$ (Larsen; Marx, 2012, seq. 7.4; Rice, 2007, cap. 6).

3.11.4 Distribuição F

! Definição — Distribuição F

Se $W_1 \sim \chi_{\nu_1}^2$ e $W_2 \sim \chi_{\nu_2}^2$ são independentes, então

$$F = \frac{W_1/\nu_1}{W_2/\nu_2} \sim F_{\nu_1, \nu_2}.$$

Essa razão de qui-quadrados independentes define a distribuição F (Larsen; Marx, 2012, seq. 9.3; Ramachandran; Tsokos, 2021, seq. 4.2; Rice, 2007, seq. 6.2).

Se $F \sim F_{\nu_1, \nu_2}$, então

$$E(F) = \frac{\nu_2}{\nu_2 - 2}, \quad \nu_2 > 2,$$

e

$$\text{Var}(F) = \frac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}, \quad \nu_2 > 4.$$

Se duas amostras normais são independentes,

$$X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} N(\mu_1, \sigma_1^2)$$

e

$$Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma_2^2),$$

então

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}.$$

Sob a hipótese $\sigma_1^2 = \sigma_2^2$,

$$\frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1}.$$

⚠ Observação — Sensibilidade à não normalidade

A distribuição F da razão de variâncias amostrais é exata sob normalidade. Procedimentos baseados nessa razão podem ser sensíveis a assimetria, caudas pesadas e valores extremos; a validade deve ser avaliada no contexto da aplicação.

i Relações úteis

Se $T \sim t_\nu$, então

$$T^2 \sim F_{1,\nu}.$$

Se $F \sim F_{\nu_1,\nu_2}$, então

$$\frac{1}{F} \sim F_{\nu_2,\nu_1}.$$

3.12 Estatísticas de ordem

Seja $X_1, \dots, X_n$ uma amostra i.i.d. de uma distribuição contínua com função de distribuição F e densidade f . A notação e os resultados desta seção seguem a formulação clássica de estatísticas de ordem (Larsen; Marx, 2012, seq. 3.10, pp. 193–200; Ramachandran; Tsokos, 2021, seq. 4.3). As observações ordenadas são denotadas por

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}.$$

As variáveis $X_{(1)}$ e $X_{(n)}$ são, respectivamente, o mínimo e o máximo amostrais.

3.12.1 Mínimo e máximo

Para o mínimo,

$$P(X_{(1)} > x) = P(X_1 > x, \dots, X_n > x) = [1 - F(x)]^n,$$

logo

$$F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n$$

e

$$f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1}f(x).$$

Para o máximo,

$$F_{X_{(n)}}(x) = P(X_1 \leq x, \dots, X_n \leq x) = [F(x)]^n$$

e

$$f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x).$$

3.12.2 k -ésima estatística de ordem

! Teorema — Densidade de $X_{(k)}$

Para $k = 1, \dots, n$,

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x).$$

A fórmula resulta da contagem das posições relativas das observações em torno de x (Larsen; Marx, 2012, teorema 3.10.2; Ramachandran; Tsokos, 2021, seq. 4.3).

💡 Exemplo — Amostra uniforme

Se $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$, então $F(x) = x$ e $f(x) = 1$ para $0 < x < 1$. Assim,

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k},$$

o que implica

$$X_{(k)} \sim \text{Beta}(k, n - k + 1).$$

Em particular,

$$E[X_{(k)}] = \frac{k}{n+1}.$$

O caso uniforme é uma aplicação direta da densidade geral e identifica uma distribuição beta (Hogg; Craig, 1978, seção sobre estatísticas de ordem; Larsen; Marx, 2012, seq. 3.10).

3.13 Distribuições amostrais por simulação

Quando a distribuição exata de uma estatística é difícil de obter, pode-se aproximá-la por Monte Carlo: simula-se um grande número de amostras do modelo, calcula-se a estatística em cada amostra e analisa-se a distribuição empírica resultante (Chihara; Hesterberg, 2022, seq. 4.2, pp. 82–85; Kerns, 2010, seq. 8.5).

! Procedimento — Simulação de Monte Carlo

1. Especifique o modelo populacional e o tamanho amostral n .
2. Gere uma amostra de tamanho n .
3. Calcule a estatística T .
4. Repita os passos 2 e 3 um grande número B de vezes.
5. Use os valores $T^{(1)}, \dots, T^{(B)}$ para aproximar probabilidades, quantis, esperança, variância e forma da distribuição amostral.

Exemplo computacional: manifestação do TCL

O código abaixo compara as distribuições de médias de amostras exponenciais para diferentes tamanhos amostrais.

```
set.seed(123)

B <- 20000
ns <- c(2, 10, 50)

par(mfrow = c(1, 3))

for (n in ns) {
  medias <- replicate(B, mean(rexp(n, rate = 1)))

  hist(
    medias,
    probability = TRUE,
    breaks = 40,
    main = paste("n =", n),
    xlab = expression(bar(X))
  )

  curva_x <- seq(min(medias), max(medias), length.out = 400)
  lines(curva_x, dnorm(curva_x, mean = 1, sd = 1 / sqrt(n)), lwd = 2)
```

```
}
```

```
par(mfrow = c(1, 1))
```




Figura 3.1: Distribuições simuladas da média de amostras exponenciais.

i Interpretação

A distribuição exponencial é assimétrica, mas a distribuição de $\bar{X}$ torna-se progressivamente mais próxima da normal conforme n aumenta. Ao mesmo tempo, sua dispersão diminui de acordo com $1/\sqrt{n}$.

Exemplo computacional: distribuição exata em população finita

```
populacao <- c(3.8, 3.9, 4.0, 4.1)

# Amostras ordenadas de tamanho 2, com reposição
amostras <- expand.grid(X1 = populacao, X2 = populacao)
amostras$media <- rowMeans(amostras)

prop.table(table(amostras$media))
```

3.8	3.85	3.9	3.95	4	4.05	4.1
0.0625	0.1250	0.1875	0.2500	0.1875	0.1250	0.0625

```
mean(amostras$media)
```

```
[1] 3.95
```

```
var_pop <- mean((populacao - mean(populacao))^2)
mean((amostras$media - mean(amostras$media))^2)
```

```
[1] 0.00625
```

```
var_pop / 2
```

```
[1] 0.00625
```

3.14 Quadro-síntese

Situação	Estatística	Distribuição ou aproximação
Amostra i.i.d., $E(X) = \mu$, $\text{Var}(X) = \sigma^2$	$\bar{X}$	$E(\bar{X}) = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$
População normal	$\bar{X}$	$N(\mu, \sigma^2/n)$, exatamente
População geral, variância finita	$\sqrt{n}(\bar{X} - \mu)/\sigma$	$N(0, 1)$, assintoticamente
Bernoulli	$Y = \sum X_i$	Binomial(n, p)
Bernoulli	$\hat{p} = Y/n$	$E(\hat{p}) = p$, $\text{Var}(\hat{p}) = p(1-p)/n$
População normal	$(n-1)S^2/\sigma^2$	χ_{n-1}^2
População normal	$(\bar{X} - \mu)/(S/\sqrt{n})$	t_{n-1}
Duas populações normais independentes	$(S_1^2/\sigma_1^2)/(S_2^2/\sigma_2^2)$	F_{n_1-1, n_2-1}
População contínua	$X_{(k)}$	densidade de estatística de ordem
População finita sem reposição	$\bar{X}$	variância com correção de população finita

3.15 Exercícios

Exercícios conceituais

1. **População e distribuição amostral.** Explique a diferença entre a distribuição de X e a distribuição de $\bar{X}$. Em que situação as duas distribuições pertencem à mesma família normal?
2. **Estatística ou parâmetro.** Classifique cada quantidade como parâmetro ou estatística: μ , σ^2 , $\bar{X}$, S^2 , p , $\hat{p}$ e $X_{(n)}$.
3. **Dois referenciais.** Explique por que as observações de uma amostra aleatória simples sem reposição de uma população finita não são independentes. Mostre que elas possuem a mesma distribuição marginal.
4. **Lei dos Grandes Números e TCL.** Compare as conclusões dos dois teoremas. Qual deles descreve concentração? Qual descreve a distribuição padronizada do erro?
5. **Normalidade.** Identifique quais resultados deste capítulo são exatos somente sob normalidade e quais permanecem válidos para uma população geral com momentos finitos.

Exercícios de cálculo

6. **População finita.** Considere a população $\{1, 3, 6, 10\}$ e amostras de tamanho 2.
 - a. Obtenha a distribuição de $\bar{X}$ com reposição.
 - b. Calcule $E(\bar{X})$ e $\text{Var}(\bar{X})$.
 - c. Repita sem reposição e verifique a correção de população finita.
7. **Média exponencial.** Seja $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\beta)$ na parametrização por escala.
 - a. Obtenha a distribuição de $\sum X_i$.
 - b. Obtenha a distribuição de $\bar{X}$.
 - c. Calcule $P(\bar{X} > c)$ em termos da função de distribuição gama.
8. **Média normal.** Uma variável tem distribuição $N(50, 12^2)$. Para uma amostra de tamanho 36:
 - a. determine a distribuição de $\bar{X}$;
 - b. calcule $P(48 < \bar{X} < 53)$;
 - c. encontre c tal que $P(|\bar{X} - 50| < c) = 0,95$.

9. **TCL para uma população não normal.** Seja $X_i \sim \text{Exp}(1)$ e $n = 64$. Use o TCL para aproximar $P(0,8 < \bar{X} < 1,2)$.
10. **Proporção.** Em uma população, $p = 0,12$. Para $n = 200$:
- determine $E(\hat{p})$ e $\text{EP}(\hat{p})$;
 - aproxime $P(\hat{p} \leq 0,09)$;
 - compare a aproximação com a probabilidade binomial exata no R.
11. **Correção de continuidade.** Seja $Y \sim \text{Binomial}(150, 0,5)$. Calcule aproximadamente:
- $P(Y \geq 90)$;
 - $P(65 \leq Y \leq 85)$;
 - compare os resultados com `pbinom()`.
12. **Variância amostral normal.** Se $X_1, \dots, X_{20} \sim N(\mu, 4)$, calcule:
- $P(S^2 > 6)$;
 - os quantis a e b tais que $P(a < S^2 < b) = 0,95$ com caudas iguais.
13. **Distribuição t .** Se uma amostra normal possui $n = 16$, determine c tal que

$$P\left(\left|\frac{\bar{X} - \mu}{S/4}\right| < c\right) = 0,95.$$

14. **Razão de variâncias.** Duas amostras normais independentes possuem tamanhos $n_1 = 12$ e $n_2 = 18$.
- determine a distribuição de $(S_1^2/\sigma_1^2)/(S_2^2/\sigma_2^2)$;
 - sob $\sigma_1^2 = \sigma_2^2$, calcule $P(S_1^2/S_2^2 > 2)$.
15. **Estatísticas de ordem.** Seja $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$.
- obtenha a função de distribuição de $X_{(n)}$;
 - obtenha sua densidade;
 - calcule $E[X_{(n)}]$;
 - proponha uma transformação de $X_{(n)}$ que seja não viesada para θ .
16. **Mínimo exponencial.** Se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ na parametrização por taxa, mostre que

$$X_{(1)} \sim \text{Exp}(n\lambda).$$

Exercícios teóricos e computacionais

17. **Variância de S^2 .** Usando a fórmula geral demonstrada neste capítulo,

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right],$$

verifique que, para uma população normal, $\text{Var}(S^2) = 2\sigma^4/(n-1)$.

18. **Simulação do TCL.** Repita a simulação deste capítulo para populações uniforme, Bernoulli, lognormal e Cauchy.
- Compare $n = 5, 30$ e 200 .
 - Explique por que o comportamento da média da distribuição de Cauchy é qualitativamente diferente.
 - Relacione o resultado às hipóteses do TCL.
19. **Aproximação Monte Carlo.** Para $X_i \sim \text{Beta}(2, 5)$ e $n = 15$, estime por simulação a distribuição de

$$T = \frac{\bar{X} - E(X)}{S/\sqrt{n}}.$$

Compare o histograma com as densidades $N(0, 1)$ e t_{14} .

20. **Demonstração por FGM.** Demonstre que, se $X_i \sim N(\mu, \sigma^2)$ são independentes, então $\bar{X} \sim N(\mu, \sigma^2/n)$.
21. **Demonstração da Lei Fraca.** Use a desigualdade de Chebyshev para demonstrar a Lei Fraca dos Grandes Números sob variância finita.
22. **Distribuição da estatística de ordem.** Demonstre a fórmula da densidade de $X_{(k)}$ contando as maneiras de obter $k-1$ observações abaixo de x , uma observação em $(x, x+dx)$ e $n-k$ observações acima de $x+dx$.

Referências

4 Avaliação de Estimadores e Princípios de Redução de Dados

Considere um modelo estatístico parametrizado $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, uma amostra aleatória $\mathbf{X} = (X_1, \dots, X_n)$ e uma função paramétrica de interesse $\tau(\theta)$. Um **estimador** de $\tau(\theta)$ é uma estatística $\delta = \delta(\mathbf{X})$; após a observação de $\mathbf{X} = \mathbf{x}$, o número $\delta(\mathbf{x})$ é denominado **estimativa**.

A avaliação de um estimador exige distinguir propriedades de amostra finita, como viés e erro quadrático médio, de propriedades assintóticas, como consistência e eficiência assintótica. Paralelamente, os princípios de redução de dados procuram substituir a amostra completa por estatísticas que preservem a informação relevante sobre o parâmetro. Essa redução fundamenta resultados centrais, como os teoremas de Rao–Blackwell e de Lehmann–Scheffé (Rice, 2007, chap. 8; Lauritzen, 2023, chaps. 4–5; Cox, 2006, secs. 2.2 and 4.3).

4.1 Avaliação de estimadores

Função de perda, risco e erro quadrático médio

A comparação entre estimadores depende do critério adotado. Uma forma geral de formalizar esse critério consiste em especificar uma **função de perda** $L(\tau(\theta), a)$, que quantifica a consequência de utilizar a ação a quando o valor verdadeiro é $\tau(\theta)$. O risco do estimador δ é

$$R(\theta, \delta) = E_\theta [L(\tau(\theta), \delta(\mathbf{X}))].$$

Essa formulação pertence ao quadro da teoria da decisão estatística (Rasch; Schott, 2018, secs. 1.5 and 2.4; Bickel; Doksum, 2016, chap. 1).

Sob perda quadrática,

$$L(\tau(\theta), a) = (a - \tau(\theta))^2,$$

o risco coincide com o **erro quadrático médio** (EQM):

$$\text{EQM}_\theta(\delta) = E_\theta \left[(\delta - \tau(\theta))^2 \right].$$

i Interpretação

O EQM avalia simultaneamente a dispersão do estimador e seu afastamento sistemático do alvo. Portanto, ele permite comparar estimadores viesados e não viesados por meio de uma única medida de desempenho.

O uso da perda quadrática é particularmente conveniente devido à sua tratabilidade analítica, mas não é universalmente adequado. Em problemas nos quais erros de sinais ou magnitudes diferentes têm consequências assimétricas, outras funções de perda podem ser mais apropriadas (Rasch; Schott, 2018, secs. 1.5 and 2.4; Lauritzen, 2023, sec. 4.1).

Viés, variância e erro-padrão

! Definição — Viés

O **viés** de δ como estimador de $\tau(\theta)$ é

$$B_\theta(\delta) = E_\theta(\delta) - \tau(\theta).$$

O estimador é **não viesado** quando

$$E_\theta(\delta) = \tau(\theta)$$

para todo $\theta \in \Theta$.

Um viés positivo significa que o estimador **superestima o parâmetro em média**; um viés negativo significa que o estimador **subestima o parâmetro em média**. Essa afirmação não descreve necessariamente o comportamento de uma realização particular da amostra.

A variância e o erro-padrão do estimador são

$$\text{Var}_\theta(\delta) = E_\theta \left[(\delta - E_\theta(\delta))^2 \right]$$

e

$$\text{EP}_\theta(\delta) = \sqrt{\text{Var}_\theta(\delta)}.$$

O erro-padrão mede a variabilidade da distribuição amostral de δ . Ele não deve ser confundido com o desvio-padrão da variável observada.

! Decomposição viés–variância

Para qualquer estimador com segundo momento finito,

$$\text{EQM}_\theta(\delta) = \text{Var}_\theta(\delta) + B_\theta(\delta)^2.$$

Demonstração. Somando e subtraindo $E_\theta(\delta)$,

$$\delta - \tau(\theta) = [\delta - E_\theta(\delta)] + [E_\theta(\delta) - \tau(\theta)].$$

Ao elevar ao quadrado e tomar esperança, o termo cruzado é nulo, pois

$$E_\theta[\delta - E_\theta(\delta)] = 0.$$

Logo, obtém-se a decomposição anterior.

⚠ Observação — Compromisso entre viés e variância

Não existe uma lei geral segundo a qual a redução do viés sempre aumente a variância, ou vice-versa. O chamado compromisso viés–variância descreve situações frequentes de construção de estimadores, nas quais aceitar um pequeno viés pode reduzir suficientemente a variância e, conseqüentemente, o EQM. A comparação correta deve ser realizada por meio do risco ou do EQM, e não apenas pelo viés.

As definições de viés, variância e EQM, bem como a decomposição viés–variância, seguem as formulações de Lauritzen (2023, sec. 4.1), Rice (2007, sec. 8.3) e Rasch; Schott (2018, sec. 2.4).

Exemplo adaptado — Estimação do limite de uma distribuição uniforme

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta), \quad \theta > 0,$$

e os estimadores

$$\delta_1 = 2\bar{X}, \quad \delta_2 = X_{(n)} = \max(X_1, \dots, X_n), \quad \delta_3 = \frac{n+1}{n}X_{(n)}.$$

Para δ_1 ,

$$E_{\theta}(\delta_1) = \theta$$

e

$$\text{Var}_{\theta}(\delta_1) = \frac{\theta^2}{3n}.$$

Portanto,

$$\text{EQM}_{\theta}(\delta_1) = \frac{\theta^2}{3n}.$$

A função de distribuição de $X_{(n)}$ é

$$P_{\theta}(X_{(n)} \leq x) = \left(\frac{x}{\theta}\right)^n, \quad 0 \leq x \leq \theta.$$

Consequentemente,

$$E_{\theta}(X_{(n)}) = \frac{n}{n+1}\theta$$

e

$$\text{Var}_{\theta}(X_{(n)}) = \frac{n\theta^2}{(n+1)^2(n+2)}.$$

Assim,

$$B_{\theta}(\delta_2) = -\frac{\theta}{n+1}$$

e

$$\text{EQM}_{\theta}(\delta_2) = \frac{2\theta^2}{(n+1)(n+2)}.$$

O estimador corrigido δ_3 é não viesado e possui

$$\text{Var}_{\theta}(\delta_3) = \frac{\theta^2}{n(n+2)}.$$

Para $n > 1$,

$$\frac{\theta^2}{n(n+2)} < \frac{\theta^2}{3n},$$

mostrando que δ_3 tem menor EQM do que δ_1 . Além disso, δ_2 , embora viesado, possui EQM de ordem n^{-2} , enquanto o EQM de δ_1 é de ordem n^{-1} . O exemplo mostra por que não se deve selecionar estimadores exclusivamente pelo não viés. A construção e a comparação dos estimadores foram adaptadas de Lauritzen (2023, ex. 4.2); a interpretação em termos de não viés, eficiência e EQM também é discutida por Chihara; Hesterberg (2022, secs. 6.3.1–6.3.3).

Consistência

! Definição — Consistência em probabilidade

Uma sequência de estimadores $\{\delta_n\}$ é **consistente em probabilidade** para $\tau(\theta)$ se, para todo $\varepsilon > 0$ e todo $\theta \in \Theta$,

$$P_\theta (|\delta_n - \tau(\theta)| > \varepsilon) \rightarrow 0$$

quando $n \rightarrow \infty$. Escreve-se

$$\delta_n \xrightarrow{p} \tau(\theta).$$

A consistência é uma propriedade assintótica: ela afirma que, à medida que o tamanho amostral cresce, o estimador se concentra arbitrariamente perto do valor verdadeiro. Ela não implica que o estimador seja não viesado para cada tamanho amostral finito.

! Definição — Consistência em erro quadrático médio

A sequência $\{\delta_n\}$ é **consistente em erro quadrático médio** para $\tau(\theta)$ se

$$\text{EQM}_\theta(\delta_n) \rightarrow 0.$$

A consistência em EQM implica consistência em probabilidade. De fato, pela desigualdade de Markov,

$$P_\theta (|\delta_n - \tau(\theta)| > \varepsilon) \leq \frac{\text{EQM}_\theta(\delta_n)}{\varepsilon^2}.$$

! Critério suficiente para consistência

Se

$$B_{\theta}(\delta_n) \rightarrow 0$$

e

$$\text{Var}_{\theta}(\delta_n) \rightarrow 0,$$

então

$$\text{EQM}_{\theta}(\delta_n) \rightarrow 0,$$

portanto δ_n é consistente em probabilidade (Rice, 2007, sec. 8.5; Lauritzen, 2023, sec. 5.1).

A hipótese de não viés para todo n é suficiente, mas não necessária: basta que o viés tenda a zero.

Comparação no modelo uniforme

No modelo $\text{Unif}(0, \theta)$:

1. $2\bar{X}$ é não viesado e consistente, pois $\bar{X} \xrightarrow{p} \theta/2$ pela lei dos grandes números;
2. $2X_1$ é não viesado, mas não é consistente, pois sua distribuição não se concentra com o crescimento de n ;
3. $X_{(n)}$ é viesado, mas consistente, pois, para $0 < \varepsilon < \theta$,

$$P_{\theta}(|X_{(n)} - \theta| > \varepsilon) = P_{\theta}(X_{(n)} < \theta - \varepsilon) = \left(1 - \frac{\varepsilon}{\theta}\right)^n \rightarrow 0;$$

4. $X_1/2$ é viesado e não consistente.

i Interpretação

Não viés é uma propriedade da esperança da distribuição amostral para um tamanho amostral fixado. Consistência é uma propriedade de uma sequência de estimadores quando n cresce. Nenhuma das duas propriedades implica, em geral, a outra.

A distinção entre não viés e consistência, assim como os critérios anteriores, é apresentada por Larsen; Marx (2012, sec. 5.7), Rice (2007, sec. 8.5) e Lauritzen (2023, sec. 5.1).

Resultados operacionais para convergência em probabilidade

Se

$$A_n \xrightarrow{p} a \quad \text{e} \quad B_n \xrightarrow{p} b,$$

então:

$$A_n + B_n \xrightarrow{p} a + b,$$

$$A_n B_n \xrightarrow{p} ab,$$

e, se $b \neq 0$,

$$\frac{A_n}{B_n} \xrightarrow{p} \frac{a}{b}.$$

Além disso, se g é contínua em a , o teorema da aplicação contínua garante

$$g(A_n) \xrightarrow{p} g(a).$$

Esses resultados permitem estabelecer a consistência de estimadores construídos por transformações, somas, produtos e quocientes de estatísticas consistentes. Eles são consequências do teorema da aplicação contínua e das propriedades elementares da convergência em probabilidade (Lauritzen, 2023, app. A.2).

Eficiência em amostras finitas

A variância permite comparar estimadores não viesados de um mesmo alvo. Um estimador não viesado δ^* de $\tau(\theta)$ é denominado **estimador não viesado de variância uniformemente mínima** (ENVUM; em inglês, UMVU) quando

$$\text{Var}_\theta(\delta^*) \leq \text{Var}_\theta(\delta)$$

para todo $\theta \in \Theta$ e para todo estimador não viesado δ de $\tau(\theta)$ (Bickel; Doksum, 2016, sec. 8.2.3; Rasch; Schott, 2018, sec. 2.4).

Para dois estimadores não viesados, define-se, neste texto, a eficiência relativa de δ_1 em relação a δ_2 por

$$e_{\theta}(\delta_1; \delta_2) = \frac{\text{Var}_{\theta}(\delta_2)}{\text{Var}_{\theta}(\delta_1)}.$$

Valores maiores do que 1 indicam que δ_1 possui menor variância. Como existem convenções inversas na literatura, a orientação do quociente deve sempre ser explicitada (Rasch; Schott, 2018, sec. 2.4.1).

Informação de Fisher

Considere um modelo dominado com densidade ou função de probabilidade $f_{\theta}(x)$. A função escore de uma observação é

$$U_{\theta}(X) = \frac{\partial}{\partial \theta} \log f_{\theta}(X).$$

Sob condições de regularidade,

$$E_{\theta}[U_{\theta}(X)] = 0.$$

Definição: informação de Fisher

A informação de Fisher de uma observação é

$$I_1(\theta) = E_{\theta}[U_{\theta}(X)^2].$$

Quando é permitido intercambiar diferenciação e integração,

$$I_1(\theta) = -E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f_{\theta}(X) \right].$$

Para uma amostra i.i.d. de tamanho n ,

$$I_n(\theta) = nI_1(\theta).$$

Essas identidades pressupõem as condições de regularidade indicadas acima (Lauritzen, 2023, sec. 1.2.2; Rasch; Schott, 2018, sec. 1.4).

A informação de Fisher quantifica a curvatura média da log-verossimilhança e a capacidade do modelo de distinguir valores próximos do parâmetro. Uma informação maior está associada a limites inferiores menores para a variância de estimadores regulares (Cox, 2006, sec. 2.1; Lauritzen, 2023, sec. 1.2.2).

Desigualdade de Cramér–Rao

A forma clássica da desigualdade de Cramér–Rao utilizada nesta seção exige condições de regularidade. Um conjunto suficiente de condições usuais inclui:

- o suporte da distribuição é comum a todos os valores de θ ;
- $f_\theta(x)$ é diferenciável em θ ;
- a derivação pode ser intercambiada com a integração ou soma;
- $0 < I_n(\theta) < \infty$.

! Teorema — Desigualdade de Cramér–Rao

Se δ possui esperança

$$E_\theta(\delta) = g(\theta),$$

então, sob as condições de regularidade,

$$\text{Var}_\theta(\delta) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Em particular, se δ é não viesado para $\tau(\theta)$,

$$\text{Var}_\theta(\delta) \geq \frac{[\tau'(\theta)]^2}{I_n(\theta)}.$$

Para $\tau(\theta) = \theta$,

$$\text{Var}_\theta(\delta) \geq \frac{1}{I_n(\theta)}.$$

Um estimador não viesado que atinge o limite de Cramér–Rao para todo θ é denominado **eficiente no sentido de Cramér–Rao**. Sua eficiência é

$$\text{ef}_\theta(\delta) = \frac{[\tau'(\theta)]^2}{I_n(\theta) \text{Var}_\theta(\delta)} \leq 1.$$

! Observações

1. O limite não garante a existência de um estimador que o atinja.
2. Um ENVUM pode não atingir o limite de Cramér–Rao.
3. O resultado, em sua forma anterior, não deve ser aplicado a modelos cujo suporte depende do parâmetro. Em particular, o modelo $\text{Unif}(0, \theta)$ não satisfaz a condição

de suporte comum.

4. Para um estimador viesado, com $E_\theta(\delta) = g(\theta)$ e viés $b(\theta) = g(\theta) - \tau(\theta)$, a desigualdade limita a variância por $[g'(\theta)]^2/I_n(\theta)$; consequentemente, o EQM satisfaz $\text{EQM}_\theta(\delta) \geq [g'(\theta)]^2/I_n(\theta) + b(\theta)^2$. Não é correto aplicar automaticamente $1/I_n(\theta)$ ao EQM.

A formulação geral, a demonstração e as condições do resultado podem ser encontradas em Lauritzen (2023, thm. 4.4), Rice (2007, sec. 8.7) e Rasch; Schott (2018, secs. 1.4 and 2.4.1).

Exemplo — Média de uma distribuição normal com variância conhecida

Considere

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

com σ^2 conhecida. Para uma observação,

$$U_\mu(X) = \frac{X - \mu}{\sigma^2}$$

e

$$I_1(\mu) = E_\mu \left[\left(\frac{X - \mu}{\sigma^2} \right)^2 \right] = \frac{1}{\sigma^2}.$$

Portanto,

$$I_n(\mu) = \frac{n}{\sigma^2}$$

e

$$\frac{1}{I_n(\mu)} = \frac{\sigma^2}{n}.$$

Como

$$E_\mu(\bar{X}) = \mu$$

e

$$\text{Var}_{\mu}(\bar{X}) = \frac{\sigma^2}{n},$$

$\bar{X}$ é eficiente para μ .

Exemplo — Parâmetro de uma distribuição de Poisson

Considere $n \geq 1$ e

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\theta).$$

A função escore de uma observação é

$$U_{\theta}(X) = \frac{X}{\theta} - 1,$$

portanto

$$I_1(\theta) = \frac{1}{\theta}.$$

Logo,

$$\frac{1}{I_n(\theta)} = \frac{\theta}{n}.$$

Como $\bar{X}$ é não viesado e

$$\text{Var}_{\theta}(\bar{X}) = \frac{\theta}{n},$$

a média amostral é eficiente para θ (Rice, 2007, sec. 8.7; Lauritzen, 2023, thm. 4.4).

Eficiência assintótica

A eficiência de Cramér–Rao descrita anteriormente é uma propriedade de amostra finita. Uma noção distinta é a **eficiência assintótica**. Se

$$\sqrt{n}(\delta_n - \theta) \xrightarrow{d} N(0, V(\theta)),$$

então, em modelos regulares, a variância assintótica é comparada com $I_1(\theta)^{-1}$. O estimador é assintoticamente eficiente quando

$$V(\theta) = I_1(\theta)^{-1}.$$

Sob condições regulares, estimadores de máxima verossimilhança frequentemente possuem essa propriedade. Essa afirmação não se estende automaticamente a modelos irregulares, a parâmetros na fronteira do espaço paramétrico ou a situações nas quais a taxa de convergência difere de $\sqrt{n}$ (Lauritzen, 2023, thm. 5.11).

4.2 Princípios de redução de dados

A amostra completa pode conter componentes irrelevantes para a inferência sobre θ . Um princípio de redução procura substituir $\mathbf{X}$ por uma estatística de menor dimensão sem eliminar informação pertinente ao parâmetro. Suficiência, suficiência mínima, completude e ancilaridade desempenham papéis distintos nesse processo (Cox, 2006, secs. 2.2 and 4.3.1; Casella; Berger, 2002, chap. 6).

Estatística suficiente

! Definição — Suficiência

Uma estatística $T = T(\mathbf{X})$ é **suficiente** para θ se a distribuição condicional de $\mathbf{X}$ dado $T = t$ não depende de θ (Cox, 2006, sec. 2.2; Rice, 2007, sec. 8.8).

A definição significa que, depois de conhecido T , a distribuição da parte restante dos dados não contém informação adicional sobre θ . Em termos inferenciais, procedimentos que dependem da amostra apenas por meio de T não perdem informação sobre o parâmetro dentro do modelo considerado (Cox, 2006, sec. 2.2; Rice, 2007, sec. 8.8).

⚠ Observação

Suficiência é uma propriedade relativa ao modelo. Uma estatística pode ser suficiente em um modelo e deixar de sê-lo quando novos parâmetros desconhecidos são introduzidos ou quando o modelo é ampliado.

Teorema da fatoração de Neyman–Fisher

! Teorema — Fatoração de Neyman–Fisher

Considere uma família dominada por uma medida comum, com densidade ou função de probabilidade conjunta $f_\theta(\mathbf{x})$. A estatística $T(\mathbf{X})$ é suficiente para θ se, e somente se, existem funções não negativas g_θ e h tais que

$$f_\theta(\mathbf{x}) = g_\theta(T(\mathbf{x}))h(\mathbf{x}),$$

em que h não depende de θ .

A dependência da verossimilhança em θ ocorre, portanto, apenas por meio de $T(\mathbf{x})$. O teorema é o método mais utilizado para identificar estatísticas suficientes (Rice, 2007, sec. 8.8.1; Ramachandran; Tsokos, 2021, sec. 5.3.2; Casella; Berger, 2002, sec. 6.2.1).

Exemplo — Amostra Bernoulli

Se

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p),$$

então

$$f_p(\mathbf{x}) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_i x_i} (1-p)^{n-\sum_i x_i}.$$

Logo,

$$T = \sum_{i=1}^n X_i$$

é suficiente para p .

A definição condicional produz a mesma conclusão. Dado $T = t$, todas as sequências binárias contendo exatamente t sucessos são equiprováveis, de modo que

$$P_p(\mathbf{X} = \mathbf{x} \mid T = t) = \frac{1}{\binom{n}{t}},$$

sempre que $\sum_i x_i = t$. Essa probabilidade não depende de p .

Suficiência mínima

Uma estatística suficiente pode conter redundâncias. Por exemplo, se T é suficiente, então (T, W) também é suficiente para qualquer estatística W , embora possa carregar informação desnecessária.

! Definição — Estatística minimal suficiente

Uma estatística T é **minimal suficiente** se é suficiente e, para toda estatística suficiente S , existe uma função mensurável r tal que

$$T = r(S)$$

quase certamente, para todo θ .

Assim, toda estatística suficiente determina a estatística minimal suficiente. A minimalidade refere-se à informação contida na estatística, e não apenas à sua dimensão numérica.

! Critério da razão de verossimilhanças

Considere uma família dominada com densidades f_θ . Para pontos $\mathbf{x}$ e $\mathbf{y}$ do espaço amostral efetivo — isto é, tais que $f_\theta(\mathbf{x}) + f_\theta(\mathbf{y}) > 0$ para algum θ —, uma estatística T é minimal suficiente quando existe uma constante $c(\mathbf{x}, \mathbf{y}) > 0$, independente de θ , tal que

$$f_\theta(\mathbf{x}) = c(\mathbf{x}, \mathbf{y}) f_\theta(\mathbf{y}) \quad \text{para todo } \theta$$

se, e somente se,

$$T(\mathbf{x}) = T(\mathbf{y}).$$

Quando o quociente $f_\theta(\mathbf{x})/f_\theta(\mathbf{y})$ está bem definido, essa condição equivale a exigir que o quociente seja independente de θ exatamente quando $T(\mathbf{x}) = T(\mathbf{y})$ (Casella; Berger, 2002, sec. 6.2.2; Ramachandran; Tsokos, 2009, sec. 5.5.3).

No modelo Bernoulli, a razão das verossimilhanças é independente de p exatamente quando

$$\sum_{i=1}^n x_i = \sum_{i=1}^n y_i.$$

Portanto, $\sum_i X_i$ é minimal suficiente. No modelo $\text{Unif}(0, \theta)$, a verossimilhança pode ser escrita como

$$L(\theta; \mathbf{x}) = \theta^{-n} I\{x_{(1)} \geq 0\} I\{x_{(n)} \leq \theta\}.$$

O primeiro indicador não depende de θ . Pelo teorema da fatoração, $X_{(n)}$ é suficiente; pelo critério da razão de verossimilhanças, é também minimal suficiente para θ (Ramachandran; Tsokos, 2009, sec. 5.5.3; Casella; Berger, 2002, sec. 6.2.2).

Famílias exponenciais

! Definição — Forma exponencial canônica

Uma família de distribuições possui forma exponencial k -paramétrica quando sua densidade ou função de probabilidade pode ser escrita como

$$f_{\eta}(x) = h(x) \exp \{ \eta^{\top} t(x) - A(\eta) \},$$

em que $\eta \in \mathcal{H} \subseteq \mathbb{R}^k$ é o parâmetro natural, $t(x)$ é a estatística canônica e o suporte não depende de η .

Para uma amostra i.i.d.,

$$f_{\eta}(\mathbf{x}) = \left[\prod_{i=1}^n h(x_i) \right] \exp \left\{ \eta^{\top} \sum_{i=1}^n t(x_i) - nA(\eta) \right\}.$$

Pelo teorema da fatoração,

$$T(\mathbf{X}) = \sum_{i=1}^n t(X_i)$$

é suficiente para η .

i Exemplos

- Bernoulli: $t(x) = x$ e $T = \sum_i X_i$;
- Poisson: $t(x) = x$ e $T = \sum_i X_i$;

- normal com média e variância desconhecidas: $t(x) = (x, x^2)^\top$ e

$$T(\mathbf{X}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right).$$

A família uniforme $\text{Unif}(0, \theta)$ não possui essa forma regular, pois seu suporte depende de θ . Ainda assim, ela possui uma estatística suficiente de dimensão um, $X_{(n)}$.

A apresentação de famílias exponenciais e de suas estatísticas canônicas segue Lauritzen (2023, chap. 3) e Ramachandran; Tsokos (2021, sec. 5.3.2).

Completude

! Definição — Completude

Uma estatística T é **completa** para $\{P_\theta : \theta \in \Theta\}$ se, para toda função mensurável a tal que $E_\theta[a(T)] < \infty$,

$$E_\theta[a(T)] = 0 \quad \text{para todo } \theta \in \Theta$$

implica

$$P_\theta(a(T) = 0) = 1 \quad \text{para todo } \theta \in \Theta.$$

Essa é a definição usual de completude para a família de distribuições induzida por T (Bickel; Doksum, 2016, def. 8.2.2; Casella; Berger, 2002, sec. 6.2.4).

A completude impede a existência de duas funções distintas de T que sejam não viesadas para o mesmo alvo. Ela é, portanto, uma propriedade de unicidade, e não uma medida de quantidade de informação.

! Teorema — Completude em famílias exponenciais

Em uma família exponencial natural de posto completo, se o espaço do parâmetro natural contém um conjunto aberto de $\mathbb{R}^k$, a estatística canônica é completa, sob as condições usuais de integrabilidade (Bickel; Doksum, 2016, thm. 8.2.2).

Essa conclusão não deve ser estendida automaticamente a famílias exponenciais curvas, nas quais o parâmetro natural está restrito a uma subvariedade de dimensão menor. Nessas famílias, a estatística suficiente pode não ser completa (Bickel; Doksum, 2016, sec. 8.2; Lauritzen, 2023, sec. 3.6).